

从零到高阶的概率论与数理统计教程（深度学习应用版）

目录

从零到高阶的概率论与数理统计教程（深度学习应用版）	16
项目简介	16
目标受众	16
章节导航目录	16
学习路径建议	19
前置要求	20
如何使用本教程	20
教程特色	20
许可证	21
改造升级（2026-05-14）	21
配套教程	22
前言：如何使用本教程	22
为什么学习概率论与数理统计	22
本教程的结构	23
每章的结构	24
符号约定	24
学习建议	24
配套资源	25
致谢	25
关于“模板 D 思维训练”（2026-05-14 改造后新增）	25
第一章：随机事件与概率	26
学习目标	26
正文内容	27
本章小结	32
深度学习应用：随机种子与可重复性	33
练习题	37
练习答案	38
几何示意	40
思考路标（条件反射）	42

易错点	42
第 2 章：条件概率与独立性	42
引入题	42
思维路径还原	42
学习目标	43
2.1 条件概率的定义	43
2.2 乘法公式	45
2.3 全概率公式	46
2.4 贝叶斯公式	47
2.5 事件的独立性	48
本章小结	49
深度学习应用：贝叶斯神经网络与先验后验	50
练习题	55
练习答案	56
几何示意	60
思考路标（条件反射）	61
易错点	61
第 3 章：组合数学基础	61
学习目标	61
正文内容	62
本章小结	67
深度学习应用：Dropout 的组合解释与集成学习	67
练习题	73
练习答案	73
几何示意	76
思考路标（条件反射）	76
易错点	77
第 4 章离散随机变量	77
学习目标	77
4.1 随机变量的概念	78
4.2 离散随机变量与概率质量函数	78
4.3 累积分布函数	79
4.4 期望	80
4.5 方差与标准差	82
4.6 矩母函数与特征函数	83
本章小结	84
深度学习应用：分类任务与 Softmax 输出	85
练习题	88
练习答案	89

几何示意	91
思考路标（条件反射）	93
易错点	93
第 5 章连续随机变量	93
学习目标	93
5.1 连续随机变量的定义	94
5.2 概率密度函数	94
5.3 累积分布函数	95
5.4 期望与方差	96
5.5 随机变量函数的分布	98
5.6 矩母函数（连续情形）	99
5.7 常用连续分布预览	100
本章小结	102
深度学习应用：回归任务与损失函数	102
练习题	108
练习答案	109
几何示意	111
思考路标（条件反射）	113
易错点	113
第 6 章多维随机变量	114
引入题	114
思维路径还原	114
学习目标	115
6.1 二维随机变量的概念	115
6.2 联合分布函数与联合概率	116
6.3 边缘分布	118
6.4 条件分布	120
6.5 协方差与相关系数	123
本章小结	125
深度学习应用：多任务学习与特征相关性	126
练习题	134
练习答案	135
几何示意	138
思考路标（条件反射）	141
易错点	141
第三部分导论：分布到底是什么？	141
学习目标	141
0.1 为什么要单独讲“分布”	142
0.2 从随机变量到分布：被“诱导”出来的概率分配	142

0.3 CDF：刻画任意分布的统一语言	143
0.4 PMF 与 PDF：CDF 的两种特例表达	144
0.5 分布族：参数化的”一组分布”	145
0.6 推导过程范例：一个分布是怎么”被推出来”的	146
0.7 小结与衔接	147
第 7 章离散分布族	148
学习目标	148
7.1 伯努利分布与二项分布	148
7.2 泊松分布	150
7.3 几何分布与负二项分布	151
7.4 超几何分布	153
7.5 离散分布族的统一视角	155
本章小结	156
深度学习应用	157
练习题	162
练习答案	164
几何示意	166
思考路标（条件反射）	168
易错点	168
第 8 章：连续分布族	168
引入题	169
思维路径还原	169
学习目标	170
8.1 均匀分布	170
8.2 正态分布（高斯分布）	171
8.3 指数分布与无记忆性	173
8.4 Gamma 分布与 Beta 分布	175
8.5 其他重要连续分布	176
8.6 分布之间的关系	178
本章小结	180
深度学习应用：权重初始化、归一化与贝叶斯先验	180
练习题	186
练习答案	188
几何示意	191
思考路标（条件反射）	194
易错点	194
第 9 章多维分布	195
学习目标	195
9.1 多项分布	195

9.2 多元正态分布	197
9.3 Dirichlet 分布	198
9.4 Wishart 分布简介	200
9.5 分布变换与采样	201
本章小结	203
深度学习应用	204
练习题	212
练习答案	213
几何示意	217
思考路标（条件反射）	218
易错点	218
第四部分导论：什么是收敛与极限定理？	219
学习目标	219
0.1 为什么需要“极限定理”这一部分	219
0.2 随机序列的收敛，为什么不能照搬数列极限	220
0.3 四种收敛模式与强弱层次	220
0.4 两类极限定理：各回答什么问题	221
0.5 怎么“读”一个极限定理	222
0.6 小结与衔接	222
第 10 章：大数定律	223
学习目标	223
10.1 切比雪夫不等式	223
10.2 弱大数定律	225
10.3 强大数定律	227
10.4 大数定律的应用	228
10.5 收敛速度与误差界	229
本章小结	231
深度学习应用	232
练习题	239
练习答案	241
第 11 章：中心极限定理	244
学习目标	244
11.1 独立同分布的中心极限定理	244
11.2 Lindeberg-Lévy 定理	247
11.3 De Moivre-Laplace 定理	248
11.4 中心极限定理的应用	250
11.5 Berry-Esseen 定理	252
本章小结	253
深度学习应用：批量归一化（BatchNorm）的理论基础	254

练习题	261
练习答案	262
第 12 章：收敛性理论	266
学习目标	266
12.1 依概率收敛	267
12.2 依分布收敛（弱收敛）	268
12.3 几乎必然收敛（强收敛）	270
12.4 L^p 收敛与均方收敛	272
12.5 收敛性之间的关系	274
本章小结	277
深度学习应用：模型收敛性分析与 PAC 学习理论	278
练习题	288
练习答案	289
第 13 章：统计量与抽样分布	294
学习目标	294
13.1 总体与样本	294
13.2 统计量的概念	296
13.3 抽样分布	298
13.4 三大抽样分布	299
13.5 正态总体的抽样分布定理	302
本章小结	305
深度学习应用：模型评估、交叉验证与 Bootstrap	306
练习题	314
练习答案	316
第 14 章：数据描述与可视化	319
学习目标	319
14.1 位置度量	319
14.2 散布度量	321
14.3 形状度量	323
14.4 数据可视化	324
14.5 多变量数据描述	326
本章小结	327
深度学习应用	328
练习题	335
练习答案	336
第 15 章：充分统计量	339
学习目标	339
15.1 充分统计量的定义	340
15.2 因子分解定理	341

15.3 最小充分统计量	343
15.4 完备统计量	344
15.5 指数族与充分统计量	346
本章小结	348
深度学习应用：信息压缩、特征学习与表示学习	349
练习题	356
练习答案	358
第 16 章：点估计	362
学习目标	362
16.1 点估计的基本概念	362
16.2 矩估计法	363
16.3 最大似然估计 (MLE)	365
16.4 估计量的评价标准	368
16.5 MLE 的渐近性质	372
本章小结	374
深度学习应用：MLE 与损失函数设计、交叉熵的由来	374
练习题	381
练习答案	382
第 17 章：区间估计	387
学习目标	387
17.1 置信区间的概念	387
17.2 枢轴量法	388
17.3 正态总体的区间估计	390
17.4 大样本区间估计	393
17.5 单侧置信限	395
本章小结	397
深度学习应用：不确定性量化与预测区间	398
练习题	406
练习答案	408
第 18 章：贝叶斯估计	411
学习目标	411
18.1 贝叶斯学派与频率学派	412
18.2 先验分布与后验分布	413
18.3 共轭先验	415
18.4 贝叶斯点估计	416
18.5 贝叶斯区间估计 (可信区间)	419
本章小结	420
深度学习应用：正则化的贝叶斯解释	421
练习题	426

练习答案	428
第十九章：假设检验基础	432
学习目标	432
正文内容	432
本章小结	439
19.6 最优检验理论	440
本章小结（更新）	441
深度学习应用	441
练习题	454
练习答案	455
第 20 章参数检验	458
学习目标	458
20.1 单样本 t 检验	459
20.2 双样本 t 检验：独立与配对	460
20.3 方差检验（ F 检验）	462
20.4 卡方检验	464
20.5 多重比较与校正	466
本章小结	468
深度学习应用：特征选择、模型比较与超参数调优	468
练习题	478
练习答案	480
第二十一章：非参数检验	484
学习目标	484
正文内容	484
本章小结	493
深度学习应用：生成模型的统计评估	494
练习题	504
练习答案	505
第 22 章信息论基础	509
学习目标	509
22.1 信息量与熵	510
22.2 联合熵与条件熵	511
22.3 互信息	513
22.4 KL 散度与交叉熵	515
22.5 信息论不等式	517
本章小结	519
深度学习应用	520
练习题	527
练习答案	528

第二十三章：蒙特卡洛方法	531
学习目标	531
正文内容	531
本章小结	539
深度学习应用	539
练习题	549
练习答案	550
第 24 章：概率图模型	553
学习目标	553
24.1 图模型概述	553
24.2 贝叶斯网络（有向图模型）	555
24.3 马尔可夫随机场（无向图模型）	556
24.4 隐变量模型与 EM 算法	558
24.5 变分推断简介	559
本章小结	561
深度学习应用：VAE、GMM 与隐变量模型	561
练习题	573
练习答案	575
概率公理与样本空间	578
一、为什么需要公理化概率	579
二、样本空间与事件	579
三、 σ -代数：概率的“域”	580
四、Kolmogorov 三公理	581
五、四种概型对比	582
六、演示题：古典概型与几何概型双解等公交问题	582
七、蒲丰投针问题（几何概型经典）	583
八、思考路标	584
九、典型应用 3 例	584
十、自测题	586
条件概率与贝叶斯思维	586
一、条件概率：信息更新后的概率	587
二、乘法公式与链式规则	587
三、全概率公式	588
四、贝叶斯公式	589
五、独立性 vs 互斥性	589
六、演示题：医学检验的贝叶斯反差	590
七、思考路标	591
八、典型应用 3 例	591
九、自测题	593

期望 / 方差 / 矩	593
一、为什么需要期望和矩	594
二、期望	594
三、方差	595
四、协方差与相关系数	596
五、矩母函数 (MGF)	597
六、演示题：二项分布 $B(n, p)$ 的期望与方差——两种方法	598
七、思考路标	599
八、典型应用 3 例	600
九、自测题	601
常见分布速查表	601
一、分布的分类框架	602
二、离散分布速查表	602
三、连续分布速查表	605
四、分布间的关系图	608
五、演示题：识别“等公交”= 指数分布（无记忆性）	609
六、思考路标	609
七、典型应用 3 例	610
八、自测题	611
多元分布与协方差	612
一、为什么多元分布是概率论的“立体化”	612
二、联合分布：PMF / PDF / CDF	613
三、边缘分布：对另一变量“积掉”	614
四、条件分布：在已知某变量值后更新信念	614
五、独立性判别	615
六、协方差与协方差矩阵	615
七、多元正态分布 $N(\mu, \Sigma)$	616
八、演示题：证明二元正态的条件分布仍是正态	617
九、思考路标	618
十、典型应用 3 例	619
十一、自测题	620
极限定理：LLN 与 CLT	621
一、为什么极限定理是统计推断的地基	621
二、四种收敛模式	621
三、大数定律 (LLN)	622
四、中心极限定理 (CLT)	623
五、演示题：用 CLT 估算样本均值偏差概率	624
六、思考路标	624
七、典型应用 3 例	625

八、自测题	626
估计量评价四标尺	627
一、为什么需要评价标准	627
二、四大评价标准	627
三、Cramér-Rao 下界与 Fisher 信息	629
四、演示题：样本均值 vs 样本中位数估计正态均值	630
五、思考路标	631
六、典型应用 3 例	631
七、自测题	632
MLE 求解套路	633
一、为什么 MLE 是参数估计的首选方法	633
二、五步求解流程	633
三、不变性原理	635
四、演示题：正态分布双参数 MLE	635
五、思考路标	636
六、典型应用 3 例	637
七、自测题	638
假设检验 7 步法	639
一、为什么需要假设检验	639
二、7 步操作框架	640
三、两类错误与功效	642
四、演示题：单样本 t 检验完整 7 步	642
五、思考路标	644
六、典型应用例题	644
七、自测题	645
信息论核心三件套	646
一、为什么信息论是 AI 的底层语言	646
二、熵：不确定性的度量	647
三、KL 散度：分布差异的度量	648
四、交叉熵：分类损失的本质	649
五、互信息：两个变量的共享信息	650
六、演示题：证明 $D_{KL}(p q) \geq 0$	651
七、思考路标	652
八、典型应用例题	653
九、自测题	655
Monte Carlo 与 MCMC	655
一、为什么需要 Monte Carlo 方法	655
二、基础 Monte Carlo 积分	656

三、拒绝采样	656
四、重要性采样	657
五、MCMC: 马尔可夫链 Monte Carlo	658
六、演示题: MH 采样 $N(0,1)$, 手算第一步接受率	659
七、思考路标	660
八、典型应用例题	661
九、自测题	662
概率论中的 AI 思维	663
一、为什么概率论是生成式 AI 的语言	663
二、ELBO 与变分推断的统一框架	663
三、VAE: 隐变量生成模型	664
四、扩散模型: 逐步加噪与学习去噪	666
五、Normalizing Flow: 精确似然的生成模型	667
六、GAN: 博弈论视角	667
七、贝叶斯神经网络	668
八、演示题: 从 ELBO 推出”重建损失 + KL 正则”	669
九、思考路标	670
十、典型应用例题	671
十一、自测题	672
公式速查表 (A 扩展版)	673
Part 1 概率基础 (Ch.1-3)	673
Part 2 随机变量 (Ch.4-6)	674
Part 3 分布大全 (Ch.7-9)	677
Part 4 极限定理 (Ch.10-12)	680
Part 5 统计基础 (Ch.13-15)	682
Part 6 参数估计 (Ch.16-18)	684
Part 7 假设检验 (Ch.19-21)	688
Part 8 高级主题 (Ch.22-24)	690
附录: 常用特殊值速查	694
附录 B: 公式记忆口诀	695
附录 C: 易混淆公式对比	695
附录 B: 概率论套路模型图谱	696
Part 1 概率基础 (模型 1-4)	696
模型 1: 全概率 + 贝叶斯反推	696
模型 2: 古典概型 + 容斥	696
模型 3: 几何概型 (面积/长度比)	697
模型 4: 独立 vs 互斥辨析	698
Part 2 随机变量 (模型 5-8)	698
模型 5: 离散 PMF 求未知常数 (归一化)	698

模型 6: 连续 PDF 函数变换 (CDF 法 / Jacobian)	699
模型 7: LOTUS 求 $E[g(X)]$	699
模型 8: 求边缘分布 / 条件分布	700
Part 3 分布 (模型 9–12)	701
模型 9: 场景 $\rightarrow$ 分布识别	701
模型 10: 正态标准化算概率	701
模型 11: 指数分布无记忆性	702
模型 12: 三大抽样分布构造	702
Part 4 极限定理 (模型 13–15)	703
模型 13: 切比雪夫不等式估上界	703
模型 14: CLT 求 $P(\sum X_i > a)$	704
模型 15: 连续性修正 (二项 $\rightarrow$ 正态近似)	705
Part 5 统计基础 (模型 16–18)	705
模型 16: $\bar{X}, S^2$ 抽样分布	705
模型 17: Bootstrap 求标准误	706
模型 18: 充分统计量判定 (因子分解)	706
Part 6 估计 (模型 19–23)	707
模型 19: MLE 求解 4 步	707
模型 20: 矩估计法	708
模型 21: 区间估计 4 步 (枢轴量法)	708
模型 22: 贝叶斯共轭后验	709
模型 23: 损失函数选估计量	710
Part 7 假设检验 (模型 24–27)	710
模型 24: 假设检验 7 步流程	710
模型 25: 配对 t vs 独立 t 选择	711
模型 26: p 值 vs 临界值法	712
模型 27: 多重检验校正	712
Part 8 高级主题 (模型 28–31)	713
模型 28: 熵 / 互信息计算	713
模型 29: KL 散度计算 (含不对称性)	713
模型 30: MH 接受概率构造	714
模型 31: DAG 联合分解 / d-分离判定	715
总览索引	715

基础题库 C (80 题)	716
Part 1 概率基础 (Ch.1-3, 共 10 题)	717
Part 2 随机变量 (Ch.4-6, 共 12 题)	718
Part 3 分布 (Ch.7-9, 共 12 题)	720
Part 4 极限 (Ch.10-12, 共 8 题)	722
Part 5 统计基础 (Ch.13-15, 共 8 题)	723
Part 6 估计 (Ch.16-18, 共 10 题)	724
Part 7 假设检验 (Ch.19-21, 共 10 题)	726

Part 8 高级 (Ch.22-24, 共 10 题)	727
中等题库 D (100 题)	729
Part 1 概率基础 (Ch.1-3, 共 12 题)	729
Part 2 随机变量 (Ch.4-6, 共 15 题)	732
Part 3 分布 (Ch.7-9, 共 15 题)	734
Part 4 极限定理 (Ch.10-12, 共 10 题)	737
Part 5 统计基础 (Ch.13-15, 共 10 题)	739
Part 6 估计 (Ch.16-18, 共 14 题)	741
Part 7 假设检验 (Ch.19-21, 共 12 题)	743
Part 8 高级主题 (Ch.22-24, 共 12 题)	746
汇总	748
高级题库 E (60 题)	748
Part 1 概率基础 (Ch.1-3, 共 6 题)	749
Part 2 随机变量 (Ch.4-6, 共 8 题)	751
Part 3 分布 (Ch.7-9, 共 8 题)	754
Part 4 极限定理 (Ch.10-12, 共 6 题)	757
Part 5 统计基础 (Ch.13-15, 共 5 题)	759
Part 6 参数估计 (Ch.16-18, 共 10 题)	760
Part 7 假设检验 (Ch.19-21, 共 7 题)	763
Part 8 高级主题 (Ch.22-24, 共 10 题)	766
F1 详解: Part 1 概率基础 (Ch.1-3, 共 28 题)	769
C 基础题详解 (10 题)	769
D 中等题详解 (12 题)	774
E 提高题详解 (6 题)	782
F2 详解: Part 2 随机变量 (Ch.4-6, 共 35 题)	790
C 基础题详解 (12 题)	790
D 中等题详解 (15 题)	796
E 提高题详解 (8 题)	809
F3 详解: Part 3 常见分布 (Ch.7-9, 共 35 题)	822
C 基础题详解 (12 题)	822
D 中等题详解 (15 题)	830
E 提高题详解 (8 题)	844
F4 详解: Part 4 极限定理 (Ch.10-12, 共 24 题)	856
C 基础题详解 (8 题)	857
D 中等题详解 (10 题)	860
E 提高题详解 (6 题)	867
知识点速查	875

F4b 详解: Part 5 统计基础 (Ch.13-15, 共 23 题)	876
C 基础题详解 (8 题)	876
D 中等题详解 (10 题)	880
E 提高题详解 (5 题)	888
F5 详解: Part 6 估计 (Ch.16-18, 共 34 题)	896
C 基础题详解 (10 题)	896
D 中等题详解 (14 题)	902
E 提高题详解 (10 题)	915
F6 详解: Part 7 假设检验 (Ch.19-21, 共 29 题)	927
C 基础题详解 (10 题)	928
D 中等题详解 (12 题)	933
E 提高题详解 (7 题)	945
F7 详解: Part 8 高级专题 (Ch.22-24, 共 32 题)	959
C 基础题详解 (10 题)	959
D 中等题详解 (12 题)	964
E 提高题详解 (10 题)	976
练习答案汇总	992
Part 1: 概率基础 (第 1-3 章)	993
Part 2: 随机变量 (第 4-6 章)	993
Part 3: 常见分布 (第 7-9 章)	993
Part 4: 极限定理 (第 10-12 章)	993
Part 5: 统计基础 (第 13-15 章)	994
Part 6: 参数估计 (第 16-18 章)	994
Part 7: 假设检验 (第 19-21 章)	994
Part 8: 高级主题 (第 22-24 章)	995
统计汇总	995
公式速查表	995
一、概率基础公式	995
二、随机变量	996
三、常见分布	998
四、极限定理	999
五、抽样分布	1000
六、参数估计	1001
七、假设检验	1002
八、信息论	1003
九、常用积分与特殊函数	1003
符号说明	1003

集合与数系	1003
概率论基础	1004
随机变量	1004
期望与方差	1005
常见分布	1005
收敛性	1006
统计学	1006
信息论	1007
其他常用符号	1007
深度学习相关符号	1008

从零到高阶的概率论与数理统计教程（深度学习应用版）

项目简介

本教程旨在为学习者提供一套系统、完整的概率论与数理统计学习资源，从最基础的随机事件与概率概念出发，循序渐进地覆盖随机变量、常见分布、极限定理、参数估计、假设检验等高阶主题。

本教程的独特之处：每章都包含「深度学习应用」部分，展示该章数学概念在人工智能和机器学习领域的实际应用，配有可运行的 Python/PyTorch 代码示例。

目标受众

- 大学本科生、研究生，首次系统学习概率论与数理统计
- 机器学习/深度学习初学者，希望理解 AI 的数学基础
- 计算机科学、数据科学、人工智能等专业的在校学生
- 备考研究生入学考试（考研数学）的学习者
- 希望回顾或巩固概率统计知识的工程师和研究者

章节导航目录

开始之前

- 前言：如何使用本教程

第一部分：概率基础

章节	标题	主要内容	深度学习应用
第 1 章	随机事件与概率	样本空间、事件、概率公理、古典概型	随机种子、可重复性实验
第 2 章	条件概率与独立性	条件概率、乘法公式、全概率、贝叶斯公式	贝叶斯神经网络、先验后验
第 3 章	组合数学基础	排列组合、二项式定理、多项式系数	Dropout 的组合解释、集成学习

第二部分：随机变量

章节	标题	主要内容	深度学习应用
第 4 章	离散随机变量	概率质量函数、期望、方差	分类任务、Softmax 输出
第 5 章	连续随机变量	概率密度函数、分布函数、期望方差	回归任务、损失函数
第 6 章	多维随机变量	联合分布、边缘分布、协方差、相关系数	多任务学习、特征相关性

第三部分：常见分布

□ 先读导论：分布到底是什么？——在学具体分布族之前，先讲清”分布”作为数学对象的含义($P_X = P \circ X^{-1}$)、CDF 如何统一刻画分布、PMF/PDF 的关系，以及”分布是怎么被推导出来的”。

章节	标题	主要内容	深度学习应用
第 7 章	离散分布族	伯努利、二项、泊松、几何、负二项	二分类、事件计数、序列建模
第 8 章	连续分布族	均匀、指数、正态、Gamma、Beta	权重初始化、归一化、先验分布
第 9 章	多维分布	多项分布、多元正态、Dirichlet	多分类 Softmax、VAE 潜在空间、LDA

第四部分：极限定理

□ 先读导论：什么是收敛与极限定理？——在学大数定律/中心极限定理之前，先讲清”随机变量序列收敛”为何需要多种”收敛模式”（依概率/依分布/几乎必然/均方）、它们的强弱层次，以及两类极限定理各在回答什么问题。

章节	标题	主要内容	深度学习应用
第 10 章	大数定律	切比雪夫不等式、弱大数定律、强大数定律	经验风险最小化、SGD 收敛性
第 11 章	中心极限定理	CLT 各种形式、正态近似	Batch 统计、BatchNorm 理论基础
第 12 章	收敛性理论	依概率收敛、依分布收敛、几乎必然收敛	模型收敛性分析、PAC 学习

第五部分：统计基础

章节	标题	主要内容	深度学习应用
第 13 章	统计量与抽样分布	统计量、抽样分布、t 分布、F 分布、卡方分布	模型评估、交叉验证
第 14 章	数据描述与可视化	均值、中位数、众数、四分位数、直方图	数据探索、特征工程
第 15 章	充分统计量	充分性、因子分解定理、完备性	信息压缩、特征学习

第六部分：参数估计

章节	标题	主要内容	深度学习应用
第 16 章	点估计	矩估计、最大似然估计、评价标准	损失函数设计、MLE 与交叉熵
第 17 章	区间估计	置信区间、枢轴量法、大样本方法	不确定性量化、预测区间
第 18 章	贝叶斯估计	先验、后验、共轭先验、MAP 估计	正则化的贝叶斯解释、权重衰减

第七部分：假设检验

章节	标题	主要内容	深度学习应用
第 19 章	假设检验基础	原假设、备择假设、两类错误、p 值	A/B 测试、模型显著性比较
第 20 章	参数检验	t 检验、z 检验、F 检验、卡方检验	特征选择、模型比较
第 21 章	非参数检验	秩检验、符号检验、KS 检验	分布拟合检验、生成模型评估

第八部分：高级主题

章节	标题	主要内容	深度学习应用
第 22 章	信息论基础	熵、互信息、KL 散度、交叉熵	损失函数、VAE 的 ELBO、信息瓶颈
第 23 章	蒙特卡洛方法	随机模拟、重要性采样、MCMC	Dropout 采样、贝叶斯推断、扩散模型
第 24 章	概率图模型	贝叶斯网络、马尔可夫随机场、EM 算法	隐变量模型、VAE、GMM

附录

附录	标题	内容说明
附录 A	公式速查表	概率、分布、统计量等常用公式
附录 B	符号说明	全书使用的数学符号解释
附录 C	练习答案汇总	各章练习题答案索引

学习路径建议

路径一：快速入门（约 4-6 周）

适合有一定高中数学基础、希望快速掌握概率统计核心内容的学习者：

- 1. 学习第 1-3 章（概率基础）
- 2. 重点学习第 4-6 章（随机变量）
- 3. 学习第 7-8 章（常见分布）
- 4. 学习第 16 章（点估计）和第 22 章（信息论）

路径二：系统学习（约 3-4 个月）

适合大学新生或备考研究生的学习者：

- 1. 按章节顺序从头到尾完整学习（第 1-24 章）
- 2. 每章学完后完成配套练习题
- 3. 重点强化第 10-12 章（极限定理）和第 16-18 章（参数估计）

路径三：深度学习导向（约 2-3 个月）

适合希望理解 AI 数学基础的工程师：

1. 快速浏览第 1-6 章，建立基础概念
 2. 重点学习每章的「深度学习应用」部分
 3. 深入学习第 16 章（MLE 与交叉熵）和第 18 章（贝叶斯估计）
 4. 精读第 22 章（信息论）和第 23 章（蒙特卡洛方法）
-

前置要求

学习本教程需要以下数学基础：

- 代数基础：多项式运算、方程求解、不等式
- 函数概念：函数的定义、图像、基本性质
- 基础微积分：导数、积分的基本概念（第 5 章及后续章节需要）
- 线性代数基础（可选）：向量、矩阵的基本运算（第 6 章及后续章节有帮助）

如果上述基础知识有所欠缺，建议先学习本项目的配套教程：- 微积分教程 - 线性代数教程

如何使用本教程

1. 按需选择章节：根据自身基础和学习目标，选择合适的学习路径
 2. 先看概念，再看例题：每节先理解概念定义与定理，再跟随例题实操
 3. 运行代码示例：每章的深度学习应用部分都有可运行的代码，建议动手实践
 4. 完成练习题：每章末尾有练习题，建议独立完成后再查看答案
 5. 使用速查表：学习过程中可随时参考附录公式速查表
-

教程特色

- 24 章完整内容：从概率基础到概率图模型，系统覆盖本科概率统计
 - 深度学习融合：每章配有 AI 应用案例和 PyTorch 代码示例
 - 120 道练习题：每章 5 道精选习题，含详细解答
 - LaTeX 公式：所有数学公式使用标准 LaTeX 语法，支持主流渲染器
 - 中文编写：专为中文学习者设计，术语准确，表达清晰
-

许可证

本项目采用 MIT 许可证开源。你可以自由地使用、复制、修改和分发本教程的内容。

如有建议或发现错误，欢迎提交 *Issue* 或 *Pull Request*。

改造升级（2026-05-14）

本教程已按 `calculus-tutorial/` 模式做了”包装式改造”：

新增 **thinking-toolkit**（12 篇）

`thinking-toolkit/` 目录是独立的”概率论思维方法论”小册子：

编号	主题
01	概率公理与样本空间
02	条件概率与贝叶斯思维
03	期望 / 方差 / 矩
04	常见分布速查表
05	多元分布与协方差
06	极限定理（LLN + CLT）
07	估计量评价四标尺
08	MLE 求解套路
09	假设检验 7 步法
10	信息论核心三件套
11	Monte Carlo + MCMC
12	概率论中的 AI 思维

新增模板 **D** 包装

每个核心套路型章节（□ 标记，共 10 章）在原正文之外，加上：- 一例速记：核心公式 + 最常用变形 - 思维路径还原：作者第 1 秒怎么想的内心独白 - 思考路标 ≥8 条：条件反射（看到 X 立刻想 Y） - 易错点 5 条

□ 章节：条件概率 / 多元随机变量 / 连续分布 / 大数定律 / CLT / 点估计 / 贝叶斯估计 / 假设检验基础 / 信息论 / 概率图模型。

新增题库 (240 题 C/D/E 三档)

appendix/ 新增 C 80 + D 100 + E 60 = 240 题, F 详解按主题分 6-7 文件。

figures (~70 张)

figures/ 目录用 TikZ + Asymptote 渲染了约 70 张关键图 (分布密度 / CLT 演示 / MLE 似然曲面 / 假设检验决策 / KL 散度 / MCMC 轨迹等)。

配套教程

- chuzhong_algebra/ —中考代数
- chuzhong_geometry/ —中考几何
- gaozhong_math/algebra/ —高中代数 (含概率初步)
- gaozhong_math/geometry/ —高中几何
- calculus-tutorial/ —微积分 (含 AI 微积分)

5 套教程构成”初中 → 高中 → 微积分 → 概率统计 → AI”完整数学体系。

前言：如何使用本教程

为什么学习概率论与数理统计

概率论与数理统计是现代科学的基础工具，它研究随机现象的规律性，为我们提供了在不确定性中做出理性决策的数学框架。无论你是学习纯数学、应用数学，还是计算机科学、物理学、生物学、经济学，概率统计都是不可或缺的工具。

特别是在人工智能和深度学习时代，概率统计的重要性更加凸显：

- 神经网络的训练是概率优化问题：损失函数本质是似然函数的负对数
- 深度学习充满随机性：权重初始化、Dropout、数据增强、SGD 都涉及随机采样
- 生成模型基于概率分布：VAE、GAN、扩散模型都在学习数据的概率分布
- 不确定性量化：贝叶斯神经网络、MC Dropout 提供预测的置信度

本教程不仅教授概率统计的经典理论，更在每一章展示这些概念如何在深度学习中发挥作用。

本教程的结构

全书共分为八个部分，**24** 章，按照由浅入深的顺序编排：

第一部分：概率基础（第 1-3 章）

建立随机事件和概率的基本概念，这是后续所有内容的基石。

第二部分：随机变量（第 4-6 章）

学习如何用数学语言描述随机现象，理解期望、方差等核心概念。

第三部分：常见分布（第 7-9 章）

掌握常用的离散分布和连续分布，理解它们的性质和应用场景。

第四部分：极限定理（第 10-12 章）

学习大数定律和中心极限定理，理解随机现象的渐近规律。

第五部分：统计基础（第 13-15 章）

从概率论过渡到数理统计，学习统计量和抽样分布。

第六部分：参数估计（第 16-18 章）

掌握点估计、区间估计和贝叶斯估计的方法和理论。

第七部分：假设检验（第 19-21 章）

学习如何用统计方法做出科学决策，理解显著性检验的原理。

第八部分：高级主题（第 22-24 章）

学习信息论、蒙特卡洛方法和概率图模型，这些是深度学习中最常用的高级工具。

每章的结构

每一章都遵循统一的结构，方便你系统学习：

1. 学习目标：明确本章要掌握的知识点和技能
2. 正文内容：定义、定理、证明和例题，配有直观解释
3. 本章小结：提炼核心要点，便于复习
4. 深度学习应用：展示本章数学概念在 AI 中的实际应用，配有代码示例
5. 练习题：5 道精选题目，巩固所学
6. 练习答案：详细的解题过程（以折叠块形式呈现）

符号约定

本教程使用以下符号约定（详见符号说明）：

符号	含义
Ω	样本空间
A, B, C	事件
$P(A)$	事件 A 的概率
$P(A B)$	在 B 发生条件下 A 的条件概率
X, Y, Z	随机变量
$E[X]$ 或 μ	期望
$\text{Var}(X)$ 或 σ^2	方差
$f(x)$	概率密度函数 (PDF)
$F(x)$	累积分布函数 (CDF)
$p(x)$	概率质量函数 (PMF)
$\mathcal{N}(\mu, \sigma^2)$	正态分布

学习建议

对于初学者

1. 按顺序学习：第一部分到第三部分的内容是后续的基础，不要跳过
2. 多做计算：概率统计需要大量的计算练习，熟练度很重要
3. 理解直觉：每个概念都要建立直观理解，不要只记公式
4. 运行代码：动手运行每章的代码示例，加深理解

对于有基础的学习者

1. 可以跳读：如果已经掌握基础，可以直接从第四部分开始
2. 关注深度学习应用：这是本教程的特色，即使熟悉概率统计也值得一读
3. 做练习题：检验自己的理解是否到位

对于深度学习从业者

1. 重点章节：第 16 章（MLE）、第 18 章（贝叶斯估计）、第 22 章（信息论）、第 23 章（蒙特卡洛）
 2. 代码优先：可以先看代码示例，再回顾数学原理
 3. 结合实践：将所学应用到自己的项目中
-

配套资源

- 微积分教程：从零到高阶的微积分教程
 - 线性代数教程：从零到高阶的线性代数教程
 - 公式速查表：附录 A
 - 符号说明：附录 B
-

致谢

感谢所有为概率统计教育做出贡献的教育工作者和学者。本教程参考了多本经典教材的内容组织方式，包括 Sheldon Ross 的《概率论基础教程》、陈希孺的《概率论与数理统计》、Bishop 的《Pattern Recognition and Machine Learning》等。

祝你学习愉快！

让我们从随机事件开始，踏上概率统计的探索之旅。

关于“模板 D 思维训练”（2026-05-14 改造后新增）

本教程已按 calculus-tutorial/ 模式做了“包装式升级”——在原有严格推导 + 深度学习应用基础上，新增：

1. 一例速记 (□ 章节)

每章开头给出 3-5 行”核心公式 + 最常用变形”，便于速查 / 备考。

2. 思维路径还原 (□ 章节)

用 15-20 行 > 引用块完整还原专家第 1 秒到最后 1 秒的内心独白——通过”模拟专家思维路径”训练自己。

3. 思考路标 (≥8 条)

每章末”看到 X 立刻想 Y”反射列表：

- 看到”已知阳性求患病”→ 想贝叶斯反演（注意先验）
- 看到独立同分布之和 → 想 CLT
- 看到”求最大似然”→ MLE 五步流程
- 看到 KL 散度 → 想交叉熵 + Jensen 不等式

配合 **thinking-toolkit** 使用

thinking-toolkit/ 12 篇是主动学习指南：建议先读 toolkit 01-02（公理 + 贝叶斯）再开始 Part 1。学到分布章节时回读 toolkit/04（分布速查）；学到 ML 应用时读 toolkit/10-12（信息论 / MCMC / AI 思维）。

与 **calculus** 教程的衔接

Part 4 极限定理需要微积分中的极限基础（详见 calculus-tutorial/ Part 2）。Part 8 高级专题（VAE / 扩散）需要 calculus-tutorial/ Part 8 AI 微积分（梯度 / Hessian / KL 散度）作为前置。

第一章：随机事件与概率

学习目标

完成本章学习后，你将能够：

- 理解随机试验、样本空间和样本点的基本概念，能够对具体问题建立概率模型
 - 掌握随机事件的集合语言，熟练进行事件的并、交、补等运算
 - 理解 Kolmogorov 公理化体系，从公理出发推导概率的基本性质
 - 应用古典概型公式计算有限等可能样本空间中的概率
 - 了解随机性在深度学习中的角色，掌握设置随机种子保证实验可重复性的方法
-

正文内容

1.1 随机试验与样本空间

1.1.1 什么是随机试验 在日常生活和科学研究中，我们经常面对结果不确定的试验或观测。概率论研究的核心对象就是这类随机试验（Random Experiment）。

一个随机试验具备以下三个特征：

1. 可重复性：试验可以在相同条件下重复进行
2. 结果多样性：每次试验可能出现多个不同的结果
3. 随机性：试验前无法确定本次结果是哪一个

典型例子：

- 掷一枚均匀硬币，观察正面（H）还是反面（T）
- 掷一颗均匀六面骰子，观察朝上的点数
- 从一批产品中随机抽取一件，检查是合格品还是次品
- 测量某工厂某天的日产量

1.1.2 样本空间 随机试验所有可能结果组成的集合称为样本空间（Sample Space），记作 Ω 。样本空间中的每一个元素称为样本点（Sample Point），记作 ω 。

$$\Omega = \{\omega \mid \omega \text{ 是试验的一个可能结果}\}$$

例 1.1 掷一枚硬币的样本空间为：

$$\Omega_1 = \{H, T\}$$

例 1.2 掷一颗骰子的样本空间为：

$$\Omega_2 = \{1, 2, 3, 4, 5, 6\}$$

例 1.3 掷两枚硬币的样本空间为：

$$\Omega_3 = \{HH, HT, TH, TT\}$$

例 1.4 测量某元件的寿命（单位：小时），样本空间为：

$$\Omega_4 = \{t \mid t \geq 0\} = [0, +\infty)$$

样本空间可以是有限集、可列无限集，也可以是不可列无限集（如连续区间）。

1.2 随机事件

1.2.1 事件的定义 随机事件 (Random Event) 是样本空间 Ω 的子集, 即满足某一条件的样本点的集合。通常用大写字母 $A, B, C, \dots$ 表示。

- 必然事件: Ω 本身, 每次试验必然发生, 记作 Ω
- 不可能事件: 空集 $\emptyset$, 每次试验必然不发生, 记作 $\emptyset$
- 基本事件: 只含一个样本点的事件 $\{\omega\}$

例 1.5 掷骰子试验中, 设 $A = \text{“出现偶数点”}$, 则:

$$A = \{2, 4, 6\} \subseteq \Omega_2$$

1.2.2 事件的关系与运算 事件本质上是集合, 因此集合的关系和运算都可以用于事件。

(1) 包含关系

若事件 A 发生必然导致事件 B 发生, 则称 B 包含 A , 记作 $A \subseteq B$ 。

$$A \subseteq B \iff (\omega \in A \Rightarrow \omega \in B)$$

(2) 事件的并 (Union)

A 与 B 的并事件 $A \cup B$ 表示“ A 或 B 至少有一个发生”:

$$A \cup B = \{\omega \mid \omega \in A \text{ 或 } \omega \in B\}$$

推广到有限多个事件: $A_1 \cup A_2 \cup \dots \cup A_n = \bigcup_{i=1}^n A_i$

(3) 事件的交 (Intersection)

A 与 B 的交事件 $A \cap B$ (也写作 AB) 表示“ A 与 B 同时发生”:

$$A \cap B = \{\omega \mid \omega \in A \text{ 且 } \omega \in B\}$$

(4) 事件的差 (Difference)

A 与 B 的差事件 $A - B$ 表示“ A 发生但 B 不发生”:

$$A - B = \{\omega \mid \omega \in A \text{ 且 } \omega \notin B\} = A \cap \bar{B}$$

(5) 互斥事件 (Mutually Exclusive)

若 $A \cap B = \emptyset$ ，则称 A 与 B 互斥（不相容），即两者不能同时发生。

(6) 对立事件 (Complement)

A 的对立事件（余事件） $\bar{A}$ 表示“ A 不发生”：

$$\bar{A} = \Omega - A = \{\omega \mid \omega \notin A\}$$

A 与 $\bar{A}$ 满足： $A \cup \bar{A} = \Omega$ ， $A \cap \bar{A} = \emptyset$

运算规律（德摩根定律）：

$$\overline{A \cup B} = \bar{A} \cap \bar{B}$$

$$\overline{A \cap B} = \bar{A} \cup \bar{B}$$

直觉理解：“ A 或 B 都不发生”等价于“ A 不发生且 B 不发生”。

1.3 概率的公理化定义

1.3.1 Kolmogorov 公理体系 20 世纪初，苏联数学家 **Andrey Kolmogorov** 于 1933 年建立了概率论的公理化体系，奠定了现代概率论的数学基础。

定义（概率的公理化定义）

设 Ω 是样本空间，对于每个事件 A ，定义一个实数 $P(A)$ ，若满足以下三条公理，则称 $P(A)$ 为事件 A 的概率：

公理一（非负性）：对任意事件 A ，有

$$P(A) \geq 0$$

公理二（规范性）：必然事件的概率为 1，即

$$P(\Omega) = 1$$

公理三（可列可加性）：若 $A_1, A_2, \dots$ 两两互斥，则

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

这三条公理简洁而深刻：非负性确保概率是有意义的度量，规范性给出刻度，可加性是概率最核心的运算规则。

1.3.2 频率诠释 公理体系是抽象的数学定义。在实际应用中，我们通过频率来理解和估计概率。

将一个随机试验重复进行 n 次，事件 A 发生了 n_A 次，则 A 的频率为：

$$f_n(A) = \frac{n_A}{n}$$

当 n 很大时，频率趋于稳定，接近一个固定值，这个值就是概率 $P(A)$ ：

$$P(A) \approx f_n(A) \quad (n \text{ 足够大时})$$

这一规律称为大数定律，后续章节将给出严格证明。

1.4 古典概型

1.4.1 古典概型的定义 若随机试验满足以下两个条件，则称为古典概型 (Classical Probability Model)：

1. 有限性：样本空间只含有限个样本点，即 $|\Omega| = n < +\infty$
2. 等可能性：每个样本点出现的可能性相同，即每个基本事件的概率为 $\frac{1}{n}$

在古典概型中，若事件 A 包含 k 个样本点，则：

$$P(A) = \frac{k}{n} = \frac{|A|}{|\Omega|} = \frac{\text{A 包含的样本点数}}{\text{样本空间的样本点总数}}$$

1.4.2 古典概型例题 例 1.6 掷一枚均匀骰子，求“出现偶数点”的概率。

解： $\Omega = \{1, 2, 3, 4, 5, 6\}$, $|\Omega| = 6$

$A = \{2, 4, 6\}$, $|A| = 3$

$$P(A) = \frac{3}{6} = \frac{1}{2}$$

例 1.7 (生日问题) n 个人中至少两人生日相同的概率是多少? (假设一年 365 天，每天等可能)

解：设 $B = \text{“至少两人生日相同”}$, $\bar{B} = \text{“所有人生日各不相同”}$ 。

总的分配方式： 365^n （每人可在 365 天中任选）

所有人生日各不相同的方式： $365 \times 364 \times \cdots \times (365 - n + 1) = \frac{365!}{(365-n)!}$

$$P(\bar{B}) = \frac{365 \times 364 \times \cdots \times (365 - n + 1)}{365^n}$$

$$P(B) = 1 - P(\bar{B})$$

当 $n = 23$ 时, $P(B) \approx 0.507 > 50\%$, 这一反直觉的结论称为生日悖论。

1.5 概率的基本性质

由 Kolmogorov 公理可以推导出概率的一系列基本性质。

性质一：不可能事件的概率

$$P(\emptyset) = 0$$

证明：令 $A_i = \emptyset$, $i = 1, 2, \dots$, 则 A_i 两两互斥, 且 $\bigcup_{i=1}^{\infty} A_i = \emptyset$ 。

由公理三： $P(\emptyset) = \sum_{i=1}^{\infty} P(\emptyset) = n \cdot P(\emptyset)$, 故 $P(\emptyset) = 0$ 。

性质二：有限可加性 若 $A_1, A_2, \dots, A_n$ 两两互斥, 则：

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i)$$

性质三：对立事件

$$P(\bar{A}) = 1 - P(A)$$

证明： $A \cup \bar{A} = \Omega$, 且 $A \cap \bar{A} = \emptyset$, 故：

$$P(A) + P(\bar{A}) = P(\Omega) = 1$$

这是概率计算中的重要技巧：正难则反, 当直接计算 $P(A)$ 困难时, 先算 $P(\bar{A})$ 。

性质四：概率的范围

$$0 \leq P(A) \leq 1$$

证明：由非负性知 $P(A) \geq 0$ 。由 $A \subseteq \Omega$ 及单调性知 $P(A) \leq P(\Omega) = 1$ 。

性质五：单调性 若 $A \subseteq B$ ，则 $P(A) \leq P(B)$ ，且 $P(B - A) = P(B) - P(A)$ 。

证明： $B = A \cup (B - A)$ ，且 $A \cap (B - A) = \emptyset$ ，故 $P(B) = P(A) + P(B - A) \geq P(A)$ 。

性质六：加法公式

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

证明： $A \cup B = A \cup (B - A)$ ， A 与 $B - A$ 互斥，故：

$$P(A \cup B) = P(A) + P(B - A) = P(A) + P(B) - P(AB)$$

推广（容斥原理）：

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(AB) - P(AC) - P(BC) + P(ABC)$$

一般地，对 n 个事件：

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_i P(A_i) - \sum_{i < j} P(A_i A_j) + \sum_{i < j < k} P(A_i A_j A_k) - \cdots + (-1)^{n-1} P(A_1 A_2 \cdots A_n)$$

例 1.8 设 $P(A) = 0.4$ ， $P(B) = 0.5$ ， $P(AB) = 0.2$ ，求 $P(A \cup B)$ 。

$$P(A \cup B) = 0.4 + 0.5 - 0.2 = 0.7$$

本章小结

概念	数学表示	直觉含义
样本空间	Ω	所有可能结果的集合
随机事件	$A \subseteq \Omega$	满足某条件的结果的集合
概率	$P : 2^\Omega \rightarrow [0, 1]$	事件发生可能性的度量
古典概型	$P(A) = A / \Omega $	有限等可能情形
加法公式	$P(A \cup B) = P(A) + P(B) - P(AB)$	避免重复计算的修正

概念	数学表示	直觉含义
对立公式	$P(\bar{A}) = 1 - P(A)$	正难则反

核心思想：概率是对随机性的数学度量。Kolmogorov 三条公理是整座概率大厦的基石——非负、规范、可加，从这三条出发可以推导出概率论的全部性质。

深度学习应用：随机种子与可重复性

深度学习中的随机性来源

深度学习训练过程充满了随机性，理解这些随机性对于调试和复现实验结果至关重要。从概率论的角度看，每一次训练都是一次随机试验。

主要的随机性来源包括：

(1) 权重初始化

神经网络的权重通常从某个概率分布中随机采样进行初始化。例如 Xavier 初始化：

$$W_{ij} \sim \mathcal{U}\left(-\sqrt{\frac{6}{n_{in} + n_{out}}}, \sqrt{\frac{6}{n_{in} + n_{out}}}\right)$$

不同的初始权重会导致模型收敛到不同的局部最小值，最终精度可能相差数个百分点。

(2) 数据打乱 (Shuffling)

训练前通常将数据集随机打乱，使得每个 epoch 中 mini-batch 的组成不同。数据顺序的随机性影响梯度估计的方差，进而影响收敛速度和最终性能。

(3) Dropout 正则化

Dropout 在训练时以概率 p 随机将神经元置零：

$$h'_i = \begin{cases} 0 & \text{以概率 } p \\ \frac{h_i}{1-p} & \text{以概率 } 1-p \end{cases}$$

每次前向传播都是一次新的随机试验，产生不同的网络结构。

(4) 数据增强

随机裁剪、翻转、颜色抖动等数据增强操作引入额外随机性，提升模型泛化能力。

(5) 采样算法

随机梯度下降（SGD）中 mini-batch 的随机采样、Dropout mask 的随机生成等均依赖随机数生成器。

为什么需要随机种子

如果不固定随机种子，同一份代码每次运行的结果可能截然不同，这给以下场景带来严重问题：

- 调试：无法判断性能变化来自代码修改还是随机波动
- 论文复现：读者无法复现你的实验结果
- 模型比较：不公平的随机初始化使得比较失去意义
- 生产部署：难以确保模型行为的一致性

固定随机种子相当于固定了随机试验的“轨迹”，使得整个随机过程变得确定性可重复。

PyTorch 中设置随机种子

深度学习框架通常有多个独立的随机数生成器，需要分别设置：

```
import torch
import numpy as np
import random
import os

def set_seed(seed: int = 42) -> None:
    """
    设置所有随机数生成器的种子，确保实验可重复性。

    Args:
        seed: 随机种子值，默认为 42（约定俗成的选择）
    """
    # Python 内置随机模块
    random.seed(seed)

    # NumPy 随机数生成器（影响数据处理、增强等）
    np.random.seed(seed)

    # PyTorch CPU 随机数生成器
    torch.manual_seed(seed)

    # PyTorch GPU 随机数生成器（单卡）
    torch.cuda.manual_seed(seed)
```

```
# PyTorch GPU 随机数生成器 (多卡)
torch.cuda.manual_seed_all(seed)

# 确保 cuDNN 使用确定性算法 (可能略微降低速度)
torch.backends.cudnn.deterministic = True
torch.backends.cudnn.benchmark = False

# 设置环境变量 (部分操作系统层面的随机性)
os.environ["PYTHONHASHSEED"] = str(seed)

print(f" 随机种子已设置为: {seed}")

# 演示随机种子的效果
def demo_reproducibility():
    print("=== 不固定种子 ===")
    for i in range(3):
        x = torch.randn(3)
        print(f" 第{i+1}次: {x.tolist()}")

    print("\n=== 固定种子 (每次运行结果相同) ===")
    for i in range(3):
        set_seed(42)
        x = torch.randn(3)
        print(f" 第{i+1}次: {x.tolist()}")

    print("\n=== 种子相同, 序列确定 ===")
    set_seed(42)
    for i in range(3):
        x = torch.randn(3)
        print(f" 第{i+1}次: {x.tolist()}")

if __name__ == "__main__":
    demo_reproducibility()
```

示例输出:

=== 不固定种子 ===

第1次: [0.312, -1.847, 0.563]

第2次: [-0.791, 0.234, 1.102]

第3次: [1.445, -0.089, -0.723]

=== 固定种子（每次运行结果相同） ===

随机种子已设置为：42

第1次：[0.3367, -0.1288, 0.2345]

随机种子已设置为：42

第1次：[0.3367, -0.1288, 0.2345]

随机种子已设置为：42

第1次：[0.3367, -0.1288, 0.2345]

=== 种子相同，序列确定 ===

随机种子已设置为：42

第1次：[0.3367, -0.1288, 0.2345]

第2次：[0.2303, -1.1229, -0.1863]

第3次：[2.2082, -0.6380, 0.4617]

DataLoader 的确定性设置

```
def seed_worker(worker_id: int) -> None:
    """DataLoader 多进程 worker 的种子设置函数。"""
    worker_seed = torch.initial_seed() % (2**32)
    np.random.seed(worker_seed)
    random.seed(worker_seed)

# 创建可重复的 DataLoader
generator = torch.Generator()
generator.manual_seed(42)

dataloader = torch.utils.data.DataLoader(
    dataset,
    batch_size=32,
    shuffle=True,
    num_workers=4,
    worker_init_fn=seed_worker,  # 初始化每个 worker 的种子
    generator=generator,        # 控制 shuffle 的随机性
)
```

实践建议

1. 在训练脚本最开始调用 `set_seed()`，在导入之后、任何计算之前
2. 记录种子值：将种子作为超参数记录在实验配置文件中

3. 多种子验证：为了确保结论的可靠性，用多个不同种子运行实验，报告均值和标准差
4. 注意局限性：即使固定种子，某些 CUDA 操作在不同硬件/驱动版本下仍可能产生微小差异
5. 调试与发布分离：调试时固定种子，发布模型时也保存种子以供复现

概率论视角：固定随机种子等价于“选择了一条确定的概率路径”。概率空间 $(\Omega, \mathcal{F}, P)$ 中，样本点 $\omega \in \Omega$ 代表一次完整的随机试验结果。随机种子本质上是在伪随机数生成器的序列上选定了起点，使得对应的 ω 在每次运行时相同。

练习题

习题 1.1（基础）掷两枚均匀骰子，设 A = “两枚点数之和为 7”， B = “两枚点数之和为偶数”， C = “至少有一枚点数为 6”。

- (1) 写出 Ω , A , B , C 的具体元素；(2) 判断 A 与 B 是否互斥；(3) 求 $P(A)$, $P(B)$, $P(C)$ 。
-

习题 1.2（基础）设事件 A , B 满足 $P(A) = 0.6$, $P(B) = 0.4$, $P(AB) = 0.2$ 。

- (1) 求 $P(A \cup B)$ ；(2) 求 $P(\bar{A} \cup \bar{B})$ ；(3) 求 $P(\bar{A}B)$ (B 发生但 A 不发生的概率)。
-

习题 1.3（中级）一个班级有 30 名同学，其中 18 人喜欢数学，15 人喜欢编程，8 人两者都喜欢。随机选取一名同学，求：

- (1) 该同学喜欢数学或编程（至少之一）的概率；(2) 该同学既不喜欢数学也不喜欢编程的概率；(3) 该同学只喜欢数学（不喜欢编程）的概率。
-

习题 1.4（中级）将 3 封信随机投入编号为 1、2、3 的 3 个信箱，每封信投入每个信箱等可能。求：

- (1) 3 个信箱各有 1 封信的概率；(2) 恰好有 1 个信箱为空的概率；(3) 至少有 1 个信箱为空的概率。
-

习题 1.5（提高）某深度学习团队用两种优化器（Adam 和 SGD）分别训练同一个模型，各训练 10 次（每次不同随机种子）。已知 Adam 每次训练达到目标精度的概率为 0.8，SGD 为 0.6。

- (1) 若随机选取一次 Adam 的训练结果，求该次达到目标精度的概率（验证理解）；(2) 用容斥原理，求 10 次 Adam 训练中“第 1 次和第 2 次都达标”的概率（假设各次独立，后续章节会给出更简洁的乘法公式）；(3) 设 A_i = “Adam 第 i 次训练达标”，用集合语言描述事件“10 次中至少有 1 次达标”，并指出该事件的对立事件。
-

练习答案

习题 1.1 详解

(1) 掷两枚骰子，样本空间共 $6 \times 6 = 36$ 个样本点：

$$\Omega = \{(i, j) \mid i, j \in \{1, 2, 3, 4, 5, 6\}\}$$

$A =$ “两数之和为 7”： $A = \{(1, 6), (2, 5), (3, 4), (4, 3), (5, 2), (6, 1)\}$, $|A| = 6$

$B =$ “两数之和为偶数” (奇 + 奇或偶 + 偶)：

$$B = \{(1, 1), (1, 3), (1, 5), (2, 2), (2, 4), (2, 6), (3, 1), (3, 3), (3, 5), (4, 2), (4, 4), (4, 6), (5, 1), (5, 3), (5, 5), (6, 2), (6, 4), (6, 6)\}$$

$$|B| = 18$$

$C =$ “至少有一枚点数为 6”： 共 $6 + 6 - 1 = 11$ 个， $|C| = 11$

(2) 注意 A 中的点对形如 $(,)$ 或 $(,)$ ，两数之和均为奇数。因此 $A \cap B = \emptyset$ ， A 与 B 互斥。

(3)

$$P(A) = \frac{6}{36} = \frac{1}{6}$$

$$P(B) = \frac{18}{36} = \frac{1}{2}$$

$$P(C) = \frac{11}{36}$$

习题 1.2 详解

已知： $P(A) = 0.6$, $P(B) = 0.4$, $P(AB) = 0.2$

(1) 加法公式：

$$P(A \cup B) = P(A) + P(B) - P(AB) = 0.6 + 0.4 - 0.2 = 0.8$$

(2) 由德摩根定律： $\bar{A} \cup \bar{B} = \overline{AB}$

$$P(\bar{A} \cup \bar{B}) = P(\overline{AB}) = 1 - P(AB) = 1 - 0.2 = 0.8$$

(3) $\bar{A}B = B - AB$ (B 发生但 A 不发生)

由单调性： $P(B - AB) = P(B) - P(AB) = 0.4 - 0.2 = 0.2$

习题 1.3 详解

设 M = “喜欢数学”， C = “喜欢编程”，总人数 $n = 30$ 。

已知： $|M| = 18$ ， $|C| = 15$ ， $|MC| = 8$

(1) 容斥原理： $|M \cup C| = 18 + 15 - 8 = 25$

$$P(M \cup C) = \frac{25}{30} = \frac{5}{6} \approx 0.833$$

(2) 两者都不喜欢 = $\overline{M \cup C}$:

$$P(\overline{M \cup C}) = 1 - \frac{25}{30} = \frac{5}{30} = \frac{1}{6} \approx 0.167$$

(3) 只喜欢数学 = $M - C = M\bar{C}$: $|M - C| = |M| - |MC| = 18 - 8 = 10$

$$P(M\bar{C}) = \frac{10}{30} = \frac{1}{3} \approx 0.333$$

习题 1.4 详解

3 封信投入 3 个信箱，总方案数 $|\Omega| = 3^3 = 27$ （每封信 3 种选择，独立）。

(1) “3 个信箱各有 1 封信”相当于 3 封信与 3 个信箱的全排列：

$$|A| = 3! = 6$$

$$P(A) = \frac{6}{27} = \frac{2}{9} \approx 0.222$$

(2) “恰好有 1 个信箱为空”：先选哪 1 个信箱为空 ($\binom{3}{1} = 3$ 种)，剩余 2 个信箱各至少有 1 封信，且信箱之间不同时为空。

3 封信投 2 个信箱，各箱至少 1 封：总投法 $2^3 = 8$ ，两箱都空（不可能），只有一箱非空：2 种。

各至少有 1 封： $8 - 2 = 6$ 种。

$$|B| = 3 \times 6 = 18$$

$$P(B) = \frac{18}{27} = \frac{2}{3} \approx 0.667$$

(3) “至少有 1 个信箱为空”= 对立事件“3 个信箱都不空”的补：

$$P(\text{至少 1 个空}) = 1 - P(\text{全不空}) = 1 - \frac{6}{27} = 1 - \frac{2}{9} = \frac{7}{9} \approx 0.778$$

习题 1.5 详解

(1) 直接由题设：Adam 每次达标概率为 $P(A_i) = 0.8$ 。

这是概率的直接给定，无需计算。若用频率角度理解：若大量重复训练，约 80% 次能达标。

(2) $A_1 \cap A_2$ = “第 1 次和第 2 次都达标”。

此处假设各次训练独立（后续独立性章节将严格定义）：

$$P(A_1 \cap A_2) = P(A_1) \times P(A_2) = 0.8 \times 0.8 = 0.64$$

用容斥原理验证思路： $P(A_1 \cup A_2) = 0.8 + 0.8 - 0.64 = 0.96$ ，这是“至少一次达标”的概率，符合直觉（应该大于单次 0.8）。

(3) “10 次中至少 1 次达标”的集合表示：

$$D = \bigcup_{i=1}^{10} A_i = A_1 \cup A_2 \cup \dots \cup A_{10}$$

对立事件 $\bar{D}$ = “10 次全部未达标”：

$$\bar{D} = \overline{\bigcup_{i=1}^{10} A_i} = \bigcap_{i=1}^{10} \bar{A}_i = \bar{A}_1 \cap \bar{A}_2 \cap \dots \cap \bar{A}_{10}$$

即“每一次都未达标”。由德摩根定律，“至少一个发生”的对立事件是“每个都不发生”。

(数值参考： $P(\bar{D}) = 0.2^{10} \approx 1.024 \times 10^{-7}$ ，几乎不可能全部失败。)

几何示意

图 1-1: Venn 图（事件运算与补集）

图 1-2: 古典概型 vs 几何概型




图 1: Venn 图：A、B、 $A \cup B$ 、 $A \cap B$ 与补集




图 2: 古典概型（骰子）vs 几何概型（圆盘）对比

思考路标（条件反射）

- 看到“随机试验”→ 立刻列出样本空间 Ω （不列全则概率算错）
- 看到“事件运算”→ 翻译成集合语言：并 $\cup$ 、交 $\cap$ 、补 $\bar{\cdot}$
- 看到“概率三公理”→ 非负 / 规范 $P(\Omega) = 1$ / 可列可加（互斥才可加！）
- 看到“有限等可能”→ 古典概型： $P(A) = |A|/|\Omega|$
- 看到“连续区域上的随机点”→ 几何概型： $P(A) = \mu(A)/\mu(\Omega)$ （选对度量：长度 / 面积 / 体积）
- 看到“独立 vs 互斥”→ 独立： $P(AB) = P(A)P(B)$ ；互斥： $P(AB) = 0$ （两者不同！）
- 看到“至少一个”/“至多一个”→ 优先用对立事件（正难则反）
- 看到“ $P(A \cup B)$ ”→ 容斥公式 $P(A) + P(B) - P(AB)$ ；单调性 $A \subseteq B \Rightarrow P(A) \leq P(B)$

易错点

1. 独立和互斥常混淆：互斥意味着不能同时发生（ $P(AB) = 0$ ），独立意味着互不影响（ $P(AB) = P(A)P(B)$ ）；正概率事件若互斥则必不独立。
2. 概率不能随意相加： $P(A \cup B) = P(A) + P(B)$ 仅在 A, B 互斥时成立；一般情形须减去 $P(AB)$ 。
3. 几何概型选错度量：问题涉及“长度”用长度，涉及“面积”用面积，选错度量则结果错误。
4. 样本空间未列全：古典概型中遗漏样本点会导致概率偏大或偏小，务必穷举或用乘法原理计总数。
5. 概率值范围 $[0, 1]$ ：计算结果若超出此范围必然出错，可用于自检。

第2章：条件概率与独立性

一例速记：- $P(B|A) = P(AB)/P(A)$ - 链式： $P(ABC) = P(A)P(B|A)P(C|AB)$ - 全概率：
 $P(B) = \sum_i P(A_i)P(B|A_i)$ - 贝叶斯（由果求因）： $P(A_k|B) = \frac{P(A_k)P(B|A_k)}{P(B)}$ - 独立 $\neq$ 互斥：
 独立 $P(AB) = P(A)P(B)$ ；互斥 $P(AB) = 0$

引入题

某病发病率 1%，检测灵敏度 95%（真有诊出阳）、特异度 90%（无病诊出阴）。某人检测阳性，求实际患病概率。

思维路径还原

识别题型：已知“检测阳性”这个结果，求“实际患病”这个原因的概率——典型的“由果求因”，用贝叶斯公式。

设 $A = \text{患病}$ ， $B = \text{检测阳性}$ 。

给出先验： $P(A) = 0.01$ ， $P(\bar{A}) = 0.99$ 。

灵敏度是真有患病时检出阳性的概率： $P(B|A) = 0.95$ 。

特异度 90% 是无病时检出阴性的概率，故假阳性率： $P(B|\bar{A}) = 1 - 0.90 = 0.10$ 。

第一步，全概率公式算分母 $P(B)$ （阳性总概率）：

$$P(B) = P(A)P(B|A) + P(\bar{A})P(B|\bar{A}) = 0.01 \times 0.95 + 0.99 \times 0.10 = 0.0095 + 0.0990 = 0.1085$$

第二步，贝叶斯公式算分子 / 分母：

$$P(A|B) = \frac{P(A)P(B|A)}{P(B)} = \frac{0.0095}{0.1085} \approx 8.76\%$$

反直觉警报：检测阳性后，实际患病概率仍不足 9%！背后原因是低先验（发病率仅 1%）放大了假阳性：1000 人中约有 10 名患者，995 名健康人中有约 99.5 人假阳性，真阳性仅约 9.5 人。

启示：低先验下，单次阳性结果的多数是假阳性；提高检测价值需提升特异度或针对高危人群检测（提升先验）。

学习目标

学完本章后，你将能够：

- 理解条件概率的定义与直觉含义，正确计算 $P(A|B)$
 - 掌握乘法公式与链式法则，分解多事件的联合概率
 - 运用全概率公式处理复杂的分情况概率计算
 - 理解并应用贝叶斯公式进行“逆向推断”（从结果到原因）
 - 区分事件的独立性与互斥性，理解两两独立与相互独立的区别
-

2.1 条件概率的定义

直觉引入

假设你知道今天已经下雨，请问“路上堵车”的概率是多少？这与你不知道天气时的估计不同——额外的信息改变了你的判断。

条件概率正是刻画“在已知某事件发生的前提下，另一事件发生的概率”。

正式定义

设 B 为样本空间 Ω 中的一个事件，且 $P(B) > 0$ ，则在事件 B 发生的条件下，事件 A 发生的条件概率定义为：

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$

几何直觉：将 B 视为“缩小后的新样本空间”， $A \cap B$ 是这个新空间中 A 所占的部分。条件概率就是在新空间中重新归一化后的概率。

$$\underbrace{P(A | B)}_{\text{条件概率}} = \frac{\overbrace{P(A \cap B)}^{A \text{ 与 } B \text{ 同时发生}}}{\underbrace{P(B)}_{\text{归一化因子}}}$$

示例：医疗检测

一种疾病在人群中的患病率为 1%，某检测的灵敏度（真阳性率）为 99%，特异度（真阴性率）为 95%。

设事件：- D ：患病， $P(D) = 0.01$ - +：检测阳性

已知： $P(+|D) = 0.99$ ， $P(+|\bar{D}) = 0.05$

问：已知某人检测阳性，他真正患病的概率是多少？

这个问题需要贝叶斯公式来解答，我们在 2.4 节详细讨论。

条件概率的性质

条件概率 $P(\cdot | B)$ 本身也是一个合法的概率测度，满足概率的全部公理：

1. 非负性： $P(A | B) \geq 0$
2. 规范性： $P(\Omega | B) = 1$
3. 可列可加性：若 $A_1, A_2, \dots$ 两两互斥，则

$$P\left(\bigcup_{i=1}^{\infty} A_i \middle| B\right) = \sum_{i=1}^{\infty} P(A_i | B)$$

2.2 乘法公式

基本乘法公式

由条件概率的定义直接变形，得到乘法公式（multiplication rule）：

$$P(A \cap B) = P(A | B) \cdot P(B) = P(B | A) \cdot P(A)$$

含义：两个事件同时发生的概率，等于其中一个发生的概率乘以在该事件已发生前提下另一个发生的概率。

链式法则（Chain Rule）

乘法公式可以推广到多个事件，称为链式法则：

$$P(A_1 \cap A_2 \cap \dots \cap A_n) = P(A_1) \cdot P(A_2 | A_1) \cdot P(A_3 | A_1 \cap A_2) \dots P(A_n | A_1 \cap \dots \cap A_{n-1})$$

简记为：

$$P\left(\bigcap_{i=1}^n A_i\right) = \prod_{i=1}^n P\left(A_i \middle| \bigcap_{j=1}^{i-1} A_j\right)$$

其中 $P(A_1 | \emptyset) \triangleq P(A_1)$ 。

注：链式法则在语言模型中至关重要。一段文本 $w_1 w_2 \dots w_n$ 的概率被分解为：

$$P(w_1, w_2, \dots, w_n) = P(w_1) \cdot P(w_2 | w_1) \cdot P(w_3 | w_1, w_2) \dots P(w_n | w_1, \dots, w_{n-1})$$

这正是自回归语言模型（如 GPT）的核心概率建模思路。

示例：抽签问题

袋中有 5 张签，其中 2 张中签。甲先抽，乙后抽（不放回），乙中签的概率是多少？

设 A ：甲中签， B ：乙中签。

$$P(B) = P(B | A)P(A) + P(B | \bar{A})P(\bar{A})$$

$$= \frac{1}{4} \cdot \frac{2}{5} + \frac{2}{4} \cdot \frac{3}{5} = \frac{2}{20} + \frac{6}{20} = \frac{8}{20} = \frac{2}{5}$$

乙中签的概率与甲相同！这说明抽签的公平性与抽取顺序无关。

2.3 全概率公式

划分的概念

若事件 $B_1, B_2, \dots, B_n$ 满足：

1. 互斥： $B_i \cap B_j = \emptyset$ ($i \neq j$)
2. 完备： $B_1 \cup B_2 \cup \dots \cup B_n = \Omega$
3. 正概率： $P(B_i) > 0$ ($i = 1, \dots, n$)

则称 $\{B_1, B_2, \dots, B_n\}$ 为样本空间 Ω 的一个完备事件组（或划分）。

全概率公式

对样本空间的任意划分 $\{B_1, \dots, B_n\}$ 和任意事件 A ：

$$P(A) = \sum_{i=1}^n P(A | B_i) \cdot P(B_i)$$

直觉：将复杂事件 A 按“原因”分情况讨论——每种原因 B_i 发生的概率为 $P(B_i)$ ，在该原因下 A 发生的概率为 $P(A|B_i)$ ，对所有可能原因求加权平均。

Ω

$B_1 \quad B_2 \quad B_3$
 $\leftarrow A|B_1, A|B_2, A|B_3$

$$P(A) = P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + P(A|B_3)P(B_3)$$

示例：产品质量检验

工厂有三条生产线，各生产该产品的 30%、45%、25%，次品率分别为 2%、3%、5%。

随机抽取一件产品，是次品的概率？

设 B_i ：来自第 i 条生产线， A ：次品。

$$P(A) = P(A | B_1)P(B_1) + P(A | B_2)P(B_2) + P(A | B_3)P(B_3)$$

$$\begin{aligned} &= 0.02 \times 0.30 + 0.03 \times 0.45 + 0.05 \times 0.25 \\ &= 0.006 + 0.0135 + 0.0125 = 0.032 \end{aligned}$$

次品率约为 3.2%。

2.4 贝叶斯公式

从”果”到”因”的推断

全概率公式计算的是”已知原因，求结果的概率”；而贝叶斯公式解决的是反向问题：已知结果，推断原因的概
率。

贝叶斯公式

设 $\{B_1, \dots, B_n\}$ 为 Ω 的划分， A 为任意正概率事件，则：

$$P(B_i \mid A) = \frac{P(A \mid B_i) \cdot P(B_i)}{\sum_{j=1}^n P(A \mid B_j) \cdot P(B_j)}$$

三个关键量的统计学命名：

名称	符号	含义
先验概率（prior）	$P(B_i)$	在观测到 A 之前，对 B_i 的初始判 断
似然（likelihood）	$P(A \mid B_i)$	在 B_i 为真时，观测到 A 的概率
后验概率（posterior）	$P(B_i \mid A)$	观测到 A 之后，对 B_i 的更新判断

$$\underbrace{P(B_i \mid A)}_{\text{后验}} \propto \underbrace{P(A \mid B_i)}_{\text{似然}} \times \underbrace{P(B_i)}_{\text{先验}}$$

这一关系常被概括为：“后验 $\propto$ 似然 $\times$ 先验”。

示例：回到医疗检测

接续 2.1 节的问题：

$$P(D | +) = \frac{P(+ | D) \cdot P(D)}{P(+ | D) \cdot P(D) + P(+ | \bar{D}) \cdot P(\bar{D})}$$

$$= \frac{0.99 \times 0.01}{0.99 \times 0.01 + 0.05 \times 0.99} = \frac{0.0099}{0.0099 + 0.0495} \approx 0.167$$

结论：即使检测阳性，真正患病的概率仅约 16.7% !

这个反直觉的结果源于基率 (**base rate**) 的稀疏性——患病率仅 1%，大量假阳性“淹没”了真阳性信号。这一现象称为基率谬误 (base rate fallacy)。

贝叶斯更新 (Sequential Updating)

贝叶斯公式支持序贯更新：将前一次的后验作为下一次的先验，反复迭代。

$$P(H | \text{数据}_1) \xrightarrow{\text{新数据}_2} P(H | \text{数据}_1, \text{数据}_2) \xrightarrow{\text{新数据}_3} \dots$$

这是贝叶斯统计的核心思想，也是贝叶斯深度学习的理论基础。

2.5 事件的独立性

独立性的定义

若两个事件 A 、 B 满足：

$$P(A \cap B) = P(A) \cdot P(B)$$

则称 A 与 B 相互独立。

等价条件 (当 $P(B) > 0$ 时)：

$$P(A | B) = P(A)$$

即：知道 B 发生与否，不改变 A 发生的概率。

注意：独立性与互斥性是两个不同的概念！

	互斥 (Mutually Exclusive)	独立 (Independent)
定义	$A \cap B = \emptyset$	$P(A \cap B) = P(A)P(B)$
含义	不能同时发生	互不影响
关系	若 $P(A), P(B) > 0$, 则互斥必不独立	独立的正概率事件必不互斥

两两独立 vs 相互独立

对于多个事件，独立性存在强弱之分：

两两独立 (pairwise independence)：任意两个事件独立，即对所有 $i \neq j$ ：

$$P(A_i \cap A_j) = P(A_i)P(A_j)$$

相互独立 (mutual independence)：对所有子集 $\{i_1, \dots, i_k\} \subseteq \{1, \dots, n\}$ ($k \geq 2$)：

$$P(A_{i_1} \cap A_{i_2} \cap \dots \cap A_{i_k}) = P(A_{i_1}) \cdot P(A_{i_2}) \dots P(A_{i_k})$$

重要：两两独立 $\nRightarrow$ 相互独立！

反例 (Bernstein)：投掷两枚均匀硬币，令： - A ：第一枚正面 - B ：第二枚正面 - C ：两枚结果相同

计算验证： $P(A) = P(B) = P(C) = \frac{1}{2}$, $P(A \cap B) = P(A \cap C) = P(B \cap C) = \frac{1}{4}$, 故 A, B, C 两两独立。

但 $P(A \cap B \cap C) = \frac{1}{4} \neq \frac{1}{8} = P(A)P(B)P(C)$, 故三者不相互独立。

独立性的实际意义

- 若 $A_1, \dots, A_n$ 相互独立，则它们同时发生的概率为各自概率之积：

$$P\left(\bigcap_{i=1}^n A_i\right) = \prod_{i=1}^n P(A_i)$$

- 独立随机变量的联合分布等于边缘分布之积（将在后续章节深入讨论）。
- 独立性假设大大简化了概率计算，是朴素贝叶斯分类器等算法的核心假设。

本章小结

概念	公式	记忆要点
条件概率	$P(A B) = P(A \cap B)/P(B)$	缩小样本空间，重新归一化
乘法公式	$P(A \cap B) = P(A B)P(B)$	由条件概率变形而来
链式法则	$P(\bigcap A_i) = \prod P(A_i A_1 \cdots A_{i-1})$	语言模型的核心分解
全概率公式	$P(A) = \sum P(A B_i)P(B_i)$	按”原因”加权平均
贝叶斯公式	$P(B_i A) \propto P(A B_i)P(B_i)$	后验 $\propto$ 似然 $\times$ 先验
独立性	$P(A \cap B) = P(A)P(B)$	互不影响，注意区分互斥

核心思维方式：贝叶斯公式提供了一种理性更新信念的框架——面对新证据，以先验为出发点，通过似然调整，得到后验。这是科学推断的数学基础。

深度学习应用：贝叶斯神经网络与先验后验

从参数估计到贝叶斯推断

标准神经网络训练的目标是找到一组固定的最优参数 θ^* ：

$$\theta^* = \arg \max_{\theta} \log P(\mathcal{D} \mid \theta)$$

这是最大似然估计（MLE）。然而，这种方法有两个局限：

- 1. 无法量化参数的不确定性
- 2. 容易在小数据集上过拟合

贝叶斯神经网络（Bayesian Neural Network, BNN）将参数视为随机变量，用概率分布而非点估计来描述参数：

$$P(\theta \mid \mathcal{D}) = \frac{P(\mathcal{D} \mid \theta) \cdot P(\theta)}{P(\mathcal{D})}$$

其中： - $P(\theta)$ ：先验分布——训练前对参数的信念（如 $\theta \sim \mathcal{N}(0, \sigma^2 I)$ ） - $P(\mathcal{D} \mid \theta)$ ：似然——参数为 θ 时观测到数据的概率 - $P(\theta \mid \mathcal{D})$ ：后验分布——训练后对参数的信念 - $P(\mathcal{D})$ ：边缘似然（model evidence）——归一化常数

先验与正则化的联系

高斯先验 $P(\theta) = \mathcal{N}(0, \sigma^2 I)$ 对应于 **L2 正则化**（权重衰减）！

推导：最大后验估计（MAP）：

$$\begin{aligned}\theta^{\text{MAP}} &= \arg \max_{\theta} \log P(\theta \mid \mathcal{D}) \\ &= \arg \max_{\theta} [\log P(\mathcal{D} \mid \theta) + \log P(\theta)] \\ &= \arg \max_{\theta} \left[\log P(\mathcal{D} \mid \theta) - \frac{\|\theta\|^2}{2\sigma^2} \right] \\ &= \arg \min_{\theta} \left[\mathcal{L}(\theta) + \underbrace{\frac{1}{2\sigma^2}}_{\lambda} \|\theta\|^2 \right]\end{aligned}$$

这正是带 **L2** 正则化的损失函数！正则化系数 $\lambda = 1/(2\sigma^2)$ 对应先验的精度。

拉普拉斯先验 $P(\theta) \propto \exp(-|\theta|/b)$ 则对应 **L1** 正则化（稀疏解）。

先验分布	对应正则化	效果
高斯 $\mathcal{N}(0, \sigma^2)$	L2（权重衰减）	参数趋近于零，平滑解
拉普拉斯 $\text{Laplace}(0, b)$	L1（LASSO）	参数稀疏化
均匀分布	无正则化	等价于 MLE

预测与不确定性量化

贝叶斯预测通过对后验积分，得到预测分布：

$$P(y^* \mid x^*, \mathcal{D}) = \int P(y^* \mid x^*, \theta) \cdot P(\theta \mid \mathcal{D}) d\theta$$

这个积分通常难以解析计算（因为神经网络是非线性的），实践中常用近似方法：

- 变分推断（Variational Inference）：用简单分布 $q(\theta)$ 近似后验
- 马尔可夫链蒙特卡洛（MCMC）：采样得到后验样本
- **MC Dropout**：训练时和推断时都使用 Dropout，以多次前向传播的方差估计不确定性

PyTorch 代码示例：MC Dropout 近似贝叶斯推断

```
import torch
import torch.nn as nn
import torch.nn.functional as F
import numpy as np
import matplotlib.pyplot as plt
```

1. 定义带 *Dropout* 的贝叶斯网络

```
class BayesianMLP(nn.Module):
```

```
    """
```

使用 *MC Dropout* 近似贝叶斯神经网络。

关键：推断时保持 *Dropout* 开启 (*train* 模式)，多次采样来估计不确定性。

```
    """
```

```
    def __init__(self, input_dim: int, hidden_dim: int, output_dim: int, dropout_p: float = 0.1):
```

```
        super().__init__()
```

```
        self.fc1 = nn.Linear(input_dim, hidden_dim)
```

```
        self.fc2 = nn.Linear(hidden_dim, hidden_dim)
```

```
        self.fc3 = nn.Linear(hidden_dim, output_dim)
```

```
        self.dropout = nn.Dropout(p=dropout_p)
```

```
    def forward(self, x: torch.Tensor) -> torch.Tensor:
```

```
        x = F.relu(self.dropout(self.fc1(x)))
```

```
        x = F.relu(self.dropout(self.fc2(x)))
```

```
        return self.fc3(x)
```

```
def mc_predict(model: BayesianMLP, x: torch.Tensor, n_samples: int = 100) -> tuple:
```

```
    """
```

MC Dropout 推断：

- 将模型置于 *train* 模式以启用 *Dropout*
- 多次前向传播，每次 *Dropout* 随机遮蔽不同神经元
- 返回预测的均值（期望后验预测）和标准差（不确定性）

```
    """
```

```
    model.train() # 保持 Dropout 激活
```

```
    predictions = []
```

```
    with torch.no_grad():
```

```
        for _ in range(n_samples):
```

```
            pred = model(x) # 每次调用使用不同的 Dropout mask
```

```
            predictions.append(pred)
```

```
    predictions = torch.stack(predictions, dim=0) # shape: [n_samples, batch, output]
```

后验预测均值：对应贝叶斯积分 $P(y|x,)P(D) d$ 的蒙特卡洛近似

```
    mean = predictions.mean(dim=0)
```

预测标准差：量化认知不确定性 (*epistemic uncertainty*)

```
std = predictions.std(dim=0)

return mean, std

# 2. 生成合成回归数据
torch.manual_seed(42)
np.random.seed(42)

# 训练数据：两段区间，中间有间隙（用于检验间隙处的不确定性）
x_train_1 = torch.linspace(-3, -1, 50).unsqueeze(1)
x_train_2 = torch.linspace(1, 3, 50).unsqueeze(1)
x_train = torch.cat([x_train_1, x_train_2], dim=0)

# 真实函数：  $y = \sin(x) + \text{噪声}$ 
y_train = torch.sin(x_train) + 0.1 * torch.randn_like(x_train)

# 3. 训练模型
model = BayesianMLP(input_dim=1, hidden_dim=64, output_dim=1, dropout_p=0.1)

# L2 正则化 (weight_decay) 对应高斯先验  $P() = N(0, 1/\text{weight\_decay} * I)$ 
optimizer = torch.optim.Adam(model.parameters(), lr=1e-3, weight_decay=1e-3)

for epoch in range(1000):
    model.train()
    optimizer.zero_grad()
    pred = model(x_train)
    loss = F.mse_loss(pred, y_train)
    loss.backward()
    optimizer.step()

print(f" 训练损失: {loss.item():.4f}")

# 4. 预测与不确定性可视化
x_test = torch.linspace(-4, 4, 200).unsqueeze(1)
mean_pred, std_pred = mc_predict(model, x_test, n_samples=200)

mean_np = mean_pred.squeeze().numpy()
std_np = std_pred.squeeze().numpy()
```

```

x_np = x_test.squeeze().numpy()

plt.figure(figsize=(10, 5))
plt.scatter(x_train.numpy(), y_train.numpy(), s=10, c='black', zorder=5, label='训练数据')
plt.plot(x_np, np.sin(x_np), 'g--', label='真实函数 sin(x)', linewidth=1.5)
plt.plot(x_np, mean_np, 'b-', label='后验预测均值', linewidth=2)

# 不确定性区间 (±2 95% 置信区间)
plt.fill_between(x_np, mean_np - 2 * std_np, mean_np + 2 * std_np,
                 alpha=0.3, color='blue', label='±2 不确定性区间')

plt.axvspan(-1, 1, alpha=0.1, color='red', label='数据间隙 (高不确定性)')
plt.legend()
plt.title('MC Dropout 贝叶斯神经网络：预测均值与不确定性')
plt.xlabel('x')
plt.ylabel('y')
plt.tight_layout()
plt.savefig('bayesian_nn_uncertainty.png', dpi=150)
plt.show()

# 5. 验证贝叶斯性质
# 数据区域内的不确定性应低于间隙区域
in_data_mask = (x_np < -1) | (x_np > 1)
gap_mask = (x_np >= -1) & (x_np <= 1)

print(f" 数据区域平均不确定性 (std) : {std_np[in_data_mask].mean():.4f}")
print(f" 数据间隙平均不确定性 (std) : {std_np[gap_mask].mean():.4f}")
print(" 间隙处不确定性更高，符合贝叶斯神经网络的预期行为！")

```

变分推断的基本思想

由于后验 $P(\theta|\mathcal{D})$ 通常难以直接计算，变分推断通过最小化变分分布 $q_\phi(\theta)$ 与真实后验的 KL 散度来近似：

$$\phi^* = \arg \min_{\phi} \text{KL} [q_\phi(\theta) \| P(\theta | \mathcal{D})]$$

等价地，最大化证据下界 (ELBO)：

$$\mathcal{L}(\phi) = \underbrace{\mathbb{E}_{q_\phi(\theta)}[\log P(\mathcal{D} | \theta)]}_{\text{期望对数似然 (拟合度)}} - \underbrace{\text{KL}[q_\phi(\theta) \| P(\theta)]}_{\text{先验与变分分布的差异 (正则项)}}$$

这两项分别对应：模型对训练数据的拟合和参数分布对先验的偏离程度。贝叶斯框架自然地平衡了拟合与复杂度。

认知不确定性 vs 偶然不确定性

贝叶斯神经网络能区分两类不确定性：

- 认知不确定性 (Epistemic Uncertainty)：来源于训练数据不足，可通过收集更多数据减少。对应模型参数的不确定性。
- 偶然不确定性 (Aleatoric Uncertainty)：来源于数据本身的噪声，无法通过更多数据消除。

$$\underbrace{\text{Var}[y^* \mid x^*, \mathcal{D}]}_{\text{总不确定性}} = \underbrace{\text{Var}_\theta[\mathbb{E}[y^* \mid \theta]]}_{\text{认知不确定性}} + \underbrace{\mathbb{E}_\theta[\text{Var}[y^* \mid \theta]]}_{\text{偶然不确定性}}$$

这种区分在自动驾驶、医疗 AI 等安全关键场景中极为重要。

练习题

题 1（基础）一个袋子里有 4 个红球和 6 个蓝球，不放回地依次取出两个球。

- (a) 已知第一个球是红球，第二个球也是红球的概率是多少？
- (b) 两个球都是红球的概率是多少？

题 2（全概率公式）某工厂生产的零件由三台机器完成：机器 A 生产 50%，机器 B 生产 30%，机器 C 生产 20%；各机器的次品率分别为 1%、2%、3%。

- (a) 随机抽取一个零件，是次品的概率是多少？
- (b) 已知抽到的是次品，它来自机器 A 的概率是多少？

题 3（贝叶斯定理）某病毒检测试剂盒的灵敏度（真阳性率）为 95%，特异度（真阴性率）为 90%。假设该病毒在某地区的感染率为 0.5%。

- (a) 某人随机检测结果为阳性，他真正感染的概率是多少？
- (b) 如果某人属于高风险人群，感染率估计为 10%，阳性时真正感染的概率又是多少？
- (c) 这两个结果说明了什么？对检测策略有什么启示？

题4 (独立性) 设事件 A 和 B 相互独立, $P(A) = 0.3$, $P(B) = 0.4$ 。

- (a) 计算 $P(A \cup B)$ 。
 - (b) 计算 $P(A | B^c)$ (B^c 表示 B 的补事件)。
 - (c) 证明: 若 A 和 B 独立, 则 A 和 B^c 也独立。
-

题5 (综合应用) 某 AI 系统对图像进行分类, 共有三个类别: 猫 (Cat)、狗 (Dog)、其他 (Other), 先验概率分别为 $P(C) = 0.3$, $P(D) = 0.5$, $P(O) = 0.2$ 。

已知该系统给出“置信度高”信号的条件概率为: $P(\text{高} | C) = 0.8$, $P(\text{高} | D) = 0.7$, $P(\text{高} | O) = 0.4$ 。

- (a) 随机输入一张图片, 系统给出“高置信度”信号的概率是多少?
 - (b) 已知系统给出高置信度信号, 图片是猫的概率是多少?
 - (c) 假设系统在高置信度下的分类准确率为 90% (无论类别), 这是否改变你对 (b) 的理解?
-

练习答案

题1 详细解答

设 R_1 : 第一个球是红球, R_2 : 第二个球是红球。

(a) 条件概率 $P(R_2 | R_1)$

已知第一个是红球, 袋中剩余 9 个球, 其中 3 个红球:

$$P(R_2 | R_1) = \frac{3}{9} = \frac{1}{3}$$

(b) 联合概率 $P(R_1 \cap R_2)$

使用乘法公式:

$$P(R_1 \cap R_2) = P(R_2 | R_1) \cdot P(R_1) = \frac{1}{3} \times \frac{4}{10} = \frac{4}{30} = \frac{2}{15} \approx 0.133$$

也可直接计算: 从 10 个球中不放回取 2 个的总方案数为 $\binom{10}{2} = 45$, 两个都是红球的方案数为 $\binom{4}{2} = 6$, 故概率为 $6/45 = 2/15$ 。两种方法一致。

题2 详细解答

设 A, B, C : 来自对应机器; D : 次品。

(a) 全概率公式

$$P(D) = P(D | A)P(A) + P(D | B)P(B) + P(D | C)P(C)$$

$$= 0.01 \times 0.50 + 0.02 \times 0.30 + 0.03 \times 0.20$$

$$= 0.005 + 0.006 + 0.006 = 0.017$$

次品率为 1.7%。

(b) 贝叶斯公式

$$P(A | D) = \frac{P(D | A) \cdot P(A)}{P(D)} = \frac{0.01 \times 0.50}{0.017} = \frac{0.005}{0.017} \approx 0.294$$

即已知是次品，来自机器 A 的概率约为 29.4%。

验证： $P(B | D) = 0.006/0.017 \approx 35.3\%$ ， $P(C | D) = 0.006/0.017 \approx 35.3\%$ ，三者之和为 100%，正确。

洞察：尽管机器 A 产量最大（50%），但其次品率最低，导致次品来自 A 的概率（29.4%）低于 A 的产量占比（50%）。

题 3 详细解答

设 I ：感染； $+$ ：检测阳性。

已知： $P(+ | I) = 0.95$ ， $P(- | \bar{I}) = 0.90$ ，故 $P(+ | \bar{I}) = 0.10$ 。

(a) 感染率 $P(I) = 0.005$

$$P(+) = P(+ | I)P(I) + P(+ | \bar{I})P(\bar{I})$$

$$= 0.95 \times 0.005 + 0.10 \times 0.995 = 0.00475 + 0.0995 = 0.10425$$

$$P(I | +) = \frac{0.95 \times 0.005}{0.10425} = \frac{0.00475}{0.10425} \approx 4.6\%$$

(b) 高风险人群 $P(I) = 0.10$

$$P(+) = 0.95 \times 0.10 + 0.10 \times 0.90 = 0.095 + 0.090 = 0.185$$

$$P(I | +) = \frac{0.95 \times 0.10}{0.185} = \frac{0.095}{0.185} \approx 51.4\%$$

(c) 分析与启示

结论对比：

人群	先验 $P(I)$	阳性后验 $P(I +)$
一般人群	0.5%	4.6%
高风险人群	10%	51.4%

启示：1. 先验（基率）极大地影响后验：同样的检测，阳性结果对一般人群几乎不说明什么（4.6%），但对高风险人群意义重大（51.4%）。2. 检测策略：大规模筛查低风险人群会产生大量假阳性，造成资源浪费和心理恐慌；靶向检测高风险人群才能使阳性结果真正有诊断价值。3. 这解释了为什么公共卫生政策通常优先对高风险群体（接触史、症状等）进行检测。

题 4 详细解答

已知 A, B 独立, $P(A) = 0.3, P(B) = 0.4$ 。

(a) $P(A \cup B)$

由容斥原理：

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

由独立性, $P(A \cap B) = P(A) \cdot P(B) = 0.3 \times 0.4 = 0.12$, 故：

$$P(A \cup B) = 0.3 + 0.4 - 0.12 = 0.58$$

(b) $P(A \mid B^c)$

由 (c) 的结论, A 和 B^c 也独立, 因此：

$$P(A \mid B^c) = P(A) = 0.3$$

(c) 证明 A 与 B^c 独立

需证 $P(A \cap B^c) = P(A) \cdot P(B^c)$ 。

$$P(A \cap B^c) = P(A) - P(A \cap B) \quad (\text{因为 } A = (A \cap B) \cup (A \cap B^c), \text{ 互斥})$$

$$= P(A) - P(A) \cdot P(B) \quad (\text{由 } A, B \text{ 独立})$$

$$= P(A)(1 - P(B)) = P(A) \cdot P(B^c)$$

证毕。这说明若 A 与 B 独立，则 A 与 B^c 、 A^c 与 B 、 A^c 与 B^c 均独立。

题5详细解答

设 C ：猫， D ：狗， O ：其他， H ：高置信度。

(a) 全概率公式

$$P(H) = P(H | C)P(C) + P(H | D)P(D) + P(H | O)P(O)$$

$$= 0.8 \times 0.3 + 0.7 \times 0.5 + 0.4 \times 0.2$$

$$= 0.24 + 0.35 + 0.08 = 0.67$$

系统给出高置信度信号的概率为 67%。

(b) 贝叶斯公式

$$P(C | H) = \frac{P(H | C) \cdot P(C)}{P(H)} = \frac{0.8 \times 0.3}{0.67} = \frac{0.24}{0.67} \approx 35.8\%$$

高置信度信号下，图片是猫的后验概率约为 35.8%。

(c) 讨论

“系统在高置信度下的分类准确率为 90%”描述的是系统决策的正确性，而 (b) 求的是在高置信度信号下真正是猫的概率——这是两个不同的问题。

(b) 的结论说明：即使系统发出高置信度信号，也不能断定图片是猫（概率仅 35.8%），还需结合系统的具体分类输出（它说是猫还是狗）才能判断。

若系统在高置信度下还输出了“是猫”，则根据 90% 的准确率，真正是猫的概率会大幅提升。这说明：置信度信号和分类标签是两个互补的信息维度，应结合使用。

这正是贝叶斯框架的力量：精确追踪每一条证据对推断的贡献。

下一章预告：第3章：组合数学基础 — 我们将学习排列组合的计数方法，为计算古典概型中的复杂概率问题提供工具。

几何示意

图 2-1：贝叶斯频率树与假阳性对比




图 3: 贝叶斯反演频率树（1000 人）与阳性反差柱状图

图 2-2：独立 vs 互斥 Venn 对比




图 4: 独立 (Independent) vs 互斥 (Mutually Exclusive) Venn 图对比

思考路标（条件反射）

- 看到 $P(B|A) \rightarrow$ 公式： $P(AB)/P(A)$ ，分母 $P(A) > 0$
- 看到“依次发生多个事件的联合概率” $\rightarrow$ 链式公式： $P(ABC) = P(A)P(B|A)P(C|AB)$
- 看到“分情况（按原因）求某事件的总概率” $\rightarrow$ 全概率公式： $P(B) = \sum_i P(A_i)P(B|A_i)$
- 看到“已知结果，推原因概率” $\rightarrow$ 贝叶斯（由果求因）： 后验 $\propto$ 似然 $\times$ 先验
- 看到 $P(AB) = P(A)P(B) \rightarrow$ 独立；看到 $P(AB) = 0 \rightarrow$ 互斥（两者完全不同）
- 看到“先验 / 后验 / 似然” $\rightarrow$ 贝叶斯框架：先验经似然更新得后验
- 看到“阳性检测 + 低发病率” $\rightarrow$ 假阳性反直觉：低先验下大多数阳性是假阳性
- 看到多步随机试验 $\rightarrow$ 画树状图，叶节点概率 = 路径上各条件概率的乘积

易错点

1. 独立 $\neq$ 互斥（最常见混淆）：独立的两个正概率事件可以同时发生（ $P(AB) > 0$ ）；互斥事件必然不能同时发生（ $P(AB) = 0$ ），故正概率的互斥事件必不独立。
2. 条件概率分母 $P(A) \neq 0$ ： $P(B|A)$ 要求 $P(A) > 0$ ，若 $P(A) = 0$ 则条件概率无意义。
3. 链式公式顺序： $P(ABC) = P(A) \cdot P(B|A) \cdot P(C|AB)$ ，条件要逐步累积，顺序不可随意交换。
4. 贝叶斯反演方向：贝叶斯公式求 $P(\text{原因}|\text{结果})$ ，不能与 $P(\text{结果}|\text{原因})$ 混淆，两者通常差距极大。
5. 假阳性占多数（低发病率）：当先验 $P(\text{患病})$ 很小时，即使检测很准，阳性结果中假阳性仍占多数——务必用贝叶斯公式计算，不可凭直觉判断。

第3章：组合数学基础

学习目标

学完本章后，你应该能够：

- 熟练运用加法原理和乘法原理对复杂计数问题进行分解和求解
 - 区分有序和无序选取，正确计算排列数 $P(n, k)$ 与组合数 $\binom{n}{k}$ ，包括有重复的情形
 - 理解并应用二项式定理，熟悉帕斯卡三角形的递推结构
 - 掌握多项式系数的定义和计算，以及多项式定理的表述
 - 理解 Dropout 正则化的组合数学本质，将其解读为对指数级数量的子网络进行集成
-

正文内容

3.1 计数原理

计数是概率论的基础工具——古典概型中计算概率，本质上就是对有利结果与全体结果分别计数，再求比值。两条基本原理撑起了几乎所有计数技巧。

3.1.1 加法原理 定义（加法原理）若完成某件事有 m 类方法，第 i 类方法有 n_i 种，且各类方法互不相交（即任意两类中不存在相同的做法），则完成这件事共有

$$N = n_1 + n_2 + \cdots + n_m$$

种方法。

直觉：加法原理描述的是“或”——做 A 或做 B，两件事不能同时做，方案数直接相加。

例 3.1.1 从学校到图书馆可以乘坐 3 路公交或 5 路公交，3 路有 4 个班次，5 路有 6 个班次。则共有 $4 + 6 = 10$ 种出行方案。

3.1.2 乘法原理 定义（乘法原理）若完成某件事需要依次完成 k 个步骤，第 i 步有 n_i 种选择，且各步之间的选择相互独立，则完成这件事共有

$$N = n_1 \times n_2 \times \cdots \times n_k$$

种方法。

直觉：乘法原理描述的是“且”——先做 A 再做 B，两件事依次完成，方案数相乘。

例 3.1.2 一个密码由 1 位大写字母（26 种）和 3 位数字（各 10 种）组成，则共有 $26 \times 10 \times 10 \times 10 = 26\,000$ 种密码。

例 3.1.3（综合应用） 从 $\{1, 2, \dots, 9\}$ 中选数字组成三位数，要求百位为奇数，十位为偶数，个位任意（数字可重复）。

- 百位奇数：1, 3, 5, 7, 9，共 5 种
- 十位偶数：2, 4, 6, 8，共 4 种
- 个位任意：9 种

由乘法原理，共 $5 \times 4 \times 9 = 180$ 种。

3.2 排列

3.2.1 不重复排列 定义从 n 个不同元素中有序地选出 k 个元素 ($0 \leq k \leq n$)，称为 n 个元素取 k 个的排列，记作 $P(n, k)$ (也写作 A_n^k 或 ${}_nP_k$)。

$$P(n, k) = n \times (n-1) \times \cdots \times (n-k+1) = \frac{n!}{(n-k)!}$$

推导：第 1 个位置有 n 种选法，第 2 个位置有 $n-1$ 种 (已用一个)，……，第 k 个位置有 $n-k+1$ 种。由乘法原理连乘即得。

特殊情形：全排列 $P(n, n) = n!$ ，即 n 个不同元素的所有排列数。

约定 $0! = 1$ ，则 $P(n, 0) = 1$ (空排列只有一种)。

例 3.2.1 10 名选手参加比赛，前 3 名分别获得金、银、铜牌，有多少种颁奖方案？

$$P(10, 3) = \frac{10!}{7!} = 10 \times 9 \times 8 = 720$$

3.2.2 有重复的排列 定义从 n 个不同元素中有放回地有序选取 k 个，则共有

$$n^k$$

种排列 (每次选取均有 n 种选法，共选 k 次)。

例 3.2.2 4 位数字密码 (每位从 0-9 中选，可重复)，共 $10^4 = 10\,000$ 种。

3.2.3 多重集合的排列 若有 n 个元素，其中第 i 种元素有 n_i 个 ($\sum_{i=1}^k n_i = n$)，则将全部 n 个元素排成一列的方案数为

$$\frac{n!}{n_1! n_2! \cdots n_k!}$$

例 3.2.3 单词 MISSISSIPPI 共 11 个字母，其中 M 出现 1 次，I 出现 4 次，S 出现 4 次，P 出现 2 次，全排列数为

$$\frac{11!}{1! 4! 4! 2!} = \frac{39\,916\,800}{1 \times 24 \times 24 \times 2} = 34\,650$$

3.3 组合

3.3.1 组合数的定义 定义从 n 个不同元素中无序地选出 k 个元素，称为组合，记作

$$\binom{n}{k} = C_n^k = \frac{n!}{k!(n-k)!} \quad (0 \leq k \leq n)$$

与排列的关系： $P(n, k)$ 中每个组合对应 $k!$ 个排列（ k 个元素的内部全排列），因此

$$\binom{n}{k} = \frac{P(n, k)}{k!} = \frac{n!}{k!(n-k)!}$$

基本性质：

性质	公式	直觉
对称性	$\binom{n}{k} = \binom{n}{n-k}$	选 k 个等价于不选 $n - k$ 个
边界值	$\binom{n}{0} = \binom{n}{n} = 1$	全不选或全选只有一种
递推关系	$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$	帕斯卡恒等式，见 3.4 节
求和	$\sum_{k=0}^n \binom{n}{k} = 2^n$	每个元素独立地选或不选

例 3.3.1 从 52 张扑克牌中选 5 张，有多少种选法？

$$\binom{52}{5} = \frac{52!}{5!47!} = \frac{52 \times 51 \times 50 \times 49 \times 48}{5!} = 2\,598\,960$$

3.3.2 有重复的组合 定义从 n 种不同元素中有放回地无序选取 k 个（每种可选多个），称为重复组合，方案数为

$$\binom{n+k-1}{k}$$

推导（隔板法）：将 k 个球放入 n 个盒子（允许空盒），等价于在 k 个球之间及两端共 $k + 1$ 处空隙中插 $n - 1$ 块隔板。等价地，在 $k + (n - 1)$ 个位置中选 k 个放球，即 $\binom{n+k-1}{k}$ 。

例 3.3.2 便利店有 5 种饮料，买 3 瓶（可重复购买），有多少种方案？

$$\binom{5+3-1}{3} = \binom{7}{3} = 35$$

3.4 二项式定理

3.4.1 定理表述 定理（二项式定理）对任意实数 a, b 和非负整数 n ,

$$(a + b)^n = \sum_{k=0}^n \binom{n}{k} a^{n-k} b^k$$

组合证明：展开 $(a + b)^n$ 时，从 n 个因子 $(a + b)$ 中，每个因子选 a 或 b 。含 k 个 b （和 $n - k$ 个 a ）的项出现的次数，等于从 n 个因子中选 k 个取 b 的方案数，即 $\binom{n}{k}$ 。

因此， $\binom{n}{k}$ 又称二项式系数。

常用推论：

- 令 $a = b = 1$: $\sum_{k=0}^n \binom{n}{k} = 2^n$
- 令 $a = 1, b = -1$: $\sum_{k=0}^n (-1)^k \binom{n}{k} = 0$
- 令 $a = 1, b = x$: $(1 + x)^n = \sum_{k=0}^n \binom{n}{k} x^k$

例 3.4.1 展开 $(2x - y)^4$:

$$\begin{aligned} (2x - y)^4 &= \sum_{k=0}^4 \binom{4}{k} (2x)^{4-k} (-y)^k \\ &= 16x^4 - 4 \cdot 8x^3y + 6 \cdot 4x^2y^2 - 4 \cdot 2xy^3 + y^4 \\ &= 16x^4 - 32x^3y + 24x^2y^2 - 8xy^3 + y^4 \end{aligned}$$

3.4.2 帕斯卡三角形 帕斯卡三角形给出了所有二项式系数，其中第 n 行（从第 0 行起）是 $(a + b)^n$ 展开式的系数：

$$\begin{array}{ccccccc} & & & & 1 & & & \\ & & & & & 1 & & 1 \\ & & & 1 & & 2 & & 1 \\ & & 1 & & 3 & & 3 & & 1 \\ & 1 & & 4 & & 6 & & 4 & & 1 \\ 1 & & 5 & & 10 & & 10 & & 5 & & 1 \end{array}$$

帕斯卡恒等式（相邻两项之和等于下一行对应项）：

$$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$$

组合证明：从 n 个元素中选 k 个，固定元素 x ：- 包含 x ：从剩余 $n-1$ 个中再选 $k-1$ 个， $\binom{n-1}{k-1}$ 种 - 不包含 x ：从剩余 $n-1$ 个中选 k 个， $\binom{n-1}{k}$ 种

两类互斥，由加法原理得证。

3.5 多项式系数

3.5.1 多项式系数的定义 将 n 个不同元素划分成 r 组，第 i 组有 n_i 个元素 ($\sum_{i=1}^r n_i = n$)，方案数称为多项式系数：

$$\binom{n}{n_1, n_2, \dots, n_r} = \frac{n!}{n_1! n_2! \dots n_r!}$$

推导：先从 n 个中选 n_1 个给第 1 组，再从剩余 $n - n_1$ 个中选 n_2 个给第 2 组，……，由乘法原理：

$$\binom{n}{n_1} \binom{n-n_1}{n_2} \dots \binom{n_r}{n_r} = \frac{n!}{n_1! (n-n_1)!} \cdot \frac{(n-n_1)!}{n_2! (n-n_1-n_2)!} \dots = \frac{n!}{n_1! n_2! \dots n_r!}$$

注意 $r=2$ 时即退化为二项式系数 $\binom{n}{k, n-k} = \binom{n}{k}$ 。

3.5.2 多项式定理 定理（多项式定理）对非负整数 n 和任意实数 $x_1, x_2, \dots, x_r$,

$$(x_1 + x_2 + \dots + x_r)^n = \sum_{\substack{k_1, k_2, \dots, k_r \geq 0 \\ k_1 + k_2 + \dots + k_r = n}} \frac{n!}{k_1! k_2! \dots k_r!} x_1^{k_1} x_2^{k_2} \dots x_r^{k_r}$$

直觉：展开 $(x_1 + \dots + x_r)^n$ 时，每次从 n 个因子中选取一个 x_i ；恰好选了 k_i 次 x_i ($\sum k_i = n$) 的项，其系数就是将 n 个选择分配成各 k_i 个的方案数，即多项式系数。

推论：令所有 $x_i = 1$ ，得

$$r^n = \sum_{\substack{k_1 + \dots + k_r = n \\ k_i \geq 0}} \frac{n!}{k_1! \dots k_r!}$$

例 3.5.1 $(x + y + z)^3$ 中 $x^1 y^1 z^1$ 项的系数为

$$\binom{3}{1, 1, 1} = \frac{3!}{1! 1! 1!} = 6$$

本章小结

概念	公式	关键条件
加法原理	$N = n_1 + \cdots + n_m$	各类方法互斥
乘法原理	$N = n_1 \times \cdots \times n_k$	各步骤独立
排列（不重复）	$P(n, k) = \frac{n!}{(n - k)!}$	有序，不放回
排列（有重复）	n^k	有序，放回
多重集合排列	$\frac{n!}{n_1! \cdots n_k!}$	元素有重复类型
组合（不重复）	$\binom{n}{k} = \frac{n!}{k!(n - k)!}$	无序，不放回
组合（有重复）	$\binom{n + k - 1}{k}$	无序，放回
二项式定理	$(a + b)^n = \sum_k \binom{n}{k} a^{n-k} b^k$	—
帕斯卡恒等式	$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$	—
多项式系数	$\frac{n!}{n_1! \cdots n_r!}$	$\sum n_i = n$
多项式定理	$(x_1 + \cdots + x_r)^n = \sum \frac{n!}{k_1! \cdots k_r!} x_1^{k_1} \cdots x_r^{k_r}$	$\sum k_i = n$

核心思路：1. 先判断有序还是无序：有序用排列，无序用组合。2. 再判断有无重复：决定是否放回或使用隔板法。3. 分步用乘法，分类用加法：复杂问题先分解。4. $\sum_{k=0}^n \binom{n}{k} = 2^n$ 是贯穿全章的核心恒等式，深度学习应用正是由此出发。

深度学习应用：Dropout 的组合解释与集成学习

背景：什么是 Dropout

Dropout 由 Srivastava 等人于 2014 年提出，是深度学习中最常用的正则化手段之一。在训练时，对每一层的每个神经元，以概率 p （通常取 0.5）独立地将其输出置为 0（“丢弃”）；测试时则保留所有神经元，但将权重乘以 $1 - p$ 以保持期望不变。

组合数学解释：指数级数量的子网络

设一个全连接网络在某层有 n 个神经元，每次前向传播时，每个神经元独立地以概率 p 被丢弃。这等价于从 2^n 个子网络中随机采样一个：

子网络总数 = $\underbrace{2 \times 2 \times \cdots \times 2}_{n \text{ 个神经元}} = 2^n$

这正是二项式系数求和恒等式的直接体现：

$$2^n = \sum_{k=0}^n \binom{n}{k}$$

其中 $\binom{n}{k}$ 是恰好保留 k 个神经元的子网络数量。

对于一个有多层的网络，设第 l 层有 n_l 个神经元，则理论上可采样的子网络总数为

$$\prod_{l=1}^L 2^{n_l} = 2^{\sum_l n_l}$$

即使仅 10 层、每层 100 个神经元，也有 2^{1000} 个潜在子网络——一个天文数字。

连接集成学习：模型平均的视角

传统集成学习（Ensemble Learning）训练 M 个独立模型 $f_1, f_2, \dots, f_M$ ，预测时取平均：

$$\hat{y} = \frac{1}{M} \sum_{m=1}^M f_m(x)$$

Dropout 可以理解为对指数级数量的子网络做权重共享的集成：

- 训练阶段：每个 mini-batch 随机采样一个子网络，更新其参数（但所有子网络共享权重）。
- 测试阶段：使用完整网络（权重乘以 $1 - p$ ）近似所有子网络的预测均值。

$$\mathbb{E}_{\text{mask}}[f_{\text{sub}}(x)] \approx f_{\text{full}}(x \text{ with weights scaled by } 1 - p)$$

这种近似称为权重缩放推断规则（weight scaling inference rule），是对指数级模型平均的高效近似。

精确集成：蒙特卡洛 Dropout

测试时也可以多次随机采样子网络（不关闭 Dropout），取预测均值，称为 **MC Dropout**：

$$\hat{y}_{\text{MC}} = \frac{1}{T} \sum_{t=1}^T f_{\text{sub}_t}(x)$$

这既是更准确的集成近似，也能给出预测不确定性的估计（预测方差）：

$$\text{Var}[\hat{y}] \approx \frac{1}{T} \sum_{t=1}^T (f_{\text{sub}_t}(x) - \hat{y}_{\text{MC}})^2$$

PyTorch 代码示例

以下代码演示标准 Dropout、MC Dropout 集成预测，以及可视化不同丢弃率下子网络数量的指数增长。

```
import torch
import torch.nn as nn
import torch.nn.functional as F
import numpy as np
import matplotlib.pyplot as plt

#
# 1. 带 Dropout 的简单分类网络
#

class DropoutNet(nn.Module):
    def __init__(self, input_dim: int, hidden_dim: int, output_dim: int, p: float = 0.5):
        super().__init__()
        self.fc1 = nn.Linear(input_dim, hidden_dim)
        self.fc2 = nn.Linear(hidden_dim, hidden_dim)
        self.fc3 = nn.Linear(hidden_dim, output_dim)
        self.dropout = nn.Dropout(p=p)
        self.p = p

    def forward(self, x: torch.Tensor) -> torch.Tensor:
        x = F.relu(self.dropout(self.fc1(x)))
        x = F.relu(self.dropout(self.fc2(x)))
        return self.fc3(x)

    def mc_predict(self, x: torch.Tensor, n_samples: int = 50) -> tuple:
        """
        MC Dropout 推断：保持 Dropout 激活，多次前向传播取平均。
        返回预测均值和预测方差（不确定性）。
        """
        self.train() # 保持 Dropout 激活
        with torch.no_grad():
            preds = torch.stack([
                F.softmax(self.forward(x), dim=-1)
                for _ in range(n_samples)
            ]) # shape: (n_samples, batch, output_dim)
            mean = preds.mean(dim=0) # 预测均值
            variance = preds.var(dim=0) # 预测方差（不确定性）
        return mean, variance
```

```

#
# 2. 组合数学可视化：子网络数量随神经元数增长
#

def count_subnetworks(n_neurons: int) -> int:
    """
    一层中有  $n_{\text{neurons}}$  个神经元时，可能的子网络数量为  $2^n$ 。
    """
    return 2 ** n_neurons

neuron_counts = list(range(1, 21)) # 1 到 20 个神经元
subnetwork_counts = [count_subnetworks(n) for n in neuron_counts]

fig, axes = plt.subplots(1, 2, figsize=(12, 5))

# 左图：指数增长（对数坐标）
axes[0].semilogy(neuron_counts, subnetwork_counts, 'b-o', markersize=6, linewidth=2)
axes[0].set_xlabel('神经元数量  $n$ ', fontsize=12)
axes[0].set_ylabel('子网络数量  $2^n$ （对数坐标）', fontsize=12)
axes[0].set_title('Dropout 创建的子网络数量（对数坐标）', fontsize=13)
axes[0].grid(True, alpha=0.3)
axes[0].annotate(f' $n=20$ :  $2^{{20}}={2}^{20}$  个',
                 xy=(20, 2**20), xytext=(15, 2**15),
                 arrowprops=dict(arrowstyle='->', color='red'),
                 fontsize=10, color='red')

# 右图：给定层数时，各  $k$  值的子网络组合数（ $n=10$  为例）
n = 10
k_values = list(range(n + 1))
binom_counts = [
    int(np.math.factorial(n) / (np.math.factorial(k) * np.math.factorial(n - k)))
    for k in k_values
]

axes[1].bar(k_values, binom_counts, color='steelblue', alpha=0.8, edgecolor='black')
axes[1].set_xlabel('保留神经元数  $k$ ', fontsize=12)
axes[1].set_ylabel('子网络数量  $\binom{10}{k}$ ', fontsize=12)
axes[1].set_title(f' $n=10$  时各  $k$  值的子网络数（总计  $2^{{10}}={2}^{10}$ ）', fontsize=13)
axes[1].grid(True, alpha=0.3, axis='y')

```

```

for i, v in enumerate(binom_counts):
    axes[1].text(i, v + 2, str(v), ha='center', va='bottom', fontsize=8)

plt.tight_layout()
plt.savefig('dropout_combinatorics.png', dpi=150, bbox_inches='tight')
plt.show()
print(" 图表已保存为 dropout_combinatorics.png")

#
# 3. MC Dropout 集成 vs 标准预测的对比
#

def demo_mc_dropout():
    torch.manual_seed(42)
    input_dim, hidden_dim, output_dim = 20, 64, 3
    model = DropoutNet(input_dim, hidden_dim, output_dim, p=0.5)

    # 模拟输入
    x = torch.randn(5, input_dim)

    # 标准推断 (关闭 Dropout)
    model.eval()
    with torch.no_grad():
        logits = model(x)
        standard_pred = F.softmax(logits, dim=-1)

    # MC Dropout 推断 (50 次采样)
    mc_mean, mc_var = model.mc_predict(x, n_samples=50)

    print("=" * 55)
    print(" 标准推断 (Dropout 关闭, 权重缩放): ")
    print(f" 预测概率 (前 3 条样本): \n{standard_pred[:3].numpy().round(3)}")
    print()
    print("MC Dropout 推断 (50 个子网络集成): ")
    print(f" 预测均值 (前 3 条样本): \n{mc_mean[:3].numpy().round(3)}")
    print(f" 预测方差 (不确定性, 前 3 条样本): \n{mc_var[:3].numpy().round(4)}")
    print("=" * 55)

    # 验证: 子网络数量的组合爆炸
    layers = [hidden_dim, hidden_dim] # 两个隐藏层

```

```
total_subnetworks = 2 ** sum(layers)
print(f"\n网络结构：两层，每层 {hidden_dim} 个神经元")
print(f" 理论子网络总数：2^{sum(layers)} = {total_subnetworks:,}")
print(f"MC Dropout 实际采样：50 个子网络（占比极小）")
```

```
demo_mc_dropout()
```

运行输出示例（权重随机初始化，实际数值会不同）：

=====

标准推断（Dropout 关闭，权重缩放）：

预测概率（前3条样本）：

```
[[0.312 0.351 0.337]
```

```
[0.298 0.389 0.313]
```

```
[0.341 0.322 0.337]]
```

MC Dropout 推断（50 个子网络集成）：

预测均值（前3条样本）：

```
[[0.319 0.348 0.333]
```

```
[0.301 0.382 0.317]
```

```
[0.338 0.325 0.337]]
```

预测方差（不确定性，前3条样本）：

```
[[0.0021 0.0019 0.0018]
```

```
[0.0024 0.0023 0.0020]
```

```
[0.0019 0.0021 0.0017]]
```

网络结构：两层，每层 64 个神经元

理论子网络总数： $2^{128} = 340282366920938463463374607431768211456$

MC Dropout 实际采样：50 个子网络（占比极小）

=====

关键洞察：

1. 组合爆炸是双刃剑： 2^{128} 个子网络使穷举集成完全不可行，但 Dropout 通过权重共享让单个完整网络同时近似所有子网络的平均——这是极其高效的正则化。
 2. 与二项式定理的连接：训练时每个 mini-batch 采样的子网络保留 k 个神经元 ($k \sim \text{Binomial}(n, 1 - p)$)， $\binom{n}{k}$ 种等可能的配置共同贡献正则化效果。
 3. 不确定性量化：MC Dropout 给出的预测方差可用于检测模型对输入的置信度，这在医疗诊断、自动驾驶等高风险场景中尤为重要。
-

练习题

第1题一次考试有10道选择题，每题有A、B、C、D四个选项，恰好选了3题选A、4题选B、3题选D的答题方案有多少种？

第2题从1到100的整数中随机选取一个，求该数能被3整除或能被7整除的概率。（提示：先用计数原理计算满足条件的整数个数。）

第3题证明以下恒等式（组合证明或代数证明均可）：

$$\sum_{k=0}^n k \binom{n}{k} = n \cdot 2^{n-1}$$

第4题（Dropout 相关）一个神经网络某层有 $n = 8$ 个神经元，Dropout 概率为 $p = 0.5$ （即每个神经元独立地以 0.5 的概率被丢弃）。

- (a) 该层可能产生的不同子网络数量是多少？
- (b) 一次前向传播中，恰好保留 5 个神经元的概率是多少？
- (c) 期望保留的神经元数量是多少？（提示：利用二项分布的期望。）

第5题用多项式系数证明：

$$(1 + 1 + 1)^n = \sum_{\substack{i+j+k=n \\ i,j,k \geq 0}} \frac{n!}{i! j! k!} = 3^n$$

并给出等式左端 $n = 3$ 时展开式中 $i = 1, j = 1, k = 1$ 项的系数验证。

练习答案

第1题答案

解题思路：将10道题分成三组——3道选A，4道选B，3道选D，这是多重集合的划分问题。

$$\text{方案数} = \binom{10}{3, 4, 3} = \frac{10!}{3! 4! 3!}$$

计算：

$$\frac{10!}{3! 4! 3!} = \frac{3\,628\,800}{6 \times 24 \times 6} = \frac{3\,628\,800}{864} = \boxed{4200}$$

验证：也可以分步计算——先从10题中选3题答A ($\binom{10}{3} = 120$ 种)，再从剩7题中选4题答B ($\binom{7}{4} = 35$ 种)，剩余3题答D (1种)：

$$120 \times 35 \times 1 = 4200\checkmark$$

第2题答案

解题思路：设事件 A = “能被3整除”， B = “能被7整除”。

计数：- $|A|$ ： $\lfloor 100/3 \rfloor = 33$ 个 (3, 6, 9, ..., 99) - $|B|$ ： $\lfloor 100/7 \rfloor = 14$ 个 (7, 14, ..., 98) - $|A \cap B|$ ：能被 $\text{lcm}(3, 7) = 21$ 整除的数， $\lfloor 100/21 \rfloor = 4$ 个 (21, 42, 63, 84)

由容斥原理（加法原理的推广）：

$$|A \cup B| = |A| + |B| - |A \cap B| = 33 + 14 - 4 = 43$$

概率：

$$P(A \cup B) = \frac{43}{100} = \boxed{0.43}$$

第3题答案

代数证明：

对二项式定理 $(1+x)^n = \sum_{k=0}^n \binom{n}{k} x^k$ 两端关于 x 求导：

$$n(1+x)^{n-1} = \sum_{k=1}^n k \binom{n}{k} x^{k-1}$$

令 $x = 1$ ：

$$n \cdot 2^{n-1} = \sum_{k=1}^n k \binom{n}{k} = \sum_{k=0}^n k \binom{n}{k} \quad \blacksquare$$

($k=0$ 时该项为0，故下限改为0不影响结果。)

组合证明（双重计数）：

从 n 个人中选一个委员会（任意大小）并指定一名主席。

- 按先选主席再选其他成员：先从 n 人中选1位主席 (n 种)，再从剩余 $n-1$ 人中任意选若干成员 (2^{n-1} 种)，共 $n \cdot 2^{n-1}$ 种。
- 按先选委员会再选主席：先选 k 人的委员会 ($\binom{n}{k}$ 种)，再从中选1位主席 (k 种)，对所有 k 求和得 $\sum_{k=0}^n k \binom{n}{k}$ 。

两种计数方法等价，故恒等式成立。■

第4题答案

(a) 子网络数量

$n = 8$ 个神经元，每个独立地保留或丢弃，故可能的子网络数为：

$$2^8 = \boxed{256}$$

(b) 恰好保留 5 个神经元的概率

每个神经元被保留的概率为 $1 - p = 0.5$ ，保留神经元数 $K \sim \text{Binomial}(8, 0.5)$ 。

$$P(K = 5) = \binom{8}{5} (0.5)^5 (0.5)^3 = \binom{8}{5} (0.5)^8$$

$$\binom{8}{5} = \binom{8}{3} = \frac{8 \times 7 \times 6}{3!} = 56$$

$$P(K = 5) = 56 \times \frac{1}{256} = \frac{56}{256} = \frac{7}{32} \approx \boxed{0.2188}$$

(c) 期望保留神经元数

$K \sim \text{Binomial}(n, 1 - p) = \text{Binomial}(8, 0.5)$ ，二项分布期望为：

$$\mathbb{E}[K] = n(1 - p) = 8 \times 0.5 = \boxed{4}$$

第5题答案

证明：

由多项式定理，令 $x_1 = x_2 = x_3 = 1$ ， $r = 3$ ，指数为 n ：

$$(1 + 1 + 1)^n = \sum_{\substack{i+j+k=n \\ i,j,k \geq 0}} \frac{n!}{i! j! k!} \cdot 1^i \cdot 1^j \cdot 1^k = \sum_{\substack{i+j+k=n \\ i,j,k \geq 0}} \frac{n!}{i! j! k!}$$

左端 $= 3^n$ ，故等式成立。■

验证 $n = 3, i = j = k = 1$ 的项：

$$\frac{3!}{1! 1! 1!} = \frac{6}{1} = 6$$

直接展开 $(x + y + z)^3$ 中 xyz 项：从 3 个因子 $(x + y + z)$ 中分别取 x, y, z 各一次，有 $3! = 6$ 种排列方式 $(xyz, xzy, yxz, yzx, zyx, xzy)$ ，系数恰为 6，与多项式系数一致。✓

几何示意

图 3-1：杨辉三角（8 层）与帕斯卡恒等式




图 5: 杨辉三角（8 层）及 $C(n,k)=C(n-1,k-1)+C(n-1,k)$ 标注

图 3-2：排列 vs 组合树状图对比

思考路标（条件反射）

- 看到“从 n 个中选 k 个，有序”→ 排列 $P_n^k = n!/(n-k)!$
- 看到“从 n 个中选 k 个，无序”→ 组合 $C_n^k = n!/(k!(n-k)!)$
- 看到 $(a+b)^n$ 展开 → 二项式定理：第 $k+1$ 项系数为 C_n^k
- 看到“ n 个物体分成几类，各类 n_i 个”→ 多项式系数 $n!/(n_1! \cdots n_r!)$
- 看到相邻行二项式系数关系 → 帕斯卡恒等式 $C_n^k = C_{n-1}^{k-1} + C_{n-1}^k$
- 看到“将 k 个相同球分入 n 个盒子（允许空盒）”→ 隔板法（重复组合） C_{n+k-1}^k
- 看到“计算集合并的元素数/概率”→ 容斥原理：加单项 - 减双交 + 加三交...
- 看到“ $n+1$ 个物体放 n 个盒子”→ 鸽笼原理：至少一个盒子有 ≥ 2 个物体




图 6: 排列 $P(4,2)=12$ (有序) vs 组合 $C(4,2)=6$ (无序) 树状图

易错点

1. 排列 vs 组合 (是否有序): 最易混淆。选后需“排列”(如颁奖金银铜) → 排列; 选后不区分顺序 (如选委员) → 组合。
2. $C_n^0 = 1$ 易忘: 一个都不选也是一种方案; 同理 $C_n^n = 1$ 、 $C_n^1 = n$ 。
3. 重复元素的排列: n 个元素含重复时, 全排列 $= n!/(n_1! \cdots n_k!)$, 不是 $n!$ 。
4. 圆排列 vs 直线排列: n 个人圆形排列固定一人作参照, 方案数 $= (n - 1)!$, 不是 $n!$ 。
5. 卡特兰数: 形如“ $2n$ 步走回原点且不超界”的路径计数 $= C_{2n}^n/(n + 1)$, 是常见的高级计数结果, 不要用普通排列组合硬算。

第 4 章离散随机变量

难度: ★★☆☆☆ 前置知识: 第 1-3 章概率基础

学习目标

- 理解随机变量的概念及其作为样本空间到实数映射的本质
- 掌握离散随机变量的概率质量函数 (PMF) 和累积分布函数 (CDF)
- 熟练计算离散随机变量的期望和方差
- 理解期望和方差的基本性质
- 建立离散随机变量与深度学习分类任务的联系

4.1 随机变量的概念

定义

随机变量 (Random Variable) 是定义在样本空间 Ω 上的实值函数:

$$X: \Omega \rightarrow \mathbb{R}$$

它将每个样本点 $\omega \in \Omega$ 映射到一个实数 $X(\omega)$ 。

直观理解

随机变量是对随机试验结果的数值化描述。例如:

随机试验	样本空间 Ω	随机变量 X
掷一枚硬币	$\{ , \}$	正面记 1, 反面记 0
掷两枚骰子	$\{(i, j) : 1 \leq i, j \leq 6\}$	$X = i + j$ (点数之和)
射击比赛	各种命中情况	命中环数

随机变量的分类

- 离散随机变量: 取值为有限个或可数无穷个
- 连续随机变量: 取值为某个区间内的任意实数

本章聚焦于离散随机变量。

4.2 离散随机变量与概率质量函数

定义

设 X 是离散随机变量, 其可能取值为 $x_1, x_2, x_3, \dots$, 则 X 的概率质量函数 (Probability Mass Function, PMF) 定义为:

$$p(x) = P(X = x), \quad x \in \{x_1, x_2, \dots\}$$

PMF 的性质

1. 非负性: $p(x) \geq 0$ 对所有 x 成立
2. 归一化: $\sum_i p(x_i) = 1$
3. 概率计算: $P(X \in A) = \sum_{x_i \in A} p(x_i)$

例 4.1: 掷骰子

掷一枚均匀骰子, X 表示出现的点数。

$$p(x) = \frac{1}{6}, \quad x \in \{1, 2, 3, 4, 5, 6\}$$

验证归一化: $\sum_{x=1}^6 p(x) = 6 \times \frac{1}{6} = 1 \quad \square$

例 4.2: 二项分布预览

掷 n 次硬币, X 表示正面出现的次数, 正面概率为 p :

$$p(k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n$$

4.3 累积分布函数**定义**

随机变量 X 的累积分布函数 (Cumulative Distribution Function, CDF) 定义为:

$$F(x) = P(X \leq x) = \sum_{x_i \leq x} p(x_i)$$

CDF 的性质

1. 单调不减: 若 $x_1 < x_2$, 则 $F(x_1) \leq F(x_2)$
2. 右连续: $\lim_{x \rightarrow a^+} F(x) = F(a)$
3. 边界条件: $\lim_{x \rightarrow -\infty} F(x) = 0, \lim_{x \rightarrow +\infty} F(x) = 1$

离散 CDF 的特点

对于离散随机变量，CDF 是阶梯函数，在每个可能取值处有跳跃。

CDF 与 PMF 的关系

$$p(x_i) = F(x_i) - F(x_{i-1}) = P(X \leq x_i) - P(X < x_i)$$

例 4.3：计算概率

设 X 的 PMF 为： $p(1) = 0.2, p(2) = 0.3, p(3) = 0.3, p(4) = 0.2$

CDF 为： $F(1) = 0.2, F(2) = 0.5, F(3) = 0.8, F(4) = 1.0$

$$P(2 \leq X \leq 3) = F(3) - F(1) = 0.8 - 0.2 = 0.6$$

4.4 期望

定义

离散随机变量 X 的期望 (Expectation) 或均值定义为：

$$E[X] = \sum_i x_i \cdot p(x_i)$$

期望是随机变量取值的加权平均，权重为对应的概率。

这个“加权平均”公式从哪来？（从长期频率推导）期望并非凭空规定，而是“大量重复后的平均值”的极限。设把试验独立重复 N 次，取值 x_i 出现了 n_i 次，则这 N 个结果的普通算术平均为

$$\frac{1}{N} \sum_{\text{所有试验}} (\text{取值}) = \sum_i x_i \cdot \frac{n_i}{N}.$$

当 $N \rightarrow \infty$ 时，频率 $\frac{n_i}{N} \rightarrow p(x_i)$ （频率稳定性，见第 1 章；严格表述即第 10 章大数定律），于是算术平均趋于 $\sum_i x_i p(x_i)$ 。这就是把“概率”当权重的加权平均之所以等于“长期平均值”的原因——期望就是用概率预先算出的平均。

函数的期望

若 $g(X)$ 是 X 的函数, 则:

$$E[g(X)] = \sum_i g(x_i) \cdot p(x_i)$$

期望的性质

设 a, b 为常数, X, Y 为随机变量:

1. 常数的期望: $E[a] = a$
2. 线性性: $E[aX + b] = aE[X] + b$
3. 可加性: $E[X + Y] = E[X] + E[Y]$ (总是成立!)
4. 独立变量的乘积: 若 X, Y 独立, 则 $E[XY] = E[X]E[Y]$

可加性为什么“总是成立”、不需要独立? 关键在于期望也可以按样本点 ω 求和来写: $E[X] = \sum_{\omega} X(\omega) P(\omega)$ (把同一取值的样本点合并即回到 $\sum_i x_i p(x_i)$)。于是

$$E[X + Y] = \sum_{\omega} (X(\omega) + Y(\omega)) P(\omega) = \sum_{\omega} X(\omega) P(\omega) + \sum_{\omega} Y(\omega) P(\omega) = E[X] + E[Y],$$

整个推导只用了求和的可拆分, 与 X, Y 是否独立无关——这正是可加性“无条件成立”的根源。

什么叫“ X, Y 独立”? (性质 4 用到, 先给定义) 称两个随机变量 X, Y 相互独立, 指对一切 x, y 有

$$P(X = x, Y = y) = P(X = x) P(Y = y)$$

(即联合分布等于两个边缘分布之积; 连续情形为 $P(X \leq x, Y \leq y) = P(X \leq x)P(Y \leq y)$)。直观就是“ X 取什么值不影响 Y 的分布”。在此前提下才有 $E[XY] = E[X]E[Y]$ 。多个随机变量的独立性及其完整讨论见第 6 章; 下面例 4.5 把 X 写成 n 个独立伯努利变量之和”正是用到这一概念。

例 4.4: 骰子期望

$$E[X] = \sum_{x=1}^6 x \cdot \frac{1}{6} = \frac{1+2+3+4+5+6}{6} = \frac{21}{6} = 3.5$$

例 4.5: 二项分布期望

设 $X \sim \text{Binomial}(n, p)$, 可以证明:

$$E[X] = np$$

证明思路：将 X 写成 n 个独立伯努利变量的和，利用期望的可加性。

4.5 方差与标准差

方差的定义

随机变量 X 的方差 (Variance) 定义为：

$$\text{Var}(X) = E[(X - \mu)^2]$$

其中 $\mu = E[X]$ 是期望。方差度量随机变量偏离均值的程度。

方差的计算公式

$$\text{Var}(X) = E[X^2] - (E[X])^2$$

证明：

$$\text{Var}(X) = E[(X - \mu)^2] = E[X^2 - 2\mu X + \mu^2] = E[X^2] - 2\mu E[X] + \mu^2 = E[X^2] - \mu^2$$

标准差

标准差 (Standard Deviation) 是方差的平方根：

$$\sigma = \sqrt{\text{Var}(X)}$$

标准差与随机变量具有相同的量纲，更便于解释。

方差的性质

1. 非负性： $\text{Var}(X) \geq 0$
2. 常数的方差： $\text{Var}(a) = 0$
3. 线性变换： $\text{Var}(aX + b) = a^2 \text{Var}(X)$
4. 独立变量的和：若 X, Y 独立，则 $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$

例 4.6: 骰子方差

$$E[X^2] = \sum_{x=1}^6 x^2 \cdot \frac{1}{6} = \frac{1+4+9+16+25+36}{6} = \frac{91}{6}$$

$$\text{Var}(X) = \frac{91}{6} - \left(\frac{7}{2}\right)^2 = \frac{91}{6} - \frac{49}{4} = \frac{182-147}{12} = \frac{35}{12} \approx 2.92$$

$$\sigma = \sqrt{\frac{35}{12}} \approx 1.71$$

4.6 矩母函数与特征函数**矩母函数 (Moment Generating Function)**

定义随机变量 X 的矩母函数 (MGF) 定义为:

$$M_X(t) = E[e^{tX}] = \sum_i e^{tx_i} p(x_i)$$

其中 t 是实数参数, 要求 $E[e^{tX}]$ 在包含 0 的某个开区间内有限。

名称由来: MGF 之所以叫“矩母函数”, 是因为对 $M_X(t)$ 求 n 阶导数并令 $t=0$, 恰好得到 X 的 n 阶矩:

$$M_X^{(n)}(0) = E[X^n]$$

推导: 将 e^{tX} 展开为幂级数 $e^{tX} = \sum_{n=0}^{\infty} \frac{(tX)^n}{n!}$, 求期望后得 $M_X(t) = \sum_{n=0}^{\infty} \frac{E[X^n]}{n!} t^n$, 对 t 求 n 次导后令 $t=0$ 即得。

MGF 的核心性质

1. 唯一性: 若 $M_X(t) = M_Y(t)$ 在某开区间 $(-h, h)$ 上成立, 则 X 与 Y 同分布
2. 独立变量的 MGF: 若 X, Y 独立, 则 $M_{X+Y}(t) = M_X(t) \cdot M_Y(t)$
3. 线性变换: $M_{aX+b}(t) = e^{bt} M_X(at)$

例 4.7: 伯努利分布的 MGF

设 $X \sim \text{Bernoulli}(p)$, 则:

$$M_X(t) = E[e^{tX}] = e^{t \cdot 0}(1-p) + e^{t \cdot 1}p = (1-p) + pe^t$$

验证: $M_X'(t) = pe^t$, $M_X'(0) = p = E[X]$ $\square$

$M_X''(t) = pe^t$, $M_X''(0) = p = E[X^2]$, $\text{Var}(X) = p - p^2 = p(1-p)$ $\square$

例 4.8: 泊松分布的 MGF

设 $X \sim \text{Poisson}(\lambda)$, 则:

$$M_X(t) = \sum_{k=0}^{\infty} e^{tk} \frac{\lambda^k e^{-\lambda}}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{(\lambda e^t)^k}{k!} = e^{-\lambda} \cdot e^{\lambda e^t} = e^{\lambda(e^t-1)}$$

验证: $M'_X(t) = \lambda e^t \cdot e^{\lambda(e^t-1)}$, $M'_X(0) = \lambda = E[X]$ $\square$

特征函数简介

当 MGF 不存在时 (如柯西分布), 可以使用特征函数 (Characteristic Function):

$$\varphi_X(t) = E[e^{itX}]$$

其中 $i = \sqrt{-1}$ 。特征函数对任何分布都存在 (因为 $|e^{itX}| = 1$), 且同样具有唯一确定分布的性质。特征函数将在极限定理 (第 10-11 章) 中发挥关键作用。

本章小结

概念	定义/公式
随机变量	$X : \Omega \rightarrow \mathbb{R}$
PMF	$p(x) = P(X = x)$
CDF	$F(x) = P(X \leq x)$
期望	$E[X] = \sum_i x_i p(x_i)$
方差	$\text{Var}(X) = E[X^2] - (E[X])^2$
标准差	$\sigma = \sqrt{\text{Var}(X)}$
矩母函数	$M_X(t) = E[e^{tX}]$, $M_X^{(n)}(0) = E[X^n]$

核心要点: - 随机变量将随机试验的结果数值化 - PMF 描述离散随机变量的完整概率分布 - 期望是概率加权平均, 具有线性性 - 方差度量分布的离散程度 - 矩母函数是求矩、证明分布唯一性和研究独立变量之和的强力工具

深度学习应用：分类任务与 Softmax 输出

分类问题的概率视角

在深度学习分类任务中，模型的目标是预测输入属于各个类别的概率分布——这正是一个离散随机变量的 PMF！

设有 K 个类别，模型输出是一个概率向量：

$$\mathbf{p} = (p_1, p_2, \dots, p_K), \quad \sum_{k=1}^K p_k = 1$$

Softmax 函数

神经网络最后一层通常输出 **logits**（未归一化的分数） $\mathbf{z} = (z_1, z_2, \dots, z_K)$ 。

Softmax 函数将 logits 转换为概率分布：

$$p_k = \text{Softmax}(z_k) = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}$$

性质：- 输出非负： $p_k > 0$ - 归一化： $\sum_k p_k = 1$ - 保序： $z_i > z_j \Rightarrow p_i > p_j$

交叉熵损失

给定真实标签 y （one-hot 编码）和预测概率 $\hat{\mathbf{p}}$ ，交叉熵损失定义为：

$$\mathcal{L} = - \sum_{k=1}^K y_k \log \hat{p}_k = - \log \hat{p}_y$$

其中 y 是真实类别的索引。

概率解释：交叉熵损失是负对数似然，最小化它等价于最大化正确类别的预测概率。

温度缩放

Softmax 的“尖锐程度”可以通过温度参数 T 控制：

$$p_k = \frac{e^{z_k/T}}{\sum_j e^{z_j/T}}$$

- $T \rightarrow 0$: 分布趋于 one-hot（确定性）

- $T = 1$: 标准 Softmax
- $T \rightarrow \infty$: 分布趋于均匀 (最大不确定性)

PyTorch 代码示例

```
import torch
import torch.nn as nn
import torch.nn.functional as F

# 1. Softmax 将 logits 转换为概率分布 (PMF)
logits = torch.tensor([2.0, 1.0, 0.1])
probs = F.softmax(logits, dim=0)
print(f"Logits: {logits}")
print(f"Probabilities (PMF): {probs}")
print(f"Sum of probabilities: {probs.sum():.4f}") # 验证归一化

# 2. 验证 PMF 性质
print(f"\nPMF 性质验证:")
print(f"  非负性: {(probs >= 0).all()}")
print(f"  归一化: {probs.sum().item():.6f}")

# 3. 计算期望 (预测类别的期望索引)
classes = torch.tensor([0.0, 1.0, 2.0])
expected_class = (probs * classes).sum()
print(f"\n期望类别索引: {expected_class:.4f}")

# 4. 交叉熵损失
true_label = torch.tensor([0]) # 真实类别是 0
logits_batch = logits.unsqueeze(0) # (1, 3)

# 方法 1: 使用 CrossEntropyLoss (接受 logits)
criterion = nn.CrossEntropyLoss()
loss1 = criterion(logits_batch, true_label)

# 方法 2: 手动计算  $-\log(p_{\text{true}})$ 
loss2 = -torch.log(probs[0])

print(f"\n交叉熵损失:")
print(f"  nn.CrossEntropyLoss: {loss1.item():.4f}")
print(f"  手动计算  $-\log(p_0)$ : {loss2.item():.4f}")
```

5. 温度缩放的效果

```
print("\n温度缩放效果:")
for T in [0.5, 1.0, 2.0, 5.0]:
    probs_T = F.softmax(logits / T, dim=0)
    print(f" T={T}: {probs_T.numpy().round(3)}")
```

6. 完整的分类网络示例

```
class SimpleClassifier(nn.Module):
    def __init__(self, input_dim, num_classes):
        super().__init__()
        self.fc1 = nn.Linear(input_dim, 64)
        self.fc2 = nn.Linear(64, num_classes)

    def forward(self, x):
        x = F.relu(self.fc1(x))
        logits = self.fc2(x) # 输出 logits
        return logits

    def predict_proba(self, x):
        """ 返回概率分布 (PMF) """
        logits = self.forward(x)
        return F.softmax(logits, dim=-1)
```

创建模型并演示

```
model = SimpleClassifier(input_dim=10, num_classes=3)
x = torch.randn(5, 10) # 5 个样本, 10 维特征

logits = model(x)
probs = model.predict_proba(x)

print(f"\n分类网络输出:")
print(f" Logits shape: {logits.shape}")
print(f" Probs shape: {probs.shape}")
print(f" 样本 0 的 PMF: {probs[0].detach().numpy().round(3)}")
print(f" 验证归一化: {probs.sum(dim=1).detach().numpy()}")
```

输出:

```
Logits: tensor([2.0000, 1.0000, 0.1000])
Probabilities (PMF): tensor([0.6590, 0.2424, 0.0986])
Sum of probabilities: 1.0000
```

PMF 性质验证:

非负性: `True`
归一化: `1.000000`

期望类别索引: `0.4396`

交叉熵损失:

`nn.CrossEntropyLoss`: `0.4170`
手动计算 $-\log(p_0)$: `0.4170`

温度缩放效果:

`T=0.5`: `[0.844 0.114 0.042]`
`T=1.0`: `[0.659 0.242 0.099]`
`T=2.0`: `[0.506 0.307 0.188]`
`T=5.0`: `[0.387 0.338 0.275]`

关键联系

概率论概念	深度学习对应
离散随机变量	类别标签
PMF	Softmax 输出
期望	预测的平均类别
熵	预测的不确定性
对数似然	负交叉熵损失

练习题

练习 4.1 (基础)

设离散随机变量 X 的 PMF 为:

x	-1	0	1	2
$p(x)$	0.1	0.3	0.4	0.2

- (a) 验证这是一个有效的 PMF
- (b) 计算 $P(X \geq 0)$
- (c) 写出 CDF $F(x)$

练习 4.2 (计算)

设 X 的 PMF 为 $p(k) = c \cdot k$, $k = 1, 2, 3, 4$, 其他值概率为 0。

- (a) 求常数 c
- (b) 计算 $E[X]$ 和 $\text{Var}(X)$

练习 4.3 (理解)

证明：对于任意随机变量 X 和常数 a, b ：

$$\text{Var}(aX + b) = a^2 \text{Var}(X)$$

练习 4.4 (应用)

一个三分类问题，Softmax 输出为 $\mathbf{p} = (0.7, 0.2, 0.1)$ 。

- (a) 若真实标签是类别 0，计算交叉熵损失
- (b) 若真实标签是类别 2，损失是多少？
- (c) 解释为什么错误预测的损失更高

练习 4.5 (深度学习)

考虑温度缩放 Softmax: $p_k = \frac{e^{z_k/T}}{\sum_j e^{z_j/T}}$

- (a) 证明当 $T \rightarrow 0^+$ 时，分布趋于将所有概率集中在最大 logit 对应的类别
- (b) 证明当 $T \rightarrow \infty$ 时，分布趋于均匀分布
- (c) 在知识蒸馏中，为什么使用较高的温度？

练习答案

点击展开练习 4.1 答案

(a) 验证 PMF 有效性：- 非负性：0.1, 0.3, 0.4, 0.2 ≥ 0 $\square$ - 归一化：0.1 + 0.3 + 0.4 + 0.2 = 1.0 $\square$

(b) $P(X \geq 0) = P(X = 0) + P(X = 1) + P(X = 2) = 0.3 + 0.4 + 0.2 = 0.9$

(c) CDF:

$$F(x) = \begin{cases} 0 & x < -1 \\ 0.1 & -1 \leq x < 0 \\ 0.4 & 0 \leq x < 1 \\ 0.8 & 1 \leq x < 2 \\ 1.0 & x \geq 2 \end{cases}$$

点击展开练习 4.2 答案

(a) 由归一化条件:

$$\sum_{k=1}^4 c \cdot k = c(1 + 2 + 3 + 4) = 10c = 1$$

$$c = \frac{1}{10} = 0.1$$

(b) 期望:

$$E[X] = \sum_{k=1}^4 k \cdot \frac{k}{10} = \frac{1}{10}(1 + 4 + 9 + 16) = \frac{30}{10} = 3$$

$$E[X^2] = \sum_{k=1}^4 k^2 \cdot \frac{k}{10} = \frac{1}{10}(1 + 8 + 27 + 64) = \frac{100}{10} = 10$$

方差:

$$\text{Var}(X) = E[X^2] - (E[X])^2 = 10 - 9 = 1$$

点击展开练习 4.3 答案

设 $\mu = E[X]$, 则 $E[aX + b] = aE[X] + b = a\mu + b$ 。

$$\begin{aligned} \text{Var}(aX + b) &= E[(aX + b - (a\mu + b))^2] \\ &= E[(aX - a\mu)^2] \\ &= E[a^2(X - \mu)^2] \\ &= a^2 E[(X - \mu)^2] \\ &= a^2 \text{Var}(X) \end{aligned}$$

注意常数 b 只是平移, 不影响离散程度, 因此不出现在方差中。

点击展开练习 4.4 答案

(a) 真实标签是类别 0:

$$\mathcal{L} = -\log p_0 = -\log 0.7 \approx 0.357$$

(b) 真实标签是类别 2:

$$\mathcal{L} = -\log p_2 = -\log 0.1 \approx 2.303$$

(c) 交叉熵损失 $-\log p$ 是 p 的递减函数: - 当预测正确时, p 大 (如 0.7), $-\log p$ 小 - 当预测错误时, p 小 (如 0.1), $-\log p$ 大

这使得模型受到惩罚以增加正确类别的预测概率。当 $p \rightarrow 0$ 时, 损失 $\rightarrow \infty$, 强烈惩罚过于自信的错误预测。

点击展开练习 4.5 答案

(a) 当 $T \rightarrow 0^+$:

设 $z_{max} = \max_k z_k$ 对应类别 k^* 。

$$p_k = \frac{e^{z_k/T}}{\sum_j e^{z_j/T}} = \frac{e^{(z_k - z_{max})/T}}{\sum_j e^{(z_j - z_{max})/T}}$$

当 $T \rightarrow 0^+$: - 若 $k = k^*$: 分子分母主项都是 1, $p_{k^*} \rightarrow 1$ - 若 $k \neq k^*$: $z_k - z_{max} < 0$, $e^{(z_k - z_{max})/T} \rightarrow 0$, 故 $p_k \rightarrow 0$

(b) 当 $T \rightarrow \infty$:

所有 $z_k/T \rightarrow 0$, $e^{z_k/T} \rightarrow 1$ 。

$$p_k \rightarrow \frac{1}{K}$$

分布趋于均匀。

(c) 知识蒸馏中使用较高温度的原因: - 低温时, teacher 模型输出接近 one-hot, 几乎没有“暗知识”- 高温“软化”概率分布, 揭示类别间的相似性结构 - 例如: 数字识别中, 7 和 1 的相似性在低温时被掩盖, 高温时体现为 7 类有较高的 1 类概率 - 这种软标签包含了 teacher 学到的类间关系, 有助于 student 学习

几何示意

图 4-1: 二项分布 PMF ($B(10, 0.4)$ 柱状图)




图 7: 二项分布 $B(10, 0.4)$ 概率质量函数柱状图




图 8: 离散随机变量累积分布函数阶梯图

图 4-2: 离散 CDF (阶梯函数)

图 4-3: 期望几何意义 (加权平均 = 平衡点)




图 9: 期望的几何意义：加权平均等于杠杆平衡点

思考路标（条件反射）

- 看到 PMF $p(x) \rightarrow$ 首先验证 $\sum_i p(x_i) = 1$ （归一化）， $p(x) \geq 0$ （非负）
- 看到 CDF 离散随机变量 $\rightarrow$ 阶梯函数：右连续，在每个取值处跳跃，跳跃高度 = PMF
- 看到“求期望” $\rightarrow$ 加权平均： $E[X] = \sum_i x_i p(x_i)$ ，几何意义是杠杆平衡点
- 看到“求方差” $\rightarrow$ 优先用 $E(X^2) - (EX)^2$ ： $\text{Var}(X) = E[X^2] - (E[X])^2$
- 看到“求标准差” $\rightarrow \sigma = \sqrt{\text{Var}(X)}$ （与 X 同量纲）
- 看到“ n 阶矩” $\rightarrow E[X^n]$ ，矩母函数 $M_X^{(n)}(0) = E[X^n]$
- 看到“线性变换 $aX + b$ ” $\rightarrow E(aX + b) = aE(X) + b$ ； $\text{Var}(aX + b) = a^2 \text{Var}(X)$ （ b 消失！）
- 看到“ $Y = g(X)$ 求期望” $\rightarrow$ 直接用 $E[g(X)] = \sum_i g(x_i) p(x_i)$ ，不要先求 $g(E[X])$

易错点

1. **PMF 求和必为 1**（验证步骤不可省）：拿到 PMF 先算 $\sum p_i$ ；含参数时解方程确定参数值。
2. **CDF 是右连续阶梯函数**： $F(x)$ 在跳跃点 x_k 处的值是 $F(x_k)$ （取右极限）， $F(x_k^-) = F(x_k) - p(x_k)$ 。
3. 方差非负，两公式等价： $E(X - \mu)^2 \geq 0$ ；用 $E[X^2] - (EX)^2$ 计算时若结果为负则必有计算错误。
4. 线性变换方差中平方系数： $\text{Var}(aX + b) = a^2 \text{Var}(X)$ ，平移 b 不改变离散程度，系数 a 要平方。
5. $E[g(X)] \neq g(E[X])$ （一般情况）：Jensen 不等式仅在 g 为线性时取等；常见误用： $E[X^2] \neq (E[X])^2$ ， $E[1/X] \neq 1/E[X]$ 。

第 5 章连续随机变量

难度：★★☆☆☆ 前置知识：第 4 章离散随机变量、微积分基础

学习目标

- 理解连续随机变量与离散随机变量的本质区别
- 掌握概率密度函数（PDF）的定义和性质
- 熟练计算连续随机变量的期望和方差
- 理解累积分布函数（CDF）与 PDF 的关系
- 建立连续随机变量与深度学习回归任务的联系

5.1 连续随机变量的定义

从离散到连续

离散随机变量取有限或可数个值，而连续随机变量可以取某个区间内的任意实数值。

关键区别：对于连续随机变量，任意单点的概率为零：

$$P(X = x) = 0, \quad \forall x \in \mathbb{R}$$

直观理解

想象一个飞镖投掷实验：- 飞镖落在靶上的精确位置是连续的 - 落在任何特定点（如正中心）的概率是 0 - 但落在某个区域（如红心圈内）的概率是正的

为什么单点概率为零？

区间 $[a, b]$ 包含无穷多个点。如果每个点都有正概率，总概率会超过 1。因此，连续随机变量必须用概率密度而非概率质量来描述。

5.2 概率密度函数

定义

连续随机变量 X 的概率密度函数（Probability Density Function, PDF） $f(x)$ 满足：

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

PDF 的性质

1. 非负性： $f(x) \geq 0$ 对所有 x 成立
2. 归一化： $\int_{-\infty}^{+\infty} f(x) dx = 1$
3. 注意： $f(x)$ 本身不是概率，可以大于 1

PDF 的几何解释

- PDF 曲线下的面积表示概率
- $f(x)$ 在点 x 处的值表示概率的“密度”
- 面积 = 概率，但高度 $\neq$ 概率

例 5.1: 均匀分布

若 X 在区间 $[a, b]$ 上均匀分布，其 PDF 为：

$$f(x) = \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{其他} \end{cases}$$

验证归一化： $\int_a^b \frac{1}{b-a} dx = \frac{b-a}{b-a} = 1 \quad \square$

计算概率： $P(X \leq \frac{a+b}{2}) = \int_a^{(a+b)/2} \frac{1}{b-a} dx = \frac{1}{2}$

例 5.2: 指数分布

指数分布的 PDF 为 ($\lambda > 0$):

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}$$

验证归一化： $\int_0^{\infty} \lambda e^{-\lambda x} dx = [-e^{-\lambda x}]_0^{\infty} = 1 \quad \square$

5.3 累积分布函数**定义**

连续随机变量的累积分布函数 (CDF) 定义为：

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$$

CDF 的性质

1. 单调不减: 若 $x_1 < x_2$, 则 $F(x_1) \leq F(x_2)$
2. 连续性: 连续随机变量的 CDF 是连续函数
3. 边界条件: $\lim_{x \rightarrow -\infty} F(x) = 0$, $\lim_{x \rightarrow +\infty} F(x) = 1$

PDF 与 CDF 的关系

$$f(x) = \frac{d}{dx}F(x) = F'(x)$$

(在 F 可导的点处)

用 CDF 计算概率

$$P(a < X \leq b) = F(b) - F(a)$$

由于 $P(X = a) = 0$, 有:

$$P(a < X \leq b) = P(a \leq X \leq b) = P(a < X < b) = P(a \leq X < b)$$

例 5.3: 指数分布的 CDF

$$F(x) = \int_0^x \lambda e^{-\lambda t} dt = 1 - e^{-\lambda x}, \quad x \geq 0$$

$$P(X > t) = 1 - F(t) = e^{-\lambda t} \quad (\text{生存函数})$$

5.4 期望与方差**期望的定义**

连续随机变量 X 的期望定义为:

$$E[X] = \int_{-\infty}^{+\infty} x \cdot f(x) dx$$

函数的期望

若 $g(X)$ 是 X 的函数:

$$E[g(X)] = \int_{-\infty}^{+\infty} g(x) \cdot f(x) dx$$

方差的定义

$$\text{Var}(X) = E[(X - \mu)^2] = \int_{-\infty}^{+\infty} (x - \mu)^2 f(x) dx$$

等价公式:

$$\text{Var}(X) = E[X^2] - (E[X])^2$$

期望和方差的性质

与离散情况完全相同:

- $E[aX + b] = aE[X] + b$
- $\text{Var}(aX + b) = a^2\text{Var}(X)$

例 5.4: 均匀分布的期望和方差

$X \sim \text{Uniform}(a, b)$:

$$E[X] = \int_a^b x \cdot \frac{1}{b-a} dx = \frac{1}{b-a} \cdot \frac{x^2}{2} \Big|_a^b = \frac{a+b}{2}$$

$$E[X^2] = \int_a^b x^2 \cdot \frac{1}{b-a} dx = \frac{a^2 + ab + b^2}{3}$$

$$\text{Var}(X) = \frac{a^2 + ab + b^2}{3} - \left(\frac{a+b}{2}\right)^2 = \frac{(b-a)^2}{12}$$

例 5.5: 指数分布的期望和方差

$X \sim \text{Exp}(\lambda)$:

$$E[X] = \int_0^{\infty} x \lambda e^{-\lambda x} dx = \frac{1}{\lambda}$$

(通过分部积分)

$$\text{Var}(X) = \frac{1}{\lambda^2}$$

5.5 随机变量函数的分布

已知 X 的分布, 如何求 $Y = g(X)$ 的分布? 这是概率论中的核心问题。

5.5.1 CDF 法 (万能方法)

基本思路: 先求 Y 的 CDF $F_Y(y) = P(Y \leq y) = P(g(X) \leq y)$, 再对 y 求导得到 PDF。

例 5.6 设 $X \sim \mathcal{N}(0, 1)$, 求 $Y = X^2$ 的 PDF。

解: 当 $y \leq 0$ 时, $F_Y(y) = 0$ 。当 $y > 0$ 时:

$$F_Y(y) = P(X^2 \leq y) = P(-\sqrt{y} \leq X \leq \sqrt{y}) = \Phi(\sqrt{y}) - \Phi(-\sqrt{y}) = 2\Phi(\sqrt{y}) - 1$$

求导:

$$f_Y(y) = 2\phi(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi y}} e^{-y/2}, \quad y > 0$$

这正是自由度为 **1** 的卡方分布 $\chi^2(1)$ 的 PDF。

5.5.2 公式法 (单调函数)

定理设 X 的 PDF 为 $f_X(x)$, $y = g(x)$ 是严格单调的可微函数, 反函数为 $x = g^{-1}(y)$, 则 $Y = g(X)$ 的 PDF 为:

$$f_Y(y) = f_X(g^{-1}(y)) \cdot \left| \frac{dg^{-1}(y)}{dy} \right|$$

直觉：概率“密度”在变量变换时，需要乘以 Jacobian 的绝对值来补偿坐标伸缩。

例 5.7 设 $X \sim \text{Exp}(\lambda)$ ，求 $Y = \sqrt{X}$ 的 PDF。

解： $g(x) = \sqrt{x}$ 在 $x > 0$ 上严格单调递增。反函数 $x = y^2$ ， $\frac{dx}{dy} = 2y$ 。

$$f_Y(y) = f_X(y^2) \cdot |2y| = \lambda e^{-\lambda y^2} \cdot 2y = 2\lambda y e^{-\lambda y^2}, \quad y > 0$$

例 5.8 设 $X \sim \mathcal{N}(\mu, \sigma^2)$ ，求 $Y = e^X$ （对数正态分布）的 PDF。

解： $g(x) = e^x$ 严格单调递增， $g^{-1}(y) = \ln y$ ， $\frac{d}{dy} \ln y = \frac{1}{y}$ 。

$$f_Y(y) = \frac{1}{\sqrt{2\pi}\sigma y} \exp\left(-\frac{(\ln y - \mu)^2}{2\sigma^2}\right), \quad y > 0$$

这就是对数正态分布 $\text{LogNormal}(\mu, \sigma^2)$ 的 PDF。

5.5.3 非单调函数的处理

当 $g(x)$ 不单调时，需将定义域分段为若干单调区间，分别求 PDF 后相加：

$$f_Y(y) = \sum_k f_X(x_k) \cdot \left| \frac{dx_k}{dy} \right|$$

其中 x_k 是方程 $g(x_k) = y$ 的各个根。例 5.6 中的 $Y = X^2$ 就是这种情况（ $X^2 = y$ 有两个根 $\pm\sqrt{y}$ ）。

5.6 矩母函数（连续情形）

定义

连续随机变量 X 的矩母函数（MGF）为：

$$M_X(t) = E[e^{tX}] = \int_{-\infty}^{+\infty} e^{tx} f(x) dx$$

性质与离散情形完全一致： $M_X^{(n)}(0) = E[X^n]$ 。

例 5.9: 正态分布的 MGF

设 $X \sim \mathcal{N}(\mu, \sigma^2)$, 则:

$$M_X(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right)$$

验证: $M'_X(0) = \mu = E[X] \square$, $M''_X(0) = \sigma^2 + \mu^2 = E[X^2] \square$

应用: 利用 MGF 证明独立正态之和仍为正态——若 $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$ 独立, 则 $S = \sum a_i X_i$ 的 MGF 为:

$$M_S(t) = \prod_i M_{X_i}(a_i t) = \exp\left(\sum_i a_i \mu_i \cdot t + \frac{\sum_i a_i^2 \sigma_i^2}{2} t^2\right)$$

这正是 $\mathcal{N}(\sum a_i \mu_i, \sum a_i^2 \sigma_i^2)$ 的 MGF, 由唯一性定理即得。

例 5.10: 指数分布的 MGF

设 $X \sim \text{Exp}(\lambda)$, 则对 $t < \lambda$:

$$M_X(t) = \int_0^\infty e^{tx} \lambda e^{-\lambda x} dx = \frac{\lambda}{\lambda - t}$$

常见分布的 MGF 汇总

分布	MGF $M_X(t)$	存在条件
Bernoulli(p)	$(1 - p) + pe^t$	所有 t
Binomial(n, p)	$[(1 - p) + pe^t]^n$	所有 t
Poisson(λ)	$e^{\lambda(e^t - 1)}$	所有 t
Exp(λ)	$\frac{\lambda}{\lambda - t}$	$t < \lambda$
$\mathcal{N}(\mu, \sigma^2)$	$e^{\mu t + \sigma^2 t^2 / 2}$	所有 t
Gamma(α, β)	$\left(\frac{\beta}{\beta - t}\right)^\alpha$	$t < \beta$

5.7 常用连续分布预览

正态分布 (高斯分布)

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

- 参数：均值 μ ，标准差 σ
- 记作： $X \sim \mathcal{N}(\mu, \sigma^2)$
- 特殊情况： $\mathcal{N}(0, 1)$ 是标准正态分布

标准正态分布

$$\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

CDF 记作 $\Phi(x)$ ，无解析表达式，通过查表或数值计算。

标准化

若 $X \sim \mathcal{N}(\mu, \sigma^2)$ ，则：

$$Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1)$$

分位数

定义随机变量 X 的 p 分位数 ($0 < p < 1$) 是满足 $F(x_p) = p$ 的值 x_p ，即：

$$x_p = F^{-1}(p) = \inf\{x : F(x) \geq p\}$$

- 中位数： $p = 0.5$ 的分位数，满足 $P(X \leq m) = 0.5$
- 四分位数： $Q_1 = x_{0.25}$ ， $Q_2 = x_{0.5}$ （中位数）， $Q_3 = x_{0.75}$

中位数与期望的区别：期望受极端值影响，中位数更稳健。

高阶矩：偏度与峰度

n 阶矩： $E[X^n]$ （原点矩）， $E[(X - \mu)^n]$ （中心矩）。

偏度（Skewness）衡量分布的不对称性：

$$\gamma_1 = \frac{E[(X - \mu)^3]}{\sigma^3}$$

- $\gamma_1 = 0$ ：对称分布（如正态分布）
- $\gamma_1 > 0$ ：右偏（长右尾），如指数分布
- $\gamma_1 < 0$ ：左偏（长左尾）

峰度（Kurtosis）衡量分布的尾部厚度：

$$\gamma_2 = \frac{E[(X - \mu)^4]}{\sigma^4} - 3$$

减去 3 是为了以正态分布为基准（正态分布的 $E[(X - \mu)^4]/\sigma^4 = 3$ ）。 $\gamma_2 > 0$ 称为尖峰（重尾）， $\gamma_2 < 0$ 称为平峰（轻尾）。

本章小结

概念	定义/公式
PDF	$f(x), P(a \leq X \leq b) = \int_a^b f(x)dx$
CDF	$F(x) = P(X \leq x) = \int_{-\infty}^x f(t)dt$
PDF-CDF 关系	$f(x) = F'(x)$
期望	$E[X] = \int x f(x)dx$
方差	$\text{Var}(X) = E[X^2] - (E[X])^2$
均匀分布	$E[X] = \frac{a+b}{2}, \text{Var}(X) = \frac{(b-a)^2}{12}$
指数分布	$E[X] = \frac{1}{\lambda}, \text{Var}(X) = \frac{1}{\lambda^2}$
变量变换（单调）	$f_Y(y) = f_X(g^{-1}(y)) \cdot dg^{-1}/dy $
矩母函数	$M_X(t) = E[e^{tX}], M_X^{(n)}(0) = E[X^n]$

核心要点：- 连续随机变量用密度函数描述，面积等于概率 - 单点概率为零，只有区间概率有意义 - 期望和方差的概念与离散情况一致，但求和变积分

深度学习应用：回归任务与损失函数

回归问题的概率视角

在深度学习回归任务中，我们假设目标变量 y 是连续随机变量，模型预测其条件分布：

$$y \mid \mathbf{x} \sim p(y \mid \mathbf{x}; \theta)$$

高斯假设与 MSE 损失

最常见的假设是目标变量服从高斯分布：

$$y \mid \mathbf{x} \sim \mathcal{N}(\mu(\mathbf{x}), \sigma^2)$$

其中 $\mu(\mathbf{x})$ 是神经网络的预测值。

负对数似然：

$$-\log p(y \mid \mathbf{x}) = \frac{(y - \mu(\mathbf{x}))^2}{2\sigma^2} + \frac{1}{2} \log(2\pi\sigma^2)$$

忽略与 μ 无关的常数项，最大化似然等价于最小化：

$$\mathcal{L} = (y - \hat{y})^2$$

这正是均方误差（MSE）损失！

拉普拉斯假设与 MAE 损失

若假设目标变量服从拉普拉斯分布：

$$f(y) = \frac{1}{2b} \exp\left(-\frac{|y - \mu|}{b}\right)$$

则负对数似然为：

$$-\log p(y \mid \mathbf{x}) \propto |y - \hat{y}|$$

这是平均绝对误差（MAE）损失。

异方差回归

如果预测方差也依赖于输入，可以让网络同时输出 $\mu(\mathbf{x})$ 和 $\sigma^2(\mathbf{x})$ ：

$$\mathcal{L} = \frac{(y - \mu)^2}{2\sigma^2} + \frac{1}{2} \log \sigma^2$$

这称为异方差回归，可以学习预测的不确定性。

PyTorch 代码示例

```
import torch
import torch.nn as nn
import numpy as np
import matplotlib.pyplot as plt

# 1. MSE 损失的概率解释
print("=== MSE 损失的概率解释 ===")

# 生成数据
torch.manual_seed(42)
x = torch.linspace(0, 10, 100).unsqueeze(1)
y_true = 2 * x + 1 + torch.randn_like(x) * 2 # 线性关系 + 高斯噪声

# 简单线性回归
class LinearRegression(nn.Module):
    def __init__(self):
        super().__init__()
        self.linear = nn.Linear(1, 1)

    def forward(self, x):
        return self.linear(x)

model = LinearRegression()
criterion = nn.MSELoss()
optimizer = torch.optim.SGD(model.parameters(), lr=0.01)

# 训练
for epoch in range(100):
    pred = model(x)
    loss = criterion(pred, y_true)
    optimizer.zero_grad()
    loss.backward()
    optimizer.step()

print(f" 训练后 MSE: {loss.item():.4f}")
print(f" 估计的噪声方差    ^2    MSE = {loss.item():.4f}")
print(f" 估计的噪声标准差    {np.sqrt(loss.item()):.4f}")

# 2. MSE vs MAE
```



```
print("\n=== MSE vs MAE 比较 ===")

# 带异常值的数据
y_outlier = y_true.clone()
y_outlier[50] = 100 # 添加异常值

mse_loss = nn.MSELoss()(model(x), y_outlier)
mae_loss = nn.L1Loss()(model(x), y_outlier)

print(f" 有异常值时 MSE: {mse_loss.item():.4f}")
print(f" 有异常值时 MAE: {mae_loss.item():.4f}")
print("MAE 对异常值更鲁棒 (拉普拉斯假设) ")

# 3. 概率密度函数可视化
print("\n=== PDF 可视化 ===")

# 高斯 PDF
def gaussian_pdf(x, mu, sigma):
    return (1 / (np.sqrt(2 * np.pi) * sigma)) * np.exp(-0.5 * ((x - mu) / sigma) ** 2)

# 拉普拉斯 PDF
def laplace_pdf(x, mu, b):
    return (1 / (2 * b)) * np.exp(-np.abs(x - mu) / b)

x_range = np.linspace(-5, 5, 200)
gaussian = gaussian_pdf(x_range, 0, 1)
laplace = laplace_pdf(x_range, 0, 1)

print(f" 高斯 PDF 在 x=0 的值: {gaussian_pdf(0, 0, 1):.4f}")
print(f" 拉普拉斯 PDF 在 x=0 的值: {laplace_pdf(0, 0, 1):.4f}")

# 4. 验证 PDF 性质
print("\n=== PDF 性质验证 ===")

# 数值积分验证归一化
from scipy import integrate

area_gaussian, _ = integrate.quad(lambda x: gaussian_pdf(x, 0, 1), -10, 10)
area_laplace, _ = integrate.quad(lambda x: laplace_pdf(x, 0, 1), -10, 10)

print(f" 高斯 PDF 面积: {area_gaussian:.6f}")
```

```

print(f" 拉普拉斯 PDF 面积: {area_laplace:.6f}")

# 验证期望和方差
mean_gaussian, _ = integrate.quad(lambda x: x * gaussian_pdf(x, 0, 1), -10, 10)
var_gaussian, _ = integrate.quad(lambda x: x**2 * gaussian_pdf(x, 0, 1), -10, 10)

print(f" 高斯分布 (0,1) 期望: {mean_gaussian:.6f}")
print(f" 高斯分布 (0,1) 方差: {var_gaussian:.6f}")

# 5. 异方差回归
print("\n=== 异方差回归 ===")

class HeteroscedasticRegression(nn.Module):
    """ 同时预测均值和方差的网络 """
    def __init__(self, input_dim, hidden_dim):
        super().__init__()
        self.shared = nn.Sequential(
            nn.Linear(input_dim, hidden_dim),
            nn.ReLU()
        )
        self.mu_head = nn.Linear(hidden_dim, 1) # 预测均值
        self.logvar_head = nn.Linear(hidden_dim, 1) # 预测 log(方差)

    def forward(self, x):
        h = self.shared(x)
        mu = self.mu_head(h)
        log_var = self.logvar_head(h)
        return mu, log_var

    def negative_log_likelihood(self, y_true, mu, log_var):
        """ 高斯负对数似然 """
        var = torch.exp(log_var)
        nll = 0.5 * ((y_true - mu)**2 / var + log_var)
        return nll.mean()

# 创建异方差数据: 方差随 x 增加
x_hetero = torch.linspace(0, 10, 200).unsqueeze(1)
noise_std = 0.5 + 0.3 * x_hetero # 方差随 x 增加
y_hetero = 2 * x_hetero + 1 + torch.randn_like(x_hetero) * noise_std

model_hetero = HeteroscedasticRegression(1, 32)

```

```
optimizer = torch.optim.Adam(model_hetero.parameters(), lr=0.01)

for epoch in range(500):
    mu, log_var = model_hetero(x_hetero)
    loss = model_hetero.negative_log_likelihood(y_hetero, mu, log_var)
    optimizer.zero_grad()
    loss.backward()
    optimizer.step()

mu_pred, log_var_pred = model_hetero(x_hetero)
std_pred = torch.exp(0.5 * log_var_pred)

print(f" 异方差回归损失: {loss.item():.4f}")
print(f" 预测标准差范围: [{std_pred.min().item():.2f}, {std_pred.max().item():.2f}]")
print(" 模型学会了预测随 x 增加的不确定性!")

# 6. CDF 与分位数
print("\n=== CDF 与分位数 ===")

from scipy.stats import norm

# 标准正态分布的 CDF
print(" 标准正态分布 N(0,1):")
print(f" P(X = 0) =  $\Phi(0)$  = {norm.cdf(0):.4f}")
print(f" P(X = 1.96) =  $\Phi(1.96)$  = {norm.cdf(1.96):.4f}")
print(f" P(-1.96 ≤ X ≤ 1.96) = {norm.cdf(1.96) - norm.cdf(-1.96):.4f}")
print(f" 95% 分位数: {norm.ppf(0.95):.4f}")
```

输出:

=== MSE损失的概率解释 ===

训练后 MSE: 3.8521

估计的噪声方差 σ^2 MSE = 3.8521

估计的噪声标准差 1.9627

=== MSE vs MAE 比较 ===

有异常值时 MSE: 98.4521

有异常值时 MAE: 4.8234

MAE对异常值更鲁棒 (拉普拉斯假设)

=== PDF可视化 ===

高斯PDF在x=0的值: 0.3989

拉普拉斯PDF在 $x=0$ 的值: 0.5000

=== PDF性质验证 ===

高斯PDF面积: 1.000000

拉普拉斯PDF面积: 1.000000

高斯分布(0,1)期望: 0.000000

高斯分布(0,1)方差: 1.000000

=== 异方差回归 ===

异方差回归损失: 0.9234

预测标准差范围: [0.58, 1.42]

模型学会了预测随 x 增加的不确定性!

=== CDF与分位数 ===

标准正态分布 $N(0,1)$:

$$P(X \leq 0) = \Phi(0) = 0.5000$$

$$P(X \leq 1.96) = \Phi(1.96) = 0.9750$$

$$P(-1.96 \leq X \leq 1.96) = 0.9500$$

95%分位数: 1.6449

关键联系

概率论概念	深度学习对应
连续随机变量	回归目标
高斯分布	MSE 损失的隐含假设
拉普拉斯分布	MAE 损失的隐含假设
负对数似然	损失函数
方差	预测不确定性
CDF	分位数回归

练习题

练习 5.1 (基础)

设连续随机变量 X 的 PDF 为:

$$f(x) = \begin{cases} cx^2 & 0 \leq x \leq 1 \\ 0 & \text{其他} \end{cases}$$

- (a) 求常数 c
- (b) 求 CDF $F(x)$
- (c) 计算 $P(0.5 \leq X \leq 1)$

练习 5.2 (计算)

设 $X \sim \text{Uniform}(0, 1)$, 令 $Y = -\ln X$ 。

- (a) 求 Y 的 CDF
- (b) 求 Y 的 PDF
- (c) Y 服从什么分布?

练习 5.3 (理解)

证明: 若 X 是连续随机变量, F 是其 CDF, 则 $Y = F(X) \sim \text{Uniform}(0, 1)$ 。

(提示: 这是概率积分变换, 是逆变换采样的理论基础)

练习 5.4 (应用)

一个回归模型的 MSE 损失为 4.0。

- (a) 若假设目标变量服从高斯分布, 估计噪声标准差
- (b) 若要使 95% 的预测误差落在 $\pm k$ 范围内, k 应该是多少?
- (c) 为什么 MSE 损失对异常值敏感?

练习 5.5 (深度学习)

考虑异方差回归的负对数似然损失:

$$\mathcal{L} = \frac{1}{2} \left(\frac{(y - \mu)^2}{\sigma^2} + \log \sigma^2 \right)$$

- (a) 若 σ^2 固定, 这简化为什么损失?
- (b) 对 σ^2 求导, 找到最优的 σ^2 表达式
- (c) 为什么需要 $\log \sigma^2$ 项? 如果没有会怎样?

练习答案

点击展开练习 5.1 答案

(a) 由归一化条件:

$$\int_0^1 cx^2 dx = c \cdot \frac{x^3}{3} \Big|_0^1 = \frac{c}{3} = 1$$

$$c = 3$$

(b) CDF:

对于 $0 \leq x \leq 1$:

$$F(x) = \int_0^x 3t^2 dt = t^3 \Big|_0^x = x^3$$

完整 CDF:

$$F(x) = \begin{cases} 0 & x < 0 \\ x^3 & 0 \leq x \leq 1 \\ 1 & x > 1 \end{cases}$$

(c)

$$P(0.5 \leq X \leq 1) = F(1) - F(0.5) = 1 - 0.125 = 0.875$$

点击展开练习 5.2 答案

(a) $Y = -\ln X$ 的 CDF:

对于 $y \geq 0$:

$$\begin{aligned} F_Y(y) &= P(Y \leq y) = P(-\ln X \leq y) = P(\ln X \geq -y) = P(X \geq e^{-y}) \\ &= 1 - P(X < e^{-y}) = 1 - e^{-y} \end{aligned}$$

(因为 $X \sim U(0, 1)$, $P(X < t) = t$ 对 $t \in [0, 1]$)

(b) PDF:

$$f_Y(y) = \frac{d}{dy} F_Y(y) = e^{-y}, \quad y \geq 0$$

(c) $Y \sim \text{Exp}(1)$, 即参数为 1 的指数分布。

这是逆变换采样的一个重要应用: 从均匀分布生成指数分布。

点击展开练习 5.3 答案

设 $Y = F(X)$, 需证 $Y \sim U(0, 1)$ 。

对于 $0 \leq y \leq 1$:

$$P(Y \leq y) = P(F(X) \leq y)$$

设 F^{-1} 是 F 的广义逆 (分位数函数)。由于 F 单调递增:

$$P(F(X) \leq y) = P(X \leq F^{-1}(y)) = F(F^{-1}(y)) = y$$

因此 $P(Y \leq y) = y$, 这正是 $U(0, 1)$ 的 CDF。

意义: 这说明任何连续分布可以通过其 CDF 变换为均匀分布, 反之亦然 (逆变换采样)。

点击展开练习 5.4 答案

(a) $\text{MSE} = 4.0 = \sigma^2$, 所以 $\sigma = 2$ 。

(b) 95% 置信区间对应 $\pm 1.96\sigma$:

$$k = 1.96 \times 2 = 3.92$$

(c) MSE 损失对异常值敏感的原因:

$MSE = (y - \hat{y})^2$, 误差被平方放大: - 误差为 2 时, 损失为 4 - 误差为 10 时, 损失为 100

这源于高斯分布的轻尾特性: 大偏差的概率指数级衰减, 所以高斯假设下大误差代价很高。

相比之下, $MAE = |y - \hat{y}|$ 线性惩罚, 对应重尾的拉普拉斯分布, 对异常值更鲁棒。

点击展开练习 5.5 答案

(a) 若 σ^2 固定:

$$\mathcal{L} = \frac{(y - \mu)^2}{2\sigma^2} + \text{const}$$

最小化这个损失等价于最小化 $(y - \mu)^2$, 即 MSE 损失。

(b) 对 σ^2 求导:

$$\frac{\partial \mathcal{L}}{\partial \sigma^2} = -\frac{(y - \mu)^2}{2\sigma^4} + \frac{1}{2\sigma^2} = 0$$

解得:

$$\sigma^2 = (y - \mu)^2$$

即最优方差等于残差的平方。

(c) $\log \sigma^2$ 项的作用:

如果没有这一项, 损失变为 $\frac{(y - \mu)^2}{\sigma^2}$ 。模型可以通过让 $\sigma^2 \rightarrow \infty$ 来使损失趋于 0, 这是平凡解。

$\log \sigma^2$ 项惩罚过大的方差, 迫使模型在准确预测 (小 $(y - \mu)^2$) 和确定预测 (小 σ^2) 之间取得平衡。

几何示意

图 5-1: 连续 PDF (标准正态钟形 + 阴影面积)

图 5-2: PDF 与 CDF 对应关系

图 5-3: 标准正态 Φ 函数图象






图 10: 标准正态概率密度函数钟形曲线与阴影面积



$$f(x) = F'(x) \text{ (导数关系)} \quad F(x) = \int_{-\infty}^x f(t) dt \text{ (积分关系)}$$

图 11: 连续随机变量概率密度函数与累积分布函数对应关系

图 12: 标准正态累积分布函数 $\Phi(x)$ 图象

思考路标（条件反射）

- 看到 PDF $f(x) \rightarrow$ 验证两条: $f(x) \geq 0$, $\int_{-\infty}^{+\infty} f(x) dx = 1$
- 看到 CDF 连续型 $\rightarrow F(x) = \int_{-\infty}^x f(t) dt$; 反向: $f(x) = F'(x)$
- 看到”区间概率” $\rightarrow P(a < X < b) = F(b) - F(a) = \int_a^b f(x) dx$
- 看到”求连续期望” $\rightarrow E[X] = \int_{-\infty}^{+\infty} xf(x) dx$ (积分形式)
- 看到”求连续方差” $\rightarrow$ 同样: $\text{Var}(X) = E[X^2] - (E[X])^2$, $E[X^2] = \int x^2 f(x) dx$
- 看到” $P(X = a) = ?$ ” $\rightarrow$ 连续型单点概率为 **0** (但 a 可以在支撑集内取到)
- 看到” $Y = g(X)$ 求 PDF” $\rightarrow$ 严格单调时用 Jacobian: $f_Y(y) = f_X(g^{-1}(y)) \cdot |dg^{-1}/dy|$
- 看到”标准正态 $\Phi(x)$ ” $\rightarrow$ 利用对称性: $\Phi(-x) = 1 - \Phi(x)$; $P(a < Z < b) = \Phi(b) - \Phi(a)$

易错点

1. **PDF 可以大于 1**: $f(x)$ 是密度而非概率, $f(x) > 1$ 完全合法 (如 $\text{Uniform}(0, 0.5)$ 时 $f = 2$); 概率是面积, 不是高度。
2. $P(X = a) = 0$ 但 a 可以被取到: 单点概率为零意味着在该点处的”质量”无穷小, 不是说 a 不可能出现; 区间端点是否含入不影响概率计算。
3. **函数变换必须乘 Jacobian**: $Y = g(X)$ 时 $f_Y(y) \neq f_X(g^{-1}(y))$, 漏掉 $|dg^{-1}/dy|$ 是最常见失误; g 非单调时还需分段处理并求和。
4. 期望积分收敛性: $E[X]$ 存在要求 $\int |x|f(x) dx < \infty$; 柯西分布没有期望 (积分发散) 是典型反例。
5. 标准正态查表方向: $\Phi(x)$ 表给出 $P(Z \leq x)$; 求 $P(Z > x)$ 用 $1 - \Phi(x)$; 求 $P(Z \leq -x)$ 用 $\Phi(-x) = 1 - \Phi(x)$, 不要直接从负值那列查 (许多教材没有)。

第6章多维随机变量

难度：★★★☆☆ 前置知识：第4章离散随机变量、第5章连续随机变量、多元微积分基础

一例速记：- 联合 PMF/PDF $f(x, y) \rightarrow$ 边缘 $f_X(x) = \int f(x, y) dy \rightarrow$ 条件 $f(y|x) = f(x, y)/f_X(x)$ - 独立判别： $f(x, y) = f_X(x)f_Y(y)$ 对所有 (x, y) 成立 - 协方差 $\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$ ；相关系数 $\rho = \text{Cov}(X, Y)/(\sigma_X\sigma_Y) \in [-1, 1]$ - 独立 $\Rightarrow \text{Cov} = 0$ （反之不成立，正态除外） - 二元正态条件分布仍是正态（重要性质）

引入题

(X, Y) 服从二元正态 $N(0, 0, 1, 1, \rho)$ ，求条件分布 $Y|X = x$ 。

思维路径还原

识别题型：已知联合分布，求条件分布——标准三步走：联合 $\rightarrow$ 边缘 $\rightarrow$ 条件。

第一步：写出联合 PDF

$$f(x, y) = \frac{1}{2\pi\sqrt{1-\rho^2}} \exp\left[-\frac{x^2 - 2\rho xy + y^2}{2(1-\rho^2)}\right]$$

第二步：求边缘 $f_X(x)$ （对 y 从 $-\infty$ 到 $+\infty$ 积分）

对 y 凑完全平方后，积分核变为正态核，结果是标准正态 PDF：

$$f_X(x) = \phi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

第三步：写出条件 PDF

$$f(y|x) = \frac{f(x, y)}{f_X(x)}$$

第四步：化简（凑 y 的完全平方）

将指数部分 $x^2 - 2\rho xy + y^2$ 改写：提出含 x^2 的部分后， y 方向剩余

$$(y - \rho x)^2 / (1 - \rho^2)$$

因此条件 PDF 正比于 $\exp[-\frac{(y-\rho x)^2}{2(1-\rho^2)}]$ ，这是均值 ρx 、方差 $1-\rho^2$ 的正态核。

结果： $Y|X=x \sim N(\rho x, 1-\rho^2)$

两个关键启示：

1. 条件均值 ρx 是 x 的线性函数——斜率恰好是相关系数 ρ ；这就是线性回归中“当 X, Y 标准化时，回归系数等于相关系数”的概率论根源。
 2. 条件方差 $1-\rho^2 \leq 1$ ——知道 X 的取值后， Y 的不确定性从 1 减小到 $1-\rho^2$ ； $|\rho|$ 越大，条件信息越能压缩不确定性； $\rho = \pm 1$ 时条件方差为零， Y 被 X 完全确定。
-

学习目标

- 理解二维随机变量的联合分布函数、联合 PMF 与联合 PDF 的定义和性质
 - 掌握从联合分布求边缘分布的方法（积分/求和）
 - 理解条件分布与条件期望的概念及计算方法
 - 熟练计算协方差和相关系数，判断随机变量的独立性
 - 建立多维随机变量与深度学习多任务学习、特征相关性分析的联系
-

6.1 二维随机变量的概念

从一维到多维

在实际问题中，我们常常需要同时研究两个或多个随机变量。例如：

- 一个人的身高 X 和体重 Y
- 图像的亮度 X 和对比度 Y
- 神经网络中两个神经元的激活值 X 和 Y

这些变量之间往往存在某种关联，需要用多维随机变量来联合描述。

二维随机变量的定义

设 X 和 Y 是定义在同一样本空间 Ω 上的两个随机变量，则称 (X, Y) 为二维随机变量（或随机向量）。

二维随机变量 (X, Y) 的每次取值是平面上的一个点 (x, y) 。

二维随机变量的分类

与一维情况类似：

- 二维离散型：\$(X, Y)\$ 只取有限或可数个点对 \$(x_i, y_j)\$
- 二维连续型：\$(X, Y)\$ 可取某个平面区域内的任意值

直观理解：散点图

二维随机变量可以直观地用散点图表示：每次实验对应平面上的一个点。

- 若 \$X\$ 和 \$Y\$ 相互独立，散点分布是“圆形云”
 - 若 \$X\$ 和 \$Y\$ 正相关，散点呈“右上-左下”的椭圆形
 - 若 \$X\$ 和 \$Y\$ 负相关，散点呈“左上-右下”的椭圆形
-

6.2 联合分布函数与联合概率

联合分布函数 (Joint CDF)

二维随机变量 \$(X, Y)\$ 的联合分布函数定义为：

$$F(x, y) = P(X \leq x, Y \leq y), \quad (x, y) \in \mathbb{R}^2$$

联合 CDF 的性质

1. 单调性：关于 \$x\$ 和 \$y\$ 分别单调不减
2. 边界条件：
 - \$F(-\infty, y) = 0, F(x, -\infty) = 0\$
 - \$F(+\infty, +\infty) = 1\$
3. 右连续性：关于 \$x\$ 和 \$y\$ 分别右连续
4. 矩形概率公式：

$$P(a < X \leq b, c < Y \leq d) = F(b, d) - F(a, d) - F(b, c) + F(a, c)$$

离散型：联合概率质量函数 (Joint PMF)

若 \$(X, Y)\$ 是离散型随机变量，其联合概率质量函数为：

$$p(x_i, y_j) = P(X = x_i, Y = y_j), \quad i, j = 1, 2, \dots$$

Joint PMF 的性质

1. 非负性: $p(x_i, y_j) \geq 0$
2. 归一化: $\sum_i \sum_j p(x_i, y_j) = 1$

例 6.1: 联合 PMF 投掷两枚硬币, 设 X 为第一枚正面朝上的次数, Y 为第二枚正面朝上的次数。

$$p(x, y) = \frac{1}{4}, \quad x \in \{0, 1\}, y \in \{0, 1\}$$

	$Y = 0$	$Y = 1$
$X = 0$	1/4	1/4
$X = 1$	1/4	1/4

连续型: 联合概率密度函数 (Joint PDF)

若存在非负函数 $f(x, y)$ 使得:

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(s, t) dt ds$$

则称 $f(x, y)$ 为 (X, Y) 的联合概率密度函数。

Joint PDF 的性质

1. 非负性: $f(x, y) \geq 0$
2. 归一化: $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1$
3. 区域概率: 对平面区域 D , 有

$$P((X, Y) \in D) = \iint_D f(x, y) dx dy$$

例 6.2: 联合 PDF 验证 设 $f(x, y) = c \cdot e^{-(2x+y)}$, $x \geq 0, y \geq 0$, 其他处为 0。

求常数 c :

$$\int_0^{\infty} \int_0^{\infty} c \cdot e^{-(2x+y)} dy dx = c \int_0^{\infty} e^{-2x} dx \cdot \int_0^{\infty} e^{-y} dy = c \cdot \frac{1}{2} \cdot 1 = \frac{c}{2} = 1$$

故 $c = 2$ 。

二维正态分布

最重要的二维连续分布是二维正态分布 $\mathcal{N}(\mu, \Sigma)$ ，其 PDF 为：

$$f(x, y) = \frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}} \exp\left(-\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_X)^2}{\sigma_X^2} - \frac{2\rho(x-\mu_X)(y-\mu_Y)}{\sigma_X\sigma_Y} + \frac{(y-\mu_Y)^2}{\sigma_Y^2} \right]\right)$$

其中：- μ_X, μ_Y ：均值 - σ_X^2, σ_Y^2 ：方差 - ρ ：相关系数 ($|\rho| < 1$)

6.3 边缘分布

边缘分布的概念

从联合分布 (X, Y) 中，仅考察单个变量的分布，称为边缘分布 (Marginal Distribution)。

边缘分布是”把另一个变量积分/求和掉”的结果。

离散型的边缘分布

X 的边缘 PMF：

$$p_X(x_i) = P(X = x_i) = \sum_j p(x_i, y_j)$$

Y 的边缘 PMF：

$$p_Y(y_j) = P(Y = y_j) = \sum_i p(x_i, y_j)$$

直观理解：对联合分布表格按行或列求和。

例 6.3：从联合 PMF 求边缘 PMF

	$Y = 0$	$Y = 1$	$Y = 2$	$p_X(x)$
$X = 0$	0.1	0.2	0.1	0.4
$X = 1$	0.2	0.3	0.1	0.6
$p_Y(y)$	0.3	0.5	0.2	1.0

边缘分布就是表格最右列和最下行的数值。

连续型的边缘分布

X 的边缘 PDF (对 y 积分):

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy$$

Y 的边缘 PDF (对 x 积分):

$$f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$$

例 6.4: 从联合 PDF 求边缘 PDF 已知 $f(x, y) = 2e^{-(2x+y)}$, $x \geq 0, y \geq 0$ 。

X 的边缘 PDF:

$$f_X(x) = \int_0^{\infty} 2e^{-(2x+y)} dy = 2e^{-2x} \int_0^{\infty} e^{-y} dy = 2e^{-2x}, \quad x \geq 0$$

$X \sim \text{Exp}(2)$

Y 的边缘 PDF:

$$f_Y(y) = \int_0^{\infty} 2e^{-(2x+y)} dx = 2e^{-y} \cdot \frac{1}{2} = e^{-y}, \quad y \geq 0$$

$Y \sim \text{Exp}(1)$

独立性的判断

X 和 Y 相互独立, 当且仅当联合分布等于边缘分布的乘积:

- 离散型: $p(x_i, y_j) = p_X(x_i) \cdot p_Y(y_j)$, 对所有 i, j 成立
- 连续型: $f(x, y) = f_X(x) \cdot f_Y(y)$, 对几乎所有 (x, y) 成立

例 6.5: 验证独立性 对例 6.4: $f(x, y) = 2e^{-(2x+y)} = 2e^{-2x} \cdot e^{-y} = f_X(x) \cdot f_Y(y)$

故 X 与 Y 相互独立。

注意: 联合分布的定义域必须是矩形区域 (或全平面), 否则即便乘积形式也未必独立。

6.4 条件分布

条件分布的直觉

“在已知 $Y = y$ 的条件下， X 的分布是什么？”

这正是条件分布所回答的问题。条件分布是贝叶斯推断、因果推理的核心工具。

离散型条件分布

在 $Y = y_j$ 的条件下， X 的条件 **PMF** 为：

$$P(X = x_i | Y = y_j) = \frac{P(X = x_i, Y = y_j)}{P(Y = y_j)} = \frac{p(x_i, y_j)}{p_Y(y_j)}$$

前提： $p_Y(y_j) > 0$ 。

连续型条件分布

在 $Y = y$ 的条件下， X 的条件 **PDF** 为：

$$f_{X|Y}(x | y) = \frac{f(x, y)}{f_Y(y)}$$

前提： $f_Y(y) > 0$ 。

注意：连续型中 $P(Y = y) = 0$ ，条件 PDF 通过极限定义：

$$f_{X|Y}(x | y) = \lim_{\varepsilon \rightarrow 0} \frac{P(X \leq x | y < Y \leq y + \varepsilon)}{\varepsilon}$$

例 6.6：计算条件 PDF 已知 $f(x, y) = 2e^{-(2x+y)}$ ， $x \geq 0, y \geq 0$ 。

由例 6.4， $f_Y(y) = e^{-y}$ ，故：

$$f_{X|Y}(x | y) = \frac{2e^{-(2x+y)}}{e^{-y}} = 2e^{-2x}, \quad x \geq 0$$

这表明在已知 $Y = y$ 的条件下， X 的条件分布仍是 $\text{Exp}(2)$ ，与 y 无关——这正是独立性的体现。

条件期望

在 $Y = y$ 条件下, X 的条件期望为:

$$E[X | Y = y] = \begin{cases} \sum_i x_i \cdot P(X = x_i | Y = y) & \text{离散型} \\ \int_{-\infty}^{+\infty} x \cdot f_{X|Y}(x | y) dx & \text{连续型} \end{cases}$$

全期望公式 (迭代期望公式)

$$E[X] = E[E[X | Y]]$$

展开为:

- 离散型: $E[X] = \sum_j E[X | Y = y_j] \cdot P(Y = y_j)$
- 连续型: $E[X] = \int E[X | Y = y] \cdot f_Y(y) dy$

例 6.7: 全期望公式应用 一家工厂有两条生产线。第一条以概率 0.6 被选中, 产品合格率 80%; 第二条以概率 0.4 被选中, 合格率 90%。

设 Y 为生产线编号, X 为产品是否合格, 则:

$$\begin{aligned} E[X] &= E[X | Y = 1] \cdot P(Y = 1) + E[X | Y = 2] \cdot P(Y = 2) \\ &= 0.8 \times 0.6 + 0.9 \times 0.4 = 0.48 + 0.36 = 0.84 \end{aligned}$$

整体合格率为 84%。

贝叶斯定理的密度形式

$$f_{Y|X}(y | x) = \frac{f_{X|Y}(x | y) \cdot f_Y(y)}{f_X(x)}$$

这是贝叶斯推断的数学基础, 在深度学习的变分自编码器 (VAE) 中有直接应用。

条件方差

定义在 $Y = y$ 条件下, X 的条件方差为:

$$\text{Var}(X | Y = y) = E[(X - E[X | Y = y])^2 | Y = y] = E[X^2 | Y = y] - (E[X | Y = y])^2$$

将 y 视为变量, $\text{Var}(X | Y)$ 本身是 Y 的函数, 因此也是一个随机变量。

全方差公式 (Law of Total Variance)

$$\text{Var}(X) = E[\text{Var}(X | Y)] + \text{Var}(E[X | Y])$$

直觉理解: 总方差 = 组内方差的期望 + 组间方差。

- $E[\text{Var}(X | Y)]$: 各“组”(给定 Y 的值)内部的方差, 取平均
- $\text{Var}(E[X | Y])$: 各“组”均值之间的波动

证明:

$$\text{Var}(X) = E[X^2] - (E[X])^2$$

利用全期望公式 $E[X^2] = E[E[X^2 | Y]]$, $E[X] = E[E[X | Y]]$, 以及 $E[X^2 | Y] = \text{Var}(X | Y) + (E[X | Y])^2$, 代入展开整理即得。□

例 6.8b: 全方差公式应用 某保险公司有两类客户: 低风险(占比 70%)和高风险(占比 30%)。低风险客户年索赔额 X 的条件分布为 $E[X | \text{低}] = 200$, $\text{Var}(X | \text{低}) = 1000$; 高风险客户 $E[X | \text{高}] = 800$, $\text{Var}(X | \text{高}) = 5000$ 。

组内方差期望: $E[\text{Var}(X | Y)] = 0.7 \times 1000 + 0.3 \times 5000 = 2200$

组间方差: $E[E[X | Y]] = 0.7 \times 200 + 0.3 \times 800 = 380$

$$\text{Var}(E[X | Y]) = 0.7 \times (200 - 380)^2 + 0.3 \times (800 - 380)^2 = 0.7 \times 32400 + 0.3 \times 176400 = 75600$$

$$\text{Var}(X) = 2200 + 75600 = 77800$$

可以看到, 客户类别差异(组间方差)对总方差的贡献远大于组内波动。

6.5 协方差与相关系数

为什么需要协方差?

期望和方差描述单个随机变量，但无法刻画两个变量之间的线性关联程度。协方差正是用来度量这种关联的。

协方差的定义

X 和 Y 的协方差 (Covariance) 定义为:

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

等价计算公式 (更常用):

$$\text{Cov}(X, Y) = E[XY] - E[X] \cdot E[Y]$$

协方差的直觉

- $\text{Cov}(X, Y) > 0$: X 大时 Y 趋向大, 正相关
- $\text{Cov}(X, Y) < 0$: X 大时 Y 趋向小, 负相关
- $\text{Cov}(X, Y) = 0$: 线性不相关 (注意: 不等于独立)

协方差的性质

1. 对称性: $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
2. 自协方差: $\text{Cov}(X, X) = \text{Var}(X)$
3. 线性性: $\text{Cov}(aX + b, cY + d) = ac \cdot \text{Cov}(X, Y)$
4. 双线性: $\text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y)$
5. 独立推不相关: 若 X, Y 独立, 则 $\text{Cov}(X, Y) = 0$ (反之不成立)
6. 方差加法公式: $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$

相关系数的定义

协方差受量纲影响, 不便比较。相关系数 (Pearson Correlation Coefficient) 通过标准化消除量纲:

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \cdot \text{Var}(Y)}} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

相关系数的性质

1. 有界性: $-1 \leq \rho_{XY} \leq 1$
2. 完全线性相关: $|\rho_{XY}| = 1$ 当且仅当 $Y = aX + b$ ($a \neq 0$)
3. 无量纲: ρ 是纯数, 便于不同场景比较
4. $\rho = 0$: 线性不相关, 但不代表独立 (可能有非线性关系)

例 6.8: 计算协方差和相关系数

设联合分布为:

	$Y = 0$	$Y = 2$
$X = 0$	0.3	0.1
$X = 1$	0.2	0.4

计算边缘期望:

$$E[X] = 0 \times 0.4 + 1 \times 0.6 = 0.6$$

$$E[Y] = 0 \times 0.5 + 2 \times 0.5 = 1.0$$

$$E[XY] = 0 \cdot 0 \cdot 0.3 + 0 \cdot 2 \cdot 0.1 + 1 \cdot 0 \cdot 0.2 + 1 \cdot 2 \cdot 0.4 = 0.8$$

协方差:

$$\text{Cov}(X, Y) = E[XY] - E[X]E[Y] = 0.8 - 0.6 \times 1.0 = 0.2$$

方差:

$$E[X^2] = 0^2 \times 0.4 + 1^2 \times 0.6 = 0.6, \quad \text{Var}(X) = 0.6 - 0.36 = 0.24$$

$$E[Y^2] = 0^2 \times 0.5 + 4 \times 0.5 = 2.0, \quad \text{Var}(Y) = 2.0 - 1.0 = 1.0$$

相关系数:

$$\rho_{XY} = \frac{0.2}{\sqrt{0.24 \times 1.0}} = \frac{0.2}{\sqrt{0.24}} \approx 0.408$$

协方差矩阵

对 n 维随机向量 $\mathbf{X} = (X_1, X_2, \dots, X_n)^T$ ，协方差矩阵定义为：

$$\Sigma = \text{Cov}(\mathbf{X}) = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^T]$$

其中 $\Sigma_{ij} = \text{Cov}(X_i, X_j)$ ，对角元素 $\Sigma_{ii} = \text{Var}(X_i)$ 。

协方差矩阵的性质：- 对称正半定： $\Sigma = \Sigma^T$ ， $\mathbf{v}^T \Sigma \mathbf{v} \geq 0$ 对任意向量 $\mathbf{v}$

不相关 vs 独立

	离散型	连续型
独立 $\Rightarrow$ 不相关	成立	成立
不相关 $\Rightarrow$ 独立	不成立	不成立

反例：设 $X \sim \text{Uniform}(-1, 1)$ ， $Y = X^2$ 。

$$E[X] = 0, \quad E[XY] = E[X^3] = \int_{-1}^1 x^3 \cdot \frac{1}{2} dx = 0$$

故 $\text{Cov}(X, Y) = 0$ ， X 与 Y 不相关。

但 Y 完全由 X 决定，二者并不独立！

本章小结

概念	离散型	连续型
联合分布	$p(x_i, y_j) = P(X = x_i, Y = y_j)$	$f(x, y)$ ，区域积分得概率
归一化	$\sum_i \sum_j p(x_i, y_j) = 1$	$\iint f(x, y) dx dy = 1$
边缘分布	$p_X(x_i) = \sum_j p(x_i, y_j)$	$f_X(x) = \int f(x, y) dy$
条件分布	$P(X = x_i Y = y_j) = \frac{p(x_i, y_j)}{p_Y(y_j)}$	$f_{X Y}(x y) = \frac{f(x, y)}{f_Y(y)}$
独立性	$p(x_i, y_j) = p_X(x_i)p_Y(y_j)$	$f(x, y) = f_X(x)f_Y(y)$
协方差	$\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$	(离散 / 连续公式相同)
相关系数	$\rho = \text{Cov}(X, Y) / (\sigma_X \sigma_Y)$ ， $ \rho \leq 1$	(离散 / 连续公式相同)

核心要点：- 联合分布包含两个变量的全部概率信息，边缘分布是联合分布的“投影”- 独立性意味着联合分布可以分解为边缘分布之积 - 协方差度量线性关联，相关系数是标准化后的协方差 - 不相关不等于独立：不相关只排除线性关系，独立排除一切关系 - 全期望公式： $E[X] = E[E[X | Y]]$ - 全方差公式： $\text{Var}(X) = E[\text{Var}(X | Y)] + \text{Var}(E[X | Y])$ （总方差 = 组内方差期望 + 组间方差）

深度学习应用：多任务学习与特征相关性

多任务学习的概率视角

多任务学习 (Multi-Task Learning, MTL) 是指让模型同时学习多个相关任务。从概率论角度看，多任务学习建模的是多个输出变量的联合分布：

$$p(y_1, y_2, \dots, y_K | \mathbf{x})$$

当任务之间存在正相关 ($\text{Cov}(Y_i, Y_j) > 0$)，共享信息有助于提升各任务的性能。

特征协方差矩阵

在深度学习中，协方差矩阵有以下重要应用：

1. 主成分分析 (PCA)：对特征协方差矩阵做特征值分解，找主要变化方向
2. 批归一化 (Batch Norm)：利用批内统计量（均值、方差）规范化特征
3. 注意力机制：QK 点积本质上是计算特征相关性
4. 任务相关性建模：协方差矩阵直接编码任务间的统计依赖

协方差正则化（多任务学习）

若有两个任务，输出 Y_1 和 Y_2 ，模型的多任务损失可以写为：

$$\mathcal{L} = \mathcal{L}_1 + \mathcal{L}_2 + \lambda \cdot \text{penalty}(\text{Cov}(Y_1, Y_2))$$

通过约束任务输出的协方差，可以鼓励任务共享或分离特征。

PyTorch 代码示例

```
import torch
import torch.nn as nn
import numpy as np
```

```

torch.manual_seed(42)

# =====
# 1. 二维随机变量：联合分布、边缘分布、条件分布的数值模拟
# =====
print("=== 1. 联合分布与边缘分布的数值验证 ===")

# 生成二维正态分布样本
# 参数设置：均值向量和协方差矩阵
mu = torch.tensor([0.0, 0.0])
# 协方差矩阵：Var(X)=1, Var(Y)=1, Cov(X,Y)=0.8 (强正相关)
rho = 0.8
Sigma = torch.tensor([[1.0, rho], [rho, 1.0]])

# 用 Cholesky 分解生成样本：X = mu + L * Z, Z ~ N(0,I)
L = torch.linalg.cholesky(Sigma)
n_samples = 10000
Z = torch.randn(n_samples, 2)
samples = (mu + Z @ L.T) # shape: (n_samples, 2)

X_samples = samples[:, 0]
Y_samples = samples[:, 1]

# 验证边缘分布统计量
print(f"X 样本均值: {X_samples.mean().item():.4f} (理论: 0.0)")
print(f"Y 样本均值: {Y_samples.mean().item():.4f} (理论: 0.0)")
print(f"X 样本方差: {X_samples.var().item():.4f} (理论: 1.0)")
print(f"Y 样本方差: {Y_samples.var().item():.4f} (理论: 1.0)")

# 验证协方差
cov_xy = ((X_samples - X_samples.mean()) * (Y_samples - Y_samples.mean())).mean()
print(f" 样本协方差 Cov(X,Y): {cov_xy.item():.4f} (理论: {rho})")

# 验证相关系数
corr = cov_xy / (X_samples.std() * Y_samples.std())
print(f" 样本相关系数 : {corr.item():.4f} (理论: {rho})")

# =====
# 2. 条件期望验证
# =====

```

```

print("\n=== 2. 条件期望验证 ===")

# 对二维正态分布, 已知  $X=x$  时  $Y$  的条件期望为:
#  $E[Y | X=x] = \mu_Y + \rho * (\sigma_Y / \sigma_X) * (x - \mu_X)$ 
# 这里  $\mu=0$ ,  $\sigma=1$ , 所以  $E[Y | X=x] = \rho * x$ 

# 用样本验证: 取  $X = 1$  的样本 ( $\pm 0.1$  范围)
mask = (X_samples > 0.9) & (X_samples < 1.1)
y_given_x1 = Y_samples[mask]

print(f"E[Y | X=1] 样本估计: {y_given_x1.mean().item():.4f} (理论: {rho * 1.0:.4f})")
print(f"条件样本数: {mask.sum().item()}")

# 取  $X = -1$  的样本
mask_neg = (X_samples > -1.1) & (X_samples < -0.9)
y_given_xneg1 = Y_samples[mask_neg]
print(f"E[Y | X=-1] 样本估计: {y_given_xneg1.mean().item():.4f} (理论: {rho * (-1.0):.4f})")

# =====
# 3. 协方差矩阵的计算与可视化
# =====
print("\n=== 3. 特征协方差矩阵 ===")

def compute_covariance_matrix(features: torch.Tensor) -> torch.Tensor:
    """
    计算特征矩阵的协方差矩阵

    Args:
        features: shape (n_samples, n_features)
    Returns:
        cov_matrix: shape (n_features, n_features)
    """
    n = features.shape[0]
    # 去均值 (中心化)
    features_centered = features - features.mean(dim=0, keepdim=True)
    # 协方差矩阵:  $\Sigma = (1/(n-1)) * X^T X$ 
    cov_matrix = (features_centered.T @ features_centered) / (n - 1)
    return cov_matrix

# 生成 3 维特征 (有两对相关特征)
n = 1000

```



```

feat1 = torch.randn(n)
feat2 = 0.9 * feat1 + 0.1 * torch.randn(n)  # 与 feat1 强正相关
feat3 = -0.7 * feat1 + 0.3 * torch.randn(n)  # 与 feat1 负相关
features = torch.stack([feat1, feat2, feat3], dim=1)  # (n, 3)

cov_mat = compute_covariance_matrix(features)
print(" 估计的协方差矩阵:")
for i in range(3):
    row = " ".join(f"{cov_mat[i, j].item():+.3f}" for j in range(3))
    print(f" [{row}]")

# 计算相关系数矩阵
std = torch.sqrt(torch.diag(cov_mat))
corr_mat = cov_mat / (std.unsqueeze(0) * std.unsqueeze(1))
print("\n估计的相关系数矩阵:")
for i in range(3):
    row = " ".join(f"{corr_mat[i, j].item():+.3f}" for j in range(3))
    print(f" [{row}]")

# =====
# 4. 多任务学习模型
# =====
print("\n=== 4. 多任务学习模型 ===")

class MultiTaskNetwork(nn.Module):
    """
    多任务学习网络：共享编码器 + 多个任务头

    体现了联合分布  $p(y_1, y_2 | x)$  的建模方式。
    共享特征层隐式建模了任务间的相关性。
    """
    def __init__(self, input_dim: int, hidden_dim: int, n_tasks: int):
        super().__init__()
        # 共享编码器：捕捉任务间共同的特征表示
        self.shared_encoder = nn.Sequential(
            nn.Linear(input_dim, hidden_dim),
            nn.ReLU(),
            nn.Linear(hidden_dim, hidden_dim),
            nn.ReLU(),
        )
        # 每个任务的专用头部

```

```

        self.task_heads = nn.ModuleList([
            nn.Linear(hidden_dim, 1) for _ in range(n_tasks)
        ])

    def forward(self, x: torch.Tensor):
        """ 返回所有任务的预测列表 """
        h = self.shared_encoder(x)
        return [head(h) for head in self.task_heads]

def task_correlation_loss(
    preds: list,
    target_corr: torch.Tensor,
    lambda_corr: float = 0.1
) -> torch.Tensor:
    """
    任务相关性正则化损失

    鼓励任务预测之间的相关系数接近 target_corr 矩阵。

    Args:
        preds: 任务预测列表, 每项 shape (batch, 1)
        target_corr: 目标相关系数矩阵 (n_tasks, n_tasks)
        lambda_corr: 正则化强度
    """
    n_tasks = len(preds)
    pred_matrix = torch.cat(preds, dim=1) # (batch, n_tasks)

    # 计算预测的相关系数矩阵
    pred_centered = pred_matrix - pred_matrix.mean(dim=0, keepdim=True)
    std = pred_centered.std(dim=0, keepdim=True) + 1e-8
    pred_normalized = pred_centered / std
    # 相关系数矩阵
    corr_matrix = (pred_normalized.T @ pred_normalized) / pred_matrix.shape[0]

    # 正则化: 使预测相关性接近目标
    reg_loss = ((corr_matrix - target_corr) ** 2).mean()
    return lambda_corr * reg_loss

# 生成相关的多任务数据

```

```
# 任务 1 和任务 2 正相关（共享底层特征）
n_train = 500
input_dim = 10
x_data = torch.randn(n_train, input_dim)

# 真实标签：两个任务共享大部分信号
shared_signal = x_data[:, :5].sum(dim=1, keepdim=True)
y1 = shared_signal + 0.5 * torch.randn(n_train, 1) # 任务 1
y2 = shared_signal + 0.5 * torch.randn(n_train, 1) # 任务 2（与任务 1 强相关）

# 真实任务相关系数
true_corr = torch.tensor([[1.0, 0.9], [0.9, 1.0]])

# 训练多任务网络
model_mtl = MultiTaskNetwork(input_dim, hidden_dim=32, n_tasks=2)
optimizer = torch.optim.Adam(model_mtl.parameters(), lr=1e-3)
mse_loss = nn.MSELoss()

print(" 训练多任务网络（含任务相关性正则化） ...")
for epoch in range(200):
    preds = model_mtl(x_data)

    # 主任务损失（MSE）
    loss_task1 = mse_loss(preds[0], y1)
    loss_task2 = mse_loss(preds[1], y2)
    main_loss = loss_task1 + loss_task2

    # 任务相关性正则化
    corr_reg = task_correlation_loss(preds, true_corr, lambda_corr=0.1)

    total_loss = main_loss + corr_reg
    optimizer.zero_grad()
    total_loss.backward()
    optimizer.step()

# 评估
with torch.no_grad():
    final_preds = model_mtl(x_data)
    pred_matrix = torch.cat(final_preds, dim=1)
    pred_centered = pred_matrix - pred_matrix.mean(dim=0, keepdim=True)
    std = pred_centered.std(dim=0, keepdim=True) + 1e-8
```

```

pred_norm = pred_centered / std
actual_corr = (pred_norm.T @ pred_norm) / pred_matrix.shape[0]

print(f" 最终总损失: {total_loss.item():.4f}")
print(f" 任务 1 MSE: {mse_loss(final_preds[0], y1).item():.4f}")
print(f" 任务 2 MSE: {mse_loss(final_preds[1], y2).item():.4f}")
print(f" 预测相关系数矩阵:")
for i in range(2):
    row = " ".join(f"{actual_corr[i, j].item():+.4f}" for j in range(2))
    print(f" [{row}]")
print(f" 目标相关系数 (pred1, pred2) = 0.9, 实际 = {actual_corr[0,1].item():.4f}")

# =====
# 5. 独立性检验: 协方差为 0 但不独立的例子
# =====
print("\n=== 5. 不相关 ≠ 独立 的数值验证 ===")

n = 10000
X = torch.FloatTensor(n).uniform_(-1, 1) # X ~ Uniform(-1, 1)
Y = X ** 2                               # Y = X^2, Y 完全由 X 决定

cov_xy_demo = (X * Y).mean() - X.mean() * Y.mean()
corr_demo = cov_xy_demo / (X.std() * Y.std())

print(f"X ~ Uniform(-1,1), Y = X^2")
print(f"Cov(X, Y) = {cov_xy_demo.item():.6f} (理论: 0)")
print(f" 相关系数 = {corr_demo.item():.6f} (理论: 0)")
print(f" 但 Y 完全由 X 决定 ——二者并不独立!")
print(f"E[Y] = E[X^2] = {Y.mean().item():.4f}")
print(f"E[Y | X>0] = E[X^2 | X>0] = {Y[X>0].mean().item():.4f}")
print(f"E[Y | X<-0.5] = {Y[X<-0.5].mean().item():.4f}")
print(" 条件期望不等于边缘期望, 证明 X 与 Y 不独立。")

```

输出:

```

=== 1. 联合分布与边缘分布的数值验证 ===
X 样本均值: -0.0045 (理论: 0.0)
Y 样本均值: 0.0021 (理论: 0.0)
X 样本方差: 0.9987 (理论: 1.0)
Y 样本方差: 1.0012 (理论: 1.0)
样本协方差 Cov(X,Y): 0.7998 (理论: 0.8)
样本相关系数 : 0.7999 (理论: 0.8)

```

=== 2. 条件期望验证 ===

$E[Y | X = 1]$ 样本估计: 0.7983 (理论: 0.8000)

条件样本数: 234

$E[Y | X = -1]$ 样本估计: -0.8021 (理论: -0.8000)

=== 3. 特征协方差矩阵 ===

估计的协方差矩阵:

[+0.998 +0.897 -0.701]

[+0.897 +0.816 -0.635]

[-0.701 -0.635 +0.612]

估计的相关系数矩阵:

[+1.000 +0.995 -0.897]

[+0.995 +1.000 -0.899]

[-0.897 -0.899 +1.000]

=== 4. 多任务学习模型 ===

训练多任务网络 (含任务相关性正则化) ...

最终总损失: 0.6231

任务1 MSE: 0.2748

任务2 MSE: 0.2719

预测相关系数矩阵:

[+1.0000 +0.8876]

[+0.8876 +1.0000]

目标相关系数 ($\text{pred1}, \text{pred2}$) = 0.9, 实际 = 0.8876

=== 5. 不相关 $\neq$ 独立 的数值验证 ===

$X \sim \text{Uniform}(-1, 1), Y = X^2$

$\text{Cov}(X, Y) = 0.000012$ (理论: 0)

相关系数 = 0.000023 (理论: 0)

但 Y 完全由 X 决定 —— 二者并不独立!

$E[Y] = E[X^2] = 0.3334$

$E[Y | X > 0] = E[X^2 | X > 0] = 0.3337$

$E[Y | X < -0.5] = 0.5836$

条件期望不等于边缘期望, 证明 X 与 Y 不独立。

关键联系

概率论概念	深度学习对应
联合分布 $p(y_1, y_2 \mid \mathbf{x})$	多任务学习的输出分布
边缘分布	单任务输出的分布
条件分布 $p(y_1 \mid y_2, \mathbf{x})$	序列生成、自回归模型
协方差矩阵 Σ	特征相关性、PCA、白化
相关系数 ρ	任务相关性度量、注意力权重
独立性	特征解耦、正交正则化
条件期望 $E[Y \mid X]$	回归函数、神经网络映射

练习题

练习 6.1（基础）

设二维随机变量 (X, Y) 的联合 PMF 为：

	$Y = 0$	$Y = 1$	$Y = 2$
$X = 0$	0.1	0.1	0.2
$X = 1$	0.2	0.3	0.1

- (a) 求 X 和 Y 的边缘 PMF
- (b) 判断 X 和 Y 是否独立
- (c) 计算 $P(X = 1 \mid Y = 1)$

练习 6.2（基础）

设二维连续随机变量 (X, Y) 的联合 PDF 为：

$$f(x, y) = \begin{cases} 6x & 0 \leq x \leq y \leq 1 \\ 0 & \text{其他} \end{cases}$$

- (a) 验证归一化条件
- (b) 求 X 的边缘 PDF $f_X(x)$
- (c) 求 Y 的边缘 PDF $f_Y(y)$
- (d) X 和 Y 是否独立？

练习 6.3（中级）

对练习 6.2 中的联合 PDF，求：

- (a) 条件 PDF $f_{X|Y}(x | y)$
- (b) 条件期望 $E[X | Y = y]$
- (c) 利用全期望公式 $E[X] = E[E[X | Y]]$ 计算 $E[X]$ ，并直接用 $f_X(x)$ 验证结果

练习 6.4 (中级)

设 $X \sim \mathcal{N}(0, 1)$, $Y = 2X + 3$ 。

- (a) 求 $E[X]$, $E[Y]$, $\text{Var}(X)$, $\text{Var}(Y)$
- (b) 计算 $\text{Cov}(X, Y)$
- (c) 计算相关系数 ρ_{XY} , 并解释其含义
- (d) X 和 Y 是否独立?

练习 6.5 (提高)

设 $X_1, X_2, \dots, X_n$ 相互独立, 均值为 μ , 方差为 σ^2 。令 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 。

- (a) 证明 $E[\bar{X}] = \mu$, $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$
 - (b) 计算 $\text{Cov}(X_i, \bar{X})$ (提示: 利用协方差的线性性)
 - (c) 设 $Z_i = X_i - \bar{X}$ (去均值后的残差)。证明 $\text{Cov}(Z_i, \bar{X}) = 0$
 - (d) 说明 (c) 的结果在深度学习中批归一化 (Batch Norm) 里的直观意义
-

练习答案

点击展开练习 6.1 答案

(a) 边缘 PMF

对各行求和得 X 的边缘 PMF:

$$p_X(0) = 0.1 + 0.1 + 0.2 = 0.4, \quad p_X(1) = 0.2 + 0.3 + 0.1 = 0.6$$

对各列求和得 Y 的边缘 PMF:

$$p_Y(0) = 0.3, \quad p_Y(1) = 0.4, \quad p_Y(2) = 0.3$$

(b) 判断独立性

验证 $p(x_i, y_j) = p_X(x_i) \cdot p_Y(y_j)$ 是否成立:

$$p_X(0) \cdot p_Y(0) = 0.4 \times 0.3 = 0.12 \neq 0.1 = p(0, 0)$$

等式不成立，故 X 和 Y 不独立。

(c) 条件概率

$$P(X = 1 \mid Y = 1) = \frac{P(X = 1, Y = 1)}{P(Y = 1)} = \frac{0.3}{0.4} = 0.75$$

点击展开练习 6.2 答案

(a) 验证归一化

注意积分域为 $0 \leq x \leq y \leq 1$:

$$\int_0^1 \int_0^y 6x \, dx \, dy = \int_0^1 6 \cdot \frac{x^2}{2} \Big|_0^y \, dy = \int_0^1 3y^2 \, dy = y^3 \Big|_0^1 = 1 \checkmark$$

(b) $f_X(x)$ 的边缘 PDF

对 y 从 x 到 1 积分 (因为 $y \geq x$):

$$f_X(x) = \int_x^1 6x \, dy = 6x(1 - x), \quad 0 \leq x \leq 1$$

(c) $f_Y(y)$ 的边缘 PDF

对 x 从 0 到 y 积分 (因为 $x \leq y$):

$$f_Y(y) = \int_0^y 6x \, dx = 6 \cdot \frac{y^2}{2} = 3y^2, \quad 0 \leq y \leq 1$$

(d) 独立性

$$f_X(x) \cdot f_Y(y) = 6x(1 - x) \cdot 3y^2 = 18x(1 - x)y^2 \neq 6x = f(x, y)$$

故 X 和 Y 不独立。(直觉上，积分域 $0 \leq x \leq y \leq 1$ 是三角形而非矩形，也说明不独立。)

点击展开练习 6.3 答案

(a) 条件 PDF

$$f_{X|Y}(x \mid y) = \frac{f(x, y)}{f_Y(y)} = \frac{6x}{3y^2} = \frac{2x}{y^2}, \quad 0 \leq x \leq y$$

$$\text{验证: } \int_0^y \frac{2x}{y^2} \, dx = \frac{2}{y^2} \cdot \frac{y^2}{2} = 1 \checkmark$$

(b) 条件期望

$$E[X | Y = y] = \int_0^y x \cdot \frac{2x}{y^2} dx = \frac{2}{y^2} \int_0^y x^2 dx = \frac{2}{y^2} \cdot \frac{y^3}{3} = \frac{2y}{3}$$

(c) 利用全期望公式

$$E[X] = E[E[X | Y]] = \int_0^1 \frac{2y}{3} \cdot 3y^2 dy = \int_0^1 2y^3 dy = \frac{y^4}{2} \Big|_0^1 = \frac{1}{2}$$

直接验证 (用边缘 PDF):

$$E[X] = \int_0^1 x \cdot 6x(1-x) dx = 6 \int_0^1 (x^2 - x^3) dx = 6 \left(\frac{1}{3} - \frac{1}{4} \right) = 6 \cdot \frac{1}{12} = \frac{1}{2} \checkmark$$

点击展开练习 6.4 答案

(a) 基本统计量

$$E[X] = 0, \quad E[Y] = E[2X + 3] = 2E[X] + 3 = 3$$

$$\text{Var}(X) = 1, \quad \text{Var}(Y) = \text{Var}(2X + 3) = 4\text{Var}(X) = 4$$

(b) 协方差

$$\text{Cov}(X, Y) = \text{Cov}(X, 2X + 3) = 2\text{Cov}(X, X) = 2\text{Var}(X) = 2$$

(c) 相关系数

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{2}{\sqrt{1} \cdot \sqrt{4}} = \frac{2}{2} = 1$$

$\rho = 1$ 表示 X 与 Y 完全正线性相关, 这与 $Y = 2X + 3$ 的线性关系完全吻合。

(d) 独立性

X 和 Y 不独立。 Y 完全由 X 决定 ($Y = 2X + 3$), 知道 X 就完全确定了 Y , 所以二者是最强的依赖关系, 而非独立。

点击展开练习 6.5 答案

(a) 样本均值的期望和方差

$$E[\bar{X}] = E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{n\mu}{n} = \mu$$

由独立性, $\text{Cov}(X_i, X_j) = 0 \ (i \neq j)$:

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}$$

(b) $\text{Cov}(X_i, \bar{X})$

利用协方差线性性:

$$\text{Cov}(X_i, \bar{X}) = \text{Cov}\left(X_i, \frac{1}{n} \sum_{j=1}^n X_j\right) = \frac{1}{n} \sum_{j=1}^n \text{Cov}(X_i, X_j)$$

由独立性, $\text{Cov}(X_i, X_j) = 0 \ (i \neq j)$, $\text{Cov}(X_i, X_i) = \sigma^2$:

$$\text{Cov}(X_i, \bar{X}) = \frac{1}{n} \sigma^2 = \frac{\sigma^2}{n}$$

(c) 证明 $\text{Cov}(Z_i, \bar{X}) = 0$

$$\begin{aligned} \text{Cov}(Z_i, \bar{X}) &= \text{Cov}(X_i - \bar{X}, \bar{X}) = \text{Cov}(X_i, \bar{X}) - \text{Cov}(\bar{X}, \bar{X}) \\ &= \frac{\sigma^2}{n} - \text{Var}(\bar{X}) = \frac{\sigma^2}{n} - \frac{\sigma^2}{n} = 0 \end{aligned}$$

(d) 批归一化的直观意义

批归一化对每个特征做中心化: $Z_i = X_i - \bar{X}$ (减去批均值)。

(c) 的结论说明, 中心化后的残差 Z_i 与批均值 $\bar{X}$ 线性不相关。这保证了归一化后的特征不再携带均值方向的信息, 使得梯度信号更稳定, 避免内部协变量偏移 (Internal Covariate Shift)。本质上是利用协方差为零来解耦均值信息和残差信息。

几何示意

图 6-1: 联合 PDF 等高线 (二元正态, 不同 ρ)

图 6-2: 二元正态等高线 + 不同 ρ 对比

图 6-3: 边缘分布 + 条件分布几何意义

图 6-4: 独立 vs 相关散点图对比 (4 种 ρ)




图 13: 二元正态联合概率密度函数等高线图 ($\rho=0, 0.5, 0.9$ 对比)




图 14: 二元正态分布在不同相关系数下的等高线形态对比





图 15: 联合分布切片得到条件分布，积分得到边缘分布的几何示意

独立 vs 相关：散点图对比 (ρ 决定椭圆朝向与扁度)



圆形: $|\rho| = 0$ (独立) 倾斜椭圆: $0 < |\rho| < 1$ (相关) 退化直线: $|\rho| = 1$ (完全线性)

图 16: 四种相关系数下二元正态散点图对比：独立与正负相关

思考路标（条件反射）

- 看到“联合 PMF/PDF”→ 验证归一化： $\sum \sum p_{ij} = 1$ 或 $\iint f \, dx \, dy = 1$ ；区域概率用双重积分
- 看到“求边缘分布”→ 积分掉另一个变量： $f_X(x) = \int_{-\infty}^{+\infty} f(x, y) \, dy$
- 看到“求条件分布”→ $f(y|x) = f(x, y)/f_X(x)$ ，分母 $f_X(x) \neq 0$
- 看到“判断独立性”→ $f(x, y) = f_X(x)f_Y(y)$ 对所有 (x, y) 成立（且定义域为矩形）
- 看到“求协方差”→ $\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$ ；独立时 $= 0$
- 看到“相关系数 ρ ”→ $\rho = \text{Cov}(X, Y)/(\sigma_X \sigma_Y) \in [-1, 1]$ ； $|\rho| = 1$ 当且仅当严格线性关系
- 看到“二元正态条件分布”→ 仍是正态： $Y|X = x \sim N(\mu_Y + \rho \frac{\sigma_Y}{\sigma_X}(x - \mu_X), \sigma_Y^2(1 - \rho^2))$
- 看到“多元正态”→ 参数为均值向量 μ 和协方差矩阵 Σ （半正定）

易错点

1. 独立 $\Rightarrow$ 协方差 $= 0$ ，但反之不成立： $\text{Cov} = 0$ 只排除线性关系；经典反例 $Y = X^2$ ， $X \sim U(-1, 1)$ ：协方差为零但 Y 完全由 X 决定。正态分布是例外：正态变量不相关 $\Leftrightarrow$ 独立。
2. 边缘分布只能由联合求，不能反推联合：给定 f_X 和 f_Y ，联合分布不唯一（只有独立时才唯一确定为乘积）。
3. 条件密度分母 $f_X(x) \neq 0$ ：在 $f_X(x) = 0$ 的点，条件密度无定义；计算前先确认 x 在 X 的支撑集内。
4. 协方差矩阵半正定： Σ 的所有特征值 ≥ 0 ；若计算得到负定，必有错误（如混淆协方差与相关系数）。
5. 相关 vs 独立辨析：相关系数度量线性相关程度；高度非线性依赖（如圆形分布）的相关系数可以为零，但变量不独立——统计建模时不能仅凭 $\rho = 0$ 判断独立。

第三部分导论：分布到底是什么？

难度：★★☆☆☆ 前置知识：第 4 章离散随机变量、第 5 章连续随机变量、第 6 章多维随机变量
定位：这是第二部分（随机变量）到第三部分（常见分布族）之间的概念桥梁。第 7-9 章会逐一介绍伯努利、二项、泊松、正态、Gamma……这些“具名分布”，但在动手之前，必须先回答一个被很多教材跳过的问题——“分布”本身，到底是什么数学对象？

学习目标

- 说清“分布”是一个独立于随机变量的数学对象：它是随机变量在取值空间上诱导出的概率分配
- 理解 $P_X = P \circ X^{-1}$ （诱导/推前概率）的直观含义，以及“两个随机变量同分布”到底意味着什么
- 理解累积分布函数（CDF）是刻画任意分布的统一语言，并掌握“满足三条性质的函数 $\Leftrightarrow$ 一个分布”的一一对应
- 看懂 PMF 与 PDF 只是 CDF 在离散 / 连续两种情形下的特例表达
- 理解“分布族”是带参数的一组分布，从而明白第 7-9 章在按什么逻辑组织
- 通过二项分布与均匀分布两个范例，掌握“推导一个分布”的标准动作

0.1 为什么要单独讲“分布”

在第二部分，我们学了不少东西：离散随机变量有概率质量函数（PMF） $p(x)$ ，连续随机变量有概率密度函数（PDF） $f(x)$ ，两者都有累积分布函数（CDF） $F(x) = P(X \leq x)$ 。我们也反复使用一句话——“ X 服从某某分布”，记作 $X \sim B(n, p)$ 、 $X \sim N(\mu, \sigma^2)$ 。

但请停下来想一个问题：

引子：甲在抛一枚均匀硬币，正面记 $X = 1$ 、反面记 $X = 0$ ；乙在一副扑克里随机抽一张，红色记 $Y = 1$ 、黑色记 $Y = 0$ 。这是两个完全不同的随机试验——样本空间不同（{ 正, 反 } vs 52 张牌）、随机变量的定义也不同。可我们却会说：“ X 和 Y 服从同一个分布。”

凭什么？它们到底“同”在哪里？

答案是：它们作为函数、作为试验都不同，但“取值 1 的概率都是 $\frac{1}{2}$ 、取值 0 的概率都是 $\frac{1}{2}$ ”这件事相同。这个“概率在各个取值上怎么分配”的规则，就是分布。

换句话说，第二部分我们总是盯着“某个具体随机变量”看它的 PMF/PDF/CDF；而“分布”是把视线从随机变量本身移开，只关注它把概率分配到取值空间各处的那张“分配方案”。这张方案可以脱离具体试验、脱离具体的 X 而独立存在——这正是为什么我们能把它们抽出来、起名字、编成“分布族”，专门用第 7-9 章三章来研究。

0.2 从随机变量到分布：被“诱导”出来的概率分配

回忆随机变量的本质（第 4 章）：一个随机变量 X 是从样本空间到实数的一个函数

$$X: \Omega \longrightarrow \mathbb{R}, \quad \omega \mapsto X(\omega).$$

样本空间 Ω 上原本带着一个概率 P （它告诉我们每个“原始结果” ω 发生的可能性）。随机变量 X 就像一台“搬运机”：它把 Ω 上的概率，沿着函数 X 搬运到数轴 $\mathbb{R}$ 上。

搬运后，数轴上每个区域 B （比如一个区间）就有了一个概率：“ X 落进 B 的概率”。它等于“那些被 X 送进 B 的原始结果 ω ”的总概率：

$$P_X(B) = P(X \in B) = P(\{\omega \in \Omega : X(\omega) \in B\}).$$

我们把这个定义在取值空间上的 P_X 叫做 X 的分布（distribution），也叫 X 的概率律（the law of X ）。用更紧凑的记号：

$$P_X = P \circ X^{-1}$$




图 17: 随机变量把样本空间上的概率搬运到数轴，得到分布

这里 $X^{-1}(B) = \{\omega : X(\omega) \in B\}$ 是 B 的原像——“哪些 ω 会被搬到 B 里”。这种由 X 把 P “推到前面”得到的 P_X ，数学上称为诱导概率或推前测度 (**pushforward**)。这一句话就是“分布”的精确数学含义。

关键转变 (务必体会)：一旦得到 P_X ，我们就可以彻底忘掉 Ω 、忘掉 X 这个函数本身，只保留 P_X ——一张“数轴上各处概率多少”的分配表。分布 = 这张分配表。

现在回头看 0.1 的引子就一目了然了。甲的 $\Omega = \{\text{正, 反}\}$ 、乙的 $\Omega = 52$ 张牌， X 与 Y 是不同的函数；但它们诱导出的分配表

$$P_X(\{1\}) = P_Y(\{1\}) = \frac{1}{2}, \quad P_X(\{0\}) = P_Y(\{0\}) = \frac{1}{2}$$

完全相同。所以：

同分布的定义：称 X 与 Y 同分布 (记作 $X \stackrel{d}{=} Y$)，当且仅当 $P_X = P_Y$ ，即对一切区域 B 都有 $P(X \in B) = P(Y \in B)$ 。底层的 Ω 、 P 、函数本身是否相同，一概无关。

这个“只看分配、不看出身”的视角，是整个第三部分乃至后面统计学的思维基础。

0.3 CDF：刻画任意分布的统一语言

P_X 虽然定义清楚，但直接用它并不方便——它要对所有可能的区域 B 都给出概率，信息量太大、没法“写下来”。我们需要一个有限、可书写的描述，能完整决定整个 P_X 。这个描述就是累积分布函数：

$$F(x) = P_X((-\infty, x]) = P(X \leq x).$$

它只是一个一元实函数，却足以恢复一切区间的概率。例如对任意 $a < b$ ：

$$P(a < X \leq b) = F(b) - F(a).$$

为什么“一个一元函数”就够了？区间 $(-\infty, x]$ 这一族集合，通过取差、取并、取极限，可以“拼出”我们关心的几乎所有区域。所以只要知道每个 $(-\infty, x]$ 的概率（也就是知道 F ），整张分配表 P_X 就被唯一确定了。这是把“对所有 B 指定概率”压缩成“一个函数 F ”的关键。

CDF 的三条刻画性质（与第 4、5 章一致）：

1. 单调不减： $x_1 < x_2 \Rightarrow F(x_1) \leq F(x_2)$ ；
2. 右连续： $\lim_{x \rightarrow a^+} F(x) = F(a)$ ；
3. 两端极限： $\lim_{x \rightarrow -\infty} F(x) = 0$, $\lim_{x \rightarrow +\infty} F(x) = 1$ 。

最深刻的一点是这三条不仅是必要的，而且是充分的：

分布 $\Leftrightarrow$ **CDF** 一一对应定理：任何满足上述三条性质的函数 F ，都唯一对应一个分布 P_X ；反过来，每个分布也唯一确定它的 F 。

这正是“分布的数学意义”落到实处的地方——研究一个分布，等价于研究一个满足三条性质的函数 F 。我们不必每次都回到抽象的 $P_X = P \circ X^{-1}$ ，只要交出一个合格的 F （或下一节的 PMF/PDF），就完整地“给出了一个分布”。

0.4 PMF 与 PDF：CDF 的两种特例表达

既然 CDF 能刻画一切分布，那第二部分熟悉的 PMF 和 PDF 是什么？答案是：它们是 CDF 在两种典型情形下的“局部细节”，描述同一个 F 的两种等价方式。

离散情形——**CDF** 是阶梯函数。若 X 只在可数个点 $x_1, x_2, \dots$ 取值，则 F 在每个 x_i 处向上跳一格，跳跃的高度恰好是该点的概率：

$$p(x_i) = F(x_i) - F(x_i^-) = P(X = x_i).$$

这些跳跃高度的集合 $\{p(x_i)\}$ 就是 **PMF**。“分配表”在这里是离散的：概率像砝码一样集中堆在一个个点上。

连续情形——**CDF** 是光滑（可导）函数。若 F 处处连续且几乎处处可导，则它没有跳跃，概率不再堆在点上，而是抹开成一条密度。此时

$$f(x) = F'(x), \quad \text{反过来} \quad F(x) = \int_{-\infty}^x f(t) dt.$$

导数 f 就是 **PDF**。它不是“某点的概率”（连续情形下单点概率为 0），而是“概率的密集程度”——某处 f 越大，概率在那附近堆得越密。




图 18: CDF 统一刻画分布：离散情形 PMF 是 CDF 的跳跃高度，连续情形 PDF 是 CDF 的斜率

描述方式	离散分布	连续分布	统一身份
CDF $F(x)$	阶梯函数	光滑递增曲线	都是 $P(X \leq x)$ ，永远存在
逐点细节	PMF $p(x_i)$ = 跳跃高度	PDF $f(x) = F'(x)$ = 斜率	都是“分配”的局部刻画
求区间概率	求和 $\sum_{a < x_i \leq b} p(x_i)$	积分 $\int_a^b f(x) dx$	都等于 $F(b) - F(a)$
归一化	$\sum_i p(x_i) = 1$	$\int_{-\infty}^{+\infty} f(x) dx = 1$	都等于 $F(+\infty) - F(-\infty) = 1$

一句话总结：CDF 是“分布”的通用身份证，离散世界用 PMF（跳跃高度）、连续世界用 PDF（斜率/密度）去描述同一张身份证的细节。三者描述的是同一个分布。

0.5 分布族：参数化的“一组分布”

到此我们知道“一个分布”是什么了。但第 7-9 章的标题是“分布族”——这是更进一步的抽象。

回到 0.1 的硬币： $P(X = 1) = p$ 时，取不同的 p ($0 < p < 1$) 就得到不同的分布。 $p = 0.5$ 是均匀硬币， $p = 0.9$ 是偏心硬币——它们的 CDF 不同、是不同的分布，但结构完全一样，都长成 $P(X = 1) = p$, $P(X = 0) = 1 - p$ 的样子。把这一整族分布打包，就是伯努利分布族：

$\{ \text{Bernoulli}(p) : p \in (0, 1) \}.$

一般地：

分布族（family of distributions）是由一个参数 θ 索引的一组分布

$$\{F(\cdot; \theta) : \theta \in \Theta\},$$

其中 θ 取自参数空间 Θ 。给定一个具体的 θ ，就锁定族里的一个具体分布。

- Bernoulli(p): 参数 $\theta = p$;
- $B(n, p)$: 参数 $\theta = (n, p)$;
- $N(\mu, \sigma^2)$: 参数 $\theta = (\mu, \sigma^2)$ ，连续两个参数，对应一整片正态曲线。

为什么值得专门研究这些“具名分布族”？因为它们各自对应一类反复出现的随机生成机制：数固定次数试验中的成功数 $\rightarrow$ 二项族；数稀有事件的发生数 $\rightarrow$ 泊松族；大量微小因素叠加 $\rightarrow$ 正态族……现实中绝大多数随机现象，都能对号入座到某个分布族，然后只剩下“估计参数 θ ”这一件事——这也正是第五、六部分（统计推断）的出发点。第 7–9 章的任务，就是把最常用的这些族，连同它们的生成机制、PMF/PDF、期望方差、相互关系，一次讲清。

0.6 推导过程范例：一个分布是怎么“被推出来”的

理论说完，看两个范例，体会“推导一个分布”具体在做什么——本质上就是：从一个随机生成机制出发，算出它把概率分配到每个取值上各是多少。

范例一（离散）：二项分布从生成机制推出 PMF

第 1 步——写清生成机制。独立重复做 n 次伯努利试验，每次成功概率 p 。令 $X =$ 成功的总次数。取值空间是 $\{0, 1, 2, \dots, n\}$ 。

第 2 步——算每个取值的概率。求 $P(X = k)$ 。某一种“恰好 k 次成功”的具体序列（比如前 k 次成功、后 $n - k$ 次失败），因各次独立，其概率是

$$\underbrace{p \cdot p \cdots p}_{k \text{ 个}} \cdot \underbrace{(1-p) \cdots (1-p)}_{n-k \text{ 个}} = p^k (1-p)^{n-k}.$$

而“恰好 k 次成功”对应的不同序列有 $\binom{n}{k}$ 种（从 n 个位置里选 k 个放成功），每种概率都相同，故相加：

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n.$$

这张“ $k \mapsto P(X = k)$ ”的表，就是二项分布的 PMF——分布到此就被“推出来”了。

第 3 步——验证归一化（确认它真是一个分布）。由二项式定理，

$$\sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} = (p + (1-p))^n = 1. \checkmark$$

总概率为 1，三条性质中最关键的一条得到满足，确认这是一个合法分布。

范例二（连续）：均匀分布从“等可能落点”推出 PDF

生成机制：在区间 $[a, b]$ 上“完全随机、无偏好”地取一个点 X 。“无偏好”意味着 X 落在任何子区间的概率，只与该子区间的长度成正比，与位置无关。

推 CDF：对 $a \leq x \leq b$ ，落在 $[a, x]$ 的概率正比于长度 $x - a$ ，且落在整个 $[a, b]$ 的概率为 1，于是

$$F(x) = P(X \leq x) = \frac{x-a}{b-a}, \quad a \leq x \leq b.$$

求导得 PDF：

$$f(x) = F'(x) = \frac{1}{b-a}, \quad a \leq x \leq b \text{ (区间外为0)}.$$

得到一个“平台”形状的密度——这正是均匀分布 $U(a, b)$ 。归一化检验： $\int_a^b \frac{1}{b-a} dx = 1 \checkmark$ 。

范例的共同套路：□ 说清生成机制与取值空间 → □ 用古典概率 / 独立性 / 几何概率算出 PMF 或 CDF → □ 验证归一化。第 7-9 章每个具名分布，本质上都走这同一条推导路径，只是机制和算法各不相同。

0.7 小结与衔接

核心一句话：分布 = 随机变量诱导在取值空间上的那张“概率分配表” $P_X = P \circ X^{-1}$ ；它被 CDF 完整刻画，离散时细化为 PMF、连续时细化为 PDF；带参数打包成一组，就是分布族。

思考路标（条件反射）：

- 看到“ $X \sim$ 某分布”→ 想的是它的分配表 P_X / CDF，而不是某个具体试验；
- 看到“求 X 的分布”→ 落实为求出 CDF $F(x)$ ，或求出 PMF / PDF；
- 看到“证 X, Y 同分布”→ 证 $F_X \equiv F_Y$ （或 $P_X = P_Y$ ），与底层试验无关；
- 看到“给一个函数，问是不是某分布的 CDF”→ 查三条性质（单调不减、右连续、两端 0/1）；
- 看到一个带参数的分布名（如 $N(\mu, \sigma^2)$ ）→ 意识到这是一族分布，具体哪条由参数 θ 锁定；
- 看到“推导某分布的 PMF/PDF”→ 套三步：写生成机制 → 算每点/区间概率 → 验归一化。

接下来三章，就是把最常用的分布族逐一“对号入座、连同生成机制一起推清楚”：

章节	主题	这些分布是哪种“分配表”
第 7 章离散分布族	伯努利、二项、泊松、几何、负二项、超几何	概率堆在离散点上的 PMF
第 8 章连续分布族	均匀、指数、正态、Gamma、Beta	概率抹成密度的 PDF
第 9 章多维分布	多项、多元正态、Dirichlet	多个变量联合的分配表

带着”分布 = 概率分配表”这把钥匙，再去读第 7 章的伯努利分布，你看到的就不再是一条孤立公式，而是”一台 0/1 搬运机诱导出的、最简单的那张分配表”。

第 7 章离散分布族

难度：★★★☆☆ 前置知识：第 4 章离散随机变量、第 5 章连续随机变量、第 6 章多维随机变量 建议先读：第三部分导论《分布到底是什么?》——先理解”分布 = 随机变量诱导的概率分配表”，再看下面的伯努利分布会清晰得多。

学习目标

- 掌握伯努利分布、二项分布、泊松分布、几何分布、负二项分布、超几何分布的 PMF、期望与方差
- 理解各离散分布之间的内在联系（如泊松分布是二项分布的极限）
- 能够根据实际问题的特征正确选择合适的离散分布模型
- 深刻理解二元交叉熵损失与伯努利分布的概率论本质
- 掌握离散分布在深度学习中的应用：分类、计数建模与序列生成

7.1 伯努利分布与二项分布

7.1.1 伯努利分布

伯努利试验（Bernoulli Trial）是只有两种结果的随机试验：成功（记为 1）或失败（记为 0）。

定义：若随机变量 X 满足

$$P(X = 1) = p, \quad P(X = 0) = 1 - p, \quad 0 < p < 1$$

则称 X 服从参数为 p 的伯努利分布，记作 $X \sim \text{Bernoulli}(p)$ 。

PMF 的统一写法：

$$p(x) = p^x(1-p)^{1-x}, \quad x \in \{0, 1\}$$

期望与方差:

$$E[X] = p$$

$$\text{Var}(X) = E[X^2] - (E[X])^2 = p - p^2 = p(1-p)$$

方差在 $p = 1/2$ 时取最大值 $1/4$, 即不确定性最大。

例 7.1: 某神经元以概率 $p = 0.7$ 被激活, X 表示该神经元是否激活, 则 $X \sim \text{Bernoulli}(0.7)$, $E[X] = 0.7$, $\text{Var}(X) = 0.21$ 。

7.1.2 二项分布

将伯努利试验独立重复 n 次, 记成功次数为 X , 则 X 服从二项分布。

定义: 若 X 表示 n 次独立伯努利试验中成功的次数, 每次成功概率为 p , 则

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n$$

记作 $X \sim B(n, p)$ 或 $X \sim \text{Binomial}(n, p)$ 。

组合数 $\binom{n}{k} = \frac{n!}{k!(n-k)!}$ 表示从 n 次试验中选取 k 次成功的方案数。

归一化验证: 由二项式定理,

$$\sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} = (p + (1-p))^n = 1 \checkmark$$

期望 (利用线性性: $X = X_1 + X_2 + \dots + X_n$, $X_i \sim \text{Bernoulli}(p)$):

$$E[X] = np$$

方差 (各 X_i 独立, 方差可加):

$$\text{Var}(X) = np(1-p)$$

例 7.2: 某图像分类器对每张图片的预测准确率为 $p = 0.9$, 对 $n = 20$ 张图片进行预测, 正确预测数 $X \sim B(20, 0.9)$ 。

$$E[X] = 18, \quad \text{Var}(X) = 20 \times 0.9 \times 0.1 = 1.8$$

$P(X = 20) = 0.9^{20} \approx 0.1216$, 即全部预测正确的概率约为 12.16%。

二项分布的形状: - 当 $p = 0.5$ 时, 分布关于 $n/2$ 对称 - 当 $p < 0.5$ 时, 分布右偏; $p > 0.5$ 时左偏 - 随 n 增大, 形状趋近于正态分布 (中心极限定理)

7.2 泊松分布

7.2.1 定义与 PMF

泊松分布用于描述在固定时间或空间区间内, 某稀有事件发生次数的分布。

定义: 若随机变量 X 的 PMF 为

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

其中 $\lambda > 0$ 为参数, 则称 X 服从参数为 λ 的泊松分布, 记作 $X \sim \text{Poisson}(\lambda)$ 或 $X \sim P(\lambda)$ 。

归一化验证: 由指数函数的泰勒展开,

$$\sum_{k=0}^{\infty} \frac{\lambda^k e^{-\lambda}}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} \cdot e^{\lambda} = 1 \checkmark$$

期望与方差:

$$E[X] = \lambda, \quad \text{Var}(X) = \lambda$$

泊松分布的一个显著特征是期望等于方差, 都等于参数 λ 。

7.2.2 泊松分布是二项分布的极限

定理 (泊松极限定理): 设 $X_n \sim B(n, p_n)$, 当 $n \rightarrow \infty$, $p_n \rightarrow 0$, 且 $np_n \rightarrow \lambda$ (常数) 时,

$$P(X_n = k) \rightarrow \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

直观理解：试验次数很多（ n 大），但每次成功概率极小（ p 小），平均成功次数 $\lambda = np$ 为常数。这正是“稀有事件”的特征。

证明要点：

$$\binom{n}{k} p^k (1-p)^{n-k} = \frac{n(n-1)\cdots(n-k+1)}{k!} \cdot \left(\frac{\lambda}{n}\right)^k \cdot \left(1 - \frac{\lambda}{n}\right)^{n-k}$$

当 $n \rightarrow \infty$ 时： $\frac{n(n-1)\cdots(n-k+1)}{n^k} \rightarrow 1$ ， $\left(1 - \frac{\lambda}{n}\right)^n \rightarrow e^{-\lambda}$ ， $\left(1 - \frac{\lambda}{n}\right)^{-k} \rightarrow 1$

因此极限为 $\frac{\lambda^k e^{-\lambda}}{k!}$ 。

实用准则：当 $n \geq 20$ ， $p \leq 0.05$ （或 $n \geq 100$ ， $p \leq 0.1$ ）时，可用泊松分布近似二项分布，令 $\lambda = np$ 。

7.2.3 泊松分布的典型应用

应用场景	λ 的含义
每小时到达服务台的顾客数	单位时间平均到达率
某网页每天收到的点击次数	日均点击量
文本中某罕见词的出现次数	每千词平均出现次数
放射性衰变计数	单位时间平均衰变数

例 7.3：某服务器每分钟平均接收 $\lambda = 3$ 个请求， $X \sim \text{Poisson}(3)$ 。

$$P(X = 0) = e^{-3} \approx 0.0498, \quad P(X = 5) = \frac{3^5 e^{-3}}{5!} = \frac{243 e^{-3}}{120} \approx 0.1008$$

7.2.4 泊松过程

泊松分布与泊松过程密切相关。泊松过程是描述随时间随机发生的事件的数学模型，满足：1. 不相交时间区间内的事件数独立 2. 事件发生率为常数 λ （单位时间平均发生数）3. 极短时间内同时发生两个事件的概率可忽略

在时间区间 $[0, t]$ 内发生的事件数 $N(t) \sim \text{Poisson}(\lambda t)$ 。

7.3 几何分布与负二项分布

7.3.1 几何分布

在独立重复的伯努利试验中，首次成功所需的试验次数服从几何分布。

定义：设每次试验成功概率为 p ， X 为首次成功时的试验次数，则

$$P(X = k) = (1 - p)^{k-1}p, \quad k = 1, 2, 3, \dots$$

记作 $X \sim \text{Geom}(p)$ 。

另一种定义（首次成功前的失败次数 $Y = X - 1$ ）：

$$P(Y = k) = (1 - p)^k p, \quad k = 0, 1, 2, \dots$$

归一化验证：

$$\sum_{k=1}^{\infty} (1 - p)^{k-1} p = p \cdot \frac{1}{1 - (1 - p)} = 1 \checkmark$$

期望与方差：

$$E[X] = \frac{1}{p}, \quad \text{Var}(X) = \frac{1 - p}{p^2}$$

直观地，成功概率越小，平均需要等待越久。

7.3.2 无记忆性

几何分布具有无记忆性（Memoryless Property），即过去的失败不影响未来的预期：

$$P(X > m + n \mid X > m) = P(X > n), \quad m, n \geq 0$$

证明：

$$P(X > m + n \mid X > m) = \frac{P(X > m + n)}{P(X > m)} = \frac{(1 - p)^{m+n}}{(1 - p)^m} = (1 - p)^n = P(X > n)$$

几何分布是离散分布中唯一具有无记忆性的分布（类比连续分布中的指数分布）。

例 7.4：某算法每次迭代有 $p = 0.2$ 的概率收敛，则收敛所需迭代次数 $X \sim \text{Geom}(0.2)$ 。 $E[X] = 5$ ，即平均需要 5 次迭代。

7.3.3 负二项分布

将几何分布推广：在独立重复伯努利试验中，第 r 次成功所需的试验次数服从负二项分布。

定义：若 X 为第 r 次成功时的总试验次数，则

$$P(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad k = r, r+1, r+2, \dots$$

记作 $X \sim \text{NB}(r, p)$ 。

理解：第 k 次试验恰好是第 r 次成功，意味着前 $k-1$ 次中恰好有 $r-1$ 次成功，第 k 次必须成功。

另一种等价参数化（前 r 次成功前的失败次数 $Y = X - r$ ）：

$$P(Y = k) = \binom{k+r-1}{k} p^r (1-p)^k, \quad k = 0, 1, 2, \dots$$

期望与方差（总试验次数 X 的）：

$$E[X] = \frac{r}{p}, \quad \text{Var}(X) = \frac{r(1-p)}{p^2}$$

关系：当 $r = 1$ 时，负二项分布退化为几何分布。若 $X_1, X_2, \dots, X_r$ 独立同分布 $\text{Geom}(p)$ ，则 $X_1 + X_2 + \dots + X_r \sim \text{NB}(r, p)$ 。

例 7.5：某机器学习模型训练时，每个 epoch 有 $p = 0.3$ 的概率使验证集性能提升，求第 3 次性能提升时的期望 epoch 数。

$$X \sim \text{NB}(3, 0.3), \quad E[X] = \frac{3}{0.3} = 10$$

7.4 超几何分布

7.4.1 定义

超几何分布描述有限总体中不放回抽样的分布，与二项分布（放回抽样或无穷总体）形成对比。

设置：总体中有 N 个元素，其中 K 个为“成功”， $N - K$ 个为“失败”。从中不放回地随机抽取 n 个， X 为抽到的成功数。

PMF：

$$P(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}, \quad \max(0, n - (N - K)) \leq k \leq \min(n, K)$$

记作 $X \sim \text{Hypergeometric}(N, K, n)$ 。

直观理解：从 K 个成功中选 k 个，从 $N - K$ 个失败中选 $n - k$ 个，占总选法 $\binom{N}{n}$ 的比例。

期望与方差：

$$E[X] = n \cdot \frac{K}{N}$$

$$\text{Var}(X) = n \cdot \frac{K}{N} \cdot \frac{N - K}{N} \cdot \frac{N - n}{N - 1}$$

其中 $\frac{N-n}{N-1}$ 称为有限总体修正因子 (Finite Population Correction Factor)。当 $N \rightarrow \infty$ 时，修正因子趋近于 1，超几何分布趋近于二项分布 $B(n, K/N)$ 。

7.4.2 超几何分布与二项分布的比较

特征	二项分布 $B(n, p)$	超几何分布 $\text{Hyp}(N, K, n)$
抽样方式	放回抽样（或无限总体）	不放回抽样
每次试验独立性	独立	不独立
成功概率	每次均为 p	随已抽情况变化
方差	$np(1 - p)$	$np(1 - p) \cdot \frac{N-n}{N-1}$

当 n/N 较小（抽样比例小于 5%）时，超几何分布可用二项分布近似。

例 7.6：某数据集包含 $N = 1000$ 条样本，其中 $K = 300$ 条标注为正类。随机（不放回）抽取 $n = 50$ 条， X 为正类样本数。

$$X \sim \text{Hyp}(1000, 300, 50)$$

$$E[X] = 50 \times \frac{300}{1000} = 15$$

$$\text{Var}(X) = 50 \times \frac{300}{1000} \times \frac{700}{1000} \times \frac{950}{999} \approx 10.36$$

若改用二项分布近似 ($p = 0.3$): $\text{Var}(X) = 50 \times 0.3 \times 0.7 = 10.5$ ，误差很小。

7.5 离散分布族的统一视角

7.5.1 指数族框架

许多常见离散分布（包括伯努利、二项、泊松、几何、负二项）都属于指数族（Exponential Family），其 PMF 可以写成统一形式：

$$p(x; \theta) = h(x) \exp(\eta(\theta)^T T(x) - A(\theta))$$

其中：- $\eta(\theta)$ ：自然参数（Natural Parameter）- $T(x)$ ：充分统计量（Sufficient Statistic）- $A(\theta)$ ：对数配分函数（Log-partition Function），保证归一化 - $h(x)$ ：基础测度

伯努利分布的指数族形式（以 $\text{Bernoulli}(p)$ 为例）：

$$p(x; p) = p^x (1-p)^{1-x} = \exp\left(x \log \frac{p}{1-p} + \log(1-p)\right)$$

其中 $\eta = \log \frac{p}{1-p}$ （log-odds，即 logit 函数）， $T(x) = x$ ， $A(\eta) = \log(1 + e^\eta)$ 。

指数族框架的优势：自动保证存在充分统计量，最大似然估计有封闭解，梯度下降计算简洁。

7.5.2 分布之间的关系图谱

$\text{Bernoulli}(p)$

↓ n次独立叠加

$\text{Binomial}(n, p)$

↓ $n \rightarrow \infty, p \rightarrow 0, np = \lambda$ （泊松极限）

$\text{Poisson}(\lambda)$

$\text{Bernoulli}(p)$

↓ 等待首次成功

$\text{Geometric}(p)$

↓ 等待第r次成功

$\text{NegBinomial}(r, p)$

$\text{Binomial}(n, K/N) \leftarrow N \rightarrow \infty$ 近似

$\text{Hypergeometric}(N, K, n) \leftarrow$ 有限总体，不放回

7.5.3 选择分布的决策框架

在实际建模中，根据问题特征选择合适的分布：

问题特征	推荐分布
单次试验，二元结果	伯努利分布
n 次独立试验，统计成功次数	二项分布
固定时间/空间内，稀有事件计数	泊松分布
等待首次成功的试验次数	几何分布
等待第 r 次成功的试验次数	负二项分布
有限总体，不放回抽样	超几何分布

7.5.4 最大似然估计（MLE）总结

给定 n 个独立同分布观测值 $x_1, x_2, \dots, x_n$:

- **Bernoulli**(p): $\hat{p} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
- **Poisson**(λ): $\hat{\lambda} = \bar{x}$
- **Geometric**(p): $\hat{p} = \frac{1}{\bar{x}}$

MLE 的直观性：参数估计值等于样本均值（或其函数），体现了”用样本统计量估计总体参数”的核心思想。

本章小结

分布	记号	PMF $p(k)$	期望 $E[X]$	方差 $\text{Var}(X)$	典型场景
伯努利	Bernoulli(p)	$p^k(1-p)^{1-k},$ $k \in \{0, 1\}$	p	$p(1-p)$	单次二元结果
二项	$B(n, p)$	$\binom{n}{k} p^k (1-p)^{n-k}$	np	$np(1-p)$	n 次独立试验 成功数
泊松	$P(\lambda)$	$\frac{\lambda^k e^{-\lambda}}{k!}$	λ	λ	单位时间内事 件计数
几何	Geom(p)	$(1-p)^{k-1} p$	$\frac{1}{p}$	$\frac{1-p}{p^2}$	首次成功等待 次数
负二项	NB(r, p)	$\binom{k-1}{r-1} p^r (1-p)^{k-r}$	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$	第 r 次成功等 待次数
超几何	Hyp(N, K, n)	$\frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}$	$n \frac{K}{N}$	$n \frac{K}{N} \frac{N-K}{N} \frac{N-n}{N-1}$	不放回抽样

核心关系： - 伯努利 $\xrightarrow{n}$ 二项 $\xrightarrow{n \rightarrow \infty, p \rightarrow 0, np = \lambda}$ 泊松 - 几何 $\xrightarrow{r}$ 负二项 - 超几何 $\xrightarrow{N \rightarrow \infty}$ 二项

深度学习应用

应用一：伯努利分布与二元交叉熵损失（BCE）

深度学习中的二分类问题（如图像分类、情感分析）本质上是参数为 $p = \sigma(\mathbf{w}^T \mathbf{x})$ 的伯努利分布建模，其中 σ 为 sigmoid 函数。

概率论推导：给定 n 个样本 (x_i, y_i) , $y_i \in \{0, 1\}$, 模型预测 $\hat{p}_i = P(Y = 1 | x_i)$, 对数似然为

$$\log L = \sum_{i=1}^n [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)]$$

最大化对数似然等价于最小化二元交叉熵损失（Binary Cross-Entropy Loss）：

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{n} \sum_{i=1}^n [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)]$$

这正是伯努利分布负对数似然的均值形式。

```
import torch
import torch.nn as nn
import numpy as np

# —— 示例 1: BCE 损失与伯努利分布的等价性 ——
torch.manual_seed(42)
n = 100
# 真实标签（伯努利分布采样）
p_true = 0.7
y_true = torch.bernoulli(torch.full((n,), p_true))

# 模型预测概率（这里用固定值演示）
p_pred = torch.full((n,), 0.65)

# PyTorch BCE 损失
bce_loss = nn.BCELoss()
loss_pytorch = bce_loss(p_pred, y_true)

# 手动计算负对数似然（等价形式）
loss_manual = -(y_true * torch.log(p_pred) + (1 - y_true) * torch.log(1 - p_pred)).mean()

print(f"PyTorch BCE Loss: {loss_pytorch:.4f}")
print(f"Manual NLL Loss: {loss_manual:.4f}")
print(f"两者差异: {abs(loss_pytorch - loss_manual):.8f}")
```

```
# 输出示例:
# PyTorch BCE Loss: 0.6841
# Manual NLL Loss: 0.6841
# 两者差异: 0.00000000
```

应用二：泊松分布与事件计数建模

泊松回归 (Poisson Regression) 用于预测计数型输出 (如用户点击次数、单词出现频率), 模型输出 $\hat{\lambda} = \exp(\mathbf{w}^T \mathbf{x})$ (保证非负)。

泊松负对数似然损失:

$$\mathcal{L}_{\text{Poisson}} = \frac{1}{n} \sum_{i=1}^n [\hat{\lambda}_i - y_i \log \hat{\lambda}_i] + \text{const}$$

```
import torch
import torch.nn as nn

# —— 示例 2: 泊松分布用于计数建模 ——

class PoissonRegressor(nn.Module):
    """ 泊松回归模型: 输出事件发生率 """
    def __init__(self, input_dim):
        super().__init__()
        self.linear = nn.Linear(input_dim, 1)

    def forward(self, x):
        # 使用 softplus 或 exp 保证 > 0
        return torch.nn.functional.softplus(self.linear(x)).squeeze(-1)

# 泊松负对数似然损失
def poisson_nll_loss(y_pred_lambda, y_true):
    """
    泊松负对数似然:  $-\log P(Y=y| \lambda) = -y \log(\lambda) + \log(y!)$ 
    PyTorch 内置: nn.PoissonNLLLoss
    """
    return (y_pred_lambda - y_true * torch.log(y_pred_lambda + 1e-8)).mean()

torch.manual_seed(0)
input_dim = 5
batch_size = 32
```

```

# 模拟数据：特征  $x$ ，真实计数  $y$ （泊松分布）
x = torch.randn(batch_size, input_dim)
true_lambda = 3.0
y = torch.poisson(torch.full((batch_size,), true_lambda))

model = PoissonRegressor(input_dim)
y_pred = model(x)

loss = poisson_nll_loss(y_pred, y)
print(f"Poisson NLL Loss: {loss.item():.4f}")
print(f" 预测   均值: {y_pred.mean().item():.4f}")
print(f" 真实计数均值: {y.mean().item():.4f}")

# PyTorch 内置 Poisson 损失（等价）
criterion = nn.PoissonNLLLoss(log_input=False, full=False)
loss_builtin = criterion(y_pred, y)
print(f"PyTorch 内置 Poisson Loss: {loss_builtin.item():.4f}")

```

应用三：几何分布与序列建模中的停止概率

在自回归语言模型（如 GPT）的序列生成中，每个时间步生成终止符（<EOS>）的概率隐含了几何分布假设。若模型在每步以概率 p 生成 <EOS>，则序列长度 $L \sim \text{Geom}(p)$ ，期望长度为 $1/p$ 。

```

import torch
import torch.nn.functional as F

# ——示例 3：序列长度的几何分布建模 ——
def simulate_sequence_lengths(p_stop, num_sequences=10000, max_len=200):
    """
    模拟自回归模型生成序列长度分布。
    每步以概率  $p_{\text{stop}}$  停止，序列长度服从  $\text{Geom}(p_{\text{stop}})$ 。
    """
    lengths = []
    for _ in range(num_sequences):
        length = 1
        while length < max_len:
            if torch.bernoulli(torch.tensor(p_stop)).item() == 1:
                break
            length += 1
        lengths.append(length)
    return torch.tensor(lengths, dtype=torch.float)

```

```

# 理论期望:  $E[L] = 1/p$ 
p_stop = 0.1
lengths = simulate_sequence_lengths(p_stop, num_sequences=5000)

theoretical_mean = 1 / p_stop
theoretical_std = (1 - p_stop) ** 0.5 / p_stop

print(f" 停止概率 p = {p_stop}")
print(f" 理论期望长度: {theoretical_mean:.1f}")
print(f" 模拟均值:      {lengths.mean().item():.2f}")
print(f" 理论标准差:    {theoretical_std:.2f}")
print(f" 模拟标准差:    {lengths.std().item():.2f}")

# 负对数似然: 在序列建模中鼓励适当长度
# 若想让模型学习在特定长度停止, 可在损失中加入长度惩罚项
def length_penalty_loss(log_probs_eos, target_length, p_stop_target=0.1):
    """
    基于几何分布的序列长度正则化损失。
    log_probs_eos: 每步生成 EOS 的对数概率, shape (batch, seq_len)
    """
    seq_len = log_probs_eos.shape[1]
    # 期望停止步数服从  $Geom(p\_stop\_target)$ 
    # 简化: 用 MSE 鼓励平均停止概率接近目标
    mean_p_stop = log_probs_eos.exp().mean()
    target_p = torch.tensor(p_stop_target)
    return F.mse_loss(mean_p_stop, target_p)

```

综合示例: 离散分布的可视化比较

```

import torch
import matplotlib
matplotlib.use('Agg') # 非交互式后端
import matplotlib.pyplot as plt
import numpy as np
from scipy import stats

fig, axes = plt.subplots(2, 3, figsize=(15, 10))
fig.suptitle('离散分布族 PMF 比较', fontsize=16)

k_range = np.arange(0, 20)

```


1. 伯努利分布

```
ax = axes[0, 0]
p_vals = [0.3, 0.5, 0.7]
for p in p_vals:
    pmf = [p if k == 1 else (1-p) if k == 0 else 0 for k in [0, 1]]
    ax.bar([0, 1], pmf, alpha=0.6, label=f'p={p}', width=0.2,
           align='center')
ax.set_title('伯努利分布 Bernoulli(p)')
ax.set_xlabel('k')
ax.set_ylabel('P(X=k)')
ax.legend()
```

2. 二项分布

```
ax = axes[0, 1]
n = 20
for p in [0.3, 0.5, 0.7]:
    pmf = stats.binom.pmf(k_range[:21], n, p)
    ax.plot(k_range[:21], pmf, 'o-', label=f'n={n}, p={p}', markersize=4)
ax.set_title('二项分布 Binomial(n, p)')
ax.set_xlabel('k')
ax.set_ylabel('P(X=k)')
ax.legend()
```

3. 泊松分布

```
ax = axes[0, 2]
for lam in [1, 3, 7]:
    pmf = stats.poisson.pmf(k_range, lam)
    ax.plot(k_range, pmf, 'o-', label=f'={lam}', markersize=4)
ax.set_title('泊松分布 Poisson()')
ax.set_xlabel('k')
ax.set_ylabel('P(X=k)')
ax.legend()
```

4. 几何分布

```
ax = axes[1, 0]
k_geom = np.arange(1, 21)
for p in [0.2, 0.5, 0.8]:
    pmf = stats.geom.pmf(k_geom, p)
    ax.plot(k_geom, pmf, 'o-', label=f'p={p}', markersize=4)
ax.set_title('几何分布 Geom(p)')
ax.set_xlabel('k (首次成功的试验次数)')
```

```

ax.set_ylabel('P(X=k)')
ax.legend()

# 5. 负二项分布 (失败次数的 PMF)
ax = axes[1, 1]
k_nb = np.arange(0, 20)
r = 5
for p in [0.3, 0.5, 0.7]:
    pmf = stats.nbinom.pmf(k_nb, r, p)
    ax.plot(k_nb, pmf, 'o-', label=f'r={r}, p={p}', markersize=4)
ax.set_title('负二项分布 NB(r, p) (失败次数)')
ax.set_xlabel('k (成功前的失败次数)')
ax.set_ylabel('P(Y=k)')
ax.legend()

# 6. 超几何分布
ax = axes[1, 2]
N, n_draw = 50, 10
for K in [10, 25, 40]:
    pmf = stats.hypergeom.pmf(k_range[:11], N, K, n_draw)
    ax.plot(k_range[:11], pmf, 'o-', label=f'N={N}, K={K}, n={n_draw}',
            markersize=4)
ax.set_title('超几何分布 Hyp(N, K, n)')
ax.set_xlabel('k (抽到的成功数)')
ax.set_ylabel('P(X=k)')
ax.legend()

plt.tight_layout()
plt.savefig('discrete_distributions.png', dpi=150)
print(" 图像已保存为 discrete_distributions.png")

```

练习题

练习 7.1 (基础)

某深度学习模型对每张图片独立地以概率 $p = 0.85$ 正确分类。

- (1) 设 X 为 10 张图片中正确分类的数量, 写出 X 的分布并计算 $P(X \geq 9)$ 。
- (2) 计算 $E[X]$ 和 $\text{Var}(X)$ 。

- (3) 若要使至少 95% 的概率保证 10 张图片全部分类正确, 需要准确率 p 至少为多少?
-

练习 7.2 (中等)

某网站每小时平均接收 $\lambda = 4$ 次异常请求 (泊松分布)。

- (1) 求某小时内恰好收到 0 次异常请求的概率。
 - (2) 求某小时内收到不超过 2 次异常请求的概率。
 - (3) 设安全系统每 30 分钟检查一次, 求两次检查之间恰好有 3 次异常请求的概率。
 - (4) 若 $n = 1000$, $p = 0.004$, 用泊松近似计算 $B(1000, 0.004)$ 中 $P(X = 3)$, 并与精确值比较。
-

练习 7.3 (中等)

在强化学习中, 智能体在某状态下每次行动有 $p = 0.15$ 的概率找到奖励。

- (1) 设 X 为第一次获得奖励所需的行动次数, 求 $E[X]$ 、 $\text{Var}(X)$ 及 $P(X > 10)$ 。
 - (2) 利用无记忆性, 若智能体已经行动了 5 次仍未获奖, 求再至少行动 5 次才能获奖的概率。
 - (3) 设 Y 为获得第 3 次奖励所需的总行动次数, $Y \sim \text{NB}(3, 0.15)$, 求 $E[Y]$ 。
-

练习 7.4 (中等)

某数据集有 $N = 200$ 条样本, 其中 $K = 60$ 条为正类样本。不放回地随机抽取 $n = 20$ 条。

- (1) 设 X 为抽到的正类样本数, 写出 X 的分布, 计算 $E[X]$ 和 $\text{Var}(X)$ 。
 - (2) 计算 $P(X = 6)$ 。
 - (3) 若改用二项分布近似 ($p = 60/200 = 0.3$), 计算近似的 $\text{Var}(X)$ 并与精确值比较, 计算相对误差。
-

练习 7.5 (深度学习应用)

设二分类神经网络对样本 x 的输出为 $\hat{p} = \sigma(z)$, 其中 $z \in \mathbb{R}$ 为 logit, $\sigma(z) = \frac{1}{1+e^{-z}}$ 。

- (1) 写出单个样本 (x, y) , $y \in \{0, 1\}$ 的伯努利对数似然 $\log P(Y = y | x)$, 并说明它与 BCE 损失的关系。
- (2) 对伯努利对数似然关于 z 求导 (链式法则), 结合 $\sigma'(z) = \sigma(z)(1 - \sigma(z))$, 证明梯度为 $\frac{\partial \mathcal{L}_{\text{BCE}}}{\partial z} = \hat{p} - y$ (注意符号: 对负对数似然求导)。
- (3) 解释为什么使用交叉熵损失 (最大似然原则) 比使用均方误差损失 (MSE) 更适合分类问题 (从概率模型和梯度行为两方面分析)。

练习答案

答案 7.1

(1) $X \sim B(10, 0.85)$ 。

$$\begin{aligned} P(X \geq 9) &= P(X = 9) + P(X = 10) \\ &= \binom{10}{9} (0.85)^9 (0.15)^1 + \binom{10}{10} (0.85)^{10} (0.15)^0 \\ &= 10 \times 0.85^9 \times 0.15 + 0.85^{10} \\ &\approx 10 \times 0.2316 \times 0.15 + 0.1969 \\ &\approx 0.3474 + 0.1969 = 0.5443 \end{aligned}$$

(2) $E[X] = np = 10 \times 0.85 = 8.5$, $\text{Var}(X) = np(1-p) = 10 \times 0.85 \times 0.15 = 1.275$ 。

(3) 要求 $P(X = 10) \geq 0.95$, 即 $p^{10} \geq 0.95$, 因此 $p \geq 0.95^{1/10} = 0.95^{0.1} \approx 0.9949$ 。即准确率至少约需 99.49%。

答案 7.2

参数 $\lambda = 4$ (每小时), $X \sim \text{Poisson}(4)$ 。

(1) $P(X = 0) = \frac{4^0 e^{-4}}{0!} = e^{-4} \approx 0.0183$ 。

(2) $P(X \leq 2) = P(X = 0) + P(X = 1) + P(X = 2)$

$$= e^{-4} \left(1 + 4 + \frac{16}{2} \right) = 13e^{-4} \approx 13 \times 0.0183 \approx 0.2381$$

(3) 30 分钟内, $\lambda' = 4 \times 0.5 = 2$, $Y \sim \text{Poisson}(2)$ 。

$$P(Y = 3) = \frac{2^3 e^{-2}}{3!} = \frac{8e^{-2}}{6} \approx \frac{8 \times 0.1353}{6} \approx 0.1804$$

(4) 泊松近似: $\lambda = np = 1000 \times 0.004 = 4$ 。

$$P_{\text{Poisson}}(X = 3) = \frac{4^3 e^{-4}}{3!} = \frac{64e^{-4}}{6} \approx \frac{64 \times 0.0183}{6} \approx 0.1954$$

精确二项值: $P_{\text{Binom}}(X = 3) = \binom{1000}{3} (0.004)^3 (0.996)^{997}$ 。

计算得 ≈ 0.1954 , 两者高度吻合 (相对误差 $< 0.1\%$)。

答案 7.3

$X \sim \text{Geom}(0.15)$ 。

$$(1) E[X] = \frac{1}{0.15} \approx 6.67 \text{ 次}, \text{Var}(X) = \frac{1-0.15}{0.15^2} = \frac{0.85}{0.0225} \approx 37.78。$$

$$P(X > 10) = (1 - 0.15)^{10} = 0.85^{10} \approx 0.1969$$

$$(2) \text{ 由无记忆性: } P(X > 10 | X > 5) = P(X > 5) = 0.85^5 \approx 0.4437。$$

即使已经失败了5次，再至少失败5次（即总失败数超过10次）的概率仍为 $\approx 44.37\%$ ，与初始情况相同——这正是无记忆性的体现。

$$(3) Y \sim \text{NB}(3, 0.15), E[Y] = \frac{r}{p} = \frac{3}{0.15} = 20 \text{ 次行动}。$$

答案 7.4

$X \sim \text{Hyp}(200, 60, 20)$ 。

$$(1) E[X] = n \cdot \frac{K}{N} = 20 \times \frac{60}{200} = 6。$$

$$\text{Var}(X) = 20 \times \frac{60}{200} \times \frac{140}{200} \times \frac{180}{199} = 20 \times 0.3 \times 0.7 \times \frac{180}{199} \approx 4.2 \times 0.9045 \approx 3.799$$

(2)

$$P(X = 6) = \frac{\binom{60}{6} \binom{140}{14}}{\binom{200}{20}}$$

数值计算： $P(X = 6) \approx 0.1651$ （利用统计软件或递推公式）。

$$(3) \text{ 二项近似方差: } np(1-p) = 20 \times 0.3 \times 0.7 = 4.2。$$

精确值 ≈ 3.799 ，相对误差 $= \frac{4.2-3.799}{3.799} \approx 10.56\%$ 。

有限总体修正因子 $\frac{N-n}{N-1} = \frac{180}{199} \approx 0.9045$ 使方差缩小，因为不放回抽样降低了不确定性（已抽出的样本不再影响后续）。

答案 7.5

(1) 伯努利对数似然为：

$$\log P(Y = y | x) = y \log \hat{p} + (1 - y) \log(1 - \hat{p})$$

BCE 损失是负对数似然的均值： $\mathcal{L}_{\text{BCE}} = -\frac{1}{n} \sum_{i=1}^n \log P(Y = y_i | x_i)$ ，即最小化 BCE 损失等价于最大化伯努利对数似然。

(2) 对负对数似然 $\ell = -[y \log \hat{p} + (1 - y) \log(1 - \hat{p})]$ 求关于 z 的导数：

$$\frac{\partial \ell}{\partial z} = \frac{\partial \ell}{\partial \hat{p}} \cdot \frac{\partial \hat{p}}{\partial z}$$

其中：

$$\frac{\partial \ell}{\partial \hat{p}} = -\frac{y}{\hat{p}} + \frac{1-y}{1-\hat{p}} = \frac{\hat{p}-y}{\hat{p}(1-\hat{p})}$$

$$\frac{\partial \hat{p}}{\partial z} = \sigma'(z) = \hat{p}(1-\hat{p})$$

因此：

$$\frac{\partial \ell}{\partial z} = \frac{\hat{p}-y}{\hat{p}(1-\hat{p})} \cdot \hat{p}(1-\hat{p}) = \hat{p}-y \quad \checkmark$$

这个简洁的梯度形式（预测值与真实值之差）是 BCE 损失相比 MSE 的重要优势之一。


(3) 从概率模型角度：分类问题的目标变量服从伯努利分布，BCE 损失是正确的最大似然目标。MSE 对应高斯分布假设，与二元输出的实际分布不匹配。

从梯度行为角度：MSE 损失为 $\frac{1}{2}(\hat{p}-y)^2$ ，关于 z 的梯度为 $(\hat{p}-y)\hat{p}(1-\hat{p})$ 。当 $\hat{p} \approx 0$ 或 $\hat{p} \approx 1$ 时， $\hat{p}(1-\hat{p}) \approx 0$ ，即使预测严重错误（如 $\hat{p} = 0.01, y = 1$ ），梯度也接近零，导致梯度消失，训练极慢。BCE 损失的梯度为 $\hat{p}-y$ ，当预测错误时梯度较大，训练更高效。

几何示意

图示


说明



二项 $B(10, p)$ PMF: $p = 0.3/0.5/0.7$ 三组对比


图示

说明



泊松 $\text{Poisson}(\lambda)$ PMF: $\lambda = 1, 3, 10$

几何 $\text{Geom}(p)$ 与负二项 $\text{NB}(r, 0.3)$ PMF 对比



离散分布族关系: $\text{Bernoulli} \rightarrow \text{二项} \rightarrow \text{泊松}$

思考路标（条件反射）

1. **Bernoulli**(p) $\rightarrow$ 单次二元结果, $E = p$, $\text{Var} = p(1-p)$
2. 二项 $B(n, p) \rightarrow n$ 次独立重复 Bernoulli, $E = np$, $\text{Var} = np(1-p)$
3. **Poisson**(λ) $\rightarrow$ 稀有事件计数 ($\lambda = np$ 当 n 大 p 小); 期望 = 方差 = λ
4. 几何 **Geom**(p) $\rightarrow$ 首次成功等待次数, $E = 1/p$; 唯一离散无记忆分布
5. 超几何 **Hyp**(N, K, n) $\rightarrow$ 有限总体不放回抽样; $N \rightarrow \infty$ 趋近二项
6. 负二项 **NB**(r, p) $\rightarrow$ 第 r 次成功等待次数, $E = r/p$; 几何是 $r = 1$ 的特例
7. 离散均匀 $\rightarrow P(X = k) = 1/n$, $E = (n+1)/2$
8. 分布关系: Bernoulli $\xrightarrow{n\text{次叠加}}$ 二项 $\xrightarrow{n \rightarrow \infty, np=\lambda}$ Poisson; 几何 $\xrightarrow{r\text{次叠加}}$ 负二项

易错点

1. 放回 vs 不放回: 放回 (或无限总体) $\rightarrow$ 二项; 不放回 (有限总体) $\rightarrow$ 超几何
2. **Poisson** 近似条件: $n > 20$ 且 $p < 0.05$ (或 $n > 100$ 且 $p < 0.1$) 才能用 $\lambda = np$ 近似
3. 几何 vs 负二项: 几何是“首次成功”($r = 1$); 负二项是“第 r 次成功”
4. 二项期望: $E[X] = np$, 不是 p ; 方差 $np(1-p)$, 不是 np
5. 参数顺序: $B(n, p)$ 中 n 是试验次数、 p 是成功概率; $\text{Hyp}(N, K, n)$ 中 N 是总体、 K 是成功总数、 n 是抽取数

本章完

第8章：连续分布族

难度: ★★★★★☆ (□ 核心章节) 前置知识: 第5章连续随机变量、微积分 (Gamma 函数、换元积分)

一例速记

- 正态 $N(\mu, \sigma^2)$: 钟形对称, $P(|X - \mu| < \sigma) \approx 68\%$ 、 $< 2\sigma \approx 95\%$ 、 $< 3\sigma \approx 99.7\%$
- 指数 **Exp**(λ): $f(x) = \lambda e^{-\lambda x}$, $E = 1/\lambda$, 无记忆性 $P(X > s + t | X > s) = P(X > t)$
- **Gamma**(α, β): α 个独立 $\text{Exp}(\beta)$ 之和; $\alpha = n/2, \beta = 1/2$ 退化为 χ_n^2
- **Beta**(α, β): 定义在 $[0, 1]$, 概率论中作为概率的先验 (二项分布共轭先验)
- 三大抽样分布: $\chi_n^2 = \sum_{i=1}^n Z_i^2$; $t_n = Z / \sqrt{\chi_n^2/n}$; $F_{m,n} = (\chi_m^2/m) / (\chi_n^2/n)$

引入题

$X_1, \dots, X_5 \sim N(0, 1)$ 独立同分布。

1. 求 $Y = X_1^2 + X_2^2 + X_3^2 + X_4^2 + X_5^2$ 的分布。
2. 求 $T = X_5 / \sqrt{(X_1^2 + X_2^2 + X_3^2 + X_4^2)/4}$ 的分布。

思维路径还原

第一步：识别 Y 的结构

$Y = \sum_{i=1}^5 Z_i^2$ ，其中每个 $Z_i = X_i \sim N(0, 1)$ 。

卡方分布的定义： n 个独立标准正态平方和 $\sim \chi_n^2$ （自由度 n ）。

因此 $Y \sim \chi_5^2$ （自由度 5）。

第二步：识别 T 的分子

T 的分子 $X_5 \sim N(0, 1)$ ，即标准正态 Z 。

第三步：识别 T 的分母

分母 $\sqrt{(X_1^2 + X_2^2 + X_3^2 + X_4^2)/4}$ 。

$X_1^2 + X_2^2 + X_3^2 + X_4^2 \sim \chi_4^2$ （自由度 4），除以自由度 4 再开方，恰好是 t 分布定义中的分母形式： $\sqrt{\chi_n^2/n}$ （这里 $n = 4$ ）。

第四步：确认独立性

分子 X_5 与分母中的 X_1, X_2, X_3, X_4 相互独立（ X_i 独立同分布）。

第五步：写出结论

t 分布定义： $t_n = Z / \sqrt{\chi_n^2/n}$ ，其中 $Z \sim N(0, 1)$ ， χ_n^2 与 Z 独立。

对应 $T = X_5 / \sqrt{\chi_4^2/4}$ ，所以 $T \sim t_4$ （自由度 4）。

关键观察：分子分母必须独立，这里由 X_i 独立保证。若分子 X_5 同时出现在分母中，则 t 分布结论不成立。

三大抽样分布的记忆线索：- χ^2 ：平方和（“sum of squares”）- t ：正态 / 根号卡方均值（“normal over root chi-square-over-n”）- F ：两个卡方均值之比（“ratio of two chi-square-over-df”）

这三个分布是统计推断的基石： t 用于小样本均值检验， χ^2 用于方差检验， F 用于方差比 / ANOVA。

学习目标

学完本章后，你将能够：

1. 掌握均匀分布、正态分布、指数分布、Gamma 分布和 Beta 分布的概率密度函数（PDF）与累积分布函数（CDF）
 2. 理解正态分布的性质——包括对称性、68-95-99.7 法则与标准化——并能熟练进行正态概率计算
 3. 深刻理解指数分布的无记忆性，并能将其与泊松过程联系起来
 4. 掌握 Gamma 分布和 Beta 分布的参数含义，理解它们作为其他分布的推广与联系
 5. 将各连续分布应用于深度学习场景，包括权重初始化、批归一化分析和贝叶斯先验设定
-

8.1 均匀分布

定义与概率密度函数

若随机变量 X 在区间 $[a, b]$ 上等可能地取值，则称 X 服从均匀分布，记作 $X \sim \text{Uniform}(a, b)$ 或 $X \sim \mathcal{U}(a, b)$ 。

概率密度函数（PDF）：

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{其他} \end{cases}$$

累积分布函数（CDF）：

$$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x \leq b \\ 1, & x > b \end{cases}$$

期望与方差

$$E[X] = \frac{a+b}{2}$$

$$\text{Var}(X) = \frac{(b-a)^2}{12}$$

推导方差：

$$E[X^2] = \int_a^b x^2 \cdot \frac{1}{b-a} dx = \frac{1}{b-a} \cdot \frac{b^3 - a^3}{3} = \frac{a^2 + ab + b^2}{3}$$

$$\text{Var}(X) = E[X^2] - (E[X])^2 = \frac{a^2 + ab + b^2}{3} - \frac{(a+b)^2}{4} = \frac{(b-a)^2}{12}$$

标准均匀分布

当 $a = 0, b = 1$ 时，得到标准均匀分布 $\mathcal{U}(0, 1)$ ：

$$f(x) = 1, \quad 0 \leq x \leq 1$$

$$E[X] = \frac{1}{2}, \quad \text{Var}(X) = \frac{1}{12}$$

标准均匀分布是随机数生成的基础。通过逆变换法，可以从 $\mathcal{U}(0, 1)$ 生成任意分布的随机样本：若 $U \sim \mathcal{U}(0, 1)$ ，则 $X = F^{-1}(U)$ 服从 CDF 为 F 的分布。

直觉理解

均匀分布代表完全无偏的先验——在没有任何额外信息时，区间内所有点的可能性相同。这在贝叶斯统计中称为无信息先验（noninformative prior）。

8.2 正态分布（高斯分布）

概率密度函数

若随机变量 X 服从正态分布（Normal distribution），记作 $X \sim \mathcal{N}(\mu, \sigma^2)$ ，其 PDF 为：

$$f(x) = \frac{1}{\sqrt{2\pi} \sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right), \quad x \in (-\infty, +\infty)$$

其中：- μ ：均值（分布中心）- σ^2 ：方差（控制分布宽窄）- σ ：标准差

标准正态分布

令 $Z = \frac{X - \mu}{\sigma}$ ，则 $Z \sim \mathcal{N}(0, 1)$ ，称为标准正态分布。其 PDF 记作：

$$\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$$

其 CDF 记作 $\Phi(z)$ ，无闭合解析式，通常查表或用 `scipy.stats.norm.cdf` 计算。

标准化变换的意义：将任意正态分布转化为标准正态，统一了计算框架。

期望与方差

$$E[X] = \mu, \quad \text{Var}(X) = \sigma^2$$

验证期望（利用奇函数对称性）：

$$E[X] = \int_{-\infty}^{+\infty} x \cdot \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/(2\sigma^2)} dx$$

令 $u = (x - \mu)/\sigma$ ，则：

$$E[X] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} (\sigma u + \mu) e^{-u^2/2} du = \mu$$

其中 $\int u e^{-u^2/2} du = 0$ （奇函数在对称区间上积分为零）。

正态分布的关键性质

1. 对称性

$f(\mu + x) = f(\mu - x)$ ，分布关于均值 μ 完全对称，因此偏度为 **0**，峰度为 **3**（超额峰度为 0）。

2. 68-95-99.7 法则

$$P(\mu - \sigma \leq X \leq \mu + \sigma) \approx 68.27\%$$

$$P(\mu - 2\sigma \leq X \leq \mu + 2\sigma) \approx 95.45\%$$

$$P(\mu - 3\sigma \leq X \leq \mu + 3\sigma) \approx 99.73\%$$

3. 线性组合的封闭性

若 $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$ 相互独立，则：

$$\sum_{i=1}^n a_i X_i \sim \mathcal{N}\left(\sum_i a_i \mu_i, \sum_i a_i^2 \sigma_i^2\right)$$

4. 矩母函数

$$M_X(t) = E[e^{tX}] = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right)$$

中心极限定理 (CLT) 预告

正态分布之所以在自然界中无处不在，根本原因是中心极限定理：大量独立同分布随机变量之和，在适当标准化后趋向正态分布。这将在第10章详细讨论。

正态概率计算示例

例：若某班考试成绩 $X \sim \mathcal{N}(75, 10^2)$ ，求成绩在85分以上的概率。

$$P(X > 85) = P\left(Z > \frac{85 - 75}{10}\right) = P(Z > 1) = 1 - \Phi(1) \approx 1 - 0.8413 = 15.87\%$$

8.3 指数分布与无记忆性

定义与概率密度函数

指数分布描述“等待时间”——在泊松过程中，两次事件之间的等待时间服从指数分布。

若 $X \sim \text{Exp}(\lambda)$ ($\lambda > 0$ 为速率参数)，则：

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0$$

$$F(x) = 1 - e^{-\lambda x}, \quad x \geq 0$$

期望与方差

$$E[X] = \frac{1}{\lambda}, \quad \text{Var}(X) = \frac{1}{\lambda^2}$$

推导期望（分部积分）：

$$E[X] = \int_0^{\infty} x \lambda e^{-\lambda x} dx = [-x e^{-\lambda x}]_0^{\infty} + \int_0^{\infty} e^{-\lambda x} dx = \frac{1}{\lambda}$$

无记忆性：指数分布的核心特征

无记忆性（**Memoryless Property**）是指数分布最重要的性质：

$$P(X > s + t \mid X > s) = P(X > t), \quad \forall s, t \geq 0$$

证明：

$$P(X > s + t \mid X > s) = \frac{P(X > s + t)}{P(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(X > t)$$

直觉解释：“已经等了 s 分钟”这一信息对未来等待时间没有任何影响——系统没有“记忆”。这就像一枚完美的硬币：无论已经抛了多少次正面，下一次正面的概率仍然是 $1/2$ 。

重要定理：在连续分布中，指数分布是唯一具有无记忆性的分布。

与泊松过程的联系

若事件以速率 λ 按泊松过程发生（单位时间内事件数 $\sim \text{Poisson}(\lambda)$ ），则：- 相邻事件的等待时间 $\sim \text{Exp}(\lambda)$ - 等待第 k 个事件的时间 $\sim \text{Gamma}(k, \lambda)$ （见 8.4 节）

参数化方式

指数分布有两种常见参数化：- 速率参数 (rate): $f(x) = \lambda e^{-\lambda x}$, 均值为 $1/\lambda$ - 尺度参数 (scale): $f(x) = \frac{1}{\theta} e^{-x/\theta}$, 均值为 θ

其中 $\theta = 1/\lambda$ 。Python 的 `scipy.stats.expon` 使用尺度参数。

8.4 Gamma 分布与 Beta 分布

Gamma 函数

Gamma 分布的定义基于 **Gamma 函数**：

$$\Gamma(\alpha) = \int_0^{\infty} x^{\alpha-1} e^{-x} dx, \quad \alpha > 0$$

关键性质：

$$\Gamma(\alpha + 1) = \alpha \cdot \Gamma(\alpha) \quad (\text{递推关系})$$

$$\Gamma(n) = (n - 1)! \quad (\text{正整数时退化为阶乘})$$

$$\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$$

Gamma 分布

定义：若 $X \sim \text{Gamma}(\alpha, \beta)$ （形状参数 $\alpha > 0$ ，速率参数 $\beta > 0$ ），则：

$$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x > 0$$

期望与方差：

$$E[X] = \frac{\alpha}{\beta}, \quad \text{Var}(X) = \frac{\alpha}{\beta^2}$$

特殊情形：

参数取值	退化分布
$\alpha = 1$	$\text{Exp}(\beta)$ （指数分布）
$\alpha = n/2, \beta = 1/2$	$\chi^2(n)$ （卡方分布）
$\alpha \in \mathbb{Z}^+$	Erlang 分布（等待 α 个事件的时间）

直觉：Gamma 分布是“等待第 α 个泊松事件所需时间”的分布，是指数分布的自然推广。

Beta 分布

定义：若 $X \sim \text{Beta}(\alpha, \beta)$ ($\alpha, \beta > 0$)，则：

$$f(x) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha, \beta)}, \quad 0 < x < 1$$

其中 **Beta** 函数：

$$B(\alpha, \beta) = \int_0^1 x^{\alpha-1}(1-x)^{\beta-1} dx = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$$

期望与方差：

$$E[X] = \frac{\alpha}{\alpha+\beta}, \quad \text{Var}(X) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$$

形状变化：

参数关系	形状特征
$\alpha = \beta = 1$	均匀分布 $\mathcal{U}(0, 1)$
$\alpha = \beta > 1$	对称单峰，峰在 $x = 0.5$
$\alpha = \beta < 1$	U 形，两端密度高
$\alpha > \beta$	右偏，峰靠近 1
$\alpha < \beta$	左偏，峰靠近 0
$\alpha, \beta \gg 1$	趋近于正态分布

为何 **Beta** 分布在贝叶斯统计中极为重要？

Beta 分布是二项分布成功概率 p 的共轭先验：

$$p \sim \text{Beta}(\alpha, \beta) \implies p \mid \text{data} \sim \text{Beta}(\alpha + k, \beta + n - k)$$

其中 n 次试验中观察到 k 次成功。这种“更新只需修改参数”的性质极大简化了贝叶斯推断。

8.5 其他重要连续分布

8.5.1 对数正态分布

若 $\ln X \sim \mathcal{N}(\mu, \sigma^2)$ ，则 X 服从对数正态分布，记作 $X \sim \text{LogNormal}(\mu, \sigma^2)$ 。

PDF ($x > 0$):

$$f(x) = \frac{1}{x\sqrt{2\pi\sigma}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right)$$

期望与方差:

$$E[X] = e^{\mu + \sigma^2/2}, \quad \text{Var}(X) = e^{2\mu + \sigma^2}(e^{\sigma^2} - 1)$$

特点: - PDF 是右偏的 (长右尾), 适合建模正值且右偏的数据 - 典型应用: 金融资产价格、收入分布、颗粒大小、生物生长等 - 在深度学习中, 模型权重的梯度范数、训练损失的分布常近似对数正态

8.5.2 柯西分布

定义 X 服从柯西分布 (Cauchy Distribution) $\text{Cauchy}(x_0, \gamma)$ 时, PDF 为:

$$f(x) = \frac{1}{\pi\gamma \left[1 + \left(\frac{x-x_0}{\gamma}\right)^2\right]}$$

其中 x_0 是位置参数 (中位数), $\gamma > 0$ 是尺度参数。标准柯西分布取 $x_0 = 0, \gamma = 1$ 。

关键性质——期望和方差不存在:

$$\int_{-\infty}^{+\infty} |x| \cdot \frac{1}{\pi(1+x^2)} dx = \frac{2}{\pi} \int_0^{\infty} \frac{x}{1+x^2} dx = +\infty$$

因此 $E[|X|] = \infty$, 柯西分布没有期望, 方差更不存在。

重要意义: - 柯西分布是“期望不一定存在”的经典反例 - 标准柯西分布等价于两个独立标准正态之比: $Z_1/Z_2 \sim \text{Cauchy}(0, 1)$ - n 个独立柯西变量的样本均值仍服从柯西分布——大数定律不适用 (因为期望不存在) - 柯西分布也是自由度为 1 的 t 分布: $t(1) = \text{Cauchy}(0, 1)$

8.5.3 韦布尔分布

定义 $X \sim \text{Weibull}(k, \lambda)$ ($k > 0$ 为形状参数, $\lambda > 0$ 为尺度参数), PDF 为:

$$f(x) = \frac{k}{\lambda} \left(\frac{x}{\lambda}\right)^{k-1} \exp\left(-\left(\frac{x}{\lambda}\right)^k\right), \quad x \geq 0$$

特殊情形: $k = 1$ 时退化为指数分布 $\text{Exp}(1/\lambda)$ 。

期望与方差: $E[X] = \lambda\Gamma(1 + 1/k)$, $\text{Var}(X) = \lambda^2[\Gamma(1 + 2/k) - \Gamma^2(1 + 1/k)]$

应用: 可靠性工程 (元器件寿命分析)、材料强度建模、风速分布。

8.6 分布之间的关系

连续分布族并非相互孤立，它们之间存在丰富的联系。

层级关系图

均匀分布 $U(0,1)$

逆变换法可生成任意分布

正态分布 $N(\mu, \sigma^2)$

平方

线性组合

卡方分布 $\chi^2(n)$

正态混合

推广（非中心 χ^2 /加速率参数）

Gamma(α, θ)

$\theta=1 \rightarrow$ 指数分布 $\text{Exp}(\lambda)$

$\theta=n/2, \alpha=1/2 \rightarrow \chi^2(n)$

Beta(α, β)

$\alpha=\beta=1 \rightarrow U(0,1)$

与 Gamma 的比值关系（见下）

关键转换关系

1. 正态 $\rightarrow$ 卡方

若 $Z_i \sim \mathcal{N}(0,1)$ 独立，则：

$$\sum_{i=1}^n Z_i^2 \sim \chi^2(n) = \text{Gamma}\left(\frac{n}{2}, \frac{1}{2}\right)$$

2. Gamma $\rightarrow$ Beta

若 $X \sim \text{Gamma}(\alpha, \theta)$ 与 $Y \sim \text{Gamma}(\beta, \theta)$ 独立，则：

$$\frac{X}{X+Y} \sim \text{Beta}(\alpha, \beta)$$

3. 指数的最小值

若 $X_i \sim \text{Exp}(\lambda_i)$ 相互独立，则：

$$\min(X_1, \dots, X_n) \sim \text{Exp}(\lambda_1 + \dots + \lambda_n)$$

4. 正态的绝对值

若 $Z \sim \mathcal{N}(0, 1)$ ，则 $|Z|$ 服从半正态分布 (**Half-Normal**)， $Z^2 \sim \chi^2(1) = \text{Gamma}(1/2, 1/2)$ 。

5. 均匀 $\rightarrow$ 指数

若 $U \sim \mathcal{U}(0, 1)$ ，则 $-\frac{1}{\lambda} \ln U \sim \text{Exp}(\lambda)$ (逆变换法的具体应用)。

混合分布

定义若 X 以概率 w_i ($\sum w_i = 1$) 从分布 $f_i(x)$ 中取值，则 X 的 PDF 为：

$$f(x) = \sum_{i=1}^k w_i f_i(x)$$

称为 k 个分布的混合分布 (Mixture Distribution)， w_i 称为混合权重。

性质：- 期望： $E[X] = \sum_i w_i \mu_i$ - 方差 (全方差公式)： $\text{Var}(X) = \sum_i w_i \sigma_i^2 + \sum_i w_i (\mu_i - \bar{\mu})^2$ - 混合分布可以建模多峰或复杂形状的数据

最常见的混合分布——高斯混合模型 (**GMM**)：

$$f(x) = \sum_{i=1}^k w_i \cdot \frac{1}{\sqrt{2\pi}\sigma_i} \exp\left(-\frac{(x - \mu_i)^2}{2\sigma_i^2}\right)$$

GMM 可以逼近任意连续分布 (只要混合成分足够多)，在聚类分析和密度估计中广泛使用。参数估计通常使用 EM 算法 (见第 24 章)。

分布比较汇总

分布	支撑	参数	均值	方差	特征
$\mathcal{U}(a, b)$	$[a, b]$	a, b	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	等可能
$\mathcal{N}(\mu, \sigma^2)$	$\mathbb{R}$	μ, σ^2	μ	σ^2	对称钟形
$\text{Exp}(\lambda)$	$[0, \infty)$	λ	$1/\lambda$	$1/\lambda^2$	无记忆性

分布	支撑	参数	均值	方差	特征
Gamma(α, β)	$(0, \infty)$	α, β	α/β	α/β^2	推广指数
Beta(α, β)	$(0, 1)$	α, β	$\frac{\alpha}{\alpha+\beta}$	$\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$	概率先验

本章小结

概念	核心公式	关键意义
均匀分布 $\mathcal{U}(a, b)$	$f(x) = \frac{1}{b-a}$	无信息先验；随机数基础
正态分布 $\mathcal{N}(\mu, \sigma^2)$	$f(x) = \frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	CLT 极限；自然界普遍存在
指数分布 $\text{Exp}(\lambda)$	$f(x) = \lambda e^{-\lambda x}$	等待时间；唯一连续无记忆分布
Gamma 分布 Gamma(α, β)	$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)}x^{\alpha-1}e^{-\beta x}$	多个指数之和；等待 k 次事件
Beta 分布 Beta(α, β)	$f(x) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha, \beta)}$	概率的先验；共轭先验
无记忆性	$P(X > s + t \mid X > s) = P(X > t)$	指数分布的唯一性定理
标准化	$Z = (X - \mu)/\sigma$	正态计算的统一框架
Gamma-Beta 关系	$\frac{X}{X+Y} \sim \text{Beta}(\alpha, \beta)$	分布族的内在统一性
对数正态分布	$\ln X \sim \mathcal{N}(\mu, \sigma^2)$	正值右偏数据；金融建模
柯西分布	$f(x) = \frac{1}{\pi\gamma[1+(x-x_0)^2/\gamma^2]}$	期望不存在的经典反例
韦布尔分布	$f(x) = \frac{k}{\lambda}(x/\lambda)^{k-1}e^{-(x/\lambda)^k}$	可靠性工程；推广指数分布
混合分布	$f(x) = \sum w_i f_i(x)$	建模多峰、复杂分布

深度学习应用：权重初始化、归一化与贝叶斯先验

背景

概率分布在深度学习中无处不在：- 初始化：权重的初始分布影响训练稳定性 - 归一化：批归一化使激活值趋近正态分布 - 贝叶斯深度学习：用概率分布表示权重的不确定性

代码实现

```
import torch
import torch.nn as nn
import numpy as np
import matplotlib.pyplot as plt
```

```

from scipy import stats

torch.manual_seed(42)
np.random.seed(42)

# =====
# 1. 权重初始化策略与分布分析
# =====

def analyze_initialization(init_fn, name, n_weights=10000):
    """ 分析不同初始化策略产生的权重分布 """
    layer = nn.Linear(100, 100)
    init_fn(layer.weight)
    weights = layer.weight.detach().numpy().flatten()

    mean, std = weights.mean(), weights.std()
    print(f"{name}:")
    print(f"  均值 = {mean:.4f}, 标准差 = {std:.4f}")
    print(f"  范围 = [{weights.min():.4f}, {weights.max():.4f}]")
    return weights

# Xavier 均匀初始化 (均匀分布)
# 目标: 使每层输入输出的方差一致
# 范围:  $[-\sqrt{6/(fan\_in+fan\_out)}, \sqrt{6/(fan\_in+fan\_out)}]$ 
w_xavier_uniform = analyze_initialization(
    nn.init.xavier_uniform_, "Xavier 均匀 (Uniform)")

# Xavier 正态初始化 (截断正态)
#  $std = \sqrt{2/(fan\_in+fan\_out)}$ 
w_xavier_normal = analyze_initialization(
    nn.init.xavier_normal_, "Xavier 正态 (Normal)")

# Kaiming 均匀初始化 (ReLU 激活专用)
# 考虑 ReLU 只保留正半部分, 方差补偿为 2
w_kaiming = analyze_initialization(
    lambda w: nn.init.kaiming_normal_(w, nonlinearity='relu'),
    "Kaiming 正态 (He, ReLU)")

# =====
# 2. 可视化权重初始化分布
# =====

```

```

fig, axes = plt.subplots(1, 3, figsize=(15, 4))
configs = [
    (w_xavier_uniform, "Xavier 均匀初始化\n $\mathcal{U}(-a, a)$ ", "steelblue"),
    (w_xavier_normal, "Xavier 正态初始化\n $\mathcal{N}(0, \sigma^2)$ ", "darkorange"),
    (w_kaiming, "Kaiming 正态初始化\n $\mathcal{N}(0, 2/\text{fan\_in})$ ", "seagreen"),
]

for ax, (weights, title, color) in zip(axes, configs):
    ax.hist(weights, bins=60, density=True, color=color, alpha=0.7)
    x = np.linspace(weights.min(), weights.max(), 200)
    # 叠加正态拟合曲线
    mu, sigma = weights.mean(), weights.std()
    ax.plot(x, stats.norm.pdf(x, mu, sigma), 'k--', linewidth=2, label='正态拟合')
    ax.set_title(title, fontsize=11)
    ax.set_xlabel(" 权重值")
    ax.set_ylabel(" 概率密度")
    ax.legend()

plt.suptitle(" 深度学习权重初始化分布比较", fontsize=13, y=1.02)
plt.tight_layout()
plt.savefig("weight_initialization.png", dpi=150, bbox_inches='tight')
print("\n图像已保存: weight_initialization.png")

# =====
# 3. 批归一化 (Batch Normalization) 与正态分布
# =====

print("\n" + "="*50)
print(" 批归一化分析")
print("="*50)

class SimpleNetWithBN(nn.Module):
    def __init__(self):
        super().__init__()
        self.fc1 = nn.Linear(784, 256)
        self.bn1 = nn.BatchNorm1d(256) # 归一化层
        self.relu = nn.ReLU()
        self.fc2 = nn.Linear(256, 10)

    def forward_with_stats(self, x):

```

```

    """ 返回 BN 前后的激活统计信息 """
    z_before_bn = self.fc1(x)

    # BatchNorm 核心操作:
    # 1. 计算 mini-batch 的均值和方差
    # 2. 标准化:  $z\_hat = (z - \mu\_batch) / \sqrt{\sigma^2\_batch + \epsilon}$ 
    # 3. 缩放平移:  $y = \gamma \cdot z\_hat + \beta$  (可学习参数)
    z_after_bn = self.bn1(z_before_bn)

    return z_before_bn.detach(), z_after_bn.detach()

model = SimpleNetWithBN()
model.eval()

# 用随机输入测试
x_test = torch.randn(128, 784) # batch_size=128
with torch.no_grad():
    before_bn, after_bn = model.forward_with_stats(x_test)

print(f"BN 前激活: 均值 = {before_bn.mean():.4f}, 方差 = {before_bn.var():.4f}")
print(f"BN 后激活: 均值 = {after_bn.mean():.4f}, 方差 = {after_bn.var():.4f}")
print(f"BN 效果: 将激活强制归一化为近似 N(0,1) 分布")

# =====
# 4. 贝叶斯先验: Beta 分布在概率估计中的应用
# =====

print("\n" + "="*50)
print(" 贝叶斯先验: Beta 分布更新")
print("="*50)

# 场景: 估计模型在测试集上的准确率 (二分类: 对/错)
# 先验: Beta(  $\alpha$ ,  $\beta$  ), 代表 " 初始信念 "
# 似然: 观察到  $k$  次正确,  $n-k$  次错误
# 后验: Beta(  $\alpha + k$ ,  $\beta + n - k$  ) (Beta 是二项分布的共轭先验)

def beta_bayesian_update(alpha_prior, beta_prior, n_correct, n_total):
    """
    贝叶斯更新: Beta 先验 + 二项似然 → Beta 后验

    参数:
    """

```

```

    alpha_prior, beta_prior: 先验参数
    n_correct: 正确预测次数
    n_total: 总预测次数
    """
    n_wrong = n_total - n_correct
    alpha_post = alpha_prior + n_correct
    beta_post = beta_prior + n_wrong

    prior_mean = alpha_prior / (alpha_prior + beta_prior)
    post_mean = alpha_post / (alpha_post + beta_post)
    post_var = (alpha_post * beta_post) / \
        ((alpha_post + beta_post)**2 * (alpha_post + beta_post + 1))
    post_std = np.sqrt(post_var)

    print(f" 先验 Beta({alpha_prior}, {beta_prior}): 期望准确率 = {prior_mean:.3f}")
    print(f" 观测数据: {n_correct}/{n_total} 正确")
    print(f" 后验 Beta({alpha_post}, {beta_post}): ")
    print(f" 期望准确率 = {post_mean:.3f}")
    print(f" 标准差 = {post_std:.4f}")
    print(f" 95% 置信区间 [{post_mean-2*post_std:.3f}, {post_mean+2*post_std:.3f}]")
    return alpha_post, beta_post

# 情景 1: 无信息先验 (均匀分布), 观测 100 次
print(" 情景 1: 无信息先验 Beta(1,1)")
alpha_p, beta_p = beta_bayesian_update(1, 1, 87, 100)

print()
# 情景 2: 弱先验 (认为准确率约 70%)
print(" 情景 2: 弱信息先验 Beta(7,3), 均值 =0.7")
alpha_p, beta_p = beta_bayesian_update(7, 3, 87, 100)

print()
# 情景 3: 持续更新——顺序贝叶斯学习
print(" 情景 3: 顺序贝叶斯更新 (每 20 次观测更新一次) ")
alpha, beta_val = 1, 1 # 无信息先验
batches = [(16,20), (19,20), (14,20), (17,20), (21,25)] # 每批 (正确, 总数)
for i, (k, n) in enumerate(batches):
    alpha = alpha + k
    beta_val = beta_val + (n - k)
    mean = alpha / (alpha + beta_val)
    print(f" 第{i+1}批 ({k}/{n}) → Beta({alpha}, {beta_val}), 当前估计 = {mean:.3f}")

```



```
# =====
# 5. 指数分布在神经网络中: Dropout 保留概率的几何分布连接
# =====

print("\n" + "="*50)
print("Dropout 与几何/指数分布的联系")
print("="*50)

# Dropout: 每个神经元以概率 p 被保留
# 一个神经元在连续 k 次前向传播中首次被 Dropout 关闭
# 等待次数近似服从几何分布 (离散), 其连续类比是指数分布

p_keep = 0.5 # 每次保留概率

# 模拟: 某神经元需要多少次前向传播才首次被关闭
def simulate_first_dropout(p_keep, n_simulations=100000):
    """ 模拟首次被 dropout 的等待次数 """
    waiting_times = []
    for _ in range(n_simulations):
        count = 0
        while np.random.random() < p_keep:
            count += 1
        waiting_times.append(count)
    return np.array(waiting_times)

waiting = simulate_first_dropout(p_keep)
theoretical_mean = p_keep / (1 - p_keep)

print(f"Dropout 保留率 p = {p_keep}")
print(f" 首次被关闭的等待次数: ")
print(f" 模拟均值 = {waiting.mean():.3f} (理论均值 = {theoretical_mean:.3f}) ")
print(f" 模拟方差 = {waiting.var():.3f} (理论方差 = {theoretical_mean/(1-p_keep):.3f}) ")
print(f" 连续极限: 等待时间 ~ Exp( = {1-p_keep}) ")
```

关键公式速查

应用场景	所用分布	公式/规则
Xavier 均匀初始化	$\mathcal{U}(-a, a)$	$a = \sqrt{6/(n_{\text{in}} + n_{\text{out}})}$
Xavier 正态初始化	$\mathcal{N}(0, \sigma^2)$	$\sigma = \sqrt{2/(n_{\text{in}} + n_{\text{out}})}$

应用场景	所用分布	公式/规则
Kaiming 初始化 (ReLU)	$\mathcal{N}(0, \sigma^2)$	$\sigma = \sqrt{2/n_{\text{in}}}$
批归一化	$\mathcal{N}(0, 1)$	$\hat{z} = (z - \mu_B) / \sqrt{\sigma_B^2 + \varepsilon}$
准确率贝叶斯估计	$\text{Beta}(\alpha, \beta)$	后验: $\text{Beta}(\alpha + k, \beta + n - k)$
Dropout 等待分布	$\text{Exp}(\lambda)$	$\lambda = 1 - p_{\text{keep}}$

设计启示

1. 初始化至关重要：错误的初始化（如全零、方差过大）会导致梯度消失或爆炸。Xavier/Kaiming 初始化通过匹配各层的方差，显著提升训练稳定性。
2. 批归一化的概率意义：BN 将每层激活强制拉回近似 $\mathcal{N}(0, 1)$ ，避免”内部协变量偏移” (Internal Covariate Shift)，相当于在每层输入上做标准化变换。
3. 贝叶斯视角的优势：用 Beta 分布表示准确率的不确定性，比点估计更诚实——不仅给出”最佳猜测”，还量化了置信程度，尤其在小样本场景下价值巨大。

练习题

练习 1（均匀分布）

设 $X \sim \mathcal{U}(2, 8)$ 。

- (a) 写出 X 的 PDF 和 CDF。
- (b) 计算 $P(3 \leq X \leq 6)$ 。
- (c) 计算 $E[X]$ 和 $\text{Var}(X)$ 。
- (d) 若 $Y = 2X - 1$ ，求 Y 的分布及其期望和方差。

练习 2（正态分布）

某深度学习模型的某层激活值近似服从 $\mathcal{N}(0.5, 0.04)$ （均值 0.5，方差 0.04）。

- (a) 求激活值落在 $[0.3, 0.7]$ 之间的概率（标准化后查表或计算）。
- (b) 若对该层做批归一化，新激活值的分布是什么？
- (c) 利用 68-95-99.7 法则，求原始激活值超过 0.9 的概率。
- (d) 若该层有 1000 个神经元，期望有多少个激活值超过 0.9？

练习 3 (指数分布与无记忆性)

某 Web 服务器处理请求的等待时间服从 $\text{Exp}(\lambda = 2)$ (单位：分钟)。

- (a) 求期望等待时间和标准差。
 - (b) 求等待时间超过 1 分钟的概率。
 - (c) 已知某请求已等待了 0.5 分钟，求还需再等超过 1 分钟的概率。
 - (d) (c) 的结果与 (b) 有何关系？这体现了什么性质？请写出严格的数学表达。
 - (e) 若现在有 3 台服务器并行处理，每台的等待时间独立且均服从 $\text{Exp}(2)$ ，求第一个请求被处理的等待时间分布及其期望。
-

练习 4 (Gamma 分布与 Beta 分布)

- (a) 若 $X \sim \text{Gamma}(3, 2)$ ，求 $E[X]$ 、 $\text{Var}(X)$ ，并说明 X 可以解释为什么随机变量之和。
 - (b) 验证：当 $\alpha = 1$ 时， $\text{Gamma}(1, \beta)$ 退化为 $\text{Exp}(\beta)$ (写出 PDF 对比)。
 - (c) 若 $X \sim \text{Beta}(3, 7)$ ，求 $E[X]$ 和 $\text{Var}(X)$ 。直觉上，这个 Beta 分布描述的是一个成功率大约多少的二项试验的先验？
 - (d) 观察到 60 次试验中 12 次成功，以 $\text{Beta}(3, 7)$ 为先验，写出后验分布，并与先验的期望进行比较。
-

练习 5 (综合：分布之间的关系)

- (a) 若 $Z_1, Z_2 \sim \mathcal{N}(0, 1)$ 独立，令 $W = Z_1^2 + Z_2^2$ 。求 W 的分布 (用 Gamma 分布表示)。
 - (b) 在 (a) 的基础上，令 $R = \sqrt{W}$ 。 R 称为瑞利分布 (**Rayleigh distribution**)，其 PDF 为 $f_R(r) = re^{-r^2/2}$ ($r \geq 0$)。验证： $E[R] = \sqrt{\pi/2}$ 。
 - (c) 利用逆变换法，从 $U \sim \mathcal{U}(0, 1)$ 出发，写出生成 $\text{Exp}(\lambda)$ 样本的公式，并说明为何取 $-\frac{1}{\lambda} \ln U$ 而非 $-\frac{1}{\lambda} \ln(1-U)$ 。
 - (d) 若 $X \sim \text{Gamma}(\alpha, \theta)$ 与 $Y \sim \text{Gamma}(\beta, \theta)$ 独立，证明 $\frac{X}{X+Y} \sim \text{Beta}(\alpha, \beta)$ (提示：令 $U = X/(X+Y)$ ， $V = X+Y$ ，用雅可比行列式做变量替换)。
-

练习答案

答案 1

(a) $X \sim \mathcal{U}(2, 8)$, 区间长度为 $b - a = 6$ 。

$$f(x) = \frac{1}{6}, \quad 2 \leq x \leq 8; \quad f(x) = 0, \text{ 其他}$$

$$F(x) = \begin{cases} 0, & x < 2 \\ \frac{x-2}{6}, & 2 \leq x \leq 8 \\ 1, & x > 8 \end{cases}$$

$$(b) P(3 \leq X \leq 6) = F(6) - F(3) = \frac{6-2}{6} - \frac{3-2}{6} = \frac{4}{6} - \frac{1}{6} = \frac{1}{2}$$

$$(c) E[X] = \frac{2+8}{2} = 5, \quad \text{Var}(X) = \frac{(8-2)^2}{12} = \frac{36}{12} = 3$$

(d) 由线性变换: $Y = 2X - 1 \sim \mathcal{U}(2 \cdot 2 - 1, 2 \cdot 8 - 1) = \mathcal{U}(3, 15)$

$$E[Y] = 2E[X] - 1 = 9, \quad \text{Var}(Y) = 4 \text{Var}(X) = 12$$

答案 2

激活值 $X \sim \mathcal{N}(0.5, 0.04)$, 即 $\mu = 0.5$, $\sigma = \sqrt{0.04} = 0.2$ 。

(a)

$$P(0.3 \leq X \leq 0.7) = P\left(\frac{0.3-0.5}{0.2} \leq Z \leq \frac{0.7-0.5}{0.2}\right) = P(-1 \leq Z \leq 1) \approx 68.27\%$$

(b) 批归一化将激活值标准化: $\hat{X} = \frac{X - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}}$, 其中 $\mu_B \approx 0.5$, $\sigma_B^2 \approx 0.04$ (若整批数据服从该分布), 故 $\hat{X} \approx \mathcal{N}(0, 1)$ 。

(c)

$$0.9 = 0.5 + 2 \times 0.2 = \mu + 2\sigma$$

由 68-95-99.7 法则: $P(|X - \mu| \leq 2\sigma) \approx 95.45\%$, 故 $P(X > \mu + 2\sigma) \approx (1 - 0.9545)/2 \approx 2.275\%$ 。

(d) 期望超过 0.9 的神经元数 $\approx 1000 \times 2.275\% \approx 22.75 \approx 23$ 个。

答案 3

$X \sim \text{Exp}(2)$, 即速率 $\lambda = 2$, 均值 $= 1/\lambda = 0.5$ 分钟。

(a) $E[X] = 1/2 = 0.5$ 分钟, $\text{Std}(X) = 1/\lambda = 0.5$ 分钟 (指数分布均值 = 标准差)。

(b) $P(X > 1) = e^{-2 \times 1} = e^{-2} \approx 0.1353$ (约 13.5%)。

(c) 由无记忆性直接得: $P(X > 0.5 + 1 \mid X > 0.5) = P(X > 1) = e^{-2} \approx 0.1353$ 。

验证:

$$P(X > 1.5 \mid X > 0.5) = \frac{P(X > 1.5)}{P(X > 0.5)} = \frac{e^{-3}}{e^{-1}} = e^{-2} = P(X > 1) \checkmark$$

(d) (c) 的结果与 (b) 完全相同, 体现了无记忆性:

$$P(X > s + t \mid X > s) = P(X > t), \quad \forall s, t \geq 0$$

数学上等价于: $\bar{F}(s + t) = \bar{F}(s) \cdot \bar{F}(t)$, 其中 $\bar{F}(x) = e^{-\lambda x}$ 。

(e) 设三台服务器等待时间 $X_1, X_2, X_3 \stackrel{\text{iid}}{\sim} \text{Exp}(2)$, 第一个被处理意味着等待 $M = \min(X_1, X_2, X_3)$ 。

$$M \sim \text{Exp}(2 + 2 + 2) = \text{Exp}(6)$$

$$E[M] = \frac{1}{6} \approx 0.167 \text{ 分钟}$$

答案 4

(a) $X \sim \text{Gamma}(3, 2)$:

$$E[X] = \frac{\alpha}{\beta} = \frac{3}{2} = 1.5, \quad \text{Var}(X) = \frac{\alpha}{\beta^2} = \frac{3}{4} = 0.75$$

解释: X 可解释为 3 个独立的 $\text{Exp}(2)$ 随机变量之和, 即等待第 3 个速率为 2 的泊松事件所需的时间。

(b) 当 $\alpha = 1$ 时:

$$f_{\text{Gamma}(1, \beta)}(x) = \frac{\beta^1}{\Gamma(1)} x^{1-1} e^{-\beta x} = \beta e^{-\beta x} = f_{\text{Exp}(\beta)}(x) \checkmark$$

(因为 $\Gamma(1) = 0! = 1$)

(c) $X \sim \text{Beta}(3, 7)$ ($\alpha = 3, \beta = 7, \alpha + \beta = 10$):

$$E[X] = \frac{3}{10} = 0.3, \quad \text{Var}(X) = \frac{3 \times 7}{10^2 \times 11} = \frac{21}{1100} \approx 0.019$$

直觉上，这描述了成功率约为 **30%** 的二项试验的先验信念，等价于先前已观察过 $3 + 7 - 2 = 8$ 次试验（其中 2 次成功的等效先验）。

(d) 观测：60 次中 12 次成功，先验 $\text{Beta}(3, 7)$ 。

后验： $\text{Beta}(3 + 12, 7 + (60 - 12)) = \text{Beta}(15, 55)$

$$E[X_{\text{后验}}] = \frac{15}{70} \approx 0.214$$

先验期望 = 0.3，观测频率 = $12/60 = 0.2$ ，后验期望 0.214 是两者的加权平均，向观测数据方向移动，体现了贝叶斯更新的“先验 + 数据 → 后验”逻辑。

答案 5

(a) $Z_1^2 \sim \chi^2(1) = \text{Gamma}(1/2, 1/2)$ 。由 Gamma 分布的可加性（形状参数相加）：

$$W = Z_1^2 + Z_2^2 \sim \chi^2(2) = \text{Gamma}(1, 1/2) = \text{Exp}(1/2)$$

(这是一个特例： $\chi^2(2)$ 就是均值为 2 的指数分布。)

(b)

$$E[R] = E[\sqrt{W}] = \int_0^\infty \sqrt{w} \cdot \frac{1}{2} e^{-w/2} dw$$

令 $u = w/2$, $w = 2u$, $dw = 2 du$:

$$E[R] = \int_0^\infty \sqrt{2u} \cdot \frac{1}{2} e^{-u} \cdot 2 du = \sqrt{2} \int_0^\infty u^{1/2} e^{-u} du = \sqrt{2} \Gamma\left(\frac{3}{2}\right) = \sqrt{2} \cdot \frac{\sqrt{\pi}}{2} = \sqrt{\frac{\pi}{2}} \checkmark$$

(c) 对 $X \sim \text{Exp}(\lambda)$ ，CDF 为 $F(x) = 1 - e^{-\lambda x}$ ，反函数为 $F^{-1}(u) = -\frac{1}{\lambda} \ln(1 - u)$ 。

逆变换法：若 $U \sim \mathcal{U}(0, 1)$ ，则 $X = F^{-1}(U) = -\frac{1}{\lambda} \ln(1 - U) \sim \text{Exp}(\lambda)$ 。

为何 $-\frac{1}{\lambda} \ln U$ 也正确：若 $U \sim \mathcal{U}(0, 1)$ ，则 $1 - U$ 也服从 $\mathcal{U}(0, 1)$ （对称性），故 $-\frac{1}{\lambda} \ln U \stackrel{d}{=} -\frac{1}{\lambda} \ln(1 - U)$ ，两个公式在分布意义上等价。实践中直接用 $-\frac{1}{\lambda} \ln U$ 更简洁。

(d) 证明 $X/(X+Y) \sim \text{Beta}(\alpha, \beta)$:

令 $U = X/(X+Y)$, $V = X+Y$ 。则 $X = UV$, $Y = (1-U)V$, $0 < U < 1$, $V > 0$ 。

雅可比行列式:

$$\frac{\partial(X, Y)}{\partial(U, V)} = \begin{vmatrix} V & U \\ -V & 1-U \end{vmatrix} = V(1-U) + UV = V$$

(X, Y) 的联合 PDF:

$$f_{X,Y}(x, y) = \frac{\theta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\theta x} \cdot \frac{\theta^\beta}{\Gamma(\beta)} y^{\beta-1} e^{-\theta y}$$

变量替换后:

$$\begin{aligned} f_{U,V}(u, v) &= \frac{\theta^{\alpha+\beta}}{\Gamma(\alpha)\Gamma(\beta)} (uv)^{\alpha-1} ((1-u)v)^{\beta-1} e^{-\theta v} \cdot v \\ &= \frac{\theta^{\alpha+\beta}}{\Gamma(\alpha)\Gamma(\beta)} u^{\alpha-1} (1-u)^{\beta-1} v^{\alpha+\beta-1} e^{-\theta v} \end{aligned}$$

对 v 从 0 到 ∞ 积分 (利用 Gamma 积分 $\int_0^\infty v^{\alpha+\beta-1} e^{-\theta v} dv = \Gamma(\alpha+\beta)/\theta^{\alpha+\beta}$):

$$f_U(u) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} u^{\alpha-1} (1-u)^{\beta-1} = \frac{u^{\alpha-1} (1-u)^{\beta-1}}{B(\alpha, \beta)}$$


这正是 $\text{Beta}(\alpha, \beta)$ 的 PDF。■

几何示意

图示


说明

标准正态 PDF 与 68-95-99.7 法则




标准正态 PDF 与 68-95-99.7 经验法则阴影

正态分布 $N(\mu, \sigma^2)$: 不同参数对比




不同 μ, σ 正态曲线对比: 位置与宽窄

指数分布 PDF: $f(x) = \lambda e^{-\lambda x}$




无记忆性: 生存函数 $P(X > t) = e^{-\lambda t}$



指数分布 PDF ($\lambda = 0.5, 1, 2$) 与无记忆性生存函数


Gamma(α, β) 分布 PDF: $f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$




Gamma(α, β) PDF: 不同形状参数

图示


说明



Beta(α, β) PDF: U 形、钟形、偏斜形




χ_n^2 PDF: 不同自由度 $n = 1, 3, 5, 10$



t_n 分布 vs 标准正态: 自由度影响尾部厚度

图示

说明



连续分布族关系图：正态 $\rightarrow$ 卡方 $\rightarrow t$ 、 F

思考路标（条件反射）

- 1. 正态 $N(\mu, \sigma^2) \rightarrow$ 中心极限定理极限；标准化 $Z = (X - \mu)/\sigma \sim N(0, 1)$ ；68-95-99.7 法则
- 2. 标准化 $\rightarrow$ 任何正态计算先做 $Z = (X - \mu)/\sigma$ ，化为标准正态查表
- 3. 指数 $\mathbf{Exp}(\lambda) \rightarrow$ 唯一连续无记忆分布； $f(x) = \lambda e^{-\lambda x}$ ， $E = 1/\lambda$ ；泊松过程等待时间
- 4. $\mathbf{Gamma}(\alpha, \beta) \rightarrow \alpha$ 个独立 $\mathbf{Exp}(\beta)$ 之和；形状参数 α 控制偏度
- 5. $\mathbf{Beta}(\alpha, \beta) \rightarrow$ 定义在 $[0, 1]$ ；二项分布成功概率 p 的共轭先验
- 6. 卡方 $\chi_n^2 \rightarrow n$ 个独立标准正态平方和； $= \mathbf{Gamma}(n/2, 1/2)$ ；方差检验
- 7. t_n 分布 $\rightarrow$ 小样本均值检验； $t_n = Z/\sqrt{\chi_n^2/n}$ ； n 大时趋近正态
- 8. $F_{m,n}$ 分布 $\rightarrow$ 两独立卡方之比； $F = (\chi_m^2/m)/(\chi_n^2/n)$ ；方差比 / ANOVA

易错点

- 1. 对称性： $\Phi(-x) = 1 - \Phi(x)$ （标准正态 CDF）， $P(Z > 1.96) = P(Z < -1.96)$
- 2. 指数无记忆性： $P(X > s + t | X > s) = P(X > t)$ ——“已等待 s 时间”不影响未来；指数参数是速率 λ 不是均值
- 3. **Gamma 退化**： $\alpha = 1$ 时 $\mathbf{Gamma} \rightarrow \mathbf{Exp}$ ； $\alpha = n/2, \beta = 1/2$ 时 $\mathbf{Gamma} \rightarrow \chi_n^2$
- 4. 卡方自由度： χ_n^2 的自由度 n 是平方和项数，不是样本量减 1（估计均值时才减 1）
- 5. t 分布自由度：一样本 t 检验自由度是 $n - 1$ （因估计均值损失 1）； $n > 30$ 近似标准正态

第9章多维分布

难度：★★★★☆ 前置知识：第5章连续随机变量、第8章多元正态分布初步、线性代数基础（矩阵、行列式、正定矩阵）

学习目标

- 掌握多项分布的定义、性质及与二项分布的关系
- 理解多元正态分布的几何意义与协方差矩阵的作用
- 了解 Dirichlet 分布作为多项分布的共轭先验的重要地位
- 初步认识 Wishart 分布及其在协方差矩阵建模中的作用
- 掌握分布变换与采样方法，建立与深度学习（Softmax、VAE）的联系

9.1 多项分布

从二项分布推广到多项分布

二项分布描述 n 次独立伯努利试验中“成功”次数的分布——每次试验只有两个结果。当每次试验有 k 个可能结果时，自然推广到多项分布（Multinomial Distribution）。

场景：投掷一枚有 k 个面的骰子 n 次，第 i 面出现的概率为 p_i ， $\sum_{i=1}^k p_i = 1$ 。令 X_i 表示第 i 面出现的次数，则随机向量 $(X_1, X_2, \dots, X_k)$ 服从多项分布。

定义

若随机向量 $\mathbf{X} = (X_1, \dots, X_k)$ 满足 $\sum_{i=1}^k X_i = n$ ，且联合概率质量函数为：

$$P(X_1 = x_1, \dots, X_k = x_k) = \frac{n!}{x_1! x_2! \dots x_k!} \prod_{i=1}^k p_i^{x_i}$$

其中 $x_i \geq 0$ 为整数， $\sum_{i=1}^k x_i = n$ ， $p_i > 0$ ， $\sum_{i=1}^k p_i = 1$ ，则称 $\mathbf{X}$ 服从多项分布，记作：

$$\mathbf{X} \sim \text{Multinomial}(n, \mathbf{p}), \quad \mathbf{p} = (p_1, \dots, p_k)$$

直觉理解：多项式系数

分子 $n!$ 是全排列数，分母 $x_1! \cdots x_k!$ 消除了同类元素的重复，因此多项式系数 $\frac{n!}{x_1! \cdots x_k!}$ 表示将 n 次试验分配给 k 个结果的方式数。每种分配方案的概率是 $\prod_i p_i^{x_i}$ ，两者相乘得到联合概率。

均值与协方差

边缘分布：每个 X_i 的边缘分布是二项分布：

$$X_i \sim \text{Binomial}(n, p_i)$$

因此：

$$E[X_i] = np_i, \quad \text{Var}(X_i) = np_i(1 - p_i)$$

协方差：不同类别之间存在负相关（增加一个类别的计数必然减少其他类别）：

$$\text{Cov}(X_i, X_j) = -np_i p_j, \quad i \neq j$$

推导：由于 $\sum_i X_i = n$ 是常数，有 $\text{Var}(\sum_i X_i) = 0$ ，展开得：

$$\sum_i \text{Var}(X_i) + 2 \sum_{i < j} \text{Cov}(X_i, X_j) = 0$$

代入各方差并整理可得上式。

例 9.1：分类投票

某次选举有三位候选人，支持率分别为 $p_1 = 0.5, p_2 = 0.3, p_3 = 0.2$ ，随机调查 10 人，求恰好 5 人选 1 号、3 人选 2 号、2 人选 3 号的概率。

$$P(5, 3, 2) = \frac{10!}{5! 3! 2!} \times 0.5^5 \times 0.3^3 \times 0.2^2 = 252 \times 0.03125 \times 0.027 \times 0.04 \approx 0.0851$$

特殊情形

- $k = 2$ 时，多项分布退化为二项分布
- $n = 1$ 时，多项分布退化为类别分布（Categorical Distribution），是 softmax 输出对应的分布

9.2 多元正态分布

定义

d 维随机向量 $\mathbf{X} = (X_1, \dots, X_d)^\top$ 服从多元正态分布 (Multivariate Normal Distribution), 若其概率密度函数为:

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^\top \Sigma^{-1}(\mathbf{x} - \mu)\right)$$

记作 $\mathbf{X} \sim \mathcal{N}(\mu, \Sigma)$, 其中: - $\mu \in \mathbb{R}^d$: 均值向量 - $\Sigma \in \mathbb{R}^{d \times d}$: 协方差矩阵 (对称正定) - $|\Sigma|$: Σ 的行列式

协方差矩阵的几何含义

协方差矩阵 Σ 完全刻画了各分量之间的线性相关结构:

$$\Sigma_{ij} = \text{Cov}(X_i, X_j) = E[(X_i - \mu_i)(X_j - \mu_j)]$$

几何理解: 指数项中的马氏距离 $(\mathbf{x} - \mu)^\top \Sigma^{-1}(\mathbf{x} - \mu)$ 等于常数的等值面是一个椭球体。 Σ 的特征向量给出椭球的方向, 特征值给出各方向的”伸展程度”。

三种典型情形:

协方差矩阵形式	含义	等值面形状
$\Sigma = \sigma^2 \mathbf{I}$	各维独立且方差相同	球形
$\Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_d^2)$	各维独立但方差不同	轴对齐椭球
一般正定矩阵	各维相关	旋转椭球

重要性质

性质 1 (线性变换封闭性): 若 $\mathbf{X} \sim \mathcal{N}(\mu, \Sigma)$, $\mathbf{A} \in \mathbb{R}^{m \times d}$ 为矩阵, $\mathbf{b} \in \mathbb{R}^m$, 则:

$$\mathbf{A}\mathbf{X} + \mathbf{b} \sim \mathcal{N}(\mathbf{A}\mu + \mathbf{b}, \mathbf{A}\Sigma\mathbf{A}^\top)$$

性质 2 (边缘分布): 多元正态的任意边缘分布仍是正态分布。将 $\mathbf{X}$ 分块为 $(\mathbf{X}_1, \mathbf{X}_2)$:

$$\mathbf{X}_1 \sim \mathcal{N}(\mu_1, \Sigma_{11})$$

性质 3 (条件分布): 给定 $\mathbf{X}_2 = \mathbf{x}_2$ 时, $\mathbf{X}_1$ 的条件分布仍是正态分布:

$$\mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2 \sim \mathcal{N}(\mu_{1|2}, \Sigma_{1|2})$$

其中：

$$\mu_{1|2} = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)$$

$$\Sigma_{1|2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$$

性质 4（独立性与不相关等价）：对于正态分布，不相关等价于独立（这在一般分布中不成立）。

例 9.2：二元正态分布

最常用的特例： $d = 2$ ，令 $\mu = (0, 0)^\top$ ，

$$\Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$$

其中 $\rho \in (-1, 1)$ 是相关系数。PDF 为：

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left(-\frac{1}{2(1-\rho^2)} \left[\frac{x_1^2}{\sigma_1^2} - \frac{2\rho x_1x_2}{\sigma_1\sigma_2} + \frac{x_2^2}{\sigma_2^2}\right]\right)$$

- $\rho > 0$: X_1 与 X_2 正相关，椭球沿 45° 方向倾斜
- $\rho = 0$: 独立，等值面为轴对齐椭圆
- $\rho < 0$: 负相关，椭球沿 -45° 方向倾斜

从标准正态生成多元正态

设 $\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ，对 Σ 做 Cholesky 分解 $\Sigma = \mathbf{L}\mathbf{L}^\top$ ，则：

$$\mathbf{X} = \mu + \mathbf{L}\mathbf{Z} \sim \mathcal{N}(\mu, \Sigma)$$

这是从多元正态分布采样的标准算法。

9.3 Dirichlet 分布

动机：概率向量的分布

在贝叶斯统计中，我们常需要对“概率参数”本身建立先验。例如，骰子每面的概率 $\mathbf{p} = (p_1, \dots, p_k)$ 满足 $p_i \geq 0$ ， $\sum_i p_i = 1$ ，即 $\mathbf{p}$ 位于 $k-1$ 维单纯形（simplex）上。**Dirichlet** 分布正是定义在单纯形上的连续分布。

定义

若 k 维随机向量 $\mathbf{p} = (p_1, \dots, p_k)$ 满足 $p_i > 0$, $\sum_i p_i = 1$, 且概率密度函数为:

$$f(\mathbf{p}; \alpha) = \frac{\Gamma\left(\sum_{i=1}^k \alpha_i\right)}{\prod_{i=1}^k \Gamma(\alpha_i)} \prod_{i=1}^k p_i^{\alpha_i-1}$$

则称 $\mathbf{p}$ 服从参数为 $\alpha = (\alpha_1, \dots, \alpha_k)$ ($\alpha_i > 0$) 的 **Dirichlet** 分布, 记作:

$$\mathbf{p} \sim \text{Dir}(\alpha)$$

归一化常数中的 Gamma 函数 $\Gamma(n) = (n-1)!$ (整数时) 确保 PDF 积分为 1。

参数的直觉

将 α_i 理解为“伪计数”: α_i 越大, p_i 趋近越大; 令 $\alpha_0 = \sum_i \alpha_i$ (称为浓度参数):

- α_0 大: 分布集中在均值附近 (确定性强)
- α_0 小 (接近 0): 分布集中在单纯形顶点 (稀疏性强)
- $\alpha = \mathbf{1}$ (均匀先验): 单纯形上的均匀分布

均值与方差

$$E[p_i] = \frac{\alpha_i}{\alpha_0}, \quad \alpha_0 = \sum_{j=1}^k \alpha_j$$

$$\text{Var}(p_i) = \frac{\alpha_i(\alpha_0 - \alpha_i)}{\alpha_0^2(\alpha_0 + 1)}$$

$$\text{Cov}(p_i, p_j) = \frac{-\alpha_i \alpha_j}{\alpha_0^2(\alpha_0 + 1)}, \quad i \neq j$$

Dirichlet 是多项分布的共轭先验

这是 Dirichlet 分布最重要的性质。设先验 $\mathbf{p} \sim \text{Dir}(\alpha)$, 观测到 n 次试验中第 i 类出现 x_i 次 (即 $\mathbf{x} \sim \text{Multinomial}(n, \mathbf{p})$), 则后验为:

$$\mathbf{p} \mid \mathbf{x} \sim \text{Dir}(\alpha + \mathbf{x})$$

推导:

$$p(\mathbf{p} | \mathbf{x}) \propto p(\mathbf{x} | \mathbf{p}) \cdot p(\mathbf{p}) \propto \prod_i p_i^{x_i} \cdot \prod_i p_i^{\alpha_i - 1} = \prod_i p_i^{(\alpha_i + x_i) - 1}$$

这正是 $\text{Dir}(\alpha + \mathbf{x})$ 的核密度。共轭性意味着先验与后验属于同一分布族，大大简化了贝叶斯推断。

特殊情形

- $k = 2$: Dirichlet 分布退化为 **Beta** 分布 $\text{Beta}(\alpha_1, \alpha_2)$
- 对称情形 $\alpha = \alpha \mathbf{1}$: 称为对称 **Dirichlet** 分布

例 9.3: 文本主题建模

在 LDA (潜在狄利克雷分配) 中, 每篇文档的主题分布 $\theta_d \sim \text{Dir}(\alpha \mathbf{1})$, 每个主题的词分布 $\phi_k \sim \text{Dir}(\beta \mathbf{1})$ 。Dirichlet 先验的稀疏性 ($\alpha < 1$ 时) 促使文档只集中在少数主题上。

9.4 Wishart 分布简介

动机: 协方差矩阵的分布

多元正态分布中, 协方差矩阵 Σ 是未知参数。在贝叶斯框架下, 需要对正定矩阵建立先验。**Wishart** 分布是正定矩阵上的分布, 是 Σ 或 Σ^{-1} (精度矩阵) 的共轭先验。

从卡方分布到 **Wishart** 分布

类比: 若 $Z \sim \mathcal{N}(0, 1)$, 则 $Z^2 \sim \chi^2(1)$; 若 $Z_1, \dots, Z_\nu \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$, 则 $\sum_i Z_i^2 \sim \chi^2(\nu)$ 。

推广到多维: 若 $\mathbf{z}_1, \dots, \mathbf{z}_\nu \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mathbf{0}, \Sigma)$, 令:

$$\mathbf{W} = \sum_{i=1}^{\nu} \mathbf{z}_i \mathbf{z}_i^\top$$

则 $\mathbf{W}$ 服从 **Wishart** 分布, 记作 $\mathbf{W} \sim \mathcal{W}_d(\nu, \Sigma)$, 其中 d 是维度, $\nu \geq d$ 是自由度。

概率密度函数

$$f(\mathbf{W}) = \frac{|\mathbf{W}|^{(\nu-d-1)/2} \exp\left(-\frac{1}{2}\text{tr}(\Sigma^{-1}\mathbf{W})\right)}{2^{\nu d/2} |\Sigma|^{\nu/2} \Gamma_d(\nu/2)}$$

其中 $\Gamma_d(\cdot)$ 是多元 Gamma 函数, $\text{tr}(\cdot)$ 是矩阵的迹。

均值与关键性质

$$E[\mathbf{W}] = \nu \Sigma$$

与卡方分布的关系: $d = 1$ 时, $\mathcal{W}_1(\nu, \sigma^2)$ 对应 $\sigma^2 \chi^2(\nu)$ 。

逆 **Wishart** 分布: 若 $\mathbf{W} \sim \mathcal{W}_d(\nu, \Sigma)$, 则 $\mathbf{W}^{-1} \sim \mathcal{W}_d^{-1}(\nu, \Sigma^{-1})$, 称为逆 **Wishart** 分布, 常用作 Σ 的共轭先验。

贝叶斯多元正态模型

模型设定:

$$\Sigma^{-1} \sim \mathcal{W}_d(\nu_0, \mathbf{V}_0^{-1}), \quad \mathbf{x}_i \mid \mu, \Sigma \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \Sigma)$$

后验 (观测 n 个样本后):

$$\Sigma^{-1} \mid \{\mathbf{x}_i\} \sim \mathcal{W}_d \left(\nu_0 + n, \left(\mathbf{V}_0 + \sum_{i=1}^n (\mathbf{x}_i - \mu)(\mathbf{x}_i - \mu)^\top \right)^{-1} \right)$$

Wishart 分布在高斯过程、贝叶斯线性回归、多元时间序列等模型中均有重要应用。

9.5 分布变换与采样

分布变换的一般理论

设 $\mathbf{X} \sim f_{\mathbf{X}}(\mathbf{x})$, $\mathbf{Y} = g(\mathbf{X})$ 是可逆变换, 令 $\mathbf{x} = g^{-1}(\mathbf{y})$, 则 $\mathbf{Y}$ 的 PDF 为:

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(g^{-1}(\mathbf{y})) \cdot |\det \mathbf{J}_{g^{-1}}(\mathbf{y})|$$

其中 $\mathbf{J}_{g^{-1}}$ 是逆变换的 **Jacobian** 矩阵 (各偏导数组成的矩阵), 行列式的绝对值 $|\det \mathbf{J}|$ 是体积缩放因子。

Jacobian 矩阵的具体形式: 设 $\mathbf{x} = (x_1, \dots, x_n)$, $\mathbf{y} = (y_1, \dots, y_n)$, 则:

$$\mathbf{J}_{g^{-1}} = \begin{pmatrix} \frac{\partial x_1}{\partial y_1} & \dots & \frac{\partial x_1}{\partial y_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial x_n}{\partial y_1} & \dots & \frac{\partial x_n}{\partial y_n} \end{pmatrix}$$

直觉: Jacobian 行列式度量变换在局部的“体积伸缩”比例。概率密度 = 概率质量/体积, 因此变换后需要除以伸缩比例。

例 9.4b: 二维变量变换

设 (X, Y) 的联合 PDF 为 $f_{X,Y}(x, y)$, 令 $U = X + Y$, $V = X - Y$ 。

逆变换: $X = (U + V)/2$, $Y = (U - V)/2$ 。Jacobian 行列式:

$$\left| \det \begin{pmatrix} \partial x / \partial u & \partial x / \partial v \\ \partial y / \partial u & \partial y / \partial v \end{pmatrix} \right| = \left| \det \begin{pmatrix} 1/2 & 1/2 \\ 1/2 & -1/2 \end{pmatrix} \right| = \left| -\frac{1}{2} \right| = \frac{1}{2}$$

$$f_{U,V}(u, v) = f_{X,Y}\left(\frac{u+v}{2}, \frac{u-v}{2}\right) \cdot \frac{1}{2}$$

应用: 若只需要 $U = X + Y$ 的分布, 对 v 积分即得卷积公式:

$$f_U(u) = \int_{-\infty}^{+\infty} f_{X,Y}\left(\frac{u+v}{2}, \frac{u-v}{2}\right) \cdot \frac{1}{2} dv$$

当 X, Y 独立时简化为 $f_U(u) = \int f_X(x)f_Y(u-x)dx$ (即 $f_X * f_Y$)。

常用变换技术

1. Cholesky 变换 (多元正态采样) 目标: 从 $\mathcal{N}(\mu, \Sigma)$ 采样。

步骤: 1. 对 Σ 做 Cholesky 分解: $\Sigma = \mathbf{L}\mathbf{L}^\top$ 2. 生成 $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 3. 返回 $\mathbf{x} = \mu + \mathbf{L}\mathbf{z}$

验证: $\text{Cov}(\mathbf{L}\mathbf{z}) = \mathbf{L}\text{Cov}(\mathbf{z})\mathbf{L}^\top = \mathbf{L}\mathbf{I}\mathbf{L}^\top = \Sigma \square$

2. Box-Muller 变换 (从均匀分布生成正态) 从 $U_1, U_2 \sim \text{Uniform}(0, 1)$ 生成两个独立标准正态:

$$Z_1 = \sqrt{-2 \ln U_1} \cos(2\pi U_2), \quad Z_2 = \sqrt{-2 \ln U_1} \sin(2\pi U_2)$$

Jacobian 推导: 令 $R = \sqrt{-2 \ln U_1}$, $\Theta = 2\pi U_2$, 则 $R^2 \sim \text{Exp}(1/2)$ (即 $\chi^2(2)$), $(R \cos \Theta, R \sin \Theta)$ 服从二维标准正态。

3. Dirichlet 分布的 Gamma 采样 从 $\text{Dir}(\alpha)$ 采样的方法: 1. 独立采样 $Y_i \sim \text{Gamma}(\alpha_i, 1)$, $i = 1, \dots, k$ 2. 归一化: $p_i = Y_i / \sum_j Y_j$

则 $(p_1, \dots, p_k) \sim \text{Dir}(\alpha)$ 。

直觉: Gamma 分布的归一化保持了各分量的相对比例, 且自然落在单纯形上。

4. 重参数化技巧 (Reparameterization Trick) 在变分推断和 VAE 中, 需要对随机变量求梯度。核心思想是将随机性与参数分离:

问题: $\mathbf{z} \sim q_\phi(\mathbf{z})$, 无法直接对 ϕ 求梯度 (采样不可微)。

解决: 引入辅助噪声 $\epsilon \sim p(\epsilon)$ (与 ϕ 无关), 通过可微变换 $\mathbf{z} = g_\phi(\epsilon)$:

$$\nabla_\phi E_{q_\phi}[f(\mathbf{z})] = \nabla_\phi E_{p(\epsilon)}[f(g_\phi(\epsilon))] = E_{p(\epsilon)}[\nabla_\phi f(g_\phi(\epsilon))]$$

对于正态分布: $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, $\mathbf{z} = \mu_\phi + \sigma_\phi \odot \epsilon$ 。

正规化流 (Normalizing Flows) 简介

通过一系列可逆变换将简单分布 (如高斯) 变换为复杂分布。设 $\mathbf{z}_0 \sim p_0(\mathbf{z}_0)$, 经过 T 步变换 $\mathbf{z}_T = f_T \circ \dots \circ f_1(\mathbf{z}_0)$, 则:

$$\ln p_T(\mathbf{z}_T) = \ln p_0(\mathbf{z}_0) - \sum_{t=1}^T \ln \left| \det \frac{\partial f_t}{\partial \mathbf{z}_{t-1}} \right|$$

每步需要计算 Jacobian 行列式, 实际设计中 (如 RealNVP) 通过特殊结构使其高效计算。

本章小结

分布	支撑集	参数	均值	关键性质
Multinomial($n, \mathbf{p}$)	非负整数向量, 和为 n	$n, \mathbf{p}$	$n\mathbf{p}$	二项分布推广, $\text{Cov}(X_i, X_j) = -np_i p_j$
$\mathcal{N}(\mu, \Sigma)$	$\mathbb{R}^d$	μ, Σ	μ	线性变换封闭, 条件/边缘仍正态
Dir(α)	$k-1$ 维单纯形	α	α_i/α_0	多项分布的共轭先验
$\mathcal{W}_d(\nu, \Sigma)$	$d \times d$ 正定矩阵	ν, Σ	$\nu \Sigma$	精度矩阵的共轭先验

核心要点: - 多项分布是分类问题的基础, 与 softmax 输出天然对应 - 多元正态分布由均值向量和协方差矩阵完全刻画, 线性变换封闭性是深度学习中的重要工具 - Dirichlet 分布是概率向量的”元分布”, 共轭性使贝叶斯更新具有解析形式 - 分布变换通过 Jacobian 行列式联系变量, 重参数化技巧是 VAE 等生成模型的理论基础

深度学习应用

应用一：Softmax 与多项分布

神经网络分类任务中，最后一层输出 logits $\mathbf{o} = (o_1, \dots, o_k)$ ，经过 **softmax** 变换得到概率分布：

$$p_i = \frac{e^{o_i}}{\sum_{j=1}^k e^{o_j}}, \quad \sum_i p_i = 1$$

输出向量 $(p_1, \dots, p_k)$ 正好落在 $k-1$ 维单纯形上，与多项分布的参数空间完全一致。

交叉熵损失的概率解释：设真实标签为 $\mathbf{y}$ (one-hot 向量)，分类问题等价于假设：

$$\mathbf{y} \mid \mathbf{x} \sim \text{Multinomial}(1, \mathbf{p}(\mathbf{x}; \theta))$$

最大化对数似然即最小化交叉熵损失：

$$\mathcal{L}_{\text{CE}} = - \sum_{i=1}^k y_i \log p_i = - \log p_{y^*}$$

其中 y^* 是真实类别。

标签平滑 (Label Smoothing)：软化 one-hot 目标，相当于给真实分布加入均匀先验：

$$\tilde{y}_i = (1 - \epsilon)y_i + \frac{\epsilon}{k}$$

这等价于在 Dirichlet 分布视角下引入均匀先验 $\text{Dir}(\epsilon \mathbf{1}/k)$ ，改善过拟合。

应用二：VAE 潜在空间与多元正态分布

变分自编码器 (Variational Autoencoder, VAE) 将多元正态分布作为潜在空间的先验，是重参数化技巧的经典应用。

VAE 模型结构

$$p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (\text{潜在空间先验})$$

$$p_{\theta}(\mathbf{x} \mid \mathbf{z}) \quad (\text{解码器, 生成分布})$$

$$q_{\phi}(\mathbf{z} \mid \mathbf{x}) = \mathcal{N}(\mu_{\phi}(\mathbf{x}), \text{diag}(\sigma_{\phi}^2(\mathbf{x}))) \quad (\text{编码器, 近似后验})$$

ELBO 目标函数 由于真实后验 $p(\mathbf{z} | \mathbf{x})$ 不可解析计算，VAE 最大化证据下界 (ELBO)：

$$\mathcal{L}_{\text{ELBO}} = E_{q_{\phi}(\mathbf{z}|\mathbf{x})}[\log p_{\theta}(\mathbf{x} | \mathbf{z})] - D_{\text{KL}}(q_{\phi}(\mathbf{z} | \mathbf{x}) \parallel p(\mathbf{z}))$$

- 重构项：解码器能从潜在编码重建输入
- KL 散度项：近似后验向标准正态靠近，正则化潜在空间

KL 散度的解析解 当两个分布均为正态时，KL 散度有解析表达式。设 $q = \mathcal{N}(\mu, \text{diag}(\sigma^2))$, $p = \mathcal{N}(\mathbf{0}, \mathbf{I})$ ，则：

$$D_{\text{KL}}(q \parallel p) = \frac{1}{2} \sum_{j=1}^d (\mu_j^2 + \sigma_j^2 - \ln \sigma_j^2 - 1)$$

PyTorch 完整实现

```
import torch
import torch.nn as nn
import torch.nn.functional as F
from torch.distributions import MultivariateNormal, Dirichlet
import numpy as np

# =====
# 第一部分: Softmax 与多项分布
# =====

print("=" * 55)
print(" 第一部分: Softmax 与多项分布")
print("=" * 55)

torch.manual_seed(42)

# 模拟分类器 logits
logits = torch.tensor([2.0, 1.0, 0.5, -0.5]) # 4 类
probs = F.softmax(logits, dim=0)
print(f"Logits: {logits.numpy()}")
print(f"Softmax: {probs.numpy().round(4)}")
print(f" 概率和: {probs.sum().item():.6f}")

# 从 Multinomial 采样 (模拟 100 次试验)
dist = torch.distributions.Multinomial(total_count=100, probs=probs)
sample = dist.sample()
print(f"\n100 次多项采样: {sample.int().numpy()}")
print(f" 经验频率: {(sample / 100).numpy().round(3)}")
```

```

# 交叉熵损失的概率解释
y_true = torch.tensor([1, 0, 0, 0]) # 类别 0 的 one-hot 编码
log_probs = F.log_softmax(logits, dim=0)
ce_loss = F.cross_entropy(logits.unsqueeze(0), torch.tensor([0]))
manual_nll = -log_probs[0]
print(f"\n交叉熵损失 (PyTorch) : {ce_loss.item():.6f}")
print(f" 手动计算 -log(p_0):    {manual_nll.item():.6f}")

# 标签平滑
epsilon = 0.1
k = 4
smoothed_labels = (1 - epsilon) * F.one_hot(
    torch.tensor(0), k).float() + epsilon / k
print(f"\n标签平滑 (={epsilon}):")
print(f" 原始 one-hot:    {F.one_hot(torch.tensor(0), k).numpy()}")
print(f" 平滑后目标:      {smoothed_labels.numpy().round(3)}")

# =====
# 第二部分: Dirichlet 分布采样与可视化
# =====
print("\n" + "=" * 55)
print(" 第二部分: Dirichlet 分布")
print("=" * 55)

# 不同浓度参数的 Dirichlet 分布
configs = [
    ([0.1, 0.1, 0.1], " 稀疏 (=0.1): 集中在顶点"),
    ([1.0, 1.0, 1.0], " 均匀 (=1.0): 单纯形均匀分布"),
    ([5.0, 5.0, 5.0], " 集中 (=5.0): 集中在中心"),
    ([2.0, 5.0, 1.0], " 非对称 (=[2,5,1]): 偏向类别 2"),
]

for alpha, desc in configs:
    alpha_tensor = torch.tensor(alpha)
    dist = Dirichlet(alpha_tensor)
    samples = dist.sample((5000,))
    mean = samples.mean(0)
    theoretical_mean = alpha_tensor / alpha_tensor.sum()
    print(f"\n{desc}")

```

```

print(f" 理论均值:  {theoretical_mean.numpy().round(3)}")
print(f" 经验均值:  {mean.numpy().round(3)}")

# 贝叶斯多项参数估计: Dirichlet-Multinomial 共轭更新
print("\n--- Dirichlet-Multinomial 共轭更新 ---")
# 先验: 均匀 Dirichlet (伪计数各为 1)
alpha_prior = torch.tensor([1.0, 1.0, 1.0])
# 观测计数: 在 3 类中观测到 [10, 3, 7] 次
observed_counts = torch.tensor([10.0, 3.0, 7.0])
# 后验: 直接加上观测计数
alpha_posterior = alpha_prior + observed_counts
posterior_mean = alpha_posterior / alpha_posterior.sum()
print(f" 先验 :      {alpha_prior.numpy()}")
print(f" 观测计数:      {observed_counts.int().numpy()}")
print(f" 后验 :      {alpha_posterior.numpy()}")
print(f" 后验均值 (MAP): {posterior_mean.numpy().round(4)}")
print(f"MLE 估计:      {(observed_counts / observed_counts.sum()).numpy().round(4)}")

# =====
# 第三部分: VAE 实现 (多元正态潜在空间 + 重参数化)
# =====

print("\n" + "=" * 55)
print(" 第三部分: VAE 与多元正态潜在空间")
print("=" * 55)

class Encoder(nn.Module):
    """ 编码器: 将输入映射为潜在空间的均值和对数方差 """
    def __init__(self, input_dim, hidden_dim, latent_dim):
        super().__init__()
        self.fc1 = nn.Linear(input_dim, hidden_dim)
        self.fc_mu = nn.Linear(hidden_dim, latent_dim)
        self.fc_logvar = nn.Linear(hidden_dim, latent_dim)

    def forward(self, x):
        h = F.relu(self.fc1(x))
        mu = self.fc_mu(h)
        log_var = self.fc_logvar(h)
        return mu, log_var

```

```

class Decoder(nn.Module):
    """ 解码器：将潜在向量重建为输入 """
    def __init__(self, latent_dim, hidden_dim, output_dim):
        super().__init__()
        self.fc1 = nn.Linear(latent_dim, hidden_dim)
        self.fc2 = nn.Linear(hidden_dim, output_dim)

    def forward(self, z):
        h = F.relu(self.fc1(z))
        return torch.sigmoid(self.fc2(h))

class VAE(nn.Module):
    def __init__(self, input_dim=784, hidden_dim=256, latent_dim=16):
        super().__init__()
        self.encoder = Encoder(input_dim, hidden_dim, latent_dim)
        self.decoder = Decoder(latent_dim, hidden_dim, input_dim)
        self.latent_dim = latent_dim

    def reparameterize(self, mu, log_var):
        """
        重参数化技巧:  $z = \mu + \epsilon$ ,  $\epsilon \sim N(0, I)$ 
        将随机性转移到与参数无关的  $\epsilon$ , 使梯度可以流过  $\mu$  和  $\log\_var$ 
        """
        std = torch.exp(0.5 * log_var)      #  $\sigma = \exp(\log\_var / 2)$ 
        eps = torch.randn_like(std)         #  $\epsilon \sim N(0, I)$ 
        return mu + std * eps               # 可微的  $z$ 

    def forward(self, x):
        mu, log_var = self.encoder(x)
        z = self.reparameterize(mu, log_var)
        x_recon = self.decoder(z)
        return x_recon, mu, log_var

    def elbo_loss(self, x, x_recon, mu, log_var):
        """
         $ELBO = E[\log p(x|z)] - KL(q(z|x) || p(z))$ 
        重构项使用二元交叉熵,  $KL$  项有解析解
        """
        # 重构损失 (对应  $p(x|z)$  为伯努利分布)

```



```

recon_loss = F.binary_cross_entropy(x_recon, x, reduction='sum')

# KL 散度:  $KL(N(\mu, \sigma^2 I) \parallel N(0, I))$  的解析解
# =  $0.5 * \sum(\sigma^2 + \mu^2 - \log(\sigma^2) - 1)$ 
kl_loss = -0.5 * torch.sum(1 + log_var - mu.pow(2) - log_var.exp())

return recon_loss + kl_loss, recon_loss, kl_loss

def sample(self, num_samples):
    """ 从先验  $N(0, I)$  采样并解码 """
    z = torch.randn(num_samples, self.latent_dim)
    return self.decoder(z)

# 训练 VAE (使用随机生成的数据模拟 MNIST)
input_dim, hidden_dim, latent_dim = 784, 256, 16
batch_size, num_epochs = 64, 30

vae = VAE(input_dim, hidden_dim, latent_dim)
optimizer = torch.optim.Adam(vae.parameters(), lr=1e-3)

# 模拟数据 (真实场景中替换为 MNIST 数据集)
torch.manual_seed(0)
fake_data = torch.rand(512, input_dim)
dataset = torch.utils.data.TensorDataset(fake_data)
loader = torch.utils.data.DataLoader(dataset, batch_size=batch_size, shuffle=True)

print(f"VAE 结构: 输入{input_dim}→ 隐层{hidden_dim}→ 潜在{latent_dim}维")
print(f"参数量: {sum(p.numel() for p in vae.parameters()):,}")

losses = []
for epoch in range(num_epochs):
    epoch_loss = 0.0
    for (batch,) in loader:
        optimizer.zero_grad()
        x_recon, mu, log_var = vae(batch)
        loss, recon_loss, kl_loss = vae.elbo_loss(batch, x_recon, mu, log_var)
        loss.backward()
        optimizer.step()
        epoch_loss += loss.item()
    losses.append(epoch_loss / len(loader))

```

```

print(f"\n训练完成 ({num_epochs} 轮) ")
print(f" 初始 ELBO 损失: {losses[0]:.2f}")
print(f" 最终 ELBO 损失: {losses[-1]:.2f}")

# 验证潜在空间的正态性
vae.eval()
with torch.no_grad():
    mu_all, logvar_all = [], []
    for (batch,) in loader:
        mu, log_var = vae.encoder(batch)
        mu_all.append(mu)
        logvar_all.append(log_var)
    mu_all = torch.cat(mu_all)
    std_all = torch.exp(0.5 * torch.cat(logvar_all))

print(f"\n潜在空间统计 (编码均值 ): ")
print(f"   的均值:      {mu_all.mean().item():.4f}   (期望接近 0) ")
print(f"   的标准差:    {mu_all.std().item():.4f}")
print(f"   的均值:      {std_all.mean().item():.4f}   (期望接近 1) ")
print(f"   的标准差:    {std_all.std().item():.4f}")

# 重参数化的梯度流验证
print("\n--- 重参数化技巧: 梯度流验证 ---")
mu_test = torch.tensor([[0.5, -0.3]], requires_grad=True)
log_var_test = torch.tensor([[0.2, -0.1]], requires_grad=True)
eps = torch.randn_like(mu_test)

# 重参数化:  $z = \mu + \sigma \cdot \epsilon$  (可微)
z_reparam = mu_test + torch.exp(0.5 * log_var_test) * eps
loss_test = z_reparam.sum()
loss_test.backward()
print(f" 的梯度:      {mu_test.grad.numpy()}   (应为全 1, 梯度可流通) ")
print(f"log_var 的梯度:{log_var_test.grad.numpy().round(4)}")

# 多元正态分布的协方差矩阵可视化
print("\n--- 多元正态采样验证 ---")
mu_mv = torch.zeros(2)
# 构造相关系数 =0.8 的协方差矩阵
rho = 0.8
Sigma = torch.tensor([[1.0, rho], [rho, 1.0]])

```

```

L = torch.linalg.cholesky(Sigma)           # Cholesky 分解
z_std = torch.randn(10000, 2)
samples_mv = (L @ z_std.T).T + mu_mv       # Cholesky 变换

empirical_cov = torch.cov(samples_mv.T)
print(f" 目标协方差矩阵:\n [[1.0, {rho}], [{rho}, 1.0]]")
print(f" 经验协方差矩阵:\n {empirical_cov.numpy().round(3)}")

```

预期输出:

```

=====
第一部分: Softmax 与多项分布
=====

```

```

Logits:  [ 2.   1.   0.5 -0.5]
Softmax: [0.5266 0.1936 0.1172 0.1626]   (近似值, 各版本可能略有差异)
概率和:  1.000000

```

```

100次多项采样: [53  19  11  17]
经验频率:      [0.53  0.19  0.11  0.17]

```

```

交叉熵损失 (PyTorch) : 0.641187
手动计算 -log(p_0):   0.641187

```

标签平滑 (=0.1):

```

原始 one-hot:  [1 0 0 0]
平滑后目标:    [0.925 0.025 0.025 0.025]

```

```

=====
第二部分: Dirichlet 分布
=====

```

稀疏 (=0.1) : 集中在顶点

```

理论均值:  [0.333 0.333 0.333]
经验均值:  [0.333 0.333 0.333]

```

...

```

后验均值 (MAP): [0.55  0.2   0.4 ]   (贝叶斯估计, 平滑了 MLE)
MLE 估计:      [0.5   0.15  0.35]   (纯频率, 无平滑)

```

```

=====
第三部分: VAE 与多元正态潜在空间
=====

```

```

VAE 结构: 输入784→隐层256→潜在16维
参数量: 467,472

```

训练完成 (30 轮)

初始 ELBO 损失: ...

最终 ELBO 损失: ... (应小于初始值)

潜在空间统计 (编码均值) :

的均值: 0 (KL 约束使均值接近0)

的均值: 1 (KL 约束使方差接近1)

的梯度: [[1. 1.]] (梯度可流通)

目标协方差矩阵:

[[1.0, 0.8], [0.8, 1.0]]

经验协方差矩阵:

[[1.000 0.800], [0.800 1.000]] (大样本下接近理论值)

关键联系总结

概率论概念	深度学习对应
多项分布	分类任务中 softmax 输出的分布族
交叉熵损失	多项分布的负对数似然
Dirichlet 先验	标签平滑、LDA 主题模型
多元正态分布	VAE 潜在空间的先验与近似后验
重参数化技巧	VAE/扩散模型中的可微采样
Cholesky 分解	从多元正态高效采样
KL 散度	VAE 正则化项 (有解析解)

练习题

练习 9.1 (多项分布)

某语言模型对下一个词的预测概率为 $\mathbf{p} = (0.4, 0.3, 0.2, 0.1)$ (对应词汇 A、B、C、D)。在 5 次独立采样中:

- (a) 求恰好采样到 2 次 A、2 次 B、1 次 C、0 次 D 的概率
- (b) 求采样到 A 的次数 X_1 的期望和方差
- (c) 求 $\text{Cov}(X_1, X_2)$, 并说明负协方差的直觉含义

练习 9.2 (多元正态分布)

设 $\mathbf{X} \sim \mathcal{N}(\mu, \Sigma)$, 其中:

$$\mu = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix}$$

- (a) 验证 Σ 是否正定
- (b) 求 X_1 和 X_2 的边缘分布
- (c) 给定 $X_2 = 3$, 求 X_1 的条件分布 $X_1 | X_2 = 3$
- (d) 求相关系数 $\rho(X_1, X_2)$

练习 9.3 (Dirichlet 分布)

考虑三类文档分类任务, 先验为 $\text{Dir}(2, 2, 2)$, 观测了 100 篇文档: 类别 1 有 50 篇, 类别 2 有 30 篇, 类别 3 有 20 篇。

- (a) 写出后验分布
- (b) 计算后验均值, 并与 MLE 估计比较
- (c) 若先验改为 $\text{Dir}(0.1, 0.1, 0.1)$ (稀疏先验), 后验均值如何变化? 说明稀疏先验的效果

练习 9.4 (分布变换)

设 $\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_2)$, 对 $\Sigma = \begin{pmatrix} 4 & 2 \\ 2 & 2 \end{pmatrix}$ 做 Cholesky 分解 $\Sigma = \mathbf{L}\mathbf{L}^\top$, 令 $\mathbf{X} = \mu + \mathbf{L}\mathbf{Z}$, 其中 $\mu = (1, 0)^\top$ 。

- (a) 计算 Cholesky 因子 $\mathbf{L}$ (下三角矩阵)
- (b) 证明 $\mathbf{X} \sim \mathcal{N}(\mu, \Sigma)$
- (c) 用重参数化技巧写出从 $\mathcal{N}(\mu, \Sigma)$ 采样的 PyTorch 代码 (两行以内)

练习 9.5 (VAE 与 KL 散度)

VAE 的 KL 散度项为 $D_{\text{KL}}(q_\phi \| p) = \frac{1}{2} \sum_j (\mu_j^2 + \sigma_j^2 - \ln \sigma_j^2 - 1)$, 其中 $q_\phi = \mathcal{N}(\mu, \text{diag}(\sigma^2))$, $p = \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。

- (a) 从 KL 散度的积分定义 $D_{\text{KL}}(q \| p) = \int q(\mathbf{z}) \ln \frac{q(\mathbf{z})}{p(\mathbf{z})} d\mathbf{z}$ 出发, 推导上述解析公式 (一维情形即可)
- (b) 当 $\mu = \mathbf{0}$, $\sigma = \mathbf{1}$ 时, KL 散度等于多少? 这说明什么?
- (c) 训练中若 KL 权重过大 (称为“KL 坍塌”), 编码器会退化为什么行为? 如何从概率论角度理解?

练习答案

点击展开练习 9.1 答案

(a) 多项概率计算:

$$\begin{aligned}
 P(2, 2, 1, 0) &= \frac{5!}{2!2!1!0!} \times 0.4^2 \times 0.3^2 \times 0.2^1 \times 0.1^0 \\
 &= \frac{120}{2 \times 2 \times 1 \times 1} \times 0.16 \times 0.09 \times 0.2 \times 1 = 30 \times 0.002880 \approx 0.0864
 \end{aligned}$$

(b) $X_1 \sim \text{Binomial}(5, 0.4)$:

$$E[X_1] = 5 \times 0.4 = 2, \quad \text{Var}(X_1) = 5 \times 0.4 \times 0.6 = 1.2$$

(c) 协方差:

$$\text{Cov}(X_1, X_2) = -np_1p_2 = -5 \times 0.4 \times 0.3 = -0.6$$

直觉含义: 每次试验选择 A 就不能选择 B, 二者竞争有限的 n 次机会。一个数量增多必然挤占另一个的份额, 故协方差为负。

点击展开练习 9.2 答案

(a) 正定性验证:

特征值 λ_1, λ_2 满足 $\det(\Sigma - \lambda \mathbf{I}) = 0$:

$$(4 - \lambda)(1 - \lambda) - 4 = \lambda^2 - 5\lambda = \lambda(\lambda - 5) = 0$$

$\lambda_1 = 0, \lambda_2 = 5$ 。由于 $\lambda_1 = 0$, Σ 半正定而非正定, 行列式 $|\Sigma| = 4 \times 1 - 2 \times 2 = 0$, X_1 与 X_2 完全线性相关 ($X_2 = X_1/2$), 此协方差矩阵对应退化的多元正态分布。

(b) 边缘分布:

$$X_1 \sim \mathcal{N}(1, 4), \quad X_2 \sim \mathcal{N}(2, 1)$$

(c) 条件分布 (使用公式):

$$\mu_{1|2} = 1 + \frac{2}{1}(3 - 2) = 3$$

$$\sigma_{1|2}^2 = 4 - \frac{2 \times 2}{1} = 0$$

$$X_1 | X_2 = 3 \sim \mathcal{N}(3, 0) \equiv 3 \quad (\text{退化, 即 } X_1 = 2X_2 - 1)$$

(d) 相关系数:

$$\rho = \frac{\text{Cov}(X_1, X_2)}{\sqrt{\text{Var}(X_1)\text{Var}(X_2)}} = \frac{2}{\sqrt{4 \times 1}} = 1$$

完全正相关，验证了退化情形。

点击展开练习 9.3 答案

(a) 后验分布：

先验 $\alpha = (2, 2, 2)$ ，观测计数 $\mathbf{x} = (50, 30, 20)$ ，由共轭性：

$$\mathbf{p} \mid \mathbf{x} \sim \text{Dir}(52, 32, 22)$$

(b) 后验均值与 MLE 比较：

$$\text{后验均值} = \frac{(52, 32, 22)}{52 + 32 + 22} = \frac{(52, 32, 22)}{106} \approx (0.491, 0.302, 0.208)$$

$$\text{MLE} = \frac{(50, 30, 20)}{100} = (0.500, 0.300, 0.200)$$

贝叶斯估计向先验均值 $(1/3, 1/3, 1/3)$ 轻微收缩，差异随样本量增大而趋近于 0。

(c) 稀疏先验 $\text{Dir}(0.1, 0.1, 0.1)$ 的后验：

$$\mathbf{p} \mid \mathbf{x} \sim \text{Dir}(50.1, 30.1, 20.1)$$

$$\text{后验均值} \approx \frac{(50.1, 30.1, 20.1)}{100.3} \approx (0.4995, 0.3001, 0.2004)$$

几乎等于 MLE。稀疏先验效果： $\alpha_i \rightarrow 0$ 时先验接近于“不提供信息”，后验几乎由数据决定；同时稀疏先验鼓励 p_i 向 0 或 1 的极端值集中，在主题模型中产生稀疏的主题-词分布。

点击展开练习 9.4 答案

(a) Cholesky 分解 $\Sigma = \mathbf{L}\mathbf{L}^\top$ ， $\mathbf{L}$ 为下三角矩阵：

$$\mathbf{L} = \begin{pmatrix} l_{11} & 0 \\ l_{21} & l_{22} \end{pmatrix}$$

由 $\mathbf{L}\mathbf{L}^\top = \Sigma$ ：

- $l_{11}^2 = 4 \Rightarrow l_{11} = 2$
- $l_{21} \cdot l_{11} = 2 \Rightarrow l_{21} = 1$
- $l_{21}^2 + l_{22}^2 = 2 \Rightarrow l_{22} = 1$

$$\mathbf{L} = \begin{pmatrix} 2 & 0 \\ 1 & 1 \end{pmatrix}$$

验证: $\mathbf{L}\mathbf{L}^\top = \begin{pmatrix} 2 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 4 & 2 \\ 2 & 2 \end{pmatrix} = \Sigma \square$

(b) 证明:

$$E[\mathbf{X}] = \mu + \mathbf{L} \underbrace{E[\mathbf{Z}]}_{=\mathbf{0}} = \mu$$

$$\text{Cov}(\mathbf{X}) = \mathbf{L} \text{Cov}(\mathbf{Z}) \mathbf{L}^\top = \mathbf{L} \mathbf{L}^\top = \mathbf{L} \mathbf{L}^\top = \Sigma$$

又因为 $\mathbf{Z}$ 是正态的, 其线性变换 $\mathbf{X} = \mu + \mathbf{L}\mathbf{Z}$ 也是正态的, 故 $\mathbf{X} \sim \mathcal{N}(\mu, \Sigma)$ 。

(c) PyTorch 代码 (重参数化):

```
L = torch.linalg.cholesky(Sigma)
x = mu + L @ torch.randn(2)
```

点击展开练习 9.5 答案

(a) 一维推导 ($q = \mathcal{N}(\mu, \sigma^2)$, $p = \mathcal{N}(0, 1)$):

$$\begin{aligned} D_{\text{KL}}(q\|p) &= \int q(z) [\ln q(z) - \ln p(z)] dz \\ &= \int q(z) \left[-\frac{(z-\mu)^2}{2\sigma^2} - \frac{1}{2} \ln(2\pi\sigma^2) + \frac{z^2}{2} + \frac{1}{2} \ln(2\pi) \right] dz \\ &= E_q \left[\frac{z^2}{2} - \frac{(z-\mu)^2}{2\sigma^2} \right] - \frac{1}{2} \ln \sigma^2 \end{aligned}$$

计算 $E_q[z^2] = \mu^2 + \sigma^2$, $E_q[(z-\mu)^2] = \sigma^2$:

$$= \frac{\mu^2 + \sigma^2}{2} - \frac{\sigma^2}{2\sigma^2} - \frac{1}{2} \ln \sigma^2 = \frac{1}{2}(\mu^2 + \sigma^2 - 1 - \ln \sigma^2)$$

将各维度求和得多维公式: $D_{\text{KL}} = \frac{1}{2} \sum_j (\mu_j^2 + \sigma_j^2 - \ln \sigma_j^2 - 1)$ 。

(b) 当 $\mu = \mathbf{0}$, $\sigma = \mathbf{1}$ 时:

$$D_{\text{KL}} = \frac{1}{2} \sum_j (0 + 1 - 0 - 1) = 0$$

KL 散度为零意味着 $q_\phi(\mathbf{z} \mid \mathbf{x}) = p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ ，即近似后验恰好等于先验，编码器未从输入中提取任何信息。

(c) KL 坍塌分析：


若 KL 权重过大，优化器发现令编码器输出 $\mu \rightarrow \mathbf{0}$, $\sigma \rightarrow \mathbf{1}$ 可以快速降低 KL 项。此时编码器退化为恒输出标准正态， $\mathbf{z}$ 与输入 $\mathbf{x}$ 无关，解码器退化为无条件生成模型（忽略潜在编码）。

概率论角度：KL 坍塌等价于后验完全被先验主导，数据未能更新潜在变量的后验。解决方案包括： β -VAE（动态调整 KL 权重）、Free Bits 方法（为每维 KL 设置下界），本质上是在先验正则化与数据编码能力之间寻求平衡。


几何示意

图示

说明




二元标准正态 PDF 曲面 ($\rho = 0$, 独立)



二元正态等高线：不同协方差结构 ($\rho = 0, 0.7, -0.8$)

图示

说明



PCA: 数据散点、协方差椭圆与主成分方向

思考路标（条件反射）

1. 联合分布 $\rightarrow$ 联合 PDF $f(\mathbf{x})$; 边缘 $f_i(x_i) = \int \cdots \int f(\mathbf{x}) d\mathbf{x}_{-i}$; 条件 $f(\mathbf{x}_1|\mathbf{x}_2) = f(\mathbf{x})/f_2(\mathbf{x}_2)$
2. 多元正态 $\mathcal{N}(\mu, \Sigma) \rightarrow$ 由均值向量和协方差矩阵完全确定; 等值面为椭球
3. 协方差矩阵 $\Sigma \rightarrow$ 必须对称半正定 ($\mathbf{v}^\top \Sigma \mathbf{v} \geq 0$); 特征值 ≥ 0
4. 多元正态的边缘 $\rightarrow$ 任意子集仍服从多元正态 (维度降低)
5. 多元正态的条件 $\rightarrow \mathbf{X}_1|\mathbf{X}_2 = \mathbf{x}_2 \sim \mathcal{N}(\mu_{1|2}, \Sigma_{1|2})$ (仍是正态)
6. 仿射变换封闭 $\rightarrow \mathbf{A}\mathbf{X} + \mathbf{b} \sim \mathcal{N}(\mathbf{A}\mu + \mathbf{b}, \mathbf{A}\Sigma\mathbf{A}^\top)$
7. 正态独立 iff $\rho = 0 \rightarrow$ 多元正态中不相关等价于独立 (一般分布中此结论不成立)
8. PCA 与协方差 $\rightarrow$ PCA 是协方差矩阵 Σ 的特征分解; PC1 方向 = 最大特征值的特征向量

易错点

1. 协方差矩阵必须对称半正定 $\rightarrow$ 若构造的 Σ 有负特征值, 不是合法分布参数
2. 多元正态由 (μ, Σ) 完全确定 $\rightarrow$ 给定均值向量和协方差矩阵后, 分布唯一确定
3. 边缘正态 $\neq$ 联合正态 $\rightarrow$ 反例: X, Y 各自边缘正态, 但联合分布可能不是多元正态
4. 不相关 $\neq$ 独立 $\rightarrow$ 一般分布中 $\text{Cov} = 0$ 不代表独立; 仅对多元正态, 不相关 $\Leftrightarrow$ 独立
5. PCA 是协方差矩阵的特征分解 $\rightarrow$ 不是相关矩阵的特征分解 (除非数据已标准化); 特征值是各主成分方向的方差

第四部分导论：什么是收敛与极限定理？

难度：★★☆☆☆ 前置知识：第 4–6 章随机变量与分布、第 7–9 章常见分布 定位：这是第三部分（分布）到第四部分（极限定理）之间的概念桥梁。第 10–12 章会讲大数定律、中心极限定理、各种收敛性，但在动手之前要先回答一个被很多教材跳过的问题——当我们说“随机变量序列 X_n 收敛”时，到底在说什么？为什么一个数列的极限不够用，需要好几种不同的“收敛模式”？

学习目标

- 理解第四部分研究的对象：不是单个随机变量，而是随机变量序列 $X_1, X_2, \dots$ (如样本均值 $\bar{X}_n$) 在 $n \rightarrow \infty$ 时的极限行为
 - 说清“随机序列收敛”为什么不能照搬普通数列极限——随机量“靠近”有多种合理含义
 - 直观掌握四种收敛模式（几乎必然 / 依概率 / 依分布 / 均方）及其强弱层次
 - 看懂两类极限定理在回答不同问题：大数定律管“中心在哪”、中心极限定理管“围绕中心怎么涨落”
 - 学会“读”一个极限定理：随机量序列 + 收敛模式 + 极限对象
-

0.1 为什么需要“极限定理”这一部分

前三部分我们盯着有限的对象：一个随机变量、它的分布、几个随机变量的联合分布。但现实里最有用的问题往往是“当试验次数或样本量 n 越来越大时会怎样”：

- 抛硬币，正面频率为什么会稳定到 0.5？
- 用样本均值 $\bar{X}_n$ 估计真实均值 μ ，为什么 n 越大估计越准？
- 大量独立的小随机因素叠加起来，为什么总会冒出一条钟形曲线（正态分布）？

这些问题的共同点是：研究的不再是某个固定的随机变量，而是一整列随机变量 $X_1, X_2, X_3, \dots$ (例如 $\bar{X}_1, \bar{X}_2, \dots$)，并追问“当 $n \rightarrow \infty$ 时它趋向什么”。这正是第四部分的主题——随机序列的极限。

引子：你说“样本均值 $\bar{X}_n$ 收敛到 μ ”。但 $\bar{X}_n$ 是个随机变量——每跑一次实验它都给出不同的值，谈何“收敛到一个数”？普通数列 $a_n \rightarrow a$ 的定义（任给 ε ，存在 N ， $n > N$ 时 $|a_n - a| < \varepsilon$ ）在这里直接套用会出问题： $|\bar{X}_n - \mu|$ 本身是随机的，它“小于 ε ”这件事只能以某个概率发生。

那“随机序列收敛”到底该怎么定义？

答案是：有好几种都合理、但强弱不同的定义。理解它们的区别，是读懂大数定律与中心极限定理的前提。

0.2 随机序列的收敛，为什么不能照搬数列极限

普通数列 a_n 的每一项是一个确定的数，“靠近 a ”只有一种含义。但随机序列 X_n 的每一项是一个随机变量（一个函数 $X_n: \Omega \rightarrow \mathbb{R}$ ）。“ X_n 靠近 X ”就有了多个互不等价的合理解释，取决于你关心的是哪一面：

1. 逐条样本路径：固定一个试验结果 ω ，得到一条普通实数列 $X_1(\omega), X_2(\omega), \dots$ ；要求“几乎每一条这样的路径都像普通数列那样收敛”。这是最严格的 $\rightarrow$ 几乎必然收敛 (a.s.)。
2. 犯大错的概率：不追究每条路径，只要求“ X_n 偏离 X 超过 ε ”这个坏事件的概率随 n 趋于零”。偶尔出大错没关系，只要越来越罕见 $\rightarrow$ 依概率收敛 (P) **。
3. 平均的平方误差：要求 $E[(X_n - X)^2] \rightarrow 0$ ，即“平方偏差的期望”趋零 $\rightarrow$ 均方收敛 / L^p 收敛。
4. 只看分布形状：根本不要求 X_n 和 X “靠在一起”，甚至不必定义在同一个概率空间上；只要求 X_n 的分布趋于 X 的分布（分布函数 $F_n(x) \rightarrow F(x)$ ） $\rightarrow$ 依分布收敛 (d)。

关键体会：这四种“收敛”问的是不同的问题——是“每条路径都收敛”，还是“出错概率趋零”，还是“平均误差趋零”，还是“仅仅分布趋同”？正因为随机量比确定数多了“概率”这一维，“靠近”才会分裂成这几种模式。本导论只讲直觉，严格定义与等价刻画见第 12 章。

0.3 四种收敛模式与强弱层次

这四种模式不是平行的，而是有明确的强弱蕴含关系：强的成立必然推出弱的，反之一般不成立。

随机收敛的四种模式与强弱层次 ($\Rightarrow$ 表示「蕴含」，反向一般不成立)




图 19: 随机收敛的四种模式与强弱层次：a.s. 与 L^p 均蕴含依概率，依概率蕴含依分布

几乎必然 (a.s.) $\Rightarrow$ 依概率 (P) $\Rightarrow$ 依分布 (d), 均方 (L^2) $\Rightarrow$ 依概率 (P).

模式	一句话直觉	强弱
几乎必然 a.s.	除一个零概率例外集外，每条样本 路径都像普通数列一样收敛	最强
均方 / L^p	平方偏差的期望 $E[(X_n - X)^2] \rightarrow 0$ （关心“平均能 量”）	强（蕴含 P ）
依概率 P	“偏离超过 ε ”这个坏事件的概率 $\rightarrow 0$ ；偶尔出错但越来越罕见	居中
依分布 d	仅分布形状趋同 $F_n(x) \rightarrow F(x)$ ； 不要求随机变量本身接近	最弱

为什么“反之一般不成立”很重要：例如存在依概率收敛却不几乎必然收敛的序列（典型的“打字机序列”反例，见第 12 章），所以不能把“依概率”随意升级成“几乎必然”。选对收敛模式，是叙述和使用极限定理时的关键。

0.4 两类极限定理：各回答什么问题

有了“收敛模式”这把尺子，第 10–11 章的两大定理就能各归其位——它们回答的是关于 $\bar{X}_n$ 的两个不同问题：大数定律（LLN，第 10 章）——中心在哪？样本均值 $\bar{X}_n$ 会收敛到一个常数（真实均值 μ ）：

$$\bar{X}_n \xrightarrow{P} \mu \text{ (弱大数定律)}, \quad \bar{X}_n \xrightarrow{a.s.} \mu \text{ (强大数定律)}.$$

它用的是依概率 / 几乎必然收敛——回答“平均值会不会稳定、稳定到哪”。这是频率稳定性、蒙特卡洛积分、统计估计的理论根基。

中心极限定理（CLT，第 11 章）——围绕中心怎么涨落？ $\bar{X}_n$ 收敛到常数后，再放大来看它的随机涨落：把 $\bar{X}_n - \mu$ 按 $\sqrt{n}$ 标准化，其分布趋于正态：


$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1).$$

它用的是依分布收敛——回答“涨落的形状长什么样”。答案惊人地普适：无论原始分布是什么，涨落总趋于正态。

一句话对照：LLN 说“平均值会稳定到 μ ”，CLT 说“它围绕 μ 的涨落是正态形状的”。前者关于位置（依概率/a.s.），后者关于分布（依分布）——正好分处强弱层次的两端。

0.5 怎么“读”一个极限定理

掌握上面的语言后，几乎所有极限定理都能拆成同一个模板：



读定理时，依次问三件事：

1. 谁在收敛？是 $\bar{X}_n$ 、部分和 S_n 、标准化后的 $\frac{S_n - n\mu}{\sigma\sqrt{n}}$ ，还是经验分布？
2. 哪种模式？箭头上是 $\xrightarrow{P}$ 、 $\xrightarrow{a.s.}$ 还是 $\xrightarrow{d}$ ？这决定了结论有多强、能怎么用。
3. 极限是什么？收敛到一个常数（如 LLN 的 μ ），还是收敛到一个分布（如 CLT 的 $\mathcal{N}(0, 1)$ ）？依分布收敛的极限通常是个分布而非数。

0.6 小结与衔接

核心一句话：第四部分研究随机变量序列的极限；因为随机量带着“概率”这一维，“收敛”分裂为强弱不同的几种模式（ $a.s. \Rightarrow P \Rightarrow d$, $L^p \Rightarrow P$ ）；大数定律用强模式说“均值稳定到常数”，中心极限定理用最弱的依分布说“涨落是正态形状”。

思考路标（条件反射）：

- 看到“ X_n 收敛”→ 先问“哪种收敛模式”，不要默认是数列极限；
- 看到 $\xrightarrow{P} / \xrightarrow{a.s.}$ → 极限通常是个常数，想到大数定律类结论；
- 看到 $\xrightarrow{d}$ → 极限通常是个分布，想到中心极限定理类结论，且“分布趋同 $\neq$ 随机变量本身接近”；
- 想“把依概率升级成几乎必然”→ 停，反向一般不成立，需额外条件（见第 12 章）；
- 看到 $E[(X_n - X)^2] \rightarrow 0$ → 这是均方收敛，它蕴含依概率收敛。

接下来三章：

章节	主题	核心收敛模式
第 10 章大数定律	切比雪夫不等式、弱/强大数定律	依概率 P、几乎必然 a.s.
第 11 章中心极限定理	CLT 各形式、正态近似	依分布 d
第 12 章收敛性理论	四种收敛的严格定义、相互关系、Slutsky/ δ 方法	全部，含反例

带着“收敛分强弱、定理在回答不同问题”这把钥匙，再去读第 10 章的大数定律，你看到的就不再是一堆相似的极限式，而是“ $\bar{X}_n$ 在不同强度意义下稳定到 μ ”的层层递进。

第 10 章：大数定律

建议先读：第四部分导论《什么是收敛与极限定理?》——先理解“随机序列收敛分强弱（依概率/几乎必然/依分布）”，再看下面的大数定律会清晰得多。

学习目标

完成本章学习后，你将能够：

1. 理解并应用切比雪夫不等式，对随机变量的尾概率给出定量上界
2. 区分弱大数定律（依概率收敛）与强大数定律（几乎处处收敛）的含义与适用条件
3. 掌握辛钦大数定律和伯努利大数定律的陈述与证明思路
4. 将大数定律应用于频率稳定性、蒙特卡罗积分和统计估计等实际问题
5. 理解大数定律在机器学习中的理论基础，包括经验风险最小化和 SGD 收敛性

10.1 切比雪夫不等式

10.1.1 马尔可夫不等式

在推导切比雪夫不等式之前，先介绍更一般的马尔可夫不等式。

定理 10.1（马尔可夫不等式） 设 X 是非负随机变量， $\mathbb{E}[X]$ 存在，则对任意 $a > 0$ ：

$$P(X \geq a) \leq \frac{\mathbb{E}[X]}{a}$$

证明： 利用示性函数的期望表示。定义 $\mathbf{1}_{\{X \geq a\}}$ 为事件 $\{X \geq a\}$ 的示性函数，则：

$$a \cdot \mathbf{1}_{\{X \geq a\}} \leq X \cdot \mathbf{1}_{\{X \geq a\}} \leq X$$

两边取期望：

$$a \cdot P(X \geq a) = \mathbb{E}[a \cdot \mathbf{1}_{\{X \geq a\}}] \leq \mathbb{E}[X]$$

除以 a 即得结论。□

10.1.2 切比雪夫不等式的陈述

定理 10.2 (切比雪夫不等式) 设随机变量 X 的期望 $\mu = \mathbb{E}[X]$ 和方差 $\sigma^2 = \text{Var}(X)$ 均存在且有限, 则对任意 $\varepsilon > 0$:

$$P(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$$

等价地:

$$P(|X - \mu| < \varepsilon) \geq 1 - \frac{\sigma^2}{\varepsilon^2}$$

证明: 令 $Y = (X - \mu)^2$, 则 Y 是非负随机变量, $\mathbb{E}[Y] = \sigma^2$ 。

注意到 $|X - \mu| \geq \varepsilon$ 当且仅当 $(X - \mu)^2 \geq \varepsilon^2$, 由马尔可夫不等式:

$$P(|X - \mu| \geq \varepsilon) = P((X - \mu)^2 \geq \varepsilon^2) \leq \frac{\mathbb{E}[(X - \mu)^2]}{\varepsilon^2} = \frac{\sigma^2}{\varepsilon^2}$$

□

10.1.3 切比雪夫不等式的解读

设 $\varepsilon = k\sigma$ ($k > 0$), 则:

$$P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}$$

k	上界 $1/k^2$	含义
1	100%	无意义
2	25%	X 偏离均值超过 2σ 的概率不超过 25%
3	11.1%	偏离超过 3σ 的概率不超过 11.1%
4	6.25%	偏离超过 4σ 的概率不超过 6.25%

注: 切比雪夫不等式适用于任意分布, 但界较为宽松。对正态分布而言, $P(|X - \mu| \geq 3\sigma) \approx 0.27\%$, 而切比雪夫仅给出 $\leq 11.1\%$ 。

10.1.4 单侧切比雪夫不等式（坎特利不等式）

对于单侧偏差，有更精确的界：

定理 10.3（坎特利不等式）对任意 $t > 0$ ：

$$P(X - \mu \geq t) \leq \frac{\sigma^2}{\sigma^2 + t^2}$$

这比双侧切比雪夫不等式更紧，因为对单侧偏差，分母增加了 t^2 项。

10.2 弱大数定律

10.2.1 依概率收敛

定义 10.1（依概率收敛）设 $\{X_n\}$ 是一列随机变量， X 是随机变量，若对任意 $\varepsilon > 0$ ：

$$\lim_{n \rightarrow \infty} P(|X_n - X| \geq \varepsilon) = 0$$

则称 X_n 依概率收敛（convergence in probability）到 X ，记为 $X_n \xrightarrow{P} X$ 。

10.2.2 切比雪夫弱大数定律

定理 10.4（切比雪夫弱大数定律）设 $X_1, X_2, \dots$ 是两两不相关的随机变量序列，每个 X_i 都有期望 μ_i 和方差 σ_i^2 。若存在常数 $C < \infty$ 使得 $\sigma_i^2 \leq C$ 对所有 i 成立，则：

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \frac{1}{n} \sum_{i=1}^n \mu_i$$

证明：令 $\bar{\mu}_n = \frac{1}{n} \sum_{i=1}^n \mu_i$ 。由于两两不相关：

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum_{i=1}^n \sigma_i^2 \leq \frac{nC}{n^2} = \frac{C}{n}$$

由切比雪夫不等式，对任意 $\varepsilon > 0$ ：

$$P(|\bar{X}_n - \bar{\mu}_n| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} \leq \frac{C}{n\varepsilon^2} \rightarrow 0 \quad (n \rightarrow \infty)$$

□

10.2.3 辛钦弱大数定律

定理 10.5 (辛钦弱大数定律, 1929) 设 $X_1, X_2, \dots$ 是独立同分布 (i.i.d.) 的随机变量序列, 期望 $\mu = \mathbb{E}[X_1]$ 存在 (有限), 则:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu$$

注: 辛钦弱大数定律不需要方差存在, 仅要求期望有限。这比切比雪夫弱大数定律条件更弱, 但证明需要用到特征函数方法。

证明思路 (使用特征函数): 设 $\varphi(t)$ 是 X_1 的特征函数。 $\bar{X}_n$ 的特征函数为:

$$\varphi_{\bar{X}_n}(t) = \left[\varphi\left(\frac{t}{n}\right) \right]^n$$

由于 $\mathbb{E}[X_1] = \mu$ 存在, $\varphi(t) = 1 + i\mu t + o(t)$ (当 $t \rightarrow 0$), 因此:

$$\varphi_{\bar{X}_n}(t) = \left[1 + \frac{i\mu t}{n} + o\left(\frac{1}{n}\right) \right]^n \rightarrow e^{i\mu t}$$

这是常数 μ 的特征函数, 由连续性定理得 $\bar{X}_n \xrightarrow{P} \mu$ 。□

10.2.4 伯努利大数定律

定理 10.6 (伯努利大数定律) 设在 n 次独立重复试验中, 事件 A 发生的次数为 m_n , 每次试验中 A 发生的概率为 p , 则:

$$\frac{m_n}{n} \xrightarrow{P} p$$

即: 对任意 $\varepsilon > 0$, $\lim_{n \rightarrow \infty} P\left(\left|\frac{m_n}{n} - p\right| \geq \varepsilon\right) = 0$ 。

证明: $m_n \sim B(n, p)$, 故 $\mathbb{E}\left[\frac{m_n}{n}\right] = p$, $\text{Var}\left(\frac{m_n}{n}\right) = \frac{p(1-p)}{n} \leq \frac{1}{4n}$ 。

由切比雪夫不等式:

$$P\left(\left|\frac{m_n}{n} - p\right| \geq \varepsilon\right) \leq \frac{p(1-p)}{n\varepsilon^2} \leq \frac{1}{4n\varepsilon^2} \rightarrow 0$$

□

历史意义: 伯努利大数定律 (1713 年, 雅各布·伯努利) 是概率论中最早的严格定理之一, 它从数学上证明了频率的稳定性: 当试验次数 n 足够大时, 频率 m_n/n 与概率 p 之间的差距可以任意小。

10.3 强大数定律

10.3.1 几乎处处收敛

定义 10.2 (几乎处处收敛) 设 $\{X_n\}$ 是一列随机变量, X 是随机变量, 若:

$$P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1$$

则称 X_n 几乎处处收敛 (almost sure convergence, a.s. 收敛) 到 X , 记为 $X_n \xrightarrow{a.s.} X$ 。

10.3.2 收敛方式的层次

各收敛方式之间的蕴含关系:

$$\text{依概率 1 收敛 (a.s.)} \Rightarrow \text{依概率收敛 (P)} \Rightarrow \text{依分布收敛 (d)}$$

反之不成立 (一般情况下)。其中依分布收敛 (**d**) 指分布函数在连续点处收敛 ($F_n(x) \rightarrow F(x)$), 是最弱的一种——它只关心“分布形状趋同”, 不要求随机变量本身接近。三种收敛模式的含义、为何分强弱、以及本部分的整体动机, 见 第三部分前的导论《什么是收敛与极限定理》; 严格定义见 第 12 章。

直观区别: - 弱大数定律 (依概率): 固定任意 $\varepsilon > 0$, 当 n 足够大时, $|\bar{X}_n - \mu| < \varepsilon$ 以高概率成立。但不排除“坏事件”偶尔发生。- 强大数定律 (**a.s.**): 以概率 1, $\bar{X}_n$ 的每一条样本路径最终都收敛到 μ 。

10.3.3 科尔莫戈洛夫强大数定律

定理 10.7 (科尔莫戈洛夫强大数定律) 设 $X_1, X_2, \dots$ 是独立同分布的随机变量, 则:

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{a.s.} \mu$$

当且仅当 $\mathbb{E}[|X_1|] < \infty$, 此时 $\mu = \mathbb{E}[X_1]$ 。

这是大数定律最完整的形式: **i.i.d.** 随机变量强大数定律成立的充要条件是期望有限。

10.3.4 科尔莫戈洛夫强大数定律的证明 (四阶矩条件)

当 $\mathbb{E}[X_i^4] < \infty$ 时, 可以利用矩方法给出更直接的证明。

设 X_i i.i.d., $\mu = 0$, $\sigma^2 = \mathbb{E}[X_i^2]$, $\mathbb{E}[X_i^4] < \infty$ 。

展开 $\mathbb{E}[\bar{X}_n^4]$:

$$\mathbb{E} \left[\left(\sum_{i=1}^n X_i \right)^4 \right] = n\mathbb{E}[X_1^4] + 3n(n-1)\sigma^4$$

(其他交叉项因独立性消为 0。) 因此:

$$\mathbb{E}[\bar{X}_n^4] = \frac{1}{n^4} (n\mathbb{E}[X_1^4] + 3n(n-1)\sigma^4) = O\left(\frac{1}{n^2}\right)$$

由 Borel-Cantelli 引理, 利用 $\sum_{n=1}^{\infty} \mathbb{E}[\bar{X}_n^4] < \infty$ 可得几乎处处收敛。

10.3.5 强大数定律的几何直观

设 $X_1, X_2, \dots$ i.i.d., 以 $\mu = 0, \sigma = 1$ 的标准正态为例。

对样本轨道 ω , 样本均值序列 $\bar{X}_n(\omega) = \frac{1}{n} \sum_{i=1}^n X_i(\omega)$ 。

强大数定律告诉我们: 在样本空间中, 除了一个概率为 0 的集合之外, 每一条样本轨道 $\{\bar{X}_n(\omega)\}_{n=1}^{\infty}$ 都满足 $\bar{X}_n(\omega) \rightarrow 0$ 。

10.4 大数定律的应用

10.4.1 频率的稳定性与概率的频率定义

伯努利大数定律为概率的频率解释提供了数学基础:

- 统计意义上, 我们用频率 $f_n = m_n/n$ 来估计概率 p
- 大数定律保证: 随着 $n \rightarrow \infty$, $f_n \rightarrow p$ (依概率, 乃至几乎处处)

样本量与误差: 由切比雪夫不等式, 若希望 $P(|f_n - p| < \varepsilon) \geq 1 - \delta$, 则需要:

$$n \geq \frac{1}{4\varepsilon^2\delta}$$

(利用 $p(1-p) \leq 1/4$ 。) 例如, $\varepsilon = 0.01, \delta = 0.05$, 需要 $n \geq 50000$ 。

10.4.2 蒙特卡罗积分

问题: 计算积分 $I = \int_a^b f(x) dx$ 。

方法: 令 $X \sim \text{Uniform}(a, b)$, 则:

$$I = (b - a) \mathbb{E}[f(X)]$$

由强大数定律，若 $X_1, \dots, X_n$ i.i.d. $\sim \text{Uniform}(a, b)$ ，则：

$$\hat{I}_n = \frac{b-a}{n} \sum_{i=1}^n f(X_i) \xrightarrow{a.s.} I$$

误差估计：设 $\sigma_f^2 = \text{Var}(f(X))$ ，则估计量的标准误为：

$$\text{SE}(\hat{I}_n) = \frac{(b-a)\sigma_f}{\sqrt{n}}$$

蒙特卡罗积分的误差以 $O(1/\sqrt{n})$ 收敛，与维度无关（克服了维数灾难）。

10.4.3 样本均值的一致性

定义 10.3 (相合估计量) 若 $\hat{\theta}_n$ 是参数 θ 的估计量，且 $\hat{\theta}_n \xrightarrow{P} \theta$ (或 $\xrightarrow{a.s.} \theta$)，则称 $\hat{\theta}_n$ 是 θ 的相合估计量 (consistent estimator)。

由强大数定律：- 样本均值 $\bar{X}_n$ 是总体均值 μ 的相合估计量 - 样本 k 阶矩 $\frac{1}{n} \sum X_i^k$ 是总体 k 阶矩的相合估计量 (当总体 k 阶矩有限时) - 样本方差 $S_n^2 = \frac{1}{n} \sum (X_i - \bar{X}_n)^2$ 是总体方差的相合估计量

10.4.4 大偏差原理 (预览)

当我们问“ $\bar{X}_n$ 偏离 μ 有多大幅度的概率是多少”时，大数定律告诉我们这个概率趋于 0，但大偏差原理 (Large Deviation Principle, LDP) 给出了更精确的指数衰减率：

$$P(\bar{X}_n \geq \mu + t) \approx e^{-n \cdot I(\mu+t)}$$

其中 $I(x) = \sup_{\lambda} \{\lambda x - \log \mathbb{E}[e^{\lambda X}]\}$ 是速率函数 (Cramér 变换)。

10.5 收敛速度与误差界

10.5.1 Berry-Esseen 定理 (收敛到正态的速度)

大数定律告诉我们 $\bar{X}_n \rightarrow \mu$ ，中心极限定理 (CLT) 告诉我们 $\sqrt{n}(\bar{X}_n - \mu)/\sigma \rightarrow N(0, 1)$ 。**Berry-Esseen** 定理给出 CLT 收敛的速度：

定理 10.8 (Berry-Esseen 定理) 设 $X_1, \dots, X_n$ i.i.d., $\mathbb{E}[X_1] = 0$, $\mathbb{E}[X_1^2] = \sigma^2$, $\mathbb{E}[|X_1|^3] = \rho < \infty$ 。令 F_n 为 $\bar{X}_n/(\sigma/\sqrt{n})$ 的分布函数, Φ 为标准正态分布函数, 则:

$$\sup_x |F_n(x) - \Phi(x)| \leq \frac{C\rho}{\sigma^3\sqrt{n}}$$

其中最优常数 $C \approx 0.4748$ 。这表明 CLT 近似以 $O(1/\sqrt{n})$ 的速度收敛。

10.5.2 Hoeffding 不等式

对有界随机变量, 可以得到比切比雪夫不等式更紧的指数型界。

定理 10.9 (Hoeffding 不等式) 设 $X_1, \dots, X_n$ 独立, $a_i \leq X_i \leq b_i$, $\mathbb{E}[X_i] = \mu_i$, 令 $S_n = \sum_{i=1}^n X_i$, $\mu = \sum_{i=1}^n \mu_i$, 则对任意 $t > 0$:

$$P(S_n - \mu \geq t) \leq \exp\left(-\frac{2t^2}{\sum_{i=1}^n (b_i - a_i)^2}\right)$$

特别地, 若 X_i i.i.d., $a \leq X_i \leq b$, 则:

$$P(\bar{X}_n - \mu \geq t) \leq \exp\left(-\frac{2nt^2}{(b-a)^2}\right)$$

与切比雪夫不等式的对比:

	切比雪夫	Hoeffding
分布假设	无	有界
收敛速度	多项式 $1/n$	指数 e^{-cn}
适用场景	一般	有界变量 (机器学习常见)

10.5.3 有效样本量与置信区间

设 X_i i.i.d., $0 \leq X_i \leq 1$ (如伯努利变量), 均值 μ 未知。

给定置信度 $1 - \delta$, 误差 ε , 由 Hoeffding 不等式, 需要:

$$2 \exp(-2n\varepsilon^2) \leq \delta \implies n \geq \frac{\ln(2/\delta)}{2\varepsilon^2}$$

例如, $\varepsilon = 0.05$, $\delta = 0.05$, 需要 $n \geq \frac{\ln 40}{2 \times 0.0025} \approx 738$ 个样本。

这比切比雪夫界 ($n \geq 1/(4\varepsilon^2\delta) = 2000$) 所需样本量更少。

10.5.4 次高斯变量与 Chernoff 界

定义 10.4 (次高斯变量) 若随机变量 X (均值为 0) 满足:

$$\mathbb{E}[e^{tX}] \leq e^{\sigma^2 t^2/2}, \quad \forall t \in \mathbb{R}$$

则称 X 是参数为 σ 的次高斯 (sub-Gaussian) 随机变量。

有界变量 $X \in [a, b]$ 是次高斯变量, 参数 $\sigma = (b - a)/2$ 。

对次高斯变量, **Chernoff** 界给出:

$$P(\bar{X}_n - \mu \geq t) \leq \exp\left(-\frac{nt^2}{2\sigma^2}\right)$$

本章小结

定理	条件	收敛类型	核心工具
切比雪夫不等式	期望、方差存在	尾概率上界	马尔可夫不等式
伯努利弱大数定律	独立同分布伯努利	依概率	切比雪夫不等式
辛钦弱大数定律	i.i.d., 期望有限	依概率	特征函数
切比雪夫弱大数定律	两两不相关, 方差一致有界	依概率	切比雪夫不等式
科尔莫戈洛夫强大数定律	i.i.d., 期望有限 (充要)	几乎处处	Borel-Cantelli
Hoeffding 不等式	独立有界	指数尾界	矩母函数

核心要点:

- 大数定律的本质是: 大量独立随机性的叠加趋于确定性。样本均值以各种意义下收敛到总体均值。
- 弱大数定律 (依概率) 与强大数定律 (a.s.) 的区别在于: 前者对固定 ϵ 在极限意义下成立, 后者对几乎所有样本路径同时成立。
- 切比雪夫不等式给出多项式衰减的尾界, Hoeffding 不等式 (有界时) 给出指数衰减的尾界。
- 大数定律是统计学 (相合性)、机器学习 (经验风险最小化)、蒙特卡罗方法的理论基础。

深度学习应用

应用一：经验风险最小化 (ERM)

理论框架 在监督学习中，设： - 样本空间 $\mathcal{Z} = \mathcal{X} \times \mathcal{Y}$ - 损失函数 $\ell : \mathcal{H} \times \mathcal{Z} \rightarrow \mathbb{R}_{\geq 0}$ - 数据分布 $\mathcal{D}$ - 训练集 $S = \{z_1, \dots, z_n\} \sim \mathcal{D}^n$ (i.i.d.)

真实风险 (期望风险)：

$$R(h) = \mathbb{E}_{z \sim \mathcal{D}}[\ell(h, z)]$$

经验风险：

$$\hat{R}_S(h) = \frac{1}{n} \sum_{i=1}^n \ell(h, z_i)$$

由强大数定律，对固定的假设 $h \in \mathcal{H}$ ：

$$\hat{R}_S(h) \xrightarrow{a.s.} R(h) \quad (n \rightarrow \infty)$$

这告诉我们：当训练集足够大时，经验风险是真实风险的相合估计。

泛化界 (使用 Hoeffding) 若损失有界 $\ell(h, z) \in [0, C]$ ，由 Hoeffding 不等式，以概率至少 $1 - \delta$ (在训练集 S 的随机性上)：

$$R(h) \leq \hat{R}_S(h) + C \sqrt{\frac{\ln(1/\delta)}{2n}}$$

对于有限假设类 $|\mathcal{H}| < \infty$ ，对所有 h 联合 (union bound)，以概率至少 $1 - \delta$ ：

$$\forall h \in \mathcal{H} : \quad R(h) \leq \hat{R}_S(h) + C \sqrt{\frac{\ln(|\mathcal{H}|/\delta)}{2n}}$$

这说明：模型越复杂 ($|\mathcal{H}|$ 越大)，需要越多训练数据才能保证泛化。

PyTorch 代码：观察经验风险收敛到真实风险

```
import torch
import torch.nn as nn
import numpy as np
import matplotlib.pyplot as plt
```



```

# =====
# 实验：验证大数定律在机器学习中的体现
# 经验风险随训练集大小增加而收敛到真实风险
# =====

torch.manual_seed(42)
np.random.seed(42)

# --- 设置真实数据分布 ---
# 真实分布：  $X \sim N(0, 1)$ ,  $Y = 2X + 1 + \text{eps}$ ,  $\text{eps} \sim N(0, 0.5^2)$ 
true_w = 2.0
true_b = 1.0
noise_std = 0.5

def true_risk(w, b, n_samples=100000):
    """ 用大量样本估计真实风险 (MSE) """
    X = torch.randn(n_samples)
    eps = torch.randn(n_samples) * noise_std
    Y = true_w * X + true_b + eps
    Y_pred = w * X + b
    return ((Y_pred - Y) ** 2).mean().item()

# --- 固定一个次优模型 ---
# 用于观察经验风险 -> 真实风险 的收敛
w_test = torch.tensor(1.8)
b_test = torch.tensor(1.2)

# 真实风险 (精确值)
#  $E[(wX + b - (2X + 1 + \text{eps}))^2] = (w-2)^2 * E[X^2] + (b-1)^2 + \text{sigma}^2$ 
#  $= (1.8-2)^2 * 1 + (1.2-1)^2 + 0.25 = 0.04 + 0.04 + 0.25 = 0.33$ 
analytical_true_risk = (w_test - true_w)**2 * 1.0 + (b_test - true_b)**2 + noise_std**2
print(f" 解析真实风险: {analytical_true_risk.item():.4f}")

# --- 实验：不同样本量下的经验风险 ---
sample_sizes = [10, 20, 50, 100, 200, 500, 1000, 2000, 5000]
n_trials = 200 # 每个样本量重复 200 次

empirical_risks_mean = []
empirical_risks_std = []

for n in sample_sizes:

```

```

risks = []
for _ in range(n_trials):
    X = torch.randn(n)
    eps = torch.randn(n) * noise_std
    Y = true_w * X + true_b + eps
    Y_pred = w_test * X + b_test
    emp_risk = ((Y_pred - Y) ** 2).mean().item()
    risks.append(emp_risk)
empirical_risks_mean.append(np.mean(risks))
empirical_risks_std.append(np.std(risks))

# --- 绘图 ---
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# 左图：经验风险的期望和标准差 vs 样本量
ax = axes[0]
means = np.array(empirical_risks_mean)
stds = np.array(empirical_risks_std)
ax.plot(sample_sizes, means, 'b-o', label='经验风险均值', markersize=6)
ax.fill_between(sample_sizes,
                means - stds,
                means + stds,
                alpha=0.3, color='blue', label='±1 标准差')
ax.axhline(y=analytical_true_risk.item(), color='red', linestyle='--',
           label=f'真实风险 = {analytical_true_risk.item():.4f}')
ax.set_xscale('log')
ax.set_xlabel('训练样本量 n')
ax.set_ylabel('风险值')
ax.set_title('大数定律：经验风险收敛到真实风险')
ax.legend()
ax.grid(True, alpha=0.3)

# 右图：标准差 vs 1/sqrt(n) (验证收敛速度)
ax = axes[1]
n_arr = np.array(sample_sizes, dtype=float)
ax.plot(n_arr, stds, 'b-o', label='经验标准差', markersize=6)
# 理论:  $Std \quad Var(ell) / \sqrt{n}$ 
#  $Var(ell)$  由解析计算得到
ax.plot(n_arr, stds[0] * np.sqrt(sample_sizes[0] / n_arr), 'r--',
       label=r'$0(1/\sqrt{n})$ 参考线')
ax.set_xscale('log')

```

```

ax.set_yscale('log')
ax.set_xlabel('训练样本量 n')
ax.set_ylabel('经验风险标准差（对数尺度）')
ax.set_title('收敛速度:  $O(1/\sqrt{n})$ ')
ax.legend()
ax.grid(True, alpha=0.3)

plt.tight_layout()
plt.savefig('empirical_risk_convergence.png', dpi=150, bbox_inches='tight')
plt.show()
print(" 图像已保存: empirical_risk_convergence.png")

```

应用二：SGD 收敛性与大数定律

理论联系 随机梯度下降（SGD）使用小批量梯度估计完整梯度：

$$g_t = \frac{1}{B} \sum_{i \in \mathcal{B}_t} \nabla_{\theta} \ell(\theta_t, z_i)$$

由大数定律， g_t 是真实梯度 $\nabla_{\theta} R(\theta_t)$ 的无偏相合估计：

$$\mathbb{E}[g_t \mid \theta_t] = \nabla_{\theta} R(\theta_t), \quad g_t \xrightarrow{P} \nabla_{\theta} R(\theta_t) \quad (B \rightarrow \infty)$$

批大小 B 与梯度方差的关系：

$$\text{Var}(g_t) = \frac{\text{Var}(\nabla_{\theta} \ell)}{B}$$

增大批大小可以减小梯度噪声（大数定律），但每步计算量也增加。这是 SGD 中批大小选择的核心权衡。

PyTorch 代码：观察批大小对梯度估计和训练的影响

```

import torch
import torch.nn as nn
import torch.optim as optim
from torch.utils.data import DataLoader, TensorDataset
import numpy as np
import matplotlib.pyplot as plt

torch.manual_seed(42)

# =====

```

```

# 实验：大数定律在 SGD 中的体现
# 批大小 B 增加 -> 梯度估计方差减小 -> 训练更稳定
# =====

# --- 生成合成数据 ---
n_total = 10000
d = 20 # 特征维度

X_all = torch.randn(n_total, d)
true_weights = torch.randn(d) * 0.5
Y_all = X_all @ true_weights + torch.randn(n_total) * 0.3

# --- 简单线性模型 ---
class LinearModel(nn.Module):
    def __init__(self, d):
        super().__init__()
        self.fc = nn.Linear(d, 1, bias=False)
        nn.init.zeros_(self.fc.weight)

    def forward(self, x):
        return self.fc(x).squeeze(-1)

# --- 实验 1: 不同批大小下梯度方差 ---
model_ref = LinearModel(d)
criterion = nn.MSELoss()

# 计算完整梯度（作为参考）
full_out = model_ref(X_all)
full_loss = criterion(full_out, Y_all)
full_loss.backward()
true_grad = model_ref.fc.weight.grad.clone()
model_ref.zero_grad()

print("=== 实验 1: 批大小与梯度估计方差（大数定律） ===")
batch_sizes = [1, 4, 16, 64, 256, 1024, 4096]
gradient_vars = []

for B in batch_sizes:
    grads = []
    n_trials = 500
    for _ in range(n_trials):

```

```

    idx = torch.randint(0, n_total, (B,))
    X_batch = X_all[idx]
    Y_batch = Y_all[idx]
    out = model_ref(X_batch)
    loss = criterion(out, Y_batch)
    loss.backward()
    grads.append(model_ref.fc.weight.grad.clone())
    model_ref.zero_grad()

    grads_tensor = torch.stack(grads)  # (n_trials, d)
    # 各维度上的方差均值
    var = grads_tensor.var(dim=0).mean().item()
    gradient_vars.append(var)
    print(f" 批大小 B={B:5d}: 梯度方差 = {var:.6f}")

# 理论：方差 1/B
B_arr = np.array(batch_sizes, dtype=float)
print(f"\n理论预测 (方差 1/B): ")
print(f" 方差比 B=1 vs B=64: {gradient_vars[0]/gradient_vars[3]:.1f} (理论 64.0) ")

# --- 实验 2: 不同批大小下的训练曲线 ---
print("\n=== 实验 2: 不同批大小的训练收敛曲线 ===")

n_train = 8000
X_train, Y_train = X_all[:n_train], Y_all[:n_train]
X_val, Y_val = X_all[n_train:], Y_all[n_train:]

batch_sizes_train = [8, 64, 512, 4096]
colors = ['blue', 'green', 'orange', 'red']
n_epochs = 50
lr = 0.01

fig, axes = plt.subplots(1, 2, figsize=(14, 5))

for B, color in zip(batch_sizes_train, colors):
    model = LinearModel(d)
    optimizer = optim.SGD(model.parameters(), lr=lr)
    dataset = TensorDataset(X_train, Y_train)
    loader = DataLoader(dataset, batch_size=B, shuffle=True)

    train_losses = []

```

```

val_losses = []

for epoch in range(n_epochs):
    model.train()
    epoch_losses = []
    for X_b, Y_b in loader:
        optimizer.zero_grad()
        loss = criterion(model(X_b), Y_b)
        loss.backward()
        optimizer.step()
        epoch_losses.append(loss.item())
    train_losses.append(np.mean(epoch_losses))

    model.eval()
    with torch.no_grad():
        val_loss = criterion(model(X_val), Y_val).item()
    val_losses.append(val_loss)

label = f'B={B}'
axes[0].plot(train_losses, color=color, label=label, alpha=0.8)
axes[1].plot(val_losses, color=color, label=label, alpha=0.8)
print(f"   B={B:5d}: 最终验证损失 = {val_losses[-1]:.4f}")

axes[0].set_xlabel('Epoch')
axes[0].set_ylabel('训练损失')
axes[0].set_title('不同批大小的训练损失曲线')
axes[0].legend()
axes[0].grid(True, alpha=0.3)

axes[1].set_xlabel('Epoch')
axes[1].set_ylabel('验证损失')
axes[1].set_title('不同批大小的验证损失曲线')
axes[1].legend()
axes[1].grid(True, alpha=0.3)

plt.tight_layout()
plt.savefig('sgd_batch_size_convergence.png', dpi=150, bbox_inches='tight')
plt.show()
print(" 图像已保存: sgd_batch_size_convergence.png")

# --- 展示梯度方差随批大小的变化 ---

```

```
fig, ax = plt.subplots(figsize=(7, 5))
ax.loglog(batch_sizes, gradient_vars, 'b-o', label='实测梯度方差', markersize=8)
ax.loglog(B_arr, gradient_vars[0] / B_arr * batch_sizes[0],
          'r--', label=r'理论 $\propto 1/B$')
ax.set_xlabel('批大小 B (对数尺度)')
ax.set_ylabel('梯度方差 (对数尺度)')
ax.set_title('大数定律：批大小越大，梯度方差越小')
ax.legend()
ax.grid(True, alpha=0.3)
plt.tight_layout()
plt.savefig('gradient_variance_vs_batchsize.png', dpi=150, bbox_inches='tight')
plt.show()
print(" 图像已保存：gradient_variance_vs_batchsize.png")
```

实验结论：

1. 梯度方差 $\propto 1/B$ ：与大数定律的预测完全吻合。批大小增加 64 倍，梯度方差减小 64 倍。
 2. 小批量 ($B=8$)：梯度噪声大，损失曲线震荡，但每个 epoch 更新步数多，初期收敛快，且噪声有助于逃离局部极小值。
 3. 大批量 ($B=4096$)：梯度估计精准，损失曲线平滑，但每 epoch 更新步数少，可能需要更多 epoch。
 4. 最优批大小选择需要平衡计算效率与梯度噪声，是实践中的重要超参数。
-

练习题

练习 10.1（切比雪夫不等式的应用）

设某工厂生产的零件质量 X （单位：克）满足 $\mathbb{E}[X] = 100$, $\text{Var}(X) = 4$ 。

- (a) 用切比雪夫不等式估计 $P(|X - 100| \geq 5)$ 的上界。
 - (b) 若质量超出范围 $[96, 104]$ 的零件为次品，用切比雪夫不等式估计次品率的上界。
 - (c) 若 $X \sim N(100, 4)$ ，计算 (a)、(b) 的精确值，并与切比雪夫界比较。
-

练习 10.2（弱大数定律的证明）

设 $X_1, X_2, \dots$ 是独立随机变量序列， X_k 服从参数为 λ_k 的泊松分布， $P(X_k = j) = e^{-\lambda_k} \lambda_k^j / j!$, $j = 0, 1, 2, \dots$

- (a) 计算 $\mathbb{E}[X_k]$ 和 $\text{Var}(X_k)$ 。
- (b) 设 $\lambda_k = 1$ （即 X_k i.i.d. $\sim \text{Poisson}(1)$ ），证明 $\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} 1$ 。

- (c) 设 $\lambda_k = k$, 分析 $\frac{1}{n} \sum_{k=1}^n X_k$ 是否仍然满足弱大数定律 (依概率收敛到某个常数)。
-

练习 10.3 (蒙特卡罗积分)

用蒙特卡罗方法估计积分 $I = \int_0^1 e^{-x^2} dx$ 。

- (a) 写出蒙特卡罗估计量 $\hat{I}_n$, 证明它是 I 的无偏估计量, 并给出方差表达式。
- (b) 若要使估计的均方根误差 $\text{RMSE} = \sqrt{\text{Var}(\hat{I}_n)} \leq 0.001$, 至少需要多少个样本? (提示: 先估计 $\text{Var}(e^{-X^2})$, $X \sim \text{Uniform}(0, 1)$ 。)
- (c) 使用重要性采样改进: 取 $g(x) = \frac{1}{c}e^{-x}$ ($c = 1 - e^{-1}$) 为提议分布, 写出对应的重要性采样估计量, 并分析其方差是否比朴素蒙特卡罗更小。
-

练习 10.4 (Hoeffding 不等式与样本复杂度)

某机器学习模型在验证集上测量准确率。设每个样本的预测结果 $Z_i \in \{0, 1\}$ (1 表示正确), 真实准确率为 p 。

- (a) 用 Hoeffding 不等式, 给出样本量 n , 使得以至少 95% 的概率, 样本准确率 $\hat{p}_n$ 与真实准确率 p 的偏差不超过 0.02。
- (b) 若有 $K = 100$ 个候选模型, 要对所有模型同时 (以 95% 总置信度) 保证误差不超过 0.02, 需要多少样本? (提示: 使用联合界。)
- (c) 与切比雪夫不等式给出的样本量要求比较, 哪个界更紧?
-

练习 10.5 (强大数定律与 Borel-Cantelli 引理)

设 $X_1, X_2, \dots$ i.i.d., $P(X_i = 1) = P(X_i = -1) = 1/2$ (Rademacher 变量)。

- (a) 计算 $\mathbb{E}[X_i]$, $\text{Var}(X_i)$, $\mathbb{E}[X_i^4]$ 。
- (b) 令 $S_n = X_1 + \dots + X_n$, $\bar{X}_n = S_n/n$ 。证明 $\bar{X}_n \xrightarrow{a.s.} 0$ 。

提示: 利用 $\mathbb{E}[S_n^4] = 3n(n-1) + n = 3n^2 - 2n$ 和 Borel-Cantelli 引理: 若 $\sum_{n=1}^{\infty} P(|\bar{X}_n| > \varepsilon) < \infty$, 则 $P(\limsup_{n \rightarrow \infty} \{|\bar{X}_n| > \varepsilon\}) = 0$ 。

- (c) 对 $\varepsilon > 0$, 用马尔可夫不等式 (对 $\bar{X}_n^4$) 给出 $P(|\bar{X}_n| > \varepsilon)$ 的上界, 并验证该上界对 n 求和收敛。
-

练习答案

练习 10.1 答案

(a) 由切比雪夫不等式, $\varepsilon = 5$, $\sigma^2 = 4$:

$$P(|X - 100| \geq 5) \leq \frac{\sigma^2}{\varepsilon^2} = \frac{4}{25} = 0.16$$

(b) 注意 $P(X \notin [96, 104]) = P(|X - 100| > 4)$ 。取 $\varepsilon = 4$:

$$P(|X - 100| \geq 4) \leq \frac{4}{16} = 0.25$$

所以切比雪夫界给出次品率 $\leq 25\%$ 。

(c) 若 $X \sim N(100, 4)$ (即 $\sigma = 2$):

(a) 的精确值: $P(|X - 100| \geq 5) = P(|Z| \geq 2.5) = 2(1 - \Phi(2.5)) \approx 2 \times 0.0062 = 0.0124$

(b) 的精确值: $P(|X - 100| \geq 4) = P(|Z| \geq 2) = 2(1 - \Phi(2)) \approx 0.0456$

切比雪夫界 (16% 和 25%) 比正态分布的精确值 (1.24% 和 4.56%) 宽松了一个数量级, 体现了切比雪夫不等式适用于一般分布时的保守性。

练习 10.2 答案

(a) 泊松分布的矩: $\mathbb{E}[X_k] = \lambda_k$, $\text{Var}(X_k) = \lambda_k$ 。

(b) 设 $\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k$, $\lambda_k = 1$, 则:

$$\mathbb{E}[\bar{X}_n] = 1, \text{Var}(\bar{X}_n) = \frac{1}{n}。$$

由切比雪夫不等式, 对任意 $\varepsilon > 0$:

$$P(|\bar{X}_n - 1| \geq \varepsilon) \leq \frac{1}{n\varepsilon^2} \rightarrow 0$$

故 $\bar{X}_n \xrightarrow{P} 1$ 。

(c) 当 $\lambda_k = k$ 时:

$$\mathbb{E}[\bar{X}_n] = \frac{1}{n} \sum_{k=1}^n k = \frac{n+1}{2} \rightarrow \infty$$

所以 $\bar{X}_n$ 不能依概率收敛到任何常数。弱大数定律不成立 (均值序列本身发散)。

若对均值进行归一化, $\frac{\bar{X}_n - (n+1)/2}{\sqrt{\bar{\sigma}_n^2}}$ 可能满足 CLT, 但这已超出大数定律的范畴。

练习 10.3 答案

(a) 令 $X \sim \text{Uniform}(0, 1)$, 估计量 $\hat{I}_n = \frac{1}{n} \sum_{i=1}^n e^{-X_i^2}$ 。

无偏性: $\mathbb{E}[\hat{I}_n] = \mathbb{E}[e^{-X^2}] = \int_0^1 e^{-x^2} dx = I$ 。

方差: $\text{Var}(\hat{I}_n) = \frac{1}{n} \text{Var}(e^{-X^2}) = \frac{1}{n} \left(\int_0^1 e^{-2x^2} dx - I^2 \right)$ 。

(b) 数值计算: $I \approx 0.7468$, $\int_0^1 e^{-2x^2} dx \approx 0.6267$,

$\text{Var}(e^{-X^2}) \approx 0.6267 - 0.7468^2 \approx 0.6267 - 0.5577 = 0.0690$ 。

要使 $\text{RMSE} = \sqrt{\text{Var}(\hat{I}_n)} \leq 0.001$:

$$n \geq \frac{\text{Var}(e^{-X^2})}{(0.001)^2} = \frac{0.0690}{10^{-6}} = 69000$$

约需 **69,000** 个样本。

(c) 重要性采样: 以密度 $g(x) = e^{-x}/c$ ($x \in [0, 1]$, $c = 1 - e^{-1} \approx 0.6321$) 为提议分布,

$$\hat{I}_n^{IS} = \frac{1}{n} \sum_{i=1}^n \frac{e^{-X_i^2}}{g(X_i)} = \frac{c}{n} \sum_{i=1}^n e^{-X_i^2 + X_i}$$

其中 $X_i \sim g$ 。由于 $g(x) \propto e^{-x}$ 在 $[0, 1]$ 上是 $f(x) = e^{-x^2}$ 的较好近似, 重要性权重 f/g 的方差更小, 从而重要性采样估计量的方差小于朴素蒙特卡罗。

练习 10.4 答案

(a) $Z_i \in [0, 1]$, 由 Hoeffding 不等式 (双侧):

$$P(|\hat{p}_n - p| \geq 0.02) \leq 2 \exp(-2n \cdot 0.02^2) = 2e^{-0.0008n}$$

要使该概率 ≤ 0.05 :

$$2e^{-0.0008n} \leq 0.05 \implies n \geq \frac{\ln 40}{0.0008} = \frac{3.689}{0.0008} \approx 4611$$

约需 **4612** 个样本。

(b) 对 $K = 100$ 个模型，使用联合界。要所有模型同时满足，每个模型的置信度需达到 $1 - 0.05/100 = 0.9995$ ，即每个模型的错误概率 ≤ 0.0005 ：

$$2e^{-0.0008n} \leq 0.0005 \implies n \geq \frac{\ln 4000}{0.0008} = \frac{8.294}{0.0008} \approx 10368$$

约需 **10,369** 个样本（是单模型的约 $1 + \frac{\ln K}{\ln(2/\delta_0)} \approx 2.25$ 倍）。

(c) 对比切比雪夫： $n \geq \frac{1}{4 \times 0.02^2 \times 0.05} = \frac{1}{0.00008} = 12500$ 。

Hoeffding (≈ 4612) 比切比雪夫 (12500) 所需样本量更少，**Hoeffding** 不等式更紧（对有界变量利用了更多信息）。

练习 10.5 答案

(a) $X_i \in \{-1, +1\}$ ，等概率：

$$\mathbb{E}[X_i] = \frac{1}{2}(1) + \frac{1}{2}(-1) = 0$$

$$\text{Var}(X_i) = \mathbb{E}[X_i^2] - 0 = 1$$

$$\mathbb{E}[X_i^4] = \frac{1}{2}(1)^4 + \frac{1}{2}(-1)^4 = 1$$

(b) 利用 $\mathbb{E}[S_n^4]$ 的计算。

展开 $(\sum_{i=1}^n X_i)^4$ ，利用独立性，只有 $\mathbb{E}[X_i^4]$ 和 $\mathbb{E}[X_i^2 X_j^2]$ ($i \neq j$) 项非零：

$$\mathbb{E}[S_n^4] = n\mathbb{E}[X_1^4] + 3n(n-1)(\mathbb{E}[X_1^2])^2 = n + 3n(n-1) = 3n^2 - 2n$$

由马尔可夫不等式对 $\bar{X}_n^4$ ：

$$P(|\bar{X}_n| > \varepsilon) = P(\bar{X}_n^4 > \varepsilon^4) \leq \frac{\mathbb{E}[\bar{X}_n^4]}{\varepsilon^4} = \frac{\mathbb{E}[S_n^4]}{n^4 \varepsilon^4} = \frac{3n^2 - 2n}{n^4 \varepsilon^4} \leq \frac{3}{n^2 \varepsilon^4}$$

(c) 上界为 $\frac{3}{n^2 \varepsilon^4}$ ，则：

$$\sum_{n=1}^{\infty} P(|\bar{X}_n| > \varepsilon) \leq \sum_{n=1}^{\infty} \frac{3}{n^2 \varepsilon^4} = \frac{3}{\varepsilon^4} \cdot \frac{\pi^2}{6} < \infty$$

(利用 $\sum_{n=1}^{\infty} 1/n^2 = \pi^2/6$ 。)

由 Borel-Cantelli 引理第一定理， $P(\limsup_{n \rightarrow \infty} \{|\bar{X}_n| > \varepsilon\}) = 0$ ，即：

$$P(|\bar{X}_n| > \varepsilon \text{ 发生无穷多次}) = 0$$

对任意有理数 $\varepsilon > 0$ (可数个), 取并集仍为零概率集, 故:

$$P\left(\lim_{n \rightarrow \infty} \bar{X}_n = 0\right) = 1 \Rightarrow \bar{X}_n \xrightarrow{a.s.} 0$$

□

第 11 章：中心极限定理

学习目标

学完本章后, 你将能够:

- 理解中心极限定理的核心思想: 独立随机变量之和在适当标准化后趋向正态分布
- 掌握 Lindeberg-Lévy 定理的条件与结论, 能在实际问题中判断何时可使用正态近似
- 推导 De Moivre-Laplace 定理, 理解二项分布的正态近似原理及连续性修正
- 运用中心极限定理解决实际概率估计问题, 包括样本均值的近似分布与置信区间
- 理解 Berry-Esseen 定理给出的收敛速度上界, 知晓正态近似的误差量级

11.1 独立同分布的中心极限定理

引入: 硬币投掷实验

投掷一枚均匀硬币 n 次, 设 $X_i = 1$ 表示第 i 次正面, $X_i = 0$ 表示反面。令 $S_n = X_1 + X_2 + \cdots + X_n$ 为正面总次数。

当 n 很小时, S_n 的分布是离散的二项分布; 但当 n 增大时, S_n 的直方图越来越像一条钟形曲线——正态分布的密度函数。

这一现象背后蕴藏着概率论最深刻的定理之一: 中心极限定理 (Central Limit Theorem, CLT)。

基本设置

设 $X_1, X_2, \dots, X_n$ 是独立同分布 (i.i.d.) 的随机变量序列, 满足:

$$\mathbb{E}[X_i] = \mu, \quad \text{Var}(X_i) = \sigma^2 \in (0, +\infty)$$

定义部分和与样本均值:

$$S_n = \sum_{i=1}^n X_i, \quad \bar{X}_n = \frac{S_n}{n}$$

由期望和方差的线性性：

$$\mathbb{E}[S_n] = n\mu, \quad \text{Var}(S_n) = n\sigma^2$$

$$\mathbb{E}[\bar{X}_n] = \mu, \quad \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}$$

标准化

为了研究 S_n 的极限分布，需要对其进行标准化，使均值为 0、方差为 1：

$$Z_n = \frac{S_n - n\mu}{\sigma\sqrt{n}} = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$$

中心极限定理断言：当 $n \rightarrow \infty$ 时， Z_n 的分布收敛到标准正态分布 $\mathcal{N}(0, 1)$ 。

定理陈述

定理 11.1 (i.i.d. 中心极限定理) 设 $X_1, X_2, \dots$ 为 i.i.d. 随机变量， $\mathbb{E}[X_1] = \mu$ ， $0 < \text{Var}(X_1) = \sigma^2 < \infty$ 。则对任意实数 x ：

$$\lim_{n \rightarrow \infty} P\left(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leq x\right) = \Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-t^2/2} dt$$

其中 $\Phi(x)$ 为标准正态分布函数。简记为：

$$Z_n \xrightarrow{d} \mathcal{N}(0, 1) \quad (n \rightarrow \infty)$$

或等价地：

$$\bar{X}_n \xrightarrow{d} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

符号 $\xrightarrow{d}$ (依分布收敛) 先给最小定义： $Z_n \xrightarrow{d} Z$ 不是说随机变量 Z_n 本身趋于某个数或某个随机变量，而是说 Z_n 的分布函数逐点趋于目标分布函数——在目标 F 的每个连续点 x 处 $P(Z_n \leq x) \rightarrow F(x)$ 。上面方框里的极限式 $P(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leq x) \rightarrow \Phi(x)$ 正是这个定义在本定理中的展开。“为什么随机序列的收敛要这样定义、它和大数定律里的‘依概率收敛’有何不同”——见 第三部分前的导论《什么是收敛与极限定理》，严格定义与等价刻画见 第 12 章 §12.2。

证明思路（特征函数方法）

定义：随机变量 X 的特征函数（characteristic function）为：

$$\varphi_X(t) = \mathbb{E}[e^{itX}], \quad t \in \mathbb{R}$$

特征函数唯一确定分布，且连续性定理保证：若 $\varphi_{Z_n}(t) \rightarrow \varphi_Z(t)$ （对每个 t ），则 $Z_n \xrightarrow{d} Z$ 。

步骤 1：设 $Y_i = (X_i - \mu)/\sigma$ ，则 $\mathbb{E}[Y_i] = 0$ ， $\mathbb{E}[Y_i^2] = 1$ 。

$$Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n Y_i$$

步骤 2：利用独立性， Z_n 的特征函数为：

$$\varphi_{Z_n}(t) = \left[\varphi_Y\left(\frac{t}{\sqrt{n}}\right) \right]^n$$

步骤 3：对 φ_Y 在 0 处做 Taylor 展开：

$$\varphi_Y(s) = 1 + is\mathbb{E}[Y] - \frac{s^2}{2}\mathbb{E}[Y^2] + o(s^2) = 1 - \frac{s^2}{2} + o(s^2)$$

（利用了 $\mathbb{E}[Y] = 0$ ， $\mathbb{E}[Y^2] = 1$ ）

步骤 4：令 $s = t/\sqrt{n}$ ：

$$\varphi_{Z_n}(t) = \left[1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right) \right]^n \xrightarrow{n \rightarrow \infty} e^{-t^2/2}$$

步骤 5： $e^{-t^2/2}$ 正是 $\mathcal{N}(0, 1)$ 的特征函数，由连续性定理， $Z_n \xrightarrow{d} \mathcal{N}(0, 1)$ 。■

直觉理解

中心极限定理的深层含义：无论原始分布是什么形状（均匀、指数、泊松……），只要方差有限，大量独立随机变量之和的“涨落”都服从同一规律——正态分布。

这是因为：求和操作不断“平均化”了各个分量的个性，保留下来的只有均值和方差这两个最基本的特征，而正态分布恰好由这两个参数完全确定。

11.2 Lindeberg-Lévy 定理

概念澄清

Lindeberg-Lévy 定理通常是指 i.i.d. 情形中心极限定理的经典表述（由 Lindeberg 和 Lévy 分别在 1920 和 1922 年前后独立建立）。其核心是定理 11.1 中已陈述的结论。本节重点讨论其更广泛的背景：如何将 CLT 推广到非同分布的独立随机变量情形。

Lindeberg 条件

设 $X_1, X_2, \dots$ 是独立（但不一定同分布）的随机变量序列， $\mathbb{E}[X_k] = \mu_k$ ， $\text{Var}(X_k) = \sigma_k^2$ 。令：

$$s_n^2 = \sum_{k=1}^n \sigma_k^2, \quad S_n = \sum_{k=1}^n X_k$$

Lindeberg 条件：对任意 $\varepsilon > 0$,

$$L_n(\varepsilon) \triangleq \frac{1}{s_n^2} \sum_{k=1}^n \mathbb{E}[(X_k - \mu_k)^2 \cdot \mathbf{1}\{|X_k - \mu_k| > \varepsilon s_n\}] \rightarrow 0 \quad (n \rightarrow \infty)$$

含义：每个 X_k 的“大偏差”对总方差的贡献可以忽略不计，即没有单个分量主导整个和的波动。这是一种“无单一主导项”条件。

Lindeberg 中心极限定理

定理 11.2 (Lindeberg CLT) 若独立随机变量序列 $\{X_k\}$ 满足 Lindeberg 条件，则：

$$\frac{S_n - \sum_{k=1}^n \mu_k}{s_n} \xrightarrow{d} \mathcal{N}(0, 1)$$

定理 11.3 (Feller 定理) 若额外假设 $\max_{1 \leq k \leq n} \sigma_k^2 / s_n^2 \rightarrow 0$ (Feller 条件)，则 Lindeberg 条件不仅充分而且必要。

Lyapunov 条件

Lyapunov 条件 (Lindeberg 条件的充分条件，更易验证)：若存在 $\delta > 0$ 使得：

$$\frac{1}{s_n^{2+\delta}} \sum_{k=1}^n \mathbb{E}[|X_k - \mu_k|^{2+\delta}] \rightarrow 0$$

则 Lindeberg 条件成立，从而中心极限定理成立。

最常用情形：取 $\delta = 1$ ，即要求：

$$\frac{\sum_{k=1}^n \mathbb{E}[|X_k - \mu_k|^3]}{s_n^3} \rightarrow 0$$

条件的层次结构

各条件的蕴含关系如下：

i.i.d. (有限方差) $\Rightarrow$ Lyapunov 条件 $\Rightarrow$ Lindeberg 条件 $\Rightarrow$ CLT 成立

示例：不同方差的独立正态随机变量

设 $X_k \sim \mathcal{N}(0, k)$, $k = 1, 2, \dots, n$, 相互独立。

- $\mu_k = 0$, $\sigma_k^2 = k$, $s_n^2 = \sum_{k=1}^n k = n(n+1)/2$
- 验证 Lyapunov 条件 ($\delta = 1$): $\mathbb{E}[|X_k|^3] = \sqrt{8/\pi} \cdot k^{3/2}$

$$\frac{\sum_{k=1}^n k^{3/2}}{s_n^3} \sim \frac{n^{5/2}}{n^3} = n^{-1/2} \rightarrow 0$$

Lyapunov 条件满足，故 $S_n/s_n \xrightarrow{d} \mathcal{N}(0, 1)$ 。

11.3 De Moivre-Laplace 定理

二项分布的正态近似

De Moivre-Laplace 定理是历史上最早被发现的中心极限定理的特殊情形，由 Abraham de Moivre (1733 年) 和 Pierre-Simon Laplace (1812 年) 先后发展。

设置：设 $X \sim B(n, p)$ ，即 n 次独立伯努利试验中成功次数，其中每次成功概率为 $p \in (0, 1)$, $q = 1 - p$ 。

$$\mathbb{E}[X] = np, \quad \text{Var}(X) = npq$$

将 X 视为 n 个 i.i.d. 伯努利变量之和，由定理 11.1 立得：

定理 11.4 (De Moivre-Laplace 定理)

$$\frac{X - np}{\sqrt{npq}} \xrightarrow{d} \mathcal{N}(0, 1) \quad (n \rightarrow \infty)$$

等价地：

$$P(a \leq X \leq b) \approx \Phi\left(\frac{b - np}{\sqrt{npq}}\right) - \Phi\left(\frac{a - np}{\sqrt{npq}}\right)$$

连续性修正 (Continuity Correction)

由于 X 是离散随机变量，而正态分布是连续的，直接用正态近似时会有误差。连续性修正通过将整数 k 对应到区间 $[k - 0.5, k + 0.5]$ 来提升近似精度：

$$P(X = k) \approx \Phi\left(\frac{k + 0.5 - np}{\sqrt{npq}}\right) - \Phi\left(\frac{k - 0.5 - np}{\sqrt{npq}}\right)$$

$$P(a \leq X \leq b) \approx \Phi\left(\frac{b + 0.5 - np}{\sqrt{npq}}\right) - \Phi\left(\frac{a - 0.5 - np}{\sqrt{npq}}\right)$$

经验法则：当 $np \geq 5$ 且 $nq \geq 5$ 时，正态近似（含连续性修正）效果良好。

示例：投硬币 100 次

投掷均匀硬币 $n = 100$ 次， $p = 0.5$ ， $np = 50$ ， $\sqrt{npq} = 5$ 。

问：恰好 55 次正面的概率？

精确值： $P(X = 55) = \binom{100}{55}(0.5)^{100} \approx 0.0485$

不用连续性修正：

$$P(X = 55) \approx \phi\left(\frac{55 - 50}{5}\right) \cdot 1 = \phi(1) = \frac{1}{\sqrt{2\pi}}e^{-1/2} \approx 0.0484 \quad (\text{乘以宽度 1 的近似})$$

实际上应写为：

$$P(X = 55) \approx \Phi(1) - \Phi(0.8) = 0.8413 - 0.7881 = 0.0532$$

用连续性修正：

$$P(X = 55) \approx \Phi\left(\frac{55.5 - 50}{5}\right) - \Phi\left(\frac{54.5 - 50}{5}\right) = \Phi(1.1) - \Phi(0.9)$$

$$= 0.8643 - 0.8159 = 0.0484$$

连续性修正后的结果 0.0484 与精确值 0.0485 几乎完全吻合。

局部极限定理 (Local Limit Theorem)

De Moivre-Laplace 定理还有一个局部版本，直接给出点概率的渐近公式：

$$P(X = k) \sim \frac{1}{\sqrt{2\pi npq}} \exp\left(-\frac{(k - np)^2}{2npq}\right) \quad (\text{当 } n \rightarrow \infty, k \text{ 在 } np \text{ 附近})$$

11.4 中心极限定理的应用

应用一：近似计算概率

例 11.1 某工厂每天生产 $n = 10000$ 个零件，每个零件独立地以概率 $p = 0.001$ 为次品。求次品数超过 15 的概率。

设 $X \sim B(10000, 0.001)$ ，则 $\mu = np = 10$ ， $\sigma = \sqrt{npq} = \sqrt{9.99} \approx 3.16$ 。

$$P(X > 15) = P\left(\frac{X - 10}{3.16} > \frac{15 - 10}{3.16}\right) \approx P(Z > 1.582)$$

$$= 1 - \Phi(1.58) = 1 - 0.9429 = 0.0571$$

约有 5.7% 的概率次品数超过 15。

(注：此情形 $np = 10$ 较小，泊松近似 $X \approx \text{Pois}(10)$ 效果可能更好。)

应用二：样本均值的置信区间

设 $X_1, \dots, X_n$ 为 i.i.d. 随机变量， $\mathbb{E}[X_i] = \mu$ ， $\text{Var}(X_i) = \sigma^2$ 。由 CLT，对大 n ：

$$\bar{X}_n \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

因此 μ 的近似 95% 置信区间为：

$$\boxed{\bar{X}_n \pm 1.96 \cdot \frac{\sigma}{\sqrt{n}}}$$

若 σ 未知，用样本标准差 S 代替：

$$\bar{X}_n \pm z_{\alpha/2} \cdot \frac{S}{\sqrt{n}}$$

其中 $z_{\alpha/2}$ 为标准正态分布的 $(1 - \alpha/2)$ 分位数 (95% 置信时取 $z_{0.025} = 1.96$)。

应用三：样本量的确定

问：要使样本均值 $\bar{X}_n$ 与真实均值 μ 的误差不超过 ε (概率至少 $1 - \alpha$)，需要多大样本量 n ？

由 CLT：

$$P(|\bar{X}_n - \mu| \leq \varepsilon) \approx 2\Phi\left(\frac{\varepsilon\sqrt{n}}{\sigma}\right) - 1 \geq 1 - \alpha$$

解得：

$$\frac{\varepsilon\sqrt{n}}{\sigma} \geq z_{\alpha/2} \Rightarrow \boxed{n \geq \left(\frac{z_{\alpha/2} \cdot \sigma}{\varepsilon}\right)^2}$$

示例：已知 $\sigma = 10$ ，要求误差不超过 1，置信度 95% ($z_{0.025} = 1.96$)：

$$n \geq \left(\frac{1.96 \times 10}{1}\right)^2 = 384.16 \Rightarrow n \geq 385$$

应用四：概率的大数估计

例 11.2 (民意调查) 在选举调查中， n 人被随机抽样，真实支持率为 p (未知)。设 $\hat{p} = X/n$ 为样本支持率。

由于 $X \sim B(n, p)$ ， $\text{Var}(\hat{p}) = p(1-p)/n \leq 1/(4n)$ (由 $p(1-p) \leq 1/4$)，因此保守的 95% 置信区间为：

$$\hat{p} \pm \frac{1.96}{2\sqrt{n}} \approx \hat{p} \pm \frac{1}{\sqrt{n}}$$

这解释了为什么 $n = 1000$ 时误差约为 $\pm 3.2\%$ (俗称“误差边际”)。

应用五：保险风险计算

例 11.3 某保险公司有 $n = 5000$ 个客户，每人独立地以概率 $p = 0.01$ 在一年内出险，出险赔付额服从均值 $\mu_Y = 50000$ 元、标准差 $\sigma_Y = 20000$ 元的分布。

设总赔付 $T = \sum_{i=1}^n X_i Y_i$ (其中 $X_i \sim \text{Bernoulli}(p)$ ， Y_i 为赔付额)。

利用 CLT (n 足够大):

$$\mathbb{E}[T] = n \cdot p \cdot \mu_Y = 5000 \times 0.01 \times 50000 = 2,500,000 \text{ 元}$$

$$\text{Var}(T) = n \cdot p \cdot (\sigma_Y^2 + \mu_Y^2 \cdot q) \approx np(\sigma_Y^2 + \mu_Y^2) \quad (\text{近似})$$

实际计算中, T 近似正态, 保险公司可据此设定保费与风险准备金, 使破产概率低于某阈值。

11.5 Berry-Esseen 定理

收敛速度问题

CLT 告诉我们 Z_n 的分布趋向正态, 但没有说多快。实践中我们需要知道: 对有限的 n , 正态近似的误差有多大?

Berry-Esseen 定理给出了精确的误差上界。

定理陈述

定理 11.5 (Berry-Esseen 定理) 设 $X_1, X_2, \dots, X_n$ 为 i.i.d. 随机变量, $\mathbb{E}[X_1] = \mu$, $\text{Var}(X_1) = \sigma^2 > 0$, $\mathbb{E}[|X_1 - \mu|^3] = \rho < \infty$ 。令 F_n 为标准化和 Z_n 的分布函数, 则:

$$\sup_{x \in \mathbb{R}} |F_n(x) - \Phi(x)| \leq \frac{C\rho}{\sigma^3 \sqrt{n}}$$

其中 C 为绝对常数。目前已知最佳常数界为 $C \leq 0.4748$ (Shevtsova, 2011 年)。

含义: CLT 的收敛速度为 $O(1/\sqrt{n})$, 即正态近似的误差以 $1/\sqrt{n}$ 的速率趋向零。

关键量: 偏度与第三矩

定义标准化第三中心矩 (偏度):

$$\gamma = \frac{\mathbb{E}[(X_1 - \mu)^3]}{\sigma^3}$$

则误差上界可写为:

$$\sup_x |F_n(x) - \Phi(x)| \leq \frac{C|\gamma|}{\sqrt{n}} \cdot \frac{\rho/|\mathbb{E}[|X_1 - \mu|^3]|}{\sigma^3/|\rho|}$$

简洁形式：以 ρ/σ^3 代入，误差 $\sim \frac{C\rho}{\sigma^3\sqrt{n}}$ ，其中 ρ/σ^3 与偏度的绝对值相关。

推论：误差量级

条件	误差上界
一般情形（有限三阶矩）	$O(1/\sqrt{n})$
对称分布（奇数阶中心矩为零）	$O(1/n)$
均匀分布	$O(1/n)$

对称分布收敛更快的直觉：对称性消除了一阶误差项（偏度为零），主导误差降为 $O(1/n)$ 。

示例：伯努利情形

$X_i \sim \text{Bernoulli}(p)$, $\mu = p$, $\sigma^2 = pq$, $\rho = \mathbb{E}[|X - p|^3]$ 。

计算：

$$\rho = p^3q + q^3p = pq(p^2 + q^2)$$

$$\frac{\rho}{\sigma^3} = \frac{pq(p^2 + q^2)}{(pq)^{3/2}} = \frac{p^2 + q^2}{\sqrt{pq}} = \frac{1 - 2pq}{\sqrt{pq}}$$

当 $p = 0.5$ 时， $\frac{\rho}{\sigma^3} = \frac{0.5}{0.5} = 1$ ，误差 $\leq C/\sqrt{n} \approx 0.4748/\sqrt{n}$ 。

当 $p = 0.1$ 时， $\frac{\rho}{\sigma^3} = \frac{0.82}{\sqrt{0.09}} \approx 2.73$ ，收敛更慢，需要更大的 n 。

这解释了为什么偏态分布（ p 远离 0.5）需要更大的样本量才能保证正态近似的准确性。

非 i.i.d. 情形的推广

对独立但非同分布的情形，Berry-Esseen 不等式推广为：

$$\sup_x \left| P\left(\frac{S_n - \sum \mu_k}{s_n} \leq x\right) - \Phi(x) \right| \leq \frac{C \sum_{k=1}^n \mathbb{E}[|X_k - \mu_k|^3]}{s_n^3}$$

本章小结

定理	条件	结论	收敛速度
i.i.d. CLT (定理 11.1)	i.i.d., $\sigma^2 < \infty$	$Z_n \xrightarrow{d} \mathcal{N}(0, 1)$	$O(1/\sqrt{n})$
Lindeberg CLT (定理 11.2)	独立, Lindeberg 条件	$Z_n \xrightarrow{d} \mathcal{N}(0, 1)$	—
De Moivre-Laplace (定理 11.4)	$X \sim B(n, p)$	$(X - np)/\sqrt{npq} \xrightarrow{d} \mathcal{N}(0, 1)$	$O(1/\sqrt{n})$
Berry-Esseen (定理 11.5)	i.i.d., 三阶矩有限	$\sup_x F_n - \Phi \leq C\rho/(\sigma^3\sqrt{n})$	精确量化

核心思维方式：

1. CLT 是大数法则的”升级版”：大数法则说均值收敛到常数；CLT 说偏差的分布收敛到正态。
2. 正态分布的普遍性源于独立叠加：任何有限方差的分布，独立叠加足够多次后都趋向正态。
3. 适用边界：连续性修正在二项近似中不可忽视；Berry-Esseen 告诉我们 n 多大才够用，取决于原始分布的偏度。

深度学习应用：批量归一化（BatchNorm）的理论基础

问题背景：内部协变量偏移

深度神经网络训练时，每层的输入分布随参数更新而不断变化，称为内部协变量偏移（Internal Covariate Shift, ICS）。这导致：

- 深层网络需要不断适应前层分布的变化，训练变慢
- 梯度消失或爆炸问题加剧
- 对学习率的选择极为敏感

Batch Normalization (BatchNorm, BN) 通过在每层激活前对每个特征做归一化来缓解这一问题。

BatchNorm 的统计学本质

对一个 mini-batch $\mathcal{B} = \{x_1, x_2, \dots, x_m\}$ (m 为批大小)，对第 j 个特征维度，BatchNorm 计算：

第一步：计算批均值和批方差

$$\mu_{\mathcal{B}}^{(j)} = \frac{1}{m} \sum_{i=1}^m x_i^{(j)}, \quad \sigma_{\mathcal{B}}^{2(j)} = \frac{1}{m} \sum_{i=1}^m \left(x_i^{(j)} - \mu_{\mathcal{B}}^{(j)}\right)^2$$

第二步：标准化

$$\hat{x}_i^{(j)} = \frac{x_i^{(j)} - \mu_{\mathcal{B}}^{(j)}}{\sqrt{\sigma_{\mathcal{B}}^{2(j)} + \varepsilon}}$$

第三步：可学习的仿射变换

$$y_i^{(j)} = \gamma^{(j)} \hat{x}_i^{(j)} + \beta^{(j)}$$

其中 $\gamma^{(j)}$ （缩放）和 $\beta^{(j)}$ （偏移）为可学习参数。

与 CLT 的联系

BatchNorm 的统计理论基础与 CLT 密切相关，体现在以下几个层面：

层面一：标准化操作

BatchNorm 对每个特征做的标准化

$$\hat{x}^{(j)} = \frac{x^{(j)} - \mu_{\mathcal{B}}^{(j)}}{\sigma_{\mathcal{B}}^{(j)}}$$

正是 CLT 中的标准化变换 $Z_n = (S_n - n\mu)/(\sigma\sqrt{n})$ ，将任意均值和方差的分布映射到零均值单位方差的空间。

层面二：批均值的分布

由 CLT，若 mini-batch 中样本 i.i.d. 地来自分布 $\mathcal{D}$ （均值 μ ，方差 σ^2 ），则批均值

$$\mu_{\mathcal{B}} = \frac{1}{m} \sum_{i=1}^m x_i \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{m}\right) \quad (\text{由 CLT})$$

这意味着：批大小 m 越大，批统计量的估计越稳定，BatchNorm 的归一化效果越好。这也是实践中 BatchNorm 要求足够大的批大小（通常 ≥ 32 ）的数学原因。

层面三：激活值的近似正态性

考虑第 l 层的一个神经元，其激活值为：

$$z = \sum_{k=1}^d w_k a_k^{(l-1)}$$

其中 $a_k^{(l-1)}$ 是前一层的激活， d 是输入维度。若 w_k 和 a_k 近似独立，且 d 足够大，由 CLT：

$$z \approx \mathcal{N}\left(\sum_k w_k \mu_k, \sum_k w_k^2 \sigma_k^2\right)$$

这就是 Xavier/He 初始化的理论出发点——利用 CLT 来控制激活值的初始分布方差，使其在各层之间保持稳定。

PyTorch 代码示例：手动实现 BatchNorm 并验证 CLT

```
import torch
import torch.nn as nn
import torch.nn.functional as F
import numpy as np
import matplotlib.pyplot as plt
from scipy import stats

torch.manual_seed(42)
np.random.seed(42)

# 1. 手动实现 BatchNorm
class ManualBatchNorm1d(nn.Module):
    """
    手动实现的 BatchNorm1d，与 nn.BatchNorm1d 等价。
    展示每步的统计计算与 CLT 的对应关系。
    """
    def __init__(self, num_features: int, eps: float = 1e-5, momentum: float = 0.1):
        super().__init__()
        # 可学习仿射参数
        self.gamma = nn.Parameter(torch.ones(num_features)) # 缩放：初始化为 1
        self.beta = nn.Parameter(torch.zeros(num_features)) # 偏移：初始化为 0
        self.eps = eps
        self.momentum = momentum
        # 推断阶段使用的运行统计量（不参与梯度计算）
        self.register_buffer('running_mean', torch.zeros(num_features))
        self.register_buffer('running_var', torch.ones(num_features))

    def forward(self, x: torch.Tensor) -> torch.Tensor:
        """
        x: [batch_size, num_features]
        """
        if self.training:
            # 训练阶段：用 mini-batch 统计量归一化
            # 批均值：由 CLT, batch_size 越大，这个估计越接近真实均值
            batch_mean = x.mean(dim=0) # [num_features]
```



```

    # 批方差（有偏估计，分母为 m）
    batch_var = x.var(dim=0, unbiased=False)          # [num_features]

    # 标准化：这正是 CLT 中的 " 中心化 + 缩放 " 操作
    x_hat = (x - batch_mean) / torch.sqrt(batch_var + self.eps)

    # 更新运行统计量（用于推断阶段）
    self.running_mean = (1 - self.momentum) * self.running_mean + self.momentum * batch_mean
    self.running_var = (1 - self.momentum) * self.running_var + self.momentum * batch_var
else:
    # 推断阶段：用全量数据的运行统计量归一化
    x_hat = (x - self.running_mean) / torch.sqrt(self.running_var + self.eps)

    # 仿射变换：恢复网络表达能力（允许学习任意均值和方差）
    return self.gamma * x_hat + self.beta

# 2. 验证 CLT: 批均值的分布随批大小趋向正态
def verify_clt_in_batchnorm():
    """
    从指数分布（非正态）中采样，演示随批大小增大，批均值趋向正态分布。
    这直观展示了 BatchNorm 依赖 CLT 假设的数学基础。
    """
    # 原始分布：指数分布（高度右偏）
    rate = 1.0
    true_mean = 1.0 / rate    # = 1.0
    true_std = 1.0 / rate    # = 1.0

    batch_sizes = [1, 4, 16, 64]
    n_experiments = 5000      # 重复实验次数

    fig, axes = plt.subplots(1, 4, figsize=(14, 4))
    fig.suptitle('CLT 验证：指数分布的批均值分布随批大小趋向正态', fontsize=13)

    for ax, m in zip(axes, batch_sizes):
        # 每次实验：抽取 m 个样本，计算批均值
        batch_means = np.array([
            np.random.exponential(scale=1/rate, size=m).mean()
            for _ in range(n_experiments)
        ])

```

```

# CLT 预测的理论正态分布
clt_mean = true_mean
clt_std = true_std / np.sqrt(m)

# 绘制直方图
ax.hist(batch_means, bins=50, density=True, alpha=0.7,
        color='steelblue', label='批均值直方图')

# 叠加 CLT 预测的正态密度曲线
x_range = np.linspace(batch_means.min(), batch_means.max(), 200)
ax.plot(x_range, stats.norm.pdf(x_range, clt_mean, clt_std),
        'r-', linewidth=2, label=f'CLT 正态近似\mathcal{{N}}({clt_mean:.1f}, {clt_std:.3f})')

# Shapiro-Wilk 正态性检验
_, p_value = stats.shapiro(batch_means[:500]) # Shapiro-Wilk 样本限 5000

ax.set_title(f'批大小 m = {m}\nShapiro-Wilk p = {p_value:.3f}', fontsize=11)
ax.set_xlabel('批均值')
ax.legend(fontsize=8)

plt.tight_layout()
plt.savefig('clt_batchnorm_verification.png', dpi=150)
plt.show()

print(" 结论: p 值越大 (越接近 1), 越不能拒绝正态分布假设, 说明批均值越符合 CLT 预测。")

```

```

verify_clt_in_batchnorm()

```

3. BatchNorm 对训练稳定性的作用

```

class DeepNetWithBN(nn.Module):
    """ 带 BatchNorm 的深层网络 """
    def __init__(self, depth: int = 10, width: int = 64):
        super().__init__()
        layers = [nn.Linear(64, width), nn.BatchNorm1d(width), nn.ReLU()]
        for _ in range(depth - 2):
            layers += [nn.Linear(width, width), nn.BatchNorm1d(width), nn.ReLU()]
        layers += [nn.Linear(width, 1)]
        self.net = nn.Sequential(*layers)

```

```

def forward(self, x):
    return self.net(x)

class DeepNetNoBN(nn.Module):
    """ 不带 BatchNorm 的深层网络 (对照组) """
    def __init__(self, depth: int = 10, width: int = 64):
        super().__init__()
        layers = [nn.Linear(64, width), nn.ReLU()]
        for _ in range(depth - 2):
            layers += [nn.Linear(width, width), nn.ReLU()]
        layers += [nn.Linear(width, 1)]
        self.net = nn.Sequential(*layers)

    def forward(self, x):
        return self.net(x)

def train_and_monitor(model, x_train, y_train, n_epochs: int = 200):
    """ 训练模型并记录损失曲线 """
    optimizer = torch.optim.SGD(model.parameters(), lr=0.01)
    losses = []
    for epoch in range(n_epochs):
        model.train()
        optimizer.zero_grad()
        pred = model(x_train).squeeze()
        loss = F.mse_loss(pred, y_train)
        loss.backward()
        optimizer.step()
        losses.append(loss.item())
    return losses

# 合成回归数据
x_data = torch.randn(256, 64)
y_data = x_data[:, 0] + 0.5 * x_data[:, 1] + torch.randn(256) * 0.1

model_bn = DeepNetWithBN(depth=10)
model_nobn = DeepNetNoBN(depth=10)

losses_bn = train_and_monitor(model_bn, x_data, y_data)

```

```

losses_nobn = train_and_monitor(model_nobn, x_data, y_data)

plt.figure(figsize=(8, 4))
plt.plot(losses_bn, label='带 BatchNorm', linewidth=2)
plt.plot(losses_nobn, label='无 BatchNorm', linewidth=2, linestyle='--')
plt.xlabel('Epoch')
plt.ylabel('MSE 损失')
plt.title('BatchNorm 对深层网络训练稳定性的影响 (10 层, SGD lr=0.01)')
plt.legend()
plt.yscale('log')
plt.tight_layout()
plt.savefig('batchnorm_training_stability.png', dpi=150)
plt.show()

final_bn = losses_bn[-1]
final_nobn = losses_nobn[-1]
print(f" 最终损失 ——带 BN: {final_bn:.4f}, 无 BN: {final_nobn:.4f}")
print(f"BatchNorm 使最终损失降低了 {(final_nobn - final_bn) / final_nobn * 100:.1f}%")

# 4. 分析批大小对归一化质量的影响
print("\n=== CLT 角度分析：批大小对归一化质量的影响 ===")
print(f"{'批大小':>8} {'批均值方差':>15} {'CLT 预测方差':>15} {'相对误差':>12}")
print("-" * 55)

# 假设真实分布均值 =0, 标准差 =1 (例如权重初始化后的激活值)
true_var = 1.0
n_trials = 2000

for m in [4, 8, 16, 32, 64, 128]:
    # 模拟 n_trials 次批均值
    batch_means = torch.randn(n_trials, m).mean(dim=1)
    empirical_var = batch_means.var().item()
    clt_predicted = true_var / m
    rel_error = abs(empirical_var - clt_predicted) / clt_predicted

    print(f"{'m':>8} {'empirical_var':>15.6f} {'clt_predicted':>15.6f} {'rel_error':>11.2%}")

print("\n结论：批大小 32 时，批均值方差与 CLT 预测高度吻合，BatchNorm 的统计假设成立。")

```

实践要点总结

CLT 视角下 BatchNorm 的关键洞察：

批大小 m	批均值标准差 $\sigma/\sqrt{m}$	归一化稳定性	实践建议
$m = 1$	σ	极差，无统计意义	不可用 BN， 改用 LayerNorm
$m = 4$	$\sigma/2$	较差	慎用
$m = 16$	$\sigma/4$	尚可	最小可用批大小
$m = 32$	$\sigma/\sqrt{32} \approx \sigma/5.7$	良好	通常推荐
$m \geq 64$	$\leq \sigma/8$	优秀	最佳实践

小批量时的替代方案（均源于对 CLT 假设失效的补救）：

- **Layer Normalization**：对每个样本的所有特征做归一化，不依赖批大小
- **Group Normalization**：将特征分组后各组做归一化，折中方案
- **Instance Normalization**：每个样本各特征独立归一化，常用于图像风格迁移

练习题

题 1（基础）设 $X_1, X_2, \dots, X_{100}$ 为 i.i.d. 均匀分布 $U(0, 1)$ 的随机变量。令 $S_{100} = \sum_{i=1}^{100} X_i$ 。

- (a) S_{100} 的精确均值和方差是多少？
- (b) 利用中心极限定理，估计 $P(S_{100} > 55)$ 。
- (c) 估计 $P(48 \leq S_{100} \leq 52)$ 。

题 2（De Moivre-Laplace）某选手参加 $n = 400$ 次独立射击，每次命中概率为 $p = 0.6$ 。

- (a) 利用正态近似（含连续性修正），估计命中次数恰好为 240 的概率。
- (b) 估计命中次数在 $[230, 250]$ 之间的概率。
- (c) 若要使命中次数低于 220 的概率不超过 1%，需要 $p \geq ?$ （用 CLT 建立方程，不必求解析解）。

题 3（Lindeberg 条件验证）设 X_k 相互独立， $X_k \sim U(-k, k)$ ， $k = 1, 2, \dots, n$ 。

- (a) 计算 $\mathbb{E}[X_k]$ 和 $\text{Var}(X_k)$ ，以及 $s_n^2 = \sum_{k=1}^n \text{Var}(X_k)$ 。

(b) 验证 Lindeberg 条件：对任意 $\varepsilon > 0$, $L_n(\varepsilon) \rightarrow 0$ 。

(c) 由此结论, S_n/s_n 的极限分布是什么?

题 4 (Berry-Esseen 应用) 设 $X_i \sim \text{Exponential}(\lambda = 1)$ (均值 1, 方差 1, 三阶矩 $\mathbb{E}[X^3] = 6$)。

(a) 计算 $\mathbb{E}[|X_i - \mu|^3]$ (其中 $\mu = 1$)，提示：可用矩生成函数或直接积分。

(b) 利用 Berry-Esseen 定理 (取 $C = 0.4748$)，要使正态近似误差不超过 0.01，需要多大的 n ?

(c) 指数分布的偏度为 $\gamma_1 = 2$ (右偏)，这与你在 (b) 中得到的结果是否一致? 请解释。

题 5 (综合: CLT 与样本量设计) 某 A/B 测试中，控制组 (A) 和实验组 (B) 各取 n 个用户，分别记录其点击率 p_A 和 p_B (已知 $p_A = 0.10$ ，待检验 $p_B = 0.12$)。

(a) 设 $\hat{p}_A = \bar{X}_A$, $\hat{p}_B = \bar{X}_B$ 分别为两组样本比例，写出 $\hat{p}_B - \hat{p}_A$ 的渐近分布 (利用 CLT)。

(b) 为使以下两个条件同时成立，至少需要多大的 n ? - 第一类错误 $\alpha = 0.05$: 若 $p_A = p_B = 0.10$ ，错误地认为有差异的概率 $\leq 5\%$ - 第二类错误 $\beta = 0.20$: 若真实差异 $p_B - p_A = 0.02$ ，错过差异 (假阴性) 的概率 $\leq 20\%$

(c) 如果 p_A 增大到 0.40 (而差异仍为 0.02)，所需 n 如何变化? 从 CLT 的角度解释原因。

练习答案

题 1 详细解答

$X_i \sim U(0, 1)$: $\mu = 1/2$, $\sigma^2 = 1/12$, $\sigma = 1/\sqrt{12}$ 。

(a) 精确值

$$\mathbb{E}[S_{100}] = 100 \times \frac{1}{2} = 50$$

$$\text{Var}(S_{100}) = 100 \times \frac{1}{12} = \frac{25}{3} \approx 8.33, \quad \sigma_{S_{100}} = \sqrt{25/3} = \frac{5}{\sqrt{3}} \approx 2.887$$

(b) $P(S_{100} > 55)$

$$Z = \frac{S_{100} - 50}{5/\sqrt{3}}, \quad P(S_{100} > 55) \approx P\left(Z > \frac{55 - 50}{5/\sqrt{3}}\right) = P(Z > \sqrt{3}) = P(Z > 1.732)$$

$$= 1 - \Phi(1.73) \approx 1 - 0.9582 = \mathbf{0.0418}$$

(c) $P(48 \leq S_{100} \leq 52)$

$$\begin{aligned} P(48 \leq S_{100} \leq 52) &\approx \Phi\left(\frac{52-50}{5/\sqrt{3}}\right) - \Phi\left(\frac{48-50}{5/\sqrt{3}}\right) \\ &= \Phi\left(\frac{2\sqrt{3}}{5}\right) - \Phi\left(-\frac{2\sqrt{3}}{5}\right) = 2\Phi(0.693) - 1 \approx 2 \times 0.7557 - 1 = \mathbf{0.5114} \end{aligned}$$

题 2 详细解答

$X \sim B(400, 0.6)$, $\mu = np = 240$, $\sigma = \sqrt{npq} = \sqrt{400 \times 0.6 \times 0.4} = \sqrt{96} \approx 9.798$ 。

(a) $P(X = 240)$ (含连续性修正)

$$\begin{aligned} P(X = 240) &\approx \Phi\left(\frac{240.5 - 240}{9.798}\right) - \Phi\left(\frac{239.5 - 240}{9.798}\right) = \Phi(0.051) - \Phi(-0.051) \\ &= 2\Phi(0.051) - 1 \approx 2 \times 0.5203 - 1 = 0.0406 \end{aligned}$$

精确二项值约为 0.0408, 近似效果良好。

(b) $P(230 \leq X \leq 250)$ (含连续性修正)

$$\begin{aligned} P(230 \leq X \leq 250) &\approx \Phi\left(\frac{250.5 - 240}{9.798}\right) - \Phi\left(\frac{229.5 - 240}{9.798}\right) \\ &= \Phi(1.0717) - \Phi(-1.0717) = 2\Phi(1.072) - 1 \approx 2 \times 0.8581 - 1 = \mathbf{0.7162} \end{aligned}$$

(c) 建立方程

设 $P(X < 220) \leq 0.01$, 即:

$$P\left(\frac{X - 400p}{\sqrt{400p(1-p)}} < \frac{220 - 400p}{\sqrt{400p(1-p)}}\right) \leq 0.01$$

要求 $\Phi\left(\frac{220-400p}{20\sqrt{p(1-p)}}\right) \leq 0.01$, 即 $\frac{220-400p}{20\sqrt{p(1-p)}} \leq -2.326$ 。

整理为: $220 - 400p \leq -46.52\sqrt{p(1-p)}$, 即 $400p - 220 \geq 46.52\sqrt{p(1-p)}$ 。

题 3 详细解答

(a) 矩的计算

$X_k \sim U(-k, k)$: $\mathbb{E}[X_k] = 0$, $\text{Var}(X_k) = k^2/3$ (均匀分布 $U(-a, a)$ 的方差为 $a^2/3$)。

$$s_n^2 = \sum_{k=1}^n \frac{k^2}{3} = \frac{1}{3} \cdot \frac{n(n+1)(2n+1)}{6} \sim \frac{n^3}{9} \quad (n \rightarrow \infty)$$

(b) 验证 Lindeberg 条件

对 $|x| \leq k$ (X_k 的支撑), $|X_k| \leq k \leq \varepsilon s_n$ 。当 $\varepsilon s_n > k$ 时, $\{|X_k| > \varepsilon s_n\} = \emptyset$, 贡献为零。

由 $s_n \sim n^{3/2}/3$, 故对固定 $\varepsilon > 0$, 当 n 足够大时, $\varepsilon s_n > n$, 从而对所有 $k \leq n$, $\varepsilon s_n > k$, 每一项贡献均为零:

$$L_n(\varepsilon) = \frac{1}{s_n^2} \sum_{k=1}^n \mathbb{E}[X_k^2 \cdot \mathbf{1}_{\{|X_k| > \varepsilon s_n\}}] = 0 \rightarrow 0$$

Lindeberg 条件满足。

(c) 极限分布

由 Lindeberg CLT (定理 11.2):

$$\frac{S_n}{s_n} = \frac{\sum_{k=1}^n X_k}{s_n} \xrightarrow{d} \mathcal{N}(0, 1)$$

题 4 详细解答

$X \sim \text{Exp}(1)$, $\mu = 1$, $\sigma^2 = 1$, 密度 $f(x) = e^{-x}$ ($x > 0$)。

(a) 计算 $\rho = \mathbb{E}[|X - 1|^3]$

$$\rho = \int_0^\infty |x - 1|^3 e^{-x} dx = \int_0^1 (1 - x)^3 e^{-x} dx + \int_1^\infty (x - 1)^3 e^{-x} dx$$

利用分部积分, 或注意到:

$$\mathbb{E}[(X - 1)^3] = \mathbb{E}[X^3] - 3\mathbb{E}[X^2] + 3\mathbb{E}[X] - 1 = 6 - 3 \times 2 + 3 \times 1 - 1 = 2$$

对于 $\mathbb{E}[|X - 1|^3]$, 直接计算 (令 $u = x - 1$):

$$\rho = \int_{-1}^\infty |u|^3 e^{-(u+1)} du = e^{-1} \left[\int_0^\infty u^3 e^{-u} du + \int_{-1}^0 (-u)^3 e^{-u} du \right]$$

经计算, $\rho = 2$ 是 $\mathbb{E}[(X - 1)^3]$ 的无符号版 (偏度为正, $(X - 1)^3$ 以正为主), 精确值 $\rho \approx 2$ 。

更精确地: $\rho = \mathbb{E}[|X - 1|^3] = e^{-1}(6 + 2) = 8e^{-1} - 2 \approx 2.943$ (积分验算略)。

(b) 所需样本量

Berry-Esseen 误差 $\leq C\rho/(\sigma^3\sqrt{n}) = 0.4748 \times \rho/\sqrt{n} \leq 0.01$:

$$\sqrt{n} \geq \frac{0.4748 \times \rho}{0.01} \approx \frac{0.4748 \times 2.943}{0.01} \approx 139.7$$

$$n \geq 139.7^2 \approx 19516 \implies \boxed{n \geq 19517}$$

(c) 与偏度的联系

指数分布的偏度 $\gamma_1 = 2 > 0$ (右偏, 分布不对称), 与前文分析一致: 偏度越大, ρ/σ^3 越大, 收敛越慢, 需要更大的 n 。对比 $p = 0.5$ 的伯努利情形 (偏度为 0), 指数分布需要大得多的样本量 (约 2 万 vs 约 500), 体现了偏度对正态近似精度的显著影响。

题 5 详细解答

设 $X_{A,i} \sim \text{Bernoulli}(p_A)$, $X_{B,i} \sim \text{Bernoulli}(p_B)$, 两组独立。

(a) $\hat{p}_B - \hat{p}_A$ 的渐近分布

$$\hat{p}_A \approx \mathcal{N}\left(p_A, \frac{p_A(1-p_A)}{n}\right), \quad \hat{p}_B \approx \mathcal{N}\left(p_B, \frac{p_B(1-p_B)}{n}\right)$$

由独立性:

$$\hat{p}_B - \hat{p}_A \approx \mathcal{N}\left(p_B - p_A, \frac{p_A(1-p_A) + p_B(1-p_B)}{n}\right)$$

(b) 样本量计算

设 $p_A = p_B = p_0 = 0.10$, $\Delta = p_B - p_A = 0.02$ 。

第一类错误 ($\alpha = 0.05$): 在零假设 ($p_A = p_B = p_0$) 下, 合并方差为 $2p_0(1-p_0)/n$, 拒绝域为:

$$\left| \frac{\hat{p}_B - \hat{p}_A}{\sqrt{2p_0(1-p_0)/n}} \right| > z_{0.025} = 1.96$$

第二类错误 ($\beta = 0.20$): 在备择假设 ($\Delta = 0.02$) 下, 检验功效 $= 1 - \beta = 0.80$, 需要:

$$z_{\alpha/2} + z_\beta = 1.96 + 0.842 = 2.802$$

$$n = \left(\frac{(z_{\alpha/2} + z_\beta) \cdot \sqrt{p_A(1-p_A) + p_B(1-p_B)}}{\Delta} \right)^2$$

$$p_A(1-p_A) + p_B(1-p_B) = 0.10 \times 0.90 + 0.12 \times 0.88 = 0.090 + 0.1056 = 0.1956$$

$$n = \left(\frac{2.802 \times \sqrt{0.1956}}{0.02} \right)^2 = \left(\frac{2.802 \times 0.4423}{0.02} \right)^2 = \left(\frac{1.239}{0.02} \right)^2 = 61.95^2 \approx \mathbf{3838}$$

每组需要约 **3838** 个用户。

(c) $p_A = 0.40$ 时的变化

$$p_A(1 - p_A) + p_B(1 - p_B) = 0.40 \times 0.60 + 0.42 \times 0.58 = 0.240 + 0.2436 = 0.4836$$

$$n = \left(\frac{2.802 \times \sqrt{0.4836}}{0.02} \right)^2 = \left(\frac{2.802 \times 0.6954}{0.02} \right)^2 = \left(\frac{1.948}{0.02} \right)^2 = 97.4^2 \approx \mathbf{9487}$$

所需 n 从约 3838 增加到约 9487，增加了约 2.5 倍。

CLT 解释：伯努利分布的方差 $p(1 - p)$ 在 $p = 0.5$ 时最大（等于 0.25），在 p 远离 0.5 时减小。 $p_A = 0.40$ 时方差接近最大值，信噪比（固定差异 $\Delta = 0.02$ vs 更大的背景波动）更低，因此需要更大的样本量才能以相同的统计功效检测到相同的绝对差异。这正是 CLT 中方差与样本量之间关系的直接体现： σ^2 增大时，需要更大的 n 来保证 σ^2/n 足够小。

下一章预告：第 12 章：收敛性理论 — 我们将深入讨论依概率收敛、依分布收敛、几乎必然收敛等不同收敛模式，理解它们之间的关系，为概率极限理论画上完整的句号。

第 12 章：收敛性理论

学习目标

学完本章后，你将能够：

- 掌握四种收敛概念（依概率、依分布、几乎必然、 L^p ）的严格定义，并理解各自的直觉含义
 - 理解“几乎必然收敛”（强收敛）与“依概率收敛”（弱收敛）的本质区别，能用反例说明二者不等价
 - 熟记并证明四种收敛之间的蕴含关系图，掌握各方向成立或不成立的条件
 - 运用连续映射定理、Slutsky 定理和 δ 方法处理依分布收敛的复合运算
 - 将收敛理论应用于深度学习模型的训练收敛性分析与 PAC 学习理论的样本复杂度推导
-

12.1 依概率收敛

直觉引入

想象你用一把有随机误差的尺子反复量同一根棍子的长度。每次测量结果 X_n 都有波动，但随着测量技术改进，出现“大误差”的可能性越来越小。这种“犯大错的概率趋于零”的收敛方式，就是依概率收敛。

严格定义

定义 12.1 (依概率收敛) 设 $X_1, X_2, \dots$ 和 X 是定义在同一概率空间 $(\Omega, \mathcal{F}, P)$ 上的随机变量。若对任意 $\varepsilon > 0$,

$$P(|X_n - X| > \varepsilon) \rightarrow 0 \quad (n \rightarrow \infty)$$

则称 X_n 依概率收敛 (converge in probability) 到 X , 记作

$$X_n \xrightarrow{P} X \quad \text{或} \quad \text{plim}_{n \rightarrow \infty} X_n = X$$

等价刻画

以下三条陈述等价:

1. $X_n \xrightarrow{P} X$
2. 对任意 $\varepsilon > 0$, $P(|X_n - X| \leq \varepsilon) \rightarrow 1$
3. 对任意 $\varepsilon > 0$, $\delta > 0$, 存在 N 使得 $n > N$ 时 $P(|X_n - X| > \varepsilon) < \delta$

注意: “依概率收敛到 X ”不要求 $X_n(\omega) \rightarrow X(\omega)$ 对每个样本点 ω 成立, 只要求违反此收敛的样本点集合的概率趋于零。

基本性质

命题 12.1 (依概率收敛的运算规则) 若 $X_n \xrightarrow{P} X$, $Y_n \xrightarrow{P} Y$, 则:

1. $aX_n + bY_n \xrightarrow{P} aX + bY$ (线性性)
2. $X_n Y_n \xrightarrow{P} XY$ (乘积性)
3. 若 g 连续, 则 $g(X_n) \xrightarrow{P} g(X)$ (连续映射定理)
4. 若 $P(Y = 0) = 0$, 则 $X_n/Y_n \xrightarrow{P} X/Y$

证明 (性质 1): 对任意 $\varepsilon > 0$,

$$\{|aX_n + bY_n - aX - bY| > \varepsilon\} \subseteq \left\{|X_n - X| > \frac{\varepsilon}{2|a|}\right\} \cup \left\{|Y_n - Y| > \frac{\varepsilon}{2|b|}\right\}$$

(当 $a, b \neq 0$ 时, $a = 0$ 时更简单) 由次可加性,

$$P(|aX_n + bY_n - aX - bY| > \varepsilon) \leq P\left(|X_n - X| > \frac{\varepsilon}{2|a|}\right) + P\left(|Y_n - Y| > \frac{\varepsilon}{2|b|}\right) \rightarrow 0$$

■

Markov 不等式与 Chebyshev 不等式

依概率收敛常通过以下工具建立:

Markov 不等式: 对非负随机变量 Y 和 $a > 0$,

$$P(Y \geq a) \leq \frac{\mathbb{E}[Y]}{a}$$

Chebyshev 不等式: 对任意随机变量 X 和 $\varepsilon > 0$,

$$P(|X - \mu| \geq \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2}$$

示例: 设 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ (i.i.d., 均值 μ , 方差 $\sigma^2 < \infty$), 则

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0$$

这正是弱大数定律的一种证明: $\bar{X}_n \xrightarrow{P} \mu$ 。

依概率收敛的局限性

依概率收敛不保证: - 每条样本路径都收敛 (可能有“游荡”行为) - 期望的收敛: $X_n \xrightarrow{P} 0$ 不能推出 $\mathbb{E}[X_n] \rightarrow 0$

反例 (期望不收敛): 令 $P(X_n = n) = 1/n$, $P(X_n = 0) = 1 - 1/n$ 。则 $X_n \xrightarrow{P} 0$, 但 $\mathbb{E}[X_n] = 1$ 不趋于零。

12.2 依分布收敛 (弱收敛)

定义

定义 12.2 (依分布收敛) 设 $X_1, X_2, \dots$ 和 X 是随机变量, F_n 和 F 分别为其分布函数。若在 F 的每个连续点 x 处均有

$$F_n(x) \rightarrow F(x) \quad (n \rightarrow \infty)$$

则称 X_n 依分布收敛 (converge in distribution) 到 X , 记作

$$X_n \xrightarrow{d} X \quad \text{或} \quad X_n \rightsquigarrow X$$

也称为弱收敛 (weak convergence)。

为何只要求连续点处收敛：分布函数 F 可能在某些点有跳跃 (如离散分布)，在跳跃点处 $F_n(x) \rightarrow F(x)$ 可能不成立即使整体分布收敛，因此只在连续点处要求收敛是自然的选择。

与特征函数的等价刻画

定理 12.1 (Lévy 连续性定理) $X_n \xrightarrow{d} X$ 当且仅当对每个 $t \in \mathbb{R}$, X_n 的特征函数 $\varphi_n(t) \rightarrow \varphi(t)$, 且 φ 在 $t = 0$ 处连续。

这是中心极限定理证明的核心工具 (见第 11 章)。

依分布收敛的等价刻画 (Portmanteau 定理)

定理 12.2 (Portmanteau 定理) 以下陈述等价：

1. $X_n \xrightarrow{d} X$
2. 对所有有界连续函数 $f: \mathbb{E}[f(X_n)] \rightarrow \mathbb{E}[f(X)]$
3. 对所有闭集 $F: \limsup_n P(X_n \in F) \leq P(X \in F)$
4. 对所有开集 $G: \liminf_n P(X_n \in G) \geq P(X \in G)$
5. 对所有 Borel 集 B 满足 $P(X \in \partial B) = 0: P(X_n \in B) \rightarrow P(X \in B)$

直觉：条件 2 说明依分布收敛等价于所有“有界连续测试函数”的期望收敛，这是弱收敛名称的由来——它是函数空间中的弱拓扑意义下的收敛。

依分布收敛的重要性质

定理 12.3 (连续映射定理, CMT) 若 $X_n \xrightarrow{d} X$, g 是连续函数 (或更一般地, $P(X \in \text{Disc}(g)) = 0$), 则

$$g(X_n) \xrightarrow{d} g(X)$$

定理 12.4 (Slutsky 定理) 若 $X_n \xrightarrow{d} X$, $Y_n \xrightarrow{P} c$ (常数), 则:

$$X_n + Y_n \xrightarrow{d} X + c, \quad X_n Y_n \xrightarrow{d} cX$$

注意：若 $Y_n \xrightarrow{d} Y$ (Y 非常数)，则一般不能得出 $X_n + Y_n \xrightarrow{d} X + Y$ (联合分布未必收敛)。

定理 12.5 (δ 方法) 设 $\sqrt{n}(X_n - \theta) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$, g 在 θ 处可微且 $g'(\theta) \neq 0$, 则

$$\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{d} \mathcal{N}(0, [g'(\theta)]^2 \sigma^2)$$

证明思路：Taylor 展开 $g(X_n) \approx g(\theta) + g'(\theta)(X_n - \theta)$, 再用 Slutsky 定理。■

δ 方法示例：设 $\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$, 取 $g(x) = e^x$, 则

$$\sqrt{n}(e^{\bar{X}_n} - e^\mu) \xrightarrow{d} \mathcal{N}(0, e^{2\mu} \sigma^2)$$

依分布收敛只是“分布层面”的收敛

依分布收敛是最弱的一种随机收敛, 它不要求 X_n 和 X 定义在同一概率空间上, 也不要求 $X_n(\omega) - X(\omega) \rightarrow 0$ 。

极端例子：设 $X_n \equiv X \sim \mathcal{N}(0, 1)$, 但令 $Y_n = -X$ (与 X 反号)。则 $Y_n \xrightarrow{d} \mathcal{N}(0, 1)$ (依分布等于 X), 但 $Y_n - X_n = -2X$ 并不趋于零。这说明“依分布相同”不等于“轨道上接近”。

12.3 几乎必然收敛 (强收敛)

定义

定义 12.3 (几乎必然收敛) 若

$$P\left(\lim_{n \rightarrow \infty} X_n = X\right) = P(\{\omega : X_n(\omega) \rightarrow X(\omega)\}) = 1$$

则称 X_n 几乎必然收敛 (converge almost surely) 到 X , 记作

$$X_n \xrightarrow{a.s.} X \quad \text{或} \quad X_n \rightarrow X \quad \text{a.s.}$$

也称以概率 1 收敛 (converge with probability one) 或强收敛。

几乎必然收敛的直觉

定义在概率空间 Ω 上, 几乎必然收敛要求: 除了一个零概率集 N 以外, 对每个样本点 $\omega \notin N$, 数列 $X_1(\omega), X_2(\omega), \dots$ 像普通实数数列一样收敛到 $X(\omega)$ 。

用 $\limsup$ 和 $\liminf$ 改写：

$$X_n \xrightarrow{a.s.} X \iff P\left(\limsup_{n \rightarrow \infty} |X_n - X| > 0\right) = 0$$

等价地（用上极限集合）：对任意 $\varepsilon > 0$,

$$X_n \xrightarrow{a.s.} X \iff P\left(\limsup_{n \rightarrow \infty} \{|X_n - X| > \varepsilon\}\right) = 0$$

即

$$P\left(\bigcap_{N=1}^{\infty} \bigcup_{n=N}^{\infty} \{|X_n - X| > \varepsilon\}\right) = 0$$

几乎必然收敛的等价条件

命题 12.2 $X_n \xrightarrow{a.s.} X$ 当且仅当对任意 $\varepsilon > 0$,

$$P\left(\sup_{k \geq n} |X_k - X| > \varepsilon\right) \rightarrow 0 \quad (n \rightarrow \infty)$$

这个条件说明： X_n 之后的所有项都接近 X 的概率趋于 1——这比依概率收敛更强，后者只要求第 n 项接近 X 。

Borel-Cantelli 引理与几乎必然收敛

引理 12.1 (Borel-Cantelli 第一引理) 若 $\sum_{n=1}^{\infty} P(A_n) < \infty$, 则 $P(\limsup_{n \rightarrow \infty} A_n) = 0$ (即无穷多个 A_n 同时发生的概率为零)。

推论 (充分条件): 若对每个 $\varepsilon > 0$, $\sum_{n=1}^{\infty} P(|X_n - X| > \varepsilon) < \infty$, 则 $X_n \xrightarrow{a.s.} X$ 。

引理 12.2 (Borel-Cantelli 第二引理) 若事件 $\{A_n\}$ 相互独立, 且 $\sum_{n=1}^{\infty} P(A_n) = \infty$, 则 $P(\limsup_{n \rightarrow \infty} A_n) = 1$ 。

示例: 强大数定律 (SLLN) 的核心结论即 $\bar{X}_n \xrightarrow{a.s.} \mu$, 通常用 Borel-Cantelli 引理或鞅理论证明 (见第 10 章)。

几乎必然收敛的逐路径性质

命题 12.3 (运算封闭性) 若 $X_n \xrightarrow{a.s.} X$, $Y_n \xrightarrow{a.s.} Y$, g 连续, 则

$$aX_n + bY_n \xrightarrow{a.s.} aX + bY, \quad g(X_n) \xrightarrow{a.s.} g(X)$$

这是因为在 a.s. 的路径集合上, 极限运算与普通实数极限的运算规则完全相同。

典型反例：依概率收敛但不几乎必然收敛

“打字机序列” (Typewriter Sequence)

设 $\Omega = [0, 1]$, P 为 Lebesgue 测度。构造如下随机变量序列 (按行排列指示函数):

$$\begin{aligned} X_1 &= \mathbf{1}_{[0,1]}, & X_2 &= \mathbf{1}_{[0,1/2]}, & X_3 &= \mathbf{1}_{[1/2,1]}, \\ X_4 &= \mathbf{1}_{[0,1/3]}, & X_5 &= \mathbf{1}_{[1/3,2/3]}, & X_6 &= \mathbf{1}_{[2/3,1]}, & \dots \end{aligned}$$

一般地, 第 $2^k + j$ ($0 \leq j < 2^k$) 个随机变量为 $\mathbf{1}_{[j/2^k, (j+1)/2^k]}$ 。

- 依概率: $P(|X_n - 0| > \varepsilon) = P(X_n = 1) = \text{相应区间长度} \rightarrow 0$, 故 $X_n \xrightarrow{P} 0$ 。
- 几乎必然: 对任意 $\omega \in [0, 1]$, $X_n(\omega)$ 无穷次等于 1 (每次 ω 被某个区间覆盖), 故数列 $\{X_n(\omega)\}$ 不收敛到 0, $X_n \not\rightarrow a.s. 0$ 。

这个例子清晰地展示: 依概率收敛不蕴含几乎必然收敛。

12.4 L^p 收敛与均方收敛

L^p 空间与范数

定义 12.4 (L^p 范数) 对 $p \geq 1$, 随机变量 X 的 L^p 范数为

$$\|X\|_p = (\mathbb{E}[|X|^p])^{1/p}$$

L^p 空间为所有 p 阶矩有限的随机变量的集合: $L^p = \{X : \mathbb{E}[|X|^p] < \infty\}$ 。

定义 12.5 (L^p 收敛) 若

$$\boxed{\mathbb{E}[|X_n - X|^p] \rightarrow 0 \quad (n \rightarrow \infty)}$$

则称 X_n 在 L^p 意义下收敛 (converge in L^p) 到 X , 记作

$$X_n \xrightarrow{L^p} X \quad \text{或} \quad X_n \xrightarrow{p} X \text{ (} p \text{ 阶矩收敛)}$$

均方收敛 (L^2 收敛)

最重要的特殊情形是 $p = 2$:

定义 12.6 (均方收敛) 若

$$\mathbb{E}[(X_n - X)^2] \rightarrow 0 \quad (n \rightarrow \infty)$$

则称 X_n 均方收敛 (converge in mean square) 到 X , 记作 $X_n \xrightarrow{m.s.} X$ 或 $X_n \xrightarrow{L^2} X$ 。

均方收敛与期望、方差的关系:

$$\mathbb{E}[(X_n - X)^2] = \text{Var}(X_n - X) + (\mathbb{E}[X_n] - \mathbb{E}[X])^2$$

因此均方收敛要求均值收敛且方差趋于零。

 L^p 收敛的基本不等式

Jensen 不等式 (ϕ 凸): $\phi(\mathbb{E}[X]) \leq \mathbb{E}[\phi(X)]$

Hölder 不等式: $\mathbb{E}[|XY|] \leq \|X\|_p \|Y\|_q$ ($1/p + 1/q = 1$)

Minkowski 不等式: $\|X + Y\|_p \leq \|X\|_p + \|Y\|_p$ (三角不等式)

L^p 空间的嵌套 (由 Jensen): 若 $p \geq q \geq 1$, 则

$$\|X\|_q \leq \|X\|_p \cdot (\text{vol}(\Omega))^{1/q - 1/p}$$

在有限测度空间 (概率空间) 中: $L^p \subseteq L^q$ ($p \geq q$), 即高阶矩有限蕴含低阶矩有限。

推论: $X_n \xrightarrow{L^p} X$ ($p \geq q$) $\Rightarrow X_n \xrightarrow{L^q} X$ 。

 L^p 收敛与期望的关系

命题 12.4: 若 $X_n \xrightarrow{L^p} X$ ($p \geq 1$), 则:

1. $\mathbb{E}[|X_n|^p] \rightarrow \mathbb{E}[|X|^p]$ (p 阶矩收敛)
2. 若 $p \geq 1$: $\mathbb{E}[X_n] \rightarrow \mathbb{E}[X]$ (可以在积分号下取极限)

证明 (2): 由 Hölder 不等式 (取 $q = 1, p = 1$ 或直接用 Markov):

$$|\mathbb{E}[X_n] - \mathbb{E}[X]| \leq \mathbb{E}[|X_n - X|] = \|X_n - X\|_1 \leq \|X_n - X\|_p \rightarrow 0$$

■

均方收敛的判别准则

充分条件（二阶矩准则）：若

$$\mathbb{E}[X_n^2] \rightarrow c < \infty \quad \text{且} \quad \mathbb{E}[X_n X_m] \rightarrow c \quad (n, m \rightarrow \infty)$$

则 $\{X_n\}$ 是 L^2 中的 Cauchy 序列，从而存在 L^2 极限 X (L^2 空间完备)。

示例（WLLN 的均方版本）：设 X_i i.i.d., 均值 μ , 方差 $\sigma^2 < \infty$, 则

$$\mathbb{E}[(\bar{X}_n - \mu)^2] = \frac{\sigma^2}{n} \rightarrow 0$$

故 $\bar{X}_n \xrightarrow{L^2} \mu$, 这比依概率收敛（WLLN）的结论更强。

一致可积与 L^1 收敛

定义 12.7（一致可积，UI）随机变量族 $\{X_n\}$ 称为一致可积，若

$$\lim_{M \rightarrow \infty} \sup_n \mathbb{E}[|X_n| \cdot \mathbf{1}_{\{|X_n| > M\}}] = 0$$

定理 12.6: $X_n \xrightarrow{L^1} X$ 当且仅当 $X_n \xrightarrow{P} X$ 且 $\{X_n\}$ 一致可积。

这是联系依概率收敛与 L^1 收敛的关键桥梁。

12.5 收敛性之间的关系

蕴含关系总图

四种收敛之间的关系如下 ($\Rightarrow$ 表示蕴含, $\nRightarrow$ 表示一般不蕴含):

$$\underbrace{X_n \xrightarrow{a.s.}}_{\text{几乎必然}} \Rightarrow \underbrace{X_n \xrightarrow{P}}_{\text{依概率}} \Rightarrow \underbrace{X_n \xrightarrow{d}}_{\text{依分布}}$$

$$\underbrace{X_n \xrightarrow{L^p}}_{L^p \text{ 收敛}} \Rightarrow \underbrace{X_n \xrightarrow{P}}_{\text{依概率}}$$

$$X_n \xrightarrow{L^p} \Rightarrow X_n \xrightarrow{L^q} \quad (p \geq q \geq 1)$$

关键不等式方向（不成立）：

$$X_n \xrightarrow{P} \not\Rightarrow X_n \xrightarrow{a.s.} \quad (\text{打字机序列反例})$$

$$X_n \xrightarrow{P} \not\Rightarrow X_n \xrightarrow{L^p} \quad (\text{需要矩条件})$$

$$X_n \xrightarrow{d} \not\Rightarrow X_n \xrightarrow{P} \quad (\text{极限须为常数时例外})$$

$$X_n \xrightarrow{a.s.} \not\Rightarrow X_n \xrightarrow{L^p} \quad (\text{需要一致可积性})$$

定理：a.s. 收敛蕴含依概率收敛

定理 12.7: 若 $X_n \xrightarrow{a.s.} X$, 则 $X_n \xrightarrow{P} X$ 。

证明：对任意 $\varepsilon > 0$,

$$\{|X_n - X| > \varepsilon\} \subseteq \bigcup_{k=n}^{\infty} \{|X_k - X| > \varepsilon\}$$

故

$$P(|X_n - X| > \varepsilon) \leq P\left(\bigcup_{k=n}^{\infty} \{|X_k - X| > \varepsilon\}\right)$$

由 a.s. 收敛, $P(\bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} \{|X_k - X| > \varepsilon\}) = 0$, 即

$$P\left(\bigcup_{k=n}^{\infty} \{|X_k - X| > \varepsilon\}\right) \rightarrow 0 \quad (n \rightarrow \infty)$$

（单调集合列，极限为零集的概率）因此 $P(|X_n - X| > \varepsilon) \rightarrow 0$ 。■

定理： L^p 收敛蕴含依概率收敛

定理 12.8: 若 $X_n \xrightarrow{L^p} X$ ($p \geq 1$), 则 $X_n \xrightarrow{P} X$ 。

证明：由 Markov 不等式（对 $|X_n - X|^p$ ）：

$$P(|X_n - X| > \varepsilon) = P(|X_n - X|^p > \varepsilon^p) \leq \frac{\mathbb{E}[|X_n - X|^p]}{\varepsilon^p} \rightarrow 0$$

■

定理：依概率收敛蕴含依分布收敛

定理 12.9: 若 $X_n \xrightarrow{P} X$, 则 $X_n \xrightarrow{d} X$ 。

证明: 对任意连续有界函数 f , 因 f 一致连续(紧集上), 对 $\varepsilon > 0$ 存在 $\delta > 0$ 使得 $|x-y| < \delta \Rightarrow |f(x)-f(y)| < \varepsilon$ 。

$$|\mathbb{E}[f(X_n)] - \mathbb{E}[f(X)]| \leq \mathbb{E}[|f(X_n) - f(X)|]$$

$$\leq \varepsilon + 2\|f\|_{\infty} \cdot P(|X_n - X| \geq \delta) \rightarrow \varepsilon$$

由 ε 的任意性结论成立。■

特殊情形：依分布收敛到常数等价于依概率收敛

定理 12.10: $X_n \xrightarrow{d} c$ (常数) 当且仅当 $X_n \xrightarrow{P} c$ 。

证明 ($\Rightarrow$ 方向): $P(|X_n - c| > \varepsilon) = P(X_n > c + \varepsilon) + P(X_n < c - \varepsilon)$ 。

$$P(X_n > c + \varepsilon) = 1 - F_n(c + \varepsilon) \rightarrow 1 - F(c + \varepsilon) = 1 - 1 = 0$$

$$P(X_n < c - \varepsilon) = F_n((c - \varepsilon)^-) \rightarrow F((c - \varepsilon)^-) = 0$$

(常数 c 的分布函数 $F(x) = \mathbf{1}_{[c, \infty)}(x)$, 在 $c \pm \varepsilon$ 处均连续) ■

重要推论 (Slutsky 定理的基础): 大数定律给出的 $\bar{X}_n \xrightarrow{P} \mu$, 结合 CLT 的 $\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$, 正是这两种收敛在统计中的典型组合。

Skorokhod 表示定理

定理 12.11 (Skorokhod 表示定理) 若 $X_n \xrightarrow{d} X$ (取值于可分度量空间), 则存在定义在同一概率空间上的随机变量 $\tilde{X}_n$ 和 $\tilde{X}$, 使得:

$$\tilde{X}_n \stackrel{d}{=} X_n, \quad \tilde{X} \stackrel{d}{=} X, \quad \text{且} \quad \tilde{X}_n \xrightarrow{a.s.} \tilde{X}$$

意义: 定理允许我们”把依分布收敛提升为几乎必然收敛”(通过重新选择概率空间)。这是很多极限定理证明的重要技巧: 先在 Skorokhod 空间里用 a.s. 收敛做运算, 再”翻译”回分布结论。

收敛关系的反例汇总

反例类型	构造	说明哪个蕴含不成立
打字机序列	$X_n = \mathbf{1}_{[j/2^k, (j+1)/2^k]}$	$\xrightarrow{P}$ 不蕴含 $\xrightarrow{a.s.}$
尖峰序列	$X_n = n \cdot \mathbf{1}_{[0, 1/n]}$	$\xrightarrow{a.s.}$ 不蕴含 $\xrightarrow{L^1}$
分布收敛到非常数	$X_n \sim \mathcal{N}(0, 1)$ (独立)	$\xrightarrow{d}$ 不蕴含 $\xrightarrow{P}$
期望不收敛	$P(X_n = n) = 1/n, P(X_n = 0) = 1 - 1/n$	$\xrightarrow{P}$ 不蕴含 $\xrightarrow{L^1}$

本章小结

四种收敛的比较

收敛类型	符号	定义核心	强弱排序	典型应用
几乎必然收敛 (a.s.)	$X_n \xrightarrow{a.s.} X$	$P(\omega : X_n(\omega) \rightarrow X(\omega)) = 1$	最强 (路径层面)	强大数定律
L^p 收敛	$X_n \xrightarrow{L^p} X$	$\mathbb{E}[X_n - X ^p] \rightarrow 0$	较强 (矩层面)	均方误差收敛、矩估计
依概率收敛	$X_n \xrightarrow{P} X$	$P(X_n - X > \varepsilon) \rightarrow 0$	中等 (概率层面)	弱大数定律、相合估计
依分布收敛	$X_n \xrightarrow{d} X$	$F_n(x) \rightarrow F(x)$ 在连续点	最弱 (分布层面)	中心极限定理、渐近理论

蕴含关系总结

$$\xrightarrow{a.s.} \implies \xrightarrow{P} \implies \xrightarrow{d}$$

$$\xrightarrow{L^p} \implies \xrightarrow{L^q} \text{ (} p \geq q \text{)} \implies \xrightarrow{P} \implies \xrightarrow{d}$$

附加条件下的逆方向：

逆蕴含	所需附加条件
$\xrightarrow{P} \Rightarrow \xrightarrow{a.s.}$	可取子列（必存在几乎必然收敛子列）
$\xrightarrow{P} \Rightarrow \xrightarrow{L^p}$	一致可积性 ($p = 1$) 或有界性
$\xrightarrow{d} \Rightarrow \xrightarrow{P}$	极限为常数
$\xrightarrow{a.s.} \Rightarrow \xrightarrow{L^p}$	一致可积 ($p \geq 1$) 或有界 ($ X_n \leq Y \in L^p$)

子列原理（常用工具）： $X_n \xrightarrow{P} X$ 当且仅当对 X_n 的任意子列，存在进一步的子列几乎必然收敛到 X 。

深度学习应用：模型收敛性分析与 PAC 学习理论

背景：为什么收敛理论在深度学习中至关重要

深度学习的理论基础在很大程度上依赖于本章所讨论的各种收敛概念：

- 模型训练：损失函数是否收敛？以何种方式收敛（a.s.、依概率还是均方）？
- 泛化理论：训练误差与测试误差之差是否依概率趋于零？
- PAC 学习：样本量多大才能以高概率近似正确地学习到目标概念？

这些问题的回答都需要精确的收敛性语言。

12.6.1 随机梯度下降（SGD）的收敛性

考虑最小化期望风险 $L(\theta) = \mathbb{E}[\ell(\theta; Z)]$ ，其中 Z 为训练数据。

SGD 更新规则（第 t 步）：

$$\theta_{t+1} = \theta_t - \eta_t \nabla_{\theta} \ell(\theta_t; Z_t)$$

其中 Z_t 为第 t 步随机抽取的样本（或 mini-batch）， $\eta_t > 0$ 为学习率。

梯度估计量的性质：设 $g_t = \nabla_{\theta} \ell(\theta_t; Z_t)$ ，由于 Z_t 随机，

$$\mathbb{E}[g_t | \theta_t] = \mathbb{E}_Z[\nabla_{\theta} \ell(\theta_t; Z)] = \nabla_{\theta} L(\theta_t) \quad (\text{无偏})$$

$$\text{Var}(g_t) = \mathbb{E}[\|g_t - \nabla L(\theta_t)\|^2] \triangleq \sigma_t^2 \quad (\text{方差随批大小减小})$$

定理（SGD 依概率收敛）：在 Lipschitz 梯度（ L -smooth）和有界方差假设下，若学习率满足 Robbins-Monro 条件

$$\sum_{t=1}^{\infty} \eta_t = \infty, \quad \sum_{t=1}^{\infty} \eta_t^2 < \infty \quad (\text{如 } \eta_t = c/t)$$

则 $\min_{t \leq T} \mathbb{E}[\|\nabla L(\theta_t)\|^2] \rightarrow 0$ (找到近似稳定点), 对非凸问题这是依概率意义下的收敛。

与四种收敛的对应关系:

收敛类型	在 SGD 中对应	所需条件
依分布收敛	参数分布趋向平稳分布	学习率衰减
依概率收敛	θ_t 以高概率接近最优点	凸或 PL 条件, 方差有界
均方收敛	$\mathbb{E}[\ \theta_t - \theta^*\ ^2] \rightarrow 0$	强凸, 常数学习率 (有偏差)
几乎必然收敛	几乎所有训练路径都收敛	较强假设, 如 Polyak 步长

12.6.2 PAC 学习理论中的收敛性

PAC (Probably Approximately Correct) 学习框架由 Leslie Valiant 在 1984 年提出, 是机器学习泛化理论的基石。

基本设置: - 输入空间 $\mathcal{X}$, 标签空间 $\mathcal{Y} = \{0, 1\}$ - 未知数据分布 $\mathcal{D}$ 定义在 $\mathcal{X} \times \mathcal{Y}$ 上 - 假设类 $\mathcal{H}$ (模型族) - 训练集 $S = \{(x_1, y_1), \dots, (x_n, y_n)\}$, i.i.d. 来自 $\mathcal{D}$

风险定义: - 真实风险 (泛化误差): $R(h) = \mathbb{E}_{(x,y) \sim \mathcal{D}}[\mathbf{1}(h(x) \neq y)]$ - 经验风险 (训练误差): $\hat{R}_n(h) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(h(x_i) \neq y_i)$

核心问题: 何时 $\hat{R}_n(h) \xrightarrow{P} R(h)$ (一致地对所有 $h \in \mathcal{H}$)?

定理 12.12 (均匀大数定律, ULLN) 若 $\mathcal{H}$ 的 Rademacher 复杂度 $\mathfrak{R}_n(\mathcal{H}) \rightarrow 0$, 则

$$\sup_{h \in \mathcal{H}} |R(h) - \hat{R}_n(h)| \xrightarrow{P} 0$$

定理 12.13 (有限假设类的 PAC 界) 设 $|\mathcal{H}| < \infty$, 则以概率至少 $1 - \delta$, 对所有 $h \in \mathcal{H}$,

$$R(h) \leq \hat{R}_n(h) + \sqrt{\frac{\ln |\mathcal{H}| + \ln(1/\delta)}{2n}}$$

证明思路: 1. 对固定 h , 由 Hoeffding 不等式 (i.i.d. 有界随机变量):

$$P(R(h) - \hat{R}_n(h) > \varepsilon) \leq \exp(-2n\varepsilon^2)$$

2. Union bound (联合界) 对所有 $h \in \mathcal{H}$:

$$P\left(\sup_{h \in \mathcal{H}} (R(h) - \hat{R}_n(h)) > \varepsilon\right) \leq |\mathcal{H}| \cdot \exp(-2n\varepsilon^2)$$

3. 令右端 = δ , 解出 $\varepsilon = \sqrt{\frac{\ln|\mathcal{H}| + \ln(1/\delta)}{2n}}$ 。 ■

PAC 界的收敛语言解读: 该界说明 $\sup_h |R(h) - \hat{R}_n(h)| = O_P(1/\sqrt{n})$, 即依概率以 $O(1/\sqrt{n})$ 速率收敛到零, 这正是依概率收敛的量化版本。

PyTorch 代码示例：模型收敛性监测与 PAC 界验证

```
import torch
import torch.nn as nn
import torch.optim as optim
import numpy as np
import matplotlib.pyplot as plt
from torch.utils.data import DataLoader, TensorDataset
```

```
torch.manual_seed(42)
```

```
np.random.seed(42)
```

1. 合成二分类数据

```
def make_dataset(n: int, d: int = 20):
    """
    生成 n 个 d 维样本的线性可分二分类数据。
    真实分类器:  $w^* = e_1$  (仅依赖第一个特征)。
    """
    X = torch.randn(n, d)
    y = (X[:, 0] > 0).long() # 真实标签
    return X, y
```

2. 简单线性分类器

```
class LinearClassifier(nn.Module):
    def __init__(self, d: int):
        super().__init__()
        self.fc = nn.Linear(d, 1)

    def forward(self, x):
        return self.fc(x).squeeze()
```



```
def predict(self, x):
    return (self.forward(x) > 0).long()
```

3. 训练并记录收敛过程

```
def train_and_track_convergence(
    model: nn.Module,
    X_train: torch.Tensor,
    y_train: torch.Tensor,
    X_test: torch.Tensor,
    y_test: torch.Tensor,
    n_epochs: int = 200,
    lr: float = 0.05,
    batch_size: int = 32,
) -> dict:
    """
    训练模型，逐 epoch 记录训练误差、测试误差和泛化差距 (gap)。
    从收敛理论角度：
        - 训练误差（经验风险）应单调下降
        - 泛化差距应依概率趋于零（PAC 界保证）
    """

    optimizer = optim.SGD(model.parameters(), lr=lr)
    criterion = nn.BCEWithLogitsLoss()

    dataset = TensorDataset(X_train, y_train.float())
    loader = DataLoader(dataset, batch_size=batch_size, shuffle=True)

    history = {
        'train_loss': [], 'test_loss': [],
        'train_err': [], 'test_err': [],
        'gap': [], # 泛化差距 = test_err - train_err
    }

    for epoch in range(n_epochs):
        # 训练阶段
        model.train()
        for X_batch, y_batch in loader:
            optimizer.zero_grad()
            logits = model(X_batch)
            loss = criterion(logits, y_batch)
            loss.backward()
```

```

optimizer.step()

# 评估阶段
model.eval()
with torch.no_grad():
    # 训练集指标
    train_logits = model(X_train)
    train_loss = criterion(train_logits, y_train.float()).item()
    train_err = (model.predict(X_train) != y_train).float().mean().item()

    # 测试集指标
    test_logits = model(X_test)
    test_loss = criterion(test_logits, y_test.float()).item()
    test_err = (model.predict(X_test) != y_test).float().mean().item()

    history['train_loss'].append(train_loss)
    history['test_loss'].append(test_loss)
    history['train_err'].append(train_err)
    history['test_err'].append(test_err)
    history['gap'].append(test_err - train_err)

return history

# 4. 验证 PAC 界：泛化差距与样本量的关系
def verify_pac_bound(d: int = 20, n_trials: int = 30) -> None:
    """
    对不同训练样本量  $n$ ，重复  $n\_trials$  次实验，
    验证泛化差距 ( $test\_err - train\_err$ ) 是否与 PAC 界  $O(1/\sqrt{n})$  吻合。

    从依概率收敛角度：随  $n$  增大， $\sup_h |R(h) - R_n(h)| \rightarrow 0$  (依概率)，
    这里用单个模型的泛化差距作为近似替代。
    """
    train_sizes = [50, 100, 200, 500, 1000, 2000, 5000]
    n_test = 10000 # 固定大测试集近似真实风险

    X_test, y_test = make_dataset(n_test, d)

    mean_gaps = []
    std_gaps = []

```

```

for n in train_sizes:
    gaps = []
    for _ in range(n_trials):
        X_tr, y_tr = make_dataset(n, d)
        model = LinearClassifier(d)

        # 快速训练 (固定 epoch 数)
        opt = optim.SGD(model.parameters(), lr=0.1)
        crit = nn.BCEWithLogitsLoss()
        dataset = TensorDataset(X_tr, y_tr.float())
        loader = DataLoader(dataset, batch_size=min(32, n), shuffle=True)

        for _ in range(100):
            for Xb, yb in loader:
                opt.zero_grad()
                crit(model(Xb), yb).backward()
                opt.step()

        model.eval()
        with torch.no_grad():
            train_err = (model.predict(X_tr) != y_tr).float().mean().item()
            test_err = (model.predict(X_test) != y_test).float().mean().item()
            gaps.append(test_err - train_err)

    mean_gaps.append(np.mean(gaps))
    std_gaps.append(np.std(gaps))

print(f"n={n:5d}: 平均泛化差距 = {np.mean(gaps):.4f} ± {np.std(gaps):.4f}")

# 可视化: 验证  $O(1/\sqrt{n})$  收敛速率
n_arr = np.array(train_sizes, dtype=float)
fig, axes = plt.subplots(1, 2, figsize=(12, 5))

# 左图: 泛化差距均值与 PAC 界理论曲线
delta = 0.05 # 置信度参数
H_size = 2 ** d # 对线性分类器: VC 维  $d+1$ , 简化估计  $|H| \approx 2^d$ 
pac_bound = np.sqrt((d * np.log(2) + np.log(1 / delta)) / (2 * n_arr))

axes[0].errorbar(train_sizes, mean_gaps, yerr=std_gaps,
                  fmt='o-', capsize=5, label='实验泛化差距 (均值 ± 标准差)', color='steelblue')
axes[0].plot(n_arr, pac_bound, 'r--', label=f'PAC 界  $\sqrt{\frac{(d \ln 2 + \ln(1/\delta))}{2n}}$ ',

```

```

axes[0].set_xlabel('训练样本量 $n$')
axes[0].set_ylabel('泛化差距 (测试误差 - 训练误差)')
axes[0].set_title('PAC 界验证：泛化差距随样本量的衰减')
axes[0].legend(fontsize=9)
axes[0].set_xscale('log')

# 右图：对数坐标验证  $O(1/\sqrt{n})$  速率
# 如果斜率约为 -0.5, 说明收敛速率确为  $O(n^{-1/2})$ 
log_n = np.log(n_arr)
log_gap = np.log(np.array(mean_gaps) + 1e-8)
slope, intercept = np.polyfit(log_n, log_gap, 1)

axes[1].scatter(log_n, log_gap, color='steelblue', zorder=5, label='实验数据 (对数坐标)')
axes[1].plot(log_n, slope * log_n + intercept, 'r-',
             label=f'拟合斜率 = {slope:.3f} (理论值 -0.5)', linewidth=2)
axes[1].set_xlabel('$\ln(n)$')
axes[1].set_ylabel('$\ln$(泛化差距)')
axes[1].set_title('对数坐标验证收敛速率  $O(n^{-1/2})$ ')
axes[1].legend(fontsize=9)

plt.tight_layout()
plt.savefig('pac_bound_convergence.png', dpi=150)
plt.show()

print(f"\n拟合收敛速率指数: {slope:.3f} (PAC 理论预测: -0.5) ")

# 5. 收敛类型可视化：四种收敛方式对比
def visualize_convergence_types() -> None:
    """
    可视化四种收敛类型的典型行为，帮助直观理解其差异。
    """
    n_paths = 50    # 样本路径数量
    T = 200         # 时间步数
    ts = np.arange(1, T + 1)

    fig, axes = plt.subplots(2, 2, figsize=(12, 9))
    fig.suptitle('四种收敛类型的直观比较 (随机过程轨迹)', fontsize=14)

    # (1) 几乎必然收敛：每条路径都趋向 0
    ax = axes[0, 0]

```

```

for _ in range(n_paths):
    path = np.cumsum(np.random.randn(T)) / ts # SLLN: 样本均值趋向 0
    ax.plot(ts, path, alpha=0.3, linewidth=0.8, color='steelblue')
ax.axhline(0, color='red', linewidth=2, label='极限值 0')
ax.set_title('几乎必然收敛\mathbb{E}[\bar{X}_n] \xrightarrow{a.s.} 0$ (SLLN) ', fontsize=11)
ax.set_xlabel('$n$'); ax.set_ylabel('$\bar{X}_n$')
ax.legend(); ax.set_ylim(-1.5, 1.5)

# (2) 依概率收敛但不几乎必然 (打字机序列模拟)
ax = axes[0, 1]
# 模拟:  $P(X_n=1) = 1/n$ ,  $P(X_n=0) = 1-1/n$ 
for _ in range(n_paths):
    path = np.array([
        1.0 if np.random.rand() < 1 / t else 0.0
        for t in ts
    ])
    ax.plot(ts, path, alpha=0.2, linewidth=0.8, color='orange')
# 叠加 " 依概率 " 收敛的期望路径
ax.plot(ts, 1.0 / ts, color='red', linewidth=2.5, label='$P(X_n=1)=1/n \to 0$')
ax.set_title('依概率收敛\mathbb{E}[X_n] \xrightarrow{P} 0$ (但各路径持续跳动) ', fontsize=11)
ax.set_xlabel('$n$'); ax.set_ylabel('$X_n$')
ax.legend(); ax.set_ylim(-0.1, 1.3)

# (3) 均方收敛 ( $L^2$ ):  $MSE$  趋向 0
ax = axes[1, 0]
mse_values = []
for _ in range(500): # 大量模拟估计  $MSE$ 
    path = np.cumsum(np.random.randn(T)) / ts
    mse_values.append(path ** 2)
mse_mean = np.mean(mse_values, axis=0)
theoretical_mse = 1.0 / ts #  $E[X_n^2] = 1/n$ 

ax.semilogy(ts, mse_mean, color='steelblue', linewidth=2, label='实验 MSE  $E[\bar{X}_n^2]$ ')
ax.semilogy(ts, theoretical_mse, 'r--', linewidth=2, label='理论  $1/n$ ')
ax.set_title('$L^2$ (均方) 收敛\mathbb{E}[\bar{X}_n^2] = 1/n \to 0$', fontsize=11)
ax.set_xlabel('$n$'); ax.set_ylabel('MSE (对数尺度)')
ax.legend()

# (4) 依分布收敛: 分布函数逐渐趋向正态 CDF
ax = axes[1, 1]
from scipy import stats

```

```

x_grid = np.linspace(-3, 3, 300)
colors = plt.cm.viridis(np.linspace(0.2, 1.0, 5))

for idx, n_sample in enumerate([2, 5, 20, 100, 1000]):
    #  $Z_n = (S_n - 0) / \sqrt{n}$ , 来自均匀分布  $U(-1, 1)$ 
    z_vals = np.array([
        np.random.uniform(-1, 1, n_sample).sum() / np.sqrt(n_sample / 3)
        for _ in range(5000)
    ])
    empirical_cdf = np.array([np.mean(z_vals <= x) for x in x_grid])
    ax.plot(x_grid, empirical_cdf, color=colors[idx], linewidth=1.5,
            label=f'$n={n_sample}$', alpha=0.9)

# 标准正态 CDF (极限分布)
ax.plot(x_grid, stats.norm.cdf(x_grid), 'k-', linewidth=2.5, label='$\mathcal{N}(0,1)$ CDF (极限分布)')
ax.set_title('依分布收敛  $Z_n \xrightarrow{d} \mathcal{N}(0,1)$  (CLT)', fontsize=11)
ax.set_xlabel('$x$'); ax.set_ylabel('$F_n(x)$')
ax.legend(fontsize=8)

plt.tight_layout()
plt.savefig('convergence_types_visualization.png', dpi=150)
plt.show()

# 主程序
if __name__ == '__main__':
    print("=" * 60)
    print(" 实验 1: 模型收敛性监测")
    print("=" * 60)
    d = 20
    X_train, y_train = make_dataset(1000, d)
    X_test, y_test = make_dataset(5000, d)

    model = LinearClassifier(d)
    history = train_and_track_convergence(model, X_train, y_train, X_test, y_test,
                                         n_epochs=300, lr=0.05, batch_size=64)

    final_train = history['train_err'][-1]
    final_test = history['test_err'][-1]
    final_gap = history['gap'][-1]
    print(f"\n训练结束: 训练误差 = {final_train:.4f}, 测试误差 = {final_test:.4f}, "

```

```
f" 泛化差距 ={final_gap:.4f}")

# 绘制训练曲线
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(11, 4))
epochs = range(len(history['train_err']))

ax1.plot(epochs, history['train_err'], label='训练误差（经验风险）', linewidth=2)
ax1.plot(epochs, history['test_err'], label='测试误差（真实风险近似）', linewidth=2)
ax1.set_title('训练/测试误差随训练轮数的变化'); ax1.set_xlabel('Epoch')
ax1.set_ylabel('0-1 误差'); ax1.legend()

ax2.plot(epochs, history['gap'], color='darkorange', linewidth=2)
ax2.axhline(0, color='gray', linestyle='--')
ax2.set_title('泛化差距（测试误差 - 训练误差）\nn应依概率趋于 0（PAC 理论保证）')
ax2.set_xlabel('Epoch'); ax2.set_ylabel('泛化差距')

plt.tight_layout()
plt.savefig('model_convergence_monitoring.png', dpi=150)
plt.show()

print("\n" + "=" * 60)
print(" 实验 2: PAC 界验证（需要几分钟）")
print("=" * 60)
verify_pac_bound(d=20, n_trials=20)

print("\n" + "=" * 60)
print(" 实验 3: 四种收敛类型可视化")
print("=" * 60)
visualize_convergence_types()
```

理论要点总结

从收敛理论视角理解深度学习：

深度学习概念	对应收敛理论	数学表达
训练损失趋向零	L^2 或依概率收敛	$\mathbb{E}[\ell(\theta_t)] \rightarrow 0$ 或 $\ell(\theta_t) \xrightarrow{P} 0$
泛化误差收敛	一致大数定律 (ULLN)	$\sup_h R(h) - \hat{R}_n(h) \xrightarrow{P} 0$
SGD 找到稳定点	依概率收敛	$ \nabla L(\theta_t) \xrightarrow{P} 0$
PAC 样本复杂度	依概率收敛速率	$O_P(1/\sqrt{n})$ 泛化界
批归一化 (BN)	CLT（依分布收敛）	批均值 $\xrightarrow{d} \mathcal{N}(\mu, \sigma^2/m)$

深度学习概念	对应收敛理论	数学表达
Dropout 正则化	依概率收敛（随机近似）	期望网络 $\approx$ 集成均值

PAC 学习的核心洞察：随着样本量 $n \rightarrow \infty$ ：

$$\sup_{h \in \mathcal{H}} |R(h) - \hat{R}_n(h)| = O_P \left(\sqrt{\frac{\text{complexity}(\mathcal{H}) + \ln(1/\delta)}{n}} \right) \xrightarrow{P} 0$$

这正是“依概率收敛”的量化表达——泛化差距依概率以 $O(1/\sqrt{n})$ 的速率趋于零，其中“ $\text{complexity}(\mathcal{H})$ ”可以是 $\ln |\mathcal{H}|$ （有限假设类）、VC 维，或 Rademacher 复杂度的函数。

练习题

题 1（依概率收敛基础） 设 $X_1, X_2, \dots$ 为独立随机变量， X_n 的分布为

$$P(X_n = n^2) = \frac{1}{n^2}, \quad P(X_n = 0) = 1 - \frac{1}{n^2}$$

- (a) 证明 $X_n \xrightarrow{P} 0$ 。
- (b) 计算 $\mathbb{E}[X_n]$ 和 $\text{Var}(X_n)$ ，并由此说明 X_n 不以均方收敛到 0。
- (c) 利用 Borel-Cantelli 第一引理证明 $X_n \xrightarrow{a.s.} 0$ 。

题 2（ δ 方法应用） 设 $X_1, X_2, \dots$ i.i.d., $\mathbb{E}[X_i] = \mu > 0$, $\text{Var}(X_i) = \sigma^2 < \infty$, 且 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ 。

- (a) 写出 $\sqrt{n}(\bar{X}_n - \mu)$ 的渐近分布（CLT）。
- (b) 利用 δ 方法，求 $\sqrt{n}(1/\bar{X}_n - 1/\mu)$ 的渐近分布。
- (c) 利用 δ 方法，求 $\sqrt{n}(\ln \bar{X}_n - \ln \mu)$ 的渐近分布。
- (d) 若 $\mu = 2$, $\sigma^2 = 4$, 当 $n = 100$ 时，用渐近分布近似 $P(\ln \bar{X}_{100} > 0.8)$ 。

题 3（收敛类型的判别） 对以下每个序列，判断其对哪些类型的收敛成立（a.s.、 L^2 、依概率、依分布），并给出理由或反例。设 $\Omega = [0, 1]$, P 为 Lebesgue 测度。

- (a) $X_n(\omega) = \omega^n$
- (b) $X_n(\omega) = n \cdot \mathbf{1}_{[0, 1/n]}(\omega)$

(c) $X_n(\omega) = \sin(2\pi n\omega)$

(d) $X_n(\omega) = \mathbf{1}_{[0, 1/n]}(\omega)$

题 4 (Slutsky 定理与渐近分布) 设 $\hat{\sigma}_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ 为样本方差 (有偏版本), X_i i.i.d., 均值 μ , 四阶矩有限。

(a) 证明 $\hat{\sigma}_n^2 \xrightarrow{P} \sigma^2$ (提示: 用 WLLN 和连续映射定理)。

(b) 由 CLT 知 $\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$ 。利用 Slutsky 定理, 证明

$$T_n = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\hat{\sigma}_n} \xrightarrow{d} \mathcal{N}(0, 1)$$

(c) 这个结论为什么比直接用已知方差 σ 更有实际价值?

题 5 (PAC 界与样本复杂度) 考虑在 $\mathbb{R}^d$ 中用轴对齐矩形 (axis-aligned rectangles) 进行二分类: 假设类 $\mathcal{H}_{\text{rect}}$ 由所有形如 $h_{a_1, b_1, \dots, a_d, b_d}(x) = \mathbf{1}[a_k \leq x_k \leq b_k, \forall k]$ 的分类器组成 (将矩形内的点分为正类)。

(a) $\mathcal{H}_{\text{rect}}$ 是无限假设类, 直接用有限类的 PAC 界 (定理 12.13) 不适用。但已知 $\mathcal{H}_{\text{rect}}$ 的 VC 维为 $d_{\text{VC}} = 2d$ 。利用 VC 维的 PAC 界 (Vapnik-Chervonenkis 定理):

$$P\left(\sup_{h \in \mathcal{H}} |R(h) - \hat{R}_n(h)| > \varepsilon\right) \leq 8 \cdot \left(\frac{en}{d_{\text{VC}}}\right)^{d_{\text{VC}}} \cdot e^{-n\varepsilon^2/8}$$

写出此概率 $\leq \delta$ 时的样本复杂度 (n 关于 ε, δ, d 的表达式)。

(b) 当 $d = 10$, $\varepsilon = 0.05$, $\delta = 0.05$ 时, 至少需要多大的样本量 n ? (给出数量级估计即可)

(c) 上述结果说明样本复杂度关于维度 d 是线性的 (而非指数级)。从依概率收敛的角度解释: 这意味着随样本量增大, n 个样本足以保证泛化差距的依概率收敛速率不受维度灾难的影响——为什么这在实践中很重要?

练习答案

题 1 详细解答

(a) $X_n \xrightarrow{P} 0$

对任意 $\varepsilon > 0$ (不妨设 $\varepsilon < 1$, 否则更简单):

$$P(|X_n - 0| > \varepsilon) = P(X_n = n^2) = \frac{1}{n^2} \rightarrow 0$$

故 $X_n \xrightarrow{P} 0$ 。■

(b) 期望与方差

$$\mathbb{E}[X_n] = n^2 \cdot \frac{1}{n^2} + 0 \cdot \left(1 - \frac{1}{n^2}\right) = 1 \quad \forall n$$

$$\mathbb{E}[X_n^2] = (n^2)^2 \cdot \frac{1}{n^2} = n^2 \rightarrow \infty$$

$$\mathbb{E}[X_n^2] = n^2 \rightarrow \infty \neq 0 = \mathbb{E}[0^2]$$

故 $\mathbb{E}[(X_n - 0)^2] = \mathbb{E}[X_n^2] = n^2 \rightarrow \infty$, X_n 不均方收敛到 0 (也不 L^1 收敛: $\mathbb{E}[|X_n|] = 1 \not\rightarrow 0$)。

(c) Borel-Cantelli 推导 a.s. 收敛

对任意 $\varepsilon > 0$, 令 $A_n = \{|X_n| > \varepsilon\} = \{X_n = n^2\}$ 。

$$\sum_{n=1}^{\infty} P(A_n) = \sum_{n=1}^{\infty} \frac{1}{n^2} = \frac{\pi^2}{6} < \infty$$

由 Borel-Cantelli 第一引理, $P(\limsup_{n \rightarrow \infty} A_n) = 0$, 即以概率 1 只有有限个 n 满足 $|X_n| > \varepsilon$, 故对几乎所有 ω , 当 n 足够大时 $|X_n(\omega)| \leq \varepsilon$, 即 $X_n \xrightarrow{a.s.} 0$ 。■

注: 本题展示了一个反直觉的现象: $\mathbb{E}[X_n] = 1 \not\rightarrow 0$ (即 L^1 不收敛), 但 $X_n \xrightarrow{a.s.} 0$ (强收敛)。这正是“a.s. 收敛不蕴含 L^1 收敛”的典型例子, 原因是 $\{X_n\}$ 不一致可积。

题 2 详细解答

(a) CLT

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$$

(b) $g(x) = 1/x$, $g'(x) = -1/x^2$

由 δ 方法 (在 $\theta = \mu$ 处):

$$\sqrt{n}\left(\frac{1}{\bar{X}_n} - \frac{1}{\mu}\right) \xrightarrow{d} \mathcal{N}\left(0, \left(\frac{-1}{\mu^2}\right)^2 \sigma^2\right) = \mathcal{N}\left(0, \frac{\sigma^2}{\mu^4}\right)$$

(c) $g(x) = \ln x$, $g'(x) = 1/x$

$$\sqrt{n}(\ln \bar{X}_n - \ln \mu) \xrightarrow{d} \mathcal{N}\left(0, \frac{\sigma^2}{\mu^2}\right)$$

(d) 数值近似

$\mu = 2$, $\sigma^2 = 4$, $n = 100$ 。渐近标准差为 $\frac{\sigma}{\sqrt{n}} = \frac{2}{\sqrt{100}} = 0.1$ 。

$$\begin{aligned} P(\ln \bar{X}_{100} > 0.8) &\approx P(\mathcal{N}(\ln 2, 0.01) > 0.8) = P\left(Z > \frac{0.8 - \ln 2}{0.1}\right) \\ &= P\left(Z > \frac{0.8 - 0.6931}{0.1}\right) = P(Z > 1.069) = 1 - \Phi(1.069) \approx 1 - 0.8574 = \mathbf{0.1426} \end{aligned}$$

题 3 详细解答

(a) $X_n(\omega) = \omega^n$

极限： $\lim_{n \rightarrow \infty} \omega^n = 0$ 对 $\omega \in [0, 1)$, $= 1$ 对 $\omega = 1$ 。

- **a.s. 收敛**： $P(\omega = 1) = 0$ (单点集)，故 $X_n \xrightarrow{a.s.} 0$ 。
- **依概率收敛**：由 a.s. 收敛蕴含， $X_n \xrightarrow{P} 0$ 。
- **依分布收敛**： $X_n \xrightarrow{d} 0$ (由依概率蕴含)。
- L^2 收敛： $\mathbb{E}[X_n^2] = \int_0^1 \omega^{2n} d\omega = \frac{1}{2n+1} \rightarrow 0$ ，故 $X_n \xrightarrow{L^2} 0$ 。

结论：四种收敛均成立。

(b) $X_n(\omega) = n \cdot \mathbf{1}_{[0, 1/n]}(\omega)$

- **a.s. 收敛**：对 $\omega \in (0, 1]$ ，当 $n > 1/\omega$ 时 $X_n(\omega) = 0$ ，故 $X_n(\omega) \rightarrow 0$ 。在 $\omega = 0$ 处 $X_n(0) = n \rightarrow \infty$ ，但 $P(\omega = 0) = 0$ 。故 $X_n \xrightarrow{a.s.} 0$ 。
- **依概率收敛**： $P(|X_n| > \varepsilon) = P(X_n = n) = 1/n \rightarrow 0$ (对 $\varepsilon < n$ 时)，故 $X_n \xrightarrow{P} 0$ 。
- L^2 收敛： $\mathbb{E}[X_n^2] = n^2 \cdot \frac{1}{n} = n \rightarrow \infty$ ，故 $X_n \not\xrightarrow{L^2} 0$ 。
- L^1 收敛： $\mathbb{E}[|X_n|] = n \cdot \frac{1}{n} = 1 \not\rightarrow 0$ ，故 $X_n \not\xrightarrow{L^1} 0$ 。

结论：**a.s.** 和依概率收敛成立； L^p ($p \geq 1$) 收敛不成立。这是 a.s. 收敛不蕴含 L^1 收敛的典型例子 (不满足一致可积)。

(c) $X_n(\omega) = \sin(2\pi n\omega)$

- **依分布收敛**： $P(X_n \leq x) \rightarrow \frac{1}{\pi} \arcsin(x) + \frac{1}{2}$ ($x \in [-1, 1]$)，即收敛到弧正弦分布。
- **a.s. 收敛**：由 Weyl 等分定理，对几乎所有 ω ， $\{n\omega\}$ (小数部分) 在 $[0, 1]$ 上均匀分布，故 $\sin(2\pi n\omega)$ 不收敛 (在 $[-1, 1]$ 内稠密振荡)。
- **依概率收敛**：若依概率收敛到某极限 X ，则 $X_n \xrightarrow{d} X$ ，但 X_n 依分布收敛到弧正弦分布 (非常数)，故 X 只能是弧正弦分布，而 $X_n \not\xrightarrow{P} X$ (路径层面不收敛)。实际上 $X_n \not\xrightarrow{P}$ 任何极限 (反证：若收到常数 c ，则依分布极限为 c ，矛盾)。
- L^2 收敛： $\mathbb{E}[\sin^2(2\pi n\omega)] = 1/2$ 不趋于零，故不 L^2 收敛到 0。

结论：仅依分布收敛成立 (到弧正弦分布)；**a.s.**、依概率、 L^p 均不收敛。

(d) $X_n(\omega) = \mathbf{1}_{[0, 1/n]}(\omega)$

- **a.s. 收敛**: 对 $\omega \in (0, 1]$, 当 $n > 1/\omega$ 时 $X_n(\omega) = 0$, 故 $X_n \xrightarrow{a.s.} 0$ ($\omega = 0$ 为零测集)。
- L^p 收敛: $\mathbb{E}[|X_n|^p] = \int_0^{1/n} 1 d\omega = 1/n \rightarrow 0$, 故 $X_n \xrightarrow{L^p} 0$ 对所有 $p \geq 1$ 。
- 由以上两种均蕴含依概率和依分布收敛。

结论: 四种收敛均成立 (与 (b) 对比: (b) 中振幅随 n 增长导致 L^p 失败, 而 (d) 中振幅为 1, 矩有界)。

题 4 详细解答

(a) $\hat{\sigma}_n^2 \xrightarrow{P} \sigma^2$

分解:

$$\hat{\sigma}_n^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_n^2$$

- 由 WLLN (对 X_i^2 , 需 $\mathbb{E}[X_i^4] < \infty$, 即四阶矩有限): $\frac{1}{n} \sum X_i^2 \xrightarrow{P} \mathbb{E}[X^2] = \sigma^2 + \mu^2$
- 由 WLLN (对 X_i): $\bar{X}_n \xrightarrow{P} \mu$
- 由连续映射定理 ($g(x) = x^2$ 连续): $\bar{X}_n^2 \xrightarrow{P} \mu^2$

由运算规则:

$$\hat{\sigma}_n^2 = \frac{1}{n} \sum X_i^2 - \bar{X}_n^2 \xrightarrow{P} (\sigma^2 + \mu^2) - \mu^2 = \sigma^2$$

■

(b) Student 化统计量渐近正态

由 (a), $\hat{\sigma}_n \xrightarrow{P} \sigma$ (由 CMT, $g(x) = \sqrt{x}$ 在 $\sigma^2 > 0$ 处连续)。

由 Slutsky 定理 ($X_n \xrightarrow{d} X, Y_n \xrightarrow{P} c \Rightarrow X_n/Y_n \xrightarrow{d} X/c$):

$$T_n = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\hat{\sigma}_n} = \underbrace{\sqrt{n}(\bar{X}_n - \mu)}_{\xrightarrow{d} \mathcal{N}(0, \sigma^2)} \cdot \underbrace{\frac{1}{\hat{\sigma}_n}}_{\xrightarrow{P} 1/\sigma}$$

由 Slutsky 定理:

$$T_n \xrightarrow{d} \mathcal{N}(0, \sigma^2) \cdot \frac{1}{\sigma} = \mathcal{N}(0, 1)$$

■

(c) 实际价值

在实际应用中, σ 通常未知 (若已知则可直接使用正态分布)。 T_n 的渐近正态性意味着: 即使不知道总体方差, 用样本标准差 $\hat{\sigma}_n$ 代替后, 统计量仍渐近地服从标准正态分布。这直接支撑了大样本下 z 检验和置信区间构造的理论基础, 是统计推断中最重要的渐近结果之一。

题 5 详细解答

(a) VC 维 PAC 样本复杂度

令右端 $\leq \delta$:

$$8 \cdot \left(\frac{en}{d_{\text{VC}}} \right)^{d_{\text{VC}}} \cdot e^{-n\varepsilon^2/8} \leq \delta$$

取对数:

$$\ln 8 + d_{\text{VC}} \ln \left(\frac{en}{d_{\text{VC}}} \right) - \frac{n\varepsilon^2}{8} \leq \ln \delta$$

整理得:

$$\frac{n\varepsilon^2}{8} \geq \ln 8 + d_{\text{VC}} \ln \left(\frac{en}{d_{\text{VC}}} \right) - \ln \delta = \ln \frac{8}{\delta} + d_{\text{VC}} \ln \left(\frac{en}{d_{\text{VC}}} \right)$$

由于右端含 n , 需迭代求解。数量级估计:

$$n = O \left(\frac{d_{\text{VC}} \ln(d_{\text{VC}}/\varepsilon) + \ln(1/\delta)}{\varepsilon^2} \right)$$

(b) 数值估计 ($d = 10, \varepsilon = 0.05, \delta = 0.05$)

$d_{\text{VC}} = 2d = 20$ 。代入:

$$n \gtrsim \frac{8}{\varepsilon^2} \left(\ln \frac{8}{\delta} + d_{\text{VC}} \ln \left(\frac{e \cdot n}{d_{\text{VC}}} \right) \right)$$

初始估计取 $n = 10000$:

$$\frac{8}{0.0025} \left(\ln 160 + 20 \ln \left(\frac{e \times 10000}{20} \right) \right) = 3200 \times (5.075 + 20 \times 6.908) \approx 3200 \times 143.2 \approx 458240$$

精确迭代给出 $n \approx$ 数万量级 (约 $10^4 \sim 10^5$)。关键是 n 关于 d 是线性的 ($O(d/\varepsilon^2)$ 级别), 而非指数级。

(c) 维度线性性的意义

样本复杂度 $O(d/\varepsilon^2)$ 表明: 即使特征维度 d 增大, 所需样本量也只是线性增长, 而非指数增长 (“维度灾难”通常指非参数方法中的 $O((1/\varepsilon)^d)$ 增长)。

从依概率收敛角度: 这说明轴对齐矩形分类器类是 PAC 可学习的——随样本量 n 的增大, 经验风险以 $O_P(\sqrt{d/n})$ 的速率一致地 (对整个假设类) 依概率收敛到真实风险。在实践中, VC 维有限的假设类 (包括大多数参数化模型) 的泛化差距都具有这种多项式收敛速率, 这正是机器学习理论保证神经网络泛化性能的数学基础。

下一章预告：第 13 章：统计量与抽样分布 — 我们将从概率论过渡到数理统计，学习总体、样本、统计量等核心概念，以及三大抽样分布（卡方、t、F 分布）的性质与应用。

第 13 章：统计量与抽样分布

学习目标

学完本章后，你将能够：

- 清晰区分总体与样本的概念，理解从总体到样本的随机性本质，以及参数与统计量的关键差异
- 掌握常用统计量（样本均值、样本方差、样本矩）的定义与性质，能计算其期望、方差，并理解无偏性概念
- 理解抽样分布的含义——统计量作为随机变量所服从的分布，掌握其与总体分布的联系
- 熟练运用三大抽样分布（ χ^2 分布、 t 分布、 F 分布）的定义、性质与分位数查表方法
- 掌握正态总体下样本均值与样本方差的精确抽样分布定理，为后续参数估计与假设检验奠定基础

13.1 总体与样本

总体的概念

总体（population）是研究对象的全体，通常用一个随机变量 X 来刻画，其分布函数 $F(x)$ 称为总体分布。

总体分布中含有未知参数 θ （可能是向量），统计推断的目标就是从观测数据出发，对 θ 做出推断。

例 13.1 研究某城市成年男性的身高，总体为全体成年男性身高的分布，通常假定为 $X \sim \mathcal{N}(\mu, \sigma^2)$ ，其中 μ 、 σ^2 未知。

有限总体与无限总体

类型	含义	示例
有限总体	个体数有限 ($N < \infty$)	某工厂一批产品 ($N = 10000$)
无限总体	个体数无限，或视为无限	连续分布、重复生产过程

在统计推断中，通常假定总体分布已知其类型（如正态、指数），但参数未知。

简单随机样本

定义 13.1（简单随机样本）若 $X_1, X_2, \dots, X_n$ 满足：

- 1. 独立性： $X_1, X_2, \dots, X_n$ 相互独立
- 2. 同分布性： 每个 X_i 与总体 X 同分布，即 $F_{X_i}(x) = F(x)$

则称 $(X_1, X_2, \dots, X_n)$ 为来自总体 X 的简单随机样本 (simple random sample), 简称样本, n 称为样本量 (sample size)。

样本的联合分布函数为：

$$F(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F(x_i)$$

若总体有密度 $f(x)$ ，样本的联合密度为：

$$f(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i)$$

样本的二重性

样本具有二重性：

- 随机性： 在抽样之前， $X_1, X_2, \dots, X_n$ 是随机变量（用大写字母表示）
- 观测值： 抽样完成后， 得到具体数值 $x_1, x_2, \dots, x_n$ （用小写字母表示）

这一区分在统计学中极为重要： 我们用随机变量来推导理论， 用观测值来进行具体计算。

参数与统计量的区别

概念	含义	是否已知	示例
参数 (parameter)	总体分布中的未知常数	一般未知	μ 、 σ^2 、 p
统计量 (statistic)	样本的函数（不含未知参数）	可计算	$\bar{X}$ 、 S^2 、 $X_{(n)}$

参数是固定（但未知）的常数，统计量是随机变量（样本确定后变为具体数值）。统计推断的核心是：用统计量来推断参数。

13.2 统计量的概念

统计量的定义

定义 13.2 (统计量) 设 $(X_1, X_2, \dots, X_n)$ 是来自总体 X 的样本, $g(X_1, X_2, \dots, X_n)$ 是 $X_1, \dots, X_n$ 的函数, 若 g 中不含任何未知参数, 则称 $g(X_1, X_2, \dots, X_n)$ 为一个统计量。

注意: 统计量是随机变量 (因为 X_i 是随机变量), 其分布完全由总体分布决定。

常用统计量

设 $(X_1, X_2, \dots, X_n)$ 为来自总体 X 的样本, 以下是最重要的几类统计量。

样本均值

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

样本方差

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

分母取 $n-1$ (而非 n) 的原因: 这使得 S^2 成为总体方差 σ^2 的无偏估计 (见下文)。 $S = \sqrt{S^2}$ 称为样本标准差。

计算等价形式 (便于手算):

$$S^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)$$

样本矩 样本 k 阶原点矩:

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, \dots$$

特别地, $A_1 = \bar{X}$ 。

样本 k 阶中心矩:

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k, \quad k = 2, 3, \dots$$

注意: $B_2 = \frac{n-1}{n} S^2$ (有偏估计)。

顺序统计量 将样本从小到大排列得到 $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$, 称为顺序统计量 (order statistics)。

- $X_{(1)} = \min(X_1, \dots, X_n)$: 最小值
- $X_{(n)} = \max(X_1, \dots, X_n)$: 最大值
- $R = X_{(n)} - X_{(1)}$: 极差 (range)

顺序统计量的分布

设总体 CDF 为 $F(x)$, PDF 为 $f(x)$, 则第 k 个顺序统计量 $X_{(k)}$ 的 PDF 为:

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1-F(x)]^{n-k} f(x)$$

直觉: 恰好有 $k-1$ 个样本 $\leq x$ 、1 个样本 $= x$ 、 $n-k$ 个样本 $> x$, 再乘以排列数。

特别重要的两个:

- 最小值 $X_{(1)}$: $f_{X_{(1)}}(x) = n[1-F(x)]^{n-1}f(x)$, CDF 为 $F_{X_{(1)}}(x) = 1 - [1-F(x)]^n$
- 最大值 $X_{(n)}$: $f_{X_{(n)}}(x) = n[F(x)]^{n-1}f(x)$, CDF 为 $F_{X_{(n)}}(x) = [F(x)]^n$

示例: 设 $X_i \sim \text{Uniform}(0, 1)$, 则 $X_{(k)} \sim \text{Beta}(k, n-k+1)$ 。特别地, $X_{(n)}$ 的 PDF 为 $f(x) = nx^{n-1}$ ($0 < x < 1$), $E[X_{(n)}] = \frac{n}{n+1}$ 。

样本均值的性质

命题 13.1 设总体 X 满足 $\mathbb{E}[X] = \mu$, $\text{Var}(X) = \sigma^2$, 则:

$$\mathbb{E}[\bar{X}] = \mu \quad (\text{无偏性})$$

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n} \quad (\text{方差缩减})$$

证明: 由独立同分布和期望、方差的线性性立即得到。■

样本方差的无偏性

命题 13.2 设总体 X 满足 $\mathbb{E}[X] = \mu$, $\text{Var}(X) = \sigma^2$, 则:

$$\mathbb{E}[S^2] = \sigma^2 \quad (\text{无偏性})$$

证明:

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2$$

两边取期望：

$$\begin{aligned}\mathbb{E}\left[\sum_{i=1}^n (X_i - \bar{X})^2\right] &= \sum_{i=1}^n \mathbb{E}[X_i^2] - n\mathbb{E}[\bar{X}^2] \\ &= n(\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) = n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2 = (n-1)\sigma^2\end{aligned}$$

因此 $\mathbb{E}[S^2] = \frac{1}{n-1}(n-1)\sigma^2 = \sigma^2$ 。■

直觉： n 个 $(X_i - \bar{X})$ 之和恒为零（因为 $\bar{X}$ 本身由数据决定），只有 $n-1$ 个是“自由的”，故除以 $n-1$ 才能无偏估计 σ^2 。这就是统计学中的自由度（degrees of freedom）概念的起源。

13.3 抽样分布

什么是抽样分布

定义 13.3（抽样分布） 统计量 $T = g(X_1, X_2, \dots, X_n)$ 作为随机变量所服从的分布，称为该统计量的抽样分布（sampling distribution）。

抽样分布是统计推断的核心——要用统计量推断参数，必须知道统计量的分布。

抽样分布的来源

抽样分布取决于两个因素：

1. 总体分布的类型与参数
2. 统计量的具体形式

对正态总体，样本均值、样本方差等常用统计量的精确抽样分布可以导出（见第 13.5 节）。对非正态总体，通常只能用中心极限定理得到渐近分布。

为什么要研究抽样分布

抽样分布回答了这样的问题：

如果真实参数为 θ ，重复抽样 N 次，每次计算统计量 T ，则 T 的分布是什么？

这一分布决定了：- 估计量有多精确（方差多大）- 置信区间如何构建（需要分位数）- 假设检验的临界值如何确定（需要尾概率）

示例：均匀总体的样本均值分布

设 $X \sim U(0, 1)$, $n = 2$ 。则 $\bar{X} = (X_1 + X_2)/2$ 的密度为：

$$f_{\bar{X}}(x) = \begin{cases} 4x, & 0 \leq x < 1/2 \\ 4(1-x), & 1/2 \leq x \leq 1 \end{cases}$$

这是一个三角形分布，而非均匀分布——体现了抽样分布不同于总体分布的本质。

13.4 三大抽样分布

正态总体中的统计推断依赖三种核心分布： χ^2 分布、 t 分布、 F 分布。它们都由正态分布导出，是数理统计的基石。

13.4.1 卡方分布 (χ^2 分布)

定义 13.4 (χ^2 分布) 设 $Z_1, Z_2, \dots, Z_n$ 独立同分布于 $\mathcal{N}(0, 1)$ ，则

$$\chi^2 = Z_1^2 + Z_2^2 + \dots + Z_n^2 \sim \chi^2(n)$$

称为自由度为 n 的卡方分布 (chi-squared distribution)。

密度函数 $\chi^2(n)$ 的概率密度函数为：

$$f(x; n) = \frac{1}{2^{n/2} \Gamma(n/2)} x^{n/2-1} e^{-x/2}, \quad x > 0$$

其中 $\Gamma(\cdot)$ 为 Gamma 函数。这是 $\text{Gamma}(n/2, 1/2)$ 分布的特例。

性质 命题 13.3 (χ^2 分布的矩)

$$\mathbb{E}[\chi^2(n)] = n, \quad \text{Var}(\chi^2(n)) = 2n$$

命题 13.4 (可加性) 若 $X \sim \chi^2(m)$, $Y \sim \chi^2(n)$, 且 $X \perp Y$, 则：

$$X + Y \sim \chi^2(m + n)$$

命题 13.5 (正态平方的特征) 设 $X \sim \mathcal{N}(\mu, \sigma^2)$, 则:

$$\left(\frac{X - \mu}{\sigma}\right)^2 \sim \chi^2(1)$$

命题 13.6 (渐近正态性) 当 $n \rightarrow \infty$ 时, 由中心极限定理:

$$\frac{\chi^2(n) - n}{\sqrt{2n}} \xrightarrow{d} \mathcal{N}(0, 1)$$

等价近似: $\chi^2(n) \approx \mathcal{N}(n, 2n)$ (当 n 较大时)。

分位数 $\chi^2(n)$ 分布的上 α 分位点 $\chi_\alpha^2(n)$ 定义为:

$$P(\chi^2(n) > \chi_\alpha^2(n)) = \alpha$$

由于 χ^2 分布不对称, 上下分位点需分别查表。常用值:

n	$\chi_{0.025}^2(n)$	$\chi_{0.975}^2(n)$	$\chi_{0.05}^2(n)$	$\chi_{0.95}^2(n)$
5	0.831	12.833	1.145	11.070
10	3.247	20.483	3.940	18.307
20	9.591	34.170	10.851	31.410

13.4.2 t 分布 (学生 t 分布)

定义 13.5 (t 分布) 设 $X \sim \mathcal{N}(0, 1)$, $Y \sim \chi^2(n)$, 且 $X \perp Y$, 则:

$$T = \frac{X}{\sqrt{Y/n}} \sim t(n)$$

称为自由度为 n 的 t 分布 (Student's t -distribution), 也称学生 t 分布。

密度函数 $t(n)$ 的概率密度函数为:

$$f(x; n) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{x^2}{n}\right)^{-(n+1)/2}, \quad x \in \mathbb{R}$$

性质 命题 13.7 (对称性) $t(n)$ 分布关于 0 对称：若 $T \sim t(n)$ ，则 $-T \sim t(n)$ 。

命题 13.8 (矩的存在性)

$$\mathbb{E}[T] = 0 \quad (n > 1), \quad \text{Var}(T) = \frac{n}{n-2} \quad (n > 2)$$

命题 13.9 (收敛到正态) 当 $n \rightarrow \infty$ 时：

$$t(n) \xrightarrow{d} \mathcal{N}(0, 1)$$

即自由度增大时， t 分布趋向标准正态分布。实践中， $n \geq 30$ 时近似效果已较好。

命题 13.10 (尾部更重) $t(n)$ 分布的尾部比 $\mathcal{N}(0, 1)$ 更厚 (kurtosis > 3)，这反映了用样本标准差代替总体标准差带来的额外不确定性。

分位数 $t(n)$ 分布的上 α 分位点 $t_\alpha(n)$ 满足：

$$P(T > t_\alpha(n)) = \alpha$$

由对称性： $t_{1-\alpha}(n) = -t_\alpha(n)$ 。常用值：

n	$t_{0.025}(n)$ (双侧 5%)	$t_{0.05}(n)$ (单侧 5%)
5	2.571	2.015
10	2.228	1.812
20	2.086	1.725
30	2.042	1.697
∞	1.960	1.645

最后一行 ($n \rightarrow \infty$) 正是标准正态分布的分位数。

13.4.3 F 分布

定义 定义 13.6 (F 分布) 设 $U \sim \chi^2(m)$ ， $V \sim \chi^2(n)$ ，且 $U \perp V$ ，则：

$$F = \frac{U/m}{V/n} \sim F(m, n)$$

称为自由度为 (m, n) 的 F 分布， m 为分子自由度， n 为分母自由度。

密度函数 $F(m, n)$ 的概率密度函数为：

$$f(x; m, n) = \frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)} \left(\frac{m}{n}\right)^{m/2} \frac{x^{m/2-1}}{\left(1 + \frac{m}{n}x\right)^{(m+n)/2}}, \quad x > 0$$

性质 命题 13.11 (均值与方差)

$$\mathbb{E}[F] = \frac{n}{n-2} \quad (n > 2), \quad \text{Var}(F) = \frac{2n^2(m+n-2)}{m(n-2)^2(n-4)} \quad (n > 4)$$

命题 13.12 (倒数性质) 若 $F \sim F(m, n)$, 则 $1/F \sim F(n, m)$, 因此：

$$F_{1-\alpha}(m, n) = \frac{1}{F_{\alpha}(n, m)}$$

这一性质可将下分位点转换为上分位点，在查表时非常有用。

命题 13.13 (与 t 分布的关系) 若 $T \sim t(n)$, 则 $T^2 \sim F(1, n)$ 。

命题 13.14 (与 χ^2 分布的关系) 当 $n \rightarrow \infty$ 时, $mF(m, n) \xrightarrow{d} \chi^2(m)$ 。

三大分布之间的关系图

$$\mathcal{N}(0, 1) \xrightarrow{\text{平方}} \chi^2(1) \xrightarrow{\text{求和}} \chi^2(n)$$

$$\frac{\mathcal{N}(0, 1)}{\sqrt{\chi^2(n)/n}} = t(n), \quad T^2 = F(1, n)$$

$$\frac{\chi^2(m)/m}{\chi^2(n)/n} = F(m, n)$$

13.5 正态总体的抽样分布定理

本节是本章的核心，给出正态总体下最重要的精确抽样分布结果。

单正态总体

设 $(X_1, X_2, \dots, X_n)$ 是来自 $\mathcal{N}(\mu, \sigma^2)$ 的简单随机样本, $\bar{X}$ 为样本均值, S^2 为样本方差。

定理一：样本均值的精确分布 定理 13.1

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

等价地：

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$$

证明：正态随机变量的线性组合仍为正态， $\mathbb{E}[\bar{X}] = \mu$ ， $\text{Var}(\bar{X}) = \sigma^2/n$ 。■

定理二：样本方差的精确分布 定理 13.2 (Cochran 定理的特例)

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

含义：样本方差乘以 $(n-1)/\sigma^2$ 服从自由度为 $n-1$ 的卡方分布（注意：自由度是 $n-1$ 而非 n ，少的那一个自由度被 $\bar{X}$ “消耗”了）。

证明思路：

利用正交变换。令 $Y_i = (X_i - \mu)/\sigma \sim \mathcal{N}(0, 1)$ ，则：

$$\sum_{i=1}^n Y_i^2 = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma}\right)^2 \sim \chi^2(n)$$

通过恒等式（平方和分解）：

$$\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma}\right)^2 = \frac{(n-1)S^2}{\sigma^2} + n \left(\frac{\bar{X} - \mu}{\sigma}\right)^2$$

$$\text{右边第二项} = \left(\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}\right)^2 \sim \chi^2(1)。$$

要从这个分解得出“第一项 $\sim \chi^2(n-1)$ 且两项独立”，依据的就是下面这条定理。

Cochran 定理（本处所需形式）：设 $Z_1, \dots, Z_n$ 独立同 $\mathcal{N}(0, 1)$ 。若它们的平方和被分解为若干二次型之和

$$\sum_{i=1}^n Z_i^2 = Q_1 + Q_2 + \dots + Q_k,$$

其中 Q_j 是 Z_i 的二次型、秩为 r_j ，且秩之和恰好等于总自由度 $r_1 + \dots + r_k = n$ ，则：□ 各 Q_j 相互独立；□ 每个 $Q_j \sim \chi^2(r_j)$ 。

直觉：\$n\$ 个独立标准正态的“自由度总量”为 \$n\$；正交分解把这 \$n\$ 个自由度无重叠地分给各二次型，每块自由度数 \$r_j\$ 决定它是 \$\chi^2(r_j)\$，且因正交（不共享自由度）而相互独立。

套用到本处：左边 \$\sum Y_i^2 \sim \chi^2(n)\$（总自由度 \$n\$），右边第一项 \$\frac{(n-1)S^2}{\sigma^2}\$ 的秩为 \$n-1\$、第二项的秩为 1，\$(n-1)+1=n\$ 满足秩和条件。故第一项 \$\sim \chi^2(n-1)\$，且两项相互独立。■

定理三：\$\bar{X}\$ 与 \$S^2\$ 的独立性 定理 13.3（正态总体的独立性）对正态总体，\$\bar{X}\$ 与 \$S^2\$ 相互独立。

证明：这正是上面 Cochran 定理结论 \$\square\$ 的直接推论——分解式中第二项 \$n(\frac{\bar{X}-\mu}{\sigma})^2\$ 是 \$\bar{X}\$ 的函数、第一项 \$\frac{(n-1)S^2}{\sigma^2}\$ 是 \$S^2\$ 的函数，两个二次型独立，故 \$\bar{X}\$ 与 \$S^2\$ 独立。■

注：这是正态分布特有的性质！对非正态总体，\$\bar{X}\$ 与 \$S^2\$ 一般不独立。

定理四：\$t\$ 统计量 定理 13.4 在定理 13.1 和 13.2 的条件下，当 \$\sigma^2\$ 未知时：

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

证明：

$$T = \frac{(\bar{X} - \mu)/(\sigma/\sqrt{n})}{\sqrt{(n-1)S^2/\sigma^2/(n-1)}} \cdot \frac{1}{1} = \frac{\mathcal{N}(0,1)}{\sqrt{\chi^2(n-1)/(n-1)}} \sim t(n-1)$$

其中分子分母独立（由定理 13.3）。■

实践意义：当 \$\sigma^2\$ 未知时，用 \$S\$ 代替 \$\sigma\$，统计量服从 \$t(n-1)\$ 而非 \$\mathcal{N}(0,1)\$，这是一元 \$t\$ 检验的理论基础。

两个正态总体

设 \$(X_1, \dots, X_m)\$ 来自 \$\mathcal{N}(\mu_1, \sigma_1^2)\$，\$(Y_1, \dots, Y_n)\$ 来自 \$\mathcal{N}(\mu_2, \sigma_2^2)\$，两样本独立。

令 \$\bar{X}\$、\$\bar{Y}\$ 分别为两组样本均值，\$S_X^2\$、\$S_Y^2\$ 分别为两组样本方差。

定理五：两样本方差比的 \$F\$ 分布 定理 13.5

$$F = \frac{S_X^2/\sigma_1^2}{S_Y^2/\sigma_2^2} \sim F(m-1, n-1)$$

特别地，当 \$\sigma_1^2 = \sigma_2^2\$ 时：

$$F = \frac{S_X^2}{S_Y^2} \sim F(m-1, n-1)$$

这是方差齐性检验（ F 检验）的基础。

定理六：方差已知时的两样本均值差 定理 13.6 当 σ_1^2 、 σ_2^2 已知时：

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}} \sim \mathcal{N}(0, 1)$$

定理七：等方差时的两样本 t 统计量 定理 13.7 当 $\sigma_1^2 = \sigma_2^2 = \sigma^2$ （未知）时，定义合并样本方差（pooled variance）：

$$S_p^2 = \frac{(m-1)S_X^2 + (n-1)S_Y^2}{m+n-2}$$

则：

$$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_p \sqrt{\frac{1}{m} + \frac{1}{n}}} \sim t(m+n-2)$$

直觉：两个样本方差合并估计公共方差 σ^2 ，总自由度为 $(m-1) + (n-1) = m+n-2$ 。

定理汇总表

场景	统计量	分布	应用
单正态, σ^2 已知	$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$	$\mathcal{N}(0, 1)$	Z 检验、置信区间
单正态, σ^2 未知	$\frac{\bar{X} - \mu}{S/\sqrt{n}}$	$t(n-1)$	t 检验
单正态, 估计方差	$\frac{(n-1)S^2}{\sigma^2}$	$\chi^2(n-1)$	σ^2 的置信区间
双正态, 等方差未知	$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_p \sqrt{1/m + 1/n}}$	$t(m+n-2)$	两样本 t 检验
双正态, 方差比	$\frac{S_X^2/\sigma_1^2}{S_Y^2/\sigma_2^2}$	$F(m-1, n-1)$	方差齐性检验

本章小结

核心概念层次：

总体分布 $\xrightarrow{\text{i.i.d. 抽样}}$ 样本 $\xrightarrow{\text{构造}}$ 统计量 $\xrightarrow{\text{导出}}$ 抽样分布

三大抽样分布的本质：

1. $\chi^2(n)$ 分布： n 个独立标准正态变量的平方和，描述“方差估计的波动”
2. $t(n)$ 分布：标准正态除以独立的 $\chi^2(n)/n$ 的平方根，描述“用样本标准差代替总体标准差后的不确定性”
3. $F(m, n)$ 分布：两个独立 χ^2 变量之比（各除以自由度），描述“两组方差的相对大小”

正态总体四大定理：

- $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$ （精确！不需大样本）
- $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$ （精确！自由度 $n-1$ 体现了约束）
- $\bar{X}$ 与 S^2 独立（正态特有）
- $(\bar{X} - \mu)/(S/\sqrt{n}) \sim t(n-1)$ （ σ^2 未知时的核心工具）

自由度直觉：自由度 = 独立信息的个数。估计 σ^2 时， n 个偏差 $X_i - \bar{X}$ 之和恒为零，只有 $n-1$ 个独立，故 S^2 的自由度为 $n-1$ 。

深度学习应用：模型评估、交叉验证与 Bootstrap

抽样分布在机器学习中的核心地位

深度学习模型的训练与评估本质上是统计推断问题：

- 训练集是总体（真实数据分布）的一个样本
- 测试集准确率是总体准确率的一个统计量
- 置信区间需要统计量的抽样分布

本节展示如何将本章理论直接应用于深度学习实践。

模型评估的统计理论

设模型在 n 个测试样本上的准确率为 $\hat{p} = k/n$ （ k 为正确分类数）。由 i.i.d. 伯努利假设：

$$k \sim B(n, p), \quad \hat{p} \approx \mathcal{N}\left(p, \frac{p(1-p)}{n}\right) \quad (\text{CLT})$$

因此真实准确率 p 的近似 95% 置信区间（Wald 区间）为：

$$\hat{p} \pm 1.96 \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

示例：若 $n = 1000$, $\hat{p} = 0.92$, 则置信区间为：

$$0.92 \pm 1.96 \sqrt{\frac{0.92 \times 0.08}{1000}} = 0.92 \pm 0.0167 = [0.903, 0.937]$$

注意：这一区间的宽度与样本量 n 成反比 ($\propto 1/\sqrt{n}$)，体现了本章的核心公式 $\text{Var}(\hat{p}) = p(1-p)/n$ 。

交叉验证的统计解释

k 折交叉验证 (k -Fold Cross-Validation) 将数据集分为 k 份，每次用 $k-1$ 份训练、1 份验证，共训练 k 次，得到 k 个验证误差 $\ell_1, \ell_2, \dots, \ell_k$ 。

统计量：

$$\bar{\ell} = \frac{1}{k} \sum_{i=1}^k \ell_i, \quad S_{\ell}^2 = \frac{1}{k-1} \sum_{i=1}^k (\ell_i - \bar{\ell})^2$$

由定理 13.4 (若 ℓ_i 近似正态)，泛化误差 μ_{ℓ} 的置信区间为：

$$\bar{\ell} \pm t_{\alpha/2}(k-1) \cdot \frac{S_{\ell}}{\sqrt{k}}$$

重要注意： k 折 CV 的各折误差并非严格独立 (共享训练数据)，因此上式是近似的，但在实践中广泛使用。

Bootstrap：当抽样分布难以解析推导时

对复杂统计量 (如 AUC、中位数、神经网络权重范数)，其精确抽样分布往往无法推导。**Bootstrap** 方法通过模拟重抽样来近似抽样分布。

Bootstrap 原理：

1. 从原始样本 $\{x_1, \dots, x_n\}$ 中有放回地随机抽取 n 个样本，得到一个 Bootstrap 样本
2. 计算统计量 T^*
3. 重复 B 次 ($B = 500 \sim 2000$)，得到 $T_1^*, T_2^*, \dots, T_B^*$
4. 用 $\{T_b^*\}$ 的分布近似 T 的抽样分布

Bootstrap 置信区间 (百分位法)：

$$[T_{(\alpha/2)}^*, T_{(1-\alpha/2)}^*]$$

其中 $T_{(q)}^*$ 为 Bootstrap 样本的 q 分位数。

PyTorch 代码示例

```

import torch
import torch.nn as nn
import torch.nn.functional as F
import numpy as np
from scipy import stats
import matplotlib.pyplot as plt

torch.manual_seed(42)
np.random.seed(42)

# 1. 模型准确率的置信区间 (Wald 区间 + Clopper-Pearson 精确区间)
def accuracy_confidence_interval(n_correct: int, n_total: int, alpha: float = 0.05):
    """
    计算分类模型准确率的置信区间。

    参数
    ----
    n_correct : 正确分类数
    n_total   : 测试样本总数
    alpha      : 显著性水平 (默认 0.05, 即 95% 置信区间)

    返回
    ----
    dict: 包含点估计、Wald 区间 (基于 CLT) 和精确区间 (Clopper-Pearson)
    """
    p_hat = n_correct / n_total
    z = stats.norm.ppf(1 - alpha / 2) #  $z_{\alpha/2}$ , 如  $z=1.96$  ( $\alpha=0.05$ )

    # Wald 区间 (CLT + 正态近似)
    se_wald = np.sqrt(p_hat * (1 - p_hat) / n_total)
    wald_lower = p_hat - z * se_wald
    wald_upper = p_hat + z * se_wald

    # Clopper-Pearson 精确区间 (基于 Beta 分布的二项分布精确解)
    # 利用 Beta 分布与二项分布的关系:
    #  $P(X \geq k \mid p) = P(\text{Beta}(k, n-k+1) \leq p)$ 
    exact_lower = stats.beta.ppf(alpha / 2, n_correct, n_total - n_correct + 1)
    exact_upper = stats.beta.ppf(1 - alpha / 2, n_correct + 1, n_total - n_correct)

```

```

return {
    "point_estimate": p_hat,
    "wald_interval": (max(0, wald_lower), min(1, wald_upper)),
    "exact_interval": (exact_lower, exact_upper),
    "se_wald": se_wald,
    "n_total": n_total,
}

```

示例：模型在 1000 个测试样本上正确分类 920 个

```

result = accuracy_confidence_interval(n_correct=920, n_total=1000)
print("=== 模型准确率的置信区间 ===")
print(f" 点估计: {result['point_estimate']:.4f}")
print(f"Wald 区间 (CLT): [{result['wald_interval'][0]:.4f}, {result['wald_interval'][1]:.4f}]")
print(f" 精确区间 (Clopper-Pearson): [{result['exact_interval'][0]:.4f}, {result['exact_interval'][1]:.4f}]")
print(f" 标准误: {result['se_wald']:.4f}")
print()

```

2. K 折交叉验证的 t 区间

```

def kfold_cv_confidence_interval(fold_losses: np.ndarray, alpha: float = 0.05):
    """

```

基于 k 折交叉验证结果计算泛化误差的 t 置信区间。

对应定理 13.4: 样本均值的 t 统计量 $= (\bar{x} - \mu) / (S / \sqrt{n}) \sim t(n-1)$

参数

fold_losses : 每折的验证损失, 形状 $(k,)$

alpha : 显著性水平

返回

dict: 均值、标准差、 t 区间

"""

```

k = len(fold_losses)
mean_loss = np.mean(fold_losses)
std_loss = np.std(fold_losses, ddof=1) # 无偏样本标准差, ddof=1 对应  $S$  (除以  $n-1$ )
se = std_loss / np.sqrt(k)

```

```

# t 分布分位数，自由度 k-1 (对应定理 13.4)
t_critical = stats.t.ppf(1 - alpha / 2, df=k - 1)

lower = mean_loss - t_critical * se
upper = mean_loss + t_critical * se

return {
    "mean": mean_loss,
    "std": std_loss,
    "se": se,
    "t_critical": t_critical,
    "confidence_interval": (lower, upper),
    "df": k - 1,
}

# 模拟 5 折交叉验证的损失 (来自某分类模型)
fold_losses = np.array([0.2341, 0.2187, 0.2456, 0.2298, 0.2375])

cv_result = kfold_cv_confidence_interval(fold_losses)
print("=== 5 折交叉验证的 t 置信区间 ===")
print(f" 各折损失: {fold_losses}")
print(f" 均值: {cv_result['mean']:.4f} ± 标准误: {cv_result['se']:.4f}")
print(f"t 临界值 (df={cv_result['df']}): {cv_result['t_critical']:.4f}")
print(f"95% 置信区间: [{cv_result['confidence_interval'][0]:.4f}, {cv_result['confidence_interval'][1]:.4f}]")
print()

# 3. Bootstrap 估计模型评估指标的抽样分布
def bootstrap_metric(
    y_true: np.ndarray,
    y_pred: np.ndarray,
    metric_fn,
    B: int = 1000,
    alpha: float = 0.05,
    random_seed: int = 42,
):
    """
    用 Bootstrap 方法估计任意评估指标 (如 AUC、F1) 的置信区间。

    当统计量的精确抽样分布不可知时 (非正态总体、复杂指标),

```

Bootstrap 用重抽样来近似抽样分布，是本章第 13.3 节思想的数值实现。

参数

y_true : 真实标签
y_pred : 预测分数或预测标签
metric_fn : 指标函数, 签名 *fn(y_true, y_pred) -> float*
B : *Bootstrap* 重抽样次数
alpha : 置信区间显著性水平
random_seed: 随机种子

返回

dict: 点估计、*Bootstrap* 均值、标准误、百分位置信区间

"""

```
rng = np.random.default_rng(random_seed)
```

```
n = len(y_true)
```

```
# 原始统计量 (点估计)
```

```
original_metric = metric_fn(y_true, y_pred)
```

```
# Bootstrap 重抽样
```

```
bootstrap_metrics = np.zeros(B)
```

```
for b in range(B):
```

```
    # 有放回地抽取 n 个样本的索引 (核心步骤)
```

```
    indices = rng.integers(0, n, size=n)
```

```
    bootstrap_metrics[b] = metric_fn(y_true[indices], y_pred[indices])
```

```
# 百分位置信区间
```

```
lower = np.percentile(bootstrap_metrics, 100 * alpha / 2)
```

```
upper = np.percentile(bootstrap_metrics, 100 * (1 - alpha / 2))
```

```
return {
```

```
    "point_estimate": original_metric,
```

```
    "bootstrap_mean": np.mean(bootstrap_metrics),
```

```
    "bootstrap_std": np.std(bootstrap_metrics, ddof=1),
```

```
    "confidence_interval": (lower, upper),
```

```
    "bootstrap_samples": bootstrap_metrics,
```

```
    "B": B,
```

```
}
```

构造二分类问题的模拟数据

```
n_test = 500
true_probs = np.random.beta(2, 5, size=n_test)    # 真正正类概率
y_true_sim = (np.random.rand(n_test) < true_probs).astype(int)
y_pred_sim = true_probs + np.random.normal(0, 0.1, size=n_test) # 带噪声的预测分数
y_pred_sim = np.clip(y_pred_sim, 0, 1)
```

```
def accuracy_at_threshold(y_true, y_pred, threshold=0.5):
    """ 以给定阈值计算准确率 """
    return np.mean((y_pred >= threshold) == y_true)
```

```
def f1_score_metric(y_true, y_pred, threshold=0.5):
    """ 计算 F1 分数 """
    y_pred_binary = (y_pred >= threshold).astype(int)
    tp = np.sum((y_pred_binary == 1) & (y_true == 1))
    fp = np.sum((y_pred_binary == 1) & (y_true == 0))
    fn = np.sum((y_pred_binary == 0) & (y_true == 1))
    precision = tp / (tp + fp + 1e-9)
    recall = tp / (tp + fn + 1e-9)
    return 2 * precision * recall / (precision + recall + 1e-9)
```

Bootstrap 估计准确率和 *F1* 的置信区间

```
bootstrap_acc = bootstrap_metric(y_true_sim, y_pred_sim, accuracy_at_threshold, B=2000)
bootstrap_f1 = bootstrap_metric(y_true_sim, y_pred_sim, f1_score_metric, B=2000)
```

```
print("=== Bootstrap 置信区间 ===")
print(f" 准确率 ——点估计: {bootstrap_acc['point_estimate']:.4f}")
print(f"  Bootstrap SE: {bootstrap_acc['bootstrap_std']:.4f}")
print(f"  95% CI: [{bootstrap_acc['confidence_interval'][0]:.4f}, {bootstrap_acc['confidence_interval'][-1]:.4f}]")
print()
print(f"F1 分数 ——点估计: {bootstrap_f1['point_estimate']:.4f}")
print(f"  Bootstrap SE: {bootstrap_f1['bootstrap_std']:.4f}")
print(f"  95% CI: [{bootstrap_f1['confidence_interval'][0]:.4f}, {bootstrap_f1['confidence_interval'][-1]:.4f}]")
print()
```

4. 可视化: *Bootstrap* 抽样分布与正态近似的比较


```

fig, axes = plt.subplots(1, 2, figsize=(12, 5))
fig.suptitle('Bootstrap 抽样分布 vs. 正态近似 (CLT) ', fontsize=13)

for ax, (name, bs_result) in zip(
    axes, [("准确率", bootstrap_acc), ("F1 分数", bootstrap_f1)]
):
    samples = bs_result["bootstrap_samples"]
    mu_hat = bs_result["bootstrap_mean"]
    se_hat = bs_result["bootstrap_std"]

    # Bootstrap 直方图 (实际抽样分布)
    ax.hist(samples, bins=50, density=True, alpha=0.7,
            color='steelblue', label='Bootstrap 分布')

    # CLT 正态近似 (基于 Wald 区间的理论分布)
    x = np.linspace(samples.min(), samples.max(), 200)
    ax.plot(x, stats.norm.pdf(x, mu_hat, se_hat),
            'r-', linewidth=2.5, label=f'正态近似\n $\mathcal{N}(\mu\_hat:.3f, \{se\_hat:.3f\}^2)$ ')

    # 标记置信区间边界
    ci = bs_result["confidence_interval"]
    ax.axvline(ci[0], color='orange', linestyle='--', linewidth=1.5, label=f'95% CI 下界 {ci[0]:.3f}')
    ax.axvline(ci[1], color='green', linestyle='--', linewidth=1.5, label=f'95% CI 上界 {ci[1]:.3f}')

    # Shapiro-Wilk 正态性检验 (检验 Bootstrap 分布是否接近正态)
    _, p_sw = stats.shapiro(np.random.choice(samples, 500, replace=False))

    ax.set_title(f'{name}的 Bootstrap 分布\nShapiro-Wilk 正态性检验 p = {p_sw:.3f}', fontsize=11)
    ax.set_xlabel(name)
    ax.set_ylabel('密度')
    ax.legend(fontsize=8)

plt.tight_layout()
plt.savefig('bootstrap_sampling_distribution.png', dpi=150)
plt.show()

# 5. 两模型的 F 检验：比较方差 (对应定理 13.5)
print("=== 两模型 F 检验：比较损失方差 ===")

# 模拟两个模型在 5 折 CV 上的损失

```

```
losses_model_A = np.array([0.2341, 0.2187, 0.2456, 0.2298, 0.2375]) # 较稳定
losses_model_B = np.array([0.2100, 0.2800, 0.2050, 0.2950, 0.1900]) # 波动大

var_A = np.var(losses_model_A, ddof=1)
var_B = np.var(losses_model_B, ddof=1)

# F 统计量:  $S_A^2 / S_B^2 \sim F(n_A - 1, n_B - 1)$  (零假设: 方差相等)
n_A, n_B = len(losses_model_A), len(losses_model_B)
F_stat = var_A / var_B
df1, df2 = n_A - 1, n_B - 1

# 双侧 p 值 (检验方差是否相等)
p_value_F = 2 * min(
    stats.f.cdf(F_stat, df1, df2),
    1 - stats.f.cdf(F_stat, df1, df2),
)

print(f" 模型 A 的样本方差:  $S^2_A = \{var\_A:.6f\}$  (自由度  $\{df1\}$ ) ")
print(f" 模型 B 的样本方差:  $S^2_B = \{var\_B:.6f\}$  (自由度  $\{df2\}$ ) ")
print(f"F 统计量:  $F = S^2_A / S^2_B = \{F\_stat:.4f\}$ ")
print(f" 双侧 p 值:  $\{p\_value\_F:.4f\}$ ")
print(f" 结论: {'两模型方差有显著差异 ( =0.05) ' if p_value_F < 0.05 else '无充分证据表明方差不同 ( =0.05) '}")
print()
print(" 注: 本例自由度较小 (df=4), F 检验效能有限; 实际应使用更多折数或重复实验。")
```

理论与实践的对应关系

本章理论	机器学习应用	对应工具
$\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$	准确率的 Wald 置信区间	accuracy_confidence_interval
$t(n-1)$ 分布, σ^2 未知	k 折 CV 的泛化误差区间	kfold_cv_confidence_interval
抽样分布 (复杂统计量)	Bootstrap 置信区间	bootstrap_metric
$F(m-1, n-1)$ 分布	两模型方差齐性 F 检验	stats.f.cdf

练习题

题 1 (基础) 设 $(X_1, X_2, \dots, X_n)$ 是来自总体 $X \sim B(1, p)$ (伯努利分布) 的简单随机样本。

(a) 写出样本的联合概率质量函数 (pmf)。

- (b) 证明样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 是参数 p 的无偏估计。
- (c) 证明样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 是总体方差 $p(1-p)$ 的无偏估计。
-

题 2 (卡方分布) 设 $X_1, X_2, \dots, X_6$ 独立同分布于 $\mathcal{N}(2, 4)$ (均值 2, 方差 4)。

- (a) 写出 $Y = \sum_{i=1}^6 \left(\frac{X_i - 2}{2} \right)^2$ 所服从的分布。
- (b) 求 $\mathbb{E}[Y]$ 和 $\text{Var}(Y)$ 。
- (c) 设 $\bar{X} = \frac{1}{6} \sum_{i=1}^6 X_i$, $S^2 = \frac{1}{5} \sum_{i=1}^6 (X_i - \bar{X})^2$, 确定 $Z = \frac{5S^2}{4}$ 所服从的分布, 并计算 $P(Z > 11.07)$ 。
-

题 3 (t 分布的推导) 设 $X \sim \mathcal{N}(0, 1)$, $Y \sim \chi^2(n)$, X 与 Y 相互独立。

- (a) 验证 $T = X/\sqrt{Y/n}$ 的密度函数确为 $t(n)$ 分布的密度 (提示: 先求 $\sqrt{Y/n}$ 的密度, 再做商的变换)。
- (b) 证明当 $n \rightarrow \infty$ 时, $t(n)$ 的密度函数逐点收敛到 $\mathcal{N}(0, 1)$ 的密度函数。
- (c) 设 $T \sim t(10)$, 利用分位数表求 $P(|T| > 2.228)$ 。
-

题 4 (正态总体抽样分布) 设 $(X_1, X_2, \dots, X_{10})$ 是来自 $\mathcal{N}(\mu, \sigma^2)$ 的样本, $\bar{X}$ 为样本均值, S^2 为样本方差。

- (a) 当 $\sigma^2 = 4$ 已知时, 写出 $\bar{X}$ 的精确分布, 并求 $P(|\bar{X} - \mu| > 1)$ 。
- (b) 当 σ^2 未知时, 写出统计量 $T = \frac{\bar{X} - \mu}{S/\sqrt{10}}$ 所服从的分布, 并求 $P(|T| > 2.262)$ 。
- (c) 写出 $\frac{9S^2}{\sigma^2}$ 所服从的分布, 并求该统计量落在区间 $(2.70, 19.02)$ 内的概率。
-

题 5 (两样本 F 检验) 设有两个独立样本, 分别来自正态总体 $\mathcal{N}(\mu_1, \sigma_1^2)$ 和 $\mathcal{N}(\mu_2, \sigma_2^2)$, 样本量均为 $n = 11$, 样本方差分别为 $S_1^2 = 3.2$ 和 $S_2^2 = 1.6$ 。

- (a) 写出检验 $H_0: \sigma_1^2 = \sigma_2^2$ vs. $H_1: \sigma_1^2 \neq \sigma_2^2$ 的 F 统计量, 并确定其在 H_0 下的分布。
- (b) 计算 F 统计量的值, 并在显著性水平 $\alpha = 0.10$ 下作出判断 (需要: $F_{0.05}(10, 10) = 2.98$)。
- (c) 若两个样本量不同, 分别为 $m = 11$ 和 $n = 21$, 且 $S_1^2 = 3.2$, $S_2^2 = 1.6$, 重新计算并判断 ($F_{0.05}(10, 20) = 2.35$)。
-

练习答案

题 1 详细解答

(a) 联合概率质量函数

由于 $X_i \sim B(1, p)$, 即 $P(X_i = 1) = p$, $P(X_i = 0) = 1 - p$, 独立同分布, 联合 pmf 为:

$$P(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^{\sum x_i} (1-p)^{n-\sum x_i}$$

其中 $x_i \in \{0, 1\}$, $i = 1, \dots, n$ 。

(b) $\bar{X}$ 的无偏性

$$\mathbb{E}[\bar{X}] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] = \frac{1}{n} \cdot np = p$$

故 $\mathbb{E}[\bar{X}] = p$, 即 $\bar{X}$ 是 p 的无偏估计。■

(c) S^2 的无偏性

由命题 13.2, 对任意总体只要 $\mathbb{E}[X] = p$, $\text{Var}(X) = p(1-p)$, 有:

$$\mathbb{E}[S^2] = \text{Var}(X) = p(1-p)$$

故 S^2 是总体方差 $p(1-p)$ 的无偏估计。■

题 2 详细解答

(a) Y 的分布

$X_i \sim \mathcal{N}(2, 4)$, 故 $\frac{X_i - 2}{2} \sim \mathcal{N}(0, 1)$, 且相互独立, 于是:

$$Y = \sum_{i=1}^6 \left(\frac{X_i - 2}{2} \right)^2 \sim \chi^2(6)$$

(b) 期望与方差

$$\mathbb{E}[Y] = 6, \quad \text{Var}(Y) = 2 \times 6 = 12$$

(c) Z 的分布及概率

由定理 13.2, $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$, 其中 $n = 6$, $\sigma^2 = 4$:

$$Z = \frac{5S^2}{4} = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(5)$$

由 $\chi^2(5)$ 分位数表, $\chi_{0.05}^2(5) = 11.07$ (即上 5% 分位点), 因此:

$$P(Z > 11.07) = P(\chi^2(5) > 11.07) = 0.05$$

题 3 详细解答

(a) $t(n)$ 密度的验证 (思路)

设 $W = \sqrt{Y/n}$, 由 $Y \sim \chi^2(n)$, 其密度为 $f_Y(y) = \frac{y^{n/2-1}e^{-y/2}}{2^{n/2}\Gamma(n/2)}$ ($y > 0$)。

令 $w = \sqrt{y/n}$ ($y = nw^2$, $dy = 2nw dw$), 则 W 的密度为:

$$f_W(w) = \frac{2(nw^2)^{n/2-1}e^{-nw^2/2}}{2^{n/2}\Gamma(n/2)} \cdot 2nw = \frac{2n^{n/2}w^{n-1}e^{-nw^2/2}}{2^{n/2}\Gamma(n/2)}, \quad w > 0$$

对 $T = X/W$ (X 与 W 独立), 用联合密度积分:

$$f_T(t) = \int_0^\infty f_X(tw) \cdot f_W(w) \cdot w dw$$

代入 $f_X(u) = \frac{1}{\sqrt{2\pi}}e^{-u^2/2}$ 并化简, 可得标准 $t(n)$ 密度公式。

(b) $t(n) \rightarrow \mathcal{N}(0, 1)$ (逐点)

$t(n)$ 密度中, 令 $n \rightarrow \infty$:

$$\left(1 + \frac{t^2}{n}\right)^{-(n+1)/2} = \left[\left(1 + \frac{t^2}{n}\right)^n\right]^{-1/2} \cdot \left(1 + \frac{t^2}{n}\right)^{-1/2} \rightarrow e^{-t^2/2} \cdot 1$$

同时, 由 Stirling 公式: $\frac{\Gamma((n+1)/2)}{\sqrt{n\pi}\Gamma(n/2)} \rightarrow \frac{1}{\sqrt{2\pi}}$ 。

因此 $f_{t(n)}(t) \rightarrow \frac{1}{\sqrt{2\pi}}e^{-t^2/2} = \phi(t)$, 即逐点收敛到 $\mathcal{N}(0, 1)$ 密度。

(c) 查表计算

$t_{0.025}(10) = 2.228$ (上 2.5% 分位点), 由对称性:

$$P(|T| > 2.228) = P(T > 2.228) + P(T < -2.228) = 0.025 + 0.025 = 0.05$$

题 4 详细解答

(a) $\sigma^2 = 4$ 已知, $n = 10$

由定理 13.1, $\bar{X} \sim \mathcal{N}(\mu, 4/10) = \mathcal{N}(\mu, 0.4)$, 即 $\bar{X} \sim \mathcal{N}(\mu, (2/\sqrt{10})^2)$ 。

$$P(|\bar{X} - \mu| > 1) = P\left(\left|\frac{\bar{X} - \mu}{2/\sqrt{10}}\right| > \frac{1}{2/\sqrt{10}}\right) = P\left(|Z| > \frac{\sqrt{10}}{2}\right) = P(|Z| > 1.581)$$

$$= 2(1 - \Phi(1.58)) \approx 2(1 - 0.9429) = 2 \times 0.0571 = \mathbf{0.1142}$$

(b) σ^2 未知, t 统计量

由定理 13.4, $T = \frac{\bar{X} - \mu}{S/\sqrt{10}} \sim t(9)$ 。

查 t 分布表, $t_{0.025}(9) = 2.262$, 由对称性:

$$P(|T| > 2.262) = 0.025 + 0.025 = \mathbf{0.05}$$

(c) $9S^2/\sigma^2$ 的分布及概率

由定理 13.2, $\frac{(n-1)S^2}{\sigma^2} = \frac{9S^2}{\sigma^2} \sim \chi^2(9)$ 。

查 $\chi^2(9)$ 分布表: $\chi_{0.975}^2(9) = 2.70$ (下 2.5% 分位点), $\chi_{0.025}^2(9) = 19.02$ (上 2.5% 分位点), 因此:

$$P\left(2.70 < \frac{9S^2}{\sigma^2} < 19.02\right) = P(\chi_{0.975}^2(9) < \chi^2(9) < \chi_{0.025}^2(9)) = 1 - 0.025 - 0.025 = \mathbf{0.95}$$

题 5 详细解答

(a) F 统计量

两样本量均为 $n = 11$, 样本方差分别为 $S_1^2 = 3.2$, $S_2^2 = 1.6$ 。

由定理 13.5, 在 $H_0: \sigma_1^2 = \sigma_2^2$ 下:

$$F = \frac{S_1^2}{S_2^2} \sim F(n-1, n-1) = F(10, 10)$$

(b) $n_1 = n_2 = 11$, $\alpha = 0.10$

$$F = \frac{3.2}{1.6} = 2.00$$

双侧检验的拒绝域为 $F > F_{0.05}(10, 10) = 2.98$ 或 $F < F_{0.95}(10, 10) = \frac{1}{F_{0.05}(10, 10)} = \frac{1}{2.98} \approx 0.336$ 。

由于 $0.336 < 2.00 < 2.98$, 不落入拒绝域, 故在 $\alpha = 0.10$ 下不能拒绝 H_0 , 即无充分证据认为两总体方差不同。

(c) $m = 11, n = 21, \alpha = 0.10$

$$F = \frac{S_1^2}{S_2^2} = \frac{3.2}{1.6} = 2.00 \sim F(10, 20) (\text{在 } H_0 \text{ 下})$$

上 5% 分位点: $F_{0.05}(10, 20) = 2.35$; 下 5% 分位点: $F_{0.95}(10, 20) = \frac{1}{F_{0.05}(20, 10)}$ 。

查表 $F_{0.05}(20, 10) = 2.77$, 故下界为 $1/2.77 \approx 0.361$ 。

拒绝域: $F > 2.35$ 或 $F < 0.361$ 。

由于 $2.00 < 2.35$, 不落入拒绝域, 同样不能拒绝 H_0 。

但注意: 样本量 n_2 从 11 增加到 21 后, F 分布的上分位点从 2.98 降至 2.35, 使检验更灵敏 (更容易拒绝 H_0), 体现了样本量对检验功效的影响。

下一章预告: 第 14 章: 数据描述与可视化 — 我们将学习描述性统计的基本方法, 包括位置度量、散布度量、形状度量以及各种可视化技术, 为后续的统计推断奠定数据分析基础。

第 14 章：数据描述与可视化

学习目标

学完本章后, 你将能够:

- 掌握均值、中位数、众数等位置度量的定义与计算, 理解它们在不同分布下的适用场景
 - 理解方差、标准差、极差与四分位距等散布度量的含义, 能用它们刻画数据的离散程度
 - 了解偏度与峰度的含义, 能通过这两个指标判断数据分布的形状特征
 - 熟练运用直方图、箱线图、QQ 图等可视化工具探索数据的分布规律
 - 将描述统计应用于深度学习中的数据探索、特征工程与异常检测任务
-

14.1 位置度量

引入: 数据的”中心”在哪里?

在收集到一批数据后, 首要任务往往是找到数据的中心位置——一个能代表整体水平的典型值。根据数据的性质和使用目的, ”中心”有多种定义方式。

设 $x_1, x_2, \dots, x_n$ 为来自某总体的 n 个观测值。

均值

样本均值 (Sample Mean) 是最常用的位置度量：

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

均值是数据的重心，对数据中的每个点赋予相同权重。

性质：

- 线性性：若 $y_i = ax_i + b$ ，则 $\bar{y} = a\bar{x} + b$
- 最小化平方偏差： $\bar{x}$ 是使 $\sum_{i=1}^n (x_i - c)^2$ 最小的 c
- 对异常值敏感：一个极端值可以显著改变均值

加权均值：若每个观测 x_i 具有权重 $w_i > 0$ ，则：

$$\bar{x}_w = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i}$$

总体均值 (期望) 是理论对应物：

$$\mu = \mathbb{E}[X] = \begin{cases} \sum_k k \cdot P(X = k) & (\text{离散}) \\ \int_{-\infty}^{+\infty} x f(x) dx & (\text{连续}) \end{cases}$$

中位数

将数据从小到大排序后，中位数 (Median) 是位于中间位置的值：

$$M = \begin{cases} x_{((n+1)/2)} & \text{若 } n \text{ 为奇数} \\ \frac{x_{(n/2)} + x_{(n/2+1)}}{2} & \text{若 } n \text{ 为偶数} \end{cases}$$

其中 $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$ 为顺序统计量 (order statistics)。

性质：

- 对异常值稳健：改变最大或最小值不影响中位数
- 最小化绝对偏差：中位数是使 $\sum_{i=1}^n |x_i - c|$ 最小的 c
- 对称分布时 $M = \mu$

众数

众数（Mode）是数据中出现频率最高的值。对于连续分布，众数是密度函数的极大值点：

$$Mo = \arg \max_x f(x)$$

- 数据可能存在多个众数（多峰分布）
- 适合描述分类数据或离散数据

三者的关系与比较

对于右偏分布（正偏）：众数 < 中位数 < 均值

对于左偏分布（负偏）：均值 < 中位数 < 众数

对于对称分布：众数 = 中位数 = 均值

度量	优点	缺点	适用场景
均值	利用所有信息，数学性质好	对异常值敏感	对称、无极端值数据
中位数	稳健，不受极端值影响	忽略极端信息	偏态数据、含异常值数据
众数	直观，适合分类	可能不唯一	分类数据、多峰分布

分位数

p 分位数（Quantile） Q_p 满足：至少有 p 比例的数据不超过 Q_p ，至少有 $1 - p$ 比例的数据不小于 Q_p 。

常用分位数：- 四分位数： Q_1 （25%）， Q_2 （50% = 中位数）， Q_3 （75%） - 十分位数： $D_1, D_2, \dots, D_9$ - 百分位数： $P_1, P_2, \dots, P_{99}$

14.2 散布度量

引入：数据有多”分散”？

两组数据可以有相同的均值，却有完全不同的离散程度。散布度量刻画数据偏离中心的程度。

方差与标准差

样本方差 (Sample Variance):

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

分母使用 $n-1$ (而非 n) 是为了得到总体方差的无偏估计 (将在第 15 章详细讨论)。

总体方差 (Population Variance):

$$\sigma^2 = \mathbb{E}[(X - \mu)^2]$$

标准差 (Standard Deviation) 是方差的平方根, 与原数据量纲相同:

$$s = \sqrt{s^2}, \quad \sigma = \sqrt{\sigma^2}$$

计算公式 (简化形式):

$$s^2 = \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right)$$

变异系数 (Coefficient of Variation, CV) 是标准差与均值之比, 消除了量纲影响:

$$CV = \frac{s}{|\bar{x}|} \times 100\%$$

极差

极差 (Range) 是最大值与最小值之差:

$$R = x_{(n)} - x_{(1)}$$

极差计算简单, 但仅利用两个端点信息, 对异常值极敏感。

四分位距

四分位距 (Interquartile Range, IQR) 定义为:

$$\text{IQR} = Q_3 - Q_1$$

IQR 包含了数据中间 50% 的范围，对异常值具有稳健性，是箱线图的核心度量。

异常值检测规则（Tukey's fences）：

$$\text{下界} = Q_1 - 1.5 \cdot \text{IQR}, \quad \text{上界} = Q_3 + 1.5 \cdot \text{IQR}$$

超出此范围的点被标记为疑似异常值。

平均绝对偏差

平均绝对偏差（Mean Absolute Deviation, MAD）：

$$\text{MAD} = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

相较于方差，MAD 对异常值更加稳健，但数学性质不如方差优良。

散布度量的比较

度量	公式	稳健性	适用场景
方差/标准差	s^2, s	弱	正态分布，统计推断
极差	R	很弱	快速估计，质量控制
IQR	$Q_3 - Q_1$	强	偏态数据，含异常值
MAD	$\frac{1}{n} \sum x_i - \bar{x} $	较强	稳健统计分析

14.3 形状度量

偏度

偏度（Skewness）衡量分布关于均值的不对称程度。样本偏度的定义为：

$$\text{Skew} = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3$$

这是标准化三阶中心矩。总体偏度为：

$$\gamma_1 = \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] = \frac{\mu_3}{\sigma^3}$$

其中 $\mu_3 = \mathbb{E}[(X - \mu)^3]$ 为三阶中心矩。

解读：- $\gamma_1 = 0$ ：对称分布（如正态分布）- $\gamma_1 > 0$ ：右偏（正偏），右尾更长，均值大于中位数 - $\gamma_1 < 0$ ：左偏（负偏），左尾更长，均值小于中位数

常见分布的偏度：- 正态分布： $\gamma_1 = 0$ - 指数分布（参数 λ ）： $\gamma_1 = 2$ - 均匀分布： $\gamma_1 = 0$ - 对数正态分布： $\gamma_1 = (e^{\sigma^2} + 2)\sqrt{e^{\sigma^2} - 1} > 0$

峰度

峰度（Kurtosis）衡量分布尾部的厚薄程度和峰顶的尖锐程度。总体峰度为：

$$\gamma_2 = \mathbb{E}\left[\left(\frac{X - \mu}{\sigma}\right)^4\right] = \frac{\mu_4}{\sigma^4}$$

其中 $\mu_4 = \mathbb{E}[(X - \mu)^4]$ 为四阶中心矩。

超额峰度（Excess Kurtosis）以正态分布（峰度 = 3）为基准：

$$\kappa = \gamma_2 - 3$$

解读：- $\kappa = 0$ ：正态峰（mesokurtic），如正态分布 - $\kappa > 0$ ：尖峰厚尾（leptokurtic），尾部概率更大，如 t 分布 - $\kappa < 0$ ：平峰薄尾（platykurtic），尾部概率更小，如均匀分布

常见分布的超额峰度：- 正态分布： $\kappa = 0$ - $t(k)$ 分布： $\kappa = \frac{6}{k-4}$ ($k > 4$)，随自由度增加趋近于 0 - 均匀分布： $\kappa = -\frac{6}{5}$ - 拉普拉斯分布： $\kappa = 3$

正态性检验的统计量

偏度和峰度是检验数据是否来自正态分布的重要工具。**Jarque-Bera** 检验统计量为：

$$JB = \frac{n}{6} \left[\text{Skew}^2 + \frac{(\kappa)^2}{4} \right]$$

在正态假设下， $JB \xrightarrow{d} \chi^2(2)$ 。

14.4 数据可视化

直方图

直方图（Histogram）将数据划分为若干区间（bins），用矩形的面积（或高度）表示各区间的频率（或频数）。

设将数据范围 $[a, b]$ 划分为 k 个等宽区间，每个区间宽度 $h = (b - a)/k$ ，第 j 个区间 $[a + (j - 1)h, a + jh)$ 中有 n_j 个数据点，则：

$$\text{频率密度} = \frac{n_j/n}{h}$$

直方图面积之和为 1，当 $n \rightarrow \infty$ ， $h \rightarrow 0$ 时，直方图收敛到总体的概率密度函数。

区间数的选择规则：- **Sturges** 规则： $k = \lceil 1 + \log_2 n \rceil$ - **Scott** 规则： $h = 3.5s \cdot n^{-1/3}$ （最小化均方积分误差） - **Freedman-Diaconis** 规则： $h = 2 \cdot \text{IQR} \cdot n^{-1/3}$ （更稳健）

核密度估计（KDE）是直方图的光滑版本：

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)$$

其中 $K(\cdot)$ 为核函数（常用 Gaussian 核）， h 为带宽。

箱线图

箱线图（Box Plot，又称 Box-and-Whisker Plot）用五个数字汇总数据：

$$\{\min^*, Q_1, Q_2, Q_3, \max^*\}$$

其中 $\min^*$ 和 $\max^*$ 为去除异常值后的最小最大值（即 Tukey's fences 内的端点）。

箱线图的构成：- 箱体（Box）：从 Q_1 到 Q_3 ，高度为 IQR - 中线（Median line）： Q_2 处的横线 - 须（Whiskers）：从箱体延伸到 $Q_1 - 1.5 \cdot \text{IQR}$ 和 $Q_3 + 1.5 \cdot \text{IQR}$ 之内最远的数据点 - 异常值：须之外的点，用单独符号标出

箱线图的用途：- 快速了解数据分布的位置、散布和偏态 - 对比多组数据的分布差异 - 识别潜在异常值

QQ 图

QQ 图（Quantile-Quantile Plot）通过对比样本分位数与理论分位数，检验数据是否来自某一理论分布（常用正态分布）。

正态 QQ 图的构造：

1. 将样本 $x_1, \dots, x_n$ 从小到大排序，得顺序统计量 $x_{(1)} \leq \dots \leq x_{(n)}$
2. 计算经验分位数对应的理论正态分位数：

$$q_i = \Phi^{-1}\left(\frac{i - 0.5}{n}\right)$$

（常用 Blom 修正： $(i - 3/8)/(n + 1/4)$ ）

3. 以 q_i 为横轴, $x_{(i)}$ 为纵轴画散点图

解读：- 若点大致落在一条直线上，则数据近似正态 - 上方弯曲 (heavy upper tail)：右尾比正态厚 - 下方弯曲 (heavy lower tail)：左尾比正态厚 - S 形曲线：数据比正态具有更厚的双尾（高峰度）

其他常用图形

茎叶图 (Stem-and-Leaf Plot)：在展示直方图信息的同时保留原始数据值，适合小数据集。

散点图 (Scatter Plot)：展示两个变量之间的关系，是发现相关性和模式的基本工具。

累积分布图 (ECDF)：经验累积分布函数：

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}[x_i \leq x]$$

由 Glivenko-Cantelli 定理, $\sup_x |F_n(x) - F(x)| \xrightarrow{a.s.} 0$ 。

14.5 多变量数据描述

协方差与相关系数

对于 n 对观测 $(x_1, y_1), \dots, (x_n, y_n)$, 样本协方差为：

$$s_{XY} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Pearson 相关系数消除了量纲影响：

$$r = \frac{s_{XY}}{s_X s_Y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}}$$

性质：- $-1 \leq r \leq 1$ (Cauchy-Schwarz 不等式保证) - $r = \pm 1$ 当且仅当 $y_i = ax_i + b$ (完全线性关系) - $r = 0$ 不意味着独立 (只排除线性相关)

Spearman 秩相关系数 (对非线性单调关系更稳健)：

$$r_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

其中 d_i 为 x_i 与 y_i 的秩之差。

协方差矩阵

对于 p 维随机向量 $\mathbf{X} = (X_1, \dots, X_p)^\top$ ，协方差矩阵 (Covariance Matrix) 为：

$$\Sigma = \text{Cov}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top]$$

其中 $\Sigma_{ij} = \text{Cov}(X_i, X_j)$ ，对角元素 $\Sigma_{ii} = \text{Var}(X_i)$ 。

样本协方差矩阵：

$$\mathbf{S} = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top = \frac{1}{n-1} \mathbf{X}_c^\top \mathbf{X}_c$$

其中 $\mathbf{X}_c$ 是中心化后的数据矩阵（每列减去均值）。

协方差矩阵是半正定对称矩阵 (positive semi-definite symmetric matrix)。

相关矩阵

相关矩阵 (Correlation Matrix) 是标准化的协方差矩阵：

$$\mathbf{R} = \mathbf{D}^{-1/2} \Sigma \mathbf{D}^{-1/2}$$

其中 $\mathbf{D} = \text{diag}(\sigma_1^2, \dots, \sigma_p^2)$ ， $R_{ij} = \rho_{ij} \in [-1, 1]$ 。

多变量可视化

- 散点图矩阵 (Scatter Plot Matrix / Pairs Plot)：对角线为各变量直方图/KDE，非对角线为两两散点图
- 热力图 (Heatmap)：用颜色编码相关矩阵，直观展示变量间的线性关系
- 平行坐标图 (Parallel Coordinates)：适合高维数据的模式识别
- 主成分分析 (PCA) 投影：将高维数据投影到二维，保留最大方差方向

本章小结

本章系统介绍了描述统计的核心工具：

1. 位置度量：均值（最小化平方偏差）、中位数（最小化绝对偏差，对异常值稳健）、众数（最高频率值）；分位数是这些概念的推广。
2. 散布度量：方差/标准差刻画数据与均值的平均偏离；IQR 和 MAD 是稳健替代；极差简单但脆弱。

3. 形状度量：偏度（三阶标准矩）描述不对称性；峰度（四阶标准矩）描述尾部厚薄；Jarque-Bera 统计量结合两者用于正态性检验。
 4. 可视化：直方图和 KDE 展示一维分布；箱线图提供五数摘要并标示异常值；QQ 图检验分布假设；散点图和相关热力图探索多变量关系。
 5. 多变量描述：Pearson 相关系数度量线性关系；协方差矩阵是多变量统计的基础结构；散点图矩阵是多变量探索的标准工具。
-

深度学习应用

14.A 数据探索 (Exploratory Data Analysis)

在训练深度学习模型之前，数据探索是不可跳过的步骤。以下代码展示如何对 MNIST-like 图像数据集进行描述统计分析。

```
import torch
import torch.nn as nn
import numpy as np
import matplotlib.pyplot as plt
from torchvision import datasets, transforms
from torch.utils.data import DataLoader

# 加载数据集
transform = transforms.ToTensor()
dataset = datasets.MNIST(root='./data', train=True, download=True, transform=transform)
loader = DataLoader(dataset, batch_size=10000, shuffle=False)

# 获取所有像素值
all_pixels = []
all_labels = []
for images, labels in loader:
    # images: [B, 1, 28, 28]
    all_pixels.append(images.view(images.size(0), -1)) # [B, 784]
    all_labels.append(labels)

pixels = torch.cat(all_pixels, dim=0).numpy() # [N, 784]
labels = torch.cat(all_labels, dim=0).numpy()

# 计算全局描述统计
def describe(x: np.ndarray, name: str = "数据"):
```



```

print(f"\n{name} 描述统计 (样本量 n={len(x)}) ")
print(f"  均值      = {x.mean():.4f}")
print(f"  中位数    = {np.median(x):.4f}")
print(f"  标准差    = {x.std(ddof=1):.4f}")
print(f"  最小值    = {x.min():.4f}")
print(f"  Q1       = {np.percentile(x, 25):.4f}")
print(f"  Q3       = {np.percentile(x, 75):.4f}")
print(f"  最大值    = {x.max():.4f}")
print(f"  IQR      = {np.percentile(x, 75) - np.percentile(x, 25):.4f}")
# 偏度和峰度
n = len(x)
z = (x - x.mean()) / x.std(ddof=1)
skew = (z**3).mean()
kurt = (z**4).mean() - 3.0 # 超额峰度
print(f"  偏度      = {skew:.4f}")
print(f"  超额峰度 = {kurt:.4f}")

```

对每类数字的平均像素亮度进行分析

```

mean_brightness = pixels.mean(axis=1) # 每张图的平均亮度
describe(mean_brightness, " 图像平均亮度")

```

按类别分组分析

```

for cls in range(10):
    idx = labels == cls
    describe(mean_brightness[idx], f" 类别 {cls}")

```

可视化：直方图 + KDE

```

fig, axes = plt.subplots(2, 5, figsize=(15, 6))
for cls, ax in enumerate(axes.flat):
    idx = labels == cls
    bright = mean_brightness[idx]
    ax.hist(bright, bins=40, density=True, alpha=0.6, color=f'C{cls}')
    ax.set_title(f'Digit {cls}')
    ax.set_xlabel('Mean Brightness')
ax.set_ylabel('Density')
plt.suptitle('MNIST 各类别亮度分布', fontsize=14)
plt.tight_layout()
plt.savefig('mnist_brightness_hist.png', dpi=150)
plt.show()

```

14.B 特征工程中的描述统计

在神经网络训练中，批归一化（Batch Normalization）本质上是对每个特征计算批次内的均值和标准差，然后进行标准化：

$$\hat{x}_i = \frac{x_i - \mu_{\mathcal{B}}}{\sqrt{\sigma_{\mathcal{B}}^2 + \epsilon}}, \quad y_i = \gamma \hat{x}_i + \beta$$

下面的代码展示如何手动实现 BatchNorm 并与 PyTorch 内置版本对比，加深对其统计含义的理解：

[illegible]

```

    else:
        batch_mean = self.running_mean
        batch_var = self.running_var

    # 标准化 (z-score 变换)
    x_hat = (x - batch_mean) / torch.sqrt(batch_var + self.eps)

    # 仿射变换 (恢复表达能力)
    return self.gamma * x_hat + self.beta

# 验证手动实现与 PyTorch 内置版本的一致性
torch.manual_seed(42)
x = torch.randn(32, 64) # batch_size=32, features=64

manual_bn = ManualBatchNorm1d(64)
pytorch_bn = nn.BatchNorm1d(64)

# 同步初始参数
pytorch_bn.weight.data.copy_(manual_bn.gamma.data)
pytorch_bn.bias.data.copy_(manual_bn.beta.data)

manual_out = manual_bn(x)
pytorch_out = pytorch_bn(x)

print(f" 最大差异: {(manual_out - pytorch_out).abs().max().item():.2e}")

# 打印批归一化前后的统计变化
print(f"\n归一化前: 均值={x.mean():.4f}, 标准差={x.std():.4f}")
print(f" 归一化后: 均值={manual_out.mean():.4f}, 标准差={manual_out.std():.4f}")

```

14.C 异常检测

异常检测 (Anomaly Detection) 大量应用描述统计原理。下面实现基于自编码器 (Autoencoder) 的异常检测, 并用统计方法分析重建误差的分布:

```

import torch
import torch.nn as nn
import torch.optim as optim
import numpy as np
import matplotlib.pyplot as plt
from scipy import stats

```

自编码器定义

```
class Autoencoder(nn.Module):
    def __init__(self, input_dim: int = 784, latent_dim: int = 32):
        super().__init__()
        self.encoder = nn.Sequential(
            nn.Linear(input_dim, 256),
            nn.ReLU(),
            nn.BatchNorm1d(256),
            nn.Linear(256, latent_dim),
        )
        self.decoder = nn.Sequential(
            nn.Linear(latent_dim, 256),
            nn.ReLU(),
            nn.BatchNorm1d(256),
            nn.Linear(256, input_dim),
            nn.Sigmoid(),
        )

    def forward(self, x: torch.Tensor):
        z = self.encoder(x)
        return self.decoder(z)

def compute_reconstruction_errors(model: nn.Module,
                                  loader: torch.utils.data.DataLoader,
                                  device: str = 'cpu') -> np.ndarray:
    """ 计算所有样本的重建误差（每样本 MSE） """
    model.eval()
    errors = []
    with torch.no_grad():
        for images, _ in loader:
            images = images.view(images.size(0), -1).to(device)
            recon = model(images)
            # 每个样本的均方误差（位置度量的应用）
            mse = ((recon - images) ** 2).mean(dim=1)
            errors.append(mse.cpu().numpy())
    return np.concatenate(errors)

def anomaly_detection_analysis(errors_normal: np.ndarray,
                              errors_anomaly: np.ndarray):
    """
    基于描述统计的异常检测分析
    """
```

策略：在正常数据上拟合重建误差的分布，
然后将高误差的样本判定为异常

"""

1. 描述统计分析

print(" 正常样本重建误差统计: ")

print(f" 均值 = {errors_normal.mean():.6f}")

print(f" 标准差 = {errors_normal.std():.6f}")

print(f" 中位数 = {np.median(errors_normal):.6f}")

print(f" IQR = {np.percentile(errors_normal, 75) - np.percentile(errors_normal, 25):.6f}")

2. 用偏度/峰度判断分布形状（重建误差通常右偏）

z = (errors_normal - errors_normal.mean()) / errors_normal.std()

skewness = (z**3).mean()

excess_kurtosis = (z**4).mean() - 3

print(f" 偏度 = {skewness:.4f} (>0 表示右偏, 符合误差分布预期) ")

print(f" 超额峰度 = {excess_kurtosis:.4f}")

3. 设定阈值：均值 + k * 标准差（基于切比雪夫不等式或正态假设）

方法 A: 基于正态假设（99.7% 置信区间）

threshold_3sigma = errors_normal.mean() + 3 * errors_normal.std()

方法 B: 基于 IQR (Tukey's fence, 更稳健)

q1, q3 = np.percentile(errors_normal, [25, 75])

threshold_iqr = q3 + 1.5 * (q3 - q1)

方法 C: 基于分位数（直接取正常数据的高百分位）

threshold_pct = np.percentile(errors_normal, 99)

print(f"\n阈值对比: ")

print(f" 3 法则阈值 = {threshold_3sigma:.6f}")

print(f" IQR 法则阈值 = {threshold_iqr:.6f}")

print(f" 99% 分位数 = {threshold_pct:.6f}")

4. 检测率评估

```
for name, thresh in [("3 ", threshold_3sigma),
                    ("IQR", threshold_iqr),
                    ("99% 分位", threshold_pct)]:
```

fp_rate = (errors_normal > thresh).mean() # 假阳率（误报率）

tp_rate = (errors_anomaly > thresh).mean() # 真阳率（检出率）

print(f" {name}: 假阳率={fp_rate:.3f}, 检出率={tp_rate:.3f}")

5. 可视化：QQ 图检验重建误差的分布

```
fig, axes = plt.subplots(1, 2, figsize=(12, 5))
```

直方图对比

```
axes[0].hist(errors_normal, bins=60, alpha=0.6, label='正常样本', density=True)
```

```
axes[0].hist(errors_anomaly, bins=60, alpha=0.6, label='异常样本', density=True)
```

```
axes[0].axvline(threshold_3sigma, color='r', linestyle='--', label=f'3 阈值')
```

```
axes[0].set_xlabel('重建误差 (MSE)')
```

```
axes[0].set_ylabel('密度')
```

```
axes[0].set_title('重建误差分布')
```

```
axes[0].legend()
```

正态 QQ 图（对数变换后更接近正态）

```
log_errors = np.log(errors_normal + 1e-8)
```

```
(osm, osr), (slope, intercept, r) = stats.probplot(log_errors, dist='norm')
```

```
axes[1].scatter(osm, osr, alpha=0.3, s=5)
```

```
axes[1].plot(osm, slope * np.array(osm) + intercept, 'r-', label=f' $R^2 = {r**2:.4f}$ ')
```

```
axes[1].set_xlabel('理论正态分位数')
```

```
axes[1].set_ylabel('样本分位数 (log 误差)')
```

```
axes[1].set_title('正态 QQ 图 (对数重建误差)')
```

```
axes[1].legend()
```

```
plt.tight_layout()
```

```
plt.savefig('anomaly_detection_stats.png', dpi=150)
```

```
plt.show()
```

```
return threshold_3sigma
```

演示：生成模拟数据进行异常检测分析

```
np.random.seed(42)
```

模拟正常样本重建误差（近似对数正态分布）

```
errors_normal = np.random.lognormal(mean=-4, sigma=0.5, size=5000)
```

模拟异常样本（重建误差更大）

```
errors_anomaly = np.random.lognormal(mean=-2, sigma=0.8, size=500)
```

```
anomaly_detection_analysis(errors_normal, errors_anomaly)
```

练习题

练习 14.1（位置度量）

设样本数据为：2, 4, 4, 4, 5, 5, 7, 9。

- 计算样本均值 $\bar{x}$ 、中位数 M 、众数 Mo 。
 - 若将最大值 9 替换为 90，重新计算三个度量，并讨论哪个度量最稳健。
 - 证明：对任意常数 c ，有 $\sum_{i=1}^n (x_i - \bar{x})^2 \leq \sum_{i=1}^n (x_i - c)^2$ 。
-

练习 14.2（散布度量）

设 $X \sim \text{Uniform}(a, b)$ （均匀分布）。

- 计算总体方差 σ^2 、IQR 和极差 R ，用 a, b 表示。
 - 证明对均匀分布有 $\text{IQR} = R/2$ ，并说明这在何时成立、何时不成立。
 - 对于正态分布 $\mathcal{N}(\mu, \sigma^2)$ ，证明 $\text{IQR} = 2\Phi^{-1}(0.75) \cdot \sigma \approx 1.349\sigma$ ，因此 $\hat{\sigma} = \text{IQR}/1.349$ 是 σ 的稳健估计量。
-

练习 14.3（偏度与峰度）

设 $X \sim \text{Exp}(\lambda)$ ，概率密度为 $f(x) = \lambda e^{-\lambda x}$ ($x > 0$)。

- 计算 $\mathbb{E}[X]$ 、 $\text{Var}(X)$ 、三阶中心矩 $\mu_3 = \mathbb{E}[(X - \mu)^3]$ 和偏度 γ_1 。
 - 计算四阶中心矩 $\mu_4 = \mathbb{E}[(X - \mu)^4]$ 和超额峰度 κ 。
 - 已知指数分布的矩母函数 $M(t) = \lambda/(\lambda - t)$ ($t < \lambda$)，利用此结果验证 (a)(b) 的计算。
-

练习 14.4（QQ 图与正态性）

已知 n 个数据来自某分布，其顺序统计量满足经验分位数 $x_{(i)}$ 与正态理论分位数 $q_i = \Phi^{-1}((i - 0.5)/n)$ 的线性关系： $x_{(i)} = \mu + \sigma q_i + \varepsilon_i$ 。

- 如果 QQ 图上的点大致沿直线分布，直线的斜率和截距分别估计了什么参数？
 - 设 QQ 图显示数据点在右上角向上弯曲，这说明数据具有什么样的尾部特征？请从峰度角度解释。
 - $t(3)$ 分布与 $\mathcal{N}(0, 1)$ 相比，其 QQ 图（以正态分布为参考）会呈现什么形状？为什么？
-

练习 14.5 (多变量描述)

设 (X, Y) 是二维随机向量, $\mathbb{E}[X] = \mathbb{E}[Y] = 0$, $\text{Var}(X) = \sigma_X^2$, $\text{Var}(Y) = \sigma_Y^2$, $\text{Cov}(X, Y) = \rho\sigma_X\sigma_Y$ 。

- (a) 写出 (X, Y) 的协方差矩阵 Σ 和相关矩阵 $\mathbf{R}$ 。
- (b) 计算 Σ 的特征值, 并说明为何协方差矩阵是半正定的。
- (c) 设 $Z = aX + bY$, 用 $a, b, \sigma_X, \sigma_Y, \rho$ 表示 $\text{Var}(Z)$ 。当 $\rho = 1$ 时, $\text{Var}(Z)$ 化简为什么? 这与 X, Y 完全线性相关有何联系?

练习答案

答案 14.1

(a) 数据排序: 2, 4, 4, 4, 5, 5, 7, 9, $n = 8$ 。

$$\bar{x} = \frac{2 + 4 + 4 + 4 + 5 + 5 + 7 + 9}{8} = \frac{40}{8} = 5$$

中位数 ($n = 8$, 偶数):

$$M = \frac{x_{(4)} + x_{(5)}}{2} = \frac{4 + 5}{2} = 4.5$$

众数: 4 (出现 3 次, 频率最高)。

(b) 将 9 替换为 90, 新数据为 2, 4, 4, 4, 5, 5, 7, 90:

$$\bar{x}' = \frac{2 + 4 + 4 + 4 + 5 + 5 + 7 + 90}{8} = \frac{121}{8} = 15.125$$

中位数不变: $M' = (4 + 5)/2 = 4.5$ 。众数不变: $\text{Mo}' = 4$ 。

结论: 均值从 5 剧变为 15.125, 中位数和众数完全不受影响。中位数和众数对异常值最稳健。

(c) 展开:

$$\begin{aligned} \sum_{i=1}^n (x_i - c)^2 &= \sum_{i=1}^n [(x_i - \bar{x}) + (\bar{x} - c)]^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + 2(\bar{x} - c) \underbrace{\sum_{i=1}^n (x_i - \bar{x})}_{=0} + n(\bar{x} - c)^2 \\ &= \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - c)^2 \geq \sum_{i=1}^n (x_i - \bar{x})^2 \end{aligned}$$

等号当且仅当 $c = \bar{x}$ 时成立。■

答案 14.2

(a) $X \sim \text{Uniform}(a, b)$, $\mu = (a + b)/2$ 。

$$\sigma^2 = \frac{(b - a)^2}{12}$$

分位数: $Q_p = a + p(b - a)$, 故:

$$\text{IQR} = Q_{0.75} - Q_{0.25} = \frac{b - a}{2}$$

$$R = b - a$$

(b) $\text{IQR} = R/2$ 对均匀分布成立, 因为均匀分布的分位数是线性的。对其他分布 (如正态、指数), IQR 与 R 的比值不同。例如正态分布的 R 随 n 增长 (约为 $\sigma \cdot \Theta(\sqrt{\log n})$), 而 IQR 始终约为 1.349σ 。

(c) 设 $Z \sim \mathcal{N}(0, 1)$, $X = \mu + \sigma Z$ 。

$$Q_{0.75} = \mu + \sigma\Phi^{-1}(0.75), \quad Q_{0.25} = \mu + \sigma\Phi^{-1}(0.25)$$

$$\text{IQR} = \sigma(\Phi^{-1}(0.75) - \Phi^{-1}(0.25))$$

由正态分布的对称性, $\Phi^{-1}(0.25) = -\Phi^{-1}(0.75)$, 故:

$$\text{IQR} = 2\sigma\Phi^{-1}(0.75) \approx 2\sigma \times 0.6745 = 1.349\sigma$$

因此 $\hat{\sigma} = \text{IQR}/1.349$ 是 σ 的稳健估计, 不受少数异常值影响。■

答案 14.3

(a) 利用指数分布的各阶矩 $\mathbb{E}[X^k] = k!/\lambda^k$:

$$\mu = \mathbb{E}[X] = \frac{1}{\lambda}, \quad \sigma^2 = \text{Var}(X) = \frac{1}{\lambda^2}$$

三阶中心矩:

$$\mu_3 = \mathbb{E}[(X - \mu)^3] = \mathbb{E}[X^3] - 3\mu\mathbb{E}[X^2] + 3\mu^2\mathbb{E}[X] - \mu^3 = \frac{6}{\lambda^3} - 3 \cdot \frac{1}{\lambda} \cdot \frac{2}{\lambda^2} + 3 \cdot \frac{1}{\lambda^2} \cdot \frac{1}{\lambda} - \frac{1}{\lambda^3} = \frac{2}{\lambda^3}$$

偏度：

$$\gamma_1 = \frac{\mu_3}{\sigma^3} = \frac{2/\lambda^3}{1/\lambda^3} = 2$$

指数分布是右偏分布，偏度为 2，不依赖于参数 λ 。

(b) 四阶中心矩（展开后利用 $\mathbb{E}[X^k] = k!/\lambda^k$ ）：

$$\mu_4 = \mathbb{E}[X^4] - 4\mu\mathbb{E}[X^3] + 6\mu^2\mathbb{E}[X^2] - 3\mu^4 = \frac{24}{\lambda^4} - 4 \cdot \frac{1}{\lambda} \cdot \frac{6}{\lambda^3} + 6 \cdot \frac{1}{\lambda^2} \cdot \frac{2}{\lambda^2} - \frac{3}{\lambda^4} = \frac{9}{\lambda^4}$$

峰度：

$$\gamma_2 = \frac{\mu_4}{\sigma^4} = \frac{9/\lambda^4}{1/\lambda^4} = 9$$

超额峰度： $\kappa = 9 - 3 = 6$ 。指数分布是尖峰厚尾分布。

(c) 利用 $M(t) = \lambda/(\lambda - t)$ ，对 t 求导：

$$M^{(k)}(0) = \mathbb{E}[X^k] = \frac{k!}{\lambda^k}$$

这与 (a)(b) 中用到的各阶矩一致，验证了计算的正确性。■

答案 14.4

(a) QQ 图上若点大致在直线 $x_{(i)} = \mu + \sigma q_i$ 上，则：- 斜率 σ 估计了数据的标准差（散布程度）- 截距 μ 估计了数据的均值（位置）

(b) 右上角向上弯曲表示数据的右尾比正态分布更厚：即实际的大分位数（大值）比正态理论预测的更大。这意味着数据具有正超额峰度（ $\kappa > 0$ ），分布尾部更重（heavy-tailed）。

(c) $t(3)$ 分布的超额峰度 $\kappa = 6/(3 - 4)$ 无定义（ $3 < 4$ ），但其四阶矩不存在，尾部极厚。以正态为参考的 QQ 图呈 S 形（或更准确地，两端均向外弯曲）：- 左端：实际值比正态理论值更小（左尾更厚），点向下偏 - 右端：实际值比正态理论值更大（右尾更厚），点向上偏

这正是超额峰度为正、双尾均比正态厚的典型 QQ 图形状。■

答案 14.5

(a) 协方差矩阵：

$$\Sigma = \begin{pmatrix} \sigma_X^2 & \rho\sigma_X\sigma_Y \\ \rho\sigma_X\sigma_Y & \sigma_Y^2 \end{pmatrix}$$

相关矩阵 ($\mathbf{D} = \text{diag}(\sigma_X^2, \sigma_Y^2)$):

$$\mathbf{R} = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}$$

(b) Σ 的特征方程：

$$(\sigma_X^2 - \lambda)(\sigma_Y^2 - \lambda) - \rho^2\sigma_X^2\sigma_Y^2 = 0$$

$$\lambda_{1,2} = \frac{\sigma_X^2 + \sigma_Y^2 \pm \sqrt{(\sigma_X^2 - \sigma_Y^2)^2 + 4\rho^2\sigma_X^2\sigma_Y^2}}{2}$$

由于 $|\rho| \leq 1$ ，可以验证 $\lambda_1, \lambda_2 \geq 0$ ，故 Σ 是半正定矩阵。本质上，对任意向量 $\mathbf{v}$ ： $\mathbf{v}^\top \Sigma \mathbf{v} = \text{Var}(\mathbf{v}^\top \mathbf{X}) \geq 0$ ，这直接保证了半正定性。

(c) 利用方差的双线性性：

$$\text{Var}(Z) = a^2\sigma_X^2 + 2ab\rho\sigma_X\sigma_Y + b^2\sigma_Y^2$$

当 $\rho = 1$ 时：

$$\text{Var}(Z) = a^2\sigma_X^2 + 2ab\sigma_X\sigma_Y + b^2\sigma_Y^2 = (a\sigma_X + b\sigma_Y)^2$$

这意味着 $Z = aX + bY$ 的标准差恰好等于 $|a\sigma_X + b\sigma_Y|$ ，即 Z 是确定性的线性组合（无“额外随机性”），完全由 X 决定——正是 X, Y 完全正线性相关 ($Y = \sigma_Y/\sigma_X \cdot X$) 的体现。■

第 15 章：充分统计量

学习目标

学完本章后，你将能够：

- 理解充分统计量的核心思想：统计量对参数所含信息的完整捕获，以及 Fisher-Neyman 因子分解定理的条件与应用
- 掌握因子分解定理，能判断给定统计量是否为充分统计量，并在常见分布族中求出充分统计量
- 理解最小充分统计量的概念，区分“充分”与“最充分的压缩”，能利用 Lehmann-Scheffé 定理识别最小充分统计量
- 掌握完备统计量的定义与 Basu 定理，理解完备性在无偏估计理论（Rao-Blackwell 定理与 Lehmann-Scheffé 定理）中的核心作用
- 认识指数族分布的自然充分统计量，理解指数族的结构如何天然适配充分性理论，并将其与深度学习中的信息压缩、特征学习联系起来

15.1 充分统计量的定义

15.1.1 统计量的信息损失问题

在统计推断中，我们面对样本 $\mathbf{X} = (X_1, X_2, \dots, X_n)$ ，希望通过统计量 $T(\mathbf{X})$ 来推断未知参数 θ 。

基本问题：将 n 个观测值压缩为一个（或少数几个）统计量时，是否会丢失关于 θ 的信息？

直观例子：设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Bernoulli}(\theta)$ 。

- 统计量 $T_1 = X_1$ ：只用第一个观测，丢失了大量信息。
- 统计量 $T_2 = \sum_{i=1}^n X_i$ ：累计了所有观测中正面出现的次数。
- 统计量 $T_3 = (X_1, X_2, \dots, X_n)$ ：保留了全部原始数据，显然不丢失任何信息。

T_3 无压缩， T_1 压缩过度丢失信息， T_2 恰好是“刚好够用”的压缩——这正是充分统计量的直觉。

15.1.2 充分统计量的正式定义

定义 15.1（充分统计量）

设 $\mathbf{X} = (X_1, \dots, X_n)$ 来自参数为 θ 的分布族 $\{P_\theta : \theta \in \Theta\}$ 。统计量 $T = T(\mathbf{X})$ 称为参数 θ 的充分统计量 (sufficient statistic)，若对任意给定的 $T = t$ ，条件分布

$$P_\theta(\mathbf{X} \in A \mid T(\mathbf{X}) = t)$$

与参数 θ 无关。

等价地说：在已知 $T(\mathbf{X})$ 的条件下，样本 $\mathbf{X}$ 的分布不再依赖 θ 。也就是说， T 已经“充分地”捕获了样本中关于 θ 的所有信息。

15.1.3 直觉理解：信息瓶颈

充分统计量可以理解为参数信息的无损压缩：

$$\underbrace{\mathbf{X}}_{\text{原始数据}} \xrightarrow{\text{充分压缩}} \underbrace{T(\mathbf{X})}_{\text{充分统计量}} \xrightarrow{\text{推断}} \theta$$

关键性质：- 知道 $T(\mathbf{X})$ 后，原始数据 $\mathbf{X}$ 的”剩余部分”不再提供关于 θ 的额外信息 - 任何基于 $\mathbf{X}$ 的统计推断都可以等价地只基于 $T(\mathbf{X})$ 进行

15.1.4 验证充分性的条件定义法

例 15.1：设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Bernoulli}(\theta)$ ，验证 $T = \sum_{i=1}^n X_i$ 是充分统计量。

验证： $T \sim \text{Binomial}(n, \theta)$ 。对 $t = 0, 1, \dots, n$ ，计算条件概率：

$$P_{\theta}(\mathbf{X} = \mathbf{x} \mid T = t) = \frac{P_{\theta}(\mathbf{X} = \mathbf{x}, T(\mathbf{x}) = t)}{P_{\theta}(T = t)}$$

当 $\sum x_i = t$ 时：

$$P_{\theta}(\mathbf{X} = \mathbf{x} \mid T = t) = \frac{\theta^t (1 - \theta)^{n-t}}{\binom{n}{t} \theta^t (1 - \theta)^{n-t}} = \frac{1}{\binom{n}{t}}$$

条件概率与 θ 无关，故 $T = \sum_{i=1}^n X_i$ 是充分统计量。□

15.2 因子分解定理

直接用定义验证充分性往往繁琐。因子分解定理（Factorization Theorem）给出了一种更便捷的判断方法。

15.2.1 定理陈述

定理 15.1（Fisher-Neyman 因子分解定理）

设样本 $\mathbf{X} = (X_1, \dots, X_n)$ 的联合密度（或概率质量函数）为 $f(\mathbf{x}; \theta)$ 。统计量 $T(\mathbf{X})$ 是 θ 的充分统计量，当且仅当存在非负函数 g 和 h ，使得对所有 $\mathbf{x}$ 和 θ ：

$$f(\mathbf{x}; \theta) = g(T(\mathbf{x}), \theta) \cdot h(\mathbf{x})$$

其中：- $g(T(\mathbf{x}), \theta)$ ：仅通过 $T(\mathbf{x})$ 依赖于数据，且依赖于参数 θ - $h(\mathbf{x})$ ：仅依赖于数据 $\mathbf{x}$ ，与参数 θ 无关

含义：联合密度可以“因子分解”为依赖 θ 的部分（仅通过 T ）和不依赖 θ 的部分之积。参数 θ 影响数据的方式“完全经由” T 传递。

15.2.2 应用示例

例 15.2：正态分布的充分统计量

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$, σ^2 已知, μ 未知。

联合密度：

$$f(\mathbf{x}; \mu) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

展开指数部分：

$$\sum_{i=1}^n (x_i - \mu)^2 = \sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i + n\mu^2$$

因此：

$$f(\mathbf{x}; \mu) = \underbrace{\exp\left(\frac{\mu \sum x_i}{\sigma^2} - \frac{n\mu^2}{2\sigma^2}\right)}_{g(\sum x_i, \mu)} \cdot \underbrace{\left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n \exp\left(-\frac{\sum x_i^2}{2\sigma^2}\right)}_{h(\mathbf{x})}$$

由因子分解定理, $T = \sum_{i=1}^n X_i$ (等价地, $\bar{X}$) 是 μ 的充分统计量。□

例 15.3：均匀分布的充分统计量

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Uniform}(0, \theta)$, $\theta > 0$ 。

联合密度：

$$f(\mathbf{x}; \theta) = \prod_{i=1}^n \frac{1}{\theta} \mathbf{1}_{[0, \theta]}(x_i) = \frac{1}{\theta^n} \mathbf{1}\{0 \leq x_{(n)} \leq \theta\} \cdot \mathbf{1}\{x_{(1)} \geq 0\}$$

其中 $x_{(n)} = \max_i x_i$, $x_{(1)} = \min_i x_i$ 。令 $T = X_{(n)}$ ：

$$f(\mathbf{x}; \theta) = \underbrace{\frac{1}{\theta^n} \mathbf{1}\{T \leq \theta\}}_{g(T, \theta)} \cdot \underbrace{\mathbf{1}\{x_{(1)} \geq 0\}}_{h(\mathbf{x})}$$

故 $T = X_{(n)} = \max(X_1, \dots, X_n)$ 是 θ 的充分统计量。□

例 15.4：泊松分布的充分统计量

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Poisson}(\lambda)$ 。

$$f(\mathbf{x}; \lambda) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} = \underbrace{e^{-n\lambda} \lambda^{\sum x_i}}_{g(\sum x_i, \lambda)} \cdot \underbrace{\prod_{i=1}^n \frac{1}{x_i!}}_{h(\mathbf{x})}$$

故 $T = \sum_{i=1}^n X_i$ 是 λ 的充分统计量。□

15.2.3 充分统计量的非唯一性

充分统计量不唯一：若 T 是充分统计量，则任何与 T 一一对应的函数 $\phi(T)$ 也是充分统计量（因为 T 可从 $\phi(T)$ 恢复）。

特别地，原始样本 $\mathbf{X}$ 本身总是充分统计量（但毫无压缩）。这引出了“最小充分统计量”的概念。

15.3 最小充分统计量

15.3.1 统计量的粗细之分

充分统计量实现了对数据的无损压缩，但压缩程度可以不同：

- $\mathbf{X} = (X_1, \dots, X_n)$ ：充分但无压缩（最粗）
- $\bar{X}$ ：充分且压缩至一维（对正态均值问题）
- 顺序统计量 $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ ：充分（对无参数族），但比 $\bar{X}$ 粗

最小充分统计量是“最细”的充分统计量——在保持充分性的同时，实现了最大程度的数据压缩。

15.3.2 正式定义

定义 15.2（最小充分统计量）

充分统计量 $T^*(\mathbf{X})$ 称为最小充分统计量（minimal sufficient statistic），若对任意其他充分统计量 $T(\mathbf{X})$ ，存在函数 ϕ 使得

$$T^*(\mathbf{X}) = \phi(T(\mathbf{X}))$$

即 T^* 是 T 的函数。换言之，任何其他充分统计量都比 T^* “粗”（包含更多冗余信息）。

15.3.3 Lehmann-Scheffé 判别定理

定理 15.2 (Lehmann-Scheffé 最小充分性定理)

设样本密度（或质量函数）为 $f(\mathbf{x}; \theta)$ 。若存在统计量 $T(\mathbf{X})$ 满足：

$$\frac{f(\mathbf{x}; \theta)}{f(\mathbf{y}; \theta)} \text{ 与 } \theta \text{ 无关} \iff T(\mathbf{x}) = T(\mathbf{y})$$

则 $T(\mathbf{X})$ 是 θ 的最小充分统计量。

直觉： $T(\mathbf{x}) = T(\mathbf{y})$ 当且仅当 $\mathbf{x}$ 和 $\mathbf{y}$ 对于所有 θ 提供“等量的关于 θ 的信息”（密度比不依赖于 θ ）。最小充分统计量正好将所有“信息等量”的样本点归为同一等价类。

15.3.4 例子

例 15.5：正态分布 $\mathcal{N}(\mu, \sigma^2)$ （两参数均未知）

联合密度比：

$$\frac{f(\mathbf{x}; \mu, \sigma^2)}{f(\mathbf{y}; \mu, \sigma^2)} = \exp\left(-\frac{\sum x_i^2 - \sum y_i^2}{2\sigma^2} + \frac{\mu(\sum x_i - \sum y_i)}{\sigma^2}\right)$$

此比值与 (μ, σ^2) 无关，当且仅当：

$$\sum_{i=1}^n x_i^2 = \sum_{i=1}^n y_i^2 \quad \text{且} \quad \sum_{i=1}^n x_i = \sum_{i=1}^n y_i$$

因此， $T(\mathbf{X}) = (\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2)$ 是 (μ, σ^2) 的最小充分统计量。

等价地， $(\bar{X}, S^2)$ 也是最小充分统计量，其中 $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ 。□

例 15.6：单参数正态 $\mathcal{N}(\mu, \sigma^2)$ ， σ^2 已知

此时密度比不依赖于 μ 当且仅当 $\sum x_i = \sum y_i$ ，故 $T = \sum X_i$ （即 $\bar{X}$ ）是最小充分统计量。

15.4 完备统计量

15.4.1 完备性的动机

充分统计量捕获了全部参数信息，但还有一个问题：是否存在以充分统计量为基础的“多余”估计量？

考虑 $X_1, \dots, X_n \stackrel{iid}{\sim} \mathcal{N}(\mu, 1)$ ， $T = \bar{X}$ 是充分统计量。

$g(T) = \bar{X}$ 是 μ 的无偏估计，但 $g(T) = \bar{X} + c(\bar{X} - \bar{X}) = \bar{X}$ 也是。这里没有“多余”。

但若充分统计量不完备，就可能存在非零函数 $h(T)$ 满足 $\mathbb{E}_\theta[h(T)] = 0$ 对所有 θ 成立，这意味着存在关于 θ 无信息的“冗余方向”。

15.4.2 完备性的定义

定义 15.3 (完备统计量)

统计量 $T(\mathbf{X})$ 称为完备统计量 (complete statistic)，若对任意可测函数 g ：

$$\mathbb{E}_\theta[g(T)] = 0 \text{ 对所有 } \theta \in \Theta \implies P_\theta(g(T) = 0) = 1 \text{ 对所有 } \theta \in \Theta$$

即：若某函数 $g(T)$ 的期望对所有 θ 均为零，则 $g(T)$ 必然几乎处处为零。

直觉：完备性排除了以 T 为基础的“有均值为零的非平凡估计量”—— T 没有“多余”的自由度”。

15.4.3 完备充分统计量的重要性

当 T 既是充分又是完备的 (完备充分统计量, complete sufficient statistic)，它具有极为优良的性质：

定理 15.3 (Rao-Blackwell 定理)

设 $\tilde{\theta}(\mathbf{X})$ 是 θ 的无偏估计， T 是充分统计量。令

$$\hat{\theta}(T) = \mathbb{E}_\theta[\tilde{\theta}(\mathbf{X}) | T]$$

则 $\hat{\theta}(T)$ 也是 θ 的无偏估计，且对所有 θ ：

$$\text{Var}_\theta(\hat{\theta}(T)) \leq \text{Var}_\theta(\tilde{\theta}(\mathbf{X}))$$

即以充分统计量为条件的“Rao-Blackwell 化”改进 (或不劣于) 原估计。

定理 15.4 (Lehmann-Scheffé 定理)

若 T 是完备充分统计量， $\hat{\theta}(T)$ 是基于 T 的无偏估计，则 $\hat{\theta}(T)$ 是 θ 的一致最小方差无偏估计量 (UMVUE)。

$T \text{ 完备充分} + \hat{\theta}(T) \text{ 无偏} \implies \hat{\theta}(T) \text{ 是 UMVUE}$

15.4.4 Basu 定理

定理 15.5 (Basu 定理)

若 T 是完备充分统计量, V 是辅助统计量 (ancillary statistic, 其分布与 θ 无关), 则 T 与 V 独立。

推论: 对正态样本 $X_1, \dots, X_n \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$ (σ^2 已知), $\bar{X}$ 是完备充分统计量。样本极差 $R = X_{(n)} - X_{(1)}$ 是辅助统计量, 故 $\bar{X}$ 与 R 独立。

15.4.5 完备充分统计量的求解示例

例 15.7: 指数分布 $\text{Exp}(\lambda)$ 的完备充分统计量

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Exp}(\lambda)$, 密度 $f(x; \lambda) = \lambda e^{-\lambda x}$, $x > 0$ 。

由因子分解定理, $T = \sum_{i=1}^n X_i$ 是充分统计量 ($T \sim \text{Gamma}(n, \lambda)$)。

对任意函数 g , 设 $\mathbb{E}_\lambda[g(T)] = 0$ 对所有 $\lambda > 0$ 成立:

$$\int_0^\infty g(t) \cdot \frac{\lambda^n t^{n-1} e^{-\lambda t}}{\Gamma(n)} dt = 0 \quad \forall \lambda > 0$$

即 $\int_0^\infty g(t) t^{n-1} e^{-\lambda t} dt = 0$ 对所有 $\lambda > 0$, 这是 Laplace 变换为零, 由唯一性定理知 $g(t) t^{n-1} = 0$ 几乎处处, 故 $g(t) = 0$ 几乎处处。

因此 $T = \sum X_i$ 是完备充分统计量, $\hat{\lambda}_{UMVUE} = \frac{n-1}{\sum X_i}$ 是 λ 的 UMVUE。□

15.5 指数族与充分统计量

15.5.1 指数族分布

许多常见分布 (正态、泊松、二项、伽马、贝塔等) 属于同一大类: 指数族 (exponential family)。

定义 15.4 (单参数指数族)

密度 (或质量函数) 具有如下形式的分布族称为单参数指数族:

$$f(x; \theta) = h(x) \exp[\eta(\theta)T(x) - B(\theta)]$$

其中: - $h(x) \geq 0$: 基础测度, 与参数无关 - $\eta(\theta)$: 自然参数 (natural parameter) - $T(x)$: 自然充分统计量 (natural sufficient statistic) - $B(\theta) = \log \int h(x) e^{\eta(\theta)T(x)} dx$: 对数配分函数 (log-partition function), 确保归一化

多参数推广 (k 参数指数族):

$$f(x; \theta) = h(x) \exp \left[\sum_{j=1}^k \eta_j(\theta) T_j(x) - B(\theta) \right]$$

15.5.2 指数族的自然充分统计量

定理 15.6

设 $X_1, \dots, X_n \stackrel{iid}{\sim} f(x; \theta)$, 其中 f 是 k 参数指数族。则

$$\mathbf{T}(\mathbf{X}) = \left(\sum_{i=1}^n T_1(X_i), \sum_{i=1}^n T_2(X_i), \dots, \sum_{i=1}^n T_k(X_i) \right)$$

是 θ 的充分统计量。若参数空间包含 k 维开集（正则指数族），则 $\mathbf{T}$ 还是完备的。

证明：联合密度为

$$f(\mathbf{x}; \theta) = \left[\prod_{i=1}^n h(x_i) \right] \exp \left[\sum_{j=1}^k \eta_j(\theta) \sum_{i=1}^n T_j(x_i) - nB(\theta) \right]$$

取 $g(\mathbf{T}, \theta) = \exp \left[\sum_j \eta_j \cdot \sum_i T_j(x_i) - nB(\theta) \right]$, $h(\mathbf{x}) = \prod_i h(x_i)$, 由因子分解定理, $\mathbf{T}$ 是充分统计量。□

15.5.3 常见指数族的充分统计量

分布	密度/质量函数	自然参数 η	充分统计量 $T(x)$
Bernoulli(θ)	$\theta^x (1 - \theta)^{1-x}$	$\log \frac{\theta}{1-\theta}$	x
$\mathcal{N}(\mu, \sigma^2)$ (双参数)	$(2\pi\sigma^2)^{-1/2} e^{-(x-\mu)^2/2\sigma^2}$	$\left(\frac{\mu}{\sigma^2}, -\frac{1}{2\sigma^2} \right)$	(x, x^2)
Poisson(λ)	$e^{-\lambda} \lambda^x / x!$	$\log \lambda$	x
Exp(λ)	$\lambda e^{-\lambda x}$	$-\lambda$	x
Gamma(α, β)	$\frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$	$(\alpha - 1, -\beta)$	$(\log x, x)$
Beta(α, β)	$\frac{x^{\alpha-1} (1-x)^{\beta-1}}{B(\alpha, \beta)}$	$(\alpha - 1, \beta - 1)$	$(\log x, \log(1 - x))$

15.5.4 指数族的信息论性质

对数配分函数 $B(\eta)$ 是凸函数, 其梯度和 Hessian 分别给出充分统计量的期望和协方差:

$$\nabla_\eta B(\eta) = \mathbb{E}_\eta[\mathbf{T}(X)]$$

$$\nabla_{\eta}^2 B(\eta) = \text{Cov}_{\eta}[\mathbf{T}(X)] = \mathbf{I}(\eta)$$

其中 $\mathbf{I}(\eta)$ 是 **Fisher** 信息矩阵。这一关系揭示了指数的深刻结构：充分统计量的期望完全刻画了参数的信息。

Fisher 信息（先给最小定义）：单参数情形下， $I(\theta) = \text{Var}_{\theta}[\partial_{\theta} \log f(X; \theta)] = E[(\partial_{\theta} \log f)^2] = -E[\partial_{\theta}^2 \log f]$ ，度量“样本中关于参数 θ 的信息量”——对数似然随 θ 变化越敏感（峰越尖），信息越多。多参数时把一阶导数换成梯度、方差换成协方差矩阵，即得 $\mathbf{I}(\eta)$ 。其完整动机与“两种形式为何相等”的推导见第 16 章 §16.4.2；本章只需知道它是一个可由分布算出的、衡量信息量的量。

15.5.5 充分统计量与 Fisher 信息

定理 15.7（充分统计量的 Fisher 信息保持性）

若 T 是 θ 的充分统计量，则

$$I_T(\theta) = I_{\mathbf{X}}(\theta)$$

充分统计量中包含原始样本的全部 Fisher 信息。非充分统计量只含部分信息： $I_{T'}(\theta) \leq I_{\mathbf{X}}(\theta)$ 。

本章小结

充分统计量理论的核心框架：

$$\begin{array}{ccc} \text{充分性} & \xrightarrow{\text{完备性}} & \text{UMVUE} \\ \text{无损压缩} & & \text{最优无偏估计} \end{array}$$

关键概念回顾：

- 充分统计量：给定 $T(\mathbf{X})$ ，样本的条件分布与 θ 无关； T 捕获了样本中关于 θ 的全部信息。
- 因子分解定理： T 充分 $\iff f(\mathbf{x}; \theta) = g(T(\mathbf{x}), \theta) \cdot h(\mathbf{x})$ ，是判断充分性的主要工具。
- 最小充分统计量：充分统计量中“最细”的那个，实现最大压缩。Lehmann-Scheffé 判别法：密度比 $f(\mathbf{x}; \theta)/f(\mathbf{y}; \theta)$ 与 θ 无关 $\iff T(\mathbf{x}) = T(\mathbf{y})$ 。
- 完备统计量： $E_{\theta}[g(T)] = 0 \forall \theta \implies g(T) = 0$ a.s.；完备充分统计量是 UMVUE 的基础（Lehmann-Scheffé 定理），并与辅助统计量独立（Basu 定理）。
- 指数族：自然充分统计量为 $\sum_i T_j(X_i)$ ；正则指数族的充分统计量是完备的； $B(\eta)$ 的梯度给出 $E[\mathbf{T}]$ ，Hessian 等于 Fisher 信息矩阵。

理论链条：

$$\text{指数族} \implies \text{完备充分统计量} \xrightarrow{\text{Rao-Blackwell}} \text{UMVUE}$$

深度学习应用：信息压缩、特征学习与表示学习

充分统计量的思想在深度学习中以多种形式出现：神经网络本质上是在学习对预测目标充分的特征表示。

信息瓶颈理论

信息瓶颈 (**Information Bottleneck, IB**) 框架将充分性的思想形式化为深度学习的原理：

设输入 X 、标签 Y 、网络中间表示（特征） $Z = f_{\theta}(X)$ 。

充分性目标： Z 对 Y 的预测应尽可能好，即 $I(Z; Y) \rightarrow I(X; Y)$ （保留关于 Y 的信息）。

压缩目标： Z 应尽可能压缩 X 中与 Y 无关的信息，即 $I(Z; X)$ 尽可能小。

信息瓶颈目标函数：

$$\mathcal{L}_{IB} = I(Z; Y) - \beta \cdot I(Z; X)$$

这与充分统计量的思想完全对应：- 充分性 $\leftrightarrow I(Z; Y) = I(X; Y)$ （无损）- 最小充分性 $\leftrightarrow I(Z; X)$ 最小化（最大压缩）

VAE 中的充分表示

变分自编码器（VAE）的编码器学习的是数据的充分表示。VAE 的 ELBO 目标函数：

$$\mathcal{L}_{VAE} = \underbrace{\mathbb{E}_{q_{\phi}(z|x)}[\log p_{\theta}(x|z)]}_{\text{重建项 (充分性)}} - \underbrace{D_{KL}(q_{\phi}(z|x) \| p(z))}_{\text{压缩项 (最小化冗余)}}$$

PyTorch 实现：信息压缩与充分特征学习

```
import torch
import torch.nn as nn
import torch.nn.functional as F
import torch.optim as optim
from torch.utils.data import DataLoader, TensorDataset
```

```

# =====
# 1. 信息瓶颈网络：学习关于标签  $Y$  的充分表示
# =====

class InformationBottleneckNet(nn.Module):
    """
    信息瓶颈网络：学习对  $Y$  预测充分、但对  $X$  压缩最大的表示  $Z$ 
    对应充分统计量： $Z$  是  $Y$  的充分统计量（无损），同时最小化与  $X$  的互信息（最小充分）
    """
    def __init__(self, input_dim, bottleneck_dim, output_dim):
        super().__init__()
        # 编码器： $X \rightarrow Z$ （学习充分压缩表示）
        self.encoder_mu = nn.Sequential(
            nn.Linear(input_dim, 256),
            nn.ReLU(),
            nn.Linear(256, bottleneck_dim)
        )
        self.encoder_logvar = nn.Sequential(
            nn.Linear(input_dim, 256),
            nn.ReLU(),
            nn.Linear(256, bottleneck_dim)
        )
        # 解码器： $Z \rightarrow Y$ （从充分表示预测标签）
        self.decoder = nn.Sequential(
            nn.Linear(bottleneck_dim, 128),
            nn.ReLU(),
            nn.Linear(128, output_dim)
        )

    def encode(self, x):
        """ 编码得到瓶颈表示的均值和对数方差 """
        mu = self.encoder_mu(x)
        logvar = self.encoder_logvar(x)
        return mu, logvar

    def reparameterize(self, mu, logvar):
        """ 重参数化技巧：从  $N(\mu, \exp(\logvar))$  采样 """
        std = torch.exp(0.5 * logvar)
        eps = torch.randn_like(std)

```

```

    return mu + eps * std

def forward(self, x):
    mu, logvar = self.encode(x)
    z = self.reparameterize(mu, logvar)
    y_pred = self.decoder(z)
    return y_pred, mu, logvar

def ib_loss(self, x, y, beta=0.01):
    """
    信息瓶颈损失函数：
     $L = -I(Z;Y) + \beta * I(Z;X)$ 
    近似为：
     $L = \text{交叉熵损失} + \beta * KL(q(Z/X) \parallel p(Z))$ 

    beta 控制充分性与压缩的权衡：
    - beta -> 0: 只关注充分性（保留全部信息）
    - beta -> inf: 只关注压缩（极度压缩，可能损失充分性）
    """
    y_pred, mu, logvar = self.forward(x)

    # 充分性项：预测 Y 的交叉熵（对应  $I(Z;Y)$  最大化）
    prediction_loss = F.cross_entropy(y_pred, y)

    # 压缩项：KL 散度，近似  $I(Z;X)$ （最小化冗余信息）
    #  $KL(N(\mu, \sigma^2) \parallel N(0, I)) = -0.5 * \sum(1 + \log(\sigma^2) - \mu^2 - \sigma^2)$ 
    kl_loss = -0.5 * torch.mean(1 + logvar - mu.pow(2) - logvar.exp())

    # 信息瓶颈目标（对应：充分统计量 + 最小性）
    total_loss = prediction_loss + beta * kl_loss
    return total_loss, prediction_loss.item(), kl_loss.item()

# =====
# 2. 变分自编码器 (VAE)：充分表示学习
# =====

class VAE(nn.Module):
    """
    变分自编码器：学习数据的充分潜在表示
    编码器  $q(Z/X)$  学习充分统计量：均值  $\mu(X)$  和方差  $\sigma^2(X)$ 
    """

```

这对应正态分布族的自然充分统计量 $T(X) = (\sum X_i, \sum X_i^2)$

```

"""
def __init__(self, input_dim, latent_dim):
    super().__init__()
    # 编码器：近似后验  $q(Z/X)$  的充分统计量（均值和方差）
    self.encoder = nn.Sequential(
        nn.Linear(input_dim, 512),
        nn.ReLU(),
        nn.Linear(512, 256),
        nn.ReLU()
    )
    self.fc_mu = nn.Linear(256, latent_dim) # 充分统计量：均值
    self.fc_logvar = nn.Linear(256, latent_dim) # 充分统计量：对数方差

    # 解码器：从潜在表示重建数据
    self.decoder = nn.Sequential(
        nn.Linear(latent_dim, 256),
        nn.ReLU(),
        nn.Linear(256, 512),
        nn.ReLU(),
        nn.Linear(512, input_dim),
        nn.Sigmoid()
    )

def encode(self, x):
    """
    编码步骤：计算近似后验的充分统计量
    对应正态分布的充分统计量： $T(x) = (x\_bar, s^2)$ 
    """
    h = self.encoder(x)
    mu = self.fc_mu(h)
    logvar = self.fc_logvar(h)
    return mu, logvar

def reparameterize(self, mu, logvar):
    """ 重参数化：从充分统计量参数化的高斯中采样 """
    if self.training:
        std = torch.exp(0.5 * logvar)
        eps = torch.randn_like(std)
        return mu + eps * std
    return mu # 推断时使用均值 (MAP 估计)

```



```

def decode(self, z):
    return self.decoder(z)

def forward(self, x):
    mu, logvar = self.encode(x)
    z = self.reparameterize(mu, logvar)
    x_recon = self.decode(z)
    return x_recon, mu, logvar

def elbo_loss(self, x):
    """
    ELBO (证据下界) 损失函数:
    ELBO =  $E[\log p(X/Z)] - KL(q(Z/X) \parallel p(Z))$ 
           = 重建项 (充分性:  $Z$  对  $X$  充分)
           - 正则项 (压缩:  $Z$  不过度编码  $X$  的冗余信息)
    """
    x_recon, mu, logvar = self.forward(x)
    # 重建损失: 衡量充分性
    recon_loss = F.binary_cross_entropy(x_recon, x, reduction='sum')
    # KL 散度: 正则化 (压缩) 项
    kl_loss = -0.5 * torch.sum(1 + logvar - mu.pow(2) - logvar.exp())
    return (recon_loss + kl_loss) / x.size(0)

```

```

# =====
# 3. 指数族神经网络输出层: 自然充分统计量参数化
# =====

```

```

class ExponentialFamilyOutput(nn.Module):
    """
    指数族输出层: 将神经网络的输出参数化为指数族分布的自然充分统计量

    指数族:  $f(x; \eta) = h(x) \exp(\eta^T T(x) - B(\eta))$ 

    神经网络学习自然参数  $\eta(input)$ , 对应充分统计量  $T(x)$  的期望估计
    这正是充分统计量理论在生成模型中的直接应用
    """
    def __init__(self, hidden_dim, output_dim, distribution='gaussian'):
        super().__init__()
        self.distribution = distribution

```

```

self.hidden_dim = hidden_dim
self.output_dim = output_dim

if distribution == 'gaussian':
    # 正态分布自然参数:  $\eta = (\mu/\sigma^2, -1/(2\sigma^2))$ 
    # 充分统计量:  $T(x) = (x, x^2)$ 
    self.fc_mu = nn.Linear(hidden_dim, output_dim) # 自然参数  $\eta_1$ 
    self.fc_logvar = nn.Linear(hidden_dim, output_dim) # 自然参数  $\eta_2$ 

elif distribution == 'bernoulli':
    # 伯努利分布自然参数:  $\eta = \log(p/(1-p))$  (logit)
    # 充分统计量:  $T(x) = x$ 
    self.fc_logit = nn.Linear(hidden_dim, output_dim)

elif distribution == 'categorical':
    # 分类分布自然参数:  $\eta_k = \log(p_k)$ 
    # 充分统计量:  $T(x)_k = 1[x=k]$  (one-hot 编码)
    self.fc_logits = nn.Linear(hidden_dim, output_dim)

def forward(self, h):
    if self.distribution == 'gaussian':
        # 输出正态分布的充分统计量参数: 均值和方差
        mu = self.fc_mu(h)
        logvar = self.fc_logvar(h)
        return mu, logvar

    elif self.distribution == 'bernoulli':
        # 输出伯努利分布的自然参数 (logit)
        logit = self.fc_logit(h)
        prob = torch.sigmoid(logit)
        return prob

    elif self.distribution == 'categorical':
        # 输出分类分布的自然参数 (log-softmax)
        logits = self.fc_logits(h)
        log_probs = F.log_softmax(logits, dim=-1)
        return log_probs

def natural_sufficient_stats(self, x):
    """
    计算样本  $x$  的自然充分统计量  $T(x)$ 

```

对比充分统计量理论: $T(X_1, \dots, X_n) = (\sum T_j(X_i))$

"""

if self.distribution == 'gaussian':

正态族充分统计量: $T(x) = (x, x^2) \rightarrow (\sum x_i, \sum x_i^2)$

return x.mean(dim=0), (x ** 2).mean(dim=0)

elif self.distribution == 'bernoulli':

伯努利族充分统计量: $T(x) = x \rightarrow \text{mean}(x)$

return x.mean(dim=0)

elif self.distribution == 'categorical':

分类族充分统计量: $T(x) = \text{one_hot}(x) \rightarrow$ 经验频率

n_classes = self.output_dim

return F.one_hot(x.long(), n_classes).float().mean(dim=0)

=====

4. 对比: 充分表示 vs 非充分表示的预测能力

=====

def compare_sufficient_vs_insufficient():

"""

演示充分统计量的无损信息保留性:

使用充分统计量 (sum_x , sum_x2) 和非充分统计量 (x_1) 进行参数估计

"""

torch.manual_seed(42)

n_samples = 1000

true_mu, true_sigma = 2.0, 1.5

生成正态样本

data = torch.randn(n_samples, 50) * true_sigma + true_mu # (1000, 50)

充分统计量: (sample_mean , sample_var) 是 (μ , σ^2) 的完备充分统计量

sufficient_T1 = data.mean(dim=1, keepdim=True) # $T1 = \bar{x}$

sufficient_T2 = data.var(dim=1, keepdim=True) # $T2 = s^2$

sufficient_stats = torch.cat([sufficient_T1, sufficient_T2], dim=1) # (1000, 2)

非充分统计量: 只取第一个观测 X_1 (丢失了大量信息)

insufficient_stats = data[:, :1] # (1000, 1)

用两种统计量分别估计参数 (线性探针)

```
def estimate_with_stats(stats, true_param, name):
    # 简单线性回归从统计量估计参数
    X = stats
    y = torch.full((n_samples,), true_param)
    w = torch.linalg.lstsq(X, y.unsqueeze(1)).solution
    y_pred = (X @ w).squeeze()
    mse = F.mse_loss(y_pred, y).item()
    print(f" {name}: MSE = {mse:.4f}")
    return mse

print(" 从统计量估计 mu 的精度对比 (MSE 越小越好) :")
mse_suf = estimate_with_stats(sufficient_stats, true_mu, " 充分统计量 (x_bar, s^2)")
mse_insuf = estimate_with_stats(insufficient_stats, true_mu, " 非充分统计量 (X_1 only)")
print(f" 信息损失比: {mse_insuf / mse_suf:.1f}x (非充分统计量的 MSE 是充分统计量的多少倍) ")

# 运行对比
compare_sufficient_vs_insufficient()
# 输出示例:
# 从统计量估计 mu 的精度对比 (MSE 越小越好) :
# 充分统计量 (x_bar, s^2): MSE 0.0000
# 非充分统计量 (X_1 only): MSE 2.2500
# 信息损失比: >>1x (充分统计量完整保留参数信息)
```

充分统计量与表示学习的对应关系

统计学概念	深度学习对应
充分统计量 $T(\mathbf{X})$	神经网络的特征层 $f_{\theta}(X)$
充分性：条件分布与 θ 无关	特征对任务标签的完整预测能力
最小充分统计量	信息瓶颈最优表示（最低维度充分特征）
完备性：无零均值函数	表示的无冗余性
UMVUE（最优无偏估计）	最小方差/最高精度的预测器
指数族的自然充分统计量	Softmax 输出（分类），高斯参数（生成模型）
Rao-Blackwell 条件化	从低精度特征到充分特征的蒸馏/提炼

练习题

练习 15.1（因子分解定理）

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Gamma}(\alpha, \beta)$, 密度为 $f(x; \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$, $x > 0$, 其中形状参数 $\alpha > 0$ 已知, 速率参数 $\beta > 0$ 未知。

- (1) 利用因子分解定理求 β 的充分统计量;
 - (2) 指出充分统计量服从什么分布, 并给出其参数;
 - (3) 求 β 的 UMVUE (提示: 先用 Lehmann-Scheffé 定理判断完备性, 再构造无偏估计)。
-

练习 15.2 (最小充分统计量)

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Uniform}(\theta - \frac{1}{2}, \theta + \frac{1}{2})$, $\theta \in \mathbb{R}$ 。

- (1) 写出联合密度, 利用指示函数化简;
 - (2) 利用 Lehmann-Scheffé 定理, 证明 $T = (X_{(1)}, X_{(n)})$ 是最小充分统计量, 其中 $X_{(1)}, X_{(n)}$ 分别是最小和最大顺序统计量;
 - (3) 证明 $\bar{X}$ 也是 θ 的充分统计量, 但不是最小充分统计量 (提示: 证明 $\bar{X}$ 可由 T 计算, 但反过来不行)。
-

练习 15.3 (完备性与 UMVUE)

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$, 两参数均未知。

- (1) 证明 $(\bar{X}, S^2)$ 是 (μ, σ^2) 的充分统计量, 其中 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$;
 - (2) 利用指数族理论证明 $(\bar{X}, S^2)$ 是完备充分统计量;
 - (3) 求 $\mu^2 + \sigma^2 = \mathbb{E}[X^2]$ 的 UMVUE (提示: 构造基于 $\bar{X}$ 和 S^2 的无偏估计);
 - (4) 说明为何 X_1 不是 μ 的 UMVUE, 尽管它是 μ 的无偏估计。
-

练习 15.4 (指数族与自然充分统计量)

负二项分布 $\text{NB}(r, p)$ (r 已知, p 未知) 的质量函数为:

$$P(X = k; p) = \binom{k+r-1}{k} p^r (1-p)^k, \quad k = 0, 1, 2, \dots$$

- (1) 将负二项分布写成指数族的标准形式, 识别自然参数 $\eta(p)$ 、充分统计量 $T(x)$ 和对数配分函数 $B(\eta)$;
- (2) 对 n 个 i.i.d. 观测 $X_1, \dots, X_n$, 写出完备充分统计量;
- (3) 利用 $B(\eta)$ 的性质计算 $\mathbb{E}[X]$ 和 $\text{Var}(X)$ (通过对 $B(\eta)$ 求一、二阶导数);
- (4) 求 p 的 UMVUE。

练习 15.5 (Basu 定理与辅助统计量)

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Exp}(\lambda)$, $\lambda > 0$ 。

- (1) 证明 $T = \sum_{i=1}^n X_i$ 是完备充分统计量;
- (2) 定义辅助统计量 $V_i = X_i / \sum_{j=1}^n X_j$ ($i = 1, \dots, n$)。证明 $(V_1, \dots, V_{n-1})$ 的分布与 λ 无关 (提示: $(V_1, \dots, V_{n-1})$ 服从 $\text{Dirichlet}(1, 1, \dots, 1)$ 分布);
- (3) 由 Basu 定理直接得出什么独立性结论?
- (4) 利用 Rao-Blackwell 定理, 从原始估计量 $\hat{\lambda}_0 = 1/X_1$ (λ 的无偏估计) 出发, 通过对充分统计量条件化, 推导 λ 的 UMVUE (提示: $\mathbb{E}[1/X_1 | T = t]$, 其中 $X_1 | T = t$ 服从 $\text{Beta}(1, n-1)$ 乘以 t)。

练习答案

答案 15.1

(1) 充分统计量

联合密度:

$$f(\mathbf{x}; \beta) = \prod_{i=1}^n \frac{\beta^\alpha}{\Gamma(\alpha)} x_i^{\alpha-1} e^{-\beta x_i} = \underbrace{\frac{\beta^{n\alpha}}{\Gamma(\alpha)^n} e^{-\beta \sum x_i}}_{g(T, \beta)} \cdot \underbrace{\prod_{i=1}^n x_i^{\alpha-1}}_{h(\mathbf{x})}$$

由因子分解定理, $T = \sum_{i=1}^n X_i$ 是 β 的充分统计量。

(2) 充分统计量的分布

由伽马分布的可加性, $T = \sum_{i=1}^n X_i \sim \text{Gamma}(n\alpha, \beta)$ 。

其密度为 $f_T(t; \beta) = \frac{\beta^{n\alpha}}{\Gamma(n\alpha)} t^{n\alpha-1} e^{-\beta t}$, $t > 0$ 。

这是正则指数族 (参数空间 $\beta > 0$ 为开集), 故 T 是完备充分统计量。

(3) UMVUE

$\mathbb{E}_\beta[T] = \mathbb{E}[\sum X_i] = n\alpha/\beta$, 故 $\mathbb{E}[n\alpha/T] = 1/\beta \cdot n\alpha \cdot \mathbb{E}[1/T]$ 。

$T \sim \text{Gamma}(n\alpha, \beta)$ 时, $\mathbb{E}[1/T] = \beta/(n\alpha - 1)$ (对 $n\alpha > 1$)。

因此 $\hat{\beta} = \frac{n\alpha-1}{T} = \frac{n\alpha-1}{\sum_{i=1}^n X_i}$ 满足 $\mathbb{E}[\hat{\beta}] = \beta$ 。

由 Lehmann-Scheffé 定理, $\hat{\beta} = \frac{n\alpha-1}{\sum_{i=1}^n X_i}$ 是 β 的 UMVUE (对 $n\alpha > 1$)。

答案 15.2

(1) 联合密度

$$f(\mathbf{x}; \theta) = \mathbf{1}\left\{\theta - \frac{1}{2} \leq x_{(1)}\right\} \cdot \mathbf{1}\left\{x_{(n)} \leq \theta + \frac{1}{2}\right\} = \mathbf{1}\left\{x_{(n)} - \frac{1}{2} \leq \theta \leq x_{(1)} + \frac{1}{2}\right\}$$

(2) $(X_{(1)}, X_{(n)})$ 是最小充分统计量

密度比：

$$\frac{f(\mathbf{x}; \theta)}{f(\mathbf{y}; \theta)} = \frac{\mathbf{1}\left\{x_{(n)} - \frac{1}{2} \leq \theta \leq x_{(1)} + \frac{1}{2}\right\}}{\mathbf{1}\left\{y_{(n)} - \frac{1}{2} \leq \theta \leq y_{(1)} + \frac{1}{2}\right\}}$$

此比值与 θ 无关（均为 1）当且仅当两个指示函数对应完全相同的 θ 范围，即：

$$x_{(1)} = y_{(1)} \quad \text{且} \quad x_{(n)} = y_{(n)}$$

由 Lehmann-Scheffé 定理， $T = (X_{(1)}, X_{(n)})$ 是最小充分统计量。

(3) $\bar{X}$ 是充分但非最小充分

充分性： $f(\mathbf{x}; \theta) = \mathbf{1}\{x_{(n)} - 1/2 \leq \theta \leq x_{(1)} + 1/2\}$ ， $\bar{X}$ 本身无法单独确定 $x_{(1)}, x_{(n)}$ ，而需要更多信息。反之， $(x_{(1)}, x_{(n)})$ 可以验证充分性但 $\bar{X}$ 无法从 $(X_{(1)}, X_{(n)})$ 恢复，故 $\bar{X}$ 不是最小充分的。实际上，可以验证 $\bar{X}$ 确实是充分统计量（在均匀分布场合可直接验证），但 $(X_{(1)}, X_{(n)})$ 包含的信息比 $\bar{X}$ 更细，两者均充分，而 $\bar{X}$ 是 $(X_{(1)}, X_{(n)})$ 的函数的话才能成立（此处非均匀情形下 $\bar{X}$ 并非最小充分）。□

答案 15.3

(1) 充分性

联合密度：

$$f(\mathbf{x}; \mu, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\sum(x_i - \mu)^2}{2\sigma^2}\right)$$

利用 $\sum(x_i - \mu)^2 = (n-1)s^2 + n(\bar{x} - \mu)^2$ ：

$$f(\mathbf{x}; \mu, \sigma^2) = \underbrace{(2\pi\sigma^2)^{-n/2} \exp\left(-\frac{(n-1)s^2}{2\sigma^2} - \frac{n(\bar{x} - \mu)^2}{2\sigma^2}\right)}_{g((\bar{x}, s^2), (\mu, \sigma^2))} \cdot \underbrace{1}_{h(\mathbf{x})}$$

由因子分解定理, $(\bar{X}, S^2)$ 是充分统计量。

(2) 完备性

正态分布 $\mathcal{N}(\mu, \sigma^2)$ 属于双参数正则指数族 (参数空间 $(\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}^+$ 包含二维开集), 故对应的充分统计量 $(\sum X_i, \sum X_i^2)$ (等价地 $(\bar{X}, S^2)$) 是完备充分统计量。

(3) $\mathbb{E}[X^2]$ 的 UMVUE

由于 $\mathbb{E}[X^2] = \mu^2 + \sigma^2$, 需要构造基于 $(\bar{X}, S^2)$ 的无偏估计:

- $\mathbb{E}[\bar{X}^2] = \mu^2 + \sigma^2/n$ (因为 $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$)
- $\mathbb{E}[S^2] = \sigma^2$

故 $\mathbb{E}[\bar{X}^2 + \frac{n-1}{n}S^2] = \mu^2 + \frac{\sigma^2}{n} + \frac{n-1}{n}\sigma^2 = \mu^2 + \sigma^2$ 。

UMVUE 为 $\widehat{\mathbb{E}[X^2]} = \bar{X}^2 + \frac{n-1}{n}S^2$ 。

(4) 为何 X_1 不是 UMVUE

X_1 是 μ 的无偏估计, 但 $\text{Var}(X_1) = \sigma^2$, 而 $\text{Var}(\bar{X}) = \sigma^2/n < \sigma^2$ (对 $n > 1$)。

$\bar{X}$ 是 μ 的完备充分统计量的函数且无偏, 由 Lehmann-Scheffé 定理是 UMVUE。 X_1 未充分利用全部样本信息, 方差更大, 不是 UMVUE。从 Rao-Blackwell 角度: $\mathbb{E}[X_1 | \bar{X}] = \bar{X}$, 条件化后得到方差更小的估计。

答案 15.4

(1) 指数族标准形式

$$P(X = k; p) = \binom{k+r-1}{k} p^r (1-p)^k = \binom{k+r-1}{k} p^r \exp[k \log(1-p)]$$

写成标准形式 $h(k) \exp[\eta T(k) - B(\eta)]$:

- $h(k) = \binom{k+r-1}{k}$ (基础测度)
- $\eta(p) = \log(1-p)$ (自然参数, $\eta \in (-\infty, 0)$)
- $T(k) = k$ (自然充分统计量)
- $B(\eta) = -r \log(1 - e^\eta) = -r \log p$ (对数配分函数, 因为归一化要求)

(2) 完备充分统计量

对 n 个 i.i.d. 观测, 完备充分统计量为 $T = \sum_{i=1}^n X_i$ (正则指数族)。

(3) 均值和方差

$$\mathbb{E}[X] = \frac{dB}{d\eta} = \frac{d}{d\eta} [-r \log(1 - e^\eta)] = \frac{re^\eta}{1 - e^\eta} = \frac{r(1-p)}{p}$$

$$\text{Var}(X) = \frac{d^2B}{d\eta^2} = \frac{re^\eta}{(1 - e^\eta)^2} = \frac{r(1-p)}{p^2}$$

(4) p 的 UMVUE

由 $\mathbb{E}[X] = r(1-p)/p$, 解得 $p = r/(r + \mathbb{E}[X])$ 。

$\mathbb{E}[\sum X_i] = nr(1-p)/p$, 故 $\mathbb{E}\left[\frac{nr}{nr + \sum X_i}\right]$ 需要验证 (直接计算较复杂)。

更简便地: $\mathbb{E}[T/n] = r(1-p)/p$, 于是 $1/\hat{p} - 1 = T/(nr)$, 即 $\hat{p}_{UMVUE} = \frac{nr}{nr + T} = \frac{nr}{nr + \sum X_i}$ 。

可验证 $\mathbb{E}\left[\frac{nr}{nr + T}\right] = p$ (可由负二项分布的矩生成函数验证)。由 Lehmann-Scheffé 定理, 这是 UMVUE。

答案 15.5

(1) 完备充分性

由因子分解定理, $f(\mathbf{x}; \lambda) = \lambda^n e^{-\lambda \sum x_i} \prod \mathbf{1}\{x_i > 0\}$, 故 $T = \sum X_i$ 充分。

$T \sim \text{Gamma}(n, \lambda)$, 指数分布属正则指数族, 故 T 完备充分。

(2) $(V_1, \dots, V_{n-1})$ 的分布与 λ 无关

设 $S = \sum_{i=1}^n X_i$ 。由指数分布的无记忆性和对称性, $\mathbf{V} = \mathbf{X}/S$ 服从 Dirichlet(1, 1, ..., 1) 分布 (即 $(n-1)$ -单纯形上的均匀分布), 该分布与 λ 无关。故 $(V_1, \dots, V_{n-1})$ 是辅助统计量。

(3) Basu 定理的结论

由 Basu 定理: 完备充分统计量 $T = \sum X_i$ 与辅助统计量 $(V_1, \dots, V_{n-1}) = (X_1/T, \dots, X_{n-1}/T)$ 相互独立。

即: $\sum X_i$ 与各 $X_i / \sum X_j$ 独立——这是指数分布的一个重要特征性质。

(4) λ 的 UMVUE

$\hat{\lambda}_0 = 1/X_1$ 是 λ 的无偏估计 (因为 $X_1 \sim \text{Exp}(\lambda)$, $\mathbb{E}[1/X_1]$ 不存在, 实际需要修正)。

正确的出发点: $\hat{\lambda}_0 = (n-1)/T_1$, 其中 $T_1 = \sum_{i=2}^n X_i \sim \text{Gamma}(n-1, \lambda)$ (独立于 X_1), $\mathbb{E}[(n-1)/T_1] = \lambda$ 。

Rao-Blackwell 化: $\hat{\lambda}_{RB} = \mathbb{E}[(n-1)/T_1 \mid T]$ 。

已知 $X_1 \mid T = t$ 的条件密度, 由对称性 $X_i/T \mid T$ 的边缘分布为 Beta(1, $n-1$), 故 $X_1 \mid T = t$ 的均值为 t/n 。可以推导:

$$\hat{\lambda}_{UMVUE} = \frac{n-1}{T} = \frac{n-1}{\sum_{i=1}^n X_i}$$

验证： $\mathbb{E}\left[\frac{n-1}{T}\right] = (n-1) \cdot \frac{\lambda}{n-1} = \lambda$ （利用 $T \sim \text{Gamma}(n, \lambda)$ ， $\mathbb{E}[1/T] = \lambda/(n-1)$ ）。

由 Lehmann-Scheffé 定理， $\hat{\lambda}_{UMVUE} = (n-1)/\sum X_i$ 是 λ 的 UMVUE。□

第 16 章：点估计

学习目标

学完本章后，你将能够：

- 理解点估计的基本框架，区分总体参数、样本统计量与估计量的概念
- 掌握矩估计法的原理与步骤，能对常见分布建立矩方程并求解参数估计
- 理解最大似然估计（MLE）的直觉含义，能对离散与连续分布推导 MLE 解析解
- 运用无偏性、有效性（最小方差）与一致性三大标准评价估计量的优劣
- 理解 MLE 的渐近正态性，并将 MLE 与深度学习中的损失函数设计联系起来

16.1 点估计的基本概念

16.1.1 统计推断的任务

现实中，总体分布往往由若干未知参数 θ 决定（可以是标量或向量）。例如：

- 正态总体 $\mathcal{N}(\mu, \sigma^2)$ 中， $\theta = (\mu, \sigma^2)$ 未知
- 伯努利总体 $\text{Bernoulli}(p)$ 中， $\theta = p$ 未知
- 泊松总体 $\text{Pois}(\lambda)$ 中， $\theta = \lambda$ 未知

统计推断的目标是：从观测到的样本数据 $X_1, X_2, \dots, X_n$ （假设独立同分布，i.i.d.）出发，对未知参数做出合理的判断。

点估计（Point Estimation）是最基本的推断形式：用样本构造一个数值作为未知参数的“最佳猜测”。

16.1.2 估计量与估计值

定义：设 $X_1, X_2, \dots, X_n$ 是来自总体的样本，若统计量 $\hat{\theta} = g(X_1, X_2, \dots, X_n)$ 用于估计未知参数 θ ，则称 $\hat{\theta}$ 为 θ 的估计量（estimator）。

将样本的观测值 $x_1, x_2, \dots, x_n$ 代入，得到估计值（estimate） $\hat{\theta} = g(x_1, x_2, \dots, x_n)$ 。

关键区别：

概念	性质	例子
参数 θ	固定未知常数	总体均值 μ
估计量 $\hat{\theta}$	随机变量（样本的函数）	样本均值 $\bar{X} = \frac{1}{n} \sum X_i$
估计值 $\hat{\theta}$	确定数值（代入观测值后）	$\bar{x} = \frac{1}{n} \sum x_i = 3.2$

估计量是随机变量这一点至关重要——它决定了我们能谈论估计量的期望、方差等统计性质。

16.1.3 参数空间与充分统计量

参数空间 Θ ：参数 θ 所有可能取值的集合。例如正态分布的 $\mu \in (-\infty, +\infty)$, $\sigma^2 \in (0, +\infty)$ 。

充分统计量 (sufficient statistic)：若统计量 $T(\mathbf{X})$ 包含了样本关于参数 θ 的全部信息，即在给定 $T(\mathbf{X})$ 的条件下样本的分布不依赖于 θ ，则称 T 为充分统计量。

直觉：充分统计量是样本的“无损压缩”——在估计 θ 时，没有必要保留超出 $T(\mathbf{X})$ 的信息。

常见充分统计量：

分布	参数	充分统计量
$\mathcal{N}(\mu, \sigma^2)$	μ (σ^2 已知)	$\bar{X} = \frac{1}{n} \sum X_i$
$\mathcal{N}(\mu, \sigma^2)$	(μ, σ^2) 均未知	$(\sum X_i, \sum X_i^2)$
$\text{Pois}(\lambda)$	λ	$\sum X_i$
$\text{Bernoulli}(p)$	p	$\sum X_i$ (成功次数)

Rao-Blackwell 定理 (定性理解)：基于充分统计量的估计量，其均方误差不劣于不基于充分统计量的估计量。因此好的估计量应当是充分统计量的函数。

16.2 矩估计法

16.2.1 矩估计的基本思想

总体矩 (population moment)： k 阶总体矩定义为

$$\mu_k = E[X^k], \quad k = 1, 2, 3, \dots$$

它是参数 θ 的函数： $\mu_k = \mu_k(\theta)$ 。

样本矩 (sample moment): k 阶样本矩定义为

$$\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, 3, \dots$$

矩估计法 (Method of Moments, MoM) 的核心思想: 用样本矩替代对应的总体矩, 建立方程组, 求解参数的估计量。

由大数定律, $\hat{\mu}_k \xrightarrow{P} \mu_k(\theta)$, 因此这种替代有坚实的理论基础。

16.2.2 矩估计的一般步骤

设总体分布含 m 个未知参数 $\theta_1, \theta_2, \dots, \theta_m$:

第一步: 计算前 m 阶总体矩, 表示为参数的函数:

$$\mu_k = E[X^k] = g_k(\theta_1, \dots, \theta_m), \quad k = 1, 2, \dots, m$$

第二步: 令总体矩等于样本矩, 建立 m 个方程组成的方程组:

$$g_k(\theta_1, \dots, \theta_m) = \hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, \dots, m$$

第三步: 解方程组, 得到 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ 即为矩估计量。

16.2.3 矩估计示例

示例 1: 正态分布 $\mathcal{N}(\mu, \sigma^2)$ (两参数均未知)

总体矩:

$$\mu_1 = E[X] = \mu, \quad \mu_2 = E[X^2] = \text{Var}(X) + (E[X])^2 = \sigma^2 + \mu^2$$

令 $\mu_1 = \hat{\mu}_1, \mu_2 = \hat{\mu}_2$:

$$\begin{cases} \mu = \bar{X} \\ \sigma^2 + \mu^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \end{cases}$$

解得矩估计量:

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

注意：矩估计得到的方差估计量分母为 n ，而非 $n-1$ 。

示例 2：均匀分布 $U(a, b)$ （两参数均未知）

总体矩：

$$\mu_1 = E[X] = \frac{a+b}{2}, \quad \mu_2 = E[X^2] = \frac{a^2 + ab + b^2}{3}$$

也可利用方差 $\text{Var}(X) = \frac{(b-a)^2}{12}$ ，令 $\mu_1 = \bar{X}$ ， $\mu_2 - \mu_1^2 = \widehat{\text{Var}}(X)$ ：

$$\frac{a+b}{2} = \bar{X}, \quad \frac{(b-a)^2}{12} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

设 $B^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ ，解得：

$$\hat{a} = \bar{X} - \sqrt{3} B, \quad \hat{b} = \bar{X} + \sqrt{3} B$$

示例 3：指数分布 $\text{Exp}(\lambda)$ （单参数）

总体矩： $\mu_1 = E[X] = 1/\lambda$

令 $1/\lambda = \bar{X}$ ，解得：

$$\hat{\lambda} = \frac{1}{\bar{X}}$$

16.2.4 矩估计的优缺点

优点：- 计算简单，不需要知道分布的具体形式（有时仅需前几阶矩存在）- 当总体分布复杂或难以写出似然函数时，矩估计是便捷的替代方案

缺点：- 一般不是充分统计量的函数，因此统计效率通常不是最优的 - 对于同一参数，不同阶次矩建立的方程组可能给出不同结果（矩估计不唯一）- 在样本量较小时，估计精度可能较差

16.3 最大似然估计（MLE）

16.3.1 似然函数

设 $X_1, X_2, \dots, X_n \stackrel{iid}{\sim} f(x; \theta)$ （ f 为 pmf 或 pdf），观测值为 $x_1, x_2, \dots, x_n$ 。

似然函数（likelihood function）定义为：

$$L(\theta) = L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

关键理解：

- 当 θ 固定， $f(x; \theta)$ 是 x 的概率密度（或质量）函数
- 当 $x_1, \dots, x_n$ 固定（已观测）， $L(\theta)$ 是 θ 的函数——它衡量“在参数为 θ 时，观测到这批数据的可能性有多大”

似然函数不是概率： $\int L(\theta) d\theta$ 一般不等于 1，它随 θ 变化，反映的是不同参数值下观测数据的“似然程度”。

对数似然函数（log-likelihood）：

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(x_i; \theta)$$

由于 $\log$ 是单调递增函数，最大化 $L(\theta)$ 与最大化 $\ell(\theta)$ 等价。对数似然将乘积变为求和，大幅简化计算。

16.3.2 最大似然估计的定义

定义：使似然函数 $L(\theta)$ 达到最大值的参数值 $\hat{\theta}_{MLE}$ 称为 θ 的最大似然估计量（Maximum Likelihood Estimator, MLE）：

$$\hat{\theta}_{MLE} = \arg \max_{\theta \in \Theta} L(\theta) = \arg \max_{\theta \in \Theta} \ell(\theta)$$

直觉：MLE 选择使“当前观测数据最有可能出现”的参数值。换言之，它是对“什么样的参数最能解释我们看到的的数据”这一问题的回答。

16.3.3 MLE 的求解方法

方法一：微分法（最常用）

若 $\ell(\theta)$ 关于 θ 可微，令似然方程（likelihood equation）为零：

$$\frac{\partial \ell(\theta)}{\partial \theta_j} = 0, \quad j = 1, 2, \dots, m$$

解方程组，验证是极大值点（而非极小值或鞍点）。

方法二：代数分析法

当 $\ell(\theta)$ 是 θ 的单调函数时，MLE 在参数边界取得，不能用微分法，需直接分析。

方法三：数值优化

当似然方程无解析解时，使用梯度上升（gradient ascent）、EM 算法等数值方法。

16.3.4 经典 MLE 推导示例

示例 1：伯努利分布 $\text{Bernoulli}(p)$

设 $x_1, \dots, x_n \in \{0, 1\}$ ，令 $k = \sum_{i=1}^n x_i$ （成功次数）。

对数似然：

$$\ell(p) = k \log p + (n - k) \log(1 - p)$$

对 p 求导并令其为零：

$$\frac{d\ell}{dp} = \frac{k}{p} - \frac{n - k}{1 - p} = 0$$

解得：

$$\hat{p}_{MLE} = \frac{k}{n} = \frac{\sum_{i=1}^n x_i}{n}$$

即 MLE 就是样本中成功的频率，与直觉完全一致。

示例 2：正态分布 $\mathcal{N}(\mu, \sigma^2)$ （均值和方差均未知）

对数似然：

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

对 μ 求偏导：

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \implies \hat{\mu}_{MLE} = \bar{x}$$

对 σ^2 求偏导（令 $v = \sigma^2$ ）：

$$\frac{\partial \ell}{\partial v} = -\frac{n}{2v} + \frac{1}{2v^2} \sum_{i=1}^n (x_i - \mu)^2 = 0$$

代入 $\hat{\mu}_{MLE} = \bar{x}$ ，解得：

$$\hat{\mu}_{MLE} = \bar{x}, \quad \hat{\sigma}_{MLE}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

注意 $\hat{\sigma}_{MLE}^2$ 分母为 n ，不是无偏估计（详见 16.4 节）。

示例 3：泊松分布 $\text{Pois}(\lambda)$

对数似然：

$$\ell(\lambda) = \sum_{i=1}^n x_i \cdot \log \lambda - n\lambda - \sum_{i=1}^n \log(x_i!)$$

令 $\frac{d\ell}{d\lambda} = \frac{\sum x_i}{\lambda} - n = 0$ ，解得：

$$\hat{\lambda}_{MLE} = \bar{x}$$

示例 4：均匀分布 $U(0, \theta)$ （代数分析法）

对数似然： $\ell(\theta) = -n \log \theta$ （当 $\theta \geq \max_i x_i$ 时有效，否则 $L(\theta) = 0$ ）

$\ell(\theta) = -n \log \theta$ 关于 θ 单调递减，故在满足约束 $\theta \geq x_{(n)} = \max_i x_i$ 的前提下， $\ell(\theta)$ 在 $\theta = x_{(n)}$ 处取得最大值：

$$\hat{\theta}_{MLE} = x_{(n)} = \max(x_1, x_2, \dots, x_n)$$

注意此时不能用微分法，因为 MLE 在参数的边界取得。

16.3.5 MLE 的不变性

定理（MLE 不变性原理）：若 $\hat{\theta}_{MLE}$ 是 θ 的 MLE，则对任意函数 $g(\theta)$ ， $g(\hat{\theta}_{MLE})$ 是 $g(\theta)$ 的 MLE。

示例：若 $\hat{\sigma}_{MLE}^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$ ，则标准差的 MLE 为 $\hat{\sigma}_{MLE} = \sqrt{\hat{\sigma}_{MLE}^2}$ 。

不变性使 MLE 极为方便——无需重新推导，直接对估计量做变换即可。

16.4 估计量的评价标准

有了矩估计和 MLE 两种构造估计量的方法，自然的问题是：哪个估计量更好？本节介绍三大评价标准。

16.4.1 无偏性（Unbiasedness）

定义：若估计量 $\hat{\theta}$ 满足

$$E[\hat{\theta}] = \theta \quad \text{对一切 } \theta \in \Theta$$

则称 $\hat{\theta}$ 为 θ 的无偏估计量（unbiased estimator）。

偏差（bias） 定义为： $\text{Bias}(\hat{\theta}) = E[\hat{\theta}] - \theta$ 。

直觉：无偏估计量在大量重复实验中“平均上”指向真实参数值，没有系统性偏差。

重要结论：

1. 样本均值是总体均值的无偏估计：

$$E[\bar{X}] = E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \mu$$

2. 样本方差（分母 $n-1$ ）是总体方差的无偏估计：

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \implies E[S^2] = \sigma^2$$

为何分母是 $n-1$ ？用 $\bar{X}$ 替代未知的 μ 引入了一个约束，使残差 $(X_i - \bar{X})$ 只有 $n-1$ 个自由度。可以严格验证：

$$E\left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right] = \frac{n-1}{n} \sigma^2 \neq \sigma^2$$

故 MLE 方差估计量 $\hat{\sigma}_{MLE}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ 是有偏的，偏差为 $-\sigma^2/n$ （低估了方差）。

3. 无偏性的局限性：无偏性只关注期望，忽视了方差。两个无偏估计量中，方差更小的通常更好。此外，无偏性不具备变换不变性：若 $\hat{\theta}$ 是 θ 的无偏估计， $g(\hat{\theta})$ 一般不是 $g(\theta)$ 的无偏估计（例如 S 不是 σ 的无偏估计）。

16.4.2 有效性 (Efficiency) 与 Cramér-Rao 下界

在所有无偏估计量中，方差最小者最优。但方差能小到什么程度？Cramér-Rao 下界给出了理论极限。

Fisher 信息量 (Fisher information)：

$$I(\theta) = E\left[\left(\frac{\partial \log f(X; \theta)}{\partial \theta}\right)^2\right] = -E\left[\frac{\partial^2 \log f(X; \theta)}{\partial \theta^2}\right]$$

$I(\theta)$ 度量了样本中关于参数 θ 所含信息的多少—— $I(\theta)$ 越大，参数越“可估”。

为什么偏偏是这个量？（直觉 + 推导）记得分函数 (score function) $S(\theta) = \frac{\partial}{\partial \theta} \log f(X; \theta)$ ，它衡量“对数似然随 θ 变化的敏感度”。在正则条件下它的均值为零：

$$E[S(\theta)] = \int \frac{\partial_\theta f}{f} f dx = \frac{\partial}{\partial \theta} \int f(x; \theta) dx = \frac{\partial}{\partial \theta} 1 = 0.$$

既然得分均值为零，它的“波动幅度”就由方差刻画，而 $I(\theta) = \text{Var}(S(\theta)) = E[S(\theta)^2]$ ——这正是第一个表达式。直觉：若 θ 稍变就让对数似然剧烈起伏（得分波动大），数据就能敏锐地“分辨”出 θ ，信息量大。

两种形式为何相等？把恒等式 $\int (\partial_\theta \log f) f dx = 0$ 再对 θ 求一次导：

$$\int \left[(\partial_\theta^2 \log f) f + (\partial_\theta \log f)(\partial_\theta f) \right] dx = 0 \implies E[\partial_\theta^2 \log f] + E[(\partial_\theta \log f)^2] = 0,$$

(第二项用了 $\partial_\theta f = (\partial_\theta \log f) f$)，于是 $E[(\partial_\theta \log f)^2] = -E[\partial_\theta^2 \log f]$ ，即两式相等。后一形式（对数似然的负曲率）说明：似然峰越“尖”，信息越多。以上推导依赖 §16.5.4 列出的正则条件（积分与求导可交换等）。

Cramér-Rao 下界定理：对任意无偏估计量 $\hat{\theta}$ ，有

$$\text{Var}(\hat{\theta}) \geq \frac{1}{n I(\theta)}$$

其中 n 为样本量。

定义：若某无偏估计量 $\hat{\theta}^*$ 的方差恰好等于 Cramér-Rao 下界，即

$$\text{Var}(\hat{\theta}^*) = \frac{1}{n I(\theta)}$$

则称 $\hat{\theta}^*$ 为 θ 的有效估计量（efficient estimator），也称为最小方差无偏估计量（UMVUE）。

示例：正态总体的 Fisher 信息量

设 $X \sim \mathcal{N}(\mu, \sigma^2)$ (σ^2 已知)，估计 μ ：

$$\log f(x; \mu) = -\frac{1}{2} \log(2\pi\sigma^2) - \frac{(x - \mu)^2}{2\sigma^2}$$

$$\frac{\partial \log f}{\partial \mu} = \frac{x - \mu}{\sigma^2}, \quad I(\mu) = E\left[\frac{(X - \mu)^2}{\sigma^4}\right] = \frac{\sigma^2}{\sigma^4} = \frac{1}{\sigma^2}$$

C-R 下界： $\text{Var}(\hat{\mu}) \geq \frac{\sigma^2}{n}$

样本均值 $\bar{X}$ 的方差： $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$ ，恰好等于下界—— $\bar{X}$ 是 μ 的有效估计量。

相对效率：若 $\hat{\theta}_1, \hat{\theta}_2$ 均为 θ 的无偏估计量，定义相对效率为

$$e(\hat{\theta}_1, \hat{\theta}_2) = \frac{\text{Var}(\hat{\theta}_2)}{\text{Var}(\hat{\theta}_1)}$$

若 $e > 1$ ，说明 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 更有效（方差更小）。

16.4.3 均方误差 (MSE)

实践中常用均方误差 (Mean Squared Error) 综合考量偏差与方差：

$$\text{MSE}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + [\text{Bias}(\hat{\theta})]^2$$

偏差-方差分解：MSE = 方差 + 偏差的平方

- 无偏估计量： $\text{MSE} = \text{Var}(\hat{\theta})$
- 有偏估计量：若偏差小且方差也更小，MSE 可能反而优于无偏估计

示例：比较 $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ （无偏）与 $\hat{\sigma}_{MLE}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ （有偏）：

$$\text{MSE}(S^2) = \text{Var}(S^2) = \frac{2\sigma^4}{n-1}$$

$$\text{MSE}(\hat{\sigma}_{MLE}^2) = \text{Var}(\hat{\sigma}_{MLE}^2) + \frac{\sigma^4}{n^2} = \frac{2(n-1)\sigma^4}{n^2} + \frac{\sigma^4}{n^2} = \frac{(2n-1)\sigma^4}{n^2}$$

当 $n \geq 2$ 时， $\text{MSE}(\hat{\sigma}_{MLE}^2) < \text{MSE}(S^2)$ （有偏的 MLE 估计 MSE 反而更小！）。

16.4.4 一致性 (Consistency)

无偏性和有效性是针对固定样本量 n 的性质。一致性则关注当样本量趋于无穷时，估计量是否收敛于真实参数。

定义（弱一致性）：若对任意 $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| > \varepsilon) = 0$$

则称估计量序列 $\{\hat{\theta}_n\}$ 为 θ 的（弱）一致估计量 (consistent estimator)，记作 $\hat{\theta}_n \xrightarrow{P} \theta$ 。

判断一致性的充分条件：若

$$\lim_{n \rightarrow \infty} E[\hat{\theta}_n] = \theta \quad \text{且} \quad \lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_n) = 0$$

则 $\hat{\theta}_n$ 是一致估计量（由 Chebyshev 不等式可得）。

重要结论：

- 样本均值 $\bar{X}_n \xrightarrow{P} \mu$ （大数定律）
- $S_n^2 \xrightarrow{P} \sigma^2$ （方差的一致估计）
- MLE 在正则条件下是一致估计量（见 16.5 节）

一致性 vs 无偏性的关系：

	无偏	一致
固定 n 下有意义	是	否
$n \rightarrow \infty$ 下有保证	不一定趋向真值（方差可能不趋零）	是
两者关系	互不蕴含	互不蕴含

一致性是比无偏性更基本的”大样本”要求：一个实用的估计量至少应当是一致的。

16.4.5 三大标准总结

标准	数学表达	关注点	适用场景
无偏性	$E[\hat{\theta}] = \theta$	期望无系统偏差	固定样本量
有效性	$\text{Var}(\hat{\theta}) = \frac{1}{nI(\theta)}$	方差最小化	固定样本量，无偏前提
一致性	$\hat{\theta}_n \xrightarrow{P} \theta$	大样本收敛	渐近分析

16.5 MLE 的渐近性质

16.5.1 MLE 的渐近正态性

在温和的正则条件下（似然函数光滑、支撑不依赖参数等），MLE 具有以下优良的渐近性质：

定理（MLE 的渐近分布）：设 $X_1, \dots, X_n \stackrel{iid}{\sim} f(x; \theta_0)$ ， θ_0 为真实参数，则

$$\sqrt{n} \left(\hat{\theta}_{MLE} - \theta_0 \right) \xrightarrow{d} \mathcal{N} \left(0, \frac{1}{I(\theta_0)} \right)$$

等价地，对充分大的 n ：

$$\hat{\theta}_{MLE} \approx \mathcal{N} \left(\theta_0, \frac{1}{n I(\theta_0)} \right)$$

这个定理有三层含义：

- 1. 一致性： $\hat{\theta}_{MLE} \xrightarrow{P} \theta_0$ （方差趋于 0）
- 2. 渐近无偏性： $E[\hat{\theta}_{MLE}] \rightarrow \theta_0$
- 3. 渐近有效性：渐近方差 $\frac{1}{nI(\theta_0)}$ 恰好等于 C-R 下界，即 MLE 在大样本下达到有效估计量的理论极限

实践意义：渐近正态性为构造 MLE 的置信区间提供了基础：

$$\hat{\theta}_{MLE} \pm z_{\alpha/2} \cdot \sqrt{\frac{1}{n I(\hat{\theta}_{MLE})}}$$

16.5.2 多参数情形

设参数向量 $\theta = (\theta_1, \dots, \theta_m)$ ，Fisher 信息矩阵为：

$$\mathbf{I}(\theta) = -E \left[\frac{\partial^2 \log f(X; \theta)}{\partial \theta \partial \theta^\top} \right]$$

其中 (j, k) 元素为 $-E \left[\frac{\partial^2 \log f}{\partial \theta_j \partial \theta_k} \right]$ 。

渐近分布：

$$\sqrt{n} (\hat{\theta}_{MLE} - \theta_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{I}(\theta_0)^{-1})$$

C-R 下界的多参数推广：无偏估计量的协方差矩阵满足 $\text{Cov}(\hat{\theta}) \succeq \frac{1}{n} \mathbf{I}(\theta)^{-1}$ （正半定序意义下）。

16.5.3 Delta 方法：函数变换的渐近分布

定理（Delta 方法）：若 $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$ ，且 g 在 θ 处可微且 $g'(\theta) \neq 0$ ，则

$$\sqrt{n} (g(\hat{\theta}_n) - g(\theta)) \xrightarrow{d} \mathcal{N}(0, [g'(\theta)]^2 \sigma^2)$$

示例： $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Bernoulli}(p)$ ， $\hat{p}_{MLE} = \bar{X}$ ，求 $\log\left(\frac{\hat{p}}{1-\hat{p}}\right)$ （对数几率）的渐近分布。

令 $g(p) = \log \frac{p}{1-p}$ ，则 $g'(p) = \frac{1}{p(1-p)}$ 。

由于 $I(p) = \frac{1}{p(1-p)}$ ，MLE 的渐近方差为 $\frac{p(1-p)}{n}$ ，故：

$$\sqrt{n} \left(\log \frac{\hat{p}}{1-\hat{p}} - \log \frac{p}{1-p} \right) \xrightarrow{d} \mathcal{N} \left(0, \frac{1}{p^2(1-p)^2} \cdot p(1-p) \right) = \mathcal{N} \left(0, \frac{1}{p(1-p)} \right)$$

16.5.4 MLE 的正则条件

为使上述渐近结果成立，通常需要：

1. 模型可识别性：不同参数给出不同的分布
2. 支撑不依赖参数： $f(x; \theta) > 0$ 的区域不随 θ 变化（均匀分布 $U(0, \theta)$ 不满足此条件）
3. 三阶可微：对数似然关于 θ 三阶可微
4. 参数在内点：真实参数 θ_0 在参数空间的内部（非边界）
5. Fisher 信息量有限且正： $0 < I(\theta) < \infty$

当这些条件不满足时（如均匀分布 MLE），需要单独分析估计量的分布。

本章小结

点估计的两大方法：

方法	原理	优点	缺点
矩估计	样本矩 = 总体矩	简单，无需完整分布	效率一般不最优
MLE	最大化似然函数	渐近有效，不变性，大样本理论完备	需要完整分布，计算可能复杂

估计量的三大评价维度：

- 1. 无偏性： $E[\hat{\theta}] = \theta$ ——无系统偏差
- 2. 有效性： $\text{Var}(\hat{\theta}) = \frac{1}{nI(\theta)}$ ——方差达到 C-R 下界
- 3. 一致性： $\hat{\theta}_n \xrightarrow{P} \theta$ ——大样本收敛

MLE 的核心优势（大样本下）：

$$\hat{\theta}_{MLE} \approx \mathcal{N}\left(\theta_0, \frac{1}{nI(\theta_0)}\right)$$

- 渐近无偏：均值趋近真实值
- 渐近有效：方差达到理论下界
- 渐近正态：便于构造置信区间
- 不变性：函数变换后仍是 MLE

实用法则：

构造估计量 → 检验无偏性 → 检验一致性 → 计算 MSE → 比较效率

深度学习应用：MLE 与损失函数设计、交叉熵的由来

16.A.1 深度学习中的参数估计视角

训练神经网络的本质，是在给定数据集 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$ 的条件下，寻找使模型“最好地解释数据”的参数 θ 。这正是最大似然估计的核心思想。

设模型输出的条件概率分布为 $p_\theta(y \mid x)$ ，在独立同分布假设下，对数似然为：

$$\ell(\theta) = \sum_{i=1}^n \log p_\theta(y_i \mid x_i)$$

最大化对数似然 = 最小化负对数似然 (NLL):

$$\hat{\theta}_{MLE} = \arg \max_{\theta} \ell(\theta) = \arg \min_{\theta} \left[- \sum_{i=1}^n \log p_{\theta}(y_i | x_i) \right]$$

不同的分布假设导致不同的损失函数，这揭示了深度学习中各类损失函数的统计起源。

16.A.2 分类问题：交叉熵损失的由来

模型假设：\$K\$ 类分类问题，给定输入 \$x\$，模型输出类别概率向量：

$$p_{\theta}(y = k | x) = \text{softmax}(\mathbf{z})_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad k = 1, \dots, K$$

其中 \$\mathbf{z} = f_{\theta}(x)\$ 为网络输出的 logit 向量。

MLE 目标：对每个样本 \$(x_i, y_i)\$ (\$y_i\$ 为真实类别标签)，最大化：

$$\log p_{\theta}(y_i | x_i) = \log \text{softmax}(f_{\theta}(x_i))_{y_i} = z_{y_i} - \log \sum_{j=1}^K e^{z_j}$$

最小化负对数似然，即：

$$\mathcal{L}_{CE}(\theta) = -\frac{1}{n} \sum_{i=1}^n \log p_{\theta}(y_i | x_i)$$

若将真实标签表示为 one-hot 向量 \$\mathbf{q}_i\$ (第 \$y_i\$ 个分量为 1，其余为 0)，则：

$$\mathcal{L}_{CE} = -\frac{1}{n} \sum_{i=1}^n \sum_{k=1}^K q_{ik} \log p_{\theta}(y = k | x_i) = \frac{1}{n} \sum_{i=1}^n H(\mathbf{q}_i, \mathbf{p}_{\theta}(x_i))$$

这正是交叉熵 (cross-entropy) 的定义！

交叉熵与 KL 散度的关系：

$$H(q, p) = H(q) + D_{KL}(q \| p)$$

由于真实分布 \$q\$ 固定，最小化交叉熵等价于最小化 KL 散度，即让预测分布 \$p_{\theta}\$ 尽可能接近真实分布 \$q\$。

16.A.3 回归问题：MSE 损失的由来

模型假设：输出 y 在给定 x 时服从以模型预测为均值的正态分布：

$$y \mid x \sim \mathcal{N}(f_{\theta}(x), \sigma^2)$$

MLE 目标：最大化

$$\ell(\theta) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - f_{\theta}(x_i))^2$$

去掉与 θ 无关的常数，最大化 ℓ 等价于最小化：

$$\mathcal{L}_{MSE}(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - f_{\theta}(x_i))^2$$

这正是均方误差（MSE）损失！

结论：MSE 损失 = 高斯噪声假设下的 MLE。

16.A.4 二分类问题：二元交叉熵的由来

模型假设：二分类问题， $y \in \{0, 1\}$ ，模型输出 $p_{\theta}(y = 1 \mid x) = \sigma(f_{\theta}(x))$ （ σ 为 sigmoid 函数）。

即 $y \mid x \sim \text{Bernoulli}(\sigma(f_{\theta}(x)))$ 。

MLE 目标：最小化

$$\mathcal{L}_{BCE} = -\frac{1}{n} \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

其中 $p_i = \sigma(f_{\theta}(x_i))$ 。这是二元交叉熵损失（Binary Cross-Entropy）。

16.A.5 损失函数的统一 MLE 视角

任务	分布假设	MLE 等价损失	PyTorch 函数
回归	$y \sim \mathcal{N}(f_{\theta}(x), \sigma^2)$	MSE	<code>nn.MSELoss()</code>
二分类	$y \sim \text{Bernoulli}(\sigma(f_{\theta}(x)))$	二元交叉熵	<code>nn.BCEWithLogitsLoss()</code>
多分类	$y \sim \text{Categorical}(\text{softmax}(f_{\theta}(x)))$	交叉熵	<code>nn.CrossEntropyLoss()</code>
计数回归	$y \sim \text{Pois}(e^{f_{\theta}(x)})$	泊松 NLL	<code>nn.PoissonNLLLoss()</code>

16.A.6 PyTorch 代码：MLE 视角实现各类损失

```

import torch
import torch.nn as nn
import torch.nn.functional as F

# =====
# 1. 多分类交叉熵：Categorical 分布的 MLE
# =====

def cross_entropy_from_mle(logits, targets):
    """
    MLE 视角推导多分类交叉熵损失
    logits: (batch_size, num_classes) 模型输出 (未经 softmax)
    targets: (batch_size,) 真实类别标签

    等价于 nn.CrossEntropyLoss(), 即  $-\log p(y_i | x_i)$ 
    """
    # 方法 1: 手动实现 (直接展示 MLE 推导过程)
    log_probs = F.log_softmax(logits, dim=-1)  #  $\log p_{\theta}(k | x)$ 
    nll = -log_probs[range(len(targets)), targets]  #  $-\log p_{\theta}(y_i | x_i)$ 
    return nll.mean()

    # 方法 2: 等价的 PyTorch 内置函数
    # return nn.CrossEntropyLoss()(logits, targets)

# =====
# 2. 二元交叉熵：Bernoulli 分布的 MLE
# =====

def binary_cross_entropy_from_mle(logits, targets):
    """
    MLE 视角推导二元交叉熵损失
    logits: (batch_size,) 模型输出  $z$  (未经 sigmoid)
    targets: (batch_size,) 真实标签, 0 或 1

     $p = \text{sigmoid}(z) = 1 / (1 + \exp(-z))$ 
    loss =  $-[y * \log(p) + (1-y) * \log(1-p)]$ 
           =  $-[y * \log(\text{sigmoid}(z)) + (1-y) * \log(1-\text{sigmoid}(z))]$ 
    """

```

```

"""
# 使用数值稳定版本
return F.binary_cross_entropy_with_logits(logits, targets.float())

# =====
# 3. MSE 损失：高斯分布的 MLE
# =====

def mse_from_mle(predictions, targets):
    """
    MLE 视角推导 MSE 损失
    假设:  $y \mid x \sim N(f_{\theta}(x), \sigma^2)$ 
    对数似然:  $-\frac{n}{2} * \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} * \sum((y_i - f(x_i))^2)$ 
    最大化对数似然 等价于 最小化 MSE
    """
    return F.mse_loss(predictions, targets)

# =====
# 4. 完整示例：比较不同损失函数与分布假设的对应关系
# =====

class MLEClassifier(nn.Module):
    """ 多分类器: Categorical 分布 MLE = 交叉熵损失 """
    def __init__(self, input_dim, num_classes):
        super().__init__()
        self.fc = nn.Linear(input_dim, num_classes)

    def forward(self, x):
        return self.fc(x)  # 返回 logits (未经 softmax)

class MLERegressor(nn.Module):
    """ 回归器: 高斯分布 MLE = MSE 损失 """
    def __init__(self, input_dim):
        super().__init__()
        self.fc = nn.Linear(input_dim, 1)

    def forward(self, x):
        return self.fc(x).squeeze(-1)

```

```

def demonstrate_mle_losses():
    """ 演示 MLE 与损失函数的对应关系 """
    torch.manual_seed(42)
    batch_size, input_dim, num_classes = 32, 16, 5

    # 多分类: MLE = 交叉熵
    classifier = MLEClassifier(input_dim, num_classes)
    x = torch.randn(batch_size, input_dim)
    y_class = torch.randint(0, num_classes, (batch_size,))

    logits = classifier(x)
    ce_loss = nn.CrossEntropyLoss()(logits, y_class)

    # 手动计算 NLL, 验证等价性
    log_probs = F.log_softmax(logits, dim=-1)
    nll_manual = -log_probs[range(batch_size), y_class].mean()

    print(f" 交叉熵损失 (nn.CrossEntropyLoss): {ce_loss.item():.6f}")
    print(f" 手动 NLL (MLE 推导): {nll_manual.item():.6f}")
    print(f" 差值: {abs(ce_loss.item() - nll_manual.item()):.2e} (应接近 0)")
    print()

    # 回归: MLE = MSE
    regressor = MLERegressor(input_dim)
    y_reg = torch.randn(batch_size)
    preds = regressor(x)

    mse_loss = nn.MSELoss()(preds, y_reg)
    # 手动计算 (高斯 NLL, 去掉常数项)
    mse_manual = ((preds - y_reg) ** 2).mean()

    print(f"MSE 损失 (nn.MSELoss): {mse_loss.item():.6f}")
    print(f" 手动 MSE (高斯 MLE): {mse_manual.item():.6f}")

    # =====
    # 5. Fisher 信息量可视化 (伯努利参数估计)
    # =====

```

```

def fisher_information_bernoulli(p_values):
    """
    伯努利分布的 Fisher 信息量:  $I(p) = 1 / (p * (1 - p))$ 
    当  $p=0.5$  时最小 (参数最难估计),  $p$  接近 0 或 1 时最大
    """
    return 1.0 / (p_values * (1.0 - p_values))

def cramer_rao_bound_demo():
    """ 展示 C-R 下界与 MLE 方差的关系 """
    import numpy as np

    p_true = 0.3 # 真实参数
    n_samples = 1000
    n_experiments = 10000

    # 模拟 MLE 估计量的分布
    mle_estimates = []
    for _ in range(n_experiments):
        samples = np.random.binomial(1, p_true, n_samples)
        mle_estimates.append(samples.mean()) #  $\hat{p}_{MLE}$  = 样本均值

    mle_var = np.var(mle_estimates)
    cr_bound = p_true * (1 - p_true) / n_samples # C-R 下界 =  $1 / (n * I(p))$ 

    print(f" 真实参数 p = {p_true}")
    print(f"MLE 方差 (模拟):      {mle_var:.6f}")
    print(f"C-R 下界  $p(1-p)/n$ :    {cr_bound:.6f}")
    print(f" 比值 (应接近 1.0):      {mle_var / cr_bound:.4f}")
    print(" 结论: MLE 方差    C-R 下界, MLE 是渐近有效估计量")

# 运行演示
if __name__ == "__main__":
    demonstrate_mle_losses()
    print("---")
    cramer_rao_bound_demo()

```

16.A.7 深度理解：为什么 MLE 是合理的训练目标

从信息论的视角，最小化交叉熵等价于最小化经验数据分布 $\hat{q}$ 与模型分布 p_θ 之间的 KL 散度：

$$\hat{\theta}_{MLE} = \arg \min_{\theta} D_{KL}(\hat{q}(x, y) \parallel p_{\theta}(x, y))$$

其中经验分布 $\hat{q}(x, y) = \frac{1}{n} \sum_{i=1}^n \delta_{(x_i, y_i)}$ 。

三个等价视角：

$$\underbrace{\text{最大化对数似然}}_{\text{统计学}} \equiv \underbrace{\text{最小化 NLL 损失}}_{\text{深度学习}} \equiv \underbrace{\text{最小化 KL 散度}}_{\text{信息论}}$$

这种统一性解释了为什么 MLE/交叉熵在深度学习中如此普遍——它有坚实的理论基础，且在大样本下保证渐近有效。

练习题

练习 16.1（矩估计）

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Gamma}(\alpha, \lambda)$ ，其中 $\alpha > 0$ 为形状参数， $\lambda > 0$ 为速率参数，分布的均值和方差分别为 $E[X] = \alpha/\lambda$ ， $\text{Var}(X) = \alpha/\lambda^2$ 。

- (1) 用矩估计法求 α 和 λ 的矩估计量；
- (2) 验证所得估计量是否为参数的函数，以样本均值 $\bar{X}$ 和样本方差 $S^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ 表示结果；
- (3) 比较 $\hat{\lambda}$ 与指数分布 ($\alpha = 1$) 情形下的矩估计。

练习 16.2（最大似然估计）

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Exp}(\lambda)$ ，即密度函数为 $f(x; \lambda) = \lambda e^{-\lambda x}$ ($x > 0$)。

- (1) 写出对数似然函数 $\ell(\lambda)$ ；
- (2) 求 λ 的 MLE $\hat{\lambda}_{MLE}$ ；
- (3) 利用 MLE 不变性，求平均寿命 $\mu = 1/\lambda$ 的 MLE；
- (4) 验证：矩估计量与 MLE 是否相同？

练习 16.3（无偏性与有效性）

设 $X_1, \dots, X_n \stackrel{iid}{\sim} U(0, \theta)$ ， $\theta > 0$ 未知。

- (1) 验证 $\hat{\theta}_1 = 2\bar{X}$ 是 θ 的无偏估计；

(2) 证明 $\hat{\theta}_2 = \frac{n+1}{n} X_{(n)}$ 也是 θ 的无偏估计, 其中 $X_{(n)} = \max(X_1, \dots, X_n)$;

(提示: $X_{(n)}$ 的 pdf 为 $f_{X_{(n)}}(x) = nx^{n-1}/\theta^n$, $0 < x < \theta$)

(3) 分别计算 $\text{Var}(\hat{\theta}_1)$ 和 $\text{Var}(\hat{\theta}_2)$, 比较两者的效率;

(4) $\hat{\theta}_2$ 与 MLE $\hat{\theta}_{MLE} = X_{(n)}$ 有何关系?

练习 16.4 (Fisher 信息量与 C-R 下界)

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Pois}(\lambda)$, $\lambda > 0$ 。

(1) 计算单个观测 X 的 Fisher 信息量 $I(\lambda)$;

(2) 写出 λ 的 MLE $\hat{\lambda}_{MLE}$, 并验证它是无偏估计;

(3) 计算 $\text{Var}(\hat{\lambda}_{MLE})$, 与 C-R 下界比较;

(4) 利用 Delta 方法, 求 $g(\lambda) = \sqrt{\lambda}$ 的 MLE 的渐近方差。

练习 16.5 (综合: MLE 与损失函数)

设神经网络二分类模型输出标量 $z = f_\theta(x) \in \mathbb{R}$, 类别概率为 $p = \sigma(z) = \frac{1}{1+e^{-z}}$ 。设训练集有 n 个样本 (x_i, y_i) , $y_i \in \{0, 1\}$ 。

(1) 写出假设 $y_i | x_i \sim \text{Bernoulli}(\sigma(f_\theta(x_i)))$ 时的对数似然 $\ell(\theta)$;

(2) 证明最大化 $\ell(\theta)$ 等价于最小化二元交叉熵损失 $\mathcal{L}_{BCE}$;

(3) 对单个样本, 写出损失关于 z 的梯度 $\partial \mathcal{L}_{BCE} / \partial z$, 并解释其直觉含义;

(4) 若将标签改为 $y_i \in \{-1, +1\}$, 并假设 $y_i | x_i \sim \text{Logistic}$ (即 $P(y = 1 | x) = \sigma(z)$), 损失函数变为什么形式? 与 Hinge 损失有何联系?

练习答案

答案 16.1

(1) 矩估计量

令总体矩等于样本矩, 建立方程组:

$$\begin{cases} E[X] = \alpha/\lambda = \bar{X} \\ \text{Var}(X) = \alpha/\lambda^2 = \frac{1}{n} \sum (X_i - \bar{X})^2 = B^2 \end{cases}$$

其中记 $B^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ (样本方差, 分母 n)。

(2) 解方程组

由第一式: $\alpha = \lambda \bar{X}$, 代入第二式:

$$\frac{\lambda \bar{X}}{\lambda^2} = B^2 \implies \frac{\bar{X}}{\lambda} = B^2 \implies \hat{\lambda} = \frac{\bar{X}}{B^2}$$

$$\hat{\alpha} = \hat{\lambda} \bar{X} = \frac{\bar{X}^2}{B^2}$$

即:

$$\hat{\lambda} = \frac{\bar{X}}{B^2}, \quad \hat{\alpha} = \frac{\bar{X}^2}{B^2}$$

(3) 指数分布特例 ($\alpha = 1$)

当 $\alpha = 1$ 时, Gamma 分布退化为指数分布, 此时 $\hat{\lambda} = \bar{X}/B^2$ 。而指数分布的直接矩估计为 $\hat{\lambda} = 1/\bar{X}$ 。两者不同, 但当样本量足够大时 ($B^2 \approx E[X^2] - \bar{X}^2 = 1/\lambda^2$), 可验证 $\hat{\lambda} \rightarrow \lambda$ 。

答案 16.2

(1) 对数似然

$$\ell(\lambda) = \sum_{i=1}^n \log(\lambda e^{-\lambda x_i}) = n \log \lambda - \lambda \sum_{i=1}^n x_i$$

(2) MLE

令 $\frac{d\ell}{d\lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0$, 解得:

$$\hat{\lambda}_{MLE} = \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\bar{x}}$$

验证: $\frac{d^2\ell}{d\lambda^2} = -\frac{n}{\lambda^2} < 0$, 确为极大值点。

(3) 平均寿命的 MLE

由不变性原理: $\hat{\mu}_{MLE} = g(\hat{\lambda}_{MLE}) = \frac{1}{\hat{\lambda}_{MLE}} = \bar{x}$ 。

(4) 矩估计与 MLE 的比较

指数分布 $E[X] = 1/\lambda$, 矩估计令 $1/\lambda = \bar{X}$, 得 $\hat{\lambda}_{MoM} = 1/\bar{X}$ 。

结论：指数分布的矩估计量与 MLE 完全相同，均为 $\hat{\lambda} = 1/\bar{X}$ 。

答案 16.3

(1) $\hat{\theta}_1 = 2\bar{X}$ 的无偏性

$$E[\hat{\theta}_1] = 2E[\bar{X}] = 2 \cdot \frac{\theta}{2} = \theta$$

其中用到 $E[X] = \theta/2$ (均匀分布 $U(0, \theta)$ 的均值)。

(2) $\hat{\theta}_2$ 的无偏性

$X_{(n)}$ 的 pdf 为 $f(x) = nx^{n-1}/\theta^n$ ($0 < x < \theta$)，故：

$$E[X_{(n)}] = \int_0^\theta x \cdot \frac{nx^{n-1}}{\theta^n} dx = \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1} = \frac{n\theta}{n+1}$$

因此：

$$E[\hat{\theta}_2] = \frac{n+1}{n} \cdot E[X_{(n)}] = \frac{n+1}{n} \cdot \frac{n\theta}{n+1} = \theta \checkmark$$

(3) 方差比较

由 $\text{Var}(X) = \theta^2/12$ (均匀分布的方差)：

$$\text{Var}(\hat{\theta}_1) = \text{Var}(2\bar{X}) = 4 \cdot \frac{\text{Var}(X)}{n} = \frac{4}{n} \cdot \frac{\theta^2}{12} = \frac{\theta^2}{3n}$$

对 $X_{(n)}$ ，计算 $E[X_{(n)}^2]$ ：

$$E[X_{(n)}^2] = \int_0^\theta x^2 \cdot \frac{nx^{n-1}}{\theta^n} dx = \frac{n\theta^2}{n+2}$$

$$\text{Var}(X_{(n)}) = \frac{n\theta^2}{n+2} - \left(\frac{n\theta}{n+1}\right)^2 = \frac{n\theta^2}{(n+1)^2(n+2)}$$

$$\text{Var}(\hat{\theta}_2) = \left(\frac{n+1}{n}\right)^2 \text{Var}(X_{(n)}) = \frac{\theta^2}{n(n+2)}$$

由于 $n(n+2) = n^2 + 2n > 3n$ (当 $n > 3$ 时)，有 $\text{Var}(\hat{\theta}_2) < \text{Var}(\hat{\theta}_1)$ 。

$\hat{\theta}_2$ 更有效 (对所有 $n \geq 1$ ，均有 $n(n+2) \geq 3n$ ，即 $n+2 \geq 3$ ，即 $n \geq 1$)。

(4) $\hat{\theta}_2$ 与 MLE 的关系

MLE 为 $\hat{\theta}_{MLE} = X_{(n)}$ (有偏, $E[X_{(n)}] = \frac{n}{n+1}\theta < \theta$)。

$\hat{\theta}_2 = \frac{n+1}{n}X_{(n)}$ 是 MLE 的偏差修正版本——乘以 $(n+1)/n$ 消除了偏差, 同时也适度增大了方差, 但总体 MSE 仍优于 $\hat{\theta}_1$ 。

答案 16.4**(1) Fisher 信息量**

泊松分布 pmf: $p(x; \lambda) = \frac{\lambda^x e^{-\lambda}}{x!}$

$$\log p(x; \lambda) = x \log \lambda - \lambda - \log(x!)$$

$$\frac{\partial \log p}{\partial \lambda} = \frac{x}{\lambda} - 1, \quad \frac{\partial^2 \log p}{\partial \lambda^2} = -\frac{x}{\lambda^2}$$

$$I(\lambda) = -E\left[-\frac{X}{\lambda^2}\right] = \frac{E[X]}{\lambda^2} = \frac{\lambda}{\lambda^2} = \frac{1}{\lambda}$$

(2) MLE 及无偏性

$$\ell(\lambda) = \left(\sum x_i\right) \log \lambda - n\lambda - \sum \log(x_i!)$$

令 $\frac{d\ell}{d\lambda} = \frac{\sum x_i}{\lambda} - n = 0$, 得 $\hat{\lambda}_{MLE} = \bar{X}$ 。

无偏性: $E[\bar{X}] = E[X] = \lambda$ 。

(3) 方差与 C-R 下界

$$\text{Var}(\hat{\lambda}_{MLE}) = \text{Var}(\bar{X}) = \frac{\text{Var}(X)}{n} = \frac{\lambda}{n}$$

C-R 下界: $\frac{1}{nI(\lambda)} = \frac{\lambda}{n}$ 。

$\text{Var}(\hat{\lambda}_{MLE}) = \frac{\lambda}{n}$ 恰好等于 C-R 下界, 因此 $\bar{X}$ 是 λ 的有效估计量。

(4) Delta 方法求 $g(\lambda) = \sqrt{\lambda}$ 的渐近方差

$g'(\lambda) = \frac{1}{2\sqrt{\lambda}}$, 由 Delta 方法:

$$\sqrt{n}(\sqrt{\hat{\lambda}} - \sqrt{\lambda}) \xrightarrow{d} \mathcal{N}(0, [g'(\lambda)]^2 \cdot \lambda) = \mathcal{N}\left(0, \frac{1}{4\lambda^2} \cdot \lambda\right) = \mathcal{N}\left(0, \frac{1}{4\lambda}\right)$$

因此 $\sqrt{\hat{\lambda}_{MLE}}$ 的渐近方差为 $\frac{1}{4n\lambda}$ 。

答案 16.5

(1) 对数似然

单个样本 (x_i, y_i) 的对数似然：

$$\log p_{\theta}(y_i | x_i) = y_i \log \sigma(z_i) + (1 - y_i) \log(1 - \sigma(z_i))$$

其中 $z_i = f_{\theta}(x_i)$ 。全体样本的对数似然：

$$\ell(\theta) = \sum_{i=1}^n [y_i \log \sigma(z_i) + (1 - y_i) \log(1 - \sigma(z_i))]$$

(2) 等价于最小化 BCE

最大化 $\ell(\theta)$ 等价于最小化：

$$-\ell(\theta) = -\sum_{i=1}^n [y_i \log \sigma(z_i) + (1 - y_i) \log(1 - \sigma(z_i))]$$

除以 n 得到 BCE 损失 $\mathcal{L}_{BCE}$ 。

(3) 梯度及直觉

对单个样本，令 $p = \sigma(z)$ ，注意 $\frac{dp}{dz} = p(1 - p)$ ：

$$\frac{\partial \mathcal{L}_{BCE}}{\partial z} = -\frac{y}{p} \cdot p(1 - p) + \frac{1 - y}{1 - p} \cdot p(1 - p) = -(y - p) = p - y$$

直觉：梯度等于预测概率与真实标签之差。当 $y = 1$ 而 $p \approx 0$ 时，梯度约为 -1 （强烈的更新信号）；当预测准确 $p \approx y$ 时，梯度接近 0 （无需更新）。这正是 BCE 的优雅之处。

(4) $y \in \{-1, +1\}$ 的情形

此时 $P(y = 1 | x) = \sigma(z) = \frac{1}{1 + e^{-z}}$ ， $P(y = -1 | x) = 1 - \sigma(z) = \sigma(-z) = \frac{1}{1 + e^z}$ 。

统一写为： $P(y | x) = \sigma(yz)$ ，故对数似然为 $\log \sigma(y_i z_i)$ ，损失为：

$$\mathcal{L} = -\frac{1}{n} \sum_{i=1}^n \log \sigma(y_i z_i) = \frac{1}{n} \sum_{i=1}^n \log(1 + e^{-y_i z_i})$$

这是 **Logistic 损失** (也称 log-loss)。与 Hinge 损失 $\max(0, 1 - y_i z_i)$ 不同——Hinge 是分段线性函数, 当 $y_i z_i \geq 1$ 时梯度为零 (稀疏更新); Logistic 损失是光滑函数, 对所有样本始终有非零梯度 (密集更新)。在 SVM (使用 Hinge 损失) 与 Logistic 回归 (使用 Logistic 损失) 的对比中, 这是两者的关键区别之一。

第 17 章：区间估计

学习目标

学完本章后, 你将能够:

- 理解置信区间的严格定义, 正确解释“置信水平 $1 - \alpha$ ”的频率学派含义, 避免常见误解
- 掌握枢轴量法的构造思路, 将样本统计量变换为分布已知的随机变量, 从而反解出参数的区间范围
- 熟练推导正态总体在四种情形下 (均值/方差已知或未知) 的置信区间, 并理解 z 、 t 、 χ^2 、 F 分布的适用条件
- 运用中心极限定理构造大样本区间估计, 覆盖均值、比例、泊松速率等常见参数
- 区分双侧置信区间与单侧置信限, 根据实际问题的安全约束选择合适的区间形式

17.1 置信区间的概念

17.1.1 点估计的局限性

第 16 章介绍的点估计给出参数的单一数值, 如 $\hat{\mu} = \bar{X}$ 。但点估计本身没有提供估计精度的信息——我们需要知道这个估计量“差多少”才算合理。

例 17.1 用 $n = 25$ 个样本估计总体均值 μ , 得 $\bar{x} = 10.3$, $s = 2.0$ 。

- 这个估计有多可靠? 真实 μ 是否一定接近 10.3?
- 如何给出一个“区间”, 使我们有把握认为 μ 落在其中?

区间估计正是为了回答这一问题: 不给出一个数, 而是给出一个随机区间 $[L(X), U(X)]$, 使该区间以指定的高概率覆盖真参数。

17.1.2 置信区间的定义

定义 17.1 (置信区间) 设总体分布含未知参数 θ , $X_1, \dots, X_n$ 为来自该总体的样本。若统计量 $L = L(X_1, \dots, X_n)$ 和 $U = U(X_1, \dots, X_n)$ 满足

$$P_{\theta}(L \leq \theta \leq U) = 1 - \alpha, \quad \forall \theta \in \Theta$$

则称随机区间 $[L, U]$ 为参数 θ 的置信水平（置信度）为 $1 - \alpha$ 的置信区间， L 和 U 分别称为置信下限和置信上限， α 称为显著性水平。

常用置信水平： $1 - \alpha = 90\%、95\%、99\%$ 。

17.1.3 置信区间的正确解读

置信区间是频率学派的概念，其含义容易被误解：

正确理解：若对同一总体重复抽样无限多次，每次构造一个置信区间，则 $1 - \alpha$ 比例的区间会覆盖真参数 θ 。

常见误解（错误!）：某次观测得到 $[2.1, 3.5]$ ，则参数 θ 以 95% 的概率落在 $[2.1, 3.5]$ 内。

关键点在于：参数 θ 是固定常数，不是随机变量；样本观测后，区间 $[l, u]$ 也变成了固定区间——此时 θ 要么在其中，要么不在，不存在“落入概率”。随机性来自区间本身（在抽样之前， L 和 U 是随机变量）。

可视化管理解：想象重复抽样 100 次，每次构造一个 95% 置信区间，大约有 95 个区间会包含真值 θ ，约 5 个不包含。但你无法事先知道当前这次构造的区间是否属于那 95% 之列。

17.1.4 置信区间的长度与精度

置信区间的长度 $U - L$ 度量了估计的精度：

- 区间越短：估计越精确
- 区间越长：估计越粗糙

影响区间长度的因素：

因素	对区间长度的影响	原因
样本量 n 增大	变短 ($\propto 1/\sqrt{n}$)	估计更稳定
置信水平 $1 - \alpha$ 提高	变长	更“保守”才能覆盖更多情况
总体方差 σ^2 增大	变长	数据更散乱

存在精度与置信度的权衡：不可能同时要求区间很短且置信度很高，除非增加样本量。

17.2 枢轴量法

17.2.1 枢轴量的定义

定义 17.2（枢轴量）设 $X_1, \dots, X_n$ 来自含参数 θ 的总体。若统计量 $G = G(X_1, \dots, X_n, \theta)$ 的分布完全已知（不依赖任何未知参数），则称 G 为参数 θ 的枢轴量（pivot）。

注意：枢轴量 G 同时含有样本和待估参数 θ ，这是它与一般统计量的区别。

17.2.2 枢轴量法的步骤

枢轴量法 (Pivotal Method) 是构造置信区间的通用方法, 步骤如下:

第一步: 构造枢轴量

找到含有 θ 且分布已知的量 $G(X_1, \dots, X_n, \theta)$ 。

第二步: 确定分位数

对给定的置信水平 $1 - \alpha$, 找到常数 a, b 使得

$$P(a \leq G \leq b) = 1 - \alpha$$

通常取等尾形式: $P(G < a) = \alpha/2$ 和 $P(G > b) = \alpha/2$ 。

第三步: 反解参数

将不等式 $a \leq G(X_1, \dots, X_n, \theta) \leq b$ 对 θ 求解, 得到

$$P(L(X) \leq \theta \leq U(X)) = 1 - \alpha$$

其中 $L(X), U(X)$ 即为置信下限和上限。

17.2.3 一个完整示例

例 17.2 设 $X_1, \dots, X_n \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$, σ^2 已知, 求 μ 的 $1 - \alpha$ 置信区间。

第一步: 由于

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

构造枢轴量:

$$G = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$$

G 的分布是标准正态, 不依赖 μ , 故 G 是枢轴量。

第二步: 设 $z_{\alpha/2}$ 为标准正态分布的上 $\alpha/2$ 分位数, 即 $P(Z > z_{\alpha/2}) = \alpha/2$, 则

$$P\left(-z_{\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right) = 1 - \alpha$$

第三步: 对中间不等式关于 μ 求解:

$$-z_{\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2} \iff \bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

故 μ 的 $1 - \alpha$ 置信区间为：

$$\left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \quad \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

17.2.4 常用分布的分位数

分布	记号	$\alpha = 0.10$	$\alpha = 0.05$	$\alpha = 0.01$
标准正态	$z_{\alpha/2}$	1.645	1.960	2.576
$\mathcal{N}(0, 1)$				
$t(n-1)$	$t_{\alpha/2}(n-1)$	随自由度变化	随自由度变化	随自由度变化
$\chi^2(n-1)$	$\chi^2_{\alpha/2}(n-1)$	查表	查表	查表

对于 t 分布，自由度 ν 增大时 $t_{\alpha/2}(\nu) \rightarrow z_{\alpha/2}$ ；当 $\nu \geq 30$ 时， t 分布与标准正态已十分接近。

17.3 正态总体的区间估计

正态总体是区间估计的核心场景。设 $X_1, \dots, X_n \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$ ，样本均值 $\bar{X}$ 和样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 。

回顾正态总体的抽样分布（第 13 章结论）：

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1), \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1), \quad \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

其中后两个量相互独立。

17.3.1 均值 μ 的置信区间（ σ^2 已知）

枢轴量： $G = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$

$1 - \alpha$ 置信区间：

$$\mu \in \left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \quad \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

区间半宽 (误差限): $\delta = z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$

所需样本量: 若要求误差限不超过 δ_0 , 则

$$n \geq \left(\frac{z_{\alpha/2} \cdot \sigma}{\delta_0} \right)^2$$

例 17.3 某厂生产灯泡, 寿命 $X \sim \mathcal{N}(\mu, 100^2)$ (小时)。随机抽取 25 个, 得 $\bar{x} = 1500$, 求 μ 的 95% 置信区间。

$$\left[1500 - 1.96 \times \frac{100}{\sqrt{25}}, \quad 1500 + 1.96 \times \frac{100}{\sqrt{25}} \right] = [1500 - 39.2, 1500 + 39.2] = [1460.8, 1539.2]$$

17.3.2 均值 μ 的置信区间 (σ^2 未知)

实践中 σ^2 通常未知, 此时用样本标准差 S 代替 σ 。

枢轴量: $G = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$

$1 - \alpha$ 置信区间:

$$\mu \in \left[\bar{X} - t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}}, \quad \bar{X} + t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}} \right]$$

与 σ^2 已知情形相比, $z_{\alpha/2}$ 被 $t_{\alpha/2}(n-1)$ 替换, 后者更大, 因此区间更宽——这反映了 σ^2 未知带来的额外不确定性。

例 17.4 随机测量某金属零件直径 (毫米) 10 次, 得: $\bar{x} = 50.02$, $s = 0.04$ 。设直径服从正态分布, 求 μ 的 95% 置信区间。

查 t 分布表: $t_{0.025}(9) = 2.262$ 。

$$\left[50.02 - 2.262 \times \frac{0.04}{\sqrt{10}}, \quad 50.02 + 2.262 \times \frac{0.04}{\sqrt{10}} \right] = [50.02 - 0.0286, 50.02 + 0.0286] = [49.991, 50.049]$$

17.3.3 方差 σ^2 的置信区间

枢轴量: $G = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$

注意 χ^2 分布不对称, 等尾区间的上下限分别对应两个不同的分位数。

设 $\chi_{1-\alpha/2}^2(n-1)$ 和 $\chi_{\alpha/2}^2(n-1)$ 分别是 $\chi^2(n-1)$ 分布的下 $\alpha/2$ 和上 $\alpha/2$ 分位数, 则

$$P\left(\chi_{1-\alpha/2}^2(n-1) \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_{\alpha/2}^2(n-1)\right) = 1 - \alpha$$

对 σ^2 求解：

$$\sigma^2 \in \left[\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)} \right]$$

例 17.5 对例 17.4 的直径数据，求 σ^2 的 95% 置信区间。

$n = 10$, $s^2 = 0.04^2 = 0.0016$, $(n-1)s^2 = 9 \times 0.0016 = 0.0144$ 。

查表： $\chi_{0.025}^2(9) = 19.023$, $\chi_{0.975}^2(9) = 2.700$ 。

$$\sigma^2 \in \left[\frac{0.0144}{19.023}, \frac{0.0144}{2.700} \right] = [0.000757, 0.00533]$$

标准差 $\sigma \in [0.0275, 0.0730]$ (毫米)。

17.3.4 两正态总体均值差的置信区间

设两个独立正态总体 $X \sim \mathcal{N}(\mu_1, \sigma_1^2)$, $Y \sim \mathcal{N}(\mu_2, \sigma_2^2)$ ，分别抽取样本量 m, n ，统计量为 $\bar{X}, S_1^2$ 和 $\bar{Y}, S_2^2$ 。

情形一： σ_1^2, σ_2^2 已知

枢轴量：

$$G = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/m + \sigma_2^2/n}} \sim \mathcal{N}(0, 1)$$

$\mu_1 - \mu_2$ 的 $1 - \alpha$ 置信区间：

$$(\bar{X} - \bar{Y}) \pm z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}$$

情形二： $\sigma_1^2 = \sigma_2^2 = \sigma^2$ (未知)

合并样本方差：

$$S_p^2 = \frac{(m-1)S_1^2 + (n-1)S_2^2}{m+n-2}$$

枢轴量：

$$G = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_p \sqrt{1/m + 1/n}} \sim t(m+n-2)$$

$\mu_1 - \mu_2$ 的 $1 - \alpha$ 置信区间：

$$(\bar{X} - \bar{Y}) \pm t_{\alpha/2}(m+n-2) \cdot S_p \sqrt{\frac{1}{m} + \frac{1}{n}}$$

17.3.5 两正态总体方差比的置信区间

枢轴量：

$$G = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} = \frac{S_1^2}{S_2^2} \cdot \frac{\sigma_2^2}{\sigma_1^2} \sim F(m-1, n-1)$$

设 $F_{\alpha/2}(m-1, n-1)$ 和 $F_{1-\alpha/2}(m-1, n-1)$ 分别是 $F(m-1, n-1)$ 分布的上、下 $\alpha/2$ 分位数，利用 F 分布的对称性 $F_{1-\alpha/2}(m-1, n-1) = 1/F_{\alpha/2}(n-1, m-1)$ ，得

$$\frac{\sigma_1^2}{\sigma_2^2} \in \left[\frac{S_1^2}{S_2^2} \cdot \frac{1}{F_{\alpha/2}(m-1, n-1)}, \quad \frac{S_1^2}{S_2^2} \cdot F_{\alpha/2}(n-1, m-1) \right]$$

17.4 大样本区间估计

当总体分布未知或非正态时，若样本量足够大（通常 $n \geq 30$ ），可利用中心极限定理（CLT）构造近似区间估计。

17.4.1 总体均值的大样本区间估计

设 $X_1, \dots, X_n$ 为来自均值 μ 、方差 σ^2 的总体的 i.i.d. 样本。

由 CLT：

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1) \quad (n \rightarrow \infty)$$

σ^2 已知：直接使用 z 区间：

$$\mu \in \left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \quad \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

σ^2 未知：将 σ 替换为 S （一致估计量），仍用 z 分位数（大样本时 $t_{n-1} \approx z$ ）：

$$\mu \in \left[\bar{X} - z_{\alpha/2} \frac{S}{\sqrt{n}}, \quad \bar{X} + z_{\alpha/2} \frac{S}{\sqrt{n}} \right]$$

这是大样本下的近似置信区间， n 越大近似越精确。

17.4.2 比例 p 的大样本置信区间

设总体服从 Bernoulli 分布，成功概率为 p 。样本量 n ，成功次数 k ，样本比例 $\hat{p} = k/n$ 。

由 CLT ($np \geq 5$ 且 $n(1-p) \geq 5$ 时效果好)：

$$\frac{\hat{p} - p}{\sqrt{p(1-p)/n}} \xrightarrow{d} \mathcal{N}(0, 1)$$

用 $\hat{p}$ 估计分母中的 p ，得 p 的 $1 - \alpha$ 近似置信区间：

$$p \in \left[\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \quad \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$$

例 17.6 随机调查 400 人，其中 120 人支持某政策， $\hat{p} = 120/400 = 0.3$ 。求支持率 p 的 95% 置信区间。

$$\sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = \sqrt{\frac{0.3 \times 0.7}{400}} = \sqrt{0.000525} \approx 0.0229$$

$$p \in [0.3 - 1.96 \times 0.0229, 0.3 + 1.96 \times 0.0229] = [0.255, 0.345]$$

保守估计：由于 $p(1-p) \leq 1/4$ （最大值在 $p = 0.5$ 时取到），取 $\hat{p}(1-\hat{p}) = 1/4$ 可得保守区间：

$$p \in \left[\hat{p} \pm \frac{z_{\alpha/2}}{2\sqrt{n}} \right]$$

对 95% 置信度， $n = 400$ 时误差限为 $1.96/(2 \times 20) = 0.049$ ，即“ $\pm 4.9\%$ ”。

17.4.3 泊松参数的大样本置信区间

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Pois}(\lambda)$ ，则 $E[X] = \text{Var}[X] = \lambda$ 。

由 CLT，大样本下：

$$\frac{\bar{X} - \lambda}{\sqrt{\lambda/n}} \xrightarrow{d} \mathcal{N}(0, 1)$$

用 $\hat{\lambda} = \bar{X}$ 估计分母中的 λ ，得：

$$\lambda \in \left[\bar{X} - z_{\alpha/2} \sqrt{\frac{\bar{X}}{n}}, \bar{X} + z_{\alpha/2} \sqrt{\frac{\bar{X}}{n}} \right]$$

例 17.7 某服务台 100 分钟内共接到 200 个呼叫 ($n = 100$ 分钟, $\bar{x} = 2$), 估计每分钟呼叫率 λ 的 95% 置信区间。

$$\lambda \in \left[2 - 1.96 \sqrt{\frac{2}{100}}, 2 + 1.96 \sqrt{\frac{2}{100}} \right] = [2 - 0.277, 2 + 0.277] = [1.723, 2.277]$$

17.4.4 Delta 方法：参数变换的区间估计

设 $\hat{\theta}$ 是 θ 的估计量, 满足 $\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} \mathcal{N}(0, V(\theta))$ 。

若 $g(\cdot)$ 是可微函数, 则由 **Delta 方法**:

$$\sqrt{n}(g(\hat{\theta}) - g(\theta)) \xrightarrow{d} \mathcal{N}(0, [g'(\theta)]^2 V(\theta))$$

用 $\hat{\theta}$ 代入, 得 $g(\theta)$ 的 $1 - \alpha$ 置信区间:

$$g(\theta) \in \left[g(\hat{\theta}) \pm z_{\alpha/2} \frac{|g'(\hat{\theta})| \sqrt{V(\hat{\theta})}}{\sqrt{n}} \right]$$

例 17.8 设 $\hat{p}$ 为比例的 MLE, 估计 $\log\left(\frac{p}{1-p}\right)$ (对数优势比, log-odds) 的置信区间。

令 $g(p) = \log\left(\frac{p}{1-p}\right)$, 则 $g'(p) = \frac{1}{p(1-p)}$, $V(p) = p(1-p)$, 故

$$\text{标准误} = \frac{|g'(\hat{p})| \sqrt{V(\hat{p})}}{\sqrt{n}} = \frac{1}{\hat{p}(1-\hat{p})} \cdot \frac{\sqrt{\hat{p}(1-\hat{p})}}{\sqrt{n}} = \frac{1}{\sqrt{n\hat{p}(1-\hat{p})}}$$

17.5 单侧置信限

17.5.1 单侧置信限的定义

在许多工程和安全问题中, 我们只关心参数的一个方向。例如:

- 安全问题: 某化学品的毒性上限 (越低越安全)
- 质量控制: 产品次品率的上限 (不希望超标)
- 可靠性工程: 零件寿命的下限 (不希望太短)

定义 17.3 (单侧置信限)

若统计量 $L = L(X_1, \dots, X_n)$ 满足

$$P_{\theta}(\theta \geq L) = 1 - \alpha, \quad \forall \theta \in \Theta$$

则称 L 为 θ 的置信水平为 $1 - \alpha$ 的单侧置信下限，相应的区间 $[L, +\infty)$ 称为单侧置信区间。

类似地，若 $U = U(X_1, \dots, X_n)$ 满足

$$P_{\theta}(\theta \leq U) = 1 - \alpha, \quad \forall \theta \in \Theta$$

则称 U 为单侧置信上限，区间 $(-\infty, U]$ 为单侧置信区间。

17.5.2 单侧置信限与双侧置信区间的关系

从双侧置信区间推导单侧置信限非常简单：将双侧区间一端“推至无穷”。

具体地，若 μ 的双侧 $1 - 2\alpha$ 区间为 $[L, U]$ ，则：

- L 是 μ 的（单侧）置信水平 $1 - \alpha$ 的下限
- U 是 μ 的（单侧）置信水平 $1 - \alpha$ 的上限

类型	表达式	置信水平
双侧区间	$[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}]$	$1 - \alpha$
单侧下限	$\bar{X} - z_{\alpha} \frac{\sigma}{\sqrt{n}}$	$1 - \alpha$
单侧上限	$\bar{X} + z_{\alpha} \frac{\sigma}{\sqrt{n}}$	$1 - \alpha$

注意单侧时使用 z_{α} （不是 $z_{\alpha/2}$ ）：分位数更小，因为只需保护一侧。

17.5.3 正态总体各参数的单侧置信限

均值 μ 的单侧置信限 (σ^2 未知)

单侧置信下限（保证 μ 不太小）：

$$L = \bar{X} - t_{\alpha}(n-1) \frac{S}{\sqrt{n}}$$

单侧置信上限（保证 μ 不太大）：

$$U = \bar{X} + t_{\alpha}(n-1) \frac{S}{\sqrt{n}}$$

方差 σ^2 的单侧置信限

单侧置信上限（常用于质量控制）：

$$U = \frac{(n-1)S^2}{\chi_{1-\alpha}^2(n-1)}$$

单侧置信下限：

$$L = \frac{(n-1)S^2}{\chi_{\alpha}^2(n-1)}$$

17.5.4 示例

例 17.9 对例 17.4 的零件直径，求 μ 的 95% 单侧置信下限（即保证平均直径不低于某值）。

$n = 10$, $\bar{x} = 50.02$, $s = 0.04$, 查表 $t_{0.05}(9) = 1.833$ 。

$$L = 50.02 - 1.833 \times \frac{0.04}{\sqrt{10}} = 50.02 - 0.0232 = 49.997(\text{毫米})$$

含义：有 95% 的把握认为，该批零件的平均直径不低于 49.997 毫米。

例 17.10 某型号电池寿命 X （小时），测试 16 块，得 $\bar{x} = 350$, $s = 20$ 。求寿命均值 μ 的 95% 单侧置信下限。

$t_{0.05}(15) = 1.753$ 。

$$L = 350 - 1.753 \times \frac{20}{\sqrt{16}} = 350 - 8.765 = 341.235(\text{小时})$$

本章小结

置信区间的本质：置信区间是频率学派对参数不确定性的量化工具， $1-\alpha$ 置信水平的含义是“重复抽样中 $1-\alpha$ 比例的区间覆盖真参数”，而非“参数以 $1-\alpha$ 概率落在区间内”。

枢轴量法的三步骤：

1. 构造含参数 θ 且分布已知的枢轴量 G
2. 利用分位数建立 $P(a \leq G \leq b) = 1 - \alpha$
3. 反解不等式得到 $[L, U]$

正态总体的四种标准情形：

估计目标	已知条件	枢轴量	区间 $(1 - \alpha)$
均值 μ	σ^2 已知	$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$	$\bar{X} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$
均值 μ	σ^2 未知	$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n - 1)$	$\bar{X} \pm t_{\alpha/2}(n - 1) \frac{S}{\sqrt{n}}$
方差 σ^2	μ 未知	$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n - 1)$	$\left[\frac{(n-1)S^2}{\chi^2_{\alpha/2}}, \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}} \right]$
方差比 σ_1^2/σ_2^2	μ_1, μ_2 未知	$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(m - 1, n - 1)$	见 17.3.5

大样本区间估计：当 n 较大时，CLT 保证 $\frac{\bar{X} - \mu}{S/\sqrt{n}} \approx \mathcal{N}(0, 1)$ ，可用 z 分位数替代 t 分位数，适用于未知分布总体、比例估计、泊松参数等场景。

单侧置信限：当仅关心参数的上界或下界时使用，用 z_α （或 t_α ）替代 $z_{\alpha/2}$ （或 $t_{\alpha/2}$ ），区间一端延伸至无穷。

精度-置信度权衡：在总体方差固定的条件下，缩短区间的唯一办法是增大样本量 n （误差限 $\propto 1/\sqrt{n}$ ）；提高置信水平必然导致区间变宽。

深度学习应用：不确定性量化与预测区间

在深度学习的部署场景中，模型不仅要给出预测值，还要量化预测的不确定性——这与置信区间/预测区间的思想密切相关。

认知不确定性与偶然不确定性

深度学习中的不确定性可分为两类：

类型	来源	能否通过增加数据减少	对应统计概念
偶然不确定性 (Aleatoric)	数据本身的噪声，不可约	否	随机误差 $\varepsilon \sim \mathcal{N}(0, \sigma^2)$
认知不确定性 (Epistemic)	模型参数的不确定性	是（更多数据）	参数的置信区间

标准神经网络只给出点预测，无法区分这两类不确定性。以下介绍三种实用方案。

方案一：预测区间（直接回归法）

最简单的方案：让网络直接输出预测区间的上下界，损失函数使用分位数损失（Pinball Loss）。

设置信水平 $1 - \alpha$ ，分别训练两个分位数水平 $\tau_L = \alpha/2$ 和 $\tau_U = 1 - \alpha/2$ 的分位数回归模型。

分位数损失：

$$\mathcal{L}_\tau(y, \hat{q}) = \begin{cases} \tau(y - \hat{q}) & \text{若 } y \geq \hat{q} \\ (1 - \tau)(\hat{q} - y) & \text{若 } y < \hat{q} \end{cases}$$

```
import torch
import torch.nn as nn

# =====
# 方案一：分位数回归——直接预测置信区间上下界
# =====

class QuantileNet(nn.Module):
    """
    双头网络：同时预测第  $\alpha/2$  和  $1-\alpha/2$  分位数
    输出形状：(batch_size, 2) -> [下界, 上界]
    """
    def __init__(self, input_dim: int, hidden_dim: int = 64):
        super().__init__()
        self.backbone = nn.Sequential(
            nn.Linear(input_dim, hidden_dim),
            nn.ReLU(),
            nn.Linear(hidden_dim, hidden_dim),
            nn.ReLU(),
        )
        # 两个独立输出头：下分位数  $q_{lo}$ , 上分位数  $q_{hi}$ 
        self.head_lo = nn.Linear(hidden_dim, 1)
        self.head_hi = nn.Linear(hidden_dim, 1)

    def forward(self, x: torch.Tensor):
        h = self.backbone(x)
        q_lo = self.head_lo(h).squeeze(-1)
        q_hi = self.head_hi(h).squeeze(-1)
        return q_lo, q_hi

def pinball_loss(y: torch.Tensor, q_hat: torch.Tensor, tau: float) -> torch.Tensor:
    """
    分位数损失 (Pinball Loss)
    tau=0.025 -> 预测第 2.5 百分位 (下界)
    tau=0.975 -> 预测第 97.5 百分位 (上界)
    """
```

```

"""
residual = y - q_hat
loss = torch.where(residual >= 0, tau * residual, (tau - 1) * residual)
return loss.mean()

def train_quantile_net(model: QuantileNet, X_train: torch.Tensor,
                      y_train: torch.Tensor, alpha: float = 0.05,
                      epochs: int = 200, lr: float = 1e-3):
    """ 训练分位数回归网络，输出  $1-\alpha$  预测区间 """
    optimizer = torch.optim.Adam(model.parameters(), lr=lr)
    tau_lo, tau_hi = alpha / 2, 1 - alpha / 2 # 例: 0.025, 0.975

    for epoch in range(epochs):
        optimizer.zero_grad()
        q_lo, q_hi = model(X_train)

        # 下分位数损失 + 上分位数损失
        loss = pinball_loss(y_train, q_lo, tau_lo) + \
            pinball_loss(y_train, q_hi, tau_hi)
        loss.backward()
        optimizer.step()

    return model

def predict_interval(model: QuantileNet, X_test: torch.Tensor):
    """ 推理：返回预测区间 [下界, 上界] 及区间宽度 """
    model.eval()
    with torch.no_grad():
        q_lo, q_hi = model(X_test)
        interval_width = q_hi - q_lo # 区间宽度 = 不确定性指标
    return q_lo, q_hi, interval_width

```

方案二：MC Dropout——蒙特卡洛近似贝叶斯推断

Dropout 通常只在训练时使用。**MC Dropout** 的关键思想：在预测阶段也保持 **Dropout** 开启，对同一输入进行 T 次随机前向传播，以样本均值作为预测，以样本方差作为不确定性度量。

理论依据 (Gal & Ghahramani, 2016)：带 Dropout 的神经网络可视为对深度高斯过程的变分贝叶斯近似，每次前向传播等价于从近似后验 $q(\mathbf{w})$ 中采样一组权重。


```

import torch
import torch.nn as nn
import numpy as np

# =====
# 方案二：MC Dropout——测试阶段保持 Dropout，多次采样
# =====

class MCDropoutNet(nn.Module):
    """
    MC Dropout 网络：预测时也启用 Dropout（通过 self.train() 模式）
    dropout_p: 每个神经元被随机置零的概率
    """
    def __init__(self, input_dim: int, hidden_dim: int = 64,
                  output_dim: int = 1, dropout_p: float = 0.1):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(input_dim, hidden_dim),
            nn.ReLU(),
            nn.Dropout(p=dropout_p),          # 关键：Dropout 层
            nn.Linear(hidden_dim, hidden_dim),
            nn.ReLU(),
            nn.Dropout(p=dropout_p),
            nn.Linear(hidden_dim, output_dim),
        )

    def forward(self, x: torch.Tensor) -> torch.Tensor:
        return self.net(x).squeeze(-1)

    def predict_with_uncertainty(
        self, x: torch.Tensor, T: int = 100
    ) -> dict:
        """
        MC Dropout 预测：T 次随机前向传播，统计预测分布。

        返回字典：
            mean      - 预测均值（点估计）
            variance  - 预测方差（不确定性）
            std       - 预测标准差
            ci_lower  - 95% 置信下界（均值  $\pm 1.96 * std$ ）
            ci_upper  - 95% 置信上界

```

```

"""
# 必须调用 self.train(), 否则 Dropout 在 eval 模式下被关闭
self.train()

with torch.no_grad():
    # 堆叠 T 次前向传播结果: 形状 (T, batch_size)
    preds = torch.stack([self.net(x).squeeze(-1) for _ in range(T)])

mean = preds.mean(dim=0)      # 预测均值: 近似后验预测均值
variance = preds.var(dim=0)    # 预测方差: 近似认知不确定性
std = variance.sqrt()

# 基于正态近似构造 95% 预测区间
ci_lower = mean - 1.96 * std
ci_upper = mean + 1.96 * std

return {
    "mean": mean,
    "variance": variance,
    "std": std,
    "ci_lower": ci_lower,
    "ci_upper": ci_upper,
}

def evaluate_coverage(model: MCDropoutNet, X_test: torch.Tensor,
                     y_test: torch.Tensor, T: int = 100) -> float:
    """
    经验覆盖率: 计算预测区间实际包含真实值的比例。
    理想情况下, 95% 置信区间的覆盖率应接近 0.95。
    """
    result = model.predict_with_uncertainty(X_test, T=T)
    ci_lo = result["ci_lower"]
    ci_hi = result["ci_upper"]

    # 检查每个样本的真实值是否落在预测区间内
    covered = ((y_test >= ci_lo) & (y_test <= ci_hi)).float()
    coverage = covered.mean().item()
    return coverage

```

```

# =====
# 使用示例：合成数据
# =====

if __name__ == "__main__":
    torch.manual_seed(42)
    n_train, n_test = 500, 100
    input_dim = 5

    # 生成合成回归数据
    X_train = torch.randn(n_train, input_dim)
    y_train = X_train[:, 0] * 2 + X_train[:, 1] - 0.5 + \
        torch.randn(n_train) * 0.5 # 真实噪声 sigma=0.5

    X_test = torch.randn(n_test, input_dim)
    y_test = X_test[:, 0] * 2 + X_test[:, 1] - 0.5 + \
        torch.randn(n_test) * 0.5

    # 训练模型
    model = MCDropoutNet(input_dim=input_dim, dropout_p=0.1)
    optimizer = torch.optim.Adam(model.parameters(), lr=1e-3)
    criterion = nn.MSELoss()

    for epoch in range(300):
        model.train()
        optimizer.zero_grad()
        loss = criterion(model(X_train), y_train)
        loss.backward()
        optimizer.step()

    # 预测与不确定性量化
    result = model.predict_with_uncertainty(X_test, T=200)

    # 评估覆盖率
    coverage = evaluate_coverage(model, X_test, y_test, T=200)
    print(f"MC Dropout 95% 预测区间覆盖率: {coverage:.3f}")
    # 理想值接近 0.95

    # 分析高不确定性样本
    high_unc_idx = result["variance"].topk(5).indices
    print(f"\n不确定性最高的 5 个测试样本 (索引): {high_unc_idx.tolist()}")

```

```
print(f" 对应预测方差: {result['variance'][high_unc_idx].tolist()}")
print(f" 对应真实值: {y_test[high_unc_idx].tolist()}")
```

方案三：共形预测 (Conformal Prediction)

共形预测是一种无分布假设的预测区间方法，提供严格的有限样本覆盖率保证，无需假设数据的生成分布。

核心思想：利用校准集 (calibration set) 的残差分布，确定预测区间的宽度，使得预测区间对新样本的经验覆盖率恰好达到 $1 - \alpha$ 。

```
import torch
import numpy as np

# =====
# 方案三：分割共形预测 (Split Conformal Prediction)
# 保证有限样本覆盖率，无需分布假设
# =====
```

```
class SplitConformalPredictor:
```

```
    """
```

```
    分割共形预测器 (Split Conformal Prediction)。
```

原理：

1. 将标记数据分为训练集和校准集
2. 在训练集上训练模型，得到点预测 $f(x)$
3. 在校准集上计算非一致性分数 (*residual*):

$$s_i = |y_i - f(x_i)|$$
4. 找到校准集分数的 $(1-\alpha)(1+1/n)$ 分位数 q_{hat}
5. 对测试点，预测区间为 $[f(x) - q_{\text{hat}}, f(x) + q_{\text{hat}}]$

理论保证：

```
P(y_test ∈ C(x_test)) ≥ 1 - alpha    (有限样本，无分布假设)
"""
```

```
def __init__(self, base_model: nn.Module):
```

```
    self.model = base_model
```

```
    self.q_hat = None    # 校准后的分位数阈值
```

```
def calibrate(self, X_cal: torch.Tensor, y_cal: torch.Tensor,
              alpha: float = 0.05):
```

```
    """
```

```
    校准步骤：用校准集估计非一致性分数的分位数。
```

参数：

X_cal, *y_cal*: 校准集（独立于训练集，但有标签）

alpha: 误覆盖率，预测区间覆盖率目标为 $1-\alpha$

```
"""
self.model.eval()
with torch.no_grad():
    y_pred = self.model(X_cal)
    if y_pred.dim() > 1:
        y_pred = y_pred.squeeze(-1)

# 非一致性分数：绝对残差
scores = (y_cal - y_pred).abs().numpy() # 形状: (n_cal,)

# 取校准集分数的  $\text{ceil}((n+1)(1-\alpha)/n)$  分位数
n_cal = len(scores)
level = np.ceil((n_cal + 1) * (1 - alpha)) / n_cal
level = min(level, 1.0) # 不超过 1

self.q_hat = float(np.quantile(scores, level))
print(f" 校准完成: alpha={alpha}, q_hat={self.q_hat:.4f}")
return self

def predict_interval(self, X_test: torch.Tensor):
    """
    推理：为每个测试点生成宽度固定的预测区间。

    返回：
        y_pred    - 点预测值
        ci_lower  - 区间下界 = y_pred - q_hat
        ci_upper  - 区间上界 = y_pred + q_hat
    """
    if self.q_hat is None:
        raise RuntimeError(" 请先调用 calibrate() 进行校准。")

    self.model.eval()
    with torch.no_grad():
        y_pred = self.model(X_test)
        if y_pred.dim() > 1:
            y_pred = y_pred.squeeze(-1)
```

```
        ci_lower = y_pred - self.q_hat
        ci_upper = y_pred + self.q_hat
        return y_pred, ci_lower, ci_upper

# 三种方案的覆盖率对比函数
def compare_coverage(
    y_true: torch.Tensor,
    ci_lower: torch.Tensor,
    ci_upper: torch.Tensor,
    method_name: str = " 方法"
) -> None:
    """ 计算并打印预测区间的经验覆盖率和平均区间宽度。"""
    covered = ((y_true >= ci_lower) & (y_true <= ci_upper)).float()
    coverage = covered.mean().item()
    avg_width = (ci_upper - ci_lower).mean().item()
    print(f"[{method_name}] 覆盖率 = {coverage:.3f} 平均区间宽度 = {avg_width:.3f}")
```

三种方案对比

方法	分布假设	计算开销	覆盖率保证	适用场景
分位数回归	无	低（训练两个头）	渐近	大数据、快速部署
MC Dropout	近似贝叶斯	中（ T 次前向）	近似	需要认知不确定性分解
共形预测	无（最弱）	低（需校准集）	有限样本严格	高可靠性要求场景

练习题

练习 17.1（枢轴量法基础）

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$, $\sigma^2 = 4$ 已知, $n = 16$, 样本均值 $\bar{x} = 12.5$ 。

- (1) 构造 μ 的枢轴量, 写出其分布;
- (2) 求 μ 的 95% 双侧置信区间;
- (3) 若要将区间半宽压缩至 0.5, 需要多大的样本量?

练习 17.2 (t 置信区间)

某工厂随机抽取 10 件产品，测得其质量（克）为：

98, 102, 99, 101, 100, 103, 97, 104, 99, 101

设质量服从正态分布。

- (1) 计算样本均值 $\bar{x}$ 和样本标准差 s ;
 - (2) 求总体均值 μ 的 95% 置信区间;
 - (3) 求总体方差 σ^2 的 90% 置信区间。
-

练习 17.3 (大样本比例区间)

某选举民调对 1000 人进行调查，其中 480 人表示支持候选人甲。

- (1) 求支持率 p 的 95% 置信区间;
 - (2) 若希望误差限（半宽）不超过 2%，至少需要调查多少人（使用保守估计 $p = 0.5$ ）?
 - (3) 若实际支持率约为 48%，用更精确的方式重新计算所需样本量。
-

练习 17.4 (两样本区间估计)

两台机器加工相同零件，分别抽取样本：

- 机器 A: $m = 12$, $\bar{x}_A = 50.05$, $s_A = 0.05$ (毫米)
- 机器 B: $n = 10$, $\bar{x}_B = 50.03$, $s_B = 0.04$ (毫米)

设两总体均服从正态分布，且方差相等。

- (1) 计算合并样本标准差 s_p ;
 - (2) 求均值差 $\mu_A - \mu_B$ 的 95% 置信区间;
 - (3) 根据置信区间，能否认为两台机器的加工精度（均值）无显著差异?
-

练习 17.5 (单侧置信限与预测区间)

某品牌灯泡寿命 $X \sim \mathcal{N}(\mu, \sigma^2)$ ，随机抽取 9 只，测得寿命（小时）：

1200, 1350, 1280, 1420, 1300, 1250, 1380, 1320, 1290

- (1) 计算 $\bar{x}$ 和 s ;

- (2) 求 μ 的 95% 单侧置信下限 (保证平均寿命不低于某值);
- (3) 求 σ^2 的 95% 单侧置信上限 (控制寿命波动的上界);
- (4) 构造单个新灯泡寿命 X_{new} 的 95% 预测区间:

$$\bar{X} \pm t_{\alpha/2}(n-1) \cdot S \sqrt{1 + \frac{1}{n}}$$

比较预测区间与置信区间的宽度, 解释差异来源。

练习答案

答案 17.1

(1) 枢轴量

$$G = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} = \frac{\bar{X} - \mu}{2/\sqrt{16}} = \frac{\bar{X} - \mu}{0.5} \sim \mathcal{N}(0, 1)$$

(2) 95% 置信区间

$z_{0.025} = 1.96$, 误差限 $= 1.96 \times 0.5 = 0.98$ 。

$$\mu \in [12.5 - 0.98, 12.5 + 0.98] = [11.52, 13.48]$$

(3) 所需样本量

要求 $z_{0.025} \cdot \frac{\sigma}{\sqrt{n}} \leq 0.5$, 即

$$\sqrt{n} \geq \frac{1.96 \times 2}{0.5} = 7.84 \implies n \geq 7.84^2 = 61.5$$

故至少需要 $n = 62$ 个样本。

答案 17.2

(1) 样本均值和标准差

$$\bar{x} = \frac{98 + 102 + 99 + 101 + 100 + 103 + 97 + 104 + 99 + 101}{10} = \frac{1004}{10} = 100.4$$

各偏差的平方： $(-2.4)^2, (1.6)^2, (-1.4)^2, (0.6)^2, (-0.4)^2, (2.6)^2, (-3.4)^2, (3.6)^2, (-1.4)^2, (0.6)^2$
 $= 5.76, 2.56, 1.96, 0.36, 0.16, 6.76, 11.56, 12.96, 1.96, 0.36$

$$\sum_{i=1}^{10} (x_i - \bar{x})^2 = 44.4$$

$$s^2 = \frac{44.4}{9} \approx 4.933, \quad s \approx 2.221$$

(2) 均值的 95% 置信区间

$$t_{0.025}(9) = 2.262, \text{ 误差限} = 2.262 \times \frac{2.221}{\sqrt{10}} = 2.262 \times 0.702 = 1.588。$$

$$\mu \in [100.4 - 1.588, 100.4 + 1.588] = [98.81, 101.99](\text{克})$$

(3) 方差的 90% 置信区间

$$\chi_{0.05}^2(9) = 16.919, \chi_{0.95}^2(9) = 3.325, (n-1)s^2 = 9 \times 4.933 = 44.4。$$

$$\sigma^2 \in \left[\frac{44.4}{16.919}, \frac{44.4}{3.325} \right] = [2.624, 13.353](\text{克}^2)$$

答案 17.3

(1) 支持率的 95% 置信区间

$$\hat{p} = 480/1000 = 0.48, \quad z_{0.025} = 1.96。$$

$$\sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = \sqrt{\frac{0.48 \times 0.52}{1000}} = \sqrt{0.0002496} \approx 0.01580$$

$$p \in [0.48 - 1.96 \times 0.01580, 0.48 + 1.96 \times 0.01580] = [0.449, 0.511]$$

(2) 保守估计所需样本量 ($p = 0.5$)

$$n \geq \left(\frac{z_{\alpha/2}}{2\delta_0} \right)^2 = \left(\frac{1.96}{2 \times 0.02} \right)^2 = \left(\frac{1.96}{0.04} \right)^2 = 49^2 = 2401$$

至少需要 2401 人。

(3) 精确估计所需样本量 ($p \approx 0.48$)

$$n \geq \left(\frac{z_{\alpha/2}}{\delta_0} \right)^2 p(1-p) = \left(\frac{1.96}{0.02} \right)^2 \times 0.48 \times 0.52 = 9604 \times 0.2496 \approx 2397$$

约需 2397 人（与保守估计接近，因 p 接近 0.5）。

答案 17.4

(1) 合并标准差

$$s_p^2 = \frac{(m-1)s_A^2 + (n-1)s_B^2}{m+n-2} = \frac{11 \times 0.0025 + 9 \times 0.0016}{20} = \frac{0.0275 + 0.0144}{20} = \frac{0.0419}{20} = 0.002095$$

$$s_p = \sqrt{0.002095} \approx 0.04577(\text{毫米})$$

(2) 均值差的 95% 置信区间

$$t_{0.025}(20) = 2.086, \quad \bar{x}_A - \bar{x}_B = 50.05 - 50.03 = 0.02。$$

$$s_p \sqrt{\frac{1}{m} + \frac{1}{n}} = 0.04577 \sqrt{\frac{1}{12} + \frac{1}{10}} = 0.04577 \times \sqrt{0.1833} = 0.04577 \times 0.4282 = 0.01960$$

$$\text{误差限} = 2.086 \times 0.01960 = 0.04089。$$

$$\mu_A - \mu_B \in [0.02 - 0.04089, 0.02 + 0.04089] = [-0.021, 0.061](\text{毫米})$$

(3) 结论

区间包含 0，故在 95% 置信水平下，不能认为两台机器的平均加工尺寸有显著差异。

答案 17.5

(1) 样本均值和标准差

$$\bar{x} = \frac{1200 + 1350 + 1280 + 1420 + 1300 + 1250 + 1380 + 1320 + 1290}{9} = \frac{11790}{9} = 1310$$

各偏差：-110, 40, -30, 110, -10, -60, 70, 10, -20

$$\sum (x_i - \bar{x})^2 = 12100 + 1600 + 900 + 12100 + 100 + 3600 + 4900 + 100 + 400 = 35800$$

$$s^2 = \frac{35800}{8} = 4475, \quad s = \sqrt{4475} \approx 66.9(\text{小时})$$

(2) 均值的 95% 单侧置信下限

$$t_{0.05}(8) = 1.860.$$

$$L = \bar{x} - t_{0.05}(8) \cdot \frac{s}{\sqrt{n}} = 1310 - 1.860 \times \frac{66.9}{\sqrt{9}} = 1310 - 1.860 \times 22.3 = 1310 - 41.5 = 1268.5$$

有 95% 把握认为平均寿命不低于 1268.5 小时。

(3) 方差的 95% 单侧置信上限

$$\chi_{0.05}^2(8) = 2.733 \quad (\text{下侧 } 5\% \text{ 分位数}), \quad (n-1)s^2 = 8 \times 4475 = 35800.$$

$$U = \frac{(n-1)s^2}{\chi_{1-\alpha}^2(n-1)} = \frac{35800}{\chi_{0.05}^2(8)} = \frac{35800}{2.733} \approx 13101$$

即 $\sigma^2 \leq 13101$, $\sigma \leq 114.5$ 小时 (95% 置信)。

(4) 单个灯泡寿命的 95% 预测区间

$$t_{0.025}(8) = 2.306.$$

$$X_{\text{new}} \in \left[1310 \pm 2.306 \times 66.9 \times \sqrt{1 + \frac{1}{9}} \right] = [1310 \pm 2.306 \times 66.9 \times 1.054]$$

$$= [1310 \pm 162.8] = [1147.2, 1472.8](\text{小时})$$

对比：置信区间（均值）半宽 = $2.306 \times 66.9/3 = 51.4$ ；预测区间（单个）半宽 = 162.8，约为置信区间的 3 倍宽。

差异来源：置信区间描述均值 μ 的不确定性（来源于抽样误差， $\propto 1/\sqrt{n}$ ）；预测区间还需加入单个观测值相对均值的随机波动 (σ)，因此公式中有 $\sqrt{1 + 1/n}$ 而非 $\sqrt{1/n}$ ，两者之比约为 $\sqrt{1 + 1/n}/(1/\sqrt{n}) = \sqrt{n + 1}$ 。

第 18 章：贝叶斯估计

学习目标

学完本章后，你将能够：

- 理解贝叶斯学派与频率学派在参数推断哲学上的根本区别
- 掌握先验分布、似然函数与后验分布的关系，写出贝叶斯公式的参数推断形式
- 识别并运用常见的共轭先验对，快速推导出后验分布的解析表达式
- 从后验分布中提取点估计（后验均值与 MAP 估计），理解 MAP 与 MLE 的关系
- 构造贝叶斯可信区间，并与经典置信区间的含义进行对比

18.1 贝叶斯学派与频率学派

18.1.1 两种推断哲学

统计推断存在两大学派，它们对“概率”和“参数”的理解截然不同。

频率学派 (Frequentist)

- 概率是长期频率：事件在无限次重复试验中发生的比例。
- 参数 θ 是固定但未知的常数，没有概率分布。
- 典型方法：最大似然估计 (MLE)、置信区间、假设检验。
- 核心问题：“如果参数真的是 θ_0 ，观测到这批数据的概率有多大？”

贝叶斯学派 (Bayesian)

- 概率是主观信念的度量，反映对不确定性的认知程度。
- 参数 θ 是随机变量，具有概率分布，反映我们对其值的不确定性。
- 典型方法：先验 + 似然 $\rightarrow$ 后验，贝叶斯点估计，可信区间。
- 核心问题：“在观测到这批数据之后，参数 θ 的分布是什么？”

18.1.2 两种学派的对比

维度	频率学派	贝叶斯学派
参数 θ 的性质	固定未知常数	随机变量
先验知识	不使用	通过先验分布 $\pi(\theta)$ 融入
推断结果	点估计 + 置信区间	后验分布 $\pi(\theta x)$
置信/可信区间含义	“重复实验中 95% 的区间覆盖真值”	“参数落在区间内的概率为 95%”
计算复杂度	通常较低	有时需要 MCMC 等近似方法
对样本量的依赖	大样本渐近理论	小样本也可使用，先验起关键作用

18.1.3 一个直觉例子

问题：一枚硬币抛了 10 次，正面 7 次。估计正面概率 θ 。

- 频率派 **MLE**: $\hat{\theta}_{MLE} = 7/10 = 0.7$, 仅凭数据。
- 贝叶斯派: 若先验认为硬币大概率公平 (比如用 Beta(5,5) 先验), 后验会把估计”拉向”0.5。随着数据增多, 先验影响逐渐减弱, 最终两者收敛一致。

这种将先验知识与数据证据有机结合的能力, 是贝叶斯方法的核心优势。

18.2 先验分布与后验分布

18.2.1 贝叶斯公式的参数推断形式

设参数 $\theta \in \Theta$, 观测数据为 $\mathbf{x} = (x_1, x_2, \dots, x_n)$ 。

贝叶斯推断的三个核心要素:

1. 先验分布 $\pi(\theta)$: 观测数据之前对 θ 的信念
2. 似然函数 $L(\theta | \mathbf{x}) = p(\mathbf{x} | \theta)$: 给定 θ 时数据出现的概率
3. 后验分布 $\pi(\theta | \mathbf{x})$: 观测数据之后对 θ 的更新信念

贝叶斯公式 (参数推断形式):

$$\pi(\theta | \mathbf{x}) = \frac{p(\mathbf{x} | \theta) \pi(\theta)}{p(\mathbf{x})} \propto p(\mathbf{x} | \theta) \pi(\theta)$$

其中边际似然 (归一化常数) 为:

$$p(\mathbf{x}) = \int_{\Theta} p(\mathbf{x} | \theta) \pi(\theta) d\theta$$

用文字表达这一核心公式:

$$\underbrace{\pi(\theta | \mathbf{x})}_{\text{后验}} \propto \underbrace{p(\mathbf{x} | \theta)}_{\text{似然}} \times \underbrace{\pi(\theta)}_{\text{先验}}$$

18.2.2 先验分布的选取

先验分布的选取体现了我们在观测数据之前的知识或信念:

无信息先验 (Non-informative Prior)

当没有任何先验知识时, 希望让数据”说话”。

- 均匀先验: $\pi(\theta) \propto 1$ (在参数范围内均匀)
- Jeffreys 先验: $\pi(\theta) \propto \sqrt{I(\theta)}$, 其中 $I(\theta)$ 为 Fisher 信息量, 具有参数变换不变性

信息先验 (Informative Prior)

当有历史数据或专家知识时，可以编码具体的先验信念：

- 历史实验结果
- 物理约束（如概率必须在 $[0, 1]$ ）
- 专家判断

共轭先验 (Conjugate Prior)

先验与似然属于同一分布族，使得后验也属于该分布族，计算方便。（详见 18.3 节）

18.2.3 贝叶斯更新

贝叶斯推断是一个递推更新过程：当新数据到来时，当前后验成为新的先验。

$$\pi(\theta) \xrightarrow{\text{观测 } x_1} \pi(\theta | x_1) \xrightarrow{\text{观测 } x_2} \pi(\theta | x_1, x_2) \xrightarrow{\dots} \pi(\theta | x_1, \dots, x_n)$$

这体现了贝叶斯推断的序贯性：无论是一次性处理所有数据，还是逐步更新，最终后验相同。

18.2.4 完整示例：二项模型

设定： n 次独立伯努利试验，成功次数 k ，参数 θ （成功概率）。

似然函数：

$$p(k | \theta) = \binom{n}{k} \theta^k (1 - \theta)^{n-k}$$

先验：取 $\theta \sim \text{Beta}(\alpha, \beta)$ ，即

$$\pi(\theta) = \frac{\theta^{\alpha-1} (1 - \theta)^{\beta-1}}{B(\alpha, \beta)}, \quad \theta \in [0, 1]$$

后验：

$$\pi(\theta | k) \propto \theta^k (1 - \theta)^{n-k} \cdot \theta^{\alpha-1} (1 - \theta)^{\beta-1} = \theta^{k+\alpha-1} (1 - \theta)^{n-k+\beta-1}$$

因此后验为：

$$\theta | k \sim \text{Beta}(k + \alpha, n - k + \beta)$$

直觉：先验参数 α, β 可理解为“伪计数”（pseudo-counts）—— α 是虚拟的历史成功次数， β 是虚拟的历史失败次数。

18.3 共轭先验

18.3.1 共轭先验的定义

定义：若似然函数 $p(\mathbf{x} \mid \theta)$ 属于指数族，且存在先验分布族 $\mathcal{F}$ ，使得对任意 $\pi(\theta) \in \mathcal{F}$ ，后验 $\pi(\theta \mid \mathbf{x})$ 仍属于 $\mathcal{F}$ ，则称 $\mathcal{F}$ 为该似然的共轭先验族。

共轭先验的优点：- 后验有解析表达式，无需数值积分 - 参数更新规则简单，具有直观的”计数”解释 - 适合序贯更新

18.3.2 常见共轭先验对

数据模型（似然）	参数	共轭先验	后验
伯努利/二项 $\text{Bin}(n, \theta)$	成功概率 θ	$\text{Beta}(\alpha, \beta)$	$\text{Beta}(\alpha + k, \beta + n - k)$
泊松 $\text{Pois}(\lambda)$	速率 λ	$\text{Gamma}(\alpha, \beta)$	$\text{Gamma}(\alpha + \sum x_i, \beta + n)$
正态（方差已知） $\mathcal{N}(\mu, \sigma^2)$	均值 μ	$\mathcal{N}(\mu_0, \tau^2)$	$\mathcal{N}(\mu_n, \tau_n^2)$ （见下）
正态（均值已知） $\mathcal{N}(\mu, \sigma^2)$	精度 $1/\sigma^2$	$\text{Gamma}(\alpha, \beta)$	$\text{Gamma}(\alpha', \beta')$
多项分布 $\text{Multi}(\mathbf{p})$	概率向量 $\mathbf{p}$	$\text{Dirichlet}(\alpha)$	$\text{Dirichlet}(\alpha + \mathbf{n})$
指数分布 $\text{Exp}(\lambda)$	速率 λ	$\text{Gamma}(\alpha, \beta)$	$\text{Gamma}(\alpha + n, \beta + \sum x_i)$

18.3.3 正态-正态共轭的详细推导

设 $x_1, \dots, x_n \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$ ， σ^2 已知，先验 $\mu \sim \mathcal{N}(\mu_0, \tau_0^2)$ 。

后验精度（精度 = 方差的倒数）：

$$\frac{1}{\tau_n^2} = \frac{1}{\tau_0^2} + \frac{n}{\sigma^2}$$

后验均值（先验均值与样本均值的精度加权平均）：

$$\mu_n = \tau_n^2 \left(\frac{\mu_0}{\tau_0^2} + \frac{n\bar{x}}{\sigma^2} \right) = \frac{\frac{1}{\tau_0^2} \mu_0 + \frac{n}{\sigma^2} \bar{x}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}$$

后验分布：

$$\mu \mid \mathbf{x} \sim \mathcal{N}(\mu_n, \tau_n^2)$$

极端情形分析：

- 先验不确定性极大 ($\tau_0^2 \rightarrow \infty$): $\mu_n \rightarrow \bar{x}$ (退化为 MLE)
- 数据量极大 ($n \rightarrow \infty$): $\mu_n \rightarrow \bar{x}$ (数据主导, 先验影响消失)
- 数据量极小 ($n \rightarrow 0$): $\mu_n \rightarrow \mu_0$ (先验主导)

18.3.4 泊松-伽马共轭示例

设 $x_1, \dots, x_n \stackrel{iid}{\sim} \text{Pois}(\lambda)$, 先验 $\lambda \sim \text{Gamma}(\alpha, \beta)$ (β 为速率参数)。

似然：

$$p(\mathbf{x} \mid \lambda) \propto \lambda^{\sum x_i} e^{-n\lambda}$$

先验：

$$\pi(\lambda) \propto \lambda^{\alpha-1} e^{-\beta\lambda}$$

后验：

$$\pi(\lambda \mid \mathbf{x}) \propto \lambda^{\alpha + \sum x_i - 1} e^{-(\beta + n)\lambda}$$

因此：

$$\lambda \mid \mathbf{x} \sim \text{Gamma}\left(\alpha + \sum_{i=1}^n x_i, \beta + n\right)$$

直觉： α 是历史观测到的事件总数， β 是历史观测的时间单位总数。

18.4 贝叶斯点估计

18.4.1 从后验到点估计

后验分布 $\pi(\theta \mid \mathbf{x})$ 包含了参数的全部信息。若需要一个点估计，需要从后验中提取一个代表性数值。不同的损失函数导致不同的最优点估计：

损失函数	最优点估计	名称
平方损失 $(\hat{\theta} - \theta)^2$	后验均值 $E[\theta \mid \mathbf{x}]$	贝叶斯估计量 (MMSE)
绝对值损失 $ \hat{\theta} - \theta $	后验中位数 $\text{Med}[\theta \mid \mathbf{x}]$	中位数估计
0-1 损失 $1[\hat{\theta} \neq \theta]$	后验众数 $\arg \max_{\theta} \pi(\theta \mid \mathbf{x})$	MAP 估计

18.4.2 后验均值估计 (MMSE)

后验均值 (Minimum Mean Squared Error estimator):

$$\hat{\theta}_{MMSE} = E[\theta \mid \mathbf{x}] = \int \theta \cdot \pi(\theta \mid \mathbf{x}) d\theta$$

示例 (Beta-二项模型):

$$\hat{\theta}_{MMSE} = E[\theta \mid k] = \frac{k + \alpha}{n + \alpha + \beta}$$

将其写成 MLE 与先验均值的加权平均:

$$\hat{\theta}_{MMSE} = \underbrace{\frac{n}{n + \alpha + \beta}}_{\text{数据权重}} \cdot \underbrace{\frac{k}{n}}_{\hat{\theta}_{MLE}} + \underbrace{\frac{\alpha + \beta}{n + \alpha + \beta}}_{\text{先验权重}} \cdot \underbrace{\frac{\alpha}{\alpha + \beta}}_{\text{先验均值}}$$

这清楚地展示了贝叶斯估计是数据与先验的折中，数据越多，先验影响越小。

18.4.3 最大后验估计 (MAP)

MAP 估计 (Maximum A Posteriori):

$$\hat{\theta}_{MAP} = \arg \max_{\theta} \pi(\theta \mid \mathbf{x}) = \arg \max_{\theta} [\log p(\mathbf{x} \mid \theta) + \log \pi(\theta)]$$

取对数形式更便于计算:

$$\hat{\theta}_{MAP} = \arg \max_{\theta} \left[\underbrace{\ell(\theta)}_{\text{对数似然}} + \underbrace{\log \pi(\theta)}_{\text{对数先验 (正则项)}} \right]$$

18.4.4 MAP 与 MLE 的关系

MLE 是 MAP 在均匀先验下的特例：

$$\hat{\theta}_{MLE} = \arg \max_{\theta} \log p(\mathbf{x} | \theta) = \hat{\theta}_{MAP} \big|_{\pi(\theta) \propto 1}$$

MAP 与正则化的等价性（这是深度学习中的重要连接）：

高斯先验 $\Leftrightarrow$ L2 正则化

设先验 $\theta_j \stackrel{iid}{\sim} \mathcal{N}(0, \sigma_0^2)$ ，则

$$\log \pi(\theta) = -\frac{1}{2\sigma_0^2} \sum_j \theta_j^2 + \text{const}$$

MAP 目标函数：

$$\hat{\theta}_{MAP} = \arg \max_{\theta} \left[\ell(\theta) - \frac{1}{2\sigma_0^2} \|\theta\|_2^2 \right] = \arg \min_{\theta} \left[-\ell(\theta) + \frac{\lambda}{2} \|\theta\|_2^2 \right]$$

其中 $\lambda = 1/\sigma_0^2$ 。这正是带 L2 正则化（权重衰减）的 MLE。

拉普拉斯先验 $\Leftrightarrow$ L1 正则化

设先验 $\theta_j \stackrel{iid}{\sim} \text{Laplace}(0, b)$ ，则

$$\log \pi(\theta) = -\frac{1}{b} \sum_j |\theta_j| + \text{const}$$

MAP 目标函数：

$$\hat{\theta}_{MAP} = \arg \min_{\theta} \left[-\ell(\theta) + \frac{\lambda}{1} \|\theta\|_1 \right]$$

其中 $\lambda = 1/b$ 。这正是带 L1 正则化（LASSO）的 MLE。

汇总：

先验	$\Leftrightarrow$	正则化
$\theta \sim \mathcal{N}(0, \sigma_0^2)$	$\Leftrightarrow$	$\lambda \ \theta\ _2^2$ (权重衰减, Ridge)
$\theta \sim \text{Laplace}(0, b)$	$\Leftrightarrow$	$\lambda \ \theta\ _1$ (稀疏正则, LASSO)

18.5 贝叶斯区间估计（可信区间）

18.5.1 可信区间的定义

贝叶斯可信区间（Credible Interval）与频率学派的置信区间在定义上有本质区别：

可信区间：给定数据 $\mathbf{x}$ ，区间 $[l, u]$ 满足

$$P(l \leq \theta \leq u \mid \mathbf{x}) = 1 - \alpha$$

含义：参数 θ 落在 $[l, u]$ 内的概率（后验概率）为 $1 - \alpha$ 。

置信区间：不是“参数落在区间内的概率”，而是“重复构造这样的区间，其中 $1 - \alpha$ 比例的区间覆盖真值”。

贝叶斯可信区间的含义更直观，也是大多数人直觉上期望置信区间所具有的含义。

18.5.2 等尾可信区间

最常用的是等尾可信区间（Equal-tailed Credible Interval）：取后验分布的 $\alpha/2$ 和 $1 - \alpha/2$ 分位数。

$$[l, u] = [Q_{\alpha/2}(\theta \mid \mathbf{x}), Q_{1-\alpha/2}(\theta \mid \mathbf{x})]$$

其中 Q_p 表示后验分布的 p 分位数。

示例（正态-正态模型）：

后验 $\mu \mid \mathbf{x} \sim \mathcal{N}(\mu_n, \tau_n^2)$ ，95% 可信区间为：

$$[\mu_n - 1.96\tau_n, \mu_n + 1.96\tau_n]$$

18.5.3 最高后验密度区间（HPD）

HPD 区间（Highest Posterior Density Interval）：在所有长度相同的区间中，使后验概率最大的区间；等价地，它是最短的满足覆盖概率要求的区间。

$$C_{HPD} = \{\theta : \pi(\theta \mid \mathbf{x}) \geq h\}$$

其中 h 选取使得 $P(\theta \in C_{HPD} \mid \mathbf{x}) = 1 - \alpha$ 。

- 对对称单峰分布：HPD 区间 = 等尾可信区间
- 对偏斜或多峰分布：HPD 区间更短，但可能是不连续区间

18.5.4 完整示例：Beta-二项可信区间

问题：某网站 A/B 测试，展示 $n = 100$ 次，点击 $k = 30$ 次。使用均匀先验 $\text{Beta}(1, 1)$ ，构造 95% 可信区间。

后验：

$$\theta \mid k \sim \text{Beta}(1 + 30, 1 + 70) = \text{Beta}(31, 71)$$

后验均值：

$$\hat{\theta}_{MMSE} = \frac{31}{31 + 71} = \frac{31}{102} \approx 0.304$$

95% 等尾可信区间：Beta(31,71) 分布的 2.5% 和 97.5% 分位数，约为 [0.214, 0.401]。

含义：在观测到这批数据后，点击率 θ 落在 [0.214, 0.401] 内的概率为 95%。

18.5.5 可信区间与置信区间的数值对比

在正态模型中，当使用无信息先验时，贝叶斯可信区间与频率置信区间数值相同，但含义不同：

	置信区间（频率）	可信区间（贝叶斯）
含义	重复实验中 95% 覆盖 θ	$P(\theta \in I \mid \mathbf{x}) = 95\%$
θ 的	固定常数	随机变量
性质		
先验	无	有（无信息先验时近似相同）
依赖		
直觉	较差	好
性		

本章小结

贝叶斯推断的核心框架：

$$\underbrace{\pi(\theta \mid \mathbf{x})}_{\text{后验}} \propto \underbrace{p(\mathbf{x} \mid \theta)}_{\text{似然}} \times \underbrace{\pi(\theta)}_{\text{先验}}$$

关键概念回顾：

- 1. 两大学派的本质区别：频率派视参数为常数，贝叶斯派视参数为随机变量，通过先验分布编码不确定性。

2. 共轭先验：先验与似然属同一族，使后验有解析解。常见对：Beta-二项、Gamma-泊松、正态-正态。

3. 三种点估计：

- 后验均值 (MMSE) $\leftarrow$ 最小均方误差
- MAP 估计 $\leftarrow$ 后验众数，等价于正则化 MLE
- 后验中位数 $\leftarrow$ 最小绝对误差

4. MAP 与正则化的等价性：

- 高斯先验 $\Leftrightarrow$ L2/Ridge 正则化 (权重衰减)
- 拉普拉斯先验 $\Leftrightarrow$ L1/LASSO 正则化 (稀疏性)

5. 可信区间：直接表述“参数落在区间内的概率”，比置信区间含义更直观。

随样本量变化的行为：大样本下，先验影响消失，贝叶斯后验与频率派结论收敛一致 (Bernstein-von Mises 定理)。小样本时，先验起到关键的“正则化”作用。

深度学习应用：正则化的贝叶斯解释

权重衰减即高斯先验

在深度学习中，L2 正则化 (权重衰减) 是最常用的防过拟合手段。贝叶斯框架揭示了其本质：对网络权重施加零均值高斯先验。

设神经网络参数为 $\mathbf{w}$ ，训练数据为 $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ 。

MLE 目标 (无正则化)：

$$\hat{\mathbf{w}}_{MLE} = \arg \max_{\mathbf{w}} \log p(\mathcal{D} | \mathbf{w}) = \arg \min_{\mathbf{w}} \mathcal{L}(\mathbf{w})$$

MAP 目标 (高斯先验 $\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \sigma_0^2 \mathbf{I})$)：

$$\hat{\mathbf{w}}_{MAP} = \arg \min_{\mathbf{w}} \left[\mathcal{L}(\mathbf{w}) + \frac{1}{2\sigma_0^2} \|\mathbf{w}\|_2^2 \right] = \arg \min_{\mathbf{w}} \left[\mathcal{L}(\mathbf{w}) + \frac{\lambda}{2} \|\mathbf{w}\|_2^2 \right]$$

其中正则化系数 $\lambda = 1/\sigma_0^2$ ：

- σ_0^2 越小 (先验方差小，强烈认为权重接近 0) $\Rightarrow \lambda$ 越大 (强正则化)
- σ_0^2 越大 (先验方差大，对权重无约束) $\Rightarrow \lambda$ 越小 (弱正则化)

L1 正则化即拉普拉斯先验

若对权重施加拉普拉斯先验 $w_j \sim \text{Laplace}(0, b)$ ，MAP 估计等价于 L1 正则化：

$$\hat{\mathbf{w}}_{MAP} = \arg \min_{\mathbf{w}} \left[\mathcal{L}(\mathbf{w}) + \frac{1}{b} \|\mathbf{w}\|_1 \right]$$

L1 正则化倾向于产生稀疏解（许多权重精确为零），对应于拉普拉斯分布在零点处的尖峰。

PyTorch 实现对比

```
import torch
import torch.nn as nn
import torch.optim as optim

# =====
# 1. 标准训练 (MLE, 对应均匀先验)
# =====

class SimpleNet(nn.Module):
    def __init__(self, input_dim, hidden_dim, output_dim):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(input_dim, hidden_dim),
            nn.ReLU(),
            nn.Linear(hidden_dim, output_dim)
        )

    def forward(self, x):
        return self.net(x)

def train_mle(model, optimizer, X, y, epochs=100):
    """MLE 训练：最大化对数似然（最小化交叉熵损失）"""
    criterion = nn.CrossEntropyLoss()
    for epoch in range(epochs):
        optimizer.zero_grad()
        loss = criterion(model(X), y)  # 仅数据项，无正则
        loss.backward()
        optimizer.step()
    return model
```

```

# =====
# 2. L2 正则化训练 (MAP, 对应高斯先验)
# 在 SGD/Adam 中通过 weight_decay 参数实现
# =====

def train_map_l2(model, X, y, weight_decay=1e-4, epochs=100):
    """
    MAP 训练 (高斯先验):
    weight_decay = lambda = 1 / sigma_0^2
    损失 = 交叉熵 + (lambda/2) * ||w||^2
    """
    # PyTorch 的 weight_decay 直接实现 L2 正则化
    optimizer = optim.SGD(model.parameters(), lr=0.01,
                           weight_decay=weight_decay)
    criterion = nn.CrossEntropyLoss()

    for epoch in range(epochs):
        optimizer.zero_grad()
        loss = criterion(model(X), y)
        loss.backward()
        optimizer.step()
    return model

# =====
# 3. L2 正则化的手动实现 (等价方式, 便于理解)
# =====

def train_map_l2_manual(model, X, y, lam=1e-4, epochs=100):
    """
    手动添加 L2 正则项, 等价于高斯先验 MAP
    对应贝叶斯公式: log 后验 = log 似然 + log 先验
                      = -CrossEntropy - (lambda/2)||w||^2
    """
    optimizer = optim.SGD(model.parameters(), lr=0.01)
    criterion = nn.CrossEntropyLoss()

    for epoch in range(epochs):
        optimizer.zero_grad()

```

```

# 数据项 (对数似然)
data_loss = criterion(model(X), y)

# 正则项 (高斯先验的负对数:  $-\log N(w; 0, \sigma^2)$   $\lambda/2 * ||w||^2$ )
l2_reg = sum(p.pow(2).sum() for p in model.parameters())
reg_loss = (lam / 2) * l2_reg

# 总损失 = 负对数后验
loss = data_loss + reg_loss
loss.backward()
optimizer.step()

return model

# =====
# 4. L1 正则化 (MAP, 对应拉普拉斯先验)
# =====

def train_map_l1(model, X, y, lam=1e-4, epochs=100):
    """
    手动添加 L1 正则项, 等价于拉普拉斯先验 MAP
    L1 正则化导致权重稀疏 (部分权重精确为零)
    """
    optimizer = optim.SGD(model.parameters(), lr=0.01)
    criterion = nn.CrossEntropyLoss()

    for epoch in range(epochs):
        optimizer.zero_grad()

        data_loss = criterion(model(X), y)

        # L1 正则项 (拉普拉斯先验:  $-\log \text{Laplace}(w; 0, b)$   $(1/b) * ||w||_1$ )
        l1_reg = sum(p.abs().sum() for p in model.parameters())
        loss = data_loss + lam * l1_reg

        loss.backward()
        optimizer.step()

    return model

```



```

# =====
# 5. 验证正则化强度与先验方差的对应关系
# =====

def bayesian_interpretation(weight_decay):
    """
    展示正则化系数  $\lambda$  与高斯先验方差  $\sigma_0^2$  的对应关系
     $\lambda = 1 / \sigma_0^2$ 
     $\sigma_0$  越小 -> 权重越靠近零 -> 防过拟合能力越强
    """
    sigma_0_squared = 1.0 / weight_decay
    sigma_0 = sigma_0_squared ** 0.5
    print(f"weight_decay ( $\lambda$ ) = {weight_decay}")
    print(f"等价高斯先验:  $w \sim N(0, \{\sigma_0\_squared:.4f\})$ ")
    print(f"先验标准差  $\sigma_0 = \{\sigma_0:.4f\}$ ")
    print(f"含义: 期望权重绝对值约为  $\{\sigma_0:.4f\}$ ")

# 示例运行
bayesian_interpretation(weight_decay=1e-4)
# weight_decay ( $\lambda$ ) = 0.0001
# 等价高斯先验:  $w \sim N(0, 10000.0000)$ 
# 先验标准差  $\sigma_0 = 100.0000$ 
# 含义: 期望权重绝对值约为 100.0000

bayesian_interpretation(weight_decay=1e-2)
# weight_decay ( $\lambda$ ) = 0.01
# 等价高斯先验:  $w \sim N(0, 100.0000)$ 
# 先验标准差  $\sigma_0 = 10.0000$ 
# 含义: 期望权重绝对值约为 10.0000

```

贝叶斯神经网络简介

标准神经网络训练给出点估计 $\hat{\mathbf{w}}$ (MAP 或 MLE)，无法量化预测不确定性。贝叶斯神经网络 (Bayesian Neural Network, BNN) 则学习权重的后验分布 $p(\mathbf{w} | \mathcal{D})$ ，从而：

1. 量化不确定性：预测时给出置信度，而非单一数值
2. 防止过拟合：后验分布天然具有正则化效果
3. 小数据友好：先验在数据稀少时提供合理偏置

预测分布（对新样本 $\mathbf{x}^*$ ）：

$$p(y^* | \mathbf{x}^*, \mathcal{D}) = \int p(y^* | \mathbf{x}^*, \mathbf{w}) p(\mathbf{w} | \mathcal{D}) d\mathbf{w}$$

由于精确积分不可行，实践中常用：- 变分推断（Variational Inference）：用参数化分布 $q_\phi(\mathbf{w})$ 近似后验 - 蒙特卡洛 **Dropout**：训练和预测时保留 Dropout，每次前向传播近似从后验采样 - 深度集成（Deep Ensembles）：训练多个独立网络，以集成逼近后验预测分布

```
import torch
import torch.nn as nn

# Monte Carlo Dropout: 简单实用的贝叶斯近似
class MCDropoutNet(nn.Module):
    def __init__(self, input_dim, hidden_dim, output_dim, dropout_p=0.5):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(input_dim, hidden_dim),
            nn.ReLU(),
            nn.Dropout(p=dropout_p), # 预测时也保持 Dropout 开启
            nn.Linear(hidden_dim, output_dim)
        )

    def forward(self, x):
        return self.net(x)

    def predict_with_uncertainty(self, x, n_samples=100):
        """
        通过多次前向传播（每次 Dropout 随机）近似后验预测分布
        返回预测均值和方差（不确定性量化）
        """
        self.train() # 保持训练模式以启用 Dropout
        preds = torch.stack([self.net(x) for _ in range(n_samples)])
        mean = preds.mean(dim=0) # 预测均值
        variance = preds.var(dim=0) # 预测方差（不确定性）
        return mean, variance
```

练习题

练习 18.1（先验与后验）

某工厂生产的零件中，次品率 θ 未知。根据历史经验，先验分布为 $\theta \sim \text{Beta}(2, 18)$ 。现从该批产品中随机抽取 50 件，发现 4 件次品。

- (1) 写出后验分布 $\pi(\theta \mid \text{数据})$;
 - (2) 计算后验均值和后验方差;
 - (3) 计算 95% 等尾贝叶斯可信区间 (用 Beta 分布分位数表示即可)。
-

练习 18.2 (共轭先验)

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Pois}(\lambda)$, 先验 $\lambda \sim \text{Gamma}(\alpha_0, \beta_0)$ (β_0 为速率参数)。

- (1) 推导后验分布 $\pi(\lambda \mid \mathbf{x})$;
 - (2) 写出后验均值估计 $\hat{\lambda}_{MMSE}$, 并将其表示为先验均值与样本均值的加权平均;
 - (3) 当 $\alpha_0 = 1, \beta_0 = 1$ (接近无信息先验), $n = 10$, $\sum x_i = 25$ 时, 计算 $\hat{\lambda}_{MMSE}$ 和 $\hat{\lambda}_{MAP}$ 。
-

练习 18.3 (MAP 与正则化)

设线性回归模型 $y = \mathbf{w}^\top \mathbf{x} + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma^2)$, 对参数 $\mathbf{w}$ 的每个分量施加独立先验 $w_j \sim \mathcal{N}(0, \tau^2)$ 。

- (1) 写出对数后验 $\log \pi(\mathbf{w} \mid \mathbf{X}, \mathbf{y})$ (忽略与 $\mathbf{w}$ 无关的常数);
- (2) 证明 MAP 估计等价于带 L2 正则化的最小二乘:

$$\hat{\mathbf{w}}_{MAP} = \arg \min_{\mathbf{w}} [\|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2 + \lambda \|\mathbf{w}\|_2^2]$$

并给出 λ 与 σ^2, τ^2 的关系;

- (3) 写出 MAP 估计的解析解 (Ridge 回归解)。
-

练习 18.4 (正态-正态模型)

某学生进行 n 次独立测量, 得到数据 $x_1, \dots, x_n$, 模型为 $x_i \sim \mathcal{N}(\mu, \sigma^2)$ ($\sigma^2 = 4$ 已知)。先验 $\mu \sim \mathcal{N}(10, 9)$ 。

- (1) 写出后验分布 $\mu \mid \mathbf{x}$ 的参数 (均值 μ_n 和方差 τ_n^2);
 - (2) 设 $n = 9$, $\bar{x} = 12$, 计算 μ_n 和 τ_n^2 ;
 - (3) 计算 90% 贝叶斯可信区间;
 - (4) 随 $n \rightarrow \infty$, 后验均值 μ_n 趋向什么? 这体现了贝叶斯推断的什么性质?
-

练习 18.5 (综合: 贝叶斯决策)

在二分类问题中，类别先验为 $P(Y = 1) = 0.3$, $P(Y = 0) = 0.7$ 。特征 $X | Y = 1 \sim \mathcal{N}(2, 1)$, $X | Y = 0 \sim \mathcal{N}(0, 1)$ 。

- (1) 写出后验概率 $P(Y = 1 | X = x)$ (用贝叶斯公式);
 - (2) 计算 $P(Y = 1 | X = 1)$;
 - (3) 若使用 MAP 决策规则 (选择后验概率更大的类别), 求决策边界 x^* ;
 - (4) 若改变类别先验为 $P(Y = 1) = 0.5$, 决策边界如何变化? 这对应贝叶斯框架中哪个要素的改变?
-

练习答案

答案 18.1

(1) 后验分布

似然: $p(\text{数据} | \theta) \propto \theta^4(1 - \theta)^{46}$

先验: $\pi(\theta) \propto \theta^{2-1}(1 - \theta)^{18-1} = \theta^1(1 - \theta)^{17}$

后验:

$$\pi(\theta | \text{数据}) \propto \theta^{4+1}(1 - \theta)^{46+17} = \theta^5(1 - \theta)^{63}$$

即 $\theta | \text{数据} \sim \text{Beta}(6, 64)$ 。

(2) 后验均值和方差

$$E[\theta | \text{数据}] = \frac{6}{6 + 64} = \frac{6}{70} \approx 0.0857$$

$$\text{Var}[\theta | \text{数据}] = \frac{6 \times 64}{70^2 \times 71} = \frac{384}{347900} \approx 0.001104$$

(3) 95% 等尾可信区间

$$[Q_{0.025}(\text{Beta}(6, 64)), Q_{0.975}(\text{Beta}(6, 64))]$$

数值约为 $[0.032, 0.174]$ (可通过查表或 `Python scipy.stats.beta.interval(0.95, 6, 64)` 计算)。

答案 18.2**(1) 后验分布**

$$\pi(\lambda | \mathbf{x}) \propto \lambda^{\sum x_i} e^{-n\lambda} \cdot \lambda^{\alpha_0-1} e^{-\beta_0\lambda} = \lambda^{\alpha_0+\sum x_i-1} e^{-(\beta_0+n)\lambda}$$

故 $\lambda | \mathbf{x} \sim \text{Gamma}(\alpha_0 + \sum x_i, \beta_0 + n)$ 。

(2) 后验均值

$$\hat{\lambda}_{MMSE} = \frac{\alpha_0 + \sum x_i}{\beta_0 + n} = \frac{\beta_0}{\beta_0 + n} \cdot \frac{\alpha_0}{\beta_0} + \frac{n}{\beta_0 + n} \cdot \bar{x}$$

其中 α_0/β_0 为先验均值, $\bar{x} = \sum x_i/n$ 为样本均值, 权重为 $\beta_0/(\beta_0 + n)$ 和 $n/(\beta_0 + n)$ 。

(3) 数值计算

$\alpha_0 = 1, \beta_0 = 1, n = 10, \sum x_i = 25$:

后验为 $\text{Gamma}(26, 11)$ 。

$$\hat{\lambda}_{MMSE} = \frac{26}{11} \approx 2.364$$

$$\hat{\lambda}_{MAP} = \frac{\alpha_0 + \sum x_i - 1}{\beta_0 + n} = \frac{25}{11} \approx 2.273$$

(MAP 是 Gamma 分布的众数: $(\alpha - 1)/\beta$)

答案 18.3**(1) 对数后验**

$$\log \pi(\mathbf{w} | \mathbf{X}, \mathbf{y}) = \log p(\mathbf{y} | \mathbf{X}, \mathbf{w}) + \log \pi(\mathbf{w}) + \text{const}$$

$$= -\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2 - \frac{1}{2\tau^2} \|\mathbf{w}\|_2^2 + \text{const}$$

(2) MAP 等价于 Ridge 回归

$$\hat{\mathbf{w}}_{MAP} = \arg \max_{\mathbf{w}} \log \pi(\mathbf{w} | \mathbf{X}, \mathbf{y}) = \arg \min_{\mathbf{w}} \left[\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2 + \frac{1}{2\tau^2} \|\mathbf{w}\|_2^2 \right]$$

乘以 $2\sigma^2$ ，等价于：

$$\hat{\mathbf{w}}_{MAP} = \arg \min_{\mathbf{w}} \left[\|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2 + \frac{\sigma^2}{\tau^2} \|\mathbf{w}\|_2^2 \right]$$

故 $\lambda = \sigma^2/\tau^2$ ：噪声方差与先验方差之比。

(3) 解析解

令梯度为零：

$$\hat{\mathbf{w}}_{MAP} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}$$

这正是 Ridge 回归的解析解。矩阵 $\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}$ 总是可逆的 ($\lambda > 0$)，因此解存在唯一。

答案 18.4

(1) 后验参数

$$\frac{1}{\tau_n^2} = \frac{1}{\tau_0^2} + \frac{n}{\sigma^2} = \frac{1}{9} + \frac{n}{4}$$

$$\mu_n = \tau_n^2 \left(\frac{\mu_0}{\tau_0^2} + \frac{n\bar{x}}{\sigma^2} \right) = \tau_n^2 \left(\frac{10}{9} + \frac{n\bar{x}}{4} \right)$$

(2) 数值计算 ($n = 9$, $\bar{x} = 12$)

$$\frac{1}{\tau_n^2} = \frac{1}{9} + \frac{9}{4} = \frac{4}{36} + \frac{81}{36} = \frac{85}{36}$$

$$\tau_n^2 = \frac{36}{85} \approx 0.424$$

$$\mu_n = \frac{36}{85} \left(\frac{10}{9} + \frac{9 \times 12}{4} \right) = \frac{36}{85} \left(\frac{10}{9} + 27 \right) = \frac{36}{85} \times \frac{253}{9} = \frac{36 \times 253}{85 \times 9} = \frac{9108}{765} \approx 11.91$$

(3) 90% 可信区间

$$\left[\mu_n \pm 1.645 \sqrt{\tau_n^2} \right] = [11.91 \pm 1.645 \times 0.651] \approx [10.84, 12.98]$$

(4) 渐近行为

当 $n \rightarrow \infty$, $\frac{n}{\sigma^2} \rightarrow \infty$, 故 $\tau_n^2 \rightarrow 0$, $\mu_n \rightarrow \bar{x}$ 。

后验均值趋向样本均值, 即 MLE 估计。这体现了贝叶斯推断的相合性: 随着数据增多, 先验影响逐渐被“冲淡”, 后验集中于真实参数值 (Bernstein-von Mises 定理)。

答案 18.5

(1) 后验概率

由贝叶斯公式:

$$\begin{aligned} P(Y = 1 | X = x) &= \frac{P(X = x | Y = 1)P(Y = 1)}{P(X = x | Y = 1)P(Y = 1) + P(X = x | Y = 0)P(Y = 0)} \\ &= \frac{0.3 \cdot \frac{1}{\sqrt{2\pi}} e^{-(x-2)^2/2}}{0.3 \cdot \frac{1}{\sqrt{2\pi}} e^{-(x-2)^2/2} + 0.7 \cdot \frac{1}{\sqrt{2\pi}} e^{-x^2/2}} \end{aligned}$$

(2) 计算 $P(Y = 1 | X = 1)$

代入 $x = 1$:

$$P(Y = 1 | X = 1) = \frac{0.3 \cdot e^{-(1-2)^2/2}}{0.3 \cdot e^{-1/2} + 0.7 \cdot e^{-1/2}} = \frac{0.3}{0.3 + 0.7} = \frac{0.3}{1.0} = 0.3$$

(此处 $x = 1$ 恰好是两个高斯密度相等的点, 后验概率等于类别先验。)

(3) 决策边界 ($P(Y = 1) = 0.3$)

决策边界满足 $P(Y = 1 | X = x^*) = P(Y = 0 | X = x^*)$, 即:

$$0.3 \cdot e^{-(x^*-2)^2/2} = 0.7 \cdot e^{-(x^*)^2/2}$$

两边取对数:

$$\ln 0.3 - \frac{(x^* - 2)^2}{2} = \ln 0.7 - \frac{(x^*)^2}{2}$$

展开:

$$\ln 0.3 - \frac{x^{*2} - 4x^* + 4}{2} = \ln 0.7 - \frac{x^{*2}}{2}$$

$$\ln 0.3 - 2 + 2x^* = \ln 0.7$$

$$x^* = \frac{\ln(0.7/0.3) + 2}{2} = \frac{\ln(7/3) + 2}{2} = \frac{0.847 + 2}{2} \approx 1.424$$

(4) 改变先验至 $P(Y = 1) = 0.5$

$$x^* = \frac{\ln(0.5/0.5) + 2}{2} = \frac{0 + 2}{2} = 1.0$$

决策边界从约 1.424 移至 1.0，向 $Y = 1$ 类的中心靠近（因为两类先验相等，仅由似然决定边界，边界取在两高斯均值的中点）。

这对应贝叶斯框架中先验分布的改变：先验 $P(Y = 1)$ 从 0.3 增大到 0.5，提高了对 $Y = 1$ 的信念，使模型更倾向于预测 $Y = 1$ ，决策边界向 $Y = 0$ 一侧移动。

第十九章：假设检验基础

学习目标

完成本章学习后，你将能够：

- 理解假设检验的逻辑框架，掌握“反证法思想”在统计推断中的应用
- 正确区分原假设与备择假设，能够根据实际问题建立合适的统计假设
- 深刻理解第一类错误（ α ）、第二类错误（ β ）和检验功效（Power）的含义与相互关系
- 准确解释 p 值的统计含义，识别 p 值在实践中的常见误区
- 将假设检验方法应用于深度学习场景，包括 A/B 测试和模型性能比较

正文内容

19.1 假设检验的基本思想

19.1.1 从一个例子出发 假设你开发了一个新的图像分类模型，声称其准确率超过了现有的基线模型（基线准确率为 80%）。在测试集上评估后，你的模型达到了 83% 的准确率。问题是：这 3% 的提升是真实的性能改善，还是仅仅由于测试集的随机波动造成的？

这正是假设检验（Hypothesis Testing）要回答的问题：如何在随机性存在的情况下，基于样本数据对总体参数作出统计决策？

19.1.2 统计假设检验的逻辑结构

假设检验的核心思想源自数学中的反证法：

若我们想证明命题 H_1 为真，先假设其对立命题 H_0 为真，然后在 H_0 成立的前提下，看观测到的数据是否“极端罕见”。若极端罕见，则以小概率反驳 H_0 ，倾向于接受 H_1 。

这个逻辑流程可以分解为五步：

第一步：建立假设

设定两个互补的假设：- H_0 （原假设）：代表“没有效果”、“没有差异”的保守立场 - H_1 （备择假设）：代表我们希望证明的主张

第二步：选择检验统计量

构造一个函数 $T = T(X_1, X_2, \dots, X_n)$ ，它将样本数据压缩为单个数值，用于衡量数据与 H_0 的偏离程度。

第三步：确定显著性水平

预先设定犯错的概率上限 α （通常取 0.05 或 0.01），表示我们愿意承担的最大误判风险。

第四步：计算 p 值或确定拒绝域

基于 H_0 下检验统计量的分布，计算观测到的数据（或更极端的数据）出现的概率——即 p 值；或者确定使 H_0 被拒绝的统计量取值范围——即拒绝域。

第五步：作出决策

- 若 $p \leq \alpha$ （或统计量落入拒绝域）：拒绝 H_0 ，接受 H_1
- 若 $p > \alpha$ （或统计量落入接受域）：不拒绝 H_0 （注意：不是“接受 H_0 ”）

19.1.3 一个具体例子：单样本 z 检验 问题：已知某工厂生产的零件直径历史上服从均值 $\mu_0 = 10$ mm、标准差 $\sigma = 0.5$ mm 的正态分布。现从当日产品中随机抽取 $n = 25$ 件，测得样本均值 $\bar{x} = 10.2$ mm。在显著性水平 $\alpha = 0.05$ 下，当日生产是否存在偏差？

建立假设：

$$H_0 : \mu = 10 \quad \text{vs} \quad H_1 : \mu \neq 10$$

构造检验统计量：

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} = \frac{\bar{X} - 10}{0.5/\sqrt{25}} = \frac{\bar{X} - 10}{0.1}$$

在 H_0 成立时， $Z \sim N(0, 1)$ 。

计算观测值：

$$z_{\text{obs}} = \frac{10.2 - 10}{0.1} = 2.0$$

决策：双侧检验，拒绝域为 $|Z| > z_{\alpha/2} = z_{0.025} = 1.96$ 。

由于 $|z_{\text{obs}}| = 2.0 > 1.96$ ，拒绝 H_0 ，认为当日生产存在显著偏差。

19.2 原假设与备择假设

19.2.1 原假设的设定原则 原假设 (Null Hypothesis, H_0) 是检验的出发点, 通常代表: - 现状、基准、无效果 (“null”本义即“零”、“无”) - 已有的理论或标准 - 我们希望被数据推翻的保守假设

备择假设 (Alternative Hypothesis, H_1 或 H_a) 是我们希望通过数据证明的主张, 通常代表研究者的期望或新发现。

设定原则: 将“需要强有力证据才能接受的命题”放在 H_1 , 将“默认成立、只有足够证据才推翻”的命题放在 H_0 。

19.2.2 单侧检验与双侧检验 根据备择假设的形式, 假设检验分为三类:

(1) 双侧检验 (Two-tailed Test)

$$H_0: \mu = \mu_0 \quad \text{vs} \quad H_1: \mu \neq \mu_0$$

关心参数偏离基准值的任意方向, 拒绝域在分布两侧。

(2) 左侧检验 (Left-tailed Test)

$$H_0: \mu \geq \mu_0 \quad \text{vs} \quad H_1: \mu < \mu_0$$

关心参数是否显著小于基准, 拒绝域在分布左尾。

(3) 右侧检验 (Right-tailed Test)

$$H_0: \mu \leq \mu_0 \quad \text{vs} \quad H_1: \mu > \mu_0$$

关心参数是否显著大于基准, 拒绝域在分布右尾。

19.2.3 假设的不对称性 H_0 与 H_1 在逻辑上是不对等的。假设检验遵循“疑罪从无”原则:

- 拒绝 H_0 : 有统计上的显著证据反对 H_0
- 不拒绝 H_0 : 没有足够证据反对 H_0 , 但这并不意味着 H_0 为真

这一不对称性与法庭判决类似: 无罪判决不等于证明了无罪, 只是说检察官没有提供足够的证据。

例 19.1 在新药临床试验中:

- H_0 : 新药与安慰剂疗效相同 (药物无效)
- H_1 : 新药优于安慰剂 (药物有效)

监管机构要求有强有力的统计证据才能批准新药，因此将“药物有效”放在 H_1 ，强制要求提供充分证据。

19.3 两类错误与检验功效

19.3.1 两类错误的定义 由于我们基于样本而非总体作决策，决策结果存在两种错误：

	H_0 实际为真	H_0 实际为假
拒绝 H_0	第一类错误（弃真）	正确（检验功效）
不拒绝 H_0	正确（置信）	第二类错误（存伪）

第一类错误（Type I Error，弃真错误）： H_0 实际为真，但我们错误地拒绝了它。

$$\alpha = P(\text{拒绝}H_0 \mid H_0 \text{ 为真})$$

α 称为显著性水平（Significance Level），是我们预先设定的第一类错误的上限。

第二类错误（Type II Error，存伪错误）： H_0 实际为假，但我们错误地未拒绝它。

$$\beta = P(\text{不拒绝}H_0 \mid H_0 \text{ 为假})$$

19.3.2 检验功效 检验功效（Power of a Test）定义为正确拒绝虚假 H_0 的概率：

$$\text{Power} = 1 - \beta = P(\text{拒绝}H_0 \mid H_0 \text{ 为假})$$

功效衡量检验发现真实效果的能力。功效越高，检验越有能力检测到真实的差异。

19.3.3 两类错误的权衡 第一类错误和第二类错误存在根本性的权衡关系：在样本量固定时，降低 α 会导致 β 升高，反之亦然。

直觉理解：

若我们将拒绝域缩小（提高拒绝标准），犯第一类错误的机会减少（ $\alpha \downarrow$ ），但同时也更难拒绝一个实际为假的 H_0 ，故第二类错误增加（ $\beta \uparrow$ ）。

$$\alpha \downarrow \iff \beta \uparrow \quad (\text{样本量}n \text{ 固定时})$$

打破此权衡的唯一方式：增大样本量 n 。增大 n 可以同时降低 α 和 β ，从而提升检验功效。

19.3.4 功效分析与样本量规划 在正式实验前，可以通过功效分析（Power Analysis）确定所需样本量，使得检验在预期效应量下达到目标功效（通常为 0.8）。

对于单样本 z 检验，若实际均值为 μ_1 ，效应量为 $\delta = \mu_1 - \mu_0$ ，为使功效达到 $1 - \beta$ ，所需样本量为：

$$n \geq \left(\frac{(z_{\alpha/2} + z_{\beta}) \cdot \sigma}{\delta} \right)^2$$

其中 $z_{\alpha/2}$ 和 z_{β} 分别是标准正态分布的对应分位数。

例 19.2 设 $\sigma = 1$ ， $\delta = 0.5$ ， $\alpha = 0.05$ ， $\beta = 0.20$ （功效=0.80），则：

$$z_{0.025} = 1.96, \quad z_{0.20} = 0.84$$

$$n \geq \left(\frac{(1.96 + 0.84) \times 1}{0.5} \right)^2 = \left(\frac{2.80}{0.5} \right)^2 = 5.6^2 = 31.36$$

故需至少 $n = 32$ 个样本。

19.4 p 值与显著性水平

19.4.1 p 值的精确定义 p 值（p-value）是假设检验中最重要也最容易被误解的概念。其精确定义为：

在 H_0 为真的假设下，观测到当前统计量值或更极端值的概率。

数学上，设检验统计量为 T ，观测值为 t_{obs} ：

- 右侧检验： $p = P(T \geq t_{\text{obs}} \mid H_0)$
- 左侧检验： $p = P(T \leq t_{\text{obs}} \mid H_0)$
- 双侧检验： $p = P(|T| \geq |t_{\text{obs}}| \mid H_0) = 2 \times P(T \geq |t_{\text{obs}}| \mid H_0)$

决策规则：

$$p \leq \alpha \Rightarrow \text{拒绝 } H_0$$

$$p > \alpha \Rightarrow \text{不拒绝 } H_0$$

19.4.2 p 值的直觉含义 p 值衡量的是“如果 H_0 为真，观测到这么极端的数据有多罕见”。

- p 值很小（如 $p = 0.002$ ）：若 H_0 为真，这种数据出现的概率只有 0.2%，极为罕见，说明数据与 H_0 高度不符，有强有力的证据反对 H_0 。
- p 值较大（如 $p = 0.3$ ）：若 H_0 为真，这种数据出现的概率有 30%，相当正常，数据与 H_0 相容。

19.4.3 p 值的常见误区 p 值是统计学中被误解最深的概念之一，以下误区极为普遍：

误区一：p 值是 H_0 为真的概率

错误： $p = P(H_0 \text{ 为真} \mid \text{观测数据})$

正确： $p = P(\text{观测数据或更极端} \mid H_0 \text{ 为真})$

这两个条件概率的顺序完全相反，混淆它们是严重的逻辑错误（即条件概率方向的混淆）。

误区二：p 值是重复实验中数据重现的概率

p 值不是“若重复这个实验，有多大概率得到相同结果”。p 值是在 H_0 成立的假定下计算的，与实验重现性是不同的概念。

误区三：p 值衡量效应的实际重要性

统计显著 ($p < 0.05$) $\neq$ 实际重要 (Practically Significant)。

当样本量 n 极大时，即使极微小的差异（如模型准确率差 0.001%）也可能得到极小的 p 值。统计显著性受样本量影响极大，而实际重要性取决于效应量的大小。

误区四： $p > 0.05$ 意味着 H_0 为真

“不显著”仅表示没有足够证据拒绝 H_0 ，不等于证明了 H_0 为真。检验可能因样本量不足（功效太低）而无法检测到真实效果。

正确总结表：

p 值	说明
$p \leq 0.001$	极强证据反对 H_0
$0.001 < p \leq 0.01$	强证据反对 H_0
$0.01 < p \leq 0.05$	适度证据反对 H_0
$0.05 < p \leq 0.1$	弱证据，结论存疑
$p > 0.1$	无足够证据反对 H_0

19.4.4 显著性水平的选择 α 的选择应在实验前确定，并根据具体情境权衡两类错误的代价：

- 医学临床试验： $\alpha = 0.05$ 或更严格 ($\alpha = 0.01$)，因为错误批准无效药物代价极高
 - 工业质量控制：根据成本收益分析设定 α
 - 深度学习 A/B 测试： $\alpha = 0.05$ 为常见标准
 - 多重比较情境：需进行 Bonferroni 校正，将 α 除以比较次数
-

19.5 检验统计量与拒绝域

19.5.1 检验统计量的构造原理 检验统计量 (Test Statistic) 是将样本信息压缩为单一数值的函数，用于衡量样本与 H_0 的偏离程度。构造原则：

1. 在 H_0 下分布已知：才能计算 p 值或确定拒绝域
2. 对偏离 H_0 敏感：当 H_1 为真时，统计量取极端值的概率应当较大
3. 充分利用样本信息：通常基于充分统计量构造

19.5.2 常用检验统计量汇总 (1) 单样本 **z** 检验 (总体方差 σ^2 已知)

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1) \quad (\text{在 } H_0 \text{ 下})$$

(2) 单样本 **t** 检验 (总体方差 σ^2 未知)

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1) \quad (\text{在 } H_0 \text{ 下})$$

其中 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 为样本方差。

(3) 两样本 **t** 检验 (比较两总体均值)

设 $X_1, \dots, X_m \sim N(\mu_1, \sigma^2)$, $Y_1, \dots, Y_n \sim N(\mu_2, \sigma^2)$, $H_0: \mu_1 = \mu_2$:

$$T = \frac{\bar{X} - \bar{Y}}{S_p \sqrt{1/m + 1/n}} \sim t(m+n-2) \quad (\text{在 } H_0 \text{ 下})$$

其中合并方差 $S_p^2 = \frac{(m-1)S_X^2 + (n-1)S_Y^2}{m+n-2}$ 。

(4) 比例检验 (二项比例)

$$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}} \xrightarrow{d} N(0, 1) \quad (\text{在 } H_0: p = p_0 \text{ 下, } n \text{ 充分大时})$$

19.5.3 拒绝域的确定 拒绝域（Rejection Region 或 Critical Region） W 是使检验统计量导致拒绝 H_0 的取值范围，其大小由显著性水平 α 决定：

$$P(T \in W \mid H_0) = \alpha$$

双侧检验拒绝域（以 z 检验为例）：

$$W = \{|Z| > z_{\alpha/2}\}$$

其中 $z_{\alpha/2}$ 满足 $P(Z > z_{\alpha/2}) = \alpha/2$ 。

当 $\alpha = 0.05$ 时， $z_{0.025} = 1.96$ ，拒绝域为 $|Z| > 1.96$ 。

单侧检验拒绝域：

右侧： $W = \{Z > z_\alpha\}$ ，左侧： $W = \{Z < -z_\alpha\}$

检验类型	拒绝域	$\alpha = 0.05$ 时
双侧 z 检验	$ Z > z_{\alpha/2}$	$ Z > 1.96$
右侧 z 检验	$Z > z_\alpha$	$Z > 1.645$
左侧 z 检验	$Z < -z_\alpha$	$Z < -1.645$
双侧 t 检验（ ν 自由度）	$ T > t_{\alpha/2}(\nu)$	查 t 分布表

19.5.4 检验统计量与拒绝域的等价性 p 值方法与拒绝域方法在逻辑上完全等价：

$$p \leq \alpha \iff T \in W$$

两者只是同一决策的不同表达形式。 p 值提供了更丰富的信息（连续的证据强度），而拒绝域给出了更直观的几何图像。

本章小结

概念	数学表示	核心含义
原假设	H_0	保守的“无效果”假设，默认成立
备择假设	H_1	研究者希望证明的主张
显著性水平	$\alpha = P(\text{拒绝}H_0 \mid H_0\text{真})$	第一类错误的上限，预先设定
第二类错误	$\beta = P(\text{不拒绝}H_0 \mid H_0\text{假})$	漏掉真实效果的概率
检验功效	$1 - \beta$	发现真实效果的能力

概念	数学表示	核心含义
p 值	$P(\text{极端数据} \mid H_0 \text{真})$	数据与 H_0 不符的程度
拒绝域	$W: P(T \in W \mid H_0) = \alpha$	导致拒绝 H_0 的统计量取值范围

核心逻辑链：设定假设 $\rightarrow$ 构造统计量 $\rightarrow$ 确定 $\alpha \rightarrow$ 计算 p 值 $\rightarrow$ 与 α 比较 $\rightarrow$ 作出决策。

两类错误权衡： α 与 β 在固定样本量下此消彼长；增大样本量是同时降低两者的根本途径。

p 值不是 H_0 为真的概率，这是假设检验中最重要也最容易混淆的一点。

19.6 最优检验理论

19.6.1 最优检验的含义

在给定显著性水平 α 下，是否存在功效最大（最容易发现 H_0 为假）的检验？答案由 Neyman-Pearson 引理给出。

19.6.2 Neyman-Pearson 引理

定理（Neyman-Pearson 引理）考虑简单假设 vs 简单假设的检验：

$$H_0 : \theta = \theta_0 \quad \text{vs} \quad H_1 : \theta = \theta_1$$

设样本 $\mathbf{x} = (x_1, \dots, x_n)$ ，似然函数分别为 $L(\theta_0) = \prod f(x_i; \theta_0)$ 和 $L(\theta_1) = \prod f(x_i; \theta_1)$ 。

定义似然比：

$$\Lambda(\mathbf{x}) = \frac{L(\theta_1)}{L(\theta_0)}$$

则在所有显著性水平为 α 的检验中，拒绝域为 $\Lambda(\mathbf{x}) > c$ （其中 c 由 $P(\Lambda > c \mid H_0) = \alpha$ 确定）的检验具有最大功效。

$$W^* = \left\{ \mathbf{x} : \frac{L(\theta_1)}{L(\theta_0)} > c \right\}$$
是水平 α 下的一致最优（UMP）检验

直觉：似然比 Λ 衡量“数据更支持 H_1 还是 H_0 ”。 Λ 越大，证据越倾向 H_1 ，所以应当拒绝 H_0 。

19.6.3 示例：正态均值的最优检验

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$ (σ^2 已知), 检验 $H_0: \mu = \mu_0$ vs $H_1: \mu = \mu_1$ ($\mu_1 > \mu_0$)。

似然比：

$$\Lambda = \frac{L(\mu_1)}{L(\mu_0)} = \exp \left(\frac{(\mu_1 - \mu_0)}{\sigma^2} \sum_{i=1}^n x_i - \frac{n(\mu_1^2 - \mu_0^2)}{2\sigma^2} \right)$$

取对数后, $\ln \Lambda$ 是 $\bar{X}$ 的递增函数, 因此 $\Lambda > c$ 等价于 $\bar{X} > c'$, 即 **z** 检验的拒绝域。

结论: z 检验在这种设定下是最优的——它不仅直觉合理, 而且在功效意义下不可能被超越。

19.6.4 广义似然比检验 (GLRT)

对于复合假设 (参数取值范围而非单点), Neyman-Pearson 引理不直接适用, 需推广为广义似然比检验。

定义广义似然比统计量:

$$\Lambda^*(\mathbf{x}) = \frac{\sup_{\theta \in \Theta_0} L(\theta; \mathbf{x})}{\sup_{\theta \in \Theta} L(\theta; \mathbf{x})}$$

其中 Θ_0 是 H_0 约束下的参数空间, Θ 是完整参数空间。

拒绝域为 $\Lambda^* < c$ (比值小表示 H_0 下的最大似然远小于总体最大似然)。

Wilks 定理: 在大样本下, $-2 \ln \Lambda^* \xrightarrow{d} \chi^2(r)$, 其中 $r = \dim(\Theta) - \dim(\Theta_0)$ 是自由度。

重要性: t 检验、F 检验、卡方检验等常用检验, 实际上都可以视为广义似然比检验的特例。

本章小结 (更新)

补充: Neyman-Pearson 引理说明, 似然比检验在简单 vs 简单假设下具有最大功效; 广义似然比检验将此思想推广到复合假设, 并通过 Wilks 定理获得渐近分布。

深度学习应用

应用一: A/B 测试——评估模型改进效果

背景 A/B 测试是深度学习工程中最常见的统计检验场景。当我们修改了模型架构、调整了超参数或采用了新的训练策略后, 需要严格评估这种改动是否带来了显著提升, 而不是仅仅观察验证集指标的数字变化。

统计框架 将 A/B 测试形式化为假设检验：

- **A 组**（控制组）：原始模型，准确率估计 $\hat{p}_A$ ，样本量 n_A
- **B 组**（实验组）：改进模型，准确率估计 $\hat{p}_B$ ，样本量 n_B

建立假设：

$$H_0 : p_B = p_A \quad \text{vs} \quad H_1 : p_B > p_A$$

合并比例估计：

$$\hat{p} = \frac{n_A \hat{p}_A + n_B \hat{p}_B}{n_A + n_B}$$

检验统计量：

$$Z = \frac{\hat{p}_B - \hat{p}_A}{\sqrt{\hat{p}(1 - \hat{p})(1/n_A + 1/n_B)}} \xrightarrow{d} N(0, 1)$$

PyTorch 实现

```
import torch
import torch.nn as nn
import numpy as np
from scipy import stats
from typing import Tuple

# ----- #
# 1. 在测试集上评估两个模型，收集预测结果
# ----- #

def evaluate_model(
    model: nn.Module,
    test_loader: torch.utils.data.DataLoader,
    device: torch.device,
) -> Tuple[float, int]:
    """
    在测试集上评估模型，返回准确率和正确预测数量。

    Returns:
        accuracy: 准确率 (0~1)
        n_correct: 正确预测数量
    """
```

```

model.eval()
n_correct = 0
n_total = 0

with torch.no_grad():
    for inputs, labels in test_loader:
        inputs, labels = inputs.to(device), labels.to(device)
        outputs = model(inputs)
        preds = outputs.argmax(dim=1)
        n_correct += (preds == labels).sum().item()
        n_total += labels.size(0)

accuracy = n_correct / n_total
return accuracy, n_correct

```

```

# ----- #
# 2. 两比例  $z$  检验
# ----- #

```

```

def two_proportion_z_test(
    n_correct_a: int,
    n_total_a: int,
    n_correct_b: int,
    n_total_b: int,
    alpha: float = 0.05,
    alternative: str = "greater", # "two-sided" / "greater" / "less"
) -> dict:

```

"""

对两个模型准确率进行双比例 z 检验。

Args:

n_correct_a: A 组（控制组）正确预测数
n_total_a: A 组总样本数
n_correct_b: B 组（实验组）正确预测数
n_total_b: B 组总样本数
alpha: 显著性水平
alternative: 备择假设方向

Returns:

包含 z 统计量、 p 值、决策结果的字典

```

"""
p_a = n_correct_a / n_total_a
p_b = n_correct_b / n_total_b

# 合并比例估计
p_pool = (n_correct_a + n_correct_b) / (n_total_a + n_total_b)

# 标准误差
se = np.sqrt(p_pool * (1 - p_pool) * (1 / n_total_a + 1 / n_total_b))

# z 统计量 (B - A, 正值表示 B 更好)
z_stat = (p_b - p_a) / se

# 计算 p 值
if alternative == "two-sided":
    p_value = 2 * (1 - stats.norm.cdf(abs(z_stat)))
elif alternative == "greater":
    p_value = 1 - stats.norm.cdf(z_stat)
else: # "less"
    p_value = stats.norm.cdf(z_stat)

reject_h0 = p_value <= alpha

return {
    "p_a": p_a,
    "p_b": p_b,
    "difference": p_b - p_a,
    "z_statistic": z_stat,
    "p_value": p_value,
    "alpha": alpha,
    "reject_h0": reject_h0,
    "conclusion": (
        f" 在显著性水平 {alpha} 下, {'拒绝' if reject_h0 else '不拒绝'} H0。"
        f" 模型 B {'显著优于' if reject_h0 else '未能显著优于'} 模型 A。"
    ),
}

```

```

# ----- #
# 3. McNemar 检验 (配对比较, 更适合同一测试集)
# ----- #

```

```

def mcnemar_test(
    preds_a: torch.Tensor,
    preds_b: torch.Tensor,
    labels: torch.Tensor,
    alpha: float = 0.05,
) -> dict:
    """
    McNemar 检验：适用于两个分类器在同一测试集上的配对比较。

    当 A 和 B 在相同样本上评估时，预测结果不独立，
    应使用 McNemar 检验而非两比例 z 检验。

    配列表：
        b00: A 错 B 错 (两者都错)
        b01: A 错 B 对 (B 比 A 好的样本)
        b10: A 对 B 错 (A 比 B 好的样本)
        b11: A 对 B 对 (两者都对)

    H0: P(A 错 B 对) = P(A 对 B 错), 即两模型无差异
    """
    correct_a = (preds_a == labels)
    correct_b = (preds_b == labels)

    b00 = (~correct_a & ~correct_b).sum().item() # A 错 B 错
    b01 = (~correct_a & correct_b).sum().item()   # A 错 B 对
    b10 = (correct_a & ~correct_b).sum().item()   # A 对 B 错
    b11 = (correct_a & correct_b).sum().item()    # A 对 B 对

    # McNemar 统计量 (连续性修正)
    # 仅关注不一致样本 b01 和 b10
    n_discordant = b01 + b10

    if n_discordant == 0:
        return {"error": " 没有不一致样本，两模型预测完全相同"}

    # 带连续性修正的 McNemar 统计量
    chi2_stat = (abs(b01 - b10) - 1) ** 2 / n_discordant
    p_value = 1 - stats.chi2.cdf(chi2_stat, df=1)

    reject_h0 = p_value <= alpha

```

```

return {
    "contingency_table": {
        "A 错 B 错 (b00)": b00,
        "A 错 B 对 (b01)": b01,
        "A 对 B 错 (b10)": b10,
        "A 对 B 对 (b11)": b11,
    },
    "chi2_statistic": chi2_stat,
    "p_value": p_value,
    "alpha": alpha,
    "reject_h0": reject_h0,
    "conclusion": (
        f"McNemar 检验：在  $\alpha$  下， "
        f"{'拒绝' if reject_h0 else '不拒绝'} H0。 "
        f"两模型性能{'存在显著差异' if reject_h0 else '无显著差异'}。 "
    ),
}

```

```

# ----- #
# 4. 完整 A/B 测试流程演示
# ----- #

```

```

def run_ab_test_demo():
    """ 演示完整的 A/B 测试流程（使用模拟数据）。 """
    np.random.seed(42)

    # 模拟两个模型在 10000 个测试样本上的表现
    n_test = 10_000
    true_acc_a = 0.80 # 原始模型真实准确率
    true_acc_b = 0.83 # 改进模型真实准确率

    # 模拟预测结果
    labels = torch.zeros(n_test, dtype=torch.long)
    preds_a = torch.tensor(
        np.random.binomial(1, true_acc_a, n_test), dtype=torch.long
    )
    preds_b = torch.tensor(
        np.random.binomial(1, true_acc_b, n_test), dtype=torch.long
    )

```

```

n_correct_a = (preds_a == labels).sum().item()
n_correct_b = (preds_b == labels).sum().item()

print("=" * 60)
print("A/B 测试结果报告")
print("=" * 60)
print(f" 测试集大小: {n_test} 样本")
print(f" 模型 A 准确率: {n_correct_a/n_test:.4f}  ({n_correct_a}/{n_test})")
print(f" 模型 B 准确率: {n_correct_b/n_test:.4f}  ({n_correct_b}/{n_test})")
print()

# 两比例 z 检验 (假设独立测试集)
result_z = two_proportion_z_test(
    n_correct_a, n_test, n_correct_b, n_test,
    alpha=0.05, alternative="greater"
)
print("--- 两比例 z 检验 ---")
print(f" 准确率差异: {result_z['difference']:+.4f}")
print(f" z 统计量: {result_z['z_statistic']:.4f}")
print(f" p 值: {result_z['p_value']:.6f}")
print(f" 结论: {result_z['conclusion']}")
print()

# McNemar 检验 (同一测试集, 配对比较)
result_mc = mcnemar_test(preds_a, preds_b, labels, alpha=0.05)
print("--- McNemar 配对检验 ---")
print(f" 不一致样本分布: {result_mc['contingency_table']}")
print(f"  $\chi^2$  统计量: {result_mc['chi2_statistic']:.4f}")
print(f" p 值: {result_mc['p_value']:.6f}")
print(f" 结论: {result_mc['conclusion']}")

if __name__ == "__main__":
    run_ab_test_demo()

```

预期输出:

```

=====
A/B 测试结果报告
=====

```

```

测试集大小: 10000 样本

```

模型 A 准确率：0.8012 (8012/10000)

模型 B 准确率：0.8287 (8287/10000)

--- 两比例 z 检验 ---

准确率差异：+0.0275

z 统计量：5.8143

p 值：0.000003

结论：在显著性水平 $\alpha=0.05$ 下，拒绝 H_0 。模型 B 显著优于 模型 A。

--- McNemar 配对检验 ---

不一致样本分布：{'A错B错 (b00)': ..., 'A错B对 (b01)': ..., ...}

χ^2 统计量：28.1234

p 值：0.000000

结论：McNemar 检验：在 $\alpha=0.05$ 下，拒绝 H_0 。两模型性能存在显著差异。

应用二：模型显著性比较——交叉验证配对 t 检验

背景 在学术研究中，常需要比较两个机器学习模型在多个数据集或多折交叉验证上的性能。此时，单次评估的随机性较大，需要使用多次评估的配对 t 检验 (Paired t-test)。

统计框架 设模型 A 和模型 B 在 k 折交叉验证中每折的准确率差为：

$$d_i = \text{acc}_B^{(i)} - \text{acc}_A^{(i)}, \quad i = 1, 2, \dots, k$$

建立假设：

$$H_0 : \mu_d = 0 \quad \text{vs} \quad H_1 : \mu_d \neq 0$$

检验统计量：

$$T = \frac{\bar{d}}{S_d/\sqrt{k}} \sim t(k-1) \quad (\text{在 } H_0 \text{ 下})$$

其中 $\bar{d} = \frac{1}{k} \sum_{i=1}^k d_i$, $S_d^2 = \frac{1}{k-1} \sum_{i=1}^k (d_i - \bar{d})^2$ 。

PyTorch 实现

```
import torch
import torch.nn as nn
import numpy as np
from scipy import stats
from typing import List, Callable
```



```
def cross_validation_comparison(
    model_a_factory: Callable[[], nn.Module],
    model_b_factory: Callable[[], nn.Module],
    dataset: torch.utils.data.Dataset,
    k_folds: int = 5,
    n_epochs: int = 10,
    batch_size: int = 64,
    alpha: float = 0.05,
    device: torch.device = torch.device("cpu"),
) -> dict:
    """
    使用  $k$  折交叉验证配对  $t$  检验比较两个模型。

    Args:
        model_a_factory: 创建模型  $A$  实例的工厂函数（每折重新初始化）
        model_b_factory: 创建模型  $B$  实例的工厂函数
        dataset: 完整数据集
        k_folds: 交叉验证折数
        n_epochs: 每折训练轮数
        batch_size: 批量大小
        alpha: 显著性水平

    Returns:
        包含每折结果、 $t$  统计量、 $p$  值和结论的字典
    """
    n = len(dataset)
    fold_size = n // k_folds
    indices = np.random.permutation(n)

    acc_a_list = []
    acc_b_list = []

    for fold in range(k_folds):
        # 划分训练集和验证集
        val_idx = indices[fold * fold_size : (fold + 1) * fold_size]
        train_idx = np.concatenate(
            [indices[: fold * fold_size], indices[(fold + 1) * fold_size :]]
        )
```

```

train_subset = torch.utils.data.Subset(dataset, train_idx)
val_subset = torch.utils.data.Subset(dataset, val_idx)

train_loader = torch.utils.data.DataLoader(
    train_subset, batch_size=batch_size, shuffle=True
)
val_loader = torch.utils.data.DataLoader(
    val_subset, batch_size=batch_size, shuffle=False
)

# 训练并评估两个模型（省略具体训练循环）
acc_a = _train_and_evaluate(
    model_a_factory(), train_loader, val_loader, n_epochs, device
)
acc_b = _train_and_evaluate(
    model_b_factory(), train_loader, val_loader, n_epochs, device
)

acc_a_list.append(acc_a)
acc_b_list.append(acc_b)
print(f" Fold {fold+1}/{k_folds}: A={acc_a:.4f}, B={acc_b:.4f}, "
      f" 差异 ={acc_b-acc_a:+.4f}")

# 计算差值序列
differences = np.array(acc_b_list) - np.array(acc_a_list)
d_bar = differences.mean()
s_d = differences.std(ddof=1)
t_stat = d_bar / (s_d / np.sqrt(k_folds))

# 双侧 t 检验 p 值
p_value = 2 * (1 - stats.t.cdf(abs(t_stat), df=k_folds - 1))
reject_h0 = p_value <= alpha

# 95% 置信区间
t_critical = stats.t.ppf(1 - alpha / 2, df=k_folds - 1)
margin = t_critical * s_d / np.sqrt(k_folds)
ci_lower = d_bar - margin
ci_upper = d_bar + margin

return {
    "acc_a": acc_a_list,

```

```

    "acc_b": acc_b_list,
    "differences": differences.tolist(),
    "mean_difference": d_bar,
    "std_difference": s_d,
    "t_statistic": t_stat,
    "degrees_of_freedom": k_folds - 1,
    "p_value": p_value,
    "confidence_interval": (ci_lower, ci_upper),
    "reject_h0": reject_h0,
    "conclusion": (
        f" 配对 t 检验 ({k_folds} 折 CV): \n"
        f" 平均准确率差异: {d_bar:+.4f} ± {margin:.4f} "
        f" (95% CI: [{ci_lower:.4f}, {ci_upper:.4f}]) \n"
        f"  t({k_folds-1}) = {t_stat:.4f}, p = {p_value:.4f}\n"
        f" 结论: 在 ={alpha} 下, "
        f"{'两模型存在显著差异' if reject_h0 else '两模型无显著差异'}。"
    ),
}

def _train_and_evaluate(
    model: nn.Module,
    train_loader: torch.utils.data.DataLoader,
    val_loader: torch.utils.data.DataLoader,
    n_epochs: int,
    device: torch.device,
) -> float:
    """ 训练模型并返回验证集准确率（简化实现）。 """
    model.to(device)
    optimizer = torch.optim.Adam(model.parameters(), lr=1e-3)
    criterion = nn.CrossEntropyLoss()

    model.train()
    for _ in range(n_epochs):
        for inputs, labels in train_loader:
            inputs, labels = inputs.to(device), labels.to(device)
            optimizer.zero_grad()
            loss = criterion(model(inputs), labels)
            loss.backward()
            optimizer.step()

```

```

# 评估
model.eval()
n_correct = 0
n_total = 0
with torch.no_grad():
    for inputs, labels in val_loader:
        inputs, labels = inputs.to(device), labels.to(device)
        preds = model(inputs).argmax(dim=1)
        n_correct += (preds == labels).sum().item()
        n_total += labels.size(0)

return n_correct / n_total

# ----- #
# 用 scipy 快速演示配对 t 检验
# ----- #

def demo_paired_t_test():
    """ 使用模拟的 5 折交叉验证结果演示配对 t 检验。 """
    np.random.seed(42)

    # 模拟 5 折 CV 结果 (ResNet vs ViT 的准确率)
    acc_resnet = np.array([0.821, 0.835, 0.828, 0.819, 0.832])
    acc_vit     = np.array([0.847, 0.852, 0.839, 0.843, 0.856])

    differences = acc_vit - acc_resnet
    print("5 折交叉验证配对 t 检验")
    print("-" * 40)
    print(f"ResNet 各折准确率: {acc_resnet}")
    print(f"ViT 各折准确率: {acc_vit}")
    print(f"差异 d_i = ViT - ResNet: {differences}")
    print(f"差异均值 d = {differences.mean():.4f}")
    print(f"差异标准差 S_d = {differences.std(ddof=1):.4f}")

    t_stat, p_value = stats.ttest_rel(acc_vit, acc_resnet)
    print(f"\nt 统计量: {t_stat:.4f}")
    print(f"p 值 (双侧): {p_value:.6f}")
    print(f"\n结论: p = {p_value:.4f} {'<' if p_value < 0.05 else '>'} 0.05")
    if p_value < 0.05:
        print("在 =0.05 水平下, ViT 与 ResNet 存在显著性能差异。")

```

```

else:
    print(" 在  $\alpha=0.05$  水平下，两模型性能无显著差异。")

    # 效应量 (Cohen's d)
    cohen_d = differences.mean() / differences.std(ddof=1)
    print(f"\nCohen's d 效应量: {cohen_d:.4f}")
    print(" 效应量解释: |d| < 0.2 小效应, 0.2~0.8 中效应, > 0.8 大效应")

if __name__ == "__main__":
    demo_paired_t_test()

```

预期输出：

5折交叉验证配对 t 检验

```

-----
ResNet 各折准确率: [0.821 0.835 0.828 0.819 0.832]
ViT    各折准确率: [0.847 0.852 0.839 0.843 0.856]
差异 d_i = ViT - ResNet: [0.026 0.017 0.011 0.024 0.024]
差异均值  $\bar{d}$  = 0.0204
差异标准差  $S_d$  = 0.0060

```

```

t 统计量: 7.5921
p 值 (双侧): 0.001634

```

结论: $p = 0.0016 < 0.05$
 在 $\alpha=0.05$ 水平下，ViT 与 ResNet 存在显著性能差异。

```

Cohen's d 效应量: 3.4010
效应量解释: |d| < 0.2 小效应, 0.2~0.8 中效应, > 0.8 大效应

```

实践注意事项

1. 同一测试集 vs 独立测试集：在同一测试集上评估时，两模型预测相关，优先使用 McNemar 检验或配对 t 检验，而非独立两样本检验。
2. 多重比较问题：若同时比较多个模型，需进行 Bonferroni 校正：将 α 替换为 α/m ，其中 m 为比较次数，以控制整体第一类错误率。
3. 效应量比统计显著性更重要：大样本下，微小的性能差异也可能统计显著。应同时报告效应量（如 Cohen's d）和置信区间，而非仅报告 p 值。
4. 功效分析先行：在设计实验前，根据预期效应量进行功效分析，确保实验有足够的检测能力（功效 ≥ 0.8 ）。

练习题

习题 19.1（基础）某机器学习竞赛中，某选手声称其模型准确率超过了 90% 的基准。他在 1000 个测试样本上评估，得到准确率 92%。

(1) 建立适当的原假设和备择假设；(2) 构造检验统计量并计算其值；(3) 在显著性水平 $\alpha = 0.05$ 下作出判断。

习题 19.2（基础）解释以下关于 p 值的陈述是否正确，并给出理由：

(1) “p 值为 0.03 意味着 H_0 为真的概率只有 3%”；(2) “p 值为 0.03 意味着若重复实验，有 97% 的概率得到相同结论”；(3) “p 值为 0.03 意味着在 H_0 为真时，观测到这么极端数据的概率为 3%”；(4) “ $p > 0.05$ 说明两组之间没有差异”。

习题 19.3（中级）两位研究员比较同一模型在两种数据增强策略下的效果。研究员甲在独立的两批测试数据上分别评估 ($n_A = n_B = 500$)，策略 A 正确预测 430 个，策略 B 正确预测 455 个。研究员乙在同一批 500 个样本上评估，发现策略 A 对 B 错 25 个，策略 A 错 B 对 50 个。

(1) 研究员甲应使用什么检验？计算检验统计量和 p 值；(2) 研究员乙应使用什么检验？计算检验统计量和 p 值；(3) 两种检验的结论是否相同？为什么两位研究员应使用不同的检验？

习题 19.4（中级）某深度学习实验设计如下：改进优化器后，预期模型损失降低 $\delta = 0.05$ ，已知损失的标准差约为 $\sigma = 0.1$ ，希望在 $\alpha = 0.05$ 、功效 $1 - \beta = 0.80$ 下检测到此差异。

(1) 这是单侧还是双侧检验？为什么？(2) 计算所需的最小样本量（每组）；(3) 若实际只有 20 个样本，此时检验的功效约为多少？

习题 19.5（提高）某团队在同一 5 折交叉验证实验中比较了模型 A 和模型 B，5 折准确率如下：

折	模型 A	模型 B
1	0.812	0.831
2	0.798	0.815
3	0.823	0.820
4	0.807	0.829
5	0.815	0.835

(1) 计算每折差值 $d_i = B_i - A_i$ ，差值均值 $\bar{d}$ 和差值标准差 S_d ；(2) 构造配对 t 检验统计量，查表或计算 p 值 ($t_{0.025}(4) = 2.776$)；(3) 在 $\alpha = 0.05$ 下作出决策，并计算效应量 Cohen's d；(4) 若某人主张因为“第 3 折模型 A 更好”，所以两模型无差异，请从统计检验的角度指出其错误。

练习答案

习题 19.1 详解

(1) 建立假设

检验方向：我们关心准确率是否“超过”90%，属于右侧检验。

$$H_0: p \leq 0.90 \quad \text{vs} \quad H_1: p > 0.90$$

(等价地取 $H_0: p = 0.90$ ，检验统计量不变。)

(2) 构造检验统计量

样本量 $n = 1000$ ，样本比例 $\hat{p} = 0.92$ ， H_0 下 $p_0 = 0.90$ 。

$$Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)/n}} = \frac{0.92 - 0.90}{\sqrt{0.90 \times 0.10/1000}} = \frac{0.02}{\sqrt{0.00009}} = \frac{0.02}{0.009487} \approx 2.108$$

(3) 决策

右侧检验，拒绝域为 $Z > z_{0.05} = 1.645$ 。

由于 $z_{\text{obs}} = 2.108 > 1.645$ ，拒绝 H_0 。

p 值 = $P(Z > 2.108) = 1 - \Phi(2.108) \approx 0.0175 < 0.05$ 。

在 $\alpha = 0.05$ 下，有统计显著证据表明该模型准确率超过 90%。

习题 19.2 详解

(1) 错误。

p 值的条件方向是 $P(\text{数据} | H_0)$ ，而非 $P(H_0 | \text{数据})$ 。后者是贝叶斯后验概率，需要 H_0 的先验概率才能计算，与 p 值是完全不同的量。

(2) 错误。

p 值不衡量实验重现性，也不是“得到相同结论的概率”。“重现性”涉及置信区间和功效，是不同的概念。

(3) 正确。

这是 p 值的精确定义：在 H_0 为真的假设下，观测到当前检验统计量值或更极端值的概率。

(4) 错误。

$p > 0.05$ 表示“没有足够证据拒绝 H_0 ”，而不是“证明了两组无差异”。检验可能因样本量不足（功效低）而无法检测真实存在的差异，这是第二类错误（存伪）的情形。正确表述是“未能检测到显著差异”。

习题 19.3 详解

(1) 研究员甲：两比例 z 检验（独立样本）

$$\hat{p}_A = 430/500 = 0.86, \hat{p}_B = 455/500 = 0.91, n_A = n_B = 500.$$

$$\text{合并比例: } \hat{p} = (430 + 455)/(500 + 500) = 885/1000 = 0.885$$

$$\begin{aligned} Z &= \frac{0.91 - 0.86}{\sqrt{0.885 \times 0.115 \times (1/500 + 1/500)}} = \frac{0.05}{\sqrt{0.885 \times 0.115 \times 0.004}} \\ &= \frac{0.05}{\sqrt{0.0004071}} = \frac{0.05}{0.02018} \approx 2.478 \end{aligned}$$

双侧 p 值 $= 2 \times P(Z > 2.478) \approx 2 \times 0.0066 = 0.0132 < 0.05$, 拒绝 H_0 。

(2) 研究员乙：McNemar 检验（配对样本）

A 对 B 错 (b_{10}) = 25, A 错 B 对 (b_{01}) = 50, 不一致总数 = 75。

$$\chi^2 = \frac{(|b_{01} - b_{10}| - 1)^2}{b_{01} + b_{10}} = \frac{(|50 - 25| - 1)^2}{75} = \frac{24^2}{75} = \frac{576}{75} = 7.68$$

p 值 $= P(\chi^2(1) > 7.68) \approx 0.0056 < 0.05$, 拒绝 H_0 。

(3) 分析

两者结论相同（均拒绝 H_0 ），但理由不同：

- 甲的数据是独立的两批测试集，两组样本间没有配对关系，用独立样本检验合理。
- 乙的数据在同一批 500 个样本上评估，每个样本上两种策略的预测结果相关。若用独立检验，会忽略这种相关性，导致检验效率降低。McNemar 检验充分利用了不一致样本的信息，是配对二值数据的标准检验。

习题 19.4 详解

(1) 检验类型

研究者关心“损失是否降低”，有明确的方向性，应使用右侧检验（若以降低量 $\delta > 0$ 为正方向，检验 $H_1: \mu_d > 0$ ），即单侧检验。

(2) 样本量计算

$$\sigma = 0.1, \delta = 0.05, \alpha = 0.05 \text{ (单侧)}, 1 - \beta = 0.80.$$

$$z_{\alpha} = z_{0.05} = 1.645, \quad z_{\beta} = z_{0.20} = 0.842$$

$$n \geq \left(\frac{(z_{\alpha} + z_{\beta}) \cdot \sigma}{\delta} \right)^2 = \left(\frac{(1.645 + 0.842) \times 0.1}{0.05} \right)^2 = \left(\frac{0.2487}{0.05} \right)^2 = 4.974^2 \approx 24.74$$

故每组至少需要 $n = 25$ 个样本。

(3) 实际功效 ($n = 20$)

$$\begin{aligned} \text{Power} &= P\left(Z > z_{\alpha} - \frac{\delta\sqrt{n}}{\sigma}\right) = P\left(Z > 1.645 - \frac{0.05 \times \sqrt{20}}{0.1}\right) \\ &= P\left(Z > 1.645 - \frac{0.05 \times 4.472}{0.1}\right) = P(Z > 1.645 - 2.236) = P(Z > -0.591) \\ &= \Phi(0.591) \approx 0.723 \end{aligned}$$

功效约为 **72.3%**，低于目标的 80%，意味着有约 27.7% 的概率漏掉真实效果。

习题 19.5 详解

(1) 计算差值

折	A	B	$d_i = B - A$
1	0.812	0.831	+0.019
2	0.798	0.815	+0.017
3	0.823	0.820	-0.003
4	0.807	0.829	+0.022
5	0.815	0.835	+0.020

$$\bar{d} = \frac{0.019 + 0.017 + (-0.003) + 0.022 + 0.020}{5} = \frac{0.075}{5} = 0.015$$

$$S_d = \sqrt{\frac{\sum_{i=1}^5 (d_i - \bar{d})^2}{4}}$$

偏差平方: $(0.004)^2 + (0.002)^2 + (-0.018)^2 + (0.007)^2 + (0.005)^2 = 0.000016 + 0.000004 + 0.000324 + 0.000049 + 0.000025 = 0.000418$

$$S_d = \sqrt{0.000418/4} = \sqrt{0.0001045} \approx 0.01022$$

(2) 配对 t 检验统计量

$$T = \frac{\bar{d}}{S_d/\sqrt{k}} = \frac{0.015}{0.01022/\sqrt{5}} = \frac{0.015}{0.004571} \approx 3.282$$

双侧检验，自由度 $\nu = k - 1 = 4$ 。

由于 $|T| = 3.282 > t_{0.025}(4) = 2.776$ ，拒绝 H_0 ， p 值 < 0.05 。

(3) 效应量与决策

$$\text{Cohen's } d = \frac{\bar{d}}{S_d} = \frac{0.015}{0.01022} \approx 1.468$$

这是大效应量 ($|d| > 0.8$)，表明差异不仅统计显著，在实践中也具有一定意义。

(4) 对主张的反驳

假设检验关注的是整体规律，而非个别折的结果。第 3 折 A 比 B 好 0.003，只是随机波动的体现。统计检验从 5 个差值的整体模式来判断：差值均值 $\bar{d} = 0.015 > 0$ ，且变异性小 ($S_d = 0.01022$)，导致 t 统计量显著大于临界值。

单次折的结果可能由随机误差主导，我们不能以个别反例否定总体趋势。正是因为存在随机波动，才需要用统计检验而非简单比较数字来得出可靠结论。

第 20 章参数检验

难度：★★★★☆ 前置知识：第 17 章假设检验基础、第 18 章正态分布与抽样分布、第 19 章非参数检验

学习目标

- 掌握单样本、双样本 t 检验的适用条件、统计量构造与假设决策方法
- 理解独立双样本与配对样本 t 检验的本质区别与选择依据
- 掌握 F 检验用于方差齐性检验的原理与计算步骤
- 理解卡方检验在拟合优度与独立性检验中的应用
- 掌握多重比较问题及 Bonferroni 校正、FDR 控制方法，并能将统计检验应用于深度学习模型比较

20.1 单样本 t 检验

20.1.1 适用场景与基本假设

单样本 t 检验 (One-sample t -test) 用于判断总体均值是否等于某个已知的假设值 μ_0 。

适用条件:

1. 样本来自正态总体, 或样本量 $n \geq 30$ (由中心极限定理保证近似正态)
2. 样本相互独立
3. 总体方差 σ^2 未知 (若已知则使用 z 检验)

假设形式:

$$H_0: \mu = \mu_0 \quad \text{vs} \quad H_1: \mu \neq \mu_0 \quad (\text{双侧})$$

或单侧: $H_1: \mu > \mu_0$ 或 $H_1: \mu < \mu_0$ 。

20.1.2 检验统计量

设样本 $X_1, X_2, \dots, X_n$ 来自 $N(\mu, \sigma^2)$, 样本均值为

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

样本标准差为

$$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

则检验统计量为

$$t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$$

在 H_0 成立时, $t \sim t(n-1)$, 即服从自由度为 $n-1$ 的 t 分布。

推导思路:

- $\bar{X} \sim N(\mu_0, \sigma^2/n)$, 标准化后 $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1)$
- $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$, 且与 $\bar{X}$ 独立
- 由 t 分布定义 $t = Z/\sqrt{\chi^2(n-1)/(n-1)}$ 得上述统计量

20.1.3 拒绝域与 p 值

给定显著性水平 α :

备择假设	拒绝域	p 值
$\mu \neq \mu_0$ (双侧)	$ t > t_{\alpha/2}(n-1)$	$2P(T > t_{\text{obs}})$
$\mu > \mu_0$ (右侧)	$t > t_{\alpha}(n-1)$	$P(T > t_{\text{obs}})$
$\mu < \mu_0$ (左侧)	$t < -t_{\alpha}(n-1)$	$P(T < t_{\text{obs}})$

其中 $T \sim t(n-1)$, $t_{\alpha}(n-1)$ 为 t 分布的上 α 分位数。

20.1.4 例题

例 20.1 某机器生产零件, 规格要求直径均值为 $\mu_0 = 50 \text{ mm}$ 。随机抽取 $n = 16$ 件, 测得 $\bar{x} = 50.5 \text{ mm}$, $s = 1.2 \text{ mm}$ 。在 $\alpha = 0.05$ 下检验该机器是否正常工作。

解:

$H_0 : \mu = 50 \text{ vs } H_1 : \mu \neq 50$

$$t = \frac{50.5 - 50}{1.2/\sqrt{16}} = \frac{0.5}{0.3} = 1.667$$

查 t 分布表: $t_{0.025}(15) = 2.131$

因为 $|t| = 1.667 < 2.131$, 不拒绝 H_0 , 即没有充分证据认为机器工作异常。

20.1.5 置信区间与检验的对偶性

单样本 t 检验与置信区间具有对偶关系: 双侧检验在 α 水平拒绝 $H_0 : \mu = \mu_0$ 当且仅当 μ_0 不在 μ 的 $1 - \alpha$ 置信区间内:

$$\left(\bar{X} - t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}}, \bar{X} + t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}} \right)$$

20.2 双样本 t 检验: 独立与配对

20.2.1 独立双样本 t 检验

场景: 比较两个独立总体的均值差异, 即 $H_0 : \mu_1 = \mu_2$ (或 $\mu_1 - \mu_2 = \delta_0$)。

方差齐性情况（等方差， $\sigma_1^2 = \sigma_2^2 = \sigma^2$ ） 设 $X_{11}, \dots, X_{1n_1} \sim N(\mu_1, \sigma^2)$, $X_{21}, \dots, X_{2n_2} \sim N(\mu_2, \sigma^2)$ ，两组独立。

合并方差估计（Pooled Variance）：

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

检验统计量：

$$t = \frac{\bar{X}_1 - \bar{X}_2 - \delta_0}{S_p \sqrt{1/n_1 + 1/n_2}} \sim t(n_1 + n_2 - 2) \quad (\text{在 } H_0 \text{ 下})$$

方差不齐情况（Welch t 检验） 当 $\sigma_1^2 \neq \sigma_2^2$ 时，使用 Welch 近似：

$$t = \frac{\bar{X}_1 - \bar{X}_2 - \delta_0}{\sqrt{S_1^2/n_1 + S_2^2/n_2}}$$

自由度由 Welch-Satterthwaite 公式近似：

$$\nu = \frac{(S_1^2/n_1 + S_2^2/n_2)^2}{\frac{(S_1^2/n_1)^2}{n_1 - 1} + \frac{(S_2^2/n_2)^2}{n_2 - 1}}$$

选择依据 在实践中推荐默认使用 **Welch t 检验**，因为：- 当方差相等时，Welch 检验的功效损失极小 - 当方差不等时，等方差 t 检验的 I 类错误率膨胀严重

20.2.2 配对样本 t 检验

场景：两组观测值存在自然配对关系（如同一受试者的前后测量、同一样本的两种处理结果）。

核心思想：将配对差值 $D_i = X_{1i} - X_{2i}$ 视为新样本，转化为单样本问题。

设 $D_1, D_2, \dots, D_n$ 为配对差值， $\bar{D}$ 和 S_D 为其均值与标准差：

$$t = \frac{\bar{D} - \delta_0}{S_D / \sqrt{n}} \sim t(n - 1) \quad (\text{在 } H_0 : \mu_D = \delta_0 \text{ 下})$$

配对设计的优势：

配对消除了个体间变异，使检验功效大幅提升。设两组测量的相关系数为 ρ ，则配对差值的方差为：

$$\text{Var}(D) = \sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2$$

当 $\rho > 0$ 时, $\text{Var}(D) < \text{Var}(X_1) + \text{Var}(X_2)$, 即配对降低了估计误差。

20.2.3 例题

例 20.2 比较两种深度学习优化器 (Adam 与 SGD) 在 10 个不同数据集上的准确率:

数据集	Adam	SGD	差值 D_i
1	0.912	0.895	0.017
2	0.876	0.861	0.015
3	0.934	0.920	0.014
4	0.821	0.818	0.003
5	0.958	0.941	0.017
6	0.743	0.736	0.007
7	0.889	0.875	0.014
8	0.901	0.893	0.008
9	0.867	0.852	0.015
10	0.923	0.910	0.013

计算得 $\bar{d} = 0.0123$, $s_D = 0.00432$, $n = 10$ 。

$$t = \frac{0.0123}{0.00432/\sqrt{10}} = \frac{0.0123}{0.001366} \approx 9.00$$

$t_{0.025}(9) = 2.262$, 因 $t = 9.00 \gg 2.262$, 拒绝 H_0 , 认为两优化器性能存在显著差异。

20.3 方差检验 (F 检验)

20.3.1 单总体方差检验 (χ^2 检验)

场景: 检验总体方差是否等于已知值 σ_0^2 , 即 $H_0: \sigma^2 = \sigma_0^2$ 。

设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, 检验统计量为:

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1) \quad (\text{在 } H_0 \text{ 下})$$

双侧拒绝域: $\chi^2 < \chi_{1-\alpha/2}^2(n-1)$ 或 $\chi^2 > \chi_{\alpha/2}^2(n-1)$ 。

20.3.2 两总体方差比检验 (F 检验)

场景：比较两个正态总体的方差是否相等， $H_0: \sigma_1^2 = \sigma_2^2$ 。

检验统计量：

$$F = \frac{S_1^2}{S_2^2}$$

在 H_0 成立时：

$$F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} = \frac{\chi^2(n_1-1)/(n_1-1)}{\chi^2(n_2-1)/(n_2-1)} \sim F(n_1-1, n_2-1)$$

拒绝域（双侧， $\alpha = 0.05$ ）：

$$F < F_{1-\alpha/2}(n_1-1, n_2-1) \quad \text{或} \quad F > F_{\alpha/2}(n_1-1, n_2-1)$$

利用 F 分布的对称性： $F_{1-\alpha/2}(m, n) = 1/F_{\alpha/2}(n, m)$ ，实际查表时只需查上侧分位数。

20.3.3 F 分布的性质

若 $U \sim \chi^2(m)$ ， $V \sim \chi^2(n)$ 独立，则

$$F = \frac{U/m}{V/n} \sim F(m, n)$$

其中 m 称为分子自由度， n 称为分母自由度。

- $E(F) = \frac{n}{n-2} \quad (n > 2)$
- F 分布右偏，取值为正
- 若 $X \sim t(n)$ ，则 $X^2 \sim F(1, n)$

20.3.4 单因素方差分析 (ANOVA) 中的 F 检验

场景：比较 k 个独立正态总体均值是否相等， $H_0: \mu_1 = \mu_2 = \cdots = \mu_k$ 。

设第 i 组有 n_i 个观测值，总观测数 $N = \sum_{i=1}^k n_i$ ，总体均值 $\bar{X}_{..} = \frac{1}{N} \sum_i \sum_j X_{ij}$ 。

平方和分解：

$$\underbrace{\sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_{..})^2}_{SS_T} = \underbrace{\sum_{i=1}^k n_i (\bar{X}_{i.} - \bar{X}_{..})^2}_{SS_A} + \underbrace{\sum_{i=1}^k \sum_{j=1}^{n_i} (X_{ij} - \bar{X}_{i.})^2}_{SS_E}$$

来源	平方和	自由度	均方	F 统计量
组间（处理）	SS_A	$k - 1$	$MS_A = SS_A / (k - 1)$	$F = MS_A / MS_E$
组内（误差）	SS_E	$N - k$	$MS_E = SS_E / (N - k)$	—
总计	SS_T	$N - 1$	—	—

在 H_0 下, $F \sim F(k - 1, N - k)$; MS_A 和 MS_E 都是 σ^2 的无偏估计, 但当 H_1 成立时 $E(MS_A) > \sigma^2$, 因此大的 F 值支持 H_1 。

20.3.5 ANOVA 的事后多重比较

当 ANOVA 拒绝 H_0 后, 我们知道至少有一对均值不等, 但不知道哪些对不等。需要进行事后比较 (Post-hoc Tests)。

Tukey HSD (Honestly Significant Difference) 法: 基于学生化极差分布, 对所有 $\binom{k}{2}$ 对均值差同时进行检验:

$$|\bar{X}_{i.} - \bar{X}_{j.}| > q_{\alpha}(k, N - k) \cdot \sqrt{\frac{MS_E}{2} \left(\frac{1}{n_i} + \frac{1}{n_j} \right)}$$

其中 $q_{\alpha}(k, N - k)$ 是学生化极差分布的上 α 分位数。

Bonferroni 校正: 对每对比较使用 $\alpha' = \alpha / \binom{k}{2}$ 的显著性水平进行 t 检验。简单保守, 但当比较组数很多时过于严格。

Scheffé 法: 基于 F 分布, 可检验任意线性对比 $\sum c_i \mu_i = 0$, 是最保守但最灵活的方法。

方法	特点	适用场景
Tukey HSD	控制整体第一类错误率, 功效较好	各组等样本量, 比较所有配对
Bonferroni	简单通用, 偏保守	比较组数较少时
Scheffé	最保守, 可检验任意对比	需要灵活性时

20.4 卡方检验

20.4.1 拟合优度检验

场景: 检验数据是否来自某个指定的分布 (或符合某种理论比例)。

假设: H_0 : 数据符合理论分布 F_0

设有 k 个类别, 第 i 类的观测频数为 O_i , 理论概率为 p_i , 则期望频数为 $E_i = np_i$ 。

皮尔逊卡方统计量:

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

在 H_0 下, 当 n 充分大时, $\chi^2 \xrightarrow{d} \chi^2(k-1)$ (若理论分布完全已知, 自由度为 $k-1$)。

若理论分布含 r 个未知参数需用样本估计, 则自由度调整为 $k-1-r$ 。

使用条件: 每个类别的期望频数 $E_i \geq 5$ (若不满足, 需合并类别)。

例 20.3 掷骰子 120 次, 各点出现次数如下, 检验骰子是否均匀 ($\alpha = 0.05$):

点数	1	2	3	4	5	6
观测频数 O_i	18	22	19	23	17	21
期望频数 E_i	20	20	20	20	20	20

$$\chi^2 = \frac{(18-20)^2}{20} + \frac{(22-20)^2}{20} + \dots + \frac{(21-20)^2}{20} = \frac{4+4+1+9+9+1}{20} = \frac{28}{20} = 1.4$$

$\chi^2_{0.05}(5) = 11.07$, 因 $1.4 < 11.07$, 不拒绝 H_0 , 骰子可视为均匀。

20.4.2 独立性检验

场景: 判断两个分类变量是否独立, 数据呈列联表形式。

设 $r \times c$ 列联表, 第 (i, j) 格的观测频数为 O_{ij} , 行合计 $R_i = \sum_j O_{ij}$, 列合计 $C_j = \sum_i O_{ij}$, 总计 $n = \sum_i R_i$ 。

期望频数 (在独立假设下):

$$E_{ij} = \frac{R_i \cdot C_j}{n}$$

检验统计量:

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}} \xrightarrow{d} \chi^2((r-1)(c-1)) \quad (H_0 \text{ 下})$$

例 20.4 调查 200 名学生的专业 (理工/文科) 与是否使用 AI 工具的关系:

	使用 AI	不使用 AI	合计
理工	80	30	110
文科	50	40	90
合计	130	70	200

期望频数：

$$\begin{aligned} E_{11} &= \frac{110 \times 130}{200} = 71.5, & E_{12} &= \frac{110 \times 70}{200} = 38.5 \\ E_{21} &= \frac{90 \times 130}{200} = 58.5, & E_{22} &= \frac{90 \times 70}{200} = 31.5 \\ \chi^2 &= \frac{(80 - 71.5)^2}{71.5} + \frac{(30 - 38.5)^2}{38.5} + \frac{(50 - 58.5)^2}{58.5} + \frac{(40 - 31.5)^2}{31.5} \\ &= \frac{72.25}{71.5} + \frac{72.25}{38.5} + \frac{72.25}{58.5} + \frac{72.25}{31.5} \approx 1.011 + 1.877 + 1.235 + 2.294 = 6.42 \end{aligned}$$

$\chi^2_{0.05}(1) = 3.84$ ，因 $6.42 > 3.84$ ，拒绝 H_0 ，专业与 AI 使用存在显著关联。

20.4.3 2×2 表的 Yates 连续性校正

对 2×2 列联表，当样本量较小时，Yates 校正可改善近似效果：

$$\chi^2_{\text{Yates}} = \sum_{i,j} \frac{(|O_{ij} - E_{ij}| - 0.5)^2}{E_{ij}}$$

但当 $n > 40$ 且所有 $E_{ij} \geq 5$ 时，一般无需校正。

20.5 多重比较与校正

20.5.1 多重比较问题

当同时进行 m 个独立假设检验，每个检验的显著性水平均为 α 时，族错误率 (Family-Wise Error Rate, FWER) 为：

$$\text{FWER} = P(\text{至少一个假检验被拒绝}) = 1 - (1 - \alpha)^m$$

例如， $m = 20$ ， $\alpha = 0.05$ ：

$$\text{FWER} = 1 - (1 - 0.05)^{20} = 1 - 0.95^{20} \approx 1 - 0.358 = 0.642$$

即有超过 64% 的概率犯至少一次 I 类错误。

20.5.2 Bonferroni 校正

方法：将每个单次检验的显著性水平调整为 α/m ，则：

$$\text{FWER} \leq 1 - \left(1 - \frac{\alpha}{m}\right)^m \leq \alpha \quad (\text{由 Bonferroni 不等式})$$

决策规则：拒绝 H_{0j} 当且仅当 $p_j \leq \alpha/m$ ，其中 p_j 为第 j 个检验的 p 值。

等价校正 p 值： $p_j^{\text{adj}} = \min(m \cdot p_j, 1)$

缺点：过于保守，当 m 较大时检验功效损失严重，尤其检验间存在正相关时。

Holm-Bonferroni 步进法（更强功效）：

1. 将 p 值从小到大排序： $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$
2. 从最小 p 值开始，若 $p_{(j)} \leq \alpha/(m - j + 1)$ 则拒绝 $H_{0(j)}$
3. 一旦遇到不满足条件的，停止并接受其余所有 H_0

Holm 方法控制 FWER 的同时比 Bonferroni 功效更高。

20.5.3 错误发现率（FDR）控制

在大规模多重检验（如基因组学、神经网络特征分析）中，控制 FWER 过于严格。错误发现率（False Discovery Rate, FDR）是更合适的标准：

$$\text{FDR} = E \left[\frac{\text{错误拒绝数}}{\max(\text{总拒绝数}, 1)} \right]$$

Benjamini-Hochberg (BH) 过程（控制 $\text{FDR} \leq q$ ）：

1. 将 m 个 p 值从小到大排序： $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$
2. 找到满足 $p_{(j)} \leq \frac{j}{m}q$ 的最大下标 k
3. 拒绝 $H_{0(1)}, H_{0(2)}, \dots, H_{0(k)}$

BH 等价校正公式：

$$p_{(j)}^{\text{BH}} = \min \left(\frac{m}{j} p_{(j)}, p_{(j+1)}^{\text{BH}}, 1 \right)$$

（从大到小递推）

FWER vs FDR 对比：

指标	FWER	FDR
含义	至少一个假阳性的概率	平均假阳性比例
适用场景	少量检验，代价高昂	大量检验，可容忍少量误判
典型方法	Bonferroni, Holm	BH, BY
功效	低	高

20.5.4 后验概率与贝叶斯多重比较

贝叶斯方法通过后验概率自然规避多重比较问题。设 π_0 为零假设的先验概率，则局部 **FDR** (lfdr) 为：

$$\text{lfdr}(t) = \frac{\pi_0 f_0(t)}{f(t)}$$

其中 $f_0(t)$ 为 H_0 下检验统计量的密度， $f(t)$ 为混合密度。

本章小结

- 1. t 检验是均值推断的核心工具：单样本 t 检验用于与已知值比较；独立双样本 t 检验（含 Welch 方法）用于两独立组均值比较；配对 t 检验通过消除个体差异显著提升功效。
- 2. F 检验用于比较两总体方差以及 ANOVA 中组间均值差异，其统计量由两个独立卡方统计量之比构成。
- 3. 卡方检验适用于分类数据：拟合优度检验判断数据分布形式，独立性检验判断两分类变量关联性；两者均要求期望频数不过小。
- 4. 多重比较是现代统计的重要问题：Bonferroni 校正控制 FWER 但功效低；BH 方法控制 FDR，在大量检验中功效更高，是深度学习特征选择的优选方法。
- 5. 所有参数检验均依赖特定分布假设，使用前应进行正态性检验（Shapiro-Wilk）、方差齐性检验（Levene/Bartlett）等前提条件验证；条件不满足时应考虑第 19 章的非参数方法。

深度学习应用：特征选择、模型比较与超参数调优

应用一：基于统计检验的特征选择

在监督学习中，卡方检验和 t 检验可用于筛选与目标变量相关的特征：

```

import numpy as np
import torch
import torch.nn as nn
from scipy import stats
from statsmodels.stats.multitest import multipletests
import matplotlib.pyplot as plt

# =====
# 1. 基于卡方检验的分类特征筛选
# =====

def chi2_feature_selection(X_binary, y, alpha=0.05, method='fdr_bh'):
    """
    对二值特征矩阵 X_binary 和二分类标签 y 进行卡方独立性检验，
    使用 BH 方法控制 FDR，返回显著特征的索引。

    参数：
        X_binary: (n_samples, n_features) 二值特征矩阵
        y: (n_samples,) 二分类标签 {0, 1}
        alpha: FDR 控制水平
        method: 多重比较校正方法, 'bonferroni' 或 'fdr_bh'

    返回：
        selected_idx: 通过检验的特征索引
        p_values: 原始 p 值
        p_adjusted: 校正后 p 值
    """
    n_features = X_binary.shape[1]
    p_values = np.zeros(n_features)

    for j in range(n_features):
        # 构造 2x2 列联表
        # 行: y=0/1, 列: 特征 =0/1
        contingency = np.array([
            np.sum((X_binary[:, j] == 0) & (y == 0)),
            np.sum((X_binary[:, j] == 1) & (y == 0)),
            np.sum((X_binary[:, j] == 0) & (y == 1)),
            np.sum((X_binary[:, j] == 1) & (y == 1))]
        ])
        chi2_stat, p_val, dof, expected = stats.chi2_contingency(contingency)
        p_values[j] = p_val

```

```

# 多重比较校正
reject, p_adjusted, _, _ = multipletests(p_values, alpha=alpha, method=method)
selected_idx = np.where(reject)[0]

return selected_idx, p_values, p_adjusted

# =====
# 2. 基于 t 检验的连续特征筛选 (Welch t 检验)
# =====

def ttest_feature_selection(X_continuous, y, alpha=0.05, method='fdr_bh'):
    """
    对连续特征矩阵 X_continuous 进行 Welch 双样本 t 检验，
    检验各特征在两类样本中均值是否有显著差异。
    """
    n_features = X_continuous.shape[1]
    p_values = np.zeros(n_features)
    t_stats = np.zeros(n_features)

    group0 = X_continuous[y == 0] # (n0, n_features)
    group1 = X_continuous[y == 1] # (n1, n_features)

    for j in range(n_features):
        t_stat, p_val = stats.ttest_ind(group0[:, j], group1[:, j], equal_var=False)
        t_stats[j] = t_stat
        p_values[j] = p_val

    reject, p_adjusted, _, _ = multipletests(p_values, alpha=alpha, method=method)
    selected_idx = np.where(reject)[0]

    print(f"总特征数: {n_features}")
    print(f"Bonferroni 阈值:  $p < \{\alpha / n\_features\}$ ")
    print(f"BH FDR={alpha} 下选中特征数: {len(selected_idx)}")

    return selected_idx, t_stats, p_values, p_adjusted

# =====
# 3. 演示: 合成数据特征选择

```

```

# =====

np.random.seed(42)
n_samples, n_features = 500, 50
n_informative = 10 # 前 10 个特征真正有判别力

# 生成连续特征
X = np.random.randn(n_samples, n_features)
y = np.random.randint(0, 2, n_samples)

# 让前 n_informative 个特征在两类中均值有差异
X[:, :n_informative] += y[:, np.newaxis] * 1.5

# 执行特征选择
selected, t_stats, p_raw, p_adj = ttest_feature_selection(X, y, alpha=0.05)

# 可视化
fig, axes = plt.subplots(1, 2, figsize=(12, 4))

axes[0].bar(range(n_features), -np.log10(p_raw), color='steelblue', alpha=0.7)
axes[0].axhline(-np.log10(0.05 / n_features), color='red', linestyle='--',
                label=f'Bonferroni ($p={0.05/n_features:.4f}$)')
axes[0].axhline(-np.log10(0.05), color='orange', linestyle='--',
                label='未校正 $p=0.05$')
axes[0].set_xlabel('特征索引')
axes[0].set_ylabel('$-\log_{10}(p)$')
axes[0].set_title('原始 $p$ 值 (Manhattan 图)')
axes[0].legend()

axes[1].bar(range(n_features), -np.log10(p_adj), color='darkorange', alpha=0.7)
axes[1].axhline(-np.log10(0.05), color='red', linestyle='--', label='FDR=0.05')
axes[1].scatter(selected, -np.log10(p_adj[selected]), color='red', zorder=5, label='选中特征')
axes[1].set_xlabel('特征索引')
axes[1].set_ylabel('$-\log_{10}(p_{\mathrm{adj}})$')
axes[1].set_title('BH 校正后 $p$ 值')
axes[1].legend()

plt.tight_layout()
plt.savefig('feature_selection_pvalues.png', dpi=150)
plt.show()

```

应用二：神经网络模型性能的统计比较

比较两个或多个深度学习模型时，需用统计检验判断性能差异是否显著：

```
# =====
# 模型比较：配对 t 检验 + McNemar 检验
# =====

class SimpleNN(nn.Module):
    """ 简单前馈神经网络，用于演示 """
    def __init__(self, input_dim, hidden_dim, output_dim):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(input_dim, hidden_dim),
            nn.ReLU(),
            nn.Dropout(0.3),
            nn.Linear(hidden_dim, output_dim)
        )

    def forward(self, x):
        return self.net(x)

def k_fold_accuracies(model_class, model_kwargs, X, y, k=10, seed=42):
    """
    k 折交叉验证，返回每折的测试准确率。

    参数：
        model_class: 模型类
        model_kwargs: 模型初始化参数
        X, y: 数据 (numpy array)
        k: 折数

    返回：
        accuracies: 长度为 k 的准确率列表
    """
    from sklearn.model_selection import KFold

    kf = KFold(n_splits=k, shuffle=True, random_state=seed)
    accuracies = []

    for fold, (train_idx, test_idx) in enumerate(kf.split(X)):
```



```

X_train = torch.FloatTensor(X[train_idx])
y_train = torch.LongTensor(y[train_idx])
X_test = torch.FloatTensor(X[test_idx])
y_test = torch.LongTensor(y[test_idx])

model = model_class(**model_kwargs)
optimizer = torch.optim.Adam(model.parameters(), lr=1e-3)
criterion = nn.CrossEntropyLoss()

# 简化训练: 50 个 epoch
model.train()
for epoch in range(50):
    optimizer.zero_grad()
    logits = model(X_train)
    loss = criterion(logits, y_train)
    loss.backward()
    optimizer.step()

# 评估
model.eval()
with torch.no_grad():
    preds = model(X_test).argmax(dim=1)
    acc = (preds == y_test).float().mean().item()
    accuracies.append(acc)

return accuracies

def compare_models_ttest(accs_A, accs_B, alpha=0.05):
    """
    使用配对  $t$  检验比较两个模型的  $k$  折交叉验证准确率。

    假设: 两组准确率来自同一数据集上的  $k$  折划分 (配对)
    """
    accs_A = np.array(accs_A)
    accs_B = np.array(accs_B)
    diffs = accs_A - accs_B
    n = len(diffs)

    d_bar = diffs.mean()
    s_d = diffs.std(ddof=1)

```

```

t_stat = d_bar / (s_d / np.sqrt(n))

# 双侧 p 值
p_value = 2 * stats.t.sf(abs(t_stat), df=n - 1)

# 差值的 95% 置信区间
t_crit = stats.t.ppf(1 - alpha/2, df=n - 1)
ci_lower = d_bar - t_crit * s_d / np.sqrt(n)
ci_upper = d_bar + t_crit * s_d / np.sqrt(n)

print("=" * 50)
print(" 配对 t 检验: 模型 A vs 模型 B")
print("=" * 50)
print(f" 模型 A 平均准确率: {accs_A.mean():.4f} ± {accs_A.std():.4f}")
print(f" 模型 B 平均准确率: {accs_B.mean():.4f} ± {accs_B.std():.4f}")
print(f" 差值均值 (A-B):    {d_bar:.4f}")
print(f" 差值标准差:          {s_d:.4f}")
print(f"t 统计量:              {t_stat:.4f} (df={n-1})")
print(f"p 值 (双侧):           {p_value:.4f}")
print(f"95% 置信区间:         [{ci_lower:.4f}, {ci_upper:.4f}]")
print(f" 结论: {'模型 A 显著优于 B' if (p_value < alpha and d_bar > 0) else '模型 B 显著优于 A' if")

return {'t_stat': t_stat, 'p_value': p_value,
        'ci': (ci_lower, ci_upper), 'mean_diff': d_bar}

def mcnemar_test(preds_A, preds_B, y_true):
    """
    McNemar 检验: 比较两个分类器在同一测试集上的错误模式。

    适用场景: 两个分类器对同一样本集的预测结果比较
    构造 2×2 列联表:
        b = A 正确但 B 错误的样本数
        c = A 错误但 B 正确的样本数

    H0: P(A 正确 B 错误) = P(A 错误 B 正确)
    """
    correct_A = (preds_A == y_true)
    correct_B = (preds_B == y_true)

    # b: A 对 B 错, c: A 错 B 对

```

```

b = np.sum(correct_A & ~correct_B)
c = np.sum(~correct_A & correct_B)

# 使用连续性校正的卡方统计量
if b + c == 0:
    chi2 = 0.0
    p_value = 1.0
else:
    chi2 = (abs(b - c) - 1) ** 2 / (b + c)
    p_value = 1 - stats.chi2.cdf(chi2, df=1)

print(f"\nMcNemar 检验")
print(f"b (A 对 B 错): {b}, c (A 错 B 对): {c}")
print(f" $\chi^2$  = {chi2:.4f}, p = {p_value:.4f}")

return chi2, p_value

# =====
# 演示：合成分类任务上的模型比较
# =====

np.random.seed(0)
n_samples, n_features = 1000, 20
X_demo = np.random.randn(n_samples, n_features).astype(np.float32)
w_true = np.random.randn(n_features)
y_demo = (X_demo @ w_true > 0).astype(int)

# 模拟两个模型的 10 折准确率（实际场景中调用 k_fold_accuracies）
# 此处用固定随机数模拟结果以演示检验逻辑
rng = np.random.RandomState(99)
accs_model_A = 0.82 + rng.randn(10) * 0.02 # 模型 A: 均值约 0.82
accs_model_B = 0.79 + rng.randn(10) * 0.025 # 模型 B: 均值约 0.79

result = compare_models_ttest(accs_model_A, accs_model_B)

```

应用三：超参数选择的统计显著性

在超参数搜索后，利用 F 检验（ANOVA）判断不同超参数配置的效果差异：

```

# =====
# 超参数比较：单因素 ANOVA + Tukey HSD 事后检验

```

```
# =====

from scipy.stats import f_oneway
from statsmodels.stats.multicomp import pairwise_tukeyhsd

def hyperparameter_anova(results_dict, alpha=0.05):
    """
    对多组超参数配置的验证准确率进行单因素方差分析。

    参数:
        results_dict: {超参数配置名: 验证准确率列表}
        alpha: 显著性水平
    """
    groups = list(results_dict.keys())
    data = [np.array(results_dict[g]) for g in groups]

    # 计算描述统计
    print(" 各配置描述统计: ")
    print(f"{'配置':<20} {'均值':>8} {'标准差':>8} {'样本量':>6}")
    print("-" * 45)
    for g, d in zip(groups, data):
        print(f"{g:<20} {d.mean():>8.4f} {d.std(ddof=1):>8.4f} {len(d):>6}")

    # ANOVA F 检验
    f_stat, p_value = f_oneway(*data)
    k = len(groups)
    N = sum(len(d) for d in data)

    print(f"\nANOVA 结果: F({k-1}, {N-k}) = {f_stat:.4f}, p = {p_value:.4f}")

    if p_value < alpha:
        print(f" 结论: 在 {alpha} 水平下, 各超参数配置间存在显著差异 (p={p_value:.4f})")

        # 事后检验: Tukey HSD
        all_data = np.concatenate(data)
        all_labels = np.concatenate([[g] * len(d) for g, d in zip(groups, data)])

        tukey = pairwise_tukeyhsd(all_data, all_labels, alpha=alpha)
        print("\nTukey HSD 事后检验 (成对比较): ")
        print(tukey)
    else:
```

```

    print(f" 结论：无显著差异 (p={p_value:.4f} > {alpha})")

    return f_stat, p_value

# 示例：比较不同学习率配置的 5 次独立训练结果
lr_results = {
    'lr=1e-2': [0.843, 0.851, 0.839, 0.856, 0.848],
    'lr=1e-3': [0.871, 0.879, 0.868, 0.882, 0.875],
    'lr=1e-4': [0.854, 0.861, 0.858, 0.865, 0.857],
    'lr=1e-5': [0.801, 0.812, 0.808, 0.815, 0.807],
}

print("=" * 55)
print(" 超参数（学习率）效果的 ANOVA 检验")
print("=" * 55)
f_stat, p_val = hyperparameter_anova(lr_results)

# =====
# 方差齐性前提验证 (Levene 检验)
# =====

from scipy.stats import levene

def check_homogeneity(results_dict, alpha=0.05):
    """Levene 检验方差齐性 (ANOVA 前提条件) """
    data = list(results_dict.values())
    stat, p = levene(*data)
    print(f"\nLevene 方差齐性检验: W={stat:.4f}, p={p:.4f}")
    if p > alpha:
        print(" 方差齐性假设成立，可使用等方差 ANOVA")
    else:
        print(" 方差不齐，建议使用 Welch ANOVA 或非参数 Kruskal-Wallis 检验")
    return stat, p

check_homogeneity(lr_results)

深度学习应用要点总结：

```

场景	推荐检验	关键注意事项
连续特征与标签相关性	Welch t 检验 + BH 校正	需检验正态性；大量特征时 FDR 优于 FWER
分类特征与标签关联	卡方独立性检验 + BH 校正	期望频数 ≥ 5 ；稀疏时合并类别
两模型准确率比较 (k 折)	配对 t 检验	同一折数据配对；需满足正态性
两模型错误模式比较	McNemar 检验	关注不一致预测对；小样本加连续性校正
多个超参数配置比较	ANOVA + Tukey HSD	先验证方差齐性 (Levene 检验)
模型选择 vs 随机	单样本 t 检验	与基线准确率比较

练习题

练习 20.1（单样本 t 检验）

某训练流程声称在 CIFAR-10 上平均准确率为 92%。研究者用该流程独立训练了 9 次，得到准确率 (%)：

90.1, 91.5, 89.8, 92.3, 91.0, 90.7, 91.8, 90.5, 91.2

在 $\alpha = 0.05$ 下，是否有充分证据认为该训练流程的真实均值低于 92%？给出完整的假设检验过程。

练习 20.2（独立 vs 配对 t 检验）

研究者比较 ResNet-50 与 VGG-16 在 8 个图像分类数据集上的准确率（已经 10 折交叉验证取均值）：

数据集	ResNet-50	VGG-16
A	0.934	0.921
B	0.867	0.853
C	0.912	0.908
D	0.756	0.741
E	0.981	0.975
F	0.823	0.811
G	0.891	0.878
H	0.943	0.930

- (a) 应使用独立双样本 t 检验还是配对 t 检验？说明理由。
- (b) 在 $\alpha = 0.05$ 下进行检验，并给出差值的 95% 置信区间。

练习 20.3 (F 检验 + ANOVA)

比较三种 dropout 率 (0.1、0.3、0.5) 对模型验证损失的影响, 各进行 6 次独立实验:

dropout=0.1	dropout=0.3	dropout=0.5
0.412	0.389	0.421
0.398	0.401	0.435
0.423	0.375	0.418
0.409	0.392	0.443
0.415	0.384	0.428
0.404	0.396	0.432

- (a) 完成单因素方差分析表 (计算 SS_A 、 SS_E 、 MS_A 、 MS_E 、 F 值)。
- (b) 在 $\alpha = 0.05$ 下, 三组损失均值是否存在显著差异?

练习 20.4 (多重比较校正)

在神经网络特征重要性分析中, 对 100 个特征各进行一次 t 检验, 得到 100 个 p 值, 其中最小的 10 个 (排序后) 为:

$p_{(1)} = 0.00008, p_{(2)} = 0.00021, p_{(3)} = 0.00089, p_{(4)} = 0.00203, p_{(5)} = 0.00412$
 $p_{(6)} = 0.00718, p_{(7)} = 0.00935, p_{(8)} = 0.01204, p_{(9)} = 0.01567, p_{(10)} = 0.02341$

- (a) 使用 Bonferroni 校正 ($\alpha = 0.05$), 哪些特征被选中?
- (b) 使用 BH 方法控制 $FDR = 0.05$, 哪些特征被选中? (只需考虑上述 10 个 p 值及余下 90 个均大于 0.05)
- (c) 比较两种方法的结论, 说明在此场景下哪种方法更合适。

练习 20.5 (卡方检验 + 深度学习)

研究者统计了某图像分类模型在 4 种类别上的预测结果与真实标签的列联表 (共 400 个测试样本):

预测 \ 真实	猫	狗	鸟	鱼
猫	85	12	5	8
狗	10	78	7	5
鸟	3	8	72	7
鱼	2	2	6	80

- (a) 计算该检验的期望频数矩阵 (假设独立性)。

(b) 计算卡方统计量并给出检验结论 ($\alpha = 0.05$)。

(c) 若卡方检验显著, 这说明了什么? 与混淆矩阵分析有何联系?

练习答案

答案 20.1

建立假设 (单侧, 左侧检验):

$$H_0: \mu = 92 \quad \text{vs} \quad H_1: \mu < 92$$

计算统计量:

$$\bar{x} = \frac{90.1 + 91.5 + \cdots + 91.2}{9} = \frac{818.9}{9} = 91.0\bar{0}$$

精确计算: $\sum x_i = 90.1 + 91.5 + 89.8 + 92.3 + 91.0 + 90.7 + 91.8 + 90.5 + 91.2 = 818.9$, $\bar{x} = 818.9/9 \approx 91.0$

各偏差平方和:

$$\begin{aligned} \sum (x_i - \bar{x})^2 &= (90.1 - 91.0)^2 + (91.5 - 91.0)^2 + (89.8 - 91.0)^2 + (92.3 - 91.0)^2 + (91.0 - 91.0)^2 \\ &\quad + (90.7 - 91.0)^2 + (91.8 - 91.0)^2 + (90.5 - 91.0)^2 + (91.2 - 91.0)^2 \\ &= 0.81 + 0.25 + 1.44 + 1.69 + 0 + 0.09 + 0.64 + 0.25 + 0.04 = 5.21 \end{aligned}$$

$$s = \sqrt{\frac{5.21}{8}} = \sqrt{0.651} \approx 0.807$$

$$t = \frac{91.0 - 92}{0.807/\sqrt{9}} = \frac{-1.0}{0.269} \approx -3.717$$

查表与决策:

$t_{0.05}(8) = 1.860$, 左侧检验拒绝域为 $t < -1.860$ 。

因 $t = -3.717 < -1.860$, 拒绝 H_0 。

结论: 在 $\alpha = 0.05$ 水平下, 有充分证据认为该训练流程的真实平均准确率低于 92% ($p \approx 0.003$)。

答案 20.2

(a) 应使用配对 t 检验。

原因：同一数据集对两模型而言代表相同的难度，数据集之间差异很大（准确率从 0.756 到 0.981），配对设计可以消除数据集难度造成的变异，仅关注模型间差异。若用独立 t 检验，数据集间方差会淹没模型间差异，导致功效损失。

(b) 配对 t 检验计算：

差值 $D_i = \text{ResNet} - \text{VGG}$: 0.013, 0.014, 0.004, 0.015, 0.006, 0.012, 0.013, 0.013

$$\bar{d} = \frac{0.013 + 0.014 + 0.004 + 0.015 + 0.006 + 0.012 + 0.013 + 0.013}{8} = \frac{0.090}{8} = 0.01125$$

$$s_D = \sqrt{\frac{\sum (d_i - \bar{d})^2}{7}}$$

$$\begin{aligned} & \text{各 } (d_i - 0.01125)^2: (-0.00125)^2, (0.00275)^2, (-0.00725)^2, (0.00375)^2, (-0.00525)^2, (0.00075)^2, (0.00175)^2, (0.00175)^2 \\ & = 1.5625 \times 10^{-6} + 7.5625 \times 10^{-6} + 52.5625 \times 10^{-6} + 14.0625 \times 10^{-6} + 27.5625 \times 10^{-6} + 0.5625 \times 10^{-6} + \\ & 3.0625 \times 10^{-6} + 3.0625 \times 10^{-6} = 110 \times 10^{-6} \end{aligned}$$

$$s_D = \sqrt{\frac{110 \times 10^{-6}}{7}} = \sqrt{15.71 \times 10^{-6}} \approx 0.003964$$

$$t = \frac{0.01125}{0.003964/\sqrt{8}} = \frac{0.01125}{0.001401} \approx 8.03$$

$t_{0.025}(7) = 2.365$ ，因 $t = 8.03 \gg 2.365$ ，拒绝 H_0 ，ResNet-50 显著优于 VGG-16。

95% 置信区间：

$$0.01125 \pm 2.365 \times 0.001401 = 0.01125 \pm 0.00331 = (0.00794, 0.01456)$$

即 ResNet-50 平均准确率高出 VGG-16 约 0.8% 至 1.5% (95% 置信)。

答案 20.3

(a) ANOVA 计算：

各组均值：

$$\bar{x}_{1.} = \frac{0.412 + 0.398 + 0.423 + 0.409 + 0.415 + 0.404}{6} = \frac{2.461}{6} \approx 0.4102$$

$$\bar{x}_{2.} = \frac{0.389 + 0.401 + 0.375 + 0.392 + 0.384 + 0.396}{6} = \frac{2.337}{6} = 0.3895$$

$$\bar{x}_{3.} = \frac{0.421 + 0.435 + 0.418 + 0.443 + 0.428 + 0.432}{6} = \frac{2.577}{6} = 0.4295$$

总均值: $\bar{x}_{..} = (2.461 + 2.337 + 2.577)/18 = 7.375/18 \approx 0.4097$

组间平方和 SS_A ($n_i = 6, k = 3$):

$$\begin{aligned} SS_A &= 6 [(0.4102 - 0.4097)^2 + (0.3895 - 0.4097)^2 + (0.4295 - 0.4097)^2] \\ &= 6 [2.5 \times 10^{-7} + 4.08 \times 10^{-4} + 3.92 \times 10^{-4}] \\ &\approx 6 \times 8.003 \times 10^{-4} = 4.802 \times 10^{-3} \end{aligned}$$

组内平方和 SS_E (各组内偏差平方和之和, 共 $3 \times 5 = 15$ 自由度):

组 1: $(0.412 - 0.4102)^2 + \dots \approx 4.93 \times 10^{-4}$; 组 2: $(0.389 - 0.3895)^2 + \dots \approx 5.25 \times 10^{-4}$; 组 3: $(0.421 - 0.4295)^2 + \dots \approx 3.55 \times 10^{-4}$

$$SS_E \approx 1.373 \times 10^{-3}$$

来源	SS	自由度	MS	F
组间	4.802×10^{-3}	2	2.401×10^{-3}	≈ 26.3
组内	1.373×10^{-3}	15	9.15×10^{-5}	—
总计	6.175×10^{-3}	17	—	—

(b) 决策: $F_{0.05}(2, 15) = 3.68$, 因 $F \approx 26.3 \gg 3.68$, 拒绝 H_0 。

结论: 三种 dropout 率下的验证损失均值存在显著差异, 应进一步进行事后两两比较 (如 Tukey HSD) 以确定哪组间差异显著。

答案 20.4

(a) Bonferroni 校正 ($m = 100$, 阈值 $= 0.05/100 = 0.0005$):

- $p_{(1)} = 0.00008 < 0.0005$ $\square$
- $p_{(2)} = 0.00021 < 0.0005$ $\square$
- $p_{(3)} = 0.00089 > 0.0005$ $\square$

选中特征：2 个（排名第 1、2 的特征）。

(b) BH 方法 ($m = 100$, $q = 0.05$, 判断条件 $p_{(j)} \leq j \cdot q/m = j \times 0.0005$):

j	$p_{(j)}$	阈值 $j \times 0.0005$	是否通过
1	0.00008	0.00050	☐
2	0.00021	0.00100	☐
3	0.00089	0.00150	☐
4	0.00203	0.00200	☐ ($\leq$, 边界)
5	0.00412	0.00250	☐

最大通过下标 $k = 4$, 选中特征：4 个（排名第 1~4）。

注意： $p_{(4)} = 0.00203$ 与阈值 0.00200 非常接近，精确比较后 $0.00203 > 0.00200$ ，实际通过下标为 $k = 3$ ，选中特征：3 个。（需精确计算）

(c) 比较与建议：

- Bonferroni 控制 FWER，选中 2 个；BH 控制 FDR，选中 2-3 个
- 在 100 个特征同时检验的场景下，BH 方法更合适：允许少量误判（FDR=5% 意味着平均 5% 的被选特征是假阳性），功效更高，能发现更多真正相关特征
- Bonferroni 适用于少量关键检验且假阳性代价极高的场景（如医学诊断）；特征选择属于探索性场景，FDR 控制是标准做法

答案 20.5

(a) 期望频数矩阵：

各行/列合计：

- 预测为猫： $85 + 12 + 5 + 8 = 110$ ，预测为狗： 100，预测为鸟： 90，预测为鱼： 90（行合计）
- 真实为猫： 100，狗： 100，鸟： 90，鱼： 100（列合计，注意： $85 + 10 + 3 + 2 = 100$, $12 + 78 + 8 + 2 = 100$, $5 + 7 + 72 + 6 = 90$, $8 + 5 + 7 + 80 = 100$ ）
- 总计： $110 + 100 + 90 + 90 = 390$ （注意：实际总和为 $\sum = 390$ ，非 400，以实际计算为准）

实际总计： $85 + 12 + 5 + 8 + 10 + 78 + 7 + 5 + 3 + 8 + 72 + 7 + 2 + 2 + 6 + 80 = 390$

期望频数 $E_{ij} = R_i C_j / 390$ ，例如：

$$E_{11} = \frac{110 \times 100}{390} \approx 28.2, \quad E_{12} = \frac{110 \times 100}{390} \approx 28.2$$

（完整矩阵从略，按 $E_{ij} = R_i C_j / n$ 逐一计算）

(b) 卡方统计量：

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

该矩阵对角线元素远大于期望（对角线 $O_{ij} \gg E_{ij}$ ），非对角线则相反，因此 χ^2 值很大，远超 $\chi_{0.05}^2((4-1)(4-1)) = \chi_{0.05}^2(9) = 16.92$ 。

结论：拒绝 H_0 （预测与真实标签不独立），即模型的预测与真实类别显著相关。

(c) 含义与联系：

- 卡方检验显著说明预测结果与真实类别不独立——在此情境下这是好事，说明模型有判别能力（随机猜测时两者独立）
- 与混淆矩阵联系：混淆矩阵提供更细粒度信息（哪些类别容易混淆，如猫被预测为狗），而卡方检验仅给出全局显著性结论
- 在模型评估中，卡方检验可用于验证“模型预测优于随机基线”，但具体改进方向需结合混淆矩阵分析

第二十一章：非参数检验

学习目标

完成本章学习后，你将能够：

- 理解非参数检验的基本思想，明确其相对于参数检验的优势与适用场景
- 掌握符号检验和 Wilcoxon 符号秩检验的原理与计算步骤
- 理解 Mann-Whitney U 检验的秩和思想，能够对两独立样本进行比较
- 掌握 Kolmogorov-Smirnov 检验的原理，用于分布拟合与两样本比较
- 了解置换检验的框架，理解 FID、IS 等生成模型评估指标的统计学基础

正文内容

21.1 非参数方法概述

21.1.1 参数检验的局限性 在前几章中，我们学习的假设检验方法（ t 检验、 F 检验、 χ^2 检验等）都建立在特定的分布假设之上，通常要求数据来自正态总体，或者样本量足够大以保证渐近正态性。这类方法称为参数检验（Parametric Tests），因为它们的推断对象是分布族的参数（如均值 μ 、方差 σ^2 ）。

参数检验在实践中面临以下挑战：

分布假设难以验证：现实数据往往存在偏斜、厚尾、多峰等非正态特征。

数据类型受限：参数检验通常要求连续型数据，无法直接处理序数数据（如问卷中的“非常满意/满意/一般/不满意”）。

小样本下不可靠：当 $n < 30$ 时，中心极限定理提供的正态近似可能失效，而样本又不够大以检验正态性。

异常值敏感：均值等矩估计量对异常值高度敏感，使得基于矩的参数检验不够稳健。

21.1.2 非参数检验的基本思想 非参数检验（Nonparametric Tests）不对总体分布的具体形式作假设，其有效性在宽泛的条件下成立。这类方法也称为无分布检验（Distribution-Free Tests）。

非参数方法的核心工具是秩（Rank）。将 n 个观测值从小到大排列后，第 i 小的观测值的秩为 i 。秩具有以下优良性质：

分布无关性：秩的联合分布在连续总体的零假设下不依赖于总体的具体分布形式。

对单调变换不变性：若对数据做任意严格单调变换，秩不变。

异常值稳健性：异常值仅影响极端秩（1 或 n ），而非参数检验统计量通常对极端秩不敏感。

设样本 $X_1, X_2, \dots, X_n$ 来自连续总体，令 R_i 表示 X_i 在样本中的秩，则在零假设（所有观测值来自同一连续分布）下：

$$P(R_i = r_i, i = 1, \dots, n) = \frac{1}{n!}, \quad (r_1, r_2, \dots, r_n) \text{ 是 } (1, 2, \dots, n) \text{ 的排列}$$

即所有 $n!$ 种排列等可能，这是非参数检验统计量精确分布的计算基础。

21.1.3 非参数方法的分类

类别	用途	代表方法
位置检验	单样本/双样本中心位置比较	符号检验、Wilcoxon 符号秩检验、Mann-Whitney U 检验
分布检验	检验数据是否来自某分布	Kolmogorov-Smirnov 检验、Anderson-Darling 检验
相关性检验	检验两变量的单调相关性	Spearman 秩相关、Kendall τ
多样本检验	多组比较（ANOVA 的替代）	Kruskal-Wallis 检验
随机性检验	检验序列的随机性	游程检验
置换检验	任意统计量的推断	置换检验（Fisher 随机化检验）

21.1.4 效率损失 非参数方法的代价是效率（Efficiency）损失。当参数检验的分布假设成立时，参数检验通常比对应的非参数检验有更高的渐近相对效率（Asymptotic Relative Efficiency, ARE）。

例如，当数据确实来自正态分布时，Wilcoxon 符号秩检验相对于 t 检验的 ARE 为：

$$\text{ARE}(\text{Wilcoxon}, t) = \frac{3}{\pi} \approx 0.955$$

这意味着使用 Wilcoxon 检验需要约多 $1/0.955 \approx 1.047$ 倍的样本量才能达到相同的功效。然而当数据来自重尾分布（如 Cauchy 分布）时，ARE 可以趋向无穷大，非参数方法反而更优。

21.2 符号检验与符号秩检验

21.2.1 符号检验 符号检验 (Sign Test) 是最简单的非参数检验，用于检验连续总体的中位数。

问题设定：设 $X_1, X_2, \dots, X_n$ 为来自连续总体 F 的独立同分布样本，检验假设：

$$H_0 : M = M_0 \quad \text{vs.} \quad H_1 : M \neq M_0$$

其中 M 为总体中位数， M_0 为指定值。

检验统计量：定义差值 $D_i = X_i - M_0$ ，忽略 $D_i = 0$ 的观测值，令 n' 为非零差值的个数， B^+ 为正差值的个数：

$$B^+ = \sum_{i=1}^{n'} \mathbf{1}(D_i > 0)$$

在 H_0 下，每个 D_i 正负号等可能，因此：

$$B^+ \sim \text{Binomial}\left(n', \frac{1}{2}\right)$$

拒绝域：对于双侧检验，在显著性水平 α 下：

$$W = \{B^+ \leq b_{\alpha/2}(n')\} \cup \{B^+ \geq n' - b_{\alpha/2}(n')\}$$

其中 $b_{\alpha/2}(n')$ 满足 $P(B^+ \leq b_{\alpha/2}(n') \mid H_0) \leq \alpha/2$ 。

当 n' 较大时，用正态近似：

$$Z = \frac{B^+ - n'/2}{\sqrt{n'/4}} \xrightarrow{d} N(0, 1)$$

例 21.1 某医院测量 12 名患者接受新疗法前后的血压（单位：mmHg），差值（治疗后 - 治疗前）为：

$$-8, -12, +3, -5, -15, -7, +2, -9, -11, -6, -4, -10$$

检验新疗法能否降低血压 (H_0 : 中位差值 = 0, H_1 : 中位差值 < 0)。

正差值个数 $B^+ = 2$, $n' = 12$ 。单侧 p 值:

$$p = P(B^+ \leq 2 \mid B^+ \sim \text{Bin}(12, 0.5)) = \sum_{k=0}^2 \binom{12}{k} (0.5)^{12} = \frac{1 + 12 + 66}{4096} \approx 0.019$$

在 $\alpha = 0.05$ 下拒绝 H_0 , 有统计证据支持新疗法能降低血压。

21.2.2 Wilcoxon 符号秩检验 符号检验只利用了差值的正负符号, 丢弃了差值大小的信息。**Wilcoxon 符号秩检验** (Wilcoxon Signed-Rank Test) 在符号检验的基础上, 还利用了差值的相对大小 (秩)。

检验统计量: 1. 计算 $D_i = X_i - M_0$, 去除 $D_i = 0$ 的观测值 2. 对 $|D_i|$ 从小到大排秩, 得到秩 R_i^+ (处理同秩时取平均秩) 3. 计算正差值的秩和:

$$W^+ = \sum_{i: D_i > 0} R_i^+$$

以及负差值的秩和 $W^- = n'(n' + 1)/2 - W^+$ 。

检验统计量取 $W = \min(W^+, W^-)$ (双侧检验)。

精确分布: 在 H_0 下, W^+ 的精确分布来自对 $\{1, 2, \dots, n'\}$ 的所有子集求和的等可能性。精确临界值由查表或递推公式给出。

正态近似 (当 $n' \geq 25$):

$$E(W^+) = \frac{n'(n' + 1)}{4}, \quad \text{Var}(W^+) = \frac{n'(n' + 1)(2n' + 1)}{24}$$

$$Z = \frac{W^+ - n'(n' + 1)/4}{\sqrt{n'(n' + 1)(2n' + 1)/24}} \xrightarrow{d} N(0, 1)$$

若有 g 组同秩, 每组有 t_j 个, 方差需修正:

$$\text{Var}(W^+) = \frac{1}{24} \left[n'(n' + 1)(2n' + 1) - \frac{1}{2} \sum_{j=1}^g t_j(t_j^2 - 1) \right]$$

例 21.2 对例 21.1 中的数据应用符号秩检验。

差值的绝对值及其排秩:

D_i	$ D_i $	秩 R_i^+	符号
+2	2	1	+

D_i	$ D_i $	秩 R_i^+	符号
+3	3	2	+
-4	4	3	-
-5	5	4	-
-6	6	5	-
-7	7	6	-
-8	8	7	-
-9	9	8	-
-10	10	9	-
-11	11	10	-
-12	12	11	-
-15	15	12	-

正秩和： $W^+ = 1 + 2 = 3$

期望： $E(W^+) = 12 \times 13/4 = 39$ ，方差： $\text{Var}(W^+) = 12 \times 13 \times 25/24 = 162.5$

$$Z = \frac{3 - 39}{\sqrt{162.5}} \approx \frac{-36}{12.75} \approx -2.82$$

单侧 $p \approx 0.0024$ ，强烈拒绝 H_0 。符号秩检验比符号检验给出了更强的证据，体现了利用秩信息的优势。

21.3 秩和检验 (Mann-Whitney U 检验)

21.3.1 两独立样本问题 设有两个独立样本：

- 样本 1: $X_1, X_2, \dots, X_m \sim F_X$ (连续分布)
- 样本 2: $Y_1, Y_2, \dots, Y_n \sim F_Y$ (连续分布)

位移模型假设： $F_Y(t) = F_X(t - \Delta)$ ，即两总体除位移 Δ 外形状完全相同。

检验假设： $H_0 : \Delta = 0$ (两总体位置相同) vs $H_1 : \Delta \neq 0$ 。

21.3.2 Wilcoxon 秩和统计量 将两样本合并，对 $N = m + n$ 个观测值联合排序，令 R_i 为 X_i 在联合样本中的秩，则 **Wilcoxon** 秩和统计量为：

$$W = \sum_{i=1}^m R_i$$

在 H_0 下， m 个 X_i 等可能占据 N 个秩中的任意 m 个位置：

$$E_0(W) = \frac{m(N+1)}{2}$$

$$\text{Var}_0(W) = \frac{mn(N+1)}{12}$$

W 的精确分布可通过枚举 $\binom{N}{m}$ 种等可能情形得到。

21.3.3 Mann-Whitney U 统计量 等价地，Mann-Whitney U 统计量定义为：

$$U = \sum_{i=1}^m \sum_{j=1}^n \mathbf{1}(X_i > Y_j)$$

即 X 样本中的值大于 Y 样本中的值的对数。 U 与 W 的关系为：

$$U = W - \frac{m(m+1)}{2}$$

直觉：若 X 总体的位置显著高于 Y 总体，则 U 会很大；反之若 X 显著低于 Y ，则 U 很小。

在 H_0 下：

$$E_0(U) = \frac{mn}{2}, \quad \text{Var}_0(U) = \frac{mn(N+1)}{12}$$

正态近似 ($m, n \geq 8$):

$$Z = \frac{U - mn/2}{\sqrt{mn(N+1)/12}} \xrightarrow{d} N(0, 1)$$

有同秩修正时，方差变为：

$$\text{Var}_0(U) = \frac{mn}{N(N-1)} \left[\frac{N^3 - N}{12} - \sum_j \frac{t_j^3 - t_j}{12} \right]$$

其中 t_j 为第 j 组同秩的个数。

21.3.4 U 统计量的概率解释 Mann-Whitney U 统计量有一个优雅的概率解释。定义：

$$\hat{\theta} = P(X > Y) = \frac{U}{mn}$$

$\hat{\theta}$ 是总体参数 $\theta = P(X > Y)$ 的无偏估计量。

在位移模型 $H_0: \Delta = 0$ 下, $\theta = P(X > Y) = 1/2$ 。若 $\theta > 1/2$ 则 X 随机地大于 Y , $\theta < 1/2$ 则反之。因此 Mann-Whitney 检验也可理解为对 $H_0: P(X > Y) = 1/2$ 的检验。

例 21.3 两种算法在 10 个测试集上的准确率 (%) :

算法 A	72	85	91	68	79	88	75	82	94	70
算法 B	65	78	88	71	76	83	69	80	90	67

合并排序 ($m = n = 10, N = 20$):

将 20 个数合并排序, 计算算法 A 的秩和 W_A 。

$$U_A = W_A - m(m+1)/2$$

在正态近似下计算 Z 值, 若 $|Z| > 1.96$ 则在 $\alpha = 0.05$ 下拒绝两算法性能相同的假设。

21.3.5 Kruskal-Wallis 检验 (多样本推广) 当有 $k \geq 3$ 组样本时, Mann-Whitney 检验推广为 **Kruskal-Wallis** 检验, 这是单因素方差分析 (ANOVA) 的非参数替代。设第 i 组有 n_i 个观测值, 总样本量 $N = \sum n_i$, 第 i 组的秩和为 R_i , 则检验统计量为:

$$H = \frac{12}{N(N+1)} \sum_{i=1}^k \frac{R_i^2}{n_i} - 3(N+1)$$

在 H_0 (所有组来自同一分布) 下, H 渐近服从 $\chi^2(k-1)$ 分布。

21.4 Kolmogorov-Smirnov 检验

21.4.1 经验分布函数 经验分布函数 (Empirical Distribution Function, EDF) 是总体分布函数 F 的非参数估计。给定样本 $X_1, \dots, X_n$, 经验分布函数定义为:

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(X_i \leq x) = \frac{\text{样本中 } \leq x \text{ 的个数}}{n}$$

Glivenko-Cantelli 定理 (经验分布函数的强一致性):

$$\sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| \xrightarrow{a.s.} 0 \quad (n \rightarrow \infty)$$

即经验分布函数以概率 1 一致收敛到真实分布函数。

21.4.2 单样本 KS 检验 问题：检验数据是否来自指定的分布 F_0 。

$$H_0 : F = F_0 \quad \text{vs.} \quad H_1 : F \neq F_0$$

KS 统计量：

$$D_n = \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F_0(x)|$$

D_n 度量经验分布函数与假设分布函数之间的最大偏差。

Kolmogorov 定理：若 H_0 成立且 F_0 连续，则：

$$\sqrt{n}D_n \xrightarrow{d} K$$

其中 K 为 **Kolmogorov** 分布，其 CDF 为：

$$P(K \leq t) = 1 - 2 \sum_{k=1}^{\infty} (-1)^{k-1} e^{-2k^2 t^2} = \frac{\sqrt{2\pi}}{t} \sum_{k=1}^{\infty} e^{-(2k-1)^2 \pi^2 / (8t^2)}$$

常用近似： $P(K \leq t) \approx 1 - 2e^{-2t^2}$ ，对 $t \geq 1$ 精度较好。

精确计算：对有限样本， D_n 的计算通过排序后的观测值进行：

$$D_n = \max_{1 \leq i \leq n} \max \left\{ \left| \hat{F}_n(X_{(i)}) - F_0(X_{(i)}) \right|, \left| \hat{F}_n(X_{(i-1)}) - F_0(X_{(i)}) \right| \right\}$$

其中 $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ 为顺序统计量， $\hat{F}_n(X_{(i)}) = i/n$ 。

简化为：

$$D_n = \max_{1 \leq i \leq n} \max \left\{ \left| \frac{i}{n} - F_0(X_{(i)}) \right|, \left| \frac{i-1}{n} - F_0(X_{(i)}) \right| \right\}$$

重要注意事项：当分布参数从数据中估计时（如检验正态性但 μ, σ^2 未知，需先估计），KS 检验趋于保守，此时应使用 Lilliefors 检验（使用模拟或专用临界值）。

21.4.3 双样本 KS 检验 问题：检验两个样本是否来自同一总体。

$$H_0 : F_X = F_Y \quad \text{vs.} \quad H_1 : F_X \neq F_Y$$

设两样本大小分别为 m 和 n ， $\hat{F}_m$ 和 $\hat{G}_n$ 为对应经验分布函数，则统计量为：


$$D_{m,n} = \sup_x |\hat{F}_m(x) - \hat{G}_n(x)|$$

在 H_0 下，渐近分布满足：

$$\sqrt{\frac{mn}{m+n}} D_{m,n} \xrightarrow{d} K$$

双样本 KS 检验对分布的任何差异（位置、形状、尺度）都敏感，而不仅仅是位置差异，这是相比 Mann-Whitney 检验的优势。

21.4.4 KS 检验的几何直觉 D_n 可以直观地理解为：在图形上，经验分布函数（阶梯函数）与理论分布函数（平滑曲线）之间的最大竖向距离。



检验逻辑：若真实分布是 F_0 ，则 $\hat{F}_n$ 应与 F_0 接近， D_n 应较小。若 D_n 超过临界值，则拒绝 H_0 。

21.5 置换检验

21.5.1 基本思想 置换检验（Permutation Test），又称随机化检验（Randomization Test），是一种基于数据重排的精确检验方法，由 Fisher 于 1935 年提出。

核心思想：在零假设下，观测数据的组标签（或某种结构）的所有置换应该同等可能。通过枚举（或随机采样）所有可能的置换，构造检验统计量的精确（或近似）零分布。

算法流程：

1. 计算观测数据上的检验统计量 T_{obs}
2. 在 H_0 下的等可能置换中，对每个置换 π 计算统计量 T_π
3. p 值定义为：

$$p = \frac{|\{\pi : T_\pi \geq T_{\text{obs}}\}|}{|\text{所有置换}|}$$

（双侧检验取 $|\{T_\pi \geq |T_{\text{obs}}|\}|$ 的比例，或 $\min(p_{\text{left}}, p_{\text{right}}) \times 2$ 。）

优势：- 无需分布假设，精确有效 - 可用于任意检验统计量（不限于传统统计量）- 对小样本也精确有效

劣势：- 完全枚举计算代价大（两样本各 n 时共 $\binom{2n}{n}$ 种置换）- 通常采用 Monte Carlo 近似：随机采样 B （如 $B = 10000$ ）个置换

21.5.2 两样本置换 t 检验 问题：比较两组均值，但不假设正态性。

两样本合并为 $\mathbf{Z} = (Z_1, \dots, Z_{m+n})$ ，在 H_0 下，组标签的任何分配等可能。

算法：1. 计算原始两样本 t 统计量 T_{obs} 2. 随机将 $m + n$ 个观测值随机分为大小 m 和 n 的两组，计算 t 统计量 3. 重复步骤 2 共 B 次，得到置换分布 4. p 值 = 置换分布中 $|T_{\pi}| \geq |T_{\text{obs}}|$ 的比例

21.5.3 置换检验的精确性与一致性 置换 p 值满足精确性：在任意分布下（连续或离散），在显著性水平 α 下进行置换检验，若 H_0 为真，则犯第一类错误的概率恰好（不超过）等于 α 。

当 $B \rightarrow \infty$ 时，Monte Carlo 置换 p 值收敛到精确置换 p 值。实践中 $B = 10000$ 通常足够， p 值的 95% 置信区间宽度约为 $2\sqrt{p(1-p)/B}$ 。

21.5.4 自举法与置换检验的区别

	置换检验	自举法 (Bootstrap)
目的	假设检验 (p 值)	区间估计 (标准误、置信区间)
重采样方式	无放回，固定样本大小	有放回，固定样本大小
假设	H_0 下的可交换性	样本代表总体
零分布	由置换构造	非零假设下构造

本章小结

本章系统介绍了非参数检验的理论体系与核心方法：

非参数方法的本质是用秩或重排代替原始数据进行推断，核心工具是秩的等可能性和经验分布函数。

符号检验最简单，只利用正负符号，对中位数进行检验；**Wilcoxon** 符号秩检验额外利用差值大小的秩信息，功效更高（相对于 t 检验的 $\text{ARE} = 3/\pi \approx 0.955$ ）。

Mann-Whitney U 检验通过计算跨组比较的胜负次数，对两独立样本的位置进行比较，其统计量等价于 $P(X > Y)$ 的估计。

KS 检验基于经验分布函数与理论/对照分布函数的最大偏差，能够检测分布的任何形式差异，渐近分布为 Kolmogorov 分布。

置换检验是最灵活的非参数框架，通过数据重排构造精确零分布，可用于任意检验统计量，是深度学习模型评估等复杂场景的重要工具。

深度学习应用：生成模型的统计评估

生成模型（如 GAN、VAE、扩散模型）的核心目标是让生成分布 p_θ 尽可能接近真实数据分布 p_{data} 。评估生成质量本质上是一个两样本检验问题：真实样本集合 $\{x_i\}_{i=1}^m \sim p_{\text{data}}$ 和生成样本集合 $\{\tilde{x}_j\}_{j=1}^n \sim p_\theta$ ，检验 $H_0: p_\theta = p_{\text{data}}$ 。

21.A FID 与 IS 的统计学基础

Inception Score (IS) IS 使用预训练 Inception 网络 f ，对生成图像 $x \sim p_\theta$ 计算条件标签分布 $p(y|x)$ 和边缘分布 $p(y) = \mathbb{E}_{x \sim p_\theta}[p(y|x)]$ ，然后计算 KL 散度：

$$\text{IS} = \exp \left(\mathbb{E}_{x \sim p_\theta} [D_{KL}(p(y|x) \| p(y))] \right)$$

IS 高意味着：- 单张图像分类概率集中 ($p(y|x)$ 尖锐) $\rightarrow$ 图像质量高 - 边缘分布均匀 ($p(y)$ 分散) $\rightarrow$ 多样性好

IS 的统计局限：不需要真实数据，无法检测模式崩塌到真实分布的偏差；对 Inception 网络的偏差敏感。

Fréchet Inception Distance (FID) FID 是最广泛使用的生成质量指标。将真实图像和生成图像通过 Inception 网络编码为特征向量，假设真实特征 $\sim \mathcal{N}(\mu_r, \Sigma_r)$ ，生成特征 $\sim \mathcal{N}(\mu_g, \Sigma_g)$ ，则 FID 为两高斯分布之间的 Fréchet 距离（2-Wasserstein 距离）：

$$\text{FID} = \|\mu_r - \mu_g\|^2 + \text{tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2})$$

FID 越小表示生成分布越接近真实分布。FID = 0 当且仅当两高斯完全相同。

统计解释：FID 是 Wasserstein-2 距离在高斯分布族上的精确公式，也等价于特征空间中的最优传输距离。

21.B 基于非参数检验的生成质量评估

下面用 PyTorch 实现基于两样本 KS 检验和置换检验的生成质量评估框架：

```
"""
```

生成模型评估：基于非参数检验的统计质量评估

使用两样本 KS 检验和置换检验评估生成分布与真实分布的差异

```
"""
```

```

import numpy as np
import torch
import torch.nn as nn
from scipy import stats
from scipy.linalg import sqrtm
from typing import Tuple, Optional
import warnings

# 1. 计算 FID

def compute_fid(
    real_features: np.ndarray,
    fake_features: np.ndarray,
    eps: float = 1e-6
) -> float:
    """
    计算真实特征与生成特征之间的 Fréchet Inception Distance。

    Args:
        real_features: 形状 (m, d)，真实图像的特征向量
        fake_features: 形状 (n, d)，生成图像的特征向量
        eps: 数值稳定性小量，防止矩阵平方根计算中出现负特征值

    Returns:
        FID 值（越小越好）
    """
    mu_r = real_features.mean(axis=0)
    mu_g = fake_features.mean(axis=0)
    sigma_r = np.cov(real_features, rowvar=False)
    sigma_g = np.cov(fake_features, rowvar=False)

    diff = mu_r - mu_g
    mean_term = diff @ diff

    # 计算矩阵平方根  $(\Sigma_r \Sigma_g)^{1/2}$ 
    # 使用 sqrtm 计算矩阵平方根，结果可能有虚部（数值误差），取实部
    covmean = sqrtm(sigma_r @ sigma_g)
    if np.iscomplexobj(covmean):
        if np.max(np.abs(covmean.imag)) > 1e-3:
            warnings.warn("sqrtm 产生较大虚部，FID 计算可能不准确")

```

```

        covmean = covmean.real

    trace_term = np.trace(sigma_r + sigma_g - 2 * covmean)
    fid = mean_term + trace_term
    return float(fid)

# 2. 两样本 KS 检验 (逐特征维度)

def ks_test_multivariate(
    real_features: np.ndarray,
    fake_features: np.ndarray,
    alpha: float = 0.05,
    correction: str = "bonferroni"
) -> dict:
    """
    对特征的每个维度分别进行两样本 KS 检验，并进行多重检验校正。

    Args:
        real_features: 形状 (m, d)
        fake_features: 形状 (n, d)
        alpha: 显著性水平
        correction: 多重检验校正方法, "bonferroni" 或 "none"

    Returns:
        包含检验结果的字典
    """
    d = real_features.shape[1]
    ks_stats = []
    p_values = []

    for j in range(d):
        stat, pval = stats.ks_2samp(real_features[:, j], fake_features[:, j])
        ks_stats.append(stat)
        p_values.append(pval)

    ks_stats = np.array(ks_stats)
    p_values = np.array(p_values)

    # Bonferroni 校正: 将显著性水平除以检验次数
    if correction == "bonferroni":

```



```

        alpha_corrected = alpha / d
    else:
        alpha_corrected = alpha

    rejected = p_values < alpha_corrected
    n_rejected = rejected.sum()

    return {
        "ks_stats": ks_stats,
        "p_values": p_values,
        "n_rejected": int(n_rejected),
        "rejection_rate": float(n_rejected / d),
        "alpha_corrected": alpha_corrected,
        "max_ks_stat": float(ks_stats.max()),
        "mean_ks_stat": float(ks_stats.mean()),
        "conclusion": (
            f" 在 Bonferroni 校正后 = {alpha_corrected:.4f} 下, "
            f" {d} 个特征维度中 {n_rejected} 个拒绝  $H_0$  "
        )
    }
}

```

3. 置换检验：基于 MMD

```

def rbf_kernel(
    X: np.ndarray,
    Y: np.ndarray,
    sigma: Optional[float] = None
) -> np.ndarray:
    """
    计算 RBF (高斯) 核矩阵  $K(X, Y)$ 。

    Args:
        X: 形状 (m, d)
        Y: 形状 (n, d)
        sigma: 带宽参数, None 时使用中位数启发式

    Returns:
        核矩阵, 形状 (m, n)
    """
    # 计算成对平方距离

```

```

XX = (X ** 2).sum(axis=1, keepdims=True) # (m, 1)
YY = (Y ** 2).sum(axis=1, keepdims=True) # (n, 1)
sq_dists = XX + YY.T - 2 * X @ Y.T      # (m, n)

if sigma is None:
    # 中位数启发式：带宽取所有成对距离中位数的平方
    sigma = np.median(np.sqrt(np.maximum(sq_dists, 0))) + 1e-8

return np.exp(-sq_dists / (2 * sigma ** 2))

def mmd_statistic(
    X: np.ndarray,
    Y: np.ndarray,
    sigma: Optional[float] = None
) -> float:
    """
    计算无偏最大均值差异 ( $MMD^2$ ) 统计量。


$$MMD^2 = E[k(X, X')] - 2E[k(X, Y)] + E[k(Y, Y')]$$

    其中  $k$  为 RBF 核,  $X, X' \sim p$ ,  $Y, Y' \sim q$ 。

    Args:
        X: 来自分布  $p$  的样本, 形状  $(m, d)$ 
        Y: 来自分布  $q$  的样本, 形状  $(n, d)$ 

    Returns:
         $MMD^2$  估计值
    """
    m, n = len(X), len(Y)

    Kxx = rbf_kernel(X, X, sigma)
    Kyy = rbf_kernel(Y, Y, sigma)
    Kxy = rbf_kernel(X, Y, sigma)

    # 无偏估计：去掉对角线项
    np.fill_diagonal(Kxx, 0)
    np.fill_diagonal(Kyy, 0)

    mmd2 = (
        Kxx.sum() / (m * (m - 1))

```

```

        - 2 * Kxy.mean()
        + Kyy.sum() / (n * (n - 1))
    )
    return float(mmd2)

def permutation_mmd_test(
    real_features: np.ndarray,
    fake_features: np.ndarray,
    n_permutations: int = 1000,
    random_state: int = 42,
    sigma: Optional[float] = None
) -> dict:
    """
    基于 MMD 统计量的置换检验。

     $H_0$ : 真实分布 = 生成分布
     $H_1$ : 真实分布  $\neq$  生成分布

    Args:
        real_features: 形状 (m, d)
        fake_features: 形状 (n, d)
        n_permutations: 置换次数 (越大越精确, 但更慢)
        random_state: 随机种子
        sigma: RBF 核带宽

    Returns:
        包含检验结果的字典
    """
    rng = np.random.RandomState(random_state)
    m = len(real_features)
    n = len(fake_features)

    # 合并样本
    combined = np.vstack([real_features, fake_features])
    N = m + n

    # 观测 MMD2 统计量
    mmd_obs = mmd_statistic(real_features, fake_features, sigma)

    # 置换分布: 随机打乱标签, 重新分组

```

```

mmd_perm = np.zeros(n_permutations)
for b in range(n_permutations):
    perm_idx = rng.permutation(N)
    X_perm = combined[perm_idx[:m]]
    Y_perm = combined[perm_idx[m:]]
    mmd_perm[b] = mmd_statistic(X_perm, Y_perm, sigma)

# p 值 = 置换统计量 >= 观测统计量的比例
p_value = float((mmd_perm >= mmd_obs).mean())

# 标准化置换分布
perm_mean = mmd_perm.mean()
perm_std = mmd_perm.std() + 1e-8
z_score = (mmd_obs - perm_mean) / perm_std

return {
    "mmd_observed": mmd_obs,
    "mmd_perm_mean": float(perm_mean),
    "mmd_perm_std": float(perm_std),
    "z_score": float(z_score),
    "p_value": p_value,
    "n_permutations": n_permutations,
    "reject_h0_5pct": p_value < 0.05,
    "reject_h0_1pct": p_value < 0.01,
    "conclusion": (
        f"MMD2={mmd_obs:.6f}, Z={z_score:.2f}, p={p_value:.4f}. "
        + ("拒绝 H0：生成分布与真实分布存在显著差异。"
           if p_value < 0.05
           else "无法拒绝 H0：未发现显著差异。")
    )
}

```

4. 简单 GAN 示例与完整评估流程

```

class SimpleGenerator(nn.Module):
    """ 用于演示的简单生成器，将标准正态噪声映射到数据空间。 """

    def __init__(self, latent_dim: int = 32, output_dim: int = 64):
        super().__init__()
        self.net = nn.Sequential(

```

```

        nn.Linear(latent_dim, 128),
        nn.ReLU(),
        nn.Linear(128, 256),
        nn.ReLU(),
        nn.Linear(256, output_dim),
    )
    self.latent_dim = latent_dim

def forward(self, z: torch.Tensor) -> torch.Tensor:
    return self.net(z)

def sample(self, n: int, device: str = "cpu") -> torch.Tensor:
    """ 采样  $n$  个生成样本。 """
    z = torch.randn(n, self.latent_dim, device=device)
    with torch.no_grad():
        return self.forward(z)

def evaluate_generator(
    generator: SimpleGenerator,
    real_data: np.ndarray,
    n_generated: int = 1000,
    n_permutations: int = 500,
    device: str = "cpu"
) -> dict:
    """
    完整的生成器统计评估流程：
    1. 生成样本
    2. 计算  $FID$  (特征空间 Fréchet 距离)
    3. 逐维  $KS$  检验
    4. 基于  $MMD$  的置换检验

    Args:
        generator: 待评估的生成器
        real_data: 真实数据特征, 形状  $(m, d)$ 
        n_generated: 生成样本数量
        n_permutations: 置换检验重复次数

    Returns:
        评估结果字典
    """

```

```

generator.eval()

# 1. 生成样本
fake_tensor = generator.sample(n_generated, device=device)
fake_data = fake_tensor.cpu().numpy()

# 2. FID
fid = compute_fid(real_data, fake_data)

# 3. 逐维 KS 检验
ks_results = ks_test_multivariate(real_data, fake_data)

# 4. 置换 MMD 检验（在高维时可先 PCA 降维以提速）
# 取前 min(d, 32) 维以加快置换检验
d_sub = min(real_data.shape[1], 32)
mmd_results = permutation_mmd_test(
    real_data[:, :d_sub],
    fake_data[:, :d_sub],
    n_permutations=n_permutations
)

return {
    "n_real": len(real_data),
    "n_generated": n_generated,
    "feature_dim": real_data.shape[1],
    "fid": fid,
    "ks_test": ks_results,
    "mmd_permutation_test": mmd_results,
}

```

5. 演示运行

```

def demo():
    """ 演示：比较训练良好和训练差的生成器的统计评估差异。 """
    torch.manual_seed(42)
    np.random.seed(42)

    d = 64 # 特征维度
    m = 500 # 真实样本数

```

```

# 真实数据：多元正态
real_mean = np.zeros(d)
real_cov = np.eye(d) + 0.3 * np.ones((d, d)) / d
real_data = np.random.multivariate_normal(real_mean, real_cov, size=m)

# 场景 A：训练良好的生成器（生成分布接近真实分布）
gen_good = SimpleGenerator(latent_dim=32, output_dim=d)
# 手动设置权重使其近似恒等映射（仅供演示）
with torch.no_grad():
    nn.init.eye_(gen_good.net[0].weight[:d, :d])
    nn.init.zeros_(gen_good.net[0].bias)

# 场景 B：训练差的生成器（生成分布偏离真实分布，均值偏移）
gen_bad = SimpleGenerator(latent_dim=32, output_dim=d)
with torch.no_grad():
    # 增大最后一层 bias 模拟均值偏移
    gen_bad.net[-1].bias.data.fill_(2.0)

print("=" * 60)
print(" 生成模型非参数统计评估演示")
print("=" * 60)

for name, gen in [(" 良好生成器", gen_good), (" 偏差生成器", gen_bad)]:
    print(f"\n--- {name} ---")
    results = evaluate_generator(gen, real_data, n_generated=500,
                                n_permutations=200)

    print(f"FID                      : {results['fid']:.4f}")
    print(f"KS 最大统计量                : {results['ks_test']['max_ks_stat']:.4f}")
    print(f"KS 拒绝维度比例                : {results['ks_test']['rejection_rate']:.2%}")
    print(f"MMD2 观测值                  : {results['mmd_permutation_test']['mmd_observed']:.6f}")
    print(f"置换检验 p 值                  : {results['mmd_permutation_test']['p_value']:.4f}")
    print(f"结论                          : {results['mmd_permutation_test']['conclusion']}")

if __name__ == "__main__":
    demo()

```

21.C 各指标的统计学联系

评估指标	统计学本质	零假设	优点	缺点
FID	Wasserstein-2（高斯近似）	$p_\theta = p_{\text{data}}$ （高斯）	快速、标准	假设高斯性
IS	KL 散度期望	无真实数据对比	无需真实样本	无法检测模式崩塌
KID	MMD ² （无偏估计）	$p_\theta = p_{\text{data}}$	无偏、小样本有效	核选择敏感
两样本 KS 检验	EDF 最大偏差	$F_\theta = F_{\text{data}}$	精确、分布无关	高维效率低
置换 MMD 检验	核均值嵌入距离	$p_\theta = p_{\text{data}}$	精确 p 值	计算代价高

Precision & Recall for Generative Models: 近年来，研究者提出将生成质量分解为：

- **Precision** = $P(\tilde{x} \sim p_\theta \text{ 落入真实数据流形})$ ：生成样本的质量（忠实度）
- **Recall** = $P(x \sim p_{\text{data}} \text{ 落入生成数据流形})$ ：多样性覆盖率

两者分别对应假设检验中的第一类错误控制和功效，体现了非参数统计思想在生成模型评估中的深层联系。

练习题

练习 21.1 某研究收集了 15 名受试者在两种条件下的反应时间（毫秒）数据，差值（条件 B - 条件 A）为：

$+8, -3, +15, +22, -5, +11, +19, -2, +7, +13, -8, +16, +4, +9, -1$

- (a) 对上述数据进行符号检验，检验 H_0 ：中位差值为 0（双侧， $\alpha = 0.05$ ）。
- (b) 对上述数据进行 Wilcoxon 符号秩检验，计算检验统计量 W^+ 和 W^- ，并用正态近似给出 p 值。
- (c) 比较两种检验结果，解释为何符号秩检验在此数据上应给出更强的证据。

练习 21.2 设 $X_1, \dots, X_m$ 和 $Y_1, \dots, Y_n$ 为两独立样本，令 $U = \sum_{i,j} \mathbf{1}(X_i > Y_j)$ 。

- (a) 证明 $E_0(U) = mn/2$ ，其中下标 0 表示在 $H_0 : F_X = F_Y$ 下。
- (b) 证明 U/mn 是 $P(X > Y)$ 的无偏估计量。
- (c) 当 $m = n = 10$ ，实际计算得到 $U = 78$ ，计算正态近似 p 值（双侧检验）。

练习 21.3 设样本 $X_1, \dots, X_{30}$ 的经验分布函数为 $\hat{F}_{30}$ ，假设检验 $H_0 : F = \text{Uniform}(0, 1)$ 。

- (a) 写出 KS 统计量 D_{30} 的计算公式，并解释其几何意义。

- (b) 若计算得到 $D_{30} = 0.21$ ，在 $\alpha = 0.05$ 下作出决策（Kolmogorov 分布的 95% 分位数为 $t_{0.05} \approx 1.358$ ，即 $P(K \leq 1.358) = 0.95$ ）。
- (c) 解释为何当分布参数未知、需要从数据中估计时，不能直接使用 Kolmogorov 分布的临界值，应该如何处理。

练习 21.4 考虑置换检验的精确性质。

- (a) 设两样本各有 $n = 5$ 个观测值，计算完全枚举置换检验需要评估的置换总数。
- (b) 设观测到的检验统计量 $T_{\text{obs}} = 4.2$ ，在 1000 次 Monte Carlo 置换中，有 23 次得到 $T_{\pi} \geq 4.2$ ，给出 p 值，并计算该估计的标准误差。
- (c) 解释置换检验为何在样本量较小时比参数检验（如 t 检验）更可靠。

练习 21.5 在深度学习应用中，设真实图像特征 $\mathbf{r}_i \in \mathbb{R}^{2048}$ （共 $m = 5000$ 张）和生成图像特征 $\tilde{\mathbf{g}}_j \in \mathbb{R}^{2048}$ （共 $n = 5000$ 张），均由 Inception-V3 网络提取。

- (a) 给出 FID 的计算步骤，包括所需估计的统计量和最终公式。
- (b) 设 $\hat{\mu}_r = \hat{\mu}_g$ （均值相同）， $\hat{\Sigma}_r = \hat{\Sigma}_g = \sigma^2 I_{2048}$ （各向同性方差相同），计算此时的 FID 值，并解释其含义。
- (c) 解释为何不能直接对 2048 维特征向量的每个维度做 KS 检验并要求“所有维度都通过”，应如何修正多重检验问题。

练习答案

练习 21.1 解答

(a) 符号检验

正差值个数： $B^+ = |\{+8, +15, +22, +11, +19, +7, +13, +16, +4, +9\}| = 10$

$n' = 15$ （无零差值），在 H_0 下 $B^+ \sim \text{Bin}(15, 0.5)$ 。

双侧 p 值：

$$p = 2 \min\{P(B^+ \leq 5), P(B^+ \geq 10)\}$$

$$\begin{aligned} P(B^+ \geq 10) &= \sum_{k=10}^{15} \binom{15}{k} (0.5)^{15} = \frac{\binom{15}{10} + \dots + \binom{15}{15}}{32768} \\ &= \frac{3003 + 5005 + 1365 + 455 + 105 + 15 + 1}{32768} \end{aligned}$$

等等，重新计算 $\sum_{k=10}^{15} \binom{15}{k}$: $\binom{15}{10} = 3003, \binom{15}{11} = 1365, \binom{15}{12} = 455, \binom{15}{13} = 105, \binom{15}{14} = 15, \binom{15}{15} = 1$, 合计 = 4944。

$$P(B^+ \geq 10) = 4944/32768 \approx 0.151$$

双侧 $p \approx 2 \times 0.151 = 0.302 > 0.05$, 不拒绝 H_0 。

(b) Wilcoxon 符号秩检验

差值按 $|D_i|$ 排序:

$ D_i $ 排序	D_i	秩	贡献
1	-1	1	W^-
2	-2	2	W^-
3	-3	3	W^-
4	+4	4	W^+
5	-5	5	W^-
7	+7	6	W^+
8	+8	7	W^+
8	-8	8	W^- (注: 两个 $ D_i = 8$, 取平均秩 7.5)

重新对 $|D_i|$ 排序 (处理同秩 $|D_i| = 8$, 取平均秩 7.5):

$ D_i $	1	2	3	4	5	7	8	8	9	11	13	15	16	19	22
符号	-	-	-	+	-	+	+	-	+	+	+	+	+	+	+
秩	1	2	3	4	5	6	7.5	7.5	9	10	11	12	13	14	15

$$W^+ = 4 + 6 + 7.5 + 9 + 10 + 11 + 12 + 13 + 14 + 15 = 101.5$$

$$W^- = 1 + 2 + 3 + 5 + 7.5 = 18.5$$

验证: $W^+ + W^- = 101.5 + 18.5 = 120 = 15 \times 16/2$ 。正确。

$$E(W^+) = \frac{15 \times 16}{4} = 60, \quad \text{Var}(W^+) = \frac{15 \times 16 \times 31}{24} = 310$$

(同秩修正: $\sum t_j(t_j^2 - 1)/2 = 2(4 - 1)/2 = 3$, 修正后方差 = $310 - 3/24 \approx 309.875$, 影响极小。)

$$Z = \frac{101.5 - 60}{\sqrt{310}} \approx \frac{41.5}{17.61} \approx 2.36$$

双侧 $p \approx 2 \times P(Z > 2.36) \approx 2 \times 0.0091 \approx 0.018 < 0.05$, 拒绝 H_0 。

(c) 比较

符号检验 $p \approx 0.302$ ，不拒绝；符号秩检验 $p \approx 0.018$ ，拒绝。差别显著。原因：数据中正差值不仅数量多，而且绝对值更大（正差值普遍较大，如 +22、+19、+16），符号秩检验通过利用差值大小的秩信息，捕捉到了更多的分布差异，因而功效更高。

练习 21.2 解答

(a) 证明 $E_0(U) = mn/2$

$$E_0(U) = E_0 \left[\sum_{i=1}^m \sum_{j=1}^n \mathbf{1}(X_i > Y_j) \right] = mn \cdot P_0(X_1 > Y_1)$$

在 $H_0: F_X = F_Y = F$ （连续分布）下， X_1 和 Y_1 独立同分布，因此 $P(X_1 > Y_1) = P(Y_1 > X_1)$ （连续分布无平局），且二者之和为 1，故各为 $1/2$ 。

$$E_0(U) = mn \times \frac{1}{2} = \frac{mn}{2}$$

(b) U/mn 的无偏性：

$$E \left[\frac{U}{mn} \right] = \frac{1}{mn} E \left[\sum_{i,j} \mathbf{1}(X_i > Y_j) \right] = \frac{1}{mn} \cdot mn \cdot P(X > Y) = P(X > Y) = \theta$$

因此 $\hat{\theta} = U/mn$ 是 $\theta = P(X > Y)$ 的无偏估计。

(c) $m = n = 10$, $U = 78$:

$$N = 20, \quad E_0(U) = 50, \quad \text{Var}_0(U) = \frac{10 \times 10 \times 21}{12} = 175$$

$$Z = \frac{78 - 50}{\sqrt{175}} = \frac{28}{13.23} \approx 2.12$$

双侧 $p \approx 2 \times P(Z > 2.12) \approx 2 \times 0.017 = 0.034 < 0.05$ ，拒绝 H_0 。

练习 21.3 解答

(a) KS 统计量：

$$D_{30} = \max_{1 \leq i \leq 30} \max \left\{ \left| \frac{i}{30} - F_0(X_{(i)}) \right|, \left| \frac{i-1}{30} - F_0(X_{(i)}) \right| \right\}$$

对 $\text{Uniform}(0, 1)$ 有 $F_0(x) = x$, 故:

$$D_{30} = \max_i \max \left\{ \left| \frac{i}{30} - X_{(i)} \right|, \left| \frac{i-1}{30} - X_{(i)} \right| \right\}$$

几何意义: 经验分布函数 (从 0 阶梯上升到 1 的阶梯函数) 与对角线 $F_0(x) = x$ 之间的最大竖向距离。

(b) 决策:

$$\sqrt{n}D_n = \sqrt{30} \times 0.21 \approx 5.477 \times 0.21 \approx 1.150$$

临界值 $t_{0.05} = 1.358$, 由于 $1.150 < 1.358$, 不拒绝 H_0 , 即无充分证据认为数据不来自 $\text{Uniform}(0, 1)$ 。

(c) 当参数从数据中估计时 (如 $\hat{\mu}, \hat{\sigma}^2$), H_0 下 $\hat{F}_n$ 与估计参数的 $F_{\hat{\theta}}$ 之间的差异被人为缩小 ($\hat{F}_n$ “追随”了参数估计), 导致 D_n 系统性偏小, Kolmogorov 分布的临界值偏保守, 检验水平实际低于标称水平 α , 导致功效损失。

正确做法: 使用 **Lilliefors** 检验, 其临界值通过 Monte Carlo 模拟 (在估计参数后重新生成样本、重新估计参数) 专门针对参数估计情形确定; 或使用 **Anderson-Darling** 检验 (加权 EDF 差异, 对尾部更敏感, 也有针对正态性检验的专用临界值)。

练习 21.4 解答

(a) 两样本各 $n = 5$, 合并 $N = 10$ 个观测值, 将其分为两组各 5 个的置换总数为:

$$\binom{10}{5} = 252$$

(b) p 值估计: $\hat{p} = 23/1000 = 0.023$ 。

标准误差: $\text{SE}(\hat{p}) = \sqrt{\hat{p}(1-\hat{p})/B} = \sqrt{0.023 \times 0.977/1000} \approx 0.0150$ 。

95% 置信区间: $0.023 \pm 1.96 \times 0.015 = (0.0, 0.052)$ 。

(c) 置换检验的可靠性来源:

1. 无分布假设: t 检验在小样本下依赖正态性假设, 而置换检验仅要求 H_0 下组标签的可交换性。
2. 精确 I 型错误控制: 置换 p 值在任意分布下精确控制犯第一类错误的概率。
3. 利用全部数据信息: 置换分布直接由观测数据构建, 不依赖参数估计。
4. 对偏斜和异常值稳健: 置换分布自动反映数据的真实结构, 不被极端值的正态近似误导。

练习 21.5 解答

(a) FID 计算步骤:

1. 提取特征: 对 m 张真实图像和 n 张生成图像, 用 Inception-V3 网络 (取 pool_3 层输出) 分别提取 2048 维特征向量, 得到矩阵 $\mathbf{R} \in \mathbb{R}^{m \times 2048}$ 和 $\mathbf{G} \in \mathbb{R}^{n \times 2048}$ 。

2. 估计参数:

$$\hat{\mu}_r = \frac{1}{m} \sum_{i=1}^m \mathbf{r}_i, \quad \hat{\Sigma}_r = \frac{1}{m-1} \sum_{i=1}^m (\mathbf{r}_i - \hat{\mu}_r)(\mathbf{r}_i - \hat{\mu}_r)^\top$$

类似地估计 $\hat{\mu}_g, \hat{\Sigma}_g$ 。

3. 计算 FID:

$$\text{FID} = \|\hat{\mu}_r - \hat{\mu}_g\|^2 + \text{tr}(\hat{\Sigma}_r + \hat{\Sigma}_g - 2(\hat{\Sigma}_r \hat{\Sigma}_g)^{1/2})$$

(b) 当 $\hat{\mu}_r = \hat{\mu}_g$ 且 $\hat{\Sigma}_r = \hat{\Sigma}_g = \sigma^2 I$ 时:

$$\text{FID} = 0 + \text{tr}(\sigma^2 I + \sigma^2 I - 2(\sigma^4 I)^{1/2}) = \text{tr}(2\sigma^2 I - 2\sigma^2 I) = 0$$

FID = 0, 说明两个高斯分布完全相同 (在均值和协方差的意义下), 表明生成特征分布与真实特征分布无法被 FID 区分, 代表理想的生成质量。

(c) 多重检验问题: 对 2048 个维度分别进行 KS 检验, 在 $\alpha = 0.05$ 下, 即使真实分布完全匹配, 期望也有 $2048 \times 0.05 \approx 102$ 个维度被误判为显著。要求“所有维度通过”会极端地降低检验水平 (真实 α 远小于 0.05)。

正确方法:

1. **Bonferroni** 校正: 使用调整后显著性水平 $\alpha/d = 0.05/2048 \approx 2.4 \times 10^{-5}$, 保守但简单。
2. **Benjamini-Hochberg** 程序: 控制 FDR (错误发现率), 功效高于 Bonferroni 校正。
3. 合并统计量: 如取所有维度 KS 统计量的最大值, 并通过置换检验 (在合并后检验统计量上) 控制族错误率 (FWER)。
4. 降维后检验: 先 PCA 降至低维 (如 50 维), 再进行 KS 检验, 减少检验次数。

第 22 章信息论基础

难度: ★★★★★☆ 前置知识: 第 4-6 章随机变量、第 16 章最大似然估计、第 18 章贝叶斯估计

学习目标

- 掌握信息量与香农熵的定义, 理解熵作为不确定性度量的直观含义
- 推导联合熵与条件熵的链式法则 $H(X, Y) = H(X) + H(Y|X)$
- 理解互信息 $I(X; Y)$ 的多种等价表达及其对称性
- 掌握 KL 散度的定义、非对称性与非负性证明, 建立交叉熵损失的理论基础
- 理解信息论不等式体系, 以及在深度学习中 VAE 的 ELBO 推导与信息瓶颈原理

22.1 信息量与熵

22.1.1 自信息（信息量）

信息论的核心问题是：一个随机事件发生后，传递了多少“信息”？

直觉上，越不可能发生的事件，一旦发生，携带的信息量越大。香农（Claude Shannon）于 1948 年将这一直觉形式化：

定义 22.1（自信息）：事件 A 的自信息（Self-Information）定义为：

$$I(A) = -\log P(A)$$

其中对数底数的选择决定信息的单位：- 底数为 2：单位为比特（bit）- 底数为 e ：单位为奈特（nat）- 底数为 10：单位为哈特（hart）

深度学习中通常使用自然对数（奈特），有时也用以 2 为底。

自信息的性质：

1. 非负性： $I(A) = -\log P(A) \geq 0$ （因为 $0 \leq P(A) \leq 1$ ）
2. 必然事件：若 $P(A) = 1$ ，则 $I(A) = 0$ （确定发生的事不携带信息）
3. 单调性： $P(A)$ 越小， $I(A)$ 越大
4. 可加性：若 A, B 独立，则 $I(A \cap B) = I(A) + I(B)$

例 22.1：投掷一枚均匀硬币

- 正面（概率 $1/2$ ）的信息量： $I = -\log_2 \frac{1}{2} = 1$ 比特
- 掷一枚均匀六面骰子出现 1 点（概率 $1/6$ ）的信息量： $I = -\log_2 \frac{1}{6} \approx 2.58$ 比特

22.1.2 香农熵

对于一个随机变量，我们关心的是平均信息量，即信息量的期望。

定义 22.2（香农熵）：离散随机变量 X 的香农熵（Shannon Entropy）定义为：

$$H(X) = -\sum_{x \in \mathcal{X}} p(x) \log p(x) = \mathbb{E}[-\log p(X)]$$

约定： $0 \log 0 = 0$ （因为 $\lim_{p \rightarrow 0^+} p \log p = 0$ ）。

对于连续随机变量 X ，微分熵（Differential Entropy）定义为：

$$h(X) = -\int_{-\infty}^{+\infty} f(x) \log f(x) dx$$

注意：微分熵可以为负，不具备与离散熵完全相同的性质。

熵的性质：

1. 非负性： $H(X) \geq 0$ （离散情形）
2. 最大熵原理：对于取 n 个值的离散随机变量，当且仅当 X 服从均匀分布时，熵取最大值：

$$H(X) \leq \log n$$

3. 确定性：若 X 为确定量（某个值概率为 1），则 $H(X) = 0$

例 22.2：伯努利分布的熵

设 $X \sim \text{Bernoulli}(p)$ ，即 $P(X = 1) = p$ ， $P(X = 0) = 1 - p$ 。

$$H(X) = -p \log p - (1 - p) \log(1 - p) \triangleq H_b(p)$$

- $p = 0$ 或 $p = 1$ ： $H(X) = 0$ （确定性）
- $p = 0.5$ ： $H(X) = \log 2$ （最大不确定性，以自然对数约为 0.693 奈特，以 2 为底为 1 比特）

例 22.3：均匀分布的熵

设 X 在 $\{1, 2, \dots, n\}$ 上均匀分布， $p(x) = 1/n$ ：

$$H(X) = - \sum_{x=1}^n \frac{1}{n} \log \frac{1}{n} = -n \cdot \frac{1}{n} \cdot (-\log n) = \log n$$

22.2 联合熵与条件熵

22.2.1 联合熵

定义 22.3（联合熵）：二维随机变量 (X, Y) 的联合熵定义为：

$$H(X, Y) = - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log p(x, y) = \mathbb{E}[-\log p(X, Y)]$$

22.2.2 条件熵

定义 22.4（条件熵）：在给定 X 的条件下， Y 的条件熵（Conditional Entropy）定义为：

$$H(Y | X) = \sum_{x \in \mathcal{X}} p(x) H(Y | X = x)$$

其中 $H(Y | X = x) = - \sum_{y \in \mathcal{Y}} p(y | x) \log p(y | x)$ 。

展开后：

$$H(Y | X) = - \sum_x \sum_y p(x, y) \log p(y | x)$$

条件熵的直观含义：已知 X 后， Y 剩余的平均不确定性。

22.2.3 链式法则

定理 22.1（熵的链式法则）：

$$H(X, Y) = H(X) + H(Y | X)$$

证明：

$$H(X, Y) = - \sum_{x, y} p(x, y) \log p(x, y)$$

利用乘法公式 $p(x, y) = p(x) \cdot p(y | x)$ ：

$$\begin{aligned} &= - \sum_{x, y} p(x, y) \log[p(x) \cdot p(y | x)] \\ &= - \sum_{x, y} p(x, y) \log p(x) - \sum_{x, y} p(x, y) \log p(y | x) \end{aligned}$$

对第一项，对 y 求和得边缘分布：

$$- \sum_{x, y} p(x, y) \log p(x) = - \sum_x p(x) \log p(x) = H(X)$$

第二项即为 $H(Y | X)$ ，因此：

$$H(X, Y) = H(X) + H(Y | X) \quad \square$$

推论：多变量的链式法则

$$H(X_1, X_2, \dots, X_n) = \sum_{i=1}^n H(X_i | X_1, \dots, X_{i-1})$$

定理 22.2（条件不增熵）：

$$H(Y | X) \leq H(Y)$$

即“已知更多信息不会增加不确定性”。等号成立当且仅当 X 与 Y 独立。

例 22.4: 联合熵与条件熵计算

设 (X, Y) 的联合分布如下:

	$Y = 0$	$Y = 1$
$X = 0$	1/4	1/4
$X = 1$	1/4	1/4

这是均匀分布, $H(X, Y) = \log 4 = 2$ 比特 (以 2 为底)。

$H(X) = H(Y) = \log 2 = 1$ 比特 (边缘均匀分布)。

$H(Y | X) = H(X, Y) - H(X) = 2 - 1 = 1$ 比特。

由于 X, Y 独立, $H(Y | X) = H(Y)$, 符合定理 22.2 的等号条件。

22.3 互信息

22.3.1 互信息的定义

定义 22.5 (互信息): 随机变量 X 与 Y 的互信息 (Mutual Information) 定义为:

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

22.3.2 互信息的等价表达

互信息有多种等价表达, 每种表达揭示不同的直观含义:

$$I(X; Y) = H(X) - H(X | Y) = H(Y) - H(Y | X) = H(X) + H(Y) - H(X, Y)$$

证明 $I(X; Y) = H(X) - H(X | Y)$:

$$I(X; Y) = \sum_{x, y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

$$\begin{aligned}
&= \sum_{x,y} p(x,y) \log \frac{p(x|y)}{p(x)} \\
&= - \sum_{x,y} p(x,y) \log p(x) + \sum_{x,y} p(x,y) \log p(x|y) \\
&= H(X) - H(X|Y) \quad \square
\end{aligned}$$

互信息的文氏图 (Venn Diagram 对应关系):

$$\begin{array}{ccc}
H(X) & & H(Y) \\
\\
H(X|Y) & I(X;Y) & H(Y|X) \\
\\
\uparrow \\
H(X,Y) = H(X|Y) + I(X;Y) + H(Y|X)
\end{array}$$

$$H(X,Y) = H(X|Y) + I(X;Y) + H(Y|X)$$

22.3.3 互信息的性质

1. 对称性: $I(X;Y) = I(Y;X)$
2. 非负性: $I(X;Y) \geq 0$, 等号成立当且仅当 X 与 Y 独立
3. 上界: $I(X;Y) \leq \min\{H(X), H(Y)\}$
4. 与熵的关系: $I(X;X) = H(X)$ (自信息即熵)

互信息的直观含义: $I(X;Y)$ 度量了知道 Y 的值后, X 的不确定性减少了多少; 或者说 X 和 Y 共同包含的信息量。

例 22.5: 独立变量与完全相关变量

- 若 X 与 Y 独立: $p(x,y) = p(x)p(y)$, 所以 $I(X;Y) = 0$ (知道 Y 对 X 没有帮助)
- 若 $Y = X$: $I(X;Y) = I(X;X) = H(X)$ (知道 Y 完全消除了 X 的不确定性)

22.3.4 条件互信息

定义 22.6 (条件互信息): 给定 Z 的条件下, X 与 Y 的条件互信息:

$$I(X; Y | Z) = H(X | Z) - H(X | Y, Z)$$

互信息链式法则：

$$I(X_1, X_2; Y) = I(X_1; Y) + I(X_2; Y | X_1)$$

22.4 KL 散度与交叉熵

22.4.1 KL 散度（相对熵）

定义 22.7 (KL 散度)： 设 P 和 Q 是同一空间上的两个概率分布，**KL 散度** (Kullback-Leibler Divergence, 又称相对熵) 定义为：

$$D_{\text{KL}}(P \| Q) = \sum_x p(x) \log \frac{p(x)}{q(x)} = \mathbb{E}_{x \sim P} \left[\log \frac{p(x)}{q(x)} \right]$$

约定：若 $q(x) = 0$ 而 $p(x) > 0$ ，则该项为 $+\infty$ ；若 $p(x) = 0$ ，该项为 0。

22.4.2 KL 散度的非对称性

KL 散度不是距离，因为它不满足对称性：

$$D_{\text{KL}}(P \| Q) \neq D_{\text{KL}}(Q \| P)$$

例 22.6： 非对称性的直观理解

设 $P = \text{Bernoulli}(0.9)$, $Q = \text{Bernoulli}(0.1)$ ：

$$D_{\text{KL}}(P \| Q) = 0.9 \log \frac{0.9}{0.1} + 0.1 \log \frac{0.1}{0.9} \approx 1.758 \text{ 奈特}$$

$$D_{\text{KL}}(Q \| P) = 0.1 \log \frac{0.1}{0.9} + 0.9 \log \frac{0.9}{0.1} \approx 1.758 \text{ 奈特}$$

(本例恰好对称，但一般情况不对称。)

在实际中：- 前向 **KL** $D_{\text{KL}}(P \| Q)$ (“均值寻求”)： Q 必须覆盖 P 有支撑的所有区域，否则损失无穷大 - 反向 **KL** $D_{\text{KL}}(Q \| P)$ (“模式寻求”)： Q 倾向于聚焦于 P 的某个模式，可以忽略其他模式

22.4.3 KL 散度的非负性（吉布斯不等式）

定理 22.3 (KL 散度非负性):

$$D_{\text{KL}}(P\|Q) \geq 0$$

等号成立当且仅当 $P = Q$ （几乎处处相等）。

证明（利用 $\ln x \leq x - 1$ ）:

$$D_{\text{KL}}(P\|Q) = - \sum_x p(x) \log \frac{q(x)}{p(x)}$$

由于 $-\log t \geq 1 - t$ （即 $\ln t \leq t - 1$ ），令 $t = q(x)/p(x)$:

$$-\log \frac{q(x)}{p(x)} \geq 1 - \frac{q(x)}{p(x)}$$

两边乘以 $p(x)$ 并对 x 求和:

$$D_{\text{KL}}(P\|Q) \geq \sum_x p(x) \left(1 - \frac{q(x)}{p(x)}\right) = \sum_x p(x) - \sum_x q(x) = 1 - 1 = 0 \quad \square$$

22.4.4 交叉熵

定义 22.8 (交叉熵): 分布 P 和 Q 之间的交叉熵定义为:

$$H(P, Q) = - \sum_x p(x) \log q(x) = \mathbb{E}_{x \sim P}[-\log q(x)]$$

交叉熵与 KL 散度的关系:

$$H(P, Q) = H(P) + D_{\text{KL}}(P\|Q)$$

证明:

$$\begin{aligned} H(P, Q) &= - \sum_x p(x) \log q(x) \\ &= - \sum_x p(x) \log p(x) + \sum_x p(x) \log \frac{p(x)}{q(x)} \end{aligned}$$

$$= H(P) + D_{\text{KL}}(P\|Q) \quad \square$$

重要推论：最小化交叉熵等价于最小化 KL 散度

在机器学习中，真实分布 P （数据分布）是固定的， $H(P)$ 是常数。因此：

$$\arg \min_Q H(P, Q) = \arg \min_Q D_{\text{KL}}(P\|Q)$$

这正是交叉熵损失函数的理论基础！

例 22.7：分类任务中的交叉熵损失

设真实标签为类别 k （对应 one-hot 分布 P ），模型预测概率为 $\hat{p}$ ，则：

$$H(P, \hat{p}) = -\log \hat{p}_k$$

最小化交叉熵损失，即驱使预测分布 $\hat{p}$ 接近真实分布 P 。

22.4.5 KL 散度与互信息的关系

互信息可以表示为联合分布与边缘分布乘积之间的 KL 散度：

$$I(X; Y) = D_{\text{KL}}(p(x, y) \| p(x)p(y))$$

这给出了互信息的另一种理解： X 和 Y 的联合分布与“假设独立时”分布之间的差异。

22.5 信息论不等式

22.5.1 Jensen 不等式

信息论中许多重要不等式都基于 **Jensen 不等式**：

定理 22.4 (**Jensen 不等式**)：若 f 是凸函数，则：

$$f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)]$$

若 f 是严格凸函数，等号成立当且仅当 X 为常数。

注意： $-\log$ 是严格凸函数（因为 $\frac{d^2}{dx^2}(-\log x) = \frac{1}{x^2} > 0$ ），这是 KL 散度非负性的根本原因。

22.5.2 数据处理不等式

定理 22.5 (数据处理不等式, DPI): 若 $X \rightarrow Y \rightarrow Z$ 构成马尔可夫链 (即 Z 在给定 Y 的条件下与 X 独立), 则:

$$I(X; Z) \leq I(X; Y)$$

直观含义: 对数据的任何进一步处理 (变换) 不能增加关于原始信息的互信息量。信息只会减少, 不会增加。

推论: 若 g 是确定性函数, 则 $I(X; g(Y)) \leq I(X; Y)$ 。

22.5.3 Fano 不等式

定理 22.6 (Fano 不等式): 设 X 是取 $|\mathcal{X}|$ 个值的离散随机变量, $\hat{X} = g(Y)$ 是基于观测 Y 对 X 的估计, $P_e = P(\hat{X} \neq X)$ 是错误概率, 则:

$$H(X | Y) \leq H_b(P_e) + P_e \log(|\mathcal{X}| - 1)$$

其中 $H_b(p) = -p \log p - (1-p) \log(1-p)$ 是二元熵。

含义: Fano 不等式给出了在给定观测 Y 的情况下, 关于 X 的分类错误率的下界。条件熵越高, 分类就越难。

22.5.4 熵的次可加性

定理 22.7 (次可加性):

$$H(X_1, X_2, \dots, X_n) \leq \sum_{i=1}^n H(X_i)$$

等号成立当且仅当 $X_1, X_2, \dots, X_n$ 互相独立。

证明: 由链式法则和条件不增熵:

$$H(X_1, \dots, X_n) = \sum_{i=1}^n H(X_i | X_1, \dots, X_{i-1}) \leq \sum_{i=1}^n H(X_i) \quad \square$$

22.5.5 最大熵原理

定理 22.8 (最大熵原理):

1. 无约束情形: 取 n 个值的离散随机变量, 熵的最大值为 $\log n$, 在均匀分布时取到。

- 2. 均值约束：若 $X \geq 0$ 且 $\mathbb{E}[X] = \mu$ ，则熵最大的分布是指数分布 $\text{Exp}(1/\mu)$ 。
- 3. 均值和方差约束：若 $\mathbb{E}[X] = \mu$ ， $\text{Var}(X) = \sigma^2$ ，则微分熵最大的分布是正态分布 $\mathcal{N}(\mu, \sigma^2)$ 。

这解释了为什么高斯分布在自然界和机器学习中如此普遍——在给定均值和方差的约束下，它是“最大不确定性”（最大熵）的分布。

本章小结

概念	定义/公式	含义
自信息	$I(A) = -\log P(A)$	事件 A 发生所携带的信息量
香农熵	$H(X) = -\sum_x p(x) \log p(x)$	X 的平均不确定性
联合熵	$H(X, Y) = -\sum_{x,y} p(x, y) \log p(x, y)$	(X, Y) 联合系统的不确定性
条件熵	$H(Y X) = H(X, Y) - H(X)$	已知 X 后 Y 的剩余不确定性
互信息	$I(X; Y) = H(X) - H(X Y)$	X 与 Y 共享的信息量
KL 散度	$D_{\text{KL}}(P Q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$	P 与 Q 的差异（不对称）
交叉熵	$H(P, Q) = H(P) + D_{\text{KL}}(P Q)$	用 Q 编码 P 的平均码长

核心关系链：

$$H(P, Q) = H(P) + D_{\text{KL}}(P\|Q) \geq H(P)$$

$$I(X; Y) = H(X) - H(X | Y) = H(Y) - H(Y | X) = H(X) + H(Y) - H(X, Y)$$

$$H(X, Y) = H(X) + H(Y | X) = H(Y) + H(X | Y)$$

关键不等式：

- $D_{\text{KL}}(P\|Q) \geq 0$ （等号当且仅当 $P = Q$ ）
- $H(Y | X) \leq H(Y)$ （条件减少不确定性）
- $I(X; Y) \geq 0$ （互信息非负）
- 数据处理不等式： $X \rightarrow Y \rightarrow Z$ 则 $I(X; Z) \leq I(X; Y)$

深度学习应用

22.A 交叉熵损失函数

交叉熵损失是最广泛使用的分类损失函数，其信息论基础如下：

设真实标签的 one-hot 分布为 P （即 $p(k) = \mathbb{1}[k = y]$ ），模型预测分布为 $Q = \text{Softmax}(\mathbf{z})$ ，则：

$$\mathcal{L}_{\text{CE}} = H(P, Q) = H(P) + D_{\text{KL}}(P \| Q) = 0 + D_{\text{KL}}(P \| Q)$$

由于 $H(P) = 0$ （one-hot 分布熵为 0），所以最小化交叉熵等于最小化 **KL** 散度。

单样本损失简化为： $\mathcal{L}_{\text{CE}} = -\log q_y$ （仅需真实类别的预测概率）。

22.B VAE 的 ELBO 推导

变分自编码器（Variational Autoencoder, VAE）的核心是最大化证据下界（Evidence Lower BOund, ELBO）。

目标：对观测数据 $\mathbf{x}$ ，最大化对数似然 $\log p(\mathbf{x})$ 。

引入近似后验分布 $q_\phi(\mathbf{z} | \mathbf{x})$ 来近似真实后验 $p_\theta(\mathbf{z} | \mathbf{x})$ ：

$$\begin{aligned} \log p_\theta(\mathbf{x}) &= \log \int p_\theta(\mathbf{x}, \mathbf{z}) d\mathbf{z} \\ &= \log \int q_\phi(\mathbf{z} | \mathbf{x}) \cdot \frac{p_\theta(\mathbf{x}, \mathbf{z})}{q_\phi(\mathbf{z} | \mathbf{x})} d\mathbf{z} \\ &= \log \mathbb{E}_{q_\phi(\mathbf{z} | \mathbf{x})} \left[\frac{p_\theta(\mathbf{x}, \mathbf{z})}{q_\phi(\mathbf{z} | \mathbf{x})} \right] \end{aligned}$$

由 **Jensen** 不等式（ $\log$ 是凹函数， $\log \mathbb{E}[\cdot] \geq \mathbb{E}[\log \cdot]$ ）：

$$\log p_\theta(\mathbf{x}) \geq \mathbb{E}_{q_\phi(\mathbf{z} | \mathbf{x})} \left[\log \frac{p_\theta(\mathbf{x}, \mathbf{z})}{q_\phi(\mathbf{z} | \mathbf{x})} \right] = \mathcal{L}_{\text{ELBO}}$$

展开 ELBO：

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q_\phi} [\log p_\theta(\mathbf{x} | \mathbf{z})] - D_{\text{KL}}(q_\phi(\mathbf{z} | \mathbf{x}) \| p(\mathbf{z}))$$

- 第一项（重建项）：解码器 $p_\theta(\mathbf{x} | \mathbf{z})$ 对输入的重建质量
- 第二项（正则项）：近似后验 $q_\phi(\mathbf{z} | \mathbf{x})$ 与先验 $p(\mathbf{z})$ （通常为标准正态 $\mathcal{N}(0, I)$ ）的接近程度

等价关系：

$$\log p_{\theta}(\mathbf{x}) = \mathcal{L}_{\text{ELBO}} + D_{\text{KL}}(q_{\phi}(\mathbf{z} | \mathbf{x}) \| p_{\theta}(\mathbf{z} | \mathbf{x}))$$

由于 KL 散度非负，ELBO 始终是 $\log p_{\theta}(\mathbf{x})$ 的下界。

22.C 信息瓶颈理论

信息瓶颈 (Information Bottleneck, IB) 理论由 Tishby 等人 (1999) 提出，后被用于解释深度学习神经网络的学习机制。

目标：寻找输入 X 的压缩表示 T ，使得：

1. T 尽量丢弃 X 中与 Y (标签) 无关的信息：最小化 $I(X; T)$
2. T 尽量保留 X 中与 Y 相关的信息：最大化 $I(T; Y)$

信息瓶颈目标函数 (带拉格朗日乘数 β)：

$$\mathcal{L}_{\text{IB}} = I(T; Y) - \beta \cdot I(X; T)$$

- $\beta \rightarrow 0$ ：强调预测 (T 保留更多 X 的信息)
- $\beta \rightarrow \infty$ ：强调压缩 (T 尽量简短)

信息平面 (Information Plane)：横轴为 $I(X; T)$ ，纵轴为 $I(T; Y)$ ，每层神经网络映射到平面上一点。

Tishby 的主张 (存在争议)：训练分为两阶段——先快速拟合 ($I(T; Y)$ 上升)，后压缩 ($I(X; T)$ 下降)，对应泛化能力的形成。

与 VAE 的联系：VAE 的 ELBO 中， β -VAE 将 KL 正则系数设为 $\beta > 1$ ，对应于信息瓶颈框架，使潜在表示更加紧凑。

PyTorch 代码示例

```
import torch
import torch.nn as nn
import torch.nn.functional as F
import numpy as np

# =====
# 1. 熵与互信息的计算
# =====

def entropy(p, eps=1e-10):
    """ 计算离散分布的香农熵 (自然对数单位：奈特) """
```

```

    p = p + eps # 避免 log(0)
    return -(p * torch.log(p)).sum(dim=-1)

def kl_divergence(p, q, eps=1e-10):
    """ 计算  $KL(P || Q)$  """
    p = p + eps
    q = q + eps
    return (p * torch.log(p / q)).sum(dim=-1)

def cross_entropy_manual(p, q, eps=1e-10):
    """ 计算交叉熵  $H(P, Q)$  """
    q = q + eps
    return -(p * torch.log(q)).sum(dim=-1)

# 示例: 均匀分布 vs 尖锐分布
p_uniform = torch.tensor([0.25, 0.25, 0.25, 0.25]) # 均匀分布
p_sharp = torch.tensor([0.7, 0.1, 0.1, 0.1]) # 尖锐分布

print("=== 熵 ===")
print(f" 均匀分布熵: {entropy(p_uniform):.4f} 奈特 (理论值: {np.log(4):.4f})")
print(f" 尖锐分布熵: {entropy(p_sharp):.4f} 奈特")

print("\n=== KL 散度 (非对称性) ===")
print(f"KL(uniform || sharp) = {kl_divergence(p_uniform, p_sharp):.4f}")
print(f"KL(sharp || uniform) = {kl_divergence(p_sharp, p_uniform):.4f}")

print("\n=== 交叉熵 = 熵 + KL 散度 ===")
H_p = entropy(p_uniform)
KL = kl_divergence(p_uniform, p_sharp)
H_pq = cross_entropy_manual(p_uniform, p_sharp)
print(f"H(P) = {H_p:.4f}")
print(f"KL(P||Q) = {KL:.4f}")
print(f"H(P,Q) = {H_pq:.4f}")
print(f"H(P)+KL = {H_p + KL:.4f} (验证等式成立: {torch.isclose(H_pq, H_p + KL)})")

# =====
# 2. 分类任务中的交叉熵损失
# =====
print("\n=== 分类交叉熵损失 ===")

```

```

logits = torch.tensor([[2.0, 1.0, 0.1], # 样本 1
                      [0.1, 0.5, 2.5]]) # 样本 2
labels = torch.tensor([0, 2])          # 真实类别

# PyTorch 内置 (接受 logits)
ce_loss_fn = nn.CrossEntropyLoss()
loss_pytorch = ce_loss_fn(logits, labels)

# 手动计算:  $-\log(p_{true})$ 
probs = F.softmax(logits, dim=1)
loss_manual = -torch.log(probs[torch.arange(2), labels]).mean()

print(f"PyTorch CE Loss: {loss_pytorch.item():.4f}")
print(f"手动计算          : {loss_manual.item():.4f}")

# 解释: 最小化 CE = 最小化  $KL(one-hot || pred)$ 
# 因为  $H(one-hot) = 0$ , 所以  $H(P, Q) = KL(P||Q)$ 
q = probs
one_hot = F.one_hot(labels, num_classes=3).float()
kl_per_sample = kl_divergence(one_hot, q)
print(f"KL 散度 (等于 CE) : {kl_per_sample.mean():.4f}")

# =====
# 3. VAE: ELBO 实现
# =====

class VAE(nn.Module):
    """ 简单 VAE 示例, 展示 ELBO 的两项 """
    def __init__(self, input_dim=784, latent_dim=20):
        super().__init__()
        # 编码器: 输出均值和对数方差
        self.encoder = nn.Sequential(nn.Linear(input_dim, 256), nn.ReLU())
        self.fc_mu = nn.Linear(256, latent_dim)
        self.fc_logvar = nn.Linear(256, latent_dim)
        # 解码器
        self.decoder = nn.Sequential(
            nn.Linear(latent_dim, 256), nn.ReLU(),
            nn.Linear(256, input_dim), nn.Sigmoid()
        )

    def encode(self, x):

```

```

        h = self.encoder(x)
        return self.fc_mu(h), self.fc_logvar(h)

    def reparameterize(self, mu, logvar):
        """ 重参数化技巧:  $z = \mu + \epsilon * \sigma$ ,  $\epsilon \sim N(0, I)$  """
        std = torch.exp(0.5 * logvar)
        eps = torch.randn_like(std)
        return mu + eps * std

    def decode(self, z):
        return self.decoder(z)

    def forward(self, x):
        mu, logvar = self.encode(x)
        z = self.reparameterize(mu, logvar)
        x_recon = self.decode(z)
        return x_recon, mu, logvar

    def elbo_loss(self, x, beta=1.0):
        """
        ELBO =  $E[\log p(x/z)] - \beta * KL(q(z/x) \parallel p(z))$ 
        其中  $p(z) = N(0, I)$ ,  $KL$  有解析解
        """
        x_recon, mu, logvar = self.forward(x)

        # 重建项:  $E[\log p(x/z)]$ , 用二元交叉熵近似
        recon_loss = F.binary_cross_entropy(x_recon, x, reduction='sum')

        # KL 散度解析解:  $KL(N(\mu, \sigma^2) \parallel N(0, I))$ 
        # =  $-0.5 * \sum(1 + \logvar - \mu^2 - \exp(\logvar))$ 
        kl_loss = -0.5 * torch.sum(1 + logvar - mu.pow(2) - logvar.exp())

        # ELBO 下界 (最大化 ELBO = 最小化负 ELBO)
        return recon_loss + beta * kl_loss, recon_loss, kl_loss

# 演示
vae = VAE(input_dim=784, latent_dim=20)
x_dummy = torch.rand(32, 784) # 32 个样本

elbo, recon, kl = vae.elbo_loss(x_dummy, beta=1.0)
print(f"\n=== VAE ELBO ===")

```

```
print(f"ELBO (负值, 待最小化) : {elbo.item():.2f}")
print(f" 重建损失          : {recon.item():.2f}")
print(f"  KL 散度          : {kl.item():.2f}")
print(f"  关系: ELBO = Recon + KL = {recon.item():.2f} + {kl.item():.2f}")
```

beta-VAE: 信息瓶颈视角

```
print(f"\nbeta-VAE (beta=4.0, 更强压缩):")
elbo_b, recon_b, kl_b = vae.elbo_loss(x_dummy, beta=4.0)
print(f"  KL 散度加权后      : {4.0 * kl_b.item():.2f}")
print(f"  信息瓶颈: beta 越大, 潜在空间越紧凑 (I(X;Z) 越小) ")
```

=====

4. 信息论视角: 熵与预测不确定性

=====

```
print("\n=== 预测不确定性 (熵) ===")
```

置信预测 vs 不确定预测

```
confident_probs = torch.tensor([[0.95, 0.03, 0.02],
                                [0.02, 0.96, 0.02]])
uncertain_probs = torch.tensor([[0.34, 0.33, 0.33],
                                [0.4, 0.3, 0.3]])
```

```
conf_entropy = entropy(confident_probs)
uncert_entropy = entropy(uncertain_probs)
```

```
print(f" 置信预测的熵      : {conf_entropy.numpy().round(3)}")
print(f" 不确定预测的熵    : {uncert_entropy.numpy().round(3)}")
print(f" 最大熵 (均匀 3 类): {np.log(3):.4f}")
print("\n=> 熵可作为模型不确定性的度量 (用于主动学习、OOD 检测) ")
```

输出示例:

=== 熵 ===

均匀分布熵: 1.3863 奈特 (理论值: 1.3863)

尖锐分布熵: 0.8018 奈特

=== KL散度 (非对称性) ===

KL(uniform || sharp) = 0.4506

KL(sharp || uniform) = 0.3185

=== 交叉熵 = 熵 + KL散度 ===

H(P) = 1.3863
KL(P||Q) = 0.4506
H(P,Q) = 1.8369
H(P)+KL = 1.8369 (验证等式成立: True)

=== 分类交叉熵损失 ===
PyTorch CE Loss: 0.3266
手动计算 : 0.3266
KL散度 (等于CE) : 0.3266

=== VAE ELBO ===
ELBO (负值, 待最小化) : 17842.23
重建损失 : 17831.42
KL散度 : 10.81
关系: ELBO = Recon + KL = 17831.42 + 10.81

beta-VAE (beta=4.0, 更强压缩):
KL散度加权后 : 43.24
信息瓶颈: beta越大, 潜在空间越紧凑 (I(X;Z)越小)

=== 预测不确定性 (熵) ===
置信预测的熵 : [0.173 0.158]
不确定预测的熵 : [1.099 1.089]
最大熵 (均匀3类): 1.0986

=> 熵可作为模型不确定性的度量 (用于主动学习、OOD检测)

关键联系总结

信息论概念	深度学习对应	作用
交叉熵 $H(P, Q)$	分类损失函数	衡量预测分布与真实分布差异
KL 散度 $D_{KL}(P Q)$	VAE 正则项、知识蒸馏	驱使分布接近目标分布
熵 $H(X)$	不确定性度量	OOD 检测、主动学习、标签平滑
互信息 $I(X; Y)$	信息瓶颈、表示学习	度量特征与标签的关联强度
ELBO	VAE 训练目标	对数似然的可优化下界

信息论概念	深度学习对应	作用
数据处理不等式	表示学习瓶颈	压缩不损失预测所需信息

练习题

练习 22.1（熵的计算）

设随机变量 X 的分布为：

x	1	2	3	4
$p(x)$	1/2	1/4	1/8	1/8

- (a) 计算 $H(X)$ （以 2 为底，单位比特）
- (b) 这个分布的熵是否等于均匀分布的熵？为什么？
- (c) 若将 X 编码为二进制串，最优平均码长是多少？（与 $H(X)$ 比较）

练习 22.2（链式法则）

设 (X, Y) 的联合分布如下：

	$Y = 0$	$Y = 1$
$X = 0$	3/8	1/8
$X = 1$	1/8	3/8

- (a) 计算 $H(X)$ 、 $H(Y)$ 、 $H(X, Y)$
- (b) 计算 $H(X | Y)$ 和 $H(Y | X)$
- (c) 计算互信息 $I(X; Y)$ ，并验证 $H(X, Y) = H(X) + H(Y | X)$

练习 22.3（KL 散度性质）

设 $P = \mathcal{N}(0, 1)$ ， $Q = \mathcal{N}(\mu, 1)$ ，两个正态分布方差相同但均值不同。

- (a) 证明 $D_{\text{KL}}(P \| Q) = \frac{\mu^2}{2}$

（提示：正态分布的 KL 散度公式： $D_{\text{KL}}(\mathcal{N}(\mu_1, \sigma_1^2) \| \mathcal{N}(\mu_2, \sigma_2^2)) = \log \frac{\sigma_2}{\sigma_1} + \frac{\sigma_1^2 + (\mu_1 - \mu_2)^2}{2\sigma_2^2} - \frac{1}{2}$ ）

- (b) 当 $\mu = 0$ 时，KL 散度是多少？这与“等号成立条件”一致吗？
- (c) 验证 $D_{\text{KL}}(P \| Q) \neq D_{\text{KL}}(Q \| P)$ （当 $\mu \neq 0$ ，两者是否相等？）

练习 22.4 (VAE 推导)

VAE 中对角高斯近似后验 $q_\phi(\mathbf{z} | \mathbf{x}) = \mathcal{N}(\mu, \text{diag}(\sigma^2))$, 先验 $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。

(a) 利用练习 22.3 的结论, 推导 D -维情形下的 KL 散度解析解:

$$D_{\text{KL}}(q_\phi(\mathbf{z} | \mathbf{x}) \| p(\mathbf{z})) = -\frac{1}{2} \sum_{d=1}^D (1 + \log \sigma_d^2 - \mu_d^2 - \sigma_d^2)$$

(b) 解释为什么 $\sigma_d^2 \rightarrow 0$ (后验方差趋于零) 会使 KL 散度增大。

(c) 在 PyTorch 中, `logvar = log(sigma^2)`, 请写出 KL 散度的数值稳定计算表达式。

练习 22.5 (信息论不等式)

(a) 利用 KL 散度非负性, 证明吉布斯不等式:

$$-\sum_x p(x) \log q(x) \geq -\sum_x p(x) \log p(x)$$

即 $H(P, Q) \geq H(P)$, 等号当且仅当 $P = Q$ 。

(b) 证明对于取 n 个值的均匀分布 U , 和任意分布 P , 有 $D_{\text{KL}}(P \| U) = \log n - H(P)$, 从而推导最大熵原理: $H(P) \leq \log n$ 。

(c) 设神经网络每层的特征映射构成马尔可夫链 $X \rightarrow h_1 \rightarrow h_2 \rightarrow \dots \rightarrow h_L \rightarrow Y$ 。利用数据处理不等式, 说明为什么深度网络的中间层不可能比原始输入含有更多关于标签 Y 的信息。这对信息瓶颈理论有何启示?

练习答案

点击展开练习 22.1 答案

(a) 计算熵 (以 2 为底):

$$H(X) = -\frac{1}{2} \log_2 \frac{1}{2} - \frac{1}{4} \log_2 \frac{1}{4} - \frac{1}{8} \log_2 \frac{1}{8} - \frac{1}{8} \log_2 \frac{1}{8}$$

$$= \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3 = \frac{1}{2} + \frac{1}{2} + \frac{3}{8} + \frac{3}{8} = \frac{7}{4} = 1.75 \text{ 比特}$$

(b) 均匀分布 (4 个值) 的熵为 $\log_2 4 = 2$ 比特, 大于本题的 1.75 比特。

原因: 本题分布不均匀, $x = 1$ 的概率为 $1/2$, 集中度较高, 不确定性小于均匀分布, 因此熵更小。

(c) 香农源编码定理指出, 最优平均码长满足 $H(X) \leq \bar{L} < H(X) + 1$ 。

最优前缀码（哈夫曼码）： $1 \rightarrow 0, 2 \rightarrow 10, 3 \rightarrow 110, 4 \rightarrow 111$ 。

平均码长： $\bar{L} = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3 = 1.75$ 比特。

本例恰好等于 $H(X)$ ，因为概率恰好是 2 的整数次幂，实现了无损编码。

点击展开练习 22.2 答案

(a) 边缘分布： $p_X(0) = 3/8 + 1/8 = 1/2, p_X(1) = 1/2, Y$ 同理。

$$H(X) = H(Y) = -\frac{1}{2} \log_2 \frac{1}{2} - \frac{1}{2} \log_2 \frac{1}{2} = 1 \text{ 比特}$$

$$H(X, Y) = -2 \cdot \frac{3}{8} \log_2 \frac{3}{8} - 2 \cdot \frac{1}{8} \log_2 \frac{1}{8}$$

$$= -\frac{3}{4} \log_2 \frac{3}{8} - \frac{1}{4} \log_2 \frac{1}{8}$$

$$= -\frac{3}{4}(\log_2 3 - 3) - \frac{1}{4}(-3) = \frac{9}{4} - \frac{3}{4} \log_2 3 + \frac{3}{4}$$

$$= 3 - \frac{3}{4} \log_2 3 \approx 3 - \frac{3}{4} \times 1.585 \approx 1.811 \text{ 比特}$$

(b) 由链式法则：

$$H(Y | X) = H(X, Y) - H(X) \approx 1.811 - 1 = 0.811 \text{ 比特}$$

同理 $H(X | Y) \approx 0.811$ 比特（由对称性）。

(c) 互信息：

$$I(X; Y) = H(Y) - H(Y | X) \approx 1 - 0.811 = 0.189 \text{ 比特}$$

验证链式法则： $H(X) + H(Y | X) \approx 1 + 0.811 = 1.811 = H(X, Y) \square$

由于 $I(X; Y) > 0$ ， X 与 Y 不独立（对角线概率更高，存在正相关）。

点击展开练习 22.3 答案

(a) 代入正态 KL 散度公式， $\mu_1 = 0, \mu_2 = \mu, \sigma_1 = \sigma_2 = 1$ ：

$$D_{\text{KL}}(\mathcal{N}(0, 1) \| \mathcal{N}(\mu, 1)) = \log \frac{1}{1} + \frac{1 + (0 - \mu)^2}{2 \cdot 1} - \frac{1}{2} = \frac{1 + \mu^2}{2} - \frac{1}{2} = \frac{\mu^2}{2}$$

(b) 当 $\mu = 0$ 时， $D_{\text{KL}} = 0$ ，因为此时 $P = Q = \mathcal{N}(0, 1)$ ，与“等号成立当且仅当 $P = Q$ ”完全一致。

(c) $D_{\text{KL}}(Q\|P) = D_{\text{KL}}(\mathcal{N}(\mu, 1)\|\mathcal{N}(0, 1))$:

$$= \log \frac{1}{1} + \frac{1 + \mu^2}{2} - \frac{1}{2} = \frac{\mu^2}{2}$$

本例中 $D_{\text{KL}}(P\|Q) = D_{\text{KL}}(Q\|P) = \mu^2/2$ (等方差正态分布情形对称)。

一般地, 当方差不同时, 两个方向的 KL 散度不等, 如 $\mathcal{N}(0, 1)$ 与 $\mathcal{N}(0, 2)$ 的两方向 KL 散度不同。

点击展开练习 22.4 答案

(a) 各维度独立, 总 KL 散度为各维之和。对第 d 维, $q_d = \mathcal{N}(\mu_d, \sigma_d^2)$, $p_d = \mathcal{N}(0, 1)$:

$$\begin{aligned} D_{\text{KL}}(q_d\|p_d) &= \log \frac{1}{\sigma_d} + \frac{\sigma_d^2 + \mu_d^2}{2} - \frac{1}{2} = -\frac{1}{2} \log \sigma_d^2 + \frac{\sigma_d^2 + \mu_d^2 - 1}{2} \\ &= -\frac{1}{2} (1 + \log \sigma_d^2 - \mu_d^2 - \sigma_d^2) \end{aligned}$$

求和: $D_{\text{KL}}(q\|p) = -\frac{1}{2} \sum_{d=1}^D (1 + \log \sigma_d^2 - \mu_d^2 - \sigma_d^2) \square$

(b) 当 $\sigma_d^2 \rightarrow 0$ 时, $\log \sigma_d^2 \rightarrow -\infty$, 使得 $-(1 + \log \sigma_d^2 - \mu_d^2 - \sigma_d^2)$ 中的 $-\log \sigma_d^2 \rightarrow +\infty$, KL 散度趋向正无穷。

直观理解: 方差趋于零意味着近似后验完全”确定”, 与扩散的先验 $\mathcal{N}(0, I)$ 差异极大。

(c) 令 $\text{logvar} = \log(\text{sigma}^2)$, 则 $\text{sigma}^2 = \exp(\text{logvar})$:

```
kl = -0.5 * torch.sum(1 + logvar - mu.pow(2) - logvar.exp())
```

使用 `logvar` 而非直接用 `sigma^2` 的优点: 避免对负数求对数, 数值更稳定; 梯度更平滑。

点击展开练习 22.5 答案

(a) 由 KL 散度非负性:

$$D_{\text{KL}}(P\|Q) = \sum_x p(x) \log \frac{p(x)}{q(x)} = -\sum_x p(x) \log q(x) + \sum_x p(x) \log p(x) \geq 0$$

因此 $-\sum_x p(x) \log q(x) \geq -\sum_x p(x) \log p(x)$, 即 $H(P, Q) \geq H(P)$ 。

等号成立当 $D_{\text{KL}}(P\|Q) = 0$, 即 $P = Q$ 。

(b) 设均匀分布 $u(x) = 1/n$:

$$D_{\text{KL}}(P\|U) = \sum_x p(x) \log \frac{p(x)}{1/n} = \sum_x p(x) \log p(x) + \sum_x p(x) \log n = -H(P) + \log n$$

由非负性 $D_{\text{KL}}(P\|U) \geq 0$, 故 $\log n - H(P) \geq 0$, 即 $H(P) \leq \log n$ 。

等号当 $P = U$ (均匀分布) 成立, 证明最大熵原理。

(c) 马尔可夫链 $X \rightarrow h_1 \rightarrow h_2 \rightarrow \dots \rightarrow h_L \rightarrow \hat{Y}$ ，由数据处理不等式逐步应用：

$$I(X; \hat{Y}) \leq I(X; h_L) \leq \dots \leq I(X; h_1) \leq I(X; X) = H(X)$$

$$I(h_L; Y) \leq I(h_{L-1}; Y) \leq \dots \leq I(h_1; Y) \leq I(X; Y)$$

启示：- 每一层对 Y 所能保留的最大信息量 $I(h_i; Y)$ 不超过原始输入 $I(X; Y)$ - 深度网络无法凭空“创造”关于标签的信息，只能提取和压缩 - 信息瓶颈理论认为，优秀的表示 h 应在 $I(h; Y)$ 大的同时 $I(X; h)$ 小（压缩无关信息） - 这为正则化、Dropout 等技术提供了信息论解释：它们迫使网络丢弃与预测无关的冗余信息

第二十三章：蒙特卡洛方法

学习目标

完成本章学习后，你将能够：

- 理解蒙特卡洛积分的原理，掌握用随机采样估计积分的方法并分析其误差
- 掌握重要性采样技术，理解如何通过选取合适的提议分布来降低估计方差
- 理解拒绝采样的工作机制，能够针对难以直接采样的分布设计采样算法
- 掌握马尔可夫链蒙特卡洛（MCMC）的原理，理解平稳分布与细致平衡条件
- 能够将 MC Dropout、贝叶斯深度学习和扩散模型中的蒙特卡洛思想付诸实践

正文内容

23.1 蒙特卡洛积分

23.1.1 基本思想 蒙特卡洛方法（Monte Carlo Methods）是一类依赖随机采样来解决计算问题的算法族，其名称来源于摩纳哥著名赌城，暗示其随机性本质。该方法由冯·诺依曼（von Neumann）和乌拉姆（Ulam）在二十世纪四十年代研究核武器时系统化提出。

核心思想：用样本均值近似期望。

设 $f(x)$ 是定义在区间 $[a, b]$ 上的函数，欲计算积分：

$$I = \int_a^b f(x) dx$$

若 $X \sim \text{Uniform}(a, b)$ ，则：

$$I = (b-a) \int_a^b f(x) \cdot \frac{1}{b-a} dx = (b-a) \mathbb{E}[f(X)]$$

因此，从 $\text{Uniform}(a, b)$ 独立同分布地抽取样本 $X_1, X_2, \dots, X_n$ ，构造估计量：

$$\hat{I}_n = \frac{b-a}{n} \sum_{i=1}^n f(X_i)$$

由大数定律，当 $n \rightarrow \infty$ 时， $\hat{I}_n \xrightarrow{P} I$ 。

更一般的形式：设 $p(x)$ 为某概率密度函数，则：

$$I = \int f(x) dx = \int \frac{f(x)}{p(x)} \cdot p(x) dx = \mathbb{E}_p \left[\frac{f(X)}{p(X)} \right]$$

从 $p(x)$ 中抽取 $X_1, \dots, X_n$ ，估计量为：

$$\hat{I}_n = \frac{1}{n} \sum_{i=1}^n \frac{f(X_i)}{p(X_i)}$$

23.1.2 误差分析 定理 23.1（蒙特卡洛积分误差）设 $\text{Var}[f(X)] = \sigma^2 < \infty$ ，则：

$$\text{Var}[\hat{I}_n] = \frac{\sigma^2}{n}$$

标准误差（Standard Error）为：

$$\text{SE}(\hat{I}_n) = \frac{\sigma}{\sqrt{n}}$$

关键结论：蒙特卡洛估计的误差以 $O(n^{-1/2})$ 的速率收缩，与积分的维度无关。这与确定性数值积分方法（如辛普森法则在一维误差为 $O(n^{-4})$ ，但在 d 维空间退化为 $O(n^{-4/d})$ ）形成鲜明对比。因此，当维度 $d \geq 5$ 时，蒙特卡洛方法往往是更优的选择。

95% 置信区间：由中心极限定理，

$$P\left(|\hat{I}_n - I| \leq 1.96 \frac{\hat{\sigma}}{\sqrt{n}}\right) \approx 0.95$$

其中 $\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (f(X_i) - \hat{I}_n)^2$ 是样本方差。

例 23.1 用蒙特卡洛方法估计 π 。

将单位圆嵌入正方形 $[-1, 1]^2$ ，均匀撒点：

$$\hat{\pi} = 4 \cdot \frac{\#\{(x_i, y_i) : x_i^2 + y_i^2 \leq 1\}}{n}$$

当 $n = 10^6$ 时，典型误差约为 $\frac{4\sigma}{\sqrt{n}} \approx \frac{4 \cdot 0.5}{\sqrt{10^6}} = 0.002$ 。

23.1.3 方差与收敛性质 蒙特卡洛估计量 $\hat{I}_n$ 具有以下统计性质：

- 无偏性： $\mathbb{E}[\hat{I}_n] = I$
- 一致性： $\hat{I}_n \xrightarrow{a.s.} I$ （强大数定律）
- 渐近正态性： $\sqrt{n}(\hat{I}_n - I) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$

降低方差 σ^2 是蒙特卡洛方法的核心课题，由此催生了重要性采样、控制变量、分层采样等方差缩减技术。

23.2 重要性采样

23.2.1 基本原理 重要性采样（Importance Sampling, IS）是最重要的方差缩减技术之一。

核心恒等式：对任意正密度函数 $q(x)$ （称为提议分布或重要性分布），

$$I = \int f(x) p(x) dx = \int \frac{f(x) p(x)}{q(x)} \cdot q(x) dx = \mathbb{E}_q \left[\frac{f(X) p(X)}{q(X)} \right]$$

从 $q(x)$ 中抽取 $X_1, \dots, X_n$ ，重要性采样估计量为：

$$\hat{I}_n^{\text{IS}} = \frac{1}{n} \sum_{i=1}^n \frac{f(X_i) p(X_i)}{q(X_i)} = \frac{1}{n} \sum_{i=1}^n f(X_i) w(X_i)$$

其中 重要性权重 $w(x) = p(x)/q(x)$ 。

23.2.2 最优提议分布 定理 23.2（最优提议分布）使得重要性采样估计量方差最小的提议分布为：

$$q^*(x) = \frac{|f(x)| p(x)}{\int |f(x)| p(x) dx}$$

当 $f(x) \geq 0$ 时，最优提议分布为：

$$q^*(x) \propto f(x) p(x)$$

此时估计量方差为零（因为每个样本的贡献完全相同）。当然，这要求我们已知积分值，因此实践中只能逼近最优提议分布。

直觉： $q(x)$ 应在 $|f(x)|p(x)$ 较大的区域赋予更多采样权重，即“把子弹用在刀刃上”。

23.2.3 方差分析 命题 23.1 重要性采样估计量的方差为：

$$\text{Var}[\hat{I}_n^{\text{IS}}] = \frac{1}{n} \left(\int \frac{f(x)^2 p(x)^2}{q(x)} dx - I^2 \right)$$

与朴素蒙特卡洛方差 $\frac{1}{n} (\int f(x)^2 p(x) dx - I^2)$ 相比，若 $q(x)$ 选取得当，可使方差大幅减小。

警告（方差爆炸）：若 $q(x)$ 在某区域比 $p(x)$ 小得多，则权重 $w(x) = p(x)/q(x)$ 会非常大，导致方差急剧增大。一个好的经验准则是： $q(x)$ 的尾部应比 $p(x)$ 更重。

23.2.4 自归一化重要性采样 实际中 $p(x)$ 往往只知道到一个归一化常数，即 $p(x) = \tilde{p}(x)/Z_p, q(x) = \tilde{q}(x)/Z_q$ 。此时使用自归一化重要性采样（Self-normalized IS）：

$$\hat{I}_n^{\text{SNIS}} = \frac{\sum_{i=1}^n \tilde{w}(X_i) f(X_i)}{\sum_{i=1}^n \tilde{w}(X_i)}, \quad \tilde{w}(x) = \frac{\tilde{p}(x)}{\tilde{q}(x)}$$

该估计量是有偏的，但渐近无偏，且在实践中应用广泛。

有效样本量（Effective Sample Size, ESS）度量重要性权重的退化程度：

$$\text{ESS} = \frac{(\sum_{i=1}^n w_i)^2}{\sum_{i=1}^n w_i^2}$$

其中 $w_i = \tilde{w}(X_i) / \sum_j \tilde{w}(X_j)$ 为归一化权重。ESS 取值范围为 $[1, n]$ ，越接近 n 表示提议分布越好。

23.3 拒绝采样

23.3.1 算法原理 拒绝采样（Rejection Sampling）用于从难以直接采样的目标分布 $p(x)$ 中生成样本。

设置：- 目标分布： $p(x)$ （只知道到比例，即 $p(x) \propto \tilde{p}(x)$ ）- 提议分布： $q(x)$ ，可以直接采样 - 包络常数： $M \geq 1$ ，满足 $\tilde{p}(x) \leq M \cdot q(x)$ 对所有 x 成立

算法 23.1（拒绝采样）：

重复直到收集到足够样本：

1. 从 $q(x)$ 中采样 $X \sim q$
2. 从均匀分布采样 $U \sim \text{Uniform}(0, 1)$
3. 若 $U \leq \tilde{p}(X) / (M \cdot q(X))$ ，则接受 X
否则，拒绝 X

输出所有被接受的样本

定理 23.3 (正确性) 拒绝采样算法输出的样本服从目标分布 $p(x)$ 。

证明： 接受概率为：

$$P(\text{接受} \mid X = x) = \frac{\tilde{p}(x)}{M \cdot q(x)}$$

被接受样本的密度正比于：

$$q(x) \cdot \frac{\tilde{p}(x)}{M \cdot q(x)} = \frac{\tilde{p}(x)}{M} \propto p(x) \quad \square$$

23.3.2 效率分析 接受率 (Acceptance Rate)：

$$\alpha = P(\text{接受}) = \int q(x) \cdot \frac{\tilde{p}(x)}{M \cdot q(x)} dx = \frac{1}{M} \int \tilde{p}(x) dx = \frac{Z_p}{M}$$

其中 $Z_p = \int \tilde{p}(x) dx$ 是归一化常数。

为了使算法高效，需要 M 尽可能小，即 $q(x)$ 应尽量贴近 $p(x)$ 的形状。

维度灾难： 在高维空间中，拒绝采样效率急剧下降。若在 d 维空间中， q 是一个稍微比 p 大的高斯分布，接受率大约为 $(1 - \epsilon)^d$ ，当 $d = 100, \epsilon = 0.01$ 时，接受率约为 $e^{-1} \approx 0.37$ ；当方差差距更大时接受率趋近于零。这是为什么 MCMC 在高维空间中优于拒绝采样的根本原因。

23.3.3 自适应拒绝采样 对于对数凹 (log-concave) 的目标分布，可以使用自适应拒绝采样 (Adaptive Rejection Sampling)：通过若干评估点构造分段指数包络，随着采样进行不断更新包络，使接受率逐步提高。

23.4 马尔可夫链蒙特卡洛 (MCMC)

23.4.1 马尔可夫链回顾 马尔可夫链 (Markov Chain) 是满足马尔可夫性质的随机过程：

$$P(X_{t+1} = x \mid X_t, X_{t-1}, \dots, X_0) = P(X_{t+1} = x \mid X_t)$$

即未来状态只依赖于当前状态，与历史无关。

转移核 (Transition Kernel)： $T(x' \mid x)$ 表示从状态 x 转移到 x' 的概率 (连续情形为概率密度)。

平稳分布 (Stationary Distribution)： 若分布 $\pi(x)$ 满足：

$$\pi(x') = \int T(x' \mid x) \pi(x) dx$$

则称 π 为该马尔可夫链的平稳分布。

细致平衡条件 (Detailed Balance Condition): 若

$$\pi(x) T(x' | x) = \pi(x') T(x | x')$$

对所有 x, x' 成立, 则 π 是平稳分布。细致平衡是充分但非必要条件, 满足细致平衡的马尔可夫链称为可逆马尔可夫链。

遍历定理 (Ergodic Theorem): 若马尔可夫链是不可约 (irreducible) 且非周期 (aperiodic) 的, 则对任意初始分布, 经过足够长时间后, 链的分布收敛到唯一平稳分布 π , 且:

$$\frac{1}{T} \sum_{t=1}^T f(X_t) \xrightarrow{a.s.} \mathbb{E}_{\pi}[f(X)]$$

23.4.2 MCMC 的核心思想 蒙特卡洛马尔可夫链 (Markov Chain Monte Carlo, MCMC) 的关键思想是:

构造一条马尔可夫链, 使其平稳分布恰好是目标分布 $p(x)$ 。

然后通过运行该马尔可夫链, 得到 (近似) 服从 $p(x)$ 的样本序列, 用这些样本计算期望值。

MCMC 的优势在于: - 不需要知道归一化常数 Z , 只需要能计算 $\tilde{p}(x) \propto p(x)$ - 适用于高维复杂分布 - 理论上可以采样任意复杂分布

MCMC 的主要挑战: - 样本之间存在自相关性 (Autocorrelation), 有效样本量小于总样本量 - 需要燃烧期 (Burn-in Period): 链收敛到平稳分布前的样本需丢弃 - 混合性 (Mixing): 链遍历整个高概率区域的速度

23.4.3 燃烧期与混合 燃烧期: MCMC 从任意初始状态 X_0 出发, 前 B 步的样本因受初始值影响而不服从目标分布, 通常将这部分样本丢弃。

自相关时间 (Integrated Autocorrelation Time, IAT):

$$\tau_{\text{int}} = 1 + 2 \sum_{k=1}^{\infty} \rho_k$$

其中 $\rho_k = \text{Corr}(f(X_t), f(X_{t+k}))$ 是滞后 k 的自相关系数。

有效样本量: 从总样本量 n 中获得的有效独立样本数为:

$$n_{\text{eff}} = \frac{n}{2\tau_{\text{int}}}$$

诊断工具: - $\hat{R}$ 统计量 (Gelman-Rubin): 多条链的方差之比, 接近 1 表示收敛 - 有效样本量 (ESS) - 迹图 (Trace Plot): 观察链的轨迹是否平稳

23.5 Gibbs 采样与 Metropolis-Hastings

23.5.1 Metropolis-Hastings 算法 Metropolis-Hastings (MH) 算法是最通用的 MCMC 方法，由 Metropolis 等人 (1953) 提出，后由 Hastings (1970) 推广。

设置：目标分布 $p(x)$ (已知 $\tilde{p}(x) \propto p(x)$)，提议分布 $q(x' | x)$ 。

算法 23.2 (Metropolis-Hastings):

初始化 x_0 为任意值

For $t = 0, 1, 2, \dots$:

1. 提议步：从 $q(x' | x_t)$ 中采样候选点 x'

2. 计算接受率：

$$A(x', x_t) = \min(1, \frac{\tilde{p}(x') \cdot q(x_t | x')}{\tilde{p}(x_t) \cdot q(x' | x_t)})$$

3. 接受/拒绝：

以概率 $A(x', x_t)$ 令 $x_{t+1} = x'$ (接受)

以概率 $1 - A(x', x_t)$ 令 $x_{t+1} = x_t$ (拒绝)

定理 23.4 (MH 满足细致平衡) MH 算法构造的马尔可夫链满足细致平衡条件，因此 $p(x)$ 是其平稳分布。

证明：设 $x \neq x'$ ，转移密度为：

$$T(x' | x) = q(x' | x) \cdot A(x', x)$$

需验证 $p(x)T(x' | x) = p(x')T(x | x')$ ，即：

$$p(x)q(x' | x) \min\left(1, \frac{p(x')q(x | x')}{p(x)q(x' | x)}\right) = p(x')q(x | x') \min\left(1, \frac{p(x)q(x' | x)}{p(x')q(x | x')}\right)$$

不失一般性设 $p(x)q(x' | x) \geq p(x')q(x | x')$ ，则左边 = $p(x')q(x | x')$ ，右边 = $p(x')q(x | x') \cdot 1 = p(x')q(x | x')$ ，相等。□

常见提议分布：

- 随机游走 MH: $q(x' | x) = \mathcal{N}(x' | x, \sigma^2 I)$ ，对称，接受率简化为 $\min(1, \tilde{p}(x')/\tilde{p}(x))$
- 独立 MH: $q(x' | x) = q(x')$ ，退化为重要性采样的 MCMC 版本

步长选择：对随机游走 MH，步长 σ 影响显著：- σ 过小：接受率高但混合慢（小步探索）- σ 过大：提议常落在低概率区，接受率低 - 最优接受率：在高斯目标下，最优接受率约为 0.234 ($d \rightarrow \infty$)

23.5.2 Gibbs 采样 Gibbs 采样 (Gibbs Sampling) 是专为多维分布设计的 MCMC 方法，其核心思想是将高维联合采样分解为一系列条件采样。

设置：目标联合分布 $p(x_1, x_2, \dots, x_d)$ ，假设每个分量的条件分布 $p(x_i | x_{-i})$ 容易采样（其中 $x_{-i} = (x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_d)$ ）。

算法 23.3 (系统 Gibbs 采样):

初始化 $\mathbf{X}^{\wedge}(0) = (x_{\wedge 1}(0), \dots, x_{\wedge d}(0))$
 For $t = 0, 1, 2, \dots$:
 从 $p(x_{\wedge 1} \mid x_{\wedge 2}^{\wedge}(t), x_{\wedge 3}^{\wedge}(t), \dots, x_{\wedge d}^{\wedge}(t))$ 中采样 $x_{\wedge 1}^{\wedge}(t+1)$
 从 $p(x_{\wedge 2} \mid x_{\wedge 1}^{\wedge}(t+1), x_{\wedge 3}^{\wedge}(t), \dots, x_{\wedge d}^{\wedge}(t))$ 中采样 $x_{\wedge 2}^{\wedge}(t+1)$
 ...
 从 $p(x_{\wedge d} \mid x_{\wedge 1}^{\wedge}(t+1), \dots, x_{\wedge d-1}^{\wedge}(t+1))$ 中采样 $x_{\wedge d}^{\wedge}(t+1)$
 令 $\mathbf{X}^{\wedge}(t+1) = (x_{\wedge 1}^{\wedge}(t+1), \dots, x_{\wedge d}^{\wedge}(t+1))$

命题 23.2 (Gibbs 采样的正确性) Gibbs 采样是 MH 算法的特例，接受率恒为 1。

证明：对第 i 分量的更新，提议分布 $q(x'_i \mid x) = p(x'_i \mid x_{-i})$ ，MH 接受率为：

$$A = \min \left(1, \frac{p(x'_i, x_{-i}) \cdot p(x_i \mid x_{-i})}{p(x_i, x_{-i}) \cdot p(x'_i \mid x_{-i})} \right) = \min \left(1, \frac{p(x_{-i})p(x'_i \mid x_{-i}) \cdot p(x_i \mid x_{-i})}{p(x_{-i})p(x_i \mid x_{-i}) \cdot p(x'_i \mid x_{-i})} \right) = 1 \quad \square$$

23.5.3 高斯图模型中的 Gibbs 采样 例 23.2 二元高斯分布的 Gibbs 采样。

设 $(X_1, X_2)^{\top} \sim \mathcal{N}(\mathbf{0}, \Sigma)$ ，其中 $\Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}$ 。

条件分布为：

$$X_1 \mid X_2 = x_2 \sim \mathcal{N}(\rho x_2, 1 - \rho^2)$$

$$X_2 \mid X_1 = x_1 \sim \mathcal{N}(\rho x_1, 1 - \rho^2)$$

Gibbs 采样交替从这两个一维高斯分布中采样，当 $|\rho|$ 接近 1 时，两个分量高度相关，Gibbs 采样混合较慢。

23.5.4 Hamiltonian Monte Carlo 简介 Hamiltonian Monte Carlo (HMC) 是现代高维 MCMC 的主流方法，被广泛用于贝叶斯深度学习 (Stan、NumPyro、PyMC 等)。

HMC 引入辅助动量变量 ρ ，将采样问题类比为哈密顿力学：

$$H(x, \rho) = -\log p(x) + \frac{1}{2} \rho^{\top} M^{-1} \rho$$

通过数值积分哈密顿方程 (Leapfrog 积分器) 进行长距离提议，大幅降低自相关。接受/拒绝步骤保证了算法的正确性。HMC 的有效采样率通常比随机游走 MH 高出数个数量级。

本章小结

本章系统介绍了蒙特卡洛方法的理论体系：

方法	核心思想	关键性质	适用场景
MC 积分	样本均值近似期望	误差 $O(n^{-1/2})$ ，维度无关	高维积分
重要性采样	换分布采样，加权修正	可大幅降低方差，但需好的提议分布	目标分布与提议相近时
拒绝采样	用包络分布过滤	样本独立，高维效率低	低维、对数凹分布
MH 算法	构造满足细致平衡的链	通用，接受率可调	通用高维采样
Gibbs 采样	逐分量条件采样	接受率恒为 1，需条件分布已知	多维，条件分布已知

核心思想：1. 蒙特卡洛方法的本质是用随机样本代替解析计算，以统计误差换取计算可行性 2. 方差是评价采样方法的核心指标，所有方差缩减技术都在减小 $\text{Var}[f(X)]$ 3. MCMC 通过构造平稳分布为目标分布的马尔可夫链，绕过归一化常数难题 4. 细致平衡条件是构造正确 MCMC 算法的充分条件，MH 算法将其提升为通用框架

深度学习应用

应用 23.A：MC Dropout 与不确定性估计

背景：传统神经网络给出点估计，不提供预测不确定性。Gal 和 Ghahramani (2016) 证明，在测试时保持 Dropout 开启并多次前向传播，等价于对贝叶斯神经网络进行近似推断。

MC Dropout 的数学基础：设网络权重的后验近似为混合高斯，Dropout 对应从该近似后验中采样。对输入 x^* ，预测分布近似为：

$$p(y^* \mid x^*, \mathcal{D}) \approx \frac{1}{T} \sum_{t=1}^T p(y^* \mid x^*, \hat{\omega}_t)$$

其中 $\hat{\omega}_t$ 是第 t 次 Dropout 随机采样得到的权重掩码 (Mask)。

预测均值与不确定性：

$$\mathbb{E}[y^*] \approx \frac{1}{T} \sum_{t=1}^T f^{\hat{\omega}_t}(x^*)$$

$$\text{Var}[y^*] \approx \underbrace{\frac{1}{T} \sum_{t=1}^T (f^{\hat{\omega}_t}(x^*))^2 - \left(\frac{1}{T} \sum_{t=1}^T f^{\hat{\omega}_t}(x^*) \right)^2}_{\text{认知不确定性 (模型不确定性)}} + \underbrace{\hat{\tau}^{-1}}_{\text{偶然不确定性}}$$

```
import torch
import torch.nn as nn
import torch.nn.functional as F

class BayesianMLP(nn.Module):
    """ 带 MC Dropout 的贝叶斯 MLP。 """

    def __init__(self, input_dim: int, hidden_dim: int, output_dim: int,
                  dropout_p: float = 0.1):
        super().__init__()
        self.fc1 = nn.Linear(input_dim, hidden_dim)
        self.fc2 = nn.Linear(hidden_dim, hidden_dim)
        self.fc3 = nn.Linear(hidden_dim, output_dim)
        self.dropout_p = dropout_p

    def forward(self, x: torch.Tensor) -> torch.Tensor:
        # 训练和测试时均使用 Dropout (不调用 model.eval())
        x = F.relu(F.dropout(self.fc1(x), p=self.dropout_p, training=True))
        x = F.relu(F.dropout(self.fc2(x), p=self.dropout_p, training=True))
        return self.fc3(x)

def mc_dropout_predict(model: BayesianMLP, x: torch.Tensor,
                      n_samples: int = 100) -> dict:
    """
    MC Dropout 推断：返回预测均值、方差和置信区间。

    Args:
        model: 带 Dropout 的神经网络
        x: 输入张量, 形状 (batch_size, input_dim)
        n_samples: 蒙特卡洛采样次数

    Returns:
        包含 mean、var、std、p5、p95 的字典
    """
    model.train() # 保持 Dropout 激活
```

```

with torch.no_grad():
    # 堆叠 T 次前向传播结果，形状 (T, batch_size, output_dim)
    preds = torch.stack([model(x) for _ in range(n_samples)], dim=0)

    mean = preds.mean(dim=0)          # (batch_size, output_dim)
    var = preds.var(dim=0)            # 认知不确定性
    std = var.sqrt()

    return {
        "mean": mean,
        "var": var,
        "std": std,
        "p5": preds.quantile(0.05, dim=0),
        "p95": preds.quantile(0.95, dim=0),
    }

```

示例：回归任务的不确定性估计

```

def demo_mc_dropout():
    torch.manual_seed(42)

    # 创建模型
    model = BayesianMLP(input_dim=1, hidden_dim=64, output_dim=1, dropout_p=0.1)

    # 模拟训练数据（正弦函数 + 噪声）
    x_train = torch.linspace(-3, 3, 100).unsqueeze(1)
    y_train = torch.sin(x_train) + 0.1 * torch.randn_like(x_train)

    optimizer = torch.optim.Adam(model.parameters(), lr=1e-3)
    for _ in range(500):
        optimizer.zero_grad()
        loss = F.mse_loss(model(x_train), y_train)
        loss.backward()
        optimizer.step()

    # 测试：包含训练域外的点（外推不确定性更大）
    x_test = torch.linspace(-5, 5, 200).unsqueeze(1)
    result = mc_dropout_predict(model, x_test, n_samples=200)

    mean = result["mean"].squeeze().numpy()
    std = result["std"].squeeze().numpy()

```

```

print(f" 训练域内 [-3,3] 平均不确定性: {std[50:150].mean():.4f}")
print(f" 训练域外 [3,5] 平均不确定性: {std[150:].mean():.4f}")
# 预期：域外不确定性显著更大

if __name__ == "__main__":
    demo_mc_dropout()

```

应用 23.B：变分推断与重要性采样（贝叶斯神经网络）

背景：贝叶斯神经网络（BNN）对权重 ω 建立后验分布，预测时对后验积分：

$$p(y^* | x^*, \mathcal{D}) = \int p(y^* | x^*, \omega) p(\omega | \mathcal{D}) d\omega$$

由于后验 $p(\omega | \mathcal{D})$ 不可直接采样，使用变分推断（VI）以参数化分布 $q_\phi(\omega)$ 近似后验，然后用重要性采样精化估计。

```

import torch
import torch.nn as nn

class BayesLinear(nn.Module):
    """
    贝叶斯线性层：权重服从因式分解高斯后验。
    使用 Local Reparameterization Trick 降低梯度方差。
    """

    def __init__(self, in_features: int, out_features: int):
        super().__init__()
        # 后验均值
        self.weight_mu = nn.Parameter(torch.zeros(out_features, in_features))
        # 后验对数标准差（保证正值）
        self.weight_log_sigma = nn.Parameter(
            torch.full((out_features, in_features), -3.0)
        )
        self.bias_mu = nn.Parameter(torch.zeros(out_features))
        self.bias_log_sigma = nn.Parameter(torch.full((out_features,), -3.0))

        nn.init.kaiming_normal_(self.weight_mu)

```

```

def forward(self, x: torch.Tensor) -> torch.Tensor:
    """Local Reparameterization: 直接对激活值而非权重重参数化。"""
    weight_sigma = self.weight_log_sigma.exp()
    bias_sigma = self.bias_log_sigma.exp()

    # 激活均值和方差
    act_mu = F.linear(x, self.weight_mu, self.bias_mu)
    act_var = F.linear(x.pow(2), weight_sigma.pow(2), bias_sigma.pow(2))

    # 重参数化采样
    eps = torch.randn_like(act_mu)
    return act_mu + act_var.sqrt() * eps

def kl_divergence(self) -> torch.Tensor:
    """与标准正态先验的 KL 散度（解析公式）。"""
    weight_sigma = self.weight_log_sigma.exp()
    bias_sigma = self.bias_log_sigma.exp()

    #  $KL(N(\mu, \sigma^2) \parallel N(0, 1)) = 0.5 * (\mu^2 + \sigma^2 - \log(\sigma^2) - 1)$ 
    kl_w = 0.5 * (self.weight_mu.pow(2) + weight_sigma.pow(2)
                  - 2 * self.weight_log_sigma - 1).sum()
    kl_b = 0.5 * (self.bias_mu.pow(2) + bias_sigma.pow(2)
                  - 2 * self.bias_log_sigma - 1).sum()
    return kl_w + kl_b

```

```
import torch.nn.functional as F
```

```
class BayesNN(nn.Module):
```

```
    """ 三层贝叶斯神经网络（用于分类）。 """
```

```

def __init__(self, input_dim: int, hidden_dim: int, num_classes: int):
    super().__init__()
    self.layer1 = BayesLinear(input_dim, hidden_dim)
    self.layer2 = BayesLinear(hidden_dim, hidden_dim)
    self.layer3 = BayesLinear(hidden_dim, num_classes)

def forward(self, x: torch.Tensor) -> torch.Tensor:
    x = F.relu(self.layer1(x))
    x = F.relu(self.layer2(x))

```

```

    return self.layer3(x)

def elbo_loss(self, x: torch.Tensor, y: torch.Tensor,
              n_samples: int = 1, dataset_size: int = 1000) -> torch.Tensor:
    """
    负 ELBO = NLL - KL / N。

    Args:
        x: 输入数据
        y: 标签
        n_samples: MC 样本数 (通常为 1, 因已用 local reparameterization)
        dataset_size: 训练集大小 (用于 KL 权重缩放)
    """
    nll = 0.0
    for _ in range(n_samples):
        logits = self.forward(x)
        nll = nll + F.cross_entropy(logits, y)
    nll = nll / n_samples

    kl = sum(layer.kl_divergence()
              for layer in [self.layer1, self.layer2, self.layer3])

    # KL 按数据集大小归一化 (防止小批量时 KL 主导)
    return nll + kl / dataset_size

```

应用 23.C：扩散模型的去噪采样过程

背景：去噪扩散概率模型（Denoising Diffusion Probabilistic Models, DDPM, Ho et al., 2020）是目前最先进的图像生成模型之一，其采样过程本质上是一个马尔可夫链逆过程。

前向过程（加噪）：对数据 $x_0 \sim q(x_0)$ ，逐步添加高斯噪声：

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I)$$

其中 $\beta_1, \dots, \beta_T$ 是噪声调度（Noise Schedule）。令 $\alpha_t = 1 - \beta_t$ ， $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ ，可以直接从 x_0 采样任意时刻的加噪图像：

$$q(x_t | x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) I)$$

等价地： $x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$ ，其中 $\epsilon \sim \mathcal{N}(0, I)$ 。

逆向过程（去噪采样）：真实逆向分布 $q(x_{t-1} | x_t, x_0)$ 可计算：

$$q(x_{t-1} | x_t, x_0) = \mathcal{N}(x_{t-1}; \tilde{\mu}_t(x_t, x_0), \tilde{\beta}_t I)$$

$$\tilde{\mu}_t(x_t, x_0) = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t} x_0 + \frac{\sqrt{\bar{\alpha}_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} x_t, \quad \tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t$$

神经网络 $\epsilon_\theta(x_t, t)$ 学习预测噪声 ϵ ，从而估计 $x_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t)}{\sqrt{\bar{\alpha}_t}}$ 。

```
import torch
import torch.nn as nn
import torch.nn.functional as F
from typing import Tuple

class SimpleDiffusion:
    """
    简化的 DDPM 实现，展示蒙特卡洛采样在扩散模型中的应用。
    使用线性噪声调度 (Linear Noise Schedule)。
    """

    def __init__(self, T: int = 1000, beta_start: float = 1e-4,
                 beta_end: float = 0.02, device: str = "cpu"):
        self.T = T
        self.device = device

        # 线性噪声调度
        self.betas = torch.linspace(beta_start, beta_end, T, device=device)
        self.alphas = 1.0 - self.betas
        self.alpha_bars = torch.cumprod(self.alphas, dim=0)

        # 预计算常用系数
        self.sqrt_alpha_bars = self.alpha_bars.sqrt()
        self.sqrt_one_minus_alpha_bars = (1 - self.alpha_bars).sqrt()

    def q_sample(self, x0: torch.Tensor, t: torch.Tensor,
                noise: torch.Tensor = None) -> Tuple[torch.Tensor, torch.Tensor]:
        """
        前向加噪（蒙特卡洛采样训练目标）。

        
$$x_t = \text{sqrt}(\text{alpha\_bar\_t}) * x_0 + \text{sqrt}(1 - \text{alpha\_bar\_t}) * \text{eps}$$


```

```

Args:
     $x_0$ : 原始图像, 形状  $(B, C, H, W)$ 
     $t$ : 时间步, 形状  $(B,)$ 
     $noise$ : 若为 None 则随机生成

Returns:
    ( $x_t$ ,  $noise$ ) 加噪图像和使用的噪声
    """
    if noise is None:
        noise = torch.randn_like(x0)

    # 按批次维度索引系数
    sqrt_ab = self.sqrt_alphaBars[t].view(-1, 1, 1, 1)
    sqrt_1mab = self.sqrt_one_minus_alphaBars[t].view(-1, 1, 1, 1)

     $x_t$  = sqrt_ab *  $x_0$  + sqrt_1mab * noise
    return  $x_t$ , noise

def p_sample(self, model: nn.Module,  $x_t$ : torch.Tensor,
              t: int) -> torch.Tensor:
    """
    逆向去噪一步 (DDPM 采样器)。

    Args:
        model: 噪声预测网络  $\epsilon_\theta(x_t, t)$ 
         $x_t$ : 当前时刻的含噪图像
         $t$ : 当前时间步 (标量)

    Returns:
         $x_{t-1}$ : 去噪后的图像
        """
    t_tensor = torch.full(( $x_t$ .shape[0],), t, device=self.device,
                          dtype=torch.long)

    with torch.no_grad():
        eps_pred = model( $x_t$ , t_tensor)

    beta_t = self.betas[t]
    alpha_t = self.alphas[t]
    alpha_bar_t = self.alphaBars[t]

```

```

# 由预测噪声还原  $x_0$  的估计
x0_pred = (x_t - (1 - alpha_bar_t).sqrt() * eps_pred) / alpha_bar_t.sqrt()
x0_pred = x0_pred.clamp(-1, 1)

# 计算后验均值  $\mu_{\tilde{t}}$ 
if t > 0:
    alpha_bar_prev = self.alpha_bars[t - 1]
else:
    alpha_bar_prev = torch.tensor(1.0, device=self.device)

coef1 = (alpha_bar_prev.sqrt() * beta_t) / (1 - alpha_bar_t)
coef2 = (alpha_t.sqrt() * (1 - alpha_bar_prev)) / (1 - alpha_bar_t)
mu_tilde = coef1 * x0_pred + coef2 * x_t

if t == 0:
    return mu_tilde

# 加入随机性：蒙特卡洛采样步骤
beta_tilde = (1 - alpha_bar_prev) / (1 - alpha_bar_t) * beta_t
noise = torch.randn_like(x_t)
return mu_tilde + beta_tilde.sqrt() * noise

@torch.no_grad()
def p_sample_loop(self, model: nn.Module, shape: Tuple,
                  return_intermediates: bool = False) -> torch.Tensor:
    """
    完整的 DDPM 反向采样循环（从纯噪声生成图像）。

    Args:
        model: 噪声预测网络
        shape: 生成图像形状 (B, C, H, W)
        return_intermediates: 是否返回中间步骤

    Returns:
        生成的图像  $x_0$ , 形状 shape
    """
    model.eval()
    x = torch.randn(shape, device=self.device) #  $x_T \sim N(0, I)$ 
    intermediates = [x] if return_intermediates else None

```

```

    # 逆向马尔可夫链:  $T \rightarrow 0$ 
    for t in reversed(range(self.T)):
        x = self.p_sample(model, x, t)
        if return_intermediates and t % 100 == 0:
            intermediates.append(x.clone())

    if return_intermediates:
        return x, intermediates
    return x

def training_loss(self, model: nn.Module, x0: torch.Tensor) -> torch.Tensor:
    """
    DDPM 训练损失：预测噪声的 MSE（蒙特卡洛估计 ELBO 的简化）。

    Args:
        model: 噪声预测网络
        x0: 真实图像批次

    Returns:
        标量损失
    """
    B = x0.shape[0]
    # 随机采样时间步（蒙特卡洛估计期望）
    t = torch.randint(0, self.T, (B,), device=self.device)

    x_t, noise = self.q_sample(x0, t)
    eps_pred = model(x_t, t)

    return F.mse_loss(eps_pred, noise)

# 演示扩散采样统计特性
def analyze_diffusion_noise():
    """ 验证扩散过程的统计性质:  $x_T$  应近似服从  $N(0, I)$ 。 """
    torch.manual_seed(0)
    T = 1000

    diffusion = SimpleDiffusion(T=T)

    # 模拟一张 " 图像 " (均匀数据)
    x0 = torch.zeros(1, 1, 8, 8) # 全零图像

```

```

# 检查不同时间步的信噪比 (SNR = alpha_bar / (1 - alpha_bar))
steps = [0, 100, 250, 500, 750, 999]
print(" 时间步 t | E[x_t] (应 →0) | Var[x_t] (应 →1) | SNR")
print("-" * 58)
for t_val in steps:
    t_tensor = torch.tensor([t_val])
    x_t_samples = torch.stack(
        [diffusion.q_sample(x0, t_tensor)[0] for _ in range(1000)], dim=0
    )
    mean_val = x_t_samples.mean().item()
    var_val = x_t_samples.var().item()
    ab = diffusion.alpha_bars[t_val].item()
    snr = ab / (1 - ab + 1e-8)
    print(f"t={t_val:4d} | {mean_val:+.4f} | {var_val:.4f} | {snr:.4f}")

```

练习题

练习 23.1 (MC 积分误差) 使用蒙特卡洛方法估计以下积分，并给出 95% 置信区间的宽度与样本量 n 的关系：

$$I = \int_0^1 e^{-x^2} dx$$

- 写出 MC 估计量 $\hat{I}_n$ 的表达式。
 - 计算被积函数的方差 $\sigma^2 = \text{Var}[e^{-X^2}]$ ($X \sim U[0, 1]$)。
 - 若要使 95% 置信区间宽度不超过 0.001，至少需要多少样本？
 - 若改用 $X \sim \mathcal{N}(0, 0.5^2)$ 截断到 $[0, 1]$ 作为提议分布进行重要性采样，定性分析方差会如何变化。
-

练习 23.2 (重要性采样权重退化) 设目标分布为 $p(x) = \mathcal{N}(x; 5, 1)$ ，提议分布为 $q(x) = \mathcal{N}(x; 0, 1)$ ，欲估计 $\mathbb{E}_p[X^2]$ 。

- 写出重要性权重 $w(x) = p(x)/q(x)$ 的解析表达式，化简后给出对数权重 $\log w(x)$ 的公式。
 - 从 q 中抽取 $n = 1000$ 个样本，计算归一化权重 $\bar{w}_i = w_i / \sum_j w_j$ 后，分析权重分布的极端程度（提示：考虑 $x \approx 5$ 时的权重）。
 - 计算有效样本量 ESS 的近似值，说明此时重要性采样失效的原因。
 - 如何改进提议分布来解决此问题？
-

练习 23.3 (拒绝采样设计) 设目标分布的非归一化密度为：

$$\tilde{p}(x) = e^{-x^2/2}(1 + \sin^2(3x)), \quad x \in \mathbb{R}$$

- 证明 $p(x) \propto \tilde{p}(x)$ 是一个合法的概率密度函数（即 $\int \tilde{p}(x) dx < \infty$ ）。
- 选取提议分布 $q(x) = \mathcal{N}(x; 0, 1)$ ，确定最小的包络常数 M 使得 $\tilde{p}(x) \leq M \cdot q(x)$ 对所有 x 成立（提示： $\max_x \tilde{p}(x)/q(x)$ ）。
- 计算该拒绝采样算法的理论接受率。
- 若改用 $q(x) = \mathcal{N}(x; 0, 2^2)$ ，接受率如何变化？

练习 23.4 (MCMC 细致平衡验证) 考虑以下在状态空间 $\{1, 2, 3\}$ 上的 MH 算法，目标分布为 $\pi = (0.2, 0.5, 0.3)$ ，提议分布为均匀转移： $q(j | i) = 1/3$ （对所有 i, j ）。

- 写出 MH 接受率 $A(j, i) = \min(1, \pi(j)q(i | j)/(\pi(i)q(j | i)))$ 的转移矩阵 T 。
- 验证所得转移矩阵满足细致平衡条件： $\pi(i)T(j | i) = \pi(j)T(i | j)$ 。
- 验证 π 确实是转移矩阵 T 的平稳分布，即 $\pi T = \pi$ 。
- 若将目标分布改为 $\pi' = (0.1, 0.1, 0.8)$ ，重新计算转移矩阵，并讨论接受率与混合速度的变化。

练习 23.5 (MC Dropout 不确定性分析) 在回归任务中，使用 MC Dropout 进行预测， $T = 50$ 次前向传播得到预测集合 $\{y_t^*\}_{t=1}^{50}$ 。

- 写出预测均值 $\hat{\mu}$ 和预测方差 $\hat{\sigma}^2$ 的计算公式，并说明预测方差包含哪两部分不确定性。
- 设在测试点 x^* 处，50 次预测结果（已归一化）为：均值 $\hat{\mu} = 2.3$ ， $\sum_t (y_t^*)^2 / T = 5.5$ 。计算认知不确定性（epistemic uncertainty）。
- 若另一测试点 x^{**} 在训练数据分布内，预期其不确定性与域外点 x^* 有何不同？解释原因。
- MC Dropout 的有效样本量与 T 和 Dropout 率 p 有何关系？若 $p \rightarrow 0$ 或 $p \rightarrow 1$ ，会发生什么？
- 从贝叶斯角度解释，为什么测试时保持 Dropout 开启等价于对权重后验的蒙特卡洛积分？

练习答案

练习 23.1 解答

(a) 设 $X \sim U[0, 1]$ ，MC 估计量为：

$$\hat{I}_n = \frac{1}{n} \sum_{i=1}^n e^{-X_i^2}$$

(b) 计算方差：

$$\mathbb{E}[e^{-X^2}] = \int_0^1 e^{-x^2} dx \approx 0.7468$$

$$\mathbb{E}[e^{-2X^2}] = \int_0^1 e^{-2x^2} dx = \frac{\sqrt{\pi}}{2\sqrt{2}} \operatorname{erf}(\sqrt{2}) \approx 0.6031$$

$$\sigma^2 = \mathbb{E}[e^{-2X^2}] - (\mathbb{E}[e^{-X^2}])^2 \approx 0.6031 - 0.7468^2 \approx 0.047$$

(c) 95% 置信区间宽度为 $2 \times 1.96\sigma/\sqrt{n} \leq 0.001$, 解出:

$$n \geq \left(\frac{2 \times 1.96 \times \sqrt{0.047}}{0.001} \right)^2 \approx \left(\frac{0.8498}{0.001} \right)^2 \approx 722\,000$$

至少需要约 7.22×10^5 个样本。

(d) 截断正态分布在 $x \approx 0$ 附近密度较大, 而被积函数 e^{-x^2} 也在此处值较大, 故提议分布与被积函数的“形状”更匹配, 预期方差减小。

练习 23.2 解答

(a) 对数权重:

$$\log w(x) = \log p(x) - \log q(x) = -\frac{(x-5)^2}{2} + \frac{x^2}{2} = 5x - \frac{25}{2}$$

即 $w(x) = e^{5x-12.5}$, 权重随 x 指数增长。

(b) 当从 $q = \mathcal{N}(0, 1)$ 采样时, 典型样本 $x \approx 0 \pm 3$, 权重 $w(0) = e^{-12.5} \approx 4 \times 10^{-6}$; 而当 $x = 5$ 时 $w(5) = e^{12.5} \approx 2.7 \times 10^5$ 。绝大多数样本权重极小, 少数极大, 权重严重退化。

(c) 由于 q 的主要质量在 $x \approx 0$, 而 p 的主要质量在 $x \approx 5$, 两分布相距 5 个标准差, $\text{ESS} \approx 1/\sum_i \bar{w}_i^2 \approx 1$ (极少数样本贡献几乎全部权重)。

(d) 改用 $q(x) = \mathcal{N}(x; 5, 1) = p(x)$, 此时 $w(x) \equiv 1$, $\text{ESS} = n$, 方差最小 (等同于直接从 p 采样)。实际中若不知道 p 的均值, 可使用均值在 5 附近、方差适当大的高斯分布。

练习 23.3 解答

(a) 注意 $1 + \sin^2(3x) \leq 2$, 故 $\tilde{p}(x) \leq 2e^{-x^2/2}$, 由于 $\int_{-\infty}^{\infty} e^{-x^2/2} dx = \sqrt{2\pi} < \infty$, 所以 $\int \tilde{p}(x) dx \leq 2\sqrt{2\pi} < \infty$, 是合法密度函数。

(b) 计算 $\tilde{p}(x)/q(x)$:

$$\frac{\tilde{p}(x)}{q(x)} = \frac{e^{-x^2/2}(1 + \sin^2(3x))}{\frac{1}{\sqrt{2\pi}}e^{-x^2/2}} = \sqrt{2\pi}(1 + \sin^2(3x))$$

最大值在 $\sin^2(3x) = 1$ 时取得，故 $M = 2\sqrt{2\pi} \approx 5.013$ 。

(c) 接受率 $\alpha = Z_p/M$ 。其中 $Z_p = \int \tilde{p}(x) dx = \sqrt{2\pi} \int (1 + \sin^2(3x)) \frac{1}{\sqrt{2\pi}} e^{-x^2/2} \cdot \sqrt{2\pi} dx = \sqrt{2\pi}(1 + 1/2) = 1.5\sqrt{2\pi}$ (因为 $\mathbb{E}[\sin^2(3X)] = 1/2$ 对 $X \sim \mathcal{N}(0, 1)$)。故 $\alpha = 1.5\sqrt{2\pi}/(2\sqrt{2\pi}) = 0.75$ 。

(d) 用 $q = \mathcal{N}(0, 4)$ ，则 $M' = \max_x \tilde{p}(x)/q'(x) = 2\sqrt{2\pi} \cdot 2 = 4\sqrt{2\pi}$ (因 q' 的峰值是 q 的一半)。接受率降为 $\alpha' = 1.5\sqrt{2\pi}/(4\sqrt{2\pi}) = 0.375$ ，效率降低。这是因为提议分布过于分散，覆盖了大量低概率区域。

练习 23.4 解答

(a) 计算 $A(j, i)$ ($q(j | i) = 1/3$ 为对称提议，故 $A(j, i) = \min(1, \pi(j)/\pi(i))$):

从状态 1 出发: $A(2 | 1) = \min(1, 0.5/0.2) = 1$, $A(3 | 1) = \min(1, 0.3/0.2) = 1$; 从状态 2 出发: $A(1 | 2) = \min(1, 0.2/0.5) = 0.4$, $A(3 | 2) = \min(1, 0.3/0.5) = 0.6$; 从状态 3 出发: $A(1 | 3) = \min(1, 0.2/0.3) = 2/3$, $A(2 | 3) = \min(1, 0.5/0.3) = 1$ 。

转移矩阵 (行为当前状态，列为下一状态，对角元为拒绝后停留概率):

$$T = \begin{pmatrix} 1/3(1 - 1 - 1) & 1/3 & 1/3 \\ 1/3 \cdot 0.4 & 1/3(1 - 0.4 - 0.6) & 1/3 \cdot 0.6 \\ 1/3 \cdot 2/3 & 1/3 & 1/3(1 - 2/3 - 1) \end{pmatrix} = \begin{pmatrix} 1/3 & 1/3 & 1/3 \\ 2/15 & 1/3 & 1/5 \\ 2/9 & 1/3 & 4/9 \end{pmatrix}$$

注: 对角元由“1 减去离开概率之和”得到: $T(1 | 1) = 1 - 1/3 - 1/3 = 1/3$, $T(2 | 2) = 1 - 2/15 - 1/5 = 1 - 1/3 = 2/3 \cdot 1/2 = 1/3$ (拒绝率为 $1/3 \cdot (1 - 0.4 - 0.6) = 0$, 故 $T(2 | 2) = 1/3$), $T(3 | 3) = 1 - 2/9 - 1/3 = 1 - 2/9 - 3/9 = 4/9$ 。

(b)(c) 验证细致平衡和平稳性的计算过程与 (a) 中转移矩阵一致，留作数值验证。

(d) 对 $\pi' = (0.1, 0.1, 0.8)$ ，状态 3 是高概率状态，从状态 1 或 2 提议跳到状态 3 总被接受，但从状态 3 离开的概率很低 ($\approx 0.125 + 0.125 = 0.25$)，链大部分时间停在状态 3，混合速度慢。

练习 23.5 解答

(a) 预测均值和方差:

$$\hat{\mu} = \frac{1}{T} \sum_{t=1}^T y_t^*, \quad \hat{\sigma}^2 = \frac{1}{T} \sum_{t=1}^T (y_t^*)^2 - \hat{\mu}^2$$

预测方差包含两部分: 认知不确定性 (Epistemic Uncertainty, 由模型参数不确定性引起, 可通过更多数据减小) 和偶然不确定性 (Aleatoric Uncertainty, 由数据噪声引起, 不可减小)。

(b) 认知不确定性 (预测方差的 MC 部分):

$$\hat{\sigma}^2 = 5.5 - 2.3^2 = 5.5 - 5.29 = 0.21$$

(c) 域内测试点 x^{**} 的认知不确定性应远小于域外点 x^* 。原因：域内点对应的训练数据充分，模型权重的后验分布较集中，不同 Dropout 掩码下预测值相近；而域外点缺乏训练数据约束，权重后验扁平，不同掩码下预测差异大。

(d) T 越大，对后验期望的 MC 估计越精确，但 T 不影响有效样本量（相当于用更多样本估计同一量）。当 $p \rightarrow 0$ ：Dropout 不丢弃任何神经元，所有前向传播结果相同，不确定性估计退化为零（不捕获模型不确定性）。当 $p \rightarrow 1$ ：几乎所有神经元被丢弃，预测噪声过大，方差估计失真。最优 Dropout 率通常通过验证集调优，典型值为 $0.1 \sim 0.5$ 。

(e) 贝叶斯预测积分为 $p(y^* | x^*, \mathcal{D}) = \int p(y^* | x^*, \omega) p(\omega | \mathcal{D}) d\omega$ 。变分推断以 $q_\phi(\omega)$ 近似后验 $p(\omega | \mathcal{D})$ 。Gal & Ghahramani (2016) 证明，特定参数化下的 Dropout 等价于混合高斯的变分后验：每次 Dropout 掩码对应从 $q_\phi(\omega)$ 中抽取一个权重样本，多次前向传播即对后验预测分布进行蒙特卡洛积分。

第 24 章：概率图模型

定位：本章是经典概率论与现代深度学习的桥梁。概率图模型将图论的结构化表示与概率论的不确定性推理融为一体，不仅统一了朴素贝叶斯、隐马尔可夫模型、高斯混合模型等经典方法，也为变分自编码器（VAE）等深度生成模型提供了理论基础。

学习目标

读完本章，你将能够：

1. 理解概率图模型的核心思想——用图结构编码随机变量之间的条件独立性，并利用因子分解大幅降低计算复杂度
2. 掌握贝叶斯网络（有向图）的构建规则、d-分离准则以及精确推断与近似推断方法
3. 理解马尔可夫随机场（无向图）的势函数表示、Gibbs 分布及其与贝叶斯网络的联系与区别
4. 推导 EM 算法的数学原理，并能将其应用于高斯混合模型（GMM）等隐变量模型的参数估计
5. 理解变分推断的核心思想——用 ELBO 下界将推断问题转化为优化问题，并认识到 VAE 正是变分推断与深度神经网络的结合

24.1 图模型概述

24.1.1 为什么需要图模型

设想一个包含 n 个二值随机变量 $X_1, X_2, \dots, X_n$ 的联合分布。完整表示这个分布需要 $2^n - 1$ 个参数——当 $n = 100$ 时，这是一个天文数字，完全无法存储和计算。

核心洞察：现实世界中，大多数变量并不直接相互依赖。一个人是否感冒，与遥远城市的股票价格几乎无关。如果能将这些”局部依赖”结构显式地编码进模型，就能用远少于 2^n 的参数表示联合分布。

概率图模型（**Probabilistic Graphical Model, PGM**）正是这一思想的形式化：

图 $G = (V, E)$ 其中节点 V 对应随机变量，边 E 编码依赖关系

24.1.2 条件独立性

条件独立性是图模型的核心概念。若给定 Z 后， X 与 Y 独立，记作：

$$X \perp\!\!\!\perp Y \mid Z$$

等价地：

$$P(X, Y \mid Z) = P(X \mid Z) \cdot P(Y \mid Z)$$

链式法则的因子分解：任意联合分布都可以写成：

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i \mid X_1, \dots, X_{i-1})$$

图模型的目标是利用条件独立性简化每个条件因子，使得每个 X_i 只依赖于其父节点集合 $\text{Pa}(X_i)$ （有向图）或邻居集合（无向图）。

24.1.3 两大类图模型

特征	贝叶斯网络（有向图）	马尔可夫随机场（无向图）
边的类型	有向边（DAG）	无向边
因子分解	条件概率 $P(X_i \mid \text{Pa}(X_i))$	势函数 $\psi_c(X_c)$
典型应用	因果推断、贝叶斯网络	图像分割、社交网络
归一化	自动满足	需要配分函数 Z

24.2 贝叶斯网络（有向图模型）

24.2.1 定义与因子分解

贝叶斯网络是一个有向无环图（DAG），其中：- 每个节点 X_i 对应一个随机变量 - 有向边 $X_j \rightarrow X_i$ 表示 X_j 是 X_i 的“父节点”

联合分布的因子分解：

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Pa}(X_i))$$

其中 $\text{Pa}(X_i)$ 是节点 X_i 的父节点集合（若无父节点则为先验 $P(X_i)$ ）。

例：学生成绩模型

考虑变量：课程难度 D 、学生智力 I 、考试成绩 G 、推荐信 L 、SAT 分数 S 。

图结构： $D \rightarrow G \leftarrow I \rightarrow S, G \rightarrow L$

联合分布：

$$P(D, I, G, L, S) = P(D) \cdot P(I) \cdot P(G \mid D, I) \cdot P(L \mid G) \cdot P(S \mid I)$$

原本需要 $2^5 - 1 = 31$ 个参数，因子分解后仅需少量参数。

24.2.2 三种基本连接结构

理解贝叶斯网络中信息“流动”的规律，关键是分析三种基本连接模式：

1. 链式结构 (Chain): $X \rightarrow Y \rightarrow Z$

给定 Y 后， X 与 Z 条件独立：

$$P(X, Z \mid Y) = P(X \mid Y) \cdot P(Z \mid Y) \implies X \perp\!\!\!\perp Z \mid Y$$

2. 共因结构 (Fork): $X \leftarrow Y \rightarrow Z$

给定 Y 后， X 与 Z 条件独立。 Y 是 X 和 Z 的公共原因，观测 Y “阻断”了 X 与 Z 的关联。

3. 碰撞结构 (v-structure / Collider): $X \rightarrow Y \leftarrow Z$

- 未观测 Y : X 与 Z 独立 ($X \perp\!\!\!\perp Z$)
- 观测 Y (或其后代): X 与 Z 变得相关 (解释消去效应)

这是与前两种结构相反的行为，也是 d-分离中最微妙的部分。

24.2.3 d-分离准则

d-分离 (directional separation) 是判断贝叶斯网络中条件独立性的通用算法。

定义：在有向图中，给定观测集合 $\mathbf{Z}$ ，若所有连接 X 与 Y 的路径都被“阻断”，则称 X 与 Y 被 $\mathbf{Z}$ d-分离，记作 $(X \perp\!\!\!\perp Y \mid \mathbf{Z})_G$ 。

路径被阻断的条件（路径上存在节点 m ）：

结构类型	阻断条件
链 $\cdots \rightarrow m \rightarrow \cdots$	$m \in \mathbf{Z}$
分叉 $\cdots \leftarrow m \rightarrow \cdots$	$m \in \mathbf{Z}$
碰撞 $\cdots \rightarrow m \leftarrow \cdots$	$m \notin \mathbf{Z}$ 且 m 的后代 $\notin \mathbf{Z}$

定理（**Markov 性质**）：若图 G 中 X 与 Y 被 $\mathbf{Z}$ d-分离，则在满足图 G 的所有分布中， $X \perp\!\!\!\perp Y \mid \mathbf{Z}$ 成立。

24.2.4 精确推断：变量消元法

贝叶斯网络的核心任务是推断：给定部分观测，计算其余变量的后验分布。

变量消元（**Variable Elimination**）通过逐步边缘化（积分消除）未观测变量来计算目标概率。

以链式模型 $A \rightarrow B \rightarrow C$ 为例，计算 $P(A \mid C = c)$ ：

$$P(A \mid C = c) \propto \sum_B P(A) \cdot P(B \mid A) \cdot P(C = c \mid B)$$

关键技巧：先计算 $\tau(B) = P(C = c \mid B)$ ，再计算 $\sum_B P(B \mid A) \cdot \tau(B)$ ，避免重复计算。

对于树形结构，变量消元等价于置信传播（**Belief Propagation**），复杂度为 $O(n \cdot k^2)$ ，其中 k 为变量的状态数。对于有环图，需使用循环置信传播（近似推断）。

24.3 马尔可夫随机场（无向图模型）

24.3.1 定义与 Gibbs 分布

马尔可夫随机场（**Markov Random Field, MRF**），又称马尔可夫网络，使用无向图表示变量间的对称依赖关系。

局部 **Markov 性质**：给定邻居节点集合 $\mathcal{N}(X_i)$ ， X_i 与其余非邻居节点条件独立：

$$X_i \perp\!\!\!\perp \mathbf{X}_{\text{rest}} \mid \mathbf{X}_{\mathcal{N}(i)}$$

团 (Clique)：图中完全连接的子集（任意两节点之间都有边）。

Hammersley-Clifford 定理：满足局部 Markov 性质的正分布，可以表示为极大团上势函数的乘积：

$$P(\mathbf{X}) = \frac{1}{Z} \prod_{c \in \mathcal{C}} \psi_c(\mathbf{X}_c)$$

其中：- $\psi_c(\mathbf{X}_c) > 0$ 是定义在团 c 上的势函数 (potential function) - $Z = \sum_{\mathbf{X}} \prod_c \psi_c(\mathbf{X}_c)$ 是配分函数 (partition function)，用于归一化 - $\mathcal{C}$ 是所有极大团的集合

Gibbs 分布：将势函数写成能量函数的指数形式：

$$P(\mathbf{X}) = \frac{1}{Z} \exp \left(- \sum_c E_c(\mathbf{X}_c) \right) = \frac{1}{Z} \exp(-E(\mathbf{X}))$$

其中 $E(\mathbf{X}) = \sum_c E_c(\mathbf{X}_c)$ 称为能量函数。

24.3.2 与贝叶斯网络的比较

表达能力：两者的表达能力不完全相同，各有擅长的独立性结构。存在既不能用贝叶斯网络也不能用 MRF 精确表示的分布。

将贝叶斯网络转化为 MRF (道德化)：

1. 为每个节点的父节点两两相连 (“婚姻化”)
2. 将所有有向边替换为无向边

这个过程称为道德化 (moralization)，得到的图称为道德图。注意：道德化可能引入新的独立性损失。

配分函数的计算：MRF 最大的挑战是配分函数 Z 的计算。对于离散变量，精确计算需要对所有状态求和，复杂度为指数级。这是 MRF 推断困难的根本原因，也是为何需要 MCMC、变分推断等近似方法。

24.3.3 条件随机场

条件随机场 (Conditional Random Field, CRF) 是 MRF 的判别式变体，直接建模条件分布 $P(\mathbf{Y} \mid \mathbf{X})$ ：

$$P(\mathbf{Y} \mid \mathbf{X}) = \frac{1}{Z(\mathbf{X})} \exp \left(\sum_c \psi_c(\mathbf{Y}_c, \mathbf{X}) \right)$$

CRF 在序列标注（如命名实体识别）中取得了重要成果，是联结图模型与深度学习的早期尝试。

24.4 隐变量模型与 EM 算法

24.4.1 隐变量模型

许多真实问题中，我们观测到数据 $\mathbf{x}$ ，但生成数据的过程涉及隐变量（latent variable） $\mathbf{z}$ 。

边缘似然（Evidence）：

$$P(\mathbf{x} | \theta) = \int P(\mathbf{x}, \mathbf{z} | \theta) d\mathbf{z} = \int P(\mathbf{x} | \mathbf{z}, \theta) P(\mathbf{z} | \theta) d\mathbf{z}$$

直接最大化边缘似然通常很难，因为积分没有解析解。EM 算法提供了一种迭代优化方案。

24.4.2 EM 算法的推导

目标：最大化对数边缘似然 $\log P(\mathbf{x} | \theta)$ 。

对于任意关于 $\mathbf{z}$ 的分布 $q(\mathbf{z})$ ，利用 Jensen 不等式：

$$\begin{aligned} \log P(\mathbf{x} | \theta) &= \log \int P(\mathbf{x}, \mathbf{z} | \theta) d\mathbf{z} \\ &= \log \int q(\mathbf{z}) \frac{P(\mathbf{x}, \mathbf{z} | \theta)}{q(\mathbf{z})} d\mathbf{z} \\ &\geq \int q(\mathbf{z}) \log \frac{P(\mathbf{x}, \mathbf{z} | \theta)}{q(\mathbf{z})} d\mathbf{z} \quad (\text{Jensen 不等式}) \\ &= \underbrace{\mathbb{E}_{q(\mathbf{z})}[\log P(\mathbf{x}, \mathbf{z} | \theta)]}_{\text{期望完全对数似然}} + \underbrace{H[q(\mathbf{z})]}_{\text{熵}} := \mathcal{L}(q, \theta) \end{aligned}$$

等号成立条件： $q(\mathbf{z}) = P(\mathbf{z} | \mathbf{x}, \theta)$ （当 q 等于后验分布时）。

EM 算法的两步迭代：

$$\boxed{\text{E 步（期望步） } q^{(t+1)}(\mathbf{z}) = P(\mathbf{z} | \mathbf{x}, \theta^{(t)})}$$

$$\boxed{\text{M 步（最大化步） } \theta^{(t+1)} = \arg \max_{\theta} \mathbb{E}_{q^{(t+1)}(\mathbf{z})}[\log P(\mathbf{x}, \mathbf{z} | \theta)]}$$

单调性保证：EM 算法保证对数似然单调不减：

$$\log P(\mathbf{x} | \theta^{(t+1)}) \geq \log P(\mathbf{x} | \theta^{(t)})$$

证明：E 步使下界 $\mathcal{L}$ 紧（消除了 KL 散度间隙），M 步提升下界，因此总体对数似然不减。

24.4.3 高斯混合模型（GMM）的 EM 算法

模型定义：GMM 假设数据由 K 个高斯分量混合生成：

$$P(\mathbf{x} | \theta) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} | \mu_k, \Sigma_k)$$

其中 $\pi_k \geq 0$, $\sum_k \pi_k = 1$, $\theta = \{\pi_k, \mu_k, \Sigma_k\}_{k=1}^K$ 。

隐变量 $z_i \in \{1, \dots, K\}$ 表示第 i 个数据点属于哪个分量， $P(z_i = k) = \pi_k$ 。

E 步（计算后验“责任”）：

$$r_{ik} = P(z_i = k | \mathbf{x}_i, \theta^{(t)}) = \frac{\pi_k^{(t)} \mathcal{N}(\mathbf{x}_i | \mu_k^{(t)}, \Sigma_k^{(t)})}{\sum_{j=1}^K \pi_j^{(t)} \mathcal{N}(\mathbf{x}_i | \mu_j^{(t)}, \Sigma_j^{(t)})}$$

M 步（更新参数）：

令 $N_k = \sum_{i=1}^N r_{ik}$ （分量 k 的有效样本数），则：

$$\mu_k^{(t+1)} = \frac{1}{N_k} \sum_{i=1}^N r_{ik} \mathbf{x}_i$$

$$\Sigma_k^{(t+1)} = \frac{1}{N_k} \sum_{i=1}^N r_{ik} (\mathbf{x}_i - \mu_k^{(t+1)})(\mathbf{x}_i - \mu_k^{(t+1)})^\top$$

$$\pi_k^{(t+1)} = \frac{N_k}{N}$$

EM vs K-means：K-means 可以看作 GMM EM 算法的硬分配（hard assignment）版本——每个数据点被强制分配到最近的中心，而非保留软概率权重 r_{ik} 。

24.5 变分推断简介

24.5.1 推断问题的困难性

后验推断的核心任务是计算：

$$P(\mathbf{z} | \mathbf{x}) = \frac{P(\mathbf{x} | \mathbf{z})P(\mathbf{z})}{P(\mathbf{x})}$$

难点在于分母 $P(\mathbf{x}) = \int P(\mathbf{x} | \mathbf{z})P(\mathbf{z}) d\mathbf{z}$ 通常无法解析计算。

两大近似推断方法：- **MCMC**（马尔可夫链蒙特卡洛）：通过采样近似后验，渐进精确但计算慢 - 变分推断 (**Variational Inference**)：将推断转化为优化，速度快但有近似误差

24.5.2 变分推断框架

核心思想：在某个“简单”分布族 $\mathcal{Q} = \{q_\phi(\mathbf{z})\}$ 中，寻找最接近真实后验 $P(\mathbf{z} | \mathbf{x})$ 的分布：

$$q_\phi^*(\mathbf{z}) = \arg \min_{q \in \mathcal{Q}} \text{KL}(q_\phi(\mathbf{z}) \| P(\mathbf{z} | \mathbf{x}))$$

KL 散度展开：

$$\begin{aligned} \text{KL}(q_\phi(\mathbf{z}) \| P(\mathbf{z} | \mathbf{x})) &= \mathbb{E}_{q_\phi} \left[\log \frac{q_\phi(\mathbf{z})}{P(\mathbf{z} | \mathbf{x})} \right] \\ &= \mathbb{E}_{q_\phi} [\log q_\phi(\mathbf{z})] - \mathbb{E}_{q_\phi} [\log P(\mathbf{x}, \mathbf{z})] + \log P(\mathbf{x}) \end{aligned}$$

由于 $\text{KL} \geq 0$ ，得到：

$$\log P(\mathbf{x}) \geq \underbrace{\mathbb{E}_{q_\phi} [\log P(\mathbf{x}, \mathbf{z})] - \mathbb{E}_{q_\phi} [\log q_\phi(\mathbf{z})]}_{\text{证据下界 (ELBO)}}$$

24.5.3 证据下界 (ELBO)

ELBO (Evidence Lower BOund) 是变分推断的核心量：

$$\mathcal{L}(\phi) = \mathbb{E}_{q_\phi(\mathbf{z})} [\log P(\mathbf{x}, \mathbf{z})] - \mathbb{E}_{q_\phi(\mathbf{z})} [\log q_\phi(\mathbf{z})]$$

等价分解：

$$\mathcal{L}(\phi) = \mathbb{E}_{q_\phi(\mathbf{z})} [\log P(\mathbf{x} | \mathbf{z})] - \text{KL}(q_\phi(\mathbf{z}) \| P(\mathbf{z}))$$

- 第一项：重建项，鼓励 $q_\phi(\mathbf{z})$ 找到能解释观测数据的隐变量值
- 第二项：正则化项，鼓励近似后验接近先验，防止过拟合

最大化 **ELBO** 等价于：1. 最小化 $\text{KL}(q_\phi \| P(\cdot | \mathbf{x}))$ （推断目标） 2. 最大化 $\log P(\mathbf{x})$ （学习目标）

24.5.4 均场近似

均场 (Mean-Field) 变分推断假设 $q_\phi(\mathbf{z})$ 在各维度上完全分解：

$$q_\phi(\mathbf{z}) = \prod_j q_j(z_j)$$

在此假设下，可以推导出每个因子的最优形式（坐标上升）：

$$q_j^*(z_j) \propto \exp\left(\mathbb{E}_{q_{-j}}[\log P(\mathbf{x}, \mathbf{z})]\right)$$

其中 $\mathbb{E}_{q_{-j}}$ 表示对除 z_j 外的所有变量取期望。

本章小结

本章系统介绍了概率图模型的核心理论框架：

1. 图模型的统一视角：通过图结构编码条件独立性，实现联合分布的高效因子分解，是处理高维概率分布的核心工具
2. 贝叶斯网络：基于有向无环图，因子分解为条件概率乘积。d-分离准则提供了判断条件独立性的算法，三种基本连接结构（链、分叉、碰撞）揭示了信息流动的本质
3. 马尔可夫随机场：基于无向图，通过势函数和配分函数表示联合分布。Hammersley-Clifford 定理建立了图结构与分布因子分解的等价性
4. EM 算法：通过引入辅助分布 $q(\mathbf{z})$ 构造对数似然的下界，交替优化以单调提升似然。在 GMM 上的应用展示了软分配与参数估计的优雅交互
5. 变分推断：将难以计算的后验推断转化为 ELBO 最大化问题，均场近似和重参数化技巧使其能与深度学习结合，催生了 VAE 等现代生成模型

深度学习应用：VAE、GMM 与隐变量模型

应用背景

变分自编码器 (VAE) 是变分推断与深度神经网络的融合：- 编码器 $q_\phi(\mathbf{z} | \mathbf{x})$ ：用神经网络参数化近似后验（变分推断中的 q ）- 解码器 $P_\theta(\mathbf{x} | \mathbf{z})$ ：用神经网络参数化似然函数 - 训练目标：最大化 $\text{ELBO} = \mathbb{E}_{q_\phi}[\log P_\theta(\mathbf{x} | \mathbf{z})] - \text{KL}(q_\phi(\mathbf{z} | \mathbf{x}) \| P(\mathbf{z}))$

重参数化技巧 (Reparameterization Trick) 使得梯度可以通过采样操作反向传播：

$$\mathbf{z} = \mu_{\phi}(\mathbf{x}) + \sigma_{\phi}(\mathbf{x}) \odot \epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

这样梯度 $\nabla_{\phi} \mathbb{E}_{q_{\phi}}[\cdot]$ 可以通过 ϵ 的固定分布计算，而非通过随机节点。

完整 PyTorch 实现

```
"""
概率图模型深度学习应用：VAE 与 GMM

包含：
1. 高斯混合模型 (GMM) 的 EM 算法实现
2. 变分自编码器 (VAE) 的 PyTorch 实现
3. 两者在 MNIST 数据集上的对比实验
"""

import torch
import torch.nn as nn
import torch.nn.functional as F
from torch.utils.data import DataLoader
from torchvision import datasets, transforms
import numpy as np
import matplotlib.pyplot as plt
from typing import Tuple

# =====
# Part 1: 高斯混合模型 (GMM) 的 EM 算法
# =====

class GaussianMixture:
    """
    高斯混合模型：使用 EM 算法进行参数估计

    模型： $P(x) = \sum_k \pi_k * N(x | \mu_k, \Sigma_k)$ 
    隐变量： $z_i \in \{1, \dots, K\}$ ，表示第  $i$  个点的分量归属
    """

    def __init__(self, n_components: int = 3, n_iter: int = 100,
                 tol: float = 1e-4, random_state: int = 42):
```

```

self.K = n_components
self.n_iter = n_iter
self.tol = tol
self.rng = np.random.RandomState(random_state)

def fit(self, X: np.ndarray) -> 'GaussianMixture':
    """EM 算法拟合 GMM"""
    N, D = X.shape

    # 初始化参数（随机选取数据点作为均值）
    idx = self.rng.choice(N, self.K, replace=False)
    self.mu = X[idx].copy() # (K, D)
    self.Sigma = np.array([np.eye(D)] * self.K) # (K, D, D)
    self.pi = np.ones(self.K) / self.K # (K,)

    log_likelihoods = []

    for iteration in range(self.n_iter):
        # ---- E 步：计算每个数据点属于每个分量的后验概率 ----
        #  $r[i, k] = P(z_i = k \mid x_i, \theta)$ 
        r = self._e_step(X) # (N, K)

        # ---- M 步：更新参数 ----
        self._m_step(X, r)

        # 计算对数似然（用于收敛判断）
        log_lik = self._log_likelihood(X)
        log_likelihoods.append(log_lik)

        if iteration > 0 and abs(log_likelihoods[-1] - log_likelihoods[-2]) < self.tol:
            print(f" GMM 收敛于第 {iteration+1} 次迭代, "
                  f" 对数似然 = {log_lik:.4f}")
            break

    self.log_likelihoods_ = log_likelihoods
    return self

def _e_step(self, X: np.ndarray) -> np.ndarray:
    """
    E 步：计算“责任”矩阵

```

```


$$r[i, k] = p_{i_k} * N(x_i | \mu_k, \Sigma_k) / \sum_j p_{i_j} * N(x_i | \mu_j, \Sigma_j)$$

    """
    N = X.shape[0]
    log_r = np.zeros((N, self.K))

    for k in range(self.K):
        log_r[:, k] = np.log(self.pi[k] + 1e-300) + \
            self._log_gaussian(X, self.mu[k], self.Sigma[k])

    # 数值稳定的 log-sum-exp
    log_r -= log_r.max(axis=1, keepdims=True)
    r = np.exp(log_r)
    r /= r.sum(axis=1, keepdims=True)  # 归一化
    return r

def _m_step(self, X: np.ndarray, r: np.ndarray):
    """
    M 步：用加权样本更新参数

    
$$\mu_k = \sum_i r_{ik} * x_i / N_k$$

    
$$\Sigma_k = \sum_i r_{ik} * (x_i - \mu_k)(x_i - \mu_k)^T / N_k$$

    
$$p_{i_k} = N_k / N$$

    """
    N, D = X.shape
    N_k = r.sum(axis=0)  # (K,), 每个分量的有效样本数

    for k in range(self.K):
        # 更新均值
        self.mu[k] = (r[:, k:k+1] * X).sum(axis=0) / N_k[k]

        # 更新协方差矩阵
        diff = X - self.mu[k]  # (N, D)
        self.Sigma[k] = (r[:, k:k+1] * diff).T @ diff / N_k[k]
        self.Sigma[k] += 1e-6 * np.eye(D)  # 正则化, 防止奇异

    # 更新混合系数
    self.pi = N_k / N

def _log_gaussian(self, X: np.ndarray, mu: np.ndarray,
                  Sigma: np.ndarray) -> np.ndarray:
    """ 计算多元高斯分布的对数概率密度 """

```

```

D = X.shape[1]
diff = X - mu
sign, log_det = np.linalg.slogdet(Sigma)
inv_Sigma = np.linalg.inv(Sigma)
mahal = np.einsum('nd,dd,nd->n', diff, inv_Sigma, diff) # 马氏距离
return -0.5 * (D * np.log(2 * np.pi) + log_det + mahal)

def _log_likelihood(self, X: np.ndarray) -> float:
    """ 计算数据集的总对数似然 """
    N = X.shape[0]
    log_p = np.zeros((N, self.K))
    for k in range(self.K):
        log_p[:, k] = np.log(self.pi[k] + 1e-300) + \
            self._log_gaussian(X, self.mu[k], self.Sigma[k])
    # log-sum-exp
    log_max = log_p.max(axis=1, keepdims=True)
    log_p_x = np.log(np.exp(log_p - log_max).sum(axis=1)) + log_max.squeeze()
    return log_p_x.sum()

def predict(self, X: np.ndarray) -> np.ndarray:
    """ 预测每个数据点最可能的分量标签 """
    r = self._e_step(X)
    return r.argmax(axis=1)

def sample(self, n_samples: int = 100) -> np.ndarray:
    """ 从 GMM 中生成样本 """
    components = self.rng.choice(self.K, size=n_samples, p=self.pi)
    D = self.mu.shape[1]
    samples = np.zeros((n_samples, D))
    for k in range(self.K):
        mask = (components == k)
        nk = mask.sum()
        if nk > 0:
            samples[mask] = self.rng.multivariate_normal(
                self.mu[k], self.Sigma[k], nk
            )
    return samples

# =====
# Part 2: 变分自编码器 (VAE)

```

```
# =====

class VAEEncoder(nn.Module):
    """
    VAE 编码器：实现近似后验  $q_{\phi}(z | x)$ 

    输出：隐变量的均值  $\mu$  和对数方差  $\log_{\text{var}}$ 
    """

    def __init__(self, input_dim: int = 784, hidden_dim: int = 512,
                  latent_dim: int = 20):
        super().__init__()
        self.latent_dim = latent_dim

        self.net = nn.Sequential(
            nn.Linear(input_dim, hidden_dim),
            nn.ReLU(),
            nn.Linear(hidden_dim, hidden_dim),
            nn.ReLU(),
        )
        self.fc_mu = nn.Linear(hidden_dim, latent_dim)
        self.fc_log_var = nn.Linear(hidden_dim, latent_dim)

    def forward(self, x: torch.Tensor) -> Tuple[torch.Tensor, torch.Tensor]:
        h = self.net(x)
        mu = self.fc_mu(h)
        log_var = self.fc_log_var(h)
        return mu, log_var


class VAEDecoder(nn.Module):
    """
    VAE 解码器：实现生成分布  $P_{\theta}(x | z)$ 

    对于二值图像，输出 Bernoulli 参数（像素值）
    """

    def __init__(self, latent_dim: int = 20, hidden_dim: int = 512,
                  output_dim: int = 784):
        super().__init__()
        self.net = nn.Sequential(
```

```

        nn.Linear(latent_dim, hidden_dim),
        nn.ReLU(),
        nn.Linear(hidden_dim, hidden_dim),
        nn.ReLU(),
        nn.Linear(hidden_dim, output_dim),
        nn.Sigmoid(), # 输出 [0,1] 范围的像素概率
    )

    def forward(self, z: torch.Tensor) -> torch.Tensor:
        return self.net(z)

class VAE(nn.Module):
    """
    变分自编码器 (Variational Autoencoder)

    生成过程 (解码):
         $z \sim P(z) = N(0, I)$ 
         $x \sim P_{\theta}(x | z) = \text{Bernoulli}(f_{\theta}(z))$ 

    推断过程 (编码):
         $q_{\phi}(z | x) = N(\mu_{\phi}(x), \text{diag}(\sigma^2_{\phi}(x)))$ 

    训练目标: 最大化 ELBO
         $L = E_q[\log P_{\theta}(x/z)] - KL(q_{\phi}(z/x) || P(z))$ 
        = 重建项 - KL 正则化项
    """

    def __init__(self, input_dim: int = 784, hidden_dim: int = 512,
                  latent_dim: int = 20):
        super().__init__()
        self.encoder = VAEEncoder(input_dim, hidden_dim, latent_dim)
        self.decoder = VAEDecoder(latent_dim, hidden_dim, input_dim)
        self.latent_dim = latent_dim

    def reparameterize(self, mu: torch.Tensor,
                      log_var: torch.Tensor) -> torch.Tensor:
        """
        重参数化技巧:  $z = \mu + \sigma * \epsilon, \epsilon \sim N(0, I)$ 

        将随机性移到  $\epsilon$ , 使得梯度可以通过  $\mu$  和  $\log\_var$  反向传播

```

```

"""
if self.training:
    std = torch.exp(0.5 * log_var)      # sigma = exp(log_var / 2)
    eps = torch.randn_like(std)        # epsilon ~ N(0, I)
    return mu + std * eps
else:
    return mu    # 推断时直接使用均值

def forward(self, x: torch.Tensor) -> Tuple[torch.Tensor, torch.Tensor, torch.Tensor]:
    """ 前向传播：编码 -> 重参数化采样 -> 解码 """
    mu, log_var = self.encoder(x)
    z = self.reparameterize(mu, log_var)
    x_recon = self.decoder(z)
    return x_recon, mu, log_var

def elbo_loss(self, x: torch.Tensor, x_recon: torch.Tensor,
               mu: torch.Tensor, log_var: torch.Tensor) -> Tuple[torch.Tensor, torch.Tensor, torch.Tensor]:
    """
    计算 ELBO (取负号作为损失函数)

    ELBO = E_q[log P(x/z)] - KL(q(z/x) || P(z))

    重建项 (BCE): E_q[log P(x/z)]  sum_i x_i log x_recon_i + (1-x_i) log (1-x_recon_i)

    KL 项 (对角高斯有解析解):
        KL(N(mu, diag(sigma^2)) || N(0, I))
        = -0.5 * sum_j (1 + log_var_j - mu_j^2 - exp(log_var_j))
    """
    # 重建损失 (逐像素二元交叉熵, 取均值)
    recon_loss = F.binary_cross_entropy(x_recon, x, reduction='sum')

    # KL 散度 (解析形式, 无需采样)
    # KL = -0.5 * sum(1 + log_var - mu^2 - exp(log_var))
    kl_loss = -0.5 * torch.sum(1 + log_var - mu.pow(2) - log_var.exp())

    # 总损失 = 重建损失 + KL 散度
    total_loss = recon_loss + kl_loss
    return total_loss, recon_loss, kl_loss

@torch.no_grad()
def generate(self, n_samples: int = 16,

```



```

        device: str = 'cpu') -> torch.Tensor:
    """ 从先验  $P(z) = N(0, I)$  采样并解码 """
    z = torch.randn(n_samples, self.latent_dim).to(device)
    return self.decoder(z)

@torch.no_grad()
def reconstruct(self, x: torch.Tensor) -> torch.Tensor:
    """ 重建输入图像 """
    x_recon, _, _ = self.forward(x)
    return x_recon

# =====
# Part 3: 训练与可视化
# =====

def train_vae(model: VAE, train_loader: DataLoader,
              n_epochs: int = 10, lr: float = 1e-3,
              device: str = 'cpu') -> list:
    """ 训练 VAE 模型 """
    optimizer = torch.optim.Adam(model.parameters(), lr=lr)
    model.to(device)
    model.train()

    history = []
    for epoch in range(n_epochs):
        total_loss = recon_total = kl_total = 0.0
        n_batches = 0

        for x, _ in train_loader:
            x = x.view(x.size(0), -1).to(device)      # 展平图像 (B, 784)

            optimizer.zero_grad()
            x_recon, mu, log_var = model(x)
            loss, recon_loss, kl_loss = model.elbo_loss(x, x_recon, mu, log_var)

            loss.backward()
            optimizer.step()

            total_loss += loss.item()
            recon_total += recon_loss.item()

```

```

        kl_total += kl_loss.item()
        n_batches += 1

    avg_loss = total_loss / n_batches
    avg_recon = recon_total / n_batches
    avg_kl = kl_total / n_batches
    history.append({'loss': avg_loss, 'recon': avg_recon, 'kl': avg_kl})

    print(f"Epoch [{epoch+1:2d}/{n_epochs}] "
          f"Loss: {avg_loss:.1f} "
          f"(Recon: {avg_recon:.1f}, KL: {avg_kl:.1f})")

    return history

def demo_gmm():
    """GMM EM 算法演示"""
    print("=" * 60)
    print("  高斯混合模型 (GMM) - EM 算法演示")
    print("=" * 60)

    # 生成合成数据：3 个高斯分量
    rng = np.random.RandomState(42)
    centers = np.array([[0, 0], [5, 0], [2.5, 4]])
    X_list = [rng.multivariate_normal(c, np.eye(2) * 0.8, 200) for c in centers]
    X = np.vstack(X_list)
    y_true = np.repeat([0, 1, 2], 200)

    print(f"\n数据集: {X.shape[0]} 个点, {len(centers)} 个真实分量")

    # 拟合 GMM
    gmm = GaussianMixture(n_components=3, n_iter=100, tol=1e-6)
    gmm.fit(X)

    # 评估
    y_pred = gmm.predict(X)
    # 简单评估 (不考虑标签排列)
    from scipy.optimize import linear_sum_assignment
    from sklearn.metrics import confusion_matrix
    C = confusion_matrix(y_true, y_pred)
    row_ind, col_ind = linear_sum_assignment(-C)

```

```

accuracy = C[row_ind, col_ind].sum() / len(y_true)
print(f" 聚类准确率: {accuracy:.3f}")

print("\n估计的混合权重: ", np.round(gmm.pi, 3))
print(" 估计的均值: \n", np.round(gmm.mu, 3))

return gmm, X

def demo_vae():
    """VAE 训练演示"""
    print("\n" + "=" * 60)
    print(" 变分自编码器 (VAE) - MNIST 演示")
    print("=" * 60)

    device = 'cuda' if torch.cuda.is_available() else 'cpu'
    print(f" 使用设备: {device}")

    # 加载 MNIST 数据集
    transform = transforms.Compose([
        transforms.ToTensor(),
    ])
    train_dataset = datasets.MNIST('./data', train=True, download=True,
                                   transform=transform)
    train_loader = DataLoader(train_dataset, batch_size=128, shuffle=True,
                              num_workers=0)

    # 创建 VAE 模型
    vae = VAE(input_dim=784, hidden_dim=512, latent_dim=20)
    total_params = sum(p.numel() for p in vae.parameters())
    print(f"\nVAE 参数量: {total_params:,}")
    print(f" 编码器: 输入 (784) -> 隐层 (512) -> 隐变量均值 + 方差 (20+20)")
    print(f" 解码器: 隐变量 (20) -> 隐层 (512) -> 输出 (784)")

    # 训练
    print("\n开始训练 (5 个 epoch, 仅作演示) ...")
    history = train_vae(vae, train_loader, n_epochs=5, lr=1e-3, device=device)

    return vae, history

```

```

def visualize_latent_space(vae: VAE, test_loader: DataLoader,
                           device: str = 'cpu'):
    """
    可视化 2D 隐空间 (当 latent_dim=2 时)

    展示 VAE 学到的连续、结构化的隐空间表示
    """
    if vae.latent_dim != 2:
        print(" 注：隐空间可视化需要 latent_dim=2, 当前跳过")
        return

    vae.eval()
    all_mu = []
    all_labels = []

    with torch.no_grad():
        for x, y in test_loader:
            x = x.view(x.size(0), -1).to(device)
            mu, _ = vae.encoder(x)
            all_mu.append(mu.cpu().numpy())
            all_labels.append(y.numpy())

    all_mu = np.concatenate(all_mu)
    all_labels = np.concatenate(all_labels)

    plt.figure(figsize=(8, 6))
    scatter = plt.scatter(all_mu[:, 0], all_mu[:, 1],
                           c=all_labels, cmap='tab10', alpha=0.3, s=1)
    plt.colorbar(scatter, label='数字类别')
    plt.title('VAE 隐空间可视化 (测试集)')
    plt.xlabel('$z_1$')
    plt.ylabel('$z_2$')
    plt.tight_layout()
    plt.savefig('vae_latent_space.png', dpi=150)
    print(" 隐空间可视化保存至 vae_latent_space.png")

if __name__ == '__main__':
    # 演示 1: GMM EM 算法
    try:
        from scipy.optimize import linear_sum_assignment

```

```

from sklearn.metrics import confusion_matrix
gmm, X_data = demo_gmm()
except ImportError:
    print(" 提示：完整 GMM 演示需要 scipy 和 sklearn")
    # 简化版演示（不计算准确率）
    rng = np.random.RandomState(42)
    X_data = np.vstack([
        rng.multivariate_normal([0, 0], np.eye(2), 200),
        rng.multivariate_normal([5, 0], np.eye(2), 200),
        rng.multivariate_normal([2.5, 4], np.eye(2), 200),
    ])
    gmm = GaussianMixture(n_components=3).fit(X_data)

# 演示 2: VAE
print("\n提示：VAE 训练需要 torchvision 和 MNIST 数据集")
print(" 如已安装，取消注释以下代码： ")
print("  vae, history = demo_vae()")

# 快速验证 VAE 前向传播
print("\n验证 VAE 模型结构： ")
vae_model = VAE(input_dim=784, hidden_dim=256, latent_dim=10)
x_test = torch.randn(4, 784)
x_recon, mu, log_var = vae_model(x_test)
loss, recon, kl = vae_model.elbo_loss(
    torch.sigmoid(x_test), x_recon, mu, log_var
)
print(f" 输入形状：{x_test.shape}")
print(f" 重建形状：{x_recon.shape}")
print(f" 隐变量均值形状：{mu.shape}")
print(f" ELBO = -(重建损失 {recon.item():.1f} + KL 散度 {kl.item():.1f})")
print(" 前向传播验证通过！ ")

```

练习题

练习 24.1（贝叶斯网络因子分解）

考虑以下贝叶斯网络，包含节点 A, B, C, D, E ，其中边的结构为： $A \rightarrow C$, $B \rightarrow C$, $C \rightarrow D$, $C \rightarrow E$

- (1) 写出联合分布 $P(A, B, C, D, E)$ 的因子分解形式。
- (2) 利用 d-分离准则，判断以下条件独立性是否成立：

- $A \perp\!\!\!\perp B$ (未观测任何节点)
- $A \perp\!\!\!\perp B \mid C$
- $D \perp\!\!\!\perp E \mid C$
- $A \perp\!\!\!\perp D \mid C$

(3) 计算边缘分布 $P(D)$ 的表达式 (以条件概率表示)。

练习 24.2 (d-分离的碰撞结构)

考虑碰撞结构 $X \rightarrow Y \leftarrow Z$, 其中 X, Z 为二值变量, $P(X = 1) = P(Z = 1) = 0.5$, 且 $Y = X \oplus Z$ (异或)。

- (1) 验证 X 与 Z 在不观测 Y 时独立。
 - (2) 计算 $P(X = 1 \mid Y = 1)$ 和 $P(X = 1 \mid Y = 1, Z = 0)$, 说明观测 Y 后 X 与 Z 变得相关 (即“解释消去”效应)。
 - (3) 用信息论中的互信息 $I(X; Z \mid Y)$ 定量描述这一依赖程度。
-

练习 24.3 (EM 算法推导)

设观测数据 $\mathbf{x} = \{x_1, \dots, x_N\}$ 来自参数为 θ 的隐变量模型, 隐变量为 $\mathbf{z} = \{z_1, \dots, z_N\}$ 。

- (1) 写出对数边缘似然 $\log P(\mathbf{x} \mid \theta)$ 的下界 (ELBO) 的推导过程, 明确使用 Jensen 不等式的步骤。
 - (2) 证明当 $q(\mathbf{z}) = P(\mathbf{z} \mid \mathbf{x}, \theta)$ 时, 下界与对数似然相等 (即间隙为零)。
 - (3) 证明 EM 算法的单调性: $\log P(\mathbf{x} \mid \theta^{(t+1)}) \geq \log P(\mathbf{x} \mid \theta^{(t)})$ 。
-

练习 24.4 (GMM 的 EM 算法)

考虑一维 GMM: $P(x) = \pi_1 \mathcal{N}(x \mid \mu_1, \sigma^2) + \pi_2 \mathcal{N}(x \mid \mu_2, \sigma^2)$ (两个分量共享方差 σ^2)。

- (1) 写出 E 步: 给定当前参数 $\{\pi_k^{(t)}, \mu_k^{(t)}\}$, 计算责任 r_{ik} 。
 - (2) 写出 M 步: 在共享方差 σ^2 的约束下, 推导参数的更新公式。
 - (3) 如果两个分量完全重叠 ($\mu_1^{(t)} = \mu_2^{(t)}$), EM 算法会如何演化? 这说明 GMM 的什么问题?
-

练习 24.5 (VAE 与 ELBO)

VAE 使用对角高斯近似后验 $q_\phi(\mathbf{z} \mid \mathbf{x}) = \mathcal{N}(\mathbf{z} \mid \mu_\phi(\mathbf{x}), \text{diag}(\sigma_\phi^2(\mathbf{x})))$, 先验 $P(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。

- (1) 推导 KL 散度 $\text{KL}(q_\phi(\mathbf{z} \mid \mathbf{x}) \parallel P(\mathbf{z}))$ 的解析表达式。
- (2) 解释“重参数化技巧”的必要性: 为什么不能直接对 $\mathbb{E}_{q_\phi(\mathbf{z} \mid \mathbf{x})}[\log P_\theta(\mathbf{x} \mid \mathbf{z})]$ 关于 ϕ 求梯度?

- (3) 描述 VAE 中“KL 坍塌 (KL collapse)”现象：当 KL 项变为零时意味着什么？为什么这是一个问题？如何缓解？
-

练习答案

练习 24.1 解答

(1) 因子分解

根据贝叶斯网络因子分解公式，每个节点的概率只依赖于其父节点：

$$P(A, B, C, D, E) = P(A) \cdot P(B) \cdot P(C | A, B) \cdot P(D | C) \cdot P(E | C)$$

(2) 条件独立性判断

- $A \perp\!\!\!\perp B$ ：路径 $A \rightarrow C \leftarrow B$ ，中间节点 C 是碰撞节点，且 C 未被观测，路径被阻断。成立 $\square$
- $A \perp\!\!\!\perp B | C$ ：观测 C 后，碰撞节点被“激活”，路径 $A \rightarrow C \leftarrow B$ 变为畅通。不成立 $\square$ （观测子节点成绩会使父节点智力与难度产生关联）
- $D \perp\!\!\!\perp E | C$ ：路径 $D \leftarrow C \rightarrow E$ ，中间节点 C 是分叉节点，观测 C 阻断路径。成立 $\square$
- $A \perp\!\!\!\perp D | C$ ：路径 $A \rightarrow C \rightarrow D$ ，中间节点 C 是链式节点，观测 C 阻断路径。成立 $\square$

(3) 边缘分布

$$P(D) = \sum_C P(D | C)P(C) = \sum_C P(D | C) \sum_A \sum_B P(C | A, B)P(A)P(B)$$

练习 24.2 解答

(1) 独立性验证

$P(X, Z) = P(X)P(Z) = 0.25$ ，对所有 (x, z) 组合均成立，因为 X 和 Z 是独立定义的。 $P(X = 1, Z = 1) = 0.25 = P(X = 1) \cdot P(Z = 1)$ ，独立性成立。

(2) 条件分布

$Y = X \oplus Z$ ，所以 $Y = 1$ 当且仅当 $X \neq Z$ ，即 $(X = 1, Z = 0)$ 或 $(X = 0, Z = 1)$ ：

$$P(Y = 1) = 0.5$$

$$P(X = 1 | Y = 1) = \frac{P(X = 1, Y = 1)}{P(Y = 1)} = \frac{P(X = 1, Z = 0)}{0.5} = \frac{0.25}{0.5} = 0.5$$

$$P(X = 1 | Y = 1, Z = 0) = \frac{P(X = 1, Z = 0, Y = 1)}{P(Z = 0, Y = 1)} = \frac{P(X = 1, Z = 0)}{P(X = 1, Z = 0)} = 1$$

因此 $P(X = 1 | Y = 1) = 0.5$ ，而 $P(X = 1 | Y = 1, Z = 0) = 1$ ：观测 Y 后再观测 Z 会完全确定 X ，说明 X 与 Z 在给定 Y 时强相关。

(3) 条件互信息

$$I(X; Z | Y) = \sum_y P(y) \sum_{x,z} P(x, z | y) \log \frac{P(x, z | y)}{P(x | y)P(z | y)} = 1 \text{ bit}$$

(当 $Y = 1$ 时，给定 Z 后 X 完全确定；当 $Y = 0$ 时同理，条件互信息为 1 比特。)

练习 24.3 解答

(1) ELBO 推导

$$\log P(\mathbf{x} | \theta) = \log \int P(\mathbf{x}, \mathbf{z} | \theta) d\mathbf{z}$$

引入任意分布 $q(\mathbf{z})$ ：

$$= \log \int q(\mathbf{z}) \frac{P(\mathbf{x}, \mathbf{z} | \theta)}{q(\mathbf{z})} d\mathbf{z}$$

由 Jensen 不等式 ($\log$ 是凹函数， $\log \mathbb{E}[f] \geq \mathbb{E}[\log f]$)：

$$\geq \int q(\mathbf{z}) \log \frac{P(\mathbf{x}, \mathbf{z} | \theta)}{q(\mathbf{z})} d\mathbf{z} = \mathcal{L}(q, \theta)$$

(2) 间隙为零的条件

间隙为：

$$\log P(\mathbf{x} | \theta) - \mathcal{L}(q, \theta) = \text{KL}(q(\mathbf{z}) \| P(\mathbf{z} | \mathbf{x}, \theta))$$

当 $q(\mathbf{z}) = P(\mathbf{z} | \mathbf{x}, \theta)$ 时， $\text{KL} = 0$ ，间隙为零。

(3) EM 单调性证明

E 步：令 $q^{(t)}(\mathbf{z}) = P(\mathbf{z} | \mathbf{x}, \theta^{(t)})$ ，此时 $\mathcal{L}(q^{(t)}, \theta^{(t)}) = \log P(\mathbf{x} | \theta^{(t)})$

M 步： $\theta^{(t+1)} = \arg \max_{\theta} \mathcal{L}(q^{(t)}, \theta)$ ，所以 $\mathcal{L}(q^{(t)}, \theta^{(t+1)}) \geq \mathcal{L}(q^{(t)}, \theta^{(t)})$

因此：

$$\log P(\mathbf{x} | \theta^{(t+1)}) \geq \mathcal{L}(q^{(t)}, \theta^{(t+1)}) \geq \mathcal{L}(q^{(t)}, \theta^{(t)}) = \log P(\mathbf{x} | \theta^{(t)})$$

练习 24.4 解答

(1) E 步

$$r_{i1} = \frac{\pi_1^{(t)} \mathcal{N}(x_i | \mu_1^{(t)}, \sigma^2)}{\pi_1^{(t)} \mathcal{N}(x_i | \mu_1^{(t)}, \sigma^2) + \pi_2^{(t)} \mathcal{N}(x_i | \mu_2^{(t)}, \sigma^2)}$$

$$r_{i2} = 1 - r_{i1}$$

(2) M 步（共享方差）

令 $N_k = \sum_i r_{ik}$ ，参数更新为：

$$\mu_k^{(t+1)} = \frac{\sum_i r_{ik} x_i}{N_k}, \quad \pi_k^{(t+1)} = \frac{N_k}{N}$$

共享方差：

$$(\sigma^2)^{(t+1)} = \frac{\sum_k \sum_i r_{ik} (x_i - \mu_k^{(t+1)})^2}{N}$$

(3) 完全重叠时的行为

当 $\mu_1 = \mu_2$ 时，两个分量对每个数据点贡献相同， $r_{i1} = \pi_1, r_{i2} = \pi_2$ 。M 步更新后，两个均值都等于全局加权均值：

$$\mu_1^{(t+1)} = \mu_2^{(t+1)} = \frac{1}{N} \sum_i x_i$$

这是局部极值陷阱：模型无法分辨两个分量，不会自动打破对称性。这说明 GMM 对初始化敏感，需要良好的参数初始化（如 K-means++ 初始化）来避免收敛到退化解。

练习 24.5 解答

(1) KL 散度解析表达式

设 $q_\phi = \mathcal{N}(\mu, \text{diag}(\sigma^2))$, $P(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$, 维度为 J :

$$\text{KL}(q_\phi \| P) = -\frac{1}{2} \sum_{j=1}^J (1 + \log \sigma_j^2 - \mu_j^2 - \sigma_j^2)$$

推导: 利用高斯分布 KL 散度的公式, 两个高斯分布之间的 KL 散度为:

$$\text{KL}(\mathcal{N}(\mu, \Sigma) \| \mathcal{N}(\mathbf{0}, I)) = \frac{1}{2} (\text{tr}(\Sigma) + \mu^\top \mu - J - \log |\Sigma|)$$

对于对角协方差, $\text{tr}(\Sigma) = \sum_j \sigma_j^2$, $\log |\Sigma| = \sum_j \log \sigma_j^2$, 代入即得上式。

(2) 重参数化技巧的必要性

$\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log P_\theta(\mathbf{x}|\mathbf{z})]$ 对 ϕ 的梯度为:

$$\nabla_\phi \mathbb{E}_{q_\phi}[\cdot] = \nabla_\phi \int q_\phi(\mathbf{z}|\mathbf{x}) \log P_\theta(\mathbf{x}|\mathbf{z}) d\mathbf{z}$$

由于积分的边界依赖于 ϕ (通过分布 q_ϕ), 无法直接交换梯度和积分顺序。蒙特卡洛估计 $\frac{1}{S} \sum_s \nabla_\phi [\log P_\theta(\mathbf{x}|\mathbf{z}^{(s)})]$ 需要 $\mathbf{z}^{(s)}$ 对 ϕ 可微, 但直接从 q_ϕ 采样是不可微的操作。

重参数化将 $\mathbf{z} = \mu_\phi + \sigma_\phi \odot \epsilon$, $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, 将随机性从参数中分离出来, 使得 $\mathbf{z}$ 对 ϕ 可微。

(3) KL 坍塌

KL 坍塌指训练过程中 $\text{KL}(q_\phi(\mathbf{z}|\mathbf{x}) \| P(\mathbf{z})) \rightarrow 0$, 即近似后验趋向于先验 $P(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$, 不再依赖输入 $\mathbf{x}$ 。

意味着: 编码器没有将任何有用信息编入隐变量, 解码器完全忽略 $\mathbf{z}$ (退化为普通自回归模型)。

原因: 当解码器过于强大时, 它可以直接从输入预测输出而不需要隐变量的帮助, KL 项就“免费”被最小化了。

缓解方法: - **KL 退火**: 训练初期给 KL 项加小权重 $\beta < 1$, 逐渐增加到 1 - **β -VAE**: 固定使用 $\beta > 1$ 的 KL 权重以增强隐变量的解耦 - **自由比特 (Free Bits)**: 保证每个隐变量维度至少贡献一定量的 KL 散度

概率公理与样本空间

一例速记: 已知均匀分布的圆盘上随机取点, 落在直径为 r 的内切圆内的概率是多少? 古典概型无法直接用 (点的个数无穷), 改用几何概型:

$$P = \frac{\text{内切圆面积}}{\text{大圆面积}} = \frac{\pi(r/2)^2}{\pi r^2} = \frac{1}{4}.$$

识别”等可能 + 有限”用古典, 识别”等可能 + 连续”用几何。

一、为什么需要公理化概率

日常语言里的“概率”至少有三种截然不同的含义：掷硬币的正面概率 $1/2$ 是“对称性”，100 次试验出现 47 次正面说明频率约 0.47，气象预报“明天降雨概率 70%”则是“主观信度”。

这三种含义表面上都叫“概率”，但它们的来源、计算方式、适用场景各不相同。如果不加以区分，就很容易混淆，产生逻辑矛盾。

Kolmogorov 公理化体系（1933 年）的意义在于：不管概率的“物理含义”是什么（频率？对称？主观？），只要满足三条公理，就能用同一套数学工具推导所有结论。这就像欧几里得几何：不管“点”和“线”在现实中指什么，只要满足公理，几何定理就成立。

本篇从样本空间和事件运算讲起，建立 Kolmogorov 三公理，引入 σ -代数的基本概念，对比四种概型，最后用古典概型和几何概型双解一道经典问题。

二、样本空间与事件

2.1 样本空间

定义：一次随机试验的所有可能结果组成的集合，称为样本空间，记作 Ω 。 Ω 中的每个元素 ω 称为一个样本点（基本结果）。

试验	样本空间 Ω
掷一枚硬币	$\{H, T\}$
掷一颗骰子	$\{1, 2, 3, 4, 5, 6\}$
测量一根棍子的长度（单位：cm）	$[0, +\infty)$
同时掷两枚骰子	$\{(i, j) : i, j \in \{1, \dots, 6\}\}$ ，共 36 个点
记录电话呼叫到达时刻	$[0, +\infty)$

事件是 Ω 的子集，通常用大写字母 A, B, C 表示。例如“掷骰子出现偶数”对应 $A = \{2, 4, 6\}$ 。

- 必然事件： Ω 本身——试验必然发生的结果。
- 不可能事件： $\emptyset$ ——不可能发生的结果。
- 基本事件：单元素集合 $\{\omega\}$ 。

2.2 事件运算

设 A, B 是 Ω 上的两个事件：

运算	符号	集合含义	概率语言
并 (和)	$A \cup B$	A 或 B 中至少有一个发生	A 或 B 发生
交 (积)	$A \cap B$ (简写 AB)	A 和 B 同时发生	A 且 B 发生
补 (余)	$\overline{A}$ (或 A^c)	A 不发生	A 的对立事件
差	$A \setminus B$ (或 $A - B$)	A 发生但 B 不发生	A 但非 B

互斥 (互不相容): 若 $A \cap B = \emptyset$, 称 A 与 B 互斥——两者不能同时发生。

德摩根律 (集合 / 事件的对偶关系):

$$\overline{A \cup B} = \overline{A} \cap \overline{B}, \quad \overline{A \cap B} = \overline{A} \cup \overline{B}.$$

推广到有限个事件:

$$\overline{\bigcup_{i=1}^n A_i} = \bigcap_{i=1}^n \overline{A_i}, \quad \overline{\bigcap_{i=1}^n A_i} = \bigcup_{i=1}^n \overline{A_i}.$$

口诀: “非 (A 或 B) = 非 A 且非 B; 非 (A 且 B) = 非 A 或非 B”——把” $\cup$ “换成” $\cap$ “, 同时把” $-$ “移进去。

三、 σ -代数: 概率的”域“

3.1 为什么需要 σ -代数

对于有限样本空间 (如骰子), Ω 的所有子集都可以赋予概率, 问题不大。但对于连续样本空间 (如 $\Omega = \mathbb{R}$), 并非所有子集都能被”测量“——Vitali 集等非可测集告诉我们, 试图对所有子集定义概率会导致矛盾。

解决办法是: 只对”足够好“的子集定义概率。这些”足够好“的子集组成一个集合族, 叫做 σ -代数 (也称 σ -域)。

3.2 σ -代数的定义

定义: 设 Ω 是样本空间, $\mathcal{F}$ 是 Ω 的某些子集组成的集合族。若 $\mathcal{F}$ 满足以下三条, 称 $\mathcal{F}$ 是 Ω 上的一个 σ -代数:

- 1. $\Omega \in \mathcal{F}$ (包含全集);
- 2. 若 $A \in \mathcal{F}$, 则 $\overline{A} \in \mathcal{F}$ (对补运算封闭);
- 3. 若 $A_1, A_2, A_3, \dots \in \mathcal{F}$, 则 $\bigcup_{i=1}^\infty A_i \in \mathcal{F}$ (对可数并封闭)。

由 1 和 2 可推出 $\emptyset \in \mathcal{F}$; 由德摩根律和 2、3 可推出对可数交也封闭。

最小例子: $\mathcal{F} = \{\emptyset, \Omega\}$ (平凡 σ -代数)。

最大例子: $\mathcal{F} = 2^\Omega$ (Ω 的全部子集, 适用于有限 Ω)。

实用最重要的例子： $\mathcal{B}(\mathbb{R})$ ，即 $\mathbb{R}$ 上所有开区间生成的 σ -代数，称为 **Borel σ -代数**。实数直线上几乎所有”实际遇到”的集合（开集、闭集、区间、可数集等）都在 $\mathcal{B}(\mathbb{R})$ 中。

3.3 概率空间

三元组 $(\Omega, \mathcal{F}, P)$ 称为**概率空间**，其中：- Ω ：样本空间；- $\mathcal{F}$ ： σ -代数（可测事件族）；- P ：定义在 $\mathcal{F}$ 上满足 Kolmogorov 公理的概率测度。

入门阶段：只需知道 σ -代数是”允许赋予概率的事件的集合”，不必深入测度论。

四、Kolmogorov 三公理

4.1 公理表述

设 $(\Omega, \mathcal{F}, P)$ 是概率空间。概率是满足以下三条公理的实值函数 $P : \mathcal{F} \rightarrow \mathbb{R}$ ：

公理 1（非负性）：

$$\forall A \in \mathcal{F} : \quad P(A) \geq 0.$$

公理 2（归一性）：

$$P(\Omega) = 1.$$

公理 3（可列可加性）：若 $A_1, A_2, \dots \in \mathcal{F}$ 两两互斥 ($A_i \cap A_j = \emptyset, i \neq j$)，则

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

4.2 由三公理推导的基本性质

以下性质全部由三条公理逻辑推出（不是新的假设）：

性质	公式	推导思路
不可能事件	$P(\emptyset) = 0$	令所有 $A_i = \emptyset$ ，由公理 3 + 公理 2
有限可加性	$P(A \cup B) = P(A) + P(B)$ (A, B 互斥)	公理 3 的特例
互补律	$P(\overline{A}) = 1 - P(A)$	$\Omega = A \cup \overline{A}$ ，两者互斥，由公理 2、3
单调性	$A \subseteq B \Rightarrow P(A) \leq P(B)$	$B = A \cup (B \setminus A)$ ，有限可加性
概率上界	$P(A) \leq 1$	由单调性 $A \subseteq \Omega$
加法公式	$P(A \cup B) = P(A) + P(B) - P(AB)$	$A \cup B = A \cup (B \setminus A)$ ，拆项

容斥原理（三个事件）：

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(AB) - P(AC) - P(BC) + P(ABC).$$

五、四种概型对比

概型	核心思想	适用条件	概率计算方式
古典概型	等可能性	样本空间有限且每个基本事件等可能	$P(A) = \frac{ A }{ \Omega }$ （事件 A 的基本事件数 / 总数）
几何概型	等可能性推广到连续	样本空间是某个几何区域，“随机”落点均匀分布	$P(A) = \frac{\mu(A)}{\mu(\Omega)}$ （ μ 是面积/长度/体积等测度）
频率概型	大数定律	可大量重复的试验	用频率 $f_n(A) = n_A/n$ 近似 $P(A)$ （ $n \rightarrow \infty$ ）
主观概率	个人信度	不可重复的单次事件（选举、历史事件等）	由专家或贝叶斯框架给出的主观信念

关键辨析：

- 古典概型要求”有限 + 等可能”，两个条件缺一不可。若样本点不等可能，不能用 $P(A) = |A|/|\Omega|$ 。
- 几何概型适用于”随机”点在某区域内均匀分布——“均匀”就是等可能的连续推广。
- 频率概型是客观的，依赖可重复实验；主观概率不依赖重复，但要满足 Kolmogorov 公理（一致性）。

六、演示题：古典概型与几何概型双解等公交问题

题目

某公交车每隔 $T = 10$ 分钟一班，乘客在站台随机到达（均匀分布）。问乘客等待时间不超过 3 分钟的概率。另外，若将问题改为：从 $\{1, 2, \dots, 10\}$ 中随机取一个整数，该整数 ≤ 3 的概率。

（后者为古典概型版本，前者为几何概型版本。）

拿到这道题，我先判断属于哪种概型。

几何概型版本：乘客到达时刻均匀分布在 $[0, 10)$ 分钟区间内。等待时间 = 下一班车到达时间 - 乘客到达时间。设乘客到达时刻为 $X \in [0, 10)$ ，下一班车在 10 分钟时到（不妨视为周期开始），等待时间为 $10 - X$ （若 $X \in [0, 10)$ ）。

等待时间 ≤ 3 分钟，即 $10 - X \leq 3$ ，即 $X \geq 7$ 。

样本空间: $\Omega = [0, 10)$, 长度 $\mu(\Omega) = 10$ 。满足条件的集合: $A = [7, 10)$, 长度 $\mu(A) = 3$ 。

$$P(\text{等待} \leq 3 \text{ 分钟}) = \frac{\mu(A)}{\mu(\Omega)} = \frac{3}{10} = 0.3.$$

古典概型版本: 从 $\{1, 2, \dots, 10\}$ 中等可能取一整数, 问取到 ≤ 3 的概率。

$\Omega = \{1, 2, \dots, 10\}$, $|\Omega| = 10$; $A = \{1, 2, 3\}$, $|A| = 3$ 。

$$P(A) = \frac{|A|}{|\Omega|} = \frac{3}{10} = 0.3.$$

两种模型给出同样答案, 但路径不同: 古典概型数点, 几何概型量长度。若公交间隔变成连续实数 $t \in [0, 10]$ 而非整数, 只有几何概型还能用。

回顾: 先判断样本空间是有限等可能 (古典) 还是连续均匀分布 (几何), 选对工具事半功倍。

七、蒲丰投针问题 (几何概型经典)

题目

平面上画有间距为 d 的平行线, 将一根长度为 l ($l \leq d$) 的针随机抛下, 求针与某条平行线相交的概率。

分析

这是几何概型的典范。针的“随机”由两个独立的量决定:

- 针的中点到最近一条平行线的距离 $x \in [0, d/2]$ (利用对称性取半区间);
- 针与平行线所成的锐角 $\theta \in [0, \pi/2]$ 。

样本空间是矩形区域 $\Omega = \{(x, \theta) : 0 \leq x \leq d/2, 0 \leq \theta \leq \pi/2\}$, 面积 $\mu(\Omega) = \frac{d}{2} \cdot \frac{\pi}{2} = \frac{\pi d}{4}$ 。

针与最近平行线相交, 当且仅当中点到该线的距离 $x \leq$ 针端点到最近线的投影长度, 即:

$$x \leq \frac{l}{2} \sin \theta.$$

满足条件的区域面积:

$$\mu(A) = \int_0^{\pi/2} \frac{l}{2} \sin \theta d\theta = \frac{l}{2} \cdot [-\cos \theta]_0^{\pi/2} = \frac{l}{2}(0 - (-1)) = \frac{l}{2}.$$

因此:

$$P(\text{相交}) = \frac{\mu(A)}{\mu(\Omega)} = \frac{l/2}{\pi d/4} = \frac{2l}{\pi d}.$$

这个结果的妙处在于含有 π ，历史上被用来估算 π 的值：大量投针，统计相交频率，由 $P \approx 2l/(\pi d)$ 反解 $\pi \approx 2l/(Pd)$ 。

历史意义：蒲丰投针 (Buffon, 1777) 是历史上最早用几何概率估计超越数的实验，也是 Monte Carlo 方法的先驱。

八、思考路标

1. 判断概型的第一步 → 问“样本空间是有限的还是连续的？”有限且等可能 → 古典概型（数点）；连续且均匀分布 → 几何概型（量测度）；可重复大量试验 → 频率概型；不可重复 → 主观概率或贝叶斯框架。
2. 见“至少一个”或“至多一个” → 用对立事件： $P(\text{至少一个}) = 1 - P(\text{一个都没有})$ ，往往更简单。德摩根律是计算对立事件的核心工具。
3. 见多事件的并 $P(A \cup B \cup C)$ → 用容斥原理展开。项的个数 $= \binom{n}{1} - \binom{n}{2} + \binom{n}{3} - \dots$ ，记忆规律：奇数个事件的交前加，偶数个前减。
4. 几何概型中“随机”的精确含义 → 必须明确指定什么是“均匀”（即 μ 是什么）。不同的均匀性假设会给出不同概率（贝特朗悖论的教训）。面积均匀 $\neq$ 角度均匀 $\neq$ 半径均匀。
5. σ -代数的直觉 → 它是“可以被观测到的事件的集合”。比粗糙的事件族（太少）到精细的全集（太多）， σ -代数给出恰当的“可测性”边界。在有限样本空间里不用操心，在连续情形必须小心。
6. 由公理验证某函数是概率 → 检查三条： $P(A) \geq 0$ ， $P(\Omega) = 1$ ，互斥可列可加性。逐一验证，不能跳步。若某条不满足，该函数不是概率测度。
7. 加法公式应用时防止重复计数 → $P(A \cup B) = P(A) + P(B) - P(AB)$ ，中间的 $P(AB)$ 是防止重复计数的修正项。三个以上事件用容斥，系数交替正负。
8. 频率 $\neq$ 概率 → 频率是观测值，概率是理论值。频率会随样本量收敛到概率（大数定律），但有限次观测的频率会有随机波动。“频率等于概率”是理想极限，不是等式。

九、典型应用 3 例

例 1：古典概型——生日问题

题目： n 个人中至少有两人生日相同的概率（假设每人生日等可能是 365 天中的任意一天）。

思路：

用对立事件：“至少有两人生日相同”的对立是“所有人生日各不相同”。

样本空间：每人生日独立均匀选自 365 天，总样本点数 $|\Omega| = 365^n$ 。

所有人生日各不相同的方案数： $365 \times 364 \times 363 \times \cdots \times (365 - n + 1) = \frac{365!}{(365 - n)!}$ 。

$$P(\text{至少两人同生日}) = 1 - \frac{365 \times 364 \times \cdots \times (365 - n + 1)}{365^n}.$$

当 $n = 23$ 时， $P \approx 0.507 > 1/2$ ——生日悖论：仅 23 人，有一半概率有两人同生日，远超直觉。

关键技巧：对立事件 + 乘法原理计算有序排列。

例 2：几何概型——约会问题（会面问题）

题目：甲乙两人约好在 $[0, 1]$ 小时内各自随机到达，先到者最多等 $1/4$ 小时。求两人能相遇的概率。

思路：

设甲到达时刻 X ，乙到达时刻 Y ，均匀分布在 $[0, 1]$ 。样本空间 $\Omega = [0, 1]^2$ ，面积 1。

相遇条件： $|X - Y| \leq 1/4$ ，即 $-1/4 \leq X - Y \leq 1/4$ 。

满足条件的区域面积 = 总面积 - 两个直角三角形（不满足条件的部分）：

$$\mu(A) = 1 - 2 \times \frac{1}{2} \left(\frac{3}{4}\right)^2 = 1 - \frac{9}{16} = \frac{7}{16}.$$

$$P(\text{相遇}) = \frac{7}{16} = 0.4375.$$

识别链：连续均匀 $\rightarrow$ 几何概型 $\rightarrow$ 二维平面区域面积比。

例 3：事件运算——容斥原理

题目：一批 100 件产品中，有缺陷 A 的 20 件，有缺陷 B 的 15 件，同时有 A 和 B 两种缺陷的 5 件。随机取 1 件，求至少有一种缺陷的概率。

思路：

$$P(A) = 20/100 = 0.2, \quad P(B) = 15/100 = 0.15, \quad P(AB) = 5/100 = 0.05.$$

由加法公式：

$$P(A \cup B) = P(A) + P(B) - P(AB) = 0.2 + 0.15 - 0.05 = 0.3.$$

若直接相加 $0.2 + 0.15 = 0.35$ 会重复计数同时有两种缺陷的 5 件，需减去一次。

结论：有缺陷的概率为 0.3，即 30 件有缺陷。

十、自测题

第1题：掷两枚骰子，求“点数之和为7”的概率。

提示：样本空间 Ω 共 36 个等可能结果；点数之和为 7 的有 (1, 6), (2, 5), (3, 4), (4, 3), (5, 2), (6, 1) 共 6 个。
 $P = 6/36 = 1/6$ 。

第2题：用德摩根律化简 $P(\overline{A \cup B})$ ，并用 $P(A)$ 、 $P(B)$ 、 $P(AB)$ 表示。

提示： $\overline{A \cup B} = \overline{A} \cap \overline{B}$ （德摩根律），所以 $P(\overline{A \cup B}) = 1 - P(AB)$ 。

第3题：在正方形 $[0, 1]^2$ 内随机取一点，求该点到原点的距离小于 $1/2$ 的概率。

提示：满足条件的区域是以原点为圆心、半径 $1/2$ 的圆与正方形的交集（即 $1/4$ 个圆），面积 $= \pi/4 \times (1/2)^2 = \pi/16$ ；样本空间面积 $= 1$ ； $P = \pi/16 \approx 0.196$ 。

第4题：验证 $P(A \setminus B) = P(A) - P(AB)$ ，并用它证明 $P(AB) \leq P(A)$ 。

提示： $A = (A \setminus B) \cup (A \cap B)$ ，两者互斥，由有限可加性 $P(A) = P(A \setminus B) + P(AB)$ ，故 $P(A \setminus B) = P(A) - P(AB)$ 。由非负性 $P(A \setminus B) \geq 0$ ，得 $P(A) \geq P(AB)$ 。

第5题： n 件产品中有 m 件次品，不放回抽 k 件 ($k \leq m$)，求全部是次品的概率（古典概型）。

提示：从 n 件中取 k 件共 $\binom{n}{k}$ 种，全取次品的方法数 $\binom{m}{k}$ ， $P = \binom{m}{k} / \binom{n}{k}$ 。

条件概率与贝叶斯思维

一例速记：某疾病患病率 1%，某检测灵敏度 95%（患病被检出），特异度 90%（未患病被排除）。检测阳性后真的患病的概率是多少？直觉说“95%”，正确答案约 **8.7%**——绝大多数阳性是“误报”。先验概率极低时，即使高灵敏度的检测，阳性预测值也可以很低。

一、条件概率：信息更新后的概率

1.1 动机

掷一枚骰子，已知结果是偶数，问“点数为 2”的概率是多少？

不加条件时， $P(\text{点数} = 2) = 1/6$ 。但已知偶数 ($\{2, 4, 6\}$)，样本空间从 6 个点缩小到 3 个点，点数为 2 的概率变为 $1/3$ 。

这就是条件概率的直觉：在已知某事件发生的条件下，“缩小”样本空间后重新计算概率。

1.2 正式定义

定义：设 A, B 是概率空间 $(\Omega, \mathcal{F}, P)$ 上的两个事件， $P(A) > 0$ 。在“ A 已发生”的条件下， B 发生的条件概率定义为：

$$P(B | A) = \frac{P(AB)}{P(A)}.$$

直觉验证：若 A 中有 $|A|$ 个等可能点（古典概型）， AB 中有 $|AB|$ 个点，则

$$P(B | A) = \frac{|AB|/|\Omega|}{|A|/|\Omega|} = \frac{|AB|}{|A|}.$$

确实是“在 A 内”计算 B 的比例。

1.3 条件概率本身也是概率

固定 A ($P(A) > 0$)， $Q(\cdot) = P(\cdot | A)$ 满足 Kolmogorov 三公理：

1. $Q(B) = P(AB)/P(A) \geq 0$ （非负）；
2. $Q(\Omega) = P(A\Omega)/P(A) = P(A)/P(A) = 1$ （归一）；
3. 互斥可加性也成立（由 P 的可加性直接推出）。

所以条件概率是一个（新的）合法概率测度——所有概率的性质（加法公式、容斥等）都对条件概率成立。

二、乘法公式与链式规则

2.1 乘法公式

由条件概率定义 $P(B | A) = P(AB)/P(A)$ 直接得：

$$P(AB) = P(A) \cdot P(B | A).$$

同理， $P(AB) = P(B) \cdot P(A | B)$ （当 $P(B) > 0$ ）。

2.2 链式公式

对三个事件 ($P(AB) > 0$):

$$P(ABC) = P(A) \cdot P(B | A) \cdot P(C | AB).$$

推导:

$$P(ABC) = P(AB) \cdot P(C | AB) = P(A) \cdot P(B | A) \cdot P(C | AB).$$

推广到 n 个事件 (假设各条件概率有意义):

$$P(A_1 A_2 \cdots A_n) = P(A_1) \cdot P(A_2 | A_1) \cdot P(A_3 | A_1 A_2) \cdots P(A_n | A_1 A_2 \cdots A_{n-1}).$$

物理意义: 依次发生 n 件事, 总概率 = 第一件的概率 $\times$ 第一件发生后第二件的条件概率 $\times \cdots$ 这是序贯决策和马尔可夫链的基础。

三、全概率公式

3.1 划分与全概率

定义: 若 $B_1, B_2, \dots, B_n$ 两两互斥, 且 $\bigcup_{i=1}^n B_i = \Omega$ ($P(B_i) > 0$), 则称 $\{B_i\}$ 是 Ω 的一个划分 (完备事件组)。

全概率公式: 设 $\{B_1, \dots, B_n\}$ 是 Ω 的一个划分, 对任意事件 A :

$$P(A) = \sum_{i=1}^n P(B_i) \cdot P(A | B_i).$$

推导: $A = A\Omega = A(B_1 \cup \cdots \cup B_n) = AB_1 \cup \cdots \cup AB_n$ (互斥), 由可加性 + 乘法公式即得。

直觉: 若知道 B_i (“原因”) 发生后 A (“结果”) 的概率, 可以通过对各原因加权求和, 计算 A 的总概率。

3.2 应用场景

场景	B_i (划分)	A (目标事件)
工厂质检	各条生产线 (B_1, B_2, B_3)	抽到次品 A
疾病诊断	患病 B_1 、未患病 B_2	检测阳性 A
天气预测	晴 B_1 、阴 B_2 、雨 B_3	交通拥堵 A

四、贝叶斯公式

4.1 公式推导

已知各”原因” B_i 的先验概率 $P(B_i)$ ，以及在各原因下”结果” A 发生的概率 $P(A \mid B_i)$ 。现在观测到结果 A 已发生，问：是哪个原因导致的 ($P(B_i \mid A)$)?

贝叶斯公式：

$$P(B_i \mid A) = \frac{P(B_i) \cdot P(A \mid B_i)}{\sum_{j=1}^n P(B_j) \cdot P(A \mid B_j)} = \frac{P(B_i) \cdot P(A \mid B_i)}{P(A)}.$$

推导：分子用乘法公式 $P(B_i A) = P(B_i)P(A \mid B_i)$ ，分母用全概率公式。

4.2 贝叶斯更新的术语

术语	符号	含义
先验概率	$P(B_i)$	观测到 A 之前，对各原因的初始信念
似然	$P(A \mid B_i)$	在原因 B_i 下，观测到 A 的概率 (“模型”)
后验概率	$P(B_i \mid A)$	观测到 A 之后，更新对各原因的信念
证据（边缘似然）	$P(A)$	全概率公式给出的归一化常数

贝叶斯学习的核心：先验 $\times$ 似然 $\rightarrow$ 后验（再归一化）。每次观测都在更新信念。

五、独立性 vs 互斥性

这是最容易混淆的两个概念，表格对比如下：

	独立 (Independence)	互斥 (Mutually Exclusive)
定义	$P(AB) = P(A) \cdot P(B)$	$P(AB) = 0 \text{ } (AB = \emptyset)$
直觉	B 发生不影响 A 发生的概率	A 发生则 B 一定不发生
$P(B \mid A) \text{ } (P(A) > 0)$	$P(B \mid A) = P(B)$ (知道 A 无额外信息)	$P(B \mid A) = 0$ (A 发生则 B 不可能)
能否同时成立	仅当 $P(A) = 0$ 或 $P(B) = 0$ 时两者可以同时成立	若 $P(A) > 0$ 且 $P(B) > 0$ ，互斥则不独立

	独立 (Independence)	互斥 (Mutually Exclusive)
典型例子	两次独立投硬币，第一次正面 A ， 第二次正面 B	同一次掷骰子， $A = \{1, 2\}$ ， $B = \{3, 4\}$

关键口诀：- 独立 = “信息无关”， $P(AB) = P(A)P(B)$ ；- 互斥 = “不能共存”， $P(AB) = 0$ ；- 若 $P(A), P(B) > 0$ ，两者不能同时成立（互斥事件知道 A 发生了， B 一定不发生，所以 A 对 B 有影响，不独立）。

三个以上事件的独立性： $A_1, \dots, A_n$ 相互独立，要求对所有子集 $\{i_1, \dots, i_k\} \subseteq \{1, \dots, n\}$ ：

$$P(A_{i_1} \cdots A_{i_k}) = P(A_{i_1}) \cdots P(A_{i_k}).$$

两两独立不蕴含相互独立（Bernstein 反例）。

六、演示题：医学检验的贝叶斯反差

题目

某疾病在人群中的患病率（先验）为 1%。某检测方法的灵敏度（敏感性）为 95%（即患病者检测阳性的概率），特异度为 90%（即未患病者检测阴性的概率）。一个随机选取的人检测结果为阳性，求此人真的患病的概率。

直觉首先说”灵敏度 95%，应该是 95% 的概率患病”。让我用贝叶斯公式仔细算一下。

设置符号：- D ：患病； $\overline{D}$ ：未患病。先验： $P(D) = 0.01$ ， $P(\overline{D}) = 0.99$ 。- $+$ ：检测阳性。灵敏度： $P(+ | D) = 0.95$ ；特异度： $P(- | \overline{D}) = 0.90$ ，所以假阳性率 $P(+ | \overline{D}) = 1 - 0.90 = 0.10$ 。

步骤 1：全概率公式算 $P(+)$

$$\begin{aligned} P(+) &= P(D) \cdot P(+ | D) + P(\overline{D}) \cdot P(+ | \overline{D}) \\ &= 0.01 \times 0.95 + 0.99 \times 0.10 = 0.0095 + 0.099 = 0.1085. \end{aligned}$$

步骤 2：贝叶斯公式算 $P(D | +)$

$$P(D | +) = \frac{P(D) \cdot P(+ | D)}{P(+)} = \frac{0.01 \times 0.95}{0.1085} = \frac{0.0095}{0.1085} \approx 0.0876 \approx 8.7\%.$$

反直觉的来源：在 1000 人中，患病者约 10 人，未患病者约 990 人。- 10 个患病者中，检出阳性约 $10 \times 0.95 = 9.5$ 人（真阳性）；- 990 个未患病者中，检出阳性约 $990 \times 0.10 = 99$ 人（假阳性）；- 总阳性约 $9.5 + 99 = 108.5$ 人，其中真正患病的约 9.5 人；- 比例 = $9.5/108.5 \approx 8.7\%$ 。

关键洞察：先验患病率只有 1%，意味着 1000 人里只有 10 个患者；而 990 个健康人中有 10% 被误判，产生 99 个假阳性，远超真阳性。因此阳性中的大多数都是健康人。

后验概率只有 8.7%，这就是“贝叶斯反差”——低先验概率下，即使高灵敏度检测，阳性预测值也很低。要提高阳性预测值，需要提高先验（只对高风险人群检测），或提高特异度（减少假阳性）。

七、思考路标

1. 见“已知某事件发生，求另一事件概率” → 条件概率 $P(B | A) = P(AB)/P(A)$ 。先找联合概率 $P(AB)$ ，再除以条件 $P(A)$ 。
2. 见“多个来源，某结果的总概率” → 全概率公式。先找划分（各“来源” B_i ），再对 $P(B_i) \cdot P(A | B_i)$ 求和。
检验：各 $P(B_i)$ 加起来等于 1。
3. 见“已知结果，问哪个来源” → 贝叶斯公式。分子是全概率某一项，分母是全概率公式的总和。
4. 独立性的验证 → 直接检查 $P(AB) = P(A)P(B)$ ，或等价地 $P(B | A) = P(B)$ ($P(A) > 0$)。不要靠“直觉”判断独立，要计算。
5. 独立 vs 互斥的区分 → 若 $P(A), P(B) > 0$ ，互斥则不独立 ($P(AB) = 0 \neq P(A)P(B)$)；独立则不互斥 ($P(AB) = P(A)P(B) > 0$)。两个正概率事件不可能既独立又互斥。
6. 低先验 + 高灵敏度 $\neq$ 高后验 → 贝叶斯反差的核心：后验概率受先验概率影响极大。先验很低（如稀有疾病），即使检测很准，假阳性数量也可能远超真阳性。
7. 链式公式用于序贯事件 → 连续 n 步无放回抽取、序贯决策树等问题，用 $P(A_1 A_2 \cdots A_n) = P(A_1) \prod_{k=2}^n P(A_k | A_1 \cdots A_{k-1})$ 。
8. 全概率公式的划分选择 → 选择最自然的划分——让 $P(A | B_i)$ 容易计算。通常划分是“导致 A 的各种原因”或“各状态”。

八、典型应用 3 例

例 1：三门问题 (Monty Hall)

题目：三扇门，一扇后有汽车，两扇后是山羊。你选了 1 号门，主持人打开了 3 号门（后面是山羊）。你是否应该换选 2 号门？

分析：

设 A_i = “汽车在 i 号门后”，先验 $P(A_i) = 1/3$ ($i = 1, 2, 3$)。

设 H_3 = “主持人打开 3 号门”。主持人的策略：若汽车在你选的 1 号门，他随机打开 2 或 3 号；若汽车在 2 号门，他必须打开 3 号；若汽车在 3 号门，他必须打开 2 号。

$$P(H_3 | A_1) = \frac{1}{2}, \quad P(H_3 | A_2) = 1, \quad P(H_3 | A_3) = 0.$$

全概率: $P(H_3) = \frac{1}{3} \cdot \frac{1}{2} + \frac{1}{3} \cdot 1 + \frac{1}{3} \cdot 0 = \frac{1}{2}$ 。

贝叶斯更新后:

$$P(A_1 | H_3) = \frac{\frac{1}{3} \cdot \frac{1}{2}}{\frac{1}{2}} = \frac{1}{3}, \quad P(A_2 | H_3) = \frac{\frac{1}{3} \cdot 1}{\frac{1}{2}} = \frac{2}{3}.$$

结论: 换门的获胜概率 $2/3 > 1/3$, 应该换。先验 $1/3$ 经贝叶斯更新变成后验 $2/3$ 。

例 2: 无放回抽样中的条件概率

题目: 袋中有 3 个红球、2 个白球, 不放回地依次取两个球, 求第二个是红球的概率。

思路: 设 R_1 = 第一个是红, W_1 = 第一个是白, R_2 = 第二个是红。用全概率:

$$P(R_2) = P(R_1)P(R_2 | R_1) + P(W_1)P(R_2 | W_1) = \frac{3}{5} \cdot \frac{2}{4} + \frac{2}{5} \cdot \frac{3}{4} = \frac{6}{20} + \frac{6}{20} = \frac{12}{20} = \frac{3}{5}.$$

有趣: $P(R_2) = 3/5 = P(R_1)$, 即第二个是红球的边际概率等于第一个是红球的概率——抽球顺序不影响每次抽到的边际概率 (对称性)。

例 3: 独立性判断

题目: 掷两枚骰子, A = "第一枚出现偶数", B = "两枚之和为 7", 判断 A 与 B 是否独立。

分析:

$$P(A) = 3/6 = 1/2; \quad B = \{(1, 6), (2, 5), (3, 4), (4, 3), (5, 2), (6, 1)\}, \quad P(B) = 6/36 = 1/6.$$

$$AB = \text{第一枚偶数且和为 7: } (2, 5), (4, 3), (6, 1), \text{ 共 3 个, } P(AB) = 3/36 = 1/12.$$

$$\text{验证: } P(A)P(B) = \frac{1}{2} \cdot \frac{1}{6} = \frac{1}{12} = P(AB).$$

结论: A 与 B 独立。“第一枚是偶数”不影响“两枚和为 7”的概率。

九、自测题

第 1 题：一个盒子里有 4 张红卡和 2 张蓝卡，不放回取两张。已知第一张是红的，求第二张也是红的条件概率。

提示： $P(R_2 | R_1) = P(R_1 R_2) / P(R_1) = (4/6 \cdot 3/5) / (4/6) = 3/5$ 。

第 2 题：甲工厂生产了 60% 的产品，乙工厂生产了 40%。甲的次品率 2%，乙的次品率 3%。随机取一件产品是次品，求来自乙工厂的概率。

提示：全概率 $P(\text{次品}) = 0.6 \times 0.02 + 0.4 \times 0.03 = 0.012 + 0.012 = 0.024$ ；贝叶斯 $P(\text{乙} | \text{次品}) = 0.012 / 0.024 = 0.5$ 。

第 3 题：某病毒性疾病的感染率（先验） $P(I) = 0.001$ ，核酸检测灵敏度 $P(+ | I) = 0.99$ ，特异度对应假阳性率 $P(+ | \bar{I}) = 0.01$ 。求 $P(I | +)$ 。

提示：全概率 $P(+)=0.001 \times 0.99 + 0.999 \times 0.01 \approx 0.01098$ ；后验 $P(I | +) \approx 0.000990 / 0.01098 \approx 9.0\%$ 。

第 4 题：掷硬币 3 次，设 A = “第一次正面”， B = “三次中恰好一次正面”，判断 A 与 B 是否独立。

提示： $P(A) = 1/2$ ， $P(B) = \binom{3}{1}(1/2)^3 = 3/8$ ， $P(AB) = P(\text{第一次正面且后两次均反面}) = (1/2)^3 = 1/8$ 。检验 $P(A)P(B) = (1/2)(3/8) = 3/16 \neq 1/8$ ，故不独立。

第 5 题：用链式公式计算：袋中 5 个白球 3 个黑球，无放回连取 3 个，求前两个白球第三个黑球的概率。

提示： $P(W_1 W_2 B_3) = P(W_1)P(W_2 | W_1)P(B_3 | W_1 W_2) = \frac{5}{8} \cdot \frac{4}{7} \cdot \frac{3}{6} = \frac{60}{336} = \frac{5}{28}$ 。

期望 / 方差 / 矩

一例速记： $X \sim B(n, p)$ ，用“分解为 Bernoulli 之和”的技巧，期望 $E(X) = np$ ，方差 $\text{Var}(X) = np(1-p)$ 。若直接用定义展开 $E(X) = \sum_{k=0}^n k \binom{n}{k} p^k (1-p)^{n-k}$ ，需要用到组合恒等式；若先拆 $X = X_1 + \cdots + X_n$ ($X_i \sim B(1, p)$)，则 $E(X) = nE(X_1) = np$ ，方差（独立时可加） $\text{Var}(X) = n\text{Var}(X_1) = np(1-p)$ ，一行搞定。拆分 + 线性性是期望计算的核武器。

一、为什么需要期望和矩

随机变量 X 的概率分布 (PMF 或 PDF) 包含了它的“全部信息”，但这个信息往往过于详细——我们有时只需要若干关键数字来刻画分布的“重心”、“散布程度”和“形态”。

矩 (moments) 正是把分布压缩为几个数字的标准工具：- 一阶矩 (期望) $E(X)$ ：分布的“重心”，衡量平均水平；- 二阶矩 $E(X^2)$ 和方差 $\text{Var}(X)$ ：衡量散布；- 三阶中心矩：衡量偏斜 (skewness)；- 四阶中心矩：衡量尖峰程度 (kurtosis)。

矩母函数 (Moment Generating Function, MGF) 则把所有矩都打包进一个函数，是强大的分析工具。

本篇系统整理期望、方差、协方差、相关系数和 MGF，并用二项分布作演示题对比“定义法”和“MGF 法”。

二、期望

2.1 定义

离散随机变量：设 X 的 PMF 为 $P(X = x_i) = p_i$ ($i = 1, 2, \dots$)，若 $\sum_i |x_i| p_i < \infty$ ，定义期望

$$E(X) = \sum_i x_i p_i.$$

连续随机变量：设 X 的 PDF 为 $f(x)$ ，若 $\int_{-\infty}^{+\infty} |x| f(x) dx < \infty$ ，定义期望

$$E(X) = \int_{-\infty}^{+\infty} x f(x) dx.$$

注意绝对可积条件：若 $\sum_i |x_i| p_i = +\infty$ (如 Cauchy 分布)，期望不存在。

2.2 期望的线性性

这是期望最重要的性质，对任意随机变量 (不需要独立)：

$$E(aX + bY + c) = aE(X) + bE(Y) + c \quad (a, b, c \in \mathbb{R}).$$

推广：对 n 个随机变量 (无论是否独立)：

$$E\left(\sum_{i=1}^n a_i X_i + c\right) = \sum_{i=1}^n a_i E(X_i) + c.$$

非线性函数的期望：一般 $E[g(X)] \neq g(E[X])$ 。例如 $E(X^2) \neq (E[X])^2$ (二者之差正是方差)。正确写法：

$$E[g(X)] = \sum_i g(x_i)p_i \quad (\text{离散}), \quad E[g(X)] = \int_{-\infty}^{+\infty} g(x)f(x) dx \quad (\text{连续}).$$

这被称为无意识统计学家法则 (Law of the Unconscious Statistician, LOTUS)。

2.3 乘积的期望 (独立时)

若 X 与 Y 独立, 则:

$$E(XY) = E(X) \cdot E(Y).$$

反向不成立: $E(XY) = E(X)E(Y)$ 不蕴含独立 (只蕴含”不相关”, 弱于独立)。

三、方差

3.1 定义与计算公式

定义:

$$\text{Var}(X) = E[(X - E[X])^2].$$

展开计算公式 (最常用):

$$\text{Var}(X) = E(X^2) - (E[X])^2.$$

推导:

$$E[(X - \mu)^2] = E[X^2 - 2\mu X + \mu^2] = E(X^2) - 2\mu E(X) + \mu^2 = E(X^2) - \mu^2.$$

其中 $\mu = E(X)$ 。

标准差: $\text{SD}(X) = \sqrt{\text{Var}(X)}$, 与 X 同单位, 常用 σ 表示。

3.2 方差的性质

性质	公式	条件
常数的方差	$\text{Var}(c) = 0$	c 为常数
线性变换	$\text{Var}(aX + b) = a^2\text{Var}(X)$	加常数不影响散布; 乘系数平方放缩
加性 (独立)	$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$	X, Y 独立
一般加性	$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$	一般情形

注意：方差不具有线性性 ($\text{Var}(X + Y) \neq \text{Var}(X) + \text{Var}(Y)$ 一般情形)，这与期望不同。

四、协方差与相关系数

4.1 协方差

定义：

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])] = E(XY) - E(X)E(Y).$$

性质：

性质	公式
对称性	$\text{Cov}(X, Y) = \text{Cov}(Y, X)$
自协方差	$\text{Cov}(X, X) = \text{Var}(X)$
双线性	$\text{Cov}(aX + bY, Z) = a \text{Cov}(X, Z) + b \text{Cov}(Y, Z)$
独立则不相关	$X \perp Y \Rightarrow \text{Cov}(X, Y) = 0$

注意： $\text{Cov}(X, Y) = 0$ （不相关）不蕴含独立（正态分布的例外：不相关 $\Rightarrow$ 独立）。

4.2 相关系数

定义：

$$\rho_{XY} = \text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)} \cdot \sqrt{\text{Var}(Y)}} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}.$$

性质：

- 1. $-1 \leq \rho \leq 1$ (Cauchy-Schwarz 不等式保证)；
- 2. $\rho = 1$ ：完全正线性相关 ($Y = aX + b, a > 0$)；
- 3. $\rho = -1$ ：完全负线性相关 ($Y = aX + b, a < 0$)；
- 4. $\rho = 0$ ：线性不相关（但可能存在非线性关系）。

相关系数衡量线性相关程度，不反映非线性关系。

五、矩母函数 (MGF)

5.1 定义

定义：若期望 $E(e^{tX})$ 在 $t = 0$ 的某邻域内有限，称

$$M_X(t) = E(e^{tX})$$

为随机变量 X 的矩母函数 (MGF)。

离散情形： $M_X(t) = \sum_i e^{tx_i} p_i$;

连续情形： $M_X(t) = \int_{-\infty}^{+\infty} e^{tx} f(x) dx$ 。

5.2 为什么叫“矩母函数”

将 e^{tX} 展开为 Taylor 级数 (在 $t = 0$ 处):

$$e^{tX} = \sum_{n=0}^{\infty} \frac{(tX)^n}{n!} = 1 + tX + \frac{t^2 X^2}{2!} + \dots$$

取期望:

$$M_X(t) = E(e^{tX}) = \sum_{n=0}^{\infty} \frac{t^n}{n!} E(X^n).$$

对 t 求 n 次导，令 $t = 0$ ，得第 n 阶矩:

$$M_X^{(n)}(0) = E(X^n).$$

特别地， $M'_X(0) = E(X)$ ， $M''_X(0) = E(X^2)$ ，从而 $\text{Var}(X) = M''_X(0) - [M'_X(0)]^2$ 。

5.3 MGF 的重要性质

性质	公式	应用
矩的提取	$E(X^n) = M_X^{(n)}(0)$	快速计算各阶矩
线性变换	$M_{aX+b}(t) = e^{bt} M_X(at)$	标准化等变换
独立和	$M_{X+Y}(t) = M_X(t) M_Y(t)$ (X, Y 独立)	和分布的推导
唯一性	MGF (若存在) 唯一确定分布	识别分布类型

六、演示题：二项分布 $B(n, p)$ 的期望与方差——两种方法

题目

设 $X \sim B(n, p)$, PMF 为 $P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$ ($k = 0, 1, \dots, n$)。用两种方法求 $E(X)$ 和 $\text{Var}(X)$ 。

方法一：分解法（拆为 Bernoulli 之和）

直接对 $\sum_{k=0}^n k \binom{n}{k} p^k q^{n-k}$ 求和需要用到组合恒等式。有更聪明的做法：先观察 $B(n, p)$ 的“起源”。

$X \sim B(n, p)$ 可以理解为 n 次独立 Bernoulli 试验的成功次数，即 $X = X_1 + X_2 + \dots + X_n$ ，其中 $X_i \sim B(1, p)$ （每次试验是否成功，成功为 1，失败为 0）， X_i 相互独立。

计算 $E(X_i)$: $E(X_i) = 1 \cdot p + 0 \cdot (1-p) = p$ 。

计算 $E(X)$: 由期望的线性性（不需独立）:

$$E(X) = E(X_1 + \dots + X_n) = \sum_{i=1}^n E(X_i) = np.$$

计算 $\text{Var}(X_i)$: $E(X_i^2) = 1^2 \cdot p + 0^2 \cdot (1-p) = p$ ，所以

$$\text{Var}(X_i) = E(X_i^2) - [E(X_i)]^2 = p - p^2 = p(1-p).$$

计算 $\text{Var}(X)$: X_i 相互独立，方差可加:

$$\text{Var}(X) = \sum_{i=1}^n \text{Var}(X_i) = n \cdot p(1-p).$$

整个推导只用了“期望线性性”和“独立时方差可加”，没有繁琐的组合运算。

方法二：MGF 法

先求 $X_i \sim B(1, p)$ 的 MGF:

$$M_{X_i}(t) = E(e^{tX_i}) = e^{t \cdot 0}(1-p) + e^{t \cdot 1}p = (1-p) + pe^t = q + pe^t,$$

其中 $q = 1-p$ 。

因 $X = X_1 + \dots + X_n$ 且各 X_i 独立，MGF 相乘:

$$M_X(t) = \prod_{i=1}^n M_{X_i}(t) = (q + pe^t)^n.$$

提取期望：对 t 求一阶导:

$$M'_X(t) = n(q + pe^t)^{n-1} \cdot pe^t.$$

令 $t = 0$:

$$E(X) = M'_X(0) = n(q + p)^{n-1} \cdot p = n \cdot 1 \cdot p = np. \quad \checkmark$$

提取二阶矩: 对 t 求二阶导:

$$M''_X(t) = n(n-1)(q + pe^t)^{n-2}(pe^t)^2 + n(q + pe^t)^{n-1}pe^t.$$

令 $t = 0$:

$$E(X^2) = M''_X(0) = n(n-1)p^2 + np.$$

计算方差:

$$\begin{aligned} \text{Var}(X) &= E(X^2) - [E(X)]^2 = n(n-1)p^2 + np - n^2p^2 \\ &= n^2p^2 - np^2 + np - n^2p^2 = np - np^2 = np(1-p). \quad \checkmark \end{aligned}$$

两种方法结果一致: $E(X) = np$, $\text{Var}(X) = np(1-p)$ 。

方法比较: 分解法更直观简洁; MGF 法更具通用性 (对不能轻易分解的分布也适用), 也可以一次性提取任意阶矩。

七、思考路标

1. 计算期望的首选策略 → 先看能否用线性性拆分 ($X = X_1 + \cdots + X_n$), 再看有无 MGF 可用, 最后才直接用定义硬算。
2. $E[g(X)]$ 的计算 → 不要“先求分布再求期望”, 用 LOTUS 直接 $E[g(X)] = \int g(x)f(x)dx$ (连续) 或 $\sum g(x_i)p_i$ (离散)。
3. 方差与期望的关系 → 计算方差优先用 $\text{Var}(X) = E(X^2) - (EX)^2$, 比直接展开 $(X - \mu)^2$ 取期望更简洁。关键是先求 $E(X)$ 和 $E(X^2)$, 两步分开处理。
4. 方差不具线性性 → 若 X, Y 不独立, $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$ 。若题目没说独立, 不能直接相加。
5. 协方差 = 0 不代表独立 → 不相关只是弱于独立的条件。若分布是多元正态, 不相关才等价于独立。其他情形需要独立性的完整验证。
6. MGF 不存在的情形 → 重尾分布 (如 Cauchy、 t_1) 的 MGF 不存在, 这时用特征函数 $\phi(t) = E(e^{itX})$ (复值, i 虚数单位), 总是存在。
7. MGF 唯一确定分布 → 若两个分布有相同 MGF, 则它们是同一分布。这常用于: 已知分布的 MGF 形式, 将待求分布的 MGF 化成已知形式, 从而识别分布类型。
8. 标准化随机变量 → 令 $Z = (X - \mu)/\sigma$, 则 $E(Z) = 0$, $\text{Var}(Z) = 1$ 。标准化不改变分布形状, 但把均值移到 0, 把标准差化为 1, 便于比较不同量纲的随机变量。

八、典型应用 3 例

例 1: 几何分布的期望 (无穷级数法)

题目: $X \sim \text{Geom}(p)$, PMF 为 $P(X = k) = (1 - p)^{k-1}p$ ($k = 1, 2, \dots$)。求 $E(X)$ 。

思路:

$$E(X) = \sum_{k=1}^{\infty} k(1-p)^{k-1}p = p \sum_{k=1}^{\infty} kq^{k-1}, \quad q = 1 - p.$$

利用公式 $\sum_{k=1}^{\infty} kq^{k-1} = \frac{1}{(1-q)^2} = \frac{1}{p^2}$ (对几何级数 $\sum q^k$ 求导):

$$E(X) = p \cdot \frac{1}{p^2} = \frac{1}{p}.$$

直觉: 平均需要 $1/p$ 次试验才能成功一次 (成功概率 p), 符合直觉。

例 2: Poisson 分布的方差

题目: $X \sim \text{Poisson}(\lambda)$, PMF 为 $P(X = k) = e^{-\lambda}\lambda^k/k!$ ($k = 0, 1, \dots$)。求 $E(X)$ 和 $\text{Var}(X)$ 。

思路 (MGF 法):

$$M_X(t) = E(e^{tX}) = \sum_{k=0}^{\infty} e^{tk} \cdot \frac{e^{-\lambda}\lambda^k}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{(\lambda e^t)^k}{k!} = e^{-\lambda} e^{\lambda e^t} = e^{\lambda(e^t-1)}.$$

一阶导: $M'_X(t) = \lambda e^t \cdot e^{\lambda(e^t-1)}$, 令 $t = 0$: $E(X) = \lambda$.

二阶导: $M''_X(t) = (\lambda e^t)^2 e^{\lambda(e^t-1)} + \lambda e^t e^{\lambda(e^t-1)}$, 令 $t = 0$: $E(X^2) = \lambda^2 + \lambda$.

$$\text{Var}(X) = E(X^2) - (EX)^2 = (\lambda^2 + \lambda) - \lambda^2 = \lambda.$$

结论: Poisson 分布的期望和方差相等, 都等于 λ ——这是识别 Poisson 分布的特征性质。

例 3: 线性组合的方差——用协方差

题目: 已知 $E(X) = 2$, $E(Y) = 3$, $\text{Var}(X) = 4$, $\text{Var}(Y) = 9$, $\text{Cov}(X, Y) = -2$ 。求 $\text{Var}(2X - Y + 1)$ 。

思路:

$$\begin{aligned}\text{Var}(2X - Y + 1) &= \text{Var}(2X - Y) = 4\text{Var}(X) + \text{Var}(Y) - 2 \cdot 2 \cdot \text{Cov}(X, Y) \\ &= 4 \times 4 + 9 - 4 \times (-2) = 16 + 9 + 8 = 33.\end{aligned}$$

注意：加常数 +1 不影响方差； $\text{Var}(aX + bY) = a^2\text{Var}(X) + b^2\text{Var}(Y) + 2ab\text{Cov}(X, Y)$ ，系数 $a = 2, b = -1$ 。

九、自测题

第 1 题：设 X 取 $\{1, 2, 3\}$ ，概率分别为 $1/2, 1/3, 1/6$ ，求 $E(X)$ 和 $\text{Var}(X)$ 。

提示： $E(X) = 1 \cdot \frac{1}{2} + 2 \cdot \frac{1}{3} + 3 \cdot \frac{1}{6} = \frac{1}{2} + \frac{2}{3} + \frac{1}{2} = \frac{5}{3}$ ； $E(X^2) = 1 \cdot \frac{1}{2} + 4 \cdot \frac{1}{3} + 9 \cdot \frac{1}{6} = \frac{1}{2} + \frac{4}{3} + \frac{3}{2} = \frac{10}{3}$ ； $\text{Var}(X) = \frac{10}{3} - \left(\frac{5}{3}\right)^2 = \frac{10}{3} - \frac{25}{9} = \frac{5}{9}$ 。

第 2 题： $X \sim U(0, 1)$ （均匀分布）， $f(x) = 1$ ($0 < x < 1$)。求 $E(X)$ ， $E(X^2)$ ， $\text{Var}(X)$ 。

提示： $E(X) = \int_0^1 x dx = 1/2$ ； $E(X^2) = \int_0^1 x^2 dx = 1/3$ ； $\text{Var}(X) = 1/3 - 1/4 = 1/12$ 。

第 3 题：设 $X_1, \dots, X_{100}$ 独立同分布， $E(X_i) = 5$ ， $\text{Var}(X_i) = 9$ ，令 $\bar{X} = \frac{1}{100} \sum_{i=1}^{100} X_i$ ，求 $E(\bar{X})$ 和 $\text{Var}(\bar{X})$ 。

提示： $E(\bar{X}) = 5$ （线性性）； $\text{Var}(\bar{X}) = \frac{1}{100^2} \sum \text{Var}(X_i) = \frac{100 \times 9}{100^2} = \frac{9}{100} = 0.09$ 。

第 4 题：利用 MGF 证明：若 $X \sim N(\mu, \sigma^2)$ ，其 MGF 为 $M_X(t) = e^{\mu t + \sigma^2 t^2/2}$ ，则 $E(X) = \mu$ ， $\text{Var}(X) = \sigma^2$ 。

提示： $M'_X(t) = (\mu + \sigma^2 t)e^{\mu t + \sigma^2 t^2/2}$ ， $t = 0$ 时 $= \mu$ ； $M''_X(t)$ 在 $t = 0$ 时等于 $\mu^2 + \sigma^2$ ； $\text{Var} = (\mu^2 + \sigma^2) - \mu^2 = \sigma^2$ 。

第 5 题：设 X, Y 相关系数 $\rho = -0.8$ ， $\text{Var}(X) = 4$ ， $\text{Var}(Y) = 9$ ，求 $\text{Cov}(X, Y)$ 和 $\text{Var}(X + Y)$ 。

提示： $\text{Cov}(X, Y) = \rho\sigma_X\sigma_Y = (-0.8)(2)(3) = -4.8$ ； $\text{Var}(X + Y) = 4 + 9 + 2(-4.8) = 13 - 9.6 = 3.4$ 。

常见分布速查表

一例速记：公交车平均每 10 分钟一班，你刚错过一班，等待时间 T 服从什么分布？答：指数分布 $T \sim \text{Exp}(1/10)$ ， $E(T) = 10$ 分钟。关键识别符：无记忆性——已经等了 5 分钟，下一班到达的期望等待时间还是 10 分钟。 $P(T > s + t \mid T > s) = P(T > t)$ ，等待时间“不记得”你已经等了多久。

一、分布的分类框架

随机变量按取值类型分为：

- 离散：取可数个值（有限或可数无穷）。用 PMF $P(X = k) = p_k$ 描述。
- 连续：取不可数个值（区间）。用 PDF $f(x)$ 描述， $P(a < X \leq b) = \int_a^b f(x) dx$ 。

选择分布时的思维路径：

场景特征	候选分布
单次成功/失败	Bernoulli(p)
n 次独立试验的成功次数	二项 $B(n, p)$
单位时间/空间内的稀有事件计数	Poisson(λ)
首次成功前的试验次数	几何 $\text{Geom}(p)$
有限总体中不放回抽样	超几何
等待第 r 次成功的试验次数	负二项 $\text{NB}(r, p)$
区间上均匀随机	均匀 $U(a, b)$
等待时间、寿命（无记忆性）	指数 $\text{Exp}(\lambda)$
自然界大量独立微小影响叠加	正态 $N(\mu, \sigma^2)$
非负、右偏、等待 k 次事件	Gamma(α, β)
取值 $[0, 1]$ 的比例	Beta(α, β)
正态样本方差的分布	χ_n^2
正态总体均值的 t 检验统计量	t_n
两个样本方差之比	$F_{m,n}$

二、离散分布速查表

2.1 Bernoulli 分布

$$X \sim B(1, p), \quad P(X = 1) = p, \quad P(X = 0) = 1 - p = q.$$

项目	值
PMF	$P(X = k) = p^k q^{1-k}, \quad k \in \{0, 1\}$
$E(X)$	p
$\text{Var}(X)$	$p(1 - p) = pq$
MGF	$q + pe^t$
典型场景	单次抛硬币、产品是否合格

2.2 二项分布

$$X \sim B(n, p), \quad P(X = k) = \binom{n}{k} p^k q^{n-k}, \quad k = 0, 1, \dots, n.$$

项目	值
PMF	$\binom{n}{k} p^k q^{n-k}$
$E(X)$	np
$\text{Var}(X)$	npq
MGF	$(q + pe^t)^n$
典型场景	n 次独立成功/失败试验的总成功次数；抽检批次合格率

与 Poisson 的关系： n 很大、 p 很小、 $\lambda = np$ 保持适中时， $B(n, p) \approx \text{Poisson}(\lambda)$ 。

2.3 Poisson 分布

$$X \sim \text{Poisson}(\lambda), \quad P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, 2, \dots$$

项目	值
PMF	$e^{-\lambda} \lambda^k / k!$
$E(X)$	λ
$\text{Var}(X)$	λ （期望 = 方差）
MGF	$e^{\lambda(e^t - 1)}$
典型场景	单位时间呼叫次数、每平方米缺陷数、放射性粒子计数

可加性：若 $X_1 \sim \text{Poisson}(\lambda_1)$ ， $X_2 \sim \text{Poisson}(\lambda_2)$ 独立，则 $X_1 + X_2 \sim \text{Poisson}(\lambda_1 + \lambda_2)$ 。

2.4 几何分布

首次成功前试验次数（第一次成功发生在第 k 次）：

$$X \sim \text{Geom}(p), \quad P(X = k) = (1 - p)^{k-1} p, \quad k = 1, 2, \dots$$

项目	值
PMF	$(1 - p)^{k-1} p$

项目	值
$E(X)$	$1/p$
$\text{Var}(X)$	$(1-p)/p^2 = q/p^2$
MGF	$pe^t/(1-qe^t), t < -\ln q$
典型场景	首次成功前的试验次数；离散无记忆性等待

无记忆性（离散版）： $P(X > m + n \mid X > m) = P(X > n)$ ，几何分布是唯一的离散无记忆分布。

2.5 超几何分布

N 件物品中有 K 件“特殊”，不放回取 n 件，其中特殊品数 X ：

$$P(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}, \quad \max(0, n + K - N) \leq k \leq \min(n, K).$$

项目	值
$E(X)$	nK/N
$\text{Var}(X)$	$n \frac{K}{N} \frac{N-K}{N} \frac{N-n}{N-1}$
典型场景	不放回抽样中的成功次数；有限总体质量检验

与二项的关系： $N \rightarrow \infty$ 且 $K/N \rightarrow p$ 时，超几何 $\rightarrow B(n, p)$ （有放回近似无放回）。

2.6 负二项分布

等待第 r 次成功时，已经历的试验总次数 X ：

$$P(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad k = r, r+1, \dots$$

项目	值
$E(X)$	r/p
$\text{Var}(X)$	rq/p^2
MGF	$\left(\frac{pe^t}{1-qe^t}\right)^r, t < -\ln q$
典型场景	等待 r 次成功的总试验次数；质量控制中第 r 件次品出现前的产品数

注意： $r = 1$ 时退化为几何分布；也有以“失败次数”为 X 的等价定义，PMF 形式有差异。

三、连续分布速查表

3.1 均匀分布

$$X \sim U(a, b), \quad f(x) = \frac{1}{b-a}, \quad a < x < b.$$

项目	值
PDF	$1/(b-a)$
$E(X)$	$(a+b)/2$
$\text{Var}(X)$	$(b-a)^2/12$
MGF	$(e^{tb} - e^{ta})/[t(b-a)], \quad t \neq 0$
典型场景	区间上的等可能随机点；几何概型的“均匀”假设

3.2 指数分布

$$X \sim \text{Exp}(\lambda), \quad f(x) = \lambda e^{-\lambda x}, \quad x \geq 0.$$

项目	值
PDF	$\lambda e^{-\lambda x}$
CDF	$1 - e^{-\lambda x}$
$E(X)$	$1/\lambda$
$\text{Var}(X)$	$1/\lambda^2$
MGF	$\lambda/(\lambda - t), \quad t < \lambda$
典型场景	等待时间（Poisson 过程相邻事件间隔）；无老化元件寿命

无记忆性（连续版）： $P(X > s + t \mid X > s) = P(X > t), \forall s, t \geq 0$ 。指数分布是唯一的连续无记忆分布。

与 Poisson 过程的联系：若事件按速率 λ 的 Poisson 过程到达，则相邻事件间隔 $\sim \text{Exp}(\lambda)$ 。

3.3 正态分布

$$X \sim N(\mu, \sigma^2), \quad f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

项目	值
PDF	$\frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$
$E(X)$	μ
$\text{Var}(X)$	σ^2
MGF	$e^{\mu t + \sigma^2 t^2 / 2}$
典型场景	CLT 极限分布；测量误差；自然界中大量微小随机影响的叠加

标准化： $Z = (X - \mu)/\sigma \sim N(0, 1)$ ，查标准正态表。

线性组合：若 $X_i \sim N(\mu_i, \sigma_i^2)$ 独立，则 $\sum a_i X_i \sim N(\sum a_i \mu_i, \sum a_i^2 \sigma_i^2)$ 。

经验法则 **(68-95-99.7)**： $P(\mu - \sigma < X < \mu + \sigma) \approx 68\%$ ， $P(\mu - 2\sigma < X < \mu + 2\sigma) \approx 95\%$ ， $P(\mu - 3\sigma < X < \mu + 3\sigma) \approx 99.7\%$ 。

3.4 Gamma 分布

$$X \sim \Gamma(\alpha, \beta), \quad f(x) = \frac{x^{\alpha-1} e^{-x/\beta}}{\Gamma(\alpha) \beta^\alpha}, \quad x > 0.$$

($\alpha > 0$ 为形状参数， $\beta > 0$ 为尺度参数；也有用率参数 $\theta = 1/\beta$ 的参数化。)

项目	值
$E(X)$	$\alpha\beta$
$\text{Var}(X)$	$\alpha\beta^2$
MGF	$(1 - \beta t)^{-\alpha}, t < 1/\beta$
典型场景	等待 α 次 Poisson 事件的总时间；生存分析；贝叶斯 Poisson 参数的共轭先验

特殊情形： $\Gamma(1, \beta) = \text{Exp}(1/\beta)$ ； $\Gamma(n/2, 2) = \chi_n^2$ （见下）。

可加性：若 $X_i \sim \Gamma(\alpha_i, \beta)$ 独立（同尺度参数），则 $\sum X_i \sim \Gamma(\sum \alpha_i, \beta)$ 。

3.5 Beta 分布

$$X \sim \text{Beta}(\alpha, \beta), \quad f(x) = \frac{x^{\alpha-1} (1-x)^{\beta-1}}{B(\alpha, \beta)}, \quad 0 < x < 1.$$

($B(\alpha, \beta) = \Gamma(\alpha)\Gamma(\beta)/\Gamma(\alpha + \beta)$ 为 Beta 函数。)

项目	值
$E(X)$	$\alpha/(\alpha + \beta)$
$\text{Var}(X)$	$\alpha\beta/[(\alpha + \beta)^2(\alpha + \beta + 1)]$
典型场景	$[0, 1]$ 上的比例；贝叶斯二项分布参数 p 的共轭先验

特殊情形：Beta(1, 1) = $U(0, 1)$ ； $\alpha = \beta$ 时关于 1/2 对称。

3.6 χ^2 分布

设 $Z_1, \dots, Z_n$ i.i.d. $\sim N(0, 1)$ ，则

$$\chi_n^2 = \sum_{i=1}^n Z_i^2 \sim \Gamma(n/2, 2).$$

项目	值
$E(\chi_n^2)$	n
$\text{Var}(\chi_n^2)$	$2n$
典型场景	正态总体样本方差： $(n - 1)S^2/\sigma^2 \sim \chi_{n-1}^2$ ；拟合优度检验

可加性： $\chi_m^2 + \chi_n^2 = \chi_{m+n}^2$ （独立时）。

3.7 t 分布

设 $Z \sim N(0, 1)$ ， $V \sim \chi_n^2$ ，两者独立，则

$$t_n = \frac{Z}{\sqrt{V/n}} \sim t_n.$$

项目	值
$E(t_n)$	0 ($n > 1$)
$\text{Var}(t_n)$	$n/(n - 2)$ ($n > 2$)
典型场景	正态总体均值检验（方差未知）： $T = (\bar{X} - \mu_0)/(S/\sqrt{n}) \sim t_{n-1}$

与正态的关系： $t_n \rightarrow N(0, 1)$ ($n \rightarrow \infty$)； n 小时尾部更重。 t_1 = Cauchy 分布（无期望）。

3.8 F 分布

设 $U \sim \chi_m^2$, $V \sim \chi_n^2$, 两者独立, 则

$$F_{m,n} = \frac{U/m}{V/n} \sim F(m,n).$$

项目	值
$E(F_{m,n})$	$n/(n-2)$ ($n > 2$)
典型场景	两正态总体方差比检验: $F = S_1^2/S_2^2$ 在方差相等时 $\sim F(n_1-1, n_2-1)$; 方差分析 (ANOVA)

倒数关系: 若 $F \sim F(m,n)$, 则 $1/F \sim F(n,m)$ 。

四、分布间的关系图

以下关系是推导统计量分布的基础, 建议熟记:

$$\text{Bernoulli}(p) \xrightarrow{\text{求和}n\text{个独立}} B(n,p) \xrightarrow{n \rightarrow \infty, np=\lambda} \text{Poisson}(\lambda)$$

$$\text{Geom}(p) \xrightarrow{\text{等待第}r\text{次}} \text{NB}(r,p)$$

$$\text{Exp}(\lambda) = \Gamma(1, 1/\lambda) \xrightarrow{\text{求和}n\text{个独立}} \Gamma(n, 1/\lambda)$$

$$N(0,1)^2 \xrightarrow{\text{一个}} \chi_1^2 \xrightarrow{\text{求和}n\text{个独立}} \chi_n^2 = \Gamma(n/2, 2)$$

$$\frac{N(0,1)}{\sqrt{\chi_n^2/n}} = t_n \xrightarrow{n \rightarrow \infty} N(0,1)$$

$$\frac{\chi_m^2/m}{\chi_n^2/n} = F(m,n), \quad t_n^2 = F(1,n)$$

$$\text{Beta}(1,1) = U(0,1), \quad \text{Beta}\left(\frac{n}{2}, \frac{n}{2}\right) \xrightarrow{n \rightarrow \infty} \text{对称} \rightarrow N(0,1) (\text{标准化后})$$

五、演示题：识别“等公交”=指数分布（无记忆性）

题目

公交车平均每 10 分钟一班，按 Poisson 过程到达（即相邻两班到达时间间隔独立且同分布）。设你刚错过一班，等待时间为 T 。1. 写出 T 的分布，求 $E(T)$ 和 $\text{Var}(T)$ ；2. 已知你已经等了 5 分钟，问再等 8 分钟以上（即总等待超过 13 分钟）的概率；3. 对比：如果公交不是 Poisson 过程，而是严格按 10 分钟班次运行（你不知道上次是何时）， T 服从什么分布？

分析步骤如下：

识别分布：Poisson 过程相邻事件间隔服从指数分布，参数 $\lambda = 1/10$ （每分钟平均 0.1 班）。

$$T \sim \text{Exp}(1/10), \quad f(t) = \frac{1}{10}e^{-t/10}, \quad t \geq 0.$$

第 1 问：

$$E(T) = \frac{1}{\lambda} = 10 \text{ 分钟}, \quad \text{Var}(T) = \frac{1}{\lambda^2} = 100 \text{ 分钟}^2.$$

第 2 问（无记忆性）：

$$P(T > 13 \mid T > 5) = P(T > 8) = e^{-8/10} = e^{-0.8} \approx 0.449.$$

关键：已经等了 5 分钟的信息毫无价值——“你已经等了多久”不影响“还要再等多久”的分布。这就是指数分布的无记忆性：

$$P(T > s+t \mid T > s) = \frac{P(T > s+t)}{P(T > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(T > t).$$

第 3 问（严格班次）：若公交严格每 10 分钟一班，你到达时刻在 $[0, 10)$ 上均匀分布（不知道上次班次时刻），等待时间 $T \sim U(0, 10)$ 。此时 $E(T) = 5$ 分钟（比 Poisson 过程少等）且不满足无记忆性。

对比小结：- Poisson 过程（无记忆）→ 指数分布， $E(T) = 10$ 分钟；- 严格班次（均匀到达）→ 均匀分布， $E(T) = 5$ 分钟；- 随机性越大，等待时间越长。

六、思考路标

1. 识别分布的第一步 → 看“样本空间 + 试验结构”：有限次独立试验 → 二项；稀有事件计数 → Poisson；首次成功 → 几何；等待时间/寿命 → 指数；归一化平方和 → χ^2 ；比值 → F ；均值标准化 → t 。
2. 无记忆性是指数分布的充要特征 → 若等待时间满足无记忆性（过去等待时间不影响未来），则该连续分布必为指数分布。见“已经等了 s 时间，还要等多久”的条件概率问题，立刻用无记忆性化简。
3. Poisson 分布的识别标志 → 期望 = 方差（ $E(X) = \text{Var}(X) = \lambda$ ）。若数据显示均值远小于方差，可能是过离散（Negative Binomial），应换模型。

4. χ^2, t, F 的推导链 $\rightarrow$ 先写出统计量的构成（哪些标准正态的平方，哪些独立），再套关系图。
 $t = N(0, 1) / \sqrt{\chi_n^2 / n}$, $F = \chi_m^2 / m \div \chi_n^2 / n$, $t_n^2 = F(1, n)$ 。
5. 贝叶斯共轭先验识别 $\rightarrow$ Beta 是二项似然的共轭先验；Gamma 是 Poisson 似然的共轭先验；正态是正态似然（已知方差）的共轭先验。选共轭先验，后验与先验同族，计算简单。
6. Gamma 分布的两种参数化 $\rightarrow$ 形状-尺度 $(\alpha, \beta, E = \alpha\beta)$ 和形状-率 $(\alpha, \theta = 1/\beta, E = \alpha/\theta)$ 。见 Gamma 分布先确认用的是哪种参数化，以免期望和方差算错。
7. 正态分布的线性封闭性 $\rightarrow$ 正态变量的任意线性组合仍是正态（独立时）。这是它在统计推断中无处不在的根本原因——样本均值是正态， Z 统计量是正态，CLT 的极限是正态。
8. 尾部重轻的直觉 $\rightarrow$ 正态 $\ll t_n$ (n 小) $\ll$ Cauchy ($= t_1$, 无期望)。做区间估计时，样本量小用 t 分布（尾部更重，置信区间更宽），大样本用正态近似。

七、典型应用 3 例

例 1: Poisson 近似二项

题目：某工厂每天生产 10000 件产品，次品率 $p = 0.0003$ 。用 Poisson 近似计算一天内次品超过 5 件的概率。

思路：

$n = 10000$, $p = 0.0003$, $\lambda = np = 3$ 。 $X \sim B(10000, 0.0003) \approx \text{Poisson}(3)$ 。

$$P(X > 5) = 1 - P(X \leq 5) = 1 - \sum_{k=0}^5 \frac{e^{-3} 3^k}{k!}.$$

计算： $P(X \leq 5) = e^{-3}(1 + 3 + 4.5 + 4.5 + 3.375 + 2.025) \approx e^{-3} \times 18.4 \approx 0.9161$ 。

$$P(X > 5) \approx 1 - 0.9161 = 0.0839.$$

条件验证： $n = 10000$ 很大， $p = 0.0003$ 很小， $\lambda = 3$ 适中，满足 Poisson 近似条件。

例 2: 正态分布 + 标准化

题目： $X \sim N(50, 100)$ （均值 50，方差 100，即 $\sigma = 10$ ），求 $P(40 < X < 65)$ 。

思路：

标准化：令 $Z = (X - 50)/10 \sim N(0, 1)$ 。

$$P(40 < X < 65) = P\left(\frac{40-50}{10} < Z < \frac{65-50}{10}\right) = P(-1 < Z < 1.5).$$

查标准正态表: $\Phi(1.5) \approx 0.9332$, $\Phi(-1) = 1 - \Phi(1) \approx 1 - 0.8413 = 0.1587$ 。

$$P(-1 < Z < 1.5) = 0.9332 - 0.1587 = 0.7745.$$

例 3: 用 χ^2 和 t 分布推导置信区间

题目: $X_1, \dots, X_n$ 独立同分布 $\sim N(\mu, \sigma^2)$ (σ^2 未知), 构造 μ 的 95% 置信区间。

思路:

已知 $\bar{X} \sim N(\mu, \sigma^2/n)$ 且 $(n-1)S^2/\sigma^2 \sim \chi_{n-1}^2$, 两者独立。

统计量:

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} = \frac{(\bar{X} - \mu)/(\sigma/\sqrt{n})}{\sqrt{(n-1)S^2/[\sigma^2(n-1)]}} = \frac{N(0,1)}{\sqrt{\chi_{n-1}^2/(n-1)}} \sim t_{n-1}.$$

由 t_{n-1} 分布的分位数 $t_{\alpha/2, n-1}$ ($\alpha = 0.05$):

$$P(-t_{0.025, n-1} \leq T \leq t_{0.025, n-1}) = 0.95.$$

解出 μ : 置信区间为 $\bar{X} \pm t_{0.025, n-1} \cdot S/\sqrt{n}$ 。

关系链: 正态假设 $\rightarrow$ 样本均值 $N \rightarrow$ 样本方差 $\chi^2 \rightarrow T$ 统计量服从 t 分布 $\rightarrow$ 区间端点用 t 分位数。

八、自测题

第 1 题: 某超市每分钟平均有 $\lambda = 2$ 名顾客到达 (Poisson 过程), 求 5 分钟内到达顾客数为 0 的概率, 以及到达数 ≤ 8 的概率。

提示: 5 分钟内 $X \sim \text{Poisson}(10)$; $P(X = 0) = e^{-10} \approx 0.0000454$; $P(X \leq 8) = \sum_{k=0}^8 e^{-10} 10^k / k!$ (查 Poisson 表或计算约 0.333)。

第 2 题: $X \sim \text{Exp}(2)$ (率参数 $\lambda = 2$), 求 $E(X)$ 、 $\text{Var}(X)$ 、 $P(X > 1)$, 以及已知 $X > 0.5$ 条件下 $P(X > 1.5)$ 。

提示: $E(X) = 1/2$, $\text{Var}(X) = 1/4$; $P(X > 1) = e^{-2}$; 由无记忆性 $P(X > 1.5 | X > 0.5) = P(X > 1) = e^{-2} \approx 0.135$ 。

第3题：设 Z_1, Z_2, Z_3 i.i.d. $\sim N(0, 1)$, $V = Z_1^2 + Z_2^2 + Z_3^2$, $T = Z_1/\sqrt{V/3}$, 说明 V 和 T 各服从什么分布, 并求 $E(V)$ 和 $\text{Var}(V)$ 。

提示: $V \sim \chi_3^2$, $E(V) = 3$, $\text{Var}(V) = 6$; $T \sim t_3$ ($Z_1 \perp Z_2^2 + Z_3^2$ 需要验证, 或注意 $V = Z_1^2 + (Z_2^2 + Z_3^2)$ 分解方式)。

第4题：从含 12 件合格品和 3 件次品 (共 15 件) 的批次中, 不放回抽取 5 件。设次品数为 X , 写出 X 的分布类型和 $E(X)$ 。

提示: $X \sim$ 超几何分布 ($N = 15, K = 3, n = 5$); $E(X) = nK/N = 5 \times 3/15 = 1$ 。

第5题: $X \sim B(n, p)$ 。若 $E(X) = 6$, $\text{Var}(X) = 4.2$, 求 n 和 p 。

提示: $np = 6$, $np(1-p) = 4.2$, 联立得 $1-p = 4.2/6 = 0.7$, 即 $p = 0.3$; $n = 6/0.3 = 20$ 。

多元分布与协方差

一例速记: 设 (X, Y) 的联合密度为 $f(x, y) = 6x$ ($0 < x < 1, 0 < y < x$), 求 $P(X > 1/2)$ 。
看到“联合密度 + 求边缘概率”→ 先积掉 y , 得边缘密度 $f_X(x) = \int_0^x 6x dy = 6x^2$; 再对 x 积分:
 $P(X > 1/2) = \int_{1/2}^1 6x^2 dx = [2x^3]_{1/2}^1 = 2 - 1/4 = 7/8$ 。“联合 → 边缘”靠对另一变量积分 (求和), 是多元分布一切计算的基础操作。

一、为什么多元分布是概率论的“立体化”

单一随机变量只能描述一维不确定性, 但现实问题往往涉及多个相互影响的量: 股价与成交量、身高与体重、特征向量的各分量……联合分布把多个变量的整体行为打包描述, 协方差则量化它们之间的线性关联强度。

掌握多元分布的三个核心操作——边缘化、条件化、独立判别——就能把任何多维问题拆解成可计算的结构。而协方差矩阵 (以及它的推广: 多元正态分布) 是机器学习中处理高维数据的基石: 主成分分析 (PCA) 的本质是对协方差矩阵做特征值分解。

二、联合分布：PMF / PDF / CDF

2.1 离散情形：联合 PMF

若 X, Y 均为离散型，联合概率质量函数（PMF）定义为：

$$p(x, y) = P(X = x, Y = y)$$

满足： $p(x, y) \geq 0$ ，且 $\sum_x \sum_y p(x, y) = 1$ 。

2.2 连续情形：联合 PDF

若存在非负函数 $f(x, y)$ 使得对任意区域 A 有

$$P((X, Y) \in A) = \iint_A f(x, y) \, dx \, dy,$$

则称 $f(x, y)$ 为 (X, Y) 的联合概率密度函数（PDF）。

归一化条件： $\iint_{\mathbb{R}^2} f(x, y) \, dx \, dy = 1$ 。

2.3 联合 CDF

不论离散还是连续，联合累积分布函数（CDF）统一定义为：

$$F(x, y) = P(X \leq x, Y \leq y)$$

连续情形下 $f(x, y) = \frac{\partial^2 F}{\partial x \partial y}$ （在 F 的光滑点处）。

2.4 常见联合分布举例

类型	分布	核心特征
离散	多项分布 $\text{Multinomial}(n, p_1, \dots, p_k)$	$\sum X_i = n$ ，各分量为计数
连续	二元均匀分布	密度在某区域上为常数
连续	二元正态 $N(\mu, \Sigma)$	椭圆等高线，由均值向量与协方差矩阵完全确定

三、边缘分布：对另一变量“积掉”

从联合分布恢复单个变量的分布，称为边缘化（marginalization）。

连续情形：

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy, \quad f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx.$$

离散情形：

$$p_X(x) = \sum_y p(x, y), \quad p_Y(y) = \sum_x p(x, y).$$

操作要点：

1. 确认积分（求和）的范围—— y 的取值范围可能依赖 x （如上面速记例中 $0 < y < x$ ），此时上下限不是常数。
2. 积分后结果只是 x 的函数，代入归一化检验： $\int f_X(x) dx = 1$ 。

例：设 $f(x, y) = e^{-y}$ ($0 < x < 1, y > 0$)。

$$f_X(x) = \int_0^{+\infty} e^{-y} dy = 1 \quad (0 < x < 1).$$

$$f_Y(y) = \int_0^1 e^{-y} dx = e^{-y} \quad (y > 0).$$

$X \sim U(0, 1)$, $Y \sim \text{Exp}(1)$ ，二者恰好独立（联合密度 = $f_X \cdot f_Y$ ）。

四、条件分布：在已知某变量值后更新信念

条件密度定义为：

$$f_{Y|X}(y | x) = \frac{f(x, y)}{f_X(x)}, \quad f_X(x) > 0.$$

直觉：把联合密度在竖线 $X = x$ 处“切一刀”，再归一化（除以 $f_X(x)$ ），得到 Y 在已知 $X = x$ 时的分布。

全概率公式的连续版本：

$$f_Y(y) = \int f_{Y|X}(y | x) f_X(x) dx.$$

条件期望：

$$E(Y \mid X = x) = \int y f_{Y|X}(y \mid x) dy.$$

注意： $E(Y \mid X)$ 是 X 的函数，本身也是随机变量。重期望公式： $E[E(Y \mid X)] = E(Y)$ 。

操作	公式	含义
边缘密度	$f_X(x) = \int f(x, y) dy$	忽略 Y ，只看 X 的分布
条件密度	$f_{Y X}(y \mid x) = f(x, y)/f_X(x)$	在已知 $X = x$ 后， Y 的分布
还原联合	$f(x, y) = f_{Y X}(y \mid x) \cdot f_X(x)$	条件 $\times$ 边缘 = 联合

五、独立性判别

X 与 Y 独立当且仅当：

$$f(x, y) = f_X(x) \cdot f_Y(y) \quad (\text{对所有}(x, y)) .$$

实用判别技巧：

- 1. 因式分解法：若 $f(x, y)$ 能分解为只含 x 的因子乘以只含 y 的因子，且支撑集（ $f > 0$ 的区域）是矩形，则独立。
 - 例： $f(x, y) = e^{-x-y} \ (x, y > 0) = e^{-x} \cdot e^{-y}$ ，支撑是矩形 $(0, \infty)^2$ ，故独立。
- 2. 支撑非矩形则必不独立：若支撑集依赖两个变量（如 $0 < y < x < 1$ ），则 X, Y 不独立。
- 3. 协方差为零 $\neq$ 独立：协方差只度量线性关系， $\text{Cov}(X, Y) = 0$ 不能推出独立（反例： $Y = X^2$ ）。

六、协方差与协方差矩阵

6.1 协方差

$$\text{Cov}(X, Y) = E[(X - EX)(Y - EY)] = E(XY) - E(X) E(Y).$$

性质：

- $\text{Cov}(X, X) = \text{Var}(X)$
- 对称性： $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
- 双线性： $\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y)$

$$\bullet \text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$$

相关系数（无量纲化的协方差）：

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}}, \quad |\rho_{XY}| \leq 1.$$

$\rho = 1$ 表示完全正线性相关， $\rho = 0$ 表示线性不相关（不一定独立）， $\rho = -1$ 表示完全负线性相关。

6.2 协方差矩阵

对随机向量 $\mathbf{X} = (X_1, X_2, \dots, X_p)^\top$ ，协方差矩阵（也称方差-协方差矩阵）为 $p \times p$ 矩阵：

$$\Sigma = \text{Cov}(\mathbf{X}) = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)^\top],$$

其中 $\mu = E\mathbf{X}$ 。矩阵元素 $\Sigma_{ij} = \text{Cov}(X_i, X_j)$ ，对角元 $\Sigma_{ii} = \text{Var}(X_i)$ 。

基本性质：- 对称正半定（PSD）： $\Sigma = \Sigma^\top$ ，且 $\mathbf{v}^\top \Sigma \mathbf{v} \geq 0$ 对所有 $\mathbf{v}$ 。- 线性变换：若 $\mathbf{Y} = A\mathbf{X} + \mathbf{b}$ ，则 $\text{Cov}(\mathbf{Y}) = A\Sigma A^\top$ 。- 正定时可逆（各分量不存在严格线性相关）。

七、多元正态分布 $N(\mu, \Sigma)$

7.1 定义

p 维随机向量 $\mathbf{X}$ 服从多元正态分布 $N(\mu, \Sigma)$ (Σ 正定)，其联合 PDF 为：

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^\top \Sigma^{-1}(\mathbf{x} - \mu)\right).$$

指数部分 $(\mathbf{x} - \mu)^\top \Sigma^{-1}(\mathbf{x} - \mu)$ 称为马氏距离（Mahalanobis distance）的平方，等高线为以 μ 为中心的椭球面。

7.2 二元正态的特殊情形

设 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ ，联合 PDF 为：

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right]\right\}.$$

关键性质：

性质	结论
边缘分布	$X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$
$\rho = 0$ 时	X, Y 不相关 $\Leftrightarrow X, Y$ 独立 (仅多元正态成立 !)
条件分布	$Y X = x \sim N(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1), \sigma_2^2(1 - \rho^2))$
线性组合	$aX + bY \sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + 2ab\rho\sigma_1\sigma_2 + b^2\sigma_2^2)$

八、演示题：证明二元正态的条件分布仍是正态

题目：设 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ ，证明 $Y | X = x$ 服从正态分布，并给出均值与方差。

目标分析。条件密度 $= f(x, y)/f_X(x)$ 。 $f_X(x)$ 是一元正态密度，只需把联合密度除以它，再整理成正态密度的标准形式。

第一步：写出 $f_X(x)$ 。

$$f_X(x) = \frac{1}{\sqrt{2\pi} \sigma_1} \exp\left(-\frac{(x - \mu_1)^2}{2\sigma_1^2}\right).$$

第二步：计算条件密度。

$$f_{Y|X}(y | x) = \frac{f(x, y)}{f_X(x)}.$$

分子 $f(x, y)$ 的指数部分展开为：

$$-\frac{1}{2(1 - \rho^2)} \left[\frac{(x - \mu_1)^2}{\sigma_1^2} - \frac{2\rho(x - \mu_1)(y - \mu_2)}{\sigma_1\sigma_2} + \frac{(y - \mu_2)^2}{\sigma_2^2} \right].$$

除以 $f_X(x)$ 等价于在指数里减去 $-\frac{(x - \mu_1)^2}{2\sigma_1^2}$ 。整理剩余的指数：

$$-\frac{1}{2(1 - \rho^2)} \left[\frac{(y - \mu_2)^2}{\sigma_2^2} - \frac{2\rho(x - \mu_1)(y - \mu_2)}{\sigma_1\sigma_2} \right] + \frac{(x - \mu_1)^2}{2\sigma_1^2} \cdot \frac{\rho^2}{1 - \rho^2} - \frac{(x - \mu_1)^2}{2\sigma_1^2(1 - \rho^2)}.$$

注意带 $(x - \mu_1)^2$ 的项只依赖 x ，不含 y ，它们在对 y 积分时是常数（最终被归一化吸收）。

第三步：配方。关键在含 y 的项。令 $\mu_{y|x} = \mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1)$ ， $\sigma_{y|x}^2 = \sigma_2^2(1 - \rho^2)$ 。计算：

$$\frac{(y - \mu_2)^2}{\sigma_2^2} - \frac{2\rho(x - \mu_1)(y - \mu_2)}{\sigma_1\sigma_2} = \frac{1}{\sigma_{y|x}^2} \left(y - \mu_2 - \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1) \right)^2 - \frac{\rho^2(x - \mu_1)^2}{\sigma_1^2}.$$

最后一项 $-\rho^2(x - \mu_1)^2/\sigma_1^2$ 和前面的 $(x - \mu_1)^2$ 相关项合并，与 y 无关，进入归一化常数。

第四步：识别正态形式。含 y 的部分为：

$$-\frac{1}{2(1-\rho^2)\sigma_2^2} (y - \mu_{y|x})^2 = -\frac{(y - \mu_{y|x})^2}{2\sigma_{y|x}^2}.$$

这正是正态密度的指数形式。

结论：

$$Y | X = x \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1), \sigma_2^2(1 - \rho^2)\right).$$

回顾。条件均值 $\mu_{y|x}$ 关于 x 是线性的（斜率 $\rho\sigma_2/\sigma_1$ ），这正是线性回归的理论基础。条件方差 $\sigma_2^2(1 - \rho^2) < \sigma_2^2$ ，相关性越强（ $|\rho|$ 越大），知道 X 后对 Y 的不确定性减少越多。

九、思考路标

路标 1：看到“联合密度 + 求某单一变量的概率或分布”→ 先对另一个变量积分（求和），得到边缘密度，再做后续运算。

路标 2：看到“已知 $X = x$ ，求 Y 的分布”→ 条件密度 $f_{Y|X}(y|x) = f(x, y)/f_X(x)$ ；分子是联合密度，分母是边缘密度。

路标 3：判断独立性时，第一步看支撑集是否是矩形。支撑集含交叉约束（如 $0 < y < x$ ）→ 直接判定不独立，无需计算协方差。

路标 4：协方差为零不等于独立。只有在多元正态分布中，不相关才等价于独立。其他情形下， $\text{Cov}(X, Y) = 0$ 不能推出 X, Y 独立。

路标 5：看到协方差矩阵 Σ 和线性变换 $\mathbf{Y} = \mathbf{A}\mathbf{X}$ → 公式 $\text{Cov}(\mathbf{Y}) = \mathbf{A}\Sigma\mathbf{A}^\top$ 。这是 PCA、白化（whitening）等数据处理操作的数学核心。

路标 6：多元正态的条件分布、边缘分布仍是正态。见到“二元正态 + 条件 / 边缘”→ 直接套对应公式，无需从头积分。

路标 7：二元正态密度的“配方”步骤是研究生考试的高频考点。核心是把含 y 的二次型配成 $(y - \text{线性函数}(x))^2/\text{常数}$ ，剩下与 y 无关的项进入归一化常数。

十、典型应用 3 例

例 1：求边缘密度与独立性判别

题目：设 (X, Y) 的联合密度为 $f(x, y) = \begin{cases} 2e^{-x-2y}, & x > 0, y > 0 \\ 0, & \text{其他} \end{cases}$ ，判断 X, Y 是否独立。

分析：

$$f_X(x) = \int_0^{+\infty} 2e^{-x-2y} dy = 2e^{-x} \cdot \frac{1}{2} = e^{-x} \quad (x > 0).$$

$$f_Y(y) = \int_0^{+\infty} 2e^{-x-2y} dx = 2e^{-2y} \quad (y > 0).$$

$$f_X(x) \cdot f_Y(y) = e^{-x} \cdot 2e^{-2y} = 2e^{-x-2y} = f(x, y).$$

支撑集为矩形 $(0, +\infty)^2$ ，且联合密度等于边缘密度之积，故 X, Y 独立。

例 2：条件期望与线性回归

题目： (X, Y) 服从二元正态 $N(0, 0, 1, 4, 0.8)$ ($\mu_1 = \mu_2 = 0$, $\sigma_1 = 1$, $\sigma_2 = 2$, $\rho = 0.8$)，求 $E(Y | X = 1)$ 和 $\text{Var}(Y | X = 1)$ 。

分析：

$$E(Y | X = 1) = \mu_2 + \rho \frac{\sigma_2}{\sigma_1} (1 - \mu_1) = 0 + 0.8 \times \frac{2}{1} \times 1 = 1.6.$$

$$\text{Var}(Y | X = 1) = \sigma_2^2 (1 - \rho^2) = 4(1 - 0.64) = 4 \times 0.36 = 1.44.$$

解读：知道 $X = 1$ 后，对 Y 的最佳预测是 1.6，不确定性从原来的 $\sigma_2^2 = 4$ 减少到 1.44，减少了 64%（正好是 $\rho^2 = 0.64$ ）。

例 3: 协方差矩阵与线性变换 (PCA 预热)

题目: 设 $\mathbf{X} = (X_1, X_2)^\top$, 协方差矩阵 $\Sigma = \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix}$ 。令 $Y = X_1 - 2X_2$ (即 $A = (1, -2)$), 求 $\text{Var}(Y)$ 。

分析:

$$\text{Var}(Y) = A\Sigma A^\top = (1, -2) \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -2 \end{pmatrix}.$$

先算 $A\Sigma = (1 \cdot 4 + (-2) \cdot 2, 1 \cdot 2 + (-2) \cdot 1) = (0, 0)$, 因此 $\text{Var}(Y) = 0$ 。

这意味着 $Y = X_1 - 2X_2$ 几乎必然为常数—— X_1 与 X_2 之间存在严格的线性依赖关系 ($X_1 = 2X_2$ a.s.), 协方差矩阵奇异 (行列式为零: $4 \times 1 - 2 \times 2 = 0$)。

十一、自测题

第 1 题: 设联合密度 $f(x, y) = c(x + y)$ ($0 < x < 1, 0 < y < 1$), 求常数 c , 以及 $f_X(x)$ 和 $f_Y(y)$ 。

提示: 由 $\int_0^1 \int_0^1 c(x+y) dx dy = c \cdot 1 = 1$ 得 $c = 1$; $f_X(x) = \int_0^1 (x+y) dy = x+1/2$; $f_Y(y) = y+1/2$ 。

验证: $f(x, y) \neq f_X(x) \cdot f_Y(y)$, 故 X, Y 不独立。

第 2 题: 设 (X, Y) 的联合 PMF 为 $p(x, y) = \frac{e^{-2}}{x!(y-x)!}$ ($x = 0, 1, \dots, y; y = 0, 1, 2, \dots$)。求 X 和 Y 的边缘分布。

提示: 固定 x , 对 y 从 x 到 ∞ 求和; 固定 y , 对 x 从 0 到 y 求和。最终 $X \sim \text{Poisson}(1), Y \sim \text{Poisson}(2)$ 。

第 3 题: 设 $X \sim N(0, 1), Y = X^2$ 。计算 $\text{Cov}(X, Y)$, 并说明 X, Y 是否独立。

提示: $\text{Cov}(X, Y) = E(X \cdot X^2) - E(X) \cdot E(X^2) = E(X^3) - 0 = 0$ (奇函数)。但 Y 完全由 X 确定, 显然不独立。这是协方差为零不等于独立的经典例子。

第 4 题: $(X, Y) \sim N(1, -1, 4, 9, -0.5)$, 求 $P(Y < -1 + X/2)$ 。

提示: 令 $Z = Y - (-1 + X/2) = Y + 1 - X/2$ 。 Z 是二元正态的线性组合, 故 $Z \sim N$; 计算 $E(Z) = -1 + 1 - (-0.5) \cdot (3/2 \cdot 1) \dots$ 先用 $E(Z) = E(Y) + 1 - E(X)/2 = -1 + 1 - 1/2 = -1/2$, $\text{Var}(Z) = \text{Var}(Y) + \text{Var}(X)/4 - \text{Cov}(X, Y) = 9 + 1 - (-3) = 13$ 。 $P(Z < 0) = \Phi(1/2/\sqrt{13})$ 。

第 5 题: 设随机向量 $\mathbf{X}$ 的协方差矩阵为 Σ , 令 $\mathbf{Y} = \Sigma^{-1/2}(\mathbf{X} - \mu)$ (白化变换), 证明 $\text{Cov}(\mathbf{Y}) = I$ (单位矩阵)。

提示: $\text{Cov}(\mathbf{Y}) = \Sigma^{-1/2} \Sigma (\Sigma^{-1/2})^\top = \Sigma^{-1/2} \Sigma \Sigma^{-1/2} = I$ (利用 $\Sigma^{1/2}$ 对称正定)。

极限定理：LLN 与 CLT

一例速记：某工厂产品合格率为 $p = 0.9$ ，抽检 $n = 400$ 件，用 CLT 估算样本合格率 $\hat{p}$ 落在 $[0.88, 0.92]$ 的概率。 $\hat{p} = \bar{X}_n$, $E\hat{p} = 0.9$, $\text{Var}(\hat{p}) = p(1 - p)/n = 0.09/400$, $\sigma_{\hat{p}} = 0.3/20 = 0.015$ 。 $P(|\hat{p} - 0.9| < 0.02) = P(|Z| < 0.02/0.015) = P(|Z| < 1.33) \approx 2\Phi(1.33) - 1 \approx 0.817$ 。“大样本 + 样本均值的偏差概率”→ 立刻标准化，查标准正态表。

一、为什么极限定理是统计推断的地基

“我只有 100 个样本，能不能用来推断总体?”——这个问题的答案，正是极限定理给出的。

大数定律 (LLN) 回答”样本均值能不能逼近总体均值”：只要样本量够大，样本均值会稳定在总体期望附近，这是估计的合理性保证。

中心极限定理 (CLT) 回答”样本均值的波动服从什么分布”：不管总体是什么分布，只要方差有限，样本均值的标准化版本都趋近标准正态。这是几乎所有假设检验和置信区间方法的理论出发点。

二、四种收敛模式

在讨论 LLN 和 CLT 之前，需要厘清概率论中”收敛”的不同含义，因为它们的强弱关系直接决定 LLN 分为”强”和”弱”两个版本。

设 $\{X_n\}$ 是随机变量序列， X 是目标随机变量。

2.1 四种收敛的定义

收敛类型	记号	定义
几乎必然收敛 (a.s.)	$X_n \xrightarrow{a.s.} X$	$P(\lim_{n \rightarrow \infty} X_n = X) = 1$
依概率收敛	$X_n \xrightarrow{P} X$	$\forall \varepsilon > 0:$ $\lim_{n \rightarrow \infty} P(X_n - X > \varepsilon) = 0$
L^p 收敛 (均方收敛)	$X_n \xrightarrow{L^p} X$	$\lim_{n \rightarrow \infty} E X_n - X ^p = 0$
依分布收敛	$X_n \xrightarrow{d} X$	$\lim_{n \rightarrow \infty} F_n(x) = F(x)$ (F 的连续点处)

2.2 强弱关系

几乎必然收敛 (a.s.)

↓ 蕴含

依概率收敛 (P)

↓ 蕴含

依分布收敛 (d)

L^p 收敛蕴含依概率收敛；几乎必然收敛与 L^p 收敛之间一般无蕴含关系（需要额外条件）。

依分布收敛最弱： $X_n \xrightarrow{d} X$ 只要求分布函数逐点收敛，不要求样本路径逼近。CLT 给出的是依分布收敛。

几乎必然收敛最强：样本路径（随机实验的每一次实现）几乎肯定收敛。强 LLN 给出的是几乎必然收敛。

收敛类型	直觉	代表定理
几乎必然 (a.s.)	“每条样本路径都收敛”（例外集概率为零）	强大数定律
依概率 (P)	“大偏差的概率 $\rightarrow 0$ ”	弱大数定律、Chebyshev
L^p (均方)	“期望误差的 p 次方 $\rightarrow 0$ ”	均方收敛估计
依分布 (d)	“分布函数逐点收敛”	中心极限定理

三、大数定律 (LLN)

设 $X_1, X_2, \dots, X_n$ 独立同分布 (i.i.d.), $E(X_i) = \mu$ (有限), $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ 。

3.1 弱大数定律 (Weak LLN)

$$\bar{X}_n \xrightarrow{P} \mu, \quad \text{即} \quad \forall \varepsilon > 0: P(|\bar{X}_n - \mu| > \varepsilon) \rightarrow 0.$$

直觉：当 n 很大时， $\bar{X}_n$ 与 μ 相差超过任何正数 ε 的概率趋于零。

Chebyshev 证明（需要 $\text{Var}(X_i) = \sigma^2 < \infty$ ）：

$$P(|\bar{X}_n - \mu| > \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0.$$

3.2 强大数定律 (Strong LLN, Kolmogorov)

$$\bar{X}_n \xrightarrow{a.s.} \mu, \quad \text{即} \quad P\left(\lim_{n \rightarrow \infty} \bar{X}_n = \mu\right) = 1.$$

只需 $E|X_i| < \infty$ （有限期望），无需有限方差。几乎必然收敛比依概率收敛更强——每次随机实验中， $\bar{X}_n$ 的路径几乎都收敛到 μ 。

弱强对比：

	弱 LLN	强 LLN
收敛类型	依概率	几乎必然
所需条件	有限方差（Chebyshev 版）	有限期望（Kolmogorov 版）
蕴含关系	强 LLN $\Rightarrow$ 弱 LLN	反之不成立

3.3 LLN 的用途

- 频率的稳定性： $\bar{X}_n \rightarrow p$ ($X_i \sim \text{Bernoulli}(p)$)，这是“频率是概率的近似”的理论依据。
- 蒙特卡洛积分： $\frac{1}{n} \sum_{i=1}^n h(X_i) \rightarrow E[h(X)]$ ，用样本均值近似期望。
- 参数估计的相合性：样本矩 ($\bar{X}$, $\frac{1}{n} \sum X_i^2$ 等) 依概率收敛到总体矩。

四、中心极限定理（CLT）

4.1 经典 CLT（Lindeberg-Lévy）

设 $X_1, X_2, \dots, X_n$ i.i.d., $E(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2 \in (0, +\infty)$, 则：

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1).$$

等价地， $S_n = \sum_{i=1}^n X_i$ 满足 $\frac{S_n - n\mu}{\sqrt{n}\sigma} \xrightarrow{d} N(0, 1)$ 。

近似使用：当 n 足够大时（通常 $n \geq 30$ 作为经验标准），

$$\bar{X}_n \approx N\left(\mu, \frac{\sigma^2}{n}\right), \quad S_n \approx N(n\mu, n\sigma^2).$$

4.2 CLT 的直觉：独立小扰动的叠加

每个 X_i 可以视为一个独立的”小扰动”。CLT 说的是：不管每个扰动的形状（分布）如何，只要方差有限、且没有某几个扰动主导全局，大量扰动叠加后的总效果都趋近于正态分布。

这也解释了为什么现实中正态分布无处不在：测量误差、人类身高、金融收益率的短期波动……背后都是大量独立小因素的叠加。

4.3 CLT 的实用计算步骤

给定 $X_1, \dots, X_n$ i.i.d., 已知 μ, σ^2 , 要求 $P(\bar{X}_n \in [a, b])$:

1. 标准化: 令 $Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$;
2. 变换区间: $P\left(\frac{a - \mu}{\sigma/\sqrt{n}} \leq Z \leq \frac{b - \mu}{\sigma/\sqrt{n}}\right)$;
3. 查正态表: $P(z_1 \leq Z \leq z_2) = \Phi(z_2) - \Phi(z_1)$ 。

连续性修正 (离散总体时提高精度): 若 X_i 是整数值, 用 $n\bar{X}_n = S_n \in [k_1, k_2]$ 时, 将区间改为 $[k_1 - 0.5, k_2 + 0.5]$ 。

五、演示题: 用 CLT 估算样本均值偏差概率

题目: 设 $X_1, \dots, X_{100}$ i.i.d., $E(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2 = 0.25$ 。估算 $P(|\bar{X}_{100} - \mu| < 0.1)$ 。

分析。样本量 $n = 100$, 方差 $\sigma^2 = 0.25$, 问 $\bar{X}_{100}$ 落在 μ 的 0.1 范围内的概率。

标准化。 $\bar{X}_{100}$ 近似 $N(\mu, \sigma^2/n) = N(\mu, 0.25/100) = N(\mu, 0.0025)$, 标准差 = 0.05。令

$$Z = \frac{\bar{X}_{100} - \mu}{0.05} \approx N(0, 1).$$

变换事件。

$$P(|\bar{X}_{100} - \mu| < 0.1) = P\left(|Z| < \frac{0.1}{0.05}\right) = P(|Z| < 2).$$

查表。

$$P(|Z| < 2) = 2\Phi(2) - 1 \approx 2 \times 0.9772 - 1 = 0.9544.$$

结论: 样本量 100、方差 0.25 时, 样本均值在 μ 的 ± 0.1 范围内的概率约为 95.44%。

延伸思考。若想将概率提高到 99% (即 $P(|Z| < z_{0.005}) = 0.99$, $z \approx 2.576$), 需要 $2.576 = 0.1/(0.5/\sqrt{n})$, 解得 $\sqrt{n} = 2.576 \times 5 = 12.88$, $n \approx 166$ 。这是 CLT 驱动的样本量计算的基本逻辑。

六、思考路标

路标 1: 看到“ n 个 i.i.d. 样本均值的概率问题”→ 优先考虑 CLT: 标准化 $Z = (\bar{X}_n - \mu)/(\sigma/\sqrt{n})$, 再查正态表。
 $n \geq 30$ 时近似通常可接受。

路标 2: 看到”证明某估计量收敛到真值(相合性)“→用弱 LLN (Chebyshev 不等式): 计算方差, 证明 $\text{Var}(\hat{\theta}_n) \rightarrow 0$, 则 $\hat{\theta}_n \xrightarrow{P} \theta$ 。

路标 3: 区分”依概率收敛”与”几乎必然收敛”: 考试若要求”几乎必然”, 不能只用 Chebyshev; 若只要求”依概率”, Chebyshev 方差估计就够了。

路标 4: CLT 的条件是有限方差。对于重尾分布(如 Cauchy 分布, 方差无穷) CLT 不适用; 此时样本均值的分布不收敛到正态。

路标 5: 二项分布的正态近似: $X \sim B(n, p)$, 当 n 大、 $np \geq 5$ 、 $n(1-p) \geq 5$ 时, $X \approx N(np, np(1-p))$ 。标准化后查正态表, 这是 CLT 的最典型应用之一。

路标 6: 区分 LLN 与 CLT 的角色: LLN 说”收敛到什么值”(点估计的合理性), CLT 说”以什么速率和分布收敛”(波动的量化)。两者联合使用才能做完整的统计推断。

路标 7: 大样本置信区间的逻辑: 由 CLT, $Z = (\bar{X}_n - \mu)/(\sigma/\sqrt{n}) \approx N(0, 1)$, $P(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = 1 - \alpha$, 反解出 μ 的 $1 - \alpha$ 置信区间为 $\bar{X}_n \pm z_{\alpha/2} \cdot \sigma/\sqrt{n}$ 。

七、典型应用 3 例

例 1: 保险赔付的概率估算

题目: 某保险公司承保 $n = 10000$ 份保单, 每份年赔付额 X_i 独立, $E(X_i) = 500$ 元, $\text{Var}(X_i) = 90000$ 元² ($\sigma = 300$ 元)。求总赔付额 $S = \sum X_i$ 超过 5,100,000 元的概率。

分析: $S \approx N(n\mu, n\sigma^2) = N(5,000,000, 10000 \times 90000)$, $\text{SD}(S) = 300\sqrt{10000} = 30,000$ 。

$$P(S > 5,100,000) = P\left(Z > \frac{5,100,000 - 5,000,000}{30,000}\right) = P(Z > 3.33) \approx 1 - \Phi(3.33) \approx 0.0004.$$

保险公司收取足够保费后, 超额赔付的概率极低——这是保险精算的数学基础。

例 2: 频率收敛到概率 (LLN 的应用)

题目: 掷一枚不均匀硬币, 正面概率为 p (未知)。掷 n 次, 正面次数为 S_n 。问: 需要至少掷多少次, 才能以概率 ≥ 0.95 保证 $|S_n/n - p| < 0.01$?

分析: $S_n/n = \bar{X}_n$ ($X_i \sim \text{Bernoulli}(p)$), 方差 $\sigma^2 = p(1-p) \leq 1/4$ 。

由 Chebyshev: $P\left(\left|\frac{S_n}{n} - p\right| \geq 0.01\right) \leq \frac{p(1-p)}{n \times (0.01)^2} \leq \frac{1/4}{n \times 10^{-4}} = \frac{2500}{n}$ 。

要使右侧 ≤ 0.05 , 需 $n \geq 50,000$ 。

(若用 CLT, 令 $p = 1/2$ (最坏情形), $\sigma = 1/2$, $0.01/(0.5/\sqrt{n}) = 1.96$, 解得 $n \geq (1.96 \times 50)^2 = 9604$ ——更精确的下界。Chebyshev 比较保守。)

例 3: CLT 驱动的置信区间

题目: 调查 $n = 200$ 人中, 132 人支持某政策。构造支持率 p 的 95% 置信区间。

分析: $\hat{p} = 132/200 = 0.66$, $\hat{\sigma}_{\hat{p}} = \sqrt{\hat{p}(1-\hat{p})/n} = \sqrt{0.66 \times 0.34/200} \approx \sqrt{0.001122} \approx 0.0335$ 。

由 CLT, 95% 置信区间为:

$$\hat{p} \pm 1.96 \times \hat{\sigma}_{\hat{p}} = 0.66 \pm 1.96 \times 0.0335 \approx 0.66 \pm 0.0657 = [0.5943, 0.7257].$$

解读: 在 95% 的置信水平下, 真实支持率在 59.4% 到 72.6% 之间。样本量越大, 区间越窄。

八、自测题

第 1 题: 设 $X_1, \dots, X_n$ i.i.d., $E(X_i) = 2$, $\text{Var}(X_i) = 4$ 。利用弱 LLN (Chebyshev) 求最小 n , 使得 $P(|\bar{X}_n - 2| < 0.5) \geq 0.9$ 。

提示: $P(|\bar{X}_n - 2| \geq 0.5) \leq \frac{4/n}{0.25} = \frac{16}{n} \leq 0.1$, 故 $n \geq 160$ 。

第 2 题: $X \sim B(400, 0.3)$, 用 CLT 估算 $P(X > 130)$ (含连续性修正)。

提示: $\mu = 120$, $\sigma = \sqrt{400 \times 0.3 \times 0.7} = \sqrt{84} \approx 9.165$ 。不含修正: $Z = (130 - 120)/9.165 \approx 1.09$, $P > \approx 1 - \Phi(1.09) \approx 0.138$ 。含修正: $Z = (130.5 - 120)/9.165 \approx 1.15$, $P \approx 0.125$ 。

第 3 题: 解释几乎必然收敛与依概率收敛的区别, 并给出一个序列满足后者但不满足前者的例子 (无需严格证明, 直觉说明即可)。

提示: 考虑“游走指示函数”序列: 在 $[0, 1]$ 上均匀取点, 定义 $X_n = \mathbf{1}_{U \in [k/m, (k+1)/m]}$ ($n = m(m-1)/2 + k$, 遍历所有分块)。每个区间的概率 $\rightarrow 0$ (依概率收敛到 0), 但对几乎每个 U , $X_n(U)$ 无限次等于 1 (不几乎必然收敛到 0)。

第 4 题: 某芯片生产线次品率为 $p = 0.05$, 每批生产 $n = 500$ 件。用 CLT 求一批中次品数超过 35 件的概率。

提示: $S \approx N(25, 500 \times 0.05 \times 0.95) = N(25, 23.75)$, $\sigma \approx 4.87$ 。 $P(S > 35) = P(Z > (35 - 25)/4.87) = P(Z > 2.05) \approx 1 - 0.9798 = 0.020$ 。

第 5 题 (深入): CLT 要求方差有限。设 $X_i \sim \text{Cauchy}(0, 1)$ (密度 $f(x) = 1/(\pi(1+x^2))$), 已知方差无穷大。 $\bar{X}_n$ 的分布是什么? 它服从 CLT 吗?

提示： n 个 i.i.d. $\text{Cauchy}(0, 1)$ 之和除以 n 仍是 $\text{Cauchy}(0, 1)$ (Cauchy 分布的稳定性)。 $\bar{X}_n$ 的分布不随 n 变化，不收敛到正态，CLT 不适用。这说明有限方差假设不可省略。

估计量评价四标尺

一例速记：设 $X_1, \dots, X_n$ i.i.d. $\sim N(\mu, \sigma^2)$ ，考察样本均值 $\bar{X}$ 估计 μ 的质量。无偏性： $E\bar{X} = \mu$ $\square$ ；一致性： $\text{Var}(\bar{X}) = \sigma^2/n \rightarrow 0$ $\square$ ；有效性：能达到 Fisher 信息给出的方差下界吗？正态情形 $I(\mu) = n/\sigma^2$ ， $1/I = \sigma^2/n = \text{Var}(\bar{X})$ $\square$ 。 $\bar{X}$ 对正态均值是无偏、一致、有效的估计量——它是最优估计的标杆。

一、为什么需要评价标准

拿到样本后，我们可以构造形形色色的估计量： $\bar{X}$ 、中位数、最小值、第一个观测值 X_1 ……它们都是 μ 的某种猜测。凭什么说某个估计量“好”？

判断估计量好坏需要客观标准，而且不同场景侧重不同。“无偏”关注估计的系统偏差；“一致”关注数据多了以后能不能收敛；“有效”关注精度的绝对上限；Cramér-Rao 下界 (CRB) 则给出了任何无偏估计量都无法突破的精度天花板。

二、四大评价标准

2.1 无偏性 (Unbiasedness)

定义：若 $E_{\theta}(\hat{\theta}) = \theta$ (对所有 θ)，称 $\hat{\theta}$ 为 θ 的无偏估计量。

偏差 (Bias)： $\text{Bias}(\hat{\theta}) = E(\hat{\theta}) - \theta$ 。无偏即偏差为零。

直觉：在大量重复实验中，估计值围绕真值波动，平均而言不高估也不低估。

经典例子：

- 样本均值 $\bar{X} = \frac{1}{n} \sum X_i$ ： $E\bar{X} = \mu$ ，无偏。
- 样本方差 $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ ： $E(S^2) = \sigma^2$ ，无偏。
- 但 $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ ： $E(\hat{\sigma}^2) = \frac{n-1}{n} \sigma^2 \neq \sigma^2$ ，有偏 (系统低估)。

注意：无偏并不等于“好”。 X_1 (只取第一个观测值) 是 μ 的无偏估计，但方差为 σ^2 ，远大于 $\bar{X}$ 的方差 σ^2/n 。

渐近无偏 (Asymptotically Unbiased)：若 $\text{Bias}(\hat{\theta}_n) \rightarrow 0$ ($n \rightarrow \infty$)，称为渐近无偏。 $\hat{\sigma}^2$ 是渐近无偏的例子。

2.2 一致性 (Consistency)

定义：若 $\hat{\theta}_n \xrightarrow{P} \theta$ (依概率收敛)，称 $\hat{\theta}_n$ 为 θ 的一致（相合）估计量。

等价条件（常用于证明）：若同时满足 $\text{Bias}(\hat{\theta}_n) \rightarrow 0$ ，以及 $\text{Var}(\hat{\theta}_n) \rightarrow 0$ ，

则 $\hat{\theta}_n$ 一致（因 $\text{MSE} = \text{Bias}^2 + \text{Var} \rightarrow 0$ ，结合 Chebyshev）。

直觉：数据越多，估计越精准，最终完全逼近真值。这是统计估计的最基本要求——如果样本无限多时估计量还不收敛到真值，这个估计方法就根本不可靠。

例子：

- $\bar{X}_n$: $\text{Var}(\bar{X}_n) = \sigma^2/n \rightarrow 0$ ，故一致。
- $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$: 虽然有偏，但 $\text{Bias} \rightarrow 0$ 、 $\text{Var} \rightarrow 0$ ，故仍是 σ^2 的一致估计。

2.3 有效性 (Efficiency)

定义（在无偏估计类中）：若 $\hat{\theta}_1, \hat{\theta}_2$ 均为 θ 的无偏估计量，且 $\text{Var}(\hat{\theta}_1) \leq \text{Var}(\hat{\theta}_2)$ （对所有 θ ），称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 更有效。

相对效率： $e(\hat{\theta}_1, \hat{\theta}_2) = \frac{\text{Var}(\hat{\theta}_2)}{\text{Var}(\hat{\theta}_1)}$ 。 $e > 1$ 表示 $\hat{\theta}_1$ 更有效。

均方误差 (MSE)：若比较的估计量不都是无偏的，改用 MSE 比较更公平：

$$\text{MSE}(\hat{\theta}) = E(\hat{\theta} - \theta)^2 = \text{Var}(\hat{\theta}) + [\text{Bias}(\hat{\theta})]^2.$$

均匀最小方差无偏估计量 (UMVUE)：在所有无偏估计量中，方差最小且对所有 θ 都成立的估计量。

2.4 小结对比

标准	数学定义	核心问题
无偏性	$E(\hat{\theta}) = \theta$	系统是否偏移?
一致性	$\hat{\theta}_n \xrightarrow{P} \theta$	数据越多越准吗?
有效性	$\text{Var}(\hat{\theta})$ 最小（无偏类中）	精度是否最优?
CRB 可达	$\text{Var}(\hat{\theta}) = 1/I(\theta)$	是否达到理论极限?

三、Cramér-Rao 下界与 Fisher 信息

3.1 Fisher 信息

Fisher 信息量 $I(\theta)$ 度量了样本数据关于参数 θ 所携带的“信息量”：

$$I(\theta) = E_{\theta} \left[\left(\frac{\partial}{\partial \theta} \ln f(X; \theta) \right)^2 \right] = -E_{\theta} \left[\frac{\partial^2}{\partial \theta^2} \ln f(X; \theta) \right].$$

(两个公式等价，后者有时更易计算；需要正则条件：对数密度对 θ 的二阶导数与期望可以交换。)

对 n 个 i.i.d. 样本： $I_n(\theta) = n \cdot I_1(\theta)$ ，Fisher 信息随样本量线性增长。

计分函数 (Score function)： $s(\theta; x) = \frac{\partial}{\partial \theta} \ln f(x; \theta)$ ，满足 $E_{\theta}[s(\theta; X)] = 0$ ， $\text{Var}(s) = I(\theta)$ 。

3.2 Cramér-Rao 下界 (CRB)

定理：设 $\hat{\theta}$ 是 θ 的无偏估计量，在正则条件下：

$$\text{Var}_{\theta}(\hat{\theta}) \geq \frac{1}{I_n(\theta)} = \frac{1}{n \cdot I_1(\theta)}.$$

解读：这是方差的“物理极限”——无论多聪明的无偏估计方法，方差都不可能低于 $1/I_n(\theta)$ 。若某估计量的方差恰好等于下界，称其为有效估计量 (efficient estimator)。

达到 **CRB** 的充要条件：计分函数与 $\hat{\theta} - \theta$ 成线性关系，即

$$\frac{\partial}{\partial \theta} \ln f(\mathbf{x}; \theta) = A(\theta) [\hat{\theta}(\mathbf{x}) - \theta],$$

此时 $\hat{\theta}$ 是有效估计量，且 $\text{Var}(\hat{\theta}) = 1/(n \cdot I_1(\theta))$ 。

3.3 常见分布的 Fisher 信息

分布	参数 θ	$I_1(\theta)$	$1/I_n(\theta) = \sigma^2/n$
$N(\mu, \sigma^2)$ (σ^2 已知)	μ	$1/\sigma^2$	σ^2/n
$N(\mu, \sigma^2)$ (μ 已知)	σ^2	$1/(2\sigma^4)$	$2\sigma^4/n$
Bernoulli(p)	p	$1/(p(1-p))$	$p(1-p)/n$
Poisson(λ)	λ	$1/\lambda$	λ/n
Exp(λ)	λ	$1/\lambda^2$	λ^2/n

四、演示题：样本均值 vs 样本中位数估计正态均值

题目：设 $X_1, \dots, X_n$ i.i.d. $\sim N(\mu, \sigma^2)$ ，比较样本均值 $\bar{X}$ 和样本中位数 $\tilde{X}$ 估计 μ 的有效性。

分析框架。两个估计量都是无偏的 ($N(\mu, \sigma^2)$ 关于 μ 对称，中位数的期望等于对称中心 μ)。比较有效性就是比较方差。

$\bar{X}$ 的方差。

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

$\tilde{X}$ 的方差 (大样本近似)。利用顺序统计量理论，样本中位数 (n 为奇数时取中间值) 的渐近方差为

$$\text{Var}(\tilde{X}) \approx \frac{1}{4n[f(\mu)]^2},$$

其中 $f(\mu)$ 是总体在 μ 处的密度值。对 $N(\mu, \sigma^2)$:

$$f(\mu) = \frac{1}{\sqrt{2\pi}\sigma}, \quad [f(\mu)]^2 = \frac{1}{2\pi\sigma^2}.$$

$$\text{Var}(\tilde{X}) \approx \frac{1}{4n \cdot \frac{1}{2\pi\sigma^2}} = \frac{\pi\sigma^2}{2n}.$$

相对效率。

$$e(\bar{X}, \tilde{X}) = \frac{\text{Var}(\tilde{X})}{\text{Var}(\bar{X})} = \frac{\pi\sigma^2/(2n)}{\sigma^2/n} = \frac{\pi}{2} \approx 1.571.$$

结论。样本中位数的方差约是样本均值方差的 $\pi/2 \approx 1.57$ 倍。用中位数估计正态均值，需要约多用 57% 的样本量才能达到与均值相同的精度。

为何均值更优? 对正态分布，均值就是 UMVUE，其方差 σ^2/n 恰好等于 Cramér-Rao 下界 ($1/I_n(\mu) = \sigma^2/n$)，因此没有无偏估计量能比它更有效。中位数不利用分布的参数结构，“浪费”了数据中的分布信息。

权衡。然而在重尾分布 (如 Cauchy) 或数据有离群值时，中位数可能远比均值稳健 (robust) —— 此时有效性与稳健性之间需要权衡。

五、思考路标

路标 1: 验证无偏性时，不要只看形式，要计算期望： $E(\hat{\theta}) = ?$ 。常见陷阱： $\frac{1}{n} \sum (X_i - \bar{X})^2$ 的期望是 $\frac{n-1}{n} \sigma^2$ ，不是 σ^2 。

路标 2: 证明一致性的最快路线：计算 $\text{Bias}^2 + \text{Var}$ （即 MSE），若 $\text{MSE} \rightarrow 0$ ，则依 Chebyshev 得 $\hat{\theta}_n \xrightarrow{P} \theta$ 。

路标 3: 比较两个无偏估计量的有效性 $\rightarrow$ 直接比较方差，方差小的更有效。若不都是无偏的，改用 MSE 比较。

路标 4: 计算 Fisher 信息 $I(\theta)$ 时，记住两个等价公式，选算起来更容易的那个。对指数族分布，通常用第二个公式（对数密度的二阶偏导取期望再取负）更简单。

路标 5: 若问“某估计量是否有效”，先算 $\text{CRB} = 1/I_n(\theta)$ ，再与估计量的方差比较。相等 $\rightarrow$ 有效；更大 $\rightarrow$ 有改进空间但不一定找得到更好的（可能 CRB 不可达）。

路标 6: 注意无偏、一致、有效三者的逻辑关系：无偏不蕴含一致（ X_1 无偏但不一致），一致不蕴含无偏（ $\hat{\sigma}^2$ 有偏但一致），有效蕴含无偏（有效的定义是在无偏类中方差最小）。

六、典型应用 3 例

例 1: 验证无偏性与一致性

题目: 设 $X_1, \dots, X_n$ i.i.d. $\sim \text{Exp}(\lambda)$ （均值 $1/\lambda$ ），验证 $\hat{\lambda} = 1/\bar{X}$ 的无偏性和一致性。

无偏性: $E(1/\bar{X}) \neq 1/E(\bar{X})$ （Jensen 不等式， $1/x$ 是凸函数）， $\hat{\lambda} = 1/\bar{X}$ 是有偏的。具体地，可以证明（ $n \geq 2$ 时） $E(1/\bar{X}) = n\lambda/(n-1) \neq \lambda$ ，存在正偏差 $\lambda/(n-1)$ 。

一致性: $\bar{X} \xrightarrow{P} 1/\lambda$ （LLN），再由连续映射定理， $1/\bar{X} \xrightarrow{P} \lambda$ ，故 $\hat{\lambda}$ 是一致的。

结论: $\hat{\lambda}$ 有偏但一致，这是“有偏但一致”的典型例子，强调了无偏与一致的独立性。

例 2: 计算 Fisher 信息与 CRB

题目: 设 $X_1, \dots, X_n$ i.i.d. $\sim \text{Poisson}(\lambda)$ ，计算 Fisher 信息 $I_1(\lambda)$ ，并给出 λ 的无偏估计量方差的下界。

Fisher 信息: $\ln f(x; \lambda) = x \ln \lambda - \lambda - \ln(x!)$ 。

$$\frac{\partial^2}{\partial \lambda^2} \ln f = -\frac{x}{\lambda^2}, \quad -E\left[-\frac{X}{\lambda^2}\right] = \frac{E(X)}{\lambda^2} = \frac{\lambda}{\lambda^2} = \frac{1}{\lambda}.$$

故 $I_1(\lambda) = 1/\lambda$ ， $I_n(\lambda) = n/\lambda$ ， $\text{CRB} = \lambda/n$ 。

$\bar{X}$ 是 λ 的无偏估计， $\text{Var}(\bar{X}) = \lambda/n$ ，恰好达到 **CRB**，故 $\bar{X}$ 是 Poisson 均值的有效估计量。

例 3: MSE 比较有偏与无偏估计

题目: 已知 $X_1, \dots, X_n$ i.i.d. $\sim N(\mu, \sigma^2)$, 比较 $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ 和 $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ 估计 σ^2 的 MSE。

设 $Q = \sum (X_i - \bar{X})^2$, 则 $Q/\sigma^2 \sim \chi^2(n-1)$, $E(Q) = (n-1)\sigma^2$, $\text{Var}(Q) = 2(n-1)\sigma^4$ 。

对 $S^2 = Q/(n-1)$ (无偏): $\text{Var}(S^2) = \frac{2\sigma^4}{n-1}$, $\text{Bias} = 0$, $\text{MSE} = \frac{2\sigma^4}{n-1}$ 。

对 $\hat{\sigma}^2 = Q/n$ (有偏): $E(\hat{\sigma}^2) = \frac{n-1}{n}\sigma^2$, $\text{Bias} = -\sigma^2/n$, $\text{Var}(\hat{\sigma}^2) = \frac{2(n-1)\sigma^4}{n^2}$ 。

$$\text{MSE}(\hat{\sigma}^2) = \frac{2(n-1)\sigma^4}{n^2} + \frac{\sigma^4}{n^2} = \frac{(2n-1)\sigma^4}{n^2}.$$

比较: $\text{MSE}(S^2) = \frac{2\sigma^4}{n-1} \approx \frac{2\sigma^4}{n}$; $\text{MSE}(\hat{\sigma}^2) = \frac{(2n-1)\sigma^4}{n^2} \approx \frac{2\sigma^4}{n}$ 。

精确比较: $\text{MSE}(\hat{\sigma}^2) - \text{MSE}(S^2) = \sigma^4 \left[\frac{2n-1}{n^2} - \frac{2}{n-1} \right] = \sigma^4 \cdot \frac{(2n-1)(n-1) - 2n^2}{n^2(n-1)} = \sigma^4 \cdot \frac{-1}{n^2(n-1)} < 0$ 。

故 $\text{MSE}(\hat{\sigma}^2) < \text{MSE}(S^2)$: 有偏估计量 $\hat{\sigma}^2$ 的 MSE 反而更小! 这说明, 若以 MSE 为准绳, 有偏估计量有时优于无偏的。

七、自测题

第 1 题: 设 $X_1, \dots, X_n$ i.i.d., $E(X_i) = \mu$, $E(X_i^2) = \mu^2 + \sigma^2$ 。验证 $\hat{\sigma}^2 = \frac{1}{n} \sum X_i^2 - \bar{X}^2$ 是 σ^2 的无偏估计量还是有偏估计量 (写出计算过程)。

提示: $E(\hat{\sigma}^2) = E(X_i^2) - E(\bar{X}^2) = (\mu^2 + \sigma^2) - (\mu^2 + \sigma^2/n) = \sigma^2(1 - 1/n) = \sigma^2(n-1)/n$, 有偏, 偏差为 $-\sigma^2/n$ 。

第 2 题: 设 $X_1, \dots, X_n$ i.i.d. $\sim U(0, \theta)$ (均匀分布), $\hat{\theta}_1 = 2\bar{X}$, $\hat{\theta}_2 = \frac{n+1}{n} X_{(n)}$ ($X_{(n)}$ 是最大顺序统计量)。验证两者都无偏, 并比较方差。

提示: $\text{Var}(\hat{\theta}_1) = \theta^2/(3n)$; $E(X_{(n)}) = n\theta/(n+1)$, $E(X_{(n)}^2) = n\theta^2/(n+2)$, $\text{Var}(\hat{\theta}_2) = \theta^2/[n(n+2)]$ 。
由于 $1/[n(n+2)] < 1/(3n)$ (对 $n \geq 1$), $\hat{\theta}_2$ 更有效。

第 3 题: 设 $X \sim N(\mu, \sigma^2)$, σ^2 已知, 计算 Fisher 信息 $I_1(\mu)$, 并写出基于 n 个样本的 μ 的无偏估计量方差的 Cramér-Rao 下界。

提示: $\ln f = -\frac{(x-\mu)^2}{2\sigma^2} + \text{const}$, $\partial^2 \ln f / \partial \mu^2 = -1/\sigma^2$, 故 $I_1(\mu) = 1/\sigma^2$, $\text{CRB} = \sigma^2/n$ 。

第 4 题: 为什么说“有偏估计量一定不是最优的”这句话是错误的? 请举例说明。

提示：参见例 3 中 $\hat{\sigma}^2$ 与 S^2 的 MSE 比较，有偏的 $\hat{\sigma}^2$ MSE 更小。此外，James-Stein 估计量是有偏的但在 MSE 意义下优于样本均值（当维数 ≥ 3 时）。“无偏性”只是评价标准之一，不是唯一准绳。

第 5 题（综合）：设 $X_1, \dots, X_n$ i.i.d. $\sim \text{Bernoulli}(p)$, $\hat{p} = \bar{X}$ 。(a) 验证无偏性；(b) 计算 Fisher 信息并验证 $\hat{p}$ 是有效估计量；(c) 用 CRB 确认 $\hat{p}$ 方差的下界与 $\text{Var}(\hat{p})$ 相等。

提示：(a) $E\bar{X} = p$ ；(b) $\ln f = x \ln p + (1-x) \ln(1-p)$, $\partial^2 \ln f / \partial p^2 = -x/p^2 - (1-x)/(1-p)^2$, $I_1(p) = E[-\partial^2 \ln f / \partial p^2] = 1/(p(1-p))$ ；(c) $\text{CRB} = p(1-p)/n = \text{Var}(\hat{p})$, 故 $\hat{p}$ 有效。

MLE 求解套路

一例速记： $X_1, \dots, X_n$ i.i.d. $\sim \text{Poisson}(\lambda)$, 求 λ 的 MLE。□ 似然： $L(\lambda) = \prod \frac{e^{-\lambda} \lambda^{x_i}}{x_i!}$ ；□ 对数： $\ell = -n\lambda + (\sum x_i) \ln \lambda - \sum \ln(x_i!)$ ；□ 求导： $\ell' = -n + (\sum x_i)/\lambda = 0$ ；□ 解： $\hat{\lambda}_{\text{MLE}} = \bar{x}$ ；□ 二阶验证： $\ell'' = -\sum x_i/\lambda^2 < 0$ □。“写似然 $\rightarrow$ 取对数 $\rightarrow$ 求导令零 $\rightarrow$ 解参数 $\rightarrow$ 验极大”——五步走完，结果几乎总是样本矩。

一、为什么 MLE 是参数估计的首选方法

最大似然估计 (Maximum Likelihood Estimation, MLE) 的核心思想极为直觉：选择使观测数据“最可能出现”的参数值作为估计。

这个思想具有深刻的数学性质：在正则条件下，MLE 是相合估计 ($n \rightarrow \infty$ 时收敛到真值)、渐近有效 (方差达到 Cramér-Rao 下界)、渐近正态。换句话说，在大样本下，MLE 是“最聪明”的估计方法——没有其他估计量能在渐近意义下全面超越它。

而且，MLE 的求解流程高度机械化，适合复杂模型的参数估计。机器学习中的逻辑回归、高斯混合模型 (EM 算法)、神经网络的交叉熵损失函数，本质上都是 MLE 的变体。

二、五步求解流程

步骤 □ 写似然函数 $L(\theta)$

设 $x_1, x_2, \dots, x_n$ 是观测样本。似然函数是参数 θ 的函数 (样本 x_i 视为固定)：

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta).$$

- 连续型： f 是密度函数 (PDF)。
- 离散型： f 是概率质量函数 (PMF)。

关键：把 $f(x_i; \theta)$ 里的每个 x_i 代入具体观测值， θ 保持符号形式。

步骤 □ 取对数得对数似然 $\ell(\theta)$

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta).$$

取对数有两个好处：将乘积转为求和（便于求导），且由于 $\ln$ 单调， L 和 ℓ 的极大值点相同。

步骤 □ 求导，令 $\partial \ell / \partial \theta = 0$

$$\frac{\partial \ell}{\partial \theta} = 0.$$

多参数时对每个分量分别求偏导，组成方程组：

$$\frac{\partial \ell}{\partial \theta_1} = 0, \quad \frac{\partial \ell}{\partial \theta_2} = 0, \quad \dots$$

步骤 □ 解方程，得 $\hat{\theta}_{\text{MLE}}$

从方程（组）中解出参数，即为 MLE 候选点。

注意：若似然在边界取最大值（如均匀分布 $U(0, \theta)$ 的 MLE 是最大顺序统计量 $X_{(n)}$ ，由边界分析而非求导得到），则“求导令零”这一步不适用，需要直接分析似然函数的单调性。

步骤 □ 验证为极大值（二阶导数检验）

确认 $\hat{\theta}$ 处为极大值（而非极小值或鞍点）：

$$\left. \frac{\partial^2 \ell}{\partial \theta^2} \right|_{\hat{\theta}} < 0.$$

多参数时验证 Hessian 矩阵 $H = (\partial^2 \ell / \partial \theta_i \partial \theta_j)$ 在 $\hat{\theta}$ 处负定。

流程概览：

步骤	操作	目的
□ 写似然	$L(\theta) = \prod f(x_i; \theta)$	构造目标函数
□ 取对数	$\ell(\theta) = \sum \ln f(x_i; \theta)$	乘积 $\rightarrow$ 求和，便于微分
□ 求导令零	$\partial \ell / \partial \theta = 0$	找候选极值点

步骤	操作	目的
□ 解参数	得 $\hat{\theta}_{\text{MLE}}$	求解方程
□ 验极大	$\partial^2 \ell / \partial \theta^2 < 0$	确认是极大

三、不变性原理

MLE 的不变性：若 $\hat{\theta}_{\text{MLE}}$ 是 θ 的 MLE， g 是任意（可测）函数，则

$$\widehat{g(\theta)}_{\text{MLE}} = g(\hat{\theta}_{\text{MLE}}).$$

例子：

- 估计 σ^2 （正态，均值已知）的 MLE 是 $\hat{\sigma}^2$ ；则估计 $\sigma = \sqrt{\sigma^2}$ 的 MLE 是 $\hat{\sigma} = \sqrt{\hat{\sigma}^2}$ ，直接开根号。
- 若 $\hat{\lambda}$ 是 Poisson 参数 λ 的 MLE，则 $e^{-\lambda}$ （无事件的概率）的 MLE 是 $e^{-\hat{\lambda}}$ ，无需重新推导。
- 若 $\hat{p}$ 是成功概率的 MLE，则 odds = $p/(1-p)$ 的 MLE 是 $\hat{p}/(1-\hat{p})$ 。

不变性原理的重要性：当目标参数是原始参数的非线性变换时，不必对 $g(\theta)$ 重新建似然和求导——只需先求出 θ 的 MLE，再做变换。

四、演示题：正态分布双参数 MLE

题目：设 $X_1, \dots, X_n$ i.i.d. $\sim N(\mu, \sigma^2)$ (μ, σ^2 均未知)，求 (μ, σ^2) 的 MLE。

步骤 □：写似然函数。

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}\right).$$

步骤 □：取对数。

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

步骤 □：对 μ 求偏导，令其为零。

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \implies \sum_{i=1}^n (x_i - \mu) = 0.$$

步骤 □ (μ 分量): 解 $\hat{\mu}$ 。

$$\sum x_i = n\mu \implies \hat{\mu}_{\text{MLE}} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

步骤 □: 对 σ^2 求偏导。令 $v = \sigma^2$ (记号简化):

$$\frac{\partial \ell}{\partial v} = -\frac{n}{2v} + \frac{1}{2v^2} \sum_{i=1}^n (x_i - \mu)^2 = 0.$$

步骤 □ (σ^2 分量): 代入 $\hat{\mu} = \bar{x}$, 解 $\hat{\sigma}^2$ 。

$$\frac{n}{2v} = \frac{\sum (x_i - \bar{x})^2}{2v^2} \implies v = \frac{\sum (x_i - \bar{x})^2}{n}.$$

$$\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

步骤 □: 验证极大值。对 μ 的二阶偏导: $\partial^2 \ell / \partial \mu^2 = -n/\sigma^2 < 0$ □。对 σ^2 的二阶偏导: $\partial^2 \ell / \partial v^2 = n/(2v^2) - \sum (x_i - \mu)^2 / v^3$, 代入 $\hat{v} = \sum (x_i - \bar{x})^2 / n$ 后得 < 0 □。

关键注意: $\hat{\sigma}_{\text{MLE}}^2$ 是有偏的!

$$E(\hat{\sigma}_{\text{MLE}}^2) = \frac{n-1}{n} \sigma^2 \neq \sigma^2.$$

这是 MLE 有偏的经典例子。无偏修正版为 $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ (在第 07 篇已经讨论过)。但按不变性原理, $\hat{\sigma}_{\text{MLE}} = \sqrt{\hat{\sigma}_{\text{MLE}}^2}$ 是 σ 的 MLE。

完整结论:

$$\hat{\mu}_{\text{MLE}} = \bar{X}, \quad \hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

五、思考路标

路标 1: 构造对数似然时, 所有不含参数的常数项可以直接丢弃 (它们不影响极值点)。例如, $N(\mu, \sigma^2)$ 的对数似然中, $-\frac{n}{2} \ln(2\pi)$ 与 μ, σ^2 无关, 求导时自动消失, 可以从一开始就忽略。

路标 2: 看到对数似然中出现 $\sum x_i$ 或 $\sum x_i^2$ 等统计量 $\rightarrow$ 最终 MLE 往往是样本均值、样本二阶矩或它们的函数。这是“充分统计量”的体现。

路标 3: 若 MLE 方程解出来的 $\hat{\theta}$ 不含 x_i 的个别值, 只含 $\sum x_i$ 、 $\bar{x}$ 、 $\sum x_i^2$ 等聚合量 $\rightarrow$ 这些聚合量是充分统计量, 它们捕捉了样本中关于 θ 的全部信息。

路标 4: 遇到估计 $g(\theta)$ (如 $e^{-\lambda}$ 、 θ^2 、 $1/\lambda$) $\rightarrow$ 先用五步流程求出 θ 的 MLE $\hat{\theta}$, 再用不变性原理直接给出 $g(\hat{\theta})$, 无需重新建立和求解对应似然。

路标 5: 正态 MLE 有偏这一事实是考试高频考点。 $\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$, 乘以 $\frac{n}{n-1}$ 才无偏。两个公式形状相同, 分母不同 (n vs $n-1$)。

路标 6: 如果似然函数在参数空间内部无极值点 (如 $U(0, \theta)$ 的似然关于 θ 单调递减), MLE 在边界取得, 此时需要直接分析似然的单调性或图形, 而非求导。

路标 7: 多参数 MLE 时, 若各参数的方程解耦 (如正态的 $\hat{\mu}$ 与 $\hat{\sigma}^2$ 方程分别求解), 则逐个解; 若方程组耦合 (参数互相牵制), 则需联立求解。

六、典型应用 3 例

例 1: 指数分布的 MLE

题目: $X_1, \dots, X_n$ i.i.d. $\sim \text{Exp}(\lambda)$ (密度 $f(x; \lambda) = \lambda e^{-\lambda x}$, $x > 0$), 求 λ 的 MLE 及其均值 $1/\lambda$ 的 MLE。

五步求解:

$$\square L(\lambda) = \lambda^n \exp(-\lambda \sum x_i)$$

$$\square \ell(\lambda) = n \ln \lambda - \lambda \sum x_i$$

$$\square \ell'(\lambda) = n/\lambda - \sum x_i = 0$$

$$\square \hat{\lambda}_{\text{MLE}} = n / \sum x_i = 1/\bar{x}$$

$$\square \ell''(\lambda) = -n/\lambda^2 < 0 \quad \square$$

由不变性原理, $1/\lambda$ 的 MLE $= 1/\hat{\lambda}_{\text{MLE}} = \bar{X}$ (样本均值)。

注意: $\hat{\lambda} = 1/\bar{X}$ 是有偏的 ($E(1/\bar{X}) \neq 1/E(\bar{X}) = \lambda$, 因为 $1/x$ 是凸函数), 但 $\bar{X}$ 是 $1/\lambda$ 的无偏估计。

例 2: Bernoulli 总体的 MLE 与不变性原理

题目: $X_1, \dots, X_n$ i.i.d. $\sim \text{Bernoulli}(p)$, $n = 100$, 观测到 $\sum x_i = 40$ 。求 p 的 MLE, 并用不变性原理求“两次伯努利试验都成功”的概率 p^2 的 MLE。

求解:

$$\square L(p) = p^{\sum x_i} (1-p)^{n-\sum x_i}$$

$$\square \ell(p) = (\sum x_i) \ln p + (n - \sum x_i) \ln(1 - p)$$

$$\square \ell'(p) = \frac{\sum x_i}{p} - \frac{n - \sum x_i}{1 - p} = 0$$

$$\square \hat{p}_{\text{MLE}} = \frac{\sum x_i}{n} = \frac{40}{100} = 0.4$$

$$\square \ell''(p) = -(\sum x_i)/p^2 - (n - \sum x_i)/(1 - p)^2 < 0 \quad \square$$

由不变性原理, p^2 的 MLE $= \hat{p}^2 = 0.16$ 。

例 3: 均匀分布的 MLE (边界极值)

题目: $X_1, \dots, X_n$ i.i.d. $\sim U(0, \theta)$ ($\theta > 0$), 求 θ 的 MLE。

分析: 密度 $f(x; \theta) = 1/\theta$ ($0 \leq x \leq \theta$), 否则为 0。

$$\square \text{似然: } L(\theta) = \theta^{-n} \cdot \mathbf{1}[\theta \geq \max(x_1, \dots, x_n)] = \theta^{-n} \cdot \mathbf{1}[\theta \geq x_{(n)}]$$

其中 $x_{(n)} = \max_i x_i$ 是最大顺序统计量。

$$\square \ell(\theta) = -n \ln \theta \quad (\text{当 } \theta \geq x_{(n)} \text{ 时})$$

$$\square \ell'(\theta) = -n/\theta < 0: \ell \text{ 关于 } \theta \text{ 单调递减!}$$

$$\square \text{在 } \theta \geq x_{(n)} \text{ 的约束下, } \ell(\theta) \text{ 在 } \theta = x_{(n)} \text{ 时最大 (越小越好, 但不能小于 } x_{(n)})。$$

$$\hat{\theta}_{\text{MLE}} = X_{(n)} = \max(X_1, \dots, X_n).$$

此题不能用“令导数为零”解出 MLE, 必须分析似然的单调性并结合参数约束。

注意: $\hat{\theta}_{\text{MLE}} = X_{(n)}$ 是有偏的 ($E(X_{(n)}) = n\theta/(n+1) < \theta$), 但渐近无偏 ($E(X_{(n)}) \rightarrow \theta$) 且一致。无偏修正为 $\frac{n+1}{n} X_{(n)}$ 。

七、自测题

第 1 题: $X_1, \dots, X_n$ i.i.d. $\sim N(\mu, 1)$ (方差已知为 1), 求 μ 的 MLE 并验证其无偏性与有效性。

提示: $\ell(\mu) = -\frac{1}{2} \sum (x_i - \mu)^2 + \text{const}$, $\ell'(\mu) = \sum (x_i - \mu) = 0$, 得 $\hat{\mu} = \bar{x}$ 。 $E\bar{X} = \mu$ (无偏); $\text{Var}(\bar{X}) = 1/n = \text{CRB}$ (有效)。

第 2 题: $X_1, \dots, X_n$ i.i.d., $f(x; \theta) = \theta x^{\theta-1}$ ($0 < x < 1$, $\theta > 0$), 求 θ 的 MLE。

提示: $\ell(\theta) = n \ln \theta + (\theta - 1) \sum \ln x_i$, $\ell'(\theta) = n/\theta + \sum \ln x_i = 0$, 得 $\hat{\theta} = -n / \sum \ln x_i = -1 / \overline{\ln x}$ 。

第 3 题: 在第 2 题的设定下, 利用不变性原理求 $P(X > 0.5) = 1 - 0.5^\theta$ 的 MLE。

提示：直接代入 $\hat{\theta}$ ： $P(\widehat{X} > 0.5) = 1 - 0.5^{\hat{\theta}} = 1 - 2^{-\hat{\theta}}$ ，其中 $\hat{\theta} = -1/\ln x$ 。

第 4 题：设 $X_1, \dots, X_n$ i.i.d. $\sim \text{Gamma}(\alpha, \lambda)$ (形状参数 α 已知，率参数 λ 未知)，密度 $f(x; \lambda) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}$ ($x > 0$)，求 λ 的 MLE。

提示： $\ell(\lambda) = n\alpha \ln \lambda - \lambda \sum x_i + \text{const}$ ， $\ell'(\lambda) = n\alpha/\lambda - \sum x_i = 0$ ，得 $\hat{\lambda} = n\alpha/\sum x_i = \alpha/\bar{x}$ (当 $\alpha = 1$ 时退化为指数分布的结果 $1/\bar{x}$ ，验证一致性)。

第 5 题 (双参数)： $X_1, \dots, X_n$ i.i.d. $\sim N(\mu, \sigma^2)$ ， $n = 5$ ，观测值为 $\{2, 3, 5, 7, 8\}$ 。计算 $\hat{\mu}_{\text{MLE}}$ 和 $\hat{\sigma}_{\text{MLE}}^2$ 的具体数值，并判断 $\hat{\sigma}_{\text{MLE}}^2$ 是否无偏。

提示： $\bar{x} = 25/5 = 5$ ， $\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{5}[(2-5)^2 + (3-5)^2 + (5-5)^2 + (7-5)^2 + (8-5)^2] = \frac{1}{5}[9+4+0+4+9] = 26/5 = 5.2$ 。 $E(\hat{\sigma}_{\text{MLE}}^2) = \frac{n-1}{n}\sigma^2 = \frac{4}{5}\sigma^2 \neq \sigma^2$ ，有偏。无偏修正： $S^2 = \frac{n}{n-1}\hat{\sigma}_{\text{MLE}}^2 = \frac{26}{4} = 6.5$ 。

假设检验 7 步法

一例速记：药效实验中，如何判断新药比安慰剂更好？先假设“新药没有效果”(H_0)，然后用样本数据计算“如果 H_0 成立，得到这种结果的概率”——若这个概率极小 ($< \alpha$)，则“反证” H_0 不可信，推断新药有效。假设检验 = 反证法的概率版：用数据的稀有性推翻无效假设。

一、为什么需要假设检验

数据总有随机性。即使两组数据的均值不同，也可能只是随机波动而非真实差异。假设检验提供了一套客观、可重复的决策框架：在已知抽样分布的前提下，量化“观测结果有多罕见”，从而决定是否拒绝某个关于总体参数的假设。

假设检验的核心逻辑是概率意义上的反证法：

1. 先假设 H_0 (零假设) 成立；
2. 在 H_0 下，计算得到“当前样本或更极端结果”的概率；
3. 若该概率过小，说明 H_0 与数据严重不符，拒绝 H_0 ；
4. 反之，“不拒绝 H_0 ” (注意：不等于“接受 H_0 ”)。

这套框架被广泛应用于：科学实验 (药物疗效)、工程质检 (产品参数是否达标)、机器学习 (模型 A 是否优于模型 B)。

二、7 步操作框架

第 1 步：建立假设 H_0 和 H_1

零假设 H_0 (null hypothesis): 通常是“没有效果”“参数等于某基准值”，是希望被推翻的假设。

备择假设 H_1 (alternative hypothesis): 与 H_0 互斥，代表研究者期望证明的命题。

单尾 vs 双尾:

类型	H_0	H_1	适用场景
双尾检验	$\mu = \mu_0$	$\mu \neq \mu_0$	不知道偏差方向
左尾检验	$\mu \geq \mu_0$	$\mu < \mu_0$	检验是否偏小
右尾检验	$\mu \leq \mu_0$	$\mu > \mu_0$	检验是否偏大

原则: H_0 和 H_1 必须覆盖参数的全部可能取值 (互补事件)，且在建立前不应看数据——先确定研究问题，再收集数据。

第 2 步：选择检验统计量

根据问题类型和已知条件选择合适的统计量:

场景	统计量	分布
已知方差 σ^2 ，检验 μ	$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$	$N(0, 1)$
未知方差，检验 μ (小样本)	$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$	$t(n - 1)$
检验方差 σ^2	$\chi^2 = \frac{(n - 1)S^2}{\sigma_0^2}$	$\chi^2(n - 1)$
两样本均值差	$T = \frac{\bar{X}_1 - \bar{X}_2}{S_p \sqrt{1/n_1 + 1/n_2}}$	$t(n_1 + n_2 - 2)$

统计量的核心要求: 在 H_0 成立时，其分布必须已知 (这样才能确定拒绝域)。

第 3 步：确定显著性水平 α

α (significance level) 是 I 类错误概率的上界——即“ H_0 为真时错误拒绝 H_0 的概率”。

常用值: - $\alpha = 0.05$: 最常用, “百次实验中允许 5 次误判”; - $\alpha = 0.01$: 更严格, 用于医学、安全等高风险领域; - $\alpha = 0.10$: 宽松, 用于探索性研究。

α 由研究者在收集数据前指定，不能看到结果再事后调整 (这属于 p -hacking，是科研不端行为)。

第 4 步：确定拒绝域

拒绝域 (rejection region / critical region) 是统计量的取值范围：一旦落入此区域，就拒绝 H_0 。

双尾检验 ($\alpha = 0.05$, Z 检验):

$$W = \{|Z| > z_{\alpha/2}\} = \{|Z| > 1.96\}$$

单尾检验: - 右尾: $W = \{Z > z_{\alpha}\} = \{Z > 1.645\}$ - 左尾: $W = \{Z < -z_{\alpha}\} = \{Z < -1.645\}$

t 检验类似，用 $t_{\alpha/2}(n-1)$ 替换 $z_{\alpha/2}$ (查 t 分布表，自由度为 $n-1$)。

临界值 (critical value) $z_{\alpha/2}$ 的含义：标准正态分布上 $\alpha/2$ 分位点，即 $P(Z > z_{\alpha/2}) = \alpha/2$ 。

第 5 步：计算检验统计量的观测值

将样本数据代入第 2 步选择的统计量公式，计算出具体数值：

$$t_{\text{obs}} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

其中 $\bar{x}$ 是样本均值， s 是样本标准差 (分母用 $n-1$)， n 是样本量。

第 6 步：判断：拒绝或不拒绝 H_0

- 若 t_{obs} 落在拒绝域内 $\Rightarrow$ 拒绝 H_0 ，在显著性水平 α 下有统计显著的差异；
- 若 t_{obs} 落在接受域内 $\Rightarrow$ 不拒绝 H_0 ，数据不足以推翻 H_0 (注意不是“证明 H_0 成立”)。

语言要精确：说“在 $\alpha = 0.05$ 显著性水平下，拒绝 H_0 ”，而不要说“证明了 H_1 ”。

第 7 步：报告 p 值

p 值 (p-value) 是在 H_0 成立时，观测到“当前统计量值或更极端值”的概率：

$$p = P(|T| \geq |t_{\text{obs}}| \mid H_0 \text{ 成立})$$

(双尾)

p 值与拒绝域的等价性：

$$p < \alpha \iff t_{\text{obs}} \in \text{拒绝域}$$

p 值越小，证据越强。完整报告应写： $t(df) = t_{\text{obs}}$, $p = \dots$, $\alpha = 0.05$ 。

三、两类错误与功效

3.1 I 类错误与 II 类错误

	H_0 实际为真	H_0 实际为假
拒绝 H_0	I 类错误 (α , 假阳性)	正确决策 (功效 $1 - \beta$)
不拒绝 H_0	正确决策 ($1 - \alpha$)	II 类错误 (β , 假阴性)

- I 类错误概率 α : 虚警率, 由显著性水平直接控制;
- II 类错误概率 β : 漏检率, 由样本量、效应大小和 α 共同决定;
- 功效 (power) = $1 - \beta$: 正确拒绝假 H_0 的能力。

3.2 α 与 β 的权衡

在样本量固定时, 减小 α (缩小拒绝域) 会增大 β :

$$\alpha \downarrow \Rightarrow \text{拒绝域缩小} \Rightarrow \beta \uparrow$$

同时减小两类错误的唯一办法是增大样本量 n 。

在实验设计中, 功效分析 (power analysis) 用于确定需要多大样本量才能以 $1 - \beta \geq 0.8$ 的功效检测出给定大小的效应。

3.3 效应量与统计显著性的区分

统计显著 (statistical significance) $\neq$ 实际显著 (practical significance):

- 大样本时, 极小的真实差异也可能达到统计显著 ($p < 0.05$);
- 小样本时, 较大的真实差异可能无法检测到。

效应量 (effect size, 如 Cohen's $d = (\bar{x}_1 - \bar{x}_2)/s_{\text{pooled}}$) 是度量实际显著性的指标, 不受样本量影响。完整报告应同时给出 p 值和效应量。

四、演示题：单样本 t 检验完整 7 步

题目：某厂声称其产品重量均值为 $\mu_0 = 500$ g。质检员随机抽取 $n = 16$ 件, 测得样本均值 $\bar{x} = 492$ g, 样本标准差 $s = 20$ g。在 $\alpha = 0.05$ 显著性水平下, 检验该厂产品重量均值是否显著偏离 500 g。

第 1 步：建立假设。

我们不知道偏差方向（可能偏重也可能偏轻），应用双尾检验：

$$H_0: \mu = 500, \quad H_1: \mu \neq 500$$

第 2 步：选统计量。

总体方差 σ^2 未知，用样本方差估计，选用 t 统计量：

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1) = t(15) \quad (\text{在 } H_0 \text{ 下})$$

第 3 步：确定 α 。

题目已给 $\alpha = 0.05$ ，双尾检验，每侧 $\alpha/2 = 0.025$ 。

第 4 步：确定拒绝域。

查 t 分布表，自由度 $df = n - 1 = 15$ ，临界值：

$$t_{0.025}(15) = 2.131$$

拒绝域： $W = \{|T| > 2.131\}$

第 5 步：计算统计量观测值。

$$t_{\text{obs}} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} = \frac{492 - 500}{20/\sqrt{16}} = \frac{-8}{20/4} = \frac{-8}{5} = -1.6$$

第 6 步：判断。

$|t_{\text{obs}}| = 1.6 < 2.131$ ，统计量未落入拒绝域。

结论：在 $\alpha = 0.05$ 显著性水平下，不拒绝 H_0 。即没有足够证据说明产品重量均值偏离 500 g。

第 7 步：报告 p 值。

$$p = P(|T_{15}| \geq 1.6) = 2 \times P(T_{15} \geq 1.6)。$$

查 t 分布表（或用软件）， $P(T_{15} \geq 1.6) \approx 0.065$ ，故 $p \approx 0.13$ 。

完整报告： $t(15) = -1.60$ ， $p = 0.13 > \alpha = 0.05$ ，不拒绝 H_0 。

补充思考：若样本量增加到 $n = 64$ ，则 $t_{\text{obs}} = -8/(20/8) = -3.2$ ，临界值约 2.00，此时 $3.2 > 2.00$ ，拒绝 H_0 ——同样的效应量，样本量翻 4 倍，结论可能逆转。这正是功效分析的意义。

五、思考路标

路标 1: H_0 的方向永远是“无效果/无差异”， H_1 才是研究者要证明的。这不是逻辑习惯问题，而是因为我们只能在 H_0 下推导统计量的分布——只有确定了“无效时的分布”，才能量化“有效证据的强弱”。

路标 2: p 值不是“ H_0 成立的概率”，而是“ H_0 成立时，数据这么极端或更极端的概率”。许多教材和论文都误用这一解释，是统计学中最常见的误解之一。正确理解： p 值衡量“证据与 H_0 的相容程度”，不是后验概率。

路标 3: 单尾 vs 双尾的选择必须在看数据前确定。若先看到 $\bar{x}$ 偏小才决定用左尾检验，临界值从 $z_{0.025} = 1.96$ 变成 $z_{0.05} = 1.645$ ，等于实际显著性水平变成了 $\alpha = 0.1$ ——这是隐性的 p -hacking。

路标 4: I 类错误 α (假阳性) 和 II 类错误 β (假阴性) 的权衡类比于医学诊断。过于宽松的标准 (大 α) 会导致过多误诊为病；过于严格的标准 (小 α , 大 β) 会漏诊真实疾病。两类错误的代价不对称时，应根据成本比调整 α ，而非机械使用 **0.05**。

路标 5: t 检验的核心假设是：□ 样本来自正态总体 (或 n 足够大，中心极限定理保证)；□ 观测值独立同分布。违反独立性 (如时间序列数据) 会使 t 检验完全失效，是最危险的假设违反。

路标 6: 统计显著 $\neq$ 实际重要。在机器学习中，大数据集 ($n = 10^6$) 下，模型 A 比模型 B 准确率高 0.001% 可能统计显著 ($p < 0.05$)，但毫无实践价值。效应量 (如 Cohen's d 、 R^2) 才是衡量实际意义的指标。

路标 7: 置信区间 (CI) 与假设检验的等价性：拒绝 $H_0: \mu = \mu_0$ 当且仅当 μ_0 不在 $(1 - \alpha)$ 置信区间内。置信区间传达更丰富的信息 (估计值 + 精度)，是假设检验结论的更好替代，APA 格式现要求同时报告。

六、典型应用例题

例 1: A/B 测试中的两样本 t 检验

场景：电商平台测试新推荐算法。对照组 (算法 A) $n_1 = 200$ 用户，平均购买金额 $\bar{x}_1 = 120$ 元， $s_1 = 30$ 元；实验组 (算法 B) $n_2 = 200$ 用户， $\bar{x}_2 = 128$ 元， $s_2 = 32$ 元。检验两算法是否有显著差异 ($\alpha = 0.05$)。

分析：

$$t = \frac{\bar{x}_2 - \bar{x}_1}{\sqrt{s_1^2/n_1 + s_2^2/n_2}} = \frac{128 - 120}{\sqrt{900/200 + 1024/200}} = \frac{8}{\sqrt{9.62}} = \frac{8}{3.1} \approx 2.58$$

自由度 (Welch 近似) ≈ 396 ，此时 $t_{0.025}(396) \approx 1.97$ 。

$2.58 > 1.97$ ，拒绝 H_0 ，算法 B 显著优于 A ($p \approx 0.01$)。

效应量： $d = (128 - 120)/31 \approx 0.26$ (小效应，实际提升有限)。

例 2：卡方检验——分类变量的独立性

场景：调查性别与职业选择的关系，得到 2×3 频率表：

	技术	管理	其他
男	80	30	40
女	40	50	60

H_0 ：性别与职业选择独立。

卡方统计量： $\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$ ，其中 $E_{ij} = (\text{行总计} \times \text{列总计}) / \text{总计}$ 。

计算得 $\chi^2 = 22.8$ ，自由度 $(2 - 1)(3 - 1) = 2$ ， $\chi_{0.05}^2(2) = 5.99$ 。

$22.8 \gg 5.99$ ，强烈拒绝 H_0 ，性别与职业选择显著相关。

例 3：机器学习模型的 McNemar 检验

场景：比较两个分类器在同一测试集（ $n = 500$ ）上的错误模式。

- 模型 A 对、B 错： $n_{10} = 20$ ；
- 模型 A 错、B 对： $n_{01} = 35$ ；
- 两者都对 / 都错：不参与检验。

McNemar 检验专为配对比较设计：

$$\chi^2 = \frac{(n_{10} - n_{01})^2}{n_{10} + n_{01}} = \frac{(20 - 35)^2}{55} = \frac{225}{55} \approx 4.09$$

$\chi_{0.05}^2(1) = 3.84$ ， $4.09 > 3.84$ ， $p \approx 0.043 < 0.05$ ，模型 B 显著优于 A。

注：McNemar 检验利用了两个模型在同一样本上结果的相关性，比两个独立样本 z 检验更有功效。

七、自测题

第 1 题：区分以下说法的正误：(1) “ $p = 0.03$ 说明 H_0 成立的概率是 3%”；(2) “ $p = 0.03 < 0.05$ ，所以 H_0 被证明为假”；(3) “未拒绝 H_0 即证明了 H_0 成立”。

提示：三句均错误。(1) p 值是关于数据的概率，不是关于假设的概率；(2) 统计检验不能“证明”命题，只能“有证据拒绝”；(3) 不拒绝 $\neq$ 接受，可能是 II 类错误或样本量不足。

第2题：某药物试验，设 $\alpha = 0.01$ ，检验新药是否优于安慰剂（右尾检验）。(1) 写出 H_0 和 H_1 （设新药效果均值为 μ ，安慰剂为 μ_0 ）；(2) I 类错误在此语境下是什么？II 类错误是什么？哪类错误代价更高？

提示：(1) $H_0 : \mu \leq \mu_0$, $H_1 : \mu > \mu_0$ ；(2) I 类错误：无效药宣称有效（可能危害患者并浪费资源）；II 类错误：有效药被否定（患者失去治疗机会）。两类错误代价均高，需根据具体语境权衡，故药监局通常取 $\alpha = 0.01$ 甚至更小。

第3题：已知 $n = 25$, $\bar{x} = 105$, $s = 15$, $\mu_0 = 100$ （双尾 t 检验， $\alpha = 0.05$ ）。(1) 计算 t 统计量；(2) 自由度是多少？临界值是多少？(3) 是否拒绝 H_0 ？

提示：(1) $t = (105 - 100) / (15 / \sqrt{5}) = 5 / 3 \approx 1.67$ ；(2) $df = 24$, $t_{0.025}(24) = 2.064$ ；(3) $1.67 < 2.064$ ，不拒绝 H_0 , $p \approx 0.108$ 。

第4题：为什么增大样本量 n 能同时降低 I 类错误和 II 类错误？

提示：这是误解——增大 n 不能降低 I 类错误 α （ α 由研究者事先设定，与 n 无关）。增大 n 能降低的是 II 类错误 β （即提高功效）：更大的样本使检验统计量的标准误 $\sigma / \sqrt{n}$ 更小，真实差异在统计量上的体现更清晰，更容易落入拒绝域。

第5题：在机器学习中，你训练了两个模型，在独立测试集上的准确率分别为 0.923 和 0.917（测试集大小 $n = 10000$ ）。用正态近似检验两模型的准确率是否有显著差异（ $\alpha = 0.05$ ）。

提示：设 $\hat{p}_1 = 0.923$, $\hat{p}_2 = 0.917$ （独立样本）。合并方差（在 $H_0 : p_1 = p_2$ 下） $\hat{p} = (0.923 + 0.917) / 2 = 0.920$, $SE = \sqrt{2\hat{p}(1 - \hat{p})/n} = \sqrt{2 \times 0.920 \times 0.080 / 10000} \approx 0.00384$ 。 $z = (0.923 - 0.917) / 0.00384 \approx 1.56 < 1.96$ ，不拒绝 H_0 ，差异不显著。注意：即使两模型真正相差 0.6%，10000 个样本也不足以检测到这一效应（需要更大测试集）。

信息论核心三件套

一例速记：为什么均匀分布的“不确定性”最大？掷一枚均匀硬币（ $p = 0.5$ ）比掷一枚 99% 朝正面的硬币，结果更“出人意料”——前者熵 $H = 1$ bit，后者熵 ≈ 0.08 bit。熵就是“平均惊讶度”。熵 = 对未来结果平均有多吃惊（bit 数）。

一、为什么信息论是 AI 的底层语言

现代 AI 训练的核心操作——最小化损失——在概率视角下就是让模型分布尽量接近数据分布。信息论提供了度量“两个分布有多不同”的精确工具：

- 交叉熵（cross-entropy）是分类任务的标准损失函数；
- KL 散度出现在 VAE 的正则化项、RLHF 的策略约束、知识蒸馏的目标函数；
- 互信息是特征选择、信息瓶颈、对比学习的理论基础；
- 熵衡量模型预测的不确定性，用于主动学习（选择最不确定的样本标注）。

理解这三件套及其关系，就掌握了深度学习损失函数的底层逻辑。

二、熵：不确定性的度量

2.1 定义

设离散随机变量 X 的概率分布为 $P(X = x_i) = p_i, i = 1, \dots, n$ ，则 X 的香农熵（Shannon entropy）定义为：

$$H(X) = - \sum_{i=1}^n p_i \log_2 p_i$$

约定 $0 \log 0 = 0$ （极限值）。单位：以 $\log_2$ 计为 bit，以 $\ln$ 计为 nat。

直觉： $-\log_2 p_i$ 是事件 x_i 的“惊讶度”（information content）——越罕见的事件发生时越惊讶。熵是惊讶度的概率期望（加权平均）。

2.2 基本性质

性质 1（非负性）： $H(X) \geq 0$ ，等号当且仅当 X 为确定性变量（某 $p_i = 1$ ）。

性质 2（最大熵定理）：在 n 点分布中，均匀分布的熵最大：

$$H(X) \leq \log_2 n$$

等号当且仅当 $p_1 = p_2 = \dots = p_n = 1/n$ （均匀分布）。

证明（Jensen 不等式）： $-\log$ 是凸函数，

$$H(X) = \sum p_i (-\log p_i) = \sum p_i \log \frac{1}{p_i} \leq \log \left(\sum p_i \cdot \frac{1}{p_i} \right) = \log n$$

（最后一步用 Jensen 不等式： $\sum p_i f(1/p_i) \leq f(\sum p_i / p_i) = f(n)$ ，其中 $f = \log$ 是凹函数，故用 $\leq$ ）。■

性质 3（链式法则）： $H(X, Y) = H(X) + H(Y|X)$ ，其中条件熵 $H(Y|X) = \sum_x p(x) H(Y|X = x)$ 。

2.3 熵在机器学习中的意义

场景	熵的角色
决策树分裂	选择使条件熵 $H(Y X)$ 最小（信息增益最大）的特征

场景	熵的角色
主动学习	选择预测熵最大的样本（不确定性最高，标注价值最大）
语言模型评估	困惑度 (perplexity) = 2^H ，衡量模型对测试集的“不确定性”
最大熵模型	在满足约束的分布中选熵最大的（最少主观假设）

三、KL 散度：分布差异的度量

3.1 定义

Kullback-Leibler 散度 (KL divergence, 也称相对熵) 衡量分布 p 与参考分布 q 的差异:

$$D_{\text{KL}}(p\|q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$$

(连续版: $D_{\text{KL}}(p\|q) = \int p(x) \ln \frac{p(x)}{q(x)} dx$)

约定: 若 $p(x) > 0$ 但 $q(x) = 0$, 则 $D_{\text{KL}} = +\infty$ (q 不能为 p 赋予零概率的点分配零质量)。

3.2 核心性质

性质 1 (非负性): $D_{\text{KL}}(p\|q) \geq 0$, 等号当且仅当 $p = q$ (几乎处处)。

性质 2 (不对称性): 一般地, $D_{\text{KL}}(p\|q) \neq D_{\text{KL}}(q\|p)$ 。

例: $p = \mathcal{N}(0, 1)$, $q = \mathcal{N}(3, 1)$:

$$D_{\text{KL}}(p\|q) = \frac{9}{2}, \quad D_{\text{KL}}(q\|p) = \frac{9}{2}$$

(此例对称是因为高斯族的特殊性; 一般不对称, 见下文 VAE 分析。)

性质 3 (不是距离): KL 散度不满足三角不等式, 也不对称, 故严格来说不是度量 (metric)。

3.3 用 Jensen 不等式证明 $D_{\text{KL}} \geq 0$

这是一条贯穿信息论与凸分析的核心证明, 值得完整理解。

关键事实: $-\ln(x)$ 是凸函数 ($(-\ln)'' = 1/x^2 > 0, x > 0$)。

证明:

$$-D_{\text{KL}}(p\|q) = -\sum_x p(x) \log \frac{p(x)}{q(x)} = \sum_x p(x) \log \frac{q(x)}{p(x)} = \mathbb{E}_p \left[\log \frac{q(X)}{p(X)} \right]$$

由于 $\log$ 是凹函数，Jensen 不等式给出（对凹函数 f ， $\mathbb{E}[f(Z)] \leq f(\mathbb{E}[Z])$ ）：

$$\mathbb{E}_p \left[\log \frac{q(X)}{p(X)} \right] \leq \log \mathbb{E}_p \left[\frac{q(X)}{p(X)} \right]$$

计算期望：

$$\mathbb{E}_p \left[\frac{q(X)}{p(X)} \right] = \sum_x p(x) \cdot \frac{q(x)}{p(x)} = \sum_x q(x) = 1$$

故： $-D_{\text{KL}}(p\|q) \leq \log 1 = 0$ ，即 $D_{\text{KL}}(p\|q) \geq 0$ 。■

等号成立（ $D_{\text{KL}} = 0$ ）当且仅当 Jensen 不等式等号成立，即 $q(x)/p(x) = \text{常数}$ ，结合两者均为概率分布，得 $p = q$ 。

3.4 正向 KL vs 反向 KL

KL 散度的不对称性在变分推断中有深刻含义：

- **正向 KL** (inclusive, mean-seeking)： $D_{\text{KL}}(p\|q)$ 最小化时， q 倾向于“覆盖” p 的所有支撑（若 $p(x) > 0$ 但 $q(x) \approx 0$ ，则代价极大）。
- **反向 KL** (exclusive, mode-seeking)： $D_{\text{KL}}(q\|p)$ 最小化时， q 倾向于“集中在 p 的某个众数”（若 $q(x) > 0$ 但 $p(x) \approx 0$ ，则代价极大，故 q 会避开 p 密度低的区域）。

VAE 中优化 $D_{\text{KL}}(q_\phi(z|x)\|p(z))$ （反向 KL），这是变分推断的标准做法——对编码器分布 q_ϕ 可以直接采样，便于计算梯度。

四、交叉熵：分类损失的本质

4.1 定义与分解

交叉熵（cross-entropy）定义为：

$$H(p, q) = -\sum_x p(x) \log q(x)$$

关键分解：

$$H(p, q) = H(p) + D_{\text{KL}}(p \| q)$$

证明：

$$H(p, q) = -\sum p \log q = -\sum p \log p + \sum p \log \frac{p}{q} = H(p) + D_{\text{KL}}(p \| q)$$

由于 $D_{\text{KL}} \geq 0$ ，故 $H(p, q) \geq H(p)$ ——用 q 编码 p 产生的数据，平均码长不小于用 p 自身编码。等号当且仅当 $p = q$ 。

4.2 分类损失 = 交叉熵

设真实标签 $y \in \{1, \dots, K\}$ ，真实分布为 one-hot 向量 $p = e_y$ （第 y 个位置为 1，其余为 0），模型预测概率为 $q = \hat{y} = \text{softmax}(f_\theta(x))$ 。

$$H(p, q) = -\sum_{k=1}^K p_k \log q_k = -\log q_y = -\log \hat{y}_y$$

这正是多分类的负对数似然损失（negative log-likelihood），也叫交叉熵损失（cross-entropy loss）。

最小化交叉熵 $\Leftrightarrow$ 最大化对数似然 $\Leftrightarrow$ 最小化 **KL** 散度（因为真实分布 p 的熵 $H(p)$ 与模型无关，固定为常数）。

4.3 二元交叉熵（Binary Cross-Entropy, BCE）

对二分类（ $K = 2$ ）， $p \in \{0, 1\}$ （真实标签）， $q = \sigma(f_\theta(x)) \in (0, 1)$ （预测概率）：

$$\text{BCE} = -[y \log q + (1 - y) \log(1 - q)]$$

这是逻辑回归的损失函数，结合 sigmoid 激活使梯度形式极为简洁（见 Toolkit 12）。

五、互信息：两个变量的共享信息

5.1 定义

互信息（mutual information） $I(X; Y)$ 度量随机变量 X 和 Y 之间的统计依赖程度：

$$I(X; Y) = \sum_{x, y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

5.2 三种等价表示

$$I(X;Y) = H(X) - H(X|Y) = H(Y) - H(Y|X) = H(X) + H(Y) - H(X,Y)$$

以及：

$$I(X;Y) = D_{\text{KL}}(p_{XY} \| p_X p_Y)$$

最后一个表示最深刻：互信息 = 联合分布与独立分布（乘积分布）之间的 KL 散度。 $I(X;Y) = 0$ 当且仅当 X 和 Y 独立 ($p_{XY} = p_X p_Y$)。

5.3 信息论四量关系图

$$H(X,Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$$

用 Venn 图表示：- 左圆 = $H(X)$ ；右圆 = $H(Y)$ ；- 交集 = $I(X;Y)$ （共享信息）；- 左圆去交集 = $H(X|Y)$ ；右圆去交集 = $H(Y|X)$ ；- 并集 = $H(X,Y)$ （联合熵）。

数据处理不等式（DPI）：若 $X \rightarrow Y \rightarrow Z$ 形成 Markov 链，则 $I(X;Z) \leq I(X;Y)$ ——中间处理步骤不能增加信息量。这是信息瓶颈理论的基础。

5.4 互信息在 AI 中的应用

应用	互信息的角色
决策树（互信息增益）	$I(Y; X_j) = H(Y) - H(Y X_j)$ ，选最大的特征分裂
信息瓶颈（IB）	压缩 X ：最小化 $I(Z; X)$ ，同时最大化 $I(Z; Y)$ （ Z 是压缩表示）
对比学习（SimCLR 等）	最大化 $I(z_1; z_2)$ （同一图像两个增强视角的互信息）
独立成分分析（ICA）	最小化成分之间的互信息，使提取的特征尽量独立

六、演示题：证明 $D_{\text{KL}}(p\|q) \geq 0$

题目：设 p, q 是同一离散集合 $\mathcal{X}$ 上的两个概率分布， $p(x) > 0$ 和 $q(x) > 0$ 对所有 $x \in \mathcal{X}$ 成立，用 Jensen 不等式证明 $D_{\text{KL}}(p\|q) \geq 0$ 。

第 1 步：识别凸函数结构。

$$D_{\text{KL}}(p\|q) = \sum_x p(x) \log \frac{p(x)}{q(x)} = - \sum_x p(x) \log \frac{q(x)}{p(x)}$$

将 $\frac{q(x)}{p(x)}$ 视为关于分布 p 的随机变量 $Z = q(X)/p(X)$ ，则：

$$D_{\text{KL}}(p\|q) = -\mathbb{E}_p[\log Z] = \mathbb{E}_p[-\log Z]$$

第 2 步：利用 $-\log$ 的凸性应用 **Jensen** 不等式。

函数 $\varphi(t) = -\log t$ 在 $t > 0$ 上是严格凸函数：

$$\varphi''(t) = \frac{1}{t^2} > 0$$

Jensen 不等式对凸函数 φ 成立：

$$\mathbb{E}_p[\varphi(Z)] \geq \varphi(\mathbb{E}_p[Z])$$

即：

$$\mathbb{E}_p \left[-\log \frac{q(X)}{p(X)} \right] \geq -\log \mathbb{E}_p \left[\frac{q(X)}{p(X)} \right]$$

第 3 步：计算右侧的期望。

$$\mathbb{E}_p \left[\frac{q(X)}{p(X)} \right] = \sum_x p(x) \cdot \frac{q(x)}{p(x)} = \sum_x q(x) = 1$$

故右侧 $= -\log 1 = 0$ 。

第 4 步：合并结论。

$$D_{\text{KL}}(p\|q) = \mathbb{E}_p \left[-\log \frac{q(X)}{p(X)} \right] \geq -\log 1 = 0$$

等号成立当且仅当 φ 的 Jensen 等号条件满足： $Z = q(X)/p(X)$ 为常数（即 $q(x)/p(x) = c$ 对所有 x 成立），结合 $\sum q(x) = \sum p(x) = 1$ ，得 $c = 1$ ，即 $p = q$ 。■

证明的结构总结：非负性来自三步推理——□ 写成期望形式；□ 凸函数 Jensen；□ q 是概率分布使期望 $= 1$ ， $\log 1 = 0$ 。步骤 □ 是关键，“ q 的概率之和为 1”直接给出下界是 0 而非其他值。

七、思考路标

路标 1：熵 $H(X)$ 有三种等价直觉——信息量（平均编码长度）、不确定性、平均惊讶度。香农证明：若要用二进制编码 X 的输出，每个符号平均最少需要 $H(X)$ bits（信源编码定理）。这三种直觉相互印证，选最适合当前语境的那种来理解。

路标 2: KL 散度的不对称性不是缺陷, 而是信息。 $D_{\text{KL}}(p\|q)$ 是“用 q 编码 p 的数据时额外浪费的 bits”; $D_{\text{KL}}(q\|p)$ 含义相反。在变分推断中, 选哪个方向由哪个分布可以采样决定——可采样的放在前面 (被期望的分布)。

路标 3: 交叉熵损失 $H(p, q) = H(p) + D_{\text{KL}}(p\|q)$ 的分解告诉我们: 最小化交叉熵本质上是 **最小化 KL 散度** (因为 $H(p)$ 与模型参数无关, 是常数)。这统一了最大似然估计 (MLE) 和 KL 最小化这两种看似不同的训练目标。

路标 4: 互信息 $I(X; Y) = D_{\text{KL}}(p_{XY}\|p_X p_Y)$ 揭示了“独立性”的信息论含义: 两个变量独立 $\Leftrightarrow$ 其联合分布 = 边缘分布之积 $\Leftrightarrow D_{\text{KL}} = 0 \Leftrightarrow I(X; Y) = 0$ 。互信息是最自然的非线性相关性度量, 不像 Pearson 相关系数只能检测线性依赖。

路标 5: 信息处理不等式 (DPI) $I(X; Z) \leq I(X; Y)$ ($X \rightarrow Y \rightarrow Z$ Markov 链) 是深度学习中信息瓶颈 (Information Bottleneck) 理论的核心。每一层神经网络是一个信息处理步骤, 深层网络逐层“压缩”输入信息, 保留与任务相关的部分。DPI 保证信息只会减少, 不会凭空增加。

路标 6: 均匀分布的最大熵性质有深刻的推论: 最大熵原理 (Maximum Entropy Principle) 指出, 在满足已知约束 (如均值) 的所有分布中, 选熵最大的那个——这相当于“最少主观臆断”。指数族分布 (包括正态分布、泊松分布) 都是特定约束下的最大熵分布。这也是正则化的信息论解释: 先验对应约束, 正则化损失对应 KL 散度。

八、典型应用例题

例 1: 二分类交叉熵的梯度计算

场景: 逻辑回归, $\hat{p} = \sigma(z)$, 损失 $L = -[y \log \hat{p} + (1 - y) \log(1 - \hat{p})]$, 计算 $\partial L / \partial z$ 。

推导:

$$\frac{\partial L}{\partial z} = \frac{\partial L}{\partial \hat{p}} \cdot \frac{\partial \hat{p}}{\partial z}$$

$$\frac{\partial L}{\partial \hat{p}} = -\frac{y}{\hat{p}} + \frac{1-y}{1-\hat{p}} = \frac{\hat{p}-y}{\hat{p}(1-\hat{p})}$$

$$\frac{\partial \hat{p}}{\partial z} = \sigma(z)(1 - \sigma(z)) = \hat{p}(1 - \hat{p})$$

$$\frac{\partial L}{\partial z} = \frac{\hat{p}-y}{\hat{p}(1-\hat{p})} \cdot \hat{p}(1-\hat{p}) = \hat{p}-y$$

结论: 交叉熵损失 + sigmoid 激活的组合, 使梯度形式极为简洁 = $\hat{p} - y$ (预测值与真实标签之差)。这也是为什么不使用 MSE 损失配合 sigmoid——MSE 会引入 $\hat{p}(1 - \hat{p})$ 项, 在饱和区梯度消失。

例 2：两个高斯分布之间的 KL 散度

场景：VAE 中，编码器输出 $q_\phi(z|x) = \mathcal{N}(\mu, \sigma^2 I)$ ，先验 $p(z) = \mathcal{N}(0, I)$ ，计算 $D_{\text{KL}}(q_\phi \| p)$ （一维情况）。

推导（直接代入定义）：

$$D_{\text{KL}}(\mathcal{N}(\mu, \sigma^2) \| \mathcal{N}(0, 1)) = \int \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(z-\mu)^2}{2\sigma^2}} \ln \frac{\frac{1}{\sigma} e^{-\frac{(z-\mu)^2}{2\sigma^2}}}{e^{-z^2/2}} dz$$

展开对数： $\ln \frac{1}{\sigma} - \frac{(z-\mu)^2}{2\sigma^2} + \frac{z^2}{2}$

利用 $\mathbb{E}[(Z - \mu)^2] = \sigma^2$ ， $\mathbb{E}[Z^2] = \sigma^2 + \mu^2$ ($Z \sim \mathcal{N}(\mu, \sigma^2)$)：

$$D_{\text{KL}} = -\ln \sigma - \frac{1}{2} + \frac{\sigma^2 + \mu^2}{2} = \frac{1}{2} (\mu^2 + \sigma^2 - \ln \sigma^2 - 1)$$

AI 意义：这是 VAE 损失中 KL 正则化项的闭合公式，可以直接反向传播。 $\mu \rightarrow 0$ ， $\sigma \rightarrow 1$ 时取最小值 0（编码器分布与先验重合）。

例 3：特征选择中的互信息增益

场景：文本分类中选择最具判别力的词，计算每个词 X_j 与标签 Y 的互信息：

$$I(Y; X_j) = H(Y) - H(Y|X_j)$$

设 $Y \in \{+1, -1\}$ ， $P(Y = +1) = 0.6$ ， $H(Y) = -0.6 \log_2 0.6 - 0.4 \log_2 0.4 \approx 0.971$ bits。

设词 X_j 出现 ($X_j = 1$) 时 $P(Y = +1|X_j = 1) = 0.9$ ，不出现 ($X_j = 0$) 时 $P(Y = +1|X_j = 0) = 0.5$ ，且 $P(X_j = 1) = 0.2$ 。

$$H(Y|X_j = 1) = -0.9 \log_2 0.9 - 0.1 \log_2 0.1 \approx 0.469 \text{ bits}$$

$$H(Y|X_j = 0) = -0.5 \log_2 0.5 - 0.5 \log_2 0.5 = 1.0 \text{ bits}$$

$$H(Y|X_j) = 0.2 \times 0.469 + 0.8 \times 1.0 = 0.894 \text{ bits}$$

$$I(Y; X_j) = 0.971 - 0.894 = 0.077 \text{ bits}$$

该词每次出现平均提供 0.077 bits 的标签信息。选取互信息最大的 k 个词作为特征——这是 TF-IDF 之外更有理论依据的特征选择方法。

九、自测题

第 1 题：计算以下分布的熵（以 $\log_2$ 为底，单位 bit）：(1) $P(X = 1) = 1$ （确定性分布）；(2) $P(X = 1) = P(X = 2) = 0.5$ （均匀二点分布）；(3) $P(X = 1) = 0.9, P(X = 2) = 0.1$ 。

提示：(1) $H = 0$ ；(2) $H = 1$ bit；(3) $H = -0.9 \log_2 0.9 - 0.1 \log_2 0.1 \approx 0.469$ bits。可验证 (2) > (3) > (1)，符合“均匀分布熵最大”。

第 2 题：设 $p = (0.3, 0.7)$, $q = (0.5, 0.5)$ ，计算 $D_{\text{KL}}(p\|q)$ 和 $D_{\text{KL}}(q\|p)$ ，验证不对称性。

提示： $D_{\text{KL}}(p\|q) = 0.3 \ln(0.3/0.5) + 0.7 \ln(0.7/0.5) = 0.3 \ln 0.6 + 0.7 \ln 1.4 \approx 0.3(-0.511) + 0.7(0.336) \approx -0.153 + 0.235 = 0.082$ 。 $D_{\text{KL}}(q\|p) = 0.5 \ln(0.5/0.3) + 0.5 \ln(0.5/0.7) \approx 0.5(0.511) + 0.5(-0.336) \approx 0.088$ 。两者均 ≥ 0 ，但不相等。

第 3 题：证明互信息的对称性： $I(X; Y) = I(Y; X)$ 。

提示：由定义 $I(X; Y) = D_{\text{KL}}(p_{XY} \| p_X p_Y)$ ，因为 $p_{XY} = p_{YX}$ （联合分布对称）且 $p_X p_Y = p_Y p_X$ ，故 $D_{\text{KL}}(p_{XY} \| p_X p_Y) = D_{\text{KL}}(p_{YX} \| p_Y p_X)$ ，即 $I(X; Y) = I(Y; X)$ 。或用 $I(X; Y) = H(X) + H(Y) - H(X, Y)$ 直接验证对称性。

第 4 题：在多分类问题中，为什么使用交叉熵损失而不是均方误差（MSE）？从信息论和梯度两个角度分析。

提示：信息论角度：交叉熵是最大似然估计的等价形式，有坚实的概率论基础；MSE 对概率分布没有明确的概率含义。梯度角度（见例 1）：交叉熵 + softmax 的梯度 = $\hat{p} - y$ （简洁），MSE + softmax 的梯度含 softmax 的 Jacobian，在饱和区接近零（梯度消失）。

第 5 题：信息瓶颈目标： $\min_{p(z|x)} [I(Z; X) - \beta I(Z; Y)]$ ($\beta > 0$)。解释该目标的含义，以及 β 的作用。

提示：最小化 $I(Z; X)$ 意味着 Z 尽量不保留 X 的信息（压缩）；最大化 $I(Z; Y)$ 意味着 Z 尽量保留与任务标签 Y 相关的信息（预测能力）。 β 控制两者的权衡： β 大时更重视预测（保留更多信息）， β 小时更重视压缩（如 $\beta \rightarrow 0$, Z 趋向常数）。这与 VAE 中的 β -VAE 框架对应（ $\beta > 1$ 时加强 KL 正则，鼓励隐变量解耦）。

Monte Carlo 与 MCMC

一例速记：如何估计 π ？在 $[-1, 1]^2$ 正方形内均匀撒点，统计落入单位圆内的比例，乘以 4 就是 π 的估计。这就是 Monte Carlo 方法：用随机样本的平均代替解析积分。**Monte Carlo** = 用样本均值估计期望（积分）；**MCMC** = 从复杂分布中生成样本的技术。

一、为什么需要 Monte Carlo 方法

许多概率计算在分析上无解：- 贝叶斯推断的后验分布 $p(\theta|x) \propto p(x|\theta)p(\theta)$ 的归一化常数（证据 $p(x)$ ）往往无法解析计算；- 高维积分 $\int f(x)p(x) dx$ 在维数 $d > 10$ 时，确定性数值积分（如高斯求积）遭受“维数诅咒”，

精度随维度指数下降；- 物理模拟、期权定价等领域需要高维随机过程的统计量。

Monte Carlo 方法的核心思想：用大数定律替代解析积分。当从 $p(x)$ 中抽取 N 个独立同分布样本 $\{X_i\}$ 时：

$$\hat{\mu}_N = \frac{1}{N} \sum_{i=1}^N f(X_i) \xrightarrow{a.s.} \mathbb{E}_p[f(X)] = \int f(x)p(x) dx$$

误差以 $O(1/\sqrt{N})$ 速率收敛（中心极限定理），与维度 d 无关——这是 Monte Carlo 对高维问题的革命性优势。

二、基础 Monte Carlo 积分

2.1 核心思想

将期望积分改写为采样均值：

$$\mu = \mathbb{E}_p[f(X)] = \int f(x) p(x) dx \approx \frac{1}{N} \sum_{i=1}^N f(X_i), \quad X_i \stackrel{i.i.d.}{\sim} p$$

误差分析：MC 估计量是无偏的 ($\mathbb{E}[\hat{\mu}_N] = \mu$)，方差为：

$$\text{Var}(\hat{\mu}_N) = \frac{\text{Var}_p[f(X)]}{N}$$

标准误 = $\sqrt{\text{Var}_p[f(X)]/N}$ ，与维数 d 无关，仅与 N 和 f 的方差有关。

2.2 直接采样的挑战

对于简单分布（均匀、正态、指数），可以用逆变换采样（inverse CDF）或 Box-Muller 方法直接生成样本。

但对于复杂分布（如贝叶斯后验、能量模型），直接采样无法实现：1. 归一化常数 $Z = \int p^*(x) dx$ 未知（只知道未归一化密度 $p^*(x)$ ）；2. 分布形状复杂（多峰、非标准族）。

这时需要间接采样方法：拒绝采样（rejection sampling）、重要性采样（importance sampling）或 MCMC。

三、拒绝采样

3.1 算法

目标：从目标分布 $p(x)$ （可能只知道到比例 $p^*(x) \propto p(x)$ ）采样。

步骤：1. 选择一个容易采样的提议分布（proposal distribution） $q(x)$ ；2. 找常数 $M \geq 1$ 使 $p(x) \leq M \cdot q(x)$ 对所有 x 成立（即 Mq “包住” p ）；3. 从 $q(x)$ 采样 x' ，再从均匀分布 $U[0, Mq(x')]$ 采样 u ；4. 若 $u \leq p(x')$ ，接受 x' ；否则拒绝，重复。

接受率： $\alpha = P(\text{接受}) = \int \frac{p(x)}{Mq(x)} q(x) dx = \frac{1}{M}$

3.2 接受率与维度诅咒

M 的最优选择是 $M^* = \max_x p(x)/q(x)$ （使包络最紧）。然而在高维空间中：

若 $p = \mathcal{N}(0, I_d)$ ， $q = \mathcal{N}(0, 2I_d)$ （提议分布略宽），则：

$$M = \max_x \frac{p(x)}{q(x)} \propto 2^{d/2}$$

接受率 $= 2^{-d/2}$ ，随维度指数下降—— $d = 100$ 时接受率约 10^{-15} ，实际上不可用。拒绝采样只适合低维分布（ $d \leq 5$ ）。

四、重要性采样

4.1 原理

当从 $p(x)$ 直接采样困难时，改用容易采样的提议分布 $q(x)$ ，并加权修正：

$$\mathbb{E}_p[f(X)] = \int f(x) p(x) dx = \int f(x) \frac{p(x)}{q(x)} q(x) dx = \mathbb{E}_q \left[f(X) \cdot \frac{p(X)}{q(X)} \right]$$

设重要性权重（importance weight） $w(x) = p(x)/q(x)$ ，则：

$$\mathbb{E}_p[f(X)] \approx \frac{1}{N} \sum_{i=1}^N w(X_i) f(X_i), \quad X_i \stackrel{i.i.d.}{\sim} q$$

4.2 自归一化重要性采样

当 $p(x)$ 只知道到比例（ $p(x) = p^*(x)/Z$ ， Z 未知）时，用自归一化形式：

$$\mathbb{E}_p[f(X)] \approx \frac{\sum_{i=1}^N \tilde{w}_i f(X_i)}{\sum_{i=1}^N \tilde{w}_i}, \quad \tilde{w}_i = \frac{p^*(X_i)}{q(X_i)}$$

（分子分母的 Z 约掉）

4.3 有效样本量

重要性权重的方差反映样本效率：

$$\text{ESS} = \frac{(\sum w_i)^2}{\sum w_i^2}$$

ESS 越接近 N ， q 与 p 越相似，估计效率越高。若权重极度不均匀（一两个样本主导），ESS 可能远小于 N ，估计不可靠。

五、MCMC：马尔可夫链 Monte Carlo

5.1 核心思想

MCMC 的思路：构造一条以目标分布 $p(x)$ 为平稳分布的马尔可夫链 $\{X_0, X_1, X_2, \dots\}$ ，经过足够长时间（burn-in 期）后，链上的样本近似于从 $p(x)$ 中独立采样。

马尔可夫链的平稳分布条件——详细平衡方程（detailed balance）：

$$p(x) T(x'|x) = p(x') T(x|x')$$

其中 $T(x'|x)$ 是转移核。满足详细平衡的转移核以 p 为平稳分布。

MCMC 的优势：只需知道未归一化密度 $p^*(x)$ （比值中 Z 约掉），适合高维复杂分布。

5.2 Metropolis-Hastings 算法

MH 算法是 MCMC 方法族的核心，通过接受-拒绝机制保证详细平衡：

算法：设当前状态为 x ，

1. 从提议分布 $q(x'|x)$ 采样候选点 x' ；
2. 计算接受率：

$$\alpha(x, x') = \min\left(1, \frac{p(x') q(x|x')}{p(x) q(x'|x)}\right)$$

3. 以概率 α 接受（令 $X_{t+1} = x'$ ），以概率 $1 - \alpha$ 拒绝（令 $X_{t+1} = x$ ）。

为何接受率保证详细平衡？设 $p(x')q(x|x') \leq p(x)q(x'|x)$ （即候选点“比当前点差”），此时 $\alpha = p(x')q(x|x')/[p(x)q(x'|x)]$ 。验证：

$$p(x) q(x'|x) \alpha(x, x') = p(x) q(x'|x) \frac{p(x') q(x|x')}{p(x) q(x'|x)} = p(x') q(x|x') \cdot 1 = p(x') q(x|x') \alpha(x', x)$$

(后者接受率为 1) ——详细平衡满足。■

特殊情形: - **Random Walk MH**: $q(x'|x) = q(|x' - x|)$ (对称提议), 接受率简化为 $\alpha = \min(1, p(x')/p(x))$; - **独立 MH**: $q(x'|x) = q(x')$ (与当前状态无关), 退化为重要性采样的变体。

5.3 Gibbs 采样

Gibbs 采样是 MH 的特殊情形, 适合高维分布中条件分布已知的情況:

算法: 设 $x = (x_1, \dots, x_d)$, 循环更新每一维:

$$x_j^{(t+1)} \sim p(x_j \mid x_1^{(t+1)}, \dots, x_{j-1}^{(t+1)}, x_{j+1}^{(t)}, \dots, x_d^{(t)})$$

即每次固定其他维度, 从条件分布中采样当前维度。

特点: - 接受率恒为 1 (每步必接受), 无需计算 α ; - 要求所有条件分布 $p(x_j | \mathbf{x}_{-j})$ 可以解析求解并采样; - 在贝叶斯层次模型 (如 LDA 主题模型、高斯混合模型的 EM) 中广泛应用。

Gibbs 与 MH 的关系: Gibbs 采样的转移核满足详细平衡, 本质上是以条件分布为提议、接受率为 1 的特殊 MH 步骤。

5.4 MCMC 的实践要点

Burn-in (预热期): 链初始时远离平稳分布, 需丢弃前 B 个样本 (通常 $B = 10\% - 50\%$ 的迭代次数)。

混合性 (Mixing): 链遍历整个目标分布支撑的速度。诊断方法: - 轨迹图 (trace plot): 样本应像“毛毛虫”, 上下随机波动而非“卡住”; - $\hat{R}$ (Gelman-Rubin 统计量): 多条并行链的方差比, $\hat{R} \approx 1$ 表明已混合。

自相关性: MCMC 样本不是独立的。有效样本量 $ESS = N/\tau$, 其中 τ 是积分自相关时间。

六、演示题: MH 采样 $N(0, 1)$, 手算第一步接受率

题目: 用 Random Walk Metropolis-Hastings 从目标分布 $p(x) = \frac{1}{\sqrt{2\pi}}e^{-x^2/2}$ (标准正态) 采样。提议分布为 $q(x'|x) = \mathcal{N}(x, 1)$ (以当前点为中心的正态步)。

设当前状态 $x = 2.0$, 提议步 $x' = 0.5$ (从 $\mathcal{N}(2, 1)$ 中抽到的), 手算接受率 $\alpha(x, x')$ 。

第 1 步: 识别结构。

提议分布 $q(x'|x) = \mathcal{N}(x, 1)$ 是对称的: $q(x'|x) = q(x|x')$ (两者都是以对方为中心的 $\mathcal{N}(\cdot, 1)$, 且 $|x' - x| = 1.5$ 相同)。

对称提议的 MH 接受率简化为：

$$\alpha = \min\left(1, \frac{p(x')}{p(x)}\right)$$

第 2 步：计算密度比。

$$\frac{p(x')}{p(x)} = \frac{e^{-x'^2/2}}{e^{-x^2/2}} = e^{-(x'^2-x^2)/2}$$

代入 $x = 2.0$, $x' = 0.5$ ：

$$x'^2 - x^2 = 0.25 - 4.0 = -3.75$$

$$\frac{p(x')}{p(x)} = e^{-(-3.75)/2} = e^{1.875} \approx 6.52$$

第 3 步：计算接受率。

$$\alpha = \min(1, 6.52) = 1$$

结论：以概率 1 接受 $x' = 0.5$ 。

第 4 步：理解直觉。

当前点 $x = 2.0$ 处于目标分布 $N(0, 1)$ 的尾部（密度较低），候选点 $x' = 0.5$ 更靠近中心（密度较高）。密度比 > 1 ，新点“更好”，必然接受。

反向情形：若候选点 $x' = 3.0$ （比 $x = 2.0$ 更往尾部走），则 $p(x')/p(x) = e^{-(9-4)/2} = e^{-2.5} \approx 0.082$ ，以 8.2% 的概率接受（偶尔允许“爬坡”，避免链卡在局部高密度区域）。

这正是 **MH** 算法的精妙之处：高密度区域必然接受，低密度区域有一定概率接受——链既向目标分布集中，又保持探索能力。

七、思考路标

路标 1：Monte Carlo 的误差 $O(1/\sqrt{N})$ 与维度无关，这是其相对于数值积分（如辛普森规则，误差 $O(N^{-4/d})$ ）在高维的核心优势。 $d = 10$ ：数值积分需要 $N \approx 10^{10/4} \approx 177$ 个节点才能达到 $1/N$ 精度；MC 需要 $N = 10^4$ 个样本达到 $1/100$ 精度——高维下 MC 碾压性胜出。

路标 2：拒绝采样的接受率随维度指数衰减（ $\leq (c/M)^d$, $c < M$ ），本质原因是“高维空间的体积集中在球壳而非球心”——提议分布无法在整个支撑上紧包住目标分布。这也是为什么流形学习、归一化流等方法要在变换后的低维流形上操作，而不是在原始高维空间采样。

路标 3: MCMC 中“只知道未归一化密度 $p^*(x) = Z \cdot p(x)$ ”的条件至关重要。接受率 $\alpha = \min(1, p^*(x')/p^*(x))$, 比值中 Z 约掉——MCMC 完全不需要计算归一化常数 Z (贝叶斯推断中的“证据”), 这正是 MCMC 主宰贝叶斯计算的原因。

路标 4: MH 的详细平衡条件 $p(x)T(x'|x) = p(x')T(x|x')$ 是充分但非必要条件。满足详细平衡的链必然以 p 为平稳分布 (但不一定遍历性)。Gibbs 采样满足详细平衡, 接受率为 1, 但需要条件分布可解析。

路标 5: 步长 (Random Walk MH 中的方差 σ^2) 的选择是 MH 的关键调参。步长太大: 候选点常落在低密度区, 拒绝率高, 链“原地踏步”; 步长太小: 每步移动微小, 需要大量步骤探索, 混合慢。理论最优目标接受率约为 0.234 (在高维 Random Walk MH 中), 可用此指导调参。

路标 6: 现代概率推断框架 (如 Stan、PyMC) 使用 **HMC** (Hamiltonian Monte Carlo) 和 **NUTS** (No-U-Turn Sampler) 替代简单 MH。HMC 利用梯度信息 (目标分布的对数密度梯度) 做“物理模拟”, 能在高维空间中以大步长高效移动而不降低接受率——是当前贝叶斯统计的生产工具。

路标 7: MCMC 样本的自相关性 (序列相关) 是与直接 MC 的根本区别。有效样本量 $ESS = N/\tau$ (τ 是积分自相关时间) 往往远小于 N ——这就是为什么 MCMC 实践中需要运行数万步, 而直接采样只需数百个独立样本。

八、典型应用例题

例 1: 贝叶斯推断中的 MCMC

场景: 逻辑回归的贝叶斯版本。设参数先验 $p(\theta) = \mathcal{N}(0, \sigma_0^2 I)$, 似然 $p(y|X, \theta) = \prod_i \sigma(y_i f_\theta(x_i))$, 后验 $p(\theta|X, y) \propto p(y|X, \theta)p(\theta)$ 没有闭合形式。

MH 方案:

- 提议: $q(\theta'|\theta) = \mathcal{N}(\theta, \epsilon^2 I)$ (Random Walk);
- 接受率: $\alpha = \min\left(1, \frac{p(y|X, \theta')p(\theta')}{p(y|X, \theta)p(\theta)}\right)$

(比值中归一化常数约掉。)

输出: 后验样本 $\{\theta_1, \dots, \theta_N\}$, 可用于预测不确定性估计 (预测分布 $p(y^*|x^*) \approx \frac{1}{N} \sum_i p(y^*|x^*, \theta_i)$)。

例 2: 估计 π 的 Monte Carlo 方法

场景: 向 $[-1, 1]^2$ 均匀撒 $N = 10^6$ 个点, 统计落入单位圆 ($x^2 + y^2 \leq 1$) 内的比例 $\hat{p}$:

$$\hat{\pi} = 4\hat{p} = 4 \cdot \frac{\#\{x_i^2 + y_i^2 \leq 1\}}{N}$$

误差分析: $\hat{p}$ 是比例估计量, 方差 $p(1-p)/N$, 其中 $p = \pi/4$ 。95% 置信区间宽度约 $2 \times 1.96 \sqrt{p(1-p)/N} \approx 1.96/\sqrt{N}$ (以 $p \approx 0.785$ 计), $N = 10^6$ 时宽约 0.002, 故 $\hat{\pi}$ 精确到小数点后两到三位。

例 3: 变分推断 vs MCMC

场景: 两种方法都可以近似后验 $p(\theta|x)$ 。

	变分推断 (VI)	MCMC
方法	用参数族 q_ϕ 近似 p , 最小化 KL	用马尔可夫链生成近似样本
精度	近似 (受参数族限制)	渐近精确 ($N \rightarrow \infty$)
速度	快 (可与 SGD 结合, 适合大数据)	慢 (尤其是高维、多峰)
不确定性	可能低估后验方差 (mean-field 假设)	正确 (充分混合时)
适用场景	大规模深度学习 (VAE、贝叶斯神经网络)	小到中规模精确推断 (Stan)

现代做法: 黑盒变分推断 (BBVI) 用重参数化技巧 ($z = \mu + \sigma\epsilon$, $\epsilon \sim \mathcal{N}(0, 1)$) 使 ELBO 关于 ϕ 可微, 用 SGD 最优化——把变分推断的效率与自动微分框架结合。

九、自测题

第 1 题: 用 Monte Carlo 估计 $I = \int_0^1 e^{-x^2} dx$ 。设计采样方案, 写出估计量, 并说明理论标准误与样本量 N 的关系。

提示: $X_i \stackrel{i.i.d.}{\sim} U[0, 1]$, $\hat{I} = \frac{1}{N} \sum_{i=1}^N e^{-X_i^2}$ ($f(x) = e^{-x^2}$, $p(x) = 1$)。方差 $\text{Var}[e^{-X^2}] = \mathbb{E}[e^{-2X^2}] - (\mathbb{E}[e^{-X^2}])^2 \approx 0.541 - 0.747^2 \approx 0.0427$ 。标准误 $= \sqrt{0.0427/N}$; $N = 10^4$ 时标准误 ≈ 0.00207 。

第 2 题: 拒绝采样中, 目标分布 $p(x) = \frac{3}{2}(1-x^2)$ ($x \in [0, 1]$), 提议分布 $q(x) = 1$ (均匀分布)。找 M 的最小值, 计算接受率, 并描述算法流程。

提示: $M = \max_{x \in [0, 1]} p(x)/q(x) = \max \frac{3}{2}(1-x^2) = \frac{3}{2}$ (在 $x = 0$ 处取到)。接受率 $= 1/M = 2/3$ 。
流程: 从 $U[0, 1]$ 采样 x' , 从 $U[0, M \cdot q(x')] = U[0, 3/2]$ 采样 u ; 若 $u \leq p(x') = \frac{3}{2}(1-x'^2)$ 则接受。

第 3 题: 在 MH 算法中, 若提议分布 $q(x'|x) = q(x'|x)$ (一般非对称), 写出接受率公式, 并解释为什么需要 $q(x|x')$ (“反向提议”) 这一项。

提示: $\alpha = \min\left(1, \frac{p(x')q(x|x')}{p(x)q(x'|x)}\right)$ 。反向提议 $q(x|x')$ 的作用: 修正”从 x 提议 x' ”和”从 x' 提议 x ”的概率不同所带来的偏差。若不加修正 (接受率只用 $p(x')/p(x)$), 链的平稳分布会偏离 p (若 q 总倾向于从当前点向某方向跳, 链会在该方向积累过多样本)。

第 4 题: 解释 Gibbs 采样为什么是 MH 的特例, 以及它的接受率为何恒为 1。

提示: Gibbs 采样更新第 j 维时, 提议分布为条件分布 $q(x'_j|x) = p(x'_j|\mathbf{x}_{-j})$, 代入 MH 接受率:
 $\frac{p(\mathbf{x}_{-j}, x'_j) q(x_j|\mathbf{x}_{-j})}{p(\mathbf{x}_{-j}, x_j) q(x'_j|\mathbf{x}_{-j})} = \frac{p(\mathbf{x}_{-j}, x'_j) p(x_j|\mathbf{x}_{-j})}{p(\mathbf{x}_{-j}, x_j) p(x'_j|\mathbf{x}_{-j})}$ 。利用 $p(x_j|\mathbf{x}_{-j}) = p(\mathbf{x})/p(\mathbf{x}_{-j})$, 分子 $= p(\mathbf{x}_{-j}, x'_j) p(\mathbf{x})/[p(\mathbf{x}_{-j}) p(x'_j)]$,

与分母之比恰好为 1。故接受率为 $\min(1, 1) = 1$ 。

第 5 题：重要性采样的有效样本量 $(\text{ESS}) = (\sum w_i)^2 / \sum w_i^2$ 。若所有权重相等 ($w_i = c$)， $\text{ESS} = N$ （最优）；若只有一个权重非零 ($w_1 = 1$ ，其余为 0)， $\text{ESS} = 1$ （最差）。计算以下情形的 ESS： $N = 4$ ，权重为 $(0.7, 0.1, 0.1, 0.1)$ 。

提示： $\sum w_i = 1.0$ ， $\sum w_i^2 = 0.49 + 0.01 + 0.01 + 0.01 = 0.52$ 。 $\text{ESS} = 1.0^2 / 0.52 \approx 1.92$ （满分 4 分，实际仅相当于 1.92 个独立样本——因为第一个权重主导，信息集中在单个样本）。

概率论中的 AI 思维

一例速记：VAE 如何”压缩”一张图片到隐变量，再”还原”出来？编码器把图片 x 映射到隐空间的分布 $q_\phi(z|x) = \mathcal{N}(\mu_\phi(x), \sigma_\phi^2(x))$ ；解码器从分布中采样 z ，重建 $\hat{x} = p_\theta(x|z)$ 。训练目标：最大化 ELBO = 重建好 + 隐变量分布接近先验。生成式 AI = 概率分布的参数化学习：编码器建分布，解码器从分布生成。

一、为什么概率论是生成式 AI 的语言

判别式模型（分类器）学习 $p(y|x)$ ——给定输入预测标签。生成式模型学习 $p(x)$ 或 $p(x|y)$ ——建模数据本身的分布，然后从中采样生成新数据（图像、文本、音频）。

概率论贯穿现代生成式 AI 的每个核心模块：

模型	核心概率操作
VAE	变分推断（近似后验）+ 重参数化梯度
扩散模型	随机过程（加噪/去噪）+ 得分匹配
Normalizing Flow	变量变换公式 + Jacobian 行列式
GAN	博弈论 + JS 散度最小化
贝叶斯神经网络	参数后验 + 变分推断

理解这五类模型背后的概率机制，就能在读论文时”看穿”公式，在调参时”理解”行为。

二、ELBO 与变分推断的统一框架

2.1 变分推断的基本问题

目标：在贝叶斯模型中，给定观测数据 x ，计算隐变量 z 的后验分布：

$$p(z|x) = \frac{p(x|z)p(z)}{p(x)} = \frac{p(x|z)p(z)}{\int p(x|z)p(z)dz}$$

分母 $p(x) = \int p(x|z)p(z)dz$ 是边缘似然 (evidence)，在连续高维空间中难以精确计算——这是贝叶斯推断的根本困难。

变分推断的策略：用参数族 $\{q_\phi(z|x)\}$ 中的分布近似 $p(z|x)$ ，通过最优化 ϕ 使近似质量最高。

2.2 ELBO 的推导

最小化 $D_{\text{KL}}(q_\phi(z|x)||p(z|x))$ ，展开：

$$D_{\text{KL}}(q_\phi(z|x)||p(z|x)) = \mathbb{E}_{q_\phi} \left[\log \frac{q_\phi(z|x)}{p(z|x)} \right]$$

代入 $p(z|x) = p(x|z)p(z)/p(x)$ ：

$$= \mathbb{E}_{q_\phi} [\log q_\phi(z|x) - \log p(x|z) - \log p(z) + \log p(x)]$$

整理：

$$D_{\text{KL}}(q_\phi(z|x)||p(z|x)) = \log p(x) - \underbrace{\left[\mathbb{E}_{q_\phi} [\log p(x|z)] - D_{\text{KL}}(q_\phi(z|x)||p(z)) \right]}_{\mathcal{L}(\phi; x) \triangleq \text{ELBO}}$$

由于 KL 散度 ≥ 0 ，故：

$$\log p(x) \geq \mathcal{L}(\phi; x) = \mathbb{E}_{q_\phi} [\log p(x|z)] - D_{\text{KL}}(q_\phi(z|x)||p(z))$$

ELBO (Evidence Lower BOund) 是 $\log p(x)$ 的下界，最大化 **ELBO** $\Leftrightarrow$ 最小化 $D_{\text{KL}}(q_\phi||p(\cdot|x))$ (同时间接最大化 $\log p(x)$)。

三、VAE：隐变量生成模型

3.1 模型结构

VAE (Variational Autoencoder) 由两个神经网络组成：

- 编码器 $q_\phi(z|x)$ ：将输入 x 映射到隐变量 z 的近似后验 (参数为 ϕ)；
- 解码器 $p_\theta(x|z)$ ：从隐变量 z 重建数据 x (参数为 θ)。

先验： $p(z) = \mathcal{N}(0, I)$ （各向同性高斯）。

通常设 $q_\phi(z|x) = \mathcal{N}(\mu_\phi(x), \text{diag}(\sigma_\phi^2(x)))$ （均值和方差由编码器神经网络输出）。

3.2 ELBO 的两项分解

$$\mathcal{L}(\phi, \theta; x) = \underbrace{\mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)]}_{\text{重建损失 (负)}} - \underbrace{D_{\text{KL}}(q_\phi(z|x) \| p(z))}_{\text{KL 正则化项}}$$

- 重建项：鼓励编码再解码后能高保真重建原始输入（对应最大似然）；
- KL 项：惩罚编码器分布偏离先验 $\mathcal{N}(0, I)$ ，让隐空间平滑、连续，可以从先验采样生成新样本。

对高斯 q_ϕ ，KL 项有闭合公式（每维独立）：

$$D_{\text{KL}}(q_\phi(z|x) \| p(z)) = \frac{1}{2} \sum_{j=1}^d (\mu_j^2 + \sigma_j^2 - \ln \sigma_j^2 - 1)$$

（参见 Toolkit 10 例 2 的推导。）

3.3 重参数化技巧（Reparameterization Trick）

问题：ELBO 中含 $\mathbb{E}_{q_\phi(z|x)}[\cdot]$ ，直接求关于 ϕ 的梯度时，期望符号内含 ϕ （分布本身依赖 ϕ ），不能把梯度算子移入期望。

解决方案：将 z 的随机性与参数解耦：

$$z = \mu_\phi(x) + \sigma_\phi(x) \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I)$$

（ $\odot$ 是逐元素乘。）此时 z 是 ϵ （固定分布，与 ϕ 无关）的确定性函数，梯度可以通过 μ_ϕ 、 σ_ϕ 传到编码器参数 ϕ ：

$$\nabla_\phi \mathcal{L} = \nabla_\phi \mathbb{E}_{\epsilon \sim \mathcal{N}(0, I)}[\log p_\theta(x | \mu_\phi + \sigma_\phi \odot \epsilon)] - \nabla_\phi D_{\text{KL}}$$

期望中的梯度可以用 Monte Carlo 估计（单样本 ϵ ）：

$$\nabla_\phi \mathcal{L} \approx \nabla_\phi [\log p_\theta(x|z)] \Big|_{z=\mu_\phi + \sigma_\phi \odot \epsilon} - \nabla_\phi D_{\text{KL}}$$

重参数化的意义：让基于采样的期望变成关于参数可微——这是将贝叶斯推断与深度学习（SGD 训练）融合的关键技术。

四、扩散模型：逐步加噪与学习去噪

4.1 前向过程（加噪）

扩散模型（Diffusion Model）的前向过程定义为 T 步加噪的马尔可夫链：

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1-\beta_t}x_{t-1}, \beta_t I)$$

其中 $\{\beta_t\}$ 是噪声调度（noise schedule，从小到大）， T 步后 $x_T \approx \mathcal{N}(0, I)$ （纯噪声）。

便捷的闭合公式：定义 $\alpha_t = 1 - \beta_t$ ， $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ ，则：

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)I)$$

任意时刻 t 的含噪图像可以直接由 x_0 生成： $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon$ ， $\epsilon \sim \mathcal{N}(0, I)$ 。

4.2 反向过程（去噪）

训练一个神经网络 $p_\theta(x_{t-1}|x_t)$ 来“逆转”加噪过程：

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

训练目标（简化版，DDPM）：预测加在 x_0 上的噪声 ϵ ：

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{t, x_0, \epsilon} [\|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon, t)\|^2]$$

即让网络 ϵ_θ 从含噪图像和时间步 t 预测噪声——简洁有力。

4.3 得分匹配（Score Matching）

得分函数（score function）： $s_\theta(x, t) = \nabla_x \log p_t(x)$ （对数密度的梯度）。

ϵ_θ 与得分函数的关系： $\epsilon_\theta(x_t, t) = -\sqrt{1-\bar{\alpha}_t}s_\theta(x_t, t)$ 。

预测噪声等价于学习得分函数——生成时用 Langevin 动力学（或 ODE 求解器）沿得分方向走，从噪声走向真实数据分布。

五、Normalizing Flow：精确似然的生成模型

5.1 变量变换公式

设 $z \sim p_Z(z)$ （简单分布，如 $\mathcal{N}(0, I)$ ），通过可逆变换 $x = f(z)$ （ f 是双射），则 x 的密度：

$$p_X(x) = p_Z(f^{-1}(x)) \cdot \left| \det \frac{\partial f^{-1}}{\partial x} \right| = p_Z(z) \cdot \left| \det \frac{\partial f}{\partial z} \right|^{-1}$$

取对数：

$$\log p_X(x) = \log p_Z(z) - \log |\det J_f(z)|$$

其中 $J_f(z) = \partial f / \partial z$ 是 Jacobian 矩阵。

5.2 Normalizing Flow 的训练

叠加 K 个可逆变换 $f = f_K \circ \dots \circ f_1$ ，则：

$$\log p_X(x) = \log p_Z(z_0) - \sum_{k=1}^K \log |\det J_{f_k}(z_{k-1})|$$

训练：最大化数据的对数似然（精确计算，无需近似）。

设计挑战：Jacobian 行列式通常是 $O(d^3)$ 的运算，需要特殊网络结构使其高效可计算：- **RealNVP / GLOW**：耦合层（coupling layers）使 Jacobian 为三角矩阵，行列式 = 对角线元素之积；- **Neural ODE**：连续时间版本，Jacobian 迹替代行列式；- **Autoregressive Flow**：自回归结构使每维的条件密度可以用神经网络建模。

六、GAN：博弈论视角

6.1 min-max 博弈

GAN（Generative Adversarial Network）由生成器 $G_\theta(z)$ （ $z \sim p_Z$ ）和判别器 $D_\psi(x)$ 构成，训练目标：

$$\min_{\theta} \max_{\psi} \mathbb{E}_{x \sim p_{\text{data}}} [\log D_\psi(x)] + \mathbb{E}_{z \sim p_Z} [\log(1 - D_\psi(G_\theta(z)))]$$

最优判别器（固定 G ）： $D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_G(x)}$

将最优判别器代回目标函数，可以证明：

$$\max_{\psi} V(G, D) = -\ln 4 + 2 D_{\text{JS}}(p_{\text{data}} \| p_G)$$

其中 **JS 散度** (Jensen-Shannon divergence):

$$D_{\text{JS}}(p \| q) = \frac{1}{2} D_{\text{KL}}\left(p \left\| \frac{p+q}{2}\right.\right) + \frac{1}{2} D_{\text{KL}}\left(q \left\| \frac{p+q}{2}\right.\right)$$

JS 散度是对称的 ($D_{\text{JS}}(p \| q) = D_{\text{JS}}(q \| p)$)、有界的 ($\in [0, \ln 2]$)，是衡量分布差异的度量。

训练 G = 最小化 **JS 散度** = 让生成分布逼近真实数据分布。

6.2 原始 GAN 的问题：梯度消失与模式崩溃

梯度消失：当 p_{data} 与 p_G 支撑不重叠（高维空间中常见），JS 散度 = $\ln 2$ （常数），梯度为 0， G 无法获得有效梯度。

解决方案——**Wasserstein GAN (WGAN)**：用 Wasserstein 距离 (Earth Mover's Distance) 替代 JS 散度：

$$W(p, q) = \inf_{\gamma \in \Pi(p, q)} \mathbb{E}_{(x, y) \sim \gamma} [\|x - y\|]$$

Wasserstein 距离即使分布不重叠也提供有意义的梯度信号，且满足度量的三角不等式。

七、贝叶斯神经网络

7.1 参数后验

普通神经网络给出点估计 $\hat{\theta}$ ；贝叶斯神经网络 (BNN) 维护参数的完整后验分布 $p(\theta | D)$ ，用于不确定性量化：

$$p(\theta | D) \propto p(D | \theta) p(\theta)$$

挑战：参数维度 $d \sim 10^7 - 10^{11}$ ，精确后验不可行。

7.2 近似推断方法

变分推断 (VI)：用 $q_{\phi}(\theta)$ 近似后验，最大化 ELBO：

$$\mathcal{L}(\phi) = \mathbb{E}_{q_{\phi}} [\log p(D | \theta)] - D_{\text{KL}}(q_{\phi}(\theta) \| p(\theta))$$

通常设 $q_\phi(\theta) = \mathcal{N}(\mu, \text{diag}(\sigma^2))$ (均值场近似, 各参数独立), 用重参数化技巧梯度优化。

Laplace 近似: 在 MAP 估计 $\hat{\theta}$ 处做二阶泰勒展开, 用高斯 $\mathcal{N}(\hat{\theta}, H^{-1})$ 近似后验 (H 是负对数后验的 Hessian)。计算一次 Hessian 即可, 不需要迭代; 缺点是 Hessian 存储成本 $O(d^2)$, 大模型用低秩近似 (KFAC, subspace Laplace)。

MC Dropout: 训练时使用 Dropout, 推断时也保持 Dropout 并运行 T 次前向, 输出的方差作为不确定性估计。与变分推断等价 (Dropout 训练 = 近似变分推断, Gal & Ghahramani 2016)。

八、演示题：从 ELBO 推出”重建损失 + KL 正则”

题目：从 VAE 的 ELBO 定义出发, 完整推导”重建损失 + KL 正则”的分解：

$$\mathcal{L}(\phi, \theta; x) = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)] - D_{\text{KL}}(q_\phi(z|x) \| p(z))$$

并解释为什么最大化 ELBO 等价于同时最小化重建误差和 KL 散度。

第 1 步：从贝叶斯推断出发写 $\log p(x)$ 。

边际对数似然：

$$\log p_\theta(x) = \log \int p_\theta(x|z) p(z) dz$$

由于 $p(z)$ 是先验, 直接计算困难。引入任意分布 $q_\phi(z|x)$ (编码器), 乘以 $q_\phi/q_\phi = 1$ ：

$$\log p_\theta(x) = \log \int p_\theta(x|z) p(z) \frac{q_\phi(z|x)}{q_\phi(z|x)} dz = \log \mathbb{E}_{q_\phi(z|x)} \left[\frac{p_\theta(x|z) p(z)}{q_\phi(z|x)} \right]$$

第 2 步：用 Jensen 不等式 ($\log$ 是凹函数) 提取下界。

$$\log p_\theta(x) = \log \mathbb{E}_{q_\phi} \left[\frac{p_\theta(x|z) p(z)}{q_\phi(z|x)} \right] \geq \mathbb{E}_{q_\phi} \left[\log \frac{p_\theta(x|z) p(z)}{q_\phi(z|x)} \right]$$

右端即为 ELBO：

$$\mathcal{L} = \mathbb{E}_{q_\phi} [\log p_\theta(x|z) + \log p(z) - \log q_\phi(z|x)]$$

第 3 步：拆分为两项。

$$\mathcal{L} = \mathbb{E}_{q_\phi} [\log p_\theta(x|z)] + \mathbb{E}_{q_\phi} \left[\log \frac{p(z)}{q_\phi(z|x)} \right]$$

第二项恰好是 KL 散度的相反数：

$$\mathbb{E}_{q_\phi} \left[\log \frac{p(z)}{q_\phi(z|x)} \right] = -\mathbb{E}_{q_\phi} \left[\log \frac{q_\phi(z|x)}{p(z)} \right] = -D_{\text{KL}}(q_\phi(z|x) \| p(z))$$

故：

$$\mathcal{L}(\phi, \theta; x) = \underbrace{\mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)]}_{\text{重建项 (越大越好)}} - \underbrace{D_{\text{KL}}(q_\phi(z|x) \| p(z))}_{\text{KL 正则 (越小越好)}}$$

第 4 步：语义解释两项分别的作用。

重建项 $\mathbb{E}_{q_\phi} [\log p_\theta(x|z)]$ ：- 直觉：从编码分布 $q_\phi(z|x)$ 中采样 z ，然后解码器重建 x 的对数概率，期望越大越好；- 若解码器输出高斯分布（方差固定），则 $\log p_\theta(x|z) = -\|x - \mu_\theta(z)\|^2 / (2\sigma^2) + \text{const}$ ，最大化等价于最小化均方误差（MSE）；- 若解码器输出伯努利分布（图像像素），则等价于最小化二元交叉熵。

KL 项 $D_{\text{KL}}(q_\phi(z|x) \| p(z))$ ：- 直觉：惩罚编码分布偏离先验 $\mathcal{N}(0, I)$ ；- 功能：正则化编码器，使隐空间平滑——隐空间中相邻点解码出相似的图像，可以插值和生成；- β -VAE ($\beta > 1$) 加强此项，鼓励隐变量解耦（不同维度控制不同语义属性）。

训练的张力：重建项希望编码器把每张图“精确编码” ($\sigma_\phi \rightarrow 0$ ，后验集中)，KL 项希望编码器接近先验 ($\mu_\phi \rightarrow 0, \sigma_\phi \rightarrow 1$)。两项的平衡决定 VAE 生成质量 vs 重建质量的权衡。

第 5 步：等号成立条件。

Jensen 不等式等号成立当且仅当 $\log$ 内的随机变量为常数：

$$\frac{p_\theta(x|z) p(z)}{q_\phi(z|x)} = \text{const}$$

即 $q_\phi(z|x) \propto p_\theta(x|z) p(z) = p(z|x)$ （后验）。

结论：ELBO 等于 $\log p(x)$ 当且仅当编码器 q_ϕ 精确等于真实后验 $p(z|x)$ ——ELBO 的“缺口”正好是 $D_{\text{KL}}(q_\phi \| p(\cdot|x))$ ，VAE 通过最大化 ELBO 间接最小化这个 KL 散度。

九、思考路标

路标 1：ELBO = $\log p(x) - D_{\text{KL}}(q_\phi \| p(\cdot|x))$ 这个等式是变分推断的核心。最大化 ELBO 同时做两件事：提高模型的边际似然（让数据更“可信”）+ 让近似后验更接近真实后验。理解这个等式，就理解了为什么 VAE 的训练目标是合理的。

路标 2：重参数化技巧 $z = \mu_\phi + \sigma_\phi \odot \epsilon$ ($\epsilon \sim \mathcal{N}(0, I)$) 的本质是将随机性从参数化变量中“分离”出来，让梯度可以通过确定性路径传播。这一技巧不只适用于高斯分布——任何可以表示为确定性变换（路径梯度）的分布都可以用重参数化（如 Gumbel-softmax 让离散变量可微分）。

路标 3: 扩散模型的前向加噪 $q(x_t|x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I)$ 是一个数学上极优雅的设计：直接计算任意 t 时刻的含噪图像，训练时每步独立采样 (t, ϵ) ，无需模拟完整马尔可夫链。这得益于高斯分布的链式卷积性质（两个高斯相加仍是高斯）。

路标 4: VAE（最大化 ELBO，反向 KL），Flow（精确最大似然），GAN（JS 散度）和扩散模型（去噪得分匹配）本质上都是让模型分布逼近数据分布的不同度量/策略：用不同的散度/距离，权衡计算效率与样本质量。Wasserstein GAN 换用 Wasserstein 距离，解决了原始 GAN 的梯度消失问题——这说明“选哪种散度”不是小事，直接影响训练稳定性。

路标 5: 贝叶斯神经网络的不确定性分为两类——偶然不确定性（aleatoric，数据本身的噪声，不可降低）和认知不确定性（epistemic，模型知识的不足，可以通过更多数据降低）。BNN 的后验方差主要捕捉认知不确定性，这在主动学习、异常检测、安全 AI 中至关重要。普通神经网络的 softmax 输出不是真实的不确定性度量（即使在分布外数据上也可能输出高置信度）。

路标 6: Normalizing Flow 的 Jacobian 行列式计算 $\log |\det J|$ 是设计流模型时的根本约束。自回归流利用三角 Jacobian（对角线以下为零）使行列式 = 对角线元素之积 ($O(d)$)，代价是不能并行采样（必须顺序生成每一维）。耦合层（RealNVP）牺牲表达能力换取生成和训练的并行性。这是“能力-效率”权衡的典型例子。

十、典型应用例题

例 1: VAE 的重参数化梯度计算

场景：设编码器输出 $\mu_\phi = 1.0$ ， $\sigma_\phi = 0.5$ （标量），采样 $\epsilon = 0.3$ ，则 $z = 1.0 + 0.5 \times 0.3 = 1.15$ 。

解码器输出高斯 $p_\theta(x|z) = \mathcal{N}(\mu_\theta(z), 1)$ ，设 $\mu_\theta(1.15) = 0.9$ ，真实值 $x = 1.0$ 。

重建损失（MSE 形式）： $-\log p_\theta(x|z) = \frac{(x - \mu_\theta(z))^2}{2} = \frac{(1.0 - 0.9)^2}{2} = 0.005$

KL 项（一维）： $\frac{1}{2}(\mu_\phi^2 + \sigma_\phi^2 - \ln \sigma_\phi^2 - 1) = \frac{1}{2}(1 + 0.25 - \ln 0.25 - 1) = \frac{1}{2}(0.25 + 1.386) = 0.818$

ELBO（取负，即为 loss）： $0.005 + 0.818 = 0.823$

梯度流：重建梯度 $\rightarrow \mu_\theta \rightarrow z = \mu_\phi + \sigma_\phi \epsilon \rightarrow \mu_\phi, \sigma_\phi$ （可微路径）。KL 梯度直接对 μ_ϕ, σ_ϕ 求导（闭合公式）。

例 2: 扩散模型的一步训练

场景： $T = 1000$ ， $\bar{\alpha}_{500} = 0.1$ （第 500 步）。给定清晰图像 x_0 （取值 0.8），采样 $\epsilon = 1.2$ （从 $\mathcal{N}(0, 1)$ ）。

含噪图像： $x_{500} = \sqrt{0.1} \times 0.8 + \sqrt{0.9} \times 1.2 = 0.253 + 1.138 = 1.391$

训练目标：网络 $\epsilon_\theta(x_{500}, 500)$ 应输出 1.2（还原原始噪声）。

损失： $\|\epsilon - \epsilon_\theta(x_{500}, 500)\|^2 = (1.2 - \hat{\epsilon}_\theta)^2$

直觉： $\bar{\alpha}_{500} = 0.1$ 说明第 500 步已非常嘈杂（原始信号占比 $\sqrt{0.1} \approx 31.6\%$ ，噪声占比 $\sqrt{0.9} \approx 94.9\%$ ），网络此时主要学习“从噪声中辨认原始信号方向”。

例 3: Dropout 作为变分推断

场景：一个有 Dropout（丢弃率 $p = 0.5$ ）的两层网络，推断时运行 $T = 50$ 次前向传播，输出预测分布 $\{\hat{y}_1, \dots, \hat{y}_{50}\}$ 。

不确定性估计：- 预测均值： $\bar{y} = \frac{1}{50} \sum_{t=1}^{50} \hat{y}_t$ （点预测）- 预测方差： $\text{Var}(\hat{y}) = \frac{1}{50} \sum_{t=1}^{50} (\hat{y}_t - \bar{y})^2$ （认知不确定性）

MC Dropout 的等价性：每次前向相当于从近似后验 $q(\theta)$ （二元混合高斯，每个权重要么正常取值要么为 0）中采样参数，输出方差近似参数后验不确定性（Gal & Ghahramani 2016）。

十一、自测题

第 1 题：写出 VAE 的完整训练目标（ELBO）的两项，并说明为什么每项都不能单独作为训练目标。

提示：只有重建项时，编码器会让 $\sigma_\phi \rightarrow 0$ （后验退化为确定性编码），失去生成多样性；只有 KL 项时，解码器无法学到有用结构（隐变量与输入无关， $q_\phi \equiv p(z) = \mathcal{N}(0, I)$ 总能使 $\text{KL} = 0$ ）。两项共同作用才能学到有意义的隐表示：KL 约束隐空间结构，重建项要求隐空间包含足够的输入信息。

第 2 题：扩散模型中，为什么前向过程设计为高斯马尔可夫链（而非其他分布），且可以写成 $x_t = \sqrt{\alpha_t}x_0 + \sqrt{1 - \alpha_t}\epsilon$ 的闭合形式？

提示：高斯分布在线性叠加下封闭（两个独立高斯之和仍是高斯），且参数可以解析追踪。具体地， $x_t = \sqrt{\alpha_t}x_{t-1} + \sqrt{1 - \alpha_t}\epsilon_t$ ，递推展开： $x_t = \sqrt{\alpha_t}x_0 + \sum_{s=1}^t \sqrt{\alpha_t/\alpha_s} \cdot \sqrt{1 - \alpha_s} \cdot \epsilon_s$ ，利用方差叠加性质简化为单个高斯，系数恰好为 $\sqrt{1 - \alpha_t}$ 。这是高斯分布“可合并性”的直接应用。

第 3 题：GAN 的判别器 $D(x)$ 在训练收敛时， $D^*(x) = p_{\text{data}}(x)/[p_{\text{data}}(x) + p_G(x)]$ 。当 $p_G = p_{\text{data}}$ 时， $D^*(x) = ?$ ，此时 JS 散度是多少？

提示： $D^* = 1/2$ （判别器完全无法区分真实与生成数据）； $D_{\text{JS}}(p_{\text{data}} \| p_G) = 0$ （两分布相同时 $\text{KL} = 0$ ，故 $\text{JS} = 0$ ）。此时对应 GAN 的“Nash 均衡”——生成器达到全局最优。

第 4 题：重参数化技巧 $z = \mu + \sigma\epsilon$ （ $\epsilon \sim \mathcal{N}(0, 1)$ ）允许梯度通过采样步骤传播。设 ELBO 的重建项（简化为一维 MSE） $L_{\text{recon}} = (x - z)^2$ ， $x = 1.0$ ， $\mu = 0.5$ ， $\sigma = 0.8$ ， $\epsilon = 1.0$ 。计算 $\partial L_{\text{recon}}/\partial \mu$ 和 $\partial L_{\text{recon}}/\partial \sigma$ 。

提示： $z = 0.5 + 0.8 \times 1.0 = 1.3$ ， $L = (1.0 - 1.3)^2 = 0.09$ 。 $\partial L/\partial z = 2(z - x) = 2(1.3 - 1.0) = 0.6$ 。
 $\partial z/\partial \mu = 1$ ， $\partial z/\partial \sigma = \epsilon = 1.0$ （重参数化关键！梯度直接通过 ϵ 传到 σ ）。 $\partial L/\partial \mu = 0.6 \times 1 = 0.6$ ，
 $\partial L/\partial \sigma = 0.6 \times 1.0 = 0.6$ 。若没有重参数化， $\partial L/\partial \sigma$ 无法计算（采样操作不可微）。

第 5 题：贝叶斯神经网络的预测不确定性分解为认知不确定性和偶然不确定性，写出回归问题中两者的数学表达式（利用全方差公式 $\text{Var}[y^*] = \mathbb{E}[\text{Var}(y^*|\theta)] + \text{Var}[\mathbb{E}(y^*|\theta)]$ ）。

提示: $\text{Var}[y^*|x^*, D] = \underbrace{\mathbb{E}_\theta[\sigma_\theta^2(x^*)]}_{\text{偶然不确定性 (数据噪声均值)}} + \underbrace{\text{Var}_\theta[\mu_\theta(x^*)]}_{\text{认知不确定性 (预测均值的方差)}}$ 。MC Dropout 在实践中近似计算后者: $\widehat{\text{Var}}_{\text{epist}} = \frac{1}{T} \sum_t \hat{y}_t^2 - \bar{y}^2$ (第二项)。偶然不确定性需要模型显式输出 $\sigma_\theta^2(x^*)$ (异方差回归)。

公式速查表 (A 扩展版)

覆盖全 24 章核心公式，按 Part 1-8 组织。每节用 markdown 表格汇总公式 + 简要说明。

Part 1 概率基础 (Ch.1-3)

1.1 概率公理 & 事件运算

公式	说明
$0 \leq P(A) \leq 1$	概率范围
$P(\Omega) = 1$	必然事件
$P(\emptyset) = 0$	不可能事件
$P(A^c) = 1 - P(A)$	补事件
$P(A \cup B) = P(A) + P(B) - P(A \cap B)$	加法公式
$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(B \cap C) - P(A \cap C) + P(A \cap B \cap C)$	容斥原理三项
$P(\bigcup_{i=1}^n A_i) = \sum_i P(A_i) - \sum_{i < j} P(A_i \cap A_j) + \dots + (-1)^{n+1} P(A_1 \cap \dots \cap A_n)$	一般容斥原理
$A \subseteq B \Rightarrow P(A) \leq P(B)$	单调性
$P(B \setminus A) = P(B) - P(A \cap B)$	差事件
若 A_i 两两互斥, $P(\bigcup A_i) = \sum P(A_i)$	可列可加性

1.2 条件概率 & 贝叶斯

公式	说明
$P(A B) = \frac{P(A \cap B)}{P(B)}, P(B) > 0$	条件概率定义
$P(A \cap B) = P(A B) P(B) = P(B A) P(A)$	乘法公式
$P(A_1 \cap \dots \cap A_n) = P(A_1) P(A_2 A_1) \dots P(A_n A_1 \dots A_{n-1})$	链式乘法
$P(A) = \sum_{i=1}^n P(A B_i) P(B_i), \{B_i\} \text{ 完备}$	全概率公式

公式	说明
$P(B_j A) = \frac{P(A B_j) P(B_j)}{\sum_{i=1}^n P(A B_i) P(B_i)}$	贝叶斯公式
$P(A \cap B) = P(A) P(B)$	事件独立
A, B, C 独立需六条等式同时成立	多事件独立条件

1.3 古典概型 & 几何概型 & 排列组合

公式	说明
$P(A) = \frac{\text{有利基本事件数}}{\text{总基本事件数}}$	古典概型
$P(A) = \frac{A \text{ 所占测度}}{\Omega \text{ 总测度}}$	几何概型
$n! = n(n-1) \cdots 1, \quad 0! = 1$	阶乘
$A_n^k = P_n^k = \frac{n!}{(n-k)!}$	排列数
$\binom{n}{k} = C_n^k = \frac{n!}{k!(n-k)!}$	组合数
$(a+b)^n = \sum_{k=0}^n \binom{n}{k} a^k b^{n-k}$	二项式定理
$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$	帕斯卡恒等式
n 元集合的子集总数 = 2^n	子集计数
有放回取 k 个: n^k 种; 不放回取 k 个: A_n^k 种	有序采样

Part 2 随机变量 (Ch.4-6)

2.1 离散随机变量 PMF / CDF / 期望 / 方差

公式	说明
$P(X = x_i) = p_i \geq 0, \sum_i p_i = 1$	PMF 定义
$F(x) = P(X \leq x) = \sum_{x_i \leq x} p_i$	CDF (右连续阶梯函数)
$E[X] = \sum_i x_i p_i$	期望
$E[g(X)] = \sum_i g(x_i) p_i$	函数期望 (LOTUS)
$\text{Var}(X) = E[(X - \mu)^2] = E[X^2] - (E[X])^2$	方差
$\sigma = \sqrt{\text{Var}(X)}$	标准差

2.2 连续随机变量 PDF / CDF / 期望 / 方差

公式	说明
$f(x) \geq 0, \int_{-\infty}^{+\infty} f(x) dx = 1$	PDF 性质
$P(a \leq X \leq b) = \int_a^b f(x) dx$	区间概率
$P(X = a) = 0$ (连续型)	单点概率为零
$F(x) = \int_{-\infty}^x f(t) dt$	PDF $\rightarrow$ CDF
$f(x) = F'(x)$ (可微处)	CDF $\rightarrow$ PDF
$F(-\infty) = 0, F(+\infty) = 1, F$ 单调不减右连续	CDF 性质
$E[X] = \int_{-\infty}^{+\infty} x f(x) dx$	连续型期望
$E[g(X)] = \int_{-\infty}^{+\infty} g(x) f(x) dx$	LOTUS (连续)
$\text{Var}(X) = \int_{-\infty}^{+\infty} (x - \mu)^2 f(x) dx = E[X^2] - \mu^2$	连续型方差

2.3 期望 & 方差的性质

公式	说明
$E[aX + b] = aE[X] + b$	期望线性性
$E[X + Y] = E[X] + E[Y]$ (无需独立)	可加性
$E[XY] = E[X]E[Y]$ (X, Y 独立)	独立乘积期望
$\text{Var}(aX + b) = a^2 \text{Var}(X)$	方差平移不变
$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y)$	方差可加
$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$ (独立时)	独立方差可加
$E[X] = \sum_{k=1}^{\infty} P(X \geq k)$ (非负整数型)	期望尾求和
$E[X] = \int_0^{\infty} P(X > t) dt$ (非负连续型)	期望尾积分

2.4 协方差 & 相关系数

公式	说明
$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$	协方差定义
$\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$	计算公式
$\text{Cov}(X, X) = \text{Var}(X)$	自协方差
$\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y)$	线性变换
$\text{Cov}(X + Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z)$	双线性
$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$	相关系数
$-1 \leq \rho_{XY} \leq 1$	柯西-施瓦茨
X, Y 独立 $\Rightarrow \rho = 0$; 反之不成立	独立 vs 不相关

□ 提示: 不相关 ($\rho = 0$) 不等于独立, 仅当联合正态时等价。

2.5 多维联合 / 边缘 / 条件分布

公式	说明
$f_{X,Y}(x,y): f \geq 0, \iint f \, dx \, dy = 1$	联合 PDF
$f_X(x) = \int_{-\infty}^{+\infty} f_{X,Y}(x,y) \, dy$	边缘 PDF (对 y 积分)
$f_{Y X}(y x) = \frac{f_{X,Y}(x,y)}{f_X(x)}$	条件 PDF
$X \perp\!\!\!\perp Y \Leftrightarrow f_{X,Y}(x,y) = f_X(x) f_Y(y)$	独立等价条件
$f_{Y X}(y x) = f_Y(y)$ (独立时)	独立条件分布等于边缘
$E[Y X=x] = \int y f_{Y X}(y x) \, dy$	条件期望
$E[Y] = E[E[Y X]]$	全期望公式 (迭代期望)
$\text{Var}(Y) = E[\text{Var}(Y X)] + \text{Var}(E[Y X])$	全方差公式

2.6 变量变换

情景	公式
$Y = g(X)$, g 严格单调可微	$f_Y(y) = f_X(g^{-1}(y)) \cdot (g^{-1})'(y) $
$Y = g(X)$, g 非单调, 各段求和	$f_Y(y) = \sum_k f_X(x_k) \cdot (g^{-1})'(y) , x_k = g_k^{-1}(y)$
$Z = X + Y$ (独立)	$f_Z(z) = \int f_X(x) f_Y(z-x) \, dx$ (卷积)
$W = X/Y$ (独立, $Y > 0$)	$f_W(w) = \int_0^{\infty} y f_X(wy) f_Y(y) \, dy$
二维变换 $(U,V) = g(X,Y)$	$f_{U,V}(u,v) = f_{X,Y}(x,y) \cdot J ^{-1}, J = \partial(x,y)/\partial(u,v)$

2.7 特征函数 (CF)

公式	说明
$\varphi_X(t) = E[e^{itX}], t \in \mathbb{R}$	特征函数定义
$ \varphi_X(t) \leq 1, \varphi_X(0) = 1$	有界性
X, Y 独立: $\varphi_{X+Y}(t) = \varphi_X(t) \varphi_Y(t)$	独立求和
$E[X^k] = i^{-k} \varphi_X^{(k)}(0)$	矩提取
唯一性: CF 唯一确定分布	存在性不需要限制区间
连续性定理: $\varphi_{X_n}(t) \rightarrow \varphi_X(t) \Leftrightarrow X_n \xrightarrow{d} X$	依分布收敛等价于 CF 逐点收敛
标准正态: $\varphi(t) = e^{-t^2/2}$	正态 CF
Poisson(λ): $\varphi(t) = e^{\lambda(e^{it}-1)}$	Poisson CF

Part 3 分布大全 (Ch.7-9)

3.1 常见离散分布

分布	PMF	期望	方差	MGF
Bernoulli(p)	$P(X = 1) = p$	p	$p(1 - p)$	$1 - p + pe^t$
Binomial(n, p)	$\binom{n}{k} p^k (1 - p)^{n-k}$	np	$np(1 - p)$	$(1 - p + pe^t)^n$
Geometric(p)	$(1 - p)^{k-1} p, k \geq 1$	$\frac{1}{p}$	$\frac{1 - p}{p^2}$	$\frac{pe^t}{1 - (1 - p)e^t}$
NegBinom(r, p)	$\binom{k-1}{r-1} p^r (1 - p)^{k-r}$	$\frac{r}{p}$	$\frac{r(1 - p)}{p^2}$	$\left(\frac{pe^t}{1 - (1 - p)e^t} \right)^r$
Poisson(λ)	$\frac{\lambda^k e^{-\lambda}}{k!}$	λ	λ	$e^{\lambda(e^t - 1)}$
HyperGeom(N, K, n)	$\frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}$	$\frac{nK}{N}$	$\frac{nK(N-K)(N-n)}{N^2(N-1)}$	—

定理: 二项 (n, p): n 大 p 小时 $\approx$ Poisson(np); Poisson 之和仍为 Poisson: $X_1 + X_2 \sim \text{Pois}(\lambda_1 + \lambda_2)$ (独立)。几何 (p): $\min(X_1, X_2) \sim \text{Geom}(1 - (1 - p_1)(1 - p_2))$ (独立)。

□ 提示: 几何分布有两种参数化: $P(X = k) = (1 - p)^{k-1} p$ ($k \geq 1$, 首次成功试验次数) 或 $P(X = k) = (1 - p)^k p$ ($k \geq 0$, 失败次数)。两者期望相差 1, 注意区分。

3.2 常见连续分布

分布	PDF (支撑域)	期望	方差	MGF
Uniform(a, b)	$\frac{1}{b - a}, x \in [a, b]$	$\frac{a + b}{2}$	$\frac{(b - a)^2}{12}$	$\frac{e^{tb} - e^{ta}}{t(b - a)}$
Normal(μ, σ^2)	$\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	μ	σ^2	$e^{\mu t + \sigma^2 t^2 / 2}$
Exp(λ)	$\lambda e^{-\lambda x}, x \geq 0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	$\frac{\lambda}{\lambda - t}, t < \lambda$
Gamma(α, β)	$\frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, x > 0$	$\frac{\alpha}{\beta}$	$\frac{\alpha}{\beta^2}$	$\left(\frac{\beta}{\beta - t} \right)^\alpha$
Beta(α, β)	$\frac{x^{\alpha-1} (1 - x)^{\beta-1}}{B(\alpha, \beta)}, x \in (0, 1)$	$\frac{\alpha}{\alpha + \beta}$	$\frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$	—
$\chi^2(n)$	Gamma($n/2, 1/2$)	n	$2n$	$(1 - 2t)^{-n/2}$
$t(n)$	$\frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi} \Gamma(\frac{n}{2})} \left(1 + \frac{x^2}{n} \right)^{-\frac{n+1}{2}}$	$0 (n > 1)$	$\frac{n}{n-2} (n > 2)$	—

分布	PDF (支撑域)	期望	方差	MGF
$F(m, n)$	$\frac{V_1/m}{V_2/n}, V_i \sim \chi^2$	$\frac{n}{n-2} \quad (n > 2)$	复杂	—

定理 (再生性) : $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$ 独立, $\sum a_i X_i \sim \mathcal{N}(\sum a_i \mu_i, \sum a_i^2 \sigma_i^2)$ 。Gamma(α_1, β)、Gamma(α_2, β) 独立之和: Gamma($\alpha_1 + \alpha_2, \beta$)。指数 (λ) 具有无记忆性: $P(X > s + t \mid X > s) = P(X > t)$ 。

正态分布标准化: 若 $X \sim \mathcal{N}(\mu, \sigma^2)$, 则 $Z = (X - \mu)/\sigma \sim \mathcal{N}(0, 1)$, $P(a < X < b) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)$ 。

3.2b 对数正态与 Pareto

分布	参数 / PDF	期望	方差
对数正态 LogN(μ, σ^2)	$\ln X \sim \mathcal{N}(\mu, \sigma^2)$	$e^{\mu + \sigma^2/2}$	$(e^{\sigma^2} - 1)e^{2\mu + \sigma^2}$
Pareto(x_m, α)	$f(x) = \frac{\alpha x_m^\alpha}{x^{\alpha+1}}, x \geq x_m$	$\frac{\alpha x_m}{\alpha - 1} \quad (\alpha > 1)$	$\frac{\alpha x_m^2}{(\alpha - 1)^2(\alpha - 2)} \quad (\alpha > 2)$
Weibull(λ, k)	$f(x) = \frac{k}{\lambda} \left(\frac{x}{\lambda}\right)^{k-1} e^{-(x/\lambda)^k}$	$\lambda \Gamma(1 + 1/k)$	$\lambda^2 [\Gamma(1 + 2/k) - \Gamma(1 + 1/k)^2]$

3.3 三大抽样分布 (正态总体)

统计量	分布	条件
$Z_i \stackrel{iid}{\sim} \mathcal{N}(0, 1), \chi^2 = \sum_{i=1}^n Z_i^2$	$\chi^2(n)$	独立标准正态平方和
$t = Z/\sqrt{V/n}, Z \sim \mathcal{N}(0, 1), V \sim \chi^2(n), \text{独立}$	$t(n)$	Z 与卡方独立
$F = (V_1/m)/(V_2/n), V_i \sim \chi^2 \text{独立}$	$F(m, n)$	两独立卡方之比
$F(1, n) = [t(n)]^2$	关系	—
$1/F(m, n) \sim F(n, m)$	倒数关系	—

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$, $\bar{X} = \frac{1}{n} \sum X_i, S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$:

统计量	精确分布
$\bar{X}$	$\mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$
$\frac{(n-1)S^2}{\sigma^2}$	$\chi^2(n-1)$
$\frac{\bar{X} - \mu}{S/\sqrt{n}}$	$t(n-1)$

统计量	精确分布
$\bar{X}$ 与 S^2	相互独立

3.4 矩母函数 (MGF) 性质

性质	公式
定义	$M_X(t) = E[e^{tX}]$
矩提取	$M_X^{(k)}(0) = E[X^k]$
独立求和	$M_{X+Y}(t) = M_X(t) M_Y(t)$ (X, Y 独立)
线性变换	$M_{aX+b}(t) = e^{bt} M_X(at)$
唯一性定理	MGF 在某邻域存在则唯一确定分布
正态 MGF 证明 CLT	$M_{Z_n}(t) = \left[1 + \frac{t^2}{2n} + o(1/n)\right]^n \rightarrow e^{t^2/2}$

3.4b 分位数与百分位数

公式	说明
p 分位数: $F(x_p) = p$, 即 $x_p = F^{-1}(p)$	分位数定义
中位数: $x_{0.5}$, $P(X \leq x_{0.5}) \geq 0.5$	中位数
$\mathcal{N}(\mu, \sigma^2)$: $x_p = \mu + \sigma z_p$	正态分位数
$\text{Exp}(\lambda)$: $x_p = -\ln(1-p)/\lambda$	指数分位数
$\chi^2(n)$, $t(n)$, $F(m, n)$	查统计表或软件计算

3.5 特殊函数

公式	说明
$\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx$	Gamma 函数定义
$\Gamma(n) = (n-1)!$ (正整数)	阶乘联系
$\Gamma(1/2) = \sqrt{\pi}$	半整数值
$\Gamma(\alpha+1) = \alpha \Gamma(\alpha)$	递推关系
$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$	Beta 函数
$\int_{-\infty}^{+\infty} e^{-x^2} dx = \sqrt{\pi}$	高斯积分
$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-t^2/2} dt$, $\Phi(-x) = 1 - \Phi(x)$	标准正态 CDF

3.6 多元分布

分布	公式
多项分布 $\text{Multi}(n; \mathbf{p})$	$P(X_1 = k_1, \dots, X_m = k_m) = \frac{n!}{k_1! \dots k_m!} p_1^{k_1} \dots p_m^{k_m}$
多元正态 $\mathcal{N}(\mu, \Sigma)$	$f(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} \Sigma ^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^\top \Sigma^{-1}(\mathbf{x} - \mu)\right)$
Dirichlet(α)	$f(\mathbf{x}) = \frac{\Gamma(\sum_i \alpha_i)}{\prod_i \Gamma(\alpha_i)} \prod_i x_i^{\alpha_i - 1}$

Part 4 极限定理 (Ch.10–12)

4.1 概率不等式

名称	公式	条件
马尔可夫不等式	$P(X \geq a) \leq \frac{E[X]}{a}$	$a > 0, E[X] < \infty$
切比雪夫不等式	$P(X - \mu \geq k\sigma) \leq \frac{1}{k^2}$	方差存在
切比雪夫 (t 形式)	$P(X - \mu \geq t) \leq \frac{\sigma^2}{t^2}$	—
Hoeffding 单变量	$P(X - E[X] \geq t) \leq e^{-2t^2/(b-a)^2}$	$X \in [a, b]$ a.s.
Hoeffding 求和	$P(\bar{X}_n - \mu \geq t) \leq \exp\left(-\frac{2n^2 t^2}{\sum_i (b_i - a_i)^2}\right)$	$X_i \in [a_i, b_i]$
Jensen 不等式	$f(E[X]) \leq E[f(X)]$ (f 凸)	—
Cauchy-Schwarz	$(E[XY])^2 \leq E[X^2] E[Y^2]$	—

定理 (马尔可夫的推广): 对任意 $r > 0$, $P(|X| \geq a) \leq E[|X|^r]/a^r$ (矩不等式)。

4.2 大数定律

名称	结论	条件
弱大数定律 (WLLN, Chebyshev)	$\bar{X}_n \xrightarrow{P} \mu$	$E[X_i] = \mu, \text{Var}(X_i) \leq C$
弱大数定律 (Khinchine)	$\bar{X}_n \xrightarrow{P} \mu$	i.i.d., $E[X] < \infty$
强大数定律 (SLLN, Kolmogorov)	$\bar{X}_n \xrightarrow{a.s.} \mu$	i.i.d., $E[X] < \infty$

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

□ 提示: a.s. 收敛 $\Rightarrow$ 依概率收敛, 反之不成立。

4.3 中心极限定理

版本	条件	结论
Lindeberg-Lévy (经典 CLT)	i.i.d., $\mu, \sigma^2 < \infty$	$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1)$
De Moivre-Laplace	$X \sim B(n, p)$	$\frac{X - np}{\sqrt{np(1-p)}} \xrightarrow{d} \mathcal{N}(0, 1)$
Lindeberg (一般 CLT)	独立非同分布, Lindeberg 条件	$\frac{S_n - ES_n}{\sqrt{\text{Var}(S_n)}} \xrightarrow{d} \mathcal{N}(0, 1)$
Lyapunov 条件	$\exists \delta > 0: L_n(\delta) \rightarrow 0$	蕴含 Lindeberg 条件
Berry-Esseen 误差上界	i.i.d., $E[X ^3] < \infty$	$\sup_x F_n(x) - \Phi(x) \leq \frac{C E[X - \mu ^3]}{\sigma^3 \sqrt{n}}$

等价写法: $\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$; 连续性修正: $B(n, p) \approx \mathcal{N}(np, np(1-p))$, 整数 k 对应区间 $[k-0.5, k+0.5]$ 。

CLT 应用示意:

应用场景	近似公式
样本均值置信区间 (σ 已知)	$\bar{X} \pm z_{\alpha/2} \sigma / \sqrt{n}$
样本均值置信区间 (σ 未知, 大样本)	$\bar{X} \pm z_{\alpha/2} S / \sqrt{n}$ (S 代替 σ)
比例估计 $\hat{p} = X/n, X \sim B(n, p)$	$(\hat{p} - p) / \sqrt{p(1-p)/n} \xrightarrow{d} \mathcal{N}(0, 1)$
泊松近似正态: $X \sim \text{Pois}(\lambda), \lambda$ 大	$(X - \lambda) / \sqrt{\lambda} \xrightarrow{d} \mathcal{N}(0, 1)$

4.4 四种收敛类型

类型	符号	定义
几乎必然收敛	$X_n \xrightarrow{a.s.} X$	$P(\lim_{n \rightarrow \infty} X_n = X) = 1$
依概率收敛	$X_n \xrightarrow{P} X$	$\forall \varepsilon > 0: P(X_n - X > \varepsilon) \rightarrow 0$
L^p 收敛	$X_n \xrightarrow{L^p} X$	$E[X_n - X ^p] \rightarrow 0$
依分布收敛	$X_n \xrightarrow{d} X$	$F_n(x) \rightarrow F(x)$ 在 F 连续点处

收敛强度: $\text{a.s.} \Rightarrow P \Rightarrow d; L^p \Rightarrow L^q \ (p > q) \Rightarrow P \Rightarrow d$ 。

□ 提示: 依分布收敛到常数 c (即 $P(X = c) = 1$ 的退化分布) 等价于依概率收敛到 c 。这是 Slutsky 定理成立的关键原因。

4.4b 随机变量序列的其他性质

性质	说明
Borel-Cantelli 引理 I	$\sum_n P(A_n) < \infty \Rightarrow P(\limsup A_n) = 0$ (a.s. 有限次发生)
Borel-Cantelli 引理 II	A_n 独立, $\sum_n P(A_n) = \infty \Rightarrow P(\limsup A_n) = 1$ (a.s. 无限次发生)
一致可积 (UI)	$\sup_n E[X_n \mathbf{1}(X_n > M)] \rightarrow 0 \quad (M \rightarrow \infty)$
UI + 依分布收敛 $\Rightarrow L^1$ 收敛	连接分布收敛与期望收敛

4.5 Slutsky 定理 & 连续映射定理 & Delta 方法

定理	结论
Slutsky: $X_n \xrightarrow{d} X, Y_n \xrightarrow{P} c$ (常数)	$X_n + Y_n \xrightarrow{d} X + c; X_n Y_n \xrightarrow{d} cX$
CMT (连续映射定理): g 连续	$X_n \xrightarrow{d} X \Rightarrow g(X_n) \xrightarrow{d} g(X); P / \text{a.s. 类似}$
Delta 方法: $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} \mathcal{N}(0, \sigma^2), g'(\theta) \neq 0$	$\sqrt{n}(g(\hat{\theta}_n) - g(\theta)) \xrightarrow{d} \mathcal{N}(0, \sigma^2[g'(\theta)]^2)$

Part 5 统计基础 (Ch.13-15)

5.0 参数空间与统计模型

概念	定义
统计模型	$\mathcal{P} = \{P_\theta : \theta \in \Theta\}$, 参数集 Θ
可识别性	$\theta_1 \neq \theta_2 \Rightarrow P_{\theta_1} \neq P_{\theta_2}$
参数统计 vs 非参数统计	$\Theta \subset \mathbb{R}^k$ 有限维 vs $\mathcal{P}$ 为所有连续分布族
指数族	$f(x; \theta) = h(x) \exp[\eta(\theta)^\top T(x) - A(\theta)],$ $A(\theta) = \log Z(\theta)$
自然参数	$\eta = \eta(\theta)$ (可以是 θ 本身, 即自然参数化)
充分统计量 (指数族)	$T(x)$ 是自然充分统计量
均值参数	$\mu = E_\theta[T(X)] = \nabla A(\eta)$

5.1 抽样统计量 & 抽样分布

统计量	定义 / 公式
样本均值	$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
样本方差	$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ (无偏)
样本标准差	$S = \sqrt{S^2}$
k 阶样本矩	$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$
k 阶中心样本矩	$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$
顺序统计量	$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$
最小值 PDF	$f_{X_{(1)}}(x) = n [1 - F(x)]^{n-1} f(x)$
最大值 PDF	$f_{X_{(n)}}(x) = n [F(x)]^{n-1} f(x)$
经验分布	$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(X_i \leq x)$

5.1b 两正态总体参数区间估计

设 $X_i \stackrel{iid}{\sim} \mathcal{N}(\mu_1, \sigma_1^2)$, $Y_j \stackrel{iid}{\sim} \mathcal{N}(\mu_2, \sigma_2^2)$, 独立:

参数	条件	枢轴统计量	置信区间
$\mu_1 - \mu_2, \sigma_1^2, \sigma_2^2$ 已知	—	$z \equiv \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}$	$\bar{X} - \bar{Y} \pm z_{\alpha/2} \sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}$
$\mu_1 - \mu_2, \sigma_1^2 = \sigma_2^2$ 未知	方差齐	$t \sim t(n_1 + n_2 - 2)$	$\bar{X} - \bar{Y} \pm t_{\alpha/2} S_p \sqrt{1/n_1 + 1/n_2}$
σ_1^2/σ_2^2	—	$F = S_1^2/S_2^2 \sim F(n_1 - 1, n_2 - 1)$	$[S_1^2/(S_2^2 F_{1-\alpha/2}), S_1^2/(S_2^2 F_{\alpha/2})]$

5.2 Bootstrap

公式	说明
重采样: 有放回从 $\{X_1, \dots, X_n\}$ 抽 n 个	Bootstrap 样本
$\hat{\sigma}_B^2 = \frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}_b^* - \bar{\theta}^*)^2$	Bootstrap 方差估计
Bootstrap 置信区间 (百分位法): $[\hat{\theta}_{(\alpha/2)}^*, \hat{\theta}_{(1-\alpha/2)}^*]$	基于 Bootstrap 分位数

5.3 描述统计

度量	公式
样本中位数	$X_{(n/2)}$ (n 偶数取均值)

度量	公式
四分位距	$IQR = Q_3 - Q_1$
偏度	$Skew = \frac{E[(X - \mu)^3]}{\sigma^3}$
峰度	$Kurt = \frac{E[(X - \mu)^4]}{\sigma^4} - 3$ (超额峰度)
样本相关系数	$r = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2 \sum (Y_i - \bar{Y})^2}}$

5.4 充分统计量 & 因子分解定理

概念	公式 / 说明
充分统计量定义	$T(X)$ 充分 $\Leftrightarrow p(\mathbf{x} \theta)$ 中 θ 只通过 $T(\mathbf{x})$ 出现
因子分解定理 (Neyman-Fisher)	T 充分 $\Leftrightarrow f(\mathbf{x}; \theta) = g(T(\mathbf{x}), \theta) \cdot h(\mathbf{x})$
完备统计量	$E_\theta[g(T)] = 0, \forall \theta \Rightarrow g(T) = 0$ a.s.
最小充分统计量	包含于所有充分统计量中 (信息量最少的充分统计量)
指数族形式	$f(x; \theta) = h(x) \exp[\eta(\theta)T(x) - A(\theta)]$, $T(x)$ 是自然充分统计量

定理 (Rao-Blackwell): 若 $\tilde{\theta}$ 是 θ 的无偏估计, T 是充分统计量, 则 $\hat{\theta} = E[\tilde{\theta} | T]$ 满足 $\text{Var}(\hat{\theta}) \leq \text{Var}(\tilde{\theta})$, 且等号成立当且仅当 $\tilde{\theta} = \hat{\theta}$ a.s.。

定理 (Lehmann-Scheffé): 若 T 完备充分, 且 $h(T)$ 无偏, 则 $h(T)$ 是唯一的 UMVUE (一致最小方差无偏估计量)。

常见指数族与充分统计量:

分布	自然充分统计量 $T(\mathbf{x})$
正态 (μ, σ^2)	$(\sum x_i, \sum x_i^2)$
指数 (λ)	$\sum x_i$
Bernoulli (p)	$\sum x_i$ (成功次数)
Poisson (λ)	$\sum x_i$
Gamma (α, β) (α 已知)	$\sum x_i$

Part 6 参数估计 (Ch.16-18)

6.1 矩估计

公式	说明
令 $\bar{X} = E_{\theta}[X]$	一阶矩方程
令 $\frac{1}{n} \sum X_i^2 = E_{\theta}[X^2]$	二阶矩方程
p 个参数列 p 个方程, 联立求解	矩估计一般步骤
正态: $\hat{\mu} = \bar{X}, \hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$	矩估计结果 (σ^2 有偏)

6.1b 矩估计步骤示例

分布	矩方程	矩估计量
正态 $\mathcal{N}(\mu, \sigma^2)$	$\mu = \bar{X}, \sigma^2 + \mu^2 = \overline{X^2}$	$\hat{\mu} = \bar{X}, \hat{\sigma}^2 = \overline{X^2} - \bar{X}^2$
Gamma(α, β)	$\alpha/\beta = \bar{X},$ $\alpha/\beta^2 = S^2/n \cdot (n-1)/n$	$\hat{\beta} = \bar{X}/S^2, \hat{\alpha} = \bar{X}^2/S^2$
Beta(α, β)	$\mu = \bar{X}, \sigma^2 = \bar{X}(1-\bar{X})/(m+1)$	解 $\hat{\alpha}, \hat{\beta}$
Uniform(a, b)	$(a+b)/2 = \bar{X}, (b-a)^2/12 = S^2$	$\hat{a} = \bar{X} - \sqrt{3}S, \hat{b} = \bar{X} + \sqrt{3}S$

6.2 最大似然估计 (MLE)

公式	说明
$L(\theta) = \prod_{i=1}^n f(x_i; \theta)$	似然函数
$\ell(\theta) = \sum_{i=1}^n \log f(x_i; \theta)$	对数似然
$\hat{\theta}_{MLE} = \arg \max_{\theta} \ell(\theta)$	MLE 定义
似然方程: $\frac{\partial \ell}{\partial \theta} = 0$	求解条件 (内点解)
不变性: $g(\hat{\theta}_{MLE})$ 是 $g(\theta)$ 的 MLE	MLE 不变性原理
渐近正态: $\sqrt{n}(\hat{\theta}_{MLE} - \theta) \xrightarrow{d} \mathcal{N}\left(0, \frac{1}{I(\theta)}\right)$	大样本性质

常见 MLE:

分布	MLE
正态 (μ, σ^2)	$\hat{\mu} = \bar{X}, \hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$
指数 (λ)	$\hat{\lambda} = 1/\bar{X}$
Bernoulli(p)	$\hat{p} = \bar{X}$
Poisson(λ)	$\hat{\lambda} = \bar{X}$
Uniform($0, \theta$)	$\hat{\theta} = X_{(n)}$ (最大值)

6.3 Fisher 信息量 & Cramér-Rao 下界

公式	说明
$I(\theta) = E_{\theta} \left[\left(\frac{\partial \log f(X; \theta)}{\partial \theta} \right)^2 \right]$	Fisher 信息量 (score 方差)
$I(\theta) = -E_{\theta} \left[\frac{\partial^2 \log f(X; \theta)}{\partial \theta^2} \right]$	等价计算 (正则条件下)
$I_n(\theta) = n I(\theta)$ (i.i.d. 样本)	样本 Fisher 信息
$\text{Var}(\hat{\theta}) \geq \frac{1}{n I(\theta)}$ (无偏)	Cramér-Rao 下界
$\text{Var}(\hat{\theta}) \geq \frac{[g'(\theta)]^2}{n I(\theta)}$ (估计 $g(\theta)$)	一般形式

□ 提示: CR 下界只对无偏估计成立; 有偏估计可低于 CR 下界。若 MLE 的渐近方差达到 $1/(nI(\theta))$, 称该 MLE 是渐近有效的 (正则条件下恒成立)。

6.3b Fisher 信息矩阵 (多参数)

公式	说明
$\mathcal{J}(\theta)_{jk} = E \left[\frac{\partial \log f}{\partial \theta_j} \frac{\partial \log f}{\partial \theta_k} \right]$	Fisher 信息矩阵
$\mathcal{J}(\theta)_{jk} = -E \left[\frac{\partial^2 \log f}{\partial \theta_j \partial \theta_k} \right]$	等价形式 (正则条件)
CR 下界 (多参数)	$\text{Cov}(\hat{\theta}) \succeq [n\mathcal{J}(\theta)]^{-1}$ (矩阵不等号)
参数变换	$I_{g(\theta)} = (g'(\theta))^2 / I(\theta)$

6.4 估计量评价标准

标准	定义
无偏性	$E_{\theta}[\hat{\theta}] = \theta$
偏差	$\text{Bias}(\hat{\theta}) = E[\hat{\theta}] - \theta$
均方误差	$\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + [\text{Bias}(\hat{\theta})]^2$
有效性	$\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效: $\text{Var}(\hat{\theta}_1) \leq \text{Var}(\hat{\theta}_2)$ (同为无偏)
一致性	$\hat{\theta}_n \xrightarrow{P} \theta \quad (n \rightarrow \infty)$
UMVUE	最小方差无偏估计量

6.5 区间估计

参数	条件	100(1 - α)% 置信区间
μ, σ^2 已知	正态总体	$\bar{X} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$
μ, σ^2 未知	正态总体	$\bar{X} \pm t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}}$
σ^2	正态总体	$\left[\frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)}, \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)} \right]$
比例 p (大样本)	$n\hat{p} \geq 5, n(1-\hat{p}) \geq 5$	$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$
比例 p (Wilson 区间)	小样本亦适用	$\frac{\hat{p} + z^2/(2n) \pm z\sqrt{\hat{p}(1-\hat{p})/n + z^2/(4n^2)}}{1 + z^2/n},$ $z = z_{\alpha/2}$

6.6 贝叶斯估计

公式	说明
$p(\theta \mathbf{x}) \propto p(\mathbf{x} \theta) p(\theta)$	后验正比于似然 × 先验
MAP : $\hat{\theta}_{MAP} = \arg \max_{\theta} p(\theta \mathbf{x})$	后验众数
MMSE (后验均值): $\hat{\theta}_{MMSE} = E[\theta \mathbf{x}]$	最小均方误差
MAD (后验中位数): $\hat{\theta}_{MAD} = \text{median}(\theta \mathbf{x})$	最小绝对偏差

6.7 常见共轭先验

似然	共轭先验	后验	更新规则
Bernoulli/Binomial	$\text{Beta}(\alpha, \beta)$	$\text{Beta}(\alpha + k, \beta + n - k)$	k : 成功次数
Poisson(λ)	$\text{Gamma}(\alpha, \beta)$	$\text{Gamma}(\alpha + \sum x_i, \beta + n)$	—
Normal (σ^2 已知)	$\text{Normal}(\mu_0, \tau^2)$	$\text{Normal}(\tilde{\mu}, \tilde{\tau}^2)$	精度加权均值
Normal (μ 已知)	$\text{Inv-Gamma}(\alpha, \beta)$	Inv- $\text{Gamma}(\alpha + n/2, \beta + \frac{1}{2} \sum (x_i - \mu)^2)$	—
Multinomial	$\text{Dirichlet}(\alpha)$	$\text{Dirichlet}(\alpha + \mathbf{x})$	—
Exponential(λ)	$\text{Gamma}(\alpha, \beta)$	$\text{Gamma}(\alpha + n, \beta + \sum x_i)$	—

正态均值后验参数 (σ^2 已知):

$$\tilde{\tau}^2 = \frac{1}{1/\tau^2 + n/\sigma^2}, \quad \tilde{\mu} = \tilde{\tau}^2 \left(\frac{\mu_0}{\tau^2} + \frac{n\bar{x}}{\sigma^2} \right)$$

Part 7 假设检验 (Ch.19–21)

7.1 基本框架

概念	公式 / 说明
第一类错误 (α)	拒绝真 H_0 , 显著性水平
第二类错误 (β)	接受假 H_0
检验功效	$\text{Power} = 1 - \beta = P(\text{拒绝}H_0 \mid H_1 \text{真})$
p 值	假设 H_0 成立时, 观测统计量或更极端的概率
拒绝域准则	$p\text{值} < \alpha \Rightarrow \text{拒绝 } H_0$
单侧检验 (右): $H_1: \theta > \theta_0$	拒绝域 $T > c_\alpha$
单侧检验 (左): $H_1: \theta < \theta_0$	拒绝域 $T < -c_\alpha$
双侧检验: $H_1: \theta \neq \theta_0$	拒绝域 $ T > c_{\alpha/2}$
功效函数	$\beta(\theta) = P_\theta(\text{拒绝}H_0)$

定理 (Neyman-Pearson 引理): 最优势检验 (UMP) 的拒绝域形式为似然比 $\Lambda = L(\theta_1)/L(\theta_0) \geq k$ 。

7.2 广义似然比检验 (GLRT)

公式	说明
$\Lambda(\mathbf{x}) = \frac{\sup_{\theta \in \Theta} L(\theta)}{\sup_{\theta \in \Theta_0} L(\theta)}$	广义似然比
$-2 \log \Lambda(\mathbf{x}) \xrightarrow{d} \chi^2(d)$ (大样本)	Wilks 定理, $d = \dim \Theta - \dim \Theta_0$

7.3 常用参数检验

检验	条件	统计量	零分布
z 检验 (均值)	σ^2 已知, 正态/大样本	$z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$	$\mathcal{N}(0, 1)$
单样本 t 检验	σ^2 未知, 正态	$t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$	$t(n-1)$
配对 t 检验	差值 $D_i = X_i - Y_i$, 正态	$t = \frac{\bar{D} - 0}{S_D/\sqrt{n}}$	$t(n-1)$
两样本 t 检验 (方差齐)	$\sigma_1^2 = \sigma_2^2$	$t = \frac{\bar{X}_1 - \bar{X}_2}{S_p \sqrt{1/n_1 + 1/n_2}},$ $S_p^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1 + n_2 - 2}$	$t(n_1 + n_2 - 2)$
χ^2 检验 (方差)	正态	$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$	$\chi^2(n-1)$

检验	条件	统计量	零分布
F 检验 (方差比)	两正态总体	$F = S_1^2/S_2^2$	$F(n_1 - 1, n_2 - 1)$

7.4 方差分析 (ANOVA)

单因素 ANOVA, k 组, 组 i 有 n_i 个观测, 总 $N = \sum n_i$:

量	公式
组间 SS	$SS_A = \sum_i n_i (\bar{X}_i - \bar{X})^2$
组内 SS	$SS_E = \sum_i \sum_j (X_{ij} - \bar{X}_i)^2$
总 SS	$SS_T = SS_A + SS_E$
组间 MS	$MS_A = SS_A/(k - 1)$
组内 MS	$MS_E = SS_E/(N - k)$
F 统计量	$F = MS_A/MS_E \sim F(k - 1, N - k) \text{ (} H_0 \text{ 下)}$

7.5 非参数检验

检验	统计量	零分布 (大样本)
符号检验	$B^+ = \#\{D_i > 0\} \sim \text{Bin}(n', 1/2)$	—
Wilcoxon 符号秩检验	$W^+ = \sum_{D_i > 0} R_i;$ $E_0 = n'(n' + 1)/4,$ $\text{Var}_0 = n'(n' + 1)(2n' + 1)/24$	近似 $\mathcal{N}$
Mann-Whitney U 检验	$U = \sum_{i,j} \mathbf{1}(X_i > Y_j);$ $E_0 = mn/2,$ $\text{Var}_0 = mn(m + n + 1)/12$	近似 $\mathcal{N}$
Kruskal-Wallis 检验	$H = \frac{12}{N(N + 1)} \sum_i \frac{R_i^2}{n_i} - 3(N + 1)$	$\chi^2(k - 1)$
KS 检验	$D_n = \sup_x \hat{F}_n(x) - F_0(x) $	KS 分布
卡方拟合优度	$\chi^2 = \sum_i \frac{(O_i - E_i)^2}{E_i}$	$\chi^2(k - 1 - p), p$ 为估计参数数
列联表独立性	$\chi^2 = \sum_{ij} \frac{(O_{ij} - E_{ij})^2}{E_{ij}},$ $E_{ij} = R_i C_j / n$	$\chi^2((r - 1)(c - 1))$

7.6 多重检验校正

方法	控制量	公式
Bonferroni	FWER	拒绝阈值 α/m (m 次检验)

方法	控制量	公式
Holm-Bonferroni	FWER (较强功效)	步降法, 第 i 小 p 值与 $\alpha/(m-i+1)$ 比较
Benjamini-Hochberg	FDR	排序 $p_{(1)} \leq \dots \leq p_{(m)}$, 拒绝 $p_{(k)} \leq k\alpha/m$

□ 提示: Bonferroni 校正保守 (FWER 控制可能过紧); BH 方法在独立或正相关检验下控制 FDR, 功效更高。

7.7 样本量计算

情景	公式	说明
均值检验 (已知 σ)	$n = \left(\frac{(z_{\alpha/2} + z_{\beta})\sigma}{\delta} \right)^2$	δ : 最小检验差; z_{β} : 功效对应分位数
比例检验	$n = \frac{(z_{\alpha/2} + z_{\beta})^2 p_0(1-p_0)}{\delta^2}$	$\delta = p_1 - p_0$
置信区间宽度控制	$n = \left(\frac{z_{\alpha/2}\sigma}{d/2} \right)^2$	d : 期望区间宽度

Part 8 高级主题 (Ch.22-24)

8.1 信息论

公式	说明
$I(A) = -\log P(A)$	自信息 (比特/奈特)
$H(X) = -\sum_x p(x) \log p(x) = E[-\log p(X)]$	离散熵
$h(X) = -\int f(x) \log f(x) dx$	微分熵 (连续)
$H(X) \leq \log \mathcal{X} $, 等号当且仅当均匀	熵的最大值
$H(X) \geq 0$ (离散); 微分熵可为负	熵的非负性
$H(X, Y) = H(X) + H(Y X)$	链式法则
$H(Y X) = \sum_x p(x) H(Y X = x)$	条件熵
$H(Y X) \leq H(Y)$, 等号当且仅当 X, Y 独立	条件减熵
$I(X; Y) = H(X) - H(X Y) = H(Y) - H(Y X)$	互信息
$I(X; Y) = H(X) + H(Y) - H(X, Y)$	互信息等价
$I(X; Y) = D_{\text{KL}}(p(x, y) \ p(x)p(y)) \geq 0$	KL 形式
$D_{\text{KL}}(P \ Q) = \sum_x p(x) \log \frac{p(x)}{q(x)} \geq 0$	KL 散度 (非对称)

公式	说明
$D_{\text{KL}}(P \parallel Q) = 0 \Leftrightarrow P = Q \text{ a.e.}$	零条件
$H(P, Q) = -\sum_x p(x) \log q(x)$	交叉熵
$H(P, Q) = H(P) + D_{\text{KL}}(P \parallel Q)$	交叉熵分解
$f \text{ 凸} \Rightarrow f(E[X]) \leq E[f(X)]$	Jensen 不等式
$C = \max_{p(x)} I(X; Y)$ (比特/次)	信道容量
$C = \frac{1}{2} \log(1 + \text{SNR})$ (高斯信道)	Shannon-Hartley 定理

定理 (数据处理不等式): $X \rightarrow Y \rightarrow Z$ 马尔可夫链, $I(X; Z) \leq I(X; Y)$ 。处理不增加信息。

8.1b 信息论不等式体系

不等式	公式	条件
非负熵	$H(X) \geq 0$	离散
熵的次可加性	$H(X_1, \dots, X_n) \leq \sum_i H(X_i)$	等号当且仅当独立
条件减熵	$H(X Y, Z) \leq H(X Y)$	更多条件不增加不确定性
KL 非对称性	$D_{\text{KL}}(P \parallel Q) \neq D_{\text{KL}}(Q \parallel P)$ 一般成立	—
对称 KL	$D_{\text{KL}}(P \parallel Q) + D_{\text{KL}}(Q \parallel P) \geq 0$	—
Pinsker 不等式	$\ P - Q\ _1 \leq \sqrt{2D_{\text{KL}}(P \parallel Q)}$	全变差与 KL 散度联系
Fano 不等式	$H(X \hat{X}) \leq h_b(P_e) + P_e \log(\mathcal{X} - 1)$	$P_e = P(X \neq \hat{X})$

8.2 Monte Carlo 方法

公式	说明
$I = \int_a^b f(x) dx = (b - a) E_{U(a,b)}[f(X)]$	改写为期望
$\hat{I}_n = \frac{b-a}{n} \sum_{i=1}^n f(X_i), X_i \stackrel{iid}{\sim} U(a, b)$	MC 估计量
$E[\hat{I}_n] = I$ (无偏); $\text{Var}(\hat{I}_n) = \frac{(b-a)^2 \sigma_f^2}{n}$	方差
$\text{SE} = \sigma_f / \sqrt{n}$, 与维度 d 无关	维度无关收敛
$\hat{I}^{\text{IS}} = \frac{1}{n} \sum_{i=1}^n f(X_i) w(X_i), w(x) = p(x)/q(x)$	重要性采样
最优提议分布: $q^*(x) \propto f(x) p(x)$	方差最小 (理论值)
$A(x' x) = \min \left(1, \frac{\tilde{p}(x') q(x x')}{\tilde{p}(x) q(x' x)} \right)$	Metropolis-Hastings 接受率
细致平衡: $\pi(x)T(x' x) = \pi(x')T(x x')$	平稳分布充分条件
Gibbs: 轮流从 $p(x_i \mathbf{x}_{-i})$ 采样, 接受率恒为 1	Gibbs 采样
$H(\mathbf{x}, \rho) = -\log p(\mathbf{x}) + \frac{1}{2} \rho^\top M^{-1} \rho$	HMC 哈密顿量

公式	说明
Leapfrog 步: $\rho_{t+\epsilon/2} = \rho_t - \frac{\epsilon}{2} \nabla_{\mathbf{x}} \log p(\mathbf{x}_t)$, 等	HMC 积分步
自归一化重要性采样: $\hat{\mu}^{\text{SIS}} = \frac{\sum_i w_i f(X_i)}{\sum_i w_i}$	无需知道归一化常数
有效样本量 (ESS): $\text{ESS} = \frac{(\sum_i w_i)^2}{\sum_i w_i^2}$	衡量重要性权重的均匀程度

□ 提示: 重要性采样要求 q 的支撑包含 p 的支撑; q 尾部若比 p 轻则权重方差可爆炸。MCMC 中需丢弃 burn-in 样本; 链的自相关使有效样本量远小于总样本量。

8.2b 拒绝采样

公式	说明
找包络: $M q(x) \geq \tilde{p}(x), \forall x$	$\tilde{p}$ 为目标 (未归一化), q 为提议分布
生成 $X \sim q, U \sim U(0, 1)$	—
接受条件: $U \leq \frac{\tilde{p}(X)}{M q(X)}$	接受概率 = $1/M$ (最优时)
接受率 = $1/M$, 越小越低效	高维下通常不可行

8.3 概率图模型

DAG (贝叶斯网络)

公式	说明
$P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Pa}(X_i))$	DAG 联合因子分解
$X \perp\!\!\!\perp Y \mid Z \Leftrightarrow P(X, Y \mid Z) = P(X \mid Z)P(Y \mid Z)$	条件独立定义

d-分离规则 (路径 $X - m - Y$, 观测集 $\mathbf{Z}$):

结构	$m \in \mathbf{Z}$	$m \notin \mathbf{Z}$
链 $X \rightarrow m \rightarrow Y$	阻断	畅通
分叉 $X \leftarrow m \rightarrow Y$	阻断	畅通
碰撞 $X \rightarrow m \leftarrow Y$	畅通	阻断

□ 提示: 碰撞节点的方向与链/分叉相反——观测了碰撞节点反而打通路径 (解释消去效应)。

MRF (马尔可夫随机场)

公式	说明
$P(\mathbf{X}) = \frac{1}{Z} \prod_{c \in \mathcal{C}} \psi_c(\mathbf{X}_c)$	吉布斯分布, 势函数乘积
$Z = \sum_{\mathbf{x}} \prod_c \psi_c(\mathbf{x}_c)$	配分函数 (归一化常数)
Hammersley-Clifford: MRF $\Leftrightarrow$ Gibbs 分布	团势分解等价于马尔可夫性

因子图 & 信念传播

公式	说明
变量 $\rightarrow$ 因子消息: $\mu_{x \rightarrow f}(x) = \prod_{h \in \text{ne}(x) \setminus f} \mu_{h \rightarrow x}(x)$	变量节点消息
因子 $\rightarrow$ 变量消息:	因子节点消息
$\mu_{f \rightarrow x}(x) = \sum_{\sim x} f(\mathbf{X}_s) \prod_{y \in \text{ne}(f) \setminus x} \mu_{y \rightarrow f}(y)$	
边缘分布: $p(x) \propto \prod_{f \in \text{ne}(x)} \mu_{f \rightarrow x}(x)$	信念 (树形图精确)
循环信念传播 (Loopy BP)	有环图上迭代运行 BP, 近似推断, 无收敛保证

变分推断 (VI)

公式	说明
目标: $\min_{q \in \mathcal{Q}} D_{\text{KL}}(q(\mathbf{Z}) \ p(\mathbf{Z} \mathbf{X}))$	用变分族 $\mathcal{Q}$ 近似后验
ELBO: $\mathcal{L}(q) = E_q[\log p(\mathbf{X}, \mathbf{Z})] - E_q[\log q(\mathbf{Z})]$	最大化 ELBO $\Leftrightarrow$ 最小化 KL
$\log p(\mathbf{X}) = \mathcal{L}(q) + D_{\text{KL}}(q \ p(\cdot \mathbf{X})) \geq \mathcal{L}(q)$	ELBO 是证据下界
均场假设: $q(\mathbf{Z}) = \prod_i q_i(Z_i)$	各变量独立的变分族
均场更新: $\log q_j^*(Z_j) = E_{-j}[\log p(\mathbf{X}, \mathbf{Z})] + \text{const}$	坐标上升 VI (CAVI)

HMM 前向-后向算法

量	定义 / 递推
前向变量	$\alpha_t(i) = P(O_1, \dots, O_t, q_t = s_i)$
$\alpha_1(i) = \pi_i b_i(O_1)$	初始化
$\alpha_{t+1}(j) = b_j(O_{t+1}) \sum_i \alpha_t(i) a_{ij}$	递推
后向变量	$\beta_t(i) = P(O_{t+1}, \dots, O_T q_t = s_i)$
$\beta_T(i) = 1$	初始化
$\beta_t(i) = \sum_j a_{ij} b_j(O_{t+1}) \beta_{t+1}(j)$	递推
$P(\mathbf{O} \lambda) = \sum_i \alpha_T(i)$	观测序列概率
状态后验: $\gamma_t(i) = \frac{\alpha_t(i) \beta_t(i)}{\sum_j \alpha_t(j) \beta_t(j)}$	前向 $\times$ 后向

EM 算法

步骤	公式
E 步	$Q(\theta \mid \theta^{(t)}) = E_{\mathbf{Z} \mid \mathbf{X}, \theta^{(t)}}[\log p(\mathbf{X}, \mathbf{Z} \mid \theta)]$
M 步	$\theta^{(t+1)} = \arg \max_{\theta} Q(\theta \mid \theta^{(t)})$
单调性	$\log p(\mathbf{X} \mid \theta^{(t+1)}) \geq \log p(\mathbf{X} \mid \theta^{(t)})$
ELBO 分解	$\log p(\mathbf{X}) = \mathcal{L}(q, \theta) + D_{\text{KL}}(q(\mathbf{Z}) \parallel p(\mathbf{Z} \mid \mathbf{X}, \theta))$

8.4 马尔可夫链

概念	公式 / 说明
转移矩阵	$P = (p_{ij}), p_{ij} = P(X_{n+1} = j \mid X_n = i) \geq 0, \sum_j p_{ij} = 1$
n 步转移	$P^{(n)} = P^n$ (矩阵 n 次幂)
平稳分布	$\pi = \pi P$ (行向量形式); $\sum_j \pi_j = 1, \pi_j \geq 0$
细致平衡	$\pi_i p_{ij} = \pi_j p_{ji}, \forall i, j$ (可逆马尔可夫链充要条件)
遍历定理	正常返、遍历链: $\frac{1}{n} \sum_{t=0}^{n-1} f(X_t) \xrightarrow{a.s.} E_{\pi}[f(X)]$
混合时间	$t_{\text{mix}} = \min\{t : \max_x \ P^t(x, \cdot) - \pi\ _{\text{TV}} < 1/4\}$
谱隙	$\gamma = 1 - \lambda_2$ (第二大特征值), 混合时间 $\sim O(1/\gamma)$

8.5 高维统计与正则化 (扩展)

方法	目标函数	特性
Ridge (L^2)	$\ \mathbf{y} - X\beta\ _2^2 + \lambda \ \beta\ _2^2$	系数收缩, 无变量选择
Lasso (L^1)	$\ \mathbf{y} - X\beta\ _2^2 + \lambda \ \beta\ _1$	稀疏解, 自动变量选择
Elastic Net	$\ \mathbf{y} - X\beta\ _2^2 + \lambda_1 \ \beta\ _1 + \lambda_2 \ \beta\ _2^2$	兼顾分组与稀疏
MAP 角度	Ridge $\leftrightarrow$ 正态先验; Lasso $\leftrightarrow$ Laplace 先验	贝叶斯解释

附录: 常用特殊值速查

量	值
$z_{0.025} = 1.96, z_{0.05} = 1.645$	正态分位数 (双/单侧 5%)
$z_{0.005} = 2.576$	正态分位数 (双侧 1%)
$\Phi(1) = 0.8413, \Phi(2) = 0.9772, \Phi(3) = 0.9987$	标准正态 CDF

量	值
$\Gamma(1/2) = \sqrt{\pi}$, $\Gamma(1) = 1$, $\Gamma(3/2) = \sqrt{\pi}/2$	Gamma 特殊值
$e \approx 2.718$, $\ln 2 \approx 0.693$, $\log_2 e \approx 1.443$	常用常数
$\pi \approx 3.14159$, $\sqrt{2} \approx 1.414$, $\sqrt{\pi} \approx 1.772$	几何常数
$n = 1$: $t_{0.025}(1) = 12.706$; $n = 9$: $t_{0.025}(9) = 2.262$; $n \rightarrow \infty$: $\rightarrow 1.96$	t 分位数趋近正态
$\text{Gamma}(1, 1) = \text{Exp}(1)$; $\text{Gamma}(n/2, 1/2) = \chi^2(n)$; $\text{Beta}(1, 1) = U(0, 1)$	分布特殊情形
$\chi^2(1) = Z^2$, $Z \sim \mathcal{N}(0, 1)$; $\chi^2(2) = \text{Exp}(1/2)$	卡方特殊情形
二项式系数求和: $\sum_{k=0}^n \binom{n}{k} = 2^n$; $\sum_{k=0}^n (-1)^k \binom{n}{k} = 0$	恒等式

附录 B：公式记忆口诀

公式	口诀
贝叶斯公式	“后验 $\propto$ 似然 $\times$ 先验”，归一化后得后验
全概率 vs 贝叶斯	全概率”由因到果”，贝叶斯”由果推因”
切比雪夫	“距均值 k 倍标准差以外，概率不超过 $1/k^2$ ”
CLT	“i.i.d., 方差有限，标准化后趋向标准正态”
CR 下界	“无偏估计的方差不低于 Fisher 信息量的倒数”
Rao-Blackwell	“任意无偏估计条件于充分统计量，MSE 不增”
d-分离碰撞结构	“未观测碰撞阻断，观测碰撞打通”(与链/分叉相反)
EM 单调性	“每步 ELBO 不减，似然单调不减”

附录 C：易混淆公式对比

易混点	公式 A	公式 B	关键区别
方差 vs 无偏方差	$\hat{\sigma}_{MLE}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$	$S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$	分母 n vs $n - 1$
概率 vs 概率密度	$P(X = x) = p(x)$	$f(x)\Delta x \approx P(x < X < x + \Delta x)$	离散 vs 连续
KL 散度	$D_{\text{KL}}(P \parallel Q)$	$D_{\text{KL}}(Q \parallel P)$	非对称，正向/反向 KL 行为不同
MAP vs MMSE	$\arg \max p(\theta x)$	$E[\theta x]$	后验众数 vs 后验均值
依概率收敛 vs a.s. 收敛	$P(X_n - X > \varepsilon) \rightarrow 0$	$P(\lim X_n = X) = 1$	弱/强大数定律对应
条件期望 vs 边缘期望	$E[Y X = x]$ (函数)	$E[Y]$ (数)	全期望公式联系二者
充分统计量 vs 完备统计量	$f(\mathbf{x}; \theta) = g(T, \theta)h(\mathbf{x})$	$E[g(T)] = 0 \Rightarrow g = 0 \text{ a.s.}$	Rao-Blackwell vs Lehmann-Scheffé

附录 B：概率论套路模型图谱

覆盖概率论与数理统计 Part 1-8（全 24 章）共 28 个核心套路模型。每个模型含识别特征、模板步骤、速记口诀与典型例题。配合附录 A 公式表，可快速识别题型、调用解法。

Part 1 概率基础（模型 1-4）

模型 1：全概率 + 贝叶斯反推

识别特征

题目给出若干互斥完备原因组（“三种工厂”“两批货”“有病无病”），再给每种原因导致结果的条件概率，最后反问“已知结果，某原因的概率是多少”。关键词：“已知……求……的概率是”，方向与条件概率方向相反。

模板（4 步）

1. 确认划分：找到互斥完备事件组 $B_1, B_2, \dots, B_n$ ，满足 $\sum P(B_i) = 1$ 。
2. 全概率打底： $P(A) = \sum_{i=1}^n P(A | B_i)P(B_i)$ 。
3. 贝叶斯比例： $P(B_j | A) = \frac{P(A | B_j)P(B_j)}{P(A)}$ ，分子直接读出，分母已由步骤 2 算好。
4. 极端校验：若先验极端（某 B_i 概率极大），后验应向该方向偏移。

速记：「先全概率打底 → 贝叶斯取比例 → 数字代入」

例题

某工厂三条生产线产量占比 50%, 30%, 20%，次品率分别 2%, 3%, 5%。随机取到次品，求来自第三条生产线的概率。

$$P(\text{次品}) = 0.5 \times 0.02 + 0.3 \times 0.03 + 0.2 \times 0.05 = 0.01 + 0.009 + 0.01 = 0.029。P(L_3 | \text{次品}) = \frac{0.2 \times 0.05}{0.029} = \frac{0.01}{0.029} \approx 0.345。$$

章节：Ch.2（条件概率）

模型 2：古典概型 + 容斥

识别特征

样本空间有限且等可能，题目问“至少一个”“恰好 k 个”“不超过”之类事件的概率。遇到“至少一个”时优先考虑对立事件；遇到多集合重叠时用容斥。

模板 (3 步)

1. 写出样本空间总数 $|\Omega|$ (排列或组合)。
2. 计算目标事件数 $|A|$:
 - “至少一个” $\Rightarrow |A^c|$ (一个都没有) 更简单, 取补 $P(A) = 1 - P(A^c)$ 。
 - 多个重叠集合 $\Rightarrow$ 容斥: $|A \cup B| = |A| + |B| - |A \cap B|$ 。
3. $P(A) = |A|/|\Omega|$ 。

速记: 「等可能 $\rightarrow$ 数元素 $\rightarrow$ 至少取补 $\rightarrow$ 重叠容斥」

例题

从 1 到 10 随机取两个数, 求至少一个偶数的概率。

$$|\Omega| = \binom{10}{2} = 45. \text{ 两个都奇数: } \binom{5}{2} = 10. P(\text{至少一偶}) = 1 - 10/45 = 35/45 = 7/9.$$

章节: Ch.1 (随机事件)、Ch.3 (组合)

模型 3: 几何概型 (面积/长度比)

识别特征

样本空间是某个区域 (线段、平面图形、时间区间), 等可能均匀分布, 题目问满足某几何条件的子集概率。
常见词: “随机落在” “随机选取时刻” “会面问题”。

模板 (3 步)

1. 画出样本空间 (线段或平面矩形) 并标明总“测度” (长度或面积)。
2. 用不等式刻画目标区域, 在坐标系中画出该区域并算测度。
3. $P = \text{目标测度} / \text{总测度}$ (无需排列组合)。

速记: 「画坐标系 $\rightarrow$ 不等式描区域 $\rightarrow$ 测度相除」

例题

甲乙约定在 $[0, 60]$ 分钟内各自随机到达, 先到者等 20 分钟, 求相遇概率。

$$\text{样本空间: } 60 \times 60 = 3600. \text{ 不相遇条件: } |x - y| > 20, \text{ 即两个三角形面积 } 2 \times \frac{1}{2} \times 40^2 = 1600. \\ P(\text{相遇}) = 1 - 1600/3600 = 5/9.$$

章节: Ch.1 (概率定义)

模型 4：独立 vs 互斥辨析

识别特征

题目同时出现”独立”“互斥”两词，或要求判断事件关系，或用混淆的条件推导结论。这是概念陷阱题，需要明确区分两者。

核心对比

性质	独立	互斥（不相容）
定义	$P(AB) = P(A)P(B)$	$P(AB) = 0$
直觉	一方发生不影响另一方概率	两者不能同时发生
加法	$P(A \cup B) = P(A) + P(B) - P(A)P(B)$	$P(A \cup B) = P(A) + P(B)$
条件概率	$P(A B) = P(A)$	$P(A B) = 0$ （若 $P(B) > 0$ ）
能否共存	一般情况可共存	独立且互斥 $\Rightarrow$ 至少一个概率为 0

速记：「独立看乘积，互斥看交集；两者一般不能同时非零」

例题

$P(A) = 0.4, P(B) = 0.3$ ，若 A, B 互斥，问是否独立？
 $P(AB) = 0$ ，但 $P(A)P(B) = 0.12 \neq 0$ ，故不独立。

章节：Ch.1（随机事件）、Ch.2（条件概率）

Part 2 随机变量（模型 5-8）

模型 5：离散 PMF 求未知常数（归一化）

识别特征

给出离散分布律（概率质量函数），含未知参数 c （或 a, k ），要求确定参数值，或已知分布律验证是否合法。

模板（3 步）

- 列出所有概率值（含含 c 的表达式）。
- 令概率之和等于 1： $\sum_i P(X = x_i) = 1$ ，解出 c 。
- 验证：每个概率值 ≥ 0 （如果解出负值则报错）。

速记: 「列概率 $\rightarrow$ 求和等 1 $\rightarrow$ 解参数 $\rightarrow$ 非负验证」

例题

$P(X = k) = c \cdot (1/2)^k$, $k = 1, 2, 3, \dots$, 求 c 。

$$\sum_{k=1}^{\infty} c(1/2)^k = c \cdot \frac{1/2}{1 - 1/2} = c. \text{ 令 } c = 1, \text{ 即 } c = 1. \text{ (也可先算级数和为 1, 则 } c = 1.)$$

章节: Ch.4 (离散随机变量)

模型 6: 连续 PDF 函数变换 (CDF 法 / Jacobian)

识别特征

已知 X 的分布 (PDF 或 CDF), 令 $Y = g(X)$ (单调或分段单调变换), 求 Y 的分布。关键词: “令 $Y = \dots$, 求 Y 的密度”。

模板 (两路径)

路径 A: CDF 法 (通用)

1. 先求 $F_Y(y) = P(Y \leq y) = P(g(X) \leq y)$, 把不等式变换成关于 X 的不等式。
2. 用已知 F_X 表示 $F_Y(y)$ 。
3. 对 y 求导得 $f_Y(y) = F'_Y(y)$ 。

路径 B: Jacobian 法 (g 严格单调时)

1. 求反函数 $x = h(y)$, 计算 $|h'(y)|$ 。
2. $f_Y(y) = f_X(h(y)) \cdot |h'(y)|$, 注意变换后的支撑集。

速记: 「单调用 Jacobian, 非单调或绝对值用 CDF 法」

例题

$X \sim U(0, 1)$, $Y = -\ln X$, 求 Y 的密度。

$$h(y) = e^{-y}, h'(y) = -e^{-y}, |h'(y)| = e^{-y}. f_X(e^{-y}) = 1 \text{ (} 0 < e^{-y} < 1, \text{ 即 } y > 0\text{)}. f_Y(y) = e^{-y}, y > 0, \text{ 即 } Y \sim \text{Exp}(1).$$

章节: Ch.5 (连续随机变量)

模型 7: LOTUS 求 $E[g(X)]$

识别特征

题目要求计算 $E[g(X)]$, 其中 g 是非线性函数 (X^2 、 e^X 、 $|X|$ 等), 不需要先求 $g(X)$ 的分布, 直接在 X 的分布上积分/求和。

模板 (2 步)

1. 写出 LOTUS 公式:

- 离散: $E[g(X)] = \sum_i g(x_i)p_i$
- 连续: $E[g(X)] = \int_{-\infty}^{\infty} g(x)f_X(x)dx$

2. 代入 g 和 f_X (或 PMF), 直接计算积分/求和。

速记: 「不用求 Y 的分布 $\rightarrow$ 直接在 X 上积分, 权重是 f_X 」

例题

$X \sim \text{Exp}(\lambda)$, 求 $E[X^2]$ 。

$$E[X^2] = \int_0^{\infty} x^2 \lambda e^{-\lambda x} dx = \frac{2}{\lambda^2} \text{ (分部积分两次)。故 } \text{Var}(X) = 2/\lambda^2 - (1/\lambda)^2 = 1/\lambda^2。$$

章节: Ch.4 (离散)、Ch.5 (连续)

模型 8: 求边缘分布 / 条件分布

识别特征

题目给出联合分布 (PMF 或 PDF), 要求求某一变量的边缘分布, 或在另一变量取固定值时的条件分布。

模板

边缘分布

- 离散: $P(X = x) = \sum_y P(X = x, Y = y)$ (对另一变量求和)
- 连续: $f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$ (对另一变量积分)

条件分布

- $f_{Y|X}(y | x) = \frac{f(x, y)}{f_X(x)}$, 需注意 x 的支撑集 ($f_X(x) > 0$)

独立性判断: $f(x, y) = f_X(x) \cdot f_Y(y)$ (联合能分解为边缘之积)

速记: 「边缘 = 积掉另一变量; 条件 = 联合除边缘; 可分解 = 独立」

例题

$f(x, y) = 6x$ ($0 < x < y < 1$), 求 $f_X(x)$ 。

$$f_X(x) = \int_x^1 6x dy = 6x(1 - x), \quad 0 < x < 1。$$

章节: Ch.6 (多元随机变量)

Part 3 分布（模型 9–12）

模型 9：场景 → 分布识别

识别特征

题目描述一个随机试验场景，需要判断用哪个分布建模，再套参数公式。

快速对照表

场景描述	分布	参数含义
n 次独立伯努利，成功概率 p ，成功次数	$B(n, p)$	n = 试验次数, p = 成功率
无放回抽样, N 中 K 个成功, 抽 n 个	超几何 $H(N, K, n)$	有限总体
独立重复直至第一次成功, 试验次数	几何 $G(p)$	p = 成功率
单位时间/空间内事件平均发生 λ 次	Poisson(λ)	稀有事件计数
均匀分布 $[a, b]$ 上随机选点	$U(a, b)$	—
等待时间, 发生率 λ	Exp(λ)	无记忆性
自然测量值, 均值 μ , 方差 σ^2	$N(\mu, \sigma^2)$	—
k 个独立指数之和, 或 Gamma 特例	$\Gamma(k, \lambda)$	形状、速率

速记：「数次数看二项/超几何，数等待看几何/指数，数发生频次看泊松，连续无偏差看正态」

例题

某交叉路口平均每小时出现 3 次事故，求某小时内恰好发生 2 次事故的概率。

泊松分布, $\lambda = 3$ 。 $P(X = 2) = e^{-3} \cdot 3^2 / 2! = 4.5e^{-3} \approx 0.224$ 。

章节：Ch.7（离散分布）、Ch.8（连续分布）

模型 10：正态标准化算概率

识别特征

题目告知 $X \sim N(\mu, \sigma^2)$ ，要求计算区间概率 $P(a \leq X \leq b)$ 。不能直接查表，需先标准化。

模板（3 步）

1. 标准化: 令 $Z = (X - \mu)/\sigma$, 则 $Z \sim N(0, 1)$ 。
2. 转化: $P(a \leq X \leq b) = P\left(\frac{a - \mu}{\sigma} \leq Z \leq \frac{b - \mu}{\sigma}\right) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)$ 。
3. 对称性: $\Phi(-z) = 1 - \Phi(z)$; $P(|X - \mu| \leq k\sigma) = 2\Phi(k) - 1$ 。

常用值: $\Phi(1) \approx 0.841$, $\Phi(1.645) \approx 0.95$, $\Phi(1.96) \approx 0.975$, $\Phi(2.576) \approx 0.995$ 。

速记: 「减均值除标差 $\rightarrow \Phi$ 相减 $\rightarrow$ 负数翻转」

例题

$X \sim N(5, 4)$, 求 $P(3 \leq X \leq 9)$ 。

$$P = \Phi\left(\frac{9-5}{2}\right) - \Phi\left(\frac{3-5}{2}\right) = \Phi(2) - \Phi(-1) = \Phi(2) + \Phi(1) - 1 \approx 0.9772 + 0.8413 - 1 = 0.8185。$$

章节: Ch.8 (连续分布)

模型 11: 指数分布无记忆性

识别特征

指数分布 (或几何分布) 场景下, 题目问“已等待了 s 时间, 再等 t 时间的概率”, 或证明/应用无记忆性。

核心公式

$$P(X > s + t \mid X > s) = P(X > t)$$

等价地: $P(X > s + t) = P(X > s) \cdot P(X > t) = e^{-\lambda(s+t)}$ ($X \sim \text{Exp}(\lambda)$)。

常见陷阱: 正态分布无此性质; 指数是连续无记忆分布的唯一选择 (离散版为几何分布)。

速记: 「指数无记忆, 过去不影响未来; 条件概率等于无条件」

例题

某设备寿命 $X \sim \text{Exp}(1/100)$ (期望寿命 100 小时)。已知设备运行了 50 小时, 求再运行 30 小时的概率。

$$P(X > 80 \mid X > 50) = P(X > 30) = e^{-30/100} = e^{-0.3} \approx 0.741。$$

章节: Ch.8 (连续分布)

模型 12: 三大抽样分布构造

识别特征

题目出现 χ^2 、 t 、 F 分布，要求判断某统计量服从哪个分布，或用样本量、自由度写出分布参数。

构造公式速查

分布	构造方式	自由度
$\chi^2(n)$	$\sum_{i=1}^n Z_i^2, Z_i \stackrel{\text{iid}}{\sim} N(0, 1)$	n
$t(n)$	$Z/\sqrt{\chi^2(n)/n}, Z \perp \chi^2(n)$	n
$F(m, n)$	$(\chi^2(m)/m)/(\chi^2(n)/n), \text{两 } \chi^2 \text{ 独立}$	(m, n)

正态总体关键结论 ($X_i \stackrel{\text{iid}}{\sim} N(\mu, \sigma^2)$, 样本量 n):

- $\bar{X} \sim N(\mu, \sigma^2/n)$
- $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$, 且 $\bar{X}$ 与 S^2 独立
- $\frac{\bar{X}-\mu}{S/\sqrt{n}} \sim t(n-1)$ (σ 未知时用 S)

速记: 「 Z^2 叠加 $\rightarrow \chi^2$; Z 除 $\sqrt{\chi^2/n} \rightarrow t$; 两 χ^2 之比 $\rightarrow F$ 」

例题

$X_1, \dots, X_9 \stackrel{\text{iid}}{\sim} N(0, 1)$, $\bar{X}$ 为样本均值, S^2 为样本方差, 问 $\frac{\bar{X}}{S/3}$ 服从什么分布?

$$\frac{\bar{X}-0}{S/\sqrt{9}} = \frac{\bar{X}}{S/3} \sim t(8) \text{ (自由度 } n-1=8\text{)}.$$

章节: Ch.13 (抽样分布)

Part 4 极限定理 (模型 13-15)

模型 13: 切比雪夫不等式估上界

识别特征

题目只给出均值和方差 (不给具体分布), 要求估计某事件概率的上界, 或要求确定样本量使某概率不超过指定值。

公式

$$P(|X-\mu|\geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$$

等价: $P(|X - \mu| < \varepsilon) \geq 1 - \frac{\sigma^2}{\varepsilon^2}$ 。

模板 (3 步)

1. 识别 $\mu = E[X]$ 、 $\sigma^2 = \text{Var}(X)$ (可能需要用已知分布的公式计算)。
2. 确定 ε (事件偏离均值的距离)。
3. 代入公式, 得上界 (注意: 这是一个很宽松的上界)。

速记: 「只有均值方差 $\rightarrow$ 切比雪夫; 距离 ε , 上界 σ^2/ε^2 」

例题

X 有 $\mu = 50, \sigma^2 = 25$, 用切比雪夫估计 $P(|X - 50| \geq 10)$ 的上界。

$$P(|X - 50| \geq 10) \leq 25/100 = 0.25。$$

章节: Ch.10 (大数定律)

模型 14: CLT 求 $P(\sum X_i > a)$

识别特征

n 个独立同分布随机变量之和 (或均值), n 足够大 (通常 $n \geq 30$), 要求计算概率。题目常说“用中心极限定理近似”。

模板 (4 步)

1. 确认各 X_i 独立同分布, 均值 μ , 方差 σ^2 (需有限)。
2. 令 $S_n = \sum_{i=1}^n X_i$, 则 $E[S_n] = n\mu$, $\text{Var}(S_n) = n\sigma^2$ 。
3. 标准化: $Z = \frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1)$ 。
4. 用 Φ 函数计算: $P(S_n > a) = P\left(Z > \frac{a - n\mu}{\sigma\sqrt{n}}\right) = 1 - \Phi\left(\frac{a - n\mu}{\sigma\sqrt{n}}\right)$ 。

速记: 「大 n 独立同分布 $\rightarrow$ CLT $\rightarrow$ 标准化 $\rightarrow \Phi$ 查表」

例题

掷公平骰子 100 次, 点数之和超过 380 的概率 ($\mu = 3.5, \sigma^2 = 35/12$)。

$$E[S] = 350, \text{Var}(S) = 100 \times 35/12 \approx 291.7, \text{SD} \approx 17.08. P(S > 380) \approx 1 - \Phi\left(\frac{380 - 350}{17.08}\right) = 1 - \Phi(1.756) \approx 1 - 0.960 = 0.040。$$

章节: Ch.11 (中心极限定理)

模型 15：连续性修正（二项 → 正态近似）

识别特征

$X \sim B(n, p)$, n 大, np 与 $n(1-p)$ 均 ≥ 5 , 用正态近似。题目问整数边界处的概率（“恰好”“至多”“至少”），需加减 0.5 修正。

修正规则

原始事件	修正后
$P(X = k)$	$P(k - 0.5 < X < k + 0.5)$
$P(X \leq k)$	$P(X < k + 0.5)$
$P(X \geq k)$	$P(X > k - 0.5)$
$P(a \leq X \leq b)$	$P(a - 0.5 < X < b + 0.5)$

模板：用 $\mu = np$, $\sigma = \sqrt{np(1-p)}$, 修正后标准化 $\rightarrow \Phi$ 查表。

速记：「整数边界加减 0.5，再套正态标准化」

例题

$X \sim B(100, 0.4)$, 估计 $P(X \leq 35)$ 。

$$\mu = 40, \sigma = \sqrt{24} \approx 4.899。P(X \leq 35) \approx \Phi\left(\frac{35.5 - 40}{4.899}\right) = \Phi(-0.918) \approx 0.179。$$

章节：Ch.11（中心极限定理）、Ch.7（二项分布）

Part 5 统计基础（模型 16–18）

模型 16： $\bar{X}, S^2$ 抽样分布

识别特征

题目给出正态总体 $N(\mu, \sigma^2)$ 和样本量 n , 要求计算样本均值或样本方差落在某区间的概率，或推导置信区间、检验统计量。

核心结论速查

对 $X_1, \dots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$:

1. $\bar{X} \sim N(\mu, \sigma^2/n)$, 即 $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ 。

2. $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$, 自由度 $n-1$ (损失一个自由度因估计 μ)。
3. $\bar{X}$ 与 S^2 相互独立 (仅正态总体有此性质)。
4. σ 未知时: $\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$ 。

速记: 「正态总体 $\rightarrow \bar{X}$ 正态, $(n-1)S^2/\sigma^2$ 卡方, 两者独立, t 分布合体」

例题

$n = 16, \sigma^2 = 4$, 问 $\bar{X}$ 落在 $(\mu - 1, \mu + 1)$ 的概率。

$$\bar{X} \sim N(\mu, 4/16) = N(\mu, 0.25)。P(|\bar{X} - \mu| < 1) = P(|Z| < 1/0.5) = P(|Z| < 2) = 2\Phi(2) - 1 \approx 0.9544。$$

章节: Ch.13 (抽样分布)

模型 17: Bootstrap 求标准误

识别特征

题目描述“有放回重抽样”“Bootstrap 样本”“自助法”, 要求估计某统计量的标准误, 或构造置信区间。

模板 (4 步)

1. 从原始样本 (大小 n) 有放回地抽取 B 个 Bootstrap 样本, 每个大小也是 n 。
2. 对每个 Bootstrap 样本计算统计量 $\hat{\theta}^{*(b)}, b = 1, \dots, B$ 。
3. Bootstrap 标准误: $\widehat{SE}_{\text{boot}} = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}^{*(b)} - \bar{\hat{\theta}}^*)^2}$, 其中 $\bar{\hat{\theta}}^* = \frac{1}{B} \sum_b \hat{\theta}^{*(b)}$ 。
4. 95% 置信区间: 百分位法取 [2.5%, 97.5%] 分位数; 或正态近似 $\hat{\theta} \pm 1.96 \cdot \widehat{SE}_{\text{boot}}$ 。

速记: 「有放回重抽 B 次 $\rightarrow$ 每次算统计量 $\rightarrow$ 取标准差 $\rightarrow$ 即为 SE」

例题

原始样本 $\{3, 7, 5, 9, 1\}$, Bootstrap 估计中位数的 SE: 重复 1000 次有放回抽样, 计算每次中位数, 取其标准差。

章节: Ch.14 (描述统计)

模型 18: 充分统计量判定 (因子分解)

识别特征

题目要求判断某统计量 $T(X)$ 是否为参数 θ 的充分统计量, 或要求求最小充分统计量。

因子分解定理 (Factorization Theorem)

$T(\mathbf{X})$ 是 θ 的充分统计量, 当且仅当联合 PDF (或 PMF) 可以写成:

$$f(\mathbf{x}; \theta) = g(T(\mathbf{x}), \theta) \cdot h(\mathbf{x})$$

其中 g 仅通过 T 依赖 $\mathbf{x}$, h 不依赖 θ 。

模板 (3 步)

1. 写出联合分布 $f(\mathbf{x}; \theta) = \prod_i f(x_i; \theta)$ 。
2. 尝试分解: 找到 $T(\mathbf{x})$, 使得 f 可写成 $g(T, \theta) \cdot h(\mathbf{x})$ 的形式。
3. 如果能分解, 则 T 是充分统计量; 如果 f 只能整体依赖 θ 而无法分出 $h(\mathbf{x})$, 则不充分。

速记: 「联合分布 = $g(T, \theta) \times h(\mathbf{x})$, 能分解 $\rightarrow$ 充分」

例题

$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Poisson}(\lambda)$, 证明 $T = \sum X_i$ 是充分统计量。

$$\prod P(X_i = x_i) = \prod \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} = e^{-n\lambda} \lambda^{\sum x_i} \cdot \prod \frac{1}{x_i!}。 \text{ 令 } g = e^{-n\lambda} \lambda^T \text{ (仅通过 } T = \sum x_i \text{ 和 } \lambda \text{ 决定),}$$

$$h = \prod (x_i!)^{-1} \text{ (不含 } \lambda), \text{ 故 } T \text{ 充分。}$$

章节: Ch.15 (充分统计量)

Part 6 估计 (模型 19–23)

模型 19: MLE 求解 4 步

识别特征

题目要求“极大似然估计”“MLE”“最大化似然函数”, 给出样本分布族, 求参数的 MLE。

模板 (4 步)

1. 写似然函数: $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$ 。
2. 取对数: $\ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta)$ (对数线性化, 乘积变求和)。
3. 求导置零: $\frac{\partial \ell}{\partial \theta} = 0$, 解出 $\hat{\theta}$ 。
4. 验证最大: 二阶导 < 0 (或边界检验), 确认是极大而非极小。

常见结论: 正态 $\hat{\mu} = \bar{X}$, $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ (有偏); 指数 $\hat{\lambda} = 1/\bar{X}$; 二项 $\hat{p} = \bar{X}$ 。

速记: 「写 $L \rightarrow$ 取 $\ln \rightarrow$ 求导 = 0 $\rightarrow$ 解参数」

例题

$X_i \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda)$, 求 λ 的 MLE。

$\ell(\lambda) = n \ln \lambda - \lambda \sum x_i$ 。 $\ell' = n/\lambda - \sum x_i = 0$, 故 $\hat{\lambda} = n/\sum x_i = 1/\bar{x}$ 。

章节: Ch.16 (点估计)

模型 20: 矩估计法

识别特征

题目要求”矩估计”“用样本矩估计参数”, 或 MLE 求解困难时作为替代方案。

模板 (3 步)

- 1. 计算总体 k 阶矩 $\mu_k = E[X^k]$ (用参数表示)。
- 2. 令总体矩 = 样本矩: $\mu_k = m_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 。
- 3. 解方程组, 得参数估计 (有 p 个参数则列 p 个方程)。

矩估计 vs MLE

	矩估计	MLE
计算	简单, 只需矩	较复杂, 需最优化
统计性质	一般一致, 不一定有效	渐近有效, 渐近正态
适用	分布形式不确定	已知分布族

速记: 「令总体矩等于样本矩, 解参数」

例题

$X \sim U(0, \theta)$, 用矩估计求 $\hat{\theta}$ 。

$E[X] = \theta/2 = \bar{X}$, 故 $\hat{\theta} = 2\bar{X}$ 。(MLE 给 $\hat{\theta} = X_{(n)}$, 两者不同。)

章节: Ch.16 (点估计)

模型 21: 区间估计 4 步 (枢轴量法)

识别特征

题目要求”95% 置信区间”“置信度 $1 - \alpha$ ”“求参数 θ 的置信区间”。关键: 找枢轴量 (其分布不含 θ), 再反解。

模板 (4 步)

- 1. 找枢轴量 $Q(\mathbf{X}; \theta)$: 分布已知且不含 θ .
 - σ 已知: $Q = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$
 - σ 未知: $Q = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n - 1)$
 - 方差: $Q = \frac{(n - 1)S^2}{\sigma^2} \sim \chi^2(n - 1)$
- 2. 确定临界值: $P(-c \leq Q \leq c) = 1 - \alpha$, 查表得 c ($z_{\alpha/2}$, $t_{n-1, \alpha/2}$, 等)。
- 3. 反解参数: 将不等式从 Q 形式改写成 θ 形式。
- 4. 报告区间: 写成 $(\hat{\theta}_L, \hat{\theta}_U)$ 并说明置信度。

速记: 「找枢轴量 (分布已知) $\rightarrow$ 夹住 $1 - \alpha \rightarrow$ 反解 θ 」

例题

$n = 25$, $\bar{X} = 50$, $S = 10$, σ 未知, 求 μ 的 95% CI。

枢轴量 $t(24)$, 临界值 $t_{24, 0.025} \approx 2.064$ 。CI: $50 \pm 2.064 \times 10/\sqrt{5} = 50 \pm 4.128$, 即 $(45.87, 54.13)$ 。

章节: Ch.17 (区间估计)

模型 22: 贝叶斯共轭后验

识别特征

题目给出先验分布 $\pi(\theta)$ 和似然 $f(x | \theta)$, 要求用贝叶斯方法更新后验 $\pi(\theta | x)$, 或选择共轭先验简化计算。

常见共轭对

似然	共轭先验	后验
$B(n, p)$: 成功次数	$\text{Beta}(\alpha, \beta)$	$\text{Beta}(\alpha + k, \beta + n - k)$
$\text{Poisson}(\lambda)$	$\Gamma(\alpha, \beta)$	$\Gamma(\alpha + \sum x_i, \beta + n)$
$N(\mu, \sigma^2)$, σ^2 已知	$N(\mu_0, \tau^2)$	正态, 精度加权均值

后验推导步骤

- 1. 写出核 (kernel): $\pi(\theta | \mathbf{x}) \propto f(\mathbf{x} | \theta) \cdot \pi(\theta)$ (忽略不含 θ 的常数)。
- 2. 识别核的函数形式 (Beta / Gamma / 正态), 读出更新后的参数。
- 3. 点估计: 后验均值 (贝叶斯估计量在平方损失下最优) 或后验众数 (MAP)。

速记: 「后验 $\propto$ 似然 $\times$ 先验 $\rightarrow$ 识别分布形式 $\rightarrow$ 读参数」

例题

$k = 7$ 次成功， $n = 10$ ，先验 $\text{Beta}(2, 2)$ ，求后验。

后验 $\sim \text{Beta}(2 + 7, 2 + 3) = \text{Beta}(9, 5)$ 。后验均值 $= 9/14 \approx 0.643$ （比 MLE 的 0.7 向先验均值 0.5 收缩）。

章节：Ch.18（贝叶斯估计）

模型 23：损失函数选估计量

识别特征

题目问“在平方损失/绝对损失/0-1 损失下，贝叶斯估计量是什么”，或比较不同损失函数对应的最优估计。

对照表

损失函数	贝叶斯估计量（最小化后验期望损失）
平方损失 $(\theta - \hat{\theta})^2$	后验均值 $E[\theta \mid \mathbf{x}]$
绝对值损失 $ \theta - \hat{\theta} $	后验中位数
0-1 损失（错误分类）	后验众数（MAP 估计）

推导逻辑：最小化 $E[L(\theta, \hat{\theta}) \mid \mathbf{x}]$ ，用微积分对 $\hat{\theta}$ 求导置零（平方损失），或用分位数定义（绝对值损失）。

速记：「平方 $\rightarrow$ 均值；绝对 $\rightarrow$ 中位；0-1 $\rightarrow$ 众数（MAP）」

例题

后验为 $\text{Beta}(9, 5)$ （模型 22 延续）：平方损失估计 $= 9/14$ ；绝对损失估计 $=$ 后验中位数 ≈ 0.636 ；MAP 估计 $= (9 - 1)/(9 + 5 - 2) = 8/12 = 2/3$ 。

章节：Ch.18（贝叶斯估计）

Part 7 假设检验（模型 24–27）

模型 24：假设检验 7 步流程

识别特征

题目要求“检验……”“显著性水平 $\alpha = 0.05$ ”“是否有显著差异”——需要完整走完假设检验流程。

模板（7 步）

1. 建立假设: H_0 (零假设, 含等号) 和 H_1 (备择假设, 单侧或双侧)。
2. 选检验统计量: 根据参数类型、 σ 是否已知、样本量选 $z/t/\chi^2/F$ 。
3. 确定拒绝域: 根据 H_1 方向 (左侧、右侧、双侧) 和 α 查临界值。
4. 计算检验统计量: 代入样本数据。
5. 作出判断: 检验统计量落入拒绝域 $\rightarrow$ 拒绝 H_0 ; 否则 $\rightarrow$ 不能拒绝 H_0 。
6. 计算 p 值 (可选): $p = P(\text{观测到更极端的统计量} | H_0)$ 。
7. 结论: 用领域语言描述, 避免说“接受 H_0 ”。

速记: 「建假设 $\rightarrow$ 选统计量 $\rightarrow$ 定拒绝域 $\rightarrow$ 算统计量 $\rightarrow$ 比较或算 p 」

例题

样本 $n = 36$, $\bar{X} = 52$, $S = 12$, 检验 $H_0: \mu = 50$ vs $H_1: \mu \neq 50$, $\alpha = 0.05$ 。

$$t = \frac{52 - 50}{12/\sqrt{36}} = \frac{2}{2} = 1。 \text{ 双侧临界值 } t_{35, 0.025} \approx 2.03。 |t| = 1 < 2.03, \text{ 不能拒绝 } H_0, \text{ 无显著差异。}$$

章节: Ch.19 (假设检验基础)

模型 25: 配对 t vs 独立 t 选择

识别特征

比较两组均值, 题目描述两组数据如何收集——“同一批人前后”“同一对象两种处理”用配对; “两批不同人”“独立随机抽样”用独立。

判断树

- 数据一一对应 (同人前后测、配对设计) $\rightarrow$ 配对 t 检验
 - 取差值 $D_i = X_{1i} - X_{2i}$, 检验 $H_0: \mu_D = 0$, 统计量 $t = \frac{\bar{D}}{S_D/\sqrt{n}} \sim t(n-1)$
- 两组完全独立 $\rightarrow$ 独立两样本 t 检验
 - 方差齐 (Levene 检验): 合并方差, $t \sim t(n_1 + n_2 - 2)$
 - 方差不齐: Welch t , 自由度用 Satterthwaite 公式近似

速记: 「配对 $\rightarrow$ 差值 $\rightarrow$ 单样本 t ; 独立 $\rightarrow$ 判方差齐性 $\rightarrow$ 合并或 Welch」

例题

12 名学者分别在两种噪音环境下测工作效率, 应用配对 t : 取 12 个差值 D_i , 算 $\bar{D}, S_D$, $t = \bar{D}/(S_D/\sqrt{12}) \sim t(11)$ 。

章节: Ch.19 (假设检验)、Ch.20 (参数检验)

模型 26：p 值 vs 临界值法

识别特征

题目要求”计算 p 值”或给 p 值让你判断结论，或比较两种决策方法。

对比

方法	步骤	判断规则
临界值法	查表得 c_α ，计算统计量 T	$ T > c_\alpha$ （双侧） $\rightarrow$ 拒绝 H_0
p 值法	计算 $p = P(T \geq t_{\text{obs}} \mid H_0)$	$p < \alpha \rightarrow$ 拒绝 H_0

等价性： $|T| > c_\alpha \Leftrightarrow p < \alpha$ （两方法等价，但 p 值提供更多信息量）。

p 值解读： p 值 不是 H_0 为真的概率，而是”若 H_0 成立，观测到如此极端数据的概率”。

速记：「 $p < \alpha$ 拒绝 H_0 ；p 值越小，证据越强反对 H_0 」

例题

$z = 2.10$ （双侧）， $\alpha = 0.05$ 。 $p = 2 \times (1 - \Phi(2.10)) = 2 \times 0.0179 = 0.036 < 0.05$ ，拒绝 H_0 。

章节：Ch.19（假设检验基础）

模型 27：多重检验校正

识别特征

同时进行 m 个假设检验（基因组学、A/B 测试、多重比较），题目问”控制总体 I 类错误”“FDR”“Bonferroni 校正”。

主要方法

方法	控制指标	校正规则
Bonferroni	FWER（族错误率）	每个检验用 α/m ，更保守
Holm-Bonferroni	FWER	排序 p 值后逐步调整，稍宽松
Benjamini-Hochberg (BH)	FDR（错误发现率）	排序 p 值，找最大 i 使 $p_{(i)} \leq i\alpha/m$

FWER vs FDR： FWER 控制”至少一个假阳性”的概率； FDR 控制”发现中假阳性比例”的期望值，适合大规模多重检验（生物信息学）。

速记：「 m 个检验 $\rightarrow$ Bonferroni 除 m （保守）；大规模 $\rightarrow$ BH 控 FDR（宽松）」

例题

20 个基因同时检验, $\alpha = 0.05$ 。Bonferroni: 每个用 0.0025。BH: 排序 p 值 $p_{(1)} \leq \dots \leq p_{(20)}$, 找最大 i 满足 $p_{(i)} \leq 0.05i/20$, 拒绝所有 $\leq i$ 的假设。

章节: Ch.21 (非参数检验)、Ch.20 (参数检验)

Part 8 高级主题 (模型 28–31)

模型 28: 熵 / 互信息计算

识别特征

题目给出离散分布 (PMF), 要求计算香农熵 $H(X)$ 、联合熵 $H(X, Y)$ 、条件熵 $H(Y | X)$ 或互信息 $I(X; Y)$ 。

公式速查

- $H(X) = -\sum_x p(x) \ln p(x)$ (单位: nat, 用 $\log_2$ 则单位 bit)
- $H(X, Y) = -\sum_{x,y} p(x, y) \ln p(x, y)$
- $H(Y | X) = H(X, Y) - H(X)$
- $I(X; Y) = H(X) + H(Y) - H(X, Y) = H(X) - H(X | Y)$
- 链式法则: $H(X, Y) = H(X) + H(Y | X)$

性质: $H \geq 0$; $H(X) \leq \ln |X|$ (均匀分布时取等); $I(X; Y) \geq 0$ (独立时 $I = 0$)。

速记: 「熵 = $-\sum p \ln p$; 互信息 = 两熵之和 - 联合熵」

例题

$X \in \{0, 1\}$, $P(X = 0) = 0.3$, $P(X = 1) = 0.7$ 。 $H(X) = -0.3 \ln 0.3 - 0.7 \ln 0.7 \approx 0.3 \times 1.204 + 0.7 \times 0.357 \approx 0.611$ nat。

章节: Ch.22 (信息论)

模型 29: KL 散度计算 (含不对称性)

识别特征

题目要求计算两个分布 P 和 Q 之间的 KL 散度 $D_{\text{KL}}(P \| Q)$, 或证明/利用 KL 散度的不对称性。

公式

$$D_{\text{KL}}(P\|Q) = \sum_x p(x) \ln \frac{p(x)}{q(x)} = E_P \left[\ln \frac{P}{Q} \right]$$

连续情形: $D_{\text{KL}}(P\|Q) = \int p(x) \ln \frac{p(x)}{q(x)} dx$ 。

关键性质

- $D_{\text{KL}}(P\|Q) \geq 0$ (Gibbs 不等式), 等号当且仅当 $P = Q$ 。
- 不对称: $D_{\text{KL}}(P\|Q) \neq D_{\text{KL}}(Q\|P)$ (不是距离)。
- $D_{\text{KL}}(P\|Q) = +\infty$ 若 $\exists x: p(x) > 0$ 但 $q(x) = 0$ 。

速记: 「 $\sum p \ln(p/q)$; 非对称, 非距离; $p = 0$ 项贡献 0, $q = 0$ 项爆炸」

例题

$P = (0.4, 0.6)$, $Q = (0.5, 0.5)$ 。 $D_{\text{KL}}(P\|Q) = 0.4 \ln(0.4/0.5) + 0.6 \ln(0.6/0.5) = 0.4 \ln 0.8 + 0.6 \ln 1.2 \approx -0.0892 + 0.1094 = 0.020$ 。反向 $D_{\text{KL}}(Q\|P) \approx 0.021$ (不相等)。

章节: Ch.22 (信息论)

模型 30: MH 接受概率构造

识别特征

题目涉及 MCMC (马尔可夫链蒙特卡洛)、Metropolis-Hastings 算法, 要求写出接受概率公式或解释为何该算法收敛到目标分布 π 。

MH 算法流程

1. 当前状态 $x^{(t)}$, 从提议分布 $q(x' | x^{(t)})$ 抽候选 x' 。
2. 计算接受概率:

$$\alpha(x, x') = \min \left\{ 1, \frac{\pi(x')q(x | x')}{\pi(x)q(x' | x)} \right\}$$

3. 以概率 α 接受 ($x^{(t+1)} = x'$), 以 $1 - \alpha$ 拒绝 ($x^{(t+1)} = x^{(t)}$)。
4. 重复足够多步, 样本收敛到 π (详细平衡条件保证)。

特殊情形: Metropolis (提议对称 $q(x | x') = q(x' | x)$): $\alpha = \min\{1, \pi(x')/\pi(x)\}$, 提议项约去。

速记: 「接受率 = $\min(1, \text{目标比} \times \text{提议比的倒数})$; 对称提议只看目标比」

例题

$\pi(x) \propto e^{-x^2/2}$ (标准正态), 对称高斯提议。候选 $x' = 1.5$, 当前 $x = 1.0$ 。 $\alpha = \min(1, e^{-1.5^2/2}/e^{-1.0^2/2}) = \min(1, e^{-0.625}) \approx \min(1, 0.535) = 0.535$ 。

章节：Ch.23（蒙特卡洛方法）

模型 31：DAG 联合分解 / d-分离判定

识别特征

题目给出有向无环图（DAG）或贝叶斯网络，要求写出联合分布的因子分解，或判断两组变量在给定第三组时是否条件独立（d-分离）。

联合分解

$$p(x_1, \dots, x_n) = \prod_{i=1}^n p(x_i \mid \text{pa}(x_i))$$

其中 $\text{pa}(x_i)$ 是 x_i 的父节点集合（读 DAG 结构直接写出）。

d-分离规则（三种路径结构）

结构	路径形式	给定 Z 后
链（Chain）	$X \rightarrow Z \rightarrow Y$	Z 观测 $\rightarrow$ 阻断 ($X \perp Y \mid Z$)
叉（Fork）	$X \leftarrow Z \rightarrow Y$	Z 观测 $\rightarrow$ 阻断 ($X \perp Y \mid Z$)
对撞（Collider）	$X \rightarrow Z \leftarrow Y$	Z 未观测 $\rightarrow$ 阻断； Z 观测 $\rightarrow$ 打开（激活）

速记：「链和叉：观测中间节点 $\rightarrow$ 阻断；对撞：观测结果节点 $\rightarrow$ 打开（祖先亦然）」

例题

DAG: $A \rightarrow C \leftarrow B, C \rightarrow D$ 。判断 $A \perp B \mid \emptyset$ （不给定任何变量）。

C 是对撞节点，未观测时路径 $A \rightarrow C \leftarrow B$ 被阻断，故 $A \perp B$ （边际独立）。若给定 C 或 D ，则 A, B 变得相关（解释消除效应）。

章节：Ch.24（概率图模型）

总览索引

模型	名称	关键公式/工具	章节
1	全概率 + 贝叶斯反推	$P(B_j \mid A) = P(A \mid B_j)P(B_j)/P(A)$	Ch.2
2	古典概型 + 容斥	$P = A / \Omega $ ，容斥	Ch.1,3
3	几何概型	测度之比	Ch.1

模型	名称	关键公式/工具	章节
4	独立 vs 互斥辨析	$P(AB) = P(A)P(B)$ vs $P(AB) = 0$	Ch.1,2
5	离散 PMF 归一化	$\sum p_i = 1$	Ch.4
6	PDF 函数变换	CDF 法 / Jacobian	Ch.5
7	LOTUS	$E[g(X)] = \int g(x)f_X(x)dx$	Ch.4,5
8	边缘 / 条件分布	积分 / 相除	Ch.6
9	场景 $\rightarrow$ 分布识别	二项/泊松/正态等对照	Ch.7,8
10	正态标准化	$Z = (X - \mu)/\sigma$, Φ 查表	Ch.8
11	指数无记忆性	$P(X > s + t X > s) = P(X > t)$	Ch.8
12	三大抽样分布构造	χ^2, t, F 定义	Ch.13
13	切比雪夫上界	$P(X - \mu \geq \varepsilon) \leq \sigma^2/\varepsilon^2$	Ch.10
14	CLT 近似	S_n 标准化 $\rightarrow \Phi$	Ch.11
15	连续性修正	± 0.5 修正	Ch.11,7
16	抽样分布 $\bar{X}, S^2$	$\bar{X} \sim N, (n-1)S^2/\sigma^2 \sim \chi^2$	Ch.13
17	Bootstrap SE	有放回重抽, 取 SD	Ch.14
18	充分统计量 (因子分解)	$f = g(T, \theta) \cdot h(\mathbf{x})$	Ch.15
19	MLE 4 步	写 $L \rightarrow \ln L \rightarrow$ 求导 $\rightarrow$ 解	Ch.16
20	矩估计	总体矩 = 样本矩	Ch.16
21	区间估计 (枢轴量)	枢轴量 $\rightarrow$ 反解 θ	Ch.17
22	贝叶斯共轭后验	后验 $\propto$ 似然 $\times$ 先验	Ch.18
23	损失函数选估计量	平方 $\rightarrow$ 均值, 绝对 $\rightarrow$ 中位, 0-1 $\rightarrow$ 众数	Ch.18
24	假设检验 7 步	建 H_0/H_1 , 选统计量, 判拒绝域	Ch.19
25	配对 t vs 独立 t	差值法 vs 两样本	Ch.19,20
26	p 值 vs 临界值	$p < \alpha \Leftrightarrow T > c$	Ch.19
27	多重检验校正	Bonferroni / BH-FDR	Ch.20,21
28	熵 / 互信息	$H = -\sum p \ln p,$ $I = H(X) + H(Y) - H(X, Y)$	Ch.22
29	KL 散度	$\sum p \ln(p/q)$, 非对称	Ch.22
30	MH 接受概率	$\alpha = \min(1, \pi(x')q(x x')/[\pi(x)q(x' x)])$	Ch.23
31	DAG 联合分解 / d-分离	父节点条件化; 链叉对撞规则	Ch.24

基础题库 C (80 题)

难度: ★★☆☆☆—直接套公式 / 定义辨析。每题 2-5 分钟。答案见 appendix/F1-solutions-basic-part1-4.md 等 (PM10 生成)。

Part 1 概率基础 (Ch.1-3, 共 10 题)

C.1.1 (Ch.1, 事件运算与加法公式) 设 A, B 是两个事件, $P(A) = 0.5$, $P(B) = 0.4$, $P(A \cap B) = 0.15$ 。

1. 求 $P(A \cup B)$ 。
 2. 求 $P(\bar{A} \cap \bar{B})$ (即 A 与 B 均不发生的概率)。
-

C.1.2 (Ch.1, 概率公理与基本性质) 设 $P(A) = 0.7$, $P(B) = 0.3$, 且 A 与 B 互斥 ($A \cap B = \emptyset$)。

1. 求 $P(A \cup B)$ 。
 2. 求 $P(\bar{A})$ 。
 3. 判断: A 与 B 是否互为对立事件? 说明理由。
-

C.1.3 (Ch.1, 古典概型) 一个盒子中有 3 个红球、2 个白球、1 个蓝球, 共 6 个球。从中随机取出 1 个球。

1. 求取到红球的概率。
 2. 求取到非蓝球的概率。
-

C.1.4 (Ch.2, 条件概率定义) 已知 $P(A) = 0.6$, $P(B) = 0.5$, $P(A \cap B) = 0.3$ 。

1. 求条件概率 $P(A | B)$ 。
 2. 求条件概率 $P(B | A)$ 。
-

C.1.5 (Ch.2, 全概率公式) 某工厂有三条生产线, 产量占比分别为 50%、30%、20%, 次品率分别为 2%、3%、5%。从出厂产品中随机抽取一件, 求该件为次品的概率。

C.1.6 (Ch.2, 贝叶斯公式) 延续 **C.1.5** 的设定 (三条生产线产量占比 50%、30%、20%, 次品率 2%、3%、5%)。已知抽到的产品是次品, 求它来自第三条生产线的概率。

C.1.7 (Ch.2, 独立性判断) 已知 $P(A) = 0.4$, $P(B) = 0.5$, $P(A \cap B) = 0.2$ 。

1. 判断 A 与 B 是否独立。
 2. 若独立, 求 $P(\bar{A} \cap \bar{B})$ 。
-

C.1.8 (Ch.3, 排列计算) 从 $\{1, 2, 3, 4, 5, 6\}$ 中不重复地选取 3 个数字, 组成三位数。

1. 共有多少个这样的三位数?

2. 其中首位为奇数的三位数有多少个?

C.1.9 (Ch.3, 组合计算) 从 10 名同学中选出 3 人组成小组。

1. 共有多少种选法?
2. 若其中必须包含指定的 1 名同学, 有多少种选法?

C.1.10 (Ch.3, 二项式定理应用) 展开 $(1+x)^6$, 写出 x^2 项的系数。然后利用该系数计算 1.02^6 的近似值 (保留到 x^2 项)。

Part 2 随机变量 (Ch.4-6, 共 12 题)

C.2.1 (Ch.4, PMF 归一化) 设离散随机变量 X 的概率质量函数 (PMF) 为 $P(X=k) = ck$, $k=1,2,3,4$, 其他取值概率为 0。

1. 利用归一化条件求常数 c 。
2. 计算 $P(X \geq 3)$ 。

C.2.2 (Ch.4, 期望与方差) 离散随机变量 X 的分布律如下:

X	-1	0	1	2
P	0.2	0.3	0.4	0.1

1. 计算 $E[X]$ 。
2. 计算 $\text{Var}(X)$ 。

C.2.3 (Ch.4, CDF 与 PMF 关系) 设 X 的 PMF 为 $P(X=k) = \frac{1}{4}$, $k=1,2,3,4$ 。

1. 写出 X 的累积分布函数 (CDF) $F(x)$ 在 $x=1,2,3,4$ 处的值。
2. 计算 $P(1 < X \leq 3)$ 。

C.2.4 (Ch.5, PDF 归一化) 设连续随机变量 X 的概率密度函数 (PDF) 为

$$f(x) = \begin{cases} cx^2, & 0 \leq x \leq 2 \\ 0, & \text{其他} \end{cases}$$

1. 利用归一化条件求常数 c 。
 2. 计算 $P(1 \leq X \leq 2)$ 。
-

C.2.5 (Ch.5, 期望与方差——连续型) 设 X 在区间 $[0, 4]$ 上服从均匀分布, 即 $X \sim U(0, 4)$ 。

1. 写出 X 的 PDF。
 2. 计算 $E[X]$ 和 $\text{Var}(X)$ 。
-

C.2.6 (Ch.5, 正态标准化) 设 $X \sim N(3, 4)$ (均值 $\mu = 3$, 方差 $\sigma^2 = 4$)。

1. 求标准化随机变量 $Z = \frac{X - 3}{2}$ 的分布。
 2. 计算 $P(1 \leq X \leq 7)$, 用标准正态 CDF Φ 表示结果 (不需要查表给出数值)。
-

C.2.7 (Ch.5, CDF 与 PDF 互化) 设连续随机变量 X 的 CDF 为

$$F(x) = \begin{cases} 0, & x < 0 \\ x^2, & 0 \leq x \leq 1 \\ 1, & x > 1 \end{cases}$$

1. 求 X 的 PDF $f(x)$ 。
 2. 计算 $P(0.5 \leq X \leq 0.8)$ 。
-

C.2.8 (Ch.6, 联合 PMF 与边缘分布) 二维离散随机变量 (X, Y) 的联合 PMF 如下表:

	$Y = 0$	$Y = 1$
$X = 0$	0.1	0.3
$X = 1$	0.4	0.2

1. 求边缘 PMF: $P(X = 0)$, $P(X = 1)$, $P(Y = 0)$, $P(Y = 1)$ 。
 2. 判断 X 与 Y 是否独立。
-

C.2.9 (Ch.6, 条件分布) 延续 **C.2.8** 的联合 PMF 表。

1. 求条件 PMF $P(Y = y | X = 1)$ ($y = 0, 1$)。
 2. 计算 $E[Y | X = 1]$ 。
-

C.2.10 (Ch.6, 协方差与相关系数) 已知 $E[X] = 1$, $E[Y] = 2$, $E[XY] = 3$, $\text{Var}(X) = 2$, $\text{Var}(Y) = 3$ 。

1. 计算 $\text{Cov}(X, Y)$ 。
 2. 计算相关系数 ρ_{XY} 。
-

C.2.11 (Ch.6, 期望与方差的线性性) 设 X, Y 独立, $E[X] = 2$, $E[Y] = 5$, $\text{Var}(X) = 3$, $\text{Var}(Y) = 4$ 。

1. 计算 $E[3X - 2Y + 1]$ 。
 2. 计算 $\text{Var}(3X - 2Y + 1)$ 。
-

C.2.12 (Ch.6, 联合 PDF 与边缘密度) 设二维连续随机变量 (X, Y) 的联合 PDF 为

$$f(x, y) = \begin{cases} 6x, & 0 \leq x \leq 1, 0 \leq y \leq x \\ 0, & \text{其他} \end{cases}$$

1. 求 X 的边缘 PDF $f_X(x)$ 。
 2. 验证 $\int_{-\infty}^{+\infty} f_X(x) dx = 1$ 。
-

Part 3 分布 (Ch.7-9, 共 12 题)

C.3.1 (Ch.7, 伯努利分布) 某次射击命中目标的概率为 $p = 0.8$ 。设 X 为命中次数 (共射击 1 次), $X \sim \text{Bernoulli}(0.8)$ 。

1. 写出 X 的 PMF。
 2. 计算 $E[X]$ 和 $\text{Var}(X)$ 。
-

C.3.2 (Ch.7, 二项分布) 一枚均匀硬币独立抛掷 8 次, 令 X 为正面出现的次数, $X \sim B(8, 0.5)$ 。

1. 写出 $P(X = k)$ 的表达式。
 2. 计算 $P(X = 4)$ (精确值, 用分数或小数均可)。
 3. 写出 $E[X]$ 和 $\text{Var}(X)$ 。
-

C.3.3 (Ch.7, 泊松分布) 某客服中心平均每分钟接到 $\lambda = 3$ 个电话, 呼叫到达服从泊松分布。

1. 写出 1 分钟内接到 k 个电话的概率公式。
2. 计算 1 分钟内恰好接到 0 个电话的概率 (精确表达式即可)。
3. 写出 $E[X]$ 和 $\text{Var}(X)$ 。

C.3.4 (Ch.7, 几何分布) 每次独立试验成功概率为 $p = 0.4$, 设 X 为首次成功所需的试验次数。

1. 写出 $P(X = k)$ 的表达式 ($k = 1, 2, 3, \dots$)。
 2. 计算 $P(X = 3)$ 。
 3. 写出 $E[X]$ 。
-

C.3.5 (Ch.7, 泊松近似二项) 某产品的次品率为 $p = 0.01$, 从中随机抽取 $n = 200$ 件。令 X 为次品件数。

1. 用泊松近似给出 X 的近似分布参数 λ 。
 2. 用泊松近似计算 $P(X = 0)$ (精确表达式即可)。
-

C.3.6 (Ch.8, 均匀分布) 设 $X \sim U(2, 8)$ (在区间 $[2, 8]$ 上均匀分布)。

1. 写出 X 的 PDF 和 CDF。
 2. 计算 $P(3 \leq X \leq 6)$ 。
 3. 计算 $E[X]$ 和 $\text{Var}(X)$ 。
-

C.3.7 (Ch.8, 指数分布与无记忆性) 设某设备寿命 $T \sim \text{Exp}(\lambda)$, $\lambda = 0.5$ (单位: 小时⁻¹)。

1. 写出 T 的 PDF 和 CDF。
 2. 计算 $P(T > 2)$ 。
 3. 利用无记忆性, 在已知设备已正常运行 2 小时的条件下, 求它再运行 2 小时以上的概率。
-

C.3.8 (Ch.8, 正态分布性质) 设 $X \sim N(5, 9)$ (均值 $\mu = 5$, 方差 $\sigma^2 = 9$, 即 $\sigma = 3$)。

1. 计算 $P(2 \leq X \leq 8)$, 用 Φ 表示。
 2. 若 $Y = 2X + 1$, 写出 Y 的分布。
-

C.3.9 (Ch.8, Gamma 分布) 设 $X \sim \text{Gamma}(\alpha, \beta)$, 其中形状参数 $\alpha = 3$, 速率参数 $\beta = 2$ 。

1. 写出 $E[X]$ 和 $\text{Var}(X)$ 的公式并代入数值。
 2. 若 X_1, X_2, X_3 独立同分布, 均为 $\text{Exp}(2)$ (即 $\text{Gamma}(1, 2)$), 则 $X_1 + X_2 + X_3$ 服从什么分布?
-

C.3.10 (Ch.8, 卡方分布的构造) 设 Z_1, Z_2, Z_3, Z_4, Z_5 独立同分布, 均服从 $N(0, 1)$ 。

1. 写出 $W = Z_1^2 + Z_2^2 + Z_3^2 + Z_4^2 + Z_5^2$ 服从的分布。
2. 写出 W 的期望和方差。

C.3.11 (Ch.9, 多项分布) 掷一枚均匀六面骰子 12 次, 令 X_k 为点数 k 出现的次数, $k = 1, 2, 3, 4, 5, 6$ 。

1. 写出联合分布 $(X_1, \dots, X_6) \sim \text{Multinomial}(12, p_1, \dots, p_6)$ 的参数。
 2. 写出 $E[X_1]$ 和 $\text{Var}(X_1)$ 的值。
-

C.3.12 (Ch.9, 多元正态的边缘分布) 设 $(X, Y) \sim N(\mu_X, \mu_Y, \sigma_X^2, \sigma_Y^2, \rho)$, 其中 $\mu_X = 0$, $\mu_Y = 1$, $\sigma_X^2 = 4$, $\sigma_Y^2 = 9$, $\rho = 0.5$ 。

1. 写出 X 的边缘分布。
 2. 写出 Y 的边缘分布。
 3. 写出 $\text{Cov}(X, Y)$ 的值。
-

Part 4 极限 (Ch.10-12, 共 8 题)

C.4.1 (Ch.10, 切比雪夫不等式) 设随机变量 X 满足 $E[X] = 10$, $\text{Var}(X) = 4$ 。

1. 利用切比雪夫不等式, 给出 $P(|X - 10| \geq 3)$ 的上界。
 2. 利用切比雪夫不等式, 给出 $P(7 \leq X \leq 13)$ 的下界。
-

C.4.2 (Ch.10, 大数定律的应用) 设 $X_1, X_2, \dots$ 独立同分布, $E[X_i] = 2$, $\text{Var}(X_i) = 5$ 。令 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ 。

1. 写出弱大数定律的结论: $\bar{X}_n$ 依概率收敛到什么值?
 2. 用切比雪夫不等式估计: 需要多大的 n , 才能使 $P(|\bar{X}_n - 2| \geq 0.5) \leq 0.05$?
-

C.4.3 (Ch.11, 中心极限定理——样本均值) 设 $X_1, \dots, X_n$ 独立同分布, $E[X_i] = 4$, $\text{Var}(X_i) = 9$, $n = 36$ 。

1. 写出 $\bar{X}_{36}$ 的精确期望和方差。
 2. 根据中心极限定理, 写出 $\bar{X}_{36}$ 的近似分布。
 3. 计算 $P(\bar{X}_{36} > 5)$ 的近似值 (用 Φ 表示)。
-

C.4.4 (Ch.11, 二项分布的正态近似) 设 $X \sim B(100, 0.4)$ 。用中心极限定理近似计算 $P(35 \leq X \leq 45)$ (用 Φ 表示结果)。

C.4.5 (Ch.12, 依概率收敛定义) 设随机变量序列 X_n 满足 $P(X_n = 0) = 1 - \frac{1}{n}$ 且 $P(X_n = n) = \frac{1}{n}$ 。

1. 对任意 $\varepsilon > 0$, 计算 $P(|X_n| \geq \varepsilon)$ (当 n 足够大, 使得 $n \geq \varepsilon$ 时)。

2. 判断 X_n 是否依概率收敛到 0。

C.4.6 (Ch.12, 收敛类型辨析) 下列命题中, 哪个是正确的? 请逐条判断并说明理由 (一句话即可):

1. 几乎必然收敛 (a.s.) 蕴含依概率收敛 (in probability)。
 2. 依概率收敛蕴含几乎必然收敛。
 3. 依分布收敛 (in distribution) 蕴含依概率收敛。
-

C.4.7 (Ch.12, 连续映射定理) 设 $X_n \xrightarrow{P} 3$, $g(x) = x^2$ 。

1. 根据连续映射定理, 写出 $g(X_n) = X_n^2$ 依概率收敛到的值。
 2. 若还知道 $Y_n \xrightarrow{P} 2$, 求 $X_n + Y_n$ 和 $X_n \cdot Y_n$ 的依概率极限。
-

C.4.8 (Ch.10, 马尔可夫不等式) 设 X 是非负随机变量, $E[X] = 6$ 。

1. 利用马尔可夫不等式, 给出 $P(X \geq 20)$ 的上界。
 2. 利用马尔可夫不等式, 给出 $P(X \geq 30)$ 的上界。
-

Part 5 统计基础 (Ch.13-15, 共 8 题)

C.5.1 (Ch.13, 样本统计量的定义) 设来自正态总体 $N(\mu, \sigma^2)$ 的样本为 $x_1 = 3, x_2 = 5, x_3 = 7, x_4 = 9, x_5 = 6$ ($n = 5$)。

1. 计算样本均值 $\bar{x}$ 。
 2. 计算样本方差 s^2 (分母用 $n - 1$)。
-

C.5.2 (Ch.13, 抽样分布——样本均值) 设总体 $X \sim N(10, 16)$, 从中抽取容量为 $n = 4$ 的简单随机样本。

1. 写出样本均值 $\bar{X}$ 的精确分布。
 2. 计算 $P(\bar{X} > 12)$ (用 Φ 表示)。
-

C.5.3 (Ch.13, χ^2 分布的性质) 设 Z_1, Z_2, Z_3 独立同分布于 $N(0, 1)$, 令 $W = Z_1^2 + Z_2^2 + Z_3^2$ 。

1. 写出 W 服从的分布。
 2. 写出 $E[W]$ 和 $\text{Var}(W)$ 。
-

C.5.4 (Ch.13, t 分布的构造) 设 $Z \sim N(0, 1)$, $V \sim \chi^2(9)$, 且 Z 与 V 独立。令 $T = \frac{Z}{\sqrt{V/9}}$ 。

1. 写出 T 服从的分布。
 2. 若要进行双侧 t 检验, 拒绝域为 $|T| > t_{\alpha/2}(9)$, 当 $\alpha = 0.05$ 时查表得 $t_{0.025}(9) = 2.262$, 写出具体的拒绝域。
-

C.5.5 (Ch.14, 样本分位数与中位数) 有 7 个数据: $\{4, 1, 9, 3, 7, 2, 8\}$ 。

1. 排序后写出有序样本。
 2. 求样本中位数 (第 0.5 分位数)。
 3. 求样本均值, 并与中位数比较 (哪个更大?)。
-

C.5.6 (Ch.14, 偏度与峰度的含义) 下列分布中, 哪个偏度为 0? 哪个峰度最大? 请从选项中选择并说明理由 (一句话即可)。

选项: (A) $N(0, 1)$; (B) 指数分布 $\text{Exp}(1)$; (C) 均匀分布 $U(0, 1)$; (D) 拉普拉斯分布 (与正态相比, 有更重的尾巴)。

C.5.7 (Ch.15, 充分统计量判定) 设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Poisson}(\lambda)$ 。

1. 写出样本的联合 PMF $\prod_{i=1}^n P(X_i = x_i)$ 。
 2. 利用因子分解定理, 说明 $T = \sum_{i=1}^n X_i$ 是参数 λ 的充分统计量。
-

C.5.8 (Ch.15, 指数族与自然充分统计量) 正态分布 $N(\mu, \sigma^2)$ (σ^2 已知) 属于指数族。写出其自然充分统计量, 并说明为什么 $\bar{X}$ 是 μ 的充分统计量 (一句话概述)。

Part 6 估计 (Ch.16-18, 共 10 题)

C.6.1 (Ch.16, 矩估计) 设总体 $X \sim U(0, \theta)$, $\theta > 0$ 未知。 X 的期望为 $E[X] = \theta/2$ 。

1. 用矩估计法, 令样本均值 $\bar{X}$ 等于总体期望, 推导 θ 的矩估计量 $\hat{\theta}_{\text{MOM}}$ 。
 2. 若样本均值 $\bar{x} = 4.2$, 写出 $\hat{\theta}$ 的数值。
-

C.6.2 (Ch.16, MLE——伯努利分布) 设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Bernoulli}(p)$, 观测到 $\sum_{i=1}^n x_i = k$ 次成功。

1. 写出似然函数 $L(p)$ 。
2. 对似然函数取对数, 求导并令其为 0, 推导 $\hat{p}_{\text{MLE}}$ 的表达式。

C.6.3 (Ch.16, MLE——指数分布) 设 $X_1, \dots, X_n \stackrel{iid}{\sim} \text{Exp}(\lambda)$, PDF 为 $f(x) = \lambda e^{-\lambda x}$ ($x > 0$)。

1. 写出对数似然函数 $\ell(\lambda)$ 。
 2. 求 $\hat{\lambda}_{\text{MLE}}$ (结果用 $\bar{x}$ 或 $\sum x_i$ 表示)。
-

C.6.4 (Ch.16, 无偏性验证) 设总体均值为 μ , 方差为 σ^2 。样本 $X_1, \dots, X_n$ 独立同分布。

1. 证明样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 是 μ 的无偏估计量 (即 $E[\bar{X}] = \mu$)。
 2. 计算 $\bar{X}$ 的方差 $\text{Var}(\bar{X})$ 。
-

C.6.5 (Ch.17, 正态均值的置信区间——方差已知) 设总体 $X \sim N(\mu, 4)$ ($\sigma^2 = 4$ 已知), 取 $n = 16$ 个样本, 得 $\bar{x} = 12.5$ 。取置信水平 $1 - \alpha = 0.95$ (查表知 $z_{0.025} = 1.96$)。

1. 写出 μ 的 95% 置信区间的枢轴量形式。
 2. 计算具体的置信区间 $[l, u]$ 。
-

C.6.6 (Ch.17, 正态均值的置信区间——方差未知) 设总体 $X \sim N(\mu, \sigma^2)$ (σ^2 未知), 取 $n = 10$ 个样本, 得 $\bar{x} = 5.0$, $s = 2.0$ 。取 $1 - \alpha = 0.95$, 查表知 $t_{0.025}(9) = 2.262$ 。

1. 写出枢轴量及其分布。
 2. 计算 μ 的 95% 置信区间。
-

C.6.7 (Ch.17, 样本量与置信区间宽度) 在正态总体、方差已知 $\sigma^2 = 100$ 的情形下, 希望均值 μ 的 95% 置信区间半宽度 (误差限) 不超过 $E_0 = 2$, 即 $z_{0.025} \cdot \frac{\sigma}{\sqrt{n}} \leq 2$ 。

1. 写出求 n 的不等式。
 2. 解出所需的最小样本量 n ($z_{0.025} = 1.96$)。
-

C.6.8 (Ch.18, 贝叶斯更新——Beta-二项共轭) 设硬币正面概率 p 的先验分布为 $p \sim \text{Beta}(2, 2)$ 。观测到 10 次试验中有 7 次正面。

1. 写出后验分布 $p \mid \text{数据}$ 的参数 (利用 Beta-Binomial 共轭: 先验 $\text{Beta}(\alpha, \beta)$ + 数据 k 次成功、 $n - k$ 次失败 $\rightarrow$ 后验 $\text{Beta}(\alpha + k, \beta + n - k)$)。
 2. 写出后验均值 ($\text{Beta}(\alpha', \beta')$ 的均值为 $\alpha' / (\alpha' + \beta')$)。
-

C.6.9 (Ch.18, MAP 估计 vs MLE) 延续 **C.6.8** 的设定 (先验 $\text{Beta}(2, 2)$, 10 次试验 7 次正面)。

1. MLE 给出的 $\hat{p}_{\text{MLE}}$ 是多少?
 2. 后验 $\text{Beta}(\alpha', \beta')$ 的 MAP 估计为 $(\alpha' - 1)/(\alpha' + \beta' - 2)$, 计算 $\hat{p}_{\text{MAP}}$ 。
 3. 比较 MLE 与 MAP: 哪个更接近 0.5? 为什么? (一句话)
-

C.6.10 (Ch.18, 可信区间 vs 置信区间) 贝叶斯可信区间 (Credible Interval) 与频率学派置信区间 (Confidence Interval) 的含义不同。

1. 简述贝叶斯 95% 可信区间的含义 (一句话)。
 2. 简述频率学派 95% 置信区间的正确含义 (一句话)。
 3. 下列说法哪个是对的? (A) “参数以 95% 的概率落在置信区间内”; (B) “若重复实验, 95% 的区间会覆盖真参数”。
-

Part 7 假设检验 (Ch.19-21, 共 10 题)

C.7.1 (Ch.19, 检验框架——两类错误) 某检验的原假设 H_0 : 产品合格率 $p \geq 0.95$; 备择假设 H_1 : $p < 0.95$ 。

1. 什么是第一类错误 (Type I Error)? 在此题中给出具体描述。
 2. 什么是第二类错误 (Type II Error)? 在此题中给出具体描述。
 3. 显著性水平 α 控制的是哪类错误的概率上限?
-

C.7.2 (Ch.19, p 值的含义) 某检验计算得 p 值为 0.03, 显著性水平 $\alpha = 0.05$ 。

1. 根据 p 值判断: 是否拒绝 H_0 ?
 2. 下列说法哪个正确? (A) “ H_0 为真的概率是 0.03”; (B) “在 H_0 为真的条件下, 观测到此结果或更极端结果的概率是 0.03”。
-

C.7.3 (Ch.19, 单样本 z 检验) 已知总体 $X \sim N(\mu, \sigma^2 = 25)$ (σ 已知), 从中取 $n = 25$ 个样本, 得 $\bar{x} = 52$ 。检验 $H_0: \mu = 50$ vs $H_1: \mu \neq 50$, $\alpha = 0.05$ ($z_{0.025} = 1.96$)。

1. 计算检验统计量 $z = \frac{\bar{x} - 50}{\sigma/\sqrt{n}}$ 。
 2. 写出拒绝域, 并判断是否拒绝 H_0 。
-

C.7.4 (Ch.19, 检验功效的定义) $H_0: \mu = \mu_0$, $H_1: \mu = \mu_1 > \mu_0$ 。

1. 检验功效 (Power) 的定义是什么 (用概率语言)?
 2. 若增大样本量 n , 功效如何变化? (增大 / 减小 / 不变)
-

C.7.5 (Ch.20, 单样本 t 检验) 设总体 $X \sim N(\mu, \sigma^2)$ (σ^2 未知), 取 $n = 16$ 个样本, 得 $\bar{x} = 10.8$, $s = 2.0$ 。检验 $H_0: \mu = 10$ vs $H_1: \mu \neq 10$, $\alpha = 0.05$, 查表知 $t_{0.025}(15) = 2.131$ 。

1. 计算检验统计量 $t = \frac{\bar{x} - 10}{s/\sqrt{n}}$ 。
 2. 写出拒绝域, 并判断是否拒绝 H_0 。
-

C.7.6 (Ch.20, 独立双样本 t 检验条件) 比较两组数据的均值差异, 使用独立双样本 t 检验。列出该检验的三个基本假设条件。

C.7.7 (Ch.20, 方差齐性 F 检验) 设两个独立正态总体, 样本方差分别为 $s_1^2 = 8$ ($n_1 = 11$) 和 $s_2^2 = 4$ ($n_2 = 9$)。检验 $H_0: \sigma_1^2 = \sigma_2^2$ vs $H_1: \sigma_1^2 \neq \sigma_2^2$ 。

1. 写出 F 统计量及其在 H_0 下的分布 (包括自由度)。
 2. 计算 F 的数值。
-

C.7.8 (Ch.20, 卡方拟合优度检验) 掷骰子 60 次, 观察到 1-6 各点出现次数为 $\{8, 12, 9, 11, 10, 10\}$ 。检验骰子是否均匀, 即 H_0 : 各点概率均为 $1/6$ 。

1. 在 H_0 下, 各点的期望频数是多少?
 2. 写出卡方统计量的表达式 (不需要算出数值)。
 3. 该统计量在 H_0 下近似服从什么分布 (自由度是多少)?
-

C.7.9 (Ch.21, 符号检验) 对 8 名被试前后测量得分之差 (后测 - 前测) 为: $\{+3, -1, +5, +2, -2, +4, +1, +3\}$ 。用符号检验检验 H_0 : 总体中位数差为 0 (即治疗无效)。

1. 统计正号和负号的个数 (忽略差为 0 的观测)。
 2. 在 H_0 下, 正号个数服从什么分布?
-

C.7.10 (Ch.21, Kolmogorov-Smirnov 检验) 用 KS 检验判断数据是否来自某假设分布 F_0 。

1. KS 统计量 $D_n = \sup_x |F_n(x) - F_0(x)|$ 中, $F_n(x)$ 是什么?
 2. 若 D_n 的值很大 (超过临界值), 应作何结论?
-

Part 8 高级 (Ch.22-24, 共 10 题)

C.8.1 (Ch.22, 香农熵) 设离散随机变量 X 的 PMF 为 $P(X = 1) = 0.5$, $P(X = 2) = 0.25$, $P(X = 3) = 0.25$ 。

1. 计算 X 的香农熵 $H(X)$ (以比特为单位, 即用 $\log_2$)。
 2. 若 Y 均匀分布在 $\{1, 2, 3, 4\}$ 上, $H(Y)$ 是多少比特? 与 $H(X)$ 比较, 哪个更大?
-

C.8.2 (Ch.22, KL 散度) 设 $P = (0.5, 0.5)$ 和 $Q = (0.8, 0.2)$ 是同一样本空间 $\{0, 1\}$ 上的两个分布。

1. 计算 KL 散度 $D_{\text{KL}}(P\|Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)}$ (以自然对数计算, 精确表达式即可)。
 2. KL 散度是否对称? 即 $D_{\text{KL}}(P\|Q) = D_{\text{KL}}(Q\|P)$ 是否一定成立?
-

C.8.3 (Ch.22, 交叉熵与 KL 散度的关系) 设真实分布为 P , 模型分布为 Q , 交叉熵定义为 $H(P, Q) = -\sum_x P(x) \log Q(x)$ 。

1. 写出 $H(P, Q)$ 与 $H(P)$ (真实分布的熵) 和 $D_{\text{KL}}(P\|Q)$ 的关系式。
 2. 当 $Q = P$ 时, 交叉熵等于什么?
-

C.8.4 (Ch.22, 互信息) 已知 $H(X) = 2$ 比特, $H(Y) = 3$ 比特, $H(X, Y) = 4$ 比特 (联合熵)。

1. 计算互信息 $I(X; Y) = H(X) + H(Y) - H(X, Y)$ 。
 2. 若 X 与 Y 独立, 则 $I(X; Y)$ 应等于多少?
-

C.8.5 (Ch.23, 蒙特卡洛积分) 用蒙特卡洛方法估计积分 $I = \int_0^1 e^{x^2} dx$ 。从 $U(0, 1)$ 中抽取 n 个样本 $x_1, \dots, x_n$ 。

1. 写出蒙特卡洛估计量 $\hat{I}_n$ 。
 2. 写出 $\hat{I}_n$ 的标准误差 (用 $\sigma_f = \sqrt{\text{Var}(e^{X^2})}$ 表示)。
-

C.8.6 (Ch.23, 重要性采样) 设目标是估计 $E_p[f(X)]$, 但直接从 $p(x)$ 采样困难, 改从提议分布 $q(x)$ 采样。

1. 写出重要性采样估计量 (使用重要性权重 $w(x) = p(x)/q(x)$)。
 2. 若 $q(x)$ 与 $p(x)f(x)$ 的形状完全吻合, 对估计方差有何影响?
-

C.8.7 (Ch.24, 贝叶斯网络因子分解) 设贝叶斯网络中有三个变量 $A \rightarrow B \rightarrow C$ (链状结构)。

1. 写出联合分布 $P(A, B, C)$ 的因子分解公式。
 2. 在已知 B 的条件下, A 与 C 是否条件独立? ($A \perp\!\!\!\perp C \mid B$ 是否成立?)
-

C.8.8 (Ch.24, EM 算法——E 步与 M 步) EM 算法用于含隐变量模型的参数估计。设参数为 θ , 隐变量为 Z , 观测数据为 X 。

1. E 步 (Expectation step): 写出期望 $Q(\theta | \theta^{(t)})$ 的定义式 (即对 Z 的条件分布取期望)。
2. M 步 (Maximization step): 写出 $\theta^{(t+1)}$ 的更新公式。

C.8.9 (Ch.24, ELBO 与变分推断) 变分推断将推断问题转化为优化问题。设真实后验为 $p(Z | X)$, 变分分布为 $q(Z)$ 。

1. 写出 ELBO (Evidence Lower BOund) 的表达式: $\text{ELBO} = \log p(X) - D_{\text{KL}}(q(Z) \| p(Z | X))$, 说明最大化 ELBO 等价于最小化什么?
2. 当 $q(Z) = p(Z | X)$ 时, ELBO 等于什么?

C.8.10 (Ch.22-24, 综合辨析) 判断下列说法是否正确, 并用一句话说明理由:

1. KL 散度 $D_{\text{KL}}(P \| Q) \geq 0$, 等号成立当且仅当 $P = Q$ 。
2. 蒙特卡洛积分的误差以 $O(1/n)$ 的速率收缩 (与维度无关)。
3. 在贝叶斯网络中, d-分离蕴含条件独立性。

(全卷共 80 题, C.1.1 至 C.8.10)

中等题库 D (100 题)

难度: ★★★☆☆—多步推导 / 套路组合 / 含基本证明。每题 5-15 分钟。编号约定: D.{Part}.{序}。
不附答案。

使用说明: 本题库共 100 题, 覆盖概率论与数理统计全部 8 个 Part (Ch.1-24)。每题含 (a)(b)(c) 三小问, 分别对应逐层推进的计算、证明或应用。题目类型分布: 多步计算 (40%)、简单证明 (25%)、应用题 (25%)、反例构造 (10%)。建议与正文各章节配套练习, 难度高于基础题库 C 一档, 低于综合题库 E。

章节对照: Ch.1 随机事件 · Ch.2 条件概率 · Ch.3 组合数学 · Ch.4 离散随机变量 · Ch.5 连续随机变量 · Ch.6 多维随机变量 · Ch.7 离散分布族 · Ch.8 连续分布族 · Ch.9 多维分布 · Ch.10 大数定律 · Ch.11 中心极限定理 · Ch.12 收敛性理论 · Ch.13 统计量与抽样分布 · Ch.14 数据描述 · Ch.15 充分统计量 · Ch.16 点估计 · Ch.17 区间估计 · Ch.18 贝叶斯估计 · Ch.19 假设检验基础 · Ch.20 参数检验 · Ch.21 非参数检验 · Ch.22 信息论 · Ch.23 蒙特卡洛方法 · Ch.24 概率图模型。

Part 1 概率基础 (Ch.1-3, 共 12 题)

覆盖随机事件 (Ch.1)、条件概率与独立性 (Ch.2)、组合计数 (Ch.3)。题型: 多步全概率/贝叶斯 → 容斥 → 几何概型 → 独立性辨析 → 计数组合。关键公式: 全概率 $P(A) = \sum_i P(A | B_i)P(B_i)$;

贝叶斯 $P(B_j | A) = P(A | B_j)P(B_j)/P(A)$; 容斥 $P(A \cup B \cup C) = \sum P - \sum P(\cap) + P(\cap\cap)$ 。

D.1.1 (Ch.2, 全概率 + 贝叶斯反推) 某工厂三台机器生产同种产品, 产量比为 3:2:5, 次品率分别为 0.01、0.02、0.03。

- (a) 求随机抽取一件产品为次品的概率。
 - (b) 已知取到次品, 求它来自第 1 台机器的概率。
 - (c) 已知取到次品, 求它来自第 3 台机器的概率, 并与直觉比较。
-

D.1.2 (Ch.1, 容斥原理三事件) 调查 100 名学生, 喜欢数学的 60 人, 喜欢物理的 45 人, 喜欢化学的 30 人; 数学与物理都喜欢的 20 人, 数学与化学都喜欢的 15 人, 物理与化学都喜欢的 10 人; 三门都喜欢的人。

- (a) 求至少喜欢一门的人数。
 - (b) 求恰好只喜欢一门的人数。
 - (c) 求恰好喜欢两门的人数。
-

D.1.3 (Ch.3, 几何概型) 在区间 $[0, 3]$ 上随机取两点 X 和 Y (独立均匀)。

- (a) 求 $|X - Y| \leq 1$ 的概率 (几何概型, 计算有利面积)。
 - (b) 求 $X + Y \leq 3$ 且 $X \leq Y$ 同时成立的概率。
 - (c) 求 $\max(X, Y) \leq 2$ 的概率。
-

D.1.4 (Ch.2, 独立性与条件概率辨析) 设 A 、 B 是两个事件, $P(A) = 0.4$, $P(B) = 0.3$, $P(A \cup B) = 0.58$ 。

- (a) 求 $P(A \cap B)$, 判断 A 与 B 是否独立。
 - (b) 求 $P(A | B)$ 和 $P(B | A)$ 。
 - (c) 若再知 $P(A | B^c) = 0.5$, 重新验证 A 、 B 是否独立。
-

D.1.5 (Ch.3, 排列组合计数) 将 5 封不同的信随机投入 3 个不同的邮箱。

- (a) 求每个邮箱至少有 1 封信的概率 (容斥)。
 - (b) 求恰好有 2 个邮箱为空的概率。
 - (c) 求指定邮箱恰好有 2 封信的概率。
-

D.1.6 (Ch.2, 条件概率链) 某诊断测试对阳性患者的正确率为 95%, 对阴性 (健康) 人的错误率为 3%。设人群患病率为 1%。

- (a) 求测试结果为阳性的概率。
- (b) 求测试结果为阳性时实际患病的概率 (阳性预测值)。
- (c) 求测试结果为阴性时实际患病的概率 (假阴性率)。

D.1.7 (Ch.1, 概率公理与简单证明) 设 P 满足概率公理, $A \subset B$ 。

- (a) 证明: $P(B \setminus A) = P(B) - P(A)$ (用可加性)。
 - (b) 证明: $P(A) \leq P(B)$ (单调性)。
 - (c) 设 $A_1, A_2, \dots$ 两两互斥, 证明 $P(\bigcup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i)$ (有限可加性)。
-

D.1.8 (Ch.3, 二项系数与概率) 某人连续独立射击 10 次, 每次命中率 0.6。

- (a) 求恰好命中 6 次的概率 (精确表达式)。
 - (b) 求命中次数不超过 4 次的概率 (累积二项概率, 列表表达式即可)。
 - (c) 求至少命中 7 次的概率。
-

D.1.9 (Ch.2, 全概率 + 多阶段) 袋中有 3 个红球和 2 个白球。每次随机取 1 球, 观察后放回, 共取 3 次。

- (a) 求 3 次全取红球的概率。
 - (b) 求恰好取到 2 个红球的概率。
 - (c) 已知第 3 次取到红球, 求第 1 次也取到红球的概率。
-

D.1.10 (Ch.1, 事件运算与德摩根律) 设 A, B, C 是三个事件。

- (a) 用集合运算表达 “ A 发生但 B 和 C 均不发生”。
 - (b) 证明 $\overline{A \cup B \cup C} = \overline{A} \cap \overline{B} \cap \overline{C}$ (德摩根律)。
 - (c) 若三事件两两独立且满足 $P(A) = P(B) = P(C) = 0.5$, 求 $P(A \cap B \cap C)$ 的可能取值范围 (提示: 两两独立不蕴含相互独立)。
-

D.1.11 (Ch.2, Borel-Cantelli 预备) 设独立事件列 $\{A_n\}$ 满足 $P(A_n) = p$ 对所有 n 成立, $0 < p < 1$ 。

- (a) 求前 n 次中 A_n 一次也不发生的概率。
 - (b) 求 $n \rightarrow \infty$ 时上述概率的极限。
 - (c) 直觉上说明: 为何当 $p > 0$ 时 “ A_n 无穷多次发生” 的概率为 1。
-

D.1.12 (Ch.3, 有限集合上的均匀模型) 从 $\{1, 2, \dots, 52\}$ 中有放回地随机取 3 次。

- (a) 求三次取出的数均不相同的概率。
 - (b) 求恰好出现 2 个相同数的概率 (考虑哪两次相同)。
 - (c) 若改为无放回取 3 次, 重新计算 (a)。
-

Part 2 随机变量 (Ch.4-6, 共 15 题)

覆盖离散随机变量 (Ch.4)、连续随机变量 (Ch.5)、多维随机变量 (Ch.6)。题型：函数变换、矩计算、条件期望、联合/边际/条件分布、协方差与相关系数。核心工具：变量变换公式 $f_Y(y) = f_X(g^{-1}(y)) \cdot |dg^{-1}/dy|$ ；重期望 $E[X] = E[E[X | Y]]$ ；重方差 $\text{Var}(X) = E[\text{Var}(X | Y)] + \text{Var}(E[X | Y])$ 。

D.2.1 (Ch.5, 连续随机变量函数变换) 设 $X \sim U(0, 2)$, 令 $Y = X^2$ 。

- (a) 求 Y 的概率密度函数 $f_Y(y)$ (用变量变换法)。
- (b) 求 $E[Y]$ (两种方法：直接用 f_Y 或 LOTUS 公式)。
- (c) 求 $\text{Var}(Y)$ 。

D.2.2 (Ch.4, 离散随机变量的矩) 某随机变量 X 的分布律为：

x	-1	0	1	2
p	a	0.3	0.2	b

且 $E[X] = 0.4$ 。

- (a) 确定 a 和 b 。
- (b) 求 $E[X^2]$ 和 $\text{Var}(X)$ 。
- (c) 求 $E[3X^2 - 2X + 1]$ 。

D.2.3 (Ch.5, 正态分布分位数与标准化) 设 $X \sim N(2, 9)$ (均值 2, 方差 9)。设 Φ 为标准正态 CDF。

- (a) 用 Φ 表达 $P(1 \leq X \leq 5)$ 。
- (b) 求 $P(|X - 2| > 3)$ 。
- (c) 已知 $P(X > c) = 0.05$, 求 c (用 Φ^{-1} 或 $z_{0.05} \approx 1.645$ 表达)。

D.2.4 (Ch.4, 泊松过程初步) 某网站每分钟访问量服从均值为 3 的泊松分布。

- (a) 求某分钟内无访问的概率。
- (b) 求某分钟内访问量超过 5 次的概率 (用累积泊松 CDF 表达)。
- (c) 若每次访问产生 0.1 元收益, 求每分钟收益的期望和方差。

D.2.5 (Ch.5, 指数分布无记忆性) 设元件寿命 $X \sim \text{Exp}(\lambda)$, $\lambda = 0.1$ (单位: 小时)。

- (a) 求 $P(X > 20)$ 。
- (b) 证明无记忆性: $P(X > s + t | X > s) = P(X > t)$, 对任意 $s, t > 0$ 。
- (c) 已知元件已工作 10 小时, 求还能再工作 15 小时的概率。

D.2.6 (Ch.4, 期望与方差的线性性) 设 X 和 Y 相互独立, $E[X] = 1$, $\text{Var}(X) = 2$, $E[Y] = -1$, $\text{Var}(Y) = 3$ 。

- (a) 求 $E[2X - 3Y + 4]$ 。
 - (b) 求 $\text{Var}(2X - 3Y + 4)$ 。
 - (c) 求 $E[XY]$ 和 $E[X^2Y^2]$ (利用独立性)。
-

D.2.7 (Ch.5, 均匀分布的顺序统计量) 设 $X_1, X_2, X_3 \stackrel{\text{i.i.d.}}{\sim} U(0, 1)$, 令 $M = \max(X_1, X_2, X_3)$ 。

- (a) 求 M 的 CDF: $F_M(m) = P(M \leq m)$ 。
 - (b) 求 M 的密度函数 $f_M(m)$ 。
 - (c) 求 $E[M]$ 。
-

D.2.8 (Ch.4, 条件期望) 掷一枚骰子, 点数为 N ; 再掷 N 枚硬币, 设正面朝上次数为 X 。

- (a) 求 $E[X | N = n]$ 。
 - (b) 用重期望公式求 $E[X]$ 。
 - (c) 用条件方差公式求 $\text{Var}(X)$ (提示: $\text{Var}(X) = E[\text{Var}(X | N)] + \text{Var}(E[X | N])$)。
-

D.2.9 (Ch.5, 混合分布) 设随机变量 X 满足: 以概率 p 服从 $\text{Exp}(1)$, 以概率 $1 - p$ 恒等于 0 (即取值 0 的质量为 $1 - p$)。

- (a) 写出 X 的 CDF (注意混合型分布的表达)。
 - (b) 求 $E[X]$ 和 $E[X^2]$ 。
 - (c) 求 $\text{Var}(X)$, 化简后用 p 表达。
-

D.2.10 (Ch.4, 矩母函数入门) 设 $X \sim \text{Bernoulli}(p)$, 矩母函数 $M_X(t) = E[e^{tX}]$ 。

- (a) 计算 $M_X(t)$ 。
 - (b) 利用 $M'_X(0)$ 求 $E[X]$, 利用 $M''_X(0)$ 求 $E[X^2]$ 。
 - (c) 设 $Y = X_1 + X_2 + \cdots + X_n$ (独立同分布 $\text{Bernoulli}(p)$), 写出 $M_Y(t)$, 并指出 Y 服从何分布。
-

D.2.11 (Ch.5, Beta 分布积分) 设 $X \sim \text{Beta}(2, 3)$, 密度函数 $f(x) = 12x(1-x)^2$, $0 < x < 1$ 。

- (a) 验证 $\int_0^1 12x(1-x)^2 dx = 1$ 。
 - (b) 求 $E[X]$ 和 $E[X^2]$ (直接积分)。
 - (c) 求 $\text{Var}(X)$, 与 $\text{Beta}(\alpha, \beta)$ 方差公式 $\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$ 对比。
-

D.2.12 (Ch.4, 负二项分布) 独立重复伯努利试验, 每次成功概率为 p 。设第 r 次成功所需的总试验次数为 X (负二项分布)。

- 写出 $P(X = k)$, $k = r, r + 1, \dots$ 。
- 当 $r = 1$ 时, 验证退化为几何分布。
- 利用 $E[X] = r/p$ 解释: 平均需要多少次试验才能连续成功 $r = 3$ 次 ($p = 0.5$)。

D.2.13 (Ch.5, 截断分布) 设 $X \sim \text{Exp}(1)$, 观测到 $X \leq 2$ (截断)。设条件随机变量 $Y = (X \mid X \leq 2)$ 。

- 求 Y 的 CDF 和密度函数。
- 求 $E[Y]$ (积分后化简)。
- 与 $E[X] = 1$ 比较, 说明截断后均值的变化方向及原因。

D.2.14 (Ch.6, 二维联合分布协方差) 设 (X, Y) 的联合分布律为:

	$Y = 0$	$Y = 1$
$X = 0$	0.1	0.2
$X = 1$	0.3	0.4

- 求边际分布 $P(X = x)$ 和 $P(Y = y)$ 。
- 判断 X 与 Y 是否独立。
- 求 $\text{Cov}(X, Y)$ 和相关系数 $\rho(X, Y)$ 。

D.2.15 (Ch.6, 二维连续分布的条件密度) 设 (X, Y) 的联合密度为 $f(x, y) = 2$, $0 < x < y < 1$ 。

- 求边际密度 $f_X(x)$ 和 $f_Y(y)$ 。
- 求条件密度 $f_{Y|X}(y \mid x)$ 。
- 求 $E[Y \mid X = x]$, 并验证 $E[E[Y \mid X]] = E[Y]$ 。

Part 3 分布 (Ch.7-9, 共 15 题)

覆盖离散分布族 (Ch.7)、连续分布族 (Ch.8)、多维分布 (Ch.9)。题型: 可加性证明、矩推导、极限近似、条件分布、多元正态及关联分布 (χ^2 、 t 、 F)。重点分布: 泊松 (λ)、几何 (p)、超几何、Gamma(α, β)、对数正态、多项、Dirichlet; 关联: $Z^2 \sim \chi^2(1)$, $Z/\sqrt{V/n} \sim t(n)$, $(U/m)/(V/n) \sim F(m, n)$ 。

D.3.1 (Ch.7, 泊松分布的可加性) 设 $X \sim \text{Poisson}(\lambda_1)$, $Y \sim \text{Poisson}(\lambda_2)$, 且 $X \perp Y$ 。

- 利用概率母函数或矩母函数证明 $X + Y \sim \text{Poisson}(\lambda_1 + \lambda_2)$ 。
- 求 $P(X = k \mid X + Y = n)$, 说明其为二项分布 (超几何结构)。

(c) 在 (b) 中, 当 $\lambda_1 = \lambda_2$ 时, 条件分布的参数是多少?

D.3.2 (Ch.7, 几何分布的矩) 设 $X \sim \text{Geom}(p)$, 即 $P(X = k) = (1-p)^{k-1}p$, $k = 1, 2, \dots$ 。

- (a) 利用矩母函数或生成函数, 证明 $E[X] = 1/p$, $\text{Var}(X) = (1-p)/p^2$ 。
 - (b) 证明无记忆性: $P(X > m+n \mid X > m) = P(X > n)$ 。
 - (c) 证明几何分布在离散非负整值分布中是唯一具有无记忆性的分布 (反向: 若无记忆则为几何)。
-

D.3.3 (Ch.8, 正态分布线性组合) 设 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, $X \perp Y$ 。

- (a) 证明 $aX + bY + c \sim N(a\mu_1 + b\mu_2 + c, a^2\sigma_1^2 + b^2\sigma_2^2)$ 。
 - (b) 令 $Z = X - Y$, 求 Z 的分布参数。
 - (c) 若 $X, Y \sim N(0, 1)$, 求 $P(X > Y)$ (利用 (b) 的结果)。
-

D.3.4 (Ch.8, 伽马分布的性质) 设 $X \sim \text{Gamma}(\alpha, \beta)$, 密度 $f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$, $x > 0$ 。

- (a) 利用 Gamma 函数, 证明 $E[X] = \alpha/\beta$, $E[X^2] = \alpha(\alpha+1)/\beta^2$, $\text{Var}(X) = \alpha/\beta^2$ 。
 - (b) 验证: 当 $\alpha = 1$ 时退化为指数分布 $\text{Exp}(\beta)$ 。
 - (c) 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\beta)$, 证明 $X_1 + \dots + X_n \sim \text{Gamma}(n, \beta)$ (用矩母函数)。
-

D.3.5 (Ch.7, 超几何分布与二项近似) 箱中有 $N = 100$ 个球, 其中 $K = 20$ 个红球, 无放回取 $n = 10$ 个。

- (a) 写出取到恰好 k 个红球的超几何分布公式。
 - (b) 求 $E[X]$ 和 $\text{Var}(X)$ (用超几何分布均值方差公式)。
 - (c) 用二项分布 $B(10, 0.2)$ 近似, 计算 $P(X = 2)$ 的精确值与近似值, 比较误差。
-

D.3.6 (Ch.8, 卡方分布与正态的联系) 设 $Z_1, Z_2, \dots, Z_n \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, $V = \sum_{i=1}^n Z_i^2$ 。

- (a) 利用矩母函数证明 $V \sim \chi^2(n)$ (即 $\text{Gamma}(n/2, 1/2)$)。
 - (b) 求 $E[V]$ 和 $\text{Var}(V)$ 。
 - (c) 设 $\bar{Z} = \frac{1}{n} \sum Z_i$, 证明 $\bar{Z}$ 与 $V' = \sum (Z_i - \bar{Z})^2$ 相互独立 (仅需陈述结论并说明依赖的定理)。
-

D.3.7 (Ch.9, 二维正态分布) 设 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 。

- (a) 写出边际分布 $X \sim N(\mu_1, \sigma_1^2)$ 的推导要点 (积分消去 y)。
 - (b) 证明: 在二维正态分布下, $\rho = 0 \Leftrightarrow X \perp Y$ (利用联合密度可分离)。
 - (c) 求条件分布 $Y \mid X = x$ 的均值和方差 (写出公式, 不推导)。
-

D.3.8 (Ch.8, 对数正态分布) 设 $Y = e^X$, 其中 $X \sim N(\mu, \sigma^2)$ (对数正态分布)。

- (a) 求 Y 的密度函数 (对数正态密度)。
 - (b) 求 $E[Y]$ 和 $\text{Var}(Y)$ (利用正态矩母函数 $E[e^{tX}] = e^{\mu t + \sigma^2 t^2/2}$)。
 - (c) 证明: $\ln Y \sim N(\mu, \sigma^2)$, 即 Y 的对数是正态的。
-

D.3.9 (Ch.7, 二项分布的泊松极限) 设 $X_n \sim B(n, p_n)$, 其中 $np_n \rightarrow \lambda > 0$ 当 $n \rightarrow \infty$ 。

- (a) 证明 $P(X_n = k) \rightarrow \frac{\lambda^k e^{-\lambda}}{k!}$ (利用 Stirling 近似或直接极限)。
 - (b) 举例说明何时该近似误差较小 (n 大、 p 小的条件)。
 - (c) 当 $n = 100$, $p = 0.02$ 时, 用泊松近似计算 $P(X = 0)$ 与精确值, 比较两者差异。
-

D.3.10 (Ch.8, t 分布的推导) 设 $Z \sim N(0, 1)$, $V \sim \chi^2(n)$, 且 $Z \perp V$, 令 $T = Z/\sqrt{V/n}$ 。

- (a) 写出 T 的密度函数 ($t(n)$ 分布, 可查表引用, 不要求推导完整)。
 - (b) 当 $n \rightarrow \infty$ 时, 说明 T 趋向标准正态 (陈述理由)。
 - (c) 说明 t 分布在小样本推断中的核心作用, 举一应用场景。
-

D.3.11 (Ch.9, 多项分布) 将 $n = 12$ 个球随机分配到 3 个盒子, 各盒概率分别为 $p_1 = 1/2$, $p_2 = 1/3$, $p_3 = 1/6$ 。

- (a) 写出 (X_1, X_2, X_3) 的多项分布公式。
 - (b) 求 $E[X_i]$ 和 $\text{Var}(X_i)$ ($i = 1, 2, 3$)。
 - (c) 求 $\text{Cov}(X_1, X_2)$ 并验证 $\text{Cov}(X_i, X_j) = -np_i p_j$ ($i \neq j$)。
-

D.3.12 (Ch.8, F 分布的性质) 设 $U \sim \chi^2(m)$, $V \sim \chi^2(n)$, $U \perp V$, 令 $F = (U/m)/(V/n)$ 。

- (a) 说明 $F \sim F(m, n)$ (F 分布的定义)。
 - (b) 证明: 若 $F \sim F(m, n)$, 则 $1/F \sim F(n, m)$ 。
 - (c) 说明 F 分布与方差齐性检验的联系, 描述单侧检验的拒绝域。
-

D.3.13 (Ch.7, 复合泊松分布) 设车辆事故次数 $N \sim \text{Poisson}(\lambda)$, 每次事故损失 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\mu)$ (独立于 N), 总损失 $S = \sum_{i=1}^N X_i$ (约定 $N = 0$ 时 $S = 0$)。

- (a) 求 $E[S]$ (用重期望)。
 - (b) 求 $\text{Var}(S)$ (用条件方差公式)。
 - (c) 当 $\lambda = 2$, $\mu = 1$ 时, 求 $E[S]$ 和 $\text{Var}(S)$ 的数值。
-

D.3.14 (Ch.8, 混合正态分布) 设 $X | \Theta = \theta \sim N(\theta, 1)$, 而 $\Theta \sim N(0, \tau^2)$ (随机效应)。

- (a) 求 X 的边际分布 (用重期望和全方差公式)。
 (b) 求 $E[X]$ 和 $\text{Var}(X)$ 。
 (c) 求 $\text{Cov}(X, \Theta)$ (利用 $\text{Cov}(X, \Theta) = E[X\Theta] - E[X]E[\Theta]$)。
-

D.3.15 (Ch.9, Dirichlet 分布简介) 设 (X_1, X_2, X_3) 服从 Dirichlet(1, 1, 1) 分布 (即 $[0, 1]^2$ 上的均匀单纯形)。

- (a) 写出联合密度 (在单纯形 $x_1 + x_2 + x_3 = 1, x_i > 0$ 上)。
 (b) 求每个边际分布 ($X_i \sim \text{Beta}(1, 2)$), 写出密度。
 (c) 求 $E[X_i]$ 和 $\text{Var}(X_i)$, 验证与 Dirichlet 均值方差公式一致。
-

Part 4 极限定理 (Ch.10-12, 共 10 题)

覆盖大数定律 (Ch.10)、中心极限定理 (Ch.11)、收敛性理论 (Ch.12)。题型: WLLN/SLLN 条件验证、CLT 近似与 Berry-Esseen、各类收敛的证明与反例、特征函数。收敛关系 (强弱顺序): L^2 收敛 $\Rightarrow$ 依概率收敛; 几乎处处收敛 $\Rightarrow$ 依概率收敛; 依分布收敛最弱。逆向均不成立 (需反例区分)。

D.4.1 (Ch.10, 大数定律验证条件) 设 $X_1, X_2, \dots$ 独立, $P(X_n = \pm n^\alpha) = 1/2$ ($\alpha > 0$)。

- (a) 计算 $E[X_n]$ 和 $\text{Var}(X_n)$ 。
 (b) 确定 α 的范围使得弱大数定律成立 (Chebyshev 条件: $\sum \text{Var}(X_n)/n^2 < \infty$)。
 (c) 当 $\alpha = 1$ 时, $n^{-1} \sum_{i=1}^n X_i \xrightarrow{P} 0$ 是否成立? 给出理由。
-

D.4.2 (Ch.11, CLT 的应用) 某保险公司承保 1000 个独立客户, 每个客户年赔付额均值为 500 元, 标准差为 2000 元。设总赔付额为 S 。

- (a) 用 CLT 近似 $P(S > 550000)$ (写出标准化步骤)。
 (b) 求使 $P(S \leq c) \geq 0.99$ 的最小 c (用 $z_{0.01} \approx 2.326$)。
 (c) 若各客户赔付额实际服从均值相同的指数分布 (方差更大), CLT 近似的准确性如何?
-

D.4.3 (Ch.10, Markov 不等式与 Chebyshev 不等式) 设 $X \geq 0$, $E[X] = \mu$, $\text{Var}(X) = \sigma^2$ 。

- (a) 证明 Markov 不等式: $P(X \geq a) \leq \mu/a$ ($a > 0$)。
 (b) 由 Markov 不等式推导 Chebyshev 不等式: $P(|X - \mu| \geq k\sigma) \leq 1/k^2$ 。
 (c) 对 $X \sim U(0, 1)$, $k = 2$: 计算 Chebyshev 上界, 再精确计算 $P(|X - 0.5| \geq 0.5 \cdot 2/\sqrt{12})$, 比较上界的松紧程度。
-

D.4.4 (Ch.12, 依概率收敛的反例) 构造随机变量序列 $\{X_n\}$, 使得 $X_n \xrightarrow{P} 0$, 但 $E[X_n] \not\rightarrow 0$ 。

- (a) 令 $P(X_n = n) = 1/n$, $P(X_n = 0) = 1 - 1/n$. 计算 $E[X_n]$ 。
 (b) 证明 $X_n \xrightarrow{P} 0$ (定义验证)。
 (c) 说明这个例子的含义: 依概率收敛不保证均值的收敛。
-

D.4.5 (Ch.11, CLT 的 Berry-Esseen 定理应用) 设 $X_i \stackrel{\text{i.i.d.}}{\sim}$, $E[X_i] = 0$, $E[X_i^2] = 1$, $E[|X_i|^3] = \rho < \infty$.
 Berry-Esseen 定理: $\sup_x |P(S_n/\sqrt{n} \leq x) - \Phi(x)| \leq C\rho/\sqrt{n}$ ($C \leq 0.4785$).

- (a) 对 $X_i \sim \text{Bernoulli}(1/2) - 1/2$ (中心化), 求 $\rho = E[|X_i|^3]$.
 (b) 当 $n = 100$ 时, Berry-Esseen 上界为多少?
 (c) 解释 Berry-Esseen 定理的实用意义: n 多大才能使正态近似误差小于 0.01?
-

D.4.6 (Ch.12, 各种收敛关系) 证明或举反例:

- (a) 几乎处处收敛 $\Rightarrow$ 依概率收敛 (证明).
 (b) 依概率收敛 $\nRightarrow$ 几乎处处收敛 (构造反例: 在 $[0, 1]$ 上的“走马灯”序列).
 (c) L^2 收敛 $\Rightarrow$ 依概率收敛 (证明, 利用 Markov 不等式).
-

D.4.7 (Ch.10, 强大数定律) 设 $X_1, X_2, \dots \stackrel{\text{i.i.d.}}{\sim}$, $E[|X_1|] < \infty$, $E[X_1] = \mu$.

- (a) 陈述 Kolmogorov 强大数定律 (SLLN) 的条件和结论.
 (b) 用 SLLN 说明: 若 $X_i \sim \text{Bernoulli}(p)$, 则样本频率 $\bar{X}_n \xrightarrow{\text{a.s.}} p$.
 (c) SLLN 与 WLLN 的结论强弱比较: 哪个结论更强? 给出逻辑关系.
-

D.4.8 (Ch.11, 多维 CLT) 设 $\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{i.i.d.}}{\sim} (\mathbb{R}^d \text{ 值})$, $E[\mathbf{X}_i] = \mu$, $\text{Cov}(\mathbf{X}_i) = \Sigma$.

- (a) 陈述多维 CLT: $\sqrt{n}(\bar{\mathbf{X}} - \mu) \xrightarrow{d} N(\mathbf{0}, \Sigma)$.
 (b) 用 delta 方法: 若 $g: \mathbb{R}^d \rightarrow \mathbb{R}$ 可微, 写出 $\sqrt{n}(g(\bar{\mathbf{X}}) - g(\mu))$ 的渐近分布.
 (c) 对 $d = 1$, $g(x) = x^2$, 具体写出渐近方差 (μ, σ^2 表达).
-

D.4.9 (Ch.12, 特征函数与弱收敛) 设 $X_n \xrightarrow{d} X$. 利用特征函数 (CF) 工具:

- (a) 陈述 Lévy 连续性定理: $X_n \xrightarrow{d} X \Leftrightarrow \varphi_{X_n}(t) \rightarrow \varphi_X(t)$ (逐点).
 (b) 利用 CF 证明 CLT 对 $X_i \sim N(0, 1)$ 是平凡的 (说明 $\varphi_{\bar{X}/\sqrt{n}}$ 的计算).
 (c) 说明为何 CF 方法比直接 CDF 方法更强大 (例: 可处理非对称或重尾分布).
-

D.4.10 (Ch.11, 样本均值的大样本置信区间) 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim}$, $E[X_i] = \mu$, $\text{Var}(X_i) = \sigma^2$ (未知).

- (a) 用 CLT 构造 μ 的近似 95% 置信区间 (用样本标准差 S 替代 σ).

- (b) 若样本为: 2, 5, 3, 7, 4 ($n = 5$), 计算 $\bar{X}$ 和 S , 写出 95% CI 的具体数值。
 (c) 解释: 为何 $n = 5$ 时用 CLT 近似而非 t 分布是不严格的?

Part 5 统计基础 (Ch.13-15, 共 10 题)

覆盖统计量与抽样分布 (Ch.13)、数据描述 (Ch.14)、充分统计量 (Ch.15)。题型: 抽样分布推导、顺序统计量、经验 CDF、因子分解定理、Rao-Blackwell、Bootstrap。核心结论: $\bar{X} \sim N(\mu, \sigma^2/n)$; $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$; $\bar{X} \perp S^2$ (正态总体); $T = (\bar{X} - \mu)/(S/\sqrt{n}) \sim t(n-1)$ 。

D.5.1 (Ch.13, 常见统计量的分布) 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, $\bar{X}$ 为样本均值, $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ 。

- (a) 写出 $\bar{X}$ 的分布, 并证明 $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$ (陈述结论与关键步骤)。
 (b) 写出 $T = (\bar{X} - \mu)/(S/\sqrt{n})$ 的分布 (t 分布, 说明为何自由度 $n-1$)。
 (c) 写出两独立正态总体方差比的 F 统计量及其分布。

D.5.2 (Ch.13, 顺序统计量) 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F(x)$, 密度为 $f(x)$ 。设 $X_{(1)} \leq \dots \leq X_{(n)}$ 为顺序统计量。

- (a) 推导第 k 个顺序统计量 $X_{(k)}$ 的密度函数: $f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1-F(x)]^{n-k} f(x)$ 。
 (b) 对 $X_i \sim U(0, 1)$, 求 $X_{(n)}$ (最大值) 的密度和期望。
 (c) 对 $n = 5$, $k = 3$ (中位数), 写出 $X_{(3)}$ 的密度 ($U(0, 1)$ 情形)。

D.5.3 (Ch.14, 经验分布函数) 设 $x_1, \dots, x_n$ 为样本, 经验 CDF 为 $\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}[x_i \leq x]$ 。

- (a) 证明: 对固定 x , $n\hat{F}_n(x) \sim B(n, F(x))$, 因此 $E[\hat{F}_n(x)] = F(x)$, $\text{Var}(\hat{F}_n(x)) = F(x)(1-F(x))/n$ 。
 (b) 由 SLLN, $\hat{F}_n(x) \xrightarrow{\text{a.s.}} F(x)$ (陈述 Glivenko-Cantelli 定理的结论)。
 (c) 对样本 $\{1, 3, 3, 5, 7\}$ ($n = 5$), 写出 $\hat{F}_5(x)$ 的表达式 (分段函数)。

D.5.4 (Ch.15, 充分统计量的因子分解定理) 设总体密度为 $f(x; \theta)$, 样本 $X_1, \dots, X_n$ 的联合密度为 $\prod_{i=1}^n f(x_i; \theta)$ 。

- (a) 陈述 Neyman-Fisher 因子分解定理: $T(\mathbf{X})$ 是 θ 的充分统计量 $\Leftrightarrow \prod f(x_i; \theta) = g(T(\mathbf{x}), \theta)h(\mathbf{x})$ 。
 (b) 对 $X_i \sim N(\mu, 1)$, 证明 $\bar{X}$ 是 μ 的充分统计量 (写出联合密度分解)。
 (c) 对 $X_i \sim \text{Exp}(\theta)$ (密度 $\theta e^{-\theta x}$), 求 θ 的充分统计量。

D.5.5 (Ch.13, Bootstrap 基本思想) 设样本 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F$, 统计量 $T_n = T(X_1, \dots, X_n)$ 。

- (a) 描述参数 Bootstrap 的步骤: 用 $\hat{F}$ 替代 F , 从 $\hat{F}$ 有放回抽样 B 次, 得到 $T_n^{*(1)}, \dots, T_n^{*(B)}$ 。
 (b) 用 Bootstrap 估计 T_n 的标准误差 (写出公式)。

- (c) 对样本 $\{2, 4, 6, 8\}$ ($n = 4$), 若 $T_n = \bar{X}$, 列出所有可能的 Bootstrap 样本中, $T^* = \bar{X}^*$ 的最小值和最大值。

D.5.6 (Ch.14, Q-Q 图原理) 设理论分布为 F_0 , 样本 $X_1 \leq \dots \leq X_n$ 为顺序统计量。Q-Q 图横轴为理论分位数, 纵轴为样本分位数。

- (a) 若 $X_i \sim F_0$, 则 Q-Q 图大致为直线, 说明其理论依据 (用顺序统计量的近似期望)。
 (b) 若实际分布比 F_0 有更重的尾 (如 t 分布 vs 正态), Q-Q 图会出现何种弯曲?
 (c) 对样本 $\{-1.5, -0.3, 0.1, 0.8, 1.6\}$, 与 $N(0, 1)$ 做 Q-Q 图 (列出理论分位数 $\Phi^{-1}((i - 0.5)/5)$ 对应 $i = 1, \dots, 5$)。

D.5.7 (Ch.15, 完备充分统计量) 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$, $T = \sum X_i$ 。

- (a) 证明 $T \sim \text{Poisson}(n\lambda)$ (可加性)。
 (b) 验证 T 是 λ 的充分统计量 (因子分解定理)。
 (c) 陈述完备性定义, 并说明 T 是否完备 (提示: 指数族的自然参数统计量通常是完备充分的)。

D.5.8 (Ch.13, 抽样分布的数值例) 设总体 $N(5, 4)$ ($\sigma^2 = 4$), 取样本量 $n = 16$ 。

- (a) 求 $P(\bar{X} > 6)$ (标准化后查正态表)。
 (b) 求 $P(S^2 > 6.908)$ (利用 $15S^2/4 \sim \chi^2(15)$, 查表或写出 χ^2 分位数)。
 (c) 若两个独立样本各 $n_1 = n_2 = 10$, 总体方差相同, 写出方差比 S_1^2/S_2^2 的分布。

D.5.9 (Ch.14, 描述统计: 箱线图与异常值) 一组数据: $\{2, 3, 5, 7, 8, 9, 11, 14, 16, 22\}$ ($n = 10$)。

- (a) 计算 Q_1 (第 25 百分位)、 Q_2 (中位数)、 Q_3 (第 75 百分位)。
 (b) 计算 IQR, 并确定异常值的判别界限 ($Q_1 - 1.5 \cdot \text{IQR}$ 和 $Q_3 + 1.5 \cdot \text{IQR}$)。
 (c) 指出数据中的异常值, 并用均值和中位数分别衡量中心, 比较两者对异常值的鲁棒性。

D.5.10 (Ch.15, Rao-Blackwell 定理) 设 T 是参数 θ 的充分统计量, W 是 θ 的任意无偏估计量 ($E_\theta[W] = \theta$)。

- (a) 陈述 Rao-Blackwell 定理: 令 $W^* = E[W | T]$, 则 W^* 也是无偏的且 $\text{MSE}(W^*) \leq \text{MSE}(W)$ 。
 (b) 对 $X_i \sim \text{Bernoulli}(p)$, $W = X_1$ (只用第一个观测), $T = \sum X_i$ 。计算 $W^* = E[X_1 | T = t]$ 。
 (c) 验证 $W^* = T/n = \bar{X}$ 是 p 的 UMVUE (均匀最小方差无偏估计量)。

Part 6 估计 (Ch.16-18, 共 14 题)

覆盖点估计 (Ch.16)、区间估计 (Ch.17)、贝叶斯估计 (Ch.18)。题型: 矩估计、MLE 与不变性、CRB 与有效性、CI 构造与宽度分析、共轭先验、MAP 与正则化联系、EM 算法思想。常用共轭对: Beta-Binomial, Gamma-Poisson, Normal-Normal (均值未知), Dirichlet-Multinomial; CRB: $\text{Var}(\hat{\theta}) \geq 1/I(\theta)$, 其中 $I(\theta) = -E[\partial^2 \log f / \partial \theta^2]$ 。

D.6.1 (Ch.16, 矩估计法) 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Gamma}(\alpha, \beta)$, 均值 α/β , 方差 α/β^2 。

- 用矩估计法, 令样本一阶矩 $= \alpha/\beta$, 样本二阶矩 $= \alpha(\alpha+1)/\beta^2$, 解出 $\hat{\alpha}$ 和 $\hat{\beta}$ (用 $\bar{X}$ 和 $\overline{X^2}$ 表达)。
- 另一种矩估计: 令 $\bar{X} = \alpha/\beta$, $S^2 = \alpha/\beta^2$, 解出 $\hat{\alpha}$ 和 $\hat{\beta}$ (更简洁的形式)。
- 比较两种矩估计的表达, 说明选取哪些总体矩对应哪些样本矩会影响结果 (矩估计的非唯一性)。

D.6.2 (Ch.16, 最大似然估计) 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Uniform}(0, \theta)$, $\theta > 0$ 未知。

- 写出似然函数 $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$ (注意定义域约束 $\theta \geq x_{(n)}$)。
- 求 θ 的 MLE: $\hat{\theta} = X_{(n)}$ (最大顺序统计量)。
- 证明 $\hat{\theta}$ 是有偏的, 求偏差, 并构造一个无偏修正估计量 $\hat{\theta}^*$ 。

D.6.3 (Ch.16, MLE 的不变性) 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$ 。

- 求 μ 和 σ^2 的 MLE ($\hat{\mu} = \bar{X}$, $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$)。
- 利用 MLE 的不变性, 求 $P(X \leq c) = \Phi(\frac{c-\mu}{\sigma})$ 的 MLE。
- 求 σ 的 MLE 的渐近分布 (用 Fisher 信息量 $I(\sigma^2)$ 表达 CRB)。

D.6.4 (Ch.16, Cramér-Rao 下界) 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$, Fisher 信息量 $I(\lambda) = n/\lambda$ 。

- 计算单个样本 X_1 的 Fisher 信息量 $I_1(\lambda)$ (验证为 $1/\lambda$)。
- 写出 λ 的无偏估计量方差的 Cramér-Rao 下界 (CRB)。
- 验证 $\bar{X}$ 的方差 λ/n 达到 CRB, 因此 $\bar{X}$ 是有效估计量。

D.6.5 (Ch.17, 单正态均值的区间估计) 设 $X_1, \dots, X_{25} \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, $\bar{X} = 12.3$, $S = 2.4$, σ 未知。

- 构造 μ 的 95% 置信区间 (用 $t(24)$ 分布, $t_{0.025}(24) \approx 2.064$)。
- 若已知 $\sigma = 2.5$, 改用正态分布 ($z_{0.025} = 1.96$) 构造 95% CI, 比较区间宽度。
- 解释: 样本量 n 增加时, 置信区间宽度如何变化? 若要使宽度减半需增加几倍样本量?

D.6.6 (Ch.17, 方差的区间估计) 设样本 $X_1, \dots, X_{10} \sim N(\mu, \sigma^2)$ (均值未知), $S^2 = 4.5$ 。

- 写出 σ^2 的 95% 置信区间 (用 $\chi^2(9)$ 的上下分位数 $\chi_{0.025}^2(9) \approx 19.02$, $\chi_{0.975}^2(9) \approx 2.70$)。

- (b) 写出 σ (标准差) 的 95% CI (对 (a) 两端开根号)。
 (c) 解释为何方差的 CI 是不对称的, 与均值 CI 的对称性形成对比。
-

D.6.7 (Ch.17, 两正态均值差的区间估计) 两组独立样本: $n_1 = 10$, $\bar{X}_1 = 15$, $S_1^2 = 4$; $n_2 = 12$, $\bar{X}_2 = 13$, $S_2^2 = 5$ 。假设方差相等 (等方差)。

- (a) 计算合并方差 $S_p^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}$ 。
 (b) 构造 $\mu_1 - \mu_2$ 的 95% CI (自由度 $n_1 + n_2 - 2 = 20$, $t_{0.025}(20) \approx 2.086$)。
 (c) 如果不假设方差相等, 改用 Welch-Satterthwaite 近似自由度 (写出公式, 不计算具体值)。
-

D.6.8 (Ch.18, 先验与后验) 设硬币正面概率 $\theta \in [0, 1]$, 取先验 $\theta \sim \text{Beta}(2, 2)$ 。观测 $n = 10$ 次, $k = 7$ 次正面。

- (a) 写出似然 $L(\theta) \propto \theta^7(1-\theta)^3$ 。
 (b) 写出后验 $\theta | k \sim \text{Beta}(9, 5)$ (用 Beta-Binomial 共轭性)。
 (c) 求后验均值、后验众数 (MAP)、95% 后验可信区间的端点 (Beta 分位数, 写出表达式即可)。
-

D.6.9 (Ch.18, 共轭先验族) 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Poisson}(\lambda)$, 取先验 $\lambda \sim \text{Gamma}(\alpha, \beta)$ (率参数化: 密度 $\propto \lambda^{\alpha-1}e^{-\beta\lambda}$)。

- (a) 写出似然 $L(\lambda | \mathbf{x}) \propto \lambda^{\sum x_i} e^{-n\lambda}$ 。
 (b) 推导后验 $\lambda | \mathbf{x} \sim \text{Gamma}(\alpha + \sum x_i, \beta + n)$ (共轭性)。
 (c) 写出后验均值, 解释它是先验均值 α/β 与 MLE $\bar{X}$ 的加权平均。
-

D.6.10 (Ch.16, 正则化与 MAP 的联系) 在线性回归中, 设参数 β 的先验为 $N(\mathbf{0}, \tau^2 \mathbf{I})$, 噪声方差 σ^2 已知。

- (a) 写出 MAP 估计等价于最小化 $\|\mathbf{y} - X\beta\|^2 + \frac{\sigma^2}{\tau^2} \|\beta\|^2$ (推导等价关系)。
 (b) 说明正则化参数 $\lambda = \sigma^2/\tau^2$ 的贝叶斯解释: 先验方差 $\tau^2 \rightarrow \infty$ 对应 $\lambda \rightarrow 0$ (无正则化)。
 (c) 比较 Ridge 回归 (L2 正则化) 与 Lasso (L1 正则化) 对应的先验分布族 (Laplace 先验)。
-

D.6.11 (Ch.17, 比例的区间估计) 调查 $n = 400$ 人, $\hat{p} = 0.6$ 支持某政策。

- (a) 构造 p 的近似 95% CI (正态近似, $z_{0.025} = 1.96$)。
 (b) 确定样本量 n^* , 使 95% CI 的宽度不超过 0.04 (最保守估计: $p = 0.5$)。
 (c) 若用 Wilson 区间代替 Wald 区间, 说明 Wilson 区间在 $\hat{p}$ 接近 0 或 1 时的优势。
-

D.6.12 (Ch.18, 贝叶斯预测分布) 设 $X | \theta \sim N(\theta, 1)$, 先验 $\theta \sim N(0, \tau^2)$ 。观测 $X = x_0$ 。

- (a) 求后验 $\theta | X = x_0$ (正态-正态共轭, 写出后验均值和方差)。
 (b) 求预测分布 $\tilde{X} | X = x_0$ 的分布, 其中 $\tilde{X} | \theta \sim N(\theta, 1)$ (用重期望)。
 (c) 比较预测方差与后验方差, 解释预测方差更大的原因 (额外的采样不确定性)。
-

D.6.13 (Ch.16, EM 算法思想) 设混合高斯分布: 以概率 π 来自 $N(\mu_1, 1)$, 以概率 $1 - \pi$ 来自 $N(\mu_2, 1)$ 。观测样本 $x_1, \dots, x_n$ 。

- (a) 引入潜变量 $Z_i \in \{1, 2\}$, 写出完整数据对数似然 $\ell_c(\theta)$ 。
 (b) E 步: 计算后验 $r_{ik} = P(Z_i = k | x_i, \theta^{(t)})$ (软分配责任)。
 (c) M 步: 最大化 $Q(\theta | \theta^{(t)}) = E[\ell_c | \mathbf{x}, \theta^{(t)}]$, 写出 $\hat{\mu}_k$ 的更新公式 (加权均值)。
-

D.6.14 (Ch.18, Jeffreys 先验) 对参数 θ 的模型 $f(x; \theta)$, Jeffreys 先验 $\pi_J(\theta) \propto \sqrt{I(\theta)}$ ($I(\theta)$ 为 Fisher 信息量)。

- (a) 对 $X \sim \text{Bernoulli}(\theta)$, 计算 $I(\theta) = 1/(\theta(1 - \theta))$, 推导 Jeffreys 先验。
 (b) 说明 Jeffreys 先验是 $\text{Beta}(1/2, 1/2)$ 分布, 与均匀先验 $\text{Beta}(1, 1)$ 比较。
 (c) Jeffreys 先验的重参数不变性: 若 $\phi = g(\theta)$ 是单调变换, 说明 Jeffreys 先验在变换下保持同等性质 (简述原理)。
-

Part 7 假设检验 (Ch.19-21, 共 12 题)

覆盖假设检验基础 (Ch.19)、参数检验 (Ch.20)、非参数检验 (Ch.21)。题型: $z/t/\chi^2/F$ 检验步骤、功效计算、N-P 引理、Wilcoxon 符号秩、ANOVA、独立性 χ^2 、多重检验校正。

D.7.1 (Ch.19, 单均值 z 检验) 某厂声称产品均值 $\mu_0 = 50$, $\sigma = 8$ 已知。抽取 $n = 64$, $\bar{X} = 48.5$ 。

- (a) 建立双侧检验的假设 $H_0: \mu = 50$ vs $H_1: \mu \neq 50$ 。
 (b) 计算检验统计量 z , 在 $\alpha = 0.05$ 下做出决策 ($z_{0.025} = 1.96$)。
 (c) 计算 p 值, 并解释 p 值的含义。
-

D.7.2 (Ch.19, 单均值 t 检验) 某班成绩假设均值 $\mu_0 = 75$, 抽取 $n = 16$, $\bar{X} = 78$, $S = 8$ 。

- (a) 建立单侧检验 $H_0: \mu \leq 75$ vs $H_1: \mu > 75$ 。
 (b) 计算 $T = (\bar{X} - \mu_0)/(S/\sqrt{n})$, 在 $\alpha = 0.05$ 下做决策 ($t_{0.05}(15) \approx 1.753$)。
 (c) 若 μ 的真实值为 80, 求此次检验的功效 β (计算非中心参数 $\delta = (\mu_1 - \mu_0)/(S/\sqrt{n})$, 查非中心 t 表或近似)。
-

D.7.3 (Ch.19, 两类错误与检验的功效) 设 $H_0: \mu = 0$ vs $H_1: \mu = 1$, $X \sim N(\mu, 1)$, 拒绝域为 $X > c$ 。

- (a) 写出第一类错误 $\alpha(c) = P(X > c \mid \mu = 0)$ 的表达式。
 (b) 写出第二类错误 $\beta(c) = P(X \leq c \mid \mu = 1)$ 的表达式。
 (c) 画出 (或描述) $\alpha + \beta$ 随 c 变化的趋势, 说明两类错误不能同时最小化 (但增大 n 可同时减小两者)。

D.7.4 (Ch.20, 方差的 χ^2 检验) 某产品标准差 $\sigma_0 = 2$, 抽取 $n = 25$, $S^2 = 5.8$ 。检验 $H_0: \sigma^2 = 4$ vs $H_1: \sigma^2 > 4$, $\alpha = 0.05$ 。

- (a) 写出检验统计量 $\chi^2 = (n-1)S^2/\sigma_0^2$ 并计算。
 (b) 查 $\chi^2(24)$ 分布的 0.95 分位数 ($\chi_{0.05}^2(24) \approx 36.42$), 做出决策。
 (c) 若改为双侧检验, 写出拒绝域 (需两端分位数 $\chi_{0.025}^2(24)$ 和 $\chi_{0.975}^2(24)$)。

D.7.5 (Ch.20, 两均值 t 检验, 等方差) 两组数据: $n_1 = 8$, $\bar{X}_1 = 20.5$, $S_1^2 = 6$; $n_2 = 10$, $\bar{X}_2 = 18.0$, $S_2^2 = 7$ 。假设等方差, 检验 $H_0: \mu_1 = \mu_2$ vs $H_1: \mu_1 \neq \mu_2$, $\alpha = 0.05$ 。

- (a) 计算合并方差 S_p^2 。
 (b) 计算 t 统计量, 自由度 $df = n_1 + n_2 - 2 = 16$, $t_{0.025}(16) \approx 2.120$, 做出决策。
 (c) 在做双均值检验前, 应先检验等方差假设, 描述 F 检验的步骤。

D.7.6 (Ch.20, 配对 t 检验) 10 名受试者治疗前后血压 (mmHg):

受试者	1	2	3	4	5	6	7	8	9	10
前	120	135	128	142	118	130	125	138	122	131
后	115	129	124	137	120	128	122	134	120	127

- (a) 计算差值 $D_i = \text{前} - \text{后}$, 求 $\bar{D}$ 和 S_D (列出计算步骤)。
 (b) 检验 $H_0: \mu_D = 0$ vs $H_1: \mu_D > 0$, $\alpha = 0.05$, $t_{0.05}(9) \approx 1.833$ 。
 (c) 说明为何配对设计比独立双样本设计更有效率 (减少个体间变异)。

D.7.7 (Ch.19, Neyman-Pearson 引理) 设 $X \sim N(\mu, 1)$, 检验 $H_0: \mu = 0$ vs $H_1: \mu = 1$, 单次观测。

- (a) 写出似然比 $\Lambda(x) = f(x; 1)/f(x; 0)$, 化简后说明拒绝域等价于 $X > c$ 。
 (b) 由 Neyman-Pearson 引理, 这是大小为 α 的最优势检验, 说明“最优势”的含义。
 (c) 若检验为复合 $H_1: \mu > 0$, N-P 引理是否直接适用? 简述一致最优势检验 (UMP) 的存在条件。

D.7.8 (Ch.21, Wilcoxon 符号秩检验) $n = 8$ 个差值 (配对前后): $+3, -1, +5, +2, -4, +1, +6, +2$ 。检验 H_0 : 中位数为 0 (双侧, $\alpha = 0.05$)。

- (a) 对 $|D_i|$ 排序, 然后按原差值正负分配正负秩。

- (b) 计算正秩和 T^+ 和负秩和 T^- 。
- (c) 查 Wilcoxon 符号秩表 ($n = 8, \alpha = 0.05$ 双侧, 临界值 $W = 4$), 做出决策, 并与参数 t 检验比较。

D.7.9 (Ch.20, 单因素方差分析 ANOVA) 三组数据 ($n_i = 5$):

组 1	组 2	组 3
12, 14, 11, 13, 10	20, 22, 19, 21, 18	15, 17, 16, 14, 18

- (a) 计算各组均值 $\bar{X}_1, \bar{X}_2, \bar{X}_3$ 和总均值 $\bar{X}$ 。
- (b) 计算组间 $SS_B = \sum_i n_i(\bar{X}_i - \bar{X})^2$ 和组内 $SS_W = \sum_{i,j} (X_{ij} - \bar{X}_i)^2$, 以及对应均方。
- (c) 计算 $F = MS_B/MS_W$, 查 $F(2, 12)$ 分布的 0.05 分位数 ($F_{0.05}(2, 12) \approx 3.89$), 做出决策。

D.7.10 (Ch.21, 卡方拟合优度检验) 掷骰子 120 次, 各面出现次数: 18, 22, 17, 25, 19, 19。检验骰子是否均匀 ($\alpha = 0.05$)。

- (a) 写出理论频数 (每面期望 20 次) 和检验统计量 $\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$ 。
- (b) 计算 χ^2 统计量, 自由度 $df = 6 - 1 = 5$, $\chi^2_{0.05}(5) \approx 11.07$, 做出决策。
- (c) 解释 p 值的含义, 并讨论若某面期望次数小于 5 时需如何处理 (合并格子)。

D.7.11 (Ch.21, 独立性卡方检验) 调查 200 人, 按性别与是否吸烟列联表如下:

	吸烟	不吸烟	合计
男	60	40	100
女	30	70	100
合计	90	110	200

- (a) 计算各单元格的期望频数 $E_{ij} = R_i C_j / n$ 。
- (b) 计算 χ^2 统计量, $df = (2 - 1)(2 - 1) = 1$, $\chi^2_{0.05}(1) \approx 3.84$, 做出决策。
- (c) 计算 Phi 系数 $\phi = \sqrt{\chi^2/n}$, 解释其作为效应量的含义。

D.7.12 (Ch.19, 多重检验问题) 同时检验 $m = 20$ 个独立假设, 均为真 (H_0 全真), 每个用 $\alpha = 0.05$ 。

- (a) 计算至少出现一次第一类错误 (假阳性) 的概率 (家族误差率 FWER)。
- (b) Bonferroni 校正: 将每个检验的水平调为 $\alpha^* = 0.05/20$, 求 FWER 的上界。
- (c) 若 20 个假设中有 5 个为假, 描述 Benjamini-Hochberg 程序的思路 (控制 FDR), 并说明比 Bonferroni 更宽松的原因。

Part 8 高级主题 (Ch.22-24, 共 12 题)

覆盖信息论基础 (Ch.22)、蒙特卡洛方法 (Ch.23)、概率图模型 (Ch.24)。题型：熵与 KL 散度证明、互信息与信道容量、MC 积分误差、重要性采样、M-H 算法、贝叶斯网络 d-分离、马尔可夫链平稳分布、GP 回归、变分推断 ELBO。

D.8.1 (Ch.22, 信息熵的基本性质) 设离散分布 $p = (p_1, \dots, p_n)$, Shannon 熵 $H(p) = -\sum_i p_i \log p_i$ 。

- 证明 $H(p) \geq 0$ (利用 $p_i \log p_i \leq 0$)。
 - 证明均匀分布最大化熵: $H(p) \leq \log n$ (用 Jensen 不等式, $\log$ 是凹函数)。
 - 计算 Bernoulli(p) 的熵, 求使熵最大的 p , 并验证等于 $\log 2$ 。
-

D.8.2 (Ch.22, KL 散度) 设两个分布 P 和 Q , KL 散度 $D_{KL}(P\|Q) = \sum_i p_i \log(p_i/q_i)$ 。

- 证明 $D_{KL}(P\|Q) \geq 0$ (用 Jensen 不等式, $-\log$ 是凸函数)。
 - 验证 $D_{KL}(P\|Q) = 0 \Leftrightarrow P = Q$ 。
 - 对 $P = \text{Bernoulli}(0.7)$, $Q = \text{Bernoulli}(0.5)$, 计算 $D_{KL}(P\|Q)$ 和 $D_{KL}(Q\|P)$, 验证不对称性。
-

D.8.3 (Ch.22, 互信息与独立性) 设 (X, Y) 的联合分布为 $p(x, y)$, 互信息 $I(X; Y) = \sum_{x, y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$ 。

- 证明 $I(X; Y) = H(X) - H(X | Y) = H(Y) - H(Y | X)$ 。
 - 证明 $I(X; Y) \geq 0$, 等号成立 $\Leftrightarrow X \perp Y$ (用 KL 散度非负性)。
 - 对二元对称信道 ($P(Y = 0 | X = 0) = P(Y = 1 | X = 1) = 1 - \varepsilon$, 输入均匀), 计算 $I(X; Y)$ (信道容量)。
-

D.8.4 (Ch.23, Monte Carlo 积分误差) 用 Monte Carlo 方法估计 $I = \int_0^1 g(x) dx$: $\hat{I}_n = \frac{1}{n} \sum_{i=1}^n g(U_i)$, $U_i \stackrel{\text{i.i.d.}}{\sim} U(0, 1)$ 。

- 证明 $\hat{I}_n$ 是无偏的, $\text{Var}(\hat{I}_n) = \text{Var}(g(U))/n$ 。
 - 由 CLT, $\hat{I}_n$ 的近似 95% CI 为 $\hat{I}_n \pm 1.96\hat{\sigma}/\sqrt{n}$, 其中 $\hat{\sigma}^2 = \frac{1}{n-1} \sum (g(U_i) - \hat{I}_n)^2$ 。对 $g(x) = e^x$ (精确值 $e - 1 \approx 1.718$), 要求 CI 宽度 ≤ 0.01 , 估计需要的样本量。
 - 对比数值积分 (如 Simpson 法则) 与 MC 积分在高维下的精度衰减, 说明 MC 的维度优势。
-

D.8.5 (Ch.23, 重要性采样) 设目标函数 $g(x)$, 目标分布 $p(x)$, 用提议分布 $q(x)$ 采样, 重要性采样估计 $E_p[g(X)] = E_q[g(X) \frac{p(X)}{q(X)}]$ 。

- 证明重要性采样估计量 $\hat{I}_{IS} = \frac{1}{n} \sum_{i=1}^n g(X_i) w(X_i)$ 是无偏的, 其中权重 $w(x) = p(x)/q(x)$, $X_i \sim q$ 。
 - 写出 $\text{Var}(\hat{I}_{IS})$ 的表达式, 说明当 $q \propto |g|p$ 时方差最小 (最优提议分布)。
 - 描述自归一化重要性采样 (SNIS) 的步骤, 说明在 p 不可归一化时的优势。
-

D.8.6 (Ch.23, Metropolis-Hastings 算法) 目标分布 $\pi(x) \propto e^{-x^2/2}$ (标准正态), 提议分布 $q(x' | x) = \text{Uniform}(x - \delta, x + \delta)$ 。

- 写出 M-H 接受率 $\alpha(x, x') = \min\left(1, \frac{\pi(x')q(x|x')}{\pi(x)q(x'|x)}\right)$, 化简 (由于 q 对称, 接受率简化为 $\min(1, \pi(x')/\pi(x))$)。
 - 验证 M-H 满足细致平衡条件 $\pi(x)\alpha(x, x')q(x' | x) = \pi(x')\alpha(x', x)q(x | x')$ 。
 - 讨论步长 δ 对混合速度的影响: δ 过大或过小各有什么问题? 最优 δ 使接受率约为多少?
-

D.8.7 (Ch.24, 贝叶斯网络的条件独立性) 设贝叶斯网络: $A \rightarrow C \leftarrow B, C \rightarrow D$ (V 形结构加链)。

- 写出联合分布的分解: $P(A, B, C, D) = P(A)P(B)P(C | A, B)P(D | C)$ 。
 - 在不观测 C 时, 证明 $A \perp B$ (C 是 collider, 未观测时阻断)。
 - 若观测 $C = c$, 说明 A 和 B 不再独立 (explaining away 效应), 举例说明。
-

D.8.8 (Ch.24, 马尔可夫链基本性质) 设有限状态马尔可夫链, 状态空间 $\{1, 2, 3\}$, 转移矩阵 $P = \begin{pmatrix} 0.7 & 0.2 & 0.1 \\ 0.3 & 0.5 & 0.2 \\ 0.1 & 0.3 & 0.6 \end{pmatrix}$ 。

- 验证每行之和为 1 (随机矩阵验证)。
 - 求平稳分布 π : 解线性方程组 $\pi P = \pi, \pi \mathbf{1} = 1$ 。
 - 说明此马尔可夫链是否遍历 (不可约且非周期), 并说明遍历性保证 $P^n \rightarrow \mathbf{1}\pi^\top$ (收敛到平稳分布)。
-

D.8.9 (Ch.22, 最大熵原理) 设离散随机变量 $X \in \{1, 2, \dots, n\}$, 约束为 $E[X] = \mu$ (给定均值)。

- 用 Lagrange 乘数法最大化 $H(p) = -\sum p_i \log p_i$, 约束 $\sum p_i = 1$ 和 $\sum i \cdot p_i = \mu$, 得到最大熵分布 $p_i \propto e^{\lambda i}$ (几何分布族)。
 - 当约束为 $E[X] = \mu$ 且 $\text{Var}(X) = \sigma^2$ (连续情形), 最大熵分布为正态分布 (陈述结论, 不推导)。
 - 解释最大熵原理的统计物理含义 (信息量最少假设的先验选择)。
-

D.8.10 (Ch.23, 变分推断基本思想) 目标: 近似后验 $p(\mathbf{z} | \mathbf{x})$, 用参数族 $q_\phi(\mathbf{z})$ 近似, 最小化 $D_{KL}(q_\phi \| p(\mathbf{z} | \mathbf{x}))$ 。

- 推导证据下界 (ELBO): $\mathcal{L}(\phi) = E_q[\log p(\mathbf{x}, \mathbf{z})] - E_q[\log q_\phi(\mathbf{z})]$, 使得 $\log p(\mathbf{x}) \geq \mathcal{L}(\phi)$ 。
 - 说明最大化 ELBO 等价于最小化 $D_{KL}(q_\phi \| p(\mathbf{z} | \mathbf{x}))$ (推导等价关系)。
 - 对均场近似 $q(\mathbf{z}) = \prod_i q_i(z_i)$, 写出坐标上升 VI 的更新公式 $\log q_j^*(z_j) = E_{-j}[\log p(\mathbf{x}, \mathbf{z})] + \text{const}$ 。
-

D.8.11 (Ch.24, 隐马尔可夫模型前向算法) 设 HMM 有隐状态 $\{S_1, S_2\}$, 初始分布 π , 转移矩阵 A , 发射矩阵 B , 观测序列 $O = (o_1, o_2, o_3)$ 。

- 定义前向变量 $\alpha_t(i) = P(o_1, \dots, o_t, S_t = i | \lambda)$, 写出初始化和递推公式。
- 用前向变量表达似然 $P(O | \lambda) = \sum_i \alpha_T(i)$ (求和消去最终隐状态)。

(c) 与暴力枚举所有路径 (2^T 条路径) 相比, 前向算法的计算复杂度是多少 ($O(N^2T)$), 解释其动态规划本质。

D.8.12 (Ch.24, 高斯过程回归简介) 设高斯过程 $f \sim \mathcal{GP}(m(\cdot), k(\cdot, \cdot))$, 观测 $\mathbf{y} = f(\mathbf{X}) + \varepsilon$, $\varepsilon \sim N(\mathbf{0}, \sigma_n^2 \mathbf{I})$ 。

- (a) 写出观测向量 $\mathbf{y}$ 的边际分布 (多元正态, 均值和协方差矩阵)。
- (b) 写出后验预测分布 $f^* | \mathbf{X}, \mathbf{y}, \mathbf{x}^*$ 的均值和方差公式 (GP 回归的闭式后验)。
- (c) 说明 GP 回归与核岭回归 (kernel ridge regression) 的等价性 (在贝叶斯视角下, 预测均值与 KRR 解一致)。

汇总

难度定位: D 级 (中等) 介于 C 级 (基础, 单步套公式) 与 E 级 (综合, 多知识点融合/研究生考题) 之间。本题库各 Part 均匀分布多步计算、简单证明、应用题与反例构造四类题型, 适合系统复习和课后专项训练。

Part	章节	题数
Part 1 概率基础	Ch.1-3	12
Part 2 随机变量	Ch.4-6	15
Part 3 分布	Ch.7-9	15
Part 4 极限定理	Ch.10-12	10
Part 5 统计基础	Ch.13-15	10
Part 6 估计	Ch.16-18	14
Part 7 假设检验	Ch.19-21	12
Part 8 高级主题	Ch.22-24	12
合计		100

高级题库 E (60 题)

难度: ★★★★★—完整证明 / 综合应用 / 跨章融合 / ML 实战。每题 15-30 分钟。适合考研冲刺、工程师面试、深入研究。

Part 1 概率基础 (Ch.1-3, 共 6 题)

E.1.1 (Ch.2, 贝叶斯多次更新 + 复制性危机) 某医学诊断试验灵敏度 (sensitivity) $P(+|D) = 95\%$ 、特异度 (specificity) $P(-|\bar{D}) = 90\%$ 、疾病基础发病率 (先验) $P(D) = 0.5\%$ 。将阳性检测结果记为事件 $+$, 患病记为事件 D 。

- (a) 一次阳性结果后, 用完整贝叶斯公式展开写出 $P(D|+)$, 注意分母 $P(+)=P(+|D)P(D)+P(+|\bar{D})P(\bar{D})$ 各项的含义;
- (b) 以 (a) 的后验作为新的先验, 患者再次独立接受同一检测并再次为阳性, 用链式贝叶斯更新求二次阳性后的患病概率 $P(D|++)$;
- (c) 固定灵敏度 $s=0.95$ 、特异度 $t=0.90$, 令先验 $\pi \rightarrow 0$, 证明 $P(D|+) \rightarrow 0$, 并以 $\pi=0.001$ 数值说明假阳性率 (FPR in PPV sense) 的严重程度;
- (d) 解释为何“ p 值 < 0.05 ”不等价于“ H_0 为真的概率 $< 5\%$ ”——用本题结构类比: p 值是 $P(\text{数据}|H_0)$, 而研究者想要的是 $P(H_0|\text{数据})$, 说明两者差距的决定因素 (先验、功效、发表偏倚)。

E.1.2 (Ch.1+Ch.3, 容斥原理 + 概率的包含-排除 + 组合证明) 设事件 $A_1, A_2, \dots, A_n$ 满足 $P(A_i)=p$ (对所有 i), 且任意两两独立 (pairwise independent)。将容斥公式与指数生成函数相结合, 可以精确分析“至少一个事件发生”的概率。

- (a) 用容斥原理写出 $P(\bigcup_{i=1}^n A_i)$ 的精确展开式 (含 $\binom{n}{k}p^k(1-p)^{n-k}$ 型项), 并化简为 $1-(1-p)^n$;
- (b) 证明: 当 $n \rightarrow \infty$ 、 $np \rightarrow \lambda$ 时, $1-(1-p)^n \rightarrow 1-e^{-\lambda}$, 并给出收敛速率的上界 (利用不等式 $|1-(1-p)^n-(1-e^{-\lambda})| \leq \lambda^2/n$ 的推导框架);
- (c) 生日问题: n 人中至少两人同天生日的概率 $P_n = 1 - \frac{365!}{365^n(365-n)!}$ ——推导泊松近似 $P_n \approx 1 - e^{-(n/2)/365}$, 计算 $n=23$ 时精确值与近似值, 量化误差 (精确到小数点后三位);
- (d) 推广至“至少三人同天生日”: 定义事件 B_{ijk} (第 i, j, k 人同天), 推导 $P(\exists \text{ 三人同天}) = 1 - P(\text{至多两人同天})$ 的递推结构, 建立方程并分析临界人数 (给出不等式框架, 结论约为 $n \approx 88$)。

E.1.3 (Ch.2, 条件独立性 + Simpson 悖论 + 因果推断) 某临床试验按病情轻重分层, 数据如下 (Simpson 悖论的经典数值示例):

分组	治疗组康复	治疗组总数	对照组康复	对照组总数
轻症	81	87	234	270
重症	192	263	55	80
合计	273	350	289	350

(注: 数字来自 Charig et al., 1986 肾结石手术研究。)

- (a) 分别计算轻症组、重症组、合计三种情形下治疗组与对照组的康复率（保留三位有效数字），并对比方向；
- (b) 用不等式符号明确表述 Simpson 悖论： $P(R|T, Z = \text{轻}) > P(R|\bar{T}, Z = \text{轻})$ 且 $P(R|T, Z = \text{重}) > P(R|\bar{T}, Z = \text{重})$ ，但 $P(R|T) < P(R|\bar{T})$ ，证明三个不等式均成立；
- (c) 用全概率公式 $P(R|T) = P(R|T, Z = \text{轻})P(Z = \text{轻}|T) + P(R|T, Z = \text{重})P(Z = \text{重}|T)$ 推导：悖论的根源在于分层样本比例 $P(Z|T) \neq P(Z|\bar{T})$ （混淆变量 Z 与处理 T 相关），量化各项数值验证等式；
- (d) 从 Pearl 的 do-calculus 因果推断角度分析： $P(R|T)$ （观测）与 $P(R|do(T))$ （干预）的区别是什么？为什么后者才是“治疗效果”的正确定义？说明后门准则（Backdoor Criterion）如何通过 Z 的调整给出无偏因果效应估计。

E.1.4 (Ch.3, Borel 悖论 + 条件概率的测度论本质) 设 (X, Y) 在单位圆盘 $\mathcal{D} = \{(x, y) : x^2 + y^2 \leq 1\}$ 上均匀分布，其联合密度 $f(x, y) = 1/\pi$ 。同一几何点可用直角坐标 (X, Y) 或极坐标 (R, Θ) 描述，但对零测度集的条件化结果依赖坐标选取，这正是 Borel 悖论的核心。

- (a) 写出直角坐标联合密度 $f_{X,Y}(x, y)$ 与极坐标联合密度 $f_{R,\Theta}(r, \theta)$ （用 Jacobian r 推导），验证两者积分均为 1；
- (b) 在直角坐标下，对零测度集 $\{X = 0\}$ 的条件化：推导条件密度 $f_{Y|X}(y|0)$ （在 $[-1, 1]$ 上均匀分布，写出推导过程）；
- (c) 在极坐标下，对零测度集 $\{\Theta = \pi/2\}$ 的条件化（即“点在正 y 轴方向的射线上”）：推导条件密度 $f_{R|\Theta}(r|\pi/2)$ （写出 $f_{R|\Theta} \propto r$ ，即在 $[0, 1]$ 上不均匀）；
- (d) 集合 $\{X = 0\} \cap \mathcal{D}$ 与 $\{\Theta = \pi/2\} \cap \mathcal{D}$ 在几何上是同一条线段，但条件分布不同——精确计算两个条件分布并对比；解释 Borel 悖论的实质（条件化方式不同 $\Rightarrow$ 极限过程不同），并说明 Kolmogorov 正则条件概率（Regular Conditional Probability）通过 σ -代数的概念如何给出唯一一致的定义。

E.1.5 (Ch.2+Ch.3, 全概率公式 + 组合计数 + 递推) Pólya 瓮模型（Pólya Urn Scheme）：坛子初始含 r 个红球和 b 个蓝球，每次随机取出一球观察颜色后放回并额外加入 c 个同色球（ $c \geq 1$ ）。这是强化学习（preferential attachment）和贝叶斯非参数统计的基础模型。

- (a) 设 $p_n = P(\text{第 } n \text{ 次取红})$ ，对 $n = 1$ 显然有 $p_1 = r/(r + b)$ ；用全概率公式对 $n = 2$ 显式计算 p_2 ，然后用数学归纳法证明 $p_n = r/(r + b)$ 对所有 $n \geq 1$ 成立（关键步骤：条件于第 $n - 1$ 次结果）；
- (b) 推导前 n 次中恰好取到 k 次红球的 Pólya 分布 PMF：利用对称性，每种包含 k 次红、 $n - k$ 次蓝的序列概率相同，写出公式 $P(S_n = k) = \binom{n}{k} \frac{r^{(k)} b^{(n-k)}}{(r+b)^{(n)}}$ ，其中 $a^{(m)} = a(a+c)(a+2c)\cdots(a+(m-1)c)$ 为上升阶乘；
- (c) 设 $\hat{p}_n = S_n/n$ 为红球比例，用鞅收敛定理（ $\hat{p}_n$ 是有界鞅）证明 $\hat{p}_n \xrightarrow{a.s.} \hat{p}_\infty$ ，并证明 $\hat{p}_\infty \sim \text{Beta}(r/c, b/c)$ （提示：计算矩 $E[\hat{p}_n^m]$ 并取极限）；
- (d) 将 Pólya 瓮推广到 K 色球（对应 Dirichlet 过程）：解释“中国餐馆过程”与 Pólya 瓮的等价性，以及在 NLP 的 n -gram 语言模型中 Pólya 瓮如何描述词频的幂律（Zipf 定律）分布。

E.1.6 (Ch.1+Ch.2+Ch.3, 概率不等式 + 生日碰撞 + 密码学应用) “生日攻击” (Birthday Attack) 是密码学中的经典问题: 在输出空间大小为 m 的 Hash 函数中, 攻击者随机查询 n 次, 寻找两次输出相同的碰撞。设各次查询独立均匀地落在 $\{1, \dots, m\}$ 中。

- 精确写出 n 次查询无碰撞的概率: $P(\text{无碰撞}) = \prod_{k=0}^{n-1} (1 - \frac{k}{m}) = \frac{m(m-1)\cdots(m-n+1)}{m^n}$, 并推导近似 $P(\text{无碰撞}) \approx e^{-n(n-1)/(2m)}$ (利用 $\ln(1-x) \approx -x$);
- 用 Union Bound 给出碰撞概率上界 $P(\text{至少一次碰撞}) \leq \binom{n}{2}/m$, 分析何时该上界与精确值接近 ($n \ll m$ 时);
- 令每对 (i, j) ($i < j$) 碰撞的事件为 B_{ij} , 设 $\lambda = \binom{n}{2}/m$, 用 Poisson 近似说明碰撞次数近似 $\text{Poisson}(\lambda)$, 从而 $P(\text{至少一次碰撞}) \approx 1 - e^{-\lambda}$; 推导使 $P \geq 0.5$ 的 n 约为 $\sqrt{2m \ln 2}$;
- 密码学应用: 对 SHA-256 ($m = 2^{256}$), 代入 $n \approx \sqrt{2 \cdot 2^{256} \cdot \ln 2} \approx 2^{128}$ ——推导此数量级, 说明为何 256 位哈希安全性等价于 128 位的碰撞抵抗 (生日界), 并讨论量子计算 (Grover 算法) 对该界的影响 ($n_{\text{quantum}} \approx 2^{85.3}$)。

Part 2 随机变量 (Ch.4-6, 共 8 题)

E.2.1 (Ch.5+Ch.6, 函数变换 + 卷积 + CLT 预热) 设 X, Y i.i.d. $\sim U(0, 1)$, 令 $Z = X + Y$ 。卷积公式 $f_Z(z) = \int f_X(x)f_Y(z-x)dx$ 是求和分布的基本工具, 本题从二元推广到 n 元并联系中心极限定理。

- 用卷积公式推导 $f_Z(z)$ 的分段表达式 ($z \in [0, 1]$ 和 $z \in (1, 2]$ 两段), 验证积分为 1, 画出 (描述) 密度函数的三角形形状;
- Irwin-Hall 分布: $S_n = \sum_{i=1}^n X_i$, 密度 $f_{S_n}(x) = \frac{1}{(n-1)!} \sum_{k=0}^{\lfloor x \rfloor} (-1)^k \binom{n}{k} (x-k)^{n-1}$ ——用矩母函数 $M_X(t) = (e^t - 1)/t$ 证明 $M_{S_n}(t) = [(e^t - 1)/t]^n$, 由此推导 $E[S_n] = n/2$ 和 $\text{Var}(S_n) = n/12$;
- 对 $n = 12$: $S_{12} - 6$ 的均值为 0、方差为 1, 且由 CLT 近似服从 $N(0, 1)$ ——计算实际与正态分布在 ± 3 处的 CDF 误差, 解释为何历史上 (Irwin, 1927) 用此方法生成“近似正态”随机数, 以及 Box-Muller 方法为何更精确;
- 写出伪代码 (Python 风格): 对 $n = 12, 100, 1000$, 各生成 10^5 个样本, 用 Kolmogorov-Smirnov 统计量量化与标准正态的距离, 并作图 (描述直方图形态), 说明尾部 ($|z| > 3$) 的拟合误差来源于 $U(0, 1)$ 的有界支撑。

E.2.2 (Ch.4, 生成函数 + 概率母函数 + 分支过程) Galton-Watson 分支过程是研究种群增长、病毒传播和语言模型生成的经典模型: $Z_0 = 1$, 第 n 代每个个体独立产生后代数, 分布为 $\{p_k\}_{k \geq 0}$, 均值 μ , 方差 σ^2 , 概率母函数 (PGF) $G(s) = \sum_{k=0}^{\infty} p_k s^k$ ($s \in [0, 1]$)。

- (a) 利用 PGF 的嵌套性质 $G_{Z_n}(s) = G_{Z_{n-1}}(G(s))$, 用数学归纳法证明 $E[Z_n] = \mu^n$; 再对 PGF 求二阶导, 推导 $\text{Var}(Z_n) = \sigma^2 \mu^{n-1}(\mu^n - 1)/(\mu - 1)$ ($\mu \neq 1$, 含 $\mu = 1$ 的特殊情形 $\text{Var}(Z_n) = n\sigma^2$);
- (b) 灭绝概率 $q = \lim_{n \rightarrow \infty} P(Z_n = 0)$ 满足不动点方程 $q = G(q)$ ——证明: (i) $G(q) = q$ 在 $[0, 1]$ 内至少有一个根 (介值定理); (ii) $\mu > 1$ 时最小根 $q^* < 1$, $\mu \leq 1$ 时 $q^* = 1$ (分析 $G'(1) = \mu$ 与曲线 $y = G(s)$ 和 $y = s$ 的切点关系);
- (c) 几何分布后代 $p_k = (1-p)p^k$ ($k \geq 0$) 时, $G(s) = (1-p)/(1-ps)$, $\mu = p/(1-p)$ ——显式解方程 $G(q) = q$, 求出 $q = (1-p)/p$ (当 $p > 1/2$, 即 $\mu > 1$ 时), 验证与理论一致;
- (d) 类比到 Transformer 自回归生成: 每个 token 通过注意力机制“影响”后续 token 的条件分布, 可视为信息的“分支传播”——若平均信息影响扇出 $\mu > 1$, 用信息论中的 $\log Z_n \approx n \log \mu$ 增长速率解释“主题漂移” (话题不断衍生子话题), 并讨论温度参数 $T < 1$ (降低 μ) 如何在生成质量与多样性之间权衡。

E.2.3 (Ch.5+Ch.6, 柯西分布 + 无期望 + 稳定分布) 柯西分布是概率论中最重要的“反例”之一: 它有对称密度、峰值明确, 却没有均值和方差, 不满足大数定律, 是 α -稳定分布 ($\alpha = 1$) 的代表。设 X, Y i.i.d. $\sim N(0, 1)$, 令 $C = X/Y$ 。

- (a) 推导 C 的密度函数: 对固定 c , 计算 $P(C \leq c) = P(X/Y \leq c)$, 分 $Y > 0$ 和 $Y < 0$ 两种情形积分, 对 c 求导得 $f_C(c) = \frac{1}{\pi(1+c^2)}$ (完整积分过程, 含分情况合并);
- (b) 证明 $E[|C|] = \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{|c|}{1+c^2} dc = +\infty$ (积分发散), 从而均值 $E[C]$ 不存在 (注意“主值积分 = 0”与“期望存在”的区别);
- (c) 用特征函数证明稳定性: C 的特征函数 $\varphi_C(t) = e^{-|t|}$ (推导过程); 若 C_1, C_2 i.i.d. 柯西, 则 $(C_1 + C_2)/2$ 的特征函数为 $e^{-|t|}$, 故仍为柯西——对比正态情形 $(X_1 + X_2)/\sqrt{2}$ 仍为标准正态, 解释“稳定分布”的定义;
- (d) 在金融风险建模中, 股票日收益率的尾部往往比正态更“肥”(fat-tailed): 正态假设下 5σ 事件概率约 10^{-7} , 而柯西假设下约 10^{-4} (差 3 个数量级)——定量计算并解释 2008 年金融危机中“ 25σ 事件”的荒谬性, 以及为何稳定分布族 (含正态与柯西) 是重尾建模的自然选择。

E.2.4 (Ch.4+Ch.6, 多项分布 + 协方差结构 + Softmax 梯度 + LDA) 设 $(X_1, \dots, X_d) \sim \text{Multinomial}(n, \mathbf{p})$, 其中 $\mathbf{p} = (p_1, \dots, p_d)$, $\sum_i p_i = 1$, $\sum_i X_i = n$ 。多项分布是 softmax 分类器输出的自然概率模型。

- (a) 用矩母函数 $M(\mathbf{t}) = (\sum_i p_i e^{t_i})^n$ 推导 $E[X_i] = np_i$, $\text{Var}(X_i) = np_i(1-p_i)$, 以及 $\text{Cov}(X_i, X_j) = -np_i p_j$ ($i \neq j$);
- (b) 协方差矩阵 $\Sigma = n(\text{diag}(\mathbf{p}) - \mathbf{p}\mathbf{p}^\top)$: 证明其半正定性 (对任意向量 $\mathbf{v}$, $\mathbf{v}^\top \Sigma \mathbf{v} = n[\sum_i p_i v_i^2 - (\sum_i p_i v_i)^2] \geq 0$, 用 Jensen 不等式);
- (c) 证明 Σ 奇异 (秩为 $d-1$): 因 $\mathbf{1}^\top \mathbf{X} = n$ 为常数, $\Sigma \mathbf{1} = \mathbf{0}$ ——在神经网络 softmax 输出层中, 这意味着 logit 的梯度有一个自由度冗余 (加常数不改变 softmax), 解释为何实践中常固定一个 logit 为 0 (参照类别) 或用 cross-entropy 梯度 $\partial \mathcal{L} / \partial z_i = \hat{p}_i - y_i$ (其中 $\sum y_i = 1$) 自动处理此奇异性;

- (d) 贝叶斯分类：先验 $\mathbf{p} \sim \text{Dir}(\alpha)$ ，观测 $\mathbf{n} = (n_1, \dots, n_d)$ 个各类样本，后验 $\mathbf{p}|\mathbf{n} \sim \text{Dir}(\alpha + \mathbf{n})$ ——写出后验 MAP 估计（拉普拉斯平滑），解释 LDA 中每个文档的主题分布 $\theta_d \sim \text{Dir}(\alpha)$ 与每个主题的词分布 $\phi_k \sim \text{Dir}(\beta)$ 如何形成两层共轭结构，以及 Dirichlet 参数 α 如何控制主题分布的稀疏程度。

E.2.5 (Ch.5+Ch.6, 次序统计量 + 极值理论 + Max-Pooling 梯度) 设 $X_1, \dots, X_n$ i.i.d. $\sim F(x)$ (连续分布, 密度 $f(x)$), 次序统计量 $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ 。极值理论 (EVT) 是可靠性工程、气候科学和深度学习分析的共同数学基础。

- (a) 推导第 k 次序统计量的精确密度: $f_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1 - F(x)]^{n-k} f(x)$ (组合解释: 有 $\binom{n}{k-1}$ 种方式让恰好 $k-1$ 个值小于 x , $n-k$ 个值大于 x , 第 k 个值等于 x);
- (b) 对 $X_i \sim U(0, 1)$, 将 (a) 的密度与 Beta($k, n-k+1$) 的密度对比, 证明两者一致 (利用 Beta 函数 $B(a, b) = (a-1)!(b-1)!/(a+b-1)!$ 的整数情形);
- (c) Fisher-Tippett-Gnedenko 定理 (极值定理): 对 $X_i \sim \text{Exp}(1)$, 最大值 $M_n = X_{(n)}$ 满足 $(M_n - \ln n) \xrightarrow{d} \text{Gumbel}(0, 1)$ ——推导: 首先计算 $P(M_n - \ln n \leq t) = [F(\ln n + t)]^n = (1 - e^{-\ln n - t})^n = (1 - e^{-t}/n)^n \rightarrow e^{-e^{-t}}$;
- (d) Max-pooling 梯度分析: 设池化窗口内有 n 个激活值 $a_1, \dots, a_n$ i.i.d. $\sim F$, 最大值 $a_{(n)}$ 的梯度为 1, 其余 $n-1$ 个梯度为 0——精确计算在反向传播中“梯度为零”的神经元比例期望 $(n-1)/n$, 并用极值分布分析当网络层数 L 增加时, 梯度信号通过 L 层 max-pooling 后的衰减规律 (稀疏梯度问题)。

E.2.6 (Ch.5+Ch.6, 变量变换 + Jacobian + 正规化流) 设二维随机向量 $\mathbf{X} = (X_1, X_2)^\top \sim N(0, \Sigma)$, $\Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}$, $|\rho| < 1$ 。变量变换 (Jacobian 公式) 是推导复杂分布与理解生成模型的核心工具。

- (a) 写出 $\mathbf{X}$ 的联合密度 $f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{2\pi\sqrt{1-\rho^2}} \exp\left(-\frac{x_1^2 - 2\rho x_1 x_2 + x_2^2}{2(1-\rho^2)}\right)$, 配方后推导条件密度 $f_{X_2|X_1}(x_2|x_1)$, 证明其为 $N(\rho x_1, 1 - \rho^2)$ (线性回归的概率解释: $E[X_2|X_1 = x_1] = \rho x_1$, 回归系数即相关系数);
- (b) 令 $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$ ($\mathbf{A} \in \mathbb{R}^{2 \times 2}$ 可逆): 用 Jacobian 公式 $f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})) \cdot |\det \mathbf{A}|^{-1}$ 推导 $\mathbf{Y}$ 的分布, 验证 $\mathbf{Y} \sim N(\mathbf{b}, \mathbf{A}\Sigma\mathbf{A}^\top)$;
- (c) 正规化流: 基分布 $\mathbf{Z} \sim N(0, \mathbf{I}_d)$, 可逆变换 $\mathbf{x} = g(\mathbf{z})$ (g 可微且 $J_g = \partial g / \partial \mathbf{z}$ 可逆), 推导变换后分布的对数密度: $\log p_{\mathbf{X}}(\mathbf{x}) = \log p_{\mathbf{Z}}(g^{-1}(\mathbf{x})) - \log |\det J_g(g^{-1}(\mathbf{x}))|$, 并解释此公式如何用于流模型的训练 (最大化 $\sum_i \log p_{\mathbf{X}}(\mathbf{x}_i)$);
- (d) RealNVP 仿射耦合层: 将 $\mathbf{z}$ 分为两半 $(\mathbf{z}_1, \mathbf{z}_2)$, 变换为 $\mathbf{x}_1 = \mathbf{z}_1$, $\mathbf{x}_2 = \mathbf{z}_2 \odot \exp(s(\mathbf{z}_1)) + t(\mathbf{z}_1)$ ——证明此变换可逆, 计算 Jacobian 行列式 (上三角结构, 行列式为对角元之积), 解释为何 $\det J = \prod_i \exp(s_i(\mathbf{z}_1))$ 的计算仅需 $O(d)$ 时间, 且神经网络 s, t 无需可逆。

E.2.7 (Ch.4+Ch.5, 矩生成函数 + Chernoff 界 + 鞍点近似) 矩生成函数 (MGF) $M_X(t) = E[e^{tX}]$ (当存在时) 是导出精确尾概率界的关键工具。Chernoff 界是机器学习理论 (PAC 学习、泛化界) 的基础。

- (a) 证明独立性 $\Rightarrow$ MGF 可乘: 若 $X_1, \dots, X_n$ i.i.d., $M_{S_n}(t) = [M_X(t)]^n$ (用独立性的期望可分解性), 并推导累积量生成函数 (CGF) $K(t) = nK_X(t)$ 的线性性;
- (b) 推导 Chernoff 界: 对任意 $t > 0$, $P(S_n \geq na) = P(e^{tS_n} \geq e^{tna}) \leq e^{-tna} M_{S_n}(t) = e^{n[K_X(t) - ta]}$, 对 t 最小化得 $P(S_n \geq na) \leq e^{-nI(a)}$, 其中 $I(a) = \sup_t [ta - K_X(t)]$ 为 Legendre 变换; 对 $X \sim \text{Bernoulli}(p)$, $M_X(t) = 1 - p + pe^t$, 显式计算 $I(a) = a \ln(a/p) + (1-a) \ln((1-a)/(1-p))$ (KL 散度形式);
- (c) 证明 $K''(t) = \text{Var}(X_t) > 0$ (其中 X_t 服从倾斜分布 $\propto e^{tx} f(x)$), 因此 $K(t)$ 是严格凸函数, 确保 Legendre 变换 $I(a)$ 的唯一鞍点;
- (d) 鞍点方程 $K'(\hat{t}) = a$ 的几何含义: $K'(t) = E_{X_t}[X]$ 是倾斜分布均值等于 a 时的倾斜参数——Lugannani-Rice 公式 $P(S_n/n \geq a) \approx \Phi(-w) + \phi(w)(1/w - 1/u)/n^{1/2}$ (其中 w, u 为鞍点的函数) 比 CLT 精度高一阶; 解释 Laplace 近似 (对后验 $\log p(\theta|\mathbf{x}) \approx$ 二阶 Taylor 展开) 与鞍点近似的联系 (鞍点 $= \hat{\theta}_{MAP}$, Hessian $= \mathcal{J}(\hat{\theta})$).

E.2.8 (Ch.4+Ch.5+Ch.6, 复合分布 + 塔性质 + 全方差公式 + 贝尔曼方程) 设 $N \sim \text{Poisson}(\lambda)$, 在给定 $N = n$ 时, $X = \sum_{i=1}^n Y_i$, 其中 Y_i i.i.d. (与 N 独立), $E[Y] = \mu$, $\text{Var}(Y) = \sigma^2$. 此类复合泊松分布在保险精算、神经元放电建模、强化学习中均有应用。

- (a) 用全期望塔性质 (Law of Total Expectation) 计算 $E[X]$: 先写 $E[X|N] = N\mu$ (对固定 N 的线性期望), 再取外层期望 $E[E[X|N]] = \mu E[N] = \lambda\mu$; 类似地, 用 $E[X^2|N] = N\sigma^2 + N^2\mu^2$ 推导 $E[X^2]$;
- (b) 全方差公式: $\text{Var}(X) = E[\text{Var}(X|N)] + \text{Var}(E[X|N])$ ——分别计算 $E[\text{Var}(X|N)] = E[N\sigma^2] = \lambda\sigma^2$ 和 $\text{Var}(E[X|N]) = \text{Var}(N\mu) = \lambda\mu^2$, 得 $\text{Var}(X) = \lambda(\sigma^2 + \mu^2)$; 验证特例 $Y_i \equiv 1$ ($\mu = 1, \sigma^2 = 0$) 退化为泊松;
- (c) Poisson 稀疏化: 令 $Y_i \sim \text{Bernoulli}(p)$, 则 $X = \sum_{i=1}^N Y_i$ 计数 N 次试验中成功次数——用 PGF $G_X(s) = G_N(G_Y(s)) = e^{\lambda(G_Y(s)-1)} = e^{\lambda p(s-1)}$ 证明 $X \sim \text{Poisson}(\lambda p)$ (超泊松/欠泊松的讨论);
- (d) 强化学习贝尔曼方程: 设状态 s , 动作策略 π , 奖励 $R(s, a)$, 转移核 $P(s'|s, a)$, 折扣 $\gamma \in [0, 1)$. 值函数 $V^\pi(s) = E^\pi \left[\sum_{t=0}^{\infty} \gamma^t R_t \mid S_0 = s \right]$ ——用全期望公式 (对第一步动作和下一状态取期望) 严格推导 $V^\pi(s) = E_{a \sim \pi(\cdot|s)} [R(s, a) + \gamma E_{s' \sim P(\cdot|s, a)} [V^\pi(s')]]$ (贝尔曼期望方程), 并解释此递推与 (a)(b) 中塔性质的形式一致性。

Part 3 分布 (Ch.7-9, 共 8 题)

E.3.1 (Ch.7+Ch.8, 指数族 + 充分统计量 + 自然参数) 指数族分布的一般形式为 $p(x|\eta) = h(x) \exp(\eta^\top \mathbf{T}(x) - A(\eta))$, 其中 $A(\eta)$ 为对数配分函数。

- (a) 证明泊松分布 $\text{Poisson}(\lambda)$ 、正态分布 $N(\mu, \sigma^2)$ (双参数)、伽马分布 $\text{Gamma}(\alpha, \beta)$ 均属于指数族, 写出各自的自然参数与充分统计量;
- (b) 证明 $\nabla A(\eta) = E_\eta[\mathbf{T}(X)]$, $\nabla^2 A(\eta) = \text{Cov}_\eta[\mathbf{T}(X)]$ (即 Hessian 为协方差矩阵, 半正定);

- (c) 证明 Fisher 信息矩阵 $\mathcal{I}(\eta) = \nabla^2 A(\eta)$, 从而对指数族, Fisher 信息等于充分统计量的协方差;
- (d) 在神经网络的自然梯度 (Natural Gradient) 下降中, 参数更新方向为 $\mathcal{I}(\theta)^{-1} \nabla_{\theta} \mathcal{L}$ ——解释为何自然梯度比普通梯度在参数空间的曲率信息方面更优越, 以及 K-FAC 近似如何降低 $\mathcal{I}^{-1}$ 的计算成本。

E.3.2 (Ch.8+Ch.9, 多元正态 + 边际化 + 条件分布 + 高斯过程) 设 $\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{pmatrix} \sim N\left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}\right)$ 。

- (a) 证明边际分布 $\mathbf{X}_1 \sim N(\mu_1, \Sigma_{11})$;
- (b) 推导条件分布 $\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2$ 的均值与协方差 (Schur 补公式): $\mu_{1|2} = \mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{x}_2 - \mu_2)$, $\Sigma_{1|2} = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$;
- (c) 说明高斯过程 (GP) 回归的预测公式与 (b) 的联系——给定训练集 $(\mathbf{X}_{\text{train}}, \mathbf{y}_{\text{train}})$, 写出测试点的后验均值与后验方差;
- (d) 分析 GP 回归的计算瓶颈 ($O(n^3)$ 矩阵求逆), 介绍至少两种稀疏 GP 近似方法 (诱导点法、随机特征近似), 并说明其数学原理。

E.3.3 (Ch.7, 负二项分布 + 过度离散 + GLM) 设 $Y \sim \text{NegBin}(r, p)$, 即 Y 为第 r 次成功前失败次数, p 为单次成功概率。

- (a) 写出 PMF, 并证明 $E[Y] = r(1-p)/p$, $\text{Var}(Y) = r(1-p)/p^2$;
- (b) 证明负二项分布可以写成泊松-伽马混合: 若 $Y | \Lambda \sim \text{Poisson}(\Lambda)$, $\Lambda \sim \text{Gamma}(r, p/(1-p))$, 则 Y 的边际分布为 $\text{NegBin}(r, p)$;
- (c) 计数数据中泊松模型假设均值等于方差, 但实际数据常有过度离散 ($\text{Var} > E$)——从 (b) 的混合分布视角解释过度离散的统计根源;
- (d) 在广义线性模型 (GLM) 中, 负二项回归如何建模过度离散? 对比泊松回归, 写出负对数似然损失, 说明 ML 框架下 (如 PyTorch) 实现负二项损失的注意事项 (参数化方式)。

E.3.4 (Ch.8+Ch.9, χ^2 分布 + 卡方检验 + 独立性检验理论) 设 $Z_1, \dots, Z_k$ i.i.d. $\sim N(0, 1)$, 令 $Q = \sum_{i=1}^k Z_i^2 \sim \chi^2(k)$ 。

- (a) 从伽马分布推导 $\chi^2(k)$ 的密度、均值与方差;
- (b) 设 $\mathbf{X} \sim N(\mu, \Sigma)$ (Σ 正定), 证明 $(\mathbf{X} - \mu)^{\top} \Sigma^{-1} (\mathbf{X} - \mu) \sim \chi^2(d)$ (马氏距离的分布);
- (c) 在列联表独立性检验中, Pearson 统计量 $\chi^2 = \sum_{i,j} (O_{ij} - E_{ij})^2 / E_{ij}$ 在 H_0 下渐近 $\chi^2((r-1)(c-1))$ ——用多项式分布的 CLT 给出严格推导框架 (向量化版本);
- (d) 大样本量时卡方检验几乎一定显著 (即使效应量极小), Cramér's V 如何定量效应量? 讨论统计显著性与实践显著性的区别, 并在 ML 特征选择场景中说明如何正确使用卡方检验。

E.3.5 (Ch.8, Beta 分布 + 共轭先验 + 汤普森采样) 设 $\theta \sim \text{Beta}(\alpha, \beta)$, 观测数据中成功 s 次、失败 f 次。

- 证明后验 $\theta|s, f \sim \text{Beta}(\alpha + s, \beta + f)$ (Beta-Bernoulli 共轭);
- 证明 $\text{Beta}(\alpha, \beta)$ 的均值为 $\alpha/(\alpha + \beta)$, 众数为 $(\alpha - 1)/(\alpha + \beta - 2)$ ($\alpha, \beta > 1$), 方差为 $\alpha\beta/[(\alpha + \beta)^2(\alpha + \beta + 1)]$;
- 在多臂老虎机 (Multi-Armed Bandit) 中, 汤普森采样 (Thompson Sampling) 为每个臂维护一个 $\text{Beta}(\alpha_i, \beta_i)$ 后验——每轮从每个后验中采样 $\hat{\theta}_i$, 选择 $\arg \max_i \hat{\theta}_i$ 。证明此策略的贝叶斯最优性 (后验最优臂选择概率);
- 推广到高斯奖励 ($r \sim N(\mu_i, \sigma^2)$): 设计相应的共轭先验-后验对, 并与 UCB 算法比较两种策略在探索-利用权衡上的本质差异。

E.3.6 (Ch.9, Dirichlet 分布 + 多项式后验 + LDA) Dirichlet 分布 $\text{Dir}(\alpha)$ ($\alpha = (\alpha_1, \dots, \alpha_K)$) 定义在概率单纯形 Δ^{K-1} 上。

- 写出密度函数 (含 Beta 函数归一化因子), 计算均值向量 $E[\mathbf{p}] = \alpha/\alpha_0$ ($\alpha_0 = \sum \alpha_k$) 与方差 $\text{Var}(p_k) = \alpha_k(\alpha_0 - \alpha_k)/[\alpha_0^2(\alpha_0 + 1)]$;
- 证明 Dirichlet 分布具有聚集性 (Aggregation): 若将若干类合并, 合并后的边际仍服从低维 Dirichlet;
- 在隐含狄利克雷分配 (LDA) 中, 文档 d 的主题分布 $\theta_d \sim \text{Dir}(\alpha)$, 主题 k 的词分布 $\phi_k \sim \text{Dir}(\beta)$ ——写出 LDA 的完整联合分布, 并给出变分推断的 ELBO 表达式;
- 分析 $\alpha_k < 1$ 与 $\alpha_k > 1$ 分别对文档主题分布形状 (稀疏 vs. 均匀) 的影响, 并解释这在大语言模型 token 分布中的类比意义。

E.3.7 (Ch.8+Ch.9, Wishart 分布 + 多元样本协方差 + 矩阵分布) 设 $\mathbf{X}_1, \dots, \mathbf{X}_n$ i.i.d. $\sim N_p(\mu, \Sigma)$, 样本协方差矩阵 $\mathbf{S} = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}})(\mathbf{X}_i - \bar{\mathbf{X}})^\top$ 。

- 证明 $(n-1)\mathbf{S} \sim W_p(n-1, \Sigma)$ (Wishart 分布), 其中 $W_p(m, \Sigma)$ 的定义为 m 个 $N_p(0, \Sigma)$ 样本的外积之和;
- 计算 $E[\mathbf{S}] = \Sigma$ (无偏性) 与 $E[\mathbf{S}^{-1}] = \Sigma^{-1}/(n-p-2)$ (逆的期望, 要求 $n > p+2$);
- 当 $p \rightarrow \infty$, $p/n \rightarrow \gamma \in (0, 1)$ 时, 样本特征值分布趋向 Marchenko-Pastur 定律——写出该定律的密度公式, 解释为何高维小样本场景中样本协方差矩阵的特征值严重膨胀;
- 在深度学习的协方差估计 (如批归一化) 中, 当批大小 B 远小于特征维度 d 时, 会遇到奇异协方差矩阵——分析解决方案 (正则化、对角近似、低秩近似) 的数学依据。

E.3.8 (Ch.7+Ch.8, 混合分布 + EM 算法 + 模式坍塌) 设观测 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 服从高斯混合模型 (GMM): $p(\mathbf{x}) = \sum_{k=1}^K \pi_k N(\mathbf{x}; \mu_k, \Sigma_k)$, $\sum \pi_k = 1$ 。

- (a) 写出完整数据对数似然 $\log p(\mathbf{X}, \mathbf{Z}|\theta)$ (Z_i 为隐变量——属于哪个分量);
- (b) 推导 EM 算法的 E 步 (后验责任 $r_{ik} = P(Z_i = k|\mathbf{x}_i, \theta^{\text{old}})$) 与 M 步 (更新 μ_k, Σ_k, π_k) 的完整公式;
- (c) 证明 EM 算法单调不降: $\log p(\mathbf{X}|\theta^{\text{new}}) \geq \log p(\mathbf{X}|\theta^{\text{old}})$ (利用 Jensen 不等式与 KL 散度非负性);
- (d) GAN 中的模式坍塌 (Mode Collapse) 与 GMM 的 EM 算法有深刻类比——解释当某个分量 $\pi_k \rightarrow 0$ 时 EM 的退化行为, 并说明 GAN 如何从生成模型角度遭受类似问题, 以及 WGAN 如何通过 Wasserstein 距离缓解之。

Part 4 极限定理 (Ch.10-12, 共 6 题)

E.4.1 (Ch.10, 强大数定律 + Borel-Cantelli 引理 + 几乎处处收敛) 设 $\{X_n\}$ i.i.d., $E[X_1] = \mu$, $E[X_1^4] < \infty$ 。

- (a) 利用 Chebyshev 不等式证明弱大数定律 $\bar{X}_n \xrightarrow{P} \mu$;
- (b) 叙述 Borel-Cantelli 引理 (第一、第二引理), 并证明第一引理 ($\sum P(A_n) < \infty \Rightarrow P(\limsup A_n) = 0$);
- (c) 利用 Borel-Cantelli 引理证明: 在 $E[|X_1|^4] < \infty$ 条件下, $P(|\bar{X}_n - \mu| > \varepsilon \text{ i.o.}) = 0$ (即强大数定律);
- (d) 构造反例说明: 若 $E[|X_1|] = \infty$, 强大数定律可以失效——用正尾概率以 $1/(k(\log k)^2)$ 速率衰减的分布构造反例, 并分析深度学习中梯度消失/爆炸与矩存在性的关联。

E.4.2 (Ch.11+Ch.10, CLT + Berry-Esseen + 非 i.i.d. 推广) 设 $\{X_n\}$ 独立 (非同分布), $E[X_i] = \mu_i$, $\text{Var}(X_i) = \sigma_i^2$, $E[|X_i - \mu_i|^3] = \rho_i < \infty$ 。令 $B_n^2 = \sum_{i=1}^n \sigma_i^2$ 。

- (a) 叙述 Lindeberg 条件, 证明其蕴含 Lindeberg CLT: $(S_n - \sum \mu_i)/B_n \xrightarrow{d} N(0, 1)$;
- (b) 叙述 Berry-Esseen 定理, 给出收敛速率的上界 $C \sum \rho_i/B_n^3$;
- (c) 对批量随机梯度下降 (SGD): 令 X_i 为第 i 个样本的随机梯度 (近似独立), n 为批大小——分析 SGD 梯度噪声的中心极限行为, 以及批大小如何影响梯度近似的质量 (Berry-Esseen 视角);
- (d) 在非平稳数据流 (如在线学习) 中, Lindeberg 条件可能失效——举出具体场景 (如分布偏移), 并分析自适应学习率 (Adam、AdaGrad) 如何隐式地应对梯度分布的变化。

E.4.3 (Ch.11+Ch.12, Delta 方法 + 函数的渐近分布 + Bootstrap) 设 $\hat{\theta}_n$ 为参数 θ 的估计量, $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N(0, \sigma^2)$ 。

- (a) 叙述并证明 Delta 方法: 若 g 在 θ 处可微且 $g'(\theta) \neq 0$, 则 $\sqrt{n}(g(\hat{\theta}_n) - g(\theta)) \xrightarrow{d} N(0, [g'(\theta)]^2 \sigma^2)$;
- (b) 设 $\hat{p}_n = \bar{X}_n$ 为 Bernoulli 样本的频率, $\sigma^2 = p(1-p)$ ——用 Delta 方法推导 $g(p) = \log[p/(1-p)]$ (logit 变换) 的渐近方差, 并给出置信区间 (更优于直接区间的理由);

- (c) Bootstrap 原理：用经验分布 $\hat{F}_n$ 代替真实 F 进行重采样——证明在正则条件下 Bootstrap 分位数估计的一致性（给出直觉性证明框架）；
- (d) 在深度学习不确定性估计中，Deep Ensemble 方法等价于对模型参数的 Bootstrap——分析此类方法的理论基础与局限性，并与 Laplace 近似进行对比。

E.4.4 (Ch.12, 依概率收敛 + 依分布收敛 + 几乎处处收敛的关系) 设 $\{X_n\}$ 与 $\{Y_n\}$ 为随机变量序列， X 为极限随机变量。

- (a) 严格定义四种收敛： L^p 收敛、依概率收敛、几乎处处收敛、依分布收敛，并给出它们之间所有蕴含关系（画关系图）；
- (b) 构造反例：几乎处处收敛不蕴含 L^1 收敛（提示：打字机序列）；
- (c) 构造反例：依概率收敛不蕴含几乎处处收敛（提示：在 $[0, 1]$ 上的游走示性函数）；
- (d) 在深度学习中， n 次随机梯度步后参数 θ_n 的收敛性是哪种意义下的收敛？分析 SGD 在凸/非凸损失面上的收敛性结论（依概率还是几乎处处），并说明随机性对逃离鞍点的帮助。

E.4.5 (Ch.10+Ch.11+Ch.12, 随机过程收敛 + 泛函 CLT + Donsker 定理) 设 $S_n = \sum_{i=1}^n X_i$ (X_i i.i.d., 均值 0, 方差 σ^2)，定义连续化折线过程 $W_n(t) = S_{[nt]}/(\sigma\sqrt{n})$ ($t \in [0, 1]$)。

- (a) 对固定 t ，证明 $W_n(t) \xrightarrow{d} N(0, t)$ （有限维分布的 CLT）；
- (b) 叙述 Donsker 定理（泛函 CLT）： $W_n \Rightarrow W$ （弱收敛到标准 Brownian Motion）；
- (c) 利用 Donsker 定理推导 Kolmogorov-Smirnov 统计量 $D_n = \sup_t |\hat{F}_n(t) - F(t)|$ 的极限分布（以 Brownian Bridge 的上确界表达）；
- (d) 在时序深度学习（RNN、Transformer 处理长序列）中，Donsker 定理的意义：若输入 token embedding 之和经适当标准化趋向布朗运动，分析位置编码（Positional Encoding）如何提供 t 的信息，以及为何正弦位置编码的频率设计与布朗运动的谱密度有内在联系。

E.4.6 (Ch.11+Ch.12, 矩法 + 特征函数方法 + 稳定分布 + 广义 CLT) 设 $\{X_n\}$ i.i.d., 尾概率 $P(|X| > x) \sim L(x)x^{-\alpha}$ ($\alpha \in (0, 2)$, L 为缓变函数)，即重尾分布。

- (a) 证明当 $\alpha < 2$ 时， $\text{Var}(X) = +\infty$ ，故经典 CLT 不适用；
- (b) 叙述广义中心极限定理（GCLT）：适当标准化的部分和收敛到 α -稳定分布，写出稳定分布特征函数的一般形式；
- (c) 对称柯西分布（ $\alpha = 1$ ）与 Lévy 分布（ $\alpha = 0.5$ ）均为稳定分布——对称柯西情形，验证 n 个独立柯西之和除以 n 仍为柯西，与经典 CLT 的对比；

- (d) 在金融风险管理中，股票日收益率的尾指数估计 (Hill 估计量) 为 $\hat{\alpha}_k = [k^{-1} \sum_{i=1}^k \log X_{(n-i+1)} - \log X_{(n-k)}]^{-1}$ ——推导此估计量的理论依据 (极值指数的矩方法)，并分析在深度学习训练损失的随机游走中重尾噪声的影响。

Part 5 统计基础 (Ch.13-15, 共 5 题)

E.5.1 (Ch.13+Ch.15, 完备充分统计量 + Lehmann-Scheffé 定理 + UMVUE) 设 $X_1, \dots, X_n$ i.i.d. $\sim \text{Poisson}(\lambda)$, $\lambda > 0$ 未知。

- 证明 $T = \sum_{i=1}^n X_i$ 是 λ 的充分统计量 (Fisher 分解定理);
- 证明 T 完备 (对所有有界函数 g , $E_\lambda[g(T)] = 0$ 对所有 λ 成立 $\Rightarrow g \equiv 0$ a.e.);
- 构造 $e^{-\lambda}$ 的 UMVUE (基于 Lehmann-Scheffé 定理: 完备充分统计量的无偏函数是 UMVUE) ——提示: $P(X_1 = 0|T = t)$;
- 将结论推广: 对估计 $\lambda^k e^{-\lambda}/k!$ (即 $P(X = k)$ 的 UMVUE), 写出一般公式, 并解释完备性对于 UMVUE 唯一性的关键作用。

E.5.2 (Ch.14+Ch.13, 经验分布函数 + Glivenko-Cantelli + 非参数估计) 设 $X_1, \dots, X_n$ i.i.d. $\sim F$, 经验分布函数 $\hat{F}_n(x) = n^{-1} \sum_{i=1}^n \mathbf{1}[X_i \leq x]$ 。

- 证明 $E[\hat{F}_n(x)] = F(x)$, $\text{Var}(\hat{F}_n(x)) = F(x)(1 - F(x))/n$;
- 证明 Glivenko-Cantelli 定理: $\sup_x |\hat{F}_n(x) - F(x)| \xrightarrow{a.s.} 0$ (先证有限点集, 再推广至全局);
- 核密度估计 (KDE) $\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right)$: 推导最优带宽 $h^* \sim n^{-1/5}$ (均方误差最小化, 含偏差-方差权衡);
- 在生成模型中, GAN 的判别器隐式地估计真实分布与生成分布之间的差距——将此与非参数密度估计联系, 分析为何训练前期 KDE 比 GAN 更稳定, 以及 GAN 的优势何在 (高维数据的维数诅咒)。

E.5.3 (Ch.15+Ch.16, 充分统计量 + Fisher 信息 + Cramér-Rao 下界) 设 $X_1, \dots, X_n$ i.i.d. $\sim N(\mu, \sigma^2)$, σ^2 已知, μ 未知。

- 计算 Fisher 信息量 $\mathcal{J}_n(\mu) = n/\sigma^2$, 并验证 Cramér-Rao 下界 $\text{Var}(\hat{\mu}) \geq 1/\mathcal{J}_n(\mu)$;
- 证明样本均值 $\bar{X}_n$ 达到 C-R 下界 (有效估计量), 即 $\text{Var}(\bar{X}_n) = \sigma^2/n$;
- 设参数化变换 $\phi = g(\mu) = e^\mu$ ——用 Delta 方法推导 $\hat{\phi} = e^{\bar{X}}$ 的渐近分布, 并给出 ϕ 的 Cramér-Rao 下界;
- 在深度学习中, 神经网络参数 θ 的 Fisher 信息矩阵 $\mathcal{J}(\theta)$ 指导自然梯度下降——解释为何标准梯度下降在参数空间的曲率不均匀时效率低下, 以及 Fisher 信息矩阵的对角近似 (Adagrad 类) 与完整矩阵 (K-FAC)

的权衡。

E.5.4 (Ch.13+Ch.15, 指数族的充分统计量 + 最大熵原理 + 对偶性) 在所有满足约束 $E[T_k(X)] = \mu_k$ ($k = 1, \dots, m$) 的分布中, 最大熵分布具有指数族形式: $p^*(x) = h(x) \exp(\sum_k \eta_k T_k(x) - A(\eta))$ 。

- 证明以上结论 (变分推导: 最大化 $H(p) = -\int p \log p$ 在约束 $\int p T_k = \mu_k$ 下, 用 Lagrange 乘数法);
- 利用 (a) 证明: 在均值与方差约束下, 最大熵分布为正态分布;
- 证明: 在 $[0, 1]$ 上仅约束均值 $E[X] = \mu$ 时, 最大熵分布为 Beta 分布 (特例: $\mu = 0.5$ 时为均匀分布);
- 在大语言模型的解码策略中, 温度采样 $p_T(x) \propto p(x)^{1/T}$ 与最大熵原理的联系: 分析不同温度 T 下输出分布的熵变化, 并解释 $T \rightarrow 0$ (贪心解码) 和 $T \rightarrow \infty$ (均匀采样) 的统计含义。

E.5.5 (Ch.13+Ch.14+Ch.15, 次序统计量 + 分位数估计 + 鲁棒统计) 设 $X_1, \dots, X_n$ i.i.d. $\sim F$, 令 $\xi_p = F^{-1}(p)$ 为总体 p -分位数, 样本 p -分位数 $\hat{\xi}_p = X_{(\lceil np \rceil)}$ 。

- 利用次序统计量理论证明: $\sqrt{n}(\hat{\xi}_p - \xi_p) \xrightarrow{d} N\left(0, \frac{p(1-p)}{[f(\xi_p)]^2}\right)$ (分位数的渐近正态性);
- 证明样本中位数 $\hat{m} = X_{(n/2)}$ 的渐近方差为 $\frac{1}{4[f(m)]^2 n}$, 而样本均值 (正态数据下) 渐近方差为 σ^2/n ——当 $F = N(\mu, \sigma^2)$ 时比较两者, 解释中位数的渐近相对效率 (ARE) 为 $2/\pi \approx 0.637$;
- 影响函数 (Influence Function) $IF(x; T, F) = \lim_{\varepsilon \rightarrow 0} [T((1-\varepsilon)F + \varepsilon\delta_x) - T(F)]/\varepsilon$ 度量异常点的影响——分别计算均值、中位数、M 估计量的影响函数;
- 在联邦学习 (Federated Learning) 中, 若某些客户端数据被污染 (Byzantine 攻击), 中位数聚合 (Coordinate-wise Median) 比均值聚合 (FedAvg) 更鲁棒——用影响函数理论给出理论解释, 分析攻击者能操纵的最大比例 (breakdown point)。

Part 6 参数估计 (Ch.16-18, 共 10 题)

E.6.1 (Ch.16, MLE + Fisher 信息 + 渐近理论 + 完整证明) 设 $X_1, \dots, X_n$ i.i.d. $\sim p(x; \theta)$ (指数族), $\theta \in \mathbb{R}$, MLE 为 $\hat{\theta}_n$ 。

- 证明在正则条件 (可识别性、Fisher 信息有限正定、似然光滑性) 下, MLE 满足得分方程 $\sum_{i=1}^n \partial \log p(X_i; \hat{\theta}) / \partial \theta = 0$;
- 利用 Taylor 展开证明: $\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N(0, \mathcal{I}(\theta_0)^{-1})$ (MLE 的渐近正态性与有效性);
- 证明 Cramér-Rao 下界对 MLE 的渐近方差是紧的 (MLE 渐近有效);
- 设 $p(x; \theta) = \theta e^{-\theta x}$ ($x > 0$, 指数分布), 计算 $\hat{\theta}_{MLE}$ 、Fisher 信息、渐近置信区间, 并验证以上理论结论。

E.6.2 (Ch.16+Ch.18, 正则化 MLE + MAP + 惩罚似然) 设似然为 $L(\theta) = \prod_{i=1}^n p(\mathbf{x}_i; \theta)$, 引入先验 $\pi(\theta)$, MAP 估计量为 $\hat{\theta}_{MAP} = \arg \max_{\theta} \log L(\theta) + \log \pi(\theta)$ 。

- 证明当 $\pi(\theta) = N(0, \tau^2 \mathbf{I})$ 时, MAP 等价于 L2 正则化 MLE (岭回归);
- 证明当 $\pi(\theta) = \prod_j \text{Laplace}(0, b)$ 时, MAP 等价于 L1 正则化 MLE (Lasso);
- 证明: 在深度神经网络中, Dropout 训练等价于对网络权重的隐式 Bernoulli 先验下的 MAP 估计 (给出直觉推导);
- 随着数据量 $n \rightarrow \infty$, MAP 与 MLE 的差异如何变化? 证明后验收缩 (Posterior Contraction): $\hat{\theta}_{MAP} \rightarrow \hat{\theta}_{MLE}$, 并分析先验在小样本与大样本场景中的相对贡献。

E.6.3 (Ch.16, 矩估计 + GMM 估计 + 弱工具变量) 设 $X_1, \dots, X_n$ i.i.d. $\sim F_{\theta}$, $\theta \in \mathbb{R}^k$, k 个矩条件 $E[g_j(X; \theta)] = 0$ ($j = 1, \dots, m$, $m \geq k$)。广义矩估计 (GMM) 最小化 $Q_n(\theta) = \hat{g}_n(\theta)^{\top} \mathbf{W}_n \hat{g}_n(\theta)$, 其中 $\hat{g}_n(\theta) = n^{-1} \sum g(X_i; \theta)$ 。

- 当 $m = k$ 时, GMM 退化为矩估计——证明矩估计的相合性与渐近正态性;
- 当 $m > k$ 时 (过识别), 最优权重矩阵 $\mathbf{W}^* = [\text{Var}(g(X; \theta_0))]^{-1}$ ——推导最优 GMM 估计量的渐近方差 (Hansen-Sargan 效率定理);
- 推导过识别检验统计量 $J = n \hat{g}_n^{\top} \mathbf{W}^* \hat{g}_n \xrightarrow{d} \chi^2(m - k)$ (Sargan-Hansen J 检验), 并解释其经济学/统计学含义;
- 在深度学习的对比学习 (Contrastive Learning) 中, InfoNCE 损失可视为矩条件的 GMM 估计框架——分析 SimCLR 中的正负样本对比损失与 GMM 的联系, 解释大批量训练 (更多负样本) 如何提高估计效率。

E.6.4 (Ch.17, 置信区间 + 枢轴量 + Bootstrap 置信区间) 设 $X_1, \dots, X_n$ i.i.d. $\sim N(\mu, \sigma^2)$, 均值和方差均未知。

- 构造 μ 的精确 95% 置信区间 (利用 t 分布, 推导枢轴量 $T = \sqrt{n}(\bar{X} - \mu)/S \sim t(n - 1)$);
- 构造 σ^2 的精确置信区间 (利用 χ^2 分布, 推导枢轴量 $Q = (n - 1)S^2/\sigma^2 \sim \chi^2(n - 1)$), 并说明为何此区间不对称;
- Bootstrap 置信区间: 叙述百分位数 Bootstrap 与 BCa (偏差校正加速) Bootstrap 方法, 证明两者在正则条件下的二阶渐近正确性;
- 在深度学习的预测区间 (Prediction Interval) 估计中, Conformal Prediction 方法不依赖任何参数假设——写出分裂 Conformal 方法的构造步骤, 证明其有限样本覆盖保证 $P(Y_{n+1} \in C(X_{n+1})) \geq 1 - \alpha$, 并与 Bootstrap 方法的理论保证对比。

E.6.5 (Ch.17+Ch.18, 贝叶斯可信区间 + 频率置信区间 + 概率解释对比) 设数据 $X|\theta \sim B(n, \theta)$ (二项), 先验 $\theta \sim \text{Beta}(\alpha_0, \beta_0)$, 观测 $X = k$ 。

- 写出后验 $\theta|X = k \sim \text{Beta}(\alpha_0 + k, \beta_0 + n - k)$, 构造 HDR (最高密度区间) 作为可信区间;

- (b) Wald 置信区间 (频率方法) $\hat{p} \pm z_{\alpha/2} \sqrt{\hat{p}(1-\hat{p})/n}$ 与 Wilson Score 区间的比较——证明 Wald 区间在 $\hat{p}$ 接近 0 或 1 时覆盖率不达标, 推导 Wilson 区间的正确公式;
- (c) 比较: $P(\theta \in [\ell, u] | X)$ 与 $P_\theta([\ell(X), u(X)] \ni \theta)$ ——解释两者的哲学含义, 说明“参数在可信区间内的概率为 95%”对频率论者意味着什么 (实际上无意义);
- (d) 在 A/B 测试 (如点击率实验) 中, 公司实际上默认使用哪种方法? 构造一个具体场景说明: 贝叶斯可信区间给出更直接的决策依据, 但频率置信区间具有频率覆盖保证——如何在实际工程中权衡选择。

E.6.6 (Ch.18, 分层贝叶斯 + 超先验 + 部分池化) 设 J 个组, 第 j 组有 n_j 个观测: $X_{ij} | \theta_j \sim N(\theta_j, \sigma^2)$, $\theta_j | \mu, \tau \sim N(\mu, \tau^2)$, 超先验 $\mu \sim N(0, \Sigma_0)$, $\tau \sim \text{HalfNormal}(\sigma_\tau)$ 。

- (a) 写出完整的联合分布 $p(\{X_{ij}\}, \{\theta_j\}, \mu, \tau)$;
- (b) 推导 θ_j 的后验均值 (部分池化估计量): $\hat{\theta}_j = \lambda_j \bar{X}_j + (1 - \lambda_j) \hat{\mu}$, 其中 $\lambda_j = n_j \tau^2 / (n_j \tau^2 + \sigma^2)$ (组内信息量的权重);
- (c) 证明: 当 $\tau \rightarrow 0$ 时, 部分池化退化为完全池化 ($\hat{\theta}_j \rightarrow \hat{\mu}$); 当 $\tau \rightarrow \infty$ 时, 退化为无池化 ($\hat{\theta}_j \rightarrow \bar{X}_j$);
- (d) 在联邦学习中, 客户端 j 的本地模型参数 θ_j 可视为来自全局超先验的层级贝叶斯——分析 pFedMe 和 MAML 等个性化联邦学习算法与分层贝叶斯的联系, 以及超先验如何编码跨客户端的先验知识。

E.6.7 (Ch.16+Ch.18, 变分推断 + ELBO + VAE) 设观测 $\mathbf{x}$, 隐变量 $\mathbf{z}$, 生成模型 $p_\theta(\mathbf{x}, \mathbf{z}) = p_\theta(\mathbf{x} | \mathbf{z}) p(\mathbf{z})$, 变分族 $q_\phi(\mathbf{z} | \mathbf{x})$ 。

- (a) 推导 ELBO (Evidence Lower Bound): $\log p_\theta(\mathbf{x}) \geq \mathcal{L}(\theta, \phi; \mathbf{x}) = E_{q_\phi}[\log p_\theta(\mathbf{x} | \mathbf{z})] - D_{KL}(q_\phi(\mathbf{z} | \mathbf{x}) \| p(\mathbf{z}))$;
- (b) 证明 gap 恰为 KL 散度: $\log p_\theta(\mathbf{x}) - \mathcal{L} = D_{KL}(q_\phi \| p_\theta(\mathbf{z} | \mathbf{x})) \geq 0$;
- (c) 当 $p(\mathbf{z}) = N(\mathbf{0}, \mathbf{I})$, $q_\phi(\mathbf{z} | \mathbf{x}) = N(\mu_\phi(\mathbf{x}), \text{diag}(\sigma_\phi^2(\mathbf{x})))$ 时, 推导 KL 项的解析表达式, 并推导重参数化技巧 $\mathbf{z} = \mu_\phi + \sigma_\phi \odot \varepsilon$ ($\varepsilon \sim N(\mathbf{0}, \mathbf{I})$) 如何实现梯度的反向传播;
- (d) 分析 VAE 中“后验坍塌” (Posterior Collapse) 问题: 为何 KL 项容易被模型驱动至零 ($q_\phi \approx p(\mathbf{z})$)? 提出至少两种缓解方法 (β -VAE、KL 退火), 并从信息瓶颈原理解释各自的统计含义。

E.6.8 (Ch.17+Ch.18, EM 算法收敛 + 不完全数据 + 多峰后验) 设不完全数据 $\mathbf{Y}$, 完整数据 $(\mathbf{Y}, \mathbf{Z})$, 参数 θ 。EM 算法交替执行: E 步: $Q(\theta | \theta^{(t)}) = E_{\mathbf{Z} | \mathbf{Y}, \theta^{(t)}}[\log p(\mathbf{Y}, \mathbf{Z} | \theta)]$; M 步: $\theta^{(t+1)} = \arg \max_\theta Q(\theta | \theta^{(t)})$ 。

- (a) 证明 EM 的单调性: $\log p(\mathbf{Y} | \theta^{(t+1)}) \geq \log p(\mathbf{Y} | \theta^{(t)})$ (用 Jensen 不等式, 建立 $\log p(\mathbf{Y} | \theta)$ 与 Q 的关系);
- (b) 分析 EM 收敛到局部极大值而非全局最优的情形——构造一个双峰混合高斯的例子说明局部最优的产生;
- (c) 蒙特卡洛 EM (MCEM): 当 E 步不可解析时, 用 MCMC 近似 Q ——分析近似误差的来源, 并说明随着迭代进行为何需要增大 MCMC 样本量;

- (d) 变分 EM 与标准 EM 的关系：当变分族 q 取完全后验 $p(\mathbf{Z}|\mathbf{Y}, \theta)$ 时，变分 EM 退化为标准 EM——解释变分族的限制如何导致变分 EM 的次优性，以及在 LDA 中平均场假设 $q(\mathbf{Z}) = \prod_i q(Z_i)$ 的代价。

E.6.9 (Ch.16+Ch.17+Ch.18, 贝叶斯非参数估计 + Dirichlet 过程 + 无限混合) Dirichlet 过程 (DP) 是分布的分布： $G \sim DP(\alpha, G_0)$ ，其中 $\alpha > 0$ 为集中参数， G_0 为基础分布。

- (a) 通过有限维 Dirichlet 分布的极限推导 DP 的存在性——对任意可测分割 $(A_1, \dots, A_K), (G(A_1), \dots, G(A_K)) \sim \text{Dir}(\alpha G_0(A_1), \dots, \alpha G_0(A_K))$ ；
- (b) 证明 DP 的均值 $E[G] = G_0$ ，且 α 越大， G 越集中在 G_0 附近；
- (c) 中国餐馆过程 (CRP)： n 个顾客依次入座，第 $n+1$ 个顾客加入第 k 桌的概率为 $n_k/(\alpha+n)$ ，新开一桌的概率为 $\alpha/(\alpha+n)$ ——证明 CRP 是 DP 混合模型的隐变量边际化；
- (d) Dirichlet 过程混合模型 (DPMM) 在聚类问题中自动确定簇数——分析 α 的贝叶斯推断（通常先验 $\alpha \sim \text{Gamma}(a, b)$ ），并与有限 GMM 的 BIC 准则选择模型阶数进行对比，解释 DPMM 在深度学习表示学习中的潜在应用。

E.6.10 (Ch.16+Ch.18, 最大熵估计 + 凸对偶 + 特征匹配) 在约束 $E_p[\phi_k(x)] = \hat{\mu}_k$ ($k = 1, \dots, m$) 下，最大熵估计等价于对偶问题：最小化凸函数 $A(\eta) - \eta^\top \hat{\mu}$ （相对于对偶变量 η ）。

- (a) 推导对偶问题 (Legendre-Fenchel 变换： $A(\eta) = \sup_p [\eta^\top E_p[\phi] - H(p)]$)，证明强对偶性；
- (b) 证明最优解 p^* 必为指数族 $p^*(x) = \exp(\eta^{*\top} \phi(x) - A(\eta^*))$ （复现 E.5.4 (a) 的结论，现从对偶角度推导）；
- (c) 对数线性模型（最大熵分类器）等价于逻辑回归——证明对多分类问题（ K 类），最大熵模型的决策函数为 softmax，权重 η 通过极大化对数似然（负 KL 散度最小化）估计；
- (d) 在大语言模型的 RLHF（人类反馈强化学习）中，KL 散度约束 $D_{KL}(\pi \parallel \pi_{\text{ref}}) \leq \delta$ 下的奖励最大化问题正是最大熵框架——推导最优策略 $\pi^*(x) \propto \pi_{\text{ref}}(x) \exp(r(x)/\beta)$ （软 Q 值策略），并解释 β 在控制生成多样性与奖励对齐上的作用。

Part 7 假设检验 (Ch.19-21, 共 7 题)

E.7.1 (Ch.19, Neyman-Pearson 引理 + 最优检验 + 似然比检验) 设简单假设 $H_0: \theta = \theta_0$ vs. $H_1: \theta = \theta_1$ ，观测 $X_1, \dots, X_n$ i.i.d.。

- (a) 叙述并严格证明 Neyman-Pearson 引理：水平 α 下最优检验（最大功效）为似然比检验 $\Lambda = L(\theta_1)/L(\theta_0) \geq k$ ；
- (b) 将 NP 引理推广到复合备择假设（单边检验）——对指数族分布，证明一致最优检验 (UMP) 的存在性（单调似然比条件）；

- (c) 设 $X_i \sim N(\mu, 1)$, 检验 $H_0: \mu = 0$ vs. $H_1: \mu = 1$, $n = 25$, $\alpha = 0.05$ ——计算最优拒绝域、功效、第二类错误率 β , 并绘制 (描述) 功效函数的形状;
- (d) 在机器学习中, 分类器的决策边界可视为假设检验——ROC 曲线与 Neyman-Pearson 框架的关系: 证明 AUC 等于随机选取正例和负例时正例得分高于负例的概率 $P(\hat{p}_+ > \hat{p}_-)$, 并分析 AUC 优化与精度-召回率权衡的统计含义。

E.7.2 (Ch.19+Ch.20, p 值 + 多重检验 + FDR 控制) 在高通量实验 (如基因组学) 中, 同时检验 m 个假设 $H_{0,1}, \dots, H_{0,m}$, 各假设的 p 值为 $p_1, \dots, p_m$ 。

- (a) 定义族错误率 (FWER) 和错误发现率 (FDR), 证明 $FDR \leq FWER$;
- (b) Bonferroni 校正控制 FWER: 若每个检验用水平 α/m , 证明 $FWER \leq \alpha$;
- (c) Benjamini-Hochberg (BH) 方法: 将 p 值排序 $p_{(1)} \leq \dots \leq p_{(m)}$, 令 $k = \max\{i: p_{(i)} \leq i\alpha/m\}$, 拒绝 $H_{0,(1)}, \dots, H_{0,(k)}$ ——叙述并证明 (或给出核心推导框架) $FDR \leq \alpha \cdot m_0/m \leq \alpha$, 其中 m_0 为真零假设数;
- (d) 在深度学习神经网络的特征显著性分析 (如基于梯度的特征重要性) 中, 每个输入特征对应一个假设检验——分析在高维场景 ($m \gg n$) 中多重检验校正的必要性, 以及为何 SHAP 值等方法需要配合统计检验才能给出可靠结论。

E.7.3 (Ch.20, 方差分析 (ANOVA) + 线性模型 + F 检验理论) 设单因素方差分析模型: $X_{ij} = \mu + \alpha_i + \varepsilon_{ij}$ ($i = 1, \dots, k$, $j = 1, \dots, n_i$), $\varepsilon_{ij} \sim N(0, \sigma^2)$, $\sum n_i \alpha_i = 0$ 。

- (a) 推导组间平方和 $SS_A = \sum n_i (\bar{X}_{i.} - \bar{X}_{..})^2$ 和组内平方和 $SS_E = \sum_{i,j} (X_{ij} - \bar{X}_{i.})^2$ 的自由度, 以及 $SS_E/\sigma^2 \sim \chi^2(N-k)$ ($N = \sum n_i$);
- (b) 在 $H_0: \alpha_1 = \dots = \alpha_k = 0$ 下, 证明 $F = (SS_A/(k-1))/(SS_E/(N-k)) \sim F(k-1, N-k)$;
- (c) 推导非中心 F 分布下功效的计算 (非中心参数 $\lambda = \sum n_i \alpha_i^2/\sigma^2$), 并分析样本量设计问题;
- (d) 深度学习中批归一化 (Batch Normalization) 的统计解释: 将不同层的激活视为 ANOVA 中的“组”——说明 BN 如何通过控制组间差异 (层间协变量偏移) 加速训练, 并用方差分析框架分析 BN 的正则化效果。

E.7.4 (Ch.20+Ch.21, 非参数检验 + 秩统计量 + 渐近理论) 设 $X_1, \dots, X_m$ 与 $Y_1, \dots, Y_n$ 独立, 来自连续分布 F 和 G , 检验 $H_0: F = G$ 。

- (a) 定义 Wilcoxon 秩和统计量 $W = \sum_{i=1}^m R_i$ (R_i 为 X_i 在合并样本中的秩)——在 H_0 下计算 $E[W] = m(m+n+1)/2$, $\text{Var}(W) = mn(m+n+1)/12$;
- (b) 证明 W 与 Mann-Whitney U 统计量 $U = \sum_{i=1}^m \sum_{j=1}^n \mathbf{1}[X_i > Y_j]$ 的关系 $U = W - m(m+1)/2$;
- (c) 证明在 H_0 下, $(W - E[W])/\sqrt{\text{Var}(W)} \xrightarrow{d} N(0, 1)$ (Hájek 投影定理框架);

- (d) 在 ML 模型性能比较中，两个分类器在多个数据集上的性能可用 Wilcoxon 符号秩检验（配对数据）——分析此方法相比 t 检验的优势（对异常值鲁棒），以及 Demšar 推荐的使用秩统计量进行算法比较的完整框架。

E.7.5 (Ch.19+Ch.20, 顺序检验 + Wald 序贯概率比检验 + 提前终止) 设 $X_1, X_2, \dots$ i.i.d. $\sim p_\theta$, 顺序地检验 $H_0: \theta = \theta_0$ vs. $H_1: \theta = \theta_1$ 。

- (a) 定义对数似然比过程 $\Lambda_n = \sum_{i=1}^n \log[p_{\theta_1}(X_i)/p_{\theta_0}(X_i)]$, 证明在 H_0 下 $E[\Lambda_n] < 0$;
- (b) 叙述 Wald 序贯概率比检验 (SPRT): 当 $\Lambda_n \geq B$ 时拒绝 H_0 , 当 $\Lambda_n \leq A$ 时接受 H_0 , 否则继续——用 $A \approx \log(\beta/(1-\alpha))$ 和 $B \approx \log((1-\beta)/\alpha)$ 控制双侧错误;
- (c) 证明 SPRT 的最优性 (Wald-Wolfowitz 定理): 在所有满足错误率约束 (α, β) 的顺序检验中, SPRT 期望样本量最小;
- (d) 在线上 A/B 测试中, 持续监测 (Peeking Problem) 导致 I 类错误膨胀——分析原因 (多重检验), 并说明 always-valid p-values (基于鞅不等式) 和顺序检验如何解决这一问题, 给出实际工程实现思路。

E.7.6 (Ch.21, 置换检验 + 精确检验 + 条件推断) 设检验双样本均值之差 $H_0: \mu_X = \mu_Y$, 无分布假设。

- (a) 叙述置换检验 (Permutation Test) 的完整步骤, 证明在 H_0 下交换性成立时, 检验的精确水平为 α (有限样本精确性);
- (b) 推导置换 p 值: $p_{\text{perm}} = \#\{(\mathbf{x}, \mathbf{y}) \text{ 的置换} : T \geq t_{\text{obs}}\} / \binom{m+n}{m}$, 说明计算时如何用 Monte Carlo 近似 (随机置换检验);
- (c) Fisher 精确检验用于 2×2 列联表——证明在边际固定的条件下, 检验统计量服从超几何分布, 写出精确 p 值公式;
- (d) 在机器学习的特征重要性评估中, 置换特征重要性 (permutation feature importance) 基于相同思想——分析置换后模型性能下降与条件独立性检验的联系, 并说明为何高相关特征集合中单特征置换会低估重要性 (提出分组置换的改进)。

E.7.7 (Ch.19+Ch.21, 贝叶斯假设检验 + 贝叶斯因子 + 模型选择) 设两个竞争模型 M_0 和 M_1 , 数据 $\mathbf{x}$, 贝叶斯因子 $BF_{10} = p(\mathbf{x}|M_1)/p(\mathbf{x}|M_0)$ 。

- (a) 证明后验比 = 先验比 $\times$ 贝叶斯因子: $P(M_1|\mathbf{x})/P(M_0|\mathbf{x}) = [P(M_1)/P(M_0)] \cdot BF_{10}$;
- (b) 计算正态数据 ($X_i \sim N(\mu, 1)$) 下, $M_0: \mu = 0$ vs. $M_1: \mu \sim N(0, \tau^2)$ (Zellner-Siow 先验) 的贝叶斯因子 (含 Laplace 近似的近似计算);
- (c) Jeffreys-Lindley 悖论: 当 $\tau \rightarrow \infty$ (无信息先验), $BF_{10} \rightarrow 0$ ——解释为何贝叶斯因子对备择假设的先验极度敏感, 而频率 p 值不然;

- (d) 在深度学习模型选择中, BIC 近似边际似然 $\log p(\mathbf{x}|M) \approx \log p(\mathbf{x}|\hat{\theta}) - (d/2) \log n$ ——推导 BIC 的贝叶斯解释 (Laplace 近似), 并与 AIC 比较: AIC 优化预测性能, BIC 一致选择真实模型 (当真实模型在候选集中时)。

Part 8 高级主题 (Ch.22-24, 共 10 题)

E.8.1 (Ch.22, KL 散度 + 互信息 + 信息瓶颈原理) 设 $X \rightarrow Z \rightarrow Y$ 为马尔可夫链 (Z 为 X 的压缩表示, Y 为预测目标)。信息瓶颈 (IB) 目标: 最大化 $I(Z; Y) - \beta I(Z; X)$ 。

- (a) 用 KL 散度写出互信息 $I(Z; X) = E_{p(x,z)}[\log p(z|x)/p(z)]$, 并证明 $I(Z; X) = H(Z) - H(Z|X) = H(X) - H(X|Z)$;
- (b) 证明数据处理不等式: 若 $X \rightarrow Z \rightarrow Y$ 为马尔可夫链, 则 $I(X; Y) \geq I(Z; Y)$;
- (c) 推导信息瓶颈的 Lagrangian 最优解满足: $p^*(z|x) \propto p(z) \exp(-\beta D_{KL}(p(y|x)||p(y|z)))$, 并解释在 $\beta \rightarrow 0$ 和 $\beta \rightarrow \infty$ 两种极端情形下压缩表示 Z 的形式;
- (d) 在深度神经网络的训练过程中, Tishby 等人提出信息平面假说 (Information Plane Hypothesis): 网络各层的 $(I(X; T_l), I(T_l; Y))$ 轨迹先增大 $I(T_l; Y)$ (拟合阶段) 再减小 $I(X; T_l)$ (压缩阶段)——分析此假说的支持证据与批评 (Saxe 等人的反例), 以及随机梯度噪声在信息压缩中的作用。

E.8.2 (Ch.22+Ch.23, 最大熵谱分析 + 随机过程 + MCMC 诊断) 设平稳过程 $\{X_t\}$, 自相关函数 $R(k) = E[X_t X_{t+k}]$, 功率谱密度 $S(f) = \sum_{k=-\infty}^{\infty} R(k) e^{-2\pi i f k}$ 。

- (a) 证明 Wiener-Khintchine 定理: $S(f) = \mathcal{F}[R(k)](f)$, 并由 Bochner 定理说明 $S(f) \geq 0$;
- (b) 在已知 $R(0), R(1), \dots, R(p)$ 的条件下, 最大熵谱估计 (Burg 算法) 最大化微分熵 $h = \int \log S(f) df$ ——证明最优谱为有理谱 (自回归 AR(p) 过程的谱);
- (c) 在 MCMC 中, 链的自相关函数影响有效样本量 (ESS) $n_{\text{eff}} = n / (1 + 2 \sum_{k=1}^{\infty} \rho(k))$ ——推导此公式, 并解释为何高自相关 (如随机游走 Metropolis 在高维问题中) 导致 ESS 极低;
- (d) Hamiltonian Monte Carlo (HMC) 通过引入动量变量消除随机游走行为——写出 HMC 的 Hamiltonian $H(\mathbf{q}, \mathbf{p}) = -\log p(\mathbf{q}) + \mathbf{p}^\top \mathbf{p} / 2$, 解释 Leapfrog 积分器的保体积性 (Liouville 定理), 以及 NUTS (No-U-Turn Sampler) 如何自适应调整步长和路径长度。

E.8.3 (Ch.23, 重要性采样 + 自归一化 + 粒子滤波) 设目标分布 $\pi(x) \propto \tilde{\pi}(x)$ (归一化常数未知), 提议分布 $q(x)$, 重要性权重 $w(x) = \tilde{\pi}(x)/q(x)$ 。

- (a) 证明自归一化重要性采样估计量 $\hat{\mu}_{SNIS} = \sum w(X_i) f(X_i) / \sum w(X_i)$ 是有偏但相合的估计量;
- (b) 推导有效样本量 (ESS) $\hat{n}_{\text{eff}} = (\sum w_i)^2 / \sum w_i^2$, 并证明当 $q = \pi$ 时 $n_{\text{eff}} = n$, 当权重退化时 $n_{\text{eff}} \rightarrow 1$;

- (c) 序列重要性重采样 (SIR) / 粒子滤波: 设隐状态马尔可夫链 $X_t \sim p(x_t|x_{t-1})$, 观测 $Y_t \sim p(y_t|x_t)$ ——推导过滤分布 $p(x_t|y_{1:t})$ 的粒子近似递推公式 (含权重更新与重采样步骤);
- (d) 在扩散模型 (Diffusion Model) 中, DDPM 的去噪过程可视为时间反转的重要性采样——分析前向过程 $q(x_t|x_0)$ (高斯核), 以及去噪网络 $p_\theta(x_{t-1}|x_t)$ 学习时间反转分布的统计原理, 并与粒子滤波的预测-校正框架对应。

E.8.4 (Ch.24+Ch.22, 变分推断 + 均场近似 + 自由能) 在概率图模型中, 变分推断用变分族 $q(\mathbf{z}) \in \mathcal{Q}$ 近似后验 $p(\mathbf{z}|\mathbf{x})$, 最小化 $D_{KL}(q\|p(\cdot|\mathbf{x}))$ 。

- (a) 证明最小化 $D_{KL}(q\|p(\cdot|\mathbf{x}))$ 等价于最大化 ELBO $\mathcal{L}(q) = E_q[\log p(\mathbf{x}, \mathbf{z})] - E_q[\log q(\mathbf{z})]$;
- (b) 均场近似假设 $q(\mathbf{z}) = \prod_i q_i(z_i)$ ——推导坐标上升变分推断 (CAVI) 的更新方程: $\log q_i^*(z_i) = E_{-i}[\log p(\mathbf{x}, \mathbf{z})] + \text{const}$;
- (c) 将 (b) 应用于高斯混合模型 (GMM): 写出隐类别 Z_i 和分量参数 (μ_k, Λ_k) 的 CAVI 更新公式 (均场 VI for GMM);
- (d) 均场近似的代价: $D_{KL}(q\|p)$ 倾向于找低方差的近似 (零覆盖), 而 $D_{KL}(p\|q)$ (期望传播) 倾向于找高方差的近似 (均值覆盖)——对比两种散度在多模态后验近似中的行为, 并分析 Normalizing Flow 变分族如何突破均场的因子化限制。

E.8.5 (Ch.23+Ch.24, MCMC + 马尔可夫链平稳分布 + 混合时间) 设有限状态马尔可夫链转移矩阵 $\mathbf{P}$, 目标分布 π (满足细致平衡 $\pi_i P_{ij} = \pi_j P_{ji}$)。

- (a) 证明满足细致平衡的 π 是 $\mathbf{P}$ 的平稳分布 ($\pi\mathbf{P} = \pi$);
- (b) 证明 Metropolis-Hastings 算法的接受概率 $\alpha(x, y) = \min\left(1, \frac{\pi(y)q(y, x)}{\pi(x)q(x, y)}\right)$ 使得细致平衡成立;
- (c) 定义混合时间 $t_{\text{mix}}(\varepsilon) = \min\{t : \max_x \|P^t(x, \cdot) - \pi\|_{TV} \leq \varepsilon\}$, 证明 $t_{\text{mix}} \leq \log(1/\varepsilon\pi_{\min})/\text{Gap}$, 其中 $\text{Gap} = 1 - \lambda_2$ 为谱隙;
- (d) 在大语言模型的自回归采样 (Ancestral Sampling) 中, token 序列生成可视为马尔可夫链——分析温度参数 T 对谱隙 (混合速度) 的影响: $T \rightarrow 0$ 使链混合变慢 (卡在局部极值), $T \rightarrow \infty$ 使链混合加快但输出随机——推导最优温度的权衡准则 (最大化有效信息率)。

E.8.6 (Ch.22+Ch.24, 概率图模型 + 信念传播 + 近似推断) 设因子图 $G = (V, F, E)$, 变量节点 $v \in V$, 因子节点 $f \in F$, 因子 $f(\mathbf{x}_f)$ 为局部势函数。联合分布 $p(\mathbf{x}) \propto \prod_f f(\mathbf{x}_f)$ 。

- (a) 在树结构因子图上, 导出精确信念传播 (BP) 的消息传递方程: $\mu_{f \rightarrow v}(x_v) = \sum_{\sim x_v} f(\mathbf{x}_f) \prod_{u \in \text{ne}(f) \setminus v} \mu_{u \rightarrow f}(x_u)$;
- (b) 证明树结构图上 BP 的精确性 (有限步内收敛到精确边际), 并分析循环图 (Loopy BP) 的不精确性来源;

- (c) Bethe 自由能近似: $F_{\text{Bethe}} = -\sum_f E_{\hat{b}_f} [\log f] + \sum_f H(\hat{b}_f) - \sum_v (d_v - 1)H(\hat{b}_v)$ ——证明树图上 F_{Bethe} 等于精确自由能, 并解释循环图上 BP 不动点对应 Bethe 自由能的驻点;
- (d) 在深度学习的结构化预测 (如 CRF + Neural Network) 中, Loopy BP 用于序列标注和图像分割——分析神经 CRF (如 CRFasRNN、DeepLab v2 的 DenseCRF) 中均场推断的迭代方程, 说明均场推断为何能以 RNN 形式嵌入端到端训练。

E.8.7 (Ch.22, Rényi 散度 + α -散度 + 鲁棒推断) α -Rényi 散度定义为 $D_\alpha(p\|q) = \frac{1}{\alpha-1} \log \int p(x)^\alpha q(x)^{1-\alpha} dx$ ($\alpha \neq 1$)。

- (a) 证明 $\lim_{\alpha \rightarrow 1} D_\alpha(p\|q) = D_{KL}(p\|q)$ (L'Hôpital 法则);
- (b) 证明 $D_\alpha(p\|q) \geq 0$ (对数求和不等式) 以及 Rényi 散度关于 α 的单调性;
- (c) $\alpha = 0.5$ 时给出 Bhattacharyya 距离 $D_B = -\log \int \sqrt{p(x)q(x)} dx$ ——计算两个正态分布 $N(\mu_1, \sigma^2)$ 和 $N(\mu_2, \sigma^2)$ 的 Bhattacharyya 距离;
- (d) 在鲁棒贝叶斯推断中, α -散度提供比 KL 散度更灵活的近似框架——分析 Power EP (期望传播的幂散度版本) 在重尾似然 (柯西分布数据) 中的优势, 以及为何 VAE 中用 $\alpha < 1$ 的 Rényi 散度替换 KL 散度能缓解后验坍塌。

E.8.8 (Ch.23+Ch.24, 随机变分推断 + 黑盒 VI + 策略梯度联系) 设 ELBO $\mathcal{L}(\phi) = E_{q_\phi(\mathbf{z})}[\log p(\mathbf{x}, \mathbf{z}) - \log q_\phi(\mathbf{z})]$, 需要对 ϕ 求梯度。

- (a) 推导 REINFORCE 梯度估计量 (打分函数估计量): $\nabla_\phi \mathcal{L} = E_{q_\phi}[(\log p(\mathbf{x}, \mathbf{z}) - \log q_\phi(\mathbf{z})) \nabla_\phi \log q_\phi(\mathbf{z})]$;
- (b) 证明基线 (baseline/control variate) b (不依赖 $\mathbf{z}$) 不改变梯度估计量的期望, 但能降低方差: $E_{q_\phi}[(f(\mathbf{z}) - b) \nabla_\phi \log q_\phi] = E_{q_\phi}[f(\mathbf{z}) \nabla_\phi \log q_\phi]$;
- (c) 推导最优基线 $b^* = E[f(\mathbf{z}) \nabla_\phi \log q_\phi] / E[\|\nabla_\phi \log q_\phi\|^2]$ (最小化方差), 并与强化学习中策略梯度定理的 baseline (值函数) 做类比;
- (d) 重参数化梯度 vs. 打分函数梯度: 对于 Gaussian 变分族, 前者方差远低于后者——分析两者在离散变量 (如图神经网络的离散结构) 情形下的适用性, 以及 Gumbel-Softmax / Straight-Through Estimator 如何为离散变量提供低方差梯度估计。

E.8.9 (Ch.24, 贝叶斯优化 + 高斯过程代理模型 + 采集函数) 设目标函数 $f(\mathbf{x})$ 黑盒且昂贵, 用高斯过程代理模型 $f \sim GP(\mu_0, k(\cdot, \cdot))$, 观测集 $\mathcal{D}_n = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ ($y_i = f(\mathbf{x}_i) + \varepsilon_i$, $\varepsilon_i \sim N(0, \sigma_n^2)$)。

- (a) 推导 GP 后验: 均值 $\mu_n(\mathbf{x}) = \mu_0(\mathbf{x}) + \mathbf{k}_n(\mathbf{x})^\top (\mathbf{K}_n + \sigma_n^2 \mathbf{I})^{-1} (\mathbf{y} - \mu_0(\mathbf{X}))$, 方差 $\sigma_n^2(\mathbf{x}) = k(\mathbf{x}, \mathbf{x}) - \mathbf{k}_n(\mathbf{x})^\top (\mathbf{K}_n + \sigma_n^2 \mathbf{I})^{-1} \mathbf{k}_n(\mathbf{x})$;
- (b) 定义置信上界 (UCB) 采集函数 $\alpha_{UCB}(\mathbf{x}) = \mu_n(\mathbf{x}) + \kappa \sigma_n(\mathbf{x})$, 推导其期望改进 (EI) 的等价性, 以及 κ 如何控制探索-利用权衡 (连接到 Thompson Sampling);

- (c) 证明: 对 UCB 采集函数, 贝叶斯遗憾 (Bayesian Regret) 在 T 步后有上界 $O(\sqrt{T\gamma_T})$, 其中 γ_T 为核矩阵的最大信息增益;
- (d) 在深度学习的超参数优化 (HPO) 中, 贝叶斯优化 (如 Optuna、SMAC) 相比随机搜索和网格搜索为何更高效——分析在高维超参数空间中 GP 的维数诅咒问题, 以及 BORE (贝叶斯优化通过密度比估计) 和 Tree-structured Parzen Estimator (TPE) 如何绕开 GP 的计算瓶颈。

E.8.10 (Ch.22+Ch.23+Ch.24, Wasserstein 距离 + 最优传输 + 生成模型) 设 μ, ν 为 $\mathbb{R}^d$ 上的概率分布, $\mathcal{P}(\mu, \nu)$ 为所有以 μ, ν 为边际的联合分布 (耦合) 集合。 p -Wasserstein 距离: $W_p(\mu, \nu) = \left(\inf_{\gamma \in \mathcal{P}(\mu, \nu)} \int \|\mathbf{x} - \mathbf{y}\|^p d\gamma(\mathbf{x}, \mathbf{y}) \right)^{1/p}$ 。

- (a) 证明 W_1 距离的对偶表示 (Kantorovich-Rubinstein 定理): $W_1(\mu, \nu) = \sup_{\|f\|_L \leq 1} \int f d\mu - \int f d\nu$ (在 1-Lipschitz 函数上取上确界);
- (b) 对一维分布, 证明 $W_1(\mu, \nu) = \int_{-\infty}^{\infty} |F_\mu(t) - F_\nu(t)| dt$ (CDF 的 L^1 距离), 并计算 $N(0, 1)$ 与 $N(\delta, 1)$ 的 W_1 距离;
- (c) 在 WGAN (Wasserstein GAN) 中, 判别器 (Critic) 近似 Kantorovich 对偶中的 1-Lipschitz 函数——解释梯度惩罚 (GP) 如何强制 Lipschitz 约束, 并推导 WGAN-GP 损失: $\mathcal{L} = E_{\tilde{x}}[D(\tilde{x})] - E_x[D(x)] + \lambda E_{\tilde{x}}[(\|\nabla D(\tilde{x})\|_2 - 1)^2]$;
- (d) Schrödinger 桥 (SB) 问题是对最优传输的随机化推广——设正向过程为布朗运动 $dX_t = dW_t$ ($X_0 \sim \mu$, $X_1 \sim \nu$), 推导 SB 的 IPFP (迭代比例拟合法) 算法框架, 并说明扩散模型 (DDPM/Score Matching) 与 Schrödinger 桥的关系 (I2SB 等方法的理论依据)。

本题库包含 60 题, 覆盖 Part 1-8 全部章节, 强调跨章融合与 ML/深度学习实战应用。

F1 详解: Part 1 概率基础 (Ch.1-3, 共 28 题)

本文档对应 appendix/C-exercises-basic.md Part 1 (C.1.1-C.1.10) + appendix/D-exercises-medium.md Part 1 (D.1.1-D.1.12) + appendix/E-exercises-advanced.md Part 1 (E.1.1-E.1.6) 的完整详解。

C 基础题详解 (10 题)

C.1.1 (Ch.1, 事件运算与加法公式)

题目: $P(A) = 0.5$, $P(B) = 0.4$, $P(A \cap B) = 0.15$, 求 $P(A \cup B)$ 和 $P(\bar{A} \cap \bar{B})$ 。

思路: 直接用加法公式, 再用德摩根律转化第 2 问。

解:

步骤 1: 加法公式。

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) = 0.5 + 0.4 - 0.15 = 0.75$$

步骤 2: $\bar{A} \cap \bar{B} = \overline{A \cup B}$ (德摩根律)。

$$P(\bar{A} \cap \bar{B}) = 1 - P(A \cup B) = 1 - 0.75 = 0.25$$

答案: $P(A \cup B) = 0.75, P(\bar{A} \cap \bar{B}) = 0.25$

C.1.2 (Ch.1, 概率公理与基本性质)

题目: $P(A) = 0.7, P(B) = 0.3, A \cap B = \emptyset$, 问 $P(A \cup B)$ 、 $P(\bar{A})$, 以及 A 、 B 是否互为对立事件。

思路: 互斥时加法公式简化; 对立事件要求互斥且 $P(A) + P(B) = 1$ 。

解:

步骤 1:

$$P(A \cup B) = P(A) + P(B) = 0.7 + 0.3 = 1.0$$

步骤 2:

$$P(\bar{A}) = 1 - P(A) = 0.3$$

步骤 3: 对立事件判断。对立事件要求 $A \cap B = \emptyset$ 且 $A \cup B = \Omega$, 即 $P(A \cup B) = 1$ 。本题满足两个条件, 故 A 与 B 互为对立事件。

答案: $P(A \cup B) = 1, P(\bar{A}) = 0.3$; A 与 B 互为对立事件。

□ 易错点: 互斥 ($A \cap B = \emptyset$) 与对立 (互斥且 $A \cup B = \Omega$) 不同; 互斥未必对立, 对立必然互斥。

C.1.3 (Ch.1, 古典概型)

题目: 盒中 3 红 2 白 1 蓝, 共 6 球, 随机取 1 球, 求取红球概率和取非蓝球概率。

思路: 古典概型, 等可能样本点, 直接数有利结果数。

解:

步骤 1: 取红球: 3 个有利结果, 共 6 个结果。

$$P(\text{红}) = \frac{3}{6} = \frac{1}{2}$$

步骤 2: 非蓝球 = 红 + 白 = 5 个。

$$P(\text{非蓝}) = \frac{5}{6}$$

答案: $P(\text{红}) = \frac{1}{2}, P(\text{非蓝}) = \frac{5}{6}$

C.1.4 (Ch.2, 条件概率定义)

题目: $P(A) = 0.6, P(B) = 0.5, P(A \cap B) = 0.3$, 求 $P(A | B)$ 和 $P(B | A)$ 。

思路: 条件概率定义 $P(A | B) = P(A \cap B) / P(B)$ 。

解:

$$P(A | B) = \frac{P(A \cap B)}{P(B)} = \frac{0.3}{0.5} = 0.6$$

$$P(B | A) = \frac{P(A \cap B)}{P(A)} = \frac{0.3}{0.6} = 0.5$$

答案: $P(A | B) = 0.6, P(B | A) = 0.5$

注: 此题中 $P(A | B) = P(A) = 0.6$ 且 $P(B | A) = P(B) = 0.5$, 说明 A 与 B 独立。

C.1.5 (Ch.2, 全概率公式)

题目: 三条生产线产量占比 50%、30%、20%, 次品率 2%、3%、5%, 求随机抽取一件为次品的概率。

思路: 以生产线为完备事件组, 用全概率公式展开。

解:

设 B_i 为来自第 i 条生产线, $P(B_1) = 0.5, P(B_2) = 0.3, P(B_3) = 0.2$; 次品率 $P(D | B_i)$ 分别为 0.02、0.03、0.05。

$$\begin{aligned}
 P(D) &= \sum_{i=1}^3 P(D | B_i)P(B_i) \\
 &= 0.02 \times 0.5 + 0.03 \times 0.3 + 0.05 \times 0.2 \\
 &= 0.010 + 0.009 + 0.010 = 0.029
 \end{aligned}$$

答案: $P(D) = 0.029$

C.1.6 (Ch.2, 贝叶斯公式)

题目: 延续 C.1.5, 已知抽到次品, 求它来自第三条生产线的概率。

思路: 贝叶斯公式, 分子为 $P(D | B_3)P(B_3)$, 分母为 C.1.5 的全概率。

解:

$$P(B_3 | D) = \frac{P(D | B_3)P(B_3)}{P(D)} = \frac{0.05 \times 0.2}{0.029} = \frac{0.010}{0.029} \approx 0.3448$$

答案: $P(B_3 | D) \approx 0.345$

注: 第三条生产线产量仅占 20%, 但次品率最高 (5%), 贡献比例达 34.5%, 远超其产量占比。

C.1.7 (Ch.2, 独立性判断)

题目: $P(A) = 0.4$, $P(B) = 0.5$, $P(A \cap B) = 0.2$, 判断 A 、 B 是否独立, 若独立求 $P(\bar{A} \cap \bar{B})$ 。

思路: 独立性等价于 $P(A \cap B) = P(A)P(B)$ 。

解:

步骤 1: 验证独立性。

$$P(A)P(B) = 0.4 \times 0.5 = 0.2 = P(A \cap B) \checkmark$$

故 A 、 B 独立。

步骤 2: $\bar{A}$ 、 $\bar{B}$ 也独立 (独立事件的对立事件仍独立)。

$$P(\bar{A} \cap \bar{B}) = P(\bar{A}) \cdot P(\bar{B}) = (1 - 0.4)(1 - 0.5) = 0.6 \times 0.5 = 0.3$$

答案: A 与 B 独立 $P(\bar{A} \cap \bar{B}) = 0.3$

C.1.8 (Ch.3, 排列计算)

题目: 从 $\{1, 2, 3, 4, 5, 6\}$ 不重复选 3 个数组成三位数, 求总数和首位为奇数的三位数个数。

思路: 排列计数, 第 1 问是 P_6^3 , 第 2 问首位固定奇数后分步计数。

解:

步骤 1: 总数: 从 6 个中取 3 个排列。

$$P_6^3 = 6 \times 5 \times 4 = 120$$

步骤 2: 首位为奇数 (1, 3, 5 共 3 个), 余下 5 个数中选 2 个排列。

$$3 \times P_5^2 = 3 \times 5 \times 4 = 60$$

答案: 120 个 60 个

C.1.9 (Ch.3, 组合计算)

题目: 从 10 名同学中选 3 人组成小组, 求总选法数和必含指定 1 人的选法数。

思路: 组合数 $\binom{n}{k}$, 第 2 问固定 1 人后从余下 9 人选 2 人。

解:

步骤 1:

$$\binom{10}{3} = \frac{10!}{3!7!} = \frac{10 \times 9 \times 8}{3 \times 2 \times 1} = 120$$

步骤 2: 指定 1 人已入选, 从余下 9 人选 2 人。

$$\binom{9}{2} = \frac{9 \times 8}{2} = 36$$

答案: 120 种; 必含指定同学时 36 种

C.1.10 (Ch.3, 二项式定理应用)

题目: 展开 $(1+x)^6$ 写出 x^2 项的系数; 利用该系数近似计算 1.02^6 (保留到 x^2 项)。

思路: 二项展开式的通项 $\binom{6}{k}x^k$; 令 $x = 0.02$ 代入前三项。

解:

步骤 1: x^2 项系数为 $\binom{6}{2} = 15$ 。

展开前三项: $(1+x)^6 = 1 + 6x + 15x^2 + \dots$

步骤 2: 令 $x = 0.02$:

$$1.02^6 \approx 1 + 6(0.02) + 15(0.02)^2 = 1 + 0.12 + 15 \times 0.0004 = 1 + 0.12 + 0.006 = 1.126$$

(精确值 ≈ 1.12616 , 误差 < 0.0002)

答案: x^2 项系数为 15; $1.02^6 \approx 1.126$

D 中等题详解 (12 题)

D.1.1 (Ch.2, 全概率 + 贝叶斯反推)

题目: 三台机器产量比 3:2:5, 次品率 0.01、0.02、0.03; 求 (a) 次品概率, (b) (c) 次品来自第 1、第 3 台机器的条件概率。

思路: 先用全概率公式求 $P(D)$, 再逐一用贝叶斯公式求 $P(B_i | D)$ 。

解:

步骤 1: 设 $P(B_1) = 0.3$, $P(B_2) = 0.2$, $P(B_3) = 0.5$ 。

$$P(D) = 0.01 \times 0.3 + 0.02 \times 0.2 + 0.03 \times 0.5 = 0.003 + 0.004 + 0.015 = 0.022$$

步骤 2 (a): $P(D) = 0.022$

步骤 3 (b):

$$P(B_1 | D) = \frac{0.01 \times 0.3}{0.022} = \frac{0.003}{0.022} \approx 0.1364$$

步骤 4 (c):

$$P(B_3 | D) = \frac{0.03 \times 0.5}{0.022} = \frac{0.015}{0.022} \approx 0.6818$$

答案: - (a) $P(D) = 0.022$ - (b) $P(B_1 | D) \approx 0.136$ - (c) $P(B_3 | D) \approx 0.682$

注: 第 3 台产量占 50%, 次品率最高, 贝叶斯更新后后验概率达 68%, 远高于先验 50%——次品”信号”使来源偏向次品率高的机器。

D.1.2 (Ch.1, 容斥原理三事件)

题目: 100 名学生中喜欢数学 60、物理 45、化学 30; 两两交集 20、15、10; 三者交集 5。求 (a) 至少一门, (b) 恰好一门, (c) 恰好两门的人数。

思路: 用三事件容斥公式, 再用逐层相减法。

解:

步骤 1 (a): 容斥公式。

$$|M \cup P \cup C| = 60 + 45 + 30 - 20 - 15 - 10 + 5 = 95$$

步骤 2 (c): 恰好两门 = 两两交集之和 - 3 倍三者交集 (每个三者交集在两两中被计了 3 次)。

$$\text{恰好两门} = (20 + 15 + 10) - 3 \times 5 = 45 - 15 = 30$$

步骤 3 (b): 恰好一门 = 至少一门 - 恰好两门 - 三者交集。

$$\text{恰好一门} = 95 - 30 - 5 = 60$$

答案: - (a) 95 人 - (b) 60 人 - (c) 30 人

□ 易错点: “恰好两门”不是直接用两两交集之和, 需减去三者同时包含在所有两两交集集中的部分 (三者交集 $\times 3$)。

D.1.3 (Ch.3, 几何概型)

题目: $[0, 3]$ 上独立均匀取 X, Y , 求 (a) $|X - Y| \leq 1$, (b) $X + Y \leq 3$ 且 $X \leq Y$, (c) $\max(X, Y) \leq 2$ 的概率。

思路: 样本空间为边长 3 的正方形 (面积 9), 用有利区域面积除以 9。

解:

步骤 1 (a): $|X - Y| \leq 1$ 的不利区域为两个三角形 ($X - Y > 1$ 和 $Y - X > 1$), 各面积 $\frac{1}{2} \times 2^2 = 2$, 合计 4。

$$P(|X - Y| \leq 1) = \frac{9 - 4}{9} = \frac{5}{9}$$

步骤 2 (b): 约束 $X + Y \leq 3, X \leq Y$ 。先 $X + Y \leq 3$ (下三角, 面积 4.5), 再限制 $X \leq Y$ (对角线以下半部), 交集面积 = 下三角中满足 $X \leq Y$ 的部分。下三角顶点为 $(0, 0), (3, 0), (0, 3)$, 其中 $X \leq Y$ 部分 ($Y \geq X$) 面积 = 下三角的一半 = 2.25。

$$P = \frac{2.25}{9} = \frac{1}{4}$$

步骤 3 (c): $\max(X, Y) \leq 2$ 等价于 $X \leq 2$ 且 $Y \leq 2$, 即正方形左下角 $[0, 2] \times [0, 2]$, 面积 4。

$$P(\max(X, Y) \leq 2) = \frac{4}{9}$$

答案: - (a) $\boxed{\frac{5}{9}}$ - (b) $\boxed{\frac{1}{4}}$ - (c) $\boxed{\frac{4}{9}}$

D.1.4 (Ch.2, 独立性与条件概率辨析)

题目: $P(A) = 0.4, P(B) = 0.3, P(A \cup B) = 0.58$, 求 (a) $P(A \cap B)$ 并判断独立性, (b) $P(A | B), P(B | A)$, (c) 若已知 $P(A | B^c) = 0.5$, 重新验证独立性。

思路: 由加法公式反解 $P(A \cap B)$, 独立性等价于 $P(A \cap B) = P(A)P(B)$; (c) 用定义验证。

解:

步骤 1 (a): $P(A \cap B) = P(A) + P(B) - P(A \cup B) = 0.4 + 0.3 - 0.58 = 0.12$ 。

$P(A)P(B) = 0.4 \times 0.3 = 0.12 = P(A \cap B)$, 故 A, B 独立。

步骤 2 (b):

$$P(A | B) = \frac{0.12}{0.3} = 0.4 = P(A), \quad P(B | A) = \frac{0.12}{0.4} = 0.3 = P(B)$$

步骤 3 (c): 若另给 $P(A | B^c) = 0.5$, 而 $P(A) = 0.4 \neq 0.5$, 这与 $A \perp B$ 矛盾 (独立时 $P(A | B^c) = P(A) = 0.4$)。说明 两个条件不能同时成立; 本题前提数据已确定独立, (c) 的额外条件与之矛盾。

答案: - (a) $P(A \cap B) = 0.12$, A, B 独立 - (b) $P(A | B) = 0.4, P(B | A) = 0.3$ - (c) 若 $P(A | B^c) = 0.5 \neq P(A) = 0.4$, 则 A, B 不独立 (条件与 (a) 矛盾, 实际数据不可能同时满足两组条件)

D.1.5 (Ch.3, 排列组合计数)

题目: 5 封不同的信随机投入 3 个不同邮箱, 求 (a) 每箱至少 1 封的概率, (b) 恰好 2 个邮箱为空的概率, (c) 指定邮箱恰好有 2 封信的概率。

思路: 每封信独立选邮箱, 总方案 $3^5 = 243$; 用容斥计算 (a)(b), 直接组合计数 (c)。

解:

步骤 1: 总方案数 $3^5 = 243$ 。

步骤 2 (a): 每箱至少 1 封, 用容斥 (包含-排除)。

设 A_i = 第 i 个邮箱为空。

$$|A_1 \cup A_2 \cup A_3| = 3 \cdot 2^5 - 3 \cdot 1^5 + 0 = 96 - 3 = 93$$

(三箱恰好有信) = $243 - 93 = 150$

$$P(\text{每箱至少 1 封}) = \frac{150}{243} = \frac{50}{81}$$

步骤 3 (b): 恰好 2 箱为空, 即 5 封信全投入 1 个邮箱: 选 1 个邮箱有 $\binom{3}{1} = 3$ 种, 每种有 1 种分配方式 (全投入那个箱), 共 3 种。

$$P(2 \text{ 箱为空}) = \frac{3}{243} = \frac{1}{81}$$

步骤 4 (c): 指定邮箱 (如邮箱 1) 恰好 2 封信: 从 5 封中选 2 封 $\binom{5}{2} = 10$, 余下 3 封投入其余 2 个邮箱 $2^3 = 8$, 共 80 种。

$$P(\text{指定箱恰好 2 封}) = \frac{80}{243}$$

答案: - (a) $\frac{50}{81} \approx 0.617$ - (b) $\frac{1}{81} \approx 0.012$ - (c) $\frac{80}{243} \approx 0.329$

D.1.6 (Ch.2, 条件概率链)

题目: 诊断测试灵敏度 95%, 特异度 97% (错误率 3%), 患病率 1%; 求 (a) 阳性概率, (b) 阳性预测值, (c) 假阴性率 (阴性时实际患病概率)。

思路: 先建立完备事件组 $\{D, \bar{D}\}$, 全概率 $\rightarrow$ 贝叶斯; (c) 是 $P(D | -)$ 。

解:

步骤 1 (a): 全概率。

$$\begin{aligned} P(+) &= P(+ | D)P(D) + P(+ | \bar{D})P(\bar{D}) \\ &= 0.95 \times 0.01 + 0.03 \times 0.99 = 0.0095 + 0.0297 = 0.0392 \end{aligned}$$

步骤 2 (b): 阳性预测值 (PPV)。

$$P(D | +) = \frac{0.95 \times 0.01}{0.0392} = \frac{0.0095}{0.0392} \approx 0.2423$$

步骤 3 (c): $P(-) = 1 - 0.0392 = 0.9608$ 。

$$P(D | -) = \frac{P(- | D)P(D)}{P(-)} = \frac{0.05 \times 0.01}{0.9608} = \frac{0.0005}{0.9608} \approx 0.00052$$

答案:-(a) $P(+) \approx 0.0392$ -(b) $\text{PPV} \approx 24.2\%$ (低患病率下阳性绝大多数为假阳性 !)- (c) $P(D | -) \approx 0.052\%$ (假阴性极低)

□ 易错点: 即使灵敏度、特异度都很高, 低基础发病率 (1%) 会导致阳性预测值远低于预期——这是 Bayes 定理的核心应用。

D.1.7 (Ch.1, 概率公理与简单证明)

题目: P 满足概率公理, $A \subset B$; 证明 (a) $P(B \setminus A) = P(B) - P(A)$, (b) $P(A) \leq P(B)$, (c) 有限可加性。

思路: 利用 $B = A \cup (B \setminus A)$ (不相交分解) 及概率的可加性。

解:

(a) 由 $A \subset B$, 有 $B = A \cup (B \setminus A)$, 且 A 与 $B \setminus A$ 互斥。由概率的有限可加性:

$$P(B) = P(A) + P(B \setminus A) \implies P(B \setminus A) = P(B) - P(A)$$

(b) 由概率非负性 $P(B \setminus A) \geq 0$, 故 $P(B) - P(A) \geq 0$, 即 $P(A) \leq P(B)$ 。

(c) 设 $A_1, \dots, A_n$ 两两互斥。由概率公理 (可列可加性), 对有限个互斥事件:

$$P\left(\bigcup_{i=1}^n A_i\right) = P\left(\bigcup_{i=1}^{\infty} A'_i\right)$$

其中令 $A'_i = A_i$ ($i \leq n$), $A'_i = \emptyset$ ($i > n$)。由可列可加性:

$$= \sum_{i=1}^{\infty} P(A'_i) = \sum_{i=1}^n P(A_i) + \sum_{i>n} P(\emptyset) = \sum_{i=1}^n P(A_i) \quad \square$$

答案: 三个命题均得证。核心工具: 互斥分解 + 可加性 + 非负性。

D.1.8 (Ch.3, 二项系数与概率)

题目: 独立射击 10 次, 命中率 $p = 0.6$; 求 (a) 恰好 6 次, (b) 不超过 4 次, (c) 至少 7 次的概率。

思路: $X \sim B(10, 0.6)$, $P(X = k) = \binom{10}{k} 0.6^k 0.4^{10-k}$ 。

解:

步骤 1 (a):

$$P(X = 6) = \binom{10}{6} 0.6^6 \cdot 0.4^4 = 210 \times 0.046656 \times 0.0256 \approx 0.2508$$

步骤 2 (b):

$$P(X \leq 4) = \sum_{k=0}^4 \binom{10}{k} 0.6^k 0.4^{10-k}$$

各项: $k = 0: 0.4^{10} \approx 0.0001$; $k = 1: \approx 0.0016$; $k = 2: \approx 0.0106$; $k = 3: \approx 0.0425$; $k = 4: \approx 0.1115$ 。合计 ≈ 0.1663 。

步骤 3 (c):

$$P(X \geq 7) = \sum_{k=7}^{10} \binom{10}{k} 0.6^k 0.4^{10-k}$$

$k = 7: \approx 0.2150$; $k = 8: \approx 0.1209$; $k = 9: \approx 0.0403$; $k = 10: \approx 0.0060$ 。合计 ≈ 0.3822 。

答案: - (a) $P(X = 6) \approx 0.251$ - (b) $P(X \leq 4) \approx 0.166$ - (c) $P(X \geq 7) \approx 0.382$

D.1.9 (Ch.2, 全概率 + 多阶段)

题目: 袋中 3 红 2 白, 有放回取 3 次; 求 (a) 3 次全红, (b) 恰好 2 个红球, (c) 已知第 3 次红、求第 1 次也红的概率。

思路: 有放回每次独立, $P(\text{红}) = 3/5$; (c) 用贝叶斯。

解:

步骤 1 (a):

$$P(\text{全红}) = \left(\frac{3}{5}\right)^3 = \frac{27}{125} = 0.216$$

步骤 2 (b): 三次中恰好 2 红, 服从 $B(3, 3/5)$ 。

$$P(\text{恰好 2 红}) = \binom{3}{2} \left(\frac{3}{5}\right)^2 \left(\frac{2}{5}\right) = 3 \times \frac{9}{25} \times \frac{2}{5} = \frac{54}{125} = 0.432$$

步骤 3 (c): 设 R_i 为第 i 次取红。求 $P(R_1 | R_3)$ 。

由独立性 (有放回), R_1 与 R_3 独立, 故:

$$P(R_1 | R_3) = P(R_1) = \frac{3}{5}$$

答案: - (a) $\boxed{\frac{27}{125}}$ - (b) $\boxed{\frac{54}{125}}$ - (c) $\boxed{\frac{3}{5}}$ (有放回时各次独立, 条件不影响结果)

D.1.10 (Ch.1, 事件运算与德摩根律)

题目: A, B, C 三事件; (a) 用集合表达“ A 发生但 B, C 均不发生”; (b) 证明德摩根律; (c) 两两独立且 $P(A) = P(B) = P(C) = 0.5$ 时, $P(A \cap B \cap C)$ 的取值范围。

思路: (a) 直接集合运算; (b) 元素属于关系互化; (c) 两两独立约束可解出范围。

解:

(a) 事件为 $A \cap \bar{B} \cap \bar{C}$ 。

(b) 证明 $\overline{A \cup B \cup C} = \bar{A} \cap \bar{B} \cap \bar{C}$:

任取 ω ,

$$\omega \in \overline{A \cup B \cup C} \iff \omega \notin A \cup B \cup C \iff \omega \notin A \text{ 且 } \omega \notin B \text{ 且 } \omega \notin C \iff \omega \in \bar{A} \cap \bar{B} \cap \bar{C} \quad \square$$

(c) 两两独立给出三个约束: $P(A \cap B) = P(A)P(B) = 0.25$, 同理另两对。

设 $p = P(A \cap B \cap C)$ 。用容斥:

$$P(A \cup B \cup C) = 3 \times 0.5 - 3 \times 0.25 + p = 0.75 + p$$

由概率非负: $P(\text{三者同时不发生}) = 1 - P(A \cup B \cup C) = 0.25 - p \geq 0$, 故 $p \leq 0.25$ 。

另由容斥的最小化条件及 $p \geq 0$: $p \in [0, 0.25]$ 。

经典例子: $p = 0$ (两两独立但非相互独立) 和 $p = 0.25$ (相互独立, $p = 0.5^3$)。

答案: - (a) $A \cap \bar{B} \cap \bar{C}$ - (b) 元素属于关系互化, 得证 - (c) $P(A \cap B \cap C) \in [0, 0.25]$

□ 易错点: 两两独立 $\nRightarrow$ 相互独立, $P(A \cap B \cap C)$ 可以是 $[0, 0.25]$ 内任意值。

D.1.11 (Ch.2, Borel-Cantelli 预备)

题目: 独立事件列 $\{A_n\}$, $P(A_n) = p \in (0, 1)$; 求 (a) 前 n 次一次不发生的概率, (b) 其极限, (c) 直觉解释“ A_n 无穷多次发生”的概率为 1。

思路: 独立性使概率连乘; 极限走向 0; Borel-Cantelli 第二引理给出直觉。

解:

(a) $A_1, \dots, A_n$ 独立, A_n 均不发生的概率:

$$P\left(\bigcap_{k=1}^n \bar{A}_k\right) = \prod_{k=1}^n (1-p) = (1-p)^n$$

(b) $0 < p < 1 \Rightarrow 0 < 1-p < 1$:

$$\lim_{n \rightarrow \infty} (1-p)^n = 0$$

即“永远不发生”的概率趋向 0。

(c) 由 (b), 前 n 次都不发生的概率趋向 0, 故补事件 (至少发生一次) 的概率趋向 1。更强地, Borel-Cantelli 第二引理: 当 $\sum_n P(A_n) = \sum_n p = \infty$ ($p > 0$) 且事件独立时, $P(A_n \text{ 无穷多次发生}) = 1$ 。

答案: - (a) $(1-p)^n$ - (b) 0 (极限) - (c) 由 $\sum P(A_n) = +\infty$ 和独立性, Borel-Cantelli 第二引理保证无穷次发生概率为 1

D.1.12 (Ch.3, 有限集合上的均匀模型)

题目: 从 $\{1, \dots, 52\}$ 有放回取 3 次; 求 (a) 三次均不同, (b) 恰好 2 个相同, (c) 无放回取 3 次时三次均不同的概率。

思路: (a)(b) 有放回, 总方案 52^3 ; (c) 无放回, 总方案 $52 \times 51 \times 50$ 。

解:

步骤 1 (a): 有放回时三次各不相同的有利方案数: $52 \times 51 \times 50$ (排列)。

$$P(\text{三次不同}) = \frac{52 \times 51 \times 50}{52^3} = \frac{51 \times 50}{52^2} = \frac{2550}{2704} \approx 0.9431$$

步骤 2 (b): 恰好 2 个相同: 选哪个值相同 $\binom{52}{1}$, 哪两次相同 $\binom{3}{2} = 3$, 第三次选不同值 51 种。

$$\text{方案数} = 52 \times 3 \times 51 = 7956$$

$$P(\text{恰好 2 个相同}) = \frac{7956}{52^3} = \frac{7956}{140608} \approx 0.0566$$

步骤 3 (c): 无放回时不存在相同值, 三次必然不同, 有利方案 $= P_{52}^3 = 52 \times 51 \times 50$, 总方案也是 $52 \times 51 \times 50$, 故:

$$P(\text{无放回三次不同}) = 1$$

□ 易错点: 无放回取 3 次, 由于每次不放回, 三次必然取到不同的数, 概率为 1 (而非 $\frac{52 \times 51 \times 50}{52^3}$, 那是有放回的公式)。

$$\text{答案: } - (a) \frac{2550}{2704} \approx 0.943 - (b) \frac{7956}{140608} \approx 0.0566 - (c) \boxed{1} \text{ (无放回必然不重复)}$$

E 提高题详解 (6 题)**E.1.1 (Ch.2, 贝叶斯多次更新 + 复制性危机)**

题目: 医学检测灵敏度 95%, 特异度 90%, 患病率 0.5%; 求 (a) 一次阳性后患病概率, (b) 两次阳性后患病概率, (c) 先验趋 0 时 PPV 趋 0 的证明与数值说明, (d) p 值与后验概率的区别。

思路: 两次贝叶斯链式更新; (c) 代数极限; (d) 类比分析 $P(\text{数据} | H_0)$ 与 $P(H_0 | \text{数据})$ 的差距。

解:

(a) 设 $\pi = P(D) = 0.005$, $s = 0.95$, $t = 0.90$ (特异度), 则 $P(+ | \bar{D}) = 1 - t = 0.10$ 。

$$P(+) = s \cdot \pi + (1 - t)(1 - \pi) = 0.95 \times 0.005 + 0.10 \times 0.995 = 0.00475 + 0.0995 = 0.10425$$

$$P(D | +) = \frac{s \cdot \pi}{P(+)} = \frac{0.00475}{0.10425} \approx 0.0456$$

(b) 以 $\pi_1 = P(D | +) \approx 0.0456$ 作为新先验, 进行第二次贝叶斯更新:

$$P(+ | \text{新先验}) = 0.95 \times 0.0456 + 0.10 \times 0.9544 \approx 0.04332 + 0.09544 = 0.13876$$

$$P(D | ++) = \frac{0.95 \times 0.0456}{0.13876} \approx \frac{0.04332}{0.13876} \approx 0.3122$$

两次阳性后患病概率约 **31%**, 仍有 69% 可能是假阳性。

(c) 令 $\pi \rightarrow 0$:

$$P(D | +) = \frac{s\pi}{s\pi + (1 - t)(1 - \pi)} \rightarrow \frac{0}{0 + (1 - t) \cdot 1} = 0$$

数值示例 ($\pi = 0.001$):

$$P(+) = 0.95 \times 0.001 + 0.10 \times 0.999 = 0.00095 + 0.0999 = 0.10085$$

$$P(D | +) = \frac{0.00095}{0.10085} \approx 0.0094 \approx 0.94\%$$

即使检测灵敏度高达 95%, 发病率仅 0.1% 时, 阳性的 99% 是假阳性!

(d) 类比: p 值 = $P(\text{数据} | H_0)$ (在 H_0 为真时观测到此极端数据的概率), 类比 $P(+ | \bar{D})$ (假阳性率)。研究者想要的是 $P(H_0 | \text{数据})$, 类比 $P(\bar{D} | +)$ 。两者差距由先验 (H_0 真实的基础概率) 决定: 若原假设在研究领域的先验概率很低 (如寻找小效应), p 值即使 < 0.05 也不意味着 H_0 不可信。发表偏倚 (只报告阳性结果) 进一步降低已发表研究的先验可信度。

答案: - (a) $P(D | +) \approx 4.56\%$ - (b) $P(D | ++) \approx 31.2\%$ - (c) 当 $\pi \rightarrow 0$, $P(D | +) \rightarrow 0$; $\pi = 0.001$ 时 PPV 仅约 0.94% - (d) p 值是似然比的一部分, 不是后验; 先验、功效和发表偏倚共同决定两者差距

E.1.2 (Ch.1+Ch.3, 容斥原理 + 泊松近似 + 生日问题)

题目: n 个两两独立事件 A_i , $P(A_i) = p$; 推导 (a) 容斥化简为 $1 - (1-p)^n$, (b) 泊松极限和收敛速率, (c) 生日问题精确与近似对比, (d) 三人同天生日的结构。

思路: (a) 二项展开; (b) 标准极限; (c) 直接代入; (d) 高阶容斥结构。

解:

(a) 容斥展开:

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{k=1}^n (-1)^{k+1} \binom{n}{k} p^k$$

(两两独立时, k 阶交集概率 $= p^k$)。识别这是 $1 - (1-p)^n$ 的展开:

$$(1-p)^n = \sum_{k=0}^n (-1)^k \binom{n}{k} p^k \implies 1 - (1-p)^n = \sum_{k=1}^n (-1)^{k+1} \binom{n}{k} p^k \quad \square$$

(b) 设 $np = \lambda$ (固定), $p = \lambda/n$:

$$1 - (1-p)^n = 1 - \left(1 - \frac{\lambda}{n}\right)^n \rightarrow 1 - e^{-\lambda} \quad (n \rightarrow \infty)$$

收敛速率: $|(1 - \lambda/n)^n - e^{-\lambda}| \leq \frac{\lambda^2}{n}$ (利用 $\ln(1-x) \approx -x - x^2/2$, 误差项量级为 $O(\lambda^2/n)$)。

(c) 生日问题: n 人, $m = 365$ 天, 同天生日 $\Leftrightarrow \binom{n}{2}$ 对中至少一对碰撞。

精确值 ($n = 23$):

$$P_{23} = 1 - \frac{365 \times 364 \times \cdots \times 343}{365^{23}} \approx 0.5073$$

泊松近似: $\lambda = \binom{23}{2}/365 = 253/365 \approx 0.6932$:

$$P \approx 1 - e^{-0.6932} = 1 - 0.5 = 0.5000$$

误差约 $|0.5073 - 0.5000| = 0.007$ (在 $\lambda^2/n \approx 0.48/23 \approx 0.021$ 上界内)。

(d) “至少三人同天”结构: 设 B_{ijk} 为 i, j, k 三人同天, $P(B_{ijk}) = 1/365^2$ (共 $\binom{n}{3}$ 对)。

$$P(\text{至少三人同天}) \approx 1 - P(\text{至多两人同天})$$

用包含-排除, 分析至多两人同天的精确计数复杂, 但可建立递推: 令 $Q(n) = P(\text{至多两人同天})$, 临界 n 约满足 $1 - Q(n) \approx 0.5$, 数值分析给出 $n \approx 88$ 。

答案: - (a) 二项展开等价, 得证 $P(\bigcup A_i) = 1 - (1 - p)^n$ - (b) 标准 e 定义极限, 收敛速率 $O(\lambda^2/n)$ - (c) 精确值 ≈ 0.507 , 泊松近似 ≈ 0.500 , 误差 ≈ 0.007 - (d) 容斥高阶结构, 临界 $n \approx 88$

E.1.3 (Ch.2, 条件独立性 + Simpson 悖论 + 因果推断)

题目: 临床试验分层数据 (轻症、重症), 治疗组在每层均优于对照组, 但合计劣于对照组; 分析 Simpson 悖论的数学根源与因果推断视角。

思路: 计算各层康复率, 用全概率公式揭示权重不均, 用 do-calculus 区分观测与干预。

解:

(a) 计算康复率 (精确到小数点后三位):

分组	治疗组	对照组
轻症	$81/87 = 0.931$	$234/270 = 0.867$
重症	$192/263 = 0.730$	$55/80 = 0.688$
合计	$273/350 = 0.780$	$289/350 = 0.826$

方向: 轻症 $T > C$, 重症 $T > C$, 但合计 $T < C$ 。悖论成立。

(b) 三个不等式:

$$\frac{81}{87} > \frac{234}{270} \checkmark, \quad \frac{192}{263} > \frac{55}{80} \checkmark, \quad \frac{273}{350} < \frac{289}{350} \checkmark$$

(c) 用全概率展开治疗组合计康复率:

$$P(R | T) = P(R | T, Z = \text{轻})P(Z = \text{轻} | T) + P(R | T, Z = \text{重})P(Z = \text{重} | T)$$

$$= 0.931 \times \frac{87}{350} + 0.730 \times \frac{263}{350} = 0.931 \times 0.249 + 0.730 \times 0.751$$

$$= 0.232 + 0.548 = 0.780 \quad \checkmark$$

类似地:

$$P(R | \bar{T}) = 0.867 \times \frac{270}{350} + 0.688 \times \frac{80}{350} = 0.867 \times 0.771 + 0.688 \times 0.229 = 0.669 + 0.157 = 0.826 \quad \checkmark$$

根源: 治疗组中重症比例 ($263/350=75\%$) 远高于对照组 ($80/350=23\%$)。重症康复率低, 拉低了治疗组整体康复率。混淆变量 Z (病情) 与处理 T 相关, 是悖论的数学根源。

(d) Pearl 的 do-calculus:

- $P(R | T)$ (观测): 在自然选择下, 重症更可能被分配到治疗组 (如医生判断), 因此携带混淆。
- $P(R | do(T))$ (干预): 随机化强制分配, 使 $Z \perp\!\!\!\perp T$, 消除混淆。

后门准则: Z 满足后门准则 (Z 阻断 $T \rightarrow R$ 之外的所有后门路径), 故:

$$\begin{aligned} P(R | do(T)) &= \sum_z P(R | T, Z = z)P(Z = z) \\ &= 0.931 \times \frac{357}{700} + 0.730 \times \frac{343}{700} \approx 0.931 \times 0.510 + 0.730 \times 0.490 = 0.475 + 0.358 = 0.833 \end{aligned}$$

类似调整后对照组 ≈ 0.817 , 治疗效果为正, 与分层一致。

答案: - (a) 各层 $T > C$, 合计 $T < C$, 悖论成立 - (b) 三不等式均验证成立 - (c) 混淆变量 Z 与 T 相关 ($P(Z | T) \neq P(Z | \bar{T})$), 全概率权重不均根源 - (d) $P(R | do(T))$ 通过后门调整消除混淆, 给出真实因果效应

E.1.4 (Ch.3, Borel 悖论 + 条件概率的测度论本质)

题目: 单位圆盘上均匀分布 (X, Y) ; 同一几何线段用直角/极坐标条件化得到不同条件分布——分析 Borel 悖论。

思路: 分别推导两种条件化的密度, 说明零测度集条件化依赖极限过程 (即坐标系), Kolmogorov 正则条件概率给出统一框架。

解:

(a) 直角坐标联合密度: $f_{X,Y}(x, y) = 1/\pi, (x^2 + y^2 \leq 1)$ 。

极坐标变换: $x = r \cos \theta, y = r \sin \theta$, Jacobian $= r$, 故:

$$f_{R,\Theta}(r, \theta) = f_{X,Y}(r \cos \theta, r \sin \theta) \cdot r = \frac{r}{\pi}, \quad 0 \leq r \leq 1, 0 \leq \theta < 2\pi$$

验证: $\int_0^{2\pi} \int_0^1 \frac{r}{\pi} dr d\theta = \frac{2\pi}{\pi} \cdot \frac{1}{2} = 1 \checkmark$

(b) 直角坐标下条件化 $\{X = 0\}$ 。

边际密度 $f_X(x) = \int_{-\sqrt{1-x^2}}^{\sqrt{1-x^2}} \frac{1}{\pi} dy = \frac{2\sqrt{1-x^2}}{\pi}$ 。

条件密度:

$$f_{Y|X}(y|0) = \frac{f_{X,Y}(0,y)}{f_X(0)} = \frac{1/\pi}{2/\pi} = \frac{1}{2}, \quad y \in [-1, 1]$$

即 $Y | \{X = 0\}$ 在 $[-1, 1]$ 上均匀分布。

(c) 极坐标下条件化 $\{\Theta = \pi/2\}$ (正 y 轴方向)。

边际密度 $f_{\Theta}(\theta) = \int_0^1 \frac{r}{\pi} dr = \frac{1}{2\pi}$ 。

条件密度:

$$f_{R|\Theta}(r|\pi/2) = \frac{f_{R,\Theta}(r, \pi/2)}{f_{\Theta}(\pi/2)} = \frac{r/\pi}{1/(2\pi)} = 2r, \quad r \in [0, 1]$$

即 $R | \{\Theta = \pi/2\}$ 的密度为 $2r$ (非均匀)。

(d) 几何上, $\{X = 0\} \cap \mathcal{D}$ 和 $\{\Theta = \pi/2\} \cap \mathcal{D}$ 是同一线段 (正 y 轴, $y \in [-1, 1]$), 但: - 直角坐标条件化: $Y | \{X = 0\} \sim U(-1, 1)$, 密度 $1/2$ 。- 极坐标条件化: $R | \{\Theta = \pi/2\} \propto r$, 密度 $2r$, 等价于点到原点距离的分布偏向远端。

两者等价于对同一集合的“不同极限逼近”(宽为 ϵ 的竖条 vs. 角度为 δ 的扇形), 极限过程不同导致结果不同。

Kolmogorov 正则条件概率: 通过指定 σ -代数 $\mathcal{G}$ (如 $\sigma(X)$ 或 $\sigma(\Theta)$), 唯一确定条件化方式, 从而消除悖论。条件期望 $E[h(X, Y) | \mathcal{G}]$ 作为随机变量, 满足几乎必然唯一性。

答案: - (a) 极坐标联合密度 $f_{R,\Theta} = r/\pi$, 验证积分为 1 - (b) $Y | \{X = 0\} \sim U(-1, 1)$ (均匀) - (c) $R | \{\Theta = \pi/2\}$ 密度为 $2r$ (非均匀) - (d) 同一集合因条件化极限过程不同而结果不同; Kolmogorov 通过 σ -代数给出唯一定义

E.1.5 (Ch.2+Ch.3, Pólya 瓮模型)

题目: 坛子初始 r 红 b 蓝, 每次取球后放回并加 c 个同色球; 求 (a) 取红球概率不变, (b) Pólya 分布 PMF, (c) $\hat{p}_n \rightarrow \text{Beta}(r/c, b/c)$, (d) 与中国餐馆过程和 Zipf 定律的关系。

思路: (a) 归纳法; (b) 序列对称性; (c) 鞅收敛; (d) 解释性分析。

解:

(a) $p_1 = r/(r+b)$ 。对 $n=2$, 全概率:

$$p_2 = \frac{r}{r+b} \cdot \frac{r+c}{r+b+c} + \frac{b}{r+b} \cdot \frac{r}{r+b+c} = \frac{r(r+c) + rb}{(r+b)(r+b+c)} = \frac{r(r+b+c)}{(r+b)(r+b+c)} = \frac{r}{r+b}$$

归纳假设 $p_{n-1} = r/(r+b)$, 对 n :

$$p_n = p_{n-1} \cdot \frac{r+(n-1)c}{r+b+(n-1)c} + (1-p_{n-1}) \cdot \frac{r}{r+b+(n-1)c}$$

$$= \frac{r}{r+b} \cdot \frac{r+(n-1)c}{r+b+(n-1)c} + \frac{b}{r+b} \cdot \frac{r}{r+b+(n-1)c} = \frac{r[r+b+(n-1)c]}{(r+b)[r+b+(n-1)c]} = \frac{r}{r+b} \quad \square$$

(b) 固定序列 (如 k 次红、 $n-k$ 次蓝的特定顺序), 概率为:

$$\frac{r(r+c)\cdots(r+(k-1)c)}{(r+b)(r+b+c)\cdots(r+b+(n-1)c)} \cdot \frac{b(b+c)\cdots(b+(n-k-1)c)}{1}$$

每种包含 k 红 $n-k$ 蓝的序列等概率 (可验证交换顺序不改变积), 共 $\binom{n}{k}$ 种。故:

$$P(S_n = k) = \binom{n}{k} \frac{r^{(k)}b^{(n-k)}}{(r+b)^{(n)}}$$

其中 $a^{(m)} = a(a+c)(a+2c)\cdots(a+(m-1)c)$ 为步长 c 的上升阶乘。

(c) $\hat{p}_n = S_n/n$ 是有界鞅 (由 (a), $E[\hat{p}_n] = r/(r+b)$ 为常数)。鞅收敛定理给出 $\hat{p}_n \xrightarrow{a.s.} \hat{p}_\infty$ 。计算矩:

$$E[\hat{p}_n^m] \rightarrow E[\hat{p}_\infty^m]$$

可以证明极限矩与 $\text{Beta}(r/c, b/c)$ 的矩一致 (通过上升阶乘递推), 由矩唯一性得 $\hat{p}_\infty \sim \text{Beta}(r/c, b/c)$ 。

(d) 中国餐馆过程: $n+1$ 个顾客选桌, 以概率 $\propto n_k$ (已坐人数) 选第 k 桌, 或以概率 $\propto \alpha$ 开新桌。等价于 Pólya 瓮 (每种颜色 = 一张桌)。在 NLP 中, 词频分布满足幂律 (Zipf 定律): 第 k 频繁词的频率 $\propto 1/k$ 。Pólya 瓮的“富者愈富”机制 (高频词更容易被选中) 正是 Zipf 分布的生成机制。Dirichlet 过程 ($K \rightarrow \infty$) 是连续推广。

答案: - (a) 归纳证明 $p_n = r/(r+b)$ 对所有 n 成立 - (b) $P(S_n = k) = \binom{n}{k} \frac{r^{(k)}b^{(n-k)}}{(r+b)^{(n)}}$ - (c) $\hat{p}_n \xrightarrow{a.s.} \text{Beta}(r/c, b/c)$ (鞅收敛 + 矩唯一性) - (d) 等价于中国餐馆过程; “富者愈富”机制产生 Zipf 幂律

E.1.6 (Ch.1+Ch.2+Ch.3, 生日攻击与密码学应用)

题目: Hash 函数输出空间大小 m , 随机查询 n 次寻找碰撞; 推导 (a) 无碰撞概率近似, (b) Union Bound 上界, (c) Poisson 近似与临界 n , (d) SHA-256 的碰撞界与量子计算影响。

思路: 经典生日问题推广到密码学; 逐步从精确到近似, 再到实用安全分析。

解:

(a) 无碰撞精确概率:

$$P(\text{无碰撞}) = \frac{m(m-1)\cdots(m-n+1)}{m^n} = \prod_{k=0}^{n-1} \left(1 - \frac{k}{m}\right)$$

取对数:

$$\ln P(\text{无碰撞}) = \sum_{k=0}^{n-1} \ln\left(1 - \frac{k}{m}\right) \approx -\sum_{k=0}^{n-1} \frac{k}{m} = -\frac{n(n-1)}{2m}$$

故 $P(\text{无碰撞}) \approx e^{-n(n-1)/(2m)}$ 。

(b) Union Bound: 碰撞事件为 $\bigcup_{i < j} B_{ij}$ 。

$$P(\text{至少一次碰撞}) \leq \sum_{i < j} P(B_{ij}) = \binom{n}{2} \cdot \frac{1}{m} = \frac{n(n-1)}{2m}$$

当 $n \ll m$ 时, B_{ij} 几乎不相关, 上界接近精确值 (精确值 $\approx 1 - e^{-n(n-1)/(2m)} \approx n(n-1)/(2m)$)。

(c) 令 $\lambda = \binom{n}{2}/m$, 碰撞次数 $\approx \text{Poisson}(\lambda)$ (各对碰撞事件近似独立, 概率小):

$$P(\text{至少一次碰撞}) \approx 1 - e^{-\lambda}$$

令 $P \geq 0.5$:

$$1 - e^{-\lambda} \geq 0.5 \implies \lambda \geq \ln 2 \implies \frac{n^2}{2m} \geq \ln 2 \implies n \geq \sqrt{2m \ln 2}$$

(d) SHA-256: $m = 2^{256}$ 。

$$n \approx \sqrt{2 \cdot 2^{256} \cdot \ln 2} = \sqrt{\ln 2} \cdot 2^{128} \approx 0.832 \cdot 2^{128} \approx 2^{127.9} \approx 2^{128}$$

即经典计算下需要约 2^{128} 次查询才能以 50% 概率找到碰撞——这解释了“256 位哈希的碰撞抵抗等价于 128 位安全级别”。

量子计算 (Grover 算法) 对碰撞搜索的加速: 量子计算机可在 $O(m^{1/3})$ 时间找到碰撞 (BHT 算法), 而非经典的 $O(m^{1/2})$:

$$n_{\text{quantum}} \approx m^{1/3} = 2^{256/3} \approx 2^{85.3}$$

故量子计算机将 SHA-256 的碰撞安全性从 128 位降至约 85 位——这也是为什么量子时代需要更长的哈希输出 (如 SHA-384 或 SHA-512)。

答案: - (a) $P(\text{无碰撞}) \approx e^{-n(n-1)/(2m)}$ (利用 $\ln(1-x) \approx -x$) - (b) Union Bound: $P(\text{碰撞}) \leq n(n-1)/(2m)$, $n \ll m$ 时紧 - (c) Poisson 近似, 临界 $n \approx \sqrt{2m \ln 2}$ - (d) SHA-256: 经典碰撞界 2^{128} , 量子界 $2^{85.3}$; 256 位安全 $\Leftrightarrow$ 经典 128 位碰撞抵抗

F2 详解: Part 2 随机变量 (Ch.4-6, 共 35 题)

覆盖离散随机变量 (Ch.4)、连续随机变量 (Ch.5)、多维随机变量 (Ch.6)。题型: PMF/PDF 归一化、期望与方差、CDF 互化、联合/边际/条件分布、协方差与相关系数、函数变换、条件期望、矩母函数。

C 基础题详解 (12 题)

C.2.1 (Ch.4, PMF 归一化)

题目: 离散随机变量 X 的 PMF 为 $P(X = k) = ck$, $k = 1, 2, 3, 4$, 求常数 c 及 $P(X \geq 3)$ 。

思路: 利用归一化条件 $\sum_k P(X = k) = 1$, 解出 c ; 再直接累加 $P(X = 3) + P(X = 4)$ 。

解:

第 1 小问:

$$\sum_{k=1}^4 ck = c(1 + 2 + 3 + 4) = 10c = 1 \implies c = \frac{1}{10}$$

第 2 小问:

$$P(X \geq 3) = P(X = 3) + P(X = 4) = \frac{3}{10} + \frac{4}{10} = \frac{7}{10}$$

答案: $c = \boxed{\frac{1}{10}}$, $P(X \geq 3) = \boxed{0.7}$

C.2.2 (Ch.4, 期望与方差)

题目: 离散随机变量 X 的分布律为

X	-1	0	1	2
P	0.2	0.3	0.4	0.1

求 $E[X]$ 和 $\text{Var}(X)$ 。

思路: 按定义逐项加权求和; 方差用 $\text{Var}(X) = E[X^2] - (E[X])^2$ 。

解:

$$E[X] = (-1)(0.2) + 0(0.3) + 1(0.4) + 2(0.1) = -0.2 + 0 + 0.4 + 0.2 = 0.4$$

$$E[X^2] = 1(0.2) + 0(0.3) + 1(0.4) + 4(0.1) = 0.2 + 0 + 0.4 + 0.4 = 1.0$$

$$\text{Var}(X) = E[X^2] - (E[X])^2 = 1.0 - 0.16 = 0.84$$

答案: $E[X] = \boxed{0.4}$, $\text{Var}(X) = \boxed{0.84}$

C.2.3 (Ch.4, CDF 与 PMF 关系)

题目: X 的 PMF 为 $P(X = k) = \frac{1}{4}$, $k = 1, 2, 3, 4$, 求 CDF 在各整数点的值及 $P(1 < X \leq 3)$ 。

思路: CDF $F(x) = P(X \leq x) = \sum_{k \leq x} P(X = k)$, 逐步累加; 区间概率用 CDF 差。

解:

$$F(1) = \frac{1}{4}, \quad F(2) = \frac{2}{4} = \frac{1}{2}, \quad F(3) = \frac{3}{4}, \quad F(4) = 1$$

$$P(1 < X \leq 3) = F(3) - F(1) = \frac{3}{4} - \frac{1}{4} = \frac{1}{2}$$

□ 易错点: $P(1 < X \leq 3) = F(3) - F(1)$, 左端开区间不含 $x = 1$, 故减去 $F(1)$ 而非 $F(2)$ 。

答案: $F(1) = \frac{1}{4}$, $F(2) = \frac{1}{2}$, $F(3) = \frac{3}{4}$, $F(4) = 1$; $P(1 < X \leq 3) = \boxed{\frac{1}{2}}$

C.2.4 (Ch.5, PDF 归一化)

题目: 连续随机变量 X 的 PDF 为 $f(x) = cx^2$ ($0 \leq x \leq 2$), 求 c 及 $P(1 \leq X \leq 2)$ 。

思路: 归一化 $\int_0^2 cx^2 dx = 1$, 解 c ; 概率为对应积分。

解:

第 1 小问:

$$\int_0^2 cx^2 dx = c \cdot \frac{x^3}{3} \Big|_0^2 = c \cdot \frac{8}{3} = 1 \implies c = \frac{3}{8}$$

第 2 小问:

$$P(1 \leq X \leq 2) = \int_1^2 \frac{3}{8} x^2 dx = \frac{3}{8} \cdot \frac{x^3}{3} \Big|_1^2 = \frac{1}{8}(8-1) = \frac{7}{8}$$

答案: $c = \boxed{\frac{3}{8}}$, $P(1 \leq X \leq 2) = \boxed{\frac{7}{8}}$

C.2.5 (Ch.5, 期望与方差——连续型)

题目: $X \sim U(0, 4)$, 写出 PDF, 计算 $E[X]$ 和 $\text{Var}(X)$ 。

思路: 均匀分布 PDF 为常数; 套公式 $E[X] = (a+b)/2$, $\text{Var}(X) = (b-a)^2/12$ 。

解:

$$f(x) = \begin{cases} \frac{1}{4}, & 0 \leq x \leq 4 \\ 0, & \text{其他} \end{cases}$$

$$E[X] = \frac{0+4}{2} = 2$$

$$\text{Var}(X) = \frac{(4-0)^2}{12} = \frac{16}{12} = \frac{4}{3}$$

答案: $E[X] = \boxed{2}$, $\text{Var}(X) = \boxed{\frac{4}{3}}$

C.2.6 (Ch.5, 正态标准化)

题目: $X \sim N(3, 4)$, 求标准化变量 Z 的分布, 及 $P(1 \leq X \leq 7)$ (用 Φ 表示)。

思路: 正态标准化 $Z = (X - \mu)/\sigma$; 将原概率转化为标准正态区间。

解:

第 1 小问: $Z = \frac{X-3}{2} \sim N(0, 1)$ 。

第 2 小问:

$$P(1 \leq X \leq 7) = P\left(\frac{1-3}{2} \leq Z \leq \frac{7-3}{2}\right) = P(-1 \leq Z \leq 2)$$

$$= \Phi(2) - \Phi(-1) = \Phi(2) - (1 - \Phi(1))$$

答案: $Z \sim N(0, 1)$; $P(1 \leq X \leq 7) = \boxed{\Phi(2) - \Phi(-1)} = \Phi(2) + \Phi(1) - 1$

C.2.7 (Ch.5, CDF 与 PDF 互化)

题目: X 的 CDF 为 $F(x) = x^2$ ($0 \leq x \leq 1$), 求 PDF $f(x)$ 及 $P(0.5 \leq X \leq 0.8)$ 。

思路: PDF 为 CDF 对 x 求导; 概率直接用 CDF 差。

解:

第 1 小问: 对 $F(x)$ 求导:

$$f(x) = F'(x) = \begin{cases} 2x, & 0 \leq x \leq 1 \\ 0, & \text{其他} \end{cases}$$

第 2 小问:

$$P(0.5 \leq X \leq 0.8) = F(0.8) - F(0.5) = 0.64 - 0.25 = 0.39$$

答案: $f(x) = 2x$ ($0 \leq x \leq 1$); $P(0.5 \leq X \leq 0.8) = \boxed{0.39}$

C.2.8 (Ch.6, 联合 PMF 与边缘分布)

题目: (X, Y) 的联合 PMF 为

	$Y = 0$	$Y = 1$
$X = 0$	0.1	0.3
$X = 1$	0.4	0.2

求边缘 PMF, 判断独立性。

思路: 边缘 PMF 按行/列求和; 独立性判据 $P(X = x, Y = y) = P(X = x)P(Y = y)$ 。

解:

边缘 PMF:

$$P(X=0) = 0.1 + 0.3 = 0.4, \quad P(X=1) = 0.4 + 0.2 = 0.6$$

$$P(Y=0) = 0.1 + 0.4 = 0.5, \quad P(Y=1) = 0.3 + 0.2 = 0.5$$

独立性检验: 若独立, $P(X=0, Y=0) = 0.4 \times 0.5 = 0.2$, 但实际为 $0.1 \neq 0.2$ 。

答案: $P(X=0) = 0.4$, $P(X=1) = 0.6$, $P(Y=0) = P(Y=1) = 0.5$; X 与 Y 不独立。

C.2.9 (Ch.6, 条件分布)

题目: 延续 C.2.8, 求条件 PMF $P(Y=y | X=1)$ 及 $E[Y | X=1]$ 。

思路: 条件 PMF = 联合 PMF 除以边缘 PMF; 条件期望加权求和。

解:

$$P(Y=0 | X=1) = \frac{P(X=1, Y=0)}{P(X=1)} = \frac{0.4}{0.6} = \frac{2}{3}$$

$$P(Y=1 | X=1) = \frac{0.2}{0.6} = \frac{1}{3}$$

$$E[Y | X=1] = 0 \cdot \frac{2}{3} + 1 \cdot \frac{1}{3} = \frac{1}{3}$$

答案: $P(Y=0 | X=1) = \frac{2}{3}$, $P(Y=1 | X=1) = \frac{1}{3}$; $E[Y | X=1] = \frac{1}{3}$

C.2.10 (Ch.6, 协方差与相关系数)

题目: 已知 $E[X] = 1$, $E[Y] = 2$, $E[XY] = 3$, $\text{Var}(X) = 2$, $\text{Var}(Y) = 3$, 求 $\text{Cov}(X, Y)$ 和 ρ_{XY} 。

思路: $\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$; $\rho_{XY} = \text{Cov}/(\sigma_X\sigma_Y)$ 。

解:

$$\text{Cov}(X, Y) = E[XY] - E[X]E[Y] = 3 - 1 \times 2 = 1$$

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}} = \frac{1}{\sqrt{2} \cdot \sqrt{3}} = \frac{1}{\sqrt{6}}$$

答案: $\text{Cov}(X, Y) = \boxed{1}$, $\rho_{XY} = \boxed{\frac{1}{\sqrt{6}}}$

C.2.11 (Ch.6, 期望与方差的线性性)

题目: X, Y 独立, $E[X] = 2$, $E[Y] = 5$, $\text{Var}(X) = 3$, $\text{Var}(Y) = 4$, 求 $E[3X - 2Y + 1]$ 和 $\text{Var}(3X - 2Y + 1)$ 。

思路: 期望线性性直接代入; 独立时方差: $\text{Var}(aX + bY) = a^2\text{Var}(X) + b^2\text{Var}(Y)$, 常数不影响方差。

解:

$$E[3X - 2Y + 1] = 3E[X] - 2E[Y] + 1 = 3(2) - 2(5) + 1 = 6 - 10 + 1 = -3$$

$$\text{Var}(3X - 2Y + 1) = 3^2\text{Var}(X) + (-2)^2\text{Var}(Y) = 9(3) + 4(4) = 27 + 16 = 43$$

□ 易错点: 常数 +1 对方差无贡献; 独立时 $\text{Cov}(X, Y) = 0$, 方差可直接相加 (含系数平方)。

答案: $E[3X - 2Y + 1] = \boxed{-3}$, $\text{Var}(3X - 2Y + 1) = \boxed{43}$

C.2.12 (Ch.6, 联合 PDF 与边缘密度)

题目: 联合 PDF 为 $f(x, y) = 6x$ ($0 \leq x \leq 1$, $0 \leq y \leq x$), 求 X 的边缘 PDF $f_X(x)$ 并验证归一化。

思路: 边缘密度对 y 从 0 到 x 积分; 归一化再对 x 从 0 到 1 积分验证等于 1。

解:

第 1 小问: 对 $0 \leq x \leq 1$:

$$f_X(x) = \int_0^x 6x \, dy = 6x \cdot x = 6x^2$$

$$f_X(x) = \begin{cases} 6x^2, & 0 \leq x \leq 1 \\ 0, & \text{其他} \end{cases}$$

第 2 小问:

$$\int_0^1 6x^2 \, dx = 6 \cdot \frac{x^3}{3} \Big|_0^1 = 2 \cdot 1 = 2 \neq 1$$

等等, 重新检验原始积分域: $0 \leq y \leq x \leq 1$, 联合密度 $f(x, y) = 6x$ 。

验证总概率:

$$\int_0^1 \int_0^x 6x \, dy \, dx = \int_0^1 6x^2 \, dx = [2x^3]_0^1 = 2$$

原题联合 PDF 有误 (此为典型出题错误), 若接受 $f_X(x) = 6x^2$ ($0 \leq x \leq 1$), 则验证:

$$\int_0^1 6x^2 \, dx = 2 \neq 1$$

说明联合 PDF 总概率为 2, 归一化常数应为 $3x$ (令 $f(x, y) = 3x$)。但按题目原文 $f(x, y) = 6x$, 边缘密度为 $f_X(x) = 6x^2$, $0 \leq x \leq 1$; 验证时总积分为 2 (题目本身联合密度未归一化, 此处按题意写出推导)。

□ 易错点: 写出边缘密度时积分上限取决于联合分布的支撑域形状 (此处 y 上限为 x , 不是 1)。

答案: $f_X(x) = \boxed{6x^2}$, $0 \leq x \leq 1$; 总积分验证 $\int_0^1 6x^2 \, dx = 2$ (联合密度未归一化; 若以题目为准, $f_X(x) = 6x^2$ 为正确边缘密度形式)。

D 中等题详解 (15 题)

D.2.1 (Ch.5, 连续随机变量函数变换)

题目: $X \sim U(0, 2)$, 令 $Y = X^2$, 求 $f_Y(y)$ 、 $E[Y]$ 、 $\text{Var}(Y)$ 。

思路: 先求 Y 的 CDF (由 X 的 CDF 推出), 再求导得 PDF; $E[Y]$ 可用 LOTUS; $\text{Var}(Y) = E[Y^2] - (E[Y])^2$ 。

解:

(a) 求 $f_Y(y)$:

$X \sim U(0, 2)$, PDF $f_X(x) = \frac{1}{2}$, $x \in [0, 2]$ 。

$Y = X^2$ 的支撑: $Y \in [0, 4]$ 。对 $y \in [0, 4]$:

$$F_Y(y) = P(Y \leq y) = P(X^2 \leq y) = P(X \leq \sqrt{y}) = \frac{\sqrt{y}}{2}$$

$$f_Y(y) = F'_Y(y) = \frac{1}{2} \cdot \frac{1}{2\sqrt{y}} = \frac{1}{4\sqrt{y}}, \quad y \in (0, 4]$$

验证: $\int_0^4 \frac{1}{4\sqrt{y}} \, dy = \frac{1}{4} \cdot 2\sqrt{y} \Big|_0^4 = \frac{1}{2} \cdot 2 = 1$ 。□

(b) 求 $E[Y]$ (两种方法):

• LOTUS: $E[Y] = E[X^2] = \int_0^2 x^2 \cdot \frac{1}{2} dx = \frac{1}{2} \cdot \frac{8}{3} = \frac{4}{3}$

• 直接用 f_Y : $E[Y] = \int_0^4 y \cdot \frac{1}{4\sqrt{y}} dy = \frac{1}{4} \int_0^4 \sqrt{y} dy = \frac{1}{4} \cdot \frac{2}{3} y^{3/2} \Big|_0^4 = \frac{1}{6} \cdot 8 = \frac{4}{3} \square$

(c) 求 $\text{Var}(Y)$:

$$E[Y^2] = E[X^4] = \int_0^2 x^4 \cdot \frac{1}{2} dx = \frac{1}{2} \cdot \frac{32}{5} = \frac{16}{5}$$

$$\text{Var}(Y) = E[Y^2] - (E[Y])^2 = \frac{16}{5} - \frac{16}{9} = \frac{144 - 80}{45} = \frac{64}{45}$$

答案:

$$f_Y(y) = \boxed{\frac{1}{4\sqrt{y}}}, \quad y \in (0, 4]; \quad E[Y] = \boxed{\frac{4}{3}}; \quad \text{Var}(Y) = \boxed{\frac{64}{45}}$$

D.2.2 (Ch.4, 离散随机变量的矩)

题目: X 的分布律含未知参数 a, b , 且 $E[X] = 0.4$, 确定 a, b 并求 $E[X^2]$ 、 $\text{Var}(X)$ 、 $E[3X^2 - 2X + 1]$ 。

x	-1	0	1	2
p	a	0.3	0.2	b

思路: 联立归一化方程和期望方程解 a, b ; 然后算各矩。

解:

(a) 确定 a, b :

归一化: $a + 0.3 + 0.2 + b = 1 \Rightarrow a + b = 0.5$

期望: $(-1)a + 0(0.3) + 1(0.2) + 2b = 0.4 \Rightarrow -a + 2b = 0.2$

两式联立: $a + b = 0.5$, $-a + 2b = 0.2$, 相加得 $3b = 0.7$, 故 $b = \frac{7}{30}$, $a = 0.5 - b = \frac{15-7}{30} = \frac{8}{30} = \frac{4}{15}$ 。

验证: $a = \frac{4}{15} \approx 0.267$, $b = \frac{7}{30} \approx 0.233$, $a + b = \frac{8+7}{30} = \frac{1}{2}$ 。 $\square$

(b) 求 $E[X^2]$ 和 $\text{Var}(X)$:

$$E[X^2] = 1 \cdot \frac{4}{15} + 0 \cdot 0.3 + 1 \cdot 0.2 + 4 \cdot \frac{7}{30} = \frac{4}{15} + 0.2 + \frac{28}{30}$$

$$= \frac{8}{30} + \frac{6}{30} + \frac{28}{30} = \frac{42}{30} = \frac{7}{5} = 1.4$$

$$\text{Var}(X) = E[X^2] - (E[X])^2 = 1.4 - 0.16 = 1.24$$

(c) 求 $E[3X^2 - 2X + 1]$:

$$E[3X^2 - 2X + 1] = 3E[X^2] - 2E[X] + 1 = 3(1.4) - 2(0.4) + 1 = 4.2 - 0.8 + 1 = 4.4$$

答案: $a = \boxed{\frac{4}{15}}$, $b = \boxed{\frac{7}{30}}$; $E[X^2] = \boxed{1.4}$, $\text{Var}(X) = \boxed{1.24}$; $E[3X^2 - 2X + 1] = \boxed{4.4}$

D.2.3 (Ch.5, 正态分布分位数与标准化)

题目: $X \sim N(2, 9)$, 用 Φ 表达各概率, 并求满足 $P(X > c) = 0.05$ 的 c 。

思路: 令 $Z = (X - 2)/3$, 将区间转化为标准正态; 分位数用 Φ^{-1} 反求。

解:

(a) $P(1 \leq X \leq 5)$:

$$Z = \frac{X - 2}{3}: \quad P\left(\frac{1 - 2}{3} \leq Z \leq \frac{5 - 2}{3}\right) = P\left(-\frac{1}{3} \leq Z \leq 1\right) = \Phi(1) - \Phi\left(-\frac{1}{3}\right)$$

(b) $P(|X - 2| > 3)$:

$$P(|X - 2| > 3) = P\left(|Z| > \frac{3}{3}\right) = P(|Z| > 1) = 2(1 - \Phi(1)) = 2\Phi(-1)$$

(c) 求 c ($P(X > c) = 0.05$):

$$P(X > c) = P\left(Z > \frac{c - 2}{3}\right) = 0.05 \Rightarrow \frac{c - 2}{3} = z_{0.05} \approx 1.645$$

$$c = 2 + 3 \times 1.645 = 2 + 4.935 = 6.935$$

答案:

(a) $P(1 \leq X \leq 5) = \Phi(1) - \Phi(-\frac{1}{3})$; (b) $P(|X - 2| > 3) = \boxed{2(1 - \Phi(1))}$; (c) $c = \boxed{2 + 3z_{0.05} \approx 6.935}$

D.2.4 (Ch.4, 泊松过程初步)

题目: 某网站每分钟访问量 $\sim \text{Poisson}(3)$, 求无访问概率、超过 5 次概率, 以及每次访问产生 0.1 元收益时的期望和方差。

思路: 泊松 PMF 直接代入; 收益 $R = 0.1X$ 的期望方差用线性变换。

解:

(a) 无访问概率 ($P(X = 0)$):

$$P(X = 0) = e^{-3} \frac{3^0}{0!} = e^{-3} \approx 0.0498$$

(b) 超过 5 次概率:

$$\begin{aligned} P(X > 5) &= 1 - P(X \leq 5) = 1 - \sum_{k=0}^5 e^{-3} \frac{3^k}{k!} \\ &= 1 - e^{-3} \left(1 + 3 + \frac{9}{2} + \frac{9}{2} + \frac{27}{8} + \frac{81}{40} \right) = 1 - e^{-3} \cdot \frac{311}{40} \end{aligned}$$

(保留累积泊松 CDF 形式)

(c) 每分钟收益 $R = 0.1X$ 的期望和方差:

$$E[R] = 0.1 \cdot E[X] = 0.1 \times 3 = 0.3 \text{ 元}$$

$$\text{Var}(R) = (0.1)^2 \text{Var}(X) = 0.01 \times 3 = 0.03 \text{ 元}^2$$

答案: $P(X = 0) = \boxed{e^{-3}}$; $P(X > 5) = 1 - e^{-3} \sum_{k=0}^5 \frac{3^k}{k!}$; $E[R] = \boxed{0.3}$ 元, $\text{Var}(R) = \boxed{0.03}$ 元²

D.2.5 (Ch.5, 指数分布无记忆性)

题目: $X \sim \text{Exp}(0.1)$, 求 $P(X > 20)$, 证明无记忆性, 并用无记忆性求已工作 10 小时后再工作 15 小时的概率。

思路: 指数分布 $P(X > t) = e^{-\lambda t}$; 无记忆性 $P(X > s + t | X > s) = P(X > t)$, 用条件概率定义证明。

解:

(a) $P(X > 20)$:

$$P(X > 20) = e^{-0.1 \times 20} = e^{-2} \approx 0.1353$$

(b) 证明无记忆性: 对任意 $s, t > 0$,

$$P(X > s + t \mid X > s) = \frac{P(X > s + t)}{P(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(X > t)$$

证毕。无记忆性在概率意义上: 已知元件正常工作了 s 小时, 其“剩余寿命”仍服从同参数指数分布。

(c) 已工作 10 小时, 再工作 15 小时的概率:

由无记忆性:

$$P(X > 10 + 15 \mid X > 10) = P(X > 15) = e^{-0.1 \times 15} = e^{-1.5} \approx 0.2231$$

答案: $P(X > 20) = \boxed{e^{-2}}$; 无记忆性已证; $P(X > 25 \mid X > 10) = \boxed{e^{-1.5}}$

D.2.6 (Ch.4, 期望与方差的线性性)

题目: X, Y 独立, $E[X] = 1$, $\text{Var}(X) = 2$, $E[Y] = -1$, $\text{Var}(Y) = 3$, 求 $E[2X - 3Y + 4]$ 、 $\text{Var}(2X - 3Y + 4)$ 、 $E[XY]$ 、 $E[X^2Y^2]$ 。

思路: 线性性直接代入; 独立时 $E[XY] = E[X]E[Y]$, $E[X^2Y^2] = E[X^2]E[Y^2]$ 。

解:

(a):

$$E[2X - 3Y + 4] = 2(1) - 3(-1) + 4 = 2 + 3 + 4 = 9$$

(b):

$$\text{Var}(2X - 3Y + 4) = 4\text{Var}(X) + 9\text{Var}(Y) = 4(2) + 9(3) = 8 + 27 = 35$$

(c):

$$E[XY] = E[X] \cdot E[Y] = 1 \times (-1) = -1$$

$$E[X^2] = \text{Var}(X) + (E[X])^2 = 2 + 1 = 3$$

$$E[Y^2] = \text{Var}(Y) + (E[Y])^2 = 3 + 1 = 4$$

$$E[X^2Y^2] = E[X^2] \cdot E[Y^2] = 3 \times 4 = 12$$

答案: $E[2X - 3Y + 4] = \boxed{9}$; $\text{Var}(2X - 3Y + 4) = \boxed{35}$; $E[XY] = \boxed{-1}$; $E[X^2Y^2] = \boxed{12}$

D.2.7 (Ch.5, 均匀分布的顺序统计量)

题目: $X_1, X_2, X_3 \stackrel{iid}{\sim} U(0, 1)$, $M = \max(X_1, X_2, X_3)$, 求 $F_M(m)$ 、 $f_M(m)$ 、 $E[M]$ 。

思路: 最大值的 CDF 为各分量 CDF 之积 (独立时); 求导得 PDF; 期望直接积分。

解:

(a) $F_M(m)$: 对 $m \in [0, 1]$,

$$F_M(m) = P(M \leq m) = P(X_1 \leq m, X_2 \leq m, X_3 \leq m) = m^3$$

(b) $f_M(m)$:

$$f_M(m) = F'_M(m) = 3m^2, \quad m \in [0, 1]$$

(这是 Beta(3, 1) 分布的密度。)

(c) $E[M]$:

$$E[M] = \int_0^1 m \cdot 3m^2 dm = 3 \int_0^1 m^3 dm = 3 \cdot \frac{1}{4} = \frac{3}{4}$$

□ 易错点: n 个 i.i.d. $U(0, 1)$ 随机变量的最大值 $X_{(n)} \sim \text{Beta}(n, 1)$, 期望为 $n/(n+1)$ 。这里 $n = 3$, $E[M] = 3/4$ 。

答案: $F_M(m) = m^3$ ($m \in [0, 1]$); $f_M(m) = \boxed{3m^2}$; $E[M] = \boxed{\frac{3}{4}}$

D.2.8 (Ch.4, 条件期望)

题目: 掷骰子得 N , 再掷 N 枚硬币得正面数 X , 求 $E[X | N = n]$ 、 $E[X]$ (重期望)、 $\text{Var}(X)$ (条件方差公式)。

思路: 给定 $N = n$, $X \sim B(n, 1/2)$; 重期望 $E[X] = E[E[X | N]]$; 条件方差公式分解总方差。

解:

(a) $E[X | N = n]$:

给定 $N = n$, $X \sim B(n, 1/2)$, 故 $E[X | N = n] = \frac{n}{2}$ 。即 $E[X | N] = \frac{N}{2}$ 。

(b) $E[X]$ (重期望):

骰子 N 均匀分布在 $\{1, 2, 3, 4, 5, 6\}$, $E[N] = \frac{1+2+\dots+6}{6} = \frac{21}{6} = \frac{7}{2}$ 。

$$E[X] = E\left[\frac{N}{2}\right] = \frac{E[N]}{2} = \frac{7/2}{2} = \frac{7}{4}$$

(c) $\text{Var}(X)$ (条件方差公式):

$$\text{Var}(X) = E[\text{Var}(X | N)] + \text{Var}(E[X | N])$$

给定 $N = n$, $\text{Var}(X | N = n) = n \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{n}{4}$, 所以 $\text{Var}(X | N) = \frac{N}{4}$ 。

$$E[\text{Var}(X | N)] = E\left[\frac{N}{4}\right] = \frac{7/2}{4} = \frac{7}{8}$$

$$\text{Var}(E[X | N]) = \text{Var}\left(\frac{N}{2}\right) = \frac{1}{4}\text{Var}(N)$$

$$\text{Var}(N) = E[N^2] - (E[N])^2 = \frac{1 + 4 + 9 + 16 + 25 + 36}{6} - \left(\frac{7}{2}\right)^2 = \frac{91}{6} - \frac{49}{4} = \frac{182 - 147}{12} = \frac{35}{12}$$

$$\text{Var}(E[X | N]) = \frac{1}{4} \cdot \frac{35}{12} = \frac{35}{48}$$

$$\text{Var}(X) = \frac{7}{8} + \frac{35}{48} = \frac{42}{48} + \frac{35}{48} = \frac{77}{48}$$

答案: $E[X | N = n] = \frac{n}{2}$; $E[X] = \boxed{\frac{7}{4}}$; $\text{Var}(X) = \boxed{\frac{77}{48}}$

D.2.9 (Ch.5, 混合分布)

题目: X 以概率 p 服从 $\text{Exp}(1)$, 以概率 $1-p$ 退化于 0, 求 CDF、 $E[X]$ 、 $E[X^2]$ 、 $\text{Var}(X)$ 。

思路: 混合 CDF 为各分量 CDF 的加权和; 期望/矩用全期望公式 (含点质量)。

解:

(a) CDF: 设 $I \in \{0, 1\}$ ($P(I=1) = p$), 当 $I=1$ 时 $X \sim \text{Exp}(1)$, 当 $I=0$ 时 $X=0$:

$$F_X(x) = \begin{cases} 0, & x < 0 \\ (1-p) + p(1-e^{-x}), & x \geq 0 \end{cases} = \begin{cases} 0, & x < 0 \\ 1-pe^{-x}, & x \geq 0 \end{cases}$$

($x=0$ 处有质量 $1-p$, 即 $P(X=0) = 1-p$; $x>0$ 绝对连续部分密度为 pe^{-x} 。)

(b) $E[X]$ 和 $E[X^2]$:

$$E[X] = p \cdot E[\text{Exp}(1)] + (1-p) \cdot 0 = p \cdot 1 = p$$

$$E[X^2] = p \cdot E[X_{\text{Exp}}^2] + (1-p) \cdot 0 = p \cdot 2 = 2p$$

($\text{Exp}(1)$ 的二阶矩: $E[X^2] = \text{Var} + \mu^2 = 1 + 1 = 2$ 。)

(c) $\text{Var}(X)$:

$$\text{Var}(X) = E[X^2] - (E[X])^2 = 2p - p^2 = p(2-p)$$

答案: $F_X(x) = 1 - pe^{-x}$ ($x \geq 0$); $E[X] = \boxed{p}$; $E[X^2] = \boxed{2p}$; $\text{Var}(X) = \boxed{p(2-p)}$

D.2.10 (Ch.4, 矩母函数入门)

题目: $X \sim \text{Bernoulli}(p)$, 计算 MGF $M_X(t)$, 用导数求 $E[X]$ 和 $E[X^2]$, 推广到 $Y = \sum_{i=1}^n X_i$ 。

思路: $M_X(t) = E[e^{tX}]$ 对 $X \in \{0, 1\}$ 求和; $E[X^k] = M_X^{(k)}(0)$; 独立时 MGF 相乘。

解:

(a) $M_X(t)$:

$$M_X(t) = E[e^{tX}] = e^{t \cdot 0}(1-p) + e^{t \cdot 1}p = (1-p) + pe^t = 1-p+pe^t$$

(b) 利用导数求矩:

$$M'_X(t) = pe^t \implies E[X] = M'_X(0) = p$$

$$M''_X(t) = pe^t \implies E[X^2] = M''_X(0) = p$$

(注: 对 Bernoulli 分布, $E[X^2] = E[X] = p$, 因为 $X^2 = X$ a.s.)

(c) $Y = X_1 + \cdots + X_n$ 的 MGF:

由独立性, MGF 相乘:

$$M_Y(t) = \prod_{i=1}^n M_{X_i}(t) = (1 - p + pe^t)^n$$

这正是 $B(n, p)$ 的 MGF, 故 $Y \sim B(n, p)$ (二项分布)。

答案: $M_X(t) = \boxed{1 - p + pe^t}$; $E[X] = p$, $E[X^2] = p$; $M_Y(t) = (1 - p + pe^t)^n$, $Y \sim \boxed{B(n, p)}$

D.2.11 (Ch.5, Beta 分布积分)

题目: $X \sim \text{Beta}(2, 3)$, 密度 $f(x) = 12x(1-x)^2$ ($0 < x < 1$), 验证归一化, 求 $E[X]$ 、 $E[X^2]$ 、 $\text{Var}(X)$ 。

思路: 展开或用 Beta 函数公式 $\int_0^1 x^{a-1}(1-x)^{b-1}dx = B(a, b) = (a-1)!(b-1)!/(a+b-1)!$ (整数时)。

解:

(a) 验证归一化:

$$\begin{aligned} \int_0^1 12x(1-x)^2 dx &= 12 \int_0^1 x(1-2x+x^2) dx = 12 \int_0^1 (x-2x^2+x^3) dx \\ &= 12 \left[\frac{1}{2} - \frac{2}{3} + \frac{1}{4} \right] = 12 \cdot \frac{6-8+3}{12} = 12 \cdot \frac{1}{12} = 1 \checkmark \end{aligned}$$

(b) $E[X]$ 和 $E[X^2]$:

$$E[X] = \int_0^1 x \cdot 12x(1-x)^2 dx = 12 \int_0^1 x^2(1-x)^2 dx = 12 \cdot B(3, 3) = 12 \cdot \frac{2!2!}{4!} = 12 \cdot \frac{4}{24} = 2$$

等等, $B(3, 3) = \frac{2!2!}{5!-1}$ ——应用公式 $B(a, b) = \frac{(a-1)!(b-1)!}{(a+b-1)!}$:

$$B(3, 3) = \frac{2!2!}{4!} = \frac{4}{24} = \frac{1}{6}$$

$$E[X] = 12 \cdot B(3, 3) = 12 \cdot \frac{1}{6} = 2$$

□ 易错点: $E[X] = \int_0^1 x \cdot 12x(1-x)^2 dx = 12 \int_0^1 x^2(1-x)^2 dx = 12B(3, 3) = 2$? 实际上理论值 $E[X] = \alpha/(\alpha + \beta) = 2/(2 + 3) = 2/5$, 请重新计算:

$$E[X] = 12 \int_0^1 x^2(1-x)^2 dx = 12 \cdot \frac{\Gamma(3)\Gamma(3)}{\Gamma(6)} = 12 \cdot \frac{2! \cdot 2!}{5!} = 12 \cdot \frac{4}{120} = \frac{48}{120} = \frac{2}{5}$$

$$(B(a, b) = \Gamma(a)\Gamma(b)/\Gamma(a+b), \quad B(3, 3) = \frac{2!2!}{5!} = \frac{4}{120} = \frac{1}{30})$$

$$E[X^2] = 12 \int_0^1 x^3(1-x)^2 dx = 12 \cdot B(4, 3) = 12 \cdot \frac{3! \cdot 2!}{6!} = 12 \cdot \frac{12}{720} = \frac{144}{720} = \frac{1}{5}$$

(c) $\text{Var}(X)$:

$$\text{Var}(X) = E[X^2] - (E[X])^2 = \frac{1}{5} - \frac{4}{25} = \frac{5-4}{25} = \frac{1}{25}$$

$$\text{验证: 公式 } \text{Var} = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)} = \frac{2 \cdot 3}{25 \cdot 6} = \frac{6}{150} = \frac{1}{25} \quad \square$$

$$\text{答案: 归一化已验证; } E[X] = \boxed{\frac{2}{5}}; \quad E[X^2] = \boxed{\frac{1}{5}}; \quad \text{Var}(X) = \boxed{\frac{1}{25}}$$

D.2.12 (Ch.4, 负二项分布)

题目: 独立重复试验 (成功概率 p), X 为第 r 次成功所需总试验次数, 写出 PMF、验证 $r=1$ 退化几何、解释期望。

思路: 第 k 次试验是第 r 次成功, 意味着前 $k-1$ 次中恰好有 $r-1$ 次成功。

解:

(a) PMF:

$$P(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad k = r, r+1, r+2, \dots$$

组合解释: 第 k 次必须是成功, 前 $k-1$ 次中恰好有 $r-1$ 次成功 ($\binom{k-1}{r-1}$ 种排列), 乘以 $p^{r-1}(1-p)^{k-r}$; 再乘以第 k 次成功的概率 p 。

(b) $r=1$ 时退化为几何分布:

$$P(X = k)|_{r=1} = \binom{k-1}{0} p^1 (1-p)^{k-1} = p(1-p)^{k-1}$$

这正是几何分布 $\text{Geom}(p)$ 的 PMF。□

(c) 期望解释 ($r = 3, p = 0.5$):

$E[X] = r/p = 3/0.5 = 6$, 即平均需要 6 次试验才能获得第 3 次成功。直觉: 每次成功平均需要 $1/p = 2$ 次试验, r 次成功共需约 $r \times (1/p) = 6$ 次。

答案:

$$P(X = k) = \boxed{\binom{k-1}{r-1} p^r (1-p)^{k-r}}, \quad k = r, r+1, \dots$$

$r = 1$ 时退化为 $\text{Geom}(p)$; $r = 3, p = 0.5$ 时 $E[X] = \boxed{6}$

D.2.13 (Ch.5, 截断分布)

题目: $X \sim \text{Exp}(1)$, 条件随机变量 $Y = (X \mid X \leq 2)$, 求 CDF、密度、 $E[Y]$, 并与 $E[X] = 1$ 比较。

思路: 截断分布 CDF $F_Y(y) = P(X \leq y \mid X \leq 2) = F_X(y)/F_X(2)$ ($y \leq 2$); 密度对应归一化; 期望直接积分。

解:

(a) CDF 和密度:

对 $y \in [0, 2]$:

$$F_Y(y) = \frac{P(X \leq y)}{P(X \leq 2)} = \frac{1 - e^{-y}}{1 - e^{-2}}$$

$$f_Y(y) = F'_Y(y) = \frac{e^{-y}}{1 - e^{-2}}, \quad 0 \leq y \leq 2$$

(b) $E[Y]$:

$$E[Y] = \int_0^2 y \cdot \frac{e^{-y}}{1 - e^{-2}} dy = \frac{1}{1 - e^{-2}} \int_0^2 y e^{-y} dy$$

积分 $\int_0^2 y e^{-y} dy$ (分部积分, 令 $u = y, dv = e^{-y} dy$):

$$\int_0^2 y e^{-y} dy = [-y e^{-y}]_0^2 + \int_0^2 e^{-y} dy = -2e^{-2} + [-e^{-y}]_0^2 = -2e^{-2} + (1 - e^{-2}) = 1 - 3e^{-2}$$

$$E[Y] = \frac{1 - 3e^{-2}}{1 - e^{-2}} \approx \frac{1 - 3(0.1353)}{1 - 0.1353} = \frac{0.5941}{0.8647} \approx 0.687$$

(c) 比较:

$E[Y] \approx 0.687 < E[X] = 1$ 。截断到 $[0, 2]$ 后, 均值下降 (合理: 仅保留了小值部分, 去掉了大于 2 的右尾)。

答案: $f_Y(y) = \frac{e^{-y}}{1 - e^{-2}} \quad (0 \leq y \leq 2)$; $E[Y] = \boxed{\frac{1 - 3e^{-2}}{1 - e^{-2}}}$; 截断后均值下降 ($\approx 0.687 < 1$)

D.2.14 (Ch.6, 二维联合分布协方差)

题目: (X, Y) 联合分布律如下, 求边际分布, 判断独立性, 求 $\text{Cov}(X, Y)$ 和 $\rho(X, Y)$ 。

	Y = 0	Y = 1
X = 0	0.1	0.2
X = 1	0.3	0.4

解:

(a) 边际分布:

$$P(X = 0) = 0.1 + 0.2 = 0.3, \quad P(X = 1) = 0.3 + 0.4 = 0.7$$

$$P(Y = 0) = 0.1 + 0.3 = 0.4, \quad P(Y = 1) = 0.2 + 0.4 = 0.6$$

(b) 独立性:

若独立, $P(X = 0, Y = 0) = P(X = 0)P(Y = 0) = 0.3 \times 0.4 = 0.12 \neq 0.1$, 故 X 与 Y 不独立。

(c) 协方差和相关系数:

$$E[X] = 0(0.3) + 1(0.7) = 0.7, \quad E[Y] = 0(0.4) + 1(0.6) = 0.6$$

$$E[XY] = \sum_{x,y} xy \cdot P(X = x, Y = y) = 0 \cdot 0 + 0 \cdot 0.2 + 0 \cdot 0.3 + 1 \cdot 1 \cdot 0.4 = 0.4$$

$$\text{Cov}(X, Y) = E[XY] - E[X]E[Y] = 0.4 - 0.7 \times 0.6 = 0.4 - 0.42 = -0.02$$

$$\text{Var}(X) = E[X^2] - (E[X])^2 = 0.7 - 0.49 = 0.21$$

$$\text{Var}(Y) = E[Y^2] - (E[Y])^2 = 0.6 - 0.36 = 0.24$$

$$\rho(X, Y) = \frac{-0.02}{\sqrt{0.21} \times \sqrt{0.24}} = \frac{-0.02}{\sqrt{0.0504}} \approx \frac{-0.02}{0.2245} \approx -0.089$$

答案: 边际分布如上; X, Y 不独立; $\text{Cov}(X, Y) = \boxed{-0.02}$; $\rho(X, Y) \approx \boxed{-0.089}$

D.2.15 (Ch.6, 二维连续分布的条件密度)

题目: 联合密度 $f(x, y) = 2$ ($0 < x < y < 1$), 求边际密度、条件密度 $f_{Y|X}(y|x)$ 、 $E[Y|X = x]$, 并验证 $E[E[Y|X]] = E[Y]$ 。

思路: 支撑域为三角形 $0 < x < y < 1$; 对 y 积分 (从 x 到 1) 得 $f_X(x)$; 对 x 积分 (从 0 到 y) 得 $f_Y(y)$ 。

解:

(a) 边际密度:

$$f_X(x) = \int_x^1 2 dy = 2(1-x), \quad 0 < x < 1$$

$$f_Y(y) = \int_0^y 2 dx = 2y, \quad 0 < y < 1$$

验证: $\int_0^1 2(1-x)dx = 1$, $\int_0^1 2y dy = 1$ 。□

(b) 条件密度 $f_{Y|X}(y|x)$ (给定 $X = x$, y 在 $(x, 1)$ 上):

$$f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)} = \frac{2}{2(1-x)} = \frac{1}{1-x}, \quad x < y < 1$$

即给定 $X = x$, Y 在 $(x, 1)$ 上均匀分布。

(c) 条件期望 $E[Y|X = x]$:

$$E[Y|X = x] = \int_x^1 y \cdot \frac{1}{1-x} dy = \frac{1}{1-x} \cdot \frac{1-x^2}{2} = \frac{1+x}{2}$$

验证重期望:

$$E[E[Y|X]] = \int_0^1 \frac{1+x}{2} \cdot 2(1-x) dx = \int_0^1 (1+x)(1-x) dx = \int_0^1 (1-x^2) dx = 1 - \frac{1}{3} = \frac{2}{3}$$

$$E[Y] = \int_0^1 y \cdot 2y \, dy = 2 \int_0^1 y^2 \, dy = \frac{2}{3} \checkmark$$

答案: $f_X(x) = 2(1-x)$, $f_Y(y) = 2y$; $f_{Y|X}(y|x) = \boxed{\frac{1}{1-x}}$ ($x < y < 1$); $E[Y|X=x] = \boxed{\frac{1+x}{2}}$; 重期望验证成立 (均等于 $\frac{2}{3}$)

E 提高题详解 (8 题)

E.2.1 (Ch.5+Ch.6, 卷积 + Irwin-Hall 分布 + CLT 预热)

题目: X, Y i.i.d. $\sim U(0, 1)$, $Z = X + Y$, 推导 $f_Z(z)$; 用 MGF 分析 $S_n = \sum_{i=1}^n X_i$ (Irwin-Hall); 讨论 $n = 12$ 的正态近似; 分析尾部误差来源。

思路: 卷积 $f_Z(z) = \int f_X(x)f_Y(z-x)dx$, 分两段计算; MGF 乘积得 S_n 的矩; CLT 说明近似精度。

解:

(a) 卷积推导 $f_Z(z)$:

$f_X(x) = f_Y(x) = 1$ ($0 \leq x \leq 1$), 卷积:

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(x)f_Y(z-x) \, dx$$

需要 $0 \leq x \leq 1$ 且 $0 \leq z-x \leq 1$, 即 $\max(0, z-1) \leq x \leq \min(1, z)$ 。

段 1 ($0 \leq z \leq 1$): $0 \leq x \leq z$,

$$f_Z(z) = \int_0^z 1 \cdot 1 \, dx = z$$

段 2 ($1 < z \leq 2$): $z-1 \leq x \leq 1$,

$$f_Z(z) = \int_{z-1}^1 1 \, dx = 1 - (z-1) = 2-z$$

$$f_Z(z) = \begin{cases} z, & 0 \leq z \leq 1 \\ 2-z, & 1 < z \leq 2 \\ 0, & \text{其他} \end{cases}$$

验证: $\int_0^1 z \, dz + \int_1^2 (2-z) \, dz = \frac{1}{2} + \frac{1}{2} = 1$ 。□

形状: 以 $z = 1$ 为顶点的等腰三角形 (帽型)。

(b) Irwin-Hall 分布的 MGF:

$X_i \sim U(0, 1)$ 的 MGF: $M_X(t) = E[e^{tX}] = \int_0^1 e^{tx} dx = \frac{e^t - 1}{t} \quad (t \neq 0)$ 。

独立时, $S_n = \sum_{i=1}^n X_i$ 的 MGF:

$$M_{S_n}(t) = \left(\frac{e^t - 1}{t} \right)^n$$

由 MGF 求矩 (展开 $(e^t - 1)/t$ 的 Taylor 级数):

$$\frac{e^t - 1}{t} = 1 + \frac{t}{2} + \frac{t^2}{6} + \dots = \exp\left(\frac{t}{2} - \frac{t^2}{12} + O(t^3)\right)$$

$$\ln M_{S_n}(t) = n \ln \frac{e^t - 1}{t} = n \left(\frac{t}{2} + \frac{t^2}{12} + \dots \right)$$

一阶系数 (累积量 = 均值): $E[S_n] = n/2$; 二阶累积量 (方差): $\text{Var}(S_n) = n/12$ 。

(c) $n = 12$ 时的正态近似精度:

S_{12} 有均值 6、方差 1 ($= 12/12$), 故 $S_{12} - 6 \approx N(0, 1)$ 。

- 精确值: S_{12} 有有界支撑 $[0, 12]$, 在 $|z| > 6$ 处概率严格为 0, 但 $N(0, 1)$ 在此处有非零概率。
- 对 $z = 3$ (即 $|S_{12} - 6| > 3$, 3σ 以外): 正态给出 $P \approx 0.0027$; Irwin-Hall ($n = 12$) 已近乎零 (支撑限制)。
- 尾部误差: $U(0, 1)$ 的有界支撑导致 S_{12} 的分布比正态尾部更“轻”——Box-Muller 变换 ($Z_1 = \sqrt{-2 \ln U_1} \cos(2\pi U_2)$) 利用逆变换直接生成精确正态变量, 无支撑截断问题。

(d) 正态生成比较 (伪代码):

```
import numpy as np
from scipy import stats

for n in [12, 100, 1000]:
    samples = np.sum(np.random.uniform(0, 1, (100000, n)), axis=1)
    samples_std = (samples - n/2) / np.sqrt(n/12)
    D, p = stats.kstest(samples_std, 'norm')
    print(f"n={n}: KS 统计量 = {D:.4f}, p 值 = {p:.4g}")
```

KS 统计量随 n 增大而减小 (CLT 收敛), 但 $n = 12$ 时尾部 ($|z| > 3$) 误差来自 $U(0, 1)$ 的有界支撑 (S_{12} 必须在 $[0, 12]$ 内, 而正态无此约束)。

答案:

$$f_Z(z) = \begin{cases} z, & 0 \leq z \leq 1 \\ 2-z, & 1 < z \leq 2 \end{cases} \quad (\text{三角形})$$

$$M_{S_n}(t) = \left(\frac{e^t - 1}{t} \right)^n; \quad E[S_n] = \left\lfloor \frac{n}{2} \right\rfloor, \quad \text{Var}(S_n) = \left\lfloor \frac{n}{12} \right\rfloor; \quad \text{尾部误差来自有界支撑, Box-Muller 更精确。}$$

E.2.2 (Ch.4, Galton-Watson 分支过程 + PGF)

题目: Galton-Watson 过程, PGF $G(s) = \sum p_k s^k$, 证明 $E[Z_n] = \mu^n$, 分析灭绝概率, 显式求解几何后代情形, 联系语言模型生成。

思路: PGF 的嵌套性质 $G_{Z_n}(s) = G_{Z_{n-1}}(G(s))$ 是核心; 灭绝概率满足不动点方程 $q = G(q)$; 凸分析 ($G'(1) = \mu$) 决定 q 的位置。

解:

(a) $E[Z_n] = \mu^n$ 的证明:

设 $G_{Z_n}(s) = E[s^{Z_n}]$ 。利用全期望 (给定 Z_1 , 每个个体独立产后代):

$$G_{Z_n}(s) = G_{Z_{n-1}}(G(s)) = G^{(n)}(s) \text{ (} G \text{ 的 } n \text{ 次迭代)}$$

对 s 求导并令 $s = 1$:

$$G'_{Z_n}(1) = G'_{Z_{n-1}}(G(1)) \cdot G'(1) = G'_{Z_{n-1}}(1) \cdot \mu$$

由归纳法 (基: $G'_{Z_1}(1) = G'(1) = \mu$): $G'_{Z_n}(1) = \mu^n$, 即 $E[Z_n] = \mu^n$ 。

方差推导 ($\mu \neq 1$):

对 $G''_{Z_n}(1)$ 递推 (利用链式法则), 经计算:

$$\text{Var}(Z_n) = \frac{\sigma^2 \mu^{n-1} (\mu^n - 1)}{\mu - 1}$$

($\mu = 1$ 时特殊情形: $\text{Var}(Z_n) = n\sigma^2$, 线性增长。)

(b) 灭绝概率 q 的分析:

$q = \lim_{n \rightarrow \infty} P(Z_n = 0)$ 满足 $G(q) = q$ (不动点方程)。

存在性 (介值定理): $G(0) = p_0 \geq 0$, $G(1) = 1$; G 在 $[0, 1]$ 上连续, 故至少存在 $q \in [0, 1]$ 使 $G(q) = q$ 。

位置分析: $G(s)$ 在 $[0, 1]$ 上凸 ($G'' \geq 0$), $G'(1) = \mu$ 。

- 若 $\mu > 1$: 切线斜率 $\mu > 1$, 曲线 $y = G(s)$ 在 $s = 1$ 处从下方穿越直线 $y = s$, 故在 $(0, 1)$ 内存在另一个交点 $q^* < 1$, 最小不动点为 $q^* < 1$ (灭绝概率 < 1)。
- 若 $\mu \leq 1$: 曲线在 $[0, 1]$ 上始终低于 $y = s$ (或相切于 $s = 1$), 最小不动点为 $q^* = 1$ (必然灭绝)。

(c) 几何后代 $p_k = (1-p)p^k$ ($k \geq 0$) 的显式求解:

$$G(s) = \sum_{k=0}^{\infty} (1-p)p^k s^k = \frac{1-p}{1-ps}$$

$$\mu = G'(1) = \frac{p(1-p)}{(1-p)^2} = \frac{p}{1-p} \quad (\mu > 1 \text{ 当 } p > 1/2)。$$

不动点方程 $G(q) = q$:

$$\frac{1-p}{1-pq} = q \implies 1-p = q(1-pq) = q - pq^2$$

$$pq^2 - q + (1-p) = 0$$

判别式: $1 - 4p(1-p) = (1-2p)^2$, 根为 $q = \frac{1 \pm (1-2p)}{2p}$:

- $q = 1$ (总是一个根)
- $q = \frac{1-(1-2p)}{2p} = \frac{2p-1+1-1}{2p}$, 等等:

$$q = \frac{1-(1-2p)}{2p} = \frac{2p}{2p} = 1 \quad \text{或} \quad q = \frac{1+(1-2p)}{2p} = \frac{2(1-p)}{2p} = \frac{1-p}{p}$$

当 $p > 1/2$ ($\mu > 1$) 时, 最小根 $q^* = \frac{1-p}{p} < 1$ (与理论一致□)。

(d) 类比 Transformer 生成:

每个 token 通过注意力机制影响后续 token, 若平均"信息扇出" $\mu > 1$, 主题链路呈指数增长 ($\log Z_n \approx n \log \mu$), 导致主题漂移 (每一层推理引入新的"子话题")。温度参数 $T < 1$ 通过 softmax 使分布更集中, 等效降低 μ , 减少分支, 提高生成连贯性 (但也降低多样性)。

答案:

$$E[Z_n] = \boxed{\mu^n} \quad (\text{归纳法 + PGF 嵌套}); \quad \mu > 1 \text{ 时 } q^* < 1, \quad \mu \leq 1 \text{ 时 } q^* = 1; \quad \text{几何后代 } q^* = \boxed{\frac{1-p}{p}} \quad (p > 1/2)$$

E.2.3 (Ch.5+Ch.6, 柯西分布 + 无期望 + 稳定分布)

题目: X, Y i.i.d. $\sim N(0, 1)$, $C = X/Y$, 推导 C 的密度, 证明 $E[|C|] = +\infty$, 用特征函数证明稳定性, 讨论金融尾部风险。

思路: 对 $P(C \leq c)$ 分 $Y > 0$ 、 $Y < 0$ 两种情形; 求导得密度; 验证期望积分发散; 特征函数 $\varphi_C(t) = e^{-|t|}$ 。

解:

(a) 推导柯西密度 $f_C(c)$:

$$P(C \leq c) = P\left(\frac{X}{Y} \leq c\right)$$

分情形:

$$= P(X \leq cY, Y > 0) + P(X \geq cY, Y < 0)$$

$$= \int_0^\infty \int_{-\infty}^{cy} \phi(x)\phi(y) dx dy + \int_{-\infty}^0 \int_{cy}^\infty \phi(x)\phi(y) dx dy$$

其中 ϕ 为标准正态密度。对 c 求导 (用 Leibniz 法则):

$$\begin{aligned} f_C(c) &= \int_0^\infty y\phi(cy)\phi(y) dy + \int_{-\infty}^0 (-y)\phi(cy)\phi(y) dy = \int_{-\infty}^\infty |y|\phi(cy)\phi(y) dy \\ &= \int_0^\infty 2y\phi(cy)\phi(y) dy = 2 \int_0^\infty y \cdot \frac{1}{2\pi} e^{-\frac{c^2 y^2 + y^2}{2}} dy = \frac{1}{\pi} \int_0^\infty y e^{-\frac{(1+c^2)y^2}{2}} dy \end{aligned}$$

令 $u = (1+c^2)y^2/2$, $du = (1+c^2)y dy$:

$$f_C(c) = \frac{1}{\pi} \cdot \frac{1}{1+c^2} \int_0^\infty e^{-u} du = \frac{1}{\pi(1+c^2)}$$

这正是柯西分布 (标准) 密度。□

(b) 证明 $E[|C|] = +\infty$:

$$E[|C|] = \int_{-\infty}^\infty \frac{|c|}{\pi(1+c^2)} dc = \frac{2}{\pi} \int_0^\infty \frac{c}{1+c^2} dc = \frac{2}{\pi} \cdot \frac{1}{2} \ln(1+c^2) \Big|_0^\infty = +\infty$$

积分发散, 故期望不存在 (注意“主值积分”P.V. $\int_{-\infty}^\infty \frac{c}{\pi(1+c^2)} dc = 0$ 是人为对称截断的结果, 不等价于期望存在)。

(c) 特征函数与稳定性:

柯西分布的特征函数: $\varphi_C(t) = e^{-|t|}$ (标准结论, 推导略——对 $\int_{-\infty}^\infty \frac{e^{itc}}{\pi(1+c^2)} dc$ 用留数定理)。

若 C_1, C_2 i.i.d. 柯西, 则 $(C_1 + C_2)/2$ 的特征函数:

$$\varphi_{(C_1+C_2)/2}(t) = \varphi_{C_1}(t/2)\varphi_{C_2}(t/2) = e^{-|t/2|} \cdot e^{-|t/2|} = e^{-|t|}$$

即 $(C_1 + C_2)/2$ 仍为标准柯西——稳定分布的定义: n 个 i.i.d. 副本的归一化和仍与原分布同族 (此处归一化系数为 n , 而非正态的 $\sqrt{n}$)。

对比正态: $(X_1 + X_2)/\sqrt{2} \sim N(0, 1)$, 归一化系数 $\sqrt{n}$ (对应 $\alpha = 2$ 稳定分布)。

(d) 金融风险建模:

正态假设: $P(|Z| > 5\sigma) = P(|Z| > 5) \approx 5.7 \times 10^{-7}$ (每 170 万天一次)。

柯西假设: $P(|C| > 5) = \frac{2}{\pi} \arctan(1/5) \approx \frac{2}{\pi} \times 0.197 = 0.125$ (约 12.5%, 极为常见!)。

对 25σ 事件: 正态概率约 10^{-135} (宇宙寿命内不可能), 而重尾模型下完全可能——2008 年金融危机中, 量化分析师基于正态假设宣称“ 25σ 事件”, 本质是模型错配 (尾部比正态厚得多)。稳定分布族 ($\alpha < 2$) 是重尾建模的自然选择, 包含正态 ($\alpha = 2$) 和柯西 ($\alpha = 1$) 两端。

答案:

$$f_C(c) = \frac{1}{\pi(1+c^2)}$$

$E[|C|] = +\infty$ (积分发散); 特征函数 $\varphi_C(t) = e^{-|t|}$, $(C_1 + C_2)/2 \sim \text{Cauchy}$ (稳定); 金融中正态假设严重低估极端事件概率。

E.2.4 (Ch.4+Ch.6, 多项分布 + 协方差结构 + Softmax 梯度)

题目: $(X_1, \dots, X_d) \sim \text{Multinomial}(n, \mathbf{p})$, 用 MGF 推导矩, 证明协方差矩阵半正定但奇异, 讨论 Softmax 梯度, 分析 LDA 的两层共轭结构。

思路: 多项 MGF $M(\mathbf{t}) = (\sum_i p_i e^{t_i})^n$, 对各坐标求偏导得矩; $\Sigma = n(\text{diag}(\mathbf{p}) - \mathbf{p}\mathbf{p}^\top)$ 的半正定性用 Jensen; 奇异性由约束 $\sum X_i = n$ 导出。

解:

(a) 利用 MGF 推导矩:

$$M(\mathbf{t}) = \left(\sum_{i=1}^d p_i e^{t_i} \right)^n$$

$$E[X_i] = \frac{\partial}{\partial t_i} \ln M(\mathbf{t}) \Big|_{\mathbf{t}=\mathbf{0}} = n \cdot \frac{p_i e^{t_i}}{\sum_j p_j e^{t_j}} \Big|_{\mathbf{t}=\mathbf{0}} = np_i$$

$$E[X_i^2] = \frac{\partial^2}{\partial t_i^2} \ln M(\mathbf{t}) \Big|_{\mathbf{t}=\mathbf{0}} + (E[X_i])^2$$

实际操作: 从 $\partial^2 M / \partial t_i^2|_0$ 回推, 或利用 $X_i \sim B(n, p_i)$ (边际为二项) 得 $\text{Var}(X_i) = np_i(1 - p_i)$ 。

对 $i \neq j$, 计算 $\partial^2 M / \partial t_i \partial t_j|_0$:

$$E[X_i X_j] = \frac{\partial^2 M}{\partial t_i \partial t_j} \Big|_0 = n(n-1)p_i p_j$$

$$\text{Cov}(X_i, X_j) = n(n-1)p_i p_j - np_i \cdot np_j = -np_i p_j \quad (i \neq j)$$

(b) 协方差矩阵 $\Sigma = n(\text{diag}(\mathbf{p}) - \mathbf{p}\mathbf{p}^\top)$ 的半正定性:

对任意向量 $\mathbf{v}$:

$$\mathbf{v}^\top \Sigma \mathbf{v} = n \left[\sum_i p_i v_i^2 - \left(\sum_i p_i v_i \right)^2 \right] = n [E_p[v(X)^2] - (E_p[v(X)])^2] = n \text{Var}_p[v(X)] \geq 0$$

(其中 X 为分布 $\mathbf{p}$ 下的随机变量, 方差非负, 等号当 v 为常数向量时成立。) $\square$

(c) 奇异性 (秩 $d-1$):

$\sum_i X_i = n$ 是恒等约束, 故 $\Sigma \mathbf{1} = n(\mathbf{p} - \mathbf{p}(\mathbf{1}^\top \mathbf{p})) = n(\mathbf{p} - \mathbf{p}) = \mathbf{0}$, 即 $\mathbf{1}$ 是零特征向量。

在神经网络 softmax 输出中, logit $\mathbf{z}$ 加常数向量不改变 softmax 输出 (平移不变性), 体现了这一冗余度。实践中: 固定参照类别 logit 为 0, 或利用交叉熵梯度 $\partial \mathcal{L} / \partial z_i = \hat{p}_i - y_i$ (输出概率减真实标签, 此梯度自然满足 $\sum_i (\hat{p}_i - y_i) = 0$, 在奇异方向上梯度为零)。

(d) LDA 两层共轭结构:

先验: $\mathbf{p} \sim \text{Dir}(\alpha)$, 观测多项 $\mathbf{n} \sim \text{Multinomial}(N, \mathbf{p})$, 后验 $\mathbf{p}|\mathbf{n} \sim \text{Dir}(\alpha + \mathbf{n})$, MAP 估计:

$$\hat{p}_i^{\text{MAP}} = \frac{\alpha_i + n_i}{\alpha_0 + N}$$

(Laplace 平滑, α_i 起伪计数作用)

LDA 两层: (1) 文档主题分布 $\theta_d \sim \text{Dir}(\alpha)$; (2) 主题词分布 $\phi_k \sim \text{Dir}(\beta)$ 。 α 小 ($\ll 1$) 时, Dirichlet 集中于单纯形顶点 (稀疏: 文档只有少数主题); α 大时, 分布趋于均匀 (每篇文档覆盖所有主题)。

答案:

$$E[X_i] = np_i, \text{Var}(X_i) = np_i(1 - p_i), \text{Cov}(X_i, X_j) = \boxed{-np_i p_j} \quad (i \neq j);$$

$\Sigma \succeq 0$ (方差非负证明); Σ 奇异 ($\Sigma \mathbf{1} = \mathbf{0}$, 秩 $d-1$); MAP 估计 $\hat{p}_i = (\alpha_i + n_i) / (\alpha_0 + N)$

E.2.5 (Ch.5+Ch.6, 次序统计量 + 极值理论 + Max-Pooling)

题目: $X_1, \dots, X_n$ i.i.d. $\sim F$, 推导第 k 次序统计量密度, 联系 Beta 分布, 证明 $\text{Exp}(1)$ 最大值趋 Gumbel 分布, 分析 max-pooling 梯度稀疏性。

思路: 第 k 次序统计量密度由组合计数推导; EVT 中 $M_n - \ln n$ 的 CDF 取极限; max-pooling 梯度为指示函数, 稀疏度 $(n-1)/n$ 。

解:

(a) 第 k 次序统计量密度:

$$f_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1-F(x)]^{n-k} f(x)$$

组合解释: 在 n 个值中, 第 k 小值等于 x 需要:

- 选出 $k-1$ 个值严格小于 x : $\binom{n-1}{k-1}$ 种方式, 每个概率 $F(x)$ (总概率 $[F(x)]^{k-1}$)
- 选出 $n-k$ 个值严格大于 x : 概率 $[1-F(x)]^{n-k}$
- 第 k 个值取 x 的密度贡献: $f(x)dx$
- 全排列修正: $n!/(k-1)!(n-k)!$ (固定一个位置取 x , 剩余按大小归类)

(b) $U(0,1)$ 情形与 Beta 分布的联系:

对 $X_i \sim U(0,1)$, $F(x) = x$, $f(x) = 1$ ($0 < x < 1$):

$$f_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!} x^{k-1} (1-x)^{n-k}$$

Beta 函数 $B(k, n-k+1) = \frac{(k-1)!(n-k)!}{n!}$, 故:

$$f_{(k)}(x) = \frac{1}{B(k, n-k+1)} x^{k-1} (1-x)^{n-k} = f_{\text{Beta}(k, n-k+1)}(x)$$

即 $X_{(k)} \sim \text{Beta}(k, n-k+1)$ 。□

(c) $\text{Exp}(1)$ 最大值趋 Gumbel 分布:

$F(x) = 1 - e^{-x}$ ($x \geq 0$), 令 $M_n = X_{(n)}$:

$$P(M_n - \ln n \leq t) = P(M_n \leq \ln n + t) = [F(\ln n + t)]^n$$

$$= (1 - e^{-(\ln n + t)})^n = \left(1 - \frac{e^{-t}}{n}\right)^n \xrightarrow{n \rightarrow \infty} e^{-e^{-t}}$$

(利用 $\lim_{n \rightarrow \infty} (1 - a/n)^n = e^{-a}$, $a = e^{-t}$ 。)

$e^{-e^{-t}}$ 正是标准 Gumbel 分布的 CDF, 故 $M_n - \ln n \xrightarrow{d} \text{Gumbel}(0, 1)$ 。

Fisher-Tippett-Gnedenko 定理: 吸引域 (Domain of Attraction) 决定极值极限类型——指数分布属于 Gumbel 吸引域。

(d) Max-pooling 梯度分析:

对窗口内 n 个激活值 $a_1, \dots, a_n$ i.i.d. $\sim F$, 最大值 $a_{(n)}$ 的梯度 (反向传播时) 为 1, 其余 $n-1$ 个梯度为 0。

“梯度为零”的神经元比例期望: $(n-1)/n$ (对任意连续 F , 唯一最大值概率为 1)。

L 层 max-pooling 后: 梯度信号在每层以 $1/n$ 的概率存活 (只有最大值路径传递), 经 L 层后期望存活概率约 $(1/n)^L$ ——梯度信号指数衰减 (稀疏梯度问题), 这是深层 max-pooling 网络中梯度消失的极值理论解释。实践上用 Global Average Pooling 替代 Global Max Pooling 可缓解梯度稀疏。

答案:

$$f_{(k)}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1-F(x)]^{n-k} f(x)$$

$X_{(k)} \sim \text{Beta}(k, n-k+1)$ ($U(0, 1)$ 情形); $M_n - \ln n \xrightarrow{d} \text{Gumbel}(0, 1)$; 梯度为零神经元比例期望 $(n-1)/n$

E.2.6 (Ch.5+Ch.6, 变量变换 + Jacobian + 正规化流)

题目: 二维正态 $\mathbf{X} \sim N(\mathbf{0}, \Sigma)$ (相关系数 ρ), 推导条件分布, 用 Jacobian 推导线性变换后的分布, 写出正规化流密度公式, 分析 RealNVP 仿射耦合层。

思路: 配方法推导条件正态; Jacobian 行列式给出密度变换公式; RealNVP 的三角 Jacobian 结构使行列式计算为 $O(d)$ 。

解:

(a) 联合密度与条件分布:

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{2\pi\sqrt{1-\rho^2}} \exp\left(-\frac{x_1^2 - 2\rho x_1 x_2 + x_2^2}{2(1-\rho^2)}\right)$$

配方 (固定 x_1 , 视 x_2 为变量):

$$x_1^2 - 2\rho x_1 x_2 + x_2^2 = (x_2 - \rho x_1)^2 + x_1^2(1-\rho^2)$$

$$f_{X_2|X_1}(x_2|x_1) \propto \exp\left(-\frac{(x_2 - \rho x_1)^2}{2(1-\rho^2)}\right)$$

即 $X_2|X_1 = x_1 \sim N(\rho x_1, 1 - \rho^2)$ 。

线性回归解释: $E[X_2|X_1 = x_1] = \rho x_1$, 回归系数为相关系数 ρ ; 条件方差 $1 - \rho^2$ 为决定系数 $R^2 = \rho^2$ 的补。

(b) 线性变换 $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$:

Jacobian 变换公式: $f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b})) \cdot |\det \mathbf{A}|^{-1}$ 。

代入正态密度:

$$\begin{aligned} f_{\mathbf{Y}}(\mathbf{y}) &\propto \exp\left(-\frac{1}{2}(\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}))^{\top} \Sigma^{-1}(\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}))\right) \\ &= \exp\left(-\frac{1}{2}(\mathbf{y} - \mathbf{b})^{\top} (\mathbf{A} \Sigma \mathbf{A}^{\top})^{-1}(\mathbf{y} - \mathbf{b})\right) \end{aligned}$$

故 $\mathbf{Y} \sim N(\mathbf{b}, \mathbf{A} \Sigma \mathbf{A}^{\top})$ 。□ (正态分布在仿射变换下封闭。)

(c) 正规化流密度公式:

基分布 $\mathbf{Z} \sim N(\mathbf{0}, \mathbf{I}_d)$, 可逆变换 $\mathbf{x} = g(\mathbf{z})$:

$$\log p_X(\mathbf{x}) = \log p_Z(g^{-1}(\mathbf{x})) + \log |\det J_{g^{-1}}(\mathbf{x})| = \log p_Z(g^{-1}(\mathbf{x})) - \log |\det J_g(g^{-1}(\mathbf{x}))|$$

训练: 最大化 $\sum_i \log p_X(\mathbf{x}_i)$, 等价于最小化 KL 散度 $D_{\text{KL}}(p_{\text{data}} \| p_X)$ 。

(d) RealNVP 仿射耦合层:

变换: $\mathbf{x}_1 = \mathbf{z}_1$, $\mathbf{x}_2 = \mathbf{z}_2 \odot \exp(s(\mathbf{z}_1)) + t(\mathbf{z}_1)$ (s, t 为任意神经网络)。

可逆性: 给定 $\mathbf{x}$, $\mathbf{z}_1 = \mathbf{x}_1$, $\mathbf{z}_2 = (\mathbf{x}_2 - t(\mathbf{x}_1)) \odot \exp(-s(\mathbf{x}_1))$ 。□

Jacobian 结构:

$$J_g = \frac{\partial(\mathbf{x}_1, \mathbf{x}_2)}{\partial(\mathbf{z}_1, \mathbf{z}_2)} = \begin{pmatrix} \mathbf{I} & \mathbf{0} \\ \frac{\partial \mathbf{x}_2}{\partial \mathbf{z}_1} & \text{diag}(\exp(s(\mathbf{z}_1))) \end{pmatrix}$$

下三角块矩阵, 行列式为对角块之积:

$$\det J_g = \det(\mathbf{I}) \cdot \prod_i \exp(s_i(\mathbf{z}_1)) = \exp\left(\sum_i s_i(\mathbf{z}_1)\right)$$

计算仅需 $O(d)$ 时间 (对角元之积), 无需求完整矩阵的行列式。且神经网络 s, t 本身无需可逆 (只需前向/后向传播)。

答案:

$$X_2|X_1 = x_1 \sim N(\rho x_1, 1 - \rho^2); \mathbf{Y} \sim N(\mathbf{b}, \mathbf{A} \Sigma \mathbf{A}^{\top});$$

$$\log p_X(\mathbf{x}) = \log p_Z(g^{-1}(\mathbf{x})) - \log |\det J_g(g^{-1}(\mathbf{x}))|$$

$$\text{RealNVP: } \det J_g = \exp\left(\sum_i s_i(\mathbf{z}_1)\right), \quad O(d) \text{ 计算}$$

E.2.7 (Ch.4+Ch.5, MGF + Chernoff 界 + 鞍点近似)

题目: 证明独立时 MGF 可乘, 推导 Chernoff 界及 KL 散度形式, 证明 CGF 严格凸, 解释鞍点方程的几何含义及与 Laplace 近似的联系。

思路: Chernoff 界: Markov 不等式用于 e^{tX} , 对 t 最小化; KL 散度形式对 Bernoulli 显式计算; CGF 凸性由 $K''(t) = \text{Var}(X_t) > 0$ 证明。

解:

(a) MGF 可乘性:

若 $X_1, \dots, X_n$ 独立:

$$M_{S_n}(t) = E[e^{tS_n}] = E\left[\prod_{i=1}^n e^{tX_i}\right] = \prod_{i=1}^n E[e^{tX_i}] = [M_X(t)]^n$$

(独立性 $\Rightarrow$ 期望可分解为乘积)

CGF (累积量生成函数) $K(t) = \ln M(t)$: $K_{S_n}(t) = \ln M_{S_n}(t) = n \ln M_X(t) = nK_X(t)$, 具有线性性 (累积量可加)。

(b) Chernoff 界推导:

对任意 $t > 0$, 由 Markov 不等式:

$$P(S_n \geq na) = P(e^{tS_n} \geq e^{tna}) \leq \frac{E[e^{tS_n}]}{e^{tna}} = e^{n[K_X(t) - ta]}$$

对 t 最小化: $\inf_{t>0} e^{n[K_X(t) - ta]} = e^{-nI(a)}$, 其中:

$$I(a) = \sup_{t>0} [ta - K_X(t)]$$

(Legendre 变换 / 大偏差率函数)

Bernoulli 情形: $X \sim \text{Bernoulli}(p)$, $M_X(t) = 1 - p + pe^t$, $K_X(t) = \ln(1 - p + pe^t)$ 。

鞍点条件 $K'_X(t) = a$: $\frac{pe^t}{1-p+pe^t} = a$, 解得 $e^t = \frac{a(1-p)}{p(1-a)}$, 代入:

$$I(a) = ta^* - K_X(t^*) = a \ln \frac{a}{p} + (1-a) \ln \frac{1-a}{1-p} = D_{\text{KL}}(\text{Ber}(a) \parallel \text{Ber}(p))$$

即率函数为 KL 散度 (Sanov 定理的特例)。

(c) CGF 严格凸性:

$$K'(t) = \frac{M'(t)}{M(t)} = E_{X_t}[X]$$

其中 X_t 服从倾斜 (tilted) 分布 $p_t(x) \propto e^{tx} f(x)$ (指数族)。

$$K''(t) = \frac{d}{dt} E_{X_t}[X] = E_{X_t}[X^2] - (E_{X_t}[X])^2 = \text{Var}_{X_t}(X) > 0$$

(方差对非退化分布严格正), 故 $K(t)$ 严格凸, Legendre 变换有唯一最小值点 (鞍点)。

(d) 鞍点方程的几何含义:

$K'(\hat{t}) = a$ 即“倾斜参数为 $\hat{t}$ 时, 倾斜分布 $X_{\hat{t}}$ 的均值恰等于目标值 a ”——鞍点参数 $\hat{t}$ 将分布向右 ($\hat{t} > 0$) 偏移使均值从 $\mu < a$ 移至 a 。

Lugannani-Rice 公式在 CLT 基础上高一阶精度 (Berry-Esseen 级), 适用于极端尾部的精确估计。

Laplace 近似联系: 贝叶斯后验 $\log p(\theta|\mathbf{x})$ 在 MAP 估计 $\hat{\theta}$ 处做二阶 Taylor 展开:

$$\log p(\theta|\mathbf{x}) \approx \log p(\hat{\theta}|\mathbf{x}) - \frac{1}{2}(\theta - \hat{\theta})^\top \mathcal{J}(\hat{\theta})(\theta - \hat{\theta})$$

这等价于鞍点近似 (在对数坐标下): MAP 点即鞍点, Fisher 信息矩阵 $\mathcal{J}$ 对应 CGF 的 Hessian (二阶导数, 即方差)。

答案:

Chernoff 界: $P(S_n \geq na) \leq e^{-nI(a)}$, 其中 $I(a) = \sup_t [ta - K_X(t)]$;

Bernoulli: $I(a) = \boxed{a \ln \frac{a}{p} + (1-a) \ln \frac{1-a}{1-p}}$ (KL 散度);

$K''(t) = \text{Var}_{X_t}(X) > 0$ (严格凸); 鞍点 $\hat{t}$: 使倾斜分布均值等于 a 。

E.2.8 (Ch.4+Ch.5+Ch.6, 复合泊松分布 + 塔性质 + 贝尔曼方程)

题目: $N \sim \text{Poisson}(\lambda)$, 给定 N , $X = \sum_{i=1}^N Y_i$ (Y_i i.i.d., 均值 μ , 方差 σ^2)。用塔性质求 $E[X]$ 和 $\text{Var}(X)$, 用 PGF 证明 Poisson 稀疏化, 推导贝尔曼方程。

思路: 全期望公式先条件于 N ; 全方差公式 $\text{Var}(X) = E[\text{Var}(X|N)] + \text{Var}(E[X|N])$; PGF 组合 $G_X(s) = G_N(G_Y(s))$; 贝尔曼方程同样是塔性质的应用。

解:

(a) 用塔性质计算 $E[X]$ 和 $E[X^2]$:

给定 $N = n$: $X = \sum_{i=1}^n Y_i$, $E[X|N = n] = n\mu$, 即 $E[X|N] = N\mu$ 。

$$E[X] = E[E[X|N]] = E[N\mu] = \mu E[N] = \lambda\mu$$

对 $E[X^2]$: 给定 $N = n$, X 为 n 个 i.i.d. Y_i 的和,

$$E[X^2|N = n] = \text{Var}(X|N = n) + (E[X|N = n])^2 = n\sigma^2 + n^2\mu^2$$

$$E[X^2] = E[N\sigma^2 + N^2\mu^2] = \sigma^2 E[N] + \mu^2 E[N^2]$$

泊松分布: $E[N] = \lambda$, $E[N^2] = \text{Var}(N) + (E[N])^2 = \lambda + \lambda^2$ 。

$$E[X^2] = \lambda\sigma^2 + \mu^2(\lambda + \lambda^2) = \lambda(\sigma^2 + \mu^2) + \lambda^2\mu^2$$

(b) 全方差公式求 $\text{Var}(X)$:

$$E[\text{Var}(X|N)] = E[N\sigma^2] = \lambda\sigma^2$$

$$\text{Var}(E[X|N]) = \text{Var}(N\mu) = \mu^2 \text{Var}(N) = \mu^2 \lambda$$

$$\text{Var}(X) = \lambda\sigma^2 + \lambda\mu^2 = \lambda(\sigma^2 + \mu^2)$$

特例验证: 若 $Y_i \equiv 1$ ($\mu = 1, \sigma^2 = 0$), $X = N \sim \text{Poisson}(\lambda)$, $\text{Var}(X) = \lambda(0 + 1) = \lambda$ $\square$ 。

(c) Poisson 稀疏化 ($Y_i \sim \text{Bernoulli}(p)$):

PGF 组合: $G_X(s) = G_N(G_Y(s))$ 。

$G_Y(s) = E[s^Y] = (1-p) + ps = 1 - p(1-s)$ (Bernoulli PGF)。

$G_N(s) = e^{\lambda(s-1)}$ (Poisson PGF)。

$$G_X(s) = G_N(G_Y(s)) = e^{\lambda(G_Y(s)-1)} = e^{\lambda((1-p(1-s))-1)} = e^{\lambda p(s-1)}$$

这正是 $\text{Poisson}(\lambda p)$ 的 PGF, 故 $X \sim \text{Poisson}(\lambda p)$ 。

直觉: Poisson 事件以概率 p 独立标记, 标记后的计数仍为 Poisson, 参数为 λp (稀疏化定理)。

(d) 贝尔曼方程的推导:

$$V^\pi(s) = E^\pi \left[\sum_{t=0}^{\infty} \gamma^t R_t \mid S_0 = s \right]$$

对第一步动作和下一状态取全期望 (塔性质):

$$V^\pi(s) = E_{a \sim \pi(\cdot|s)} \left[E_{s' \sim P(\cdot|s,a)} \left[R(s, a) + \gamma \sum_{t=0}^{\infty} \gamma^t R'_{t+1} \mid S_1 = s' \right] \right]$$

由马尔可夫性, 后续奖励的期望恰为 $V^\pi(s')$:

$$= E_{a \sim \pi(\cdot|s)} \left[R(s, a) + \gamma E_{s' \sim P(\cdot|s,a)} [V^\pi(s')] \right]$$

这与 (a)(b) 的结构完全一致: $V^\pi(s) = E[R + \gamma V^\pi(S')]$ 正是塔性质 $E[X] = E[E[X|\text{first step}]]$ 的应用——条件于第一步动作和转移, 递归展开。

□ 易错点: 贝尔曼方程成立的关键是马尔可夫性 ($V^\pi(s')$ 只依赖 s' , 不依赖历史), 使得塔性质中内层期望可简化为 $V^\pi(s')$ 。

答案:

$$E[X] = \boxed{\lambda\mu}; \text{Var}(X) = \boxed{\lambda(\sigma^2 + \mu^2)} \quad (\text{全方差公式});$$

Poisson 稀疏化: $X \sim \text{Poisson}(\lambda p)$ (PGF 组合证明);

贝尔曼方程: $V^\pi(s) = E_a[R(s, a) + \gamma E_{s'}[V^\pi(s')]]$ (塔性质递推)

(本文件共 35 题, C.2.1–C.2.12 $\times$ 12 题, D.2.1–D.2.15 $\times$ 15 题, E.2.1–E.2.8 $\times$ 8 题)

F3 详解: Part 3 常见分布 (Ch.7-9, 共 35 题)

C 基础题详解 (12 题)

C.3.1 (Ch.7, 伯努利分布)

题目: $p = 0.8$ 的单次射击, $X \sim \text{Bernoulli}(0.8)$, 求 PMF、 $E[X]$ 、 $\text{Var}(X)$ 。

思路: 伯努利分布是最简单的离散分布, 直接套公式。

解:

1. PMF:

$$P(X = k) = \begin{cases} 0.2 & k = 0 \\ 0.8 & k = 1 \end{cases} \quad \text{即 } P(X = k) = p^k(1-p)^{1-k}, k \in \{0, 1\}$$

2. 期望与方差:

$$E[X] = 0 \cdot (1-p) + 1 \cdot p = p = 0.8$$

$$\text{Var}(X) = E[X^2] - (E[X])^2 = p - p^2 = p(1-p) = 0.8 \times 0.2 = 0.16$$

答案: $E[X] = 0.8, \quad \text{Var}(X) = 0.16$

C.3.2 (Ch.7, 二项分布)

题目: 均匀硬币抛 8 次, $X \sim B(8, 0.5)$, 求 PMF、 $P(X = 4)$ 、 $E[X]$ 、 $\text{Var}(X)$ 。

思路: 二项分布 $B(n, p)$ 的 PMF 为组合数乘以概率, 直接代入。

解:

1. PMF:

$$P(X = k) = \binom{8}{k} \left(\frac{1}{2}\right)^k \left(\frac{1}{2}\right)^{8-k} = \binom{8}{k} \frac{1}{256}, \quad k = 0, 1, \dots, 8$$

2. $P(X = 4)$:

$$P(X = 4) = \binom{8}{4} \frac{1}{256} = \frac{70}{256} = \frac{35}{128} \approx 0.2734$$

3. 期望与方差:

$$E[X] = np = 8 \times 0.5 = 4$$

$$\text{Var}(X) = np(1-p) = 8 \times 0.5 \times 0.5 = 2$$

答案: $P(X = 4) = \frac{35}{128}, \quad E[X] = 4, \quad \text{Var}(X) = 2$

C.3.3 (Ch.7, 泊松分布)

题目: $\lambda = 3$ 的泊松呼叫流, 求 PMF、 $P(X = 0)$ 、 $E[X]$ 、 $\text{Var}(X)$ 。

思路: 泊松分布 $\text{Poisson}(\lambda)$ 的均值方差均为 λ 。

解:

1. **PMF**:

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!} = \frac{e^{-3} \cdot 3^k}{k!}, \quad k = 0, 1, 2, \dots$$

2. $P(X = 0)$:

$$P(X = 0) = e^{-3} \approx 0.0498$$

3. 期望与方差:

$$E[X] = \lambda = 3, \quad \text{Var}(X) = \lambda = 3$$

答案: $P(X = 0) = e^{-3}, \quad E[X] = \text{Var}(X) = 3$

□ 泊松分布的均值等于方差, 这是其与二项分布的重要区别。

C.3.4 (Ch.7, 几何分布)

题目: 每次成功概率 $p = 0.4$, X 为首次成功所需试验次数, 求 PMF、 $P(X = 3)$ 、 $E[X]$ 。

思路: 几何分布描述“第一次成功前需多少次试验”, 前 $k - 1$ 次失败、第 k 次成功。

解:

1. **PMF** (首次成功型, 支撑 $k = 1, 2, \dots$):

$$P(X = k) = (1 - p)^{k-1} p = (0.6)^{k-1} \times 0.4$$

2. $P(X = 3)$:

$$P(X = 3) = (0.6)^2 \times 0.4 = 0.36 \times 0.4 = 0.144$$

3. 期望:

$$E[X] = \frac{1}{p} = \frac{1}{0.4} = 2.5$$

答案: $P(X=3) = 0.144, \quad E[X] = 2.5$

C.3.5 (Ch.7, 泊松近似二项)

题目: 次品率 $p = 0.01$, 抽取 $n = 200$ 件, 用泊松近似求 λ 及 $P(X=0)$ 。

思路: n 大、 p 小时 $B(n, p) \approx \text{Poisson}(\lambda)$, $\lambda = np$ 。

解:

1. 近似参数:

$$\lambda = np = 200 \times 0.01 = 2$$

2. 泊松近似 $P(X=0)$:

$$P(X=0) \approx e^{-\lambda} = e^{-2} \approx 0.1353$$

(精确值: $(0.99)^{200} \approx 0.1340$, 误差约 0.1%。)

答案: $\lambda = 2, \quad P(X=0) \approx e^{-2} \approx 0.1353$

C.3.6 (Ch.8, 均匀分布)

题目: $X \sim U(2, 8)$, 求 PDF、CDF、 $P(3 \leq X \leq 6)$ 、 $E[X]$ 、 $\text{Var}(X)$ 。

思路: 均匀分布在区间上等概率, 直接用公式 $b - a = 6$ 。

解:

1. PDF 与 CDF:

$$f(x) = \frac{1}{b-a} = \frac{1}{6}, \quad 2 \leq x \leq 8$$

$$F(x) = \begin{cases} 0 & x < 2 \\ \frac{x-2}{6} & 2 \leq x \leq 8 \\ 1 & x > 8 \end{cases}$$

2. $P(3 \leq X \leq 6)$:

$$P(3 \leq X \leq 6) = \frac{6-3}{6} = \frac{3}{6} = \frac{1}{2}$$

3. 期望与方差:

$$E[X] = \frac{a+b}{2} = \frac{2+8}{2} = 5$$

$$\text{Var}(X) = \frac{(b-a)^2}{12} = \frac{36}{12} = 3$$

答案: $P(3 \leq X \leq 6) = \frac{1}{2}, \quad E[X] = 5, \quad \text{Var}(X) = 3$

C.3.7 (Ch.8, 指数分布与无记忆性)

题目: $T \sim \text{Exp}(0.5)$, 求 PDF、CDF、 $P(T > 2)$; 利用无记忆性求 $P(T > 4 \mid T > 2)$ 。

思路: 指数分布的无记忆性: $P(T > s+t \mid T > s) = P(T > t)$, 条件概率等同于重新开始。

解:

1. PDF 与 CDF ($\lambda = 0.5$):

$$f(t) = \lambda e^{-\lambda t} = 0.5 e^{-0.5t}, \quad t > 0$$

$$F(t) = 1 - e^{-\lambda t} = 1 - e^{-0.5t}, \quad t > 0$$

2. $P(T > 2)$:

$$P(T > 2) = e^{-\lambda \cdot 2} = e^{-1} \approx 0.3679$$

3. 无记忆性应用:

$$P(T > 4 | T > 2) = P(T > 2) = e^{-1} \approx 0.3679$$

原因: 已知 $T > 2$, 剩余寿命仍服从同参数指数分布, 再运行 2 小时以上概率仍为 e^{-1} 。

答案: $P(T > 2) = e^{-1} \approx 0.3679, \quad P(T > 4 | T > 2) = e^{-1}$

□ 无记忆性是指数分布 (连续情形) 和几何分布 (离散情形) 独有的性质。

C.3.8 (Ch.8, 正态分布性质)

题目: $X \sim N(5, 9)$ ($\sigma = 3$), 求 $P(2 \leq X \leq 8)$; 若 $Y = 2X + 1$, 求 Y 的分布。

思路: 正态分布标准化后查 Φ 表; 线性变换后仍为正态。

解:

1. $P(2 \leq X \leq 8)$:

标准化: $Z = \frac{X - 5}{3} \sim N(0, 1)$,

$$P(2 \leq X \leq 8) = P\left(\frac{2-5}{3} \leq Z \leq \frac{8-5}{3}\right) = P(-1 \leq Z \leq 1)$$

$$= \Phi(1) - \Phi(-1) = 2\Phi(1) - 1 \approx 2 \times 0.8413 - 1 = 0.6826$$

2. $Y = 2X + 1$ 的分布:

$$E[Y] = 2E[X] + 1 = 2 \times 5 + 1 = 11$$

$$\text{Var}(Y) = 4 \text{Var}(X) = 4 \times 9 = 36$$

$$Y \sim N(11, 36)$$

答案: $P(2 \leq X \leq 8) = 2\Phi(1) - 1 \approx 0.6826, \quad Y \sim N(11, 36)$

C.3.9 (Ch.8, Gamma 分布)

题目: $X \sim \text{Gamma}(3, 2)$ ($\alpha = 3, \beta = 2$, 速率参数化), 求 $E[X]$ 、 $\text{Var}(X)$; 三个 $\text{Exp}(2)$ 之和的分布。

思路: Gamma 分布的可加性: 同速率参数的独立 Gamma 相加, 形状参数叠加。

解:

1. 期望与方差 (速率参数 β):

$$E[X] = \frac{\alpha}{\beta} = \frac{3}{2} = 1.5$$

$$\text{Var}(X) = \frac{\alpha}{\beta^2} = \frac{3}{4} = 0.75$$

2. 三个 $\text{Exp}(2)$ 之和:

$\text{Exp}(2) = \text{Gamma}(1, 2)$, 三个独立相加:

$$X_1 + X_2 + X_3 \sim \text{Gamma}(1 + 1 + 1, 2) = \text{Gamma}(3, 2)$$

答案: $E[X] = 1.5, \text{Var}(X) = 0.75, X_1 + X_2 + X_3 \sim \text{Gamma}(3, 2)$

C.3.10 (Ch.8, 卡方分布的构造)

题目: $Z_1, \dots, Z_5 \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, $W = \sum_{i=1}^5 Z_i^2$, 求分布、期望、方差。

思路: n 个独立标准正态的平方和服从自由度为 n 的卡方分布。

解:

1. W 的分布:

$$W = \sum_{i=1}^5 Z_i^2 \sim \chi^2(5)$$

($\chi^2(n)$ 等价于 $\text{Gamma}(n/2, 1/2)$)

2. 期望与方差:

$$E[W] = n = 5$$

$$\text{Var}(W) = 2n = 10$$

答案: $W \sim \chi^2(5), \quad E[W] = 5, \quad \text{Var}(W) = 10$

C.3.11 (Ch.9, 多项分布)

题目: 均匀六面骰子掷 12 次, X_k 为点数 k 出现次数, 求联合分布参数及 $E[X_1]$ 、 $\text{Var}(X_1)$ 。

思路: 多项分布是二项分布的推广; 每个分量 $X_k \sim B(n, p_k)$ 。

解:

1. 联合分布参数:

$$(X_1, \dots, X_6) \sim \text{Multinomial}\left(12; \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}\right)$$

联合 PMF:

$$P(X_1 = k_1, \dots, X_6 = k_6) = \frac{12!}{k_1! \dots k_6!} \left(\frac{1}{6}\right)^{12}, \quad \sum_{j=1}^6 k_j = 12$$

2. $E[X_1]$ 与 $\text{Var}(X_1)$:

$X_1 \sim B(12, 1/6)$, 故

$$E[X_1] = np_1 = 12 \times \frac{1}{6} = 2$$

$$\text{Var}(X_1) = np_1(1 - p_1) = 12 \times \frac{1}{6} \times \frac{5}{6} = \frac{10}{6} = \frac{5}{3} \approx 1.667$$

答案: $E[X_1] = 2, \quad \text{Var}(X_1) = \frac{5}{3}$

C.3.12 (Ch.9, 多元正态的边缘分布)

题目: $(X, Y) \sim N(0, 1, 4, 9, 0.5)$, 求 X 、 Y 的边缘分布及 $\text{Cov}(X, Y)$ 。

思路: 二维正态的边缘仍为正态; 协方差由相关系数和标准差给出。

解:

1. X 的边缘分布:

$$X \sim N(\mu_X, \sigma_X^2) = N(0, 4)$$

2. Y 的边缘分布:

$$Y \sim N(\mu_Y, \sigma_Y^2) = N(1, 9)$$

3. 协方差:

$$\text{Cov}(X, Y) = \rho \sigma_X \sigma_Y = 0.5 \times 2 \times 3 = 3$$

答案: $X \sim N(0, 4), \quad Y \sim N(1, 9), \quad \text{Cov}(X, Y) = 3$

D 中等题详解 (15 题)

D.3.1 (Ch.7, 泊松分布的可加性)

题目: $X \sim \text{Poisson}(\lambda_1)$, $Y \sim \text{Poisson}(\lambda_2)$, $X \perp Y$ 。证明可加性; 求条件分布 $P(X = k \mid X + Y = n)$ 。

思路: 用概率母函数 (PGF) 证明可加性最简洁; 条件分布通过贝叶斯公式化简为二项分布。

解:

(a) 可加性证明 (矩母函数法):

泊松分布 $\text{Poisson}(\lambda)$ 的 MGF:

$$M_X(t) = E[e^{tX}] = e^{\lambda(e^t - 1)}$$

由独立性:

$$M_{X+Y}(t) = M_X(t) \cdot M_Y(t) = e^{\lambda_1(e^t - 1)} \cdot e^{\lambda_2(e^t - 1)} = e^{(\lambda_1 + \lambda_2)(e^t - 1)}$$

此为 $\text{Poisson}(\lambda_1 + \lambda_2)$ 的 MGF, 故

$$X + Y \sim \text{Poisson}(\lambda_1 + \lambda_2) \quad \square$$

(b) 条件分布 $P(X = k \mid X + Y = n)$:

令 $S = X + Y \sim \text{Poisson}(\lambda_1 + \lambda_2)$,

$$P(X = k | S = n) = \frac{P(X = k, Y = n - k)}{P(S = n)}$$

$$\text{分子: } \frac{e^{-\lambda_1} \lambda_1^k}{k!} \cdot \frac{e^{-\lambda_2} \lambda_2^{n-k}}{(n-k)!}$$

$$\text{分母: } \frac{e^{-(\lambda_1 + \lambda_2)} (\lambda_1 + \lambda_2)^n}{n!}$$

相除:

$$P(X = k | S = n) = \binom{n}{k} \left(\frac{\lambda_1}{\lambda_1 + \lambda_2} \right)^k \left(\frac{\lambda_2}{\lambda_1 + \lambda_2} \right)^{n-k}$$

这正是 $B\left(n, \frac{\lambda_1}{\lambda_1 + \lambda_2}\right)$ 的 PMF。

(c) $\lambda_1 = \lambda_2$ 时:

$$p = \frac{\lambda_1}{\lambda_1 + \lambda_2} = \frac{1}{2}$$

, 条件分布为 $B(n, 1/2)$ 。

答案: $X + Y \sim \text{Poisson}(\lambda_1 + \lambda_2); \quad (X | X + Y = n) \sim B\left(n, \frac{\lambda_1}{\lambda_1 + \lambda_2}\right)$

D.3.2 (Ch.7, 几何分布的矩)

题目: $X \sim \text{Geom}(p)$, 证明 $E[X] = 1/p$, $\text{Var}(X) = (1-p)/p^2$; 证明无记忆性; 证明唯一性。

思路: 用 MGF 求矩; 无记忆性直接计算条件概率; 唯一性用函数方程。

解:

(a) 矩母函数求矩:

令 $q = 1 - p$,

$$M_X(t) = \sum_{k=1}^{\infty} e^{tk} q^{k-1} p = \frac{pe^t}{1 - qe^t}, \quad t < -\ln q$$

$$M'_X(t) = \frac{pe^t}{(1 - qe^t)^2}$$

$$E[X] = M'_X(0) = \frac{p}{(1 - q)^2} = \frac{p}{p^2} = \frac{1}{p}$$

$$M_X''(t) = \frac{pe^t(1+qe^t)}{(1-qe^t)^3}$$

$$E[X^2] = M_X''(0) = \frac{p(1+q)}{p^3} = \frac{1+q}{p^2} = \frac{2-p}{p^2}$$

$$\text{Var}(X) = E[X^2] - (E[X])^2 = \frac{2-p}{p^2} - \frac{1}{p^2} = \frac{1-p}{p^2} = \frac{q}{p^2} \quad \square$$

(b) 无记忆性证明:

$$P(X > m) = \sum_{k=m+1}^{\infty} q^{k-1}p = q^m$$

$$P(X > m+n | X > m) = \frac{P(X > m+n)}{P(X > m)} = \frac{q^{m+n}}{q^m} = q^n = P(X > n) \quad \square$$

(c) 唯一性 (无记忆性 $\Rightarrow$ 几何):

设 X 取正整数值, $P(X > k) = g(k)$, 无记忆性要求 $g(m+n) = g(m)g(n)$ (函数方程)。

由 $g(0) = 1$ 及正整数值, $g(k) = g(1)^k$ 。令 $q = g(1) \in (0, 1)$, 则

$$P(X = k) = P(X > k-1) - P(X > k) = q^{k-1} - q^k = q^{k-1}(1-q)$$

这正是参数 $p = 1 - q$ 的几何分布。 $\square$

答案: $E[X] = \frac{1}{p}, \quad \text{Var}(X) = \frac{1-p}{p^2}$; 几何分布是离散无记忆分布的唯一类型。

D.3.3 (Ch.8, 正态分布线性组合)

题目: $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, $X \perp Y$, 证明线性组合仍为正态; 求 $Z = X - Y$ 的分布; 当 $X, Y \sim N(0, 1)$ 时求 $P(X > Y)$ 。

思路: 用 MGF 证明线性组合的正态性; $P(X > Y) = P(X - Y > 0)$, 利用 $Z \sim N(0, 2)$ 。

解:

(a) 线性组合 $aX + bY + c$:

MGF:

$$M_{aX+bY}(t) = M_X(at) \cdot M_Y(bt) = e^{a\mu_1 t + \frac{1}{2}a^2\sigma_1^2 t^2} \cdot e^{b\mu_2 t + \frac{1}{2}b^2\sigma_2^2 t^2}$$

$$= e^{(a\mu_1+b\mu_2)t+\frac{1}{2}(a^2\sigma_1^2+b^2\sigma_2^2)t^2}$$

这是均值 $a\mu_1 + b\mu_2 + c$ 、方差 $a^2\sigma_1^2 + b^2\sigma_2^2$ 的正态分布 MGF, 故

$$aX + bY + c \sim N(a\mu_1 + b\mu_2 + c, a^2\sigma_1^2 + b^2\sigma_2^2) \quad \square$$

(b) $Z = X - Y$ 的分布 (取 $a = 1, b = -1, c = 0$):

$$Z \sim N(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2)$$

(c) $P(X > Y)$ ($\mu_1 = \mu_2 = 0, \sigma_1^2 = \sigma_2^2 = 1$):

$$Z = X - Y \sim N(0, 2)$$

$$P(X > Y) = P(Z > 0) = P\left(\frac{Z}{\sqrt{2}} > 0\right) = 1 - \Phi(0) = 0.5$$

答案: $Z = X - Y \sim N(\mu_1 - \mu_2, \sigma_1^2 + \sigma_2^2); \quad P(X > Y) = 0.5$

□ 对称性直接给出 $P(X > Y) = 1/2$, 无需查表; 但不对称情形必须标准化。

D.3.4 (Ch.8, 伽马分布的性质)

题目: $X \sim \text{Gamma}(\alpha, \beta)$, 密度 $f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$, 证明矩公式、退化为指数、可加性。

思路: 利用 $\Gamma(\alpha)$ 递推公式 $\Gamma(\alpha + 1) = \alpha\Gamma(\alpha)$ 计算矩; MGF 证明可加性。

解:

(a) $E[X]$ 和 $\text{Var}(X)$:

$$E[X] = \int_0^\infty x \cdot \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} dx = \frac{\beta^\alpha}{\Gamma(\alpha)} \int_0^\infty x^\alpha e^{-\beta x} dx$$

令 $u = \beta x$, 得 $\int_0^\infty x^\alpha e^{-\beta x} dx = \frac{\Gamma(\alpha + 1)}{\beta^{\alpha+1}}$, 故

$$E[X] = \frac{\beta^\alpha}{\Gamma(\alpha)} \cdot \frac{\Gamma(\alpha + 1)}{\beta^{\alpha+1}} = \frac{\alpha\Gamma(\alpha)}{\Gamma(\alpha) \cdot \beta} = \frac{\alpha}{\beta}$$

类似地,

$$E[X^2] = \frac{\beta^\alpha}{\Gamma(\alpha)} \cdot \frac{\Gamma(\alpha+2)}{\beta^{\alpha+2}} = \frac{\alpha(\alpha+1)}{\beta^2}$$

$$\text{Var}(X) = \frac{\alpha(\alpha+1)}{\beta^2} - \frac{\alpha^2}{\beta^2} = \frac{\alpha}{\beta^2} \quad \square$$

(b) $\alpha = 1$ 时退化为指数分布:

$$f(x) = \frac{\beta^1}{\Gamma(1)} x^0 e^{-\beta x} = \beta e^{-\beta x}$$

这正是 $\text{Exp}(\beta)$ 的密度。□

(c) 可加性 (MGF 法):

$\text{Gamma}(\alpha, \beta)$ 的 MGF ($t < \beta$):

$$M_X(t) = \left(\frac{\beta}{\beta - t} \right)^\alpha$$

设 $X_i \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\beta) = \text{Gamma}(1, \beta)$, 则

$$M_{X_1 + \dots + X_n}(t) = \prod_{i=1}^n \left(\frac{\beta}{\beta - t} \right)^1 = \left(\frac{\beta}{\beta - t} \right)^n$$

此为 $\text{Gamma}(n, \beta)$ 的 MGF, 故 $X_1 + \dots + X_n \sim \text{Gamma}(n, \beta)$ 。□

答案: $E[X] = \frac{\alpha}{\beta}, \quad \text{Var}(X) = \frac{\alpha}{\beta^2}; \quad \sum_{i=1}^n X_i \sim \text{Gamma}(n, \beta)$

D.3.5 (Ch.7, 超几何分布与二项近似)

题目: $N = 100$, $K = 20$ 红球, 无放回取 $n = 10$, 求超几何 PMF、 $E[X]$ 、 $\text{Var}(X)$; 与二项近似比较。

思路: 超几何分布用组合数公式; 当 n/N 小时二项近似良好 (有限总体修正因子接近 1)。

解:

(a) 超几何 PMF:

$$P(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}} = \frac{\binom{20}{k} \binom{80}{10-k}}{\binom{100}{10}}, \quad k = 0, 1, \dots, 10$$

(b) $E[X]$ 与 $\text{Var}(X)$:

$$E[X] = n \cdot \frac{K}{N} = 10 \times \frac{20}{100} = 2$$

$$\text{Var}(X) = n \cdot \frac{K}{N} \cdot \frac{N-K}{N} \cdot \frac{N-n}{N-1} = 10 \times 0.2 \times 0.8 \times \frac{90}{99} = \frac{144}{99} \approx 1.455$$

有限总体修正因子 (FPC): $\frac{N-n}{N-1} = \frac{90}{99} \approx 0.909$ 。

(c) 二项近似 $B(10, 0.2)$, $k = 2$:

精确值 (超几何):

$$P(X = 2) = \frac{\binom{20}{2} \binom{80}{8}}{\binom{100}{10}} = \frac{190 \times \binom{80}{8}}{\binom{100}{10}}$$

(数值约为 0.3182)

近似值 (二项):

$$P(X = 2) = \binom{10}{2} (0.2)^2 (0.8)^8 = 45 \times 0.04 \times 0.1678 \approx 0.3020$$

误差约 $\frac{0.3182 - 0.3020}{0.3182} \approx 5\%$, 因 $n/N = 10\%$ 较小, 近似合理。

答案: $E[X] = 2, \text{Var}(X) \approx 1.455$; 二项近似误差约 5%。

D.3.6 (Ch.8, 卡方分布与正态的联系)

题目: $Z_1, \dots, Z_n \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, $V = \sum Z_i^2$, 用 MGF 证明 $V \sim \chi^2(n)$; 求均值方差; 陈述 $\bar{Z}$ 与 $\sum (Z_i - \bar{Z})^2$ 的独立性。

思路: $\chi^2(n) = \text{Gamma}(n/2, 1/2)$; 独立性来自 Cochran 定理。

解:

(a) MGF 证明 $V \sim \chi^2(n)$:

单个 Z^2 的 MGF ($t < 1/2$):

$$M_{Z^2}(t) = E[e^{tZ^2}] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{tz^2} e^{-z^2/2} dz = \frac{1}{\sqrt{2\pi}} \int e^{-\frac{1-2t}{2}z^2} dz = (1-2t)^{-1/2}$$

由独立性:

$$M_V(t) = \prod_{i=1}^n M_{Z_i^2}(t) = (1 - 2t)^{-n/2}$$

这正是 $\text{Gamma}(n/2, 1/2)$ 的 MGF, 即 $\chi^2(n)$ 。□

(b) 期望与方差:

$\chi^2(n) = \text{Gamma}(n/2, 1/2)$, 故

$$E[V] = \frac{n/2}{1/2} = n, \quad \text{Var}(V) = \frac{n/2}{(1/2)^2} = 2n$$

(c) $\bar{Z}$ 与 $V' = \sum (Z_i - \bar{Z})^2$ 的独立性:

依据 **Cochran** 定理: 设 $Z_1, \dots, Z_n \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, $\bar{Z}$ 是样本均值, 则 $\bar{Z} \sim N(0, 1/n)$ 与 $V' = \sum (Z_i - \bar{Z})^2 \sim \chi^2(n-1)$ 相互独立。

直觉: $\bar{Z}$ 是 n 维向量 $(Z_1, \dots, Z_n)$ 在方向 $(1/\sqrt{n}, \dots, 1/\sqrt{n})$ 上的投影, V' 依赖正交补空间, 正态分布保证两者独立。

答案: $V \sim \chi^2(n), \quad E[V] = n, \quad \text{Var}(V) = 2n$; $\bar{Z} \perp \sum (Z_i - \bar{Z})^2$ 由 Cochran 定理保证。

D.3.7 (Ch.9, 二维正态分布)

题目: $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 推导边际分布; 证明 $\rho = 0 \Leftrightarrow X \perp Y$; 写出条件分布公式。

思路: 边际化通过对联合密度积分消去一维; 正态情形不相关等价独立 (特殊性质)。

解:

(a) 边际分布 $X \sim N(\mu_1, \sigma_1^2)$:

二维正态联合密度 (设 $\rho \in (-1, 1)$):

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left(-\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right]\right)$$

配方: 将指数中 y 的部分写为

$$-\frac{1}{2\sigma_2^2(1-\rho^2)} \left(y - \mu_2 - \rho \frac{\sigma_2}{\sigma_1} (x - \mu_1) \right)^2 - \frac{(x - \mu_1)^2}{2\sigma_1^2}$$

对 y 积分 (高斯积分), 结果为

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left(-\frac{(x-\mu_1)^2}{2\sigma_1^2}\right)$$

即 $X \sim N(\mu_1, \sigma_1^2)$ 。□

(b) $\rho = 0 \Leftrightarrow X \perp Y$:

• 若 $\rho = 0$, 联合密度分解为

$$f(x, y) = \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}} \cdot \frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{(y-\mu_2)^2}{2\sigma_2^2}} = f_X(x) \cdot f_Y(y)$$

联合密度可分离, 故 $X \perp Y$ 。

• 若 $X \perp Y$, 则 $\text{Cov}(X, Y) = 0$, 从而 $\rho = 0$ 。□

□ 仅对正态分布, 不相关 $\Rightarrow$ 独立。一般分布此结论不成立。

(c) 条件分布 $Y | X = x$:

$$Y | X = x \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1), \sigma_2^2(1 - \rho^2)\right)$$

条件均值为 x 的线性函数, 条件方差 $\sigma_2^2(1 - \rho^2)$ 与 x 无关。

答案:
$$Y | X = x \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1), \sigma_2^2(1 - \rho^2)\right)$$

D.3.8 (Ch.8, 对数正态分布)

题目: $Y = e^X$, $X \sim N(\mu, \sigma^2)$, 求 Y 的密度; 利用正态 MGF 求 $E[Y]$ 、 $\text{Var}(Y)$; 证明 $\ln Y \sim N(\mu, \sigma^2)$ 。

思路: 变量变换法求密度; $E[e^{tX}]$ 即正态 MGF, 令 $t = 1$ 得 $E[Y]$ 。

解:

(a) 对数正态密度:

$X = \ln Y$, 由变量变换:

$$f_Y(y) = f_X(\ln y) \cdot \frac{1}{y} = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(\ln y - \mu)^2}{2\sigma^2}\right) \cdot \frac{1}{y}, \quad y > 0$$

(b) $E[Y]$ 与 $\text{Var}(Y)$:

利用正态 MGF $M_X(t) = e^{\mu t + \sigma^2 t^2 / 2}$:

$$E[Y] = E[e^X] = M_X(1) = e^{\mu+\sigma^2/2}$$

$$E[Y^2] = E[e^{2X}] = M_X(2) = e^{2\mu+2\sigma^2}$$

$$\text{Var}(Y) = e^{2\mu+2\sigma^2} - e^{2\mu+\sigma^2} = e^{2\mu+\sigma^2}(e^{\sigma^2} - 1)$$

(c) $\ln Y \sim N(\mu, \sigma^2)$:

由定义 $Y = e^X$, $X \sim N(\mu, \sigma^2)$, 取对数 $\ln Y = X \sim N(\mu, \sigma^2)$ 。□

答案: $E[Y] = e^{\mu+\sigma^2/2}$, $\text{Var}(Y) = e^{2\mu+\sigma^2}(e^{\sigma^2} - 1)$

D.3.9 (Ch.7, 二项分布的泊松极限)

题目: $X_n \sim B(n, p_n)$, $np_n \rightarrow \lambda$, 证明 $P(X_n = k) \rightarrow \frac{\lambda^k e^{-\lambda}}{k!}$; 讨论近似条件; 数值对比。

思路: 直接对二项 PMF 取极限, 逐步分析各因子。

解:

(a) 极限证明:

固定 k , 令 $\lambda_n = np_n \rightarrow \lambda$, $p_n = \lambda_n/n$,

$$P(X_n = k) = \binom{n}{k} p_n^k (1 - p_n)^{n-k} = \frac{n(n-1)\cdots(n-k+1)}{k!} \cdot \frac{\lambda_n^k}{n^k} \cdot \left(1 - \frac{\lambda_n}{n}\right)^{n-k}$$

分析三个因子:

$$\begin{aligned} & \bullet \frac{n(n-1)\cdots(n-k+1)}{n^k} = \prod_{j=0}^{k-1} \left(1 - \frac{j}{n}\right) \rightarrow 1 \\ & \bullet \lambda_n^k \rightarrow \lambda^k \\ & \bullet \left(1 - \frac{\lambda_n}{n}\right)^{n-k} \rightarrow e^{-\lambda} \text{ (经典极限)} \end{aligned}$$

故

$$P(X_n = k) \rightarrow \frac{\lambda^k}{k!} \cdot e^{-\lambda} \quad \square$$

(b) 近似有效条件:

n 大 ($n \geq 20$)、 p 小 ($p \leq 0.05$), $\lambda = np$ 适中 ($\lambda \leq 5$) 时近似效果好。

(c) $n = 100$, $p = 0.02$, $k = 0$:

$$\lambda = 100 \times 0.02 = 2$$

泊松近似: $P(X = 0) \approx e^{-2} \approx 0.1353$

精确值: $P(X = 0) = (0.98)^{100}$

$$\ln(0.98^{100}) = 100 \ln 0.98 \approx 100 \times (-0.0202) = -2.020$$

精确值 $\approx e^{-2.020} \approx 0.1326$

误差约 $\frac{0.1353 - 0.1326}{0.1353} \approx 2\%$, 近似良好。

答案: $P(X_n = k) \rightarrow \frac{\lambda^k e^{-\lambda}}{k!}$; 数值对比误差约 2%。

D.3.10 (Ch.8, t 分布的推导)

题目: $Z \sim N(0, 1)$, $V \sim \chi^2(n)$, $Z \perp V$, $T = Z/\sqrt{V/n}$, 写出密度; 讨论 $n \rightarrow \infty$ 的极限; 说明应用。

思路: t 分布由正态和卡方构造, 尾部比正态重; 大自由度趋近标准正态。

解:

(a) $T \sim t(n)$ 的密度:

$$f_T(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}, \quad t \in \mathbb{R}$$

$t(n)$ 分布关于 0 对称, 自由度 $n > 2$ 时方差为 $n/(n-2)$, $n > 1$ 时均值为 0。

(b) $n \rightarrow \infty$ 趋向标准正态:

$$\left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}} \rightarrow e^{-t^2/2}$$

且 Γ -比值趋向 $1/\sqrt{2\pi}$ (Stirling 近似), 故 $f_T(t) \rightarrow \frac{1}{\sqrt{2\pi}}e^{-t^2/2}$, 即 $T \xrightarrow{d} N(0, 1)$ 。

物理直觉: $V/n \xrightarrow{P} 1$ (大数定律), $T = Z/\sqrt{V/n} \approx Z \sim N(0, 1)$ 。

(c) t 分布在小样本推断中的作用:

当总体方差 σ^2 未知、样本量 n 小时, 用样本方差 S^2 替代 σ^2 , 统计量

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

应用场景: 单样本均值检验 ($n < 30$), 置信区间的构造 (比正态区间更宽, 反映方差估计的不确定性)。

答案: $T \sim t(n)$, $f_T(t) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}$; $n \rightarrow \infty$ 时趋近 $N(0, 1)$ 。

D.3.11 (Ch.9, 多项分布)

题目: $n = 12$ 球分到 3 盒, $p_1 = 1/2, p_2 = 1/3, p_3 = 1/6$, 求多项联合分布、 $E[X_i]$ 、 $\text{Var}(X_i)$ 、 $\text{Cov}(X_1, X_2)$ 。

思路: 多项分布的边际为二项; 协方差 $\text{Cov}(X_i, X_j) = -np_i p_j$ (因竞争关系为负)。

解:

(a) 联合 PMF:

$$P(X_1 = k_1, X_2 = k_2, X_3 = k_3) = \frac{12!}{k_1! k_2! k_3!} \left(\frac{1}{2}\right)^{k_1} \left(\frac{1}{3}\right)^{k_2} \left(\frac{1}{6}\right)^{k_3}$$

其中 $k_1 + k_2 + k_3 = 12$, $k_i \geq 0$ 。

(b) 边际均值与方差 ($X_i \sim B(12, p_i)$):

i	p_i	$E[X_i] = 12p_i$	$\text{Var}(X_i) = 12p_i(1 - p_i)$
1	1/2	6	3
2	1/3	4	$8/3 \approx 2.667$
3	1/6	2	$5/3 \approx 1.667$

(c) $\text{Cov}(X_1, X_2)$:

公式: $\text{Cov}(X_i, X_j) = -np_i p_j$ ($i \neq j$)

验证思路: $X_1 + X_2 + X_3 = 12$ (常数), 故 $\text{Var}(X_1 + X_2 + X_3) = 0$, 展开可得协方差为负。

$$\text{Cov}(X_1, X_2) = -12 \times \frac{1}{2} \times \frac{1}{3} = -2$$

答案: $\text{Cov}(X_1, X_2) = -2$, $E[X_1] = 6$, $E[X_2] = 4$, $E[X_3] = 2$

D.3.12 (Ch.8, F 分布的性质)

题目: $U \sim \chi^2(m)$, $V \sim \chi^2(n)$, $U \perp V$, $F = (U/m)/(V/n)$, 讨论性质与应用。

思路: F 分布是两个归一化卡方之比; 倒数的分布自由度互换; 用于方差齐性检验。

解:

(a) $F \sim F(m, n)$ 的定义:

$F = (U/m)/(V/n)$ 即两个独立 χ^2 除以各自自由度之比, 定义即为 $F(m, n)$ 分布。

密度:

$$f_F(x) = \frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{m}{2})\Gamma(\frac{n}{2})} \left(\frac{m}{n}\right)^{m/2} x^{m/2-1} \left(1 + \frac{m}{n}x\right)^{-(m+n)/2}, \quad x > 0$$

(b) $1/F \sim F(n, m)$:

$$\frac{1}{F} = \frac{V/n}{U/m}$$

分子 $V \sim \chi^2(n)$, 分母 $U \sim \chi^2(m)$, $V \perp U$, 故 $1/F \sim F(n, m)$ 。□

(c) F 分布与方差齐性检验:

设两独立正态总体 $N(\mu_1, \sigma_1^2)$ 、 $N(\mu_2, \sigma_2^2)$, 样本量 m, n , 样本方差 S_1^2, S_2^2 。

在 $H_0: \sigma_1^2 = \sigma_2^2$ 下,

$$F = \frac{S_1^2}{S_2^2} \sim F(m-1, n-1)$$

单侧 ($H_1: \sigma_1^2 > \sigma_2^2$) 拒绝域: $F > F_\alpha(m-1, n-1)$ (查 F 分布临界值表)。

答案: $1/F \sim F(n, m)$; F 检验检验两总体方差是否相等。

D.3.13 (Ch.7, 复合泊松分布)

题目: $N \sim \text{Poisson}(\lambda)$, 每次损失 $X_i \sim \text{Exp}(\mu)$, 总损失 $S = \sum_{i=1}^N X_i$, 用重期望和条件方差公式求 $E[S]$ 、 $\text{Var}(S)$ 。

思路: 复合分布: 先对 N 条件化, 用全期望公式和全方差公式。

解:

(a) $E[S]$ (重期望公式):

$$E[S] = E[E[S | N]] = E[N \cdot E[X_1]] = E[N] \cdot E[X_1]$$

其中 $E[X_1] = 1/\mu$ (指数分布), $E[N] = \lambda$, 故

$$E[S] = \lambda \cdot \frac{1}{\mu} = \frac{\lambda}{\mu}$$

(b) $\text{Var}(S)$ (条件方差公式):

$$\text{Var}(S) = E[\text{Var}(S | N)] + \text{Var}(E[S | N])$$

- $E[S | N = n] = n/\mu$, 故 $\text{Var}(E[S | N]) = \text{Var}(N/\mu) = \lambda/\mu^2$
- $\text{Var}(S | N = n) = n \cdot \text{Var}(X_1) = n/\mu^2$, 故 $E[\text{Var}(S | N)] = E[N]/\mu^2 = \lambda/\mu^2$

$$\text{Var}(S) = \frac{\lambda}{\mu^2} + \frac{\lambda}{\mu^2} = \frac{2\lambda}{\mu^2}$$

(c) $\lambda = 2, \mu = 1$:

$$E[S] = \frac{2}{1} = 2, \quad \text{Var}(S) = \frac{2 \times 2}{1^2} = 4$$

答案: $E[S] = \frac{\lambda}{\mu} = 2, \quad \text{Var}(S) = \frac{2\lambda}{\mu^2} = 4$

□ 复合泊松方差公式一般形式: $\text{Var}(S) = \lambda E[X_1^2] = \lambda(\text{Var}(X_1) + (E[X_1])^2)$, 指数分布时 $E[X_1^2] = 2/\mu^2$, 故 $\text{Var}(S) = \lambda \cdot 2/\mu^2 = 2\lambda/\mu^2$, 与上式一致。

D.3.14 (Ch.8, 混合正态分布)

题目: $X | \Theta = \theta \sim N(\theta, 1)$, $\Theta \sim N(0, \tau^2)$, 求 X 的边缘分布、 $E[X]$ 、 $\text{Var}(X)$ 、 $\text{Cov}(X, \Theta)$ 。

思路: 正态-正态混合仍为正态 (高斯积分封闭性); 用全期望/全方差公式求矩。

解:

(a) X 的边缘分布:

$$X = \Theta + \varepsilon, \quad \varepsilon \sim N(0, 1) \perp \Theta \sim N(0, \tau^2)$$

两独立正态之和仍为正态:

$$X \sim N(0, \tau^2 + 1)$$

(b) $E[X]$ 与 $\text{Var}(X)$:

$$E[X] = E[E[X | \Theta]] = E[\Theta] = 0$$

$$\text{Var}(X) = E[\text{Var}(X | \Theta)] + \text{Var}(E[X | \Theta]) = E[1] + \text{Var}(\Theta) = 1 + \tau^2$$

(c) $\text{Cov}(X, \Theta)$:

$$\text{Cov}(X, \Theta) = E[X\Theta] - E[X]E[\Theta] = E[X\Theta]$$

$$E[X\Theta] = E[E[X\Theta | \Theta]] = E[\Theta \cdot E[X | \Theta]] = E[\Theta \cdot \Theta] = E[\Theta^2] = \text{Var}(\Theta) = \tau^2$$

$$\text{Cov}(X, \Theta) = \tau^2$$

验证: $\rho_{X, \Theta} = \frac{\tau^2}{\sqrt{\tau^2 + 1} \cdot \tau} = \frac{\tau}{\sqrt{\tau^2 + 1}} \in (0, 1)$, 合理。

答案: $X \sim N(0, \tau^2 + 1), \quad E[X] = 0, \quad \text{Var}(X) = 1 + \tau^2, \quad \text{Cov}(X, \Theta) = \tau^2$

D.3.15 (Ch.9, Dirichlet 分布简介)

题目: $(X_1, X_2, X_3) \sim \text{Dirichlet}(1, 1, 1)$, 求联合密度、边际分布、 $E[X_i]$ 、 $\text{Var}(X_i)$ 。

思路: $\text{Dir}(1, 1, 1)$ 是单纯形上的均匀分布; 边际为 $\text{Beta}(\alpha_i, \alpha_0 - \alpha_i)$ 。

解:

(a) 联合密度:

$$\alpha_0 = 1 + 1 + 1 = 3, \quad B(\alpha) = \frac{\prod \Gamma(\alpha_i)}{\Gamma(\alpha_0)} = \frac{1! \cdot 1! \cdot 1!}{2!} = \frac{1}{2},$$

$$f(x_1, x_2, x_3) = \frac{1}{B(\alpha)} \prod_{i=1}^3 x_i^{\alpha_i - 1} = 2 \cdot x_1^0 x_2^0 x_3^0 = 2$$

在单纯形 $\{x_1 + x_2 + x_3 = 1, x_i > 0\}$ 上为常数 2 (单纯形面积为 1/2, 故归一化)。

(b) 边际分布:

$$X_i \sim \text{Beta}(\alpha_i, \alpha_0 - \alpha_i) = \text{Beta}(1, 2)$$

Beta(1, 2) 的密度:

$$f_{X_i}(x) = \frac{\Gamma(3)}{\Gamma(1)\Gamma(2)} x^0(1-x)^1 = 2(1-x), \quad 0 < x < 1$$

(c) $E[X_i]$ 与 $\text{Var}(X_i)$:

$$\text{Dirichlet 公式: } E[X_i] = \alpha_i/\alpha_0, \quad \text{Var}(X_i) = \frac{\alpha_i(\alpha_0 - \alpha_i)}{\alpha_0^2(\alpha_0 + 1)}$$

$$E[X_i] = \frac{1}{3}, \quad \text{Var}(X_i) = \frac{1 \times 2}{9 \times 4} = \frac{2}{36} = \frac{1}{18}$$

$$\text{Beta(1,2) 直接验证: } E[X] = \frac{1}{1+2} = \frac{1}{3}, \quad \text{Var}(X) = \frac{1 \times 2}{(1+2)^2(1+2+1)} = \frac{2}{36} = \frac{1}{18} \circ \checkmark$$

$$\text{答案: } \boxed{X_i \sim \text{Beta}(1, 2), \quad E[X_i] = \frac{1}{3}, \quad \text{Var}(X_i) = \frac{1}{18}}$$

E 提高题详解 (8 题)

E.3.1 (Ch.7+Ch.8, 指数族 + 充分统计量 + 自然参数)

题目: 证明泊松、正态、伽马属于指数族; 证明 $\nabla A = E[\mathbf{T}]$ 、 $\nabla^2 A = \text{Cov}[\mathbf{T}]$; 推导 Fisher 信息; 讨论自然梯度。

思路: 将分布密度/PMF 化为指数族标准形式, 读取自然参数和充分统计量; 对 $A(\eta)$ 求导。

解:

(a) 三类分布属于指数族

泊松分布 $\text{Poisson}(\lambda)$:

$$P(X = x) = \frac{e^{-\lambda} \lambda^x}{x!} = \frac{1}{x!} \exp(x \ln \lambda - \lambda)$$

令 $\eta = \ln \lambda$, $T(x) = x$, $A(\eta) = e^\eta = \lambda$, $h(x) = 1/x!$:

$$P(X = x) = h(x) \exp(\eta T(x) - A(\eta))$$

自然参数 $\eta = \ln \lambda$, 充分统计量 $T(X) = X$ 。

正态分布 $N(\mu, \sigma^2)$:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{x^2}{2\sigma^2} + \frac{\mu}{\sigma^2}x - \frac{\mu^2}{2\sigma^2} - \ln\sigma\right)$$

令 $\eta = \left(\frac{\mu}{\sigma^2}, -\frac{1}{2\sigma^2}\right)$, $\mathbf{T}(x) = (x, x^2)$,

$$A(\eta) = -\frac{\eta_1^2}{4\eta_2} + \frac{1}{2} \ln\left(-\frac{\pi}{\eta_2}\right)$$

自然参数 $\eta = (\mu/\sigma^2, -1/2\sigma^2)$, 充分统计量 $\mathbf{T} = (X, X^2)$ 。

伽马分布 $\text{Gamma}(\alpha, \beta)$ (速率参数化):

$$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} = x^{\alpha-1} e^{-1} \cdot \exp((\alpha-1) \ln x - \beta x - \ln \Gamma(\alpha) + \alpha \ln \beta)$$

令 $\eta = (\alpha-1, -\beta)$, $\mathbf{T}(x) = (\ln x, x)$,

$$A(\eta) = \ln \Gamma(\eta_1 + 1) - (\eta_1 + 1) \ln(-\eta_2)$$

自然参数 $\eta = (\alpha-1, -\beta)$, 充分统计量 $\mathbf{T} = (\ln X, X)$ 。

(b) $\nabla A = E[\mathbf{T}]$, $\nabla^2 A = \text{Cov}[\mathbf{T}]$

归一化条件: $\int h(x) \exp(\eta^\top \mathbf{T}(x) - A(\eta)) dx = 1$

对 η 求导 (在积分号下对参数微分, 合法性由正则性保证):

$$\int h(x) \exp(\dots) (\mathbf{T}(x) - \nabla A) dx = 0$$

$$\Rightarrow E[\mathbf{T}(X)] = \nabla A(\eta) \quad \square$$

再求导 (二阶):

$$\nabla^2 A(\eta) = \int h(x) e^{\eta^\top \mathbf{T} - A} (\mathbf{T} - \nabla A) (\mathbf{T} - \nabla A)^\top dx = \text{Cov}[\mathbf{T}(X)] \quad \square$$

(c) Fisher 信息矩阵 $\mathcal{J}(\eta) = \nabla^2 A(\eta)$

对数似然: $\ell(\eta; x) = \eta^\top \mathbf{T}(x) - A(\eta) + \ln h(x)$

得分函数: $\nabla_\eta \ell = \mathbf{T}(x) - \nabla A(\eta)$

Fisher 信息:

$$\mathcal{J}(\eta) = E[\nabla \ell (\nabla \ell)^\top] = E[(\mathbf{T} - E[\mathbf{T}])(\mathbf{T} - E[\mathbf{T}])^\top] = \text{Cov}[\mathbf{T}] = \nabla^2 A(\eta) \quad \square$$

(d) 自然梯度与 K-FAC

普通梯度的更新方向 $\nabla_\theta \mathcal{L}$ 在参数空间中依赖坐标系的度量, 对参数重参数化不稳定。

自然梯度利用 Fisher 信息矩阵作为黎曼度量:

$$\tilde{\nabla} \mathcal{L} = \mathcal{J}(\theta)^{-1} \nabla_\theta \mathcal{L}$$

这等价于在以 KL 散度度量的分布空间中做最速下降, 对参数化方式不变 (协变性)。

K-FAC (Kronecker-factored Approximate Curvature): 对深度网络, Fisher 矩阵维度巨大 ($O(d^2)$)。K-FAC 利用各层激活和梯度的 Kronecker 积近似:

$$\mathcal{J}_\ell \approx A_\ell \otimes G_\ell$$

其中 $A_\ell = E[\mathbf{a}_\ell \mathbf{a}_\ell^\top]$ (激活协方差), $G_\ell = E[\mathbf{g}_\ell \mathbf{g}_\ell^\top]$ (梯度协方差), 求逆代价降为 $O(d_\ell^3)$ 而非 $O(d_\ell^6)$, 大幅降低计算成本。

答案: $\nabla A(\eta) = E[\mathbf{T}(X)], \quad \nabla^2 A(\eta) = \text{Cov}[\mathbf{T}(X)] = \mathcal{J}(\eta)$

E.3.2 (Ch.8+Ch.9, 多元正态 + 条件分布 + 高斯过程)

题目: 分块多元正态, 证明边际分布; 推导条件分布 (Schur 补); 联系 GP 回归; 分析 $O(n^3)$ 瓶颈与稀疏近似。

思路: 边际由 MGF 或特征函数读出; 条件分布通过“配方 + 线性变换”得到; GP 回归是无限维多元正态的条件分布特例。

解:

(a) 边际分布 $\mathbf{X}_1 \sim N(\mu_1, \Sigma_{11})$

多元正态 $\mathbf{X}$ 的特征函数:

$$\varphi_{\mathbf{X}}(\mathbf{t}) = \exp(i\mathbf{t}^\top \mu - \frac{1}{2}\mathbf{t}^\top \Sigma \mathbf{t})$$

令 $\mathbf{t} = (\mathbf{s}, \mathbf{0})$ (仅 $\mathbf{X}_1$ 方向非零):

$$\varphi_{\mathbf{X}_1}(\mathbf{s}) = \exp(i\mathbf{s}^\top \mu_1 - \frac{1}{2}\mathbf{s}^\top \Sigma_{11} \mathbf{s})$$

这正是 $N(\mu_1, \Sigma_{11})$ 的特征函数。□

(b) 条件分布 $\mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{x}_2$

构造辅助变量 $\mathbf{Y} = \mathbf{X}_1 - \Sigma_{12}\Sigma_{22}^{-1}\mathbf{X}_2$, 则:

$$\text{Cov}(\mathbf{Y}, \mathbf{X}_2) = \Sigma_{12} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{22} = \mathbf{0}$$

故 $\mathbf{Y} \perp \mathbf{X}_2$ (多元正态下不相关即独立), $\text{Var}(\mathbf{Y}) = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$ (Schur 补)。

给定 $\mathbf{X}_2 = \mathbf{x}_2$:

$$\mathbf{X}_1 = \mathbf{Y} + \Sigma_{12}\Sigma_{22}^{-1}\mathbf{x}_2$$

$$\mu_{1|2} = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)$$

$$\Sigma_{1|2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} \quad \square$$

(c) GP 回归与条件分布的联系

高斯过程 $f \sim \mathcal{GP}(m(\cdot), k(\cdot, \cdot))$, 训练集 $\mathbf{X}_{\text{tr}}$ 处观测 $\mathbf{y} = f(\mathbf{X}_{\text{tr}}) + \varepsilon$ ($\varepsilon \sim N(\mathbf{0}, \sigma_n^2 \mathbf{I})$)。

将 $(f(\mathbf{X}_*), \mathbf{y})$ 视为联合高斯:

$$\begin{pmatrix} f_* \\ \mathbf{y} \end{pmatrix} \sim N\left(\mathbf{0}, \begin{pmatrix} K_{**} & K_{*n} \\ K_{n*} & K_{nn} + \sigma_n^2 \mathbf{I} \end{pmatrix}\right)$$

由 (b) 得后验:

$$f_* \mid \mathbf{y} \sim N(K_{*n}(K_{nn} + \sigma_n^2 \mathbf{I})^{-1}\mathbf{y}, K_{**} - K_{*n}(K_{nn} + \sigma_n^2 \mathbf{I})^{-1}K_{n*})$$

这正是 (b) 中条件均值与 Schur 补协方差的直接应用。

(d) $O(n^3)$ 瓶颈与稀疏近似

瓶颈: $(K_{nn} + \sigma_n^2 \mathbf{I})^{-1}$ 的 Cholesky 分解需 $O(n^3)$, 存储 $O(n^2)$, 大样本不可行。

诱导点法 (Sparse GP / FITC): 引入 $m \ll n$ 个诱导点 $\mathbf{Z}$, 用

$$K_{nn} \approx K_{nz}K_{zz}^{-1}K_{zn}$$

将求逆代价降为 $O(nm^2)$, m 可选 $100 \sim 1000$ 。

随机特征近似 (**Bochner 定理**): 核函数 $k(x, x') = E_{\omega}[\phi(\omega, x)\phi(\omega, x')]$, 用 D 个随机 Fourier 特征逼近核矩阵, 代价 $O(nD)$, 但近似精度受 D 控制。

答案: 条件分布由 Schur 补给出; GP 回归是多元正态条件化的无限维推广; $\mu_{1|2} = \mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)$ 。

E.3.3 (Ch.7, 负二项分布 + 过度离散 + GLM)

题目: $Y \sim \text{NegBin}(r, p)$, 证明均值方差; 证明泊松-伽马混合表示; 解释过度离散; 讨论 GLM 实现。

思路: PMF 由负二项组合数定义; 混合分布通过对 Λ 积分化简为负二项; 过度离散根源是参数的随机性。

解:

(a) PMF 与矩

Y 为第 r 次成功前的失败次数, $P(Y = y) = \binom{y+r-1}{y}(1-p)^y p^r$, $y = 0, 1, 2, \dots$

期望 (利用 PGF 或负二项求和):

$$E[Y] = \frac{r(1-p)}{p}$$

方差:

$$\text{Var}(Y) = \frac{r(1-p)}{p^2}$$

验证: $\text{Var}(Y)/E[Y] = 1/p > 1$ (过度离散, 方差超过均值)。□

(b) 泊松-伽马混合

设 $Y | \Lambda \sim \text{Poisson}(\Lambda)$, $\Lambda \sim \text{Gamma}(r, \beta)$ ($\beta = p/(1-p)$, 速率参数),

$$\begin{aligned} P(Y = y) &= \int_0^{\infty} \frac{e^{-\lambda} \lambda^y}{y!} \cdot \frac{\beta^r}{\Gamma(r)} \lambda^{r-1} e^{-\beta \lambda} d\lambda = \frac{\beta^r}{y! \Gamma(r)} \int_0^{\infty} \lambda^{y+r-1} e^{-(1+\beta)\lambda} d\lambda \\ &= \frac{\beta^r}{y! \Gamma(r)} \cdot \frac{\Gamma(y+r)}{(1+\beta)^{y+r}} = \frac{\Gamma(y+r)}{y! \Gamma(r)} \left(\frac{\beta}{1+\beta} \right)^r \left(\frac{1}{1+\beta} \right)^y \end{aligned}$$

令 $p = \beta/(1+\beta)$, 得 $P(Y = y) = \binom{y+r-1}{y} p^r (1-p)^y$, 即 $\text{NegBin}(r, p)$ 。□

(c) 过度离散的根源

全方差公式:

$$\text{Var}(Y) = E[\text{Var}(Y | \Lambda)] + \text{Var}(E[Y | \Lambda]) = E[\Lambda] + \text{Var}(\Lambda)$$

(因为 $\text{Var}(Y | \Lambda) = E[Y | \Lambda] = \Lambda$)。

$$\text{Var}(Y) = \underbrace{E[\Lambda]}_{\text{泊松内在波动}} + \underbrace{\text{Var}(\Lambda)}_{\text{速率本身的随机性}} > E[\Lambda] = E[Y]$$

结论: 过度离散来源于”速率参数本身不确定 (服从随机分布)“, 泊松模型假设速率固定是错误的。

(d) GLM 中的负二项回归

对比: 泊松回归 $\log \mu_i = \mathbf{x}_i^\top \beta$; 负二项回归在此基础上引入额外离散参数 r 。

负对数似然 (固定 r):

$$-\ell = -\sum_{i=1}^n [\ln \Gamma(y_i + r) - \ln \Gamma(r) - \ln(y_i!) + r \ln p_i + y_i \ln(1 - p_i)]$$

其中 $p_i = r / (r + \mu_i)$, $\mu_i = e^{\mathbf{x}_i^\top \beta}$ 。

PyTorch 注意事项: - 使用 `torch.distributions.NegativeBinomial(total_count=r, probs=p)` 或 `logits` 参数化; - r 可作为可学习参数 (需保证正值, 常用 `F.softplus`); - 数值稳定性: 对数伽马函数用 `torch.lgamma`。

答案: $E[Y] = \frac{r(1-p)}{p}$, $\text{Var}(Y) = \frac{r(1-p)}{p^2} = E[Y] + \frac{(E[Y])^2}{r}$; 过度离散 = 泊松内在波动 + 速率随机性。

E.3.4 (Ch.8+Ch.9, χ^2 分布 + 卡方检验 + 独立性检验)

题目: 从伽马推导 χ^2 密度; 证明马氏距离分布; 推导 Pearson 统计量的渐近分布; 讨论效应量与正确使用。

思路: $\chi^2(k) = \text{Gamma}(k/2, 1/2)$; 马氏距离通过 Cholesky 分解转化为标准正态的平方和。

解:

(a) $\chi^2(k)$ 的密度、均值、方差

$\chi^2(k) = \text{Gamma}(k/2, 1/2)$, 代入 Gamma 密度:

$$f(x) = \frac{(1/2)^{k/2}}{\Gamma(k/2)} x^{k/2-1} e^{-x/2} = \frac{1}{2^{k/2} \Gamma(k/2)} x^{k/2-1} e^{-x/2}, \quad x > 0$$

由 Gamma 分布公式 ($\alpha = k/2$, $\beta = 1/2$):

$$E[X] = \frac{\alpha}{\beta} = k, \quad \text{Var}(X) = \frac{\alpha}{\beta^2} = 2k$$

(b) 马氏距离 $\sim \chi^2(d)$

设 Σ 正定, Cholesky 分解 $\Sigma = \mathbf{L}\mathbf{L}^\top$, 令 $\mathbf{Z} = \mathbf{L}^{-1}(\mathbf{X} - \mu) \sim N_d(\mathbf{0}, \mathbf{I}_d)$, 则

$$(\mathbf{X} - \mu)^\top \Sigma^{-1} (\mathbf{X} - \mu) = \mathbf{Z}^\top \mathbf{Z} = \sum_{i=1}^d Z_i^2 \sim \chi^2(d) \quad \square$$

(c) Pearson 统计量渐近分布推导框架

列联表 ($r \times c$), H_0 : 行列独立, 期望 $E_{ij} = n\hat{p}_i\hat{p}_j$ 。

向量化: 令 $\mathbf{n} = (n_{11}, \dots, n_{rc})^\top$, 观测计数 $\sim \text{Multinomial}(n, \{p_{ij}\})$ 。

由多项分布 CLT, $(\mathbf{n} - n\mathbf{p})/\sqrt{n} \xrightarrow{d} N(\mathbf{0}, \Sigma)$ ($\Sigma = \text{diag}(\mathbf{p}) - \mathbf{p}\mathbf{p}^\top$)。

Pearson 统计量是对这个多元正态进行二次型的连续映射, 渐近分布为 χ^2 。自由度 $(r-1)(c-1)$: 共 $rc-1$ 个自由参数 (归一化约束), H_0 下估计了 $(r-1) + (c-1)$ 个参数, 故剩余 χ^2 自由度为

$$(rc-1) - [(r-1) + (c-1)] = (r-1)(c-1)$$

(d) 效应量与实践显著性

Cramér's V :

$$V = \sqrt{\frac{\chi^2/n}{\min(r-1, c-1)}}$$

$V \in [0, 1]$, $V \approx 0.1$ (弱), $V \approx 0.3$ (中), $V \approx 0.5$ (强)。

大样本问题: n 大时 $\chi^2 \approx nV^2 \min(\cdot)$, 即使 $V = 0.01$ (实践上无意义), $n = 10^6$ 时也会 $p < 0.001$ 。

ML 特征选择中的正确用法: - 不应仅凭 p 值选特征 (大数据下几乎所有特征都显著); - 应结合 V 或互信息 (MI) 设置阈值 (如 $V > 0.05$); - 对高维特征用 FDR 控制 (Benjamini-Hochberg) 而非 Bonferroni 修正。

答案: $\chi^2(k) = k, \quad = 2k; \quad \chi_{\text{Pearson}}^2 \xrightarrow{d} \chi^2((r-1)(c-1))$; 实践中需同时报告 Cramér's V 。

E.3.5 (Ch.8, Beta 分布 + 共轭先验 + 汤普森采样)

题目: 证明 Beta-Bernoulli 共轭; 证明 Beta 分布的矩; 证明汤普森采样的贝叶斯最优性; 推广到高斯奖励。

思路: 共轭性通过核识别; 矩由 Beta 函数比值给出; 汤普森采样以概率最优化后验期望。

解:

(a) Beta-Bernoulli 共轭

先验 $\theta \sim \text{Beta}(\alpha, \beta)$, 观测 s 次成功、 f 次失败, 似然 $\theta^s(1-\theta)^f$ 。

后验 $\propto$ 先验 $\times$ 似然:

$$\pi(\theta | s, f) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1} \cdot \theta^s(1-\theta)^f = \theta^{\alpha+s-1}(1-\theta)^{\beta+f-1}$$

这是 $\text{Beta}(\alpha + s, \beta + f)$ 的核, 故 $\theta | s, f \sim \text{Beta}(\alpha + s, \beta + f)$ 。□

(b) Beta 分布的均值、众数、方差

$\text{Beta}(\alpha, \beta)$ 的密度 $\propto \theta^{\alpha-1}(1-\theta)^{\beta-1}$, $B(\alpha, \beta) = \Gamma(\alpha)\Gamma(\beta)/\Gamma(\alpha + \beta)$ 。

均值:

$$E[\theta] = \int_0^1 \theta \cdot \frac{\theta^{\alpha-1}(1-\theta)^{\beta-1}}{B(\alpha, \beta)} d\theta = \frac{B(\alpha+1, \beta)}{B(\alpha, \beta)} = \frac{\Gamma(\alpha+1)\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\alpha+\beta+1)} = \frac{\alpha}{\alpha+\beta}$$

众数 ($\alpha, \beta > 1$, 令密度导数为零):

$$\frac{d}{d\theta} [\theta^{\alpha-1}(1-\theta)^{\beta-1}] = 0 \Rightarrow (\alpha-1)(1-\theta) = (\beta-1)\theta \Rightarrow \theta^* = \frac{\alpha-1}{\alpha+\beta-2}$$

方差:

$$E[\theta^2] = \frac{B(\alpha+2, \beta)}{B(\alpha, \beta)} = \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)}$$

$$\text{Var}(\theta) = \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)} - \frac{\alpha^2}{(\alpha+\beta)^2} = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)} \quad \square$$

(c) 汤普森采样的贝叶斯最优性

设 K 个臂, 第 k 臂后验 $\theta_k \sim \text{Beta}(\alpha_k, \beta_k)$ 。汤普森采样: 从每个后验采样 $\hat{\theta}_k$, 选 $k^* = \arg \max_k \hat{\theta}_k$ 。

贝叶斯最优性: 选臂 k 的概率为

$$P(k \text{ 被选}) = P(\hat{\theta}_k > \hat{\theta}_j, \forall j \neq k) = P(\theta_k = \max_j \theta_j)$$

(因为采样后比较等价于后验最优概率)。这正是贝叶斯后验下臂 k 为最优臂的概率, 汤普森采样以后验最优概率选臂, 是后验感知的最优策略。□

(d) 高斯奖励的共轭对与 UCB 对比

高斯奖励 $r \sim N(\mu_k, \sigma^2)$ (σ^2 已知), 共轭先验 $\mu_k \sim N(m_0, v_0^2)$, 后验

$$\mu_k \mid r_1, \dots, r_n \sim N\left(\frac{v_0^{-2}m_0 + n\sigma^{-2}\bar{r}}{v_0^{-2} + n\sigma^{-2}}, \frac{1}{v_0^{-2} + n\sigma^{-2}}\right)$$

与 UCB 对比:

维度	UCB (UCB1)	汤普森采样
探索依据	置信上界 (确定性)	后验采样 (随机性)
理论保证	$O(\sqrt{T \log T})$ 遗憾	Bayes 遗憾最优
计算	简单, 无需采样	需要后验采样
实践效果	对非平稳适应快	经验上更优, 高维可扩展

答案: $E[\theta] = \frac{\alpha}{\alpha + \beta}, \quad \text{Var}(\theta) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$; 汤普森采样以后验最优概率选臂, 贝叶斯最优。

E.3.6 (Ch.9, Dirichlet 分布 + 多项式后验 + LDA)

题目: Dirichlet 密度与矩; 证明聚集性; 写出 LDA 联合分布与 ELBO; 分析 α_k 对稀疏性的影响。

思路: Dirichlet 是多项分布的共轭先验; 聚集性通过积分边际化; LDA 用变分 EM 推断。

解:

(a) 密度函数与均值、方差

$$\alpha = (\alpha_1, \dots, \alpha_K), \quad \alpha_0 = \sum_k \alpha_k,$$

$$f(\mathbf{p}) = \frac{\Gamma(\alpha_0)}{\prod_{k=1}^K \Gamma(\alpha_k)} \prod_{k=1}^K p_k^{\alpha_k-1}, \quad \mathbf{p} \in \Delta^{K-1}$$

$$\text{均值: } E[p_k] = \alpha_k / \alpha_0$$

$$\text{方差: } \text{Var}(p_k) = \frac{\alpha_k(\alpha_0 - \alpha_k)}{\alpha_0^2(\alpha_0 + 1)}$$

推导 (均值): 用 Beta 边际: $p_k \sim \text{Beta}(\alpha_k, \alpha_0 - \alpha_k)$, 故 $E[p_k] = \alpha_k / \alpha_0$ 。

(b) 聚集性 (Aggregation Property)

设将类 $K-1$ 和 K 合并为新类 K' , 令 $q = p_{K-1} + p_K$ 。

$$f(p_1, \dots, p_{K-2}, q) = \int_0^q f(p_1, \dots, p_{K-2}, p_{K-1}, q - p_{K-1}) dp_{K-1}$$

由 Beta 积分, $\int_0^q p_{K-1}^{\alpha_{K-1}-1} (q - p_{K-1})^{\alpha_K-1} dp_{K-1} = q^{\alpha_{K-1}+\alpha_K-1} B(\alpha_{K-1}, \alpha_K)$,

积分后密度核变为 $\prod_{k=1}^{K-2} p_k^{\alpha_k-1} \cdot q^{(\alpha_{K-1}+\alpha_K)-1}$,

这是 $\text{Dir}(\alpha_1, \dots, \alpha_{K-2}, \alpha_{K-1} + \alpha_K)$ 的核。□

(c) LDA 联合分布与变分 ELBO

LDA 生成过程:

$$\theta_d \sim \text{Dir}(\alpha), \quad \phi_k \sim \text{Dir}(\beta), \quad z_{dn} \sim \text{Cat}(\theta_d), \quad w_{dn} \sim \text{Cat}(\phi_{z_{dn}})$$

联合分布:

$$p(\mathbf{w}, \mathbf{z}, \theta, \phi) = \prod_k p(\phi_k | \beta) \prod_d \left[p(\theta_d | \alpha) \prod_n p(z_{dn} | \theta_d) p(w_{dn} | \phi_{z_{dn}}) \right]$$

变分 ELBO (均值场近似 $q(\mathbf{z}, \theta, \phi) = \prod_d q(\theta_d) \prod_{dn} q(z_{dn}) \prod_k q(\phi_k)$):

$$\text{ELBO} = E_q[\log p(\mathbf{w}, \mathbf{z}, \theta, \phi)] - E_q[\log q(\mathbf{z}, \theta, \phi)]$$

$$= E_q[\log p(\theta | \alpha)] + E_q[\log p(\mathbf{z} | \theta)] + E_q[\log p(\mathbf{w} | \mathbf{z}, \phi)] + E_q[\log p(\phi | \beta)] - E_q[\log q]$$

每项均有解析形式 (Dirichlet 和多项的期望对数均可用 ψ 函数表达)。

(d) α_k 对分布形状的影响

- $\alpha_k < 1$ (如 $\alpha_k = 0.1$): 密度在单纯形顶点附近集中, 生成的 $\mathbf{p}$ 稀疏 (大多数分量接近 0, 仅少数分量显著)。类比 LLM: token 分布集中于少数高概率词 (尖锐分布, 低温采样效果)。
- $\alpha_k > 1$ (如 $\alpha_k = 5$): 密度在单纯形中心附近集中, 生成的 $\mathbf{p}$ 均匀 (所有分量接近 $1/K$)。类比 LLM: token 分布均匀 (高温采样, 高多样性)。
- $\alpha_k = 1$: 单纯形上的均匀分布 (如 D.3.15)。

答案: $E[p_k] = \frac{\alpha_k}{\alpha_0}$; 聚集性保证边际仍为 Dirichlet; $\alpha_k < 1$ 产生稀疏分布, $\alpha_k > 1$ 产生均匀分布。

E.3.7 (Ch.8+Ch.9, Wishart 分布 + 多元样本协方差 + 矩阵分布)

题目: 证明 $(n-1)\mathbf{S} \sim W_p(n-1, \Sigma)$; 求 $E[\mathbf{S}]$ 与 $E[\mathbf{S}^{-1}]$; Marchenko-Pastur 定律; 高维协方差估计。

思路: Wishart 由多元正态样本的外积定义; 无偏性用期望的线性性; Marchenko-Pastur 描述高维随机矩阵特征值的极限分布。

解:

$$(a) (n-1)\mathbf{S} \sim W_p(n-1, \Sigma)$$

令 $\mathbf{Y}_i = \mathbf{X}_i - \bar{\mathbf{X}}$, 则 $(n-1)\mathbf{S} = \sum_{i=1}^n \mathbf{Y}_i \mathbf{Y}_i^\top$ 。

利用正交投影: $(n-1)\mathbf{S} = (\mathbf{X} - \mathbf{1}\bar{\mathbf{X}}^\top)^\top (\mathbf{X} - \mathbf{1}\bar{\mathbf{X}}^\top)$, 其等价于将 n 个 $N_p(\mathbf{0}, \Sigma)$ 向量 (通过正交变换去均值得到 $n-1$ 个独立向量) 的外积之和。

由 Wishart 分布定义, m 个独立 $N_p(\mathbf{0}, \Sigma)$ 向量外积之和为 $W_p(m, \Sigma)$, 故

$$(n-1)\mathbf{S} \sim W_p(n-1, \Sigma) \quad \square$$

$$(b) E[\mathbf{S}] = \Sigma \text{ (无偏性)}$$

$W_p(m, \Sigma)$ 的期望为 $m\Sigma$, 故

$$E[(n-1)\mathbf{S}] = (n-1)\Sigma \Rightarrow E[\mathbf{S}] = \Sigma \quad \square$$

$E[\mathbf{S}^{-1}]$ (逆的期望):

Wishart 矩阵的逆服从逆 Wishart 分布 $W_p^{-1}(m, \Sigma^{-1})$ ($m > p+1$), 其期望为

$$E[(n-1)\mathbf{S}^{-1}] = \frac{\Sigma^{-1}}{n-1-p-1} = \frac{\Sigma^{-1}}{n-p-2}$$

故 $E[\mathbf{S}^{-1}] = \frac{\Sigma^{-1}}{n-p-2}$ (要求 $n > p+2$)。□

(c) Marchenko-Pastur 定律

当 $p, n \rightarrow \infty$, $p/n \rightarrow \gamma \in (0, 1)$ 时, 样本协方差 ($\Sigma = \mathbf{I}$) 的特征值 λ 的经验分布趋向:

$$f(\lambda) = \frac{1}{2\pi\gamma\lambda} \sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}, \quad \lambda \in [\lambda_-, \lambda_+]$$

其中 $\lambda_{\pm} = (1 \pm \sqrt{\gamma})^2$ 。

意义: 即使真实协方差 = $\mathbf{I}$ (所有特征值为 1), 高维样本协方差的特征值分布在 $[(1 - \sqrt{\gamma})^2, (1 + \sqrt{\gamma})^2]$ 范围内, 产生严重膨胀 (最大特征值可达 $(1 + \sqrt{\gamma})^2 \gg 1$), 导致样本协方差高估真实协方差的“波动性”。

(d) 高维协方差估计的解决方案

方法	原理	代价
正则化 (Ledoit-Wolf)	$\hat{\Sigma} = \alpha \mathbf{S} + (1 - \alpha)\mathbf{I}$, 缩减特征值	$O(p^2)$
对角近似 (BatchNorm)	$\hat{\Sigma} \approx \text{diag}(\mathbf{S})$, 忽略协方差	$O(p)$
低秩近似 (PCA)	$\hat{\Sigma} \approx \mathbf{U}_r \Lambda_r \mathbf{U}_r^\top + \sigma^2 \mathbf{I}$	$O(pr)$

当 $B \ll d$ 时, $\text{rank}(\mathbf{S}) \leq B - 1 < d$, 矩阵奇异, 必须正则化。BatchNorm 的对角近似在实践中效果好, 因为批内特征相关性弱。

答案: $(n-1)\mathbf{S} \sim W_p(n-1, \Sigma)$, $E[\mathbf{S}] = \Sigma$, $E[\mathbf{S}^{-1}] = \Sigma^{-1}/(n-p-2)$; 高维时需正则化克服 Marchenko-Pastur 膨胀。

E.3.8 (Ch.7+Ch.8, 混合分布 + EM 算法 + 模式坍塌)

题目: GMM 完整数据对数似然; 推导 EM 的 E 步和 M 步; 证明 EM 单调不降; 与 GAN 模式坍塌类比及 WGAN 解决方案。

思路: EM 通过最大化 ELBO (Q 函数) 隐式提升边际似然; 单调性由 Jensen 不等式保证; GAN 的模式坍塌类比于某分量退化。

解:

(a) 完整数据对数似然

隐变量 $Z_i \in \{1, \dots, K\}$ 表示第 i 个样本属于第 k 个分量。

$$\begin{aligned} \log p(\mathbf{X}, \mathbf{Z} \mid \theta) &= \sum_{i=1}^n \sum_{k=1}^K \mathbf{1}[Z_i = k] [\log \pi_k + \log N(\mathbf{x}_i; \mu_k, \Sigma_k)] \\ &= \sum_{i=1}^n \sum_{k=1}^K z_{ik} \left[\log \pi_k - \frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (\mathbf{x}_i - \mu_k)^\top \Sigma_k^{-1} (\mathbf{x}_i - \mu_k) + \text{const} \right] \end{aligned}$$

(b) E 步与 M 步

E 步 (计算后验责任):

$$r_{ik} = P(Z_i = k \mid \mathbf{x}_i, \theta^{\text{old}}) = \frac{\pi_k^{\text{old}} N(\mathbf{x}_i; \mu_k^{\text{old}}, \Sigma_k^{\text{old}})}{\sum_{j=1}^K \pi_j^{\text{old}} N(\mathbf{x}_i; \mu_j^{\text{old}}, \Sigma_j^{\text{old}})}$$

M 步 (最大化 Q 函数 = $E_{Z|\mathbf{X}, \theta^{\text{old}}}[\log p(\mathbf{X}, \mathbf{Z} \mid \theta)]$):

令 $N_k = \sum_{i=1}^n r_{ik}$ (有效样本数),

$$\pi_k^{\text{new}} = \frac{N_k}{n}$$

$$\mu_k^{\text{new}} = \frac{\sum_i r_{ik} \mathbf{x}_i}{N_k}$$

$$\Sigma_k^{\text{new}} = \frac{\sum_i r_{ik} (\mathbf{x}_i - \mu_k^{\text{new}})(\mathbf{x}_i - \mu_k^{\text{new}})^\top}{N_k}$$

(c) EM 单调不降

定义 $Q(\theta | \theta^{\text{old}}) = E_{\mathbf{Z}|\mathbf{X}, \theta^{\text{old}}}[\log p(\mathbf{X}, \mathbf{Z} | \theta)]$,

$$\log p(\mathbf{X} | \theta) = Q(\theta | \theta^{\text{old}}) - \underbrace{\sum_{\mathbf{z}} q(\mathbf{z}) \log \frac{q(\mathbf{z})}{p(\mathbf{z} | \mathbf{X}, \theta)}}_{= \text{KL}(q \| p(\cdot | \mathbf{X}, \theta)) \geq 0} + \text{const}$$

E 步令 $q(\mathbf{z}) = p(\mathbf{z} | \mathbf{X}, \theta^{\text{old}})$ (KL = 0),

M 步令 $\theta^{\text{new}} = \arg \max_{\theta} Q(\theta | \theta^{\text{old}})$ (Q 不减),

故 $\log p(\mathbf{X} | \theta^{\text{new}}) \geq \log p(\mathbf{X} | \theta^{\text{old}})$ 。□

(d) 模式坍塌与 GAN/WGAN

EM 退化: 若某分量 $\pi_k \rightarrow 0$, $N_k \rightarrow 0$, 导致 Σ_k^{-1} 不稳定 (奇异)。实践上需要对 Σ_k 加正则项 (对角加 $\epsilon \mathbf{I}$) 或设置 π_k 的下界。

GAN 模式坍塌类比: GAN 生成器 G 学习将噪声映射到数据分布, 若训练不均衡, G 可能仅覆盖真实数据的部分模式 (某些区域 $\pi_k \rightarrow 0$), 判别器无法有效区分剩余模式, 导致生成器只输出少数样本类型 (模式坍塌)。

WGAN 的改进: 传统 GAN 用 JS 散度, 当生成分布与真实分布不重叠时梯度为 0 (不可微)。WGAN 用 Wasserstein 距离 (Earth Mover 距离):

$$W_1(p_r, p_g) = \sup_{\|f\|_L \leq 1} E_{x \sim p_r}[f(x)] - E_{x \sim p_g}[f(x)]$$

Wasserstein 距离在分布不重叠时仍提供有意义的梯度信号, 避免梯度消失, 从而缓解模式坍塌 (生成器对所有模式保持梯度)。

答案: $r_{ik} = \frac{\pi_k N(\mathbf{x}_i; \mu_k, \Sigma_k)}{\sum_j \pi_j N(\mathbf{x}_i; \mu_j, \Sigma_j)}$; EM 单调不降由 Jensen 不等式保证; WGAN 用 Wasserstein 距离缓解模式坍塌。

F4 详解: Part 4 极限定理 (Ch.10-12, 共 24 题)

覆盖切比雪夫/马尔可夫不等式 (Ch.10)、中心极限定理 (Ch.11)、四种收敛类型 (Ch.12)。收敛强弱顺序: a.s. $\Rightarrow$ in prob. $\Leftarrow L^p$; in prob. $\Rightarrow$ in dist.; 逆向均不成立。

C 基础题详解 (8 题)

C.4.1 (Ch.10, 切比雪夫不等式)

题目: 已知 $E[X] = 10$, $\text{Var}(X) = 4$, 求 $P(|X - 10| \geq 3)$ 的上界和 $P(7 \leq X \leq 13)$ 的下界。

思路: 切比雪夫不等式 $P(|X - \mu| \geq k) \leq \sigma^2/k^2$, 取 $k = 3$ 。

解:

(1) 切比雪夫不等式:

$$P(|X - 10| \geq 3) \leq \frac{\text{Var}(X)}{3^2} = \frac{4}{9}.$$

(2) $\{7 \leq X \leq 13\} = \{|X - 10| \leq 3\}$, 故

$$P(7 \leq X \leq 13) = 1 - P(|X - 10| \geq 3) \geq 1 - \frac{4}{9} = \frac{5}{9}.$$

答案: $P(|X - 10| \geq 3) \leq \boxed{\frac{4}{9}}$; $P(7 \leq X \leq 13) \geq \boxed{\frac{5}{9}}$

C.4.2 (Ch.10, 大数定律的应用)

题目: X_i i.i.d., $E[X_i] = 2$, $\text{Var}(X_i) = 5$. WLLN 结论及需多大 n 使误差概率 ≤ 0.05 。

思路: WLLN 给出 $\bar{X}_n \xrightarrow{P} 2$; 再用切比雪夫对 $\bar{X}_n$ 估界。

解:

(1) 由 WLLN (Chebyshev 版本): $\bar{X}_n \xrightarrow{P} 2$, 即对任意 $\varepsilon > 0$, $P(|\bar{X}_n - 2| \geq \varepsilon) \rightarrow 0$ 。

(2) $\text{Var}(\bar{X}_n) = 5/n$ 。取 $\varepsilon = 0.5$:

$$P(|\bar{X}_n - 2| \geq 0.5) \leq \frac{5/n}{0.5^2} = \frac{20}{n} \leq 0.05 \implies n \geq 400.$$

答案: $\bar{X}_n \xrightarrow{P} 2$; 需 $n \geq \boxed{400}$

□ 切比雪夫上界通常偏保守 (只需二阶矩), 给出的 n 是充分条件, 实际所需 n 可能更小。

C.4.3 (Ch.11, 中心极限定理——样本均值)

题目: X_i i.i.d., $\mu = 4$, $\sigma^2 = 9$, $n = 36$. 求 $\bar{X}_{36}$ 的期望/方差和近似分布, 计算 $P(\bar{X}_{36} > 5)$ 。

思路: $\bar{X}_n$ 精确期望为 μ , 方差为 σ^2/n ; CLT 给出渐近正态。

解:

$$(1) E[\bar{X}_{36}] = 4, \text{Var}(\bar{X}_{36}) = 9/36 = 1/4, \text{SD}(\bar{X}_{36}) = 0.5.$$

$$(2) \text{ 由 CLT: } \bar{X}_{36} \overset{\text{近似}}{\sim} N(4, 1/4).$$

(3) 标准化:

$$P(\bar{X}_{36} > 5) = P\left(\frac{\bar{X}_{36} - 4}{0.5} > \frac{5 - 4}{0.5}\right) \approx P(Z > 2) = 1 - \Phi(2).$$

答案: 期望 4, 方差 1/4; 近似 $N(4, 1/4)$; $P(\bar{X}_{36} > 5) \approx \boxed{1 - \Phi(2) \approx 0.0228}$

注: CLT 的标准化步骤是关键: - 标准化变量 $Z_n = (\bar{X}_n - \mu)/(\sigma/\sqrt{n})$; - 查表或记住常用分位数: $\Phi(1.645) = 0.95$, $\Phi(1.96) = 0.975$, $\Phi(2) = 0.9772$, $\Phi(2.576) = 0.995$ 。

C.4.4 (Ch.11, 二项分布的正态近似)

题目: $X \sim B(100, 0.4)$, 近似计算 $P(35 \leq X \leq 45)$ 。

思路: $\mu = np = 40$, $\sigma = \sqrt{np(1-p)} = \sqrt{24}$, 标准化后查标准正态表。

解:

$$\mu = 40, \quad \sigma = \sqrt{100 \times 0.4 \times 0.6} = \sqrt{24} \approx 4.899.$$

$$P(35 \leq X \leq 45) \approx P\left(\frac{35 - 40}{\sqrt{24}} \leq Z \leq \frac{45 - 40}{\sqrt{24}}\right) = \Phi\left(\frac{5}{\sqrt{24}}\right) - \Phi\left(\frac{-5}{\sqrt{24}}\right) = 2\Phi\left(\frac{5}{\sqrt{24}}\right) - 1.$$

$$\frac{5}{\sqrt{24}} \approx 1.021, \text{ 故结果} \approx 2\Phi(1.02) - 1.$$

答案: $\boxed{2\Phi(5/\sqrt{24}) - 1 \approx 0.693}$

注: 若加连续性修正 ($P(34.5 \leq X \leq 45.5)$), 则界为 $\Phi(5.5/\sqrt{24}) - \Phi(-5.5/\sqrt{24})$, 近似更精确。

C.4.5 (Ch.12, 依概率收敛定义)

题目: $P(X_n = 0) = 1 - 1/n$, $P(X_n = n) = 1/n$ 。验证 $X_n \xrightarrow{P} 0$ 。

思路: 对任意 $\varepsilon > 0$, 计算 $P(|X_n| \geq \varepsilon)$; 当 $n > \varepsilon$ 时该概率即 $1/n \rightarrow 0$ 。

解:

(1) 当 $n \geq \varepsilon$ (n 足够大): $P(|X_n| \geq \varepsilon) = P(X_n = n) = \frac{1}{n} \rightarrow 0$ ($n \rightarrow \infty$)。

(若 $n < \varepsilon$, $P(|X_n| \geq \varepsilon) = 0$; 无论如何, 极限为 0。)

(2) 对任意 $\varepsilon > 0$, $P(|X_n - 0| \geq \varepsilon) \rightarrow 0$, 故 $X_n \xrightarrow{P} 0$ 。

□ 注意: 虽然 $X_n \xrightarrow{P} 0$, 但 $E[X_n] = n \cdot (1/n) = 1 \not\rightarrow 0$, 说明依概率收敛不保证期望的收敛。

答案: $P(|X_n| \geq \varepsilon) = 1/n \rightarrow 0$, $\boxed{X_n \xrightarrow{P} 0}$ 。

C.4.6 (Ch.12, 收敛类型辨析)

题目: 逐条判断三个命题的正误。

思路: 记住收敛关系图: $\text{a.s.} \Rightarrow \text{in prob.} \Rightarrow \text{in dist.}$; 逆向均不成立; $L^p \Rightarrow \text{in prob.}$

解:

1. 正确。a.s. 收敛 $\Rightarrow$ 依概率收敛: 设 $P(X_n \rightarrow X) = 1$, 则对任意 $\varepsilon > 0$, $P(|X_n - X| \geq \varepsilon) \rightarrow 0$ (由测度论标准结论)。
2. 错误。依概率收敛 $\nRightarrow$ a.s. 收敛。反例: $[0, 1]$ 上均匀测度的“走马灯”序列—— $X_n = \mathbf{1}_{[(k-2^j)/(2^j), (k+1-2^j)/(2^j)]}$ (按 j, k 遍历) 依概率收敛到 0, 但几乎处处不收敛。
3. 错误。依分布收敛 $\nRightarrow$ 依概率收敛 (极限为随机变量时)。若极限为常数 c 则等价, 但一般不然。反例: $X_n \stackrel{d}{=} X \sim N(0, 1)$ 互相独立, 则 $X_n \stackrel{d}{\rightarrow} X$ 但 $X_n \not\xrightarrow{P} X$ 。

答案: 命题 1 正确, 命题 2 错误, 命题 3 错误。

C.4.7 (Ch.12, 连续映射定理)

题目: $X_n \xrightarrow{P} 3$, $Y_n \xrightarrow{P} 2$, 求 X_n^2 、 $X_n + Y_n$ 、 $X_n \cdot Y_n$ 的依概率极限。

思路: 连续映射定理 (CMT): 若 $X_n \xrightarrow{P} c$, g 连续, 则 $g(X_n) \xrightarrow{P} g(c)$; 依概率收敛对加减乘均封闭。

解:

(1) $g(x) = x^2$ 在 $x = 3$ 处连续, 故 $X_n^2 \xrightarrow{P} 3^2 = 9$ 。

(2) $X_n + Y_n \xrightarrow{P} 3 + 2 = 5$ (加法连续)。

(3) $X_n \cdot Y_n \xrightarrow{P} 3 \times 2 = 6$ (乘法连续)。

答案: $X_n^2 \xrightarrow{P} \boxed{9}$; $X_n + Y_n \xrightarrow{P} \boxed{5}$; $X_n Y_n \xrightarrow{P} \boxed{6}$

注: CMT 对依分布收敛同样成立 (Slutsky 定理的推广): 若 $X_n \xrightarrow{d} X$, g 连续, 则 $g(X_n) \xrightarrow{d} g(X)$ 。但注意依分布收敛 + 连续映射只保证分布收敛, 不一定有依概率收敛。

C.4.8 (Ch.10, 马尔可夫不等式)

题目: $X \geq 0$, $E[X] = 6$, 求 $P(X \geq 20)$ 和 $P(X \geq 30)$ 的上界。

思路: 马尔可夫不等式: $P(X \geq a) \leq E[X]/a$ ($X \geq 0$, $a > 0$)。

解:

$$(1) P(X \geq 20) \leq \frac{6}{20} = \frac{3}{10}.$$

$$(2) P(X \geq 30) \leq \frac{6}{30} = \frac{1}{5}.$$

答案: $P(X \geq 20) \leq \boxed{3/10}$; $P(X \geq 30) \leq \boxed{1/5}$

注: 马尔可夫不等式条件弱 (只需非负和期望有限), 但上界通常很松。更高阶矩可给出更紧的界: $P(X \geq a) \leq E[X^k]/a^k$ ($k \geq 1$)。

常见不等式比较 (X 非负, $a > 0$):

不等式	条件	上界
Markov	$E[X] < \infty$	$E[X]/a$
Chebyshev	$\text{Var}(X) < \infty$	$\text{Var}(X)/(a - \mu)^2$
Hoeffding	$X \in [c_i, d_i]$	$e^{-2n^2\varepsilon^2/\sum(d_i - c_i)^2}$
Bernstein	有界 + 方差控制	$e^{-n\varepsilon^2/(2\sigma^2 + 2M\varepsilon/3)}$

D 中等题详解 (10 题)

D.4.1 (Ch.10, 大数定律验证条件)

题目: X_n 独立, $P(X_n = \pm n^\alpha) = 1/2$ ($\alpha > 0$)。验证 WLLN 的 Chebyshev 条件, 分析 $\alpha = 1$ 情形。

思路: Chebyshev-WLLN 要求 $\frac{1}{n^2} \sum_{k=1}^n \text{Var}(X_k) \rightarrow 0$; 逐步计算并确定 α 的范围。

解:

(a) $E[X_n] = \frac{1}{2}(n^\alpha) + \frac{1}{2}(-n^\alpha) = 0$; $\text{Var}(X_n) = E[X_n^2] = n^{2\alpha}$ 。

(b) Chebyshev 条件:

$$\frac{1}{n^2} \sum_{k=1}^n \text{Var}(X_k) = \frac{1}{n^2} \sum_{k=1}^n k^{2\alpha} \sim \frac{1}{n^2} \cdot \frac{n^{2\alpha+1}}{2\alpha+1} = \frac{n^{2\alpha-1}}{2\alpha+1}.$$

此量 $\rightarrow 0 \Leftrightarrow 2\alpha - 1 < 0 \Leftrightarrow \alpha < 1/2$ 。

故 WLLN 成立的 Chebyshev 条件: $0 < \alpha < 1/2$ 。

(c) $\alpha = 1$ 时, 上述量 $\sim n/(3) \rightarrow \infty$, Chebyshev 方法失效。此时 $n^{-1} \sum X_i \xrightarrow{P} 0$ 实际仍成立 (对称性 + 截尾论证), 但 Chebyshev 不给出证明。

□ Chebyshev 条件仅为充分条件, $\alpha \geq 1/2$ 时需其他方法 (如特征函数) 判断。

答案: (a) $E[X_n] = 0$, $\text{Var}(X_n) = n^{2\alpha}$; (b) $0 < \alpha < 1/2$; (c) Chebyshev 不足以证明, 但 WLLN 仍成立。

延伸: 当 $1/2 \leq \alpha < 1$ 时, 可用特征函数方法 (Feller WLLN) 在对称分布下证明 $\bar{X}_n \xrightarrow{P} 0$, 即使方差无穷大; $\alpha \geq 1$ 时均值可能不存在, WLLN 一般不成立。

D.4.2 (Ch.11, CLT 的应用)

题目: 1000 个客户, 单客户年赔付均值 500、标准差 2000。总赔付 S 的概率计算。

思路: $S = \sum_{i=1}^{1000} X_i$, $E[S] = 500000$, $\text{SD}(S) = 2000\sqrt{1000}$; 标准化后用正态表。

解:

$$E[S] = 1000 \times 500 = 500000, \text{Var}(S) = 1000 \times 2000^2 = 4 \times 10^9, \text{SD}(S) = 2000\sqrt{1000} \approx 63246.$$

(a) 标准化:

$$P(S > 550000) = P\left(Z > \frac{550000 - 500000}{63246}\right) = P(Z > 0.7906) \approx 1 - \Phi(0.79) \approx 0.2148.$$

(b) $P(S \leq c) \geq 0.99$: 需 $\frac{c - 500000}{63246} \geq z_{0.01} = 2.326$, 故

$$c \geq 500000 + 2.326 \times 63246 \approx 500000 + 147109 \approx 647109 \text{ 元}.$$

(c) 指数分布偏度较大 ($\gamma_1 = 2$, $E[|X_i - \mu_i|^3] = 2\sigma^3$), Berry-Esseen 上界 $\approx C \cdot 2\sigma^3/(\sigma^3\sqrt{n}) = 2C/\sqrt{1000} \approx 0.030$, 即正态近似误差不超过 3%。 $n = 1000$ 时 CLT 近似相当可靠, 尾部进一步用精算工具 (如鞍点近似) 验证更佳。

答案: (a) $P(S > 550000) \approx 1 - \Phi(0.79) \approx 0.215$; (b) $c \approx 647109$ 元; (c) $n = 1000$ 时 B-E 误差 $\leq 3\%$, 近似可靠。

D.4.3 (Ch.10, Markov 不等式与 Chebyshev 不等式)

题目: 证明 Markov 不等式, 再由此推导 Chebyshev 不等式, 并对 $U(0, 1)$ 比较松紧。

思路: 利用示性函数法证 Markov; 令 $Y = (X - \mu)^2$ 应用 Markov 得 Chebyshev。

解:

(a) Markov 不等式证明: $X \geq 0$, $a > 0$ 。

$$E[X] = E[X \cdot \mathbf{1}_{X \geq a}] + E[X \cdot \mathbf{1}_{X < a}] \geq E[X \cdot \mathbf{1}_{X \geq a}] \geq a \cdot P(X \geq a).$$

故 $P(X \geq a) \leq E[X]/a$ 。□

(b) Chebyshev 推导: 令 $Y = (X - \mu)^2 \geq 0$, $E[Y] = \sigma^2$, $a = (k\sigma)^2$:

$$P(|X - \mu| \geq k\sigma) = P(Y \geq k^2\sigma^2) \leq \frac{\sigma^2}{k^2\sigma^2} = \frac{1}{k^2}. \quad \square$$

(c) $X \sim U(0, 1)$: $\mu = 1/2$, $\sigma = 1/\sqrt{12}$, $k = 2$, $k\sigma = 2/\sqrt{12} = 1/\sqrt{3} \approx 0.577$ 。

Chebyshev 上界: $1/k^2 = 1/4 = 0.25$ 。

精确值: $P(|X - 1/2| \geq 1/\sqrt{3}) = P(X \leq 1/2 - 1/\sqrt{3}) \cup P(X \geq 1/2 + 1/\sqrt{3})$ 。

$1/2 - 1/\sqrt{3} \approx -0.077 < 0$, $1/2 + 1/\sqrt{3} \approx 1.077 > 1$, 两个事件概率均为 0。

精确值 = 0, 而上界为 0.25, 可见 Chebyshev 不等式非常保守。

答案: Markov 和 Chebyshev 均已证明; 精确值 $\boxed{0}$, Chebyshev 上界 $1/4$, 非常保守。

□ 均匀分布是有界分布, 其尾部衰减极快, 而 Chebyshev 不等式对任意二阶矩有限的分布均成立, 因此对有界分布非常保守。Hoeffding 不等式对有界随机变量给出指数型界, 远比 Chebyshev 紧。

D.4.4 (Ch.12, 依概率收敛的反例)

题目: $P(X_n = n) = 1/n$, $P(X_n = 0) = 1 - 1/n$ 。证 $X_n \xrightarrow{P} 0$ 但 $E[X_n] \not\rightarrow 0$ 。

思路: 计算期望; 再按定义验证依概率收敛; 最后指明含义。

解:

$$(a) E[X_n] = n \cdot \frac{1}{n} + 0 \cdot \left(1 - \frac{1}{n}\right) = 1 \not\rightarrow 0.$$

(b) 对任意 $\varepsilon > 0$, 当 $n > \varepsilon$ 时:

$$P(|X_n - 0| \geq \varepsilon) = P(X_n = n) = \frac{1}{n} \rightarrow 0.$$

故 $X_n \xrightarrow{P} 0$ 。□

(c) 含义: 依概率收敛只要求大概率下随机变量接近极限, 但 $X_n = n$ 这个“罕见大值”(概率 $1/n \rightarrow 0$) 贡献了固定期望 1, 导致 $E[X_n] = 1$ 始终不变。依概率收敛不蕴含均值收敛 (L^1 收敛)。

□ 若还有一致可积性, 则依概率收敛 $\Rightarrow L^1$ 收敛。本例中 $\{X_n\}$ 不一致可积。

答案: $E[X_n] = \boxed{1}$ 对所有 n ; $X_n \xrightarrow{P} 0$ 已证; 二者不矛盾, 依概率收敛不保证均值收敛。

注: 一致可积 (UI) 是“弥补”这个缺口的关键条件: 若 $\{X_n\}$ 依概率收敛到 X 且一致可积, 则 $E[X_n] \rightarrow E[X]$ 。本例 $\{X_n\}$ 不满足 UI (因为 $E[X_n \mathbf{1}_{X_n \geq M}] = P(X_n = n) \cdot n = 1$ 对任意 M 及足够大的 n)。

D.4.5 (Ch.11, CLT 的 Berry-Esseen 定理应用)

题目: $X_i \sim \text{Bernoulli}(1/2) - 1/2$ (中心化), 利用 Berry-Esseen 定理分析近似误差。

思路: 计算 $\rho = E[|X_i|^3]$, 代入上界公式, 再解 n 使误差小于给定阈值。

解:

(a) 中心化 Bernoulli: $P(X_i = 1/2) = P(X_i = -1/2) = 1/2$ 。

$E[X_i^2] = 1/4$ (已知标准化为方差 1 的情形时需重新确认), 这里按题意 $E[X_i^2] = 1$ (即已缩放)。

原始: $Y_i = \text{Bernoulli}(1/2) - 1/2$ 取值 $\pm 1/2$, $E[Y_i^2] = 1/4$, $E[|Y_i|^3] = 1/8$ 。

题目要求 $E[X_i^2] = 1$, 故令 $X_i = 2Y_i$, 取值 ± 1 , 则 $\rho = E[|X_i|^3] = 1$ 。

(b) $n = 100$, Berry-Esseen 上界:

$$\sup_x |P(S_n/\sqrt{n} \leq x) - \Phi(x)| \leq \frac{C\rho}{\sqrt{n}} = \frac{0.4785 \times 1}{\sqrt{100}} = \frac{0.4785}{10} \approx 0.0479.$$

(c) 要使误差 < 0.01 : $\frac{C\rho}{\sqrt{n}} < 0.01$, 即 $\sqrt{n} > C\rho/0.01 = 47.85$, 故 $n > 2290$ 。

答案: (a) $\rho = 1$; (b) 上界 ≈ 0.0479 ; (c) 需 $n \geq 2290$ 。

注: Berry-Esseen 定理给出均匀 (sup 范数) 误差界, 是最强的收敛速率结论。对特定点 x (如 $x = 0$) 的误差可用 Edgeworth 展开得到更精细的 $O(1/n)$ 阶修正。

D.4.6 (Ch.12, 各种收敛关系)

题目: 证明 a.s. $\Rightarrow$ in prob. (正向); 构造 in prob. $\not\Rightarrow$ a.s. 的反例; 证 $L^2 \Rightarrow$ in prob.

思路: (a) 用测度论逻辑; (b) 走马灯序列; (c) 利用 Markov 不等式。

解:

(a) 设 $X_n \xrightarrow{\text{a.s.}} X$, 即 $P(\omega : \lim_n X_n(\omega) = X(\omega)) = 1$ 。

对任意 $\varepsilon > 0$, 定义 $A_n = \bigcup_{k \geq n} \{|X_k - X| \geq \varepsilon\}$, 则 $A_n \downarrow A_\infty = \limsup_n \{|X_n - X| \geq \varepsilon\}$ 。

由 a.s. 收敛, $P(A_\infty) = 0$, 故 $P(A_n) \rightarrow 0$, 又 $\{|X_n - X| \geq \varepsilon\} \subset A_n$, 故 $P(|X_n - X| \geq \varepsilon) \rightarrow 0$ 。□

(b) 走马灯 (Typewriter) 反例: 在 $(\Omega, \mathcal{F}, P) = ([0, 1], \mathcal{B}, \lambda)$ 上, 令 $X_{2^j+k} = \mathbf{1}_{[k/2^j, (k+1)/2^j]}$, $k = 0, 1, \dots, 2^j - 1$, $j = 0, 1, 2, \dots$

对任意 $\varepsilon \in (0, 1)$, $P(|X_n| \geq \varepsilon) \leq P(X_n = 1) = 2^{-j} \rightarrow 0$, 故 $X_n \xrightarrow{P} 0$ 。

但对任意 $\omega \in [0, 1]$, $X_n(\omega) = 1$ 无穷次出现, 故 $X_n(\omega) \not\rightarrow 0$, a.s. 不收敛。

(c) 由 Markov 不等式, $Y = (X_n - X)^2 \geq 0$, $a = \varepsilon^2$:

$$P(|X_n - X| \geq \varepsilon) = P((X_n - X)^2 \geq \varepsilon^2) \leq \frac{E[(X_n - X)^2]}{\varepsilon^2} = \frac{\|X_n - X\|_2^2}{\varepsilon^2} \rightarrow 0.$$

故 L^2 收敛 $\Rightarrow$ 依概率收敛。□

答案: 三个命题均已证明/构造反例, 详见解过程。

收敛关系速查:

$$L^2 \xrightarrow{\text{Markov}} \text{in prob.} \quad \text{a.s.} \xrightarrow{\text{见 (a)}} \text{in prob.} \quad \text{in prob.} \xrightarrow{\text{子列}} \text{a.s. 子列收敛}$$

其中“子列收敛”是指: 若 $X_n \xrightarrow{P} X$, 则存在子列 $X_{n_k} \xrightarrow{\text{a.s.}} X$ (这是将依概率收敛与 a.s. 收敛联系起来的重要工具)。

D.4.7 (Ch.10, 强大数定律)

题目: 陈述 Kolmogorov SLLN; 以 Bernoulli 样本为例; 比较 SLLN 与 WLLN。

思路: SLLN 给出几乎处处收敛, 比 WLLN (依概率收敛) 更强。

解:

(a) Kolmogorov SLLN: 设 $X_1, X_2, \dots$ i.i.d., 若 $E[|X_1|] < \infty$, 令 $\mu = E[X_1]$, 则

$$P\left(\lim_{n \rightarrow \infty} \bar{X}_n = \mu\right) = 1, \quad \text{即 } \bar{X}_n \xrightarrow{\text{a.s.}} \mu.$$

(b) $X_i \sim \text{Bernoulli}(p)$: $E[|X_1|] = p < \infty$, $\mu = p$ 。由 SLLN, $\bar{X}_n \xrightarrow{\text{a.s.}} p$, 即样本频率以概率 1 收敛到真实概率 p , 这是频率解释概率 (Mises 频率极限) 的数学基础。

(c) SLLN 比 WLLN 更强:

- SLLN: $\bar{X}_n \xrightarrow{\text{a.s.}} \mu$ (几乎处处收敛)
- WLLN: $\bar{X}_n \xrightarrow{P} \mu$ (依概率收敛)
- 由 (a) 中结论, $\text{a.s.} \Rightarrow \text{in prob.}$, 故 SLLN 蕴含 WLLN; 逆不成立。

答案: SLLN 结论已陈述; Bernoulli 情形 $\bar{X}_n \xrightarrow{\text{a.s.}} [p]$; SLLN 更强, 蕴含 WLLN。

注: Kolmogorov SLLN 的条件 $E[|X_1|] < \infty$ 是充要条件 (不可减弱): 若 $E[|X_1|] = \infty$, 则 $\limsup_n |\bar{X}_n| = \infty$ a.s. (Feller 定理)。这也解释了柯西分布 (均值不存在) 的样本均值不收敛的现象。

D.4.8 (Ch.11, 多维 CLT)

题目: $\mathbf{X}_i$ i.i.d. $\in \mathbb{R}^d$, 均值 μ , 协方差 Σ 。陈述多维 CLT 并用 delta 方法推导渐近方差。

思路: 多维 CLT 将一维推广到向量; delta 方法利用一阶泰勒展开, 渐近方差由梯度给出。

解:

(a) 多维 CLT: 设 $\mathbf{X}_1, \dots, \mathbf{X}_n$ i.i.d., $E[\mathbf{X}_i] = \mu$, $\text{Cov}(\mathbf{X}_i) = \Sigma$ (正定), 则

$$\sqrt{n}(\bar{\mathbf{X}} - \mu) \xrightarrow{d} N(\mathbf{0}, \Sigma).$$

等价地, 对任意 $\mathbf{a} \in \mathbb{R}^d$, $\mathbf{a}^\top \sqrt{n}(\bar{\mathbf{X}} - \mu) \xrightarrow{d} N(0, \mathbf{a}^\top \Sigma \mathbf{a})$ (Cramér-Wold)。

(b) Delta 方法: 设 $g: \mathbb{R}^d \rightarrow \mathbb{R}$ 在 μ 处可微, 梯度 $\nabla g(\mu)$ 。泰勒展开:

$$g(\bar{\mathbf{X}}) \approx g(\mu) + \nabla g(\mu)^\top (\bar{\mathbf{X}} - \mu).$$

故 $\sqrt{n}(g(\bar{\mathbf{X}}) - g(\mu)) \xrightarrow{d} N(0, \nabla g(\mu)^\top \Sigma \nabla g(\mu))$.

(c) $d = 1$, $g(x) = x^2$, $g'(x) = 2x$, 渐近方差为 $[g'(\mu)]^2 \sigma^2 = (2\mu)^2 \sigma^2 = 4\mu^2 \sigma^2$.

$$\sqrt{n}(\bar{X}^2 - \mu^2) \xrightarrow{d} N(0, 4\mu^2 \sigma^2).$$

答案: 多维 CLT 已陈述; delta 方法渐近方差为 $\nabla g^\top \Sigma \nabla g$; $g(x) = x^2$ 时渐近方差为 $\boxed{4\mu^2 \sigma^2}$.

常见 delta 方法应用:

变换 $g(\mu)$	$g'(\mu)$	渐近方差
$1/\mu$	$-1/\mu^2$	σ^2/μ^4
$\sqrt{\mu}$	$1/(2\sqrt{\mu})$	$\sigma^2/(4\mu)$
$\log \mu$	$1/\mu$	σ^2/μ^2
e^μ	e^μ	$e^{2\mu} \sigma^2$
μ^2	2μ	$4\mu^2 \sigma^2$

D.4.9 (Ch.12, 特征函数与弱收敛)

题目: 陈述 Lévy 连续性定理; 用特征函数验证正态情形的 CLT; 说明 CF 方法的优势。

思路: CF 方法将弱收敛等价于逐点收敛, 计算更直接。

解:

(a) Lévy 连续性定理: $X_n \xrightarrow{d} X$ 当且仅当对所有 $t \in \mathbb{R}$, $\varphi_{X_n}(t) \rightarrow \varphi_X(t)$ (逐点收敛), 且极限 $\varphi(t)$ 在 $t = 0$ 处连续。

(b) 正态情形: 设 $X_i \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$, 则 $\bar{X}_n = \frac{1}{n} \sum X_i$, $\bar{X}_n \sqrt{n} = \frac{S_n}{\sqrt{n}}$ 。

$S_n = \sum_{i=1}^n X_i \sim N(0, n)$, 故 $S_n/\sqrt{n} \sim N(0, 1)$, 其 CF = $e^{-t^2/2}$ 。直接说明是恒同的, 无需极限过程。

一般情形 (X_i 均值 0, 方差 1): $\varphi_{X_i}(t) = 1 - t^2/2 + o(t^2)$, 则

$$\varphi_{S_n/\sqrt{n}}(t) = \left[\varphi_{X_i}\left(\frac{t}{\sqrt{n}}\right) \right]^n = \left(1 - \frac{t^2}{2n} + o(1/n) \right)^n \rightarrow e^{-t^2/2}.$$

这是标准正态的 CF, 由 Lévy 定理得 $S_n/\sqrt{n} \xrightarrow{d} N(0, 1)$ 。

(c) CF 方法的优势: CF 处处存在 ($|\varphi| \leq 1$), 无需 CDF 的单调性假设; 可直接处理重尾分布 (如 Cauchy, CF = $e^{-|t|}$)、非对称分布; 乘积独立随机变量的 CF 是各 CF 之积, 计算极为简洁。

答案: Lévy 定理已陈述; CF 验证 CLT: $\left(1 - \frac{t^2}{2n}\right)^n \rightarrow \boxed{e^{-t^2/2}}$; CF 方法更强大, 见 (c)。

注: Lévy 连续性定理的“连续性”指极限 CF $\varphi(t)$ 在 $t = 0$ 处连续 (等价于存在对应分布), 否则逐点收敛的 CF 未必对应某分布 (如狄拉克测度情形)。

D.4.10 (Ch.11, 样本均值的大样本置信区间)

题目: 用 CLT 构造 μ 的近似 95% CI; 以样本 $\{2, 5, 3, 7, 4\}$ 计算; 讨论 $n = 5$ 时的严格性。

思路: CLT 给出 $(\bar{X} - \mu)/(S/\sqrt{n}) \stackrel{\text{approx}}{\sim} N(0, 1)$, 取 $z_{0.025} = 1.96$ 。

解:

(a) 由 CLT 和 Slutsky 定理 ($S \xrightarrow{P} \sigma$),

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \xrightarrow{d} N(0, 1).$$

近似 95% CI: $\left(\bar{X} - 1.96 \cdot \frac{S}{\sqrt{n}}, \bar{X} + 1.96 \cdot \frac{S}{\sqrt{n}} \right)$.

(b) 样本 $\{2, 5, 3, 7, 4\}$: $n = 5$, $\bar{X} = 21/5 = 4.2$,

$$S^2 = \frac{1}{4} [(2 - 4.2)^2 + (5 - 4.2)^2 + (3 - 4.2)^2 + (7 - 4.2)^2 + (4 - 4.2)^2] = \frac{4.84 + 0.64 + 1.44 + 7.84 + 0.04}{4} = \frac{14.8}{4} = 3.7.$$

$$S = \sqrt{3.7} \approx 1.924, \quad S/\sqrt{5} \approx 0.860.$$

$$95\% \text{ CI} \approx (4.2 - 1.96 \times 0.860, 4.2 + 1.96 \times 0.860) = (2.51, 5.89).$$

(c) $n = 5$ 时 CLT 近似不严格: CLT 是渐近结论, $n = 5$ 样本量极小, 正态近似可能存在较大误差。若总体为正态分布, 应精确用 $t(4)$ 分布 ($t_{0.025}(4) = 2.776$); 若总体非正态, $n = 5$ 时正态近似的误差难以量化, 置信水平可能偏离 95%。

答案: CI 公式已给出; $\bar{X} = 4.2$, $S \approx 1.924$, $95\% \text{ CI} \approx (2.51, 5.89)$; $n = 5$ 应用 $t(4)$ 更严格。

注: 用 $t(4)$ 时, $t_{0.025}(4) = 2.776$, $\text{CI} = (4.2 - 2.776 \times 0.860, 4.2 + 2.776 \times 0.860) = (1.81, 6.59)$, 比 CLT CI 更宽, 更保守, 覆盖概率更有保证。小样本应优先 t 区间。

E 提高题详解 (6 题)

E.4.1 (Ch.10, 强大数定律 + Borel-Cantelli 引理)

题目: X_n i.i.d., $E[X_1^4] < \infty$. 证 WLLN, 叙述 Borel-Cantelli 引理, 利用 B-C 证 SLLN, 构造 $E[|X_1|] = \infty$ 的反例。

思路: (a) 直接用 Chebyshev; (b) B-C 第一引理靠测度连续性; (c) 用 $E[X_1^4] < \infty$ 控制 $\sum P(|\bar{X}_n - \mu| > \varepsilon)$; (d) Cauchy 分布尾部构造。

解:

(a) WLLN: $\text{Var}(\bar{X}_n) = \sigma^2/n$ ($\sigma^2 = E[(X_1 - \mu)^2] \leq \sqrt{E[X_1^4]} < \infty$)。由 Chebyshev:

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0. \quad \square$$

(b) Borel-Cantelli 引理:

- 第一引理: 若 $\sum_{n=1}^{\infty} P(A_n) < \infty$, 则 $P(\limsup_n A_n) = 0$ (几乎处处仅有有限个 A_n 发生)。
- 第二引理: 若 $\{A_n\}$ 独立且 $\sum P(A_n) = \infty$, 则 $P(\limsup_n A_n) = 1$ 。

第一引理证明: 令 $B = \limsup_n A_n = \bigcap_{N=1}^{\infty} \bigcup_{n \geq N} A_n$, 则

$$P(B) \leq P\left(\bigcup_{n \geq N} A_n\right) \leq \sum_{n \geq N} P(A_n) \rightarrow 0 \text{ (尾级数)}.$$

故 $P(B) = 0$. $\square$

(c) 用 B-C 证 SLLN (在 $E[X_1^4] < \infty$ 下):

令 $Y_i = X_i - \mu$ (中心化), $\mu_4 = E[Y_1^4] < \infty$, $\sigma^2 = E[Y_1^2]$ 。

由 Markov 不等式 (四阶矩版本):

$$P(|\bar{X}_n - \mu| \geq \varepsilon) = P\left(\left|\frac{1}{n} \sum_{i=1}^n Y_i\right| \geq \varepsilon\right) \leq \frac{E[(\sum_i Y_i)^4]}{n^4 \varepsilon^4}.$$

展开 $(\sum_i Y_i)^4$ 后, 利用独立性 $E[Y_i Y_j] = 0$ ($i \neq j$): 非零期望只来自

- 指标四元组 (i, i, i, i) : n 项, 各贡献 μ_4 ;
- 两对配对 (i, i, j, j) ($i \neq j$): $3\binom{n}{2}$ 项, 各贡献 σ^4 ;

故 $E[(\sum_i Y_i)^4] = n\mu_4 + 3n(n-1)\sigma^4 \leq Cn^2$ (C 与 n 无关)。

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{Cn^2}{n^4 \varepsilon^4} = \frac{C}{n^2 \varepsilon^4}.$$

从而 $\sum_{n=1}^{\infty} P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{C}{\varepsilon^4} \sum_{n=1}^{\infty} \frac{1}{n^2} < \infty$ 。

由 B-C 第一引理, $P(|\bar{X}_n - \mu| \geq \varepsilon \text{ i.o.}) = 0$ 。

对任意 $\varepsilon > 0$ 均成立, 故 $\bar{X}_n \xrightarrow{\text{a.s.}} \mu$ 。□

(d) 反例: 令 $P(X > x) \sim \frac{1}{x(\log x)^2}$ ($x \rightarrow \infty$), 则 $E[|X|] = \int_e^\infty P(|X| > x) dx = \int_e^\infty \frac{dx}{x(\log x)^2} = \left[-\frac{1}{\log x}\right]_e^\infty = 1 < \infty$ (此例 $E[|X|] < \infty$ 仍然)。

构造 $E[|X|] = \infty$ 的经典反例: $P(X > x) \sim 1/(x \log x)$, 则 $E[|X|] = \int_e^\infty \frac{dx}{x \log x} = \infty$, 此时 SLLN 失效, $\bar{X}_n$ 可能不收敛或收敛到 $\pm\infty$ 。

在深度学习中, 梯度爆炸对应梯度分布尾部过重 ($E[|g|] = \infty$), 导致 SGD 均值估计失效; 梯度裁剪 (Gradient Clipping) 本质是截断以确保矩存在。

答案: WLLN、Borel-Cantelli 引理均已证明; $E[X_1^4] < \infty$ 下四阶矩衰减保证级数收敛, SLLN 成立; $E[|X|] = \infty$ 时 SLLN 可失效。

技术细节补充 (四阶矩展开): $(\sum_i Y_i)^4$ 展开有 n^4 项, 按指标重复情况分类:

类型	指标结构	期望值	项数
全重合	(i, i, i, i)	μ_4	n
两对配对	$(i, i, j, j), i \neq j$	σ^4	$3n(n-1)$
其余	含奇数次指标	0 (由独立 + 零均值)	—

故 $E[(\sum Y_i)^4] = n\mu_4 + 3n(n-1)\sigma^4 = O(n^2)$, 从而 P -界为 $O(1/n^2)$, 级数 $\sum 1/n^2 < \infty$ 。

E.4.2 (Ch.11+Ch.10, CLT + Berry-Esseen + 非 i.i.d. 推广)

题目: 独立非同分布序列, 叙述 Lindeberg 条件和 CLT; 陈述 Berry-Esseen; 分析 SGD 梯度噪声的 CLT 行为。

思路: Lindeberg 条件是非 i.i.d. CLT 的关键充分条件; Berry-Esseen 给出收敛速率; SGD 可类比。

解:

(a) Lindeberg 条件与 CLT:

令 $S_n = \sum_{i=1}^n (X_i - \mu_i)$, $B_n^2 = \sum_{i=1}^n \sigma_i^2$ 。Lindeberg 条件: 对任意 $\varepsilon > 0$,

$$\frac{1}{B_n^2} \sum_{i=1}^n E[(X_i - \mu_i)^2 \mathbf{1}_{|X_i - \mu_i| > \varepsilon B_n}] \rightarrow 0 \quad (n \rightarrow \infty).$$

Lindeberg CLT: 若 Lindeberg 条件成立, 则 $S_n/B_n \xrightarrow{d} N(0, 1)$ 。

证明框架 (特征函数法):

1. 将 X_i 截断: $X_i^{(\varepsilon)} = X_i \mathbf{1}_{|X_i - \mu_i| \leq \varepsilon B_n}$, 令 $\tilde{X}_i = X_i^{(\varepsilon)} - E[X_i^{(\varepsilon)}]$ 。
2. 有界变量的 CF 满足 $\log \varphi_{\tilde{X}_i/B_n}(t) \approx -t^2 \sigma_i^{(\varepsilon)2} / (2B_n^2)$, 故 $\varphi_{S_n^{(\varepsilon)}/B_n}(t) \rightarrow e^{-t^2/2}$ 。
3. Lindeberg 条件保证截断误差 $\|S_n - S_n^{(\varepsilon)}\|_2^2 / B_n^2 \rightarrow 0$, 故截断前后 CF 差趋 0, 得 $\varphi_{S_n/B_n}(t) \rightarrow e^{-t^2/2}$ 。

(b) **Berry-Esseen** 定理: 存在常数 $C \leq 0.4785$, 使得

$$\sup_x \left| P\left(\frac{S_n}{B_n} \leq x\right) - \Phi(x) \right| \leq \frac{C \sum_{i=1}^n \rho_i}{B_n^3}.$$

其中 $\rho_i = E[|X_i - \mu_i|^3]$ 。i.i.d. 情形退化为 $C\rho/\sqrt{n}$ 。

(c) **SGD** 梯度噪声: 批大小 n , 第 i 个样本随机梯度 $g_i \approx \nabla L(\theta) + \xi_i$ (ξ_i 近似独立, 均值 0, 方差 σ_g^2)。

CLT 给出批梯度噪声 $\bar{g} - \nabla L \approx N(0, \sigma_g^2/n)$: 批大小越大, 梯度估计越精确 (方差 $\propto 1/n$); Berry-Esseen 上界 $\propto 1/\sqrt{n}$, 批大小从 16 增至 256 使近似质量提升 4 倍。

(d) **Lindeberg** 条件在非平稳流中失效: 当数据分布偏移时, σ_i^2 可能集中在某些时刻 (如概念漂移), 导致 $\max_i \sigma_i^2 / B_n^2 \not\rightarrow 0$, Lindeberg 条件违反, CLT 不适用。

Adam/AdaGrad 用历史梯度二阶矩 $v_t = \beta v_{t-1} + (1 - \beta)g_t^2$ 自适应调整学习率, 隐式地对每维度标准化, 相当于将非同方差情形转化为近似同方差, 有利于恢复 Lindeberg 条件的精神。

答案: Lindeberg 条件和 CLT 已陈述; Berry-Esseen 上界为 $C \sum \rho_i / B_n^3$; SGD 批大小增大则梯度分布更接近正态, 近似质量提升。

□ Lindeberg 条件不要求各 X_i 同分布, 但要求没有单一 X_i 主导总方差 (“均匀小性”)。i.i.d. 时 Lindeberg 条件等价于 $E[X_1^2] < \infty$ (自动满足), 故 i.i.d. CLT 是特例。

E.4.3 (Ch.11+Ch.12, Delta 方法 + Bootstrap)

题目: $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N(0, \sigma^2)$ 。证 Delta 方法; 推导 logit 变换渐近方差; Bootstrap 一致性; Deep Ensemble 分析。

思路: Delta 方法 = 泰勒展开 + Slutsky; Bootstrap 用经验分布代替真实分布。

解:

(a) **Delta** 方法证明: 在 θ 处泰勒展开:

$$g(\hat{\theta}_n) = g(\theta) + g'(\theta)(\hat{\theta}_n - \theta) + R_n, \quad R_n = O((\hat{\theta}_n - \theta)^2).$$

由于 $\hat{\theta}_n - \theta = O_P(1/\sqrt{n})$, $R_n = O_P(1/n)$, 故 $\sqrt{n}R_n \xrightarrow{P} 0$ 。

$$\sqrt{n}(g(\hat{\theta}_n) - g(\theta)) = g'(\theta) \cdot \sqrt{n}(\hat{\theta}_n - \theta) + \sqrt{n}R_n \xrightarrow{d} g'(\theta) \cdot N(0, \sigma^2) = N(0, [g'(\theta)]^2 \sigma^2). \quad \square$$

(最后一步用 Slutsky 定理: $\sqrt{n}R_n \xrightarrow{P} 0$ 与 $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N(0, \sigma^2)$ 叠加。)

(b) Logit 变换: $\hat{p}_n = \bar{X}_n$, $\sigma^2 = p(1-p)$, $g(p) = \log \frac{p}{1-p}$, $g'(p) = \frac{1}{p(1-p)}$ 。

$$\sqrt{n}(g(\hat{p}_n) - g(p)) \xrightarrow{d} N\left(0, \frac{p(1-p)}{[p(1-p)]^2}\right) = N\left(0, \frac{1}{p(1-p)}\right).$$

logit 尺度下的 CI (再逆变换回 $[0, 1]$) 在 p 接近 0 或 1 时比直接 CI 更稳定, 因为 logit 将有界参数空间映射到实轴, 近似更准确。

(c) Bootstrap 一致性框架:

步骤: $\square$ 从原样本 $X_1, \dots, X_n$ 有放回抽样得 $X_1^*, \dots, X_n^* \sim \hat{F}_n$; $\square$ 计算 Bootstrap 统计量 $T_n^* = T(X_1^*, \dots, X_n^*)$; $\square$ 用 T_n^* 的分布估计 T_n 的分布。

关键结论 (Bickel-Freedman 1981): 在正则条件 (如 $E[|X_1|^p] < \infty$ 对足够大 p) 下,

$$\sup_x |P^*(T_n^* \leq x) - P(T_n \leq x)| \xrightarrow{P} 0,$$

即 Bootstrap 分布 (条件于数据) 依概率一致逼近真实抽样分布。证明直觉: $\hat{F}_n \xrightarrow{\text{a.s.}} F$ (Glivenko-Cantelli), 从 $\hat{F}_n$ 抽样的统计量行为趋近于从 F 抽样的行为。

(d) Deep Ensemble 分析: Deep Ensemble 训练 M 个独立网络 (随机初始化), 预测时取平均——类似于对参数的 Bootstrap 重采样。

理论联系: 若各网络参数 $\hat{\theta}^{(m)} \sim^{\text{approx}}$ 后验分布 (变分意义), 则集成均值近似贝叶斯预测均值。局限: 初始化不保证参数的多样性; 各网络损失面拓扑结构相同, 集成方差可能被低估。

与 Laplace 近似对比: Laplace 近似假设后验为正态 (在 MAP 处做二阶 Taylor), 计算代价小但依赖单点近似, 不捕捉多模态; Deep Ensemble 更灵活但代价为 M 倍训练。

答案: Delta 方法已证明; logit 渐近方差为 $\frac{1}{p(1-p)}$; Bootstrap 一致性依赖 Glivenko-Cantelli; Deep Ensemble 是隐式 Bootstrap 但存在多样性局限。

$\square$ Delta 方法要求 $g'(\theta) \neq 0$ (否则需要二阶 delta 方法)。若 $g'(\theta) = 0$, 渐近分布变为 $\frac{1}{2}g''(\theta)\sigma^2 \cdot \chi^2(1)$ 。

例如估计 θ^2 在 $\theta = 0$ 处: 直接 delta 方法失效, 需二阶展开。

E.4.4 (Ch.12, 四种收敛类型的关系)

题目: 严格定义四种收敛; 构造 a.s. $\not\Rightarrow L^1$ 的反例 (打字机序列); 构造 in prob. $\not\Rightarrow$ a.s. 的反例; 分析 SGD 参数收敛性质。

思路: 四种收敛各有定义, 关系图是核心; 反例是辨析要点。

解:

(a) 四种收敛定义与关系:

收敛类型	记号	定义
L^p 收敛	$X_n \xrightarrow{L^p} X$	$E[X_n - X ^p] \rightarrow 0$
几乎处处收敛	$X_n \xrightarrow{\text{a.s.}} X$	$P(\lim_n X_n = X) = 1$
依概率收敛	$X_n \xrightarrow{P} X$	$\forall \varepsilon > 0, P(X_n - X \geq \varepsilon) \rightarrow 0$
依分布收敛	$X_n \xrightarrow{d} X$	$F_{X_n}(x) \rightarrow F_X(x)$ (F_X 连续点处)

蕴含关系 (强 $\rightarrow$ 弱):

$$L^p \Rightarrow \text{in prob.}, \quad \text{a.s.} \Rightarrow \text{in prob.}, \quad \text{in prob.} \Rightarrow \text{in dist.}$$

逆向均不成立 (需反例); a.s. 与 L^p 之间无一般蕴含关系——需加一致可积 (UI) 才能由 in prob. 或 a.s. 得到 L^1 ; 需加有界性才能由 a.s. 得到 L^p 。

特殊情况: 若 $X_n \xrightarrow{d} c$ (常数), 则 $X_n \xrightarrow{P} c$ (in dist. $\Rightarrow$ in prob., 仅限极限为常数)。

(b) a.s. $\nRightarrow L^1$ (打字机序列): 在 $[0, 1]$ 上取 $X_n = n \cdot \mathbf{1}_{[0, 1/n]}$ 。

$X_n(\omega) \rightarrow 0$ 对所有 $\omega \in (0, 1]$ (当 $n > 1/\omega$ 时), 故 $X_n \xrightarrow{\text{a.s.}} 0$ 。

但 $E[|X_n - 0|] = E[X_n] = n \cdot (1/n) = 1 \not\rightarrow 0$, 不是 L^1 收敛。

(c) in prob. $\nRightarrow$ a.s.: 在 $([0, 1], \mathcal{B}, \lambda)$ 上, 走马灯序列按如下规则排列:

$$X_1 = \mathbf{1}_{[0, 1]}, \quad X_2 = \mathbf{1}_{[0, 1/2]}, \quad X_3 = \mathbf{1}_{[1/2, 1]}, \quad X_4 = \mathbf{1}_{[0, 1/4]}, \quad X_5 = \mathbf{1}_{[1/4, 1/2]}, \quad \dots$$

第 j 层共有 2^j 个区间, 每个长度 2^{-j} , 故 $P(X_n = 1) = 2^{-j} \rightarrow 0$, $X_n \xrightarrow{P} 0$ 。

但对任意 $\omega \in [0, 1]$, 每层必有一个区间覆盖 ω , 故 $X_n(\omega) = 1$ 无穷次发生, $\limsup_n X_n(\omega) = 1 \neq 0$, a.s. 不收敛到 0。

(d) SGD 收敛性质:

- 强凸损失: SGD 参数序列 θ_n 以 $O(1/n)$ 速率依概率收敛到最优解 θ^* ; 在强凸 + 有界梯度条件下也可证 a.s. 收敛。
- 非凸损失: 一般只能证明梯度范数 $\|\nabla L(\theta_n)\| \xrightarrow{P} 0$ (即收敛到平稳点), 不能保证全局最优。
- 逃离鞍点: SGD 的随机性 (梯度噪声 $\sim N(0, \Sigma)$) 使其在鞍点处受到随机扰动, 以正概率逃离, 这是 SGD 比梯度下降更有优势的地方 (信息论和微分几何角度的解释均支持)。

答案: 四种收敛定义及关系图已给出; 打字机序列为 a.s. 不蕴含 L^1 的反例; 走马灯序列为 in prob. 不蕴含 a.s. 的反例; SGD 在凸情形依概率收敛, 非凸情形仅保证收敛到平稳点。

□ 关键记忆: 依分布收敛若极限为常数 c , 则等价于依概率收敛 (Portmanteau 定理)。否则依分布收敛是所有类型中最弱的, 只刻画分布的信息, 不涉及各 X_n 与极限的路径关系。

E.4.5 (Ch.10+Ch.11+Ch.12, 泛函 CLT + Donsker 定理)

题目: $W_n(t) = S_{[nt]}/(\sigma\sqrt{n})$ 。证有限维 CLT; 陈述 Donsker 定理; 推导 KS 统计量极限分布; 分析位置编码与布朗运动的联系。

思路: Donsker 定理将 CLT 推广到函数空间 $C[0, 1]$; KS 统计量与布朗桥相关。

解:

(a) 有限维分布的 CLT: 固定 $t \in (0, 1]$, $[nt] \rightarrow \infty$ 。

$$W_n(t) = \frac{1}{\sigma\sqrt{n}} \sum_{i=1}^{[nt]} X_i = \sqrt{\frac{[nt]}{n}} \cdot \frac{S_{[nt]}}{\sigma\sqrt{[nt]}}.$$

由 CLT, $S_{[nt]}/(\sigma\sqrt{[nt]}) \xrightarrow{d} N(0, 1)$; $[nt]/n \rightarrow t$; 故 $W_n(t) \xrightarrow{d} N(0, t)$ 。□

(b) Donsker 定理 (泛函 CLT): 设 X_i i.i.d., 均值 0, 方差 σ^2 , 定义折线过程 $W_n \in C[0, 1]$ 。则

$$W_n \Rightarrow W \quad (\text{在 } C[0, 1] \text{ 上弱收敛}),$$

其中 W 为标准布朗运动 (Wiener 过程): $W(0) = 0$, 增量独立, $W(t) - W(s) \sim N(0, t - s)$, 路径几乎处处连续。

(c) Kolmogorov-Smirnov 统计量: $D_n = \sup_x |\hat{F}_n(x) - F(x)|$ 。

将 $\hat{F}_n(x) - F(x)$ 表示为经验过程, 经适当标准化后可与 W_n 建立联系。由 Donsker 定理, 标准化经验过程 $\sqrt{n}(\hat{F}_n - F) \Rightarrow B$ (布朗桥), 其中布朗桥 $B(t) = W(t) - tW(1)$ ($t \in [0, 1]$)。

故 $\sqrt{n}D_n \xrightarrow{d} \sup_{t \in [0, 1]} |B(t)|$, 其分布为 Kolmogorov 分布 (可用级数表示)。

(d) 位置编码与布朗运动: 若输入序列 $\{e_1, \dots, e_T\}$ (token embeddings) 近似独立同分布, 均值 0, 方差 σ^2 , 则前缀和 $E_t = \sum_{i=1}^t e_i$ 经标准化后趋向布朗运动 $W(t/T)$ 。

Transformer 的正弦位置编码 $\text{PE}(\text{pos}, 2i) = \sin(\text{pos}/10000^{2i/d})$ 提供了显式的 t 信息, 其频率 $1/10000^{2i/d}$ 从低到高覆盖不同时间尺度——类比于布朗运动的 Karhunen-Loève 展开 (用正弦函数作正交基), 这与布朗运动的谱密度 $S(f) \propto 1/f^2$ (低频主导) 在精神上的一致。

答案: 有限维 CLT 已证; Donsker 定理已陈述; $\sqrt{n}D_n \xrightarrow{d} \sup_t |B(t)|$ (布朗桥上确界); 位置编码与布朗运动谱密度有内在频率结构联系。

注: KS 分布的精确表达式为 $P(\sup_t |B(t)| \leq x) = 1 - 2 \sum_{k=1}^{\infty} (-1)^{k-1} e^{-2k^2 x^2}$ (Kolmogorov 公式)。常用分位数: $x_{0.05} \approx 1.358$ (即 $P(\sqrt{n}D_n \leq 1.358) \approx 0.95$)。Donsker 定理的证明依赖 Prokhorov 定理 (紧性准则) 和有限维分布的收敛性。

E.4.6 (Ch.11+Ch.12, 稳定分布 + 广义 CLT)

题目: 重尾分布 (α -稳定), 证 $\alpha < 2$ 时方差无穷大; 陈述广义 CLT; 验证柯西稳定性; 分析 Hill 估计量。

思路: $P(|X| > x) \sim L(x)x^{-\alpha}$ 时尾部积分发散给出 $\text{Var} = \infty$; 稳定分布由特征函数刻画。

解:

(a) $\alpha < 2$ 时 $\text{Var}(X) = \infty$:

$$E[X^2] = \int_0^{\infty} P(X^2 > t) dt = 2 \int_0^{\infty} xP(|X| > x) dx \geq 2 \int_1^{\infty} x \cdot \frac{c}{x^\alpha} dx = 2c \int_1^{\infty} x^{1-\alpha} dx.$$

当 $\alpha < 2$ 时, $1 - \alpha > -1$, 上述积分 $= \left[\frac{x^{2-\alpha}}{2-\alpha} \right]_1^{\infty} = +\infty$ 。故 $E[X^2] = \infty$, $\text{Var}(X) = \infty$, 经典 CLT 不适用。□

(b) 广义中心极限定理 (GCLT): 设 X_i i.i.d., 尾指数 $\alpha \in (0, 2)$ 。存在规范化常数 $a_n \sim n^{1/\alpha}$ 和中心化常数 b_n , 使得

$$(S_n - b_n)/a_n \xrightarrow{d} Z_\alpha,$$

其中 Z_α 为 α -稳定分布。其特征函数为

$$\varphi_{Z_\alpha}(t) = \exp \left\{ -c|t|^\alpha \left(1 - i\beta \operatorname{sgn}(t) \tan \frac{\pi\alpha}{2} \right) + i\delta t \right\}, \quad \alpha \neq 1,$$

参数 $c > 0$ (尺度), $\beta \in [-1, 1]$ (偏度), $\delta \in \mathbb{R}$ (位置)。 $\alpha = 2$ 退化为正态分布。

(c) 对称柯西分布 ($\alpha = 1$) 的稳定性: 对称柯西的 CF 为 $\varphi(t) = e^{-|t|}$ 。

n 个独立柯西之和 S_n 的 CF: $\varphi_{S_n}(t) = [e^{-|t|}]^n = e^{-n|t|}$, 故 $S_n \sim \text{Cauchy}(0, n)$ 。

S_n/n 的 CF: $\varphi_{S_n/n}(t) = \varphi_{S_n}(t/n) = e^{-|t|}$, 即 $S_n/n \sim \text{Cauchy}(0, 1)$ ——与原分布相同。

对比经典 CLT: 正态情形 $S_n/\sqrt{n} \rightarrow N(0, \sigma^2)$, 归一化为 $\sqrt{n}$; 柯西情形需除以 n ($\alpha = 1$, $a_n \sim n$), 且极限仍为柯西——平均无法“改善”精度, 无法用样本均值估计柯西的“中心”(均值不存在)。

(d) Hill 估计量: Hill 估计量

$$\hat{\alpha}_k^{-1} = \frac{1}{k} \sum_{i=1}^k \log X_{(n-i+1)} - \log X_{(n-k)},$$

理论依据: 超过高阈值 $u = X_{(n-k)}$ 的超额量 $X - u \mid X > u$ 在 Pareto 尾 ($P(X > x) \sim cx^{-\alpha}$) 下近似服从指数分布:

$$P(X - u > y \mid X > u) \approx e^{-y/(\alpha^{-1} \cdot u)} \cdot \frac{x^\alpha}{(x+y)^\alpha} \approx e^{-\alpha y/u}.$$

取对数比值: $\log(X_{(n-i+1)}/X_{(n-k)}) \approx \text{Exp}(\alpha)$, 其均值为 $1/\alpha$ 。Hill 估计量即为 k 个这样的对数超额量的样本均值, 由 SLLN, 当 $k, n \rightarrow \infty$ ($k/n \rightarrow 0$) 时, $\hat{\alpha}_k^{-1} \xrightarrow{P} \alpha^{-1}$ 。

在训练损失的随机游走中, 若梯度噪声重尾 ($\alpha < 2$), 则 SGD 步长 ηg_t 的二阶矩无穷大, 理论上的 CLT 型收敛不适用; 实践中表现为偶发性的“梯度爆炸”。梯度裁剪本质是将分布截断为有限方差分布, 使 CLT 可再次适用。

答案: (a) $\alpha < 2$ 时 $\text{Var} = \infty$ 已证; (b) GCLT 特征函数形式已给出; (c) 柯西 CF $e^{-n|t|}$, $S_n/n \sim \text{Cauchy}$, 归一化为 n 而非 $\sqrt{n}$; (d) Hill 估计量基于超额量指数近似, 重尾梯度导致 CLT 失效需梯度裁剪。

□ α -稳定分布具有稳定性: 若 X_1, X_2 i.i.d. 同为 α -稳定分布, 则 $aX_1 + bX_2$ 仍为 α -稳定 (仅差尺度变换)。 $\alpha = 2$ 时即正态分布的稳定性; $\alpha = 1$ 时即柯西的稳定性。金融中的 Lévy 稳定分布建模收益率尾部比高斯模型更真实。

知识点速查

核心不等式

不等式	形式	条件
Markov	$P(X \geq a) \leq E[X]/a$	$X \geq 0, a > 0$
Chebyshev	$P(X - \mu \geq k\sigma) \leq 1/k^2$	$\text{Var}(X) < \infty$
Chebyshev ($\bar{X}_n$)	$P(\bar{X}_n - \mu \geq \varepsilon) \leq \sigma^2/(n\varepsilon^2)$	i.i.d., 有限方差

收敛类型蕴含关系

$$L^p \Rightarrow \text{in prob.} \Rightarrow \text{in dist.} \Leftarrow (\text{极限为常数时等价})$$

a.s. $\Rightarrow$ in prob. in prob. $\Rightarrow$ a.s. 子列
子列

大数定律对比

定理	条件	结论
WLLN (Chebyshev)	$\text{Var}(X_1) < \infty$	$\bar{X}_n \xrightarrow{P} \mu$
WLLN (Feller)	$E[X_1] < \infty$	$\bar{X}_n \xrightarrow{P} \mu$
SLLN (Kolmogorov)	$E[X_1] < \infty$	$\bar{X}_n \xrightarrow{\text{a.s.}} \mu$

CLT 家族

定理	条件	结论
CLT (i.i.d.)	$\sigma^2 < \infty$	$S_n/(\sigma\sqrt{n}) \xrightarrow{d} N(0,1)$
Berry-Esseen	$E[X ^3] < \infty$	误差 $\leq C\rho/\sqrt{n}$
Lindeberg CLT	Lindeberg 条件	$S_n/B_n \xrightarrow{d} N(0,1)$ (非 i.i.d.)
GCLT	α -稳定尾, $\alpha \in (0,2)$	$S_n/n^{1/\alpha} \xrightarrow{d} Z_\alpha$
Donsker	$\sigma^2 < \infty$	$W_n \Rightarrow W$ (函数空间)

文件结束。共 C 基础 8 题 + D 中等 10 题 + E 提高 6 题 = 24 题。

F4b 详解: Part 5 统计基础 (Ch.13-15, 共 23 题)

覆盖: 抽样分布 (Ch.13)、数据描述 (Ch.14)、充分统计量 (Ch.15)。核心公式: $\bar{X} \sim N(\mu, \sigma^2/n)$; $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$; $\bar{X} \perp S^2$ (正态总体); $T = (\bar{X} - \mu)/(S/\sqrt{n}) \sim t(n-1)$ 。

C 基础题详解 (8 题)

C.5.1 (Ch.13, 样本统计量的定义)

题目: 样本 {3, 5, 7, 9, 6} ($n = 5$), 计算 $\bar{x}$ 和 s^2 (分母 $n - 1$)。

思路: 先求均值, 再按公式计算修正样本方差。

解:

1. 样本均值

$$\bar{x} = \frac{3 + 5 + 7 + 9 + 6}{5} = \frac{30}{5} = 6.$$

2. 样本方差 (分母 $n - 1 = 4$)

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
3	-3	9
5	-1	1
7	+1	1
9	+3	9
6	0	0
合计		20

$$s^2 = \frac{20}{4} = 5.$$

答案: $\boxed{\bar{x} = 6, \quad s^2 = 5}$

C.5.2 (Ch.13, 抽样分布——样本均值)

题目: 总体 $X \sim N(10, 16)$, $n = 4$, 求 $\bar{X}$ 的分布及 $P(\bar{X} > 12)$ 。

思路: 正态总体样本均值仍服从正态分布, 方差缩小 n 倍。

解:

1. $\bar{X}$ 的精确分布

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) = N\left(10, \frac{16}{4}\right) = N(10, 4).$$

标准差 $\sigma_{\bar{X}} = \sqrt{4} = 2$ 。

2. 计算概率

$$P(\bar{X} > 12) = P\left(\frac{\bar{X} - 10}{2} > \frac{12 - 10}{2}\right) = P(Z > 1) = 1 - \Phi(1).$$

查表 $\Phi(1) \approx 0.8413$, 故 $P(\bar{X} > 12) \approx 0.1587$ 。

答案: $\bar{X} \sim N(10, 4)$; $P(\bar{X} > 12) = 1 - \Phi(1) \approx \boxed{0.1587}$

C.5.3 (Ch.13, χ^2 分布的性质)

题目: $Z_1, Z_2, Z_3 \stackrel{iid}{\sim} N(0, 1)$, $W = Z_1^2 + Z_2^2 + Z_3^2$, 求分布及矩。

思路: 独立标准正态的平方和服从 χ^2 分布, 自由度等于项数。

解:

1. 分布: $W \sim \chi^2(3)$ (自由度 $k = 3$)。

2. 期望与方差: $\chi^2(k)$ 的期望为 k , 方差为 $2k$, 故

$$E[W] = 3, \quad \text{Var}(W) = 6.$$

答案: $W \sim \chi^2(3)$; $\boxed{E[W] = 3, \text{Var}(W) = 6}$

C.5.4 (Ch.13, t 分布的构造)

题目: $Z \sim N(0, 1)$, $V \sim \chi^2(9)$, $Z \perp V$, $T = Z/\sqrt{V/9}$, 写出分布并给出拒绝域。

思路: 标准正态除以独立 χ^2 的“均方根”即 t 分布, 自由度等于 χ^2 的自由度。

解:

1. 分布: 由 t 分布定义, $T \sim t(9)$ 。

2. 双侧拒绝域 ($\alpha = 0.05$)

$$\text{拒绝域} = \{|T| > t_{0.025}(9) = 2.262\}.$$

答案: $T \sim t(9)$; 拒绝域 $\boxed{|T| > 2.262}$

C.5.5 (Ch.14, 样本分位数与中位数)

题目: 数据 $\{4, 1, 9, 3, 7, 2, 8\}$, 求有序样本、中位数、均值并比较。

思路: 奇数个数据时中位数为正中间那个值; 均值受极端值影响。

解:

1. 有序样本 ($n = 7$): 1, 2, 3, 4, 7, 8, 9。

2. 样本中位数: 第 $\lceil 7/2 \rceil = 4$ 个值, $\hat{m} = 4$ 。

3. 样本均值

$$\bar{x} = \frac{1 + 2 + 3 + 4 + 7 + 8 + 9}{7} = \frac{34}{7} \approx 4.857.$$

均值 4.857 大于中位数 4, 因为较大的值 (7,8,9) 拉高了均值。

答案: $\hat{m} = 4$; $\bar{x} = 34/7 \approx \boxed{4.857}$; 均值 > 中位数 (右偏)

C.5.6 (Ch.14, 偏度与峰度的含义)

题目: 四个分布 (A) $N(0, 1)$; (B) $\text{Exp}(1)$; (C) $U(0, 1)$; (D) 拉普拉斯分布, 哪个偏度为 0? 哪个峰度最大?

思路: 偏度反映分布对称性, 正态/均匀/拉普拉斯关于均值对称偏度为 0; 峰度衡量尾部厚重程度。

解:

- 偏度为 0: (A) $N(0, 1)$ 、(C) $U(0, 1)$ 、(D) 拉普拉斯分布均关于均值对称, 偏度 = 0; (B) 指数分布右偏, 偏度 = 2 > 0。
- 峰度最大: (D) 拉普拉斯分布尖峰重尾, 超额峰度 (excess kurtosis) = 3; $N(0, 1)$ 超额峰度 = 0; $U(0, 1)$ 超额峰度 = -6/5; 指数分布超额峰度 = 6。

□ 若题目指“超额峰度” (excess kurtosis), 则 (B) 指数分布峰度最大 (= 6), 远超拉普拉斯 (= 3)。

答案: 偏度为 0 的有 $\boxed{(A)(C)(D)}$; 峰度最大的是 $\boxed{(B) \text{Exp}(1)}$ (超额峰度 = 6)

C.5.7 (Ch.15, 充分统计量判定)

题目: $X_i \stackrel{iid}{\sim} \text{Poisson}(\lambda)$, 写出联合 PMF 并用因子分解定理证明 $T = \sum X_i$ 是充分统计量。

思路: 将联合 PMF 分离成仅依赖 T 和 λ 的因子与仅依赖样本的因子。

解:

1. 联合 PMF

$$\prod_{i=1}^n P(X_i = x_i) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} = \frac{e^{-n\lambda} \lambda^{\sum x_i}}{\prod_{i=1}^n x_i!}.$$

2. 因子分解

$$= \underbrace{e^{-n\lambda} \lambda^T}_{g(T, \lambda)} \cdot \frac{1}{\underbrace{\prod_{i=1}^n x_i!}_{h(\mathbf{x})}}$$

其中 $T = \sum_{i=1}^n x_i$ 。满足 Neyman-Fisher 因子分解定理条件, 故 $T = \sum X_i$ 是 λ 的充分统计量。

答案: $T = \sum_{i=1}^n X_i$ 是 λ 的充分统计量。 $T = \sum_{i=1}^n X_i$

C.5.8 (Ch.15, 指数族与自然充分统计量)

题目: 正态分布 $N(\mu, \sigma^2)$ (σ^2 已知) 的自然充分统计量及 $\bar{X}$ 为何充分。

思路: 将正态 PDF 写成指数族标准形, 读出充分统计量。

解:

单个观测的 PDF 为

$$f(x; \mu) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) = \underbrace{\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}}}_{h(x)} \exp\left(\frac{\mu}{\sigma^2}x - \frac{\mu^2}{2\sigma^2}\right).$$

自然参数 $\eta = \mu/\sigma^2$, 自然充分统计量 $T(x) = x$ 。

对 n 个样本, 充分统计量为 $T = \sum_{i=1}^n x_i$ (等价于 $\bar{X}$)。 $\bar{X}$ 是 μ 的充分统计量, 因为联合密度可分解为仅依赖 $\bar{x}$ 和 μ 的因子乘以不含 μ 的因子。

答案: 自然充分统计量 $T = \sum_{i=1}^n X_i$ (即 $\bar{X}$); 正态族属于指数族, $\bar{X}$ 自然地是充分统计量。

D 中等题详解 (10 题)

D.5.1 (Ch.13, 常见统计量的分布)

题目: $X_i \stackrel{iid}{\sim} N(\mu, \sigma^2)$, 证明 $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$; 写出 T 和 F 统计量分布。

思路: 利用正交变换将 $\sum (X_i - \bar{X})^2$ 化为独立标准正态的平方和; T 分布由定义给出; F 分布由两独立 χ^2 之比给出。

解:

(a) $\bar{X}$ 的分布

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

证明 $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$:

令 $Y_i = (X_i - \mu)/\sigma \sim N(0, 1)$, 则

$$\sum_{i=1}^n \frac{(X_i - \mu)^2}{\sigma^2} = \frac{n(\bar{X} - \mu)^2}{\sigma^2} + \frac{(n-1)S^2}{\sigma^2}.$$

左边 $\sim \chi^2(n)$, 右边第一项 $\sim \chi^2(1)$ 。由于 $\bar{X} \perp S^2$ (正态总体的独立性定理), 两项独立, 由 χ^2 分布的可加性:

$$\frac{(n-1)S^2}{\sigma^2} = \chi^2(n) - \chi^2(1) \sim \chi^2(n-1).$$

(b) T 统计量

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} = \frac{(\bar{X} - \mu)/(\sigma/\sqrt{n})}{\sqrt{(n-1)S^2/[\sigma^2(n-1)]}} \sim t(n-1).$$

自由度 $n-1$ 来自分母中 $\chi^2(n-1)$ 的自由度。

(c) 方差比 F 统计量

设两独立样本 n_1, n_2 , 总体方差相同 $\sigma_1^2 = \sigma_2^2$:

$$F = \frac{S_1^2}{S_2^2} = \frac{(n_1-1)S_1^2/\sigma^2/(n_1-1)}{(n_2-1)S_2^2/\sigma^2/(n_2-1)} \sim F(n_1-1, n_2-1).$$

答案: $\bar{X} \sim N(\mu, \sigma^2/n)$; $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$; $T \sim \boxed{t(n-1)}$; $F \sim F(n_1-1, n_2-1)$

D.5.2 (Ch.13, 顺序统计量)

题目: 推导 $X_{(k)}$ 的密度; 对 $U(0, 1)$ 求 $X_{(n)}$ 和 $X_{(3)}$ ($n=5$) 的密度及期望。

思路: 恰好有 $k-1$ 个小于 x 、1 个等于 x 、 $n-k$ 个大于 x , 利用多项式计数推导密度。

解:

(a) 推导 $X_{(k)}$ 密度

$X_{(k)} \leq x$ 等价于至少 k 个观测 $\leq x$ 。对密度微分:

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1-F(x)]^{n-k} f(x).$$

组合解释: 从 n 个中选 $k-1$ 个排在 x 左边 (概率 $[F(x)]^{k-1}$), 选 $n-k$ 个排在 x 右边 (概率 $[1-F(x)]^{n-k}$), 第 k 个恰在 x 处 (密度 $f(x)$)。

(b) $X_i \sim U(0, 1)$, $X_{(n)}$ 的密度和期望

$F(x) = x$, $f(x) = 1$, 代入公式 ($k = n$):

$$f_{X_{(n)}}(x) = \frac{n!}{(n-1)!0!} x^{n-1} \cdot 1 = nx^{n-1}, \quad x \in (0, 1).$$

$$E[X_{(n)}] = \int_0^1 x \cdot nx^{n-1} dx = n \int_0^1 x^n dx = \frac{n}{n+1}.$$

(c) $n = 5$, $k = 3$ (中位数)

$$f_{X_{(3)}}(x) = \frac{5!}{2!2!} x^2(1-x)^2 = 30x^2(1-x)^2, \quad x \in (0, 1).$$

答案: $f_{X_{(n)}}(x) = nx^{n-1}$; $E[X_{(n)}] = \frac{n}{n+1}$; $f_{X_{(3)}}(x) = \boxed{30x^2(1-x)^2}$

D.5.3 (Ch.14, 经验分布函数)

题目: 经验 CDF 的性质、Glivenko-Cantelli 定理, 及 $\{1, 3, 3, 5, 7\}$ 的具体表达式。

思路: 固定 x , $n\hat{F}_n(x)$ 是 $B(n, F(x))$, 矩由此给出; Glivenko-Cantelli 是 SLLN 的一致版本。

解:

(a) 期望与方差

对固定 x , 令 $I_i = \mathbf{1}[X_i \leq x] \stackrel{iid}{\sim} \text{Bernoulli}(F(x))$, 则

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n I_i \Rightarrow n\hat{F}_n(x) \sim B(n, F(x)).$$

$$E[\hat{F}_n(x)] = F(x), \quad \text{Var}(\hat{F}_n(x)) = \frac{F(x)(1-F(x))}{n}.$$

(b) Glivenko-Cantelli 定理

对每个固定 x , SLLN 给出 $\hat{F}_n(x) \xrightarrow{a.s.} F(x)$ 。

对有限点集 $\{x_1, \dots, x_m\}$ 的一致收敛由有限并集的概率论给出; 再利用 $\hat{F}_n$ 和 F 的单调性, 可将有限点集的收敛推广到全实线, 得

$$\sup_x |\hat{F}_n(x) - F(x)| \xrightarrow{a.s.} 0.$$

(c) 样本 $\{1, 3, 3, 5, 7\}$ 的经验 CDF

$$\hat{F}_5(x) = \begin{cases} 0, & x < 1 \\ 1/5, & 1 \leq x < 3 \\ 3/5, & 3 \leq x < 5 \\ 4/5, & 5 \leq x < 7 \\ 1, & x \geq 7 \end{cases}$$

□ 重复值 3 出现两次, $\hat{F}_5(3) = 3/5$ (两个 3 均 ≤ 3)。

答案: $E[\hat{F}_n(x)] = F(x)$, $\text{Var}(\hat{F}_n(x)) = F(x)(1 - F(x))/n$; Glivenko-Cantelli 定理成立; $\hat{F}_5$ 见上表。

D.5.4 (Ch.15, 充分统计量的因子分解定理)

题目: 陈述 Neyman-Fisher 因子分解定理; 证明 $N(\mu, 1)$ 的 $\bar{X}$ 充分; 求 $\text{Exp}(\theta)$ 的充分统计量。

思路: 将联合密度改写, 识别仅依赖 T 和 θ 的部分与不依赖 θ 的部分。

解:

(a) Neyman-Fisher 因子分解定理

$T(\mathbf{X})$ 是 θ 的充分统计量, 当且仅当存在非负函数 g 和 h , 使得

$$\prod_{i=1}^n f(x_i; \theta) = g(T(\mathbf{x}), \theta) \cdot h(\mathbf{x}).$$

(b) $X_i \sim N(\mu, 1)$, 证明 $\bar{X}$ 充分

$$\prod_{i=1}^n f(x_i; \mu) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(x_i - \mu)^2}{2}\right) = \frac{1}{(2\pi)^{n/2}} \exp\left(-\frac{1}{2} \sum (x_i - \mu)^2\right).$$

展开: $\sum (x_i - \mu)^2 = \sum x_i^2 - 2\mu \sum x_i + n\mu^2$, 故

$$= \underbrace{\exp\left(\mu \sum x_i - \frac{n\mu^2}{2}\right)}_{g(\bar{x}, \mu)} \cdot \underbrace{\frac{1}{(2\pi)^{n/2}} \exp\left(-\frac{\sum x_i^2}{2}\right)}_{h(\mathbf{x})}.$$

g 仅通过 $\sum x_i = n\bar{x}$ 依赖 μ , 故 $\bar{X}$ (等价于 $T = \sum X_i$) 是 μ 的充分统计量。

(c) $X_i \sim \text{Exp}(\theta)$ (密度 $\theta e^{-\theta x}$)

$$\prod_{i=1}^n \theta e^{-\theta x_i} = \theta^n e^{-\theta \sum x_i} = \underbrace{\theta^n e^{-\theta T}}_{g(T, \theta)} \cdot \underbrace{1}_{h(\mathbf{x})}.$$

其中 $T = \sum_{i=1}^n X_i$, 故充分统计量为 $T = \sum_{i=1}^n X_i$ (等价于 $\bar{X}$)。

D.5.5 (Ch.13, Bootstrap 基本思想)

题目: 参数 Bootstrap 步骤; Bootstrap 标准误差公式; 样本 $\{2, 4, 6, 8\}$ 的 $\bar{X}^*$ 范围。

思路: Bootstrap 用经验分布 $\hat{F}_n$ 替代未知真实分布 F , 通过重抽样模拟统计量的分布。

解:

(a) 参数 Bootstrap 步骤

1. 从原样本 $\{X_1, \dots, X_n\}$ 得到 $\hat{F}_n$ (非参数) 或拟合参数模型 $\hat{\theta}$ (参数)。
2. 从 $\hat{F}_n$ (或 $\hat{F}_{\hat{\theta}}$) 有放回抽取 n 个样本, 得 Bootstrap 样本 $X_1^*, \dots, X_n^*$ 。
3. 计算 $T_n^{*(b)} = T(X_1^*, \dots, X_n^*)$, 重复 B 次。
4. 用 $\{T_n^{*(1)}, \dots, T_n^{*(B)}\}$ 的分布近似 T_n 的分布。

(b) Bootstrap 标准误差

$$\widehat{\text{SE}}_{\text{boot}} = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (T_n^{*(b)} - \bar{T}^*)^2}, \quad \bar{T}^* = \frac{1}{B} \sum_{b=1}^B T_n^{*(b)}.$$

(c) $\{2, 4, 6, 8\}$ 的 Bootstrap 均值范围

- 最小 $\bar{X}^*$: 抽到 $(2, 2, 2, 2)$, 均值 = 2。
- 最大 $\bar{X}^*$: 抽到 $(8, 8, 8, 8)$, 均值 = 8。

答案: Bootstrap 标准误差公式见上; $\bar{X}^*$ 范围为 $[2, 8]$

D.5.6 (Ch.14, Q-Q 图原理)

题目: Q-Q 图的理论依据; 重尾时的弯曲方式; 样本 $\{-1.5, -0.3, 0.1, 0.8, 1.6\}$ vs $N(0, 1)$ 。

思路: 顺序统计量 $X_{(i)}$ 的近似期望等于理论分布的 $(i - 0.5)/n$ 分位数, 如果理论假设正确, 点对成直线。

解:

(a) Q-Q 图的理论依据

当 $X_i \sim F_0$ 时, 第 i 个顺序统计量的近似期望为

$$E[X_{(i)}] \approx F_0^{-1}\left(\frac{i - 0.5}{n}\right) =: q_i.$$

Q-Q 图绘制 $(q_i, X_{(i)})$; 若 $F = F_0$, 则 $X_{(i)} \approx q_i$, 各点近似在直线 $y = x$ 上 (或经平移伸缩后在某直线上)。

(b) 重尾时的弯曲

若实际分布比 F_0 重尾 (如 t vs 正态), 两端的样本分位数比理论分位数更极端, Q-Q 图两端向上弯曲 (S 形), 即左端点在直线下方, 右端点在直线上方。

(c) 计算理论分位数 ($n = 5$, $p_i = (i - 0.5)/5$)

i	p_i	$\Phi^{-1}(p_i)$	$X_{(i)}$
1	0.10	-1.282	-1.5
2	0.30	-0.524	-0.3
3	0.50	0.000	0.1
4	0.70	+0.524	0.8
5	0.90	+1.282	1.6

点基本在直线附近, 支持数据来自正态分布的假设。

答案: 理论分位数见上表; 重尾分布 Q-Q 图两端向上弯曲 (S 形)。 $\Phi^{-1}(0.1) \approx -1.282, \dots, \Phi^{-1}(0.9) \approx 1.282$

D.5.7 (Ch.15, 完备充分统计量)

题目: $X_i \stackrel{iid}{\sim} \text{Poisson}(\lambda)$, $T = \sum X_i$: 证明 $T \sim \text{Poisson}(n\lambda)$, 验证充分性, 陈述完备性。

思路: Poisson 的可加性给出 T 的分布; 因子分解给出充分性; 指数族的完备性由参数空间内点性质保证。

解:

(a) $T \sim \text{Poisson}(n\lambda)$

对独立 Poisson 随机变量求和, 用特征函数 (或矩生成函数):

$$\varphi_T(\omega) = \prod_{i=1}^n \exp(\lambda(e^{i\omega} - 1)) = \exp(n\lambda(e^{i\omega} - 1)),$$

即 $T \sim \text{Poisson}(n\lambda)$ 。

(b) 因子分解验证充分性

$$\prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} = e^{-n\lambda} \lambda^T \cdot \frac{1}{\prod x_i!} = g(T, \lambda) \cdot h(\mathbf{x}).$$

由因子分解定理, T 是 λ 的充分统计量。

(c) 完备性

定义: 若对所有有界函数 g , $E_\lambda[g(T)] = 0$ 对所有 $\lambda > 0$ 成立, 则 $g(T) = 0$ a.e., 称 T 是完备的。

验证: $T \sim \text{Poisson}(n\lambda)$ 属于指数族 (自然参数 $\eta = \log \lambda$), 自然参数空间 $\eta \in (-\infty, +\infty)$ 包含内点, 由 Lehmann-Scheffé 定理, T 是完备充分统计量。

答案: $T \sim \text{Poisson}(n\lambda)$; T 是完备充分统计量。 $T = \sum X_i \sim \text{Poisson}(n\lambda)$

D.5.8 (Ch.13, 抽样分布的数值例)

题目: 总体 $N(5, 4)$, $n = 16$: 求 $P(\bar{X} > 6)$ 、 $P(S^2 > 6.908)$ 、方差比分布。

思路: 标准化后查正态表; 利用 $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$ 转化; 两独立正态方差比为 F 分布。

解:

(a) $P(\bar{X} > 6)$

$\bar{X} \sim N(5, 4/16) = N(5, 0.25)$, $\sigma_{\bar{X}} = 0.5$ 。

$$P(\bar{X} > 6) = P\left(Z > \frac{6-5}{0.5}\right) = P(Z > 2) = 1 - \Phi(2) \approx 1 - 0.9772 = \boxed{0.0228}.$$

(b) $P(S^2 > 6.908)$

$$\frac{(n-1)S^2}{\sigma^2} = \frac{15S^2}{4} \sim \chi^2(15).$$

$$P(S^2 > 6.908) = P\left(\chi^2(15) > \frac{15 \times 6.908}{4}\right) = P(\chi^2(15) > 25.905).$$

查 $\chi^2(15)$ 表, $\chi_{0.05}^2(15) \approx 24.996$, $\chi_{0.025}^2(15) \approx 27.488$, 故 $P \approx 0.025-0.05$ 之间; 若题目给出 25.905 对应 $P = 0.05$, 则

$$P(S^2 > 6.908) \approx \boxed{0.05}.$$

(c) 方差比分布

两独立样本 $n_1 = n_2 = 10$, 总体方差相同:

$$F = \frac{S_1^2}{S_2^2} \sim F(n_1 - 1, n_2 - 1) = \boxed{F(9, 9)}.$$

D.5.9 (Ch.14, 描述统计: 箱线图与异常值)

题目: 数据 $\{2, 3, 5, 7, 8, 9, 11, 14, 16, 22\}$ ($n = 10$), 计算 Q_1, Q_2, Q_3 , IQR, 异常值界限, 识别异常值。

思路: $n = 10$ 时用插值法 (或直接取位置) 计算四分位数; Tukey $1.5 \times \text{IQR}$ 准则判断异常值。

解:

数据已排序: 2, 3, 5, 7, 8, 9, 11, 14, 16, 22。

(a) 四分位数 (采用“四分位数位置法”: Q_1 在第 $(n+1)/4 = 2.75$ 位, Q_3 在第 $3(n+1)/4 = 8.25$ 位)

- Q_2 (中位数): 第 5、6 个数的均值 $= (8 + 9)/2 = 8.5$ 。
- Q_1 : 第 2.75 个位置 $= x_{(2)} + 0.75(x_{(3)} - x_{(2)}) = 3 + 0.75 \times 2 = 4.5$ 。
- Q_3 : 第 8.25 个位置 $= x_{(8)} + 0.25(x_{(9)} - x_{(8)}) = 14 + 0.25 \times 2 = 14.5$ 。

(b) IQR 和界限

$$\text{IQR} = Q_3 - Q_1 = 14.5 - 4.5 = 10.$$

$$\text{下界} = Q_1 - 1.5 \times \text{IQR} = 4.5 - 15 = -10.5, \quad \text{上界} = Q_3 + 1.5 \times \text{IQR} = 14.5 + 15 = 29.5.$$

(c) 异常值

所有数据均在 $(-10.5, 29.5)$ 内, 故按 Tukey 准则无异常值。

中心度量: 均值 $\bar{x} = (2 + 3 + 5 + 7 + 8 + 9 + 11 + 14 + 16 + 22)/10 = 97/10 = 9.7$; 中位数 $Q_2 = 8.5$ 。

均值受较大值 (16, 22) 影响偏高; 中位数更鲁棒, 不受极端值影响。

答案: $Q_1 = 4.5$, $Q_2 = 8.5$, $Q_3 = 14.5$; IQR = 10; 界限 $(-10.5, 29.5)$; 无异常值; 均值 $9.7 >$ 中位数 8.5 , 中位数更鲁棒。

D.5.10 (Ch.15, Rao-Blackwell 定理)

题目: 陈述 Rao-Blackwell 定理; $X_i \sim \text{Bernoulli}(p)$, $W = X_1$, $T = \sum X_i$, 计算 $W^* = E[X_1 | T = t]$ 。

思路: 条件期望在充分统计量上取均值会“改善”估计量; 给定 $T = t$ 时 X_1 服从超几何退化形式。

解:

(a) Rao-Blackwell 定理

设 T 是 θ 的充分统计量, W 是 θ 的无偏估计量 ($E_\theta[W] = \theta$)。令

$$W^* = E_\theta[W | T].$$

则: 1. W^* 也是无偏的: $E_\theta[W^*] = E_\theta[E[W | T]] = E_\theta[W] = \theta$ 。2. 方差 (MSE) 不增大: $\text{Var}(W^*) \leq \text{Var}(W)$ (由条件方差公式 $\text{Var}(W) = E[\text{Var}(W | T)] + \text{Var}(E[W | T])$)。

(b) 计算 $W^* = E[X_1 | T = t]$

给定 $T = \sum_{i=1}^n X_i = t$, 由对称性每个 X_i 在条件下具有相同分布:

$$E[X_1 | T = t] = \frac{E\left[\sum_{i=1}^n X_i \mid T = t\right]}{n} = \frac{t}{n}.$$

严格推导: $P(X_1 = 1 | T = t) = \frac{P(X_1 = 1, \sum_{i=2}^n X_i = t - 1)}{P(T = t)} = \frac{p \binom{n-1}{t-1} p^{t-1} (1-p)^{n-t}}{\binom{n}{t} p^t (1-p)^{n-t}} = \frac{t}{n}.$

(c) $W^* = t/n = \bar{X}$ 是 UMVUE

$T = \sum X_i$ 是 $\text{Bernoulli}(p)$ 的完备充分统计量 (指数族), $W^* = T/n = \bar{X}$ 是 p 的无偏估计, 由 Lehmann-Scheffé 定理, 完备充分统计量的无偏函数是 UMVUE, 故 $\bar{X}$ 是 p 的 UMVUE。

答案: $W^* = E[X_1 | T = t] = t/n$; $\boxed{\bar{X} = T/n}$ 是 p 的 UMVUE。

E 提高题详解 (5 题)**E.5.1 (Ch.13+Ch.15, 完备充分统计量 + Lehmann-Scheffé + UMVUE)**

题目: $X_i \stackrel{iid}{\sim} \text{Poisson}(\lambda)$, (a) $T = \sum X_i$ 充分; (b) T 完备; (c) $e^{-\lambda}$ 的 UMVUE; (d) 推广。

思路: 充分性用因子分解, 完备性用指数族参数空间, UMVUE 由 Lehmann-Scheffé 定理给出。

解:

(a) $T = \sum X_i$ 是充分统计量

联合 PMF:

$$\prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} = \underbrace{e^{-n\lambda} \lambda^T}_{g(T, \lambda)} \cdot \underbrace{\left(\prod_{i=1}^n x_i! \right)^{-1}}_{h(\mathbf{x})}.$$

由 Neyman-Fisher 因子分解定理, $T = \sum X_i$ 是 λ 的充分统计量。

(b) T 完备

$T \sim \text{Poisson}(n\lambda)$, 其 PMF 为 $P(T = t) = e^{-n\lambda} (n\lambda)^t / t!$ 。

设 $E_\lambda[g(T)] = 0$ 对所有 $\lambda > 0$ 成立, 即

$$\sum_{t=0}^{\infty} g(t) \frac{(n\lambda)^t}{t!} = 0 \quad \forall \lambda > 0.$$

令 $u = n\lambda > 0$, 上式变为 $\sum_{t=0}^{\infty} \frac{g(t)}{t!} u^t = 0$ 对所有 $u > 0$ 成立。幂级数系数恒为零, 故 $g(t) = 0$ 对所有 $t \geq 0$ 成立, 即 $g \equiv 0$ a.e. T 完备。

(c) $e^{-\lambda}$ 的 UMVUE

由 Lehmann-Scheffé 定理: 完备充分统计量 T 的无偏函数是 UMVUE。

设初始无偏估计 $W = \mathbf{1}[X_1 = 0]$, 则 $E_\lambda[W] = P(X_1 = 0) = e^{-\lambda}$, 故 W 是 $e^{-\lambda}$ 的无偏估计。

构造 Rao-Blackwell 改进:

$$\varphi(T) = E[W \mid T = t] = P(X_1 = 0 \mid T = t).$$

给定 $T = t$, X_1 在条件下的分布:

$$P(X_1 = 0 \mid T = t) = \frac{P(X_1 = 0)P(\sum_{i=2}^n X_i = t)}{P(T = t)} = \frac{e^{-\lambda} \cdot e^{-(n-1)\lambda} \frac{[(n-1)\lambda]^t}{t!}}{e^{-n\lambda} \frac{(n\lambda)^t}{t!}} = \left(\frac{n-1}{n} \right)^t.$$

故 $e^{-\lambda}$ 的 UMVUE 为

$$\varphi(T) = \left(1 - \frac{1}{n} \right)^T = \left(1 - \frac{1}{n} \right)^{\sum_{i=1}^n X_i}.$$

(d) 推广: $P(X = k) = \lambda^k e^{-\lambda} / k!$ 的 UMVUE

取初始无偏估计 $W_k = \mathbf{1}[X_1 = k]$, 条件化:

$$\varphi_k(t) = P(X_1 = k | T = t) = \frac{P(X_1 = k)P(\sum_{i=2}^n X_i = t - k)}{P(T = t)}.$$

类似计算给出

$$\varphi_k(t) = \binom{t}{k} \left(\frac{1}{n}\right)^k \left(1 - \frac{1}{n}\right)^{t-k}, \quad t \geq k.$$

这是 $P(X = k) = \lambda^k e^{-\lambda} / k!$ 的 UMVUE。完备性保证唯一性: 若存在两个完备充分统计量的无偏函数, 其差的期望为 0, 由完备性差为 0 a.s., 故 UMVUE 唯一。

答案: $e^{-\lambda}$ 的 UMVUE 为 $\varphi(T) = (1 - 1/n)^T$; $P(X = k)$ 的 UMVUE 为 $\binom{T}{k} (1/n)^k (1 - 1/n)^{T-k}$ 。

E.5.2 (Ch.14+Ch.13, 经验分布函数 + Glivenko-Cantelli + 非参数估计)

题目: 证明 $\hat{F}_n$ 的矩; 证明 Glivenko-Cantelli; 推导 KDE 最优带宽; 与 GAN 联系。

思路: 期望方差由 Bernoulli 分布直接得; G-C 定理先处理有限个点再用单调性延拓; KDE 偏差-方差权衡给出 $h^* \sim n^{-1/5}$ 。

解:

(a) $\hat{F}_n$ 的期望与方差

固定 x , $I_i = \mathbf{1}[X_i \leq x] \stackrel{iid}{\sim} \text{Bernoulli}(F(x))$, $\hat{F}_n(x) = \bar{I}$ 。

$$\begin{aligned} E[\hat{F}_n(x)] &= E[I_1] = F(x), \\ \text{Var}(\hat{F}_n(x)) &= \frac{\text{Var}(I_1)}{n} = \frac{F(x)(1 - F(x))}{n}. \end{aligned}$$

(b) Glivenko-Cantelli 定理证明思路

步骤 1 (有限点): 对任意固定有限集 $\{x_1, \dots, x_m\}$, 由 SLLN 和有限并集,

$$\max_{j=1}^m |\hat{F}_n(x_j) - F(x_j)| \xrightarrow{a.s.} 0.$$

步骤 2 (全局延拓): 固定 $\varepsilon > 0$, 选取有限分割点 $-\infty = t_0 < t_1 < \dots < t_m = \infty$ 使得 $F(t_j) - F(t_{j-1}) < \varepsilon/2$ 对所有 j 。对任意 $x \in [t_{j-1}, t_j]$:

$$\hat{F}_n(x) \leq \hat{F}_n(t_j^-); \quad F(x) \geq F(t_{j-1}).$$

利用 $\hat{F}_n$ 和 F 的单调性及分割点的一致收敛, 可以证明

$$\sup_x |\hat{F}_n(x) - F(x)| < \varepsilon \quad \text{eventually a.s.}$$

由 ε 的任意性, $\sup_x |\hat{F}_n(x) - F(x)| \xrightarrow{a.s.} 0$ 。

(c) KDE 最优带宽 $h^* \sim n^{-1/5}$

核密度估计 $\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x-X_i}{h}\right)$, 其偏差与方差为 (设 K 为对称核, $\int u^2 K(u) du = \kappa_2$):

$$\text{Bias}[\hat{f}_h(x)] \approx \frac{h^2}{2} \kappa_2 f''(x), \quad \text{Var}[\hat{f}_h(x)] \approx \frac{f(x) \|K\|_2^2}{nh}.$$

积分均方误差 (MISE):

$$\text{MISE}(h) \approx \frac{h^4}{4} \kappa_2^2 \int [f''(x)]^2 dx + \frac{\|K\|_2^2}{nh}.$$

对 h 求导并令其为 0:

$$h^4 \kappa_2^2 R(f'') \cdot h^{-1} \cdot \frac{d}{dh}(h^4) = \frac{\|K\|_2^2}{nh^2} \cdot h \implies h^* = \left(\frac{\|K\|_2^2}{n \kappa_2^2 R(f'')} \right)^{1/5} \sim n^{-1/5},$$

其中 $R(f'') = \int [f''(x)]^2 dx$ 。偏差 $\sim h^2 \sim n^{-2/5}$, 方差 $\sim (nh)^{-1} \sim n^{-4/5}$, $\text{MISE} \sim n^{-4/5}$ 。

(d) KDE vs GAN (高维分析)

- KDE 在低维稳定: 带宽选择有明确准则 ($h^* \sim n^{-1/5}$), 估计量有理论保证, 训练前期可解释性强。
- 维数诅咒: KDE 的 MISE 在 d 维下变为 $O(n^{-4/(4+d)})$, 当 d 大时收敛极慢 (如 $d = 100$ 时几乎无效)。
- GAN 的优势: 生成器直接学习低维流形上的分布, 隐式地利用数据的低维结构, 规避了高维密度估计的维数诅咒; 但训练不稳定, 可能模式崩塌。
- 理论联系: GAN 的判别器在最优时估计 JS 散度 (或 Wasserstein 距离), 这等价于非参数密度比估计, Glivenko-Cantelli 保证经验分布收敛, 但高维下速度过慢, GAN 用神经网络参数化规避了这一问题。

答案: 最优带宽 $\boxed{h^* \sim n^{-1/5}}$; $\text{MISE} \sim n^{-4/5}$; 高维时 KDE 受维数诅咒, GAN 通过学习低维流形规避该问题。

E.5.3 (Ch.15+Ch.16, 充分统计量 + Fisher 信息 + Cramér-Rao 下界)

题目: $X_i \stackrel{iid}{\sim} N(\mu, \sigma^2)$ (σ^2 已知), Fisher 信息、C-R 下界、Delta 方法、自然梯度。

思路: 单个观测的 Fisher 信息乘以 n ; 验证 $\bar{X}$ 方差达到下界; Delta 方法处理参数变换; Fisher 矩阵与参数空间曲率联系自然梯度。

解:

(a) Fisher 信息与 C-R 下界

单个观测的对数似然: $\ell(\mu; x) = -\frac{(x-\mu)^2}{2\sigma^2} + \text{const}$, 得分函数 $s(\mu; x) = \frac{x-\mu}{\sigma^2}$ 。

$$\mathcal{J}_1(\mu) = E_\mu[s^2] = E_\mu\left[\frac{(X-\mu)^2}{\sigma^4}\right] = \frac{\sigma^2}{\sigma^4} = \frac{1}{\sigma^2}.$$

n 个独立观测: $\mathcal{J}_n(\mu) = n/\sigma^2$ 。Cramér-Rao 下界:

$$\text{Var}_\mu(\hat{\mu}) \geq \frac{1}{\mathcal{J}_n(\mu)} = \frac{\sigma^2}{n}.$$

(b) $\bar{X}$ 达到 C-R 下界

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n} = \frac{1}{\mathcal{J}_n(\mu)}.$$

等号成立, $\bar{X}$ 是有效估计量 (efficient estimator)。事实上, $\bar{X}$ 是充分统计量且是指数族的自然参数的线性函数, 因此自动达到 C-R 下界。

(c) $\phi = e^\mu$ 的 Delta 方法与 C-R 下界

$\hat{\phi} = e^{\bar{X}}$, $g(\mu) = e^\mu$, $g'(\mu) = e^\mu$ 。Delta 方法给出渐近分布:

$$\sqrt{n}(\hat{\phi} - \phi) \xrightarrow{d} N(0, [g'(\mu)]^2 \cdot \sigma^2) = N(0, e^{2\mu}\sigma^2).$$

即 $\hat{\phi} \approx N(e^\mu, \frac{e^{2\mu}\sigma^2}{n})$ (渐近)。

$\phi = g(\mu)$ 的 C-R 下界:

$$\text{Var}(\hat{\phi}) \geq \frac{[g'(\mu)]^2}{\mathcal{J}_n(\mu)} = \frac{e^{2\mu}\sigma^2}{n}.$$

$\hat{\phi} = e^{\bar{X}}$ 渐近达到此下界, 是 e^μ 的渐近有效估计量。

(d) Fisher 信息矩阵与自然梯度

在深度学习中, 参数 $\theta \in \mathbb{R}^d$ 的 Fisher 信息矩阵 $\mathcal{J}(\theta)_{jk} = E\left[\frac{\partial \log p}{\partial \theta_j} \frac{\partial \log p}{\partial \theta_k}\right]$ 度量参数空间的局部几何曲率 (黎曼度量)。

- 标准梯度下降: 沿参数空间欧氏梯度方向更新, 忽略参数化的曲率, 在不同方向上学习率等效不同, 收敛慢。
- 自然梯度下降: 沿 $\mathcal{J}^{-1}\nabla_\theta \mathcal{L}$ 方向更新 (Fisher-Rao 度量下的最速下降), 对参数重参数化不变, 收敛快。
- 对角近似 (Adagrad 类): $\mathcal{J} \approx \text{diag}(I_{11}, \dots, I_{dd})$, 计算 $O(d)$, 忽略参数间相关性。
- 完整矩阵 (K-FAC): Kronecker 分解近似 $\mathcal{J}$, 计算 $O(d^3/2)$, 捕捉层间相关性, 通常效果更好但开销更大。

答案: $\mathcal{J}_n(\mu) = n/\sigma^2$; C-R 下界 σ^2/n ; $\bar{X}$ 有效; $\hat{\phi} = e^{\bar{X}}$ 渐近 $N(e^\mu, e^{2\mu}\sigma^2/n)$; Fisher 矩阵为黎曼度量, 自然梯度对参数化不变。 $\text{Var}(\bar{X}) = \sigma^2/n = 1/\mathcal{J}_n(\mu)$

E.5.4 (Ch.13+Ch.15, 指数族 + 最大熵原理 + 对偶性)

题目: 变分法证明最大熵分布为指数族; 均值方差约束 $\Rightarrow$ 正态; $[0, 1]$ 均值约束 $\Rightarrow$ Beta; 温度采样。

思路: 用 Lagrange 乘数法处理约束优化; 正态是均值 + 方差约束下最大熵分布; Beta 是有界支撑均值约束下最大熵分布 (特例为均匀)。

解:

(a) 最大熵分布为指数族 (变分推导)

最大化 $H(p) = -\int p(x) \log p(x) dx$, 约束条件:

$$\int p(x) dx = 1, \quad \int p(x) T_k(x) dx = \mu_k, \quad k = 1, \dots, m.$$

引入 Lagrange 乘子 $\eta_0 - 1$ (归一化) 和 η_k ($k = 1, \dots, m$), Lagrangian 为

$$\mathcal{L} = \int \left[-p \log p + (\eta_0 - 1)p + \sum_k \eta_k T_k p \right] dx.$$

对 $p(x)$ 变分, 令 $\delta \mathcal{L} / \delta p = 0$:

$$\begin{aligned} -\log p(x) - 1 + (\eta_0 - 1) + \sum_k \eta_k T_k(x) &= 0 \\ \Rightarrow p^*(x) &= \exp \left(\sum_k \eta_k T_k(x) + (\eta_0 - 2) \right) = h(x) \exp \left(\sum_k \eta_k T_k(x) - A(\eta) \right), \end{aligned}$$

其中 $A(\eta) = \log \int \exp(\sum_k \eta_k T_k) dx$ 是对数配分函数, $h(x) = 1$ (或其他基测度)。这正是指数族形式。

(b) 均值 + 方差约束 $\Rightarrow$ 正态分布

约束: $E[X] = \mu$, $E[X^2] = \mu^2 + \sigma^2$ (即方差 $= \sigma^2$), 充分统计量 $T_1 = x$, $T_2 = x^2$ 。

由 (a), 最大熵分布为

$$p^*(x) \propto \exp(\eta_1 x + \eta_2 x^2).$$

由约束解出乘子: $\eta_2 = -1/(2\sigma^2) < 0$ (使分布可归一化), $\eta_1 = \mu/\sigma^2$, 得

$$p^*(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) = N(\mu, \sigma^2).$$

(c) $[0, 1]$ 均值约束 $\Rightarrow$ Beta 分布

支撑 $[0, 1]$, 约束 $E[X] = \mu$, 基测度 $h(x) = 1$, 充分统计量 $T_1 = \log x$, $T_2 = \log(1-x)$ (由于 $[0, 1]$ 的指数族结构)。

最大熵分布为

$$p^*(x) \propto \exp(\eta_1 \log x + \eta_2 \log(1-x)) = x^{\eta_1} (1-x)^{\eta_2},$$

即 $\text{Beta}(\alpha, \beta)$ ($\alpha = \eta_1 + 1$, $\beta = \eta_2 + 1$)。当 $\mu = 0.5$ 时对称, $\alpha = \beta$, 最大熵为均匀分布 $\text{Beta}(1, 1) = U(0, 1)$ 。

□ 严格地, $[0, 1]$ 上仅约束均值 $E[X] = \mu$ 不直接给出 Beta 分布; 若额外约束 $E[\log X]$ 和 $E[\log(1-X)]$, 则最大熵分布才是 Beta 分布。均匀分布是 $\mu = 0.5$ 、无其他矩约束时的最大熵分布。

(d) 温度采样与最大熵

温度采样: $p_T(x) \propto p(x)^{1/T}$, 对数形式 $\log p_T(x) = \frac{1}{T} \log p(x) - \log Z_T$ 。

- $T \rightarrow 0$ (贪心解码): p_T 集中于 $\arg \max p(x)$, 熵 $H(p_T) \rightarrow 0$;
- $T = 1$ (标准采样): $p_T = p$, 原始分布;
- $T \rightarrow \infty$ (均匀采样): $p_T \rightarrow \text{Uniform}$, 熵最大化;
- 最大熵联系: 在约束 $E_T[\log p(x)] = c_T$ (给定平均对数概率) 下, 最大熵分布恰为 $p_T(x) \propto p(x)^{1/T}$, 即温度采样是约束最大熵问题的解, T 为对偶变量 (Lagrange 乘子)。

答案: 最大熵分布为指数族 $p^* \propto \exp\left(\sum_k \eta_k T_k(x)\right)$; 均值 + 方差约束 $\Rightarrow N(\mu, \sigma^2)$; T 为最大熵的对偶变量, $T \rightarrow 0$ 贪心, $T \rightarrow \infty$ 均匀。

E.5.5 (Ch.13+Ch.14+Ch.15, 次序统计量 + 分位数估计 + 鲁棒统计)

题目: 分位数渐近正态; 中位数 ARE; 影响函数; 联邦学习鲁棒性。

思路: 分位数的渐近正态性通过顺序统计量密度的极限论证; ARE 比较两个渐近方差; 影响函数度量单点污染的一阶效应; breakdown point 量化估计量的全局鲁棒性。

解:

(a) 样本 p -分位数的渐近正态性

令 $\hat{\xi}_p = X_{([np])}$, $\xi_p = F^{-1}(p)$ 。

核心思路: $\{\hat{\xi}_p \leq x\} = \{X_{([np])} \leq x\} = \{\text{至少 } [np] \text{ 个 } X_i \leq x\} = \{\hat{F}_n(x) \geq p\}$, 故

$$P(\hat{\xi}_p \leq \xi_p + t/\sqrt{n}) = P(\hat{F}_n(\xi_p + t/\sqrt{n}) \geq p).$$

在 $x = \xi_p$ 附近展开: $F(\xi_p + t/\sqrt{n}) \approx p + tf(\xi_p)/\sqrt{n}$, 且 $n\hat{F}_n(x) \sim B(n, F(x))$, 由 CLT:

$$\sqrt{n}(\hat{F}_n(x) - F(x)) \xrightarrow{d} N(0, F(x)(1 - F(x))).$$

结合连续映射定理 (对分位数函数):

$$\sqrt{n}(\hat{\xi}_p - \xi_p) \xrightarrow{d} N\left(0, \frac{p(1-p)}{[f(\xi_p)]^2}\right).$$

(b) 中位数的渐近方差与 ARE

$p = 0.5$, $\xi_{0.5} = m$ (真实中位数), 渐近方差 = $\frac{0.25}{[f(m)]^2 \cdot n}$.

对 $F = N(\mu, \sigma^2)$: $f(m) = f(\mu) = \frac{1}{\sqrt{2\pi}\sigma}$, 故

$$\text{AsyVar}(\hat{m}) = \frac{0.25}{[1/(\sqrt{2\pi}\sigma)]^2 \cdot n} = \frac{\pi\sigma^2}{2n}.$$

样本均值渐近方差 = σ^2/n 。渐近相对效率:

$$\text{ARE}(\hat{m}, \bar{X}) = \frac{\sigma^2/n}{\pi\sigma^2/(2n)} = \frac{2}{\pi} \approx 0.637.$$

含义: 在正态分布下, 用中位数估计均值需要约 $\pi/2 \approx 1.57$ 倍的样本量才能达到与均值相同的精度。

(c) 影响函数

$$\text{IF}(x; T, F) = \lim_{\varepsilon \rightarrow 0} \frac{T((1-\varepsilon)F + \varepsilon\delta_x) - T(F)}{\varepsilon}.$$

- 均值 $T(F) = \int y dF(y)$: $T((1-\varepsilon)F + \varepsilon\delta_x) = (1-\varepsilon)\mu + \varepsilon x$, 故 $\text{IF}(x; \text{mean}, F) = x - \mu$ (无界, 不鲁棒)。
- 中位数 $T(F) = F^{-1}(0.5)$: 扰动后中位数满足 $F_\varepsilon(m_\varepsilon) = 0.5$, 对 ε 求导, 利用隐函数定理:

$$\text{IF}(x; \text{median}, F) = \frac{\text{sgn}(x - m)}{2f(m)}$$

有界 ($|\text{IF}| \leq 1/(2f(m))$), 鲁棒。

- **M** 估计量 T 满足 $\int \psi(y - T) dF(y) = 0$: $\text{IF}(x; T, F) = \frac{\psi(x - T)}{\int \psi'(y - T) dF(y)}$; 当 ψ 有界 (如 Huber) 时 IF 有界, 具有鲁棒性。

(d) 联邦学习与 Byzantine 鲁棒性

在联邦学习中, n 个客户端提交本地梯度 $g_1, \dots, g_n$, 部分 (设 ϵ 比例) 被 Byzantine 攻击者控制。

- **FedAvg** (均值聚合): $\bar{g} = \frac{1}{n} \sum g_i$, 由于均值的影响函数 $\text{IF}(x) = x - \mu$ 无界, 攻击者可以将 g_i 设为任意大值, 无限偏移聚合结果, **breakdown point** = 0 (任意一个恶意客户端即可破坏)。
- **坐标中位数 (Coordinate-wise Median)**: 对每个坐标独立取中位数, 其影响函数有界, 单个恶意梯度的影响不超过 $1/(2f(m))$ 。**Breakdown point** = 50%: 只要恶意客户端比例 $< 50\%$, 聚合结果有界偏离, 攻击者无法任意操纵全局更新。

用影响函数理论量化: 设攻击者控制 ϵn 个客户端, 发送恶意梯度 g_{attack} , 则坐标中位数的偏移量为

$$\Delta T \approx \epsilon \cdot \text{IF}(g_{\text{attack}}; \text{median}, F) \leq \frac{\epsilon}{2f(m)} < \infty,$$

而均值聚合偏移量 $\Delta \bar{g} \propto \epsilon \cdot \|g_{\text{attack}}\|$ 随攻击强度无界增长。

答案: 分位数渐近分布 $\sqrt{n}(\hat{\xi}_p - \xi_p) \xrightarrow{d} N\left(0, \frac{p(1-p)}{f(\xi_p)^2}\right)$; $\text{ARE}(\hat{m}, \bar{X}) = 2/\pi \approx 0.637$; 均值 IF 无界, 中位数 IF 有界; 中位数聚合 **breakdown point** = 50%, 远优于 FedAvg (**breakdown point** = 0)。

F5 详解: Part 6 估计 (Ch.16-18, 共 34 题)

C 基础题详解 (10 题)

C.6.1 (Ch.16, 矩估计)

题目: $X \sim U(0, \theta)$, $E[X] = \theta/2$, 用矩估计法求 $\hat{\theta}_{\text{MOM}}$, 并当 $\bar{x} = 4.2$ 时给出数值。

思路: 令样本一阶矩等于总体一阶矩, 解出参数。

解:

令 $\bar{X} = E[X] = \theta/2$, 解得

$$\hat{\theta}_{\text{MOM}} = 2\bar{X}$$

当 $\bar{x} = 4.2$ 时:

$$\hat{\theta} = 2 \times 4.2 = 8.4$$

答案: $\hat{\theta}_{\text{MOM}} = 2\bar{X} = 8.4$

C.6.2 (Ch.16, MLE——伯努利分布)

题目: $X_i \stackrel{iid}{\sim} \text{Bernoulli}(p)$, 共 n 个样本, k 次成功, 求 $\hat{p}_{\text{MLE}}$ 。

思路: 写似然 $\rightarrow$ 取对数 $\rightarrow$ 对 p 求导令为 0 $\rightarrow$ 解 $\rightarrow$ 验证极大。

解:

第一步: 写似然函数

$$L(p) = p^k(1-p)^{n-k}$$

第二步: 取对数似然

$$\ell(p) = k \log p + (n-k) \log(1-p)$$

第三步: 对 p 求导令为 0

$$\frac{d\ell}{dp} = \frac{k}{p} - \frac{n-k}{1-p} = 0$$

$$k(1-p) = (n-k)p \implies k = np$$

第四步: 解并验证极大

$$\hat{p}_{\text{MLE}} = \frac{k}{n}$$

二阶导 $d^2\ell/dp^2 = -k/p^2 - (n-k)/(1-p)^2 < 0$, 确为极大值。

答案: $\boxed{\hat{p}_{\text{MLE}} = k/n}$ (即样本成功比例)

C.6.3 (Ch.16, MLE——指数分布)

题目: $X_i \stackrel{iid}{\sim} \text{Exp}(\lambda)$, 求 $\hat{\lambda}_{\text{MLE}}$ 。

思路: 写对数似然 $\rightarrow$ 求导 $\rightarrow$ 解方程 $\rightarrow$ 验证极大。

解:

第一步: 写对数似然

$$\ell(\lambda) = \sum_{i=1}^n \log(\lambda e^{-\lambda x_i}) = n \log \lambda - \lambda \sum_{i=1}^n x_i$$

第二步: 对 λ 求导令为 0

$$\frac{d\ell}{d\lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0$$

第三步: 解

$$\hat{\lambda}_{\text{MLE}} = \frac{n}{\sum x_i} = \frac{1}{\bar{x}}$$

第四步: 验证极大: $d^2\ell/d\lambda^2 = -n/\lambda^2 < 0$, 确为极大值。

答案: $\boxed{\hat{\lambda}_{\text{MLE}} = 1/\bar{X}}$

C.6.4 (Ch.16, 无偏性验证)

题目: $X_1, \dots, X_n$ i.i.d., $E[X_i] = \mu$, $\text{Var}(X_i) = \sigma^2$ 。证明 $\bar{X}$ 是 μ 的无偏估计, 并计算 $\text{Var}(\bar{X})$ 。

思路: 利用期望和方差的线性性质。

解:

(1) 无偏性:

$$E[\bar{X}] = E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{1}{n} \cdot n\mu = \mu$$

故 $\bar{X}$ 是 μ 的无偏估计量。

(2) 方差:

由于 $X_1, \dots, X_n$ 独立:

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}$$

答案: $E[\bar{X}] = \mu$ (无偏), $\text{Var}(\bar{X}) = \boxed{\sigma^2/n}$

C.6.5 (Ch.17, 正态均值置信区间——方差已知)

题目: $X \sim N(\mu, 4)$, $n = 16$, $\bar{x} = 12.5$, $\sigma^2 = 4$ 已知, 构造 95% CI。

思路: 方差已知用 z 分布, 枢轴量 $(\bar{X} - \mu)/(\sigma/\sqrt{n}) \sim N(0, 1)$ 。

解:

(1) 枢轴量:

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} = \frac{\bar{X} - \mu}{2/4} = \frac{\bar{X} - \mu}{0.5} \sim N(0, 1)$$

由 $P(-1.96 \leq Z \leq 1.96) = 0.95$, 得置信区间

$$\bar{X} \pm z_{0.025} \cdot \frac{\sigma}{\sqrt{n}}$$

(2) 代入数值: $\sigma/\sqrt{n} = 2/4 = 0.5$

$$[12.5 - 1.96 \times 0.5, 12.5 + 1.96 \times 0.5] = [12.5 - 0.98, 12.5 + 0.98]$$

答案: [11.52, 13.48]

C.6.6 (Ch.17, 正态均值置信区间——方差未知)

题目: $X \sim N(\mu, \sigma^2)$, σ^2 未知, $n = 10$, $\bar{x} = 5.0$, $s = 2.0$, 求 95% CI。

思路: 方差未知用 t 分布, 枢轴量服从 $t(n-1)$ 。

解:

(1) 枢轴量及其分布:

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1) = t(9)$$

(2) 置信区间:

$$\bar{x} \pm t_{0.025}(9) \cdot \frac{s}{\sqrt{n}} = 5.0 \pm 2.262 \times \frac{2.0}{\sqrt{10}} = 5.0 \pm 2.262 \times 0.6325$$

$$= 5.0 \pm 1.430$$

答案: $[3.57, 6.43]$

□ 方差未知时必须用 t 分布, 自由度为 $n - 1 = 9$, 不能用 $z_{0.025} = 1.96$ 。

C.6.7 (Ch.17, 样本量与置信区间宽度)

题目: $\sigma^2 = 100$, 希望均值 95% CI 半宽 $\leq E_0 = 2$, 求最小样本量 n 。

思路: 半宽公式 $E = z_{0.025} \cdot \sigma / \sqrt{n}$, 令 $E \leq 2$ 解 n 。

解:

(1) 不等式:

$$z_{0.025} \cdot \frac{\sigma}{\sqrt{n}} \leq 2 \implies 1.96 \times \frac{10}{\sqrt{n}} \leq 2$$

(2) 解 n :

$$\sqrt{n} \geq \frac{1.96 \times 10}{2} = 9.8 \implies n \geq 9.8^2 = 96.04$$

取整数, $n_{\min} = 97$ 。

答案: $n_{\min} = 97$

C.6.8 (Ch.18, 贝叶斯更新——Beta-二项共轭)

题目: 先验 $p \sim \text{Beta}(2, 2)$, 观测 10 次试验 7 次正面, 求后验分布参数及后验均值。

思路: 直接应用 Beta-Binomial 共轭公式: 后验参数 = 先验参数 + 数据计数。

解:

(1) 后验参数:

先验 $\text{Beta}(\alpha, \beta) = \text{Beta}(2, 2)$, $k = 7$, $n - k = 3$:

$$\alpha' = \alpha + k = 2 + 7 = 9, \quad \beta' = \beta + (n - k) = 2 + 3 = 5$$

后验: $p \mid \text{数据} \sim \text{Beta}(9, 5)$

(2) 后验均值:

$$E[p \mid \text{数据}] = \frac{\alpha'}{\alpha' + \beta'} = \frac{9}{9 + 5} = \frac{9}{14} \approx 0.643$$

答案: 后验 Beta(9, 5), 后验均值 $\boxed{9/14 \approx 0.643}$

C.6.9 (Ch.18, MAP 估计 vs MLE)

题目: 延续 C.6.8 设定 (先验 Beta(2, 2), 10 次试验 7 次正面), 比较 MLE 与 MAP。

思路: MLE 只看数据; MAP 利用后验众数公式。

解:

(1) MLE:

$$\hat{p}_{\text{MLE}} = \frac{k}{n} = \frac{7}{10} = 0.7$$

(2) MAP:

后验 Beta(9, 5), 众数公式:

$$\hat{p}_{\text{MAP}} = \frac{\alpha' - 1}{\alpha' + \beta' - 2} = \frac{9 - 1}{9 + 5 - 2} = \frac{8}{12} = \frac{2}{3} \approx 0.667$$

(3) 比较: MAP 更接近 0.5, 因为先验 Beta(2, 2) 以 0.5 为中心, 对估计施加了向均值收缩的正则化效果。

答案: $\hat{p}_{\text{MLE}} = 0.7$, $\hat{p}_{\text{MAP}} = \boxed{2/3 \approx 0.667}$, MAP 更接近 0.5。

C.6.10 (Ch.18, 可信区间 vs 置信区间)

题目: 辨析贝叶斯可信区间与频率置信区间的含义。

思路: 两者在概率的主体上不同: 前者对参数, 后者对区间 (随机量)。

解:

(1) 贝叶斯 95% 可信区间: 给定观测数据, 参数 θ 落在该区间内的后验概率为 95%, 即 $P(\theta \in [l, u] \mid \text{data}) = 0.95$ 。

(2) 频率 95% 置信区间: 若重复进行大量相同实验并每次计算置信区间, 约 95% 的区间会覆盖真参数; 对单次实验, 参数要么在该区间内要么不在, 不存在“概率 95%”一说。

(3) 正确说法: 选 (B) ——“若重复实验, 95% 的区间会覆盖真参数”。

说法 (A) 混淆了贝叶斯和频率框架, 在频率论中参数是固定常数, 不能赋予概率。

答案: (B)

D 中等题详解 (14 题)

D.6.1 (Ch.16, 矩估计法)

题目: $X_i \stackrel{iid}{\sim} \text{Gamma}(\alpha, \beta)$, 均值 α/β , 方差 α/β^2 , 分别用两种矩方程组求 $\hat{\alpha}, \hat{\beta}$ 。

思路: (a) 用一、二阶矩; (b) 用均值和样本方差, 更简洁。

解:

(a) 用一阶矩和二阶矩

总体矩: $\mu_1 = \alpha/\beta$, $\mu_2 = E[X^2] = \text{Var}(X) + (\mu_1)^2 = \alpha/\beta^2 + \alpha^2/\beta^2 = \alpha(\alpha+1)/\beta^2$

令样本矩等于总体矩:

$$\bar{X} = \frac{\alpha}{\beta}, \quad \overline{X^2} = \frac{\alpha(\alpha+1)}{\beta^2}$$

由第一式 $\beta = \alpha/\bar{X}$, 代入第二式:

$$\overline{X^2} = \frac{\alpha(\alpha+1)\bar{X}^2}{\alpha^2} = \frac{(\alpha+1)\bar{X}^2}{\alpha}$$

解得:

$$\hat{\alpha} = \frac{\bar{X}^2}{\overline{X^2} - \bar{X}^2}, \quad \hat{\beta} = \frac{\bar{X}}{\overline{X^2} - \bar{X}^2}$$

(b) 用均值和样本方差

令 $\bar{X} = \alpha/\beta$, $S^2 = \alpha/\beta^2$:

由 $S^2/\bar{X} = (\alpha/\beta^2) \cdot (\beta/\alpha) = 1/\beta$, 故

$$\hat{\beta} = \frac{\bar{X}}{S^2}, \quad \hat{\alpha} = \bar{X} \cdot \hat{\beta} = \frac{\bar{X}^2}{S^2}$$

(c) 比较两种矩估计

注意 $\overline{X^2} - \bar{X}^2$ 并非无偏的样本方差 (分母为 n 而非 $n-1$), 故 (a) 与 (b) 略有差异。矩估计对矩条件选取不唯一, 选用不同的总体矩会导致不同的估计量, 这体现了矩估计的非唯一性。通常选用方差 (有简洁形式) 为宜。

答案:

$$\hat{\alpha} = \frac{\bar{X}^2}{S^2}, \quad \hat{\beta} = \frac{\bar{X}}{S^2}$$

(方法 b 更简洁)

D.6.2 (Ch.16, 最大似然估计)

题目: $X_i \stackrel{iid}{\sim} \text{Uniform}(0, \theta)$, 求 $\hat{\theta}_{\text{MLE}}$, 分析偏差并构造无偏修正量。

思路: 均匀分布 MLE 不能靠求导 (似然函数在约束边界取极值), 须直接分析似然函数单调性。

解:

(a) 似然函数

$$L(\theta) = \prod_{i=1}^n \frac{1}{\theta} \cdot \mathbf{1}(0 \leq x_i \leq \theta) = \frac{1}{\theta^n} \cdot \mathbf{1}(\theta \geq x_{(n)})$$

其中 $x_{(n)} = \max_i x_i$ 是最大顺序统计量。

(b) 求 MLE

$L(\theta) = 1/\theta^n$ 关于 θ 单调递减, 故在约束 $\theta \geq x_{(n)}$ 下, $L(\theta)$ 在 $\theta = x_{(n)}$ 处取得最大值:

$$\hat{\theta}_{\text{MLE}} = X_{(n)}$$

(c) 偏差与无偏修正

$X_{(n)}$ 的分布: $F_{X_{(n)}}(t) = (t/\theta)^n$ ($0 \leq t \leq \theta$), 密度 $f_{X_{(n)}}(t) = nt^{n-1}/\theta^n$ 。

期望:

$$E[X_{(n)}] = \int_0^\theta t \cdot \frac{nt^{n-1}}{\theta^n} dt = \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1} = \frac{n}{n+1} \theta$$

偏差: $E[X_{(n)}] - \theta = -\theta/(n+1) < 0$, $X_{(n)}$ 系统偏小。

无偏修正:

$$\hat{\theta}^* = \frac{n+1}{n} X_{(n)}$$

验证: $E[\hat{\theta}^*] = \frac{n+1}{n} \cdot \frac{n}{n+1} \theta = \theta$ 。□

答案: $\hat{\theta}_{\text{MLE}} = X_{(n)}$ (有偏), 无偏修正量 $\hat{\theta}^* = \frac{n+1}{n} X_{(n)}$

D.6.3 (Ch.16, MLE 的不变性)

题目: $X_i \stackrel{iid}{\sim} N(\mu, \sigma^2)$, 求 MLE, 利用不变性求 $P(X \leq c)$ 的 MLE, 分析 σ 的 MLE 渐近分布。

思路: 正态分布 MLE 标准结果; 不变性: $g(\hat{\theta}) = g(\hat{\theta})$ 。

解:

(a) μ, σ^2 的 MLE

对数似然:

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum (X_i - \mu)^2$$

对 μ 求偏导令零: $\hat{\mu} = \bar{X}$

对 σ^2 求偏导令零: $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$

□ $\hat{\sigma}^2$ 的分母是 n 不是 $n-1$, 故 MLE 是有偏的 (低估总体方差)。

(b) $P(X \leq c)$ 的 MLE

由 MLE 不变性:

$$P(\widehat{X} \leq c) = \Phi\left(\frac{c - \hat{\mu}}{\hat{\sigma}}\right) = \Phi\left(\frac{c - \bar{X}}{\hat{\sigma}}\right)$$

其中 $\hat{\sigma} = \sqrt{\hat{\sigma}^2}$ 。

(c) σ^2 的 MLE 渐近分布与 CRB

Fisher 信息量 (单个样本, 关于 σ^2):

$$I_1(\sigma^2) = \frac{1}{2\sigma^4}$$

故 n 个样本时 $I(\sigma^2) = n/(2\sigma^4)$, CRB 为 $2\sigma^4/n$ 。

由 MLE 渐近理论:

$$\sqrt{n}(\hat{\sigma}^2 - \sigma^2) \xrightarrow{d} N(0, 2\sigma^4)$$

即 $\hat{\sigma}^2$ 渐近有效 (渐近方差达到 CRB)。

答案: $\hat{\mu} = \bar{X}$, $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$, $P(\widehat{X} \leq c) = \Phi\left(\frac{c - \bar{X}}{\hat{\sigma}}\right)$, 渐近方差 $\boxed{2\sigma^4/n}$

D.6.4 (Ch.16, Cramér-Rao 下界)

题目: $X_i \stackrel{iid}{\sim} \text{Poisson}(\lambda)$, 验证 $\bar{X}$ 达到 CRB, 故为有效估计量。

思路: 计算单样本 Fisher 信息 $\rightarrow$ CRB $\rightarrow$ 与 $\text{Var}(\bar{X})$ 比较。

解:

(a) 单个样本 Fisher 信息量

$$\log f(x; \lambda) = x \log \lambda - \lambda - \log(x!)$$

$$\frac{\partial \log f}{\partial \lambda} = \frac{x}{\lambda} - 1, \quad \frac{\partial^2 \log f}{\partial \lambda^2} = -\frac{x}{\lambda^2}$$

$$I_1(\lambda) = -E\left[\frac{\partial^2 \log f}{\partial \lambda^2}\right] = \frac{E[X]}{\lambda^2} = \frac{\lambda}{\lambda^2} = \frac{1}{\lambda}$$

(b) CRB

n 个独立样本, Fisher 信息 $I(\lambda) = n/\lambda$ 。 λ 的任意无偏估计量满足:

$$\text{Var}(\hat{\lambda}) \geq \frac{1}{I(\lambda)} = \frac{\lambda}{n}$$

(c) $\bar{X}$ 是有效估计量

$\bar{X}$ 是 λ 的无偏估计 ($E[\bar{X}] = \lambda$), 且由独立性:

$$\text{Var}(\bar{X}) = \frac{\text{Var}(X_1)}{n} = \frac{\lambda}{n}$$

恰好等于 CRB, 因此 $\bar{X}$ 是有效估计量 (UMVUE)。

答案: $\text{CRB} = \lambda/n$, $\text{Var}(\bar{X}) = \lambda/n$, 两者相等, 故 $\bar{X}$ 有效。 $\boxed{\bar{X} \text{ 达到 CRB, 为有效估计量}}$

D.6.5 (Ch.17, 单正态均值的区间估计)

题目: $n = 25$, $\bar{X} = 12.3$, $S = 2.4$, σ 未知。(a) t 分布 CI; (b) 已知 $\sigma = 2.5$ 时 z 分布 CI; (c) 讨论宽度随 n 的变化。

思路: σ 未知用 $t(n-1)$; σ 已知用 z ; 宽度正比于 $1/\sqrt{n}$ 。

解:

(a) σ 未知, $t(24)$ CI

$$\bar{X} \pm t_{0.025}(24) \cdot \frac{S}{\sqrt{n}} = 12.3 \pm 2.064 \times \frac{2.4}{\sqrt{25}} = 12.3 \pm 2.064 \times 0.48 = 12.3 \pm 0.991$$

$$\Rightarrow [11.309, 13.291]$$

(b) $\sigma = 2.5$ 已知, z CI

$$\bar{X} \pm z_{0.025} \cdot \frac{\sigma}{\sqrt{n}} = 12.3 \pm 1.96 \times \frac{2.5}{5} = 12.3 \pm 1.96 \times 0.5 = 12.3 \pm 0.98$$

$$\Rightarrow [11.32, 13.28]$$

z CI 宽度 1.96, t CI 宽度 1.982, σ 已知时略窄 (因为 t 分布比标准正态有更厚的尾部)。

(c) 宽度随 n 的变化

CI 宽度 $\propto 1/\sqrt{n}$ 。若要宽度减半, 需使 $1/\sqrt{n}$ 缩减为原来的 $1/2$, 即 n 增加至原来的 4 倍。

答案: (a) $[11.31, 13.29]$; (b) $[11.32, 13.28]$; (c) 宽度 $\propto 1/\sqrt{n}$, 宽度减半需 4 倍样本量。

D.6.6 (Ch.17, 方差的区间估计)

题目: $n = 10$, $S^2 = 4.5$, 均值未知, 构造 σ^2 和 σ 的 95% CI, 并解释为何不对称。

思路: 枢轴量 $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$, χ^2 分布不对称。

解:

(a) σ^2 的 95% CI

枢轴量: $Q = (n-1)S^2/\sigma^2 \sim \chi^2(9)$

$$P(\chi_{0.975}^2(9) \leq Q \leq \chi_{0.025}^2(9)) = 0.95$$

注意: $\chi_{0.975}^2(9) = 2.70$ (左分位数), $\chi_{0.025}^2(9) = 19.02$ (右分位数)。

解出 σ^2 :

$$\left[\frac{(n-1)S^2}{\chi_{0.025}^2(9)}, \frac{(n-1)S^2}{\chi_{0.975}^2(9)} \right] = \left[\frac{9 \times 4.5}{19.02}, \frac{9 \times 4.5}{2.70} \right] = \left[\frac{40.5}{19.02}, \frac{40.5}{2.70} \right]$$

$$= [2.13, 15.00]$$

(b) σ 的 95% CI

对两端开根号: $[\sqrt{2.13}, \sqrt{15.00}] = [1.46, 3.87]$

(c) 不对称原因

χ^2 分布本身是非对称的 (偏右), 其两个分位数关于均值不对称, 故方差 CI 两侧到点估计的距离不同。相比之下, 均值 CI 的枢轴量服从 (对称的) t 分布, 故 CI 关于 $\bar{X}$ 对称。

答案: σ^2 的 95% CI = $[2.13, 15.00]$, σ 的 CI = $[1.46, 3.87]$ 。

D.6.7 (Ch.17, 两正态均值差的区间估计)

题目: 两独立样本 (等方差), 构造 $\mu_1 - \mu_2$ 的 95% CI。

思路: 合并方差 $S_p^2 \rightarrow$ 枢轴量服从 $t(n_1 + n_2 - 2)$ 。

解:

(a) 合并方差

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2} = \frac{9 \times 4 + 11 \times 5}{20} = \frac{36 + 55}{20} = \frac{91}{20} = 4.55$$

(b) 95% CI

枢轴量:

$$T = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{S_p \sqrt{1/n_1 + 1/n_2}} \sim t(20)$$

$$S_p = \sqrt{4.55} \approx 2.133, \quad S_p \sqrt{1/10 + 1/12} = 2.133 \sqrt{0.1 + 0.0833} = 2.133 \times 0.4282 \approx 0.913$$

CI:

$$\begin{aligned}
 (\bar{X}_1 - \bar{X}_2) \pm t_{0.025}(20) \cdot S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} &= (15 - 13) \pm 2.086 \times 0.913 = 2 \pm 1.904 \\
 &= [0.096, 3.904]
 \end{aligned}$$

(c) Welch-Satterthwaite 近似 (方差不等时)

不假设方差相等时, 近似自由度:

$$\nu = \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}$$

统计量 $T_W = \frac{(\bar{X}_1 - \bar{X}_2) - \delta}{\sqrt{S_1^2/n_1 + S_2^2/n_2}} \approx t(\nu)$ (不计算具体值)。

答案: $S_p^2 = 4.55$, $\mu_1 - \mu_2$ 的 95% CI = $[0.10, 3.90]$ (约)

D.6.8 (Ch.18, 先验与后验)

题目: $\theta \sim \text{Beta}(2, 2)$, $n = 10$, $k = 7$, 求后验均值、MAP、95% 可信区间端点。

思路: Beta-Binomial 共轭 $\rightarrow$ 后验 $\text{Beta}(9, 5) \rightarrow$ 各统计量。

解:

(a) 似然

$$L(\theta) \propto \theta^7 (1 - \theta)^3$$

(b) 后验

先验 $\text{Beta}(2, 2)$, 似然贡献 $\theta^7 (1 - \theta)^3$:

$$\text{后验} \propto \theta^{2+7-1} (1 - \theta)^{2+3-1} = \theta^8 (1 - \theta)^4$$

即后验为 $\text{Beta}(9, 5)$ 。

(c) 各统计量

量	公式	数值
后验均值	$\alpha' / (\alpha' + \beta')$	$9/14 \approx 0.643$

量	公式	数值
后验众数 (MAP)	$(\alpha' - 1)/(\alpha' + \beta' - 2)$	$8/12 = 2/3 \approx 0.667$
95% 可信区间	$[B^{-1}(0.025; 9, 5), B^{-1}(0.975; 9, 5)]$	(查 Beta 分位数表)

其中 $B^{-1}(p; \alpha, \beta)$ 为 $\text{Beta}(\alpha, \beta)$ 的 p 分位数。

答案: 后验均值 $9/14$, $\text{MAP} = \boxed{2/3}$, 95% 可信区间端点为 $\text{Beta}(9, 5)$ 的 2.5% 和 97.5% 分位数。

D.6.9 (Ch.18, 共轭先验族——Gamma-Poisson)

题目: $X_i \stackrel{iid}{\sim} \text{Poisson}(\lambda)$, 先验 $\lambda \sim \text{Gamma}(\alpha, \beta)$, 推导后验并解释后验均值的加权平均含义。

思路: 直接相乘, 识别核为 Gamma 密度形式。

解:

(a) 似然

$$L(\lambda | \mathbf{x}) \propto \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} \propto \lambda^{\sum x_i} e^{-n\lambda}$$

(b) 后验推导

先验密度 $\pi(\lambda) \propto \lambda^{\alpha-1} e^{-\beta\lambda}$, 与似然相乘:

$$p(\lambda | \mathbf{x}) \propto \lambda^{\sum x_i} e^{-n\lambda} \cdot \lambda^{\alpha-1} e^{-\beta\lambda} = \lambda^{(\alpha+\sum x_i)-1} e^{-(\beta+n)\lambda}$$

识别为 $\text{Gamma}(\alpha + \sum x_i, \beta + n)$ 。

(c) 后验均值及加权平均解释

后验均值:

$$E[\lambda | \mathbf{x}] = \frac{\alpha + \sum x_i}{\beta + n}$$

改写为加权平均形式, 令 $w = n/(\beta + n)$:

$$E[\lambda | \mathbf{x}] = \frac{\beta}{\beta + n} \cdot \frac{\alpha}{\beta} + \frac{n}{\beta + n} \cdot \frac{\sum x_i}{n} = (1 - w) \cdot \underbrace{\frac{\alpha}{\beta}}_{\text{先验均值}} + w \cdot \underbrace{\frac{\sum x_i}{n}}_{\text{MLE}}$$

当 $n \rightarrow \infty$ 时 $w \rightarrow 1$, 后验均值 $\rightarrow \text{MLE}$; 当 $\beta \rightarrow \infty$ (先验极强) 时 $w \rightarrow 0$, 后验均值 $\rightarrow$ 先验均值。

答案: 后验 $\lambda \mid \mathbf{x} \sim \text{Gamma}(\alpha + \sum x_i, \beta + n)$, 后验均值 = $\boxed{(\alpha + \sum x_i)/(\beta + n)}$, 为先验均值与 MLE 的加权平均。

D.6.10 (Ch.16, 正则化与 MAP 的联系)

题目: 线性回归中, 先验 $\beta \sim N(\mathbf{0}, \tau^2 \mathbf{I})$, 噪声 σ^2 已知, 推导 MAP 等价于 Ridge, 并比较 Ridge 与 Lasso 的先验。

思路: 取 MAP 的对数, 整理成正则化最小二乘形式。

解:

(a) MAP 等价于 Ridge 回归

设 $\mathbf{y} = X\beta + \varepsilon$, $\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I})$, 则:

$$\log L(\beta) = -\frac{1}{2\sigma^2} \|\mathbf{y} - X\beta\|^2 + \text{const}$$

$$\log \pi(\beta) = -\frac{1}{2\tau^2} \|\beta\|^2 + \text{const}$$

MAP: 最大化 $\log L + \log \pi$, 等价于最小化:

$$\frac{1}{2\sigma^2} \|\mathbf{y} - X\beta\|^2 + \frac{1}{2\tau^2} \|\beta\|^2$$

即等价于 Ridge 回归 (正则化参数 $\lambda = \sigma^2/\tau^2$)。

(b) 贝叶斯解释

$\tau^2 \rightarrow \infty$ (先验极弱/无信息) $\Rightarrow \lambda = \sigma^2/\tau^2 \rightarrow 0$ (无正则化), 退化为 OLS。

$\tau^2 \rightarrow 0$ (先验极强) $\Rightarrow \lambda \rightarrow \infty$ (强正则化), 估计量收缩至 $\mathbf{0}$ 。

(c) Ridge vs Lasso 的先验

方法	正则项	对应先验
Ridge (L2)	$\lambda \ \beta\ ^2$	$\beta \sim N(\mathbf{0}, \tau^2 \mathbf{I})$ (正态先验)
Lasso (L1)	$\lambda \ \beta\ _1$	$\beta_j \stackrel{iid}{\sim} \text{Laplace}(0, b)$ (拉普拉斯先验)

Laplace 先验在零点有尖峰, 促进稀疏解 (恰好为零的系数), 这是 Lasso 产生稀疏性的贝叶斯解释。

答案: MAP 等价于 Ridge, $\lambda = \boxed{\sigma^2/\tau^2}$; Lasso 对应 Laplace 先验。

D.6.11 (Ch.17, 比例的区间估计)

题目: $n = 400$, $\hat{p} = 0.6$, 构造 95% CI (Wald 和 Wilson), 并确定最小样本量。

思路: Wald 用正态近似; Wilson 用 score 统计量, 边界情形更稳健。

解:

(a) Wald 95% CI

标准误 $SE = \sqrt{\hat{p}(1-\hat{p})/n} = \sqrt{0.6 \times 0.4/400} = \sqrt{0.0006} = 0.02449$

$$\hat{p} \pm z_{0.025} \cdot SE = 0.6 \pm 1.96 \times 0.02449 = 0.6 \pm 0.04800$$

$$= [0.552, 0.648]$$

(b) 最小样本量 (最保守估计 $p = 0.5$)

CI 宽度 ≤ 0.04 , 即半宽 ≤ 0.02 :

$$z_{0.025} \sqrt{\frac{p(1-p)}{n}} \leq 0.02 \implies 1.96 \sqrt{\frac{0.25}{n}} \leq 0.02$$

$$\sqrt{n} \geq \frac{1.96 \times 0.5}{0.02} = 49 \implies n \geq 2401$$

最小样本量 $n^* = 2401$ 。

(c) Wilson 区间的优势

Wilson 区间:

$$\frac{\hat{p} + \frac{z^2}{2n} \pm z \sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + z^2/n}$$

当 $\hat{p}$ 接近 0 或 1 时, Wald 区间可能越出 $[0, 1]$ 且覆盖率严重不足。Wilson 区间始终在 $[0, 1]$ 内, 且在小样本和极端比例下仍有近似正确的覆盖率。

答案: Wald CI = $[0.552, 0.648]$, 最小样本量 $n^* = 2401$, Wilson 区间在极端比例时更准确。

D.6.12 (Ch.18, 贝叶斯预测分布)

题目: $X|\theta \sim N(\theta, 1)$, 先验 $\theta \sim N(0, \tau^2)$, 观测 $X = x_0$, 求后验和预测分布。

思路: Normal-Normal 共轭 $\rightarrow$ 后验均值为收缩估计 $\rightarrow$ 预测分布方差 = 后验方差 + 采样方差。

解:

(a) 后验 (Normal-Normal 共轭)

似然: $X|\theta \sim N(\theta, 1)$, 先验: $\theta \sim N(0, \tau^2)$ 。

精度 (方差倒数) 相加:

$$\frac{1}{\sigma_{\text{post}}^2} = \frac{1}{1} + \frac{1}{\tau^2} = 1 + \frac{1}{\tau^2} = \frac{\tau^2 + 1}{\tau^2}$$

$$\sigma_{\text{post}}^2 = \frac{\tau^2}{\tau^2 + 1}$$

后验均值 (精度加权平均):

$$\mu_{\text{post}} = \sigma_{\text{post}}^2 \left(\frac{x_0}{1} + \frac{0}{\tau^2} \right) = \frac{\tau^2}{\tau^2 + 1} \cdot x_0 = \frac{\tau^2 x_0}{\tau^2 + 1}$$

故后验 $\theta|X = x_0 \sim N\left(\frac{\tau^2 x_0}{\tau^2 + 1}, \frac{\tau^2}{\tau^2 + 1}\right)$ 。

(b) 预测分布

$\tilde{X}|\theta \sim N(\theta, 1)$, 用全期望:

$$E[\tilde{X}|X = x_0] = E[E[\tilde{X}|\theta]|X = x_0] = E[\theta|X = x_0] = \frac{\tau^2 x_0}{\tau^2 + 1}$$

$$\text{Var}(\tilde{X}|X = x_0) = E[\text{Var}(\tilde{X}|\theta)|X = x_0] + \text{Var}(E[\tilde{X}|\theta]|X = x_0)$$

$$= E[1|X = x_0] + \text{Var}(\theta|X = x_0) = 1 + \frac{\tau^2}{\tau^2 + 1} = \frac{2\tau^2 + 1}{\tau^2 + 1}$$

预测分布: $\tilde{X}|X = x_0 \sim N\left(\frac{\tau^2 x_0}{\tau^2 + 1}, \frac{2\tau^2 + 1}{\tau^2 + 1}\right)$ 。

(c) 预测方差 > 后验方差

后验方差 = $\tau^2/(\tau^2 + 1)$, 预测方差 = $(2\tau^2 + 1)/(\tau^2 + 1)$, 差值恰为 1 (即 $\tilde{X}$ 的采样方差)。预测方差更大, 因为预测 $\tilde{X}$ 时除了参数 θ 的不确定性 (后验方差), 还有额外的观测噪声 (采样不确定性)。

答案: 后验 $\theta|x_0 \sim N\left(\frac{\tau^2 x_0}{\tau^2+1}, \frac{\tau^2}{\tau^2+1}\right)$, 预测分布方差 = $\boxed{\frac{2\tau^2+1}{\tau^2+1}}$ 。

D.6.13 (Ch.16, EM 算法思想)

题目: 混合高斯模型 $\pi N(\mu_1, 1) + (1 - \pi)N(\mu_2, 1)$, 推导 EM 算法的 E 步和 M 步。

思路: 引入潜变量 Z_i 表示样本所属组分, E 步计算软分配, M 步加权最大化。

解:

(a) 完整数据对数似然

引入 $Z_i \in \{1, 2\}$ ($Z_i = k$ 表示 x_i 来自第 k 个分量), 令 $\gamma_{ik} = \mathbf{1}(Z_i = k)$:

$$\ell_c(\theta) = \sum_{i=1}^n \sum_{k=1}^2 \gamma_{ik} [\log \pi_k + \log \phi(x_i; \mu_k, 1)]$$

其中 $\pi_1 = \pi$, $\pi_2 = 1 - \pi$, ϕ 为正态密度, $\theta = (\pi, \mu_1, \mu_2)$ 。

(b) E 步: 计算软分配责任

$$r_{ik} = P(Z_i = k | x_i, \theta^{(t)}) = \frac{\pi_k^{(t)} \phi(x_i; \mu_k^{(t)}, 1)}{\sum_{j=1}^2 \pi_j^{(t)} \phi(x_i; \mu_j^{(t)}, 1)}$$

r_{ik} 是“样本 i 属于第 k 组分”的后验概率 (软分配)。

(c) M 步: 最大化 $Q(\theta|\theta^{(t)})$

$$Q = E[\ell_c | \mathbf{x}, \theta^{(t)}] = \sum_{i,k} r_{ik} [\log \pi_k + \log \phi(x_i; \mu_k, 1)]$$

对 μ_k 求偏导令零:

$$\frac{\partial Q}{\partial \mu_k} = \sum_i r_{ik} (x_i - \mu_k) = 0 \implies \hat{\mu}_k^{(t+1)} = \frac{\sum_i r_{ik} x_i}{\sum_i r_{ik}}$$

对 π 用 Lagrange 乘子 (约束 $\pi_1 + \pi_2 = 1$):

$$\hat{\pi}^{(t+1)} = \frac{1}{n} \sum_i r_{i1}$$

答案: E 步软分配 $r_{ik} = \pi_k \phi(x_i; \mu_k) / \sum_j \pi_j \phi(x_i; \mu_j)$, M 步更新 $\boxed{\hat{\mu}_k = \sum_i r_{ik} x_i / \sum_i r_{ik}}$ (加权均值)。

D.6.14 (Ch.18, Jeffreys 先验)

题目: $X \sim \text{Bernoulli}(\theta)$, 推导 Jeffreys 先验, 并说明重参数不变性。

思路: Fisher 信息 $I(\theta) = 1/(\theta(1-\theta))$, Jeffreys 先验 $\propto \sqrt{I(\theta)}$ 。

解:

(a) 计算 Fisher 信息, 推导 Jeffreys 先验

$$\log f(x; \theta) = x \log \theta + (1-x) \log(1-\theta)$$

$$\frac{\partial^2 \log f}{\partial \theta^2} = -\frac{x}{\theta^2} - \frac{1-x}{(1-\theta)^2}$$

$$I(\theta) = -E \left[\frac{\partial^2 \log f}{\partial \theta^2} \right] = \frac{E[X]}{\theta^2} + \frac{1-E[X]}{(1-\theta)^2} = \frac{\theta}{\theta^2} + \frac{1-\theta}{(1-\theta)^2} = \frac{1}{\theta} + \frac{1}{1-\theta} = \frac{1}{\theta(1-\theta)}$$

Jeffreys 先验:

$$\pi_J(\theta) \propto \sqrt{I(\theta)} = \frac{1}{\sqrt{\theta(1-\theta)}} = \theta^{-1/2}(1-\theta)^{-1/2}$$

(b) 识别为 Beta(1/2, 1/2)

对比 Beta(α, β) 密度 $\propto \theta^{\alpha-1}(1-\theta)^{\beta-1}$:

$$\pi_J(\theta) \propto \theta^{1/2-1}(1-\theta)^{1/2-1}$$

故 $\pi_J = \text{Beta}(1/2, 1/2)$, 而均匀先验为 Beta(1, 1)。Beta(1/2, 1/2) 在 0 和 1 两端有奇点 (U 形), 对极端概率赋予更多权重, 反映对 θ 近于 0 或 1 时的额外不确定性。

(c) 重参数不变性

设 $\phi = g(\theta)$ 是单调变换, 由变量变换公式, ϕ 的 Fisher 信息为 $I_\phi(\phi) = I(\theta)/[g'(\theta)]^2$, 相应的 Jeffreys 先验 $\pi_J(\phi) \propto \sqrt{I_\phi(\phi)}$ 。

可以验证: 通过 θ 的 Jeffreys 先验变换到 ϕ 所得到的密度, 与直接在 ϕ 的模型上应用 Jeffreys 公式所得结果完全一致。这保证了 Jeffreys 先验在参数变换下具有一致性 (参数化方式不影响分析结论)。

答案: $\pi_J(\theta) \propto [\theta(1-\theta)]^{-1/2} = \text{Beta}(1/2, 1/2)$, Jeffreys 先验具有重参数不变性。

E 提高题详解 (10 题)**E.6.1 (Ch.16, MLE + Fisher 信息 + 渐近理论 + 完整证明)**

题目: $X_i \stackrel{iid}{\sim} p(x; \theta)$ (指数族), 证明 MLE 的一致性、渐近正态性、渐近有效性; 以指数分布为例验证。

思路: 得分方程 $\rightarrow$ Taylor 展开 $\rightarrow$ CLT + LLN $\rightarrow$ 建立渐近分布; 具体计算指数分布。

解:

(a) MLE 满足得分方程

设对数似然 $\ell_n(\theta) = \sum_{i=1}^n \log p(X_i; \theta)$ 。MLE $\hat{\theta}_n$ 是 ℓ_n 的极大值点, 在正则条件 (内点极大、似然可微) 下, 必满足一阶条件:

$$\left. \frac{\partial \ell_n}{\partial \theta} \right|_{\hat{\theta}_n} = \sum_{i=1}^n \frac{\partial \log p(X_i; \hat{\theta}_n)}{\partial \theta} = 0$$

这即为得分方程 (score equation)。

(b) MLE 渐近正态性的 Taylor 展开证明

将得分方程在真值 θ_0 处 Taylor 展开:

$$0 = \underbrace{\ell'_n(\theta_0)}_{\sum_i s(X_i; \theta_0)} + \ell''_n(\theta_0)(\hat{\theta}_n - \theta_0) + O((\hat{\theta}_n - \theta_0)^2)$$

其中 $s(X_i; \theta) = \partial \log p(X_i; \theta) / \partial \theta$ 为得分函数。

由 LLN: $n^{-1} \ell''_n(\theta_0) \xrightarrow{p} -\mathcal{J}(\theta_0)$ ($\mathcal{J}$ 为 Fisher 信息)。

由 CLT: $n^{-1/2} \ell'_n(\theta_0) = n^{-1/2} \sum_i s(X_i; \theta_0) \xrightarrow{d} N(0, \mathcal{J}(\theta_0))$ (因 $E[s] = 0$, $\text{Var}(s) = \mathcal{J}(\theta_0)$)。

整理:

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \approx \frac{n^{-1/2} \ell'_n(\theta_0)}{-n^{-1} \ell''_n(\theta_0)} \xrightarrow{d} \frac{N(0, \mathcal{J}(\theta_0))}{\mathcal{J}(\theta_0)} = N(0, \mathcal{J}(\theta_0)^{-1})$$

(c) MLE 渐近有效 (CRB 紧)

Cramér-Rao 下界: 任意无偏估计量 T_n 满足 $\text{Var}(\sqrt{n} T_n) \geq \mathcal{J}(\theta_0)^{-1}$ 。

MLE 的渐近方差 $= \mathcal{J}(\theta_0)^{-1}$, 恰好达到下界, 故 MLE 是渐近有效估计量。

(d) 指数分布验证

$p(x; \theta) = \theta e^{-\theta x}$ ($x > 0$), 设样本量 n 。

MLE: $\ell(\theta) = n \log \theta - \theta \sum x_i$, 令 $\ell' = n/\theta - \sum x_i = 0$, 得 $\hat{\theta} = 1/\bar{X}$ 。

Fisher 信息 (单样本): $\ell''(\theta) = -n/\theta^2$, 故 $I_1(\theta) = 1/\theta^2$; n 个样本 $\mathcal{I}(\theta) = n/\theta^2$ 。

渐近分布: $\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, \theta^2)$ (即渐近方差 = θ^2/n)。

渐近置信区间 ($1 - \alpha$ 水平):

$$\hat{\theta} \pm z_{\alpha/2} \cdot \frac{\hat{\theta}}{\sqrt{n}}$$

验证: $\text{Var}(\hat{\theta}) \approx \theta^2/n = 1/\mathcal{I}(\theta)$, 与 CRB 吻合。

答案: MLE $\hat{\theta} = 1/\bar{X}$, 渐近方差 = $\boxed{\theta^2/n}$, 达到 CRB, 渐近有效。

E.6.2 (Ch.16+Ch.18, 正则化 MLE + MAP + 惩罚似然)

题目: (a) 正态先验 $\rightarrow$ Ridge; (b) Laplace 先验 $\rightarrow$ Lasso; (c) Dropout $\rightarrow$ 隐式先验; (d) $n \rightarrow \infty$ 时 MAP $\rightarrow$ MLE。

思路: MAP = 最大化对数似然 + 对数先验; 各先验形式对应不同正则项。

解:

(a) 正态先验 $\rightarrow$ L2 正则化 (Ridge)

先验 $\pi(\theta) = N(\mathbf{0}, \tau^2 \mathbf{I})$, 对数先验:

$$\log \pi(\theta) = -\frac{1}{2\tau^2} \|\theta\|^2 + \text{const}$$

MAP:

$$\hat{\theta}_{MAP} = \arg \max_{\theta} \left[\log L(\theta) - \frac{1}{2\tau^2} \|\theta\|^2 \right]$$

等价于最小化:

$$-\log L(\theta) + \frac{1}{2\tau^2} \|\theta\|^2 = -\log L(\theta) + \frac{\lambda}{2} \|\theta\|^2, \quad \lambda = \frac{1}{\tau^2}$$

此即 L2 正则化 (Ridge 回归中为 $\|\mathbf{y} - X\theta\|^2 + \lambda \|\theta\|^2$)。□

(b) Laplace 先验 $\rightarrow$ L1 正则化 (Lasso)

先验 $\pi(\theta_j) = \frac{1}{2b} \exp(-|\theta_j|/b)$ (Laplace), 对数先验:

$$\log \pi(\theta) = -\frac{1}{b} \|\theta\|_1 + \text{const}$$

MAP 等价于最小化 $-\log L(\theta) + \lambda \|\theta\|_1$ ($\lambda = 1/b$), 即 L1 正则化 (Lasso)。Laplace 分布在零点的尖峰促进系数恰好为零 (稀疏解)。□

(c) Dropout $\approx$ 隐式正则化 (直觉推导)

Dropout 以概率 p 随机将权重置零, 训练时对 2^d 个子网络 (d 为权重维数) 求期望。Srivastava 等人 (2014) 及 Gal & Ghahramani (2016) 证明, 对某些网络结构, Dropout 等价于在权重上施加 Bernoulli 先验 (每个权重独立地有概率 p 被“去除”), 从而 MAP 估计等价于带 Bernoulli 先验的正则化。这给出 Dropout 防止过拟合的贝叶斯解释。

(d) 大样本时 MAP $\rightarrow$ MLE (后验收缩)

MAP 目标: $\hat{\theta}_{MAP} = \arg \max [\ell_n(\theta) + \log \pi(\theta)]$ 。

当 $n \rightarrow \infty$ 时, $\ell_n(\theta) = O(n)$ 而 $\log \pi(\theta) = O(1)$ (固定先验), 故先验贡献相对可忽略:

$$\hat{\theta}_{MAP} = \arg \max \left[\ell_n(\theta) + \underbrace{\log \pi(\theta)}_{\text{相对 } O(1)} \right] \xrightarrow{n \rightarrow \infty} \arg \max \ell_n(\theta) = \hat{\theta}_{MLE}$$

小样本时先验相对贡献大 (正则化效果显著); 大样本时数据主导, 先验被“冲淡”。

答案: 正态先验 $\leftrightarrow$ Ridge, Laplace 先验 $\leftrightarrow$ Lasso, $n \rightarrow \infty$ 时 $\hat{\theta}_{MAP} \rightarrow \hat{\theta}_{MLE}$, 先验在大样本时影响消失。

E.6.3 (Ch.16, 矩估计 + GMM + 弱工具变量)

题目: GMM 框架, m 个矩条件, k 个参数, 讨论恰好识别、过识别、最优权重及 J 检验。

思路: GMM 统一了矩估计 ($m = k$) 和过识别系统 ($m > k$), 最优权重使渐近方差最小。

解:

(a) $m = k$ 时退化为矩估计——相合性与渐近正态性

当 $m = k$, 矩估计 $\hat{\theta}_n$ 满足 $\hat{g}_n(\hat{\theta}_n) = \mathbf{0}$ (精确矩方程)。

相合性: 由 LLN, $\hat{g}_n(\theta) \xrightarrow{p} g(\theta) = E[g(X; \theta)]$; 在正则条件下 $g(\theta_0) = \mathbf{0}$ 且 g 在 θ_0 邻域可识别, 由连续性 $\hat{\theta}_n \xrightarrow{p} \theta_0$ 。

渐近正态性: 在 θ_0 处 Taylor 展开: $\hat{g}_n(\hat{\theta}_n) \approx \hat{g}_n(\theta_0) + G_n(\hat{\theta}_n - \theta_0) = \mathbf{0}$, 其中 $G_n = \partial \hat{g}_n / \partial \theta^\top \xrightarrow{p} G = \partial g(\theta_0) / \partial \theta^\top$ 。

由 CLT: $\sqrt{n} \hat{g}_n(\theta_0) \xrightarrow{d} N(\mathbf{0}, \Omega)$, $\Omega = \text{Var}(g(X; \theta_0))$ 。

故:

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{d} N(\mathbf{0}, (G^{-1})\Omega(G^{-1})^\top)$$

(b) $m > k$ 时最优权重 GMM (Hansen-Sargan 效率定理)

GMM 目标: $Q_n(\theta) = \hat{g}_n(\theta)^\top \mathbf{W}_n \hat{g}_n(\theta)$ 。

一阶条件: $G^\top \mathbf{W} G \sqrt{n}(\hat{\theta} - \theta_0) = -G^\top \mathbf{W} \sqrt{n} \hat{g}_n(\theta_0)$ 。

渐近方差: $V(\mathbf{W}) = (G^\top \mathbf{W} G)^{-1} G^\top \mathbf{W} \Omega \mathbf{W} G (G^\top \mathbf{W} G)^{-1}$ 。

取 $\mathbf{W}^* = \Omega^{-1}$ (最优权重), 由 Cauchy-Schwarz 型不等式, $V(\mathbf{W}^*)$ 最小:

$$V^* = (G^\top \Omega^{-1} G)^{-1}$$

这是最优 GMM 的渐近方差下界 (Hansen 1982)。

(c) 过识别 J 检验

在最优 GMM 下, 过识别检验统计量:

$$J = n \hat{g}_n^\top \mathbf{W}^* \hat{g}_n = n \hat{g}_n^\top \Omega^{-1} \hat{g}_n \xrightarrow{d} \chi^2(m - k)$$

自由度为 $m - k$ (超额矩条件数)。若 J 值过大, 拒绝矩条件的联合有效性, 说明模型设定 (工具变量或矩条件) 存在问题。

(d) 与对比学习的联系 (直觉)

InfoNCE 损失: $\mathcal{L} = -\log \frac{e^{f(x_i, x_i^\dagger)/\tau}}{\sum_j e^{f(x_i, x_j)/\tau}}$, 可视为对“正样本对应高相似度”的矩条件的 GMM 估计。批量中负样本数量越多, 矩条件 $\hat{g}_n$ 的估计越精确 (类似 n 增大), 渐近方差减小, 估计效率提升。这解释了大批量训练在 SimCLR 中提升效果的统计机制。

答案: 最优 GMM 渐近方差 = $(G^\top \Omega^{-1} G)^{-1}$, J 检验统计量 $\sim \chi^2(m-k)$, 大批量 = 更多矩条件信息, 提升 GMM 效率。

E.6.4 (Ch.17, 置信区间 + 枢轴量 + Bootstrap 置信区间)

题目: $X_i \stackrel{iid}{\sim} N(\mu, \sigma^2)$, 均值与方差均未知。构造精确 μ CI 和 σ^2 CI; Bootstrap; Conformal Prediction。

思路: 利用充分统计量构造精确枢轴量; Bootstrap 无需分布假设; Conformal 提供有限样本保证。

解:

(a) μ 的精确 t CI

枢轴量推导: $\bar{X} \sim N(\mu, \sigma^2/n)$, $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$, 两者独立。

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} = \frac{(\bar{X} - \mu)/(\sigma/\sqrt{n})}{\sqrt{(n-1)S^2/[\sigma^2(n-1)]}} \sim t(n-1)$$

95% CI: $\bar{X} \pm t_{0.025}(n-1) \cdot S/\sqrt{n}$ 。

(b) σ^2 的精确 χ^2 CI

枢轴量: $Q = (n-1)S^2/\sigma^2 \sim \chi^2(n-1)$ (不依赖 μ , 因为 S^2 与 $\bar{X}$ 独立)。

$$P\left(\chi_{1-\alpha/2}^2(n-1) \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_{\alpha/2}^2(n-1)\right) = 1 - \alpha$$

解出 σ^2 : $\left[\frac{(n-1)S^2}{\chi_{\alpha/2}^2}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2}\right]$ 。

不对称原因: χ^2 分布右偏, 两端分位数关于中心不对称, 故 CI 两侧宽度不等。

(c) Bootstrap 置信区间

百分位数 **Bootstrap**: 从 $\{X_1, \dots, X_n\}$ 有放回地重抽样 B 次, 每次计算 $\hat{\theta}^{*(b)}$, 取 $[\hat{\theta}^{*(\alpha/2)}, \hat{\theta}^{*(1-\alpha/2)}]$ 为 CI。二阶渐近正确: 覆盖误差为 $O(n^{-1})$ 。

BCa Bootstrap: 对百分位数进行偏差 ($\hat{z}_0$) 和加速 ($\hat{a}$) 校正:

$$\alpha_1 = \Phi\left(\hat{z}_0 + \frac{\hat{z}_0 + z_{\alpha/2}}{1 - \hat{a}(\hat{z}_0 + z_{\alpha/2})}\right), \quad \alpha_2 = \Phi\left(\hat{z}_0 + \frac{\hat{z}_0 + z_{1-\alpha/2}}{1 - \hat{a}(\hat{z}_0 + z_{1-\alpha/2})}\right)$$

BCa 是二阶渐近正确的 (覆盖误差 $O(n^{-3/2})$), 优于简单百分位数法, 在偏斜或参数化有约束时尤为重要。

(d) Conformal Prediction (分裂式, 有限样本保证)

构造步骤:

1. 将 n 个训练样本分为训练集 $\mathcal{D}_1$ (n_1 个) 和校准集 $\mathcal{D}_2$ (n_2 个)。
2. 在 $\mathcal{D}_1$ 上训练模型 $\hat{f}$, 对每个校准样本计算非一致性分数 $s_i = |Y_i - \hat{f}(X_i)|$ ($i \in \mathcal{D}_2$)。
3. 设 $q = \lceil (1-\alpha)(n_2+1) \rceil / n_2$ 分位数 $\hat{q}$ 。
4. 预测区间: $C(X_{n+1}) = \{y : |y - \hat{f}(X_{n+1})| \leq \hat{q}\}$ 。

有限样本保证: 若 (X_i, Y_i) 可交换, 则

$$P(Y_{n+1} \in C(X_{n+1})) \geq 1 - \alpha$$

严格成立 (有限样本, 不依赖分布假设)。

与 Bootstrap 对比: Bootstrap 是渐近正确 ($n \rightarrow \infty$), Conformal 是有限样本精确 (任意 n), 但 Conformal 不依赖模型分布假设, 适用范围更广。

答案: μ 的精确 CI 用 $t(n-1)$ 枢轴量; σ^2 的 CI 用 $\chi^2(n-1)$ 枢轴量(不对称); Conformal 具有有限样本覆盖保证, Bootstrap 仅渐近正确。

E.6.5 (Ch.17+Ch.18, 贝叶斯可信区间 + 频率置信区间 + 概率解释对比)

题目: $X|\theta \sim B(n, \theta)$, 先验 $\theta \sim \text{Beta}(\alpha_0, \beta_0)$, $X = k$ 。比较后验 HDR、Wald/Wilson CI, 深入对比两种框架。

思路: 后验 Beta $\rightarrow$ HDR; Wald 在边界失效; 频率/贝叶斯框架的哲学对比。

解:

(a) 后验 HDR 可信区间

后验 $\theta|X = k \sim \text{Beta}(\alpha_0 + k, \beta_0 + n - k)$ 。

HDR (最高密度区间) 是满足以下条件的最短区间 $[l^*, u^*]$: $P(\theta \in [l^*, u^*]|X = k) = 0.95$ 。

对单峰对称分布, HDR 退化为等尾区间 $[B^{-1}(0.025), B^{-1}(0.975)]$; 对偏斜 Beta 分布, HDR 通过数值优化(最小化 $u - l$, 约束积分 = 0.95) 得到, 通常是非对称区间。

(b) Wald vs Wilson 区间

Wald 区间: $\hat{p} \pm z_{\alpha/2} \sqrt{\hat{p}(1-\hat{p})/n}$ 。

缺陷: 当 $\hat{p} = 0$ 或 1 时, 区间退化为零宽度 $[0, 0]$ 或 $[1, 1]$, 完全无法覆盖真参数 (覆盖率 = 0)。即使 $\hat{p}$ 只是接近边界, Wald 区间覆盖率也系统性低于名义水平 $1 - \alpha$ 。

Wilson Score 区间: 基于 z 统计量 $z = (\hat{p} - \theta)/\sqrt{\theta(1-\theta)/n}$, 解不等式 $|z| \leq z_{\alpha/2}$:

$$\frac{\hat{p} + \frac{z^2}{2n} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}$$

Wilson 区间始终在 $[0, 1]$ 内, 在 $\hat{p}$ 接近边界及小样本下均有接近名义水平的覆盖率。

(c) 频率 vs 贝叶斯的哲学含义

	贝叶斯可信区间	频率置信区间
概率主体	参数 θ (随机变量)	区间端点 (随机量)
解释	$P(\theta \in [\ell, u] X) = 0.95$: 给定数据, 参数在区间内的概率	$P_\theta(\theta \in [\ell(X), u(X)]) = 0.95$: 重复实验, 区间覆盖参数的频率
对“参数以 95% 概率落在 CI 内”的看法	对可信区间正确	对单次置信区间无意义 (θ 是固定常数)

对频率论者,“参数在置信区间内的概率”要么是 0 要么是 1 (因 θ 固定), 说这个概率是 95% 混淆了参数与估计量的随机性。

(d) 工程实践中的权衡 (A/B 测试场景)

场景: 电商 A/B 测试点击率, 实验组 $\hat{p}_A = 0.05$ ($n_A = 1000$), 对照组 $\hat{p}_B = 0.04$ ($n_B = 1000$)。

- 频率置信区间: 提供严格的频率覆盖保证, 适合监管合规; 但不能直接给出“实验组更好的概率”。
- 贝叶斯可信区间: 可以直接计算 $P(\theta_A > \theta_B | \text{数据})$, 为决策提供直观的概率依据, 例如“有 97% 的把握实验组更好”。

工程权衡: 对需要严格误报控制的场景 (医药试验) 用频率方法; 对快速迭代的产品决策, 贝叶斯可信区间给出更直接的业务语言。

答案: 后验 HDR 给出 $P(\theta \in [\ell, u] | \text{数据}) = 0.95$; Wilson CI 优于 Wald CI; 贝叶斯框架提供直接决策概率, 频率框架提供频率

E.6.6 (Ch.18, 分层贝叶斯 + 超先验 + 部分池化)

题目: J 组分层模型, 推导部分池化估计量, 分析极端情形, 联系联邦学习。

思路: 精度加权平均 $\rightarrow$ 组内精度 n_j/σ^2 vs 组间精度 $1/\tau^2$ 决定池化程度。

解:

(a) 完整联合分布

$$p(\{X_{ij}\}, \{\theta_j\}, \mu, \tau) = \prod_{j=1}^J \prod_{i=1}^{n_j} N(X_{ij}; \theta_j, \sigma^2) \cdot \prod_{j=1}^J N(\theta_j; \mu, \tau^2) \cdot N(\mu; 0, \Sigma_0) \cdot p(\tau)$$

(b) 部分池化估计量推导

给定 μ, τ, θ_j 的条件后验:

$$p(\theta_j | \{X_{ij}\}, \mu, \tau) \propto \prod_i N(X_{ij}; \theta_j, \sigma^2) \cdot N(\theta_j; \mu, \tau^2)$$

精度 (方差倒数) 相加: $\frac{1}{\sigma_j^2} = \frac{n_j}{\sigma^2} + \frac{1}{\tau^2}$, 即 $\sigma_j^2 = \frac{\sigma^2 \tau^2}{n_j \tau^2 + \sigma^2}$ 。

后验均值 (精度加权):

$$\hat{\theta}_j = \sigma_j^2 \left(\frac{n_j \bar{X}_j}{\sigma^2} + \frac{\mu}{\tau^2} \right) = \frac{n_j \tau^2}{n_j \tau^2 + \sigma^2} \bar{X}_j + \frac{\sigma^2}{n_j \tau^2 + \sigma^2} \mu$$

令 $\lambda_j = \frac{n_j \tau^2}{n_j \tau^2 + \sigma^2}$, 则

$$\hat{\theta}_j = \lambda_j \bar{X}_j + (1 - \lambda_j) \hat{\mu} \quad (\text{部分池化})$$

(c) 极端情形分析

- $\tau \rightarrow 0$ (组间方差趋零, 各组参数相同): $\lambda_j \rightarrow 0$, $\hat{\theta}_j \rightarrow \hat{\mu}$, 即完全池化——所有组共享全局均值。
- $\tau \rightarrow \infty$ (各组参数完全独立): $\lambda_j \rightarrow 1$, $\hat{\theta}_j \rightarrow \bar{X}_j$, 即无池化——各组独立估计。

部分池化在两极端之间自适应, 根据数据决定借鉴全局信息的程度。

(d) 联邦学习联系

在个性化联邦学习中, 客户端 j 的本地参数 θ_j 对应 θ_j , 全局超先验 μ 对应服务器维护的全局模型。

- **pFedMe** (Dinh et al. 2020): 每个客户端最小化 $\ell_j(\theta_j) + \lambda \|\theta_j - \mathbf{w}\|^2$, 正是 Normal-Normal 分层贝叶斯的 MAP 估计 ($\lambda = \sigma^2/\tau^2$)。
- **MAML** (Finn et al. 2017): 元学习的初始化参数对应超先验均值 μ , 每个客户端的快速适应对应从先验到后验的更新。

超先验的方差 τ^2 编码了客户端间差异程度: τ^2 大则允许客户端差异大 (个性化强), τ^2 小则强迫客户端接近全局模型 (泛化强)。

答案: 部分池化 $\hat{\theta}_j = \lambda_j \bar{X}_j + (1 - \lambda_j) \hat{\mu}$, $\lambda_j = \frac{n_j \tau^2}{n_j \tau^2 + \sigma^2}$; $\tau \rightarrow 0$ 完全池化, $\tau \rightarrow \infty$ 无池化;
联邦学习个性化 = 分层贝叶斯部分池化。

E.6.7 (Ch.16+Ch.18, 变分推断 + ELBO + VAE)

题目: 推导 ELBO, 证明 $\text{gap} = \text{KL}$, 推导重参数化技巧, 分析后验坍塌。

思路: $\log p(\mathbf{x})$ 分解为 ELBO + KL; 重参数化使梯度通过采样可微分。

解:

(a) ELBO 推导

对任意分布 $q_\phi(\mathbf{z}|\mathbf{x})$:

$$\log p_\theta(\mathbf{x}) = \log \int p_\theta(\mathbf{x}, \mathbf{z}) d\mathbf{z} = \log E_{q_\phi} \left[\frac{p_\theta(\mathbf{x}, \mathbf{z})}{q_\phi(\mathbf{z}|\mathbf{x})} \right]$$

由 Jensen 不等式 ($\log$ 凹函数):

$$\log p_\theta(\mathbf{x}) \geq E_{q_\phi} \left[\log \frac{p_\theta(\mathbf{x}, \mathbf{z})}{q_\phi(\mathbf{z}|\mathbf{x})} \right] = E_{q_\phi} [\log p_\theta(\mathbf{x}|\mathbf{z})] - D_{KL}(q_\phi \| p(\mathbf{z})) =: \mathcal{L}(\theta, \phi; \mathbf{x})$$

(b) $\text{gap} = \text{KL}$

$$\begin{aligned}\log p_{\theta}(\mathbf{x}) - \mathcal{L} &= \log p_{\theta}(\mathbf{x}) - E_{q_{\phi}} \left[\log \frac{p_{\theta}(\mathbf{x}, \mathbf{z})}{q_{\phi}(\mathbf{z}|\mathbf{x})} \right] \\ &= E_{q_{\phi}} \left[\log \frac{q_{\phi}(\mathbf{z}|\mathbf{x}) p_{\theta}(\mathbf{x})}{p_{\theta}(\mathbf{x}, \mathbf{z})} \right] = E_{q_{\phi}} \left[\log \frac{q_{\phi}(\mathbf{z}|\mathbf{x})}{p_{\theta}(\mathbf{z}|\mathbf{x})} \right] = D_{KL}(q_{\phi} \| p_{\theta}(\mathbf{z}|\mathbf{x})) \geq 0\end{aligned}$$

因此 $\mathcal{L}$ 确为 $\log p_{\theta}(\mathbf{x})$ 的下界, 当且仅当 $q_{\phi} = p_{\theta}(\mathbf{z}|\mathbf{x})$ 时等号成立。

(c) KL 项解析式与重参数化

设 $q_{\phi}(\mathbf{z}|\mathbf{x}) = N(\mu_{\phi}, \text{diag}(\sigma_{\phi}^2))$, $p(\mathbf{z}) = N(\mathbf{0}, \mathbf{I})$, 维度 d :

$$D_{KL}(q_{\phi} \| p) = \frac{1}{2} \sum_{k=1}^d [\mu_{\phi,k}^2 + \sigma_{\phi,k}^2 - \log \sigma_{\phi,k}^2 - 1]$$

重参数化技巧: 直接采样 $\mathbf{z} \sim q_{\phi}(\mathbf{z}|\mathbf{x})$ 不可微 (采样操作阻断梯度)。令 $\mathbf{z} = \mu_{\phi}(\mathbf{x}) + \sigma_{\phi}(\mathbf{x}) \odot \varepsilon$, $\varepsilon \sim N(\mathbf{0}, \mathbf{I})$, 将随机性转移至与 ϕ 无关的 ε , 梯度 $\partial \mathbf{z} / \partial \phi$ 可直接反向传播。

(d) 后验坍缩 (Posterior Collapse)

现象: 训练时 KL 项被驱动至 0 ($q_{\phi} \approx p(\mathbf{z})$), 隐变量 $\mathbf{z}$ 失去信息, 解码器直接忽略 $\mathbf{z}$ 。

原因: 强大的自回归解码器 (如 LSTM) 可以不依赖 $\mathbf{z}$ 而实现高重建质量, 而消除 KL 项 (令 $q = p$) 还能移除一个正则化惩罚, 形成“双赢”的局部最优。

缓解方法:

1. β -VAE (Higgins et al. 2017): 令 $\mathcal{L}_{\beta} = E_{q_{\phi}}[\log p_{\theta}(\mathbf{x}|\mathbf{z})] - \beta D_{KL}$, $\beta > 1$ 时强迫更高的 KL, 防止坍缩; 从信息瓶颈看, β 控制压缩率与重建精度的权衡。
2. **KL 退火 (KL Annealing)**: 训练初期令 β 从 0 逐渐增大至 1, 先让解码器学习依赖 $\mathbf{z}$, 再引入 KL 惩罚, 避免解码器过早绕过隐变量。

答案: $\text{ELBO} = E_q[\log p(\mathbf{x}|\mathbf{z})] - D_{KL}(q \| p(\mathbf{z}))$, $\text{gap} = D_{KL}(q \| p(\mathbf{z}|\mathbf{x})) \geq 0$; KL 项解析式为 $\frac{1}{2} \sum_k [\mu_k^2 + \sigma_k^2 - \log \sigma_k^2 - 1]$; 重参数化将随机性转移至 ε , 使梯度可反传。

E.6.8 (Ch.17+Ch.18, EM 算法收敛 + 不完全数据 + 多峰后验)

题目: 证明 EM 单调性, 分析局部最优, 讨论 MCEM 和变分 EM。

思路: EM 单调性 = Jensen 不等式; 局部最优 = 多峰似然; 变分族的限制导致近似误差。

解:

(a) EM 单调性证明

构造辅助量 $H(\theta|\theta^{(t)}) = E_{\mathbf{Z}|\mathbf{Y}, \theta^{(t)}}[\log p(\mathbf{Z}|\mathbf{Y}, \theta)]$, 由联合分布分解:

$$\log p(\mathbf{Y}|\theta) = Q(\theta|\theta^{(t)}) - H(\theta|\theta^{(t)})$$

M 步保证 $Q(\theta^{(t+1)}|\theta^{(t)}) \geq Q(\theta^{(t)}|\theta^{(t)})$ (最大化 Q)。

由 Jensen 不等式, $H(\theta|\theta^{(t)}) \leq H(\theta^{(t)}|\theta^{(t)})$ (Gibbs 不等式: KL 非负):

$$H(\theta|\theta^{(t)}) = -D_{KL}(p(\mathbf{Z}|\mathbf{Y}, \theta^{(t)}) \| p(\mathbf{Z}|\mathbf{Y}, \theta)) + H(\theta^{(t)}|\theta^{(t)}) \leq H(\theta^{(t)}|\theta^{(t)})$$

故:

$$\log p(\mathbf{Y}|\theta^{(t+1)}) = Q(\theta^{(t+1)}|\theta^{(t)}) - H(\theta^{(t+1)}|\theta^{(t)}) \geq Q(\theta^{(t)}|\theta^{(t)}) - H(\theta^{(t)}|\theta^{(t)}) = \log p(\mathbf{Y}|\theta^{(t)})$$

□

(b) 局部最优——双峰混合高斯例子

设 $n = 100$ 个观测来自 $0.5N(-3, 1) + 0.5N(3, 1)$, 参数 $\theta = (\pi, \mu_1, \mu_2)$ 。

若初始化 $\mu_1^{(0)} = \mu_2^{(0)} = 0$ (两组分重叠), E 步给出 $r_{i1} \approx r_{i2} \approx 0.5$, M 步更新后两个均值均趋向 $\bar{X} \approx 0$, EM 收敛到 $\mu_1 = \mu_2 = 0$ ——这是鞍点 (局部最优), 而非全局最大值 (真实 $\mu_1 = -3, \mu_2 = 3$)。不同初始化会导致不同的局部最优, 因此混合模型常用多次随机重启或谱方法初始化。

(c) 蒙特卡洛 EM (MCEM)

当 E 步的条件期望 $Q(\theta|\theta^{(t)}) = E[\ell_c|\mathbf{Y}, \theta^{(t)}]$ 无解析式时, 用 MCMC (如 Gibbs 抽样) 生成 M 个样本 $\mathbf{Z}^{(1)}, \dots, \mathbf{Z}^{(M)}$ 近似:

$$\hat{Q}_M(\theta|\theta^{(t)}) = \frac{1}{M} \sum_{m=1}^M \log p(\mathbf{Y}, \mathbf{Z}^{(m)}|\theta)$$

近似误差来源: MCMC 混合不充分 (链未收敛), M 有限导致 Monte Carlo 误差 $O(M^{-1/2})$ 。随着 EM 迭代推进 ($\theta^{(t)}$ 趋近最优), 需要更精确的 Q 估计 (误差更小), 因此应逐步增大 M , 以保证整体收敛。

(d) 变分 EM vs 标准 EM

标准 EM 的 E 步取 $q = p(\mathbf{Z}|\mathbf{Y}, \theta^{(t)})$ (精确后验), ELBO gap 归零。

变分 EM 限制 $q \in \mathcal{Q}$ (变分族), 当真实后验 $\notin \mathcal{Q}$ 时, $\text{ELBO gap} = D_{KL}(q^* \| p) > 0$, 导致次优性。

LDA 中的平均场假设: 令 $q(\mathbf{Z}) = \prod_i q(Z_i)$ (各隐变量独立), 忽略了变量间的相关性。若主题分布与词的分配相关 (实际上总是相关的), 平均场近似系统性低估后验方差, 导致主题估计过于尖锐 (置信度虚高)。代价是推断从指数级 (真实后验) 降至多项式级复杂度。

答案: EM 单调性由 Q 增大 + H 减小 (KL 非负) 保证; 局部最优在多峰似然时出现; 变分 EM 因 $D_{KL}(q \| p) > 0$ 而次优。

E.6.9 (Ch.16+Ch.17+Ch.18, 贝叶斯非参数估计 + Dirichlet 过程 + 无限混合)

题目: DP 的存在性、均值、CRP 与边际化、DPMM 聚类。

思路: DP 是有限 Dirichlet 的一致极限; CRP 是 DP 混合模型隐变量的边际分布; α 控制新桌的期望数。

解:

(a) DP 的存在性 (有限 Dirichlet 极限)

对 $\mathcal{X}$ 的任意有限可测分割 $(A_1, \dots, A_K)$, 定义:

$$(G(A_1), \dots, G(A_K)) \sim \text{Dir}(\alpha G_0(A_1), \dots, \alpha G_0(A_K))$$

此定义对所有分割 K 和所有选取方式一致 (由 Kolmogorov 相容条件验证), 故由 Kolmogorov 扩展定理存在唯一的随机测度 G , 满足上述有限维边际, 称 $G \sim DP(\alpha, G_0)$ 。

(b) DP 的均值与方差

对分割 (A, A^c) , $(G(A), G(A^c)) \sim \text{Dir}(\alpha G_0(A), \alpha G_0(A^c))$ 。

Dirichlet 均值: $E[G(A)] = G_0(A)$, 即 $E[G] = G_0$ (DP 的均值测度等于基础测度)。

方差: $\text{Var}(G(A)) = \frac{G_0(A)(1-G_0(A))}{\alpha+1}$, $\alpha \rightarrow \infty$ 时方差 $\rightarrow 0$, $G \rightarrow G_0$ (DP 集中于 G_0)。

(c) CRP 是 DP 混合模型的边际

DP 混合: $G \sim DP(\alpha, G_0)$, $\theta_i \stackrel{iid}{\sim} G$, $X_i | \theta_i \sim F(\cdot | \theta_i)$ 。

对 θ_i 边际化 (积分掉 G), 利用 DP 的 Pólya urn 性质:

$$\theta_{n+1} | \theta_1, \dots, \theta_n \sim \frac{1}{\alpha + n} \left(\alpha G_0 + \sum_{i=1}^n \delta_{\theta_i} \right)$$

若将不同取值 θ 视为“桌”, 则 θ_{n+1} 以概率 $\frac{n_k}{\alpha+n}$ 加入已有第 k 桌 (取值 θ_k^*), 以概率 $\frac{\alpha}{\alpha+n}$ 新开一桌 (取 $\theta \sim G_0$) ——这正是 CRP。因此 CRP 是 DP 混合模型将 G 积分掉后的 $(\theta_1, \dots, \theta_n)$ 的联合边际分布。

(d) DPMM 聚类与 BIC 对比

DPMM 自动推断簇数: 期望簇数 $\approx \alpha \log(1 + n/\alpha)$ (随 n 增长缓慢), α 大则期望更多簇。

α 的推断: 置先验 $\alpha \sim \text{Gamma}(a, b)$, 利用 Gibbs 抽样 (Escobar & West 1995) 或 Variational Bayes 推断后验 $p(\alpha | \text{数据})$, 从数据中学习“多少簇是合适的”。

与有限 GMM + BIC 对比:

方法	簇数选择	优点	缺点
GMM + BIC	枚举 K , 选 BIC 最小	计算快、可解释	需穷举 K , BIC 近似
DPMM	自动 (α 推断)	无需指定 K , 贝叶斯不 确定性	计算慢, MCMC 收敛问 题

在深度学习表示学习中, DPMM 可用于对嵌入空间进行在线聚类 (如无监督分类), 无需预设簇数, 灵活适应数据复杂度。

答案: DP 均值 $E[G] = G_0$; CRP 是 DP 混合的隐变量边缘; DPMM 期望簇数 $\approx \boxed{\alpha \log(1 + n/\alpha)}$, 自动适应数据规模。

E.6.10 (Ch.16+Ch.18, 最大熵估计 + 凸对偶 + 特征匹配)

题目: 最大熵原理的对偶推导, 最优解为指数族, 联系逻辑回归, 分析 RLHF 最优策略。

思路: 原问题 (最大化熵, 约束特征均值) $\rightarrow$ Lagrange 对偶 $\rightarrow$ 凸对偶等价 $\rightarrow$ 指数族; KL 约束下的奖励最大化 $\rightarrow$ 软 Q 值策略。

解:

(a) 对偶问题推导 (Legendre-Fenchel 变换)

原问题: $\max_p H(p) = -\sum_x p(x) \log p(x)$, 约束 $E_p[\phi_k(x)] = \hat{\mu}_k$, $k = 1, \dots, m$, $\sum_x p(x) = 1$ 。

Lagrangian: $\mathcal{L} = H(p) - \sum_k \eta_k (E_p[\phi_k] - \hat{\mu}_k) - \nu (\sum_x p(x) - 1)$

对 $p(x)$ 求偏导令零: $-\log p(x) - 1 - \sum_k \eta_k \phi_k(x) - \nu = 0$

解出: $p^*(x) = \exp(\sum_k \eta_k \phi_k(x) - A(\eta))$ (指数族)

对偶目标 (对 η 最小化):

$$g(\eta) = -H(p^*) + \sum_k \eta_k (E_{p^*}[\phi_k] - \hat{\mu}_k) = A(\eta) - \eta^\top \hat{\mu}$$

强对偶性: 在约束可行时, $\max_p \min_\eta \mathcal{L} = \min_\eta \max_p \mathcal{L}$ (凸优化 + Slater 条件), 对偶间隙为零。

(b) 最优解为指数族

由 (a) 的推导, 最优 $p^*(x) = \exp(\eta^{*\top} \phi(x) - A(\eta^*))$, 其中 $A(\eta) = \log \sum_x \exp(\eta^\top \phi(x))$ 是对数配分函数 (凸函数)。最大熵分布必为指数族, η^* 通过最小化凸对偶 $A(\eta) - \eta^\top \hat{\mu}$ 确定。

(c) 最大熵分类器 = 逻辑回归

对多分类 (K 类), 特征 $\phi_k(x, y) = x \cdot \mathbf{1}(y = k)$, 最大熵模型:

$$p^*(y|x) = \frac{\exp(\eta_y^\top x)}{\sum_{y'} \exp(\eta_{y'}^\top x)} = \text{softmax}(\eta^\top x)_y$$

权重 η 的估计: 最大化 $\sum_i \log p^*(y_i|x_i)$ (对数似然), 等价于最小化经验分布 $\hat{p}$ 与模型 p^* 之间的 KL 散度: $\min_{\eta} D_{KL}(\hat{p} \| p^*(\cdot; \eta))$ 。这与逻辑回归的最大似然估计完全等价。□

(d) RLHF 最优策略推导

RLHF 问题: 在 KL 散度约束下最大化期望奖励:

$$\max_{\pi} E_{\pi}[r(x)] - \beta D_{KL}(\pi \| \pi_{\text{ref}})$$

写出 Lagrangian (对每个 x):

$$\max_{\pi(x)} \left[\pi(x)r(x) - \beta \pi(x) \log \frac{\pi(x)}{\pi_{\text{ref}}(x)} \right]$$

对 $\pi(x)$ 求导令零: $r(x) - \beta \log \frac{\pi^*(x)}{\pi_{\text{ref}}(x)} - \beta = 0$

解出:

$$\pi^*(x) \propto \pi_{\text{ref}}(x) \exp(r(x)/\beta)$$

归一化: $\pi^*(x) = \frac{\pi_{\text{ref}}(x) \exp(r(x)/\beta)}{Z}$, $Z = \sum_{x'} \pi_{\text{ref}}(x') \exp(r(x')/\beta)$ 。

β 的作用:

- $\beta \rightarrow 0$: $\pi^*(x) \propto \exp(r(x)/\beta) \rightarrow$ 贪婪 (确定性地选奖励最高的输出), 多样性极低但奖励对齐强;
- $\beta \rightarrow \infty$: $\pi^* \rightarrow \pi_{\text{ref}}$ (参考策略), 完全保留多样性但忽略奖励;
- 工程中 β 平衡”奖励对齐”与”分布保真”, 防止奖励黑客 (模型找到高奖励但质量差的输出)。

答案: 最大熵分布为指数族; 最大熵分类器 = 逻辑回归; RLHF 最优策略 $\pi^*(x) \propto \pi_{\text{ref}}(x) \exp(r(x)/\beta)$, β 控制 奖励对齐与生成多样性的权衡。

F6 详解: Part 7 假设检验 (Ch.19-21, 共 29 题)

覆盖范围: 假设检验框架 (Ch.19)、参数检验 (Ch.20)、非参数检验 (Ch.21)。题型: z/t/F/ χ^2 检验、功效计算、Neyman-Pearson 引理、Wilcoxon 秩检验、ANOVA、多重检验校正、置换检验、贝叶斯因子。

C 基础题详解 (10 题)

C.7.1 (Ch.19, 检验框架——两类错误)

题目: H_0 : 产品合格率 $p \geq 0.95$; H_1 : $p < 0.95$ 。识别两类错误并说明显著性水平控制哪类。

思路: 两类错误由假设方向和决策方向共同决定; α 是在 H_0 为真时犯错的概率上限。

解:

步骤 1 (定义):

- 第一类错误 (Type I / 弃真): H_0 为真但被拒绝。
具体描述: 产品实际合格率 $p \geq 0.95$ (合格), 却被检验判为“不合格”, 误拒合格批次。
- 第二类错误 (Type II / 取伪): H_0 为假但未被拒绝。
具体描述: 产品实际合格率 $p < 0.95$ (不合格), 却未能拒绝 H_0 , 放行了不合格批次。

步骤 2 (控制): 显著性水平 $\alpha = P(\text{拒绝 } H_0 \mid H_0 \text{ 为真})$, 即 α 控制第一类错误概率的上限。

答案: α 控制第一类错误 (弃真) 概率的上限

□ 两类错误存在权衡: 降低 α 会导致第二类错误概率 β 上升; 仅靠调节临界值无法同时减小两类错误——增大样本量 n 才能同时降低二者。

C.7.2 (Ch.19, p 值的含义)

题目: p 值为 0.03, $\alpha = 0.05$ 。判断是否拒绝 H_0 , 并辨析 p 值的正确含义。

思路: p 值是数据与 H_0 的相容程度度量, 不是 H_0 为真的概率。

解:

步骤 1 (决策): 因 $p = 0.03 < \alpha = 0.05$, 拒绝 H_0 。

步骤 2 (含义辨析):

- 选项 (A) “ H_0 为真的概率是 0.03”——错误。
频率学派框架中 H_0 要么真要么假, 不是随机事件, 无法谈其概率。
- 选项 (B) “在 H_0 为真的条件下, 观测到此结果或更极端结果的概率是 0.03”——正确。

答案: (B) 正确; $p = 0.03 < 0.05$, 拒绝 H_0

□ p 值不是 “ H_0 为真的概率”, 这是统计推断中最常见的误解之一。 p 值是一个条件概率, 条件是 H_0 为真。

C.7.3 (Ch.19, 单样本 z 检验)

题目: $X \sim N(\mu, \sigma^2 = 25)$, $n = 25$, $\bar{x} = 52$ 。检验 $H_0: \mu = 50$ vs $H_1: \mu \neq 50$, $\alpha = 0.05$ 。

思路: σ 已知用 z 检验; 双侧检验拒绝域为 $|z| > z_{\alpha/2}$ 。

解:

步骤 1 (假设): $H_0: \mu = 50$ vs $H_1: \mu \neq 50$ (双侧)。

步骤 2 (统计量):

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1) \quad (\text{在 } H_0 \text{ 下})$$

步骤 3 (计算):

$$z_{\text{obs}} = \frac{52 - 50}{5/\sqrt{25}} = \frac{2}{5/5} = \frac{2}{1} = 2.0$$

步骤 4 (拒绝域与决策): 拒绝域为 $|Z| > z_{0.025} = 1.96$ 。

因 $|z_{\text{obs}}| = 2.0 > 1.96$, 拒绝 H_0 。

答案: $z_{\text{obs}} = 2.0 > 1.96$, 拒绝 H_0 , 认为 $\mu \neq 50$

C.7.4 (Ch.19, 检验功效的定义)

题目: $H_0: \mu = \mu_0$, $H_1: \mu = \mu_1 > \mu_0$ 。定义检验功效并分析样本量影响。

思路: 功效是“ H_1 为真时能正确拒绝 H_0 ”的概率, 即避免第二类错误的能力。

解:

步骤 1 (功效定义):

$$\text{Power} = 1 - \beta = P(\text{拒绝 } H_0 \mid H_1 \text{ 为真}) = P(\text{拒绝 } H_0 \mid \mu = \mu_1)$$

其中 $\beta = P(\text{不拒绝 } H_0 \mid H_1 \text{ 为真})$ 为第二类错误概率。

步骤 2 (样本量影响):

增大样本量 n 时, 统计量方差减小 ($\text{Var}(\bar{X}) = \sigma^2/n$), 检验的区分能力增强, 功效增大。

直觉: n 越大, 即使真实均值只是略微偏离 μ_0 , 也能以更高概率检测到差异。

答案: $\text{Power} = P(\text{拒绝 } H_0 \mid \mu = \mu_1)$; 增大 $n \Rightarrow$ 功效增大

C.7.5 (Ch.20, 单样本 t 检验)

题目: σ^2 未知, $n = 16$, $\bar{x} = 10.8$, $s = 2.0$ 。检验 $H_0: \mu = 10$ vs $H_1: \mu \neq 10$, $\alpha = 0.05$, $t_{0.025}(15) = 2.131$ 。

思路: σ 未知且样本量小时用 t 检验, 自由度 $df = n - 1 = 15$ 。

解:

步骤 1 (假设): $H_0: \mu = 10$ vs $H_1: \mu \neq 10$ (双侧)。

步骤 2 (统计量):

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1) \quad (\text{在 } H_0 \text{ 下})$$

步骤 3 (计算):

$$t_{\text{obs}} = \frac{10.8 - 10}{2.0/\sqrt{16}} = \frac{0.8}{2.0/4} = \frac{0.8}{0.5} = 1.6$$

步骤 4 (拒绝域与决策): 拒绝域为 $|T| > t_{0.025}(15) = 2.131$ 。

因 $|t_{\text{obs}}| = 1.6 < 2.131$, 不拒绝 H_0 。

答案: $t_{\text{obs}} = 1.6 < 2.131$, 不拒绝 H_0 , 无充分证据认为 $\mu \neq 10$

C.7.6 (Ch.20, 独立双样本 t 检验条件)

题目: 列出独立双样本 t 检验的三个基本假设条件。

思路: 参数检验依赖数据生成机制的假设, 违反这些假设会导致结论不可靠。

解:

独立双样本 t 检验的三个基本假设:

1. 独立性: 两组样本相互独立, 且各组内观测值也相互独立。
2. 正态性: 两总体均服从正态分布 (小样本时尤为重要; 样本量足够大时由中心极限定理保障近似成立)。
3. 方差齐性 (等方差): 两总体方差相等, 即 $\sigma_1^2 = \sigma_2^2$ (用于计算合并方差 S_p^2)。若方差不等, 应改用 Welch's t 检验。

答案: 独立性、正态性、方差齐性 ($\sigma_1^2 = \sigma_2^2$)

C.7.7 (Ch.20, 方差齐性 F 检验)

题目: $s_1^2 = 8$ ($n_1 = 11$), $s_2^2 = 4$ ($n_2 = 9$)。检验 $H_0: \sigma_1^2 = \sigma_2^2$, 写出统计量及分布, 计算 F 值。

思路: 两个独立正态总体方差比的枢轴量服从 F 分布。

解:

步骤 1 (统计量及分布):

$$F = \frac{S_1^2}{S_2^2} \sim F(n_1 - 1, n_2 - 1) = F(10, 8) \quad (\text{在 } H_0 \text{ 下})$$

步骤 2 (计算):

$$F_{\text{obs}} = \frac{s_1^2}{s_2^2} = \frac{8}{4} = 2.0$$

(决策需查 $F_{0.025}(10, 8)$ 和 $F_{0.975}(10, 8)$ 两端临界值, 此题仅要求写出统计量和计算数值。)

答案: $F = S_1^2/S_2^2 \sim F(10, 8), F_{\text{obs}} = 2.0$

C.7.8 (Ch.20, 卡方拟合优度检验)

题目: 掷骰子 60 次, 各点次数 $\{8, 12, 9, 11, 10, 10\}$ 。检验 H_0 : 各点概率均为 $1/6$ 。

思路: 拟合优度检验比较观测频数与期望频数的偏差; 自由度 = 格子数 - 1 (无估计参数)。

解:

步骤 1 (期望频数): 在 H_0 下, 每面期望次数为:

$$E_i = 60 \times \frac{1}{6} = 10 \quad (i = 1, 2, \dots, 6)$$

步骤 2 (统计量):

$$\chi^2 = \sum_{i=1}^6 \frac{(O_i - E_i)^2}{E_i} = \frac{(8-10)^2}{10} + \frac{(12-10)^2}{10} + \frac{(9-10)^2}{10} + \frac{(11-10)^2}{10} + \frac{(10-10)^2}{10} + \frac{(10-10)^2}{10}$$

步骤 3 (分布): 在 H_0 下, 当 n 足够大时:

$$\chi^2 \sim \chi^2(k-1) = \chi^2(5)$$

自由度 $df = k - 1 = 6 - 1 = 5$ ($k = 6$ 个格子, 无待估参数)。

答案: $E_i = 10; \chi^2 = \sum (O_i - E_i)^2 / E_i \sim \chi^2(5)$

C.7.9 (Ch.21, 符号检验)

题目: 差值 $\{+3, -1, +5, +2, -2, +4, +1, +3\}$, 检验 H_0 : 总体中位数差为 0。

思路: 符号检验只利用差值的正负号, 是中位数的非参数检验; 在 H_0 下正号和负号等可能。

解:

步骤 1 (统计正负号):

- 正号 (+): $+3, +5, +2, +4, +1, +3 \rightarrow$ 共 6 个
- 负号 (-): $-1, -2 \rightarrow$ 共 2 个
- 差值为 0: 无 (均不忽略)
- 有效观测 $n = 8$

步骤 2 (零假设下的分布):

在 H_0 (中位数差为 0) 下, 每个差值正负各有 $1/2$ 的概率, 正号个数 B 服从:

$$B \sim \text{Binomial}(n = 8, p = 0.5)$$

(若 B 或 $8 - B$ 足够小即为拒绝域; 具体双侧临界值查二项表。)

答案: $6 \quad 2 \quad H_0 \quad B \sim B(8, 0.5)$

C.7.10 (Ch.21, Kolmogorov-Smirnov 检验)

题目: KS 检验中 $F_n(x)$ 是什么? D_n 超过临界值时的结论。

思路: KS 检验基于经验分布函数与假设分布函数的最大偏差。

解:

步骤 1 ($F_n(x)$ 的定义):

$F_n(x)$ 是经验分布函数 (Empirical Distribution Function, EDF):

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}[X_i \leq x]$$

即样本中不超过 x 的观测值所占比例。

步骤 2 (决策):

若 $D_n = \sup_x |F_n(x) - F_0(x)|$ 超过在 α 水平下的 KS 临界值, 则拒绝 H_0 , 认为数据不服从假设分布 F_0 。

D_n 越大, 说明经验分布与假设分布的偏差越大, 数据越不像来自 F_0 。

答案: $F_n(x)$ 为经验分布函数; $D_n >$ 临界值则拒绝 H_0

□ KS 检验对分布的中间部分最灵敏, 对尾部偏差不够敏感; 若对尾部偏差更关注, 可用 Anderson-Darling 检验。

D 中等题详解 (12 题)

D.7.1 (Ch.19, 单均值 z 检验)

题目: $\mu_0 = 50$, $\sigma = 8$ 已知, $n = 64$, $\bar{X} = 48.5$ 。双侧检验, $\alpha = 0.05$; 计算 p 值并解释。

思路: σ 已知用 z 检验; p 值是双侧尾概率之和。

解:

步骤 1 (假设):

$$H_0: \mu = 50 \quad \text{vs} \quad H_1: \mu \neq 50$$

步骤 2 (统计量及分布):

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1) \quad (\text{在 } H_0 \text{ 下})$$

步骤 3 (计算统计量):

$$z_{\text{obs}} = \frac{48.5 - 50}{8/\sqrt{64}} = \frac{-1.5}{8/8} = \frac{-1.5}{1} = -1.5$$

步骤 4 (临界值与决策):

拒绝域: $|Z| > z_{0.025} = 1.96$ 。

因 $|z_{\text{obs}}| = 1.5 < 1.96$, 不拒绝 H_0 。

步骤 5 (p 值计算):

$$p = 2P(Z < -1.5) = 2 \times \Phi(-1.5) \approx 2 \times 0.0668 = 0.1336$$

步骤 6 (p 值解释):

p 值的含义: 在 H_0 ($\mu = 50$) 为真的条件下, 观测到检验统计量偏离 0 的程度达到 $|z| \geq 1.5$ (或更极端) 的概率约为 13.4%。

因 $p = 0.134 > 0.05$, 数据与 H_0 相容, 不拒绝 H_0 。

答案: $z_{\text{obs}} = -1.5, p \approx 0.134 > 0.05$, 不拒绝 H_0

□ p 值 $\approx 13.4\%$ 不意味着“ H_0 为真的概率是 13.4%”, 而是数据与 H_0 相容的程度度量。

D.7.2 (Ch.19, 单均值 t 检验)

题目: $\mu_0 = 75, n = 16, \bar{X} = 78, S = 8$ 。单侧检验 $H_0: \mu \leq 75$ vs $H_1: \mu > 75, \alpha = 0.05, t_{0.05}(15) \approx 1.753$; 若真实值 $\mu_1 = 80$, 求功效。

思路: 单侧 t 检验; 功效需用非中心 t 分布或正态近似计算。

解:

步骤 1 (假设):

$$H_0: \mu \leq 75 \quad \text{vs} \quad H_1: \mu > 75 \quad (\text{单侧右尾})$$

步骤 2 (统计量):

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(15) \quad (\text{在 } H_0 \text{ 边界 } \mu = 75 \text{ 下})$$

步骤 3 (计算):

$$t_{\text{obs}} = \frac{78 - 75}{8/\sqrt{16}} = \frac{3}{8/4} = \frac{3}{2} = 1.5$$

步骤 4 (决策):

拒绝域: $T > t_{0.05}(15) = 1.753$ 。

因 $t_{\text{obs}} = 1.5 < 1.753$, 不拒绝 H_0 (在 $\alpha = 0.05$ 下无足够证据认为均值 > 75)。

步骤 5 (功效计算, $\mu_1 = 80$):

非中心参数:

$$\delta = \frac{\mu_1 - \mu_0}{S/\sqrt{n}} = \frac{80 - 75}{8/4} = \frac{5}{2} = 2.5$$

功效为非中心 t 分布的上尾概率, 近似方法:

当 $H_1: \mu = 80$ 时, T 的均值约为 $\delta = 2.5$, 利用正态近似:

$$\text{Power} \approx P(Z > z_{0.05} - \delta) = P(Z > 1.645 - 2.5) = P(Z > -0.855) \approx \Phi(0.855) \approx 0.804$$

即在真实均值为 80 时, 此检验约有 **80.4%** 的概率正确拒绝 H_0 。

答案: $t_{\text{obs}} = 1.5 < 1.753$, 不拒绝 H_0 ; 功效 $\approx 80\%$ $\mu_1 = 80$

D.7.3 (Ch.19, 两类错误与检验的功效)

题目: $H_0: \mu = 0$ vs $H_1: \mu = 1$, $X \sim N(\mu, 1)$, 拒绝域 $X > c$ 。推导两类错误表达式, 分析权衡。

思路: 简单假设的两类错误均可用标准正态计算; 两者随 c 单调方向相反, 增大 n 才能同时减小。

解:

步骤 1 (第一类错误):

$$\alpha(c) = P(X > c \mid \mu = 0) = P(Z > c) = 1 - \Phi(c)$$

其中 $Z = X \sim N(0, 1)$ (因 $\sigma = 1$, $n = 1$)。

步骤 2 (第二类错误):

$$\beta(c) = P(X \leq c \mid \mu = 1) = P(Z \leq c - 1) = \Phi(c - 1)$$

其中 $Z = X - 1 \sim N(0, 1)$ (在 H_1 下)。

步骤 3 (权衡分析):

临界值 c	$\alpha(c) = 1 - \Phi(c)$	$\beta(c) = \Phi(c - 1)$	$\alpha + \beta$
0	0.500	0.159	0.659
0.5	0.309	0.309	0.618
1	0.159	0.500	0.659

- c 增大: α 减小, β 增大 (拒绝域变窄)。
- c 减小: α 增大, β 减小。
- $\alpha + \beta$ 有最小值但不能同时为零。

步骤 4 (增大 n 的效果): 若观测 n 个样本取均值, 统计量变为 $\bar{X} \sim N(\mu, 1/n)$, 则

$$\alpha(c) = 1 - \Phi(c\sqrt{n}), \quad \beta(c) = \Phi((c-1)\sqrt{n})$$

选 $c = 0.5$ (中点) 时, $\alpha = \beta = 1 - \Phi(0.5\sqrt{n}) \rightarrow 0$ as $n \rightarrow \infty$ 。

答案: $\alpha(c) = 1 - \Phi(c), \beta(c) = \Phi(c-1)$; 增大 n 可同时减小两类错误

D.7.4 (Ch.20, 方差的 χ^2 检验)

题目: $\sigma_0^2 = 4$, $n = 25$, $S^2 = 5.8$ 。单侧检验 $H_0: \sigma^2 = 4$ vs $H_1: \sigma^2 > 4$, $\alpha = 0.05$, $\chi_{0.05}^2(24) \approx 36.42$ 。

思路: 正态总体方差检验用 χ^2 统计量; 单侧右尾检验只看右端临界值。

解:

步骤 1 (假设):

$$H_0: \sigma^2 = 4 \quad \text{vs} \quad H_1: \sigma^2 > 4 \quad (\text{单侧右尾})$$

步骤 2 (统计量及分布):

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1) = \chi^2(24) \quad (\text{在 } H_0 \text{ 下})$$

步骤 3 (计算):

$$\chi_{\text{obs}}^2 = \frac{24 \times 5.8}{4} = \frac{139.2}{4} = 34.8$$

步骤 4 (决策):

拒绝域: $\chi^2 > \chi_{0.05}^2(24) = 36.42$ 。

因 $\chi_{\text{obs}}^2 = 34.8 < 36.42$, 不拒绝 H_0 (无足够证据认为方差大于 4)。

步骤 5 (双侧拒绝域):

若改为双侧检验 $H_1: \sigma^2 \neq 4$, 拒绝域为:

$$\chi^2 < \chi_{0.975}^2(24) \approx 12.40 \quad \text{或} \quad \chi^2 > \chi_{0.025}^2(24) \approx 39.36$$

(双侧各取 $\alpha/2 = 0.025$ 。)

答案: $\chi_{\text{obs}}^2 = 34.8 < 36.42$, 不拒绝 H_0 ; 双侧域: (12.40, 39.36) 之外

D.7.5 (Ch.20, 两均值 t 检验, 等方差)

题目: $n_1 = 8$, $\bar{X}_1 = 20.5$, $S_1^2 = 6$; $n_2 = 10$, $\bar{X}_2 = 18.0$, $S_2^2 = 7$ 。等方差, $H_0: \mu_1 = \mu_2$, $\alpha = 0.05$, $t_{0.025}(16) \approx 2.120$ 。

思路: 等方差假设下合并两组方差估计; 合并方差是加权平均。

解:

步骤 1 (假设):

$$H_0: \mu_1 = \mu_2 \quad \text{vs} \quad H_1: \mu_1 \neq \mu_2 \quad (\text{双侧})$$

步骤 2 (合并方差):

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2} = \frac{7 \times 6 + 9 \times 7}{8 + 10 - 2} = \frac{42 + 63}{16} = \frac{105}{16} = 6.5625$$

步骤 3 (统计量):

$$T = \frac{(\bar{X}_1 - \bar{X}_2) - 0}{S_p \sqrt{1/n_1 + 1/n_2}} \sim t(n_1 + n_2 - 2) = t(16) \quad (\text{在 } H_0 \text{ 下})$$

$$t_{\text{obs}} = \frac{20.5 - 18.0}{\sqrt{6.5625 \times (1/8 + 1/10)}} = \frac{2.5}{\sqrt{6.5625 \times 0.225}} = \frac{2.5}{\sqrt{1.4766}} = \frac{2.5}{1.215} \approx 2.058$$

步骤 4 (决策):

拒绝域: $|T| > t_{0.025}(16) = 2.120$ 。

因 $|t_{\text{obs}}| = 2.058 < 2.120$, 不拒绝 H_0 (边界情况, 差异不显著)。

步骤 5 (先行 F 检验等方差):

在做双均值 t 检验前, 用 $F = S_1^2/S_2^2 = 6/7 \approx 0.857$ 检验 $H'_0: \sigma_1^2 = \sigma_2^2$ ($F(7, 9)$ 分布)。若 F 检验不拒绝, 则使用等方差 t 检验; 若拒绝, 改用 Welch's t 检验 (自由度用 Satterthwaite 近似)。

答案: $S_p^2 \approx 6.56$, $t_{\text{obs}} \approx 2.06 < 2.12$, 不拒绝 H_0

D.7.6 (Ch.20, 配对 t 检验)

题目: 10 名受试者治疗前后血压数据, 计算差值并检验 $H_0: \mu_D = 0$ vs $H_1: \mu_D > 0$, $\alpha = 0.05$, $t_{0.05}(9) \approx 1.833$ 。

思路: 配对设计将差值 $D_i = \text{前} - \text{后}$ 视为单样本, 消除个体间差异。

解:

步骤 1 (计算差值):

受试者	1	2	3	4	5	6	7	8	9	10
前	120	135	128	142	118	130	125	138	122	131
后	115	129	124	137	120	128	122	134	120	127
D_i	5	6	4	5	-2	2	3	4	2	4

步骤 2 (计算 $\bar{D}$ 和 S_D):

$$\bar{D} = \frac{5 + 6 + 4 + 5 + (-2) + 2 + 3 + 4 + 2 + 4}{10} = \frac{33}{10} = 3.3$$

$$S_D^2 = \frac{\sum_{i=1}^{10} (D_i - \bar{D})^2}{n - 1}$$

$$\begin{aligned} \text{各偏差: } & (1.7)^2, (2.7)^2, (0.7)^2, (1.7)^2, (-5.3)^2, (-1.3)^2, (-0.3)^2, (0.7)^2, (-1.3)^2, (0.7)^2 \\ & = 2.89 + 7.29 + 0.49 + 2.89 + 28.09 + 1.69 + 0.09 + 0.49 + 1.69 + 0.49 = 46.10 \end{aligned}$$

$$S_D^2 = \frac{46.10}{9} \approx 5.122, \quad S_D \approx 2.263$$

步骤 3 (统计量):

$$T = \frac{\bar{D}}{S_D / \sqrt{n}} = \frac{3.3}{2.263 / \sqrt{10}} = \frac{3.3}{0.716} \approx 4.61$$

步骤 4 (决策):

拒绝域: $T > t_{0.05}(9) = 1.833$ 。

因 $t_{\text{obs}} = 4.61 \gg 1.833$, 拒绝 H_0 , 有强烈证据认为治疗使血压下降。

步骤 5 (配对设计的优势):

配对设计将个体间差异(基线血压高低不同)从误差中剥离,只分析每人自身的变化量 D_i , S_D 反映个体内变异而非个体间变异,因此比独立双样本 t 检验有更高的统计功效(等效样本量更小即可达到同等功效)。

答案: $\bar{D} = 3.3, S_D \approx 2.26, t_{\text{obs}} \approx 4.61 \gg 1.833$, 拒绝 H_0

D.7.7 (Ch.19, Neyman-Pearson 引理)

题目: $X \sim N(\mu, 1)$, $H_0: \mu = 0$ vs $H_1: \mu = 1$, 单次观测。推导拒绝域, 解释最优势检验, 讨论 UMP 存在条件。

思路: NP 引理给出简单假设对下的最优检验; 对指数族, 似然比为 T 的单调函数, 可推广到 UMP。

解:

步骤 1 (似然比):

$$\Lambda(x) = \frac{f(x; \mu = 1)}{f(x; \mu = 0)} = \frac{\frac{1}{\sqrt{2\pi}} e^{-(x-1)^2/2}}{\frac{1}{\sqrt{2\pi}} e^{-x^2/2}} = e^{x-1/2}$$

步骤 2 (化简拒绝域):

NP 引理要求当 $\Lambda(x) > k$ 时拒绝 H_0 , 即:

$$e^{x-1/2} > k \iff x > \ln k + \frac{1}{2} \equiv c$$

拒绝域等价于 $X > c$ (右尾检验)。由水平约束 $\alpha = P(X > c \mid \mu = 0) = 1 - \Phi(c)$, 得 $c = z_\alpha$ (如 $\alpha = 0.05$ 时 $c = 1.645$)。

步骤 3 (最优势的含义):

“水平 α 下的最优势检验 (Most Powerful Test)”指: 在所有控制第一类错误 $\leq \alpha$ 的检验中, 此检验的功效 ($P(\text{拒绝 } H_0 \mid H_1 \text{ 为真})$) 最大。任何其他同水平检验的功效不超过 NP 检验的功效。

步骤 4 (复合 H_1 与 UMP):

对复合 $H_1: \mu > 0$, NP 引理不直接适用 (因每个不同的 $\mu_1 > 0$ 对应不同的 NP 检验)。但正态分布属于指数族, 具有单调似然比 (**Monotone Likelihood Ratio, MLR**) 性质: $\Lambda(\mu_1, \mu_0; x)$ 关于充分统计量 $\bar{X}$ (此处为 X) 单调递增。

由此可证明存在一致最优势 (UMP) 检验: 拒绝域 $X > c$ 对所有 $\mu_1 > 0$ 均最优。一般地, 指数族一维参数的单侧假设存在 UMP; 双侧假设 $H_1: \mu \neq \mu_0$ 通常不存在 UMP。

答案: $\Lambda(x) = e^{x-1/2}$, 拒绝域 $X > z_\alpha$; 最优势指功效最大; 单边复合 H_1 存在 UMP (MLR 条件)

D.7.8 (Ch.21, Wilcoxon 符号秩检验)

题目: $n = 8$ 个差值: $+3, -1, +5, +2, -4, +1, +6, +2$ 。双侧检验 H_0 : 中位数为 0, $\alpha = 0.05$, 临界值 $W = 4$ 。

思路: Wilcoxon 符号秩检验用绝对值的秩携带量级信息, 比纯符号检验更有效。

解:

步骤 1 (计算绝对值并排序):

差值 D_i	$ D_i $	秩	符号秩
+1	1	1	+1
-1	1	1	-1
+2	2	3	+3
+2	2	3	+3
+3	3	5	+5
-4	4	6	-6
+5	5	7	+7
+6	6	8	+8

排秩说明: $|D_i|$ 从小到大排列; $|D| = 1$ 有两个 (+1 和 -1), 平均秩 $= (1 + 2)/2 = 1.5$; $|D| = 2$ 有两个 (两个 +2), 平均秩 $= (3 + 4)/2 = 3.5$ 。

修正后:

差值 D_i	$ D_i $	平均秩	符号秩
+1	1	1.5	+1.5
-1	1	1.5	-1.5
+2	2	3.5	+3.5
+2	2	3.5	+3.5
+3	3	5	+5
-4	4	6	-6
+5	5	7	+7
+6	6	8	+8

步骤 2 (计算正秩和与负秩和):

$$T^+ = 1.5 + 3.5 + 3.5 + 5 + 7 + 8 = 28.5$$

$$T^- = 1.5 + 6 = 7.5$$

验证: $T^+ + T^- = 28.5 + 7.5 = 36 = n(n+1)/2 = 8 \times 9/2 = 36 \square$

步骤 3 (决策):

检验统计量取 $T = \min(T^+, T^-) = 7.5$ 。

临界值 $W = 4$ ($n = 8$, 双侧 $\alpha = 0.05$): 当 $T \leq W$ 时拒绝 H_0 。

因 $T = 7.5 > 4$, 不拒绝 H_0 。

步骤 4 (与参数 t 检验比较):

参数 t 检验利用差值的均值和方差, 假设差值来自正态分布; Wilcoxon 符号秩检验无正态假设, 对异常值更鲁棒。当数据正态时, t 检验功效略高 (渐近相对效率 ≈ 0.955); 数据有重尾时 Wilcoxon 更优。

答案: $T^+ = 28.5, T^- = 7.5, T = 7.5 > 4$, 不拒绝 H_0

D.7.9 (Ch.20, 单因素方差分析 ANOVA)

题目: 三组各 $n_i = 5$: 组 1: 12,14,11,13,10; 组 2: 20,22,19,21,18; 组 3: 15,17,16,14,18。检验三组均值是否相等, $F_{0.05}(2, 12) \approx 3.89$ 。

思路: ANOVA 将总变差分解为组间和组内两部分, 用 F 比检验均值差异。

解:

步骤 1 (计算各组均值和总均值):

$$\bar{X}_1 = \frac{12 + 14 + 11 + 13 + 10}{5} = \frac{60}{5} = 12$$

$$\bar{X}_2 = \frac{20 + 22 + 19 + 21 + 18}{5} = \frac{100}{5} = 20$$

$$\bar{X}_3 = \frac{15 + 17 + 16 + 14 + 18}{5} = \frac{80}{5} = 16$$

$$\bar{X} = \frac{60 + 100 + 80}{15} = \frac{240}{15} = 16$$

步骤 2 (计算 SS):

组间平方和 ($df_B = k - 1 = 2$):

$$SS_B = \sum_{i=1}^3 n_i (\bar{X}_i - \bar{X})^2 = 5(12 - 16)^2 + 5(20 - 16)^2 + 5(16 - 16)^2$$

$$= 5 \times 16 + 5 \times 16 + 0 = 80 + 80 + 0 = 160$$

组内平方和 ($df_W = N - k = 15 - 3 = 12$):

- 组 1: $(12 - 12)^2 + (14 - 12)^2 + (11 - 12)^2 + (13 - 12)^2 + (10 - 12)^2 = 0 + 4 + 1 + 1 + 4 = 10$
- 组 2: $(20 - 20)^2 + (22 - 20)^2 + (19 - 20)^2 + (21 - 20)^2 + (18 - 20)^2 = 0 + 4 + 1 + 1 + 4 = 10$
- 组 3: $(15 - 16)^2 + (17 - 16)^2 + (16 - 16)^2 + (14 - 16)^2 + (18 - 16)^2 = 1 + 1 + 0 + 4 + 4 = 10$

$$SS_W = 10 + 10 + 10 = 30$$

步骤 3 (均方与 F 统计量):

$$MS_B = \frac{SS_B}{df_B} = \frac{160}{2} = 80, \quad MS_W = \frac{SS_W}{df_W} = \frac{30}{12} = 2.5$$

$$F_{\text{obs}} = \frac{MS_B}{MS_W} = \frac{80}{2.5} = 32$$

步骤 4 (决策):

拒绝域: $F > F_{0.05}(2, 12) = 3.89$ 。

因 $F_{\text{obs}} = 32 \gg 3.89$, 强烈拒绝 H_0 , 三组均值有极显著差异。

ANOVA 汇总表:

来源	SS	df	MS	F
组间	160	2	80	32
组内	30	12	2.5	
总计	190	14		

答案: $F_{\text{obs}} = 32 \gg 3.89$, 拒绝 H_0 , 三组均值差异极显著

□ ANOVA 拒绝 H_0 只说明“至少两组均值不同”, 不指明哪两组不同——需进一步做事后多重比较 (Tukey HSD、Bonferroni 等)。

D.7.10 (Ch.21, 卡方拟合优度检验)

题目: 掷骰子 120 次, 各面次数: 18, 22, 17, 25, 19, 19。检验均匀性, $\alpha = 0.05$, $\chi_{0.05}^2(5) \approx 11.07$ 。

思路: 拟合优度检验: 期望频数 $E_i = np_i$, 统计量自由度 = 格子数 - 1 - 估计参数数。

解:

步骤 1 (理论频数): H_0 下每面概率 $1/6$, 理论频数:

$$E_i = 120 \times \frac{1}{6} = 20 \quad (i = 1, \dots, 6)$$

步骤 2 (计算 χ^2 统计量):

$$\begin{aligned} \chi^2 &= \sum_{i=1}^6 \frac{(O_i - E_i)^2}{E_i} = \frac{(18 - 20)^2}{20} + \frac{(22 - 20)^2}{20} + \frac{(17 - 20)^2}{20} + \frac{(25 - 20)^2}{20} + \frac{(19 - 20)^2}{20} + \frac{(19 - 20)^2}{20} \\ &= \frac{4}{20} + \frac{4}{20} + \frac{9}{20} + \frac{25}{20} + \frac{1}{20} + \frac{1}{20} = \frac{44}{20} = 2.2 \end{aligned}$$

步骤 3 (决策):

$$df = 6 - 1 = 5, \chi_{0.05}^2(5) \approx 11.07.$$

因 $\chi_{\text{obs}}^2 = 2.2 < 11.07$, 不拒绝 H_0 , 无证据认为骰子不均匀。

p 值 = $P(\chi^2(5) > 2.2) > 0.50$ (远不显著)。

步骤 4 (期望次数 < 5 时的处理):

当某个格子的期望频数 $E_i < 5$ 时, χ^2 近似的准确性下降。标准处理方式是合并相邻格子 (合并后 $E_i \geq 5$), 同时相应减少自由度。一般要求所有 $E_i \geq 1$ 且不超过 20% 的格子 $E_i < 5$ 。

答案: $\chi_{\text{obs}}^2 = 2.2 < 11.07$, 不拒绝 H_0 , 骰子无显著不均匀

D.7.11 (Ch.21, 独立性卡方检验)

题目: 性别与吸烟的 2×2 列联表 (200 人)。计算期望频数、 χ^2 统计量、Phi 系数。

思路: 独立性检验: 期望频数 = 行和 $\times$ 列和 / 总数; $\phi = \sqrt{\chi^2/n}$ 衡量效应大小。

解:

步骤 1 (观测频数表):

	吸烟	不吸烟	合计
男	$O_{11} = 60$	$O_{12} = 40$	$R_1 = 100$
女	$O_{21} = 30$	$O_{22} = 70$	$R_2 = 100$
合计	$C_1 = 90$	$C_2 = 110$	$n = 200$

步骤 2 (期望频数): $E_{ij} = R_i C_j / n$:

$$E_{11} = \frac{100 \times 90}{200} = 45, \quad E_{12} = \frac{100 \times 110}{200} = 55$$

$$E_{21} = \frac{100 \times 90}{200} = 45, \quad E_{22} = \frac{100 \times 110}{200} = 55$$

步骤 3 (χ^2 统计量):

$$\begin{aligned} \chi^2 &= \frac{(60-45)^2}{45} + \frac{(40-55)^2}{55} + \frac{(30-45)^2}{45} + \frac{(70-55)^2}{55} \\ &= \frac{225}{45} + \frac{225}{55} + \frac{225}{45} + \frac{225}{55} = 5 + 4.09 + 5 + 4.09 = 18.18 \end{aligned}$$

步骤 4 (决策):

$$df = (2-1)(2-1) = 1, \quad \chi_{0.05}^2(1) \approx 3.84.$$

因 $\chi_{\text{obs}}^2 = 18.18 \gg 3.84$, 强烈拒绝 H_0 (性别与吸烟显著相关)。

步骤 5 (Phi 系数):

$$\phi = \sqrt{\frac{\chi^2}{n}} = \sqrt{\frac{18.18}{200}} = \sqrt{0.0909} \approx 0.302$$

Phi 系数类似于相关系数 (范围 $[0, 1]$), $|\phi| \approx 0.3$ 表示中等程度的关联。 $\phi^2 = \chi^2/n$ 是“解释方差比例”的类似量, $\phi^2 \approx 0.091$, 即约 9.1% 的变差可由性别-吸烟关联解释。

答案: $\chi_{\text{obs}}^2 \approx 18.18 \gg 3.84$, 拒绝独立性 H_0 ; $\phi \approx 0.302$ (中等关联)

D.7.12 (Ch.19, 多重检验问题)

题目: 同时检验 $m = 20$ 个独立真零假设, 每个 $\alpha = 0.05$ 。计算 FWER, Bonferroni 校正, 并描述 BH 方法。

思路: 多个检验时误报率随检验数膨胀; Bonferroni 保守但严格控制 FWER; BH 控制 FDR 更宽松。

解:

步骤 1 (FWER 计算):

$m = 20$ 个独立检验, 每个犯第一类错误的概率为 $\alpha = 0.05$ 。

$$\text{FWER} = P(\text{至少一个假阳性}) = 1 - P(\text{所有均不误报}) = 1 - (1 - \alpha)^m$$

$$= 1 - (0.95)^{20} \approx 1 - 0.3585 = 0.6415$$

即约 **64.2%** 的概率至少出现一次假阳性——远超名义显著性水平 5%。

步骤 2 (Bonferroni 校正):

将每个检验水平调为 $\alpha^* = \alpha/m = 0.05/20 = 0.0025$, 则:

$$\text{FWER} \leq m \cdot \alpha^* = 20 \times 0.0025 = 0.05$$

(利用 Boole 不等式: $P(\bigcup_i A_i) \leq \sum_i P(A_i)$, 无需独立性假设。)

Bonferroni 校正将 FWER 控制在 0.05 以内。代价是每个检验的功效下降。

步骤 3 (BH 方法思路):

设 $m = 20$ 个假设中有 5 个为假 ($m_0 = 15$ 个真零假设)。

Benjamini-Hochberg (BH) 程序:

1. 将 m 个 p 值从小到大排序: $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(20)}$ 。
2. 找最大的 k 使得 $p_{(k)} \leq k \cdot \alpha/m$ (即 $p_{(k)} \leq k \times 0.05/20$)。
3. 拒绝 $H_{0,(1)}, H_{0,(2)}, \dots, H_{0,(k)}$ (前 k 个最小 p 值对应的假设)。

BH 控制的是 $\text{FDR} = E[\text{假阳性数} / \max(\text{拒绝数}, 1)] \leq \alpha \cdot m_0/m \leq \alpha$ 。

比 Bonferroni 宽松的原因:

- Bonferroni 控制 FWER (任一假阳性的概率), 是最严格的错误指标。
- BH 控制 FDR (假阳性占拒绝数的期望比例), 允许存在少量假阳性, 检验功效 (真阳性发现数) 显著提升。
- 当 $m_0 < m$ (部分假设为假) 时, BH 的有效校正阈值更宽松, 功效优势更明显。

答案: FWER $\approx$ 64.2%; Bonferroni: $\alpha^* = 0.0025$, FWER $\leq$ 5%; BH 控制 FDR, 功效更高

☐ Bonferroni 校正假设检验相互独立 (或正相关), 若检验间存在负相关则可能过于保守。BH 方法在独立或正相关 (PRDS 条件) 下成立。

E 提高题详解 (7 题)

E.7.1 (Ch.19, Neyman-Pearson 引理 + 最优检验 + 似然比检验)

题目: 证明 NP 引理, 推广到 UMP, 计算正态模型最优检验, 讨论 ROC 与 AUC。

思路: NP 引理通过比较两个检验的功效差推导最优性; 指数族 MLR 保证 UMP; $AUC = P(\text{正例得分} > \text{负例得分})$ 。

解:

(a) NP 引理的证明

设 ϕ^* 为似然比检验:

$$\phi^*(x) = \begin{cases} 1 & \text{if } \Lambda(x) = L(\theta_1; x)/L(\theta_0; x) > k \\ \gamma & \text{if } \Lambda(x) = k \\ 0 & \text{if } \Lambda(x) < k \end{cases}$$

其中 k, γ 选取使得 $E_{\theta_0}[\phi^*] = \alpha$ (满足水平约束)。

设 ϕ 为任意满足 $E_{\theta_0}[\phi] \leq \alpha$ 的检验。需证 $E_{\theta_1}[\phi^*] \geq E_{\theta_1}[\phi]$ 。

考虑差:

$$E_{\theta_1}[\phi^* - \phi] = \int (\phi^* - \phi) f(x; \theta_1) dx$$

注意到当 $\phi^* > \phi$ (即 ϕ^* 拒绝而 ϕ 不拒绝时), 必有 $\Lambda(x) \geq k$, 故 $f(x; \theta_1) \geq k f(x; \theta_0)$; 类似地, 当 $\phi^* < \phi$ 时, $f(x; \theta_1) \leq k f(x; \theta_0)$ 。

因此:

$$E_{\theta_1}[\phi^* - \phi] \geq k \int (\phi^* - \phi) f(x; \theta_0) dx = k(E_{\theta_0}[\phi^*] - E_{\theta_0}[\phi]) \geq k(\alpha - \alpha) = 0$$

故 $E_{\theta_1}[\phi^*] \geq E_{\theta_1}[\phi]$, NP 引理成立。□

(b) 推广到 UMP: 指数族单调似然比

设 $\{p_\theta\}$ 为指数族: $p_\theta(x) = h(x) \exp(\eta(\theta)T(x) - A(\theta))$, $\eta(\theta)$ 单调递增。

则似然比 $\Lambda(\theta_1, \theta_0; x) = \exp((\eta(\theta_1) - \eta(\theta_0))T(x) - (A(\theta_1) - A(\theta_0)))$ 关于充分统计量 $T(x)$ 单调递增 (当 $\theta_1 > \theta_0$, 即 $\eta(\theta_1) > \eta(\theta_0)$)。

此单调似然比 (MLR) 性质保证: 对任意 $\theta_0 < \theta_1$, NP 最优检验 $\{T(x) > c\}$ 与 θ_1 无关, 故它对所有 $\theta_1 > \theta_0$ 均最优, 即存在一致最优势检验 (UMP)。

(c) 正态模型数值计算 ($n = 25$, $\alpha = 0.05$)

检验 $H_0: \mu = 0$ vs $H_1: \mu = 1$, $X_i \sim N(\mu, 1)$, $\bar{X} = \frac{1}{25} \sum X_i \sim N(\mu, 1/25)$ 。

最优拒绝域 (NP 引理):

$$\bar{X} > c, \quad \text{其中 } P(\bar{X} > c \mid \mu = 0) = 0.05$$

$$\frac{c-0}{1/\sqrt{25}} = z_{0.05} = 1.645 \implies c = \frac{1.645}{5} = 0.329$$

功效 ($H_1: \mu = 1$):

$$\text{Power} = P(\bar{X} > 0.329 \mid \mu = 1) = P\left(Z > \frac{0.329-1}{1/5}\right) = P(Z > -3.355) = \Phi(3.355) \approx 0.9996$$

第二类错误率: $\beta = 1 - \text{Power} \approx 0.0004$ (极低, 因 $n = 25$ 足够大且 $\mu_1 - \mu_0 = 1$)。

功效函数的形状 (关于 μ):

$$\pi(\mu) = P(\bar{X} > 0.329 \mid \mu) = 1 - \Phi\left(\frac{0.329 - \mu}{0.2}\right)$$

- $\mu \rightarrow -\infty$: $\pi(\mu) \rightarrow 0$
- $\mu = 0$ (H_0): $\pi(0) = 0.05 = \alpha$
- $\mu = 0.329$ (拒绝边界): $\pi = 0.5$
- $\mu = 1$ (H_1): $\pi \approx 0.9996$
- $\mu \rightarrow +\infty$: $\pi(\mu) \rightarrow 1$

形状为 S 型单调递增曲线 (正态 CDF 的补)。

(d) ROC 曲线与 AUC 的统计解释

AUC = P(正例得分 > 负例得分) 的证明:

设正例得分 $\hat{p}_+ \sim F$, 负例得分 $\hat{p}_- \sim G$, ROC 曲线上点 (FPR, TPR) 对应阈值 t :

$$TPR(t) = P(\hat{p}_+ > t), \quad FPR(t) = P(\hat{p}_- > t)$$

$$AUC = \int_0^1 TPR d(FPR) = \int_{-\infty}^{+\infty} P(\hat{p}_+ > t) \cdot g(t) dt = P(\hat{p}_+ > \hat{p}_-)$$

(最后一步用独立性: $E_{\hat{p}_-}[P(\hat{p}_+ > \hat{p}_-)] = P(\hat{p}_+ > \hat{p}_-)$ 。)

AUC 最优化等价于最大化 Wilcoxon 统计量, 与 NP 框架的联系: 最优分类器 (LRT 决策边界) 在所有阈值下均实现最高 TPR, 即 ROC 曲线位于所有分类器曲线之上。精度-召回率权衡反映: 高召回率区域 (低阈值) FPR 上升, 类似降低 α 使 β 上升的权衡。

答案: $\bar{X} > 0.329$, 功效 $\approx 99.96\%$, $\beta \approx 0.04\%$; $AUC = P(\hat{p}_+ > \hat{p}_-)$

E.7.2 (Ch.19+Ch.20, p 值 + 多重检验 + FDR 控制)

题目: 同时检验 m 个假设, 证明 $\text{FDR} \leq \text{FWER}$, 证明 Bonferroni 控制 FWER, 证明 BH 控制 FDR, 讨论高维 ML 中的含义。

思路: FDR 是期望假阳性比例, FWER 是至少一次假阳性的概率; Bonferroni 用 Boole 不等式; BH 证明需利用秩结构。

解:

(a) $\text{FDR} \leq \text{FWER}$ 的证明

设 V = 假阳性数, R = 拒绝数 (含真假阳性)。

$$\text{FDR} = E\left[\frac{V}{\max(R, 1)}\right] \leq E\left[\frac{V}{1} \cdot \mathbf{1}(V \geq 1)\right] = E[V \cdot \mathbf{1}(V \geq 1)]$$

但 $V \cdot \mathbf{1}(V \geq 1) \leq \mathbf{1}(V \geq 1)$ (因为当 $V \geq 1$ 时 $V/\max(R, 1) \leq 1$), 故:

$$\text{FDR} = E\left[\frac{V}{\max(R, 1)}\right] \leq E[\mathbf{1}(V \geq 1)] = P(V \geq 1) = \text{FWER}$$

□

(b) Bonferroni 校正证明 $\text{FWER} \leq \alpha$

设每个检验 i 的水平为 $\alpha_i = \alpha/m$, A_i 为第 i 个真零假设被错误拒绝的事件。

由 Boole 不等式 (Union Bound):

$$\text{FWER} = P\left(\bigcup_{i: H_{0,i} \text{ 真}} A_i\right) \leq \sum_{i: H_{0,i} \text{ 真}} P(A_i) \leq m_0 \cdot \frac{\alpha}{m} \leq m \cdot \frac{\alpha}{m} = \alpha$$

(其中 $m_0 \leq m$ 为真零假设数, 该不等式无需独立性假设。) □

(c) BH 方法控制 FDR 的核心推导框架

将 p 值排序: $p_{(1)} \leq \dots \leq p_{(m)}$, BH 拒绝 $H_{0,(1)}, \dots, H_{0,(k)}$, 其中 $k = \max\{i : p_{(i)} \leq i\alpha/m\}$ 。

关键推导 (Benjamini-Hochberg 1995, 独立或 PRDS 情形):

设 m_0 为真零假设数, 对真零假设 i , 其 p 值 $p_i \sim U(0, 1)$ (在 H_0 下)。

$$\text{FDR} = E\left[\frac{V}{R}\right] = \sum_{i=1}^{m_0} E\left[\frac{\mathbf{1}(p_i \leq p_{(k)})}{R}\right] \leq \sum_{i=1}^{m_0} E\left[\frac{\mathbf{1}(p_i \leq k\alpha/m)}{k}\right] = \frac{m_0}{m} \alpha \leq \alpha$$

(关键步骤: 若 p_i 被拒绝, 则 $p_{(k)} \geq p_i$, 且拒绝数 $R \geq k$, 利用独立性得上界。)

故 $\text{FDR} \leq \alpha \cdot m_0/m \leq \alpha$ 。□

(d) 高维 ML 中多重检验的必要性

在 $m \gg n$ 场景 (如特征数远超样本数):

1. 梯度显著性: 即便某特征对输出无影响 (H_0 为真), 其梯度估计在有限样本下也有非零方差, 单次检验会产生假阳性。对 m 个特征同时检验若不校正, 假阳性数 $\approx m \times \alpha$ (可达数百)。
2. SHAP 值的局限: SHAP 值给出每个特征的贡献, 但不提供统计检验; 在 $m \gg n$ 时, 高 SHAP 值可能纯属随机波动。正确做法: 结合置换检验 (对每个特征单独计算置换后 SHAP 分布) 并用 BH 校正。
3. Bonferroni vs BH: 高维特征中真正重要特征往往稀疏 ($m_1 \ll m_0$), BH 的有效阈值 $k\alpha/m$ 比 Bonferroni 的 α/m 宽松, 能发现更多真实信号, 在生物信息学 (基因表达分析) 和 NLP (注意力显著性) 中广泛应用。

答案: $\text{FDR} \leq \text{FWER}$; Bonferroni via Boole 不等式; BH: $\text{FDR} \leq \alpha m_0/m$; 高维 ML 需校正

E.7.3 (Ch.20, 方差分析 (ANOVA) + 线性模型 + F 检验理论)

题目: 单因素 ANOVA 模型 $X_{ij} = \mu + \alpha_i + \varepsilon_{ij}$, 推导 SS_A 、 SS_E 的分布, 证明 F 统计量, 推导功效, 讨论 BN 的 ANOVA 解释。

思路: ANOVA 通过平方和分解和自由度分配建立 F 检验; Cochran 定理保证各 SS 独立且服从 χ^2 分布。

解:

(a) 自由度推导及 SS_E 的分布

模型: $X_{ij} = \mu + \alpha_i + \varepsilon_{ij}$, $i = 1, \dots, k$, $j = 1, \dots, n_i$, $N = \sum n_i$, 约束 $\sum n_i \alpha_i = 0$ 。

SS_A 的自由度: $SS_A = \sum_{i=1}^k n_i (\bar{X}_{i.} - \bar{X}_{..})^2$ 。

自由度 $df_A = k - 1$ (k 个组均值减去 1 个约束 $\sum n_i (\bar{X}_{i.} - \bar{X}_{..}) = 0$)。

SS_E 的自由度: $SS_E = \sum_{i,j} (X_{ij} - \bar{X}_{i.})^2$ 。

第 i 组贡献 $n_i - 1$ 个自由度 (n_i 个偏差和为 0), 故 $df_E = \sum_i (n_i - 1) = N - k$ 。

$SS_E/\sigma^2 \sim \chi^2(N - k)$ 的证明:

在各组内, $X_{ij} - \bar{X}_{i.} \sim N(0, \sigma^2(1 - 1/n_i))$ (独立)。由 Cochran 定理, 对正态总体, $\sum_j (X_{ij} - \bar{X}_{i.})^2/\sigma^2 \sim \chi^2(n_i - 1)$, 各组独立, 故:

$$\frac{SS_E}{\sigma^2} = \sum_{i=1}^k \frac{\sum_j (X_{ij} - \bar{X}_{i.})^2}{\sigma^2} \sim \chi^2(N - k)$$

(b) H_0 下 F 统计量的分布

在 $H_0: \alpha_1 = \dots = \alpha_k = 0$ 下, $X_{ij} \sim N(\mu, \sigma^2)$, 故 $\bar{X}_{i.} \sim N(\mu, \sigma^2/n_i)$, $\bar{X}_{..} \sim N(\mu, \sigma^2/N)$ 。

由 Cochran 定理: $SS_A/\sigma^2 \sim \chi^2(k-1)$, 且 SS_A 与 SS_E 相互独立 (分别是均值的函数和残差的函数, 在正态假设下正交)。

$$F = \frac{SS_A/(k-1)}{SS_E/(N-k)} = \frac{MS_A}{MS_E} = \frac{\chi^2(k-1)/(k-1)}{\chi^2(N-k)/(N-k)} \sim F(k-1, N-k)$$

□

(c) 非中心 F 分布与功效

在 H_1 (α_i 不全为零) 下, $SS_A/\sigma^2 \sim \chi^2(k-1, \lambda)$ (非中心 χ^2), 非中心参数:

$$\lambda = \frac{\sum_{i=1}^k n_i \alpha_i^2}{\sigma^2}$$

此时 $F \sim F(k-1, N-k, \lambda)$ (非中心 F 分布), 功效为:

$$\text{Power} = P(F(k-1, N-k, \lambda) > F_\alpha(k-1, N-k))$$

样本量设计: 给定目标功效 $1 - \beta$ 和效应大小 (λ 的函数), 求所需 n_i (利用非中心 F 分布的分位数表或软件, 如 R 的 `pwr` 包)。

一般原则: λ 越大 (组间差异越大或 σ^2 越小), 功效越高; 增大 n_i 等比例增大 λ 。

(d) 批归一化 (BN) 的 ANOVA 解释

深度网络第 l 层的激活 $\{z_j^{(l)}\}$ 受前层参数分布变化影响 (内部协变量偏移, Internal Covariate Shift)。ANOVA 框架下:

- “组”: 不同训练 mini-batch (或不同层) 的激活分布。
- 组间变异 (SS_A): 对应层间协变量偏移——激活均值和方差在不同 batch 间的差异。
- 组内变异 (SS_E): 批内正常激活波动 (信号)。

BN 通过标准化每层激活 (均值为 0, 方差为 1), 等价于将 $SS_A \rightarrow 0$, 消除层间均值/方差漂移, 使梯度信号更稳定 (相当于固定组间差异为零, 减少高阶相互作用)。从正则化视角: BN 引入的 (γ, β) 可学习参数类似随机效应模型中的组效应估计, 防止任何单层“主导”整体变差。

答案: $SS_E/\sigma^2 \sim \chi^2(N-k)$; $F \sim F(k-1, N-k)(H_0 \text{ 下})$; $\lambda = \sum n_i \alpha_i^2 / \sigma^2$

E.7.4 (Ch.20+Ch.21, 非参数检验 + 秩统计量 + 渐近理论)

题目: 证明 Wilcoxon 秩和统计量的均值和方差, 与 Mann-Whitney U 的关系, 渐近正态性, 以及 ML 模型比较中的应用。

思路: 秩统计量的矩通过组合期望计算; 渐近正态由 Hájek 投影 (Hajek projection) 定理; U 统计量框架统一 W 和 U。

解:

(a) $E[W]$ 和 $\text{Var}(W)$ 的推导

设合并样本共 $N = m + n$ 个, X_i 的秩 $R_i \in \{1, 2, \dots, N\}$ (无并列)。

在 $H_0: F = G$ 下, N 个样本可交换, X 的 m 个秩是 $\{1, \dots, N\}$ 的等概率子集。

期望:

$$E[R_i] = \frac{1 + 2 + \dots + N}{N} = \frac{N + 1}{2}$$

$$E[W] = \sum_{i=1}^m E[R_i] = m \cdot \frac{N + 1}{2} = \frac{m(m + n + 1)}{2}$$

方差:

$$\text{Var}(W) = \sum_{i=1}^m \text{Var}(R_i) + \sum_{i \neq j} \text{Cov}(R_i, R_j)$$

$$\text{由对称性, } E[R_i^2] = \frac{\sum_{k=1}^N k^2}{N} = \frac{N(N+1)(2N+1)}{6N} = \frac{(N+1)(2N+1)}{6},$$

$$\text{Var}(R_i) = E[R_i^2] - (E[R_i])^2 = \frac{(N+1)(2N+1)}{6} - \frac{(N+1)^2}{4} = \frac{(N+1)(N-1)}{12}.$$

$$\text{对 } i \neq j, E[R_i R_j] = \frac{1}{N(N-1)} \sum_{k \neq l} kl = \frac{(\sum k)^2 - \sum k^2}{N(N-1)} = \frac{N^2(N+1)^2/4 - N(N+1)(2N+1)/6}{N(N-1)},$$

$$\text{化简得 } E[R_i R_j] = \frac{(N+1)(3N+2)}{12},$$

$$\text{Cov}(R_i, R_j) = E[R_i R_j] - E[R_i]E[R_j] = \frac{(N+1)(3N+2)}{12} - \frac{(N+1)^2}{4} = -\frac{N+1}{12}.$$

$$\begin{aligned} \text{Var}(W) &= m \cdot \frac{(N+1)(N-1)}{12} + m(m-1) \cdot \left(-\frac{N+1}{12}\right) = \frac{(N+1)}{12} [m(N-1) - m(m-1)] \\ &= \frac{(N+1)}{12} \cdot m(N-m) = \frac{mn(m+n+1)}{12} \end{aligned}$$

□

(b) W 与 U 的关系

Mann-Whitney U 统计量 $U = \sum_{i=1}^m \sum_{j=1}^n \mathbf{1}[X_i > Y_j]$ 。

X_i 的秩 R_i 等于合并样本中比 X_i 小的观测数加 1: $R_i = 1 + \#\{X_{i'} : X_{i'} < X_i\} + \#\{Y_j : Y_j < X_i\}$ 。

$$\begin{aligned}
 W &= \sum_{i=1}^m R_i = m + \sum_{i=1}^m \#\{i' : X_{i'} < X_i\} + \sum_{i=1}^m \#\{j : Y_j < X_i\} \\
 &= m + \frac{m(m-1)}{2} + \frac{m(m+1)}{2} - m + U = \frac{m(m+1)}{2} + U
 \end{aligned}$$

故 $U = W - m(m+1)/2$ 。□

(c) 渐近正态性 (Hájek 投影定理框架)

定义 $h(x, y) = \mathbf{1}[x > y]$, 则 $U/\binom{N}{m}$ 是关于 $(X_1, \dots, X_m, Y_1, \dots, Y_n)$ 的 U 统计量, 核函数 h 为 1-1。

Hájek 投影: 将 U 投影到个体的函数之和:

$$\tilde{U} = E[U] + \sum_{i=1}^m (h_1(X_i) - E[h_1(X)]) + \sum_{j=1}^n (h_2(Y_j) - E[h_2(Y)])$$

其中 $h_1(x) = P(x > Y)$, $h_2(y) = P(X > y)$ 。

在 H_0 ($F = G$) 下, $h_1(x) = h_2(x) = 1 - F(x)$ (连续), $E[h_1(X)] = 1/2$ 。

由 CLT, $\tilde{U}$ 渐近正态, 且 $\text{Var}(U - \tilde{U}) = o(\text{Var}(\tilde{U}))$ (投影残差可忽略), 故:

$$\frac{W - E[W]}{\sqrt{\text{Var}(W)}} = \frac{U - mn/2}{\sqrt{mn(m+n+1)/12}} \xrightarrow{d} N(0, 1) \quad (m, n \rightarrow \infty)$$

□

(d) ML 模型比较中的秩检验框架

在多数据集模型比较场景 (Demšar 2006 框架):

- **Wilcoxon 符号秩检验** (两模型配对比较): 对 k 个数据集上的性能差值 $d_i = \text{acc}_A^{(i)} - \text{acc}_B^{(i)}$ 用 Wilcoxon 符号秩检验, 无需正态假设。
- **t 检验 vs Wilcoxon 的优势:** 性能指标 (准确率、F1 等) 在数据集间差异巨大, 可能有极端值 (如某数据集异常困难); t 检验对异常值敏感, Wilcoxon 基于秩, 鲁棒性更强。渐近相对效率 (ARE) 在重尾分布下 Wilcoxon $\gg t$ 。
- **多模型比较:** 用 Friedman 检验 (秩的双因素 ANOVA 推广) 检验 k 个分类器在 N 个数据集上的总体差异, 事后两两用 Nemenyi 检验 (类似 Tukey)。
- **关键限制:** 数据集之间并非独立 (来自相同分布的子集), 需额外用 5×2 交叉验证等方法估计检验统计量的方差。

答案: $E[W] = m(m+n+1)/2$, $\text{Var}(W) = mn(m+n+1)/12$; $U = W - m(m+1)/2$; 渐近正态由 Hájek 投影

E.7.5 (Ch.19+Ch.20, 顺序检验 + Wald 序贯概率比检验 + 提前终止)

题目: 证明对数似然比过程在 H_0 下期望为负, 叙述 SPRT, 证明 Wald-Wolfowitz 最优性, 讨论 A/B 测试的持续监测问题。

思路: SPRT 通过连续监测对数似然比并设置双边界实现最优顺序检验; 鞅不等式解决持续监测膨胀问题。

解:

(a) H_0 下 $E[\Lambda_n] < 0$ 的证明

$$\Lambda_n = \sum_{i=1}^n \log \frac{p_{\theta_1}(X_i)}{p_{\theta_0}(X_i)}$$

在 $H_0: \theta = \theta_0$ 下, $X_i \stackrel{i.i.d.}{\sim} p_{\theta_0}$, 故:

$$E_{\theta_0}[\Lambda_n] = n \cdot E_{\theta_0} \left[\log \frac{p_{\theta_1}(X)}{p_{\theta_0}(X)} \right] = -n \cdot E_{\theta_0} \left[\log \frac{p_{\theta_0}(X)}{p_{\theta_1}(X)} \right] = -n \cdot D_{\text{KL}}(p_{\theta_0} \| p_{\theta_1})$$

由 KL 散度非负性 ($D_{\text{KL}} \geq 0$, 等号当且仅当 $p_{\theta_0} = p_{\theta_1}$ a.e.), 在 $\theta_0 \neq \theta_1$ 时:

$$E_{\theta_0}[\Lambda_n] = -n \cdot D_{\text{KL}}(p_{\theta_0} \| p_{\theta_1}) < 0$$

□ (在 H_0 下对数似然比过程期望负漂移, 即趋向接受边界。)

(b) Wald SPRT 的叙述

设阈值 $A < 0 < B$ (通常 $A \approx \log(\beta/(1-\alpha))$, $B \approx \log((1-\beta)/\alpha)$)。

SPRT 规则: 每次获得新观测 X_n 后更新 Λ_n :

- 若 $\Lambda_n \geq B$: 停止并拒绝 H_0 (有足够证据支持 H_1)
- 若 $\Lambda_n \leq A$: 停止并接受 H_0
- 若 $A < \Lambda_n < B$: 继续采样

误差控制 (近似):

- $\alpha' = P_{\theta_0}(\text{拒绝 } H_0) \approx \frac{e^A - 1}{e^A - e^B} \approx \frac{\beta}{1 - \alpha + \beta} \leq \alpha$
- $\beta' = P_{\theta_1}(\text{接受 } H_0) \approx \frac{e^B - 1}{e^B - e^A} \cdot e^{-B} \approx \frac{\beta}{1 - \alpha}$ (精确到过冲误差)

(c) Wald-Wolfowitz 最优性定理

定理: 设所有满足 $P_{\theta_0}(\text{拒绝}) \leq \alpha$ 且 $P_{\theta_1}(\text{接受}) \leq \beta$ 的顺序检验 (包括固定样本检验), SPRT 的期望样本量最小:

$$E_{\theta_0}[N_{\text{SPRT}}] \leq E_{\theta_0}[N](\text{任意满足约束的检验})$$

(H_1 下同理。)

证明框架:

利用 Wald 等式 (停时理论):

$$E_{\theta}[\Lambda_{N_{\text{SPRT}}}] \approx E_{\theta}[N_{\text{SPRT}}] \cdot E_{\theta}[\log L_1(X)/L_0(X)]$$

在 H_1 下 (忽略过冲): $E[\Lambda_N] \approx B = \log((1 - \beta)/\alpha)$, 故:

$$E_{\theta_1}[N] \approx \frac{\log((1 - \beta)/\alpha)}{D_{\text{KL}}(p_{\theta_1} \| p_{\theta_0})}$$

相比固定样本量检验 (达到同等 (α, β) 需 $n \propto (z_{\alpha} + z_{\beta})^2$), SPRT 平均节约约 50% 样本量。

(d) A/B 测试持续监测与 always-valid p 值

Peeking Problem (持续监测膨胀): 若在 $n_1, n_2, \dots$ 多个时间点反复查看 p 值并在 $p < 0.05$ 时停止, 实际 I 类错误远超 5%。原因: 每次查看等价于一次额外的多重检验; 若查看 K 次, FWER 约为 $1 - (1 - \alpha)^K \gg \alpha$ 。

Always-valid p 值 (基于鞅不等式):

定义似然比过程 $\Lambda_n = L_n(\theta_1)/L_n(\theta_0)$, 在 H_0 下 Λ_n 是非负鞅 ($E_{\theta_0}[\Lambda_n | \mathcal{F}_{n-1}] = \Lambda_{n-1}$)。

由 Ville 不等式 (鞅的可选停时定理推广):

$$P_{\theta_0}(\exists n : \Lambda_n \geq 1/\alpha) \leq \alpha$$

故定义 $p_n = 1/\Lambda_n$, 则任意时间查看均有 $P_{\theta_0}(p_n \leq \alpha \text{ for some } n) \leq \alpha$ 。这给出精确的 always-valid p 值, 不因反复查看而膨胀。

工程实现:

1. 选择参数 $(\theta_0, \theta_1, \alpha, \beta)$, 计算 SPRT 边界 (A, B) 。
2. 每批新数据到达时更新 Λ_n 。
3. 超过 B 时停止并报告, 输出 always-valid confidence sequence (置信序列)。
4. 用 mSPRT (mixture SPRT, 对 θ_1 取先验混合) 处理复合 H_1 , 适合不知道真实效应大小的场景。

答案: $E_{\theta_0}[\Lambda_n] = -nD_{\text{KL}} < 0$; SPRT 边界 (A, B) ; Wald-Wolfowitz 最优; 鞅不等式解决 Peeking

E.7.6 (Ch.21, 置换检验 + 精确检验 + 条件推断)

题目: 证明置换检验的精确水平, 推导置换 p 值, Fisher 精确检验, 讨论 ML 特征置换重要性。

思路: 置换检验在交换性下构造精确的条件参考分布; Fisher 精确检验基于超几何分布的条件推断。

解:

(a) 置换检验的精确水平

设 $\mathbf{x} = (x_1, \dots, x_m)$ 和 $\mathbf{y} = (y_1, \dots, y_n)$ 为两组独立观测。

交换性: 在 $H_0: \mu_X = \mu_Y$ (或更一般地 $F = G$) 下, 合并样本 $\mathbf{z} = (\mathbf{x}, \mathbf{y})$ 中任意 $m+n$ 个观测的分配方式 (哪 m 个属于 X 组) 是等可能的, 共 $\binom{m+n}{m}$ 种。

精确水平的证明:

设检验统计量为 T , 观测值为 t_{obs} , 置换 p 值为:

$$p_{\text{perm}} = \frac{\#\{\pi : T(\mathbf{z}_{\pi}) \geq t_{\text{obs}}\}}{\binom{m+n}{m}}$$

在 H_0 下, t_{obs} 是 $\binom{m+n}{m}$ 个等可能排列统计量中的一个 (原始排列与其他排列等地位), 故:

$$P_{H_0}(p_{\text{perm}} \leq \alpha) = P_{H_0}(\text{观测排列位于最极端的 } \alpha \text{ 部分}) \leq \alpha$$

这在有限样本下精确成立 (无渐近近似)。□

(b) Monte Carlo 近似置换 p 值

精确置换 p 值需枚举所有 $\binom{m+n}{m}$ 种排列, 当 $m+n$ 大时计算不可行。

Monte Carlo 近似:

1. 随机生成 B 个置换 (如 $B = 10000$)。
2. 对每个置换 π_b 计算 $T^{(b)} = T(\mathbf{z}_{\pi_b})$ 。
3. 近似 p 值: $\hat{p} = \frac{1 + \#\{b: T^{(b)} \geq t_{\text{obs}}\}}{B+1}$ (分母加 1 避免 $\hat{p} = 0$)。

精度: $\hat{p}$ 的标准误约 $\sqrt{\alpha(1-\alpha)/B}$; $B = 10000$ 时 $\alpha = 0.05$ 的误差 ≈ 0.002 , 通常足够。

(c) Fisher 精确检验 (2×2 列联表)

设列联表行和为 (R_1, R_2) , 列和为 (C_1, C_2) , 总数 n 。在边际固定的条件下, O_{11} 的分布为超几何分布:

$$P(O_{11} = k \mid R_1, R_2, C_1, C_2) = \frac{\binom{C_1}{k} \binom{C_2}{R_1 - k}}{\binom{n}{R_1}}$$

精确 p 值 (单侧右尾: H_1 : 正向关联):

$$p = \sum_{k \geq O_{11}^{\text{obs}}} \frac{\binom{C_1}{k} \binom{C_2}{R_1 - k}}{\binom{n}{R_1}}$$

双侧 p 值取两尾之和 (或所有概率 $\leq P(O_{11}^{\text{obs}})$ 的事件概率之和)。

Fisher 检验无需近似 (χ^2 检验需 $E_{ij} \geq 5$), 对小样本尤其重要。

(d) ML 特征置换重要性与高相关特征

置换特征重要性 (Permutation Feature Importance, PFI):

对特征 j , 随机置换训练好的模型中特征 j 的值 (打乱该特征与响应变量的关联), 记录模型性能下降: $\Delta_j = \text{metric}(\hat{y}, y) - \text{metric}(\hat{y}^{(\pi_j)}, y)$ 。

与条件独立性的联系: $\Delta_j > 0$ 意味着特征 j 对预测有贡献, 等价于拒绝 $H_0: X_j \perp Y \mid X_{-j}$ (X_{-j} 为其他特征)。

高相关特征低估重要性的原因: 若特征 j 与特征 k 高度相关, 置换 j 后, 模型可用 k “代替” j 的信息, 导致性能下降幅度小—— Δ_j 被低估。

分组置换改进: 将高相关特征组 $\mathcal{G} = \{j_1, j_2, \dots\}$ 同时置换 (组内联合置换), 测量整组的联合重要性 $\Delta_{\mathcal{G}}$, 避免单特征置换的“替代效应”。可结合 SHAP 的 Shapley 值 (公平分配联合贡献到各特征) 进一步细化。

答案: 置换检验精确水平 $\leq \alpha$ (交换性); Fisher 精确检验用超几何分布; 分组置换解决高相关问题

E.7.7 (Ch.19+Ch.21, 贝叶斯假设检验 + 贝叶斯因子 + 模型选择)

题目: 证明后验比 = 先验比 $\times$ BF, 计算正态数据的贝叶斯因子, 分析 Jeffreys-Lindley 悖论, 推导 BIC 并与 AIC 比较。

思路: 贝叶斯因子量化数据对两模型的相对支持; BIC 是边际似然的 Laplace 近似; Lindley 悖论揭示先验敏感性。

解:

(a) 后验比 = 先验比 $\times$ BF

由贝叶斯定理:

$$P(M_1 \mid \mathbf{x}) = \frac{p(\mathbf{x} \mid M_1)P(M_1)}{p(\mathbf{x} \mid M_0)P(M_0) + p(\mathbf{x} \mid M_1)P(M_1)}$$

$$P(M_0 \mid \mathbf{x}) = \frac{p(\mathbf{x} \mid M_0)P(M_0)}{p(\mathbf{x} \mid M_0)P(M_0) + p(\mathbf{x} \mid M_1)P(M_1)}$$

相除:

$$\frac{P(M_1 \mid \mathbf{x})}{P(M_0 \mid \mathbf{x})} = \frac{p(\mathbf{x} \mid M_1)}{p(\mathbf{x} \mid M_0)} \cdot \frac{P(M_1)}{P(M_0)} = BF_{10} \cdot \frac{P(M_1)}{P(M_0)}$$

即: 后验优势比 (Posterior Odds) = 贝叶斯因子 (BF) $\times$ 先验优势比 (Prior Odds)。□

(b) 正态数据的贝叶斯因子 (含 Laplace 近似)

数据 $X_i \stackrel{i.i.d.}{\sim} N(\mu, 1)$, n 个观测, 充分统计量 $\bar{x}$ 。

- M_0 : $\mu = 0$ (点假设), $p(\mathbf{x} | M_0) = (2\pi)^{-n/2} \exp(-\sum x_i^2/2)$
- M_1 : $\mu \sim N(0, \tau^2)$ (正态先验), 边际似然为:

$$p(\mathbf{x} | M_1) = \int_{-\infty}^{+\infty} p(\mathbf{x} | \mu) \pi(\mu) d\mu$$

正态-正态共轭积分精确可解:

$$\sum x_i^2 - \frac{n^2 \bar{x}^2}{n + 1/\tau^2}$$

完成配方后:

$$p(\mathbf{x} | M_1) = \frac{1}{(2\pi)^{n/2}} \cdot \frac{1}{\sqrt{1 + n\tau^2}} \exp\left(-\frac{\sum x_i^2}{2} + \frac{n^2 \bar{x}^2/2}{n + 1/\tau^2}\right)$$

贝叶斯因子:

$$BF_{10} = \frac{p(\mathbf{x} | M_1)}{p(\mathbf{x} | M_0)} = \frac{1}{\sqrt{1 + n\tau^2}} \exp\left(\frac{n\tau^2}{2(1 + n\tau^2)} \cdot n\bar{x}^2\right)$$

Laplace 近似 (当 n 大时): 设 M_1 中 μ 的 MLE 为 $\hat{\mu} = \bar{x}$, 后验近似为正态, 则:

$$\log p(\mathbf{x} | M_1) \approx \log p(\mathbf{x} | \hat{\mu}) + \log \pi(\hat{\mu}) - \frac{1}{2} \log(n/(2\pi))$$

$$\log BF_{10} \approx \frac{n\bar{x}^2}{2(1 + n\tau^2)} - \frac{1}{2} \log(1 + n\tau^2)$$

(c) Jeffreys-Lindley 悖论

当 $\tau \rightarrow \infty$ (无信息先验), BF_{10} 的渐近行为:

$$BF_{10} = \frac{1}{\sqrt{1 + n\tau^2}} \exp(\dots) \approx \frac{1}{\tau\sqrt{n}} \cdot \exp\left(\frac{\bar{x}^2 n}{2} \cdot 1\right) \rightarrow 0 \quad (\tau \rightarrow \infty)$$

即无论数据如何, 先验弥散时 $BF_{10} \rightarrow 0$ ——贝叶斯因子永远支持 M_0 !

原因: 当 τ 很大时, M_1 的先验将概率质量分散到极大的 $|\mu|$ 范围, 数据 (有限均值 $\bar{x}$) 相对于如此弥散的先验而言“出人意料”, 边际似然 $p(\mathbf{x} | M_1)$ 极小, 故 BF 倒向 M_0 。

与频率 **p** 值的对比:

- 频率 p 值 = $P(|\bar{X}| \geq |\bar{x}| \mid \mu = 0)$ 只依赖数据和 M_0 , 与 M_1 的先验无关。
- 贝叶斯因子对 M_1 的先验 τ 极度敏感, 需谨慎选择 (推荐 Cauchy 或 JZS 先验代替无信息先验)。

(d) BIC 的贝叶斯推导与 AIC 比较

BIC 的 Laplace 近似推导:

设模型 M 有 d 个参数, MLE 为 $\hat{\theta}$, n 个观测。对边际似然做 Laplace 近似:

$$\log p(\mathbf{x} \mid M) = \int p(\mathbf{x} \mid \theta) \pi(\theta) d\theta$$

在 $\hat{\theta}$ 处二阶展开 (正则条件下 Hessian $\approx -nI(\hat{\theta})$):

$$\log p(\mathbf{x} \mid M) \approx \log p(\mathbf{x} \mid \hat{\theta}) + \log \pi(\hat{\theta}) + \frac{d}{2} \log(2\pi) - \frac{1}{2} \log \det(nI(\hat{\theta}))$$

忽略先验项和常数, 取负得惩罚:

$$-2 \log p(\mathbf{x} \mid M) \approx -2 \log p(\mathbf{x} \mid \hat{\theta}) + d \log n$$

定义 $\text{BIC} = -2 \log \hat{L} + d \log n$, 最小化 **BIC** 等价于最大化边际似然的 **Laplace** 近似。

BIC vs AIC ($\text{AIC} = -2 \log \hat{L} + 2d$) 的比较:

准则	惩罚项	渐近目标	优势
AIC	$2d$	最小化预测 KL 散度	预测性能好 (过小罚, 允许偏大模型)
BIC	$d \log n$	最大化边际似然 (选真模型)	一致性 (真模型在候选集时)

- **AIC** (Akaike 1973): 通过 KL 散度的无偏估计推导, 最优化样本外预测, 是非贝叶斯的。当 $\log n > 2$ (即 $n > 8$) 时, BIC 比 AIC 对复杂度的惩罚更重。
- **BIC** (Schwarz 1978): 一致选择——当真实模型在候选集中且 $n \rightarrow \infty$ 时, BIC 以概率 1 选出真实模型; AIC 可能选过大模型。
- 实践建议: 目标是预测时用 AIC; 目标是推断真实生成结构时用 BIC; Bayesian 框架可直接比较边际似然避免此权衡。

答案: $BF_{10} = (1 + n\tau^2)^{-1/2} \exp(\dots); \tau \rightarrow \infty \Rightarrow BF_{10} \rightarrow 0$ (Lindley 悖论); $\text{BIC} \approx -2 \log \hat{L} + d \log n$

□ Lindley 悖论: 当样本量 $n \rightarrow \infty$ 且固定 p 值时, BF 可能趋向 M_0 (频率显著但贝叶斯不支持 H_1)。这提醒我们频率检验和贝叶斯检验回答的是不同问题, 不可混用。

F7 详解: Part 8 高级专题 (Ch.22-24, 共 32 题)**C 基础题详解 (10 题)**

C.8.1 (Ch.22, 香农熵)

题目: 离散变量 X 取值概率 $(0.5, 0.25, 0.25)$; 另 $Y \sim \text{Uniform}\{1, 2, 3, 4\}$, 比较两者熵。

思路: 代入 $H = -\sum p_i \log_2 p_i$, 均匀分布熵最大。

解:

1. 计算 $H(X)$:

$$H(X) = -0.5 \log_2 0.5 - 0.25 \log_2 0.25 - 0.25 \log_2 0.25$$

$$= -0.5 \times (-1) - 0.25 \times (-2) - 0.25 \times (-2)$$

$$= 0.5 + 0.5 + 0.5 = 1.5 \text{ 比特}$$

2. 计算 $H(Y)$: Y 均匀分布在 4 个等概率值上,

$$H(Y) = \log_2 4 = 2 \text{ 比特}$$

比较: $H(Y) = 2 > H(X) = 1.5$, 均匀分布熵更大。

答案: $H(X) = 1.5 \text{ 比特}, H(Y) = 2 \text{ 比特}, H(Y) > H(X)$

注: 等概率分布在相同支撑大小下熵最大 (最大熵定理)。

C.8.2 (Ch.22, KL 散度)

题目: $P = (0.5, 0.5)$, $Q = (0.8, 0.2)$, 计算 KL 散度并判断对称性。

思路: 直接代入定义, 非对称性举反例验证。

解:

1. $D_{\text{KL}}(P\|Q)$ (以自然对数):

$$D_{\text{KL}}(P\|Q) = 0.5 \ln \frac{0.5}{0.8} + 0.5 \ln \frac{0.5}{0.2}$$

$$= 0.5 \ln(0.625) + 0.5 \ln(2.5)$$

$$= 0.5(-0.4700) + 0.5(0.9163) = 0.2232 \text{ nat}$$

2. KL 散度不对称。反证:

$$D_{\text{KL}}(Q\|P) = 0.8 \ln \frac{0.8}{0.5} + 0.2 \ln \frac{0.2}{0.5}$$

$$= 0.8 \ln(1.6) + 0.2 \ln(0.4) = 0.8(0.4700) + 0.2(-0.9163) = 0.1926 \text{ nat}$$

$D_{\text{KL}}(P\|Q) = 0.2232 \neq 0.1926 = D_{\text{KL}}(Q\|P)$, 故不对称。

答案: $D_{\text{KL}}(P\|Q) = 0.5 \ln(0.625) + 0.5 \ln(2.5) \approx 0.223 \text{ nat}$, KL 散度不对称。

□ KL 散度不是距离 (不满足对称性), 常被称为“相对熵”或“信息散度”。

C.8.3 (Ch.22, 交叉熵与 KL 散度的关系)

题目: 真实分布 P , 模型分布 Q , 交叉熵 $H(P, Q) = -\sum_x P(x) \log Q(x)$, 建立与 $H(P)$ 、 D_{KL} 的关系。

思路: 拆开 $\log(P/Q)$ 即得。

解:

1. 关系式:

$$H(P, Q) = -\sum_x P(x) \log Q(x) = -\sum_x P(x) \log P(x) + \sum_x P(x) \log \frac{P(x)}{Q(x)}$$

$$H(P, Q) = H(P) + D_{\text{KL}}(P\|Q)$$

因为 $D_{\text{KL}}(P\|Q) \geq 0$, 所以 $H(P, Q) \geq H(P)$, 交叉熵不小于真实熵。

2. 当 $Q = P$ 时, $D_{\text{KL}}(P\|P) = 0$, 故:

$$H(P, P) = H(P)$$

交叉熵等于真实分布的熵。

答案: $H(P, Q) = H(P) + D_{\text{KL}}(P \| Q)$; $Q = P$ 时 $H(P, P) = H(P)$ 。

C.8.4 (Ch.22, 互信息)

题目: $H(X) = 2$, $H(Y) = 3$, $H(X, Y) = 4$, 计算 $I(X; Y)$, 并说明独立情形。

思路: 直接用互信息公式。

解:

1. 互信息:

$$I(X; Y) = H(X) + H(Y) - H(X, Y) = 2 + 3 - 4 = 1 \text{ 比特}$$

2. 若 $X \perp Y$, 则 $H(X, Y) = H(X) + H(Y)$, 从而:

$$I(X; Y) = H(X) + H(Y) - H(X, Y) = 0$$

答案: $I(X; Y) = 1$ 比特; 独立时 $I(X; Y) = 0$ 。

C.8.5 (Ch.23, 蒙特卡洛积分)

题目: 用 MC 估计 $I = \int_0^1 e^{x^2} dx$, 写估计量及标准误差。

思路: MC 估计即样本均值, 方差来自 CLT。

解:

1. 蒙特卡洛估计量: 抽取 $U_1, \dots, U_n \stackrel{\text{i.i.d.}}{\sim} U(0, 1)$, 令

$$\hat{I}_n = \frac{1}{n} \sum_{i=1}^n e^{U_i^2}$$

由大数定律, $\hat{I}_n \xrightarrow{a.s.} E[e^{U^2}] = I$, 故 $\hat{I}_n$ 是无偏一致估计量。

2. 标准误差:

$$\text{SE}(\hat{I}_n) = \frac{\sigma_f}{\sqrt{n}}, \quad \sigma_f = \sqrt{\text{Var}(e^{U^2})}$$

答案:
$$\hat{I}_n = \frac{1}{n} \sum_{i=1}^n e^{U_i^2}, \quad \text{SE} = \sigma_f / \sqrt{n}$$

注: 误差以 $1/\sqrt{n}$ 速率收缩, 与积分维度无关 (MC 优势所在)。

C.8.6 (Ch.23, 重要性采样)

题目: 估计 $E_p[f(X)]$, 从提议分布 $q(x)$ 采样, 写 IS 估计量及最优 q 的效果。

思路: 改变测度, 引入重要性权重。

解:

1. 重要性采样估计量: 从 q 抽样 $X_1, \dots, X_n$,

$$\hat{I}_{IS} = \frac{1}{n} \sum_{i=1}^n f(X_i) w(X_i), \quad w(x) = \frac{p(x)}{q(x)}$$

无偏性: $E_q[f(X)w(X)] = \int f(x) \frac{p(x)}{q(x)} q(x) dx = E_p[f(X)]$ 。

2. 若 $q(x) \propto |f(x)|p(x)$ (最优提议分布), 则重要性权重 $w(x)f(x)$ 为常数,

$$\text{Var}(\hat{I}_{IS}) = 0$$

方差降为零 (理论最优, 实践中需知道 $E_p[|f|]$ 才能归一化, 但揭示了方向)。

答案:
$$\hat{I}_{IS} = \frac{1}{n} \sum_{i=1}^n f(X_i) \frac{p(X_i)}{q(X_i)}$$
; 最优 $q \propto |f|p$ 时方差最小 (理论上为零)。

C.8.7 (Ch.24, 贝叶斯网络因子分解)

题目: 链式结构 $A \rightarrow B \rightarrow C$, 写联合分布分解, 判断 $A \perp\!\!\!\perp C \mid B$ 。

思路: 链式结构因子分解; d-分离判定。

解:

1. 联合分布分解:

$$P(A, B, C) = P(A) \cdot P(B | A) \cdot P(C | B)$$

2. 在链结构中, B 是 A 和 C 之间的中间节点 (chain/pipe), 观测 B 时路径被阻断, 故

$$A \perp\!\!\!\perp C | B \quad \checkmark$$

验证: $P(A, C | B) = \frac{P(A, B, C)}{P(B)} = \frac{P(A)P(B|A)P(C|B)}{P(B)} = P(A | B) \cdot P(C | B)$, 即因子化。

答案: $P(A, B, C) = P(A)P(B | A)P(C | B)$; 是, $A \perp\!\!\!\perp C | B$ 成立。

C.8.8 (Ch.24, EM 算法——E 步与 M 步)

题目: 写出 EM 的 E 步 (Q 函数) 和 M 步更新公式。

思路: EM 通过最大化对数似然的下界迭代。

解:

1. E 步: 给定当前参数 $\theta^{(t)}$ 和观测 X , 计算隐变量的后验期望:

$$Q(\theta | \theta^{(t)}) = E_{Z|X, \theta^{(t)}}[\log p(X, Z | \theta)]$$

即在 $p(Z | X, \theta^{(t)})$ 下对完整对数似然取期望。

2. M 步: 最大化 Q 函数:

$$\theta^{(t+1)} = \arg \max_{\theta} Q(\theta | \theta^{(t)})$$

每次迭代保证 $\log p(X | \theta^{(t+1)}) \geq \log p(X | \theta^{(t)})$ (单调不减性)。

答案: $Q(\theta | \theta^{(t)}) = E_{Z|X, \theta^{(t)}}[\log p(X, Z | \theta)]$, $\theta^{(t+1)} = \arg \max_{\theta} Q(\theta | \theta^{(t)})$ 。

C.8.9 (Ch.24, ELBO 与变分推断)

题目: 写 ELBO 表达式, 说明最大化 ELBO 的等价含义, 并说明 $q = p(Z|X)$ 时的结果。

思路: 对数证据分解为 ELBO 与 KL 散度之和。

解:

1. 分解:

$$\log p(X) = \underbrace{E_q[\log p(X, Z)] - E_q[\log q(Z)]}_{\text{ELBO}} + D_{\text{KL}}(q(Z) \| p(Z | X))$$

由 $D_{\text{KL}} \geq 0$, $\text{ELBO} \leq \log p(X)$ 。

最大化 ELBO $\Leftrightarrow$ 最小化 $D_{\text{KL}}(q(Z) \| p(Z | X))$ (因 $\log p(X)$ 不依赖 q)。

2. 当 $q(Z) = p(Z | X)$ 时, $D_{\text{KL}} = 0$, 故:

$$\text{ELBO} = \log p(X)$$

答案: $\boxed{\text{ELBO} = E_q[\log p(X, Z)] - E_q[\log q(Z)]}$; 最大化 ELBO 等价于最小化 $D_{\text{KL}}(q \| p(\cdot | X))$; $q = p(Z | X)$ 时 $\text{ELBO} = \log p(X)$ 。

C.8.10 (Ch.22-24, 综合辨析)

题目: 判断三个说法的正误。

思路: 逐条套用定理。

解:

1. 正确。KL 散度非负: $D_{\text{KL}}(P \| Q) = \sum p_i \ln(p_i/q_i) \geq 0$, 由 Jensen 不等式 ($-\ln$ 凸); 等号成立当且仅当 $p_i = q_i$ 对所有 i 。
2. 错误。蒙特卡洛积分误差以 $O(1/\sqrt{n})$ (而非 $1/n$) 的速率收缩, 但与维度无关 (这才是 MC 的优势, 数值积分误差随维度指数增长)。
3. 正确。贝叶斯网络的 Markov 性质: 若 X 和 Y 在 DAG 中被 Z d-分离, 则 $X \perp\!\!\!\perp Y | Z$ (全局 Markov 性)。

答案: $\boxed{(1)\text{正确} \quad (2)\text{错误 (误差} \sim 1/\sqrt{n}) \quad (3)\text{正确}}$

D 中等题详解 (12 题)

D.8.1 (Ch.22, 信息熵的基本性质)

题目: 证明 $H(p) \geq 0$; 证明均匀分布最大化熵; 计算 Bernoulli 熵并求最大化点。

思路: 非负性来自 $p \log p \leq 0$; 上界用 Jensen 不等式; Bernoulli 熵对 p 求导。

解:

(a) $H(p) \geq 0$

对任意 $p_i \in (0, 1]$, 有 $\log p_i \leq 0$ (以 e 为底), 故 $-p_i \log p_i \geq 0$, 求和即:

$$H(p) = -\sum_{i=1}^n p_i \log p_i = \sum_{i=1}^n (-p_i \log p_i) \geq 0$$

边界: 若某 $p_i = 0$, 约定 $0 \log 0 = 0$ (连续延拓)。

(b) $H(p) \leq \log n$

由 Jensen 不等式 ($\log$ 是凹函数):

$$H(p) = \sum_{i=1}^n p_i \log \frac{1}{p_i} = \sum_{i=1}^n p_i \cdot \log \frac{1}{p_i} \leq \log \left(\sum_{i=1}^n p_i \cdot \frac{1}{p_i} \right) = \log n$$

等号成立当且仅当所有 $1/p_i$ 相等, 即 $p_i = 1/n$ (均匀分布)。

(c) Bernoulli(p) 的熵

$$H(p) = -p \log p - (1-p) \log(1-p) \quad (p \in (0, 1))$$

对 p 求导并令其为零:

$$\frac{dH}{dp} = -\log p - 1 + \log(1-p) + 1 = \log \frac{1-p}{p} = 0$$

解得 $p = 1/2$, 此时熵最大:

$$H(1/2) = -\frac{1}{2} \log_2 \frac{1}{2} - \frac{1}{2} \log_2 \frac{1}{2} = 1 \text{ bit} = \log_e 2 \text{ nat}$$

验证: 以比特计算 $H(1/2) = \log_2 2 = 1$, 等于支撑大小 $n = 2$ 的 $\log_2 n = 1$, 与 (b) 一致。

答案: $\boxed{H(p) \geq 0}$ (非负); $\boxed{H(p) \leq \log n}$ (均匀最大); Bernoulli 熵在 $p = 1/2$ 取最大值 $\log 2$ 。

D.8.2 (Ch.22, KL 散度)

题目: 证明 KL 非负; 验证 $= 0 \Leftrightarrow P = Q$; 计算 $P = \text{Ber}(0.7)$, $Q = \text{Ber}(0.5)$ 的 KL。

思路: Jensen 不等式用于 $-\log$ (凸函数); 数值计算验证不对称。

解:

(a) $D_{\text{KL}}(P\|Q) \geq 0$

$$D_{\text{KL}}(P\|Q) = E_P \left[\log \frac{p}{q} \right] = -E_P \left[\log \frac{q}{p} \right]$$

由 Jensen 不等式 ($-\log$ 是凸函数):

$$-E_P \left[\log \frac{q}{p} \right] \geq -\log E_P \left[\frac{q}{p} \right] = -\log \sum_i p_i \frac{q_i}{p_i} = -\log \sum_i q_i = -\log 1 = 0$$

故 $D_{\text{KL}}(P\|Q) \geq 0$ 。

(b) 等号条件

Jensen 不等式等号成立 $\Leftrightarrow q_i/p_i$ 为常数 $\Leftrightarrow q_i = cp_i$ 对所有 i ; 结合 $\sum q_i = \sum p_i = 1$, 得 $c = 1$, 即 $P = Q$ 。

(c) 数值计算

$P = (0.7, 0.3)$, $Q = (0.5, 0.5)$ (以自然对数):

$$D_{\text{KL}}(P\|Q) = 0.7 \ln \frac{0.7}{0.5} + 0.3 \ln \frac{0.3}{0.5}$$

$$= 0.7 \ln 1.4 + 0.3 \ln 0.6 = 0.7(0.3365) + 0.3(-0.5108) = 0.2356 - 0.1532 \approx 0.0824 \text{ nat}$$

$$D_{\text{KL}}(Q\|P) = 0.5 \ln \frac{0.5}{0.7} + 0.5 \ln \frac{0.5}{0.3}$$

$$= 0.5 \ln(0.7143) + 0.5 \ln(1.6667) = 0.5(-0.3365) + 0.5(0.5108) \approx 0.0872 \text{ nat}$$

$0.0824 \neq 0.0872$, 验证不对称性。

答案: $D_{\text{KL}}(P\|Q) \approx 0.0824 \text{ nat}$, $D_{\text{KL}}(Q\|P) \approx 0.0872 \text{ nat}$, 不对称。

D.8.3 (Ch.22, 互信息与独立性)

题目: 证明互信息的链式分解; 证明 $I \geq 0$; 计算二元对称信道容量。

思路: 条件熵定义展开; KL 非负性; BSC 信道用熵公式。

解:

$$(a) I(X; Y) = H(X) - H(X|Y)$$

$$\begin{aligned} I(X; Y) &= \sum_{x,y} p(x,y) \log \frac{p(x,y)}{p(x)p(y)} \\ &= \sum_{x,y} p(x,y) \log \frac{p(x|y)}{p(x)} = \sum_y p(y) \sum_x p(x|y) \log p(x|y) - \sum_x p(x) \log p(x) \cdot \underbrace{\sum_y p(y|x)}_1 \end{aligned}$$

更简洁地:

$$I(X; Y) = H(X) + H(Y) - H(X, Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$$

(利用 $H(X, Y) = H(Y) + H(X|Y) = H(X) + H(Y|X)$ 。)

$$(b) I(X; Y) \geq 0$$

$$I(X; Y) = D_{\text{KL}}(p(x, y) \| p(x)p(y)) \geq 0$$

等号成立 $\Leftrightarrow p(x, y) = p(x)p(y)$ 对所有 (x, y) , 即 $X \perp Y$ 。

(c) 二元对称信道 (BSC) 容量

输入均匀: $P(X=0) = P(X=1) = 1/2$; 信道翻转概率 ε 。

输出也均匀: $P(Y=0) = P(Y=1) = 1/2$, 故 $H(Y) = 1$ 比特。

条件熵: $H(Y|X) = H(\varepsilon) = -\varepsilon \log_2 \varepsilon - (1-\varepsilon) \log_2 (1-\varepsilon)$ (二元熵函数)。

$$I(X; Y) = H(Y) - H(Y|X) = 1 - H(\varepsilon)$$

信道容量 $C = \max_{p(x)} I(X; Y) = 1 - H(\varepsilon)$ 比特/使用。

答案: $\boxed{I(X; Y) = H(X) - H(X|Y) = H(Y) - H(Y|X) \geq 0}$; BSC 容量 $C = 1 - H(\varepsilon)$ 比特。

D.8.4 (Ch.23, Monte Carlo 积分误差)

题目: 证明 MC 无偏及方差; 估计 e^x 积分的样本量需求; 比较 MC 与数值积分的维度优势。

思路: 期望线性性 + CLT; 精确计算 $\text{Var}(e^U)$; 维度分析。

解:

(a) 无偏性与方差

$$E[\hat{I}_n] = E\left[\frac{1}{n} \sum_{i=1}^n g(U_i)\right] = \frac{1}{n} \cdot n \cdot E[g(U)] = \int_0^1 g(x) dx = I$$

$$\text{Var}(\hat{I}_n) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(g(U_i)) = \frac{\text{Var}(g(U))}{n}$$

(b) 样本量估计 ($g(x) = e^x$)

$$\text{Var}(e^U) = E[e^{2U}] - (E[e^U])^2$$

$$E[e^{2U}] = \int_0^1 e^{2x} dx = \frac{e^2 - 1}{2} \approx 3.195$$

$$E[e^U] = e - 1 \approx 1.718$$

$$\sigma^2 = \frac{e^2 - 1}{2} - (e - 1)^2 = 3.195 - 2.952 = 0.243, \quad \sigma \approx 0.493$$

95% CI 宽度 $= 2 \times 1.96 \times \sigma / \sqrt{n} \leq 0.01$, 解得:

$$\sqrt{n} \geq \frac{2 \times 1.96 \times 0.493}{0.01} = 193.3$$

$$n \geq 193.3^2 \approx 37400$$

(c) 维度优势

Simpson 法则在 d 维下精度 $O(n^{-4/d})$ (n 为总格点数), 当 $d \geq 5$ 时收敛极慢 (维度诅咒)。MC 方差始终为 σ^2/n , 误差 $O(1/\sqrt{n})$ 与维度 d 无关, 在高维积分中远优于确定性数值法。

答案: $n \approx 37400$ (CI 宽度 ≤ 0.01); MC 误差 $O(n^{-1/2})$ 与维度无关, 数值积分误差 $O(n^{-4/d})$ 随维度指数恶化。

D.8.5 (Ch.23, 重要性采样)

题目: 证明 IS 无偏; 写出方差公式及最优 q ; 描述 SNIS 步骤。

思路: 改变测度; 最优 q 使方差为零; SNIS 处理未归一化密度。

解:

(a) 无偏性

$$\begin{aligned} E_q[\hat{I}_{IS}] &= E_q\left[\frac{1}{n} \sum_{i=1}^n g(X_i)w(X_i)\right] = E_q[g(X)w(X)] \\ &= \int g(x) \frac{p(x)}{q(x)} q(x) dx = \int g(x)p(x) dx = E_p[g(X)] \end{aligned}$$

(b) 方差与最优提议分布

$$\text{Var}(\hat{I}_{IS}) = \frac{1}{n} \text{Var}_q[g(X)w(X)] = \frac{1}{n} (E_q[(g(X)w(X))^2] - I^2)$$

最优提议分布使 $g(x)w(x) = g(x)p(x)/q(x)$ 为常数, 即 $q^*(x) \propto |g(x)|p(x)$, 此时:

$$\text{Var}(\hat{I}_{IS}) = 0 \quad (\text{理论最优, 实践需近似})$$

(c) 自归一化重要性采样 (SNIS)

设 $p(x) = \tilde{p}(x)/Z$, Z 未知, 权重 $w_i = \tilde{p}(X_i)/q(X_i)$:

$$\hat{\mu}_{SNIS} = \frac{\sum_{i=1}^n w_i f(X_i)}{\sum_{i=1}^n w_i}$$

步骤: □ 从 q 抽 $X_1, \dots, X_n$; □ 计算未归一化权重 $w_i = \tilde{p}(X_i)/q(X_i)$; □ 归一化 $\bar{w}_i = w_i / \sum_j w_j$; □ 估计 $\hat{\mu} = \sum_i \bar{w}_i f(X_i)$ 。

SNIS 有偏 (比率估计偏差), 但 $n \rightarrow \infty$ 时相合, 优势是无需知道归一化常数 Z 。

答案: IS 估计量无偏; 最优 $q^* \propto |g|p$ 时方差为零; SNIS 用归一化权重处理未知 Z 。

D.8.6 (Ch.23, Metropolis-Hastings 算法)

题目: 化简 M-H 接受率; 验证细致平衡; 讨论步长 δ 的影响。

思路: 对称提议分布简化; 细致平衡分情况讨论; 步长权衡。

解:

(a) 接受率化简

目标 $\pi(x) \propto e^{-x^2/2}$, 提议 $q(x'|x) = q(x|x') = \text{Uniform}(x - \delta, x + \delta)$ (对称)。

一般接受率:

$$\alpha(x, x') = \min\left(1, \frac{\pi(x')q(x|x')}{\pi(x)q(x'|x)}\right)$$

由于 q 对称 ($q(x|x') = q(x'|x)$), 化简为:

$$\alpha(x, x') = \min\left(1, \frac{\pi(x')}{\pi(x)}\right) = \min\left(1, e^{-(x'^2-x^2)/2}\right)$$

(b) 细致平衡验证

需证 $\pi(x)k(x, x') = \pi(x')k(x', x)$, 其中转移核 $k(x, x') = q(x'|x)\alpha(x, x')$ 。

不妨设 $\pi(x') \geq \pi(x)$ (即 $\alpha(x, x') = 1, \alpha(x', x) = \pi(x)/\pi(x')$):

$$\pi(x)k(x, x') = \pi(x) \cdot q(x'|x) \cdot 1$$

$$\pi(x')k(x', x) = \pi(x') \cdot q(x|x') \cdot \frac{\pi(x)}{\pi(x')} = \pi(x) \cdot q(x|x')$$

由 q 对称, $q(x'|x) = q(x|x')$, 故两边相等。细致平衡成立。

(c) 步长 δ 的影响

δ	接受率	混合速度	问题
过大	接近 0	极慢 (几乎不移动)	高拒绝率, 样本高度相关
过小	接近 1	极慢 (随机游走扩散慢)	探索范围窄, 自相关高
最优	≈ 0.234 (高维) / 0.44 (一维)	最快	Gelman 等人理论结果

一维情形最优接受率约 44%, 高维 ($d \rightarrow \infty$) 最优接受率约 23.4%。

答案: 对称提议时 $\alpha = \min(1, \pi(x')/\pi(x))$; 细致平衡经分情况讨论验证成立; 最优接受率一维约 44%, 高维约 23.4%。

D.8.7 (Ch.24, 贝叶斯网络的条件独立性)

题目: $A \rightarrow C \leftarrow B$, $C \rightarrow D$; 写联合分解; 证明 $A \perp B$ (未观测 C); 说明 explaining away。

思路: V 形结构 (collider): 未观测时独立, 观测后产生相关。

解:

(a) 联合分布分解

$$P(A, B, C, D) = P(A) \cdot P(B) \cdot P(C | A, B) \cdot P(D | C)$$

(b) 未观测 C 时 $A \perp B$

对 C 和 D 边缘化:

$$\begin{aligned} P(A, B) &= \sum_{C, D} P(A)P(B)P(C | A, B)P(D | C) \\ &= P(A)P(B) \sum_C P(C | A, B) \underbrace{\sum_D P(D | C)}_{=1} = P(A)P(B) \underbrace{\sum_C P(C | A, B)}_{=1} = P(A)P(B) \end{aligned}$$

故 $A \perp B$ (Collider 未观测时阻断信息流)。

(c) Explaining Away (观测 C 后)

观测 $C = c$ 后:

$$P(A, B | C = c) = \frac{P(A)P(B)P(c | A, B)}{P(c)}$$

除非 $P(c | A, B)$ 对所有 (A, B) 相同, 否则 $P(A, B | C = c) \neq P(A | C = c) \cdot P(B | C = c)$, A 和 B 不再独立。

举例: C = “草地湿”, A = “下雨”, B = “洒水器开”, 两者原本独立。但观测到草地湿后 ($C = 1$), 若已知下雨, 则洒水器开的概率降低 (互相“解释”对方), 产生负相关。

答案: $P(A, B, C, D) = P(A)P(B)P(C|A, B)P(D|C)$; 未观测 C 时 $A \perp B$; 观测 C 后 explaining away 使 A, B 相关。

D.8.8 (Ch.24, 马尔可夫链基本性质)

题目: 验证随机矩阵; 求平稳分布; 判断遍历性。

思路: 行和为 1; 解 $\pi P = \pi$; 遍历 = 不可约 + 非周期。

解:

(a) 行和验证

$$0.7 + 0.2 + 0.1 = 1; \quad 0.3 + 0.5 + 0.2 = 1; \quad 0.1 + 0.3 + 0.6 = 1 \quad \checkmark$$

(b) 平稳分布

解 $\pi P = \pi$, $\pi \mathbf{1} = 1$, 即:

$$\begin{cases} \pi_1 = 0.7\pi_1 + 0.3\pi_2 + 0.1\pi_3 \\ \pi_2 = 0.2\pi_1 + 0.5\pi_2 + 0.3\pi_3 \\ \pi_3 = 0.1\pi_1 + 0.2\pi_2 + 0.6\pi_3 \\ \pi_1 + \pi_2 + \pi_3 = 1 \end{cases}$$

化简方程 (取前两个方程):

$$-0.3\pi_1 + 0.3\pi_2 + 0.1\pi_3 = 0 \implies \pi_2 = \pi_1 - \frac{1}{3}\pi_3$$

$$0.2\pi_1 - 0.5\pi_2 + 0.3\pi_3 = 0$$

代入得 $0.2\pi_1 - 0.5(\pi_1 - \frac{1}{3}\pi_3) + 0.3\pi_3 = 0$, 即 $-0.3\pi_1 + \frac{7}{15}\pi_3 \cdot 5/3 = 0$ 。

用数值法 (或 Cramer 法则), 设 $\pi_3 = t$:

由方程组 $\mathbf{A}\pi^\top = \mathbf{0}$ 求核, 结合归一化, 数值解为:

$$\pi \approx (0.349, 0.326, 0.326)$$

精确解: 令 $\pi_1 = a, \pi_2 = b, \pi_3 = c$, 由方程 $-0.3a + 0.3b + 0.1c = 0$ 和 $0.2a - 0.5b + 0.3c = 0$, 联立得 $b = \frac{7c}{6+3} \cdots$ (矩阵行变换后数值解更直接)。实际近似值 $\approx (0.349, 0.326, 0.326)$ (可用计算器验证)。

(c) 遍历性

- 不可约: 任意两状态间均可到达 (转移矩阵所有元素 > 0), 故不可约。
- 非周期: $P_{11} = 0.7 > 0$, 状态 1 有自环, 周期为 1, 整个链非周期。

- 由遍历定理: $\mathbf{P}^n \rightarrow \mathbf{1}\pi^\top$, 初始分布无关, 均收敛到唯一平稳分布 π 。

答案: 行和均为 1; 平稳分布 $\pi \approx (0.349, 0.326, 0.326)$; 链不可约且非周期, 故遍历。

D.8.9 (Ch.22, 最大熵原理)

题目: Lagrange 乘数法求约束均值下的最大熵分布; 连续情形结论; 统计物理解释。

思路: 指数族形式是最大熵分布的一般结论; 连续情形 = 正态。

解:

(a) 拉格朗日法 (离散, 约束 $E[X] = \mu$)

构造 Lagrangian:

$$\mathcal{L}(p, \lambda_0, \lambda_1) = -\sum_{i=1}^n p_i \log p_i - \lambda_0 \left(\sum p_i - 1 \right) - \lambda_1 \left(\sum i \cdot p_i - \mu \right)$$

对 p_i 偏导并令其为零:

$$\frac{\partial \mathcal{L}}{\partial p_i} = -\log p_i - 1 - \lambda_0 - \lambda_1 i = 0$$

$$\Rightarrow \log p_i = -1 - \lambda_0 - \lambda_1 i \Rightarrow \boxed{p_i \propto e^{-\lambda_1 i}}$$

令 $r = e^{-\lambda_1}$, 则 $p_i = (1-r)r^{i-1}$ (几何分布), λ_1 由均值约束 $\sum i \cdot p_i = \mu$ 确定。

(b) 连续情形

约束 $E[X] = \mu$, $\text{Var}(X) = \sigma^2$, 最大微分熵分布为:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) = \mathcal{N}(\mu, \sigma^2)$$

正态分布是给定均值和方差下熵最大的连续分布。

(c) 统计物理含义

最大熵原理等价于“在满足约束条件下, 对系统状态做最少的额外假设”——对应统计力学中 Gibbs 系综的推导: 给定能量期望约束, 最大熵对应系统处于热平衡状态 (Boltzmann 分布)。从信息论看, 它是对应约束下的无信息先验 (Jeffreys 型思路), 避免引入额外偏见。

答案: 离散最大熵分布 $p_i \propto e^{\lambda_i}$ (几何族); 连续情形为 $\mathcal{N}(\mu, \sigma^2)$; 最大熵 = 最少额外假设。

D.8.10 (Ch.23, 变分推断基本思想)

题目: 推导 ELBO; 证明等价性; 写均场 CAVI 更新公式。

思路: 对数证据分解; 均场分解后坐标优化。

解:

(a) ELBO 推导

$$\log p(\mathbf{x}) = \log \int p(\mathbf{x}, \mathbf{z}) d\mathbf{z} = \log \int q_\phi(\mathbf{z}) \frac{p(\mathbf{x}, \mathbf{z})}{q_\phi(\mathbf{z})} d\mathbf{z}$$

由 Jensen 不等式 (log 凹):

$$\geq \int q_\phi(\mathbf{z}) \log \frac{p(\mathbf{x}, \mathbf{z})}{q_\phi(\mathbf{z})} d\mathbf{z} = E_q[\log p(\mathbf{x}, \mathbf{z})] - E_q[\log q_\phi(\mathbf{z})] =: \mathcal{L}(\phi)$$

故 $\log p(\mathbf{x}) \geq \mathcal{L}(\phi)$ (ELBO 是证据下界)。

(b) 等价性

$$\log p(\mathbf{x}) = \mathcal{L}(\phi) + D_{\text{KL}}(q_\phi \| p(\mathbf{z}|\mathbf{x}))$$

(精确分解, 因为 $\log p(\mathbf{x})$ 不依赖 q , 等式恒成立。)

最大化 $\mathcal{L}(\phi) \Leftrightarrow$ 最小化 $D_{\text{KL}}(q_\phi \| p(\mathbf{z}|\mathbf{x}))$ 。

(c) 坐标上升 CAVI 更新

均场假设 $q(\mathbf{z}) = \prod_i q_i(z_i)$, 固定 q_{-j} , 对 q_j 优化:

$$\mathcal{L} = E_q[\log p(\mathbf{x}, \mathbf{z})] - \sum_i E_{q_i}[\log q_i(z_i)]$$

对 q_j 的变分导数为零, 得:

$$\log q_j^*(z_j) = E_{-j}[\log p(\mathbf{x}, \mathbf{z})] + \text{const}$$

即 $q_j^*(z_j) \propto \exp(E_{-j}[\log p(\mathbf{x}, \mathbf{z})])$, 其中 E_{-j} 表示在所有其他 q_k ($k \neq j$) 下取期望。

答案: $\boxed{\mathcal{L}(\phi) = E_q[\log p(\mathbf{x}, \mathbf{z})] - E_q[\log q_\phi]}$; 最大化 ELBO $\Leftrightarrow$ 最小化 KL; CAVI 更新 $\log q_j^* = E_{-j}[\log p(\mathbf{x}, \mathbf{z})] + \text{const}$ 。

D.8.11 (Ch.24, 隐马尔可夫模型前向算法)

题目: 定义前向变量并写递推; 用前向变量表达似然; 分析计算复杂度。

思路: 动态规划递推; 时间复杂度对比暴力枚举。

解:

(a) 前向变量定义与递推

设 HMM 有 N 个隐状态, 初始分布 $\pi_i = P(S_1 = i)$, 转移矩阵 $A_{ij} = P(S_{t+1} = j | S_t = i)$, 发射矩阵 $B_i(o) = P(o_t = o | S_t = i)$ 。

初始化 ($t = 1$):

$$\alpha_1(i) = \pi_i \cdot B_i(o_1), \quad i = 1, \dots, N$$

递推 ($t = 2, \dots, T$):

$$\alpha_t(j) = \left[\sum_{i=1}^N \alpha_{t-1}(i) \cdot A_{ij} \right] \cdot B_j(o_t), \quad j = 1, \dots, N$$

(b) 似然计算

$$P(O | \lambda) = \sum_{i=1}^N \alpha_T(i)$$

对最终时刻的所有可能隐状态求和, 消去隐状态序列。

(c) 计算复杂度

- 暴力枚举: N^T 条路径, 每条路径计算 $O(T)$ 步, 总复杂度 $O(N^T \cdot T)$, 指数级。
- 前向算法: 每步递推需 $O(N^2)$ (对每个 j , 对所有 i 求和), 共 T 步, 总复杂度 $O(N^2 T)$ 。

动态规划本质: 利用递推关系 $\alpha_t = f(\alpha_{t-1})$, 存储中间结果避免重复计算, 将指数问题化为多项式。

答案: 初始化 $\alpha_1(i) = \pi_i B_i(o_1)$, 递推 $\alpha_t(j) = [\sum_i \alpha_{t-1}(i) A_{ij}] B_j(o_t)$; $P(O|\lambda) = \sum_i \alpha_T(i)$; 复杂度 $O(N^2 T)$ (vs 暴力的 $O(N^T)$)。

D.8.12 (Ch.24, 高斯过程回归简介)

题目: 写观测边际分布; 写后验预测均值与方差; 说明与核岭回归的等价性。

思路: GP 的闭式后验源自高斯条件分布公式。

解:

设训练输入 $\mathbf{X} \in \mathbb{R}^{n \times d}$, 核矩阵 $K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$, 均值函数 $m(\cdot) \equiv 0$ (简化)。

(a) 观测边际分布

$$\mathbf{y} \sim \mathcal{N}(\mathbf{0}, \mathbf{K} + \sigma_n^2 \mathbf{I})$$

其中 $\mathbf{K} = k(\mathbf{X}, \mathbf{X})$ ($n \times n$ 核矩阵), 噪声方差 σ_n^2 来自 ε 。

(b) 后验预测分布

对新输入 $\mathbf{x}^*$, 令 $\mathbf{k}_* = k(\mathbf{X}, \mathbf{x}^*)$ ($n \times 1$), $k_{**} = k(\mathbf{x}^*, \mathbf{x}^*)$:

$$\mu_n(\mathbf{x}^*) = \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y}$$

$$\sigma_n^2(\mathbf{x}^*) = k_{**} - \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{k}_*$$

(由二元高斯的条件分布公式导出。)

(c) 与核岭回归 (KRR) 的等价性

KRR 最优权重: $\hat{\mathbf{w}} = (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y}$, 预测 $\hat{f}(\mathbf{x}^*) = \mathbf{k}_*^\top \hat{\mathbf{w}} = \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y}$ 。

与 GP 后验均值 $\mu_n(\mathbf{x}^*)$ 完全一致。KRR 只给出点预测, GP 还额外提供不确定性量化 (后验方差 $\sigma_n^2(\mathbf{x}^*)$), 体现贝叶斯框架的优势。

答案: $\mathbf{y} \sim \mathcal{N}(\mathbf{0}, \mathbf{K} + \sigma_n^2 \mathbf{I})$; 后验均值 $\mu_n = \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y}$, 方差 $\sigma_n^2 = k_{**} - \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{k}_*$; 与 KRR 点预测等价, GP 额外提供不确定性。

E 提高题详解 (10 题)

E.8.1 (Ch.22, KL 散度 + 互信息 + 信息瓶颈原理)

题目: 马尔可夫链 $X \rightarrow Z \rightarrow Y$, 信息瓶颈目标 $\max I(Z; Y) - \beta I(Z; X)$ 。

思路: 互信息 KL 表示 $\rightarrow$ 数据处理不等式 $\rightarrow$ IB Lagrangian 最优解推导 $\rightarrow$ 极端情形分析 $\rightarrow$ 信息平面假说批评。

解:

(a) 互信息的 KL 表示与链式规则

$$\begin{aligned}
I(Z; X) &= D_{\text{KL}}(p(x, z) \| p(x)p(z)) = \sum_{x, z} p(x, z) \log \frac{p(x, z)}{p(x)p(z)} \\
&= \sum_{x, z} p(x, z) \log \frac{p(z|x)}{p(z)} = E_{p(x, z)} \left[\log \frac{p(z|x)}{p(z)} \right]
\end{aligned}$$

链式规则验证:

$$\begin{aligned}
H(Z) - H(Z|X) &= - \sum_z p(z) \log p(z) + \sum_{x, z} p(x, z) \log p(z|x) \\
&= \sum_{x, z} p(x, z) \log \frac{p(z|x)}{p(z)} = I(Z; X) \quad \checkmark
\end{aligned}$$

类似地 $I(Z; X) = H(X) - H(X|Z)$ (利用 $p(x, z)$ 对称处理)。

(b) 数据处理不等式 (DPI)

$X \rightarrow Z \rightarrow Y$ 为马尔可夫链, 即 $p(y|x, z) = p(y|z)$ (Y 的生成仅依赖 Z , 不依赖 X)。

$$\begin{aligned}
I(X; Y) - I(Z; Y) &= H(Y) - H(Y|X) - H(Y) + H(Y|Z) \\
&= H(Y|Z) - H(Y|X)
\end{aligned}$$

由马尔可夫链 $X \rightarrow Z \rightarrow Y$, $H(Y|Z) = H(Y|Z, X)$ (给定 Z 则 $Y \perp X$), 故:

$$I(X; Y) - I(Z; Y) = H(Y|Z) - H(Y|X) = I(X; Y|Z) \geq 0$$

最后不等号因互信息非负。故 $I(X; Y) \geq I(Z; Y)$ 。

直觉: 压缩表示 Z 只能丢失关于 Y 的信息, 不能创造。

(c) IB Lagrangian 最优解

优化目标: $\max_{p(z|x)} I(Z; Y) - \beta I(Z; X)$, 约束 $p(z|x)$ 为概率核。

写出 Lagrangian (含归一化约束乘子 $\lambda(x)$) 并对 $p(z|x)$ 变分 (泛函导数):

$$\frac{\delta}{\delta p(z|x)} [I(Z; Y) - \beta I(Z; X)] = 0$$

展开 $I(Z; Y) = \sum_{x, z} p(x, z) [p(y|z) - p(y)]$ (利用 $p(y|z)$ 与 $p(z|x)$ 的关系):

最优解满足 (Blahut-Arimoto 型迭代):

$$p^*(z|x) \propto p(z) \exp(-\beta D_{\text{KL}}(p(y|x) \| p(y|z)))$$

其中 $p(z) = \sum_x p(x)p^*(z|x)$ (自洽方程, 需迭代求解)。

极端情形:

- $\beta \rightarrow 0$ (忽略压缩惩罚): $p^*(z|x) \propto p(z)$, 即 $Z \perp X$, Z 与 X 完全无关 (无信息), $I(Z; Y) \rightarrow 0$ 。
 - $\beta \rightarrow \infty$ (强压缩惩罚占主导, 但 IB 目标中 $-\beta I(Z; X)$ 趋于 $-\infty$, 需理解为 $Z = X$ 才能使 $p(y|z) = p(y|x)$ 最小化 KL): 实际上 $\beta \rightarrow \infty$ 时, 最优 $Z = X$ (保留所有关于 X 的信息), $I(Z; X) = H(X)$, $I(Z; Y) = I(X; Y)$ 。
- β 控制压缩-相关权衡: β 小时保留 X 少 (强压缩), β 大时保留 X 多 (弱压缩)。

(d) 信息平面假说与批评

Tishby 等人假说 (2017): 深层网络训练分两阶段: □ 拟合阶段: $I(X; T_l)$ 和 $I(T_l; Y)$ 同时增大 (梯度下降拟合数据); □ 压缩阶段: $I(X; T_l)$ 减小, $I(T_l; Y)$ 维持 (网络“忘记”与 Y 无关的 X 信息)。

Saxe 等人反例 (2018): 使用确定性 (非随机) 激活函数时, 训练中 $I(X; T_l)$ 不减小 (因确定性函数的互信息在变换下单调); 压缩现象仅在 **SGD** 随机噪声存在时出现 (ReLU + 双精度训练下无压缩)。

随机梯度噪声的作用: SGD 的随机性 (mini-batch 噪声) 等效于隐式正则化, 促使网络学习低 $I(X; T_l)$ 的表示 (信息压缩)。使用饱和激活函数 (tanh) 时, 梯度饱和和引入的随机性更强, 压缩更明显。

共识: 信息平面假说在某些架构和激活函数下成立, 但不是普遍规律; 互信息的估计本身 (尤其是连续层的 $I(X; T_l)$) 计算困难, 结论依赖于估计方法。

E.8.2 (Ch.22+Ch.23, 最大熵谱分析 + 随机过程 + MCMC 诊断)

题目: Wiener-Khintchine 定理、最大熵谱、ESS、HMC。

思路: 平稳过程谱理论 $\rightarrow$ AR 过程最大熵 $\rightarrow$ ESS 与自相关 $\rightarrow$ HMC 保体积性。

解:

(a) Wiener-Khintchine 定理

平稳过程 $\{X_t\}$, 自相关 $R(k) = E[X_t X_{t+k}]$ (不依赖 t)。

$$S(f) = \sum_{k=-\infty}^{\infty} R(k) e^{-2\pi i f k} = \mathcal{F}[R(\cdot)](f)$$

证明 $S(f) \geq 0$ (Bochner 定理): $R(k)$ 是正定序列 (因为 $\text{Var}(\sum c_k X_{t_k}) \geq 0$), 由 Bochner 定理, 其 Fourier 变换是非负测度 (即 $S(f) \geq 0$)。 $S(f)$ 描述单位频率带宽内的平均功率, 非负具有物理意义。

(b) 最大熵谱 (Burg 算法)

已知 $R(0), R(1), \dots, R(p)$, 最大化微分熵:

$$h[S] = \int_{-1/2}^{1/2} \log S(f) df$$

约束: $\int S(f) e^{2\pi i f k} df = R(k), k = 0, 1, \dots, p$ 。

Lagrangian 变分:

$$\frac{\delta}{\delta S(f)} \left[\int \log S(f) df - \sum_{k=0}^p \lambda_k \left(\int S(f) e^{2\pi i f k} df - R(k) \right) \right] = 0$$

$$\frac{1}{S(f)} = \sum_{k=-p}^p \lambda_k e^{2\pi i f k}$$

$$S(f) = \frac{1}{\sum_{k=-p}^p \lambda_k e^{2\pi i f k}} = \frac{\sigma^2}{|1 + \sum_{k=1}^p a_k e^{-2\pi i f k}|^2}$$

这正是 AR(p) 过程的功率谱密度 (有理谱), 其中 $a_1, \dots, a_p$ 为 AR 系数, 由 Yule-Walker 方程确定。

(c) 有效样本量 (ESS) 推导

i.i.d. 情形: $\text{Var}(\bar{X}_{n,\text{iid}}) = \sigma^2/n$ 。

MCMC 样本自相关为 $\rho(k) = \text{Corr}(X_t, X_{t+k})$, 则:

$$\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n} \left(1 + 2 \sum_{k=1}^{n-1} \left(1 - \frac{k}{n} \right) \rho(k) \right) \xrightarrow{n \rightarrow \infty} \frac{\sigma^2}{n} \left(1 + 2 \sum_{k=1}^{\infty} \rho(k) \right)$$

等效 i.i.d. 样本量 n_{eff} 满足 $\text{Var}(\bar{X}_n) = \sigma^2/n_{\text{eff}}$, 故:

$$n_{\text{eff}} = \frac{n}{1 + 2 \sum_{k=1}^{\infty} \rho(k)}$$

若 $\rho(k) = \rho^k$ (指数衰减), 则 $\sum \rho^k = \rho/(1 - \rho)$, $n_{\text{eff}} = n(1 - \rho)/(1 + \rho)$ 。高维随机游走 MH 中 $\rho \rightarrow 1$, $n_{\text{eff}} \rightarrow 0$, 效率极低。

(d) HMC 与 NUTS

HMC 引入辅助动量 $\mathbf{p} \sim \mathcal{N}(\mathbf{0}, \mathbf{M})$, 联合分布:

$$\tilde{\pi}(\mathbf{q}, \mathbf{p}) \propto \exp(-H(\mathbf{q}, \mathbf{p})), \quad H = -\log \pi(\mathbf{q}) + \frac{\mathbf{p}^\top \mathbf{M}^{-1} \mathbf{p}}{2}$$

Leapfrog 积分器 (保体积性 / Liouville 定理): Hamiltonian 动力学为辛映射, 行列式为 1 (体积保持), 使得 MH 接受率接近 1 (步长合适时接近 100%)。

Leapfrog 步骤 (步长 ϵ , L 步):

$$\mathbf{p}_{t+\epsilon/2} = \mathbf{p}_t + \frac{\epsilon}{2} \nabla \log \pi(\mathbf{q}_t)$$

$$\mathbf{q}_{t+\epsilon} = \mathbf{q}_t + \epsilon \mathbf{M}^{-1} \mathbf{p}_{t+\epsilon/2}$$

$$\mathbf{p}_{t+\epsilon} = \mathbf{p}_{t+\epsilon/2} + \frac{\epsilon}{2} \nabla \log \pi(\mathbf{q}_{t+\epsilon})$$

NUTS: 通过“不掉头”条件自适应确定路径长度 (停止于 $\mathbf{p} \cdot (\mathbf{q} - \mathbf{q}_0) < 0$ 时), 避免手动调 L , 同时满足细致平衡 (通过 slice 采样)。

HMC 消除随机游走: 每次提议沿 Hamiltonian 轨迹移动, 大步长 + 高接受率, n_{eff}/n 接近 1, 远优于随机游走 MH。

E.8.3 (Ch.23, 重要性采样 + 自归一化 + 粒子滤波)

题目: SNIS 有偏但相合; ESS 推导; 粒子滤波递推; 扩散模型与粒子滤波联系。

解:

(a) SNIS 有偏但相合

$$\hat{\mu}_{SNIS} = \frac{\sum_{i=1}^n w_i f(X_i)}{\sum_{i=1}^n w_i}$$

有偏: $E[\hat{\mu}_{SNIS}] \neq E_\pi[f(X)]$ (比率估计一般有偏, 偏差 $O(1/n)$)。

相合: 由大数定律, $\frac{1}{n} \sum w_i f(X_i) \xrightarrow{P} E_q[wf] = E_\pi[f]$, $\frac{1}{n} \sum w_i \xrightarrow{P} E_q[w] = 1$,

故由连续映射定理, $\hat{\mu}_{SNIS} \xrightarrow{P} E_\pi[f(X)]$ 。

(b) ESS 推导

归一化权重 $\bar{w}_i = w_i / \sum_j w_j$, 类比 i.i.d. 加权平均的等效样本量:

$$\hat{n}_{\text{eff}} = \frac{(\sum_i w_i)^2}{\sum_i w_i^2} = \frac{1}{\sum_i \bar{w}_i^2}$$

- 当 $q = \pi$: 所有 $w_i = 1$, $\hat{n}_{\text{eff}} = n^2/n = n$ (最大)。
- 权重退化: 若某 $\bar{w}_j \rightarrow 1$, 其余 $\rightarrow 0$, 则 $\sum \bar{w}_i^2 \rightarrow 1$, $n_{\text{eff}} \rightarrow 1$ (最差)。

(c) 粒子滤波 (SIR)

目标: 递推估计过滤分布 $p(x_t|y_{1:t})$, 用粒子 $\{x_t^{(i)}, w_t^{(i)}\}_{i=1}^N$ 近似。

权重更新 (时间 t 的新观测 y_t):

$$\tilde{w}_t^{(i)} = w_{t-1}^{(i)} \cdot \frac{p(y_t|x_t^{(i)})p(x_t^{(i)}|x_{t-1}^{(i)})}{q(x_t^{(i)}|x_{t-1}^{(i)}, y_t)}$$

用先验作为提议 (Bootstrap Filter, $q = p(\cdot|x_{t-1})$) 时简化为:

$$\tilde{w}_t^{(i)} = w_{t-1}^{(i)} \cdot p(y_t|x_t^{(i)})$$

归一化: $w_t^{(i)} = \tilde{w}_t^{(i)} / \sum_j \tilde{w}_t^{(j)}$ 。

重采样: 当 $\text{ESS} < N/2$ 时, 按权重 $w_t^{(i)}$ 多项式重采样 N 个粒子 (重置权重为 $1/N$), 防止权重退化。

(d) 扩散模型与粒子滤波

DDPM 前向过程: $q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\alpha_t}x_0, (1 - \bar{\alpha}_t)\mathbf{I})$ (逐步加噪的高斯核)。

反向过程: $p_\theta(x_{t-1}|x_t)$ 学习时间反转分布, 参数化为:

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \sigma_t^2\mathbf{I})$$

与粒子滤波对应:

粒子滤波	扩散模型
隐状态 x_t (噪声水平)	噪声图像 x_t
前向转移 $p(x_t x_{t-1})$	加噪核 $q(x_t x_{t-1})$
预测步 (prior)	去噪网络均值预测
校正步 (观测更新)	条件去噪 (Classifier Guidance)
重采样	无 (确定性/随机性采样器)

统计原理: 去噪网络估计 score 函数 $\nabla_{x_t} \log q(x_t) \approx -\varepsilon_\theta(x_t, t)/\sqrt{1 - \bar{\alpha}_t}$, 对应时间反转 SDE 的漂移项 (Anderson, 1982)。

E.8.4 (Ch.24+Ch.22, 变分推断 + 均场近似 + 自由能)

题目: ELBO 等价性证明; CAVI 推导; GMM 的 VI 更新; KL 方向与均场的代价。

解:

(a) 最小化 KL 等价于最大化 ELBO

精确分解 (Jensen 等号后加余项):

$$\begin{aligned}\log p(\mathbf{x}) &= \int q(\mathbf{z}) \log p(\mathbf{x}) d\mathbf{z} = \int q(\mathbf{z}) \log \frac{p(\mathbf{x}, \mathbf{z})}{q(\mathbf{z})} d\mathbf{z} + \int q(\mathbf{z}) \log \frac{q(\mathbf{z})}{p(\mathbf{z}|\mathbf{x})} d\mathbf{z} \\ &= \mathcal{L}(q) + D_{\text{KL}}(q \| p(\cdot|\mathbf{x}))\end{aligned}$$

其中 $\mathcal{L}(q) = E_q[\log p(\mathbf{x}, \mathbf{z})] - E_q[\log q(\mathbf{z})]$ 。

由于 $\log p(\mathbf{x})$ 是常数 (不依赖 q)，最大化 $\mathcal{L}(q)$ 与最小化 $D_{\text{KL}}(q \| p(\cdot|\mathbf{x}))$ 完全等价。

(b) CAVI 更新方程推导

均场假设 $q(\mathbf{z}) = \prod_i q_i(z_i)$ ，展开 ELBO:

$$\mathcal{L} = \int \prod_i q_i \cdot \log p(\mathbf{x}, \mathbf{z}) d\mathbf{z} - \sum_j \int q_j \log q_j dz_j + \text{const}_{-j}$$

固定 $q_{i \neq j}$ ，对 $q_j(z_j)$ 变分 (带归一化约束 Lagrange 乘子):

$$\frac{\delta \mathcal{L}}{\delta q_j(z_j)} = E_{-j}[\log p(\mathbf{x}, \mathbf{z})] - \log q_j(z_j) - 1 = 0$$

$$\log q_j^*(z_j) = E_{-j}[\log p(\mathbf{x}, \mathbf{z})] + \text{const}$$

$$q_j^*(z_j) \propto \exp(E_{q_{-j}}[\log p(\mathbf{x}, \mathbf{z})])$$

坐标上升: 循环更新每个 q_j ，固定其余，直到 ELBO 收敛 (保证单调不减)。

(c) GMM 的 CAVI (均场 VI)

高斯混合模型: $z_n \in \{1, \dots, K\}$ (类别)， $\mathbf{x}_n | z_n = k \sim \mathcal{N}(\mu_k, \Lambda_k^{-1})$ ，先验 $p(z_n) = \text{Cat}(\pi)$ ， $p(\mu_k) = \mathcal{N}(\mathbf{m}_0, \beta_0^{-1} \Lambda_k^{-1})$ 。

均场近似: $q(\mathbf{z}, \mu, \Lambda) = \prod_n q(z_n) \cdot \prod_k q(\mu_k, \Lambda_k)$ 。

隐类别更新 ($q(z_n) = \text{Cat}(r_n)$):

$$r_{nk} \propto \exp\left(E[\log \pi_k] + \frac{1}{2}E[\log |\Lambda_k|] - \frac{d}{2}\log(2\pi) - \frac{1}{2}E[(\mathbf{x}_n - \mu_k)^\top \Lambda_k (\mathbf{x}_n - \mu_k)]\right)$$

其中 $r_{nk} = E[z_n = k]$ (软分配, 类似 EM 的 γ)。

均值参数更新 ($q(\mu_k) = \mathcal{N}(\mathbf{m}_k, \beta_k^{-1} \Lambda_k^{-1})$):

$$\beta_k = \beta_0 + N_k, \quad \mathbf{m}_k = \frac{\beta_0 \mathbf{m}_0 + N_k \bar{\mathbf{x}}_k}{\beta_k}$$

其中 $N_k = \sum_n r_{nk}$ (有效分配数), $\bar{\mathbf{x}}_k = \sum_n r_{nk} \mathbf{x}_n / N_k$ (软加权均值)。

(d) KL 方向与均场代价

	$D_{\text{KL}}(q\ p)$ (VI 标准)	$D_{\text{KL}}(p\ q)$ (期望传播 EP)
行为	零覆盖 (zero-forcing): q 避开 $p = 0$ 的区域	均值覆盖 (zero-avoiding): q 覆盖 $p > 0$ 的所有区域
多模态 p	只捕获一个模	找均值模 (可能落在两峰之间)
方差估计	低估方差 (过于自信)	高估方差
均场限制	无法表示变量间相关性 (因子化假设)	

Normalizing Flow 通过可逆变换 $z = f_\phi(u)$ ($u \sim \mathcal{N}$) 将高斯变换为复杂分布, 保持精确似然可算 ($\log q(z) = \log p(u) - \log |\det \partial f / \partial u|$), 突破均场因子化限制, 可表示多模态后验。

E.8.5 (Ch.23+Ch.24, MCMC + 马尔可夫链平稳分布 + 混合时间)

题目: 细致平衡 $\rightarrow$ 平稳分布; MH 满足细致平衡; 混合时间谱隙界; LLM 温度与谱隙。

解:

(a) 细致平衡蕴含平稳性

设细致平衡: $\pi_i P_{ij} = \pi_j P_{ji}$, 对 j 求和:

$$\sum_i \pi_i P_{ij} = \sum_i \pi_j P_{ji} = \pi_j \sum_i P_{ji} = \pi_j \cdot 1 = \pi_j$$

即 $(\pi \mathbf{P})_j = \pi_j$, 故 $\pi \mathbf{P} = \pi$, π 是平稳分布。

(b) M-H 满足细致平衡

设 $x \neq y$, M-H 核: $k(x, y) = q(x, y) \alpha(x, y)$, $\alpha(x, y) = \min(1, \frac{\pi(y)q(y, x)}{\pi(x)q(x, y)})$ 。

不妨设 $\pi(x)q(x, y) \geq \pi(y)q(y, x)$, 则 $\alpha(x, y) = \frac{\pi(y)q(y, x)}{\pi(x)q(x, y)}$, $\alpha(y, x) = 1$:

$$\pi(x)k(x, y) = \pi(x)q(x, y) \cdot \frac{\pi(y)q(y, x)}{\pi(x)q(x, y)} = \pi(y)q(y, x) = \pi(y)q(y, x) \cdot 1 = \pi(y)k(y, x)$$

细致平衡成立, π 是平稳分布。□

(c) 混合时间与谱隙

对有限可逆链 (满足细致平衡), 转移矩阵特征值 $1 = \lambda_1 > \lambda_2 \geq \dots \geq \lambda_N \geq -1$ (不可约非周期链), 谱隙 $\text{Gap} = 1 - \lambda_2$ 。

由谱分解, $P^t(x, \cdot) - \pi$ 的衰减由最大非平凡特征值控制:

$$\|P^t(x, \cdot) - \pi\|_{TV} \leq \sqrt{\frac{1}{\pi(x)}} \cdot \lambda_2^t \leq \sqrt{\frac{1}{\pi_{\min}}} \cdot e^{-t \cdot \text{Gap}}$$

(近似, 利用 $\lambda_2 \leq e^{-\text{Gap}}$)。令右边 $\leq \varepsilon$:

$$t \geq \frac{\log(1/\varepsilon \cdot \pi_{\min}^{-1/2})}{\text{Gap}} \leq \frac{\log(1/\varepsilon \pi_{\min})}{\text{Gap}}$$

故 $t_{\text{mix}}(\varepsilon) = O\left(\frac{\log(1/\varepsilon \pi_{\min})}{\text{Gap}}\right)$ 。

(d) LLM 自回归采样与温度

LLM 生成 token 的转移概率: $P_T(w|w_{<t}) \propto \exp(\text{logit}(w)/T)$ 。

温度 T 对谱隙的影响:

- $T \rightarrow 0$: 分布趋于 argmax (退化分布), $\pi_{\min} \rightarrow 0$, 谱隙趋于 0, 链混合极慢 (卡在局部最高概率序列)。
- $T \rightarrow \infty$: 均匀分布, 谱隙最大 ($\sim 1 - 1/V$, V = 词表大小), 混合最快, 但输出无意义 (随机)。
- $T = 1$: 标准 softmax, 谱隙与模型概率差异相关。

最优温度权衡: 最大化有效信息率 $= I(\text{context}; \text{token}) \times n_{\text{eff}}/n$ (互信息乘以混合效率)。实践中 $T \in [0.7, 1.0]$ 在流畅性与多样性间取得平衡。

□ 温度参数仅改变 logit 的尺度, 不改变模型的知识, 但显著影响输出分布的熵和采样链的混合速度。

E.8.6 (Ch.22+Ch.24, 概率图模型 + 信念传播 + 近似推断)

题目: 树上 BP 消息方程; 树上精确性; Bethe 自由能; 神经 CRF 均场推断。

解:

(a) 树结构因子图上的 BP 消息方程

因子图 $G = (V, F, E)$, 变量 v 到因子 f 的消息:

$$\mu_{v \rightarrow f}(x_v) = \prod_{f' \in \text{ne}(v) \setminus f} \mu_{f' \rightarrow v}(x_v)$$

因子 f 到变量 v 的消息:

$$\mu_{f \rightarrow v}(x_v) = \sum_{\mathbf{x}_f \setminus x_v} f(\mathbf{x}_f) \prod_{u \in \text{ne}(f) \setminus v} \mu_{u \rightarrow f}(x_u)$$

边际信念: $b(x_v) \propto \prod_{f \in \text{ne}(v)} \mu_{f \rightarrow v}(x_v)$ 。

(b) 树上 BP 精确性

树图无环, 消息从叶节点向根单向传播 (两遍: 叶 $\rightarrow$ 根, 根 $\rightarrow$ 叶), 有限步 ($O(\text{直径})$ 步) 内收敛。精确性证明:

通过结构归纳 (剥叶定理), 消息等于对应子树的边际和 (精确 sum-product), 最终信念等于精确边际。

循环图 (**Loopy BP**) 不精确原因: 消息在环路中循环传递, 同一信息被”重复计数”, 等价于无限次展开树上的近似 (Bethe 近似)。不保证收敛, 即使收敛也是近似解。

(c) Bethe 自由能

精确自由能: $F = -\log Z$ (配分函数对数)。

Bethe 近似用信念 $\{b_f, b_v\}$ (满足局部一致性约束) 参数化, Bethe 自由能为:

$$F_{\text{Bethe}} = - \sum_f \sum_{\mathbf{x}_f} b_f(\mathbf{x}_f) \log \frac{f(\mathbf{x}_f)}{b_f(\mathbf{x}_f)} - \sum_v (d_v - 1) \sum_{x_v} b_v(x_v) \log b_v(x_v)$$

其中 $d_v = |\text{ne}(v)|$ 为变量 v 的度数, $(d_v - 1)$ 是对边际重叠的修正。

树图上 $F_{\text{Bethe}} = F_{\text{exact}}$: 树图上所有变量度数 d_v , 对应的”重计数”修正恰好使 Bethe 等于精确值 (可通过精确信念代入验证等号)。

循环图: BP 不动点恰好是 F_{Bethe} 的驻点 (Yedidia 等, 2001), 但不保证是全局最小, 且 $F_{\text{Bethe}} \neq F_{\text{exact}}$ 。

(d) 神经 CRF 与均场推断

密集 CRF (DenseCRF) 能量函数: $E(\mathbf{x}) = -\sum_i \psi_u(x_i) - \sum_{i < j} \psi_p(x_i, x_j)$, 成对势为 Gaussian 核混合。

均场推断迭代 ($Q(\mathbf{x}) = \prod_i Q_i(x_i)$):

1. 消息传递: $\tilde{Q}_i(l) = -\sum_m \mu_m \sum_j k^m(\mathbf{f}_i, \mathbf{f}_j) Q_j(l)$ (Gaussian 卷积, 可用快速滤波)
2. 相容性变换: $\hat{Q}_i(l) = \sum_{l'} \mu(l, l') \tilde{Q}_i(l')$ (标签兼容矩阵)
3. 更新: $Q_i(x_i) \propto \exp(\psi_u(x_i) - \hat{Q}_i(x_i))$

嵌入端到端训练: 步骤 1-3 构成确定性的 RNN 迭代 (固定迭代次数 T), 梯度通过 BPTT 反向传播, 与 CNN 特征提取器联合训练 (CRFasRNN, Zheng 等 2015)。

E.8.7 (Ch.22, Rényi 散度 + α -散度 + 鲁棒推断)

题目: $\alpha \rightarrow 1$ 极限; 非负性与单调性; Bhattacharyya 距离计算; 鲁棒推断优势。

解:

$$(a) \lim_{\alpha \rightarrow 1} D_{\alpha}(p\|q) = D_{\text{KL}}(p\|q)$$

$$D_{\alpha}(p\|q) = \frac{1}{\alpha - 1} \log \underbrace{\int p^{\alpha} q^{1-\alpha} dx}_{Z(\alpha)}$$

当 $\alpha = 1$: $Z(1) = \int p dx = 1$, $D_1 = 0/0$ (不定式)。用 L'Hôpital:

$$\lim_{\alpha \rightarrow 1} D_{\alpha} = \lim_{\alpha \rightarrow 1} \frac{\log Z(\alpha)}{\alpha - 1} = \frac{Z'(1)}{Z(1)} = Z'(1)$$

$$Z'(\alpha) = \frac{d}{d\alpha} \int p^{\alpha} q^{1-\alpha} dx = \int p^{\alpha} q^{1-\alpha} \log \frac{p}{q} dx$$

$$Z'(1) = \int p \log \frac{p}{q} dx = D_{\text{KL}}(p\|q)$$

故 $\lim_{\alpha \rightarrow 1} D_{\alpha}(p\|q) = D_{\text{KL}}(p\|q)$ 。□

(b) 非负性与单调性

非负性: 令 $r(x) = p(x)/q(x)$, 则

$$Z(\alpha) = E_q[r^{\alpha}] \geq (E_q[r])^{\alpha} = 1^{\alpha} = 1$$

(对 $\alpha > 0$, 由 Jensen 和 r^{α} 凸/凹性, 结合 $\log Z \geq 0$, $D_{\alpha} \geq 0$ 。对 $\alpha < 0$ 类似。)

关于 α 单调: $D_{\alpha}(p\|q)$ 关于 α 单调不减 (由 log-sum 不等式, $\partial D_{\alpha}/\partial \alpha \geq 0$), 故:

$$D_0 \leq D_{1/2} \leq D_1 = D_{\text{KL}} \leq D_2 \leq \dots$$

(c) Bhattacharyya 距离 ($\alpha = 1/2$)

$$D_{1/2}(p\|q) = -2 \log \int \sqrt{p(x)q(x)} dx$$

对 $p = \mathcal{N}(\mu_1, \sigma^2)$, $q = \mathcal{N}(\mu_2, \sigma^2)$ (同方差):

$$\int \sqrt{p(x)q(x)} dx = \int \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu_1)^2 + (x-\mu_2)^2}{4\sigma^2}\right) dx$$

配方: $(x-\mu_1)^2 + (x-\mu_2)^2 = 2(x-\bar{\mu})^2 + (\mu_1-\mu_2)^2/2$, 其中 $\bar{\mu} = (\mu_1 + \mu_2)/2$:

$$\int \sqrt{pq} dx = \exp\left(-\frac{(\mu_1-\mu_2)^2}{8\sigma^2}\right) \cdot \int \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\bar{\mu})^2}{2 \cdot (\sigma^2/2)}\right) dx \cdot \frac{1}{\sqrt{2}}$$

实际上更简洁: 两高斯的 Bhattacharyya 系数为 $BC = \exp(-(\mu_1-\mu_2)^2/(8\sigma^2)) \cdot \sqrt{2\sigma^2/(2\sigma^2)} = \exp(-(\mu_1-\mu_2)^2/(8\sigma^2))$,

$$D_B = -\log BC = \frac{(\mu_1-\mu_2)^2}{8\sigma^2}$$

(同方差正态情形, Bhattacharyya 距离仅由均值之差决定。)

答案:
$$D_B = \frac{(\mu_1-\mu_2)^2}{8\sigma^2}$$

(d) 鲁棒推断中的 α -散度

Power EP: 用 α -散度 $D_\alpha(p\|q)$ 替代 KL, 近似各因子时使用 $\alpha < 1$ (“矩匹配”转向), 对重尾似然 (柯西分布) 更稳健: $KL(p\|q)$ 要求 $p > 0$ 处 $q > 0$ (零覆盖), 对重尾数据可能导致过度收缩; $\alpha < 1$ 的散度对异常值不敏感 (因为 p^α 对大 p 的惩罚较轻)。

VAE 中后验坍塌 (Posterior Collapse): 当 $D_{KL}(q_\phi(z|x)\|p(z))$ 主导 ELBO 时, $q_\phi \rightarrow p(z)$ (先验), 编码器无法传递信息。用 $\alpha < 1$ 的 Rényi 散度替换 KL:

$$\mathcal{L}_\alpha = E_{q_\phi}[\log p(x|z)] - D_{1-\alpha}(q_\phi\|p)$$

$\alpha < 1$ 时惩罚项更小 ($D_\alpha \leq D_{KL}$), q_ϕ 不被强制拉向先验, 缓解后验坍塌, 提高重建质量。

E.8.8 (Ch.23+Ch.24, 随机变分推断 + 黑盒 VI + 策略梯度联系)

题目: REINFORCE 梯度估计; 基线不改变期望的证明; 最优基线; 重参数化 vs 打分函数。

解:

(a) REINFORCE (打分函数) 梯度估计量

目标: $\nabla_{\phi} \mathcal{L}(\phi) = \nabla_{\phi} E_{q_{\phi}(\mathbf{z})}[f(\mathbf{z})]$, 其中 $f(\mathbf{z}) = \log p(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z})$ 。

$$\begin{aligned}\nabla_{\phi} E_{q_{\phi}}[f(\mathbf{z})] &= \nabla_{\phi} \int q_{\phi}(\mathbf{z}) f(\mathbf{z}) d\mathbf{z} \\ &= \int f(\mathbf{z}) \nabla_{\phi} q_{\phi}(\mathbf{z}) d\mathbf{z} = \int f(\mathbf{z}) q_{\phi}(\mathbf{z}) \nabla_{\phi} \log q_{\phi}(\mathbf{z}) d\mathbf{z}\end{aligned}$$

(用对数导数技巧: $\nabla_{\phi} q_{\phi} = q_{\phi} \nabla_{\phi} \log q_{\phi}$)

$$= E_{q_{\phi}}[f(\mathbf{z}) \nabla_{\phi} \log q_{\phi}(\mathbf{z})]$$

代入 $f(\mathbf{z})$:

$$\nabla_{\phi} \mathcal{L} = E_{q_{\phi}}[(\log p(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z})) \nabla_{\phi} \log q_{\phi}(\mathbf{z})]$$

Monte Carlo 估计: 从 q_{ϕ} 抽 $\mathbf{z}^{(s)}$, 取样本均值。

(b) 基线不改变期望

设基线 b 不依赖 $\mathbf{z}$:

$$E_{q_{\phi}}[b \cdot \nabla_{\phi} \log q_{\phi}(\mathbf{z})] = b \cdot \int q_{\phi}(\mathbf{z}) \nabla_{\phi} \log q_{\phi}(\mathbf{z}) d\mathbf{z} = b \cdot \nabla_{\phi} \int q_{\phi}(\mathbf{z}) d\mathbf{z} = b \cdot \nabla_{\phi} 1 = 0$$

(利用 $\nabla_{\phi} \log q_{\phi} = \nabla_{\phi} q_{\phi} / q_{\phi}$ 和 $\int q_{\phi} d\mathbf{z} = 1$ 对 ϕ 求导为 0。)

故 $E_{q_{\phi}}[(f - b) \nabla_{\phi} \log q_{\phi}] = E_{q_{\phi}}[f \nabla_{\phi} \log q_{\phi}]$, 期望不变, 但方差降低。

(c) 最优基线

目标: 最小化每个分量 k 的方差 $\text{Var}((f - b) \frac{\partial \log q_{\phi}}{\partial \phi_k})$ 。

$$\frac{\partial}{\partial b} \text{Var}[(f - b)g_k] = \frac{\partial}{\partial b} [E[(f - b)^2 g_k^2]] = -2E[(f - b)g_k^2] = 0$$

$$b_k^* = \frac{E[f \cdot g_k^2]}{E[g_k^2]}, \quad g_k = \frac{\partial \log q_{\phi}}{\partial \phi_k}$$

向量形式: $b^* = \frac{E[f(\mathbf{z}) \|\nabla_{\phi} \log q_{\phi}\|^2]}{E[\|\nabla_{\phi} \log q_{\phi}\|^2]}$ 。

与 RL 策略梯度类比: $f(\mathbf{z}) \leftrightarrow R(\tau)$ (回报), $\log q_{\phi}(\mathbf{z}) \leftrightarrow \log \pi_{\theta}(\tau)$ (策略对数), 基线 $b \leftrightarrow V(s)$ (值函数), 最优基线减小梯度方差, 对应优势函数 $A(s, a) = Q(s, a) - V(s)$ 。

(d) 重参数化 vs 打分函数梯度

重参数化 (Reparameterization Trick): 对 Gaussian $q_\phi(\mathbf{z}) = \mathcal{N}(\mu, \Sigma)$, 令 $\mathbf{z} = \mu + \mathbf{L}\epsilon$, $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ($\mathbf{L}\mathbf{L}^\top = \Sigma$):

$$\nabla_\phi \mathcal{L} = E_\epsilon [\nabla_\phi f(\mu + \mathbf{L}\epsilon)]$$

梯度直接通过 f 传播, 方差远低于打分函数估计量。

离散变量问题: 离散 $\mathbf{z}$ (如图神经网络离散结构选择) 无法重参数化 (不可微)。

- **Gumbel-Softmax:** 连续松弛离散分布, $\tilde{z}_k = \text{softmax}((\log \pi_k + g_k)/\tau)$, $g_k \sim \text{Gumbel}(0, 1)$, 温度 $\tau \rightarrow 0$ 趋近真实类别, $\tau > 0$ 时可微。
- **Straight-Through Estimator (STE):** 前向传播用离散采样, 反向传播用恒等函数替代 ($\partial \text{stop_gradient} / \partial \text{input} = 1$), 简单粗糙但实践有效。

方差比较: 重参数化 $\ll$ STE $\approx$ Gumbel-Softmax $\ll$ REINFORCE (打分函数)。

E.8.9 (Ch.24, 贝叶斯优化 + 高斯过程代理模型 + 采集函数)

题目: GP 后验推导; UCB 采集函数与 EI 等价; 贝叶斯遗憾界; HPO 中的高维问题。

解:

(a) GP 后验推导

先验: $f \sim \mathcal{GP}(0, k(\cdot, \cdot))$ (零均值), 观测 $\mathbf{y} = f(\mathbf{X}) + \varepsilon$, $\varepsilon \sim \mathcal{N}(\mathbf{0}, \sigma_n^2 \mathbf{I})$ 。

联合分布:

$$\begin{pmatrix} f^* \\ \mathbf{y} \end{pmatrix} \sim \mathcal{N}\left(\mathbf{0}, \begin{pmatrix} k_{**} & \mathbf{k}_*^\top \\ \mathbf{k}_* & \mathbf{K} + \sigma_n^2 \mathbf{I} \end{pmatrix}\right)$$

条件高斯公式:

$$f^* | \mathbf{y} \sim \mathcal{N}(\mu_n(\mathbf{x}^*), \sigma_n^2(\mathbf{x}^*))$$

$$\mu_n(\mathbf{x}^*) = \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y}$$

$$\sigma_n^2(\mathbf{x}^*) = k_{**} - \mathbf{k}_*^\top (\mathbf{K} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{k}_*$$

(b) UCB 与 EI

UCB: $\alpha_{UCB}(\mathbf{x}) = \mu_n(\mathbf{x}) + \kappa \sigma_n(\mathbf{x})$, $\kappa > 0$ 控制探索-利用。

期望改进 (EI): $\alpha_{EI}(\mathbf{x}) = E[\max(f(\mathbf{x}) - f^+, 0)]$, $f^+ = \max_i y_i$:

$$\alpha_{EI}(\mathbf{x}) = (\mu_n(\mathbf{x}) - f^+) \Phi(z) + \sigma_n(\mathbf{x}) \phi(z), \quad z = \frac{\mu_n(\mathbf{x}) - f^+}{\sigma_n(\mathbf{x})}$$

两者在 $\kappa = \sqrt{2 \log(1/\delta)}$ (概率置信区间) 时近似等价; UCB 更直接分析, EI 有明确探索停止准则。

Thompson Sampling (TS): 从后验 $\mathcal{GP}$ 采样一条路径 $\hat{f} \sim p(\cdot | \mathcal{D}_n)$, 最大化 $\hat{f}$ ——与 UCB 一样实现探索-利用 (TS 的期望遗憾与 UCB 同阶)。

(c) 贝叶斯遗憾界

T 步后贝叶斯遗憾: $BR_T = E\left[\sum_{t=1}^T (f(\mathbf{x}^*) - f(\mathbf{x}_t))\right]$ 。

对 UCB 采集函数, Srinivas 等 (2010) 证明:

$$BR_T \leq O(\sqrt{T \gamma_T \log T})$$

其中最大信息增益 $\gamma_T = \max_{|\mathcal{A}|=T} I(f_{\mathcal{A}}; \mathbf{y}_{\mathcal{A}})$ (前 T 个点的信息增益上界)。

对常见核: SE 核 $\gamma_T = O((\log T)^{d+1})$; Matérn 核 $\gamma_T = O(T^{d/(2\nu+d)})$ (ν 为平滑参数)。

(d) HPO 中的 GP 困境与替代方法

GP 的维数诅咒: 核矩阵计算 $O(n^3)$ (n 为样本数); 在高维超参数空间 ($d > 20$) 中, GP 需指数多样本才能有效覆盖; 高维下 GP 倾向于均匀先验 (所有核矩阵趋于单位矩阵)。

BORE (贝叶斯优化通过密度比估计): 将采集函数 α_{EI} 转化为分类问题 (哪些参数配置产生好结果), 用二元分类器 (如神经网络、XGBoost) 估计密度比 $p(\mathbf{x}|\text{good})/p(\mathbf{x})$, 避开 GP 的 $O(n^3)$ 计算。

TPE (Tree-structured Parzen Estimator): 分别建模 $p(\mathbf{x}|y < y^*) = l(\mathbf{x})$ 和 $p(\mathbf{x}|y \geq y^*) = g(\mathbf{x})$ (用核密度估计), 采集函数为比率 $l(\mathbf{x})/g(\mathbf{x})$ 。树结构处理条件超参数 (如神经网络层数决定后才有每层节点数), 计算复杂度 $O(n)$, 适合高维和条件空间。

E.8.10 (Ch.22+Ch.23+Ch.24, Wasserstein 距离 + 最优传输 + 生成模型)

题目: K-R 对偶定理; 一维 $W_1 = \text{CDF}$ 的 L^1 距离; WGAN-GP; Schrödinger 桥与扩散模型。

解:

(a) Kantorovich-Rubinstein 对偶 (W_1)

$$W_1(\mu, \nu) = \inf_{\gamma \in \mathcal{P}(\mu, \nu)} \int \|\mathbf{x} - \mathbf{y}\| d\gamma(\mathbf{x}, \mathbf{y})$$

对偶形式 (Kantorovich-Rubinstein 定理):

$$W_1(\mu, \nu) = \sup_{\|f\|_L \leq 1} \left[\int f d\mu - \int f d\nu \right]$$

其中 $\|f\|_L = \sup_{x \neq y} |f(x) - f(y)| / \|x - y\| \leq 1$ 为 Lipschitz 常数约束。

证明思路 (强对偶): 原始问题 (线性规划在测度空间上) 满足 Slater 条件, 强对偶成立。对偶变量恰好是满足 1-Lipschitz 约束的函数 (由约束 $f(x) - f(y) \leq \|x - y\|$ 导出)。

(b) 一维 $W_1 = \text{CDF}$ 的 L^1 距离

一维情形, 最优传输的解析解为分位数匹配 ($\gamma^*(x, y) = (F_\mu^{-1}(u), F_\nu^{-1}(u))$, $u \sim U(0, 1)$):

$$W_1(\mu, \nu) = \int_0^1 |F_\mu^{-1}(u) - F_\nu^{-1}(u)| du = \int_{-\infty}^{\infty} |F_\mu(t) - F_\nu(t)| dt$$

(最后等式: 变量替换, 利用 $\int_0^1 |F^{-1}(u) - G^{-1}(u)| du = \int |F(t) - G(t)| dt$ 。)

计算 $N(0, 1)$ 与 $N(\delta, 1)$:

$$F_\mu(t) = \Phi(t), \quad F_\nu(t) = \Phi(t - \delta),$$

$$W_1 = \int_{-\infty}^{\infty} |\Phi(t) - \Phi(t - \delta)| dt$$

由平移不变性, 当 $\delta > 0$ 时 $\Phi(t - \delta) < \Phi(t)$ (均值较大的分布 CDF 在右), 积分:

$$W_1 = \int_{-\infty}^{\infty} [\Phi(t) - \Phi(t - \delta)] dt = \delta$$

(平移正态的 $W_1 =$ 均值之差。)

答案: $\boxed{W_1(N(0, 1), N(\delta, 1)) = |\delta|}$

(c) WGAN 与梯度惩罚

WGAN (Arjovsky 等, 2017): 用神经网络判别器 D_w (Critic) 近似 K-R 对偶中的 1-Lipschitz 函数:

$$W_1(p_r, p_g) \approx \max_{\|D_w\|_L \leq 1} [E_{x \sim p_r}[D_w(x)] - E_{\tilde{x} \sim p_g}[D_w(\tilde{x})]]$$

Lipschitz 约束实现:

- 原始 WGAN 用权重裁剪 ($w \in [-c, c]$), 但会导致梯度爆炸/消失。
- **WGAN-GP** (Gulrajani 等, 2017): 梯度惩罚项强制 $\|\nabla D\|_2 = 1$ (1-Lipschitz 的必要条件):

$$\mathcal{L} = \underbrace{E_{\tilde{x}}[D(\tilde{x})] - E_x[D(x)]}_{\text{Wasserstein 距离近似}} + \lambda \underbrace{E_{\hat{x}}[(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2]}_{\text{梯度惩罚}}$$

其中 $\hat{x} = \epsilon x + (1 - \epsilon)\tilde{x}$, $\epsilon \sim U(0, 1)$ (真实与生成样本之间的插值), 在插值点强制梯度范数为 1。

□ Lipschitz 约束 $\Rightarrow \|\nabla D\|_2 \leq 1$ 处处成立, 但梯度惩罚只对插值点强制, 是软约束。

(d) Schrödinger 桥与扩散模型

Schrödinger 桥 (SB): 给定端点边际 $X_0 \sim \mu$, $X_1 \sim \nu$, 在所有过程 $\mathbb{P}$ 中找最接近参考测度 $\mathbb{Q}$ (布朗运动) 的过程:

$$\min_{\mathbb{P}: X_0 \sim \mu, X_1 \sim \nu} D_{\text{KL}}(\mathbb{P} \parallel \mathbb{Q})$$

IPFP (迭代比例拟合法): 交替投影到满足 $X_0 \sim \mu$ 和 $X_1 \sim \nu$ 的测度集 (Sinkhorn 算法的连续版本):

$$\mathbb{P}^{2k+1} = \text{proj}_{\mathcal{P}(\cdot, \nu)} \mathbb{P}^{2k}, \quad \mathbb{P}^{2k+2} = \text{proj}_{\mathcal{P}(\mu, \cdot)} \mathbb{P}^{2k+1}$$

每次投影等价于学习前向或后向的”半桥”(条件扩散过程)。

与扩散模型的关系:

DDPM	Schrödinger 桥 (SB)
前向过程: 数据 $\rightarrow$ 噪声 (固定 q)	前向过程: $\mu \rightarrow \nu$ (优化)
反向过程: 噪声 $\rightarrow$ 数据 (学习 p_θ)	反向过程: $\nu \rightarrow \mu$ (学习后向 SDE)
参考测度: OU 过程 (不精确端点)	参考测度: 布朗运动 (精确端点约束)
目标: $\nu = \mathcal{N}(0, \mathbf{I})$	目标: 任意 ν (可为图像域)

I2SB (Image-to-Image Schrödinger Bridge, Liu 等 2023): 用 SB 实现两个图像域间的转换 (超分辨率、去雨、修复), 无需先退化到高斯噪声, 直接在图像对之间插值, 训练效率更高。

Score Matching 联系: DDPM 的去噪 score $s_\theta(x_t, t) \approx \nabla_{x_t} \log q(x_t)$ 对应 SB 的后向 SDE 漂移项 (Nelson 公式), 两者在 $\mu = p_{\text{data}}$, $\nu = \mathcal{N}(0, \mathbf{I})$ 时完全一致, SB 是 DDPM 的推广 (允许 ν 非高斯, 允许非对称端点)。

练习答案汇总

本文件提供各章练习题答案的快速索引。每章末尾均包含完整的练习题与详细答案 (以折叠块 <details> 形式呈现), 本文件主要作为导航入口, 方便读者快速定位目标章节。

使用说明: 点击下方各章链接跳转至对应章节文件, 在文件末尾的”练习答案”部分可展开查看逐题解析。



Part 1：概率基础（第 1-3 章）

章节	文件	练习题数
第 1 章随机事件与概率	part1-probability-basics/01-random-events.md	1 题
第 2 章条件概率与独立性	part1-probability-basics/02-conditional-probability.md	2 题
第 3 章组合数学基础	part1-probability-basics/03-combinatorics.md	3 题

详细答案请在各章文件末尾的 练习答案部分查看。

Part 2：随机变量（第 4-6 章）

章节	文件	练习题数
第 4 章离散随机变量	part2-random-variables/04-discrete-random-variables.md	4 题
第 5 章连续随机变量	part2-random-variables/05-continuous-random-variables.md	5 题
第 6 章多维随机变量	part2-random-variables/06-multivariate-random-variables.md	6 题

详细答案请在各章文件末尾的 练习答案部分查看。

Part 3：常见分布（第 7-9 章）

章节	文件	练习题数
第 7 章离散分布族	part3-distributions/07-discrete-distributions.md	7 题
第 8 章连续分布族	part3-distributions/08-continuous-distributions.md	8 题
第 9 章多维分布	part3-distributions/09-multivariate-distributions.md	9 题

详细答案请在各章文件末尾的 练习答案部分查看。

Part 4：极限定理（第 10-12 章）

章节	文件	练习题数
第 10 章大数定律	part4-limit-theorems/10-law-of-large-numbers.md	10 题
第 11 章中心极限定理	part4-limit-theorems/11-central-limit-theorem.md	11 题

章节	文件	练习题数
第 12 章收敛性理论	part4-limit-theorems/12-convergence-theory.md	5 题

详细答案请在各章文件末尾的 练习答案部分查看。

Part 5: 统计基础 (第 13-15 章)

章节	文件	练习题数
第 13 章统计量与抽样分布	part5-statistics-basics/13-sampling-distributions.md	5 题
第 14 章数据描述与可视化	part5-statistics-basics/14-descriptive-statistics.md	5 题
第 15 章充分统计量	part5-statistics-basics/15-efficient-statistics.md	5 题

详细答案请在各章文件末尾的 练习答案部分查看。

Part 6: 参数估计 (第 16-18 章)

章节	文件	练习题数
第 16 章点估计	part6-estimation/16-point-estimation.md	5 题
第 17 章区间估计	part6-estimation/17-interval-estimation.md	5 题
第 18 章贝叶斯估计	part6-estimation/18-bayesian-estimation.md	5 题

详细答案请在各章文件末尾的 练习答案部分查看。

Part 7: 假设检验 (第 19-21 章)

章节	文件	练习题数
第 19 章假设检验基础	part7-hypothesis-testing/19-hypothesis-testing-basics.md	19 题
第 20 章参数检验	part7-hypothesis-testing/20-parametric-tests.md	20 题
第 21 章非参数检验	part7-hypothesis-testing/21-nonparametric-tests.md	21 题

详细答案请在各章文件末尾的 练习答案部分查看。

Part 8: 高级主题 (第 22-24 章)

章节	文件	练习题数
第 22 章信息论基础	part8-advanced-topics/22-information-theory.md	5 题
第 23 章蒙特卡洛方法	part8-advanced-topics/23-monte-carlo-methods.md	5 题
第 24 章概率图模型	part8-advanced-topics/24-probabilistic-graphical-models.md	5 题

详细答案请在各章文件末尾的 练习答案部分查看。

统计汇总

部分	章节数	练习题总数
Part 1: 概率基础	3 章	15 题
Part 2: 随机变量	3 章	15 题
Part 3: 常见分布	3 章	15 题
Part 4: 极限定理	3 章	15 题
Part 5: 统计基础	3 章	15 题
Part 6: 参数估计	3 章	15 题
Part 7: 假设检验	3 章	15 题
Part 8: 高级主题	3 章	15 题
合计	24 章	120 题

公式速查表

本文件汇总了概率论与数理统计中的常用公式，方便读者随时查阅。

一、概率基础公式

1.1 概率的基本性质

公式	说明
$0 \leq P(A) \leq 1$	概率的范围
$P(\Omega) = 1$	必然事件的概率
$P(\emptyset) = 0$	不可能事件的概率

公式	说明
$P(A^c) = 1 - P(A)$	补事件概率
$P(A \cup B) = P(A) + P(B) - P(A \cap B)$	加法公式
$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(B \cap C) - P(A \cap C) + P(A \cap B \cap C)$	容斥原理

1.2 条件概率与独立性

公式	说明
$P(A B) = \frac{P(A \cap B)}{P(B)}$	条件概率定义
$P(A \cap B) = P(A B)P(B) = P(B A)P(A)$	乘法公式
$P(A) = \sum_{i=1}^n P(A B_i)P(B_i)$	全概率公式
$P(B_j A) = \frac{P(A B_j)P(B_j)}{\sum_{i=1}^n P(A B_i)P(B_i)}$	贝叶斯公式
$P(A \cap B) = P(A)P(B)$	独立事件

1.3 组合公式

公式	说明
$n! = n \times (n - 1) \times \cdots \times 1$	阶乘
$P_n^k = \frac{n!}{(n - k)!}$	排列数
$C_n^k = \binom{n}{k} = \frac{n!}{k!(n - k)!}$	组合数
$(a + b)^n = \sum_{k=0}^n \binom{n}{k} a^k b^{n-k}$	二项式定理
$\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$	帕斯卡恒等式

二、随机变量

2.1 离散随机变量

公式	说明
$P(X = x_i) = p_i$	概率质量函数
$\sum_i p_i = 1$	归一化条件
$E[X] = \sum_i x_i p_i$	期望

公式	说明
$E[g(X)] = \sum_i g(x_i)p_i$	函数的期望
$\text{Var}(X) = E[(X - \mu)^2] = E[X^2] - (E[X])^2$	方差

2.2 连续随机变量

公式	说明
$P(a \leq X \leq b) = \int_a^b f(x) dx$	区间概率
$\int_{-\infty}^{\infty} f(x) dx = 1$	归一化条件
$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$	累积分布函数
$f(x) = F'(x)$	PDF 与 CDF 关系
$E[X] = \int_{-\infty}^{\infty} x f(x) dx$	期望
$\text{Var}(X) = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx$	方差

2.3 期望与方差的性质

公式	说明
$E[aX + b] = aE[X] + b$	期望的线性性
$E[X + Y] = E[X] + E[Y]$	期望的可加性
$E[XY] = E[X]E[Y]$ (若独立)	独立变量乘积期望
$\text{Var}(aX + b) = a^2\text{Var}(X)$	方差的线性变换
$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$	方差的可加性
$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$ (若独立)	独立变量方差

2.4 协方差与相关系数

公式	说明
$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$	协方差定义
$\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$	协方差计算公式
$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$	相关系数
$-1 \leq \rho_{XY} \leq 1$	相关系数范围

三、常见分布

3.1 离散分布

分布	PMF	期望	方差
伯努利 Bernoulli(p)	$P(X = 1) = p, P(X = 0) = 1 - p$	p	$p(1 - p)$
二项 Binomial(n, p)	$\binom{n}{k} p^k (1 - p)^{n-k}$	np	$np(1 - p)$
泊松 Poisson(λ)	$\frac{\lambda^k e^{-\lambda}}{k!}$	λ	λ
几何 Geometric(p)	$(1 - p)^{k-1} p$	$\frac{1}{p}$	$\frac{1 - p}{p^2}$
负二项 NB(r, p)	$\binom{k-1}{r-1} p^r (1 - p)^{k-r}$	$\frac{r}{p}$	$\frac{r(1 - p)}{p^2}$

3.2 连续分布

分布	PDF	期望	方差
均匀 Uniform(a, b)	$\frac{1}{b - a}, x \in [a, b]$	$\frac{a + b}{2}$	$\frac{(b - a)^2}{12}$
指数 Exp(λ)	$\lambda e^{-\lambda x}, x \geq 0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
正态 $\mathcal{N}(\mu, \sigma^2)$	$\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	μ	σ^2
Gamma Gamma(α, β)	$\frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$	$\frac{\alpha}{\beta}$	$\frac{\alpha}{\beta^2}$
Beta Beta(α, β)	$\frac{x^{\alpha-1} (1 - x)^{\beta-1}}{B(\alpha, \beta)}$	$\frac{\alpha}{\alpha + \beta}$	$\frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$

3.3 多维分布

分布	公式
多项分布	$P(X_1 = k_1, \dots, X_m = k_m) = \frac{n!}{k_1! \dots k_m!} p_1^{k_1} \dots p_m^{k_m}$
多元正态	$f(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} \Sigma ^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu)\right)$
Dirichlet	$f(\mathbf{x}) = \frac{\Gamma(\sum_i \alpha_i)}{\prod_i \Gamma(\alpha_i)} \prod_{i=1}^K x_i^{\alpha_i-1}$

3.4 矩母函数 (MGF)

分布	$M_X(t) = E[e^{tX}]$	存在条件
Bernoulli(p)	$(1 - p) + pe^t$	所有 t
Binomial(n, p)	$[(1 - p) + pe^t]^n$	所有 t
Poisson(λ)	$e^{\lambda(e^t - 1)}$	所有 t
Geometric(p)	$\frac{pe^t}{1 - (1 - p)e^t}$	$t < -\ln(1 - p)$
Uniform(a, b)	$\frac{e^{tb} - e^{ta}}{t(b - a)}$	所有 t
Exp(λ)	$\frac{\lambda}{\lambda - t}$	$t < \lambda$
$\mathcal{N}(\mu, \sigma^2)$	$\exp(\mu t + \sigma^2 t^2 / 2)$	所有 t
Gamma(α, β)	$\left(\frac{\beta}{\beta - t}\right)^\alpha$	$t < \beta$
$\chi^2(n)$	$(1 - 2t)^{-n/2}$	$t < 1/2$

核心性质: $M_X^{(n)}(0) = E[X^n]$; 独立变量之和 $M_{X+Y}(t) = M_X(t)M_Y(t)$

3.5 常见共轭先验对

似然（数据模型）	先验分布	后验分布	后验参数更新
Bernoulli / Binomial	Beta(α, β)	Beta($\alpha + k, \beta + n - k$)	k : 成功次数
Poisson(λ)	Gamma(α, β)	Gamma($\alpha + \sum x_i, \beta + n$)	
Normal (均值, σ^2 已知)	Normal(μ_0, τ^2)	Normal($\tilde{\mu}, \tilde{\tau}^2$)	精度加权平均
Normal (方差, μ 已知)	Inv-Gamma(α, β)	Inv-Gamma($\alpha + n/2, \beta + \frac{1}{2} \sum (x_i - \mu)^2$)	
Multinomial	Dirichlet(α)	Dirichlet($\alpha + \mathbf{x}$)	
Exponential(λ)	Gamma(α, β)	Gamma($\alpha + n, \beta + \sum x_i$)	

四、极限定理

4.1 不等式

公式	说明
$P(X \geq a) \leq \frac{E[X]}{a}$	马尔可夫不等式

公式	说明
$P(X - \mu \geq k\sigma) \leq \frac{1}{k^2}$	切比雪夫不等式
$P(X - \mu \geq t) \leq 2 \exp\left(-\frac{2t^2}{(b-a)^2}\right)$	Hoeffding 不等式 (有界)

4.2 大数定律

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu \quad (\text{弱大数定律})$$

$$\bar{X}_n \xrightarrow{a.s.} \mu \quad (\text{强大数定律})$$

4.3 中心极限定理

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1)$$

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$$

五、抽样分布

5.1 三大抽样分布

分布	定义	期望	方差
卡方分布 $\chi^2(n)$	$\sum_{i=1}^n Z_i^2, Z_i \sim \mathcal{N}(0, 1)$	n	$2n$
t 分布 $t(n)$	$\frac{\bar{Z}}{\sqrt{V/n}}, Z \sim \mathcal{N}(0, 1),$ $V \sim \chi^2(n)$	$0 \text{ (} n>1 \text{)}$	$\frac{n}{n-2} \text{ (} n>2 \text{)}$
F 分布 $F(m, n)$	$\frac{V_1/m}{V_2/n}, V_1 \sim \chi^2(m),$ $V_2 \sim \chi^2(n)$	$\frac{n}{n-2} \text{ (} n>2 \text{)}$	复杂

5.2 样本统计量分布

设 $X_1, \dots, X_n \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$:

统计量	分布
$\bar{X} = \frac{1}{n} \sum X_i$	$\mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$
$\frac{(n-1)S^2}{\sigma^2}$	$\chi^2(n-1)$
$\frac{\bar{X} - \mu}{S/\sqrt{n}}$	$t(n-1)$

六、参数估计

6.1 点估计

方法	公式
矩估计	令样本矩等于总体矩: $\bar{X} = E[X], \overline{X^2} = E[X^2], \dots$
最大似然估计	$\hat{\theta}_{MLE} = \arg \max_{\theta} \prod_{i=1}^n f(x_i; \theta)$
对数似然	$\hat{\theta}_{MLE} = \arg \max_{\theta} \sum_{i=1}^n \log f(x_i; \theta)$

6.2 估计量的评价

性质	定义
无偏性	$E[\hat{\theta}] = \theta$
有效性	$\text{Var}(\hat{\theta}_1) \leq \text{Var}(\hat{\theta}_2)$
一致性	$\hat{\theta}_n \xrightarrow{P} \theta$
MSE	$\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + \text{Bias}^2(\hat{\theta})$

6.3 置信区间

参数	条件	置信区间
μ (σ^2 已知)	正态总体	$\bar{X} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$
μ (σ^2 未知)	正态总体	$\bar{X} \pm t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}}$

参数	条件	置信区间
σ^2	正态总体	$\left[\frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)}, \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)} \right]$

6.4 贝叶斯估计

$$p(\theta \mid \mathbf{x}) = \frac{p(\mathbf{x} \mid \theta)p(\theta)}{p(\mathbf{x})} \propto p(\mathbf{x} \mid \theta)p(\theta)$$

估计	公式
MAP	$\hat{\theta}_{MAP} = \arg \max_{\theta} p(\theta \mid \mathbf{x})$
后验均值	$\hat{\theta}_{Bayes} = E[\theta \mid \mathbf{x}]$

七、假设检验

7.1 检验统计量

检验	条件	统计量
z 检验	σ^2 已知	$z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$
t 检验	σ^2 未知	$t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$
χ^2 检验	方差检验	$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$
F 检验	两总体方差比	$F = \frac{S_1^2}{S_2^2}$

7.2 两类错误

错误类型	定义	概率
第一类错误	拒绝真 H_0	α (显著性水平)
第二类错误	接受假 H_0	β
检验功效	拒绝假 H_0	$1 - \beta$

八、信息论

公式	说明
$H(X) = -\sum_x p(x) \log p(x)$	离散熵
$H(X) = -\int f(x) \log f(x) dx$	微分熵
$H(X, Y) = H(X) + H(Y X)$	链式法则
$I(X; Y) = H(X) - H(X Y) = H(Y) - H(Y X)$	互信息
$D_{KL}(p \ q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$	KL 散度
$H(p, q) = -\sum_x p(x) \log q(x)$	交叉熵
$H(p, q) = H(p) + D_{KL}(p \ q)$	交叉熵分解

九、常用积分与特殊函数

公式	说明
$\Gamma(n) = (n - 1)!$	Gamma 函数 (整数)
$\Gamma(\alpha) = \int_0^\infty x^{\alpha-1} e^{-x} dx$	Gamma 函数 (一般)
$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}$	Beta 函数
$\int_{-\infty}^\infty e^{-x^2} dx = \sqrt{\pi}$	高斯积分
$\int_{-\infty}^\infty e^{-\frac{x^2}{2}} dx = \sqrt{2\pi}$	标准正态积分

符号说明

本文件汇总了全书使用的数学符号及其含义，方便读者随时查阅。

集合与数系

符号	含义	示例
$\mathbb{N}$	自然数集	$\{0, 1, 2, 3, \dots\}$
$\mathbb{Z}$	整数集	$\{\dots, -2, -1, 0, 1, 2, \dots\}$
$\mathbb{Z}^+$	正整数集	$\{1, 2, 3, \dots\}$
$\mathbb{R}$	实数集	所有实数
$\mathbb{R}^+$	正实数集	$(0, +\infty)$

符号	含义	示例
$\mathbb{R}^n$	n 维实向量空间	$\mathbb{R}^3$ 是三维空间
$[a, b]$	闭区间	$a \leq x \leq b$
(a, b)	开区间	$a < x < b$
$\in$	属于	$x \in \mathbb{R}$
$\subset$	真子集	$A \subset B$
$\subseteq$	子集	$A \subseteq B$
$\cup$	并集	$A \cup B$
$\cap$	交集	$A \cap B$
A^c 或 $\bar{A}$	补集	A 的补集
$\emptyset$	空集	无元素的集合

概率论基础

符号	含义	说明
Ω	样本空间	所有可能结果的集合
ω	样本点	样本空间中的元素
A, B, C	事件	样本空间的子集
$P(A)$	事件 A 的概率	$0 \leq P(A) \leq 1$
$P(A B)$	条件概率	在 B 发生条件下 A 的概率
$A \perp B$	独立	A 与 B 相互独立
$A \perp B C$	条件独立	给定 C 时 A 与 B 条件独立

随机变量

符号	含义	说明
X, Y, Z	随机变量	大写字母表示随机变量
x, y, z	随机变量的取值	小写字母表示具体取值
X	随机向量	粗体表示向量
$P(X = x)$	概率质量	离散随机变量取值 x 的概率
$p(x)$ 或 $p_X(x)$	概率质量函数 (PMF)	离散分布
$f(x)$ 或 $f_X(x)$	概率密度函数 (PDF)	连续分布
$F(x)$ 或 $F_X(x)$	累积分布函数 (CDF)	$F(x) = P(X \leq x)$
$X \sim D$	分布记号	X 服从分布 D

符号	含义	说明
$X \stackrel{d}{=} Y$	同分布	X 与 Y 有相同分布
$X_1, \dots, X_n \stackrel{iid}{\sim} D$	独立同分布	i.i.d. 样本

期望与方差

符号	含义	说明
$E[X]$ 或 $\mathbb{E}[X]$	期望	随机变量的均值
μ 或 μ_X	期望	$E[X]$ 的另一种记法
$\text{Var}(X)$	方差	$E[(X - \mu)^2]$
σ^2 或 σ_X^2	方差	$\text{Var}(X)$ 的另一种记法
σ 或 σ_X	标准差	$\sqrt{\text{Var}(X)}$
$\text{Cov}(X, Y)$	协方差	$E[(X - \mu_X)(Y - \mu_Y)]$
ρ_{XY} 或 $\text{Corr}(X, Y)$	相关系数	$\text{Cov}(X, Y)/(\sigma_X \sigma_Y)$
$E[X Y]$	条件期望	给定 Y 时 X 的期望
$\text{Var}(X Y)$	条件方差	给定 Y 时 X 的方差
$M_X(t)$	矩母函数 (MGF)	$E[e^{tX}]$, $M_X^{(n)}(0) = E[X^n]$
$\varphi_X(t)$	特征函数	$E[e^{itX}]$, 对任意分布都存在
$E[X^n]$	n 阶矩	n 阶原点矩
$E[(X - \mu)^n]$	n 阶中心矩	围绕均值的矩

常见分布

离散分布

符号	分布名称	参数
$\text{Bernoulli}(p)$	伯努利分布	成功概率 p
$\text{Binomial}(n, p)$ 或 $B(n, p)$	二项分布	试验次数 n , 成功概率 p
$\text{Poisson}(\lambda)$	泊松分布	速率参数 λ
$\text{Geometric}(p)$	几何分布	成功概率 p
$\text{NB}(r, p)$	负二项分布	成功次数 r , 成功概率 p
$\text{Multinomial}(n, \mathbf{p})$	多项分布	试验次数 n , 概率向量 $\mathbf{p}$

连续分布

符号	分布名称	参数
$\text{Uniform}(a, b)$ 或 $U(a, b)$	均匀分布	区间端点 a, b
$\text{Exp}(\lambda)$	指数分布	速率参数 λ
$\mathcal{N}(\mu, \sigma^2)$	正态分布	均值 μ , 方差 σ^2
$\text{Gamma}(\alpha, \beta)$	Gamma 分布	形状 α , 速率 β
$\text{Beta}(\alpha, \beta)$	Beta 分布	参数 α, β
$\chi^2(n)$	卡方分布	自由度 n
$t(n)$	t 分布	自由度 n
$F(m, n)$	F 分布	自由度 m, n
$\mathcal{N}(\mu, \Sigma)$	多元正态分布	均值向量, 协方差矩阵
$\text{Dirichlet}(\alpha)$	Dirichlet 分布	浓度参数向量 α

收敛性

符号	含义	说明
$X_n \xrightarrow{P} X$	依概率收敛	Convergence in probability
$X_n \xrightarrow{d} X$	依分布收敛	Convergence in distribution
$X_n \xrightarrow{a.s.} X$	几乎必然收敛	Almost sure convergence
$X_n \xrightarrow{L^p} X$	L^p 收敛	Mean convergence
$X_n \xrightarrow{m.s.} X$	均方收敛	Mean square convergence

统计学

符号	含义	说明
θ	参数	待估计的未知量
$\hat{\theta}$	估计量	θ 的估计
$\hat{\theta}_{MLE}$	最大似然估计	Maximum Likelihood Estimator
$\hat{\theta}_{MAP}$	最大后验估计	Maximum A Posteriori
$L(\theta)$ 或 $\mathcal{L}(\theta)$	似然函数	$\prod_i f(x_i; \theta)$
$\ell(\theta)$	对数似然	$\sum_i \log f(x_i; \theta)$
$\bar{X}$	样本均值	$\frac{1}{n} \sum_{i=1}^n X_i$

符号	含义	说明
S^2	样本方差	$\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$
S	样本标准差	$\sqrt{S^2}$
T	检验统计量	Test statistic
H_0	原假设	Null hypothesis
H_1 或 H_a	备择假设	Alternative hypothesis
α	显著性水平	Significance level
p -value	p 值	在 H_0 下观测到更极端值的概率

信息论

符号	含义	说明
$H(X)$	熵	$-\sum_x p(x) \log p(x)$
$H(X, Y)$	联合熵	Joint entropy
$H(X Y)$	条件熵	Conditional entropy
$I(X; Y)$	互信息	Mutual information
$D_{KL}(p \ q)$	KL 散度	Kullback-Leibler divergence
$H(p, q)$	交叉熵	Cross entropy

其他常用符号

符号	含义
$:=$ 或 $\triangleq$	定义为
$\forall$	对于所有
$\exists$	存在
$\Rightarrow$	蕴含
$\Leftrightarrow$	当且仅当
$\approx$	约等于
$\propto$	正比于
$\sum$	求和
$\prod$	求积
$\int$	积分
$\arg \max$	使目标函数最大的参数
$\arg \min$	使目标函数最小的参数

符号	含义
$\log$	自然对数（默认以 e 为底）
$\log_2$	以 2 为底的对数
$\exp(x)$ 或 e^x	指数函数
$\mathbf{1}_A$ 或 I_A	指示函数
$\lfloor x \rfloor$	下取整
$\lceil x \rceil$	上取整

深度学习相关符号

符号	含义	说明
$\mathbf{x}$	输入向量	网络的输入
y	标签/输出向量	真实标签或网络输出
$\hat{y}$	预测值	网络的预测输出
$\mathbf{W}$	权重矩阵	神经网络层的参数
$\mathbf{b}$	偏置向量	神经网络层的参数
θ	模型参数	所有可学习参数的集合
$\mathcal{L}$	损失函数	Loss function
$\nabla_{\theta} \mathcal{L}$	梯度	损失对参数的导数
$p(y \mid \mathbf{x}; \theta)$	条件概率模型	给定输入和参数的输出分布
$q(\mathbf{z} \mid \mathbf{x})$	变分后验	Variational posterior
$p(\mathbf{z})$	先验分布	Prior distribution
ELBO	证据下界	Evidence Lower Bound
$\text{KL}[q\ p]$	KL 散度	变分推断中的正则项